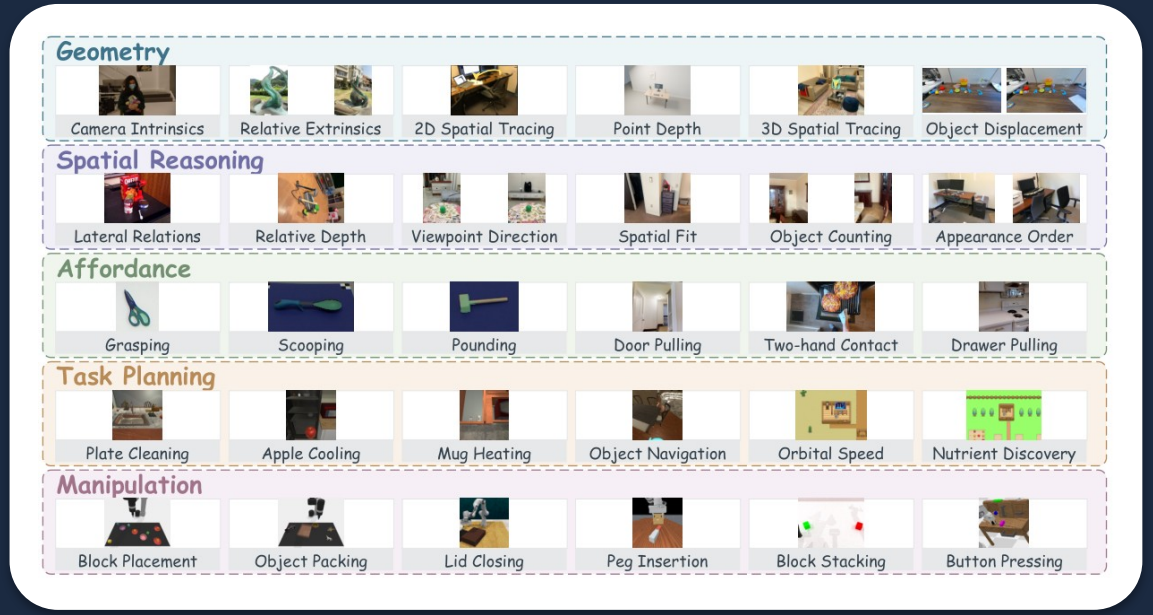
论文解读 | 具身智能评测

前沿 VLM 智能体
准备好当机器人通才了吗?

Are Frontier VLM Agents Ready to Be Robot Generalists? An Empirical Study with the Embodied Agent Arena

Haojian Huang, Pukun Zhao, Zexi Li, … , Ying-Cong Chen, Yinchuan Li
HKUST (GZ) · 香港中文大学 · Knowin AI

arXiv 2610.00854 · 2026-10-23



图源： Fig.1 五个能力域 × 六类任务

一句话总结

答案：还没有——失败常发生在“中间步骤已经做对”之后

1,000

案例｜32 个已有基准 + 自建 GeoProbe （168 例），五个能力域

10

个前沿 VLM 智能体｜7 个闭源服务 +3 个开源权重 VLM

47.8%

最高操作成功率（Opus 5.5， 182 个任务）；规划最高 80.3% （Astra）

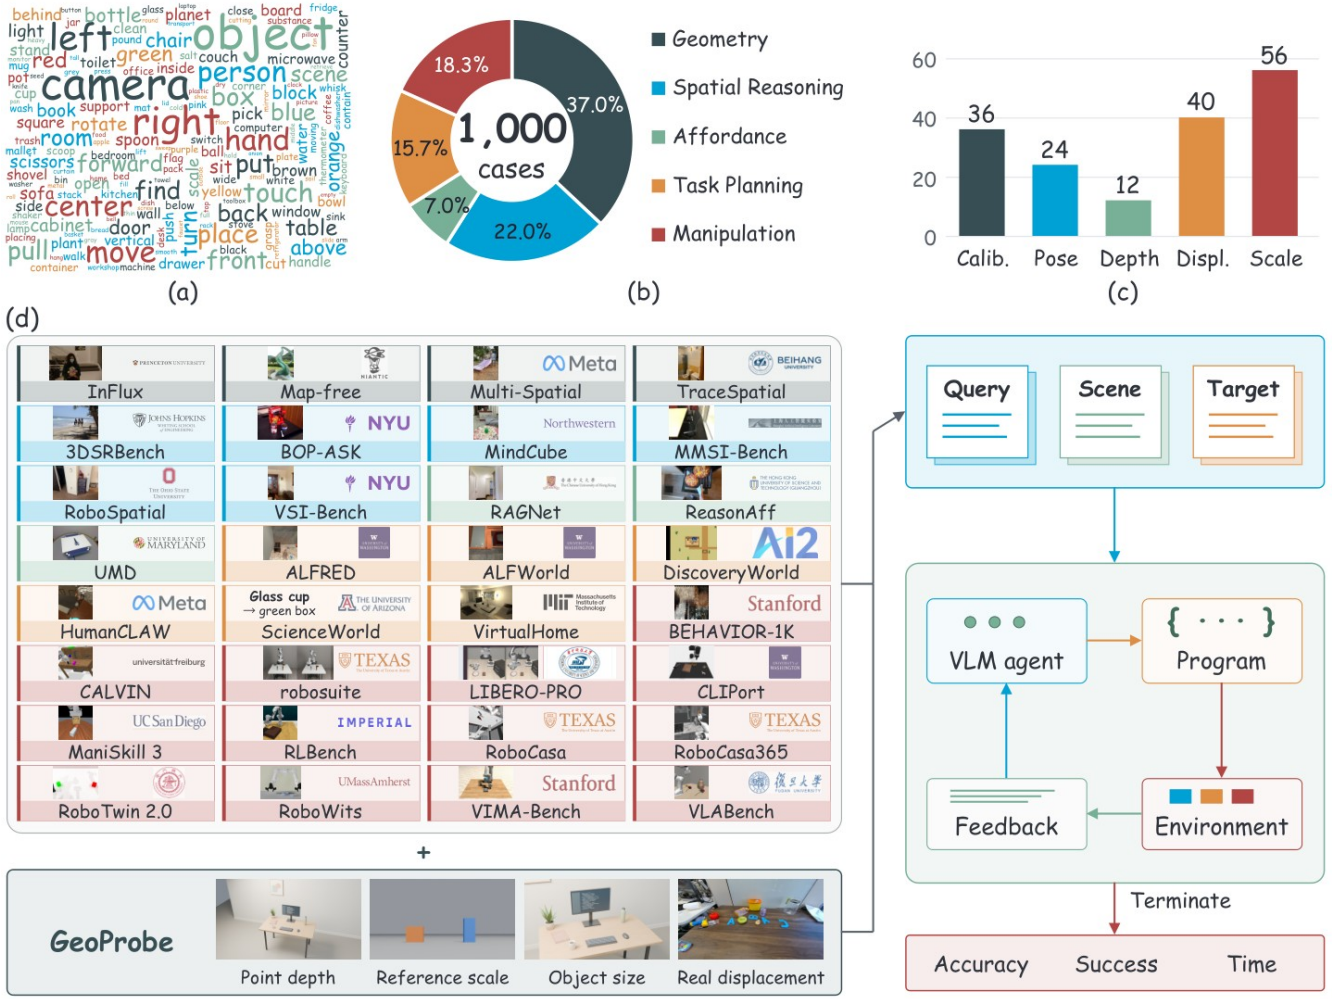
3 / 65

CALVIN 出错 episode 中，62 个代码恢复运行，只有 3 个最终完成

论文的核心发现

- **闭源全面领先，开源执行差距大：**开源 VLM 空间推理 48–52%，规划只有 19–31%，操作只有 10–21%。
- **平均分掩盖了不同的错误：**尺度偏差 vs 形状失真；区域框对了 vs 动作点选对了；代码能跑 vs 物体状态达成。
- **额外计算并不稳定有效：**修代码能恢复执行但不保证完成；自我复查会把正确答案改错；失败 token 集中在长程身体控制任务。

Arena： 1,000 例 × 五个能力域，原生接口 + 统一执行回路



组成

- Geometry 370 · Spatial 220 · Affordance 70
- Planning 157 · Manipulation 183
- 660 道固定输入题 + 340 个交互 episode
- GeoProbe： Blender 受控变量，分离相机运动、物体运动和尺度参照

Harness 原则

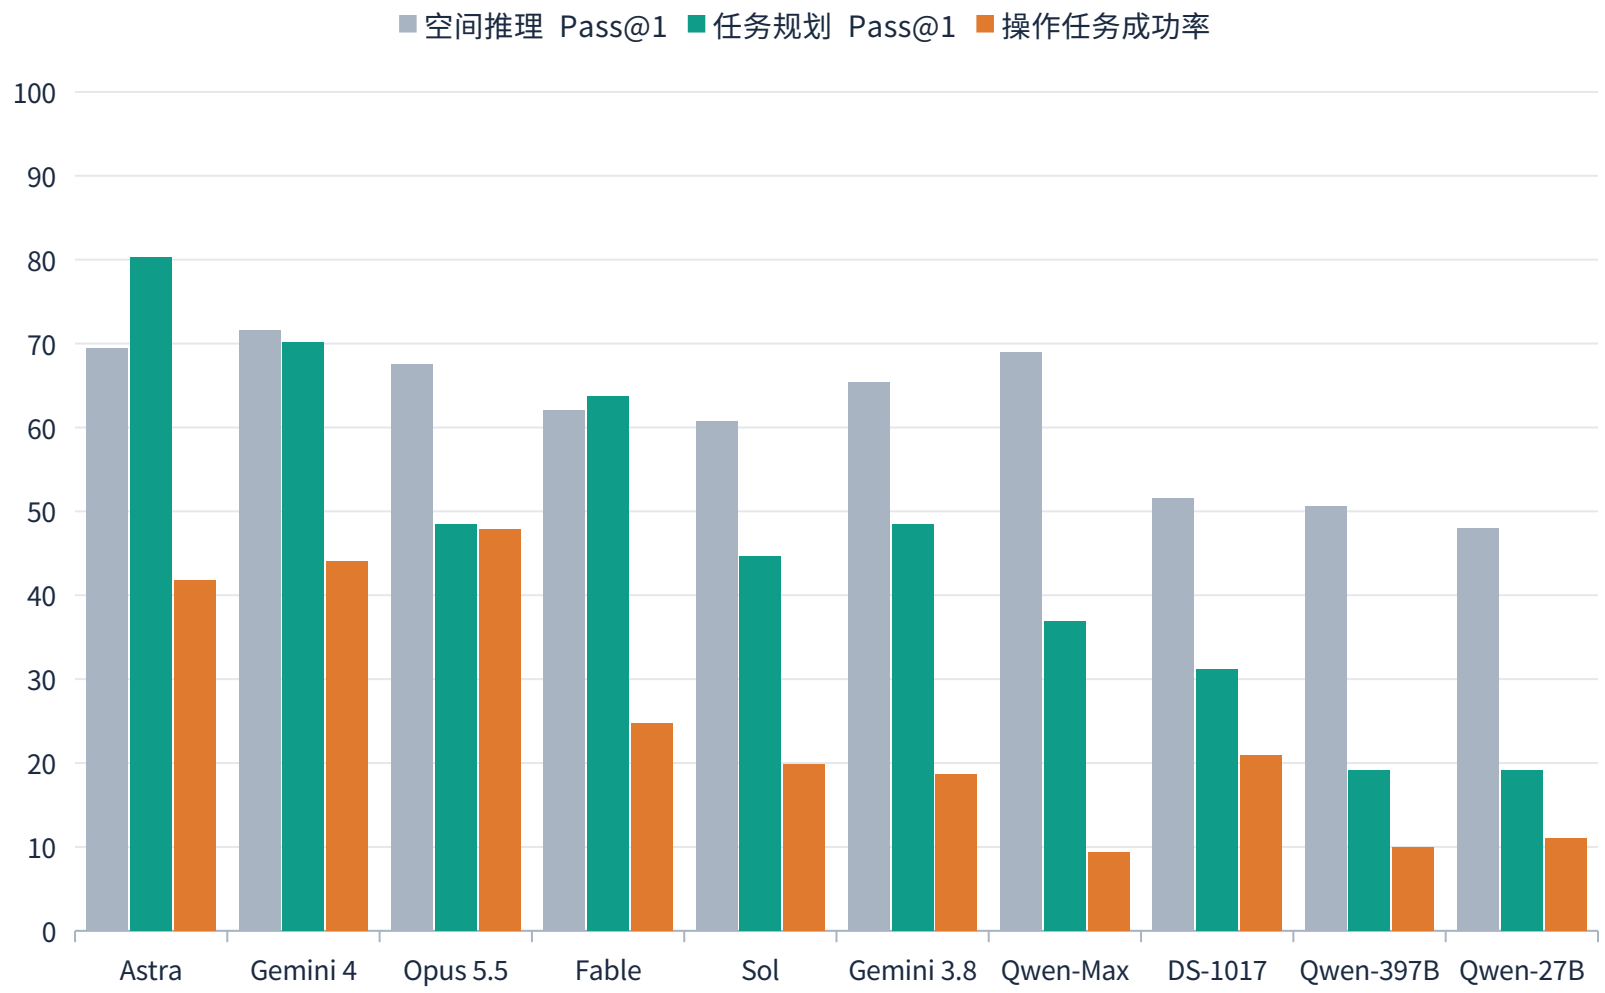
保留原生接口：沿用各来源的观测、操作和成功判据，不加感知或控制模块

决策交给模型：持久化 Python runtime ，图像和变量跨轮保留

终止 ≠ 成功：由独立评估器检查终态，复合目标的所有谓词都要成立

主结果

感知强 ≠ 会执行：空间推理接近的模型，规划与操作差距巨大



36.9 vs 80.3

Qwen-Max 与 Astra 的规划成功率；两者空间推理几乎持平（68.9 vs 69.4）

47.8%

Opus 5.5 操作第一，规划（48.4%）却落后 Astra 与 Fable

10–21%

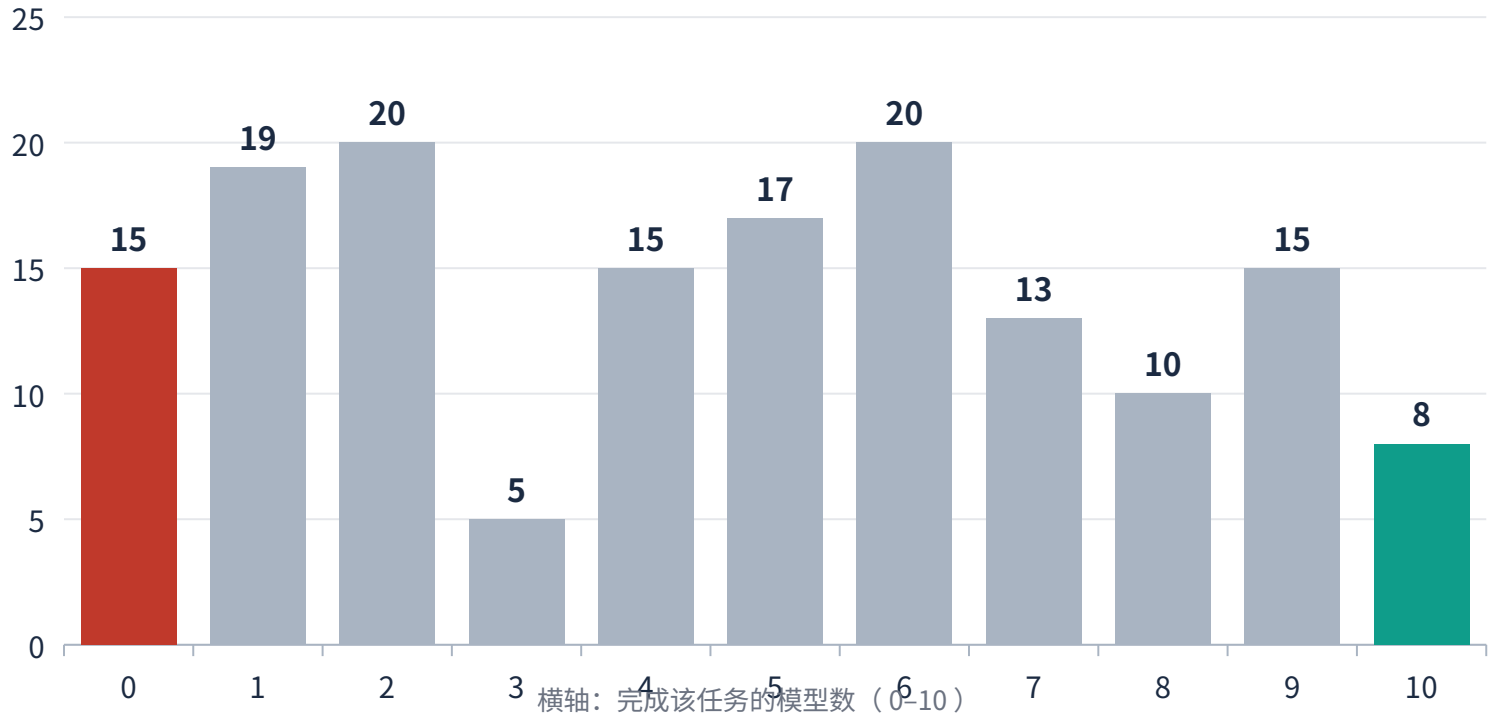
三个开源 VLM 的操作成功率；空间推理有 48–52%

arXiv 2610.00854 | 数据来源： Table 2 （左 7 个为闭源，右 3 个为开源权重；规划 157 例、操作 182 例为单次运行；空间推理为 5 次均值）

任务规划重叠分析

模型互补收益有限：十个模型合计只多解 16 题，15 题无人能解

157 个规划任务：按“能解出该任务的模型数”统计的任务数



- 只有 8 个任务被全部 10 个模型解出，其中 7 个是符号化的 VirtualHome
- 39 个任务只有 1–2 个模型能解，其中 20 个来自 ALFRED/ALFWorld 视觉家务任务

覆盖率的边际递减

126 Astra 单独

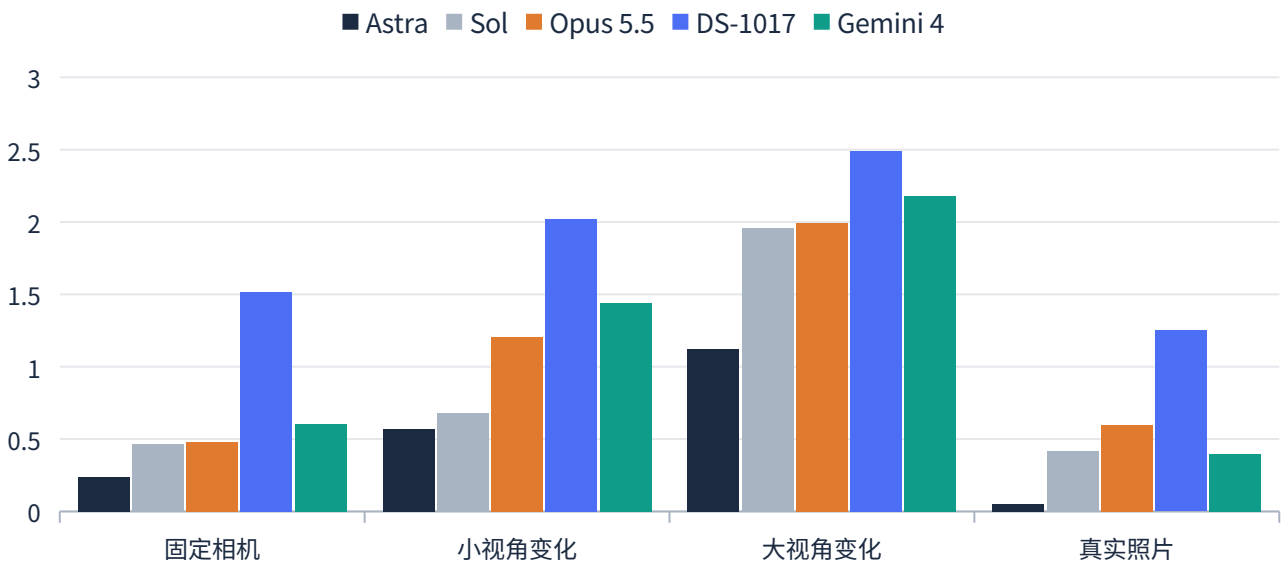
137 + Gemini 4 （新增 11 题）

142 全部 10 个模型（其余 8 个只再加 5 题）

15 个共同失败并不同质：8 个“坐下”任务、4 个 ALFRED/ALFWorld 、 2 个 ScienceWorld 、 1 个电视任务，需要不同的修正方式。

几何：相近的误差背后，可能是尺度偏差，也可能是形状失真

GeoProbe 位移 MAE （cm，越低越好）：相机变化越大误差越高



TraceSpatial 3D 轨迹联合约束成功率（%）



0.299→0.065

Gemini 4 深度 AbsRel 经 oracle 尺度对齐后大降； Qwen-397B 0.312→0.203 ，残差主要是形状误差

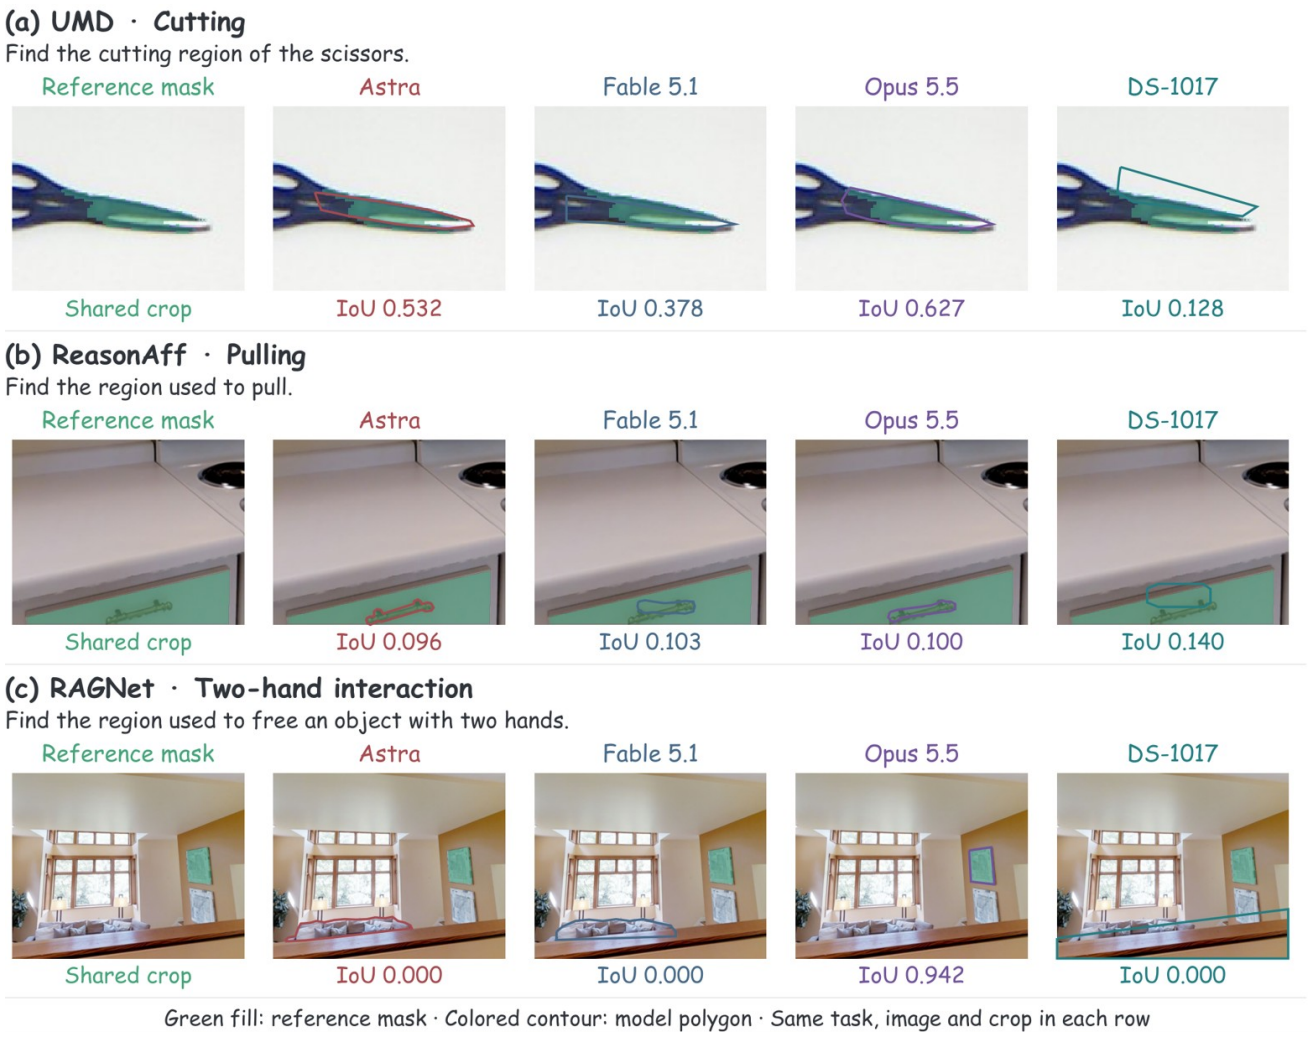
0 → 26 / 37

Astra / Gemini 4 固定相机下 50 个运动样本零漏检，大视角变化下漏掉 26 / 37 个；Qwen-27B 每种条件都全漏

21 / 35

Astra 两端点都在图像中命中的 35 条轨迹里，21 条仍违反 3D 起止约束； Gemini 4 另有 10 条只因碰撞失败

可供性：选对物体、覆盖区域、选准动作点是三件不同的事



96 vs 18

Qwen-397B 350 次预测中只过点判据 96 次，点和框都过只有 18 次

IoU 0.784 但点在区外

Gemini 4 有 16 次框通过、点落在功能区外（剪刀抓取，5 次运行中 4 次）

0.942 vs 0

RAGNet 双手任务： Opus 选对目标， Astra/Fable/DeepSeek 框了别的物体

9 / 10

个模型用直接多边形比用矩形框的 IoU 更高；交互场景仍远难于工具

arXiv 2610.00854 | 图源： Fig.A7 （多边形输出，绿色为参考 mask ）；数据： Table A46 、 Fig.6 、 Section 4.3

诊断 ③ Task Planning

规划：执行了动作，不等于达到了要求的状态

案例 A | ALFRED：洗肥皂后放进浴缸

接收区域绑定错误

DeepSeek	洗净肥皂 → 放进 Bathtub （外层器具）	1/3
Gemini 3.8	检查父容器 → 重新拿起 → 改放 BathtubBasin	3/3
Qwen-Max	检查父容器 → 重洗 → 改接收区域为 Basin	3/3

反馈有效的前提是改变了目标绑定，而不是重复原来的操作。

案例 B | HumanCLAW：找到沙发并坐下

把“尝试过交互”误当成终态

7 / 8

Gemini 4 已进入 20 cm 内并发出 sit 指令

0 / 8

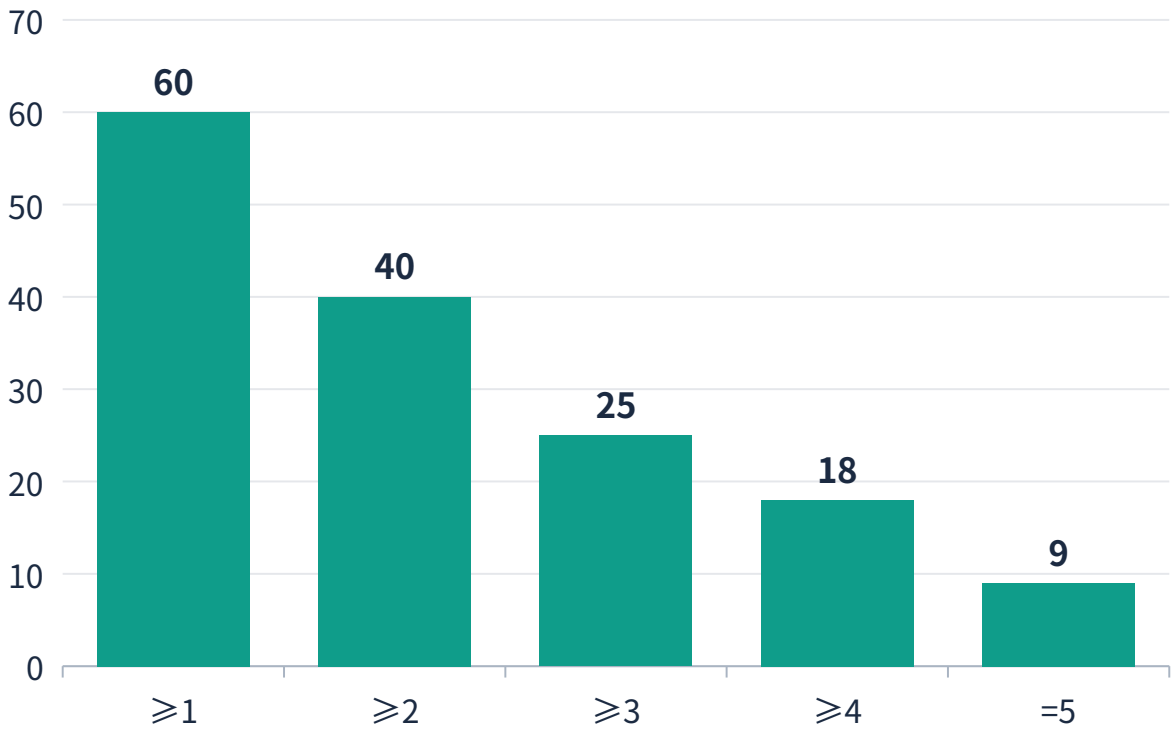
全部 10 个模型的坐下任务成功数

- 同一沙发案例：Gemini 4 和 DeepSeek 发出 sit 后自称“已坐下”，分别在第 44 、 70 轮停止，都没通过私有验证器
- 靠近目标 + 发出指令 ≠ 建立了身体与物体的关系；这类失败属于停止判断失误

诊断 ④ Manipulation

操作：开始一个序列容易，完成它很难；坐标收敛不等于抓住物体

CALVIN：达到 ⩾ k 个连续目标的 episode 数（共 100 个）



60 个完成首个目标的 episode 中只有 9 个走完全程；Gemini 4 为 10→4，Astra 为 8→3。

配对轨迹揭示的状态问题

PlaceSphere

DeepSeek 夹爪距悬停目标仅 2.8 mm，之后 4 次检查 is_grasped 仍为 false，球被推离原位；Opus 确认抓取 → 释放 → 在箱上且静止，成功。

CALVIN 0526

Opus 第 11 轮抓取、第 13 轮叠放，共 18 轮；DeepSeek 在第 17–27 轮反复重新抓取（方块高度回落到约 2 cm），共 37 轮。

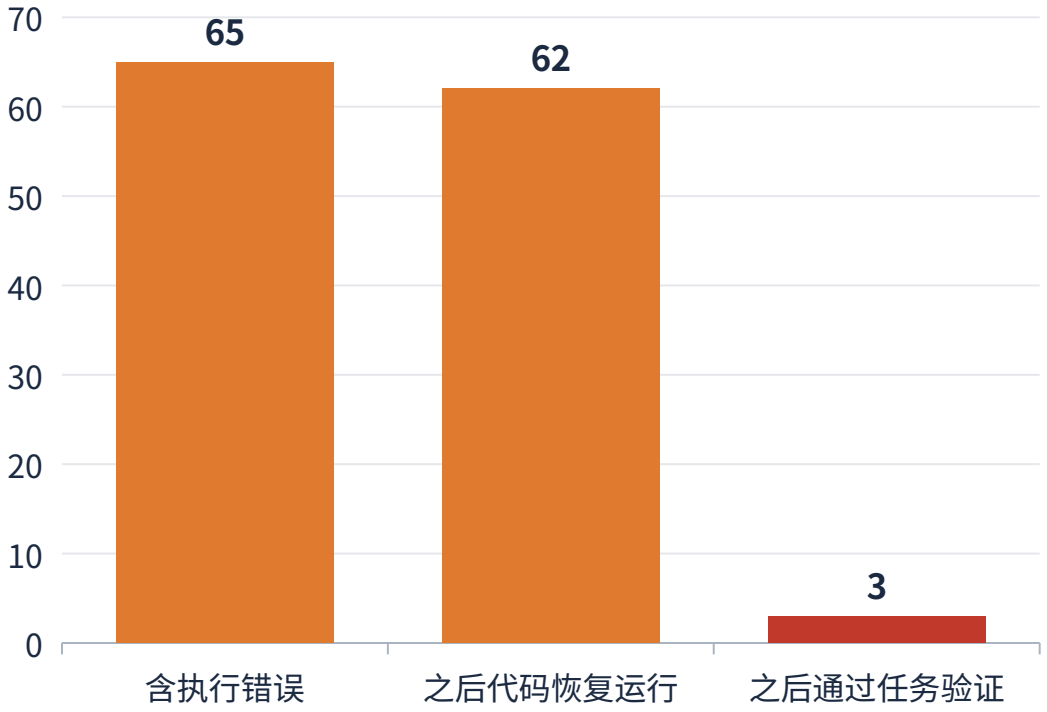
精密插入

Opus 完成 PickCube / PlaceSphere / StackCube，但 PegInsertionSide 和 PlugCharger（要求 5 mm、0.2 rad）失败。

反馈的作用

额外计算不保证进步：修好代码 ≠ 完成任务，复查会把对的改错

CALVIN：执行错误之后发生了什么



Qwen-Max 200 轮中有 103 轮执行错误（95 轮语法错误）：接口不合规会白白消耗交互机会。

固定输入多轮复查（46 例共享子集）

Qwen-27B 自我复查	+1 修正	−2 改错
Qwen-27B 裁剪复查	+2 修正	−4 改错

两种复查都把 3DSRBench 上正确的“back”改成了“left”。

0.034→0.152

自我复查修好全部 6 个越界框，平均 IoU 上升

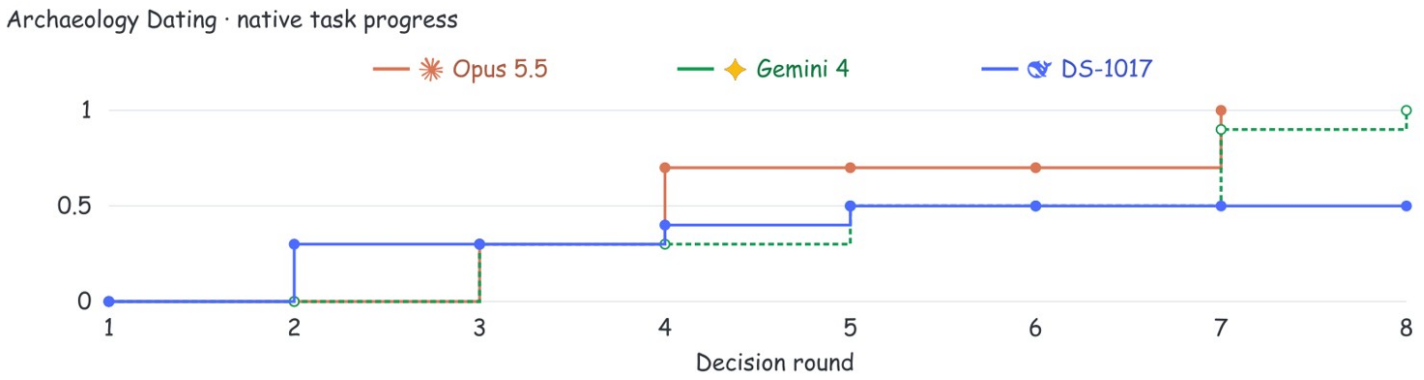
0 / 9

但仍没有一个框达到 IoU ⩾ 0.5 的判据

表示合法性修好了，功能区域的误差还在：要分别度量语义修正、坐标合法性和任务是否被接受。

成功恢复长什么样

有效的恢复是补上前提条件，并让反馈推进剩余任务



DiscoveryWorld 考古测年：每轮的原生任务分数（阶梯线为最新分数）

Opus 5.5

前两轮在任何环境动作前出错 → 取工具 → 挖掘三个地点 → 读取文物年代 → 在最老地点插旗，第 7 轮得 1.0

Gemini 4

第 2 轮出错，第 3 轮恢复推进，第 8 轮完成

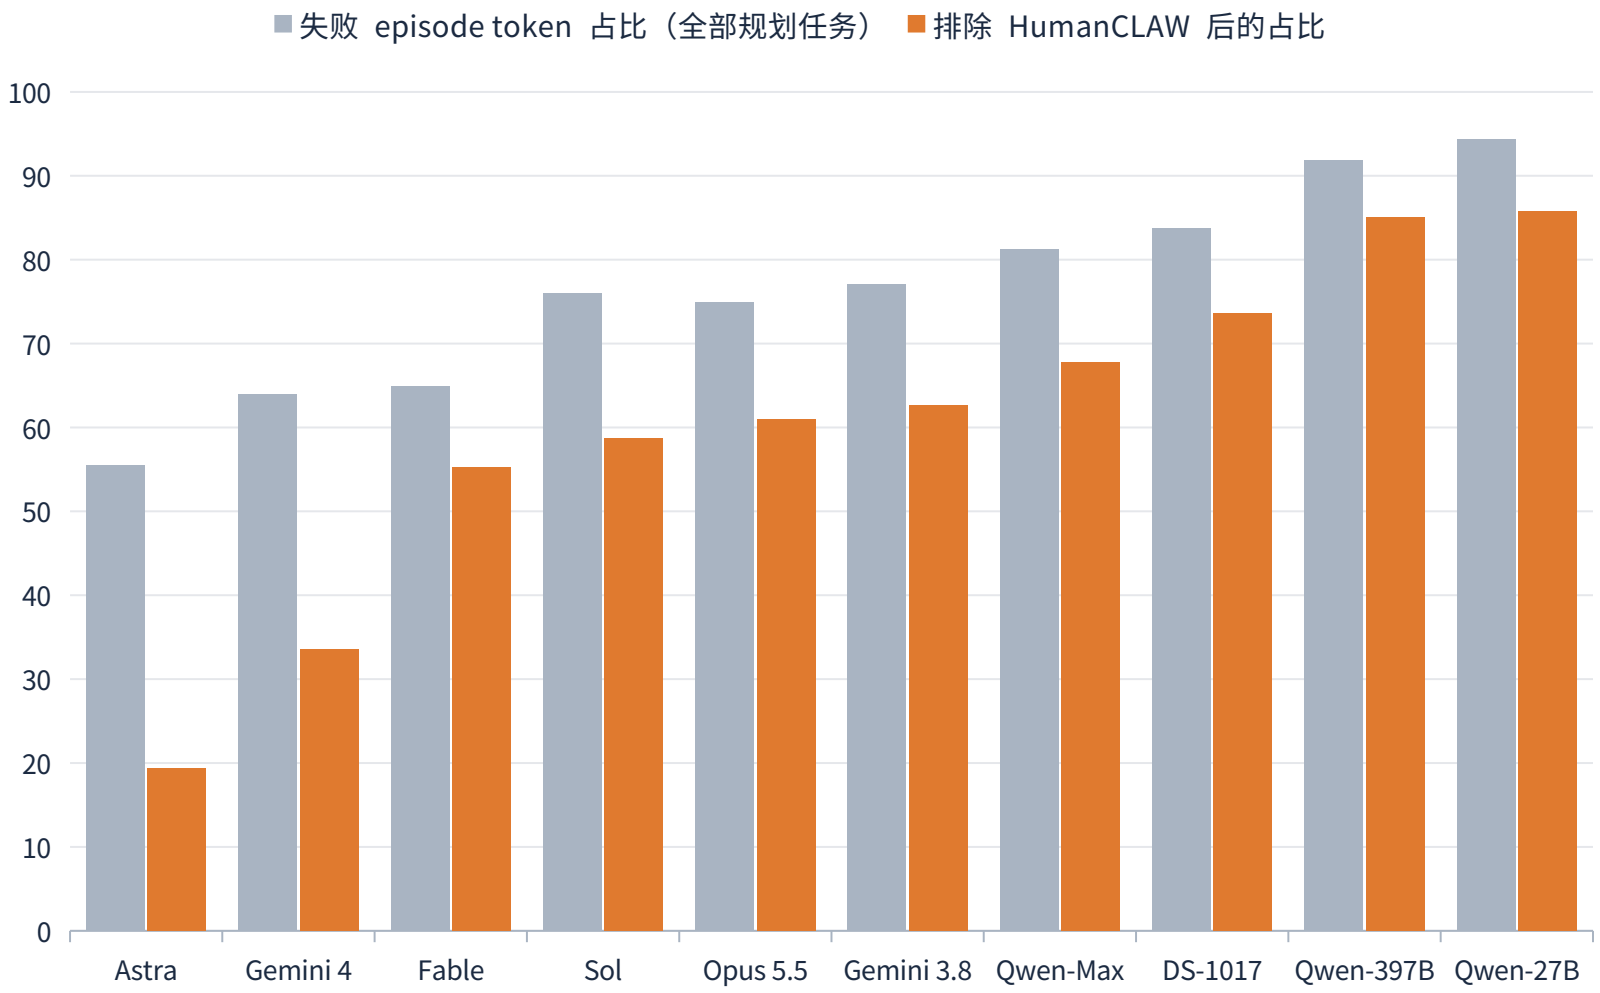
DeepSeek

第 5 轮达到 0.5，最后三轮都是代码错误，没有新的环境步，停滞

关键：每次修正都换来下一步决策需要的证据

资源消耗

失败成本不同：最强规划者的失败 token 集中在长程身体控制



81.7%

Astra 失败 token 中来自 HumanCLAW 的比例（13/157 个任务，预算 101 轮 / 2M token）

55.5→19.4%

排除 HumanCLAW 后 Astra 的失败 token 占比；Gemini 4 为 64.0→33.5%

98–99%

HumanCLAW 轨迹中 prompt token 的占比：成本主要是重复处理输入

贡献与局限

贡献

以完整任务需求为中心的评测：同时度量预测精度、功能 grounding 、子目标达成和最终成功

统一 arena + GeoProbe：保留 32 个来源的原生接口与判据；用受控渲染拆分相机、运动和尺度因素

细粒度失败诊断：点 / 框交叉表、 oracle 尺度对齐、序列前缀生存计数、错误→恢复→成功嵌套计数、配对轨迹

可操作的启示：指出恢复时该改什么：目标绑定、前提状态，还是不成立的完成声明

局限 / 注意

样本量小：规划和操作每个任务只跑 1 次； CALVIN 10 条序列， HumanCLAW 13 例；不少结论基于单条配对轨迹

执行设置不完全一致： CALVIN 中后加入的 3 个模型有 40 轮、 1.28M token 和每轮 RGB ，最初 7 个模型为 16–20 轮、640k token

只测原生能力：最小 harness 不代表加上专用感知 / 控制或 VLA 策略后的系统上限

复查实验规模小： 46 例、 2 个模型；部分端点不是不可变快照，影响复现

Take-away

前沿 VLM 已有不错的空间感知；真正的短板是在长程执行中维持物理状态、正确绑定动作目标，以及判断任务是否真的完成。

评测

只看平均分会误导；要同时看子目标、终态条件和失败成本

反馈

有效的反馈要针对卡住进度的那个具体条件，而不是更多 token 或重复复查

系统

把目标绑定、状态验证和停止判断显式化，可能比单纯增强感知更关键