论文解读 · arXiv 2610.37393

Learning Quality-Controllable Robot Policies with Iterative Hindsight Relabeling

让机器人策略的「执行质量」可调，并靠迭代后见重标注不断变好

Sinjae Kang, Dong Kyu Shin, Jaehong Kim, Kamin Lee, Hyoeun Kim, Kaixin Wang, Li Zhao, Seonghyeon Ye, Kimin Lee

KAIST · LGE · Microsoft Research

首次提交： 2026-10-27　　项目页： sinnnj.github.io/qcp

质量条件化行为克隆

迭代后见重标注

无需人工质量标注

π0.5 真机验证

SUMMARY

一句话总结

把执行质量量化成**分位数标签**作为策略的条件输入，推理时按档位控制；再通过「**最高档采集 → 保留成功 → 按实测质量重标注 → 从头重训**」的循环，**无需人工标注**即可把可控质量推到初始示教之外，质量与成功率同时提升。

8 / 8

仿真「任务 × 属性」组合
质量指标全部最优 · Table 1

≈1.6

平滑度 / 关节路径长度
分布偏移 W1/IQR · Fig. 4

+59%

真机传送带吞吐
8.2 → 13.0 罐 / 分 · Fig. 7b

42.0%

真机端酒成功率
BC 仅 16.0% · Fig. 7a

MOTIVATION

BC 只学「做成」，不管「怎么做」——而部署需要可调的执行质量

1

BC 一视同仁

所有成功示教被视为同样好 → 复现快慢、平滑 / 抖动混杂的「平均行为」，无法定向引导

2

需求因场景而异

传送带看重执行速度；端着酒杯托盘看重运输稳定性

3

已有方法有天花板

SORL / SCIQL 等只在静态示教上训练：可控范围受示教上限约束，且质量与成功率此消彼长

本文目标

01 推理时可控

按需指定单个质量属性或其组合的档位

02 可控范围持续外扩

通过在线 rollout 与策略更新，超越初始示教

03 零人工质量标注

质量由规则化评分函数自动计算

图表出处：论文第 1–2 节

QCP 总览：质量标签当「旋钮」，迭代重标注把刻度往上推

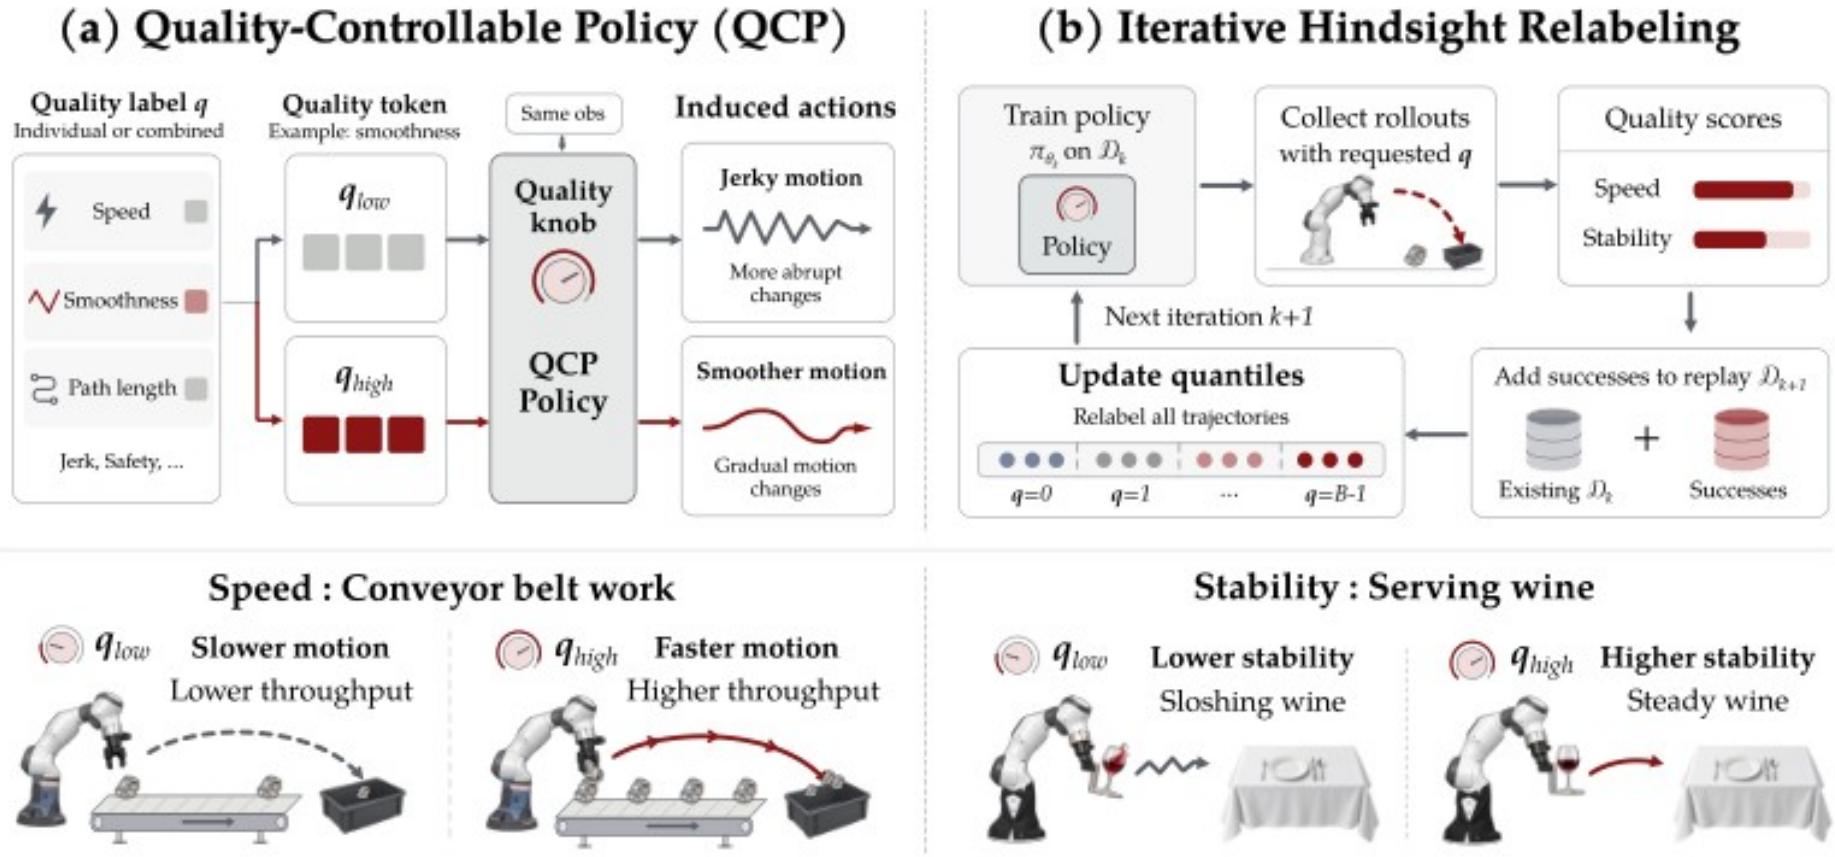

(a) Quality-Controllable Policy 质量标签 q → 质量 token → 同一观测下生成不同质量的动作（抖动 vs 平滑）

(b) Iterative Hindsight Relabeling 训练 → 按请求档位采集 → 打分 → 成功轨迹入库 → 更新分位数、重标注全部轨迹

图表出处： Fig. 1

QCP： 用分位数标签把「质量」变成行为克隆的条件输入

① 规则打分 m(τ)

速度 1/T 、动作 jerk 、关节路径长度、末端倾角……统一为「越高越好」

② 等频量化为标签

按经验 CDF 分 B=4 档（四分位）： $q \in \{0,1,2,3\}$ ；整条轨迹的每个动作块共享同一标签

③ 条件 flow matching

$\pi_\theta(A_t \mid h_t, q)$ 。 MLP： q → embedding 与观测编码拼接；VLA (π0.5)： prompt 写入 “quality level: 3”

等频分档示意（每档约 1/4 轨迹）

核心设计：条件化，而非过滤

低质量的成功轨迹不会被丢弃——它们照样教会策略「怎么完成任务」，只是被标成低档。

→ 质量与成功率可以**同时**提升

图表出处：论文第 3.1 节、附录 A/B

METHOD • ITERATIVE RELABELING

迭代后见重标注：只靠自己的成功 rollout，把最高档门槛不断上移

① 采集

以最高档 q*=3 运行 π_k
（仿真每轮 300 条）

② 过滤

只保留成功轨迹
（加入失败轨迹反而变差）

③ 重标注

按实测分数入库
在 D_{k+1} 上重算全部分位数

④ 重训

从头训练 π_{k+1}
（MLP 随机初始化 / VLA 回预训练）

↺ 下一轮 k+1：高质量 rollout 不断积累 → 最高档门槛上移；原始示教保住低端 → 可控区间变宽

为什么 rollout 能超过最好的示教?

- 标签贴在每个动作块上 → 可拼接不同示教中各阶段的高质量片段
- 动作采样随机，最高档条件 → 更可能抽到更高质量的样本

为什么每轮从头训练?

- 重标注改变了每个标签对应的质量区间，旧的「标签→行为」映射需要被遗忘
- 也可能缓解持续训练中的可塑性损失（作者未直接验证）

图表出处：论文第 3.2 节、 Algorithm 1 6

主结果： QCP 是唯一同时提升质量和成功率的方法

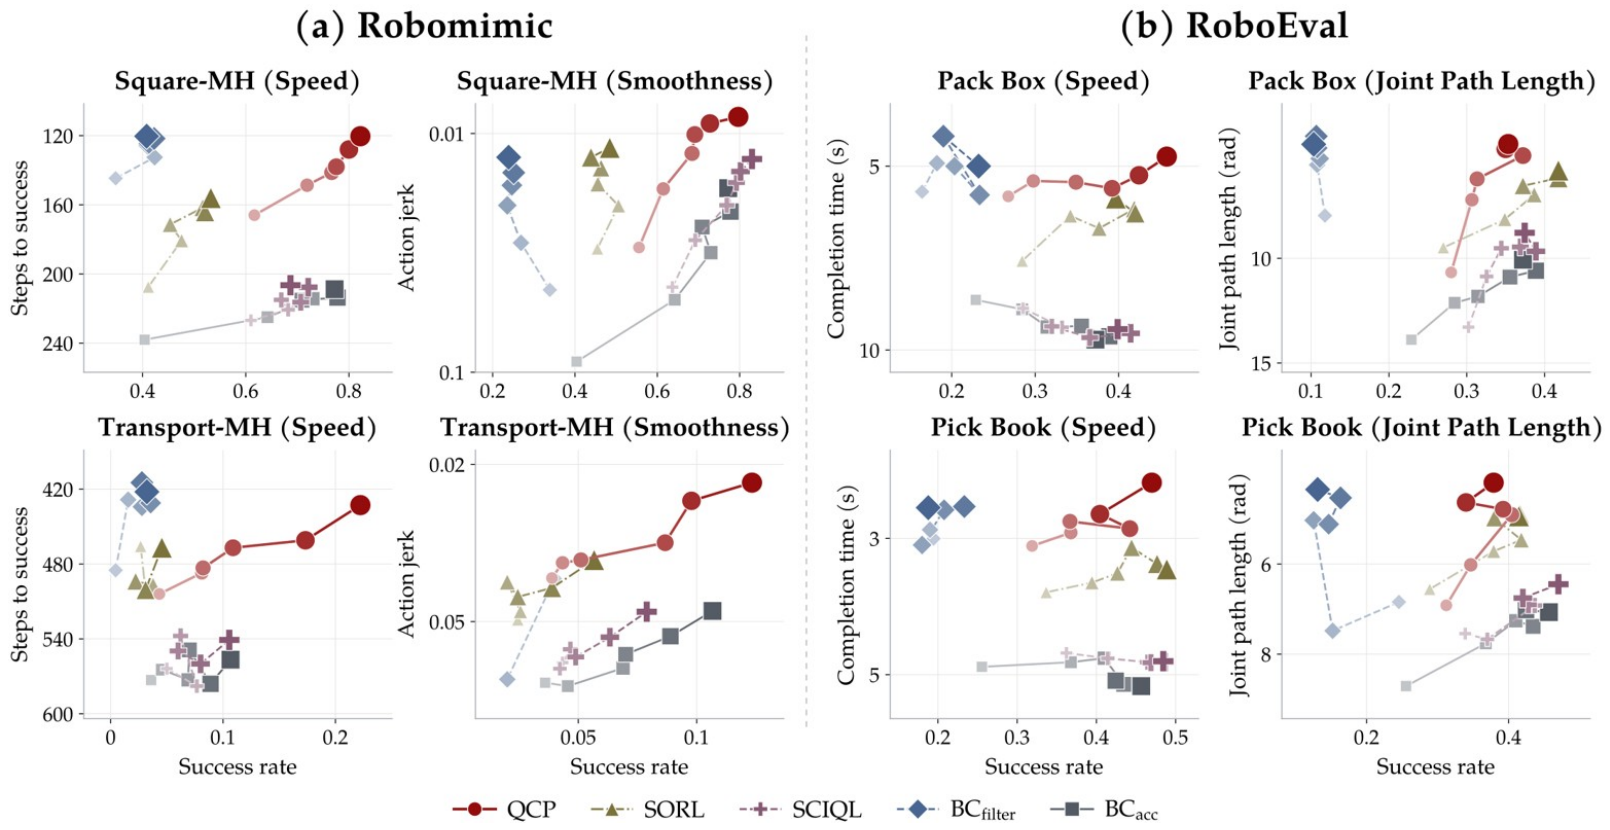

各基线为何「偏科」

BC_acc

无质量信号 → 只涨成功率

BC_filter / SORL

只用匹配标签的数据，丢掉大部分成功轨迹 → 成功率受损

SCIQL

成功优势 + 质量优势加权 → 此消彼长

QCP

全部成功轨迹按标签条件化 → 向右上方移动

x：成功率； y：质量（向上更好）；颜色越深＝迭代越晚； 3 seeds

RESULTS • VS RL BASELINES

对比在线 / 离线 RL： 8 组设置中 QCP 的质量指标全部最优

方法	Square 速度（步）	Square jerk ×1e-3	Transport 速度（步）	Transport jerk ×1e-3	Pack Box 速度（s）	Pack Box JPL (rad)	Pick Book 速度（s）	Pick Book JPL (rad)
QCP (ours)	**120.3** SR 82.2%	**8.5** SR 79.7%	**432.8** **SR 22.2%**	**22.2** **SR 12.3%**	**4.82** SR 45.8%	**6.42** SR 35.3%	**2.43** SR 47.0%	**4.63** SR 37.9%
SORL	156 SR 53.2%	11.5 SR 48.4%	466.8 SR 4.6%	34.9 SR 5.7%	5.64 SR 39.7%	7.11 SR 41.8%	3.37 **SR 48.9%**	5.15 SR 41.4%
SCIQL	206.5 SR 68.7%	12.8 **SR 83.0%**	540.8 SR 10.6%	47.2 SR 7.9%	9.24 SR 39.9%	9.06 SR 37.4%	4.75 SR 48.4%	6.4 **SR 47.0%**
DSRL	208.8 SR 37.0%	46.9 SR 43.0%	549.5 SR 4.0%	79.4 SR 7.0%	6.35 **SR 60.7%**	66.05 **SR 50.7%**	— SR 0.0%	— SR 0.0%
EXPO	162.5 **SR 96.0%**	157.4 SR 79.0%	567.7 SR 11.0%	176.5 SR 3.0%	8.72 SR 39.0%	24.43 SR 43.7%	5.73 SR 3.0%	29.2 SR 4.3%

大字：质量指标（越低越好，红色＝最优）；小字：成功率 SR （加粗＝该列最高）。第 5 轮迭代， 3 seeds 平均。

注意： EXPO 在 Square 速度、 DSRL 在 Pack Box 的成功率更高，但质量明显更差； DSRL / EXPO 在 Pick Book 基本失败。

作者解释： flow 策略的 RL 方法为吃「成功」信号而调，新增的质量奖励难以被有效利用（λ=4，仅在 Square 上调参）

可控性始终保持： 4 个档位的排序在 10 轮迭代中从不交叉

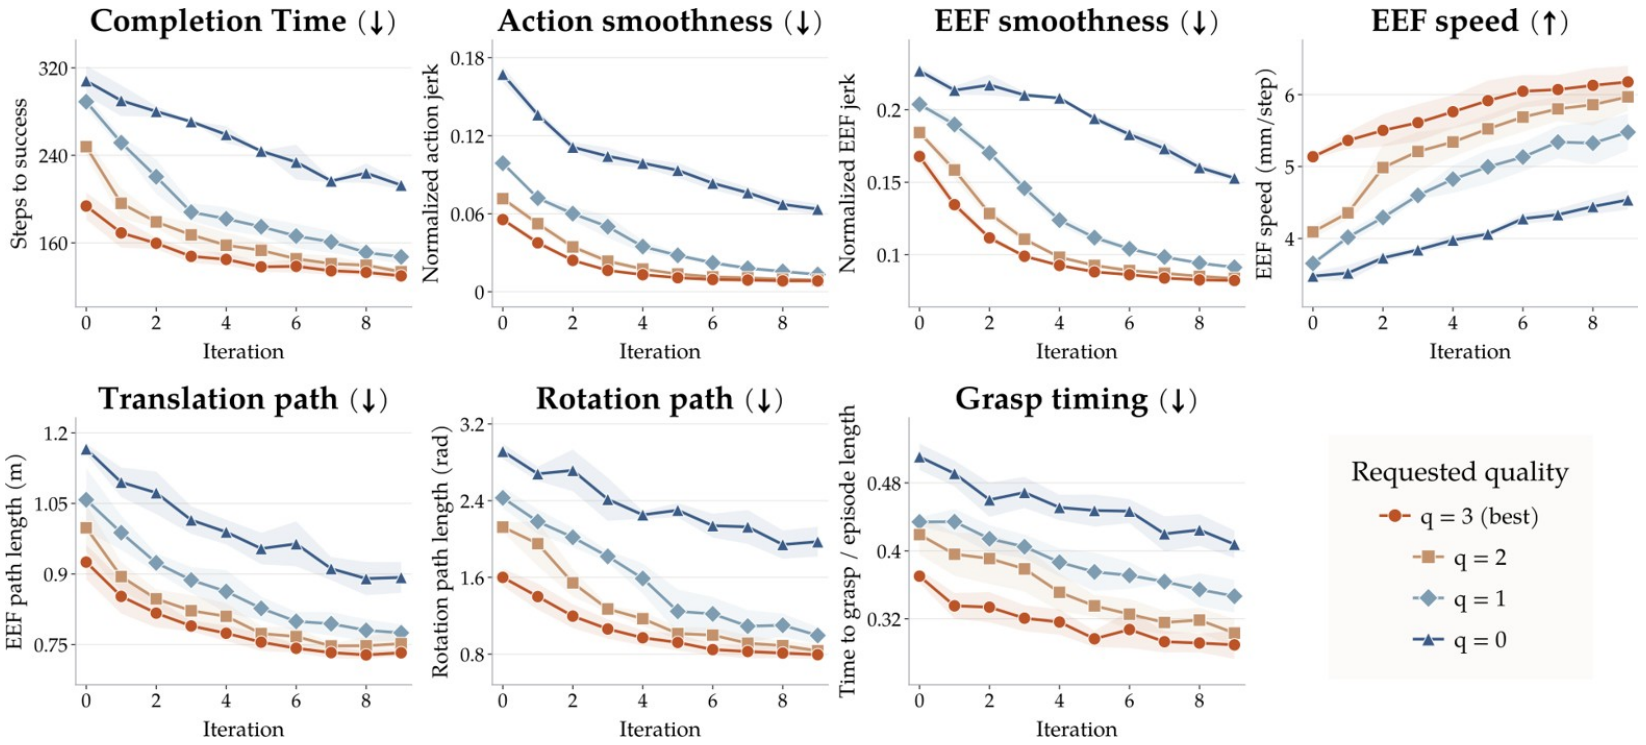

193.7 vs 308.1

第 0 轮 Square 平均完成步数
请求 q=3 vs q=0 （中间档居中）

- 新数据只来自最高档，但 7 个指标的档位顺序每轮都不变
- 整个可控区间同时向高质量移动（图中箭头）
- 单一策略：既在变好，也仍可选择不同的执行风格

超越示教：成功 rollout 的质量分布越过「最佳初始示教」

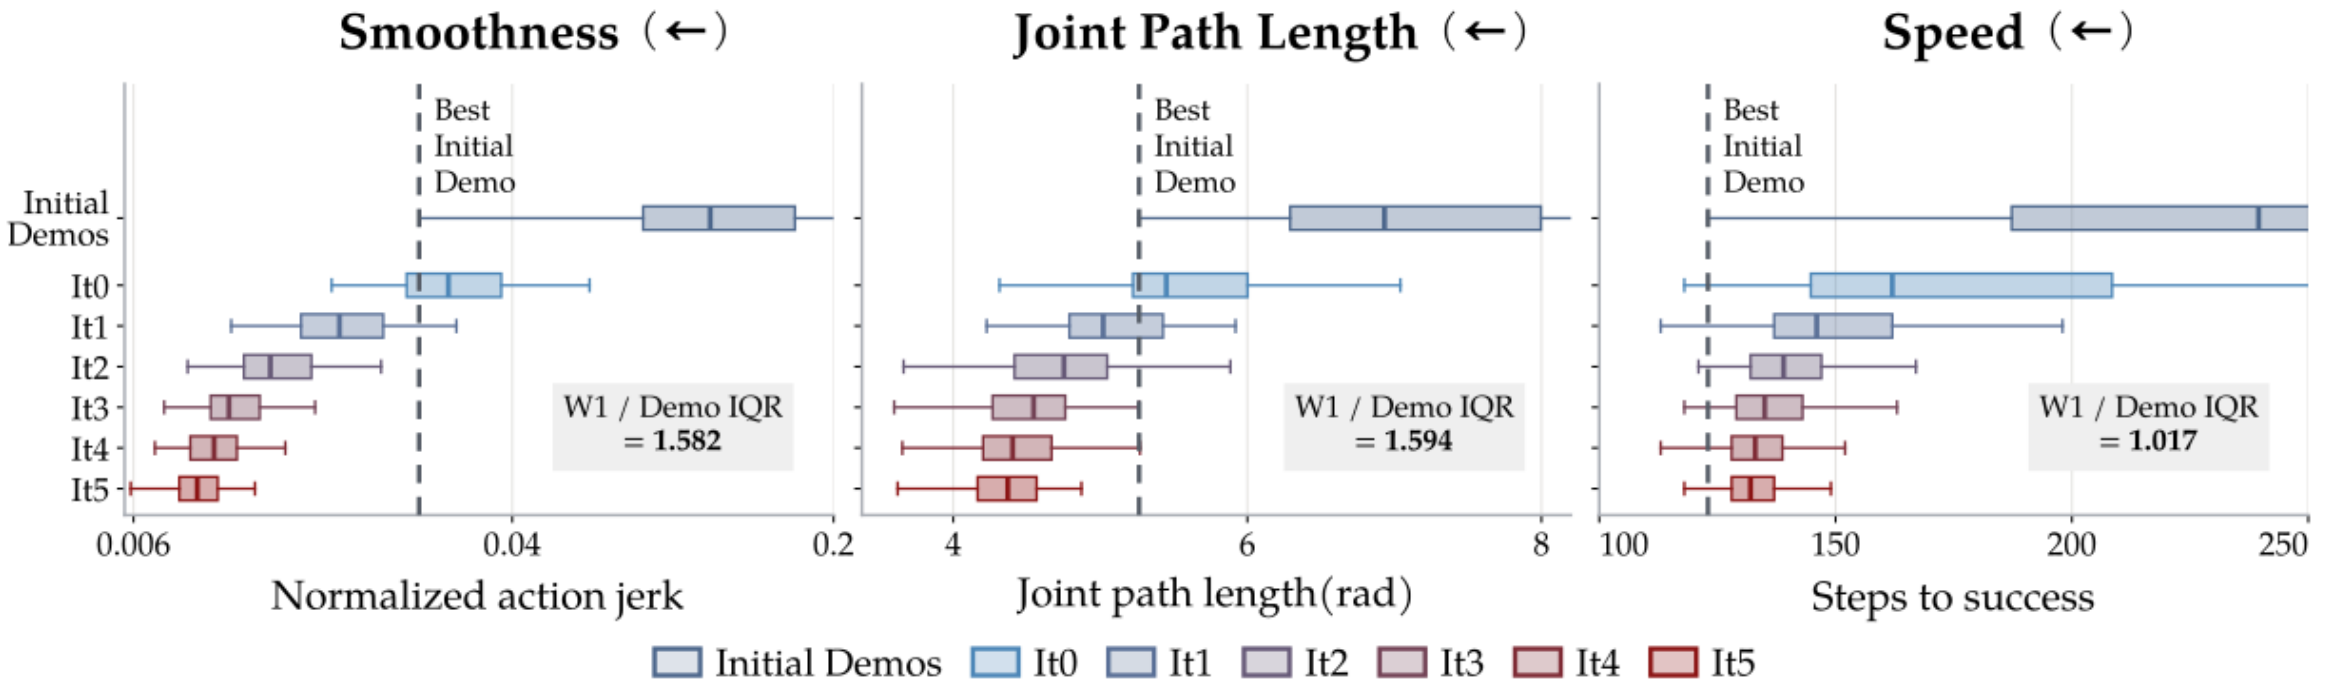

1.582
平滑度（归一化动作 jerk）
Square

1.594
关节路径长度 JPL
RoboEval

1.017
速度（完成步数）
接近物理可达最快速度

W1 / IQR
初始示教与最终成功 rollout 的 Wasserstein-1 距离 ÷ 示教分数的四分位距

多属性：既能双向组合控制，也能让 6 个属性一起变好

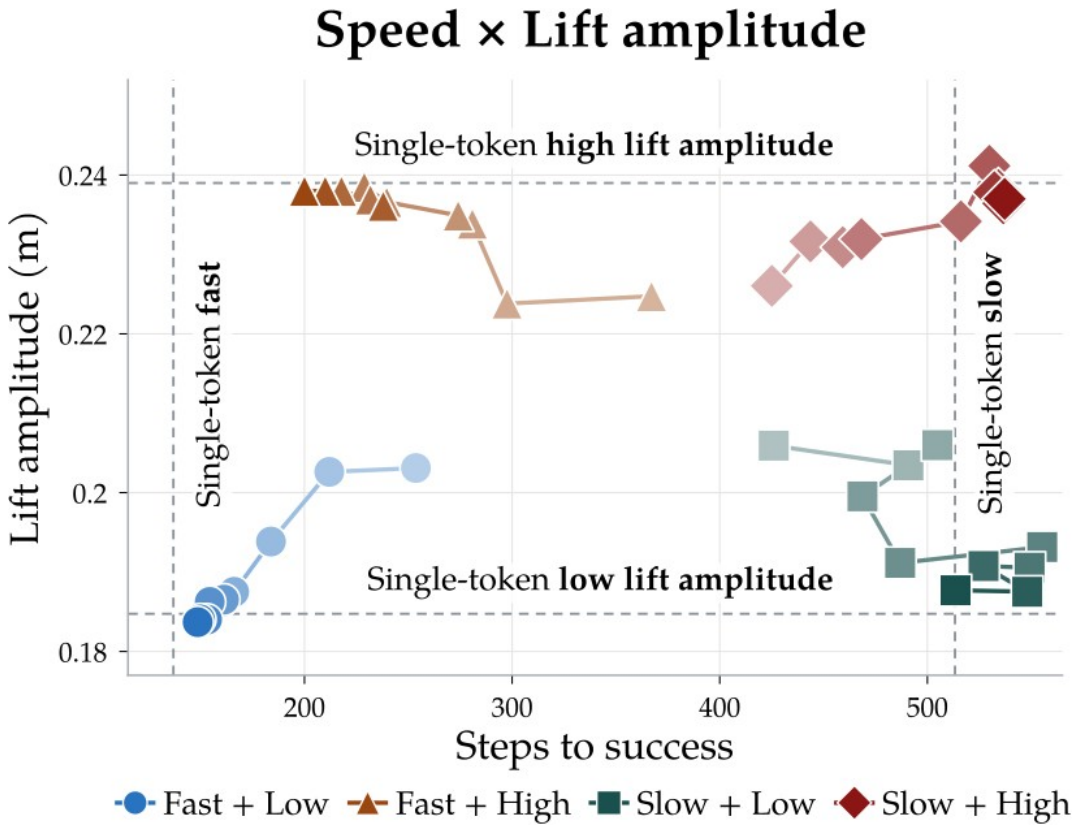

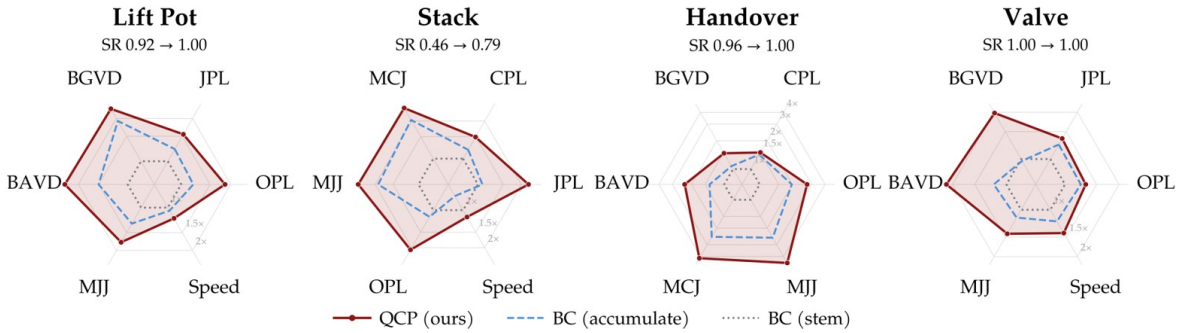

0.46→0.79
Stack 成功率

8.16→3.63
Stack 关节路径长度

169.6→36.2
Handover 关节 jerk

Square 双属性： 快 / 慢 × 高 / 低抬升幅度四种组合，最终都逼近单属性参考线（虚线），慢速组合成功率较低

RoboEval 6 属性： 单策略同时以 6 个质量标签为条件；雷达图外扩＝更好（初始 BC 为 1×）。每个任务事先剔除 2 个不受影响 / 与任务冲突的属性

真机（π0.5 + Franka）：托盘更稳、传送带更快，并超过人类遥操作

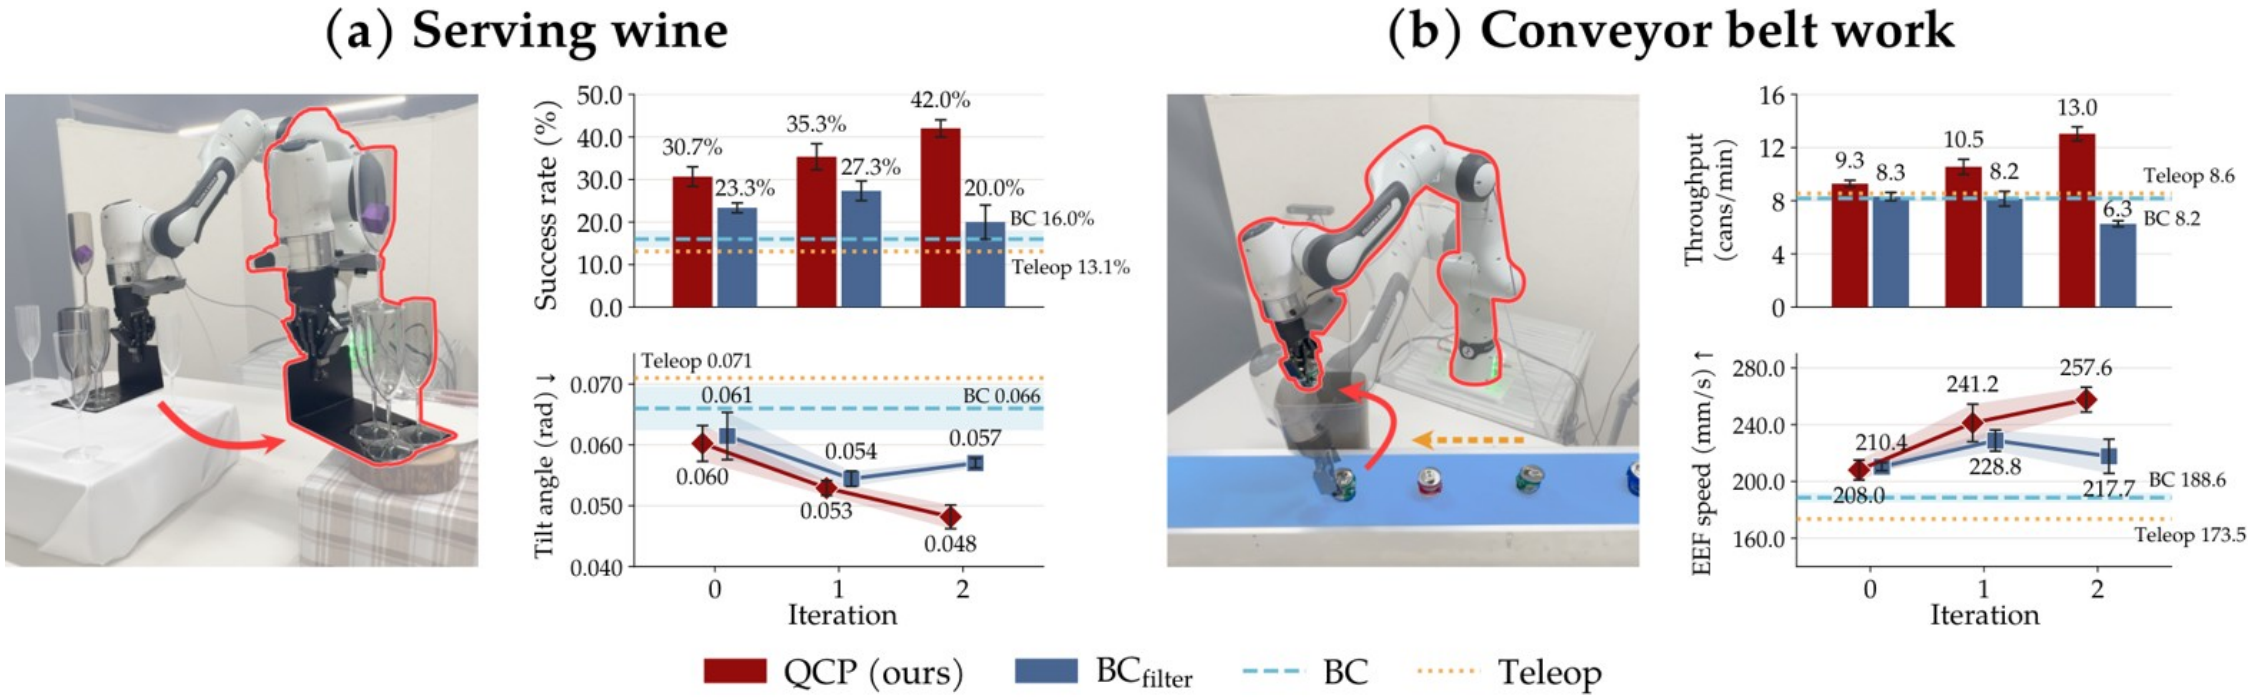

42.0%
端酒成功率
BC 16.0% • 遥操作 13.1%

−27%
托盘平均倾角
0.066 → 0.048 rad

13.0
传送带吞吐（罐 / 分）
BC 8.2 • +59%

257.6
末端速度 mm/s
BC 188.6 • 遥操作 173.5

ANALYSIS

消融：提升来自迭代循环本身，且整条轨迹打标签优于片段标签

同样 1,800 条 rollout：冻结 It0 vs 迭代（Square 平滑度）

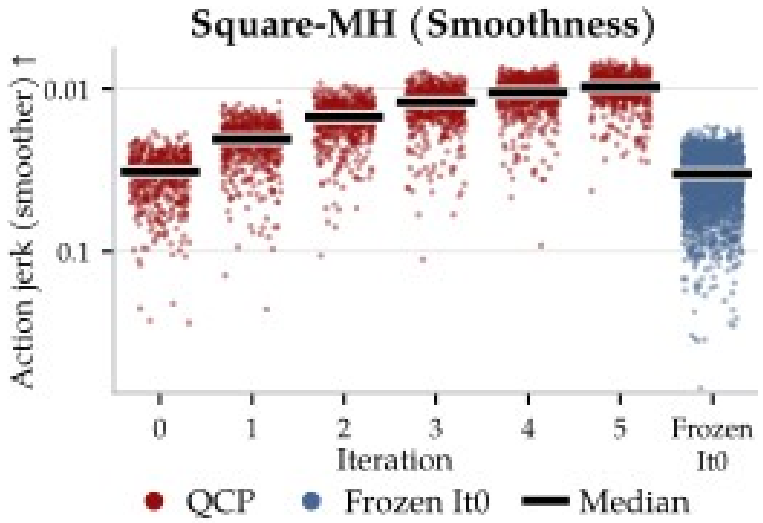

0.0335

冻结 It0 中位 jerk
最平滑一条 0.0171（仍差于 It5 的 75 分位）

0.0098

迭代第 5 轮中位 jerk
成功率 73.9%

标签粒度：轨迹级 vs 片段级 vs Hybrid（EEF 速度）

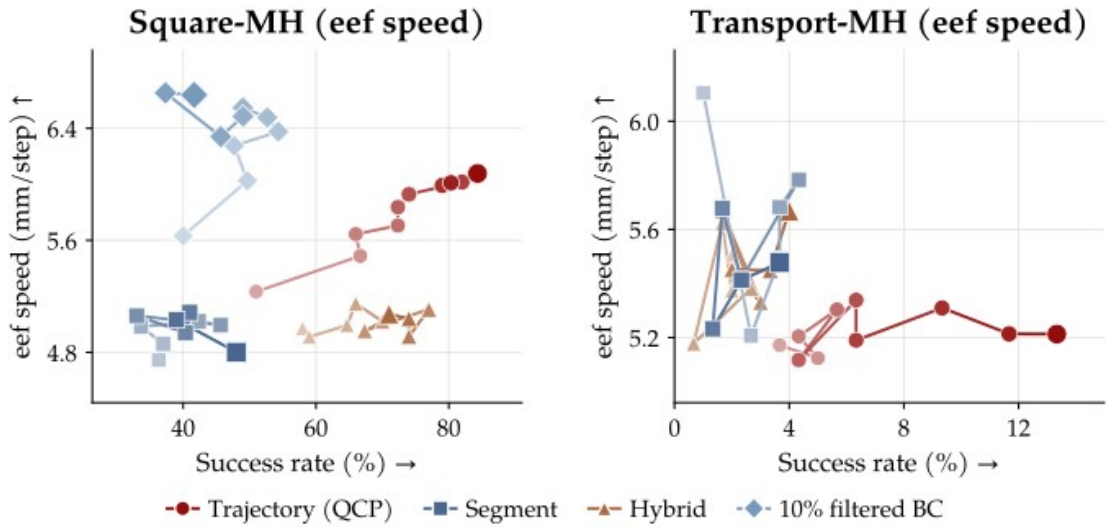

Square 第 9 轮：轨迹级 **84.3% / 6.08**；片段级 48.0% / 4.80；Hybrid 71.0% / 5.07（成功率 / mm per step）

Transport：轨迹级 13.3% vs 3.7% / 4.0%

片段分数与任务阶段耦合，策略会刷高局部分数而不推进任务（单 seed）

图表出处：Fig. 8（左）、Fig. 10、附录 F/G

四分位标签是稳妥的默认：分档越细越快，但成功率明显下降

成功率（%，越高越好）

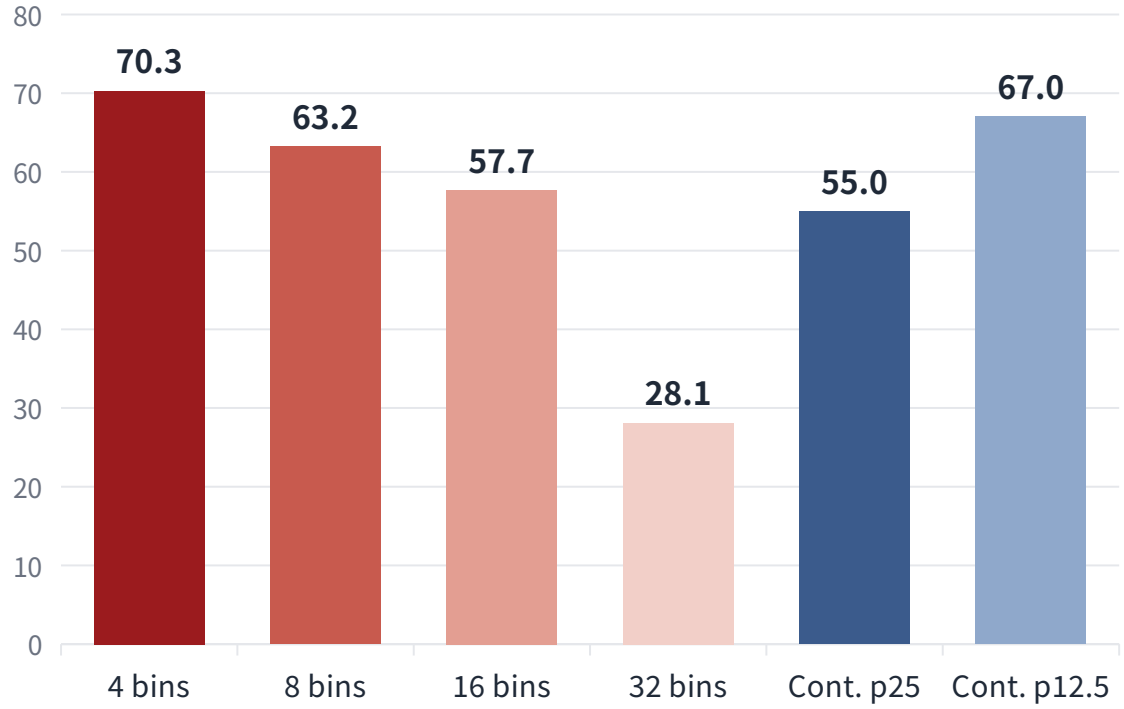

完成步数（越低越好）

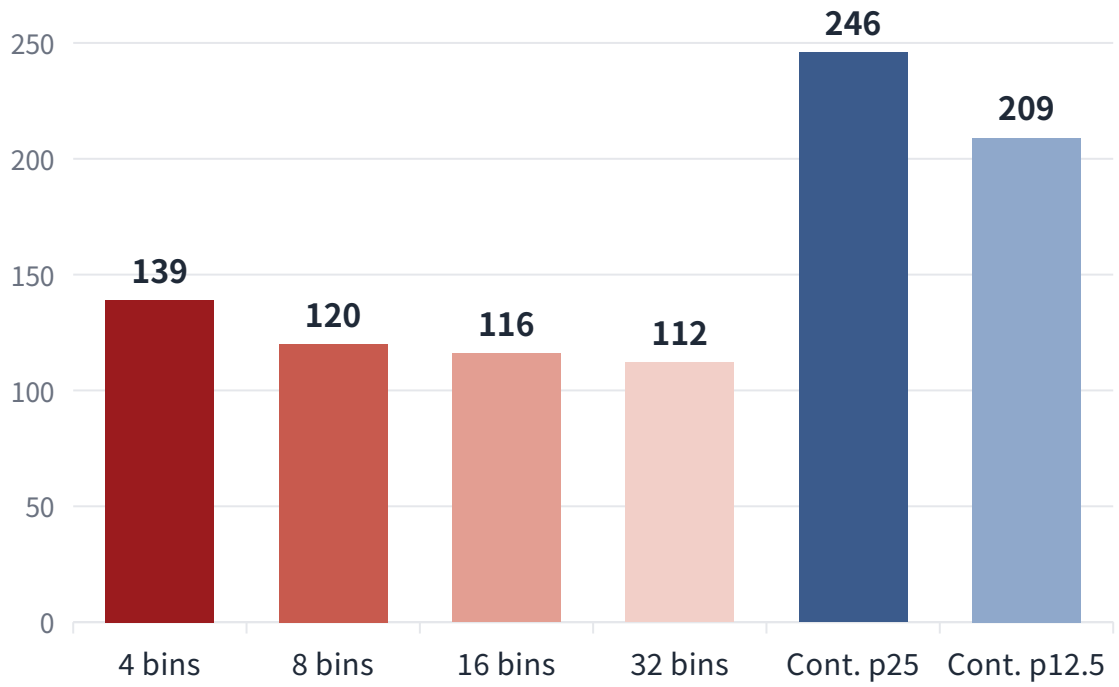

为什么量化更好？ 4 档时最高档约含 1/4 的训练轨迹，样本支撑充足；连续目标只有少量示例对应。注意连续变体的请求值选取方式也不同，结论是「四分位 + 每轮重算」为可靠默认，而非否定连续条件。

图表出处：附录 F （Fig. 9 右）数据，本页重绘

DISCUSSION

评价：简单、易落地；代价是依赖成功判定和手写质量函数

优点

- 极简：规则化质量函数 + 成功过滤即可自举，无需奖励塑形或人工偏好
- VLA 友好：只在 prompt 写入 “quality level” ，不改结构
- 「条件化而非过滤」打破质量—成功率取舍，证据充分
- 消融完整：冻结策略、分档数、连续条件、片段标签

局限 / 疑问

- 依赖成功判定与预定义质量函数，主观质量（如「优雅」）难以覆盖
- 每轮从头重训、数据只增不减， VLA 上成本随迭代线性增长
- 真机仅迭代 0–2 轮； Transport 最终成功率仅 22%（平滑度 12% ）
- RL 基线系数只在 Square 上调参；多属性冲突靠手动剔除属性

TAKEAWAYS

三点带走

01 条件化优于过滤

所有成功数据都被利用，低质量轨迹教「怎么做成」，标签决定「做成什么样」→ 质量与成功率可同时提升

02 后见重标注 + 分位数重算

只需规则化质量函数与成功判定，策略即可用自己的 rollout 自举，把可控范围推到示教之外

03 对 VLA 几乎零改造

π0.5 只改 prompt 文本，真机即带来更高吞吐（+59%）与更稳的运输（倾角 −27%）

适用场景：已有 BC/VLA 策略、部署时需在「快 / 稳 / 省」之间切换，且具备自动成功判定和可计算的质量指标