论文解读 · arXiv 2610.39278

WorldFlow

Joint Video and 3D Motion Prediction via Large-Scale Pretraining

视频与查询点 3D 运动联合生成的具身世界模型

Yuhao Lu, Jiongxu Chen 等 · RoboScience / 新加坡国立大学

首次提交： 2026-10-29

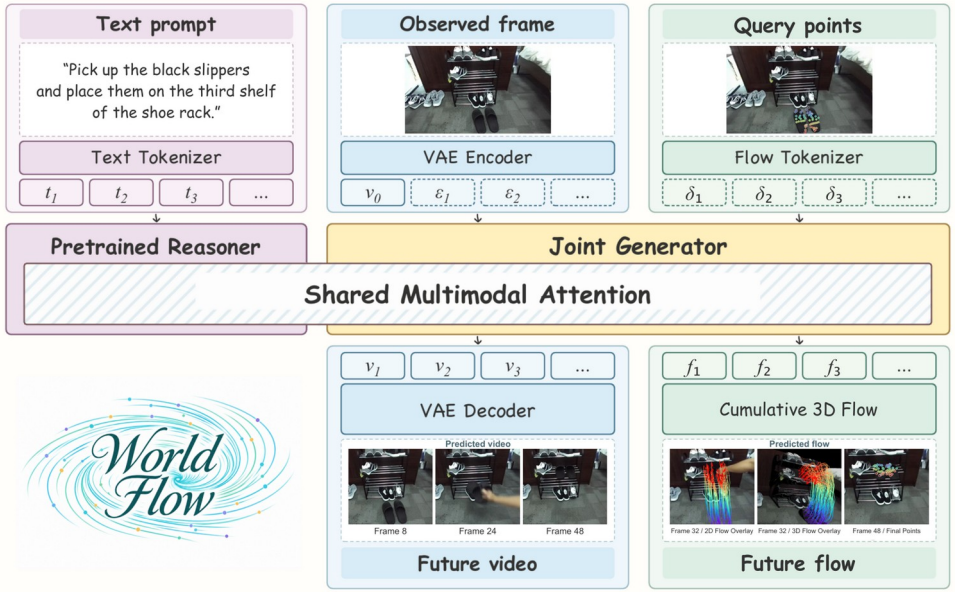

图源：论文 Fig. 2 （WorldFlow 总览）

一句话总结

在预训练视频模型 Cosmos-Nano 上增加“3D 位移 token” 模态，用一个 MoT 生成器同时去噪未来视频与查询点的度量 3D 轨迹；联合生成视频让 3D 运动误差下降近一半，但在真实场景子集上仍不及“零运动”参考。

现有三条路线各缺一块： 3D 显式性、跨本体性或监督信号

视频世界模型

Wan · Seedance · Cosmos

能做什么

预测越来越连贯的未来画面

缺什么

只输出像素， 3D 动力学隐式，难直接用于规划控制

世界动作模型 WAM

同时预测观测与动作

能做什么

把动作纳入世界建模，可端到端控制

缺什么

动作标注昂贵，且绑定具体机器人本体

3D 运动预测

MolmoMotion · μ0 · TraceGen

能做什么

直接预测未来 3D 轨迹 /flow

缺什么

仅用 flow 监督，信号稀疏；稠密场景 flow 计算昂贵

WorldFlow 的思路：把“查询点条件下的 3D flow” 作为与本体无关的几何接口，并与视频**联合生成**——视频的稠密监督反哺运动学习，预训练视频模型的物理常识被直接利用。

一个生成器同时去噪未来视频与 3D 轨迹，无需单独跟踪阶段

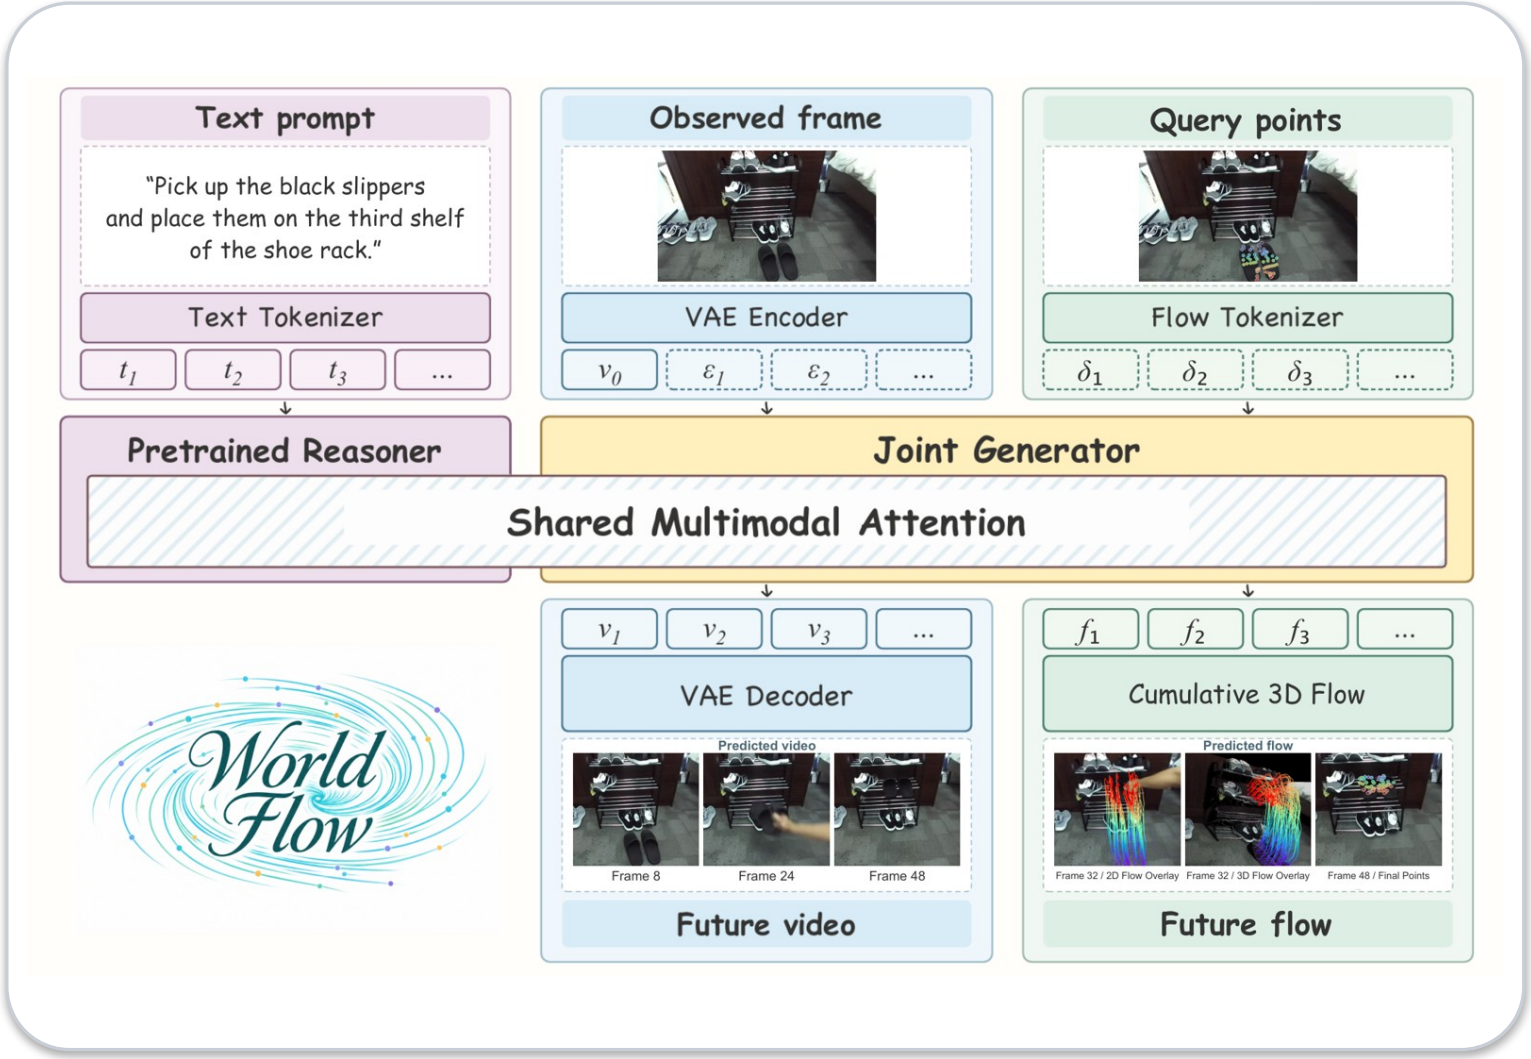

1 输入

指令 c、首帧 I_0、N 个 3D 查询点及其像素坐标

2 联合去噪

视频 token 与 flow token 全注意力交互，并读取 Reasoner 的语言上下文；两模态共享噪声水平

3 输出

VAE 解码未来视频；逐帧位移 f_t 反归一化后累加 → 度量 3D 轨迹（首帧相机坐标系）

建模目标： $p(I_{1:t}, f_{1:t} \mid I_0, Q, S_0, c)$

3D flow token： 连续位移 + 几何嵌入 + 与视频共用的时空 RoPE

① 域级归一化

$$f = f / a_d$$

a_d 为每个数据域预先估计、训练中固定的标量，平衡跨域运动尺度

② 查询点几何编码

$$e^{3D} = \mathrm{MLP}[E_abs(p_0); E_rel(p_0 - \mu)]$$

绝对位置与相对质心位置各经 Fourier 特征 + MLP；同一点所有未来帧共享

③ 连续 flow token

$$h = \mathrm{Linear}(f^{l}\sigma^{l}) + e^{3D} + e_cond(\sigma)$$

每个“点 × 帧”一个连续 token； e_cond 含模态嵌入与噪声水平嵌入

④ 时空对齐 RoPE

$$r = (t/q_t, \lfloor v_0/q_s p_s \rfloor, \lfloor u_0/q_s p_s \rfloor)$$

锚定到未来帧与该点首帧所在 patch，与视频 token 共用位置规则

13 × 9 × 15
每个 clip 的视频 token 网格

48 × 64
flow token （48 步位移 × 64 查询点）

49 帧 · 288×480
q_t=4, q_s=16, p_s=2

训练目标：联合 rectified flow 为主，三项辅助损失约束干净运动

$$L = \lambda_video \cdot L_video + \lambda_flow \cdot L_flow + 0.1 \cdot L_dir + 0.1 \cdot L_vmag + 0.05 \cdot L_end$$

联合 flow matching： 视频与 flow 共享每样本噪声水平、分别计算损失；**辅助项：** 作用在重建的干净 flow $\hat{x}_0 = x_\sigma - \sigma \cdot v_\theta$ 上

L_vmag 逐步位移

$$\| \hat{f}_{ti} - f_{ti} \|^2$$

约束局部位移的大小与方向；可证明等价于向量场误差的 σ^2 重加权

L_dir 累积方向

$$1 - \cos(\hat{d}_{ti}, d_{ti})$$

防止小误差累积成方向错误；按真值累积位移幅度加权

L_end 相对终点

$$\| \hat{d}_T - d_T \| / \max(\| d_T \|, 0.1)$$

约束最终位置；净位移 < 0.1（归一化坐标）的点不参与

三项辅助损失均乘以噪声权重 $1-\sigma$（低噪声样本权重更大）；消融：去掉后 Sim7 ADE 0.051 → 0.063 m

训练语料： 144 万物体级 clip ， AgiBot World 约占 44%

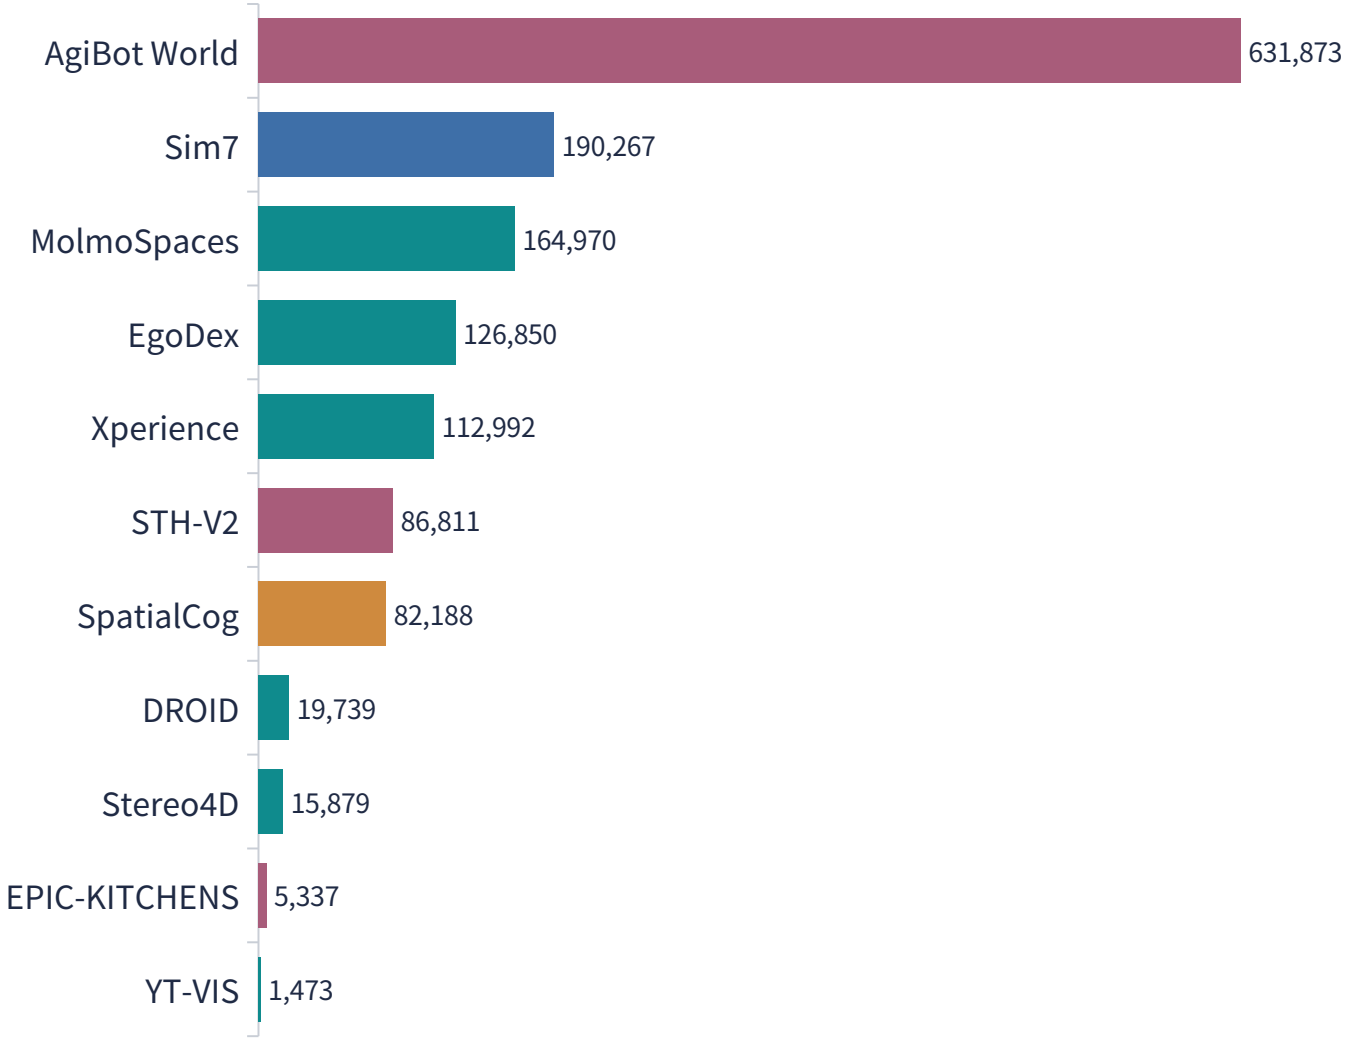

Sim7　Real3

SpatialCog　MolmoMotion-1M

1.44M

物体级 clip

49 帧 @16 FPS， 64 个查询点 / clip

1,224 h

标准化时长

按 clip 数换算，非去重原始视频时长

44 亿

3D 位移向量

9,206 万条点轨迹 × 48 步

数据高度异质：保留率、时间长度、运动尺度都需逐源处理

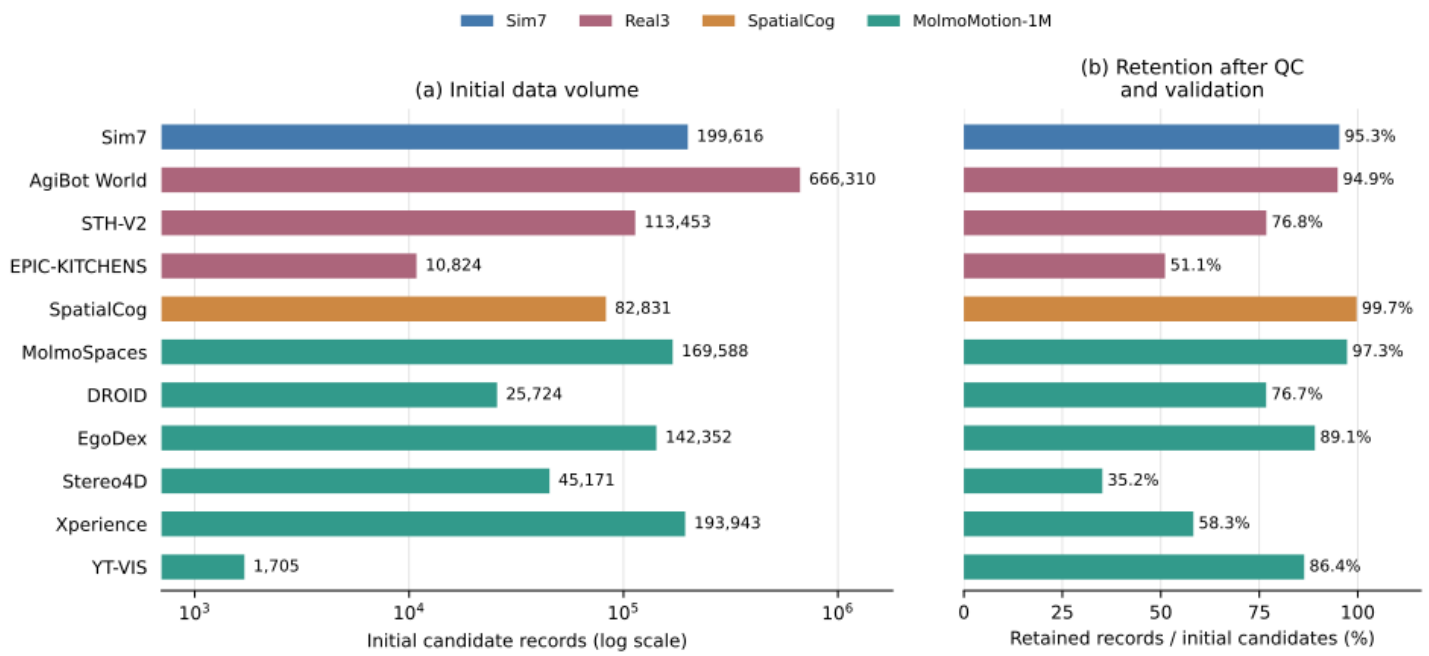

35.2%

Stereo4D 质控保留率最低

SpatialCog 99.7%， AgiBot 94.9%， EPIC 51.1%（Fig. I）

97.8–99.7%

三个 Molmo 子集需尾部补帧

MolmoSpaces / EgoDex / DROID；补帧位移为 0（Fig. II）

数倍到百倍

跨源运动尺度差异

读 Fig. III 估计；故按域固定归一化系数 a_d

两阶段课程训练： SpatialCog 预热 → 仿真 → 真实 → SpatialCog 精调

阶段一

SpatialCog 预热 32k 步

从 Cosmos-Nano 初始化；峰值 lr 1e-4，余弦衰减

阶段二

混合数据 51.1k 步

EMA 权重初始化，五个采样区间平滑过渡

域内采样 $p \propto N^{\alpha}$（Real3 α=0.8，其余 0.5）

lr： 1e-4 → 8e-5 平台 → 末尾 5e-6

64 × H800，全局 batch 128

推理： 40 步采样， CFG = 2

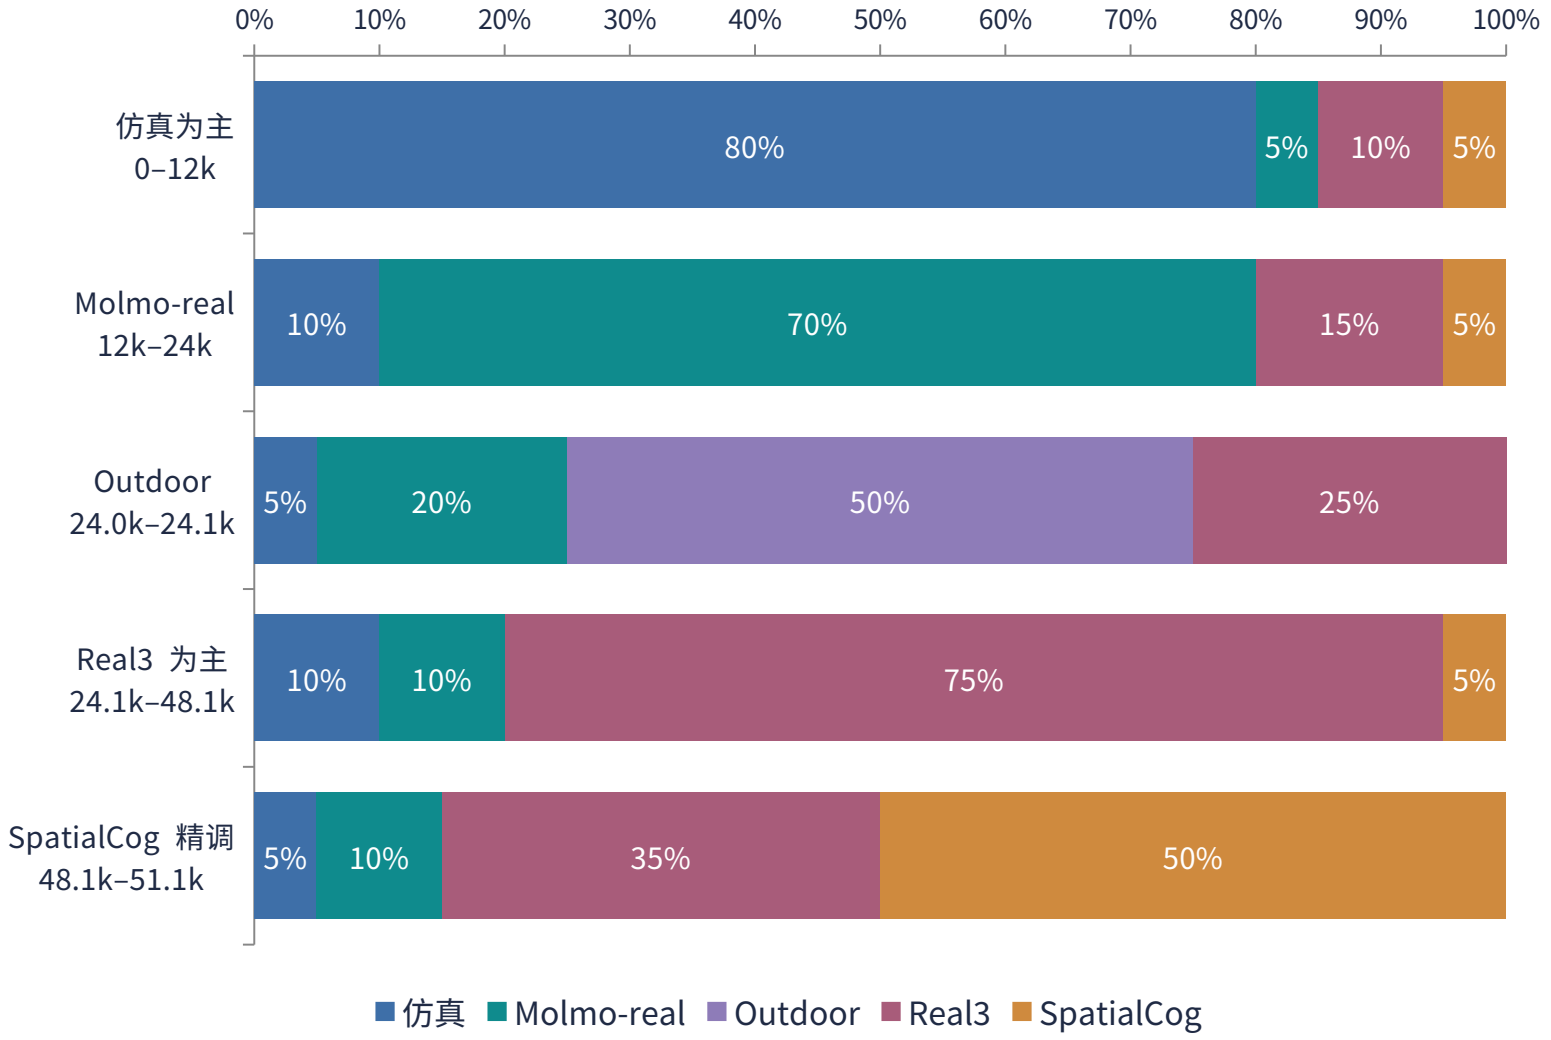

出处：论文 §4.2、附录表 II、 Fig. IV

主结果：三个子集 ADE 均为学习方法最低，SpatialCog 降低 54%

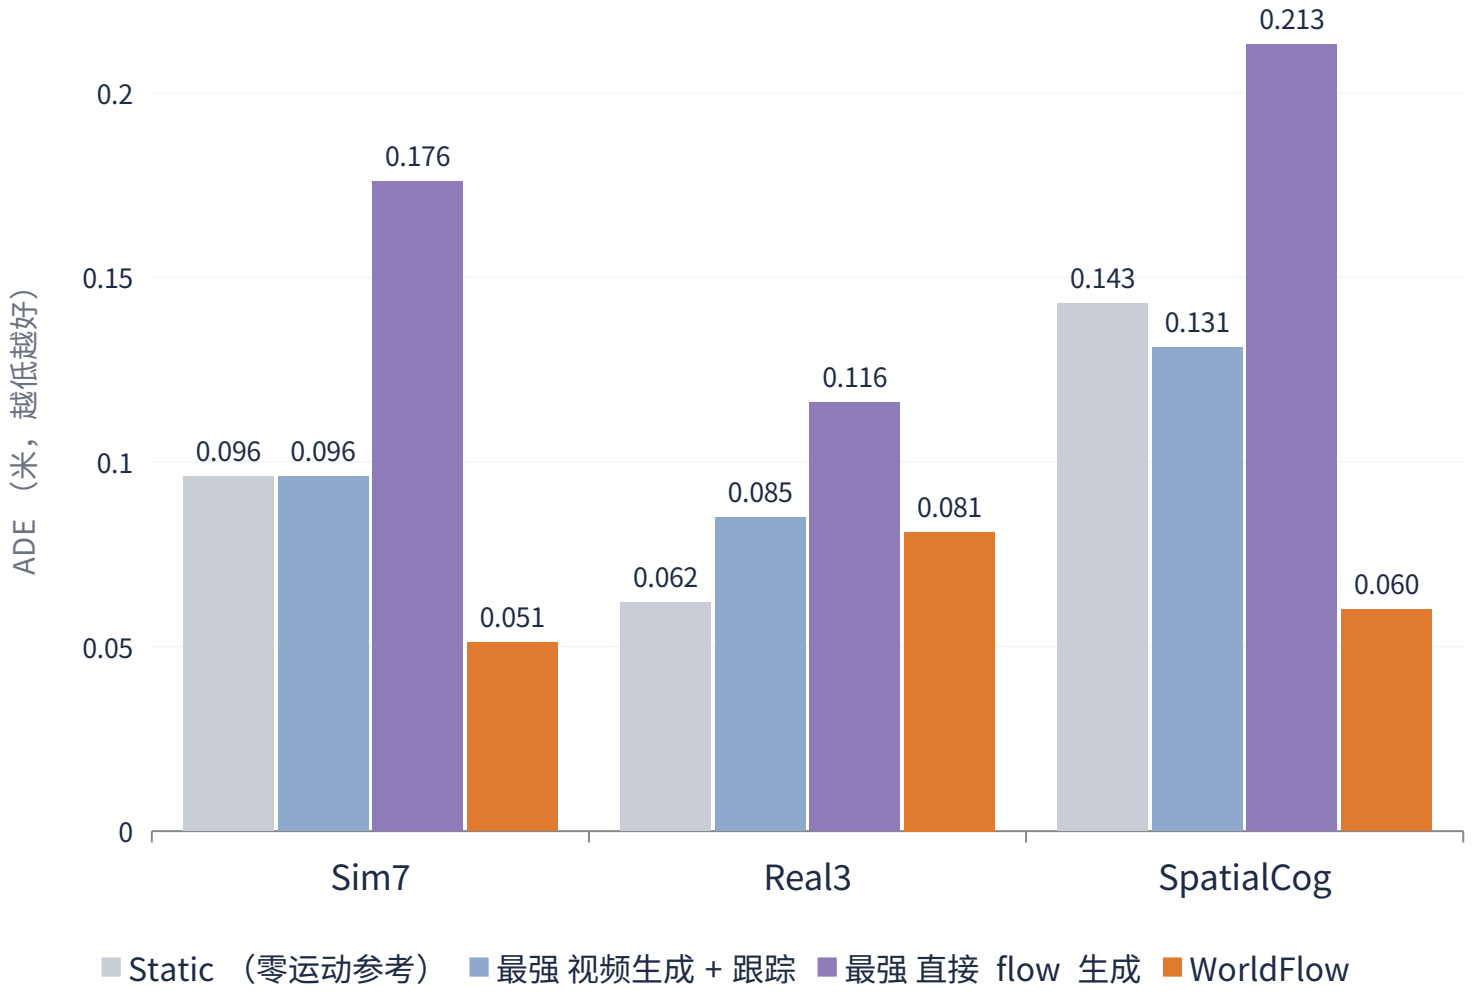

相对最强外部学习基线的 ADE 降幅

SpatialCog **−54.2%**

0.131 → 0.060 m （空间关系推理）

Sim7 **−46.9%**

0.096 → 0.051 m （7 个仿真平台）

Real3 **−4.7%**

0.085 → 0.081 m；但 Static 仅 0.062

最强基线：Sim7 / Real3 为 Cosmos3-Nano+4RC，SpatialCog 为 LingBot-Video-MoE+4RC

出处：论文表 1（WorldFlowBench，ADE 单位：米）

消融：视频联合生成是最大功臣，直接生成 flow 优于事后跟踪

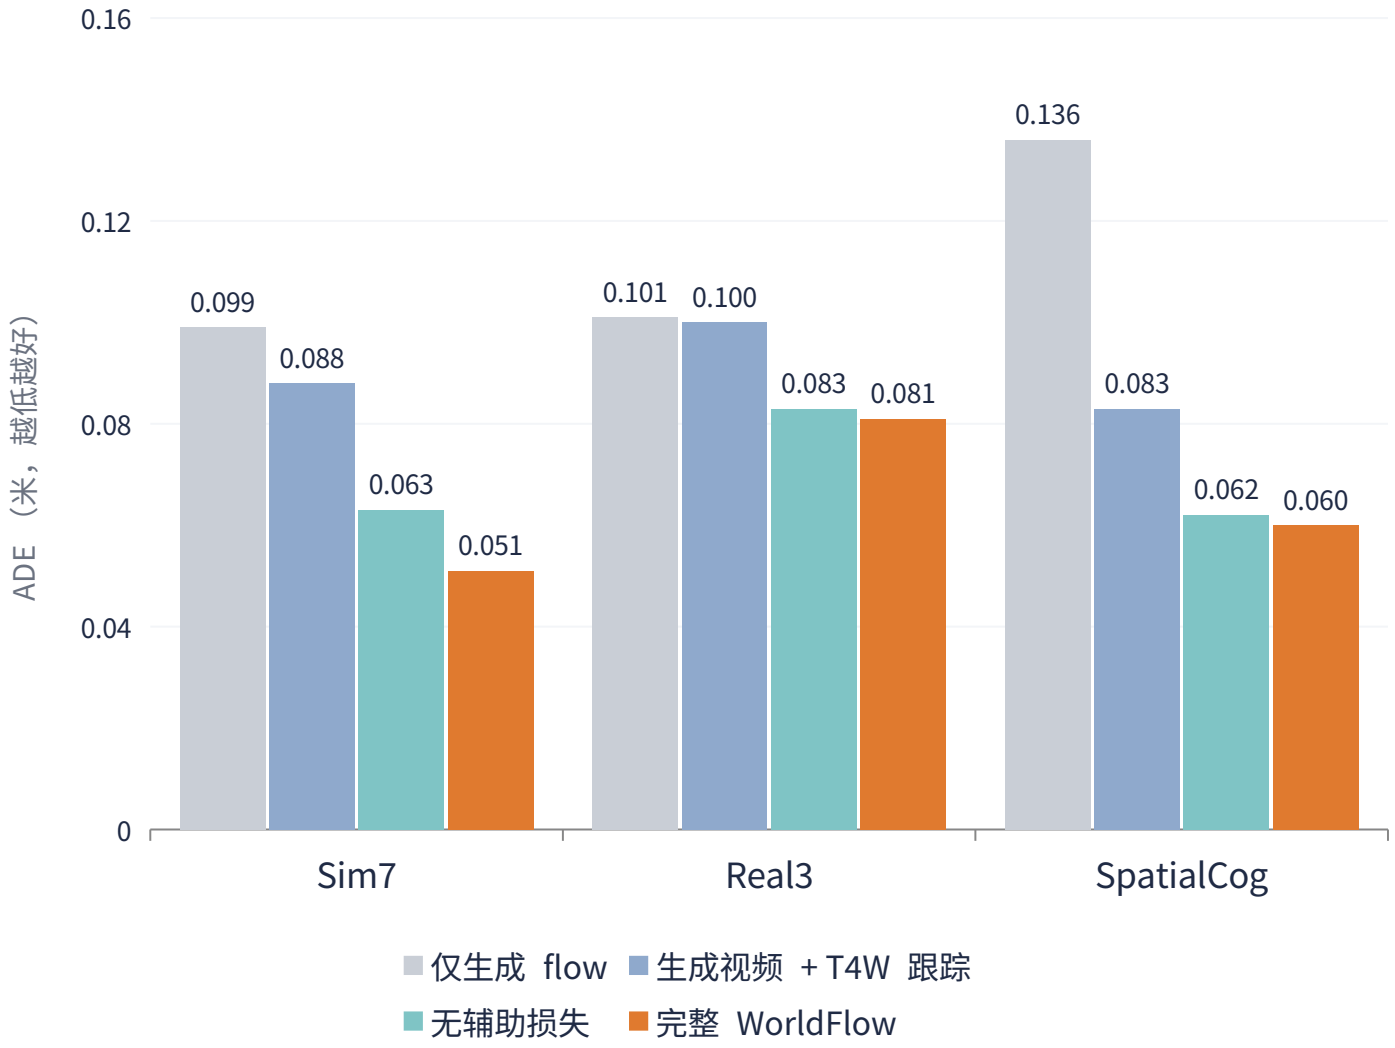

联合生成 vs 仅 flow

−48.5% / −19.8% / −55.9%

ADE 降幅（Sim7 / Real3 / SpatialCog）； SpatialCog FDE 0.248 → 0.078 （− 68.5% ）

直接 flow vs 事后跟踪

0.060 vs 0.083 / 0.098

SpatialCog ADE： 直接生成 vs T4W / 4RC 跟踪同一视频；三个子集 ADE 、 FDE 、 PWT 全部更优

辅助运动损失

Sim7 0.063 → 0.051

ADE −19%； 三个子集 ADE 、 FDE 、 PWT 全部提升

出处：论文表 1 消融部分、 § 4.3.3 （ADE 单位：米）

定性对比：轨迹形状最接近真值，但开放场景仍会低估运动幅度

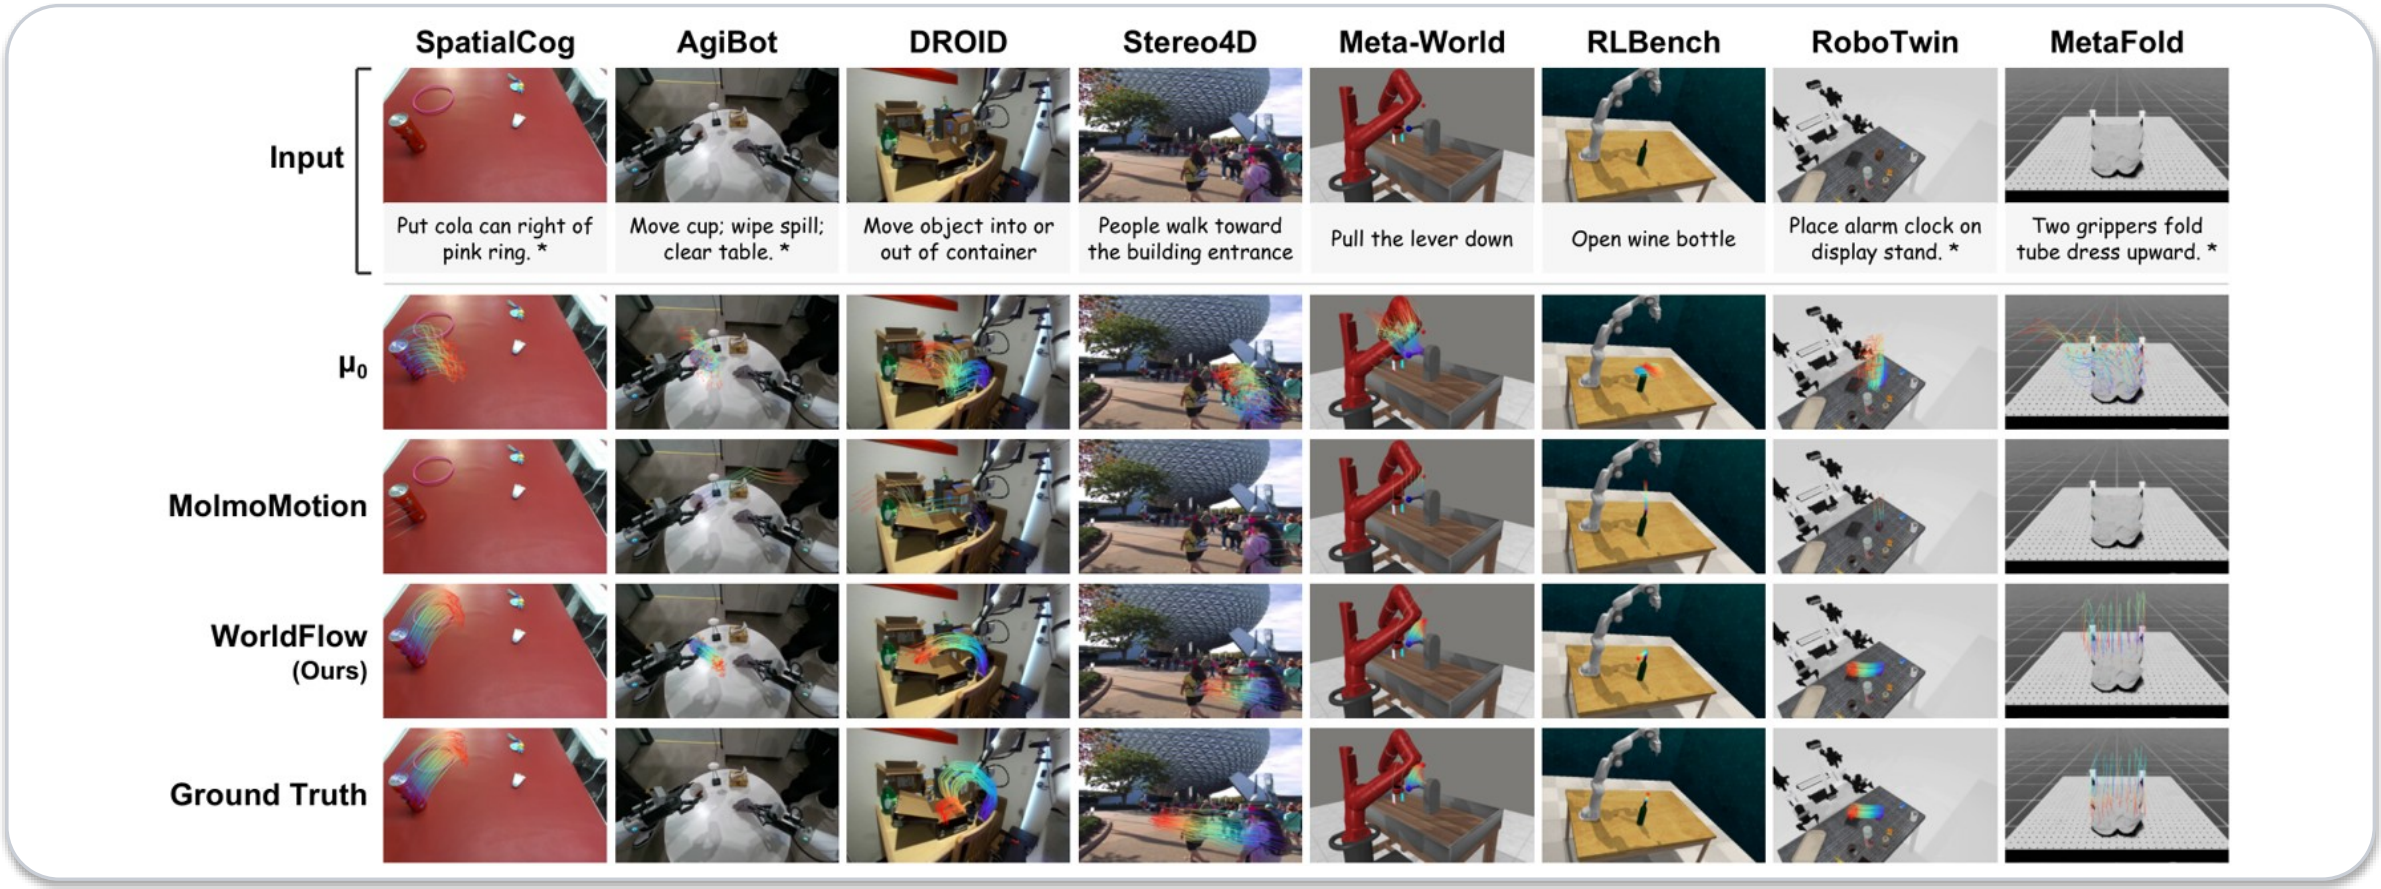

形状贴合真值

SpatialCog 绕行放置、 Meta-World 拉杆、 MetaFold 折裙等，轨迹与真值高度相似

基线常见失败

μ0 轨迹发散成团； MolmoMotion 常近乎静止或方向错误

仍有短板

Stereo4D 行人长距离位移被明显低估； DROID 弧线幅度有偏

出处：论文 Fig. 3 （轨迹投影到输入帧）

真机实验：仅替换 flow 预测器，执行成功率 66.7% vs 11.1%

97.2%

flow 预测合理率（35/36）

μ0： 25.0%（9/36）

66.7%

真机执行成功率（24/36）

μ0： 11.1%（4/36）

执行流程

Qwen 定位目标 → 物体点云作查询点 → WorldFlow 预测轨迹 → T(R,O) Grasp 抓取 → 局部刚体拟合生成手臂轨迹

按任务组统计的真机执行成功率（每组 4 个任务 × 3 次）

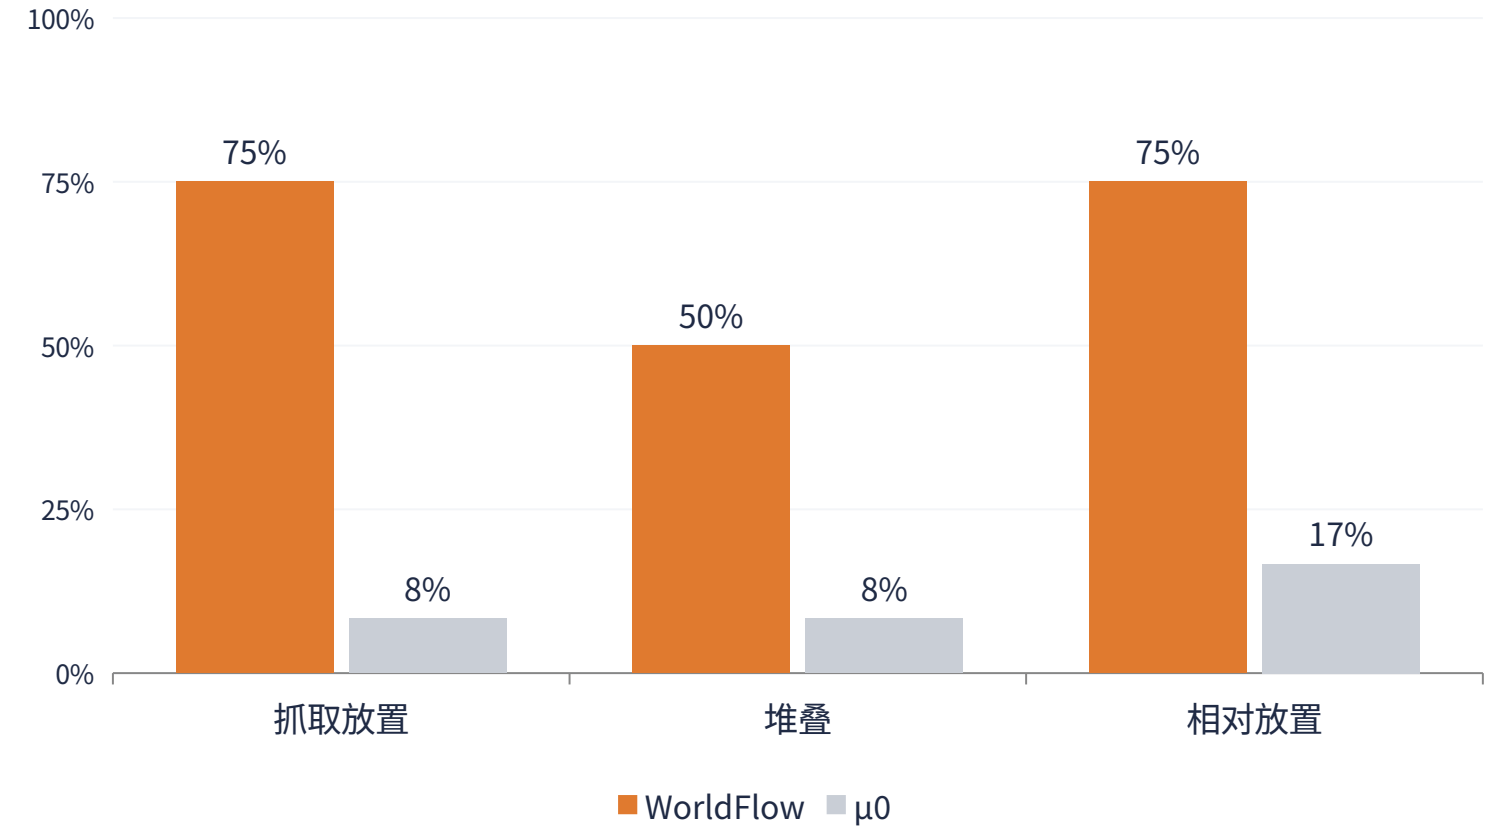

WorldFlow 的“预测合理”与“执行成功”相差约 30 个百分点，主要来自抓取失败、轨迹优化失败和堆叠放置不稳。

出处：论文 §4.4、表 2（12 个任务 × 3 次 = 36 次 / 方法）

需谨慎解读：真实场景子集上，“一动不动”反而更准

Static （零运动） vs WorldFlow

指标	Static	WorldFlow
Real3 ADE ↓	**0.062**	0.081
Real3 FDE ↓	**0.086**	0.113
Real3 PWT ↑	**0.464**	0.311
Sim7 PWT ↑	**0.573**	0.564
SpatialCog ADE ↓	0.143	**0.060**

红色： Static 更优。 Real3 上所有学习方法（含 WorldFlow ）都没超过零运动参考；论文将 Static 排除在排名之外。 SpatialCog 上 WorldFlow 则明显优于 Static 。

SpatialCog 有域内优势

自采数据； WorldFlow 在首尾两阶段专门训练，而基线是零样本

真值来自自动跟踪

Sim7/Real3/SpatialCog 轨迹由 Track4World 提取，训练与评测同源，可能学到跟踪器偏差

尾部零位移填充多

大量短片段补帧至 49 帧，可能使模型倾向低估后期运动

真机证据有限

36 次试验、仅对比 μ0 ； “ flow 合理”为人工判断

出处：论文表 1 、 §4 、 §5 ；评述为本解读观点

结论：把显式 3D 运动作为视频世界模型的“第二输出头”

1 表示

“点 × 帧”连续位移 token + 与视频共用的时空 RoPE，以很小改动接入预训练视频生成器

2 证据

受控消融最有说服力：联合生成视频让 ADE 降低 19.8–55.9%；直接生成 flow 优于事后跟踪

3 意义

flow 是与本体无关的运动接口，与 WAM 互补；真机执行成功率 66.7% vs 11.1%

开放问题

需预先给定查询点（作者计划自动选点） · 仅建模单一未来 · 真实开放场景中“是否动、动多少”仍难预测（Real3 不及 Static） · 与动作联合生成以服务策略学习