论文解读 · Vision-Language-Action

HiFOR

Hierarchical Foresight with Action-Guided World Grounding for Vision-Language-Action Model

让 VLA 同时看见“下一步、下一个里程碑、终点”，**并按当前动作需要挑着用**

Rongxing Ding, Hongyu Qu, Kehong Wu, Xudong Wang, Fan Zhang, Xinguang Xiang, Xiangbo Shu

南京理工大学 · 新加坡国立大学 · 中科院沈阳自动化所 · 香港中文大学

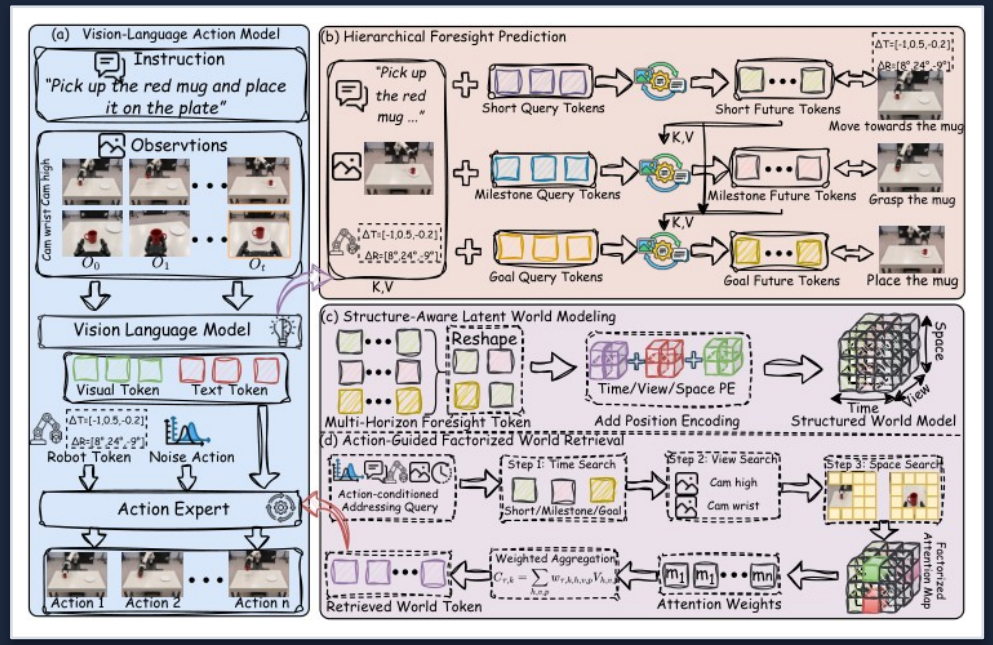

图： HiFOR 整体框架（论文 Fig. 2）

arXiv:2610.40373 · 2026-10-29 首次提交

一句话总结：多视野预见 + 按需检索，在 π0.5 之上稳定提升

HiFOR 在 DINOv2 特征空间同时预测 **短期状态** / **下一个语义里程碑** / **最终目标**，用分层依赖掩码串起来；再把预测组织成 **视野 × 视角 × 空间** 的结构化潜在世界，由动作专家在**每个去噪步**按需分解式检索，指导动作生成。

49.40%

RoboTwin 2.0 Hard

π0.5 † 40.35% → +9.05

98.3%

LIBERO 四套件平均

π0.5 96.9% → +1.4

+3.4

LIBERO-Long 提升（点）

92.4% → 95.8%

81.7%

真机 6 任务平均

π0.5 70.7% → +11.0

† π0.5 为作者复现结果；真机基线 70.7% 由 Fig. 4 六任务数值平均得到。

现有预见式 VLA 的两个短板：只看一个时间尺度、预测不加区分地喂给策略

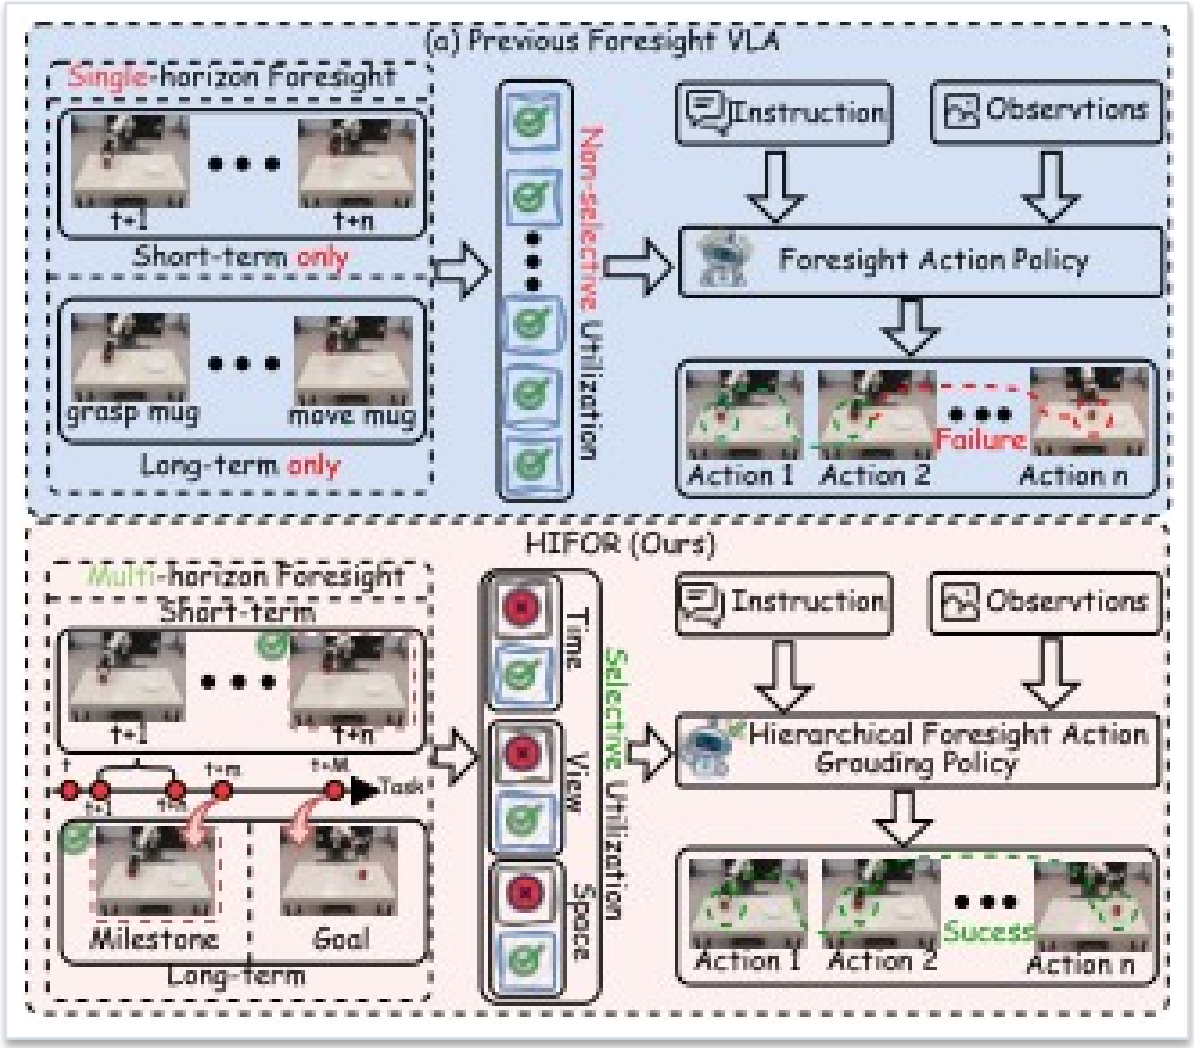

短板 ① 时间尺度割裂

短期预测只刻画局部运动；长期预测（子任务 / 子目标图）缺少连续动力学。两者独立建模，缺乏 局部演化 → 里程碑 → 终点 的显式依赖。

→ HiFOR： 分层预见预测 + HDM

短板 ② 未来信息“一股脑”使用

预测的未来图像 / 隐特征被直接当作条件输入；不同视野、视角、空间区域的相关性不同，且随执行阶段与去噪过程变化。

→ HiFOR： 结构化潜在世界 + 动作引导检索

整体框架：在 VLA 主干上外挂“预测 → 组织 → 检索”三步

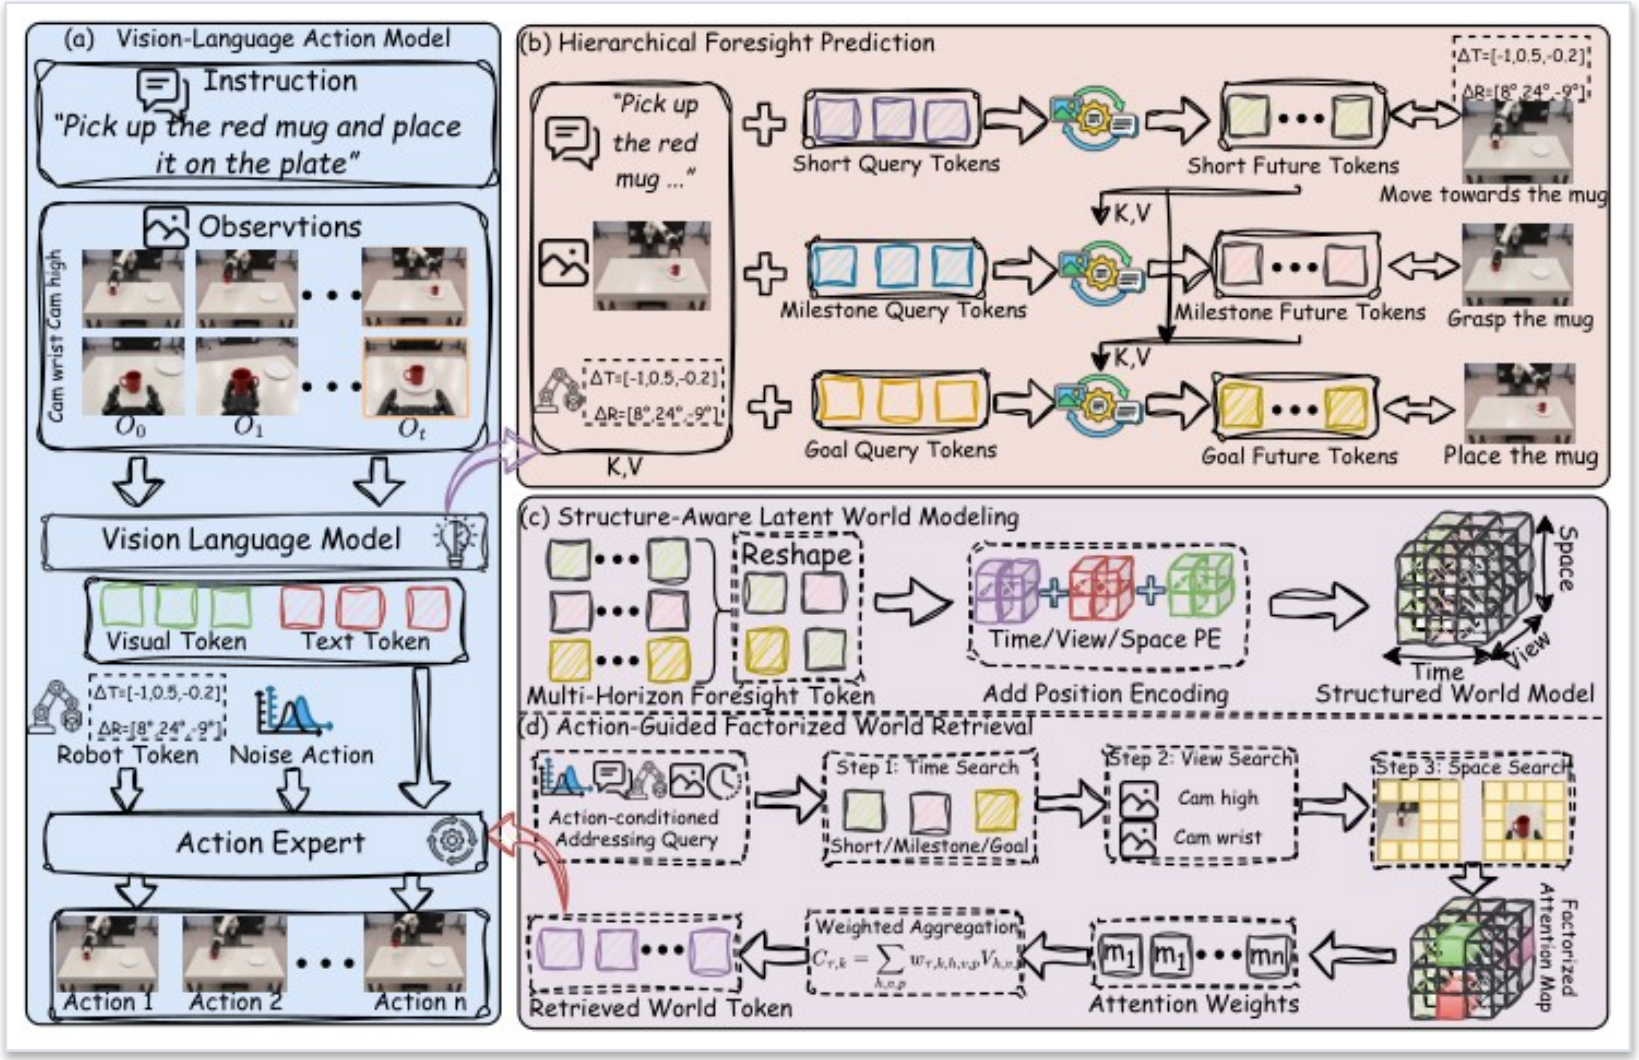

① 分层预见预测

Short / Milestone / Goal 三组 query + HDM，回归 DINOv2 特征（短期另含状态）

② 结构化潜在世界

加时间 / 视角 / 空间位置编码，得到 W ∈ ℝ^{3×V×16×d}

③ 动作引导分解检索

去噪步 τ 的动作隐状态作 query：时间 → 视角 → 空间三级注意力

L = L_ACT + L_HFP

监督从哪来：从已有成功示范中自动标注语义里程碑，不采集新轨迹

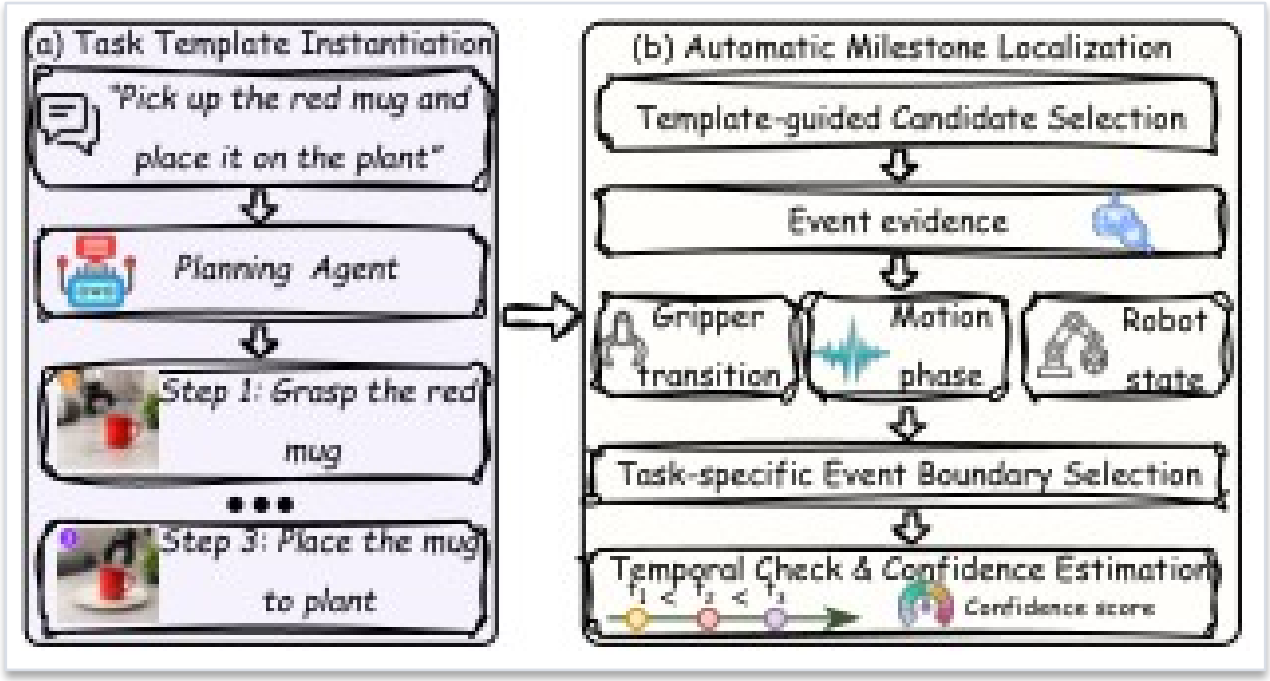

示例：“Pick up the red mug and place it on the plate” → 抓杯 / 移动 / 放置

1 **任务模板**

Planning Agent 将指令分解为有序子目标 $G_1 \ldots G_K$（阶段 / 事件类型 / 完成判据）

2 **候选边界**

夹爪开合、运动阶段、机器人状态 → 候选事件边界

3 **事件定位**

稳定态事件：条件持续满足的最早帧；动态事件：运动 / 状态转折点

4 **一致性校验**

$t_1 < t_2 < \ldots < t_K$；置信度打分，低置信样本人工复核

视觉目标：冻结 DINOv2 ViT-L/14，去掉前缀 token 后自适应池化为 4×4 网格

每视角 $F \in \mathbb{R}^{16\times1024}$，作为三种视野的预测目标

分层预见：三种视野共享预测器， HDM 让依赖单向逐级传递

三种预测目标（每个时刻 t）

$t^s = \min(t+\Delta, t_K)$ $t^m = \min_{k: t_k > t} t_k$ $t^g = t_K$

为什么短期要加状态监督?

仅凭目标时刻的视觉特征不足以约束细粒度的机器人运动，因此短期分支额外预测 $s_{t+1}\ldots s_{t^s}$。

损失： $L_{HFP} = \lambda \cdot D_{vis}(\hat{Z}, Z) + \lambda' \cdot D_{state}(\hat{S}, S)$

HDM 可见性（行 = query，列 = 可见 token）

	VLM token 视觉 + 语言	Q^s	Q^m	Q^g
Q^s 短期	✓	✓	—	—
Q^m 里程碑	✓	✓	✓	—
Q^g 目标	✓	✓	✓	✓

$U^h = H_\theta(Q^h ; [V_t ; E_L ; Q^{\leqslant h}])$

三组可学习 query 共享同一预测网络 H_θ；可见范围按 s → m → g 逐级扩大，形成从局部动力学到中间进度、再到终态的单向依赖。

结构化世界 + 分解检索：动作按“时间 → 视角 → 空间”逐级寻址未来信息

结构化潜在世界 $W_t \in \mathbb{R}^{3 \times V \times 16 \times d_w}$

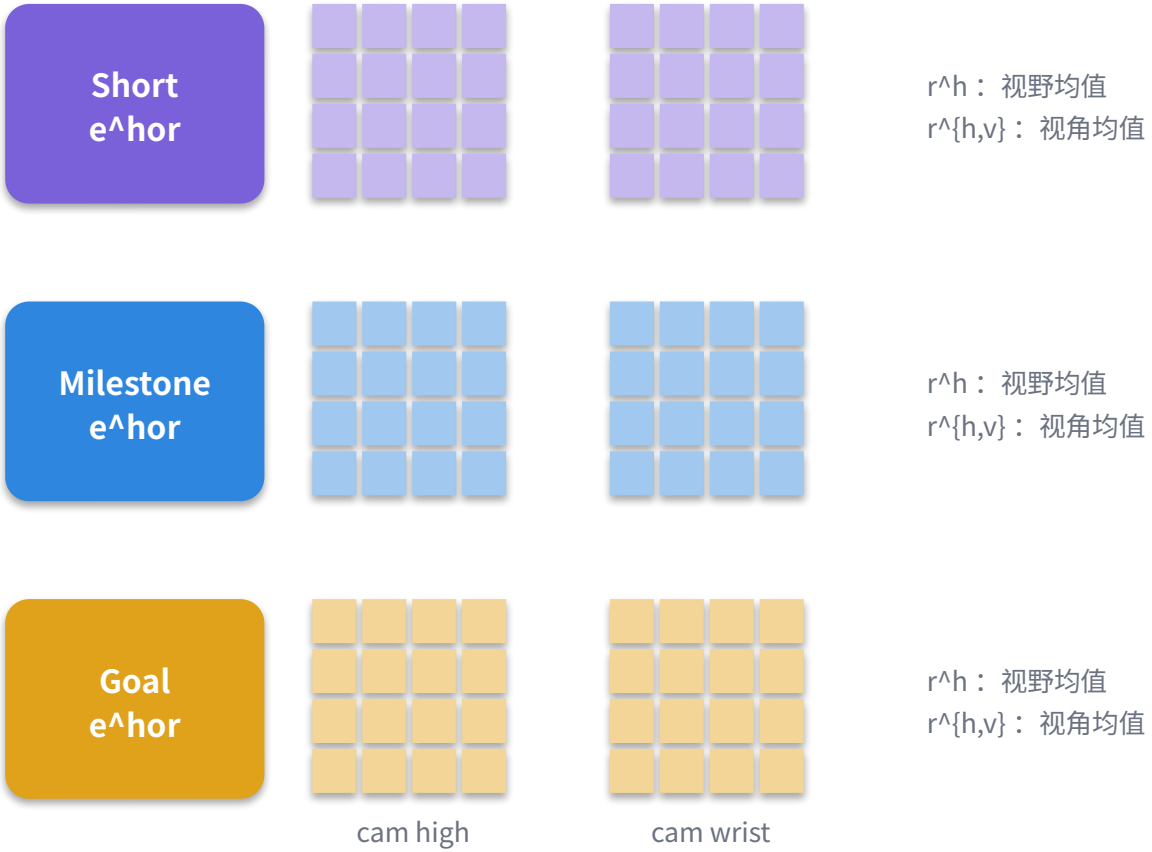

$w = P_w(\hat{Z}[h,v,p]) + e^{hor}_h + e^{view}_v + e^{spa}_p$ （每格 = 1 个空间 token）

AWR： 去噪步 τ 的动作隐状态 H^a 作为查询

Step 1 时间

$\alpha^h = \text{Softmax over } \{s, m, g\}$

key： 视野摘要 r^h

Step 2 视角

$\beta^{v|h} = \text{Softmax over } V \text{ 个视角}$

key： 视角摘要 $r^{h,v}$

Step 3 空间

$\gamma^{p|h,v} = \text{Softmax over } 16 \text{ 格}$

key： 空间 token $k^{h,v,p}$

$$f_{t,\tau} = W_O \cdot \Sigma_{h,v,p}\, \alpha^h \cdot \beta^{v|h} \cdot \gamma^{p|h,v} \cdot u^{h,v,p}$$

→ 与动作表示、短期状态特征融合，残差注入 Action Expert； query 随去噪步变化，检索结果也动态变化

RoboTwin 2.0 Hard：平均 49.40%，比最强基线 π0.5 高 9.05 个点

20 任务平均成功率（%）

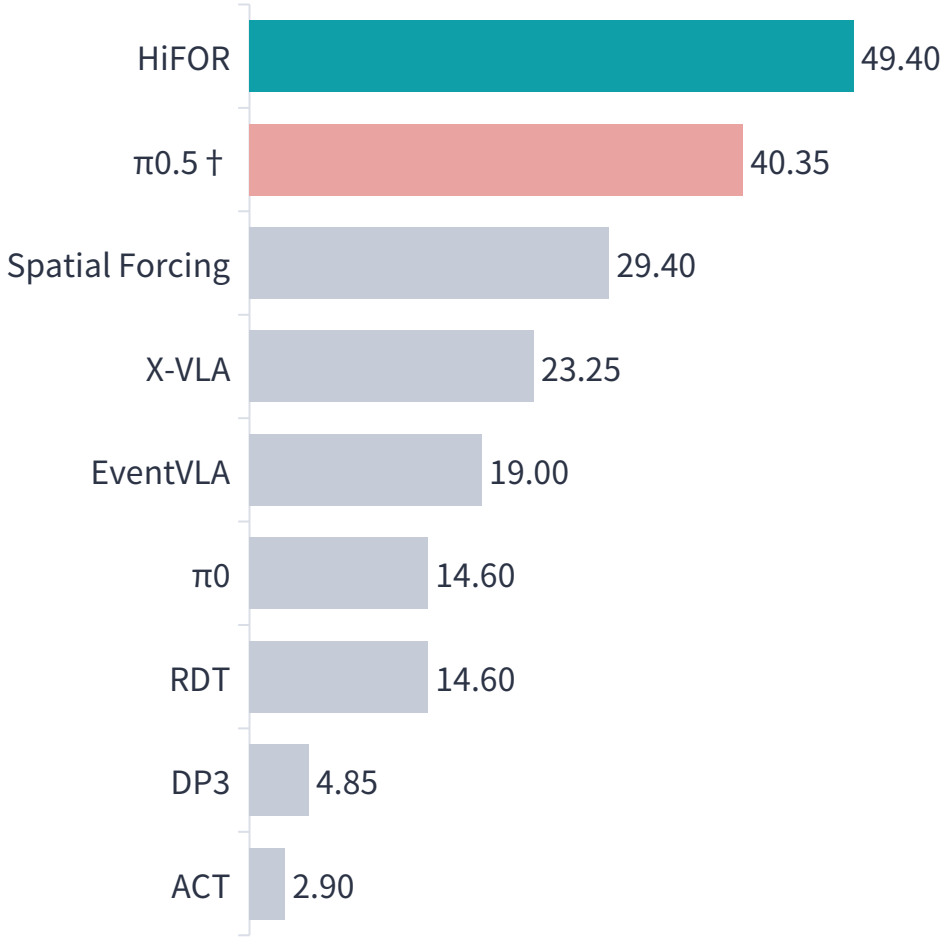

正文展示的 10 个任务（%）

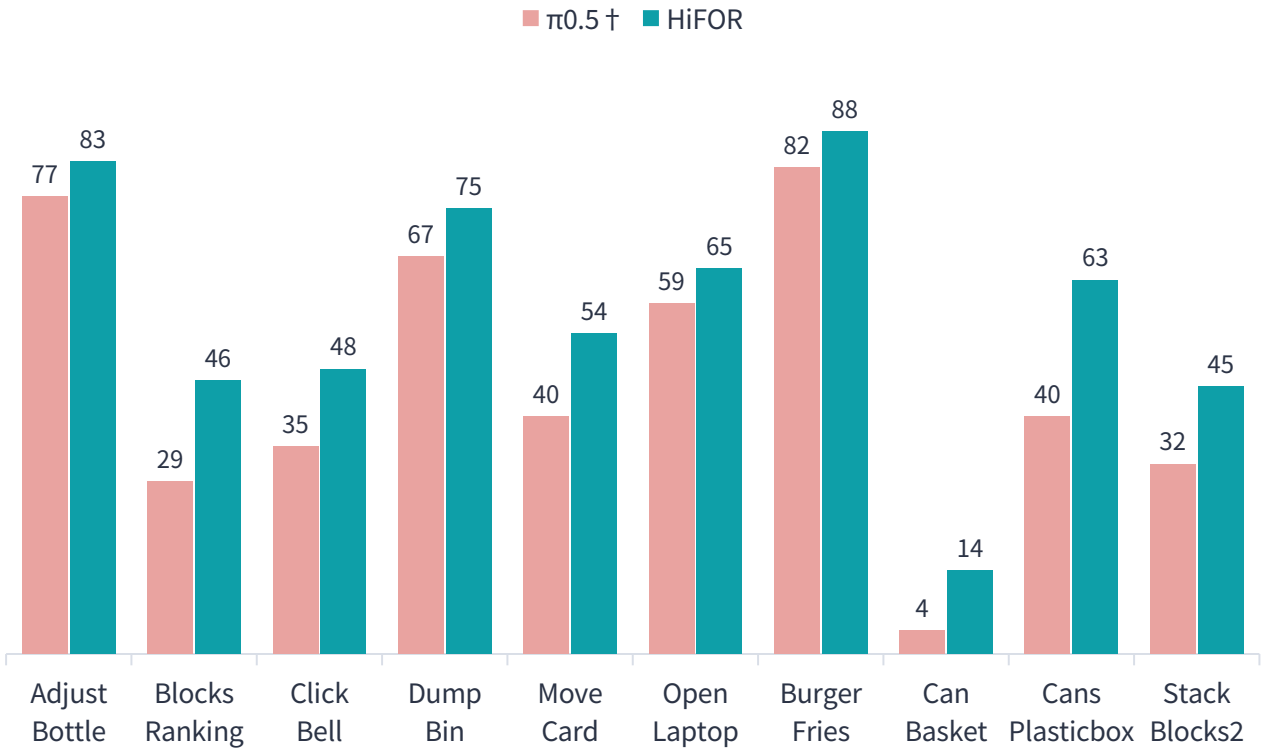

10 个展示任务全部提升；最大增益： Cans Plasticbox +23 、 Blocks Ranking +17 、 Move Card +14 、 Stack Blocks +13 。

Can Basket 仍仅 14%，困难任务仍未解决。

LIBERO：平均 98.3% 登顶，增益主要来自长时程套件（+3.4）

方法	Spatial	Object	Goal	Long	Avg.
OpenVLA-OFT	97.6	98.4	97.9	94.5	97.1
MemoryVLA	98.4	98.4	96.4	93.4	96.7
π0	96.8	98.8	95.8	85.2	94.2
π0.5 （基线）	98.8	98.2	98.0	92.4	96.9
VLA-Adapter	97.8	99.2	97.2	95.0	97.3
LEAP-VLA	98.4	**99.4**	97.6	93.0	97.1
HiFOR （Ours）	**99.4**	**99.2**	**98.6**	**95.8**	**98.3**

节选自 Table 2；青色加粗 = 该列最高。

LIBERO-Long （vs π0.5）

92.4 → **95.8**

+3.4 个点，四个套件中增益最大

解读

平均 96.9 → 98.3 （+1.4）。LIBERO 已接近饱和，与次优方法差距约 1 个点，且未报告多种子方差；长时程增益更能说明问题。

真机 6 任务：全部超过 π0.5，平均 81.7%（+11.0），堆积木任务 +16

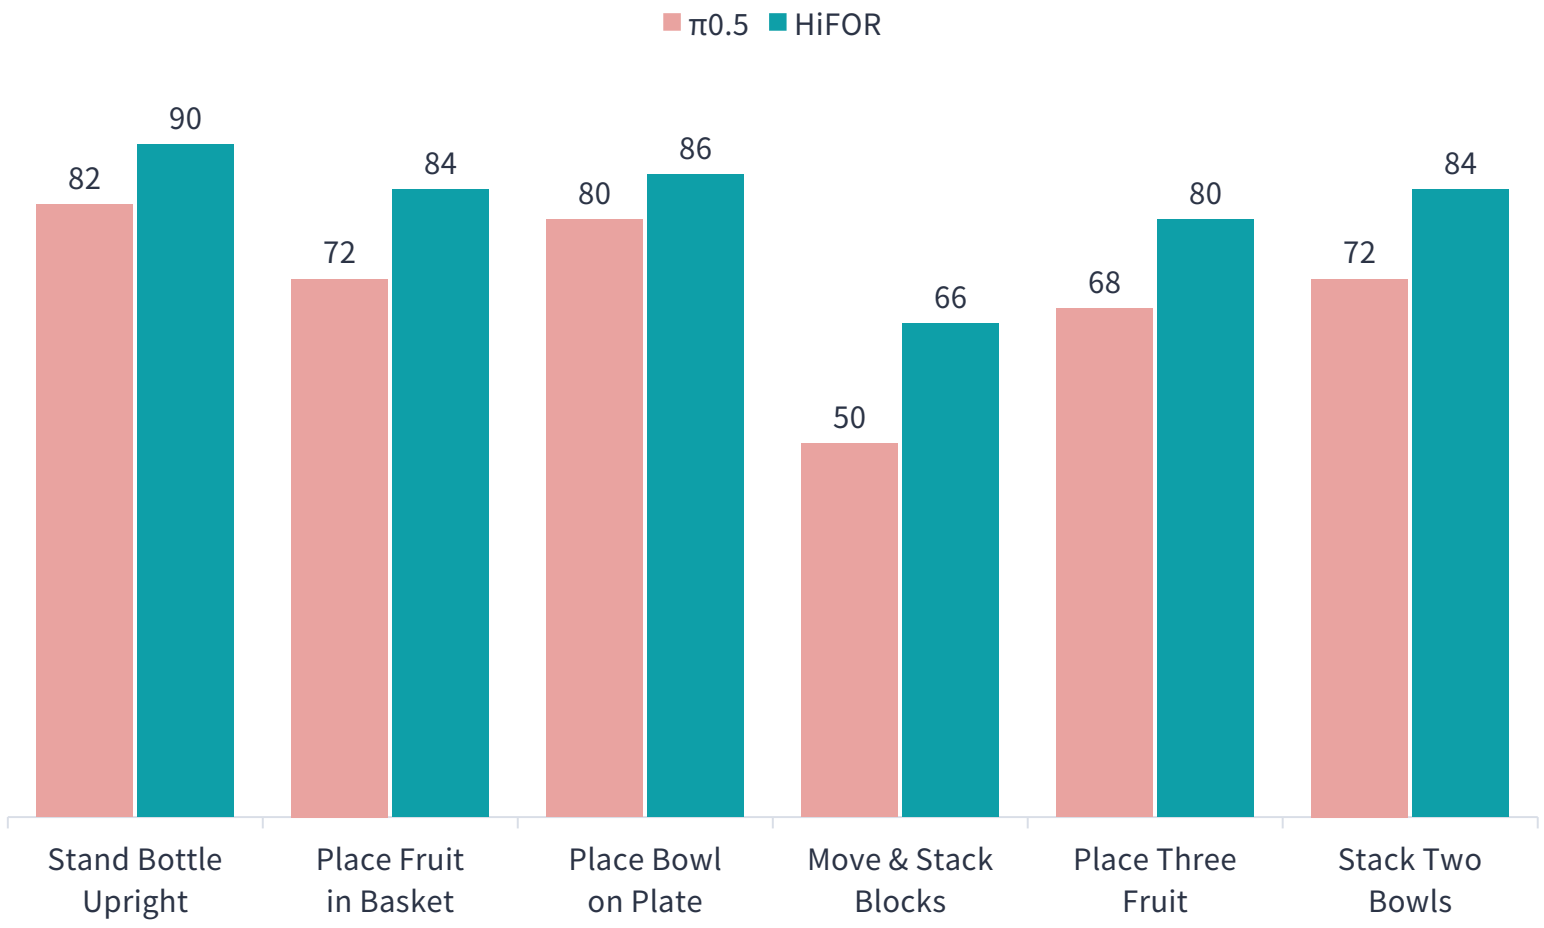

泛化任务（100 条示范 / 任务）　　长时程任务（200 条示范 / 任务）

81.7%
6 任务平均（π0.5 70.7%）

+16
Move & Stack Blocks： 50 → 66

实验设置
AgileX Piper 6-DoF 单臂 + 平行夹爪
腕部 + 第三人称 2× D435i
每任务 50 次，物体位置随机
训练 8×H200，部署 1×RTX 4090

组件消融：每加一层预见都有增益，短期预测与 AWR 贡献最大

RoboTwin 2.0 Hard 平均成功率（%）

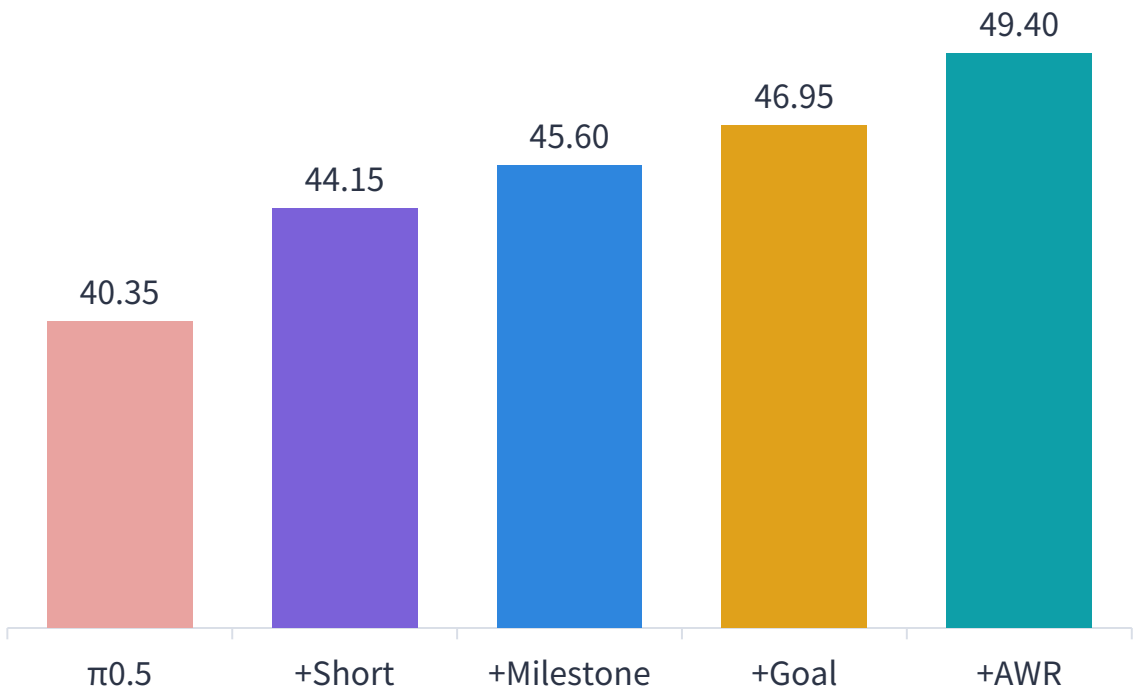

LIBERO-Long 成功率（%）

下方卡片 = RoboTwin 每步增量；纵轴未从 0 开始

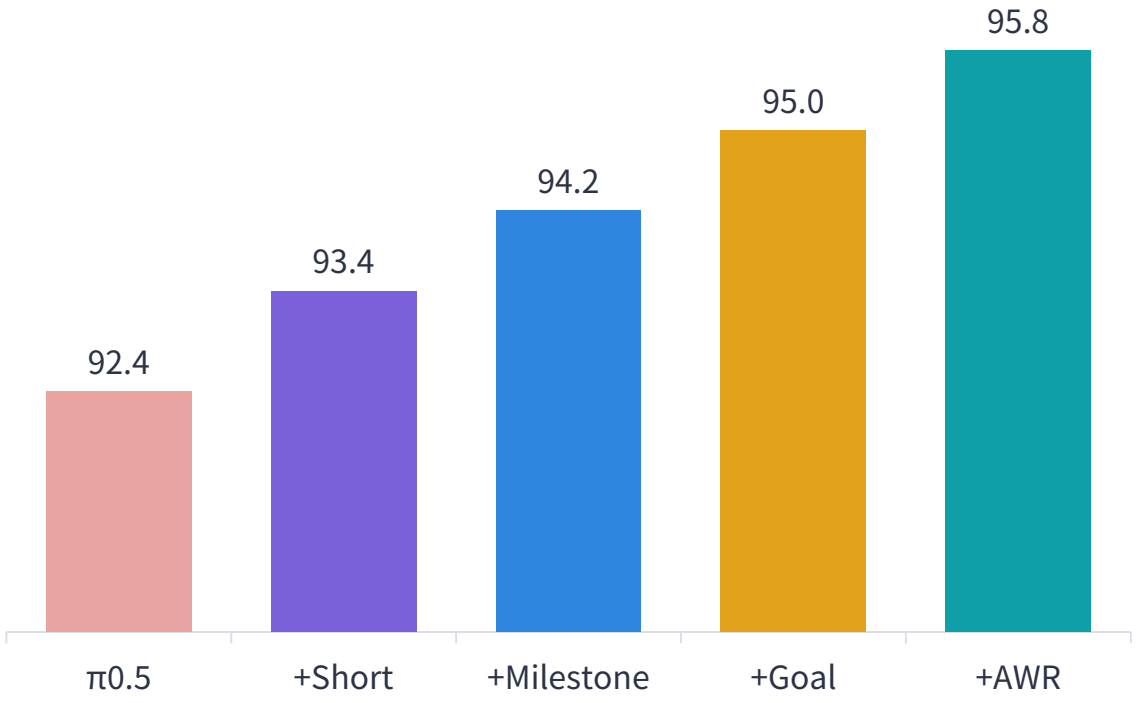

+3.80 +Short

+1.45 +Milestone

+1.35 +Goal

+2.45 +AWR

两个设计选择：短期视野与执行周期对齐最好；预测语义特征优于预测像素

① 短期预测长度 Δ

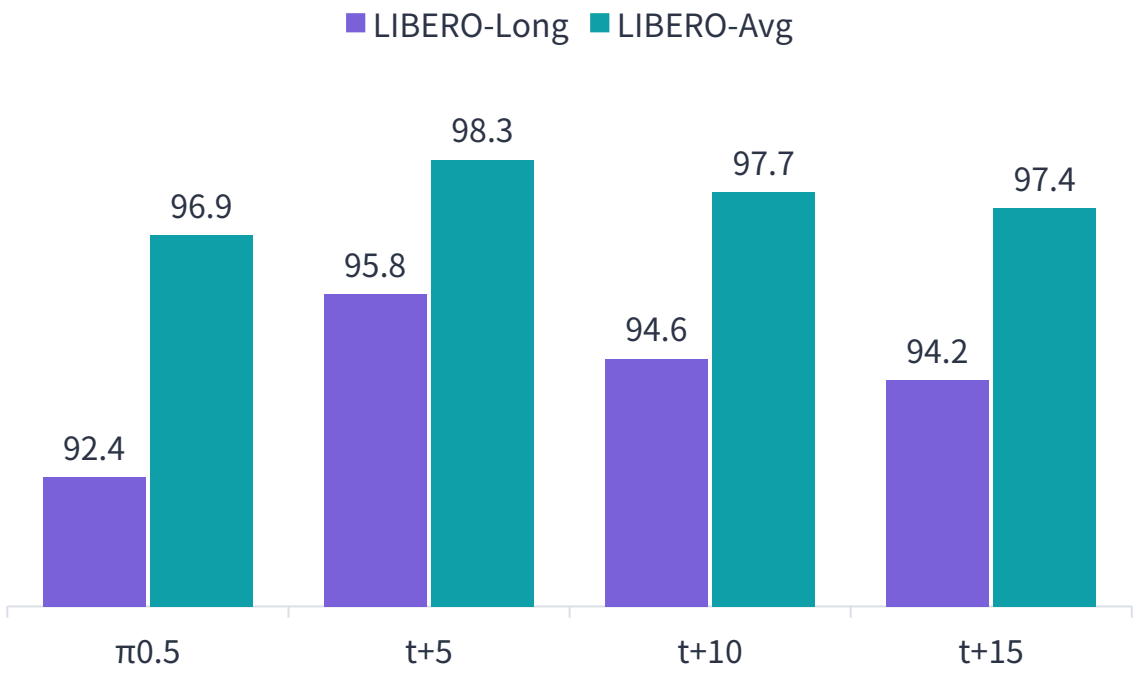

② 预测目标的表示

注：纵轴从 90 开始

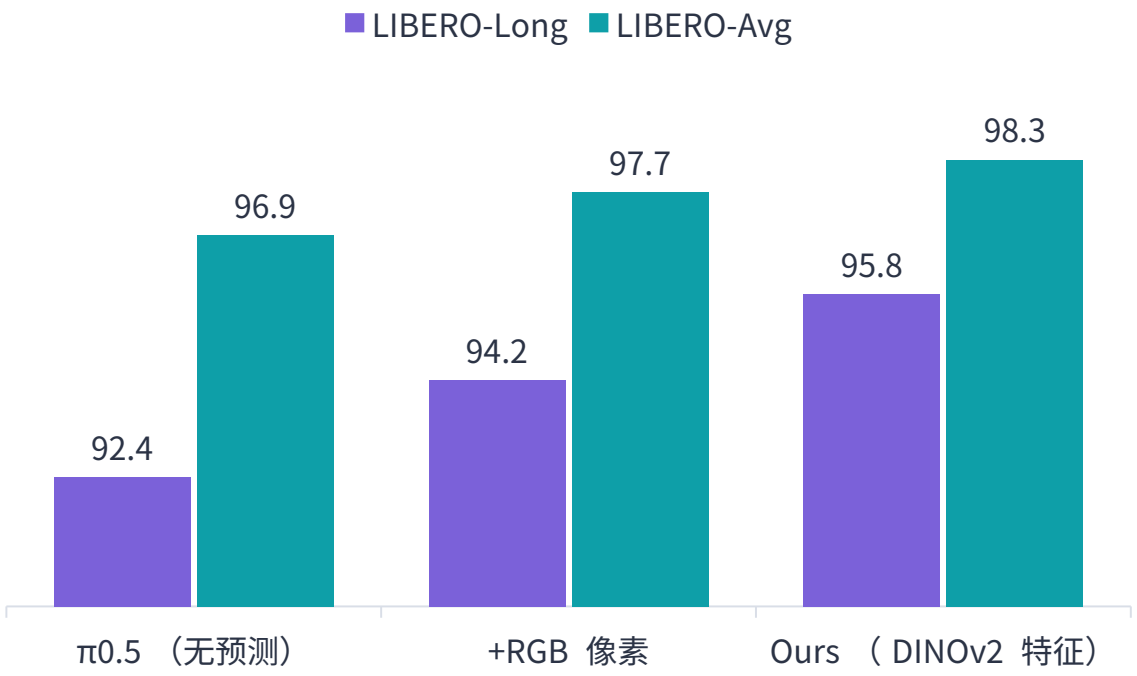

Δ = 5 最佳： LIBERO 每 5 步重新预测一次，短期视野与动作执行周期对齐；更长视野越过了下一次更新。

语义特征 > 像素： Long 比 RGB 预测高 1.6、平均高 0.6 个点；预见本身有效，特征空间更适合作动作指导。

可视化：检索注意力随任务阶段切换——开炉看里程碑、抓取看短期、放置看目标

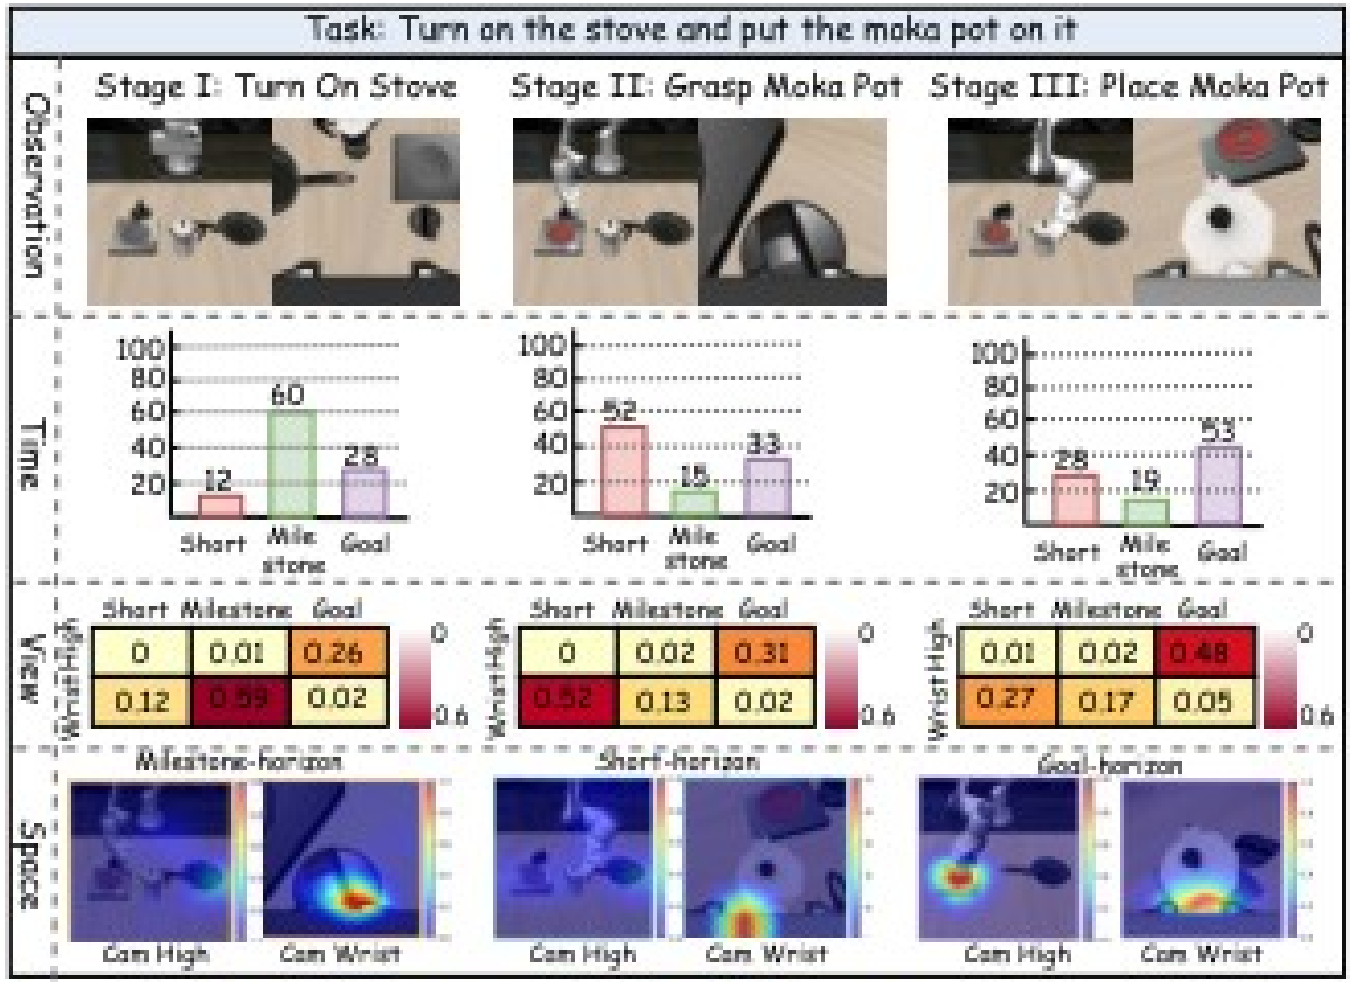

Stage I　打开炉子　60% 里程碑

偏腕部视角，聚焦炉子旋钮

Stage II　抓取摩卡壶　52% 短期

腕部视角，关注局部操作细节

Stage III　放置摩卡壶　53% 目标

第三人称视角，突出放置区域

■ 短期 ■ 里程碑 ■ 目标　（时间注意力 %）

评价：思路清晰、长时程收益明显，但关键设计的独立贡献证据不足

亮点

问题 ↔ 设计一一对应

时间尺度割裂 → 分层预见 + HDM ； 不加区分 → 动作引导检索

监督成本低

里程碑自动标注；视觉目标为冻结 DINOv2 特征，无需像素生成

长时程收益明显

RoboTwin Hard +9.05 ； LIBERO-Long +3.4 ； 真机堆叠 +16

可解释

分解注意力直接读出“看哪个视野 / 视角 / 区域”

局限与疑问

消融不充分

缺少 去掉 HDM 、扁平 cross-attention 、固定 query 的对照

统计与覆盖

无多种子方差； RoboTwin 只评测 20 个任务；真机只比 π0.5

标注可推广性

依赖夹爪等启发式 + 人工复核，比例未报告

效率与细节

未报告推理延迟 / 参数量；式 (6) 记号、 Table 2 数值存疑

Take-aways

01

预见要分层

短期动力学、语义里程碑、最终目标联合预测，并用单向掩码建立依赖，长时程任务受益最大。

02

预见要按需使用

把预测组织成 时间 × 视角 × 空间 的结构化世界，由去噪中的动作状态逐级检索，而非直接拼接。

03

语义特征是好的预测目标

DINOv2 特征优于 RGB 像素，监督可从已有示范自动构建，成本低。

一句话： HiFOR 是把世界模型式预见融入 VLA 的扎实增量工作——效果稳定，但关键设计的独立贡献、效率与泛化边界仍待验证。