论文解读 · arXiv 2610.40636

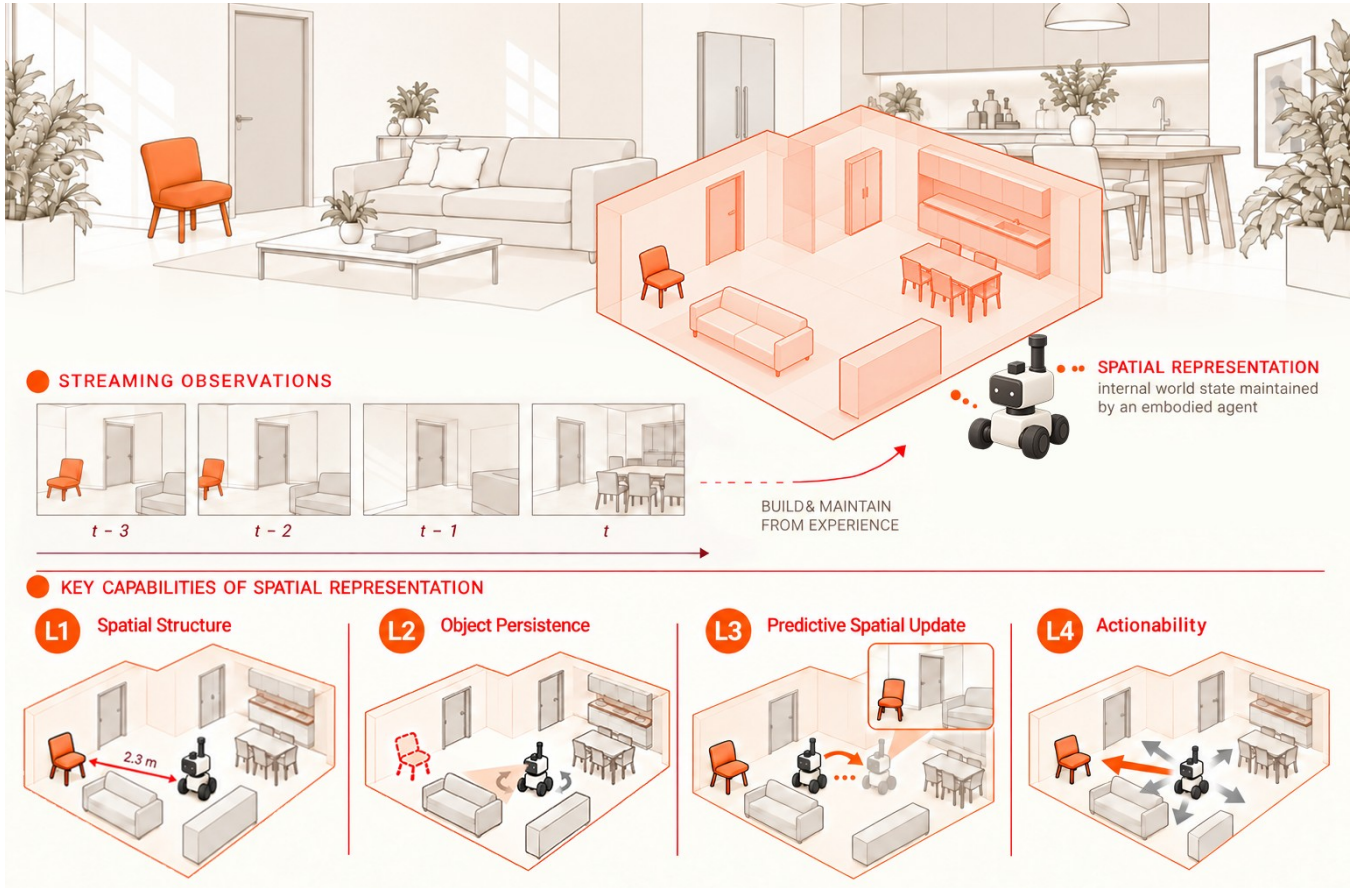
Probing Spatial State Representations in Visual Foundation Models

视觉基础模型里，有没有一个“会记、会推、会用”的空间状态?

Baiqiao Yin, Zhongang Cai, Ruisi Wang, Qiwei Liang, Lei Yang, Ziwei Liu

NYU · NTU · HKUST · CUHK

首次提交： 2026-10-29



图源：论文 Figure 1 （流式第一人称观测与四层空间能力）

核心结论

一句话：能读出 ≠ 会用上 ≠ 真有用

用冻结特征探针在 ScanNet++ 流式第一人称视频上测试 10 个视觉基础模型的四层空间能力：没有模型全面领先，且“可解码 / 输入被使用 / 对目标有功能性帮助”三者相互分离。

可解码

Decodability

VideoMAE 定位误差 36.5°，远好于 DINOv2 的 65.4°，尽管后者的深度 / 实例 / 视角读出都更强

输入使用

Input use

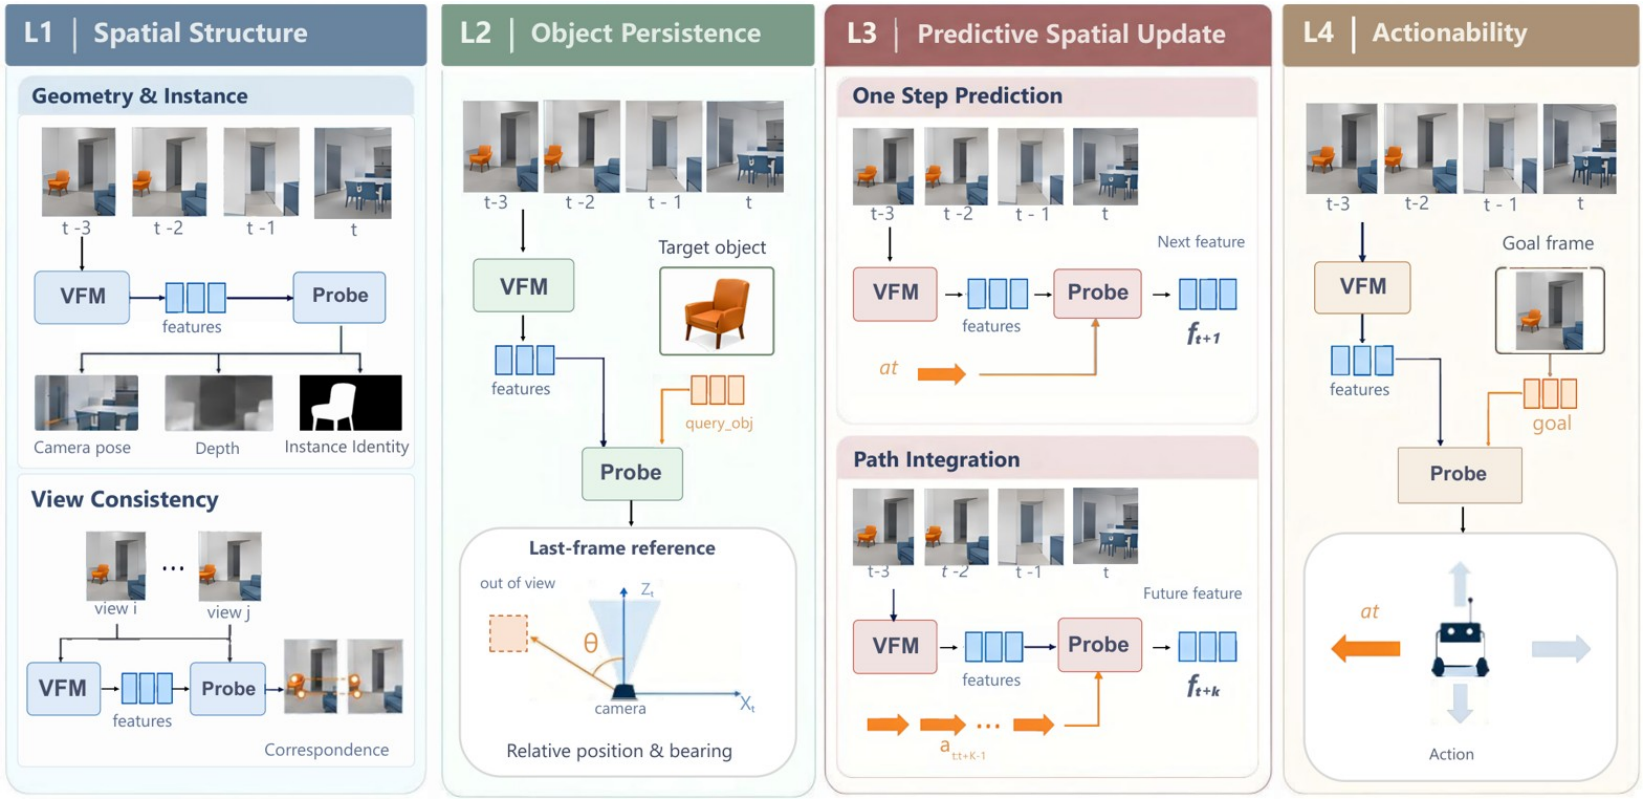
VideoMAE 定位最准，却看不出从历史帧获益（+2.1°，区间跨 0）；V-JEPA2 上“复制最后一帧”胜过学习到的预测

功能效用

Functional utility

换目标会让预测动作偏转 30–46°，但正确目标对进展的影响在 −2.3~+1.2pp，区间均含 0

把“空间状态”拆成四个逐级递进的功能层级



L1 空间结构

只读当前可见场景

L2 物体持久性

+ 保留更早视角的信息

L3 预测性更新

+ 预测尚未看到的画面

L4 可行动性

+ 把状态和目标、动作联系起来

实验设定

10 个冻结表征 × 因果流式前缀 × 浅层探针

图像编码器	DINOv2-L	
视频编码器	V-JEPA2 ViT-L	VideoMAE-L
3D 编码器	Fast3R ViT-L	
多模态	Qwen2.5-VL-7B	
视频生成器	Wan2.1-1.3B	CogVideoX-5B
	MiniMax-H3	LingBot-video
世界模型	AetherV1	

$p \in \{8,12,16,24\}$

因果前缀长度，每个前缀独立编码

69 场景

验证集，与训练场景不重叠；1,000 次场景级配对 bootstrap

276 窗口 / 前缀

主表评估规模； direct/path 检索库 828 个候选

7 项测量

6 个主诊断（几何拆为深度 + 位姿）； L4 另有两种设定

骨干全部冻结，只训练浅层探针；主表固定在指定层、对前缀取平均，不做事后挑选最佳层。

主结果 • L1–L3

没有任何模型在所有空间任务上领先

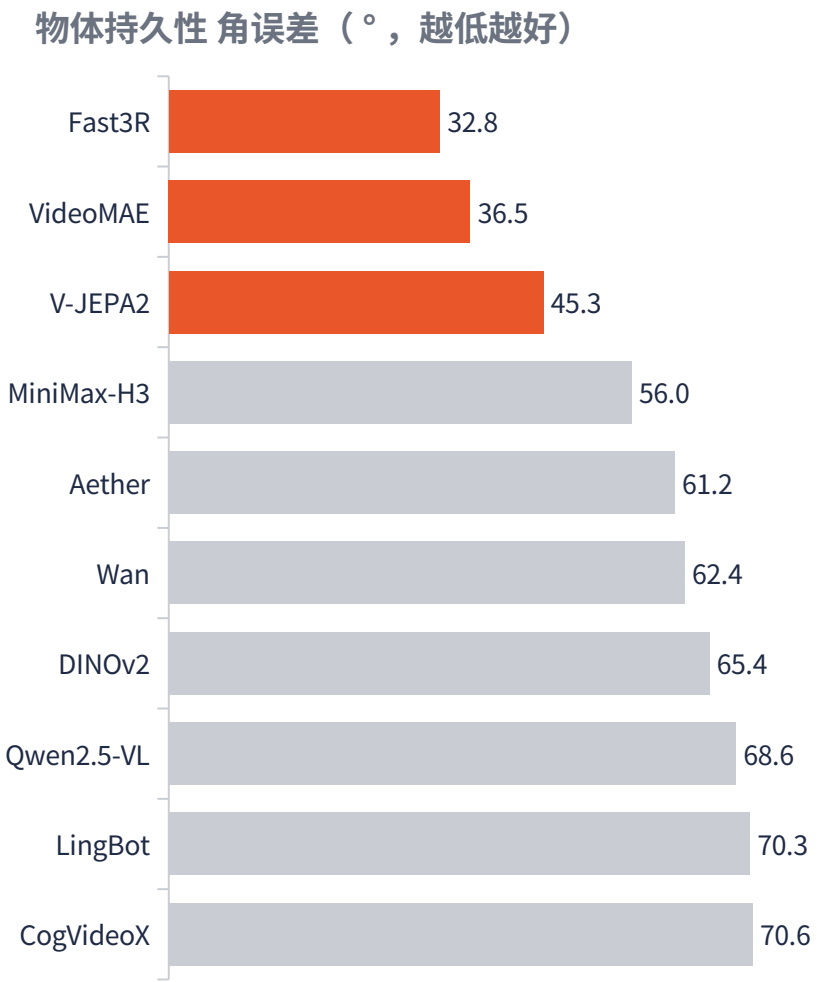
模型（层）	深度损失↓	位姿 AUC@30↑	实例损失↓	视角一致↑	持久性误差°↓	Direct R@1↑	Path R@1↑
DINOv2-L (0)	**0.1422**	0.0412	**1.3828**	0.9557	65.38	**0.2373**	0.0900
Fast3R (24)	**0.1386**	**0.3870**	1.6072	**0.9808**	**32.79**	0.0133	0.0190
VideoMAE-L (23)	0.2968	0.2026	4.1571	0.9118	36.45	0.0531	0.0685
V-JEPA2-L (23)	0.2708	0.1854	2.9211	0.9256	45.31	0.0625	**0.1588**
Qwen2.5-VL (−1)	0.2244	0.0269	2.9476	0.9385	68.59	0.1712	0.0903
Wan (20)	0.3609	0.0650	4.9301	0.8215	62.38	0.0260	0.0405
CogVideoX (20)	0.4340	0.0276	6.6992	0.8001	70.62	0.0088	0.0160
Aether (1)	0.5270	0.0185	7.1847	0.6928	61.18	0.0024	0.0042
MiniMax-H3 (30)	0.4252	0.0477	6.2265	0.8255	55.97	0.0249 †	0.0117 †
LingBot-video (30)	0.4314	0.0232	5.5875	0.7858	70.30	0.0302	0.0429

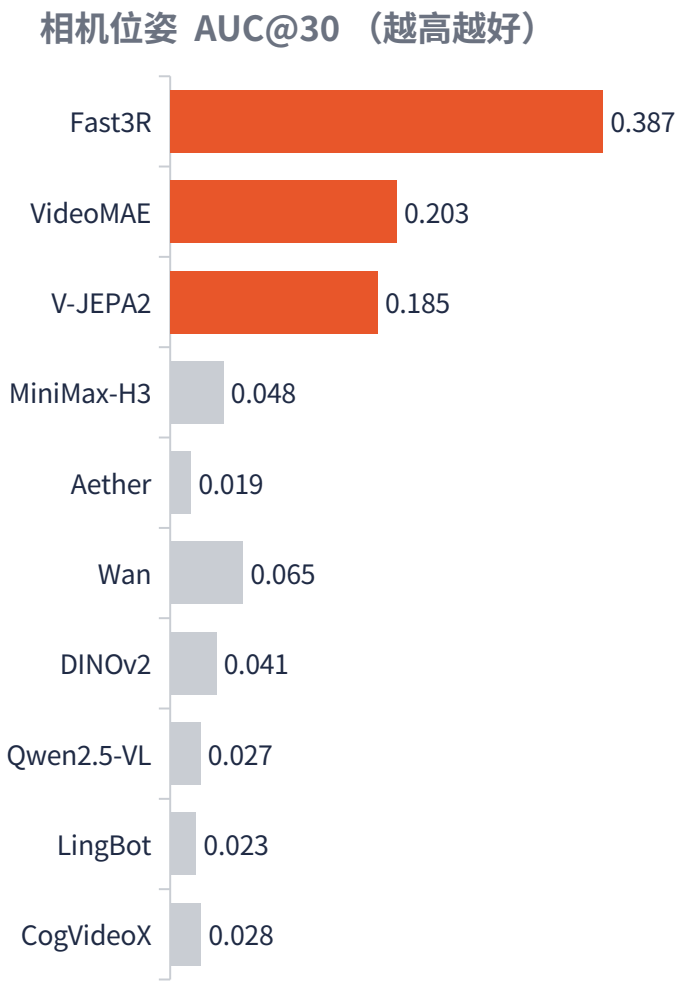
† MiniMax-H3 预测仅在 171/276 窗口上评估，直接预测只用下一帧目标，不参与排名。

Fast3R 领跑位姿与持久性，却在特征预测上几乎垫底； DINOv2 领跑直接预测， V-JEPA2 领跑路径积分。

L2 ← L1

物体持久性跟随相机位姿读出，而不是可见场景读出





ρ = 0.76

持久性 vs 相机位姿（10 个模型）

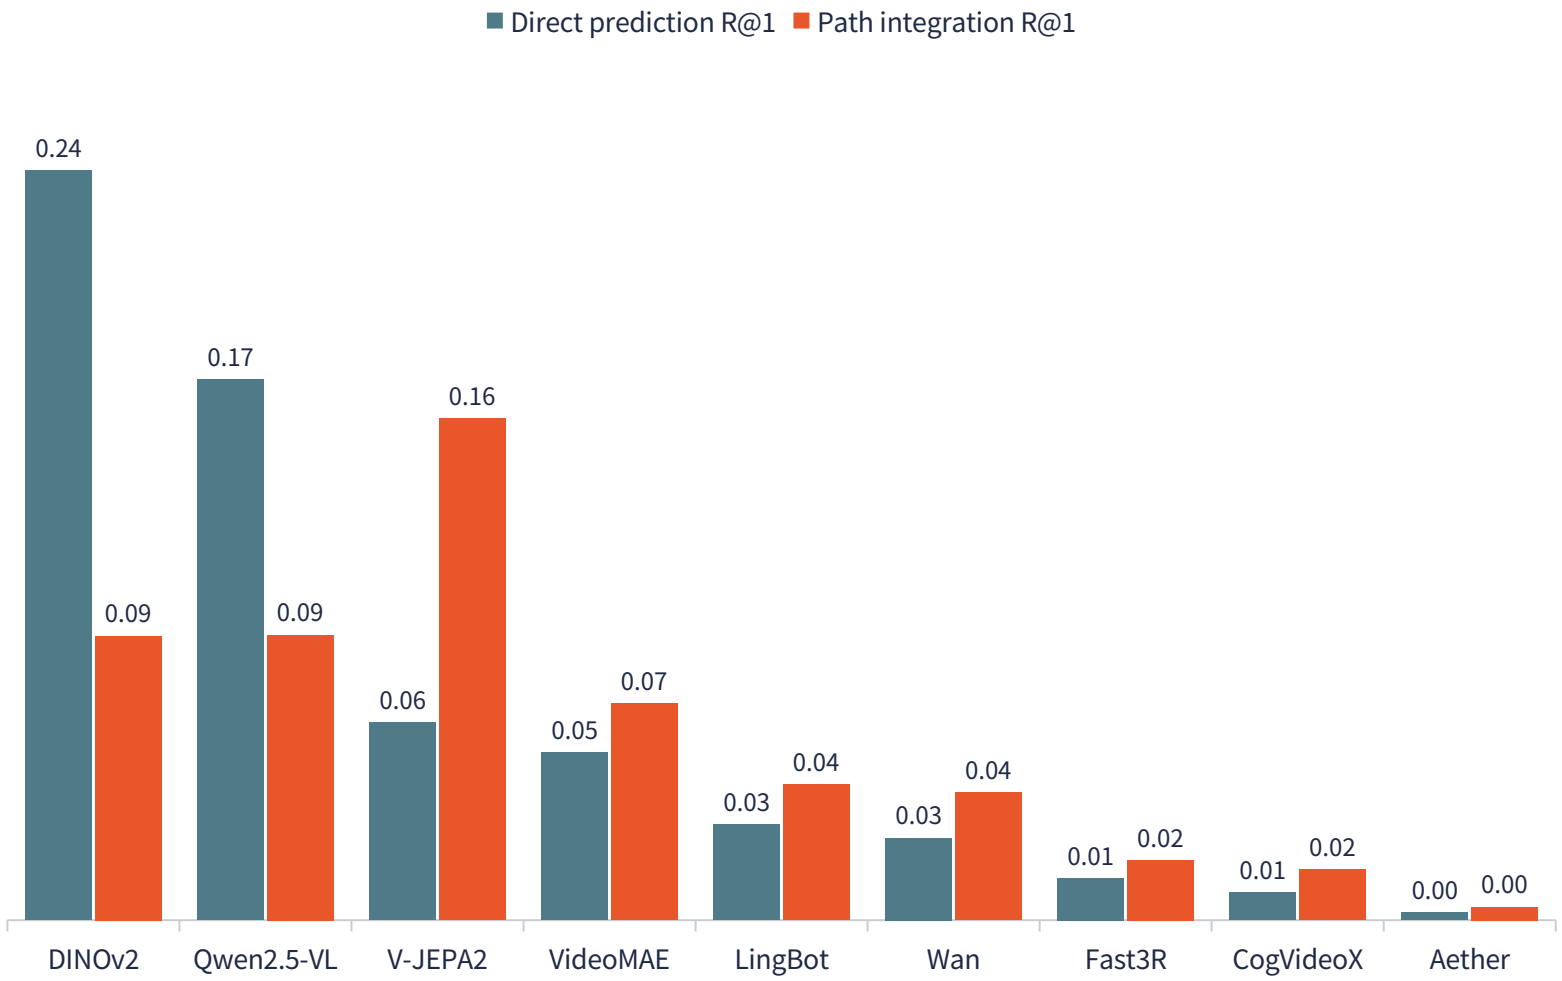
ρ ⩽ 0.43

持久性 vs 深度 / 实例 / 视角

定位视野外的物体，需要把当前相机和更早的视角联系起来；四个多层骨干中，持久性与几何在同一层达峰。

L3

特征预测的排序与持久性完全无关



ρ = 0.93

Direct 与 Path 的模型排序

|ρ| < 0.1

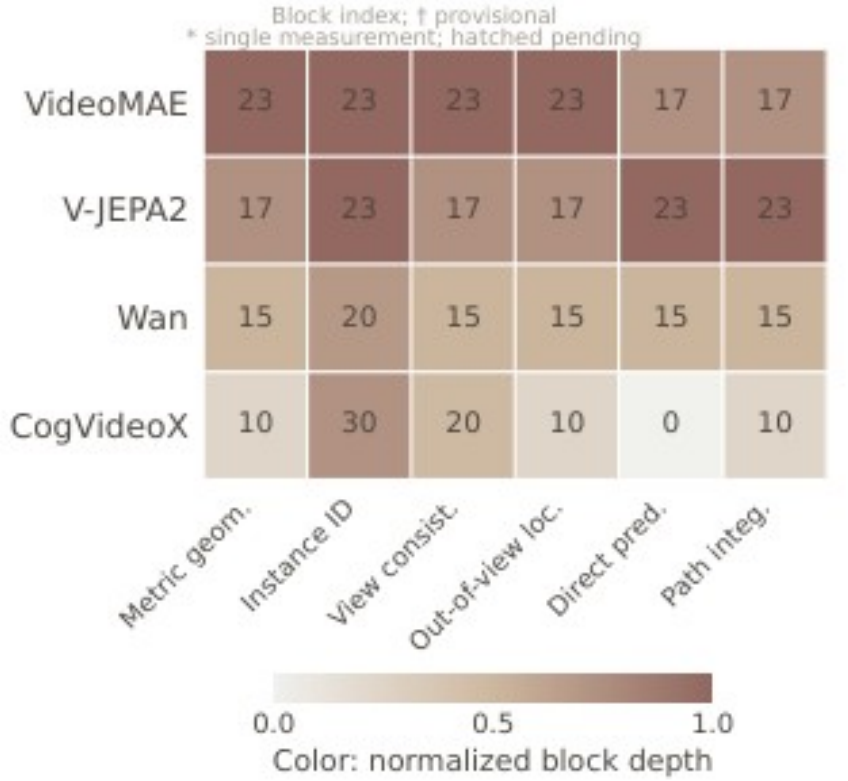
两种预测 vs 物体持久性

第 8 / 第 7

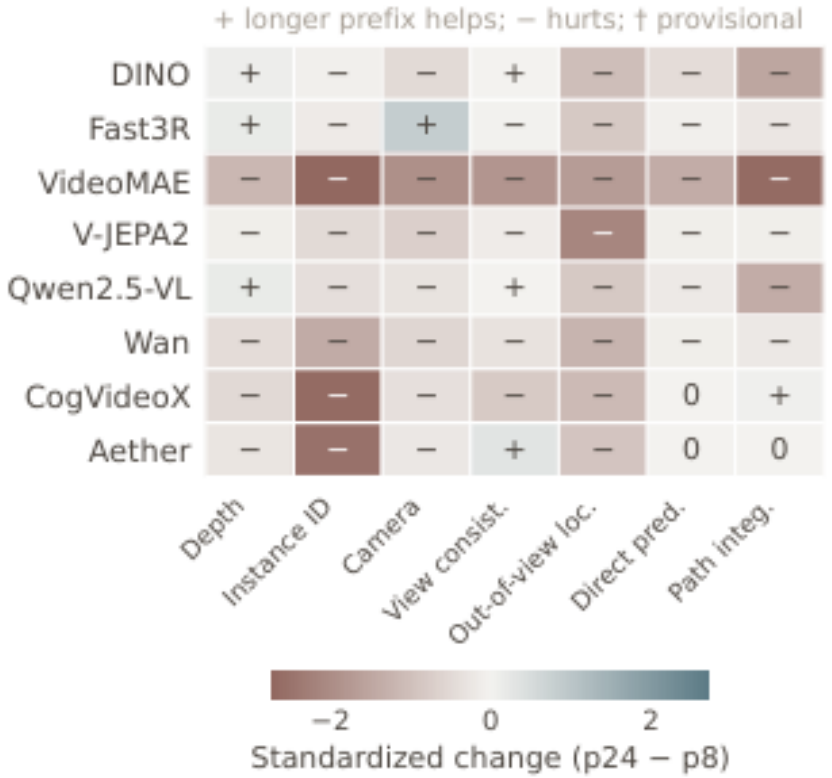
Fast3R 在 Direct / Path 上的名次（L1 几乎全最好）

R@1 在各模型自己的特征空间内检索，跨模型只比较排序。

提取层与前缀长度都会改写结论



(a) 各任务的最佳层（颜色 = 归一化深度）



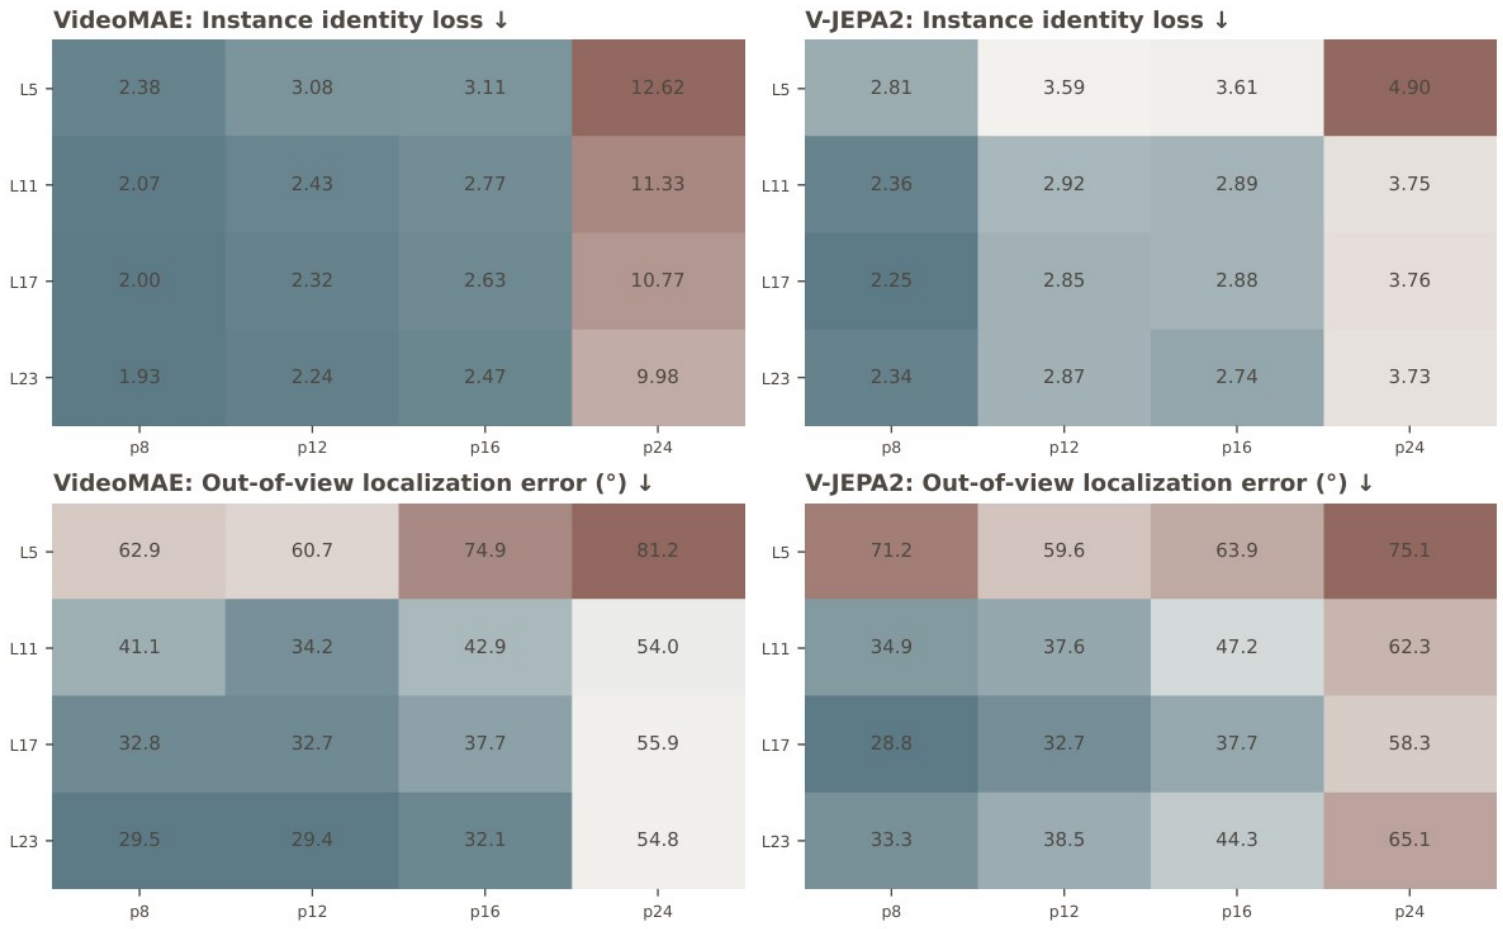
(b) p24 − p8 标准化差异（− 表示短前缀更好）

28.8° V-JEPA2 （L17, p8）定位误差，低于 VideoMAE 最好值 29.4°

45 / 56 个模型 × 指标配对偏好更短的 p8

8 / 8 个模型的持久性在 p24 显著变差

VideoMAE 到 p24 突然崩塌，V-JEPA2 则逐步退化



29.6° → 54.8°

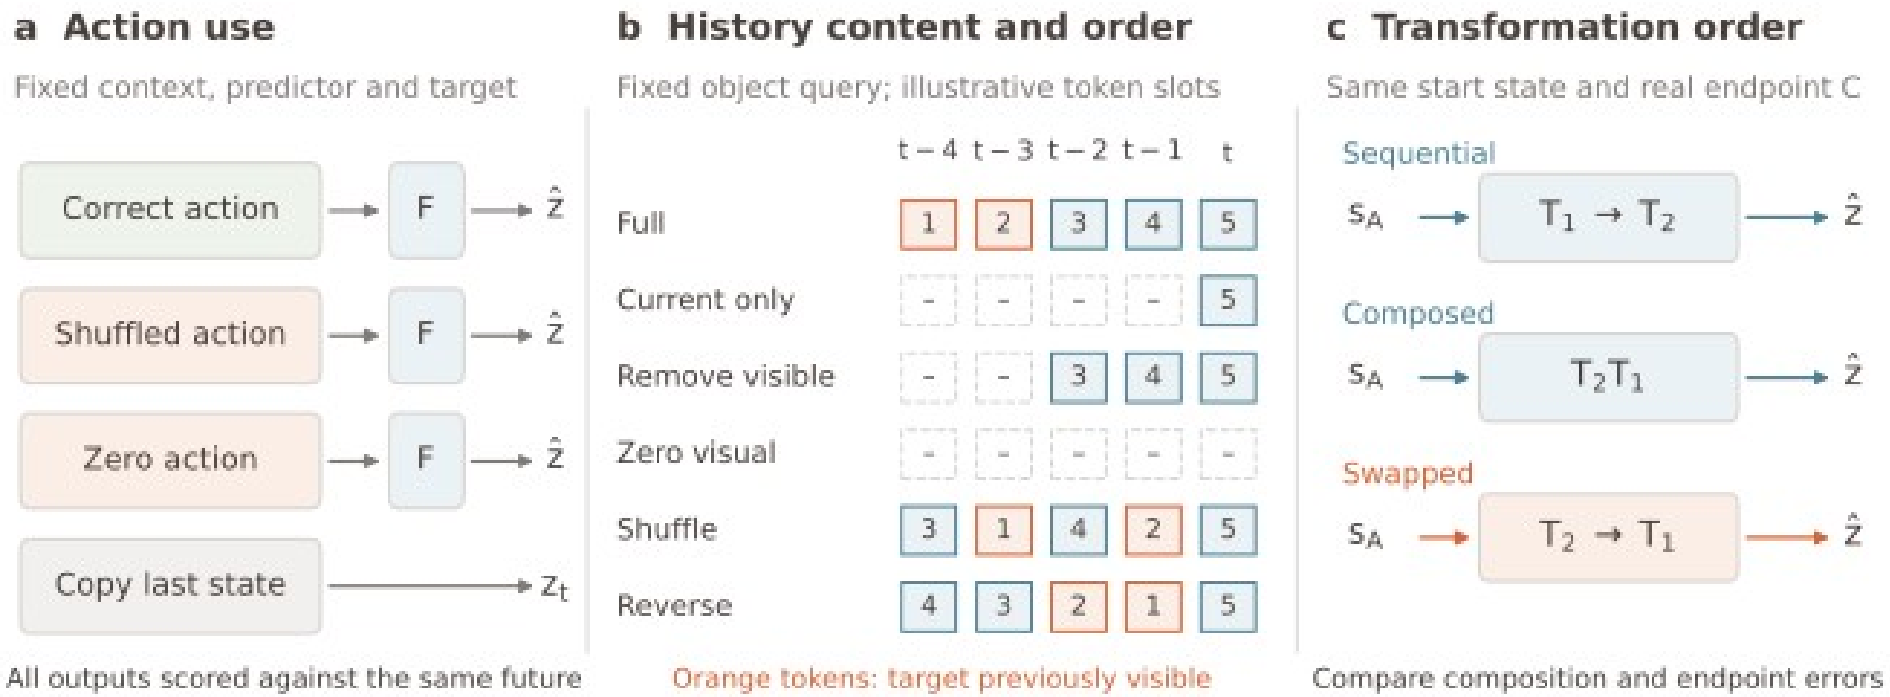
VideoMAE 定位误差，p8 → p24（指定层）

2.47 → 9.98

VideoMAE 第 23 块实例损失，p16 → p24

提取层和前缀长度本身就是评估的一部分，不能当成可随意替换的特征接口。

匹配对照：固定探针与目标，只改输入



a 动作使用

正确 / 打乱 / 置零动作；或直接复制最后一帧特征作为时间基线

b 历史内容与顺序

只用当前帧、去掉目标可见帧、清零视觉 token 、打乱或反转帧序；保留物体查询

c 变换顺序

顺序更新 T1→T2 、组合更新 T2T1 、交换顺序 T2→T1 ，与同一真实终点比较

可解码不等于在用：最准的定位者没有用上历史

复制最后一帧 vs 学习预测

V-JEPA2 （全局检索，一步）

19.93% 复制

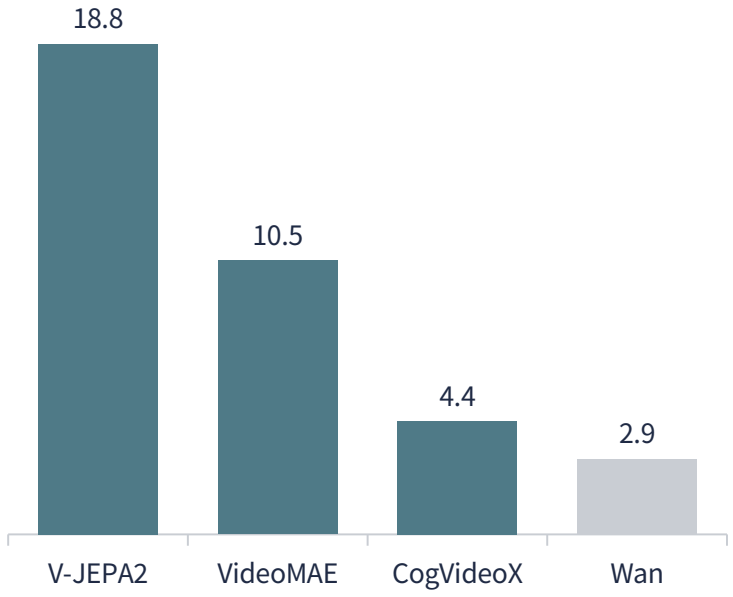
13.04% 预测

Wan

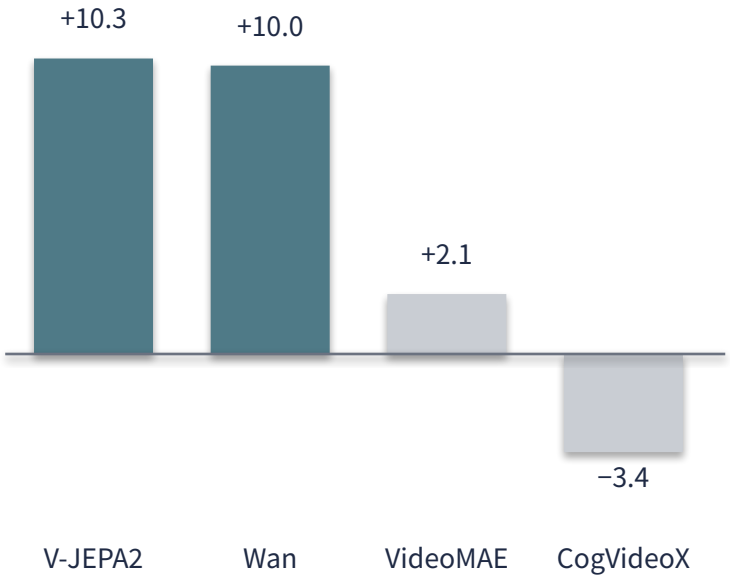
预测 15.22% > 复制 11.96%

对 V-JEPA2 而言，学习到的预测还不如“什么都不做”的复制基线。

运动增益（正确 − 错误运动， pp ）



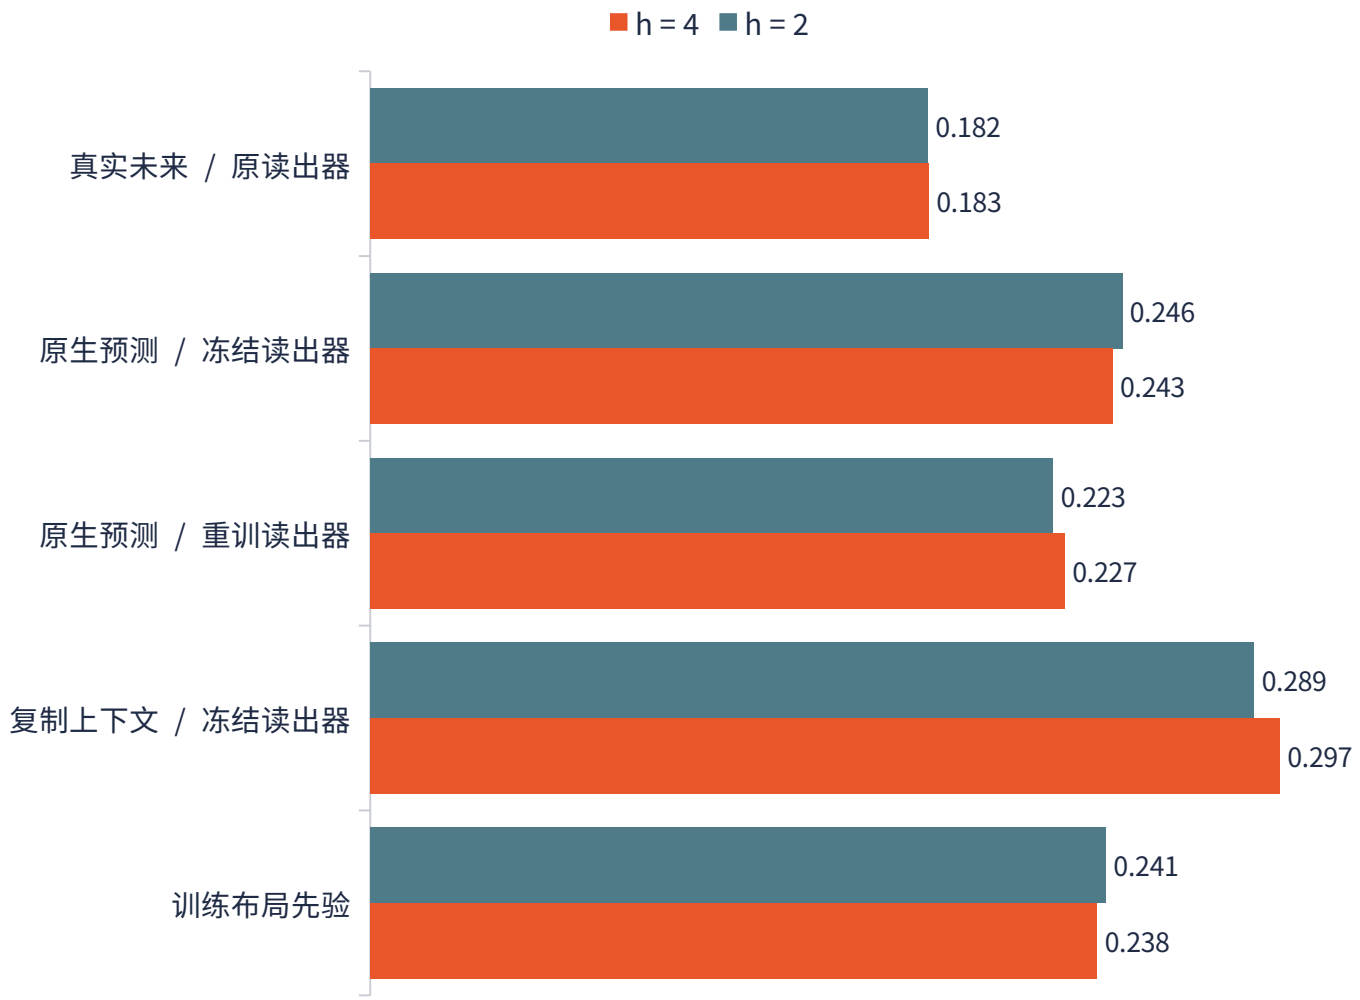
历史收益（只用当前帧 → 完整历史， °）



灰色 = 区间跨 0； CogVideoX 为 − 3.41°（不显著）

VideoMAE 定位最准（ 36.5° ），却看不出从历史获益（ +2.1° ，区间跨 0 ）；打乱帧序几乎无影响，探针读的是历史内容，而非有序的状态更新。

原生预测保留了空间结构，却换掉了读出接口



0.182 → 0.246

h=2： 同一读出器从真实特征换到原生预测

0.223

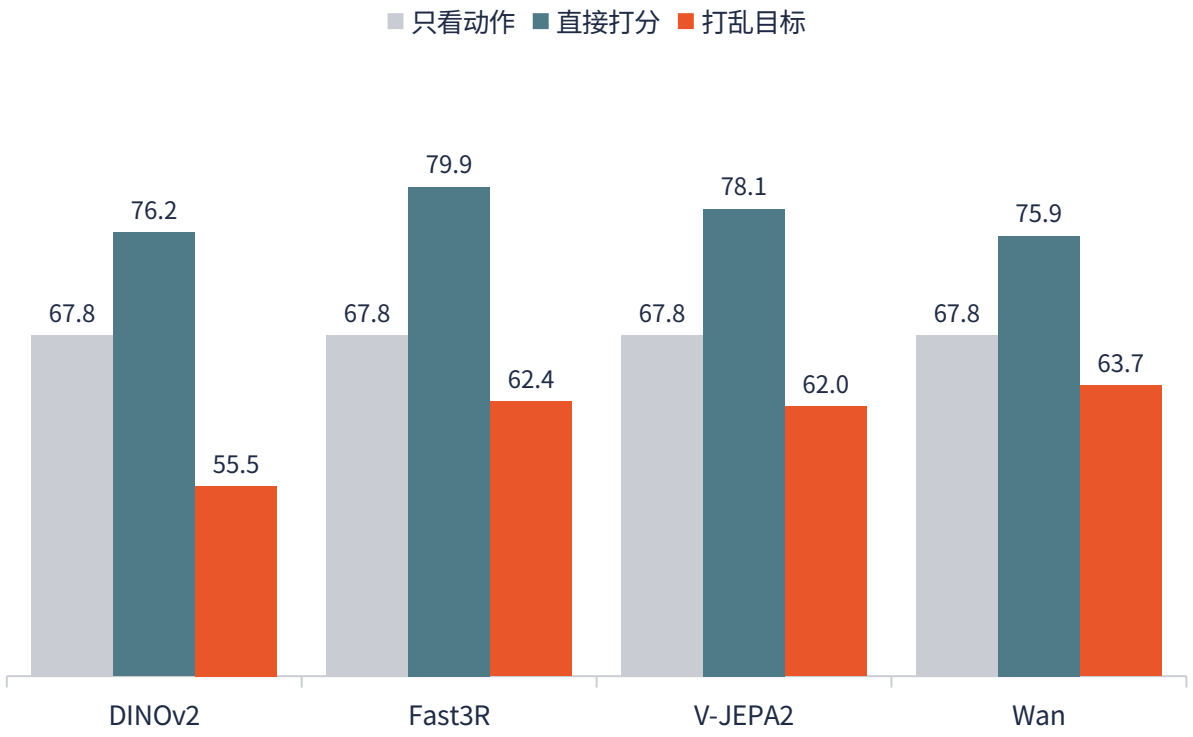
重训读出器：好于先验 0.241 ，仍不如真实特征

结构可恢复 ≠ 可直接读出：预测既不是无损的空间传播，也不代表空间信息全部消失。

arXiv 2610.40636 • 数据：论文 Table 15 / Figure 5(a) （归一化深度 MAE ，越低越好， 3 个种子均值）

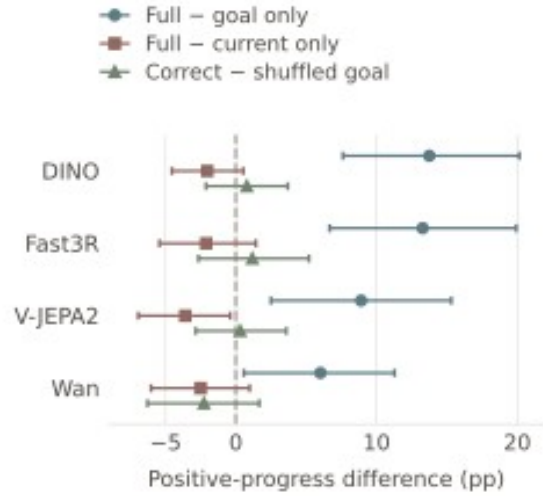
动作会随目标变化，但正确目标并没有带来更多进展

候选选择准确率（%， 3 个种子均值；随机水平 50%）



候选选择确实用到了目标：打乱目标后准确率下降 12.2–20.7pp 。

连续输出设定：正进展差异（pp）



30–46°

换目标后预测方向的偏转

−2.3~+1.2

正确 vs 打乱目标的进展差（pp），区间均含 0

FULL 比 GOAL-ONLY 高 6.0–13.8pp，但没有一个骨干超过 CURRENT-ONLY；离线诊断，非闭环策略。

层级关系

两条“成分链”贯穿四个层级

链 A： 位姿 → 持久性 → 行动

相机位姿读出

L1： AUC@30

→ ρ = 0.76

物体持久性

L2： 视野外方位角

→ 排序一致

可行动性

L4： 目标条件动作

链 B： 可见场景 → 特征预测

可见场景读出

L1： 深度 / 实例 / 视角

→ ρ = 0.52–0.63

特征预测

L3： Direct / Path

L4 排序： Fast3R > V-JEPA2 > DINOv2 / Wan

与持久性（32.8° / 45.3° / 65.4° / 62.4°）一致，与 Direct 预测（DINOv2 第一、 Fast3R 最后）无关

低层是高层的必要条件但不充分： Fast3R 的 L1 几乎全最好，预测却排第 8 / 第 7 。

总结

启示：用多维剖面评估空间表征，而不是单一分数

主要发现

- 没有模型全面领先： Fast3R 领跑位姿与持久性， DINOv2 领跑直接预测， V-JEPA2 领跑路径积分
- 层、前缀和生成坐标都会改写排名；更长前缀普遍损害持久性
- 可解码 ≠ 输入被使用 ≠ 对目标有功能性帮助
- 两条成分链：位姿 → 持久性 → 行动；可见场景 → 特征预测

局限与注意

- 前缀独立编码，测不到在线递归状态；前缀长度与终点位置混淆
- 仅静态室内场景（ ScanNet++ ）； Fast3R 可能见过部分验证场景
- 结论依赖浅层探针及层 / 坐标选择；跨模型 R@1 只能比较排序
- L4 仅 4 个模型、离线诊断；成分链是相关性证据，不是因果证据

评估空间表征，不仅要看能读出什么，还要看信息能否在视野外保持、随运动预测更新，并真正服务于目标导向的行动。