论文解读 · World Action Model

WorldBridge：用“视频→动作之桥”实现世界动作模型的任务泛化

WorldBridge: Bridging Video and Action for Task Generalization in World Action Models

WorldBridge Team · Joy Future Academy （京东）

arXiv 2610.40748 · 首次提交 2026-10-29

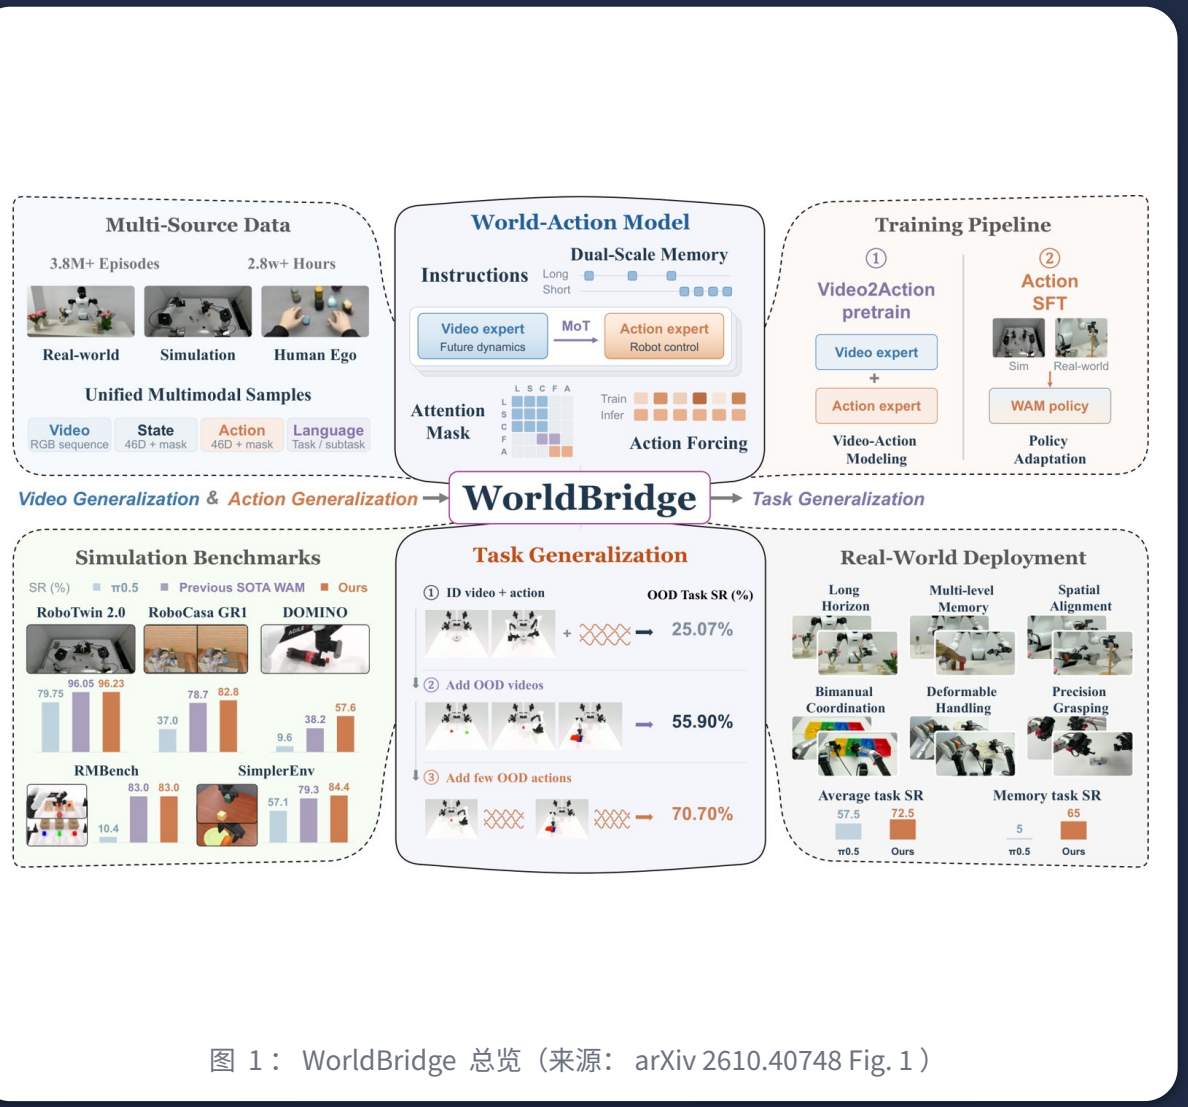

图 1： WorldBridge 总览（来源： arXiv 2610.40748 Fig. 1）

TL;DR

一句话总结：视频扩覆盖，少量动作示范把“桥”接通

把 WAM 的任务泛化拆成 **视频泛化**（预测新任务的画面演化）与 **动作泛化**（视频→动作之桥 ≈ 逆动力学模型）：无标注视频扩大覆盖，极少量配对示范校准桥；据此设计的 WorldBridge 在多个操作基准与两种真机上取得领先表现。

25.07→55.90%

只加新任务的无标注视频

RoboTwin 2.0 OOD 任务成功率 +30.83 点

→ 70.70%

每个新任务再加 1 条动作示范

再 +14.80 点；20 条 / 任务即达 90.03%

96.23%

RoboTwin 2.0 全量

Clean2Random 80.9%，RoboCasa GR1 82.8%

72.5%

真机 6 任务平均成功率

π0.5 为 57.5%；记忆任务 65% vs 5%

来源： arXiv 2610.40748 摘要、表 2/3、图 7

任务泛化 = 视频泛化 + 动作泛化，瓶颈在“视频→动作之桥”

视频泛化 Video generalization

预测训练分布之外任务的视觉演化——“新任务应该怎样展开”。

视频提供稠密的物理交互监督，可超出动作标注的覆盖。

动作泛化 Action generalization

把预测出的视觉演化转成可执行动作。

这一环即 video-to-action bridge，作用相当于逆动力学模型（IDM）。

画面预测对了，但没有动作落地，仍会失败。

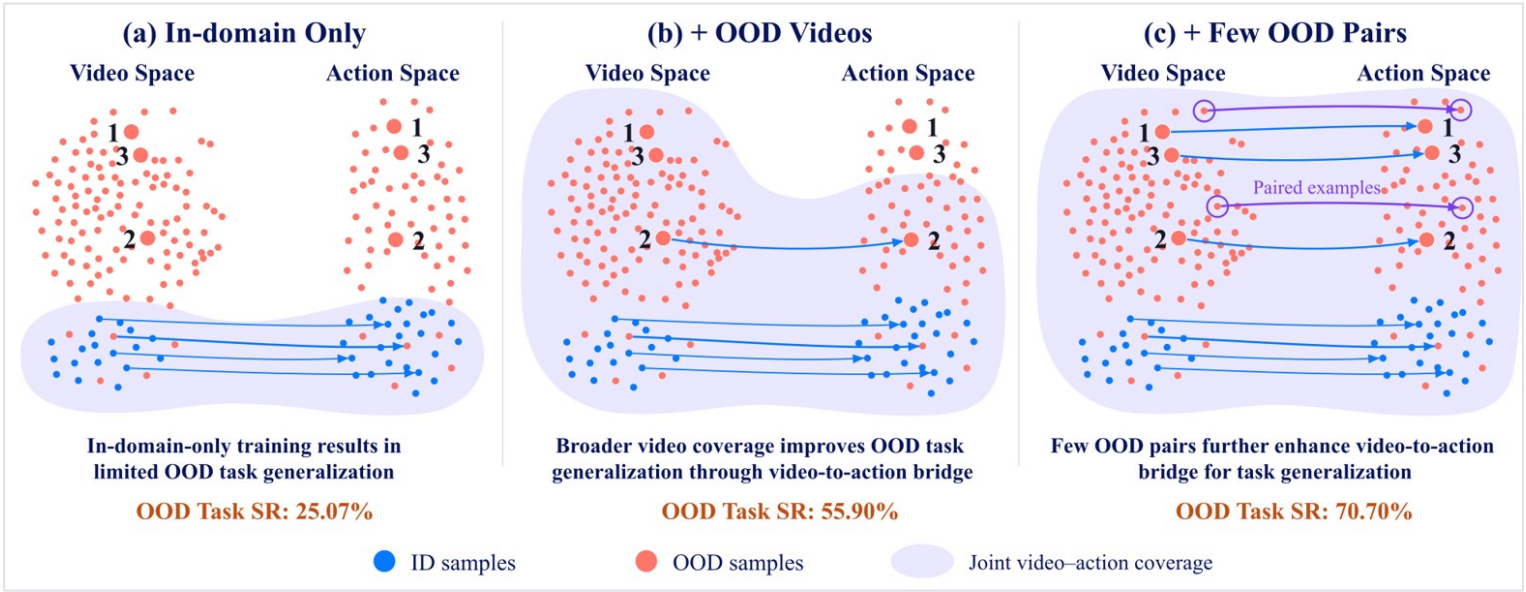

来源： arXiv 2610.40748 Fig. 2

核心发现 ①

只加无标注视频 OOD 成功率 +30.8 点；每任务 1 条动作示范再 +14.8 点

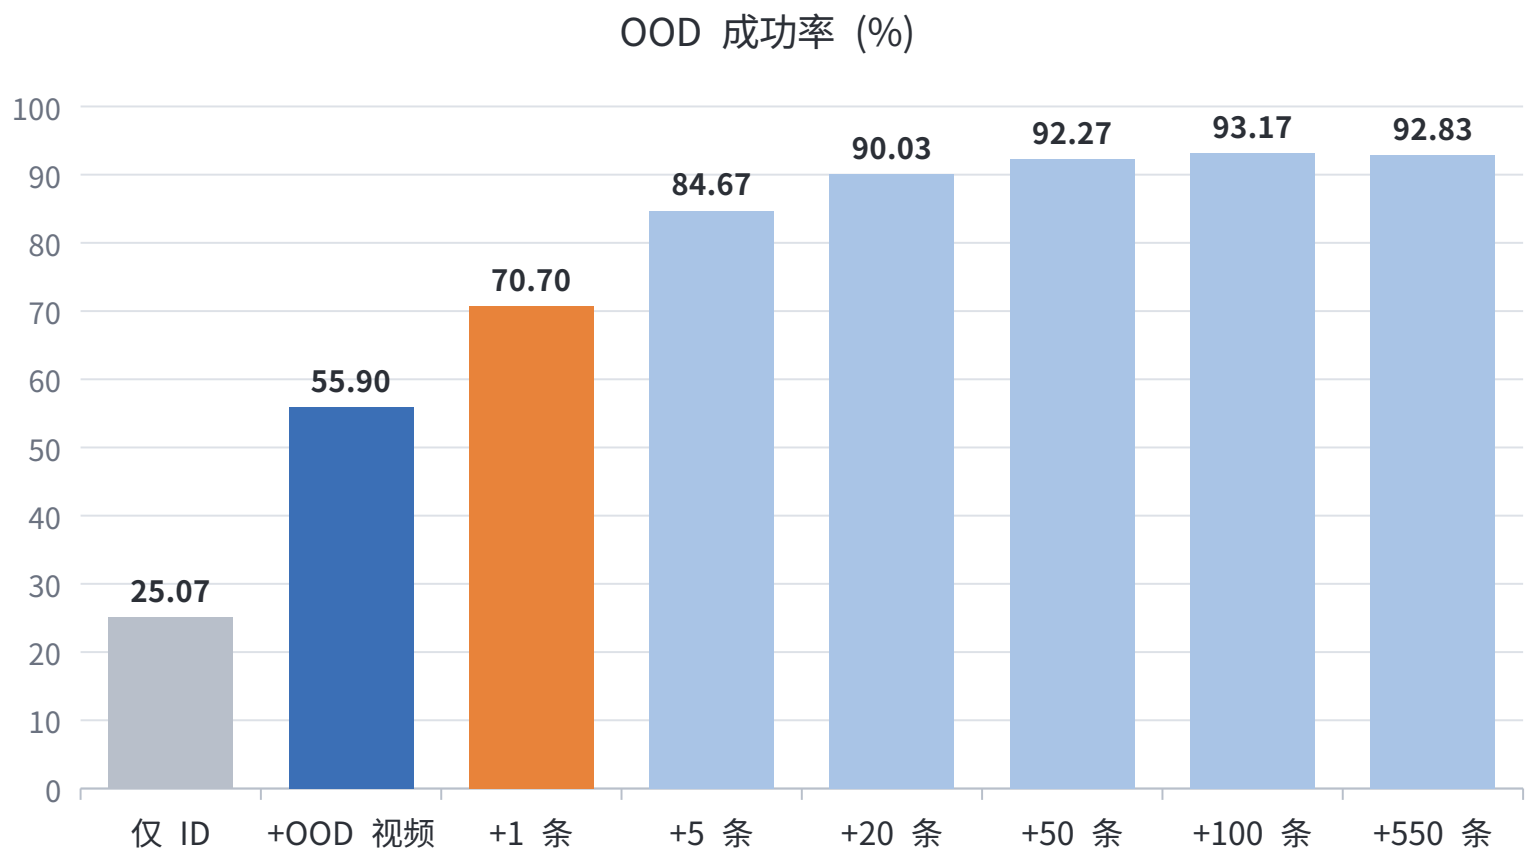

横轴： OOD 监督设置。“+OOD 视频”起 OOD 视频固定 550，之后为每个 OOD 任务的带动作示范数； ID 数据始终为 550 视频 + 550 动作。

+30.83

仅加无标注 OOD 视频

ID 成功率保持 91.96%，总体 71.81→81.14

3.6%

20 条 / 任务的动作标注量

OOD 90.03%，仅比全量 92.83% 低 2.8 点

≈饱和

100 条之后

100 条 93.17% vs 550 条 92.83%

来源： arXiv 2610.40748 Table 2 （RoboTwin 2.0）

核心发现 ②

动作示范够用之后，扩充视频比增加动作标注更划算

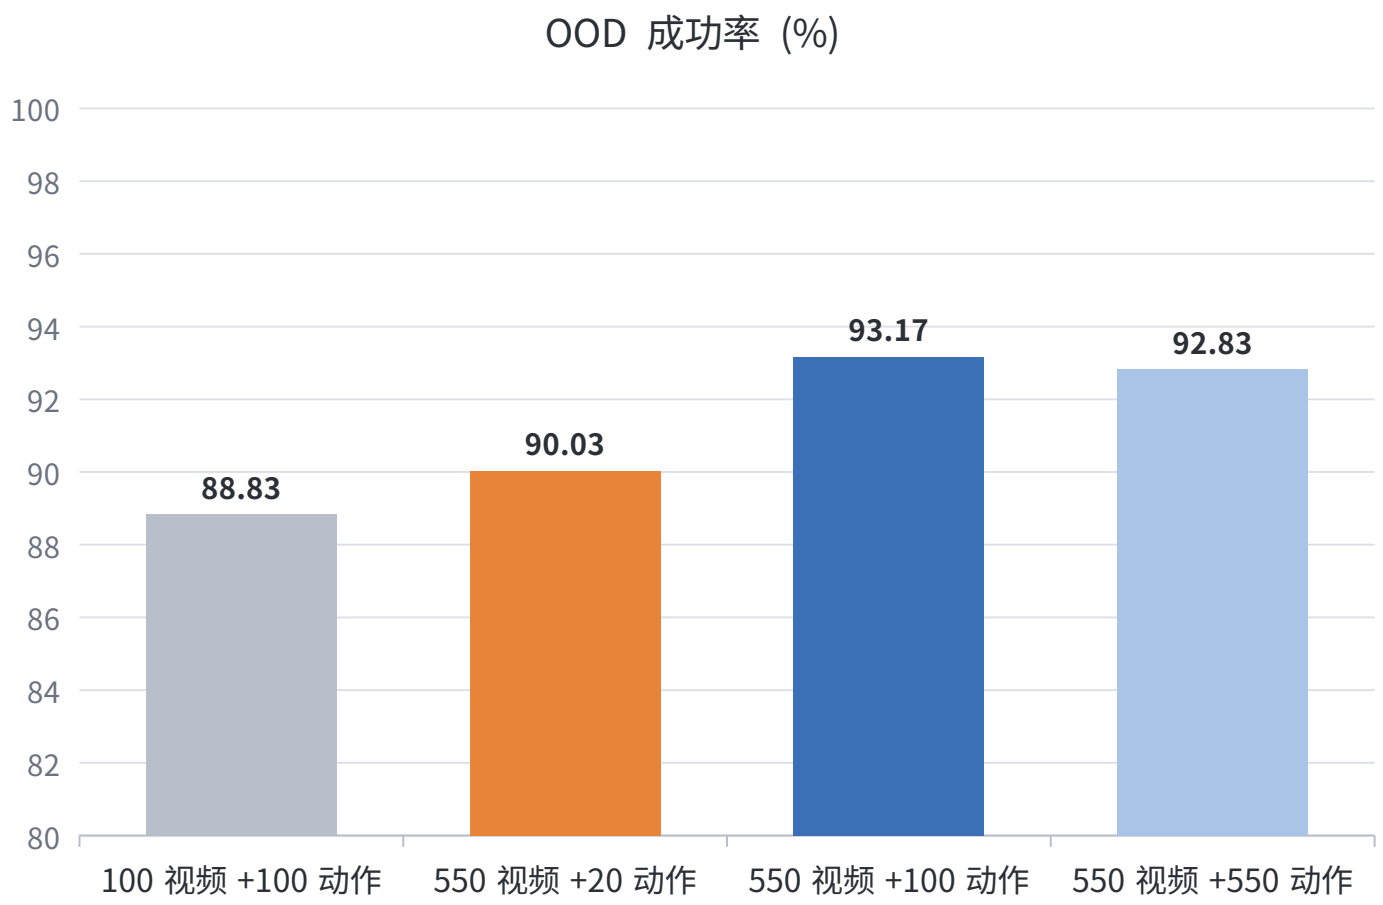

注：纵轴从 80% 起，以放大差异。动作数为每个 OOD 任务的示范条数。

视频 100 → 550 （动作固定 100 ）

OOD **88.83 → 93.17 （ +4.34 ）**

动作 100 → 550 （视频固定 550 ）

OOD **93.17 → 92.83 （无提升）**

1/5 的动作标注反而更好

550 视频 + 20 动作 **90.03** ＞ 100 视频 + 100 动作 88.83

来源： arXiv 2610.40748 Table 2 （ Exp. 5/7/8/9 ）

MoT 架构：视频专家与动作专家共享注意力，联合 flow matching 训练

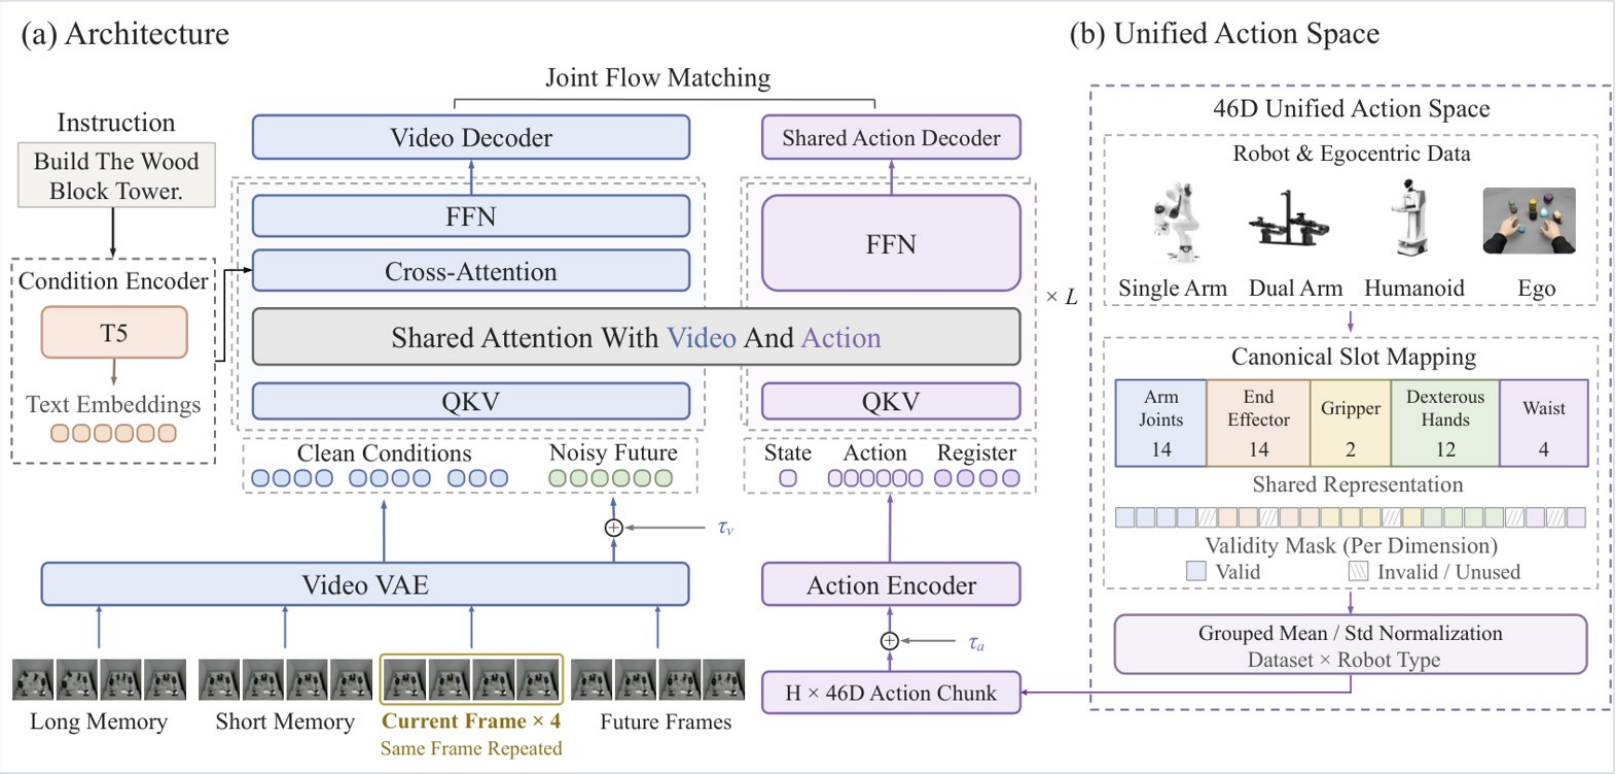

两个专家，参数分离

各自 QKV / FFN / 解码器，每层经共享联合自注意力交换信息；视频专家另用 cross-attention 接收 T5 指令特征。

联合 flow matching

视频时间步 τv 与动作时间步 τa 独立采样，线性加噪、回归速度 ε − x；视频与动作损失等权。

输入组织

视频 VAE 编码 长期记忆 / 短期记忆 / 当前帧 ×4 / 未来帧；动作端为 H×46D 动作块 + 状态 token 。

来源： arXiv 2610.40748 Fig. 3

后训练掩码强制信息流：记忆 / 当前 → 预测的未来 → 动作

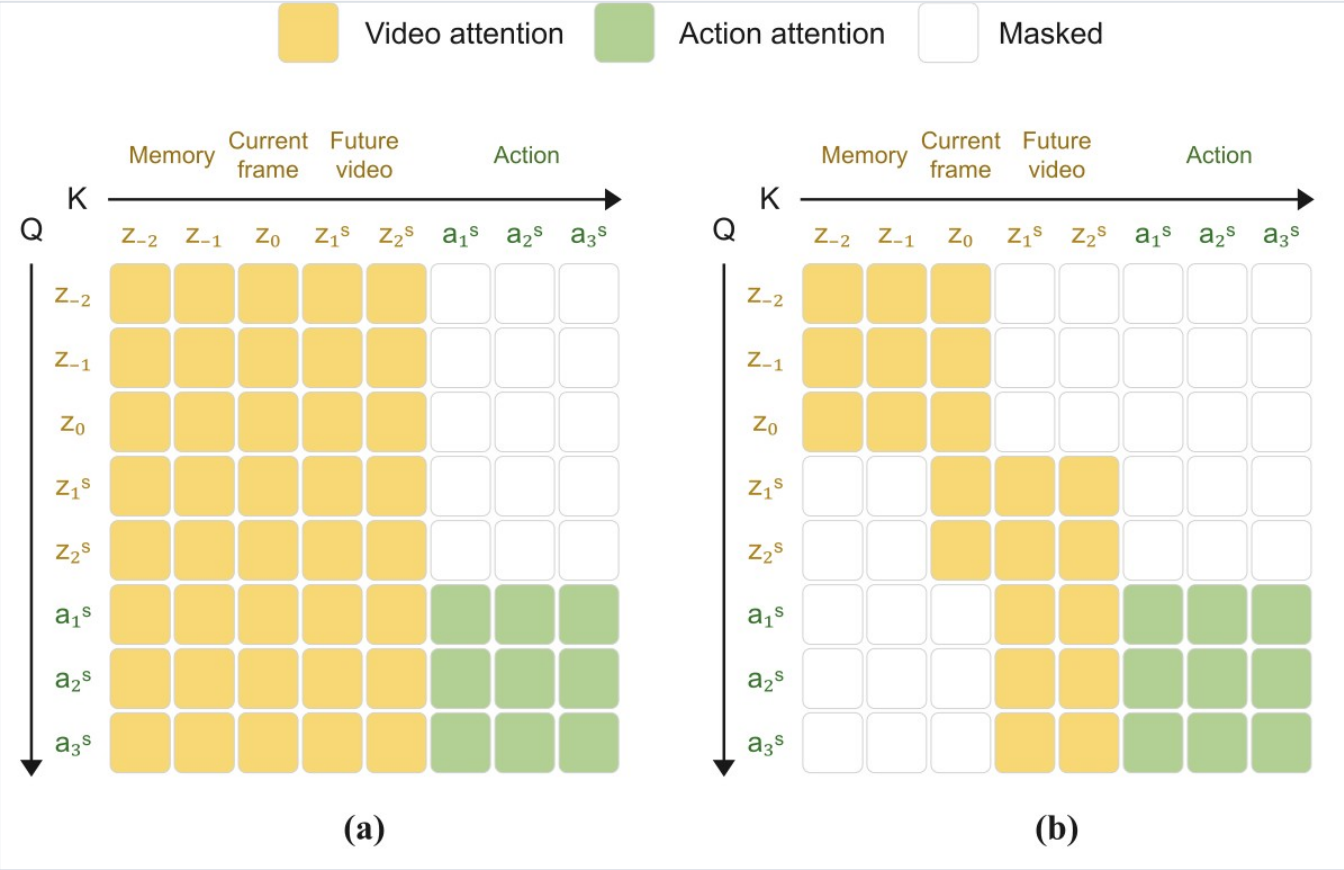

(a) 预训练：稠密视频掩码

视频只看视频，视频生成与动作无关；

动作可看全部视频 + 动作 token 。

(b) 后训练：定向通路

记忆 ↔ 当前帧；未来视频 → 当前帧 + 未来视频；

动作 → 仅未来视频 + 动作

动作必须依赖“预测的视觉演化”。

例外与副作用

强记忆任务（如 RMBench ）改用预训练掩码；

单向掩码使推理时可缓存视频 KV 特征。

来源： arXiv 2610.40748 Fig. 4

双尺度视觉记忆 + Action Forcing：补足时间上下文，迫使动作依赖视觉

双尺度视觉记忆（各 4 帧）

短期：偏移 [-8, -6, -4, -2]，捕捉局部运动

长期：偏移 [-128, -96, -64, -32]，步长 = 动作块长度 32

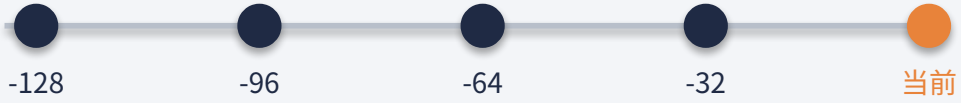

[零填充，长期 ×4，短期 ×4，当前帧 ×4] → 因果视频 VAE （时间压缩 4× ）→ 丢弃首个 latent

= 长期 / 短期 / 当前 3 个 latent，**历史开销极小**

消融： + 短期 +0.67 / + 长期 +1.22 （RoboTwin）； RoboCasa 合计 +9.41

Action Forcing （仅后训练启用）

训练：每组（示意 g=4 ）独立噪声水平 τa,k

颜色越深 = 噪声越大；同组共享 τ，噪声向量仍独立

推理：所有动作共享时间步，联合去噪

动机：噪声水平差异大的动作 token 难以孤立建模 → 更多依赖动作上下文与未来视频特征

消融： RoboTwin 91.28 → 93.31 （+2.03）， RoboCasa +1.67， RoboDojo +2.02

来源： arXiv 2610.40748 §2.1.2–2.1.3、 §2.3.3、 Table 6 （示意图为本解读绘制）

2.2 万小时机器人 + 人手第一视角数据，统一进 46 维动作空间

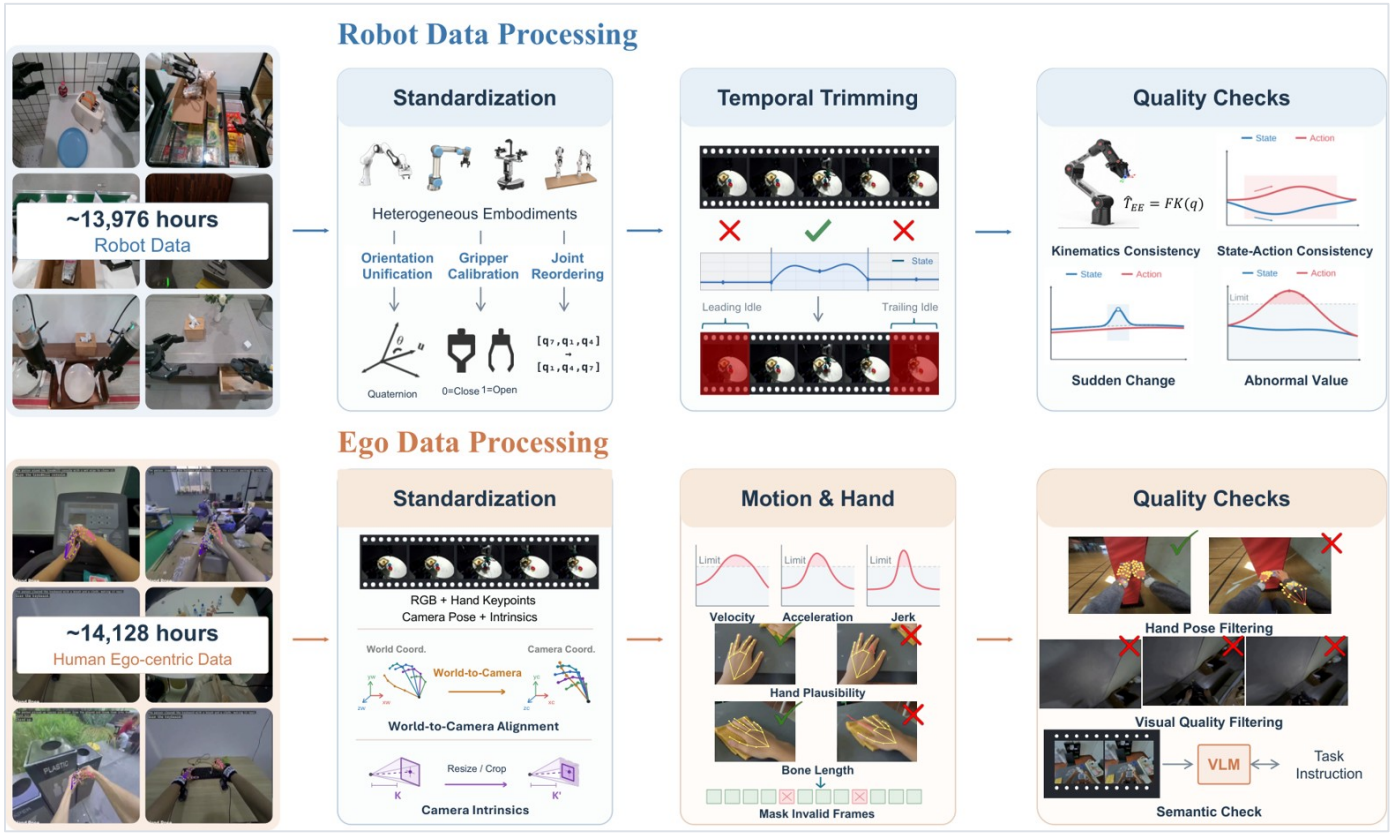

9,730 h 机器人数据（127.6 万条，10 个来源）

12,592 h 第一视角人手数据（210.6 万条，7 个来源）

22,321 h 筛选后合计，时长保留率 79.4%

预训练采样：机器人 0.7 / 人手 0.3；64 卡，batch 1536，6 万步

46 维统一动作空间

臂关节 14	末端位姿 14（相对当前 EEF）		灵巧手 12	腰 4

绿色为夹爪 2 维；逐维有效性掩码：缺失维度置零并在损失中屏蔽；归一化统计按 数据集 × 机器人类型 分组计算

来源：arXiv 2610.40748 Fig. 5、Table 1、§2.3.2

仿真基准：多数领先， DOMINO 零微调比第二名高 19.4 点

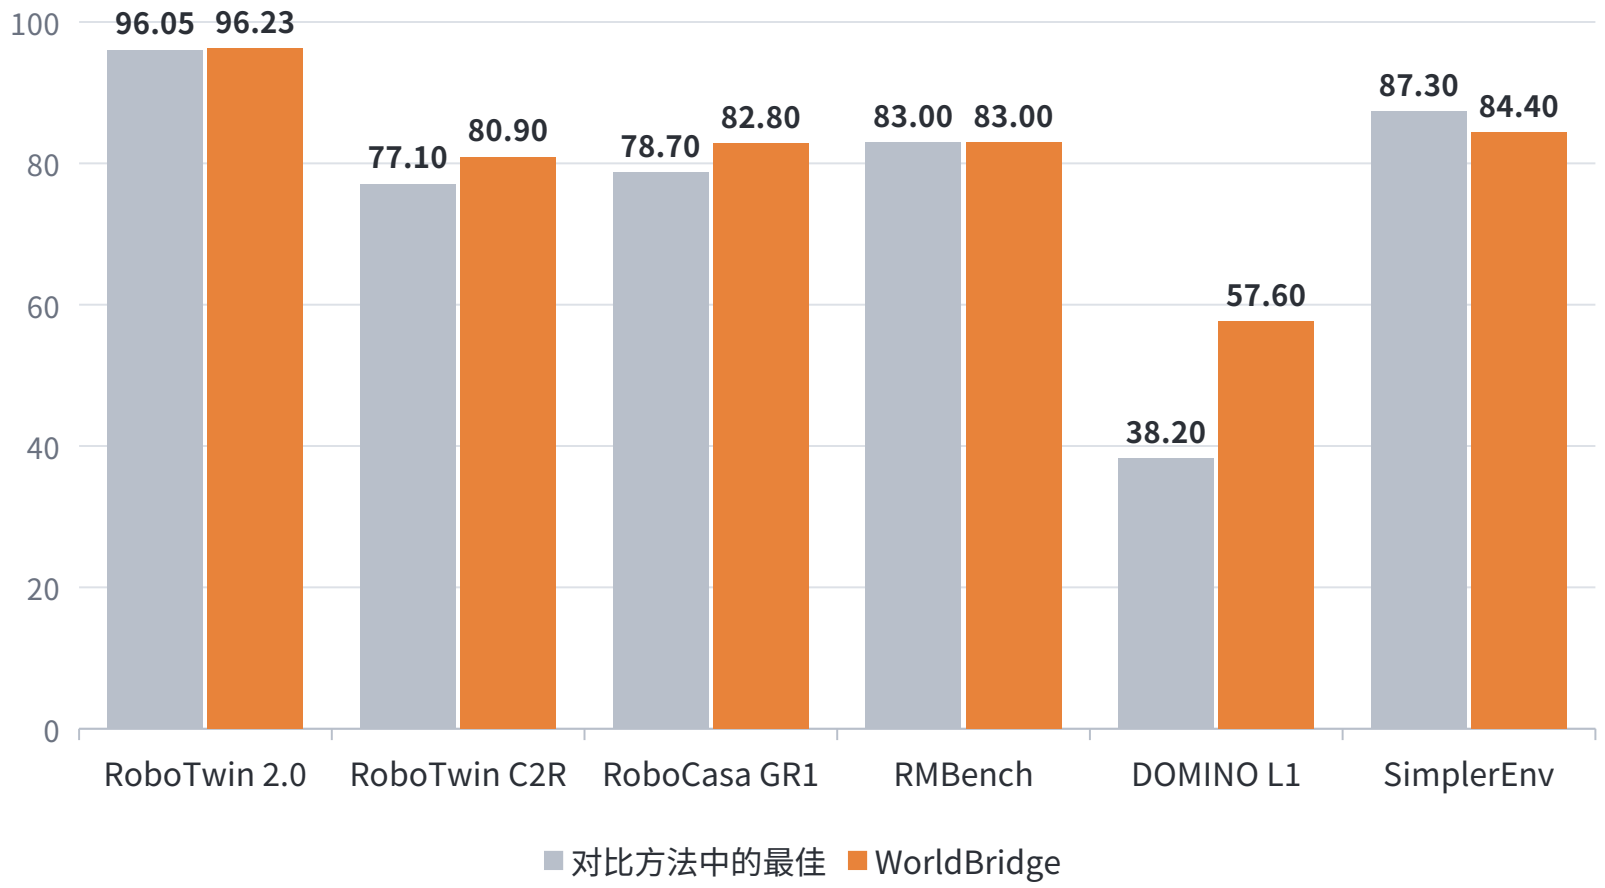

最佳对手： Kairos / Qwen-RobotManip-Context / Long-WAM / MemoryWAM / DynamicWAM / GalaxeaVLA (G0.5)

DOMINO： 静态→动态

复用 RoboTwin 权重，不做动态任务微调； SR 57.6 / MS 64.6

C2R 随机场景 73.4%

Fast-WAM 1.9%、 AHA-WAM 3.2% 在该设定几乎失效

并非全部第一

SimplerEnv 84.4 < 87.3； RoboDojo Score 26.03 最高， SR 19.15 < DM0.5 19.34

来源： arXiv 2610.40748 Table 3/4/5

消融： Action Forcing 、记忆与预训练各有贡献，预训练对随机场景最关键

Table 6 ｜累加消融（成功率 %）

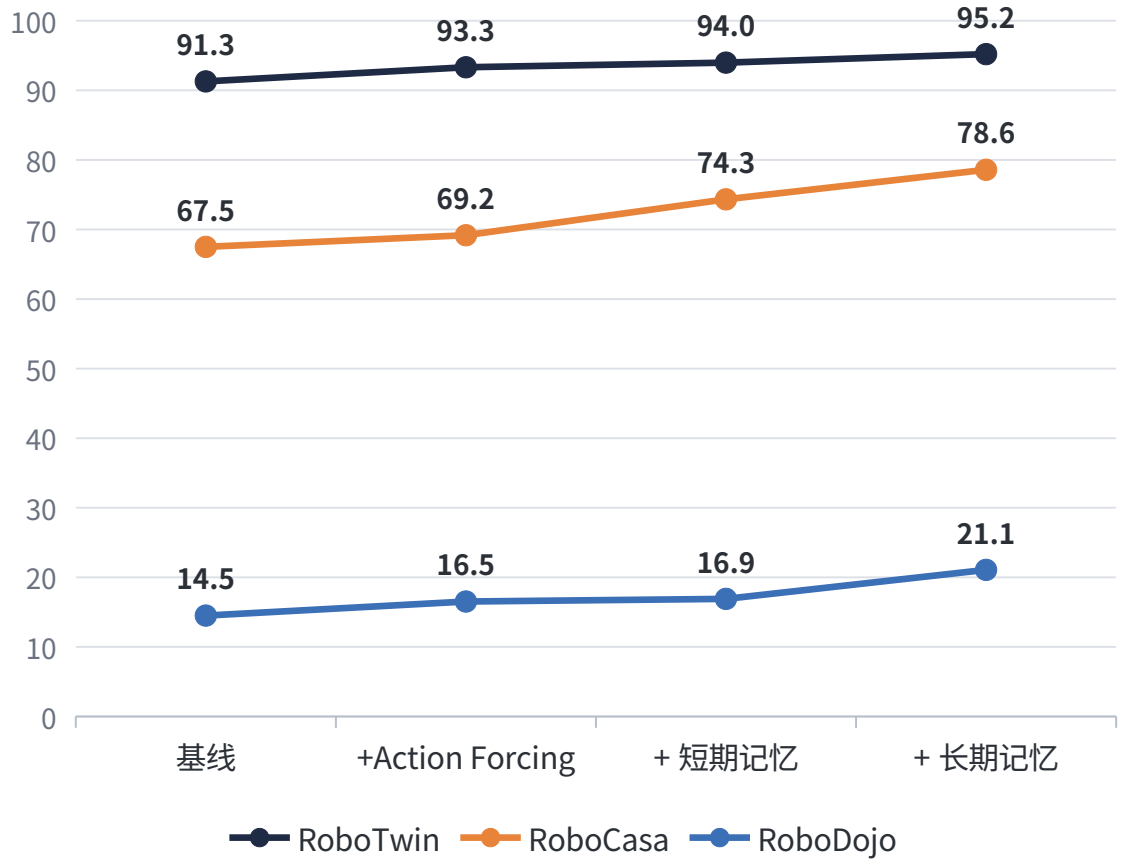

Table 7 ｜预训练数据（RoboTwin Clean→Random，%）

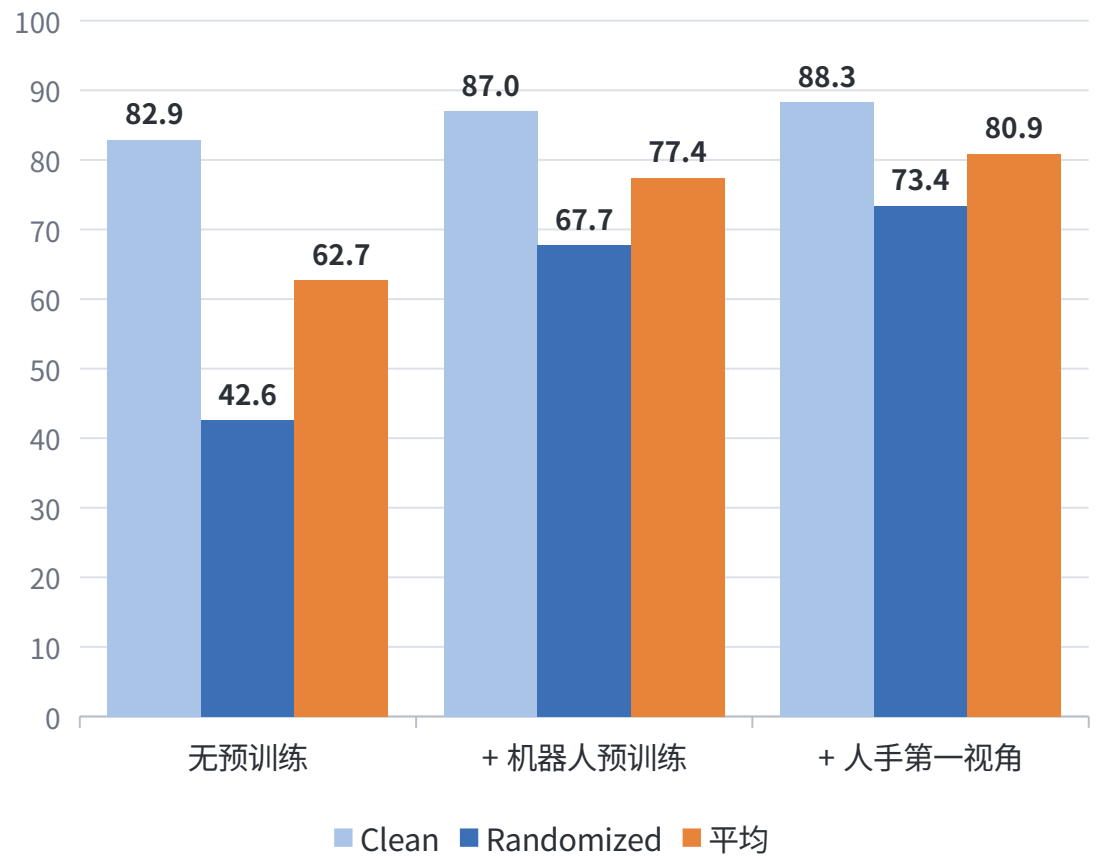

来源： arXiv 2610.40748 Table 6 / Table 7

真机评测：两种平台、六个任务，覆盖长程、精细、记忆与双臂协调

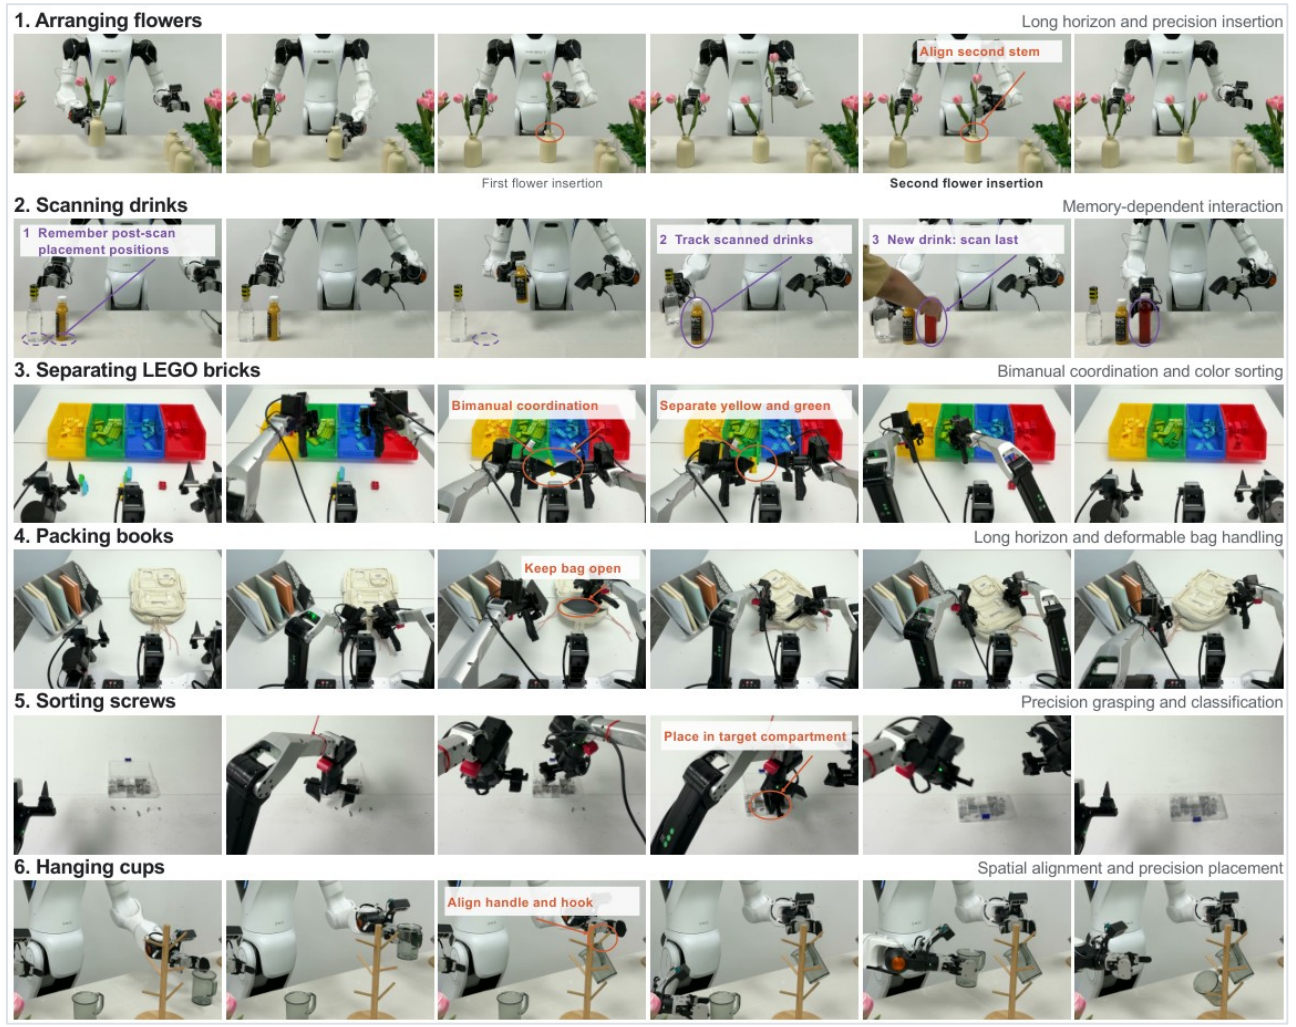

AgiBot G2

插花 长程 + 精确插入

扫描饮料 记忆：放置位置 / 已扫 / 新饮料最后扫

挂杯 空间对齐、朝向敏感放置

ARX AC-1

分离乐高 双臂协调 + 颜色分拣

分拣螺丝 小零件精细抓取与分类

装书 长程 + 可变形书包

同一预训练权重分别微调到两平台（G2 16 维 / AC-1 14 维原生指令，经适配器连接）

所有方法同一示范集微调，每任务 20 次试验，全程无人工协助才算成功

来源： arXiv 2610.40748 Fig. 6 、 §3.3

真机平均 72.5%（π0.5 57.5%），联合预训练贡献 +25.8 点

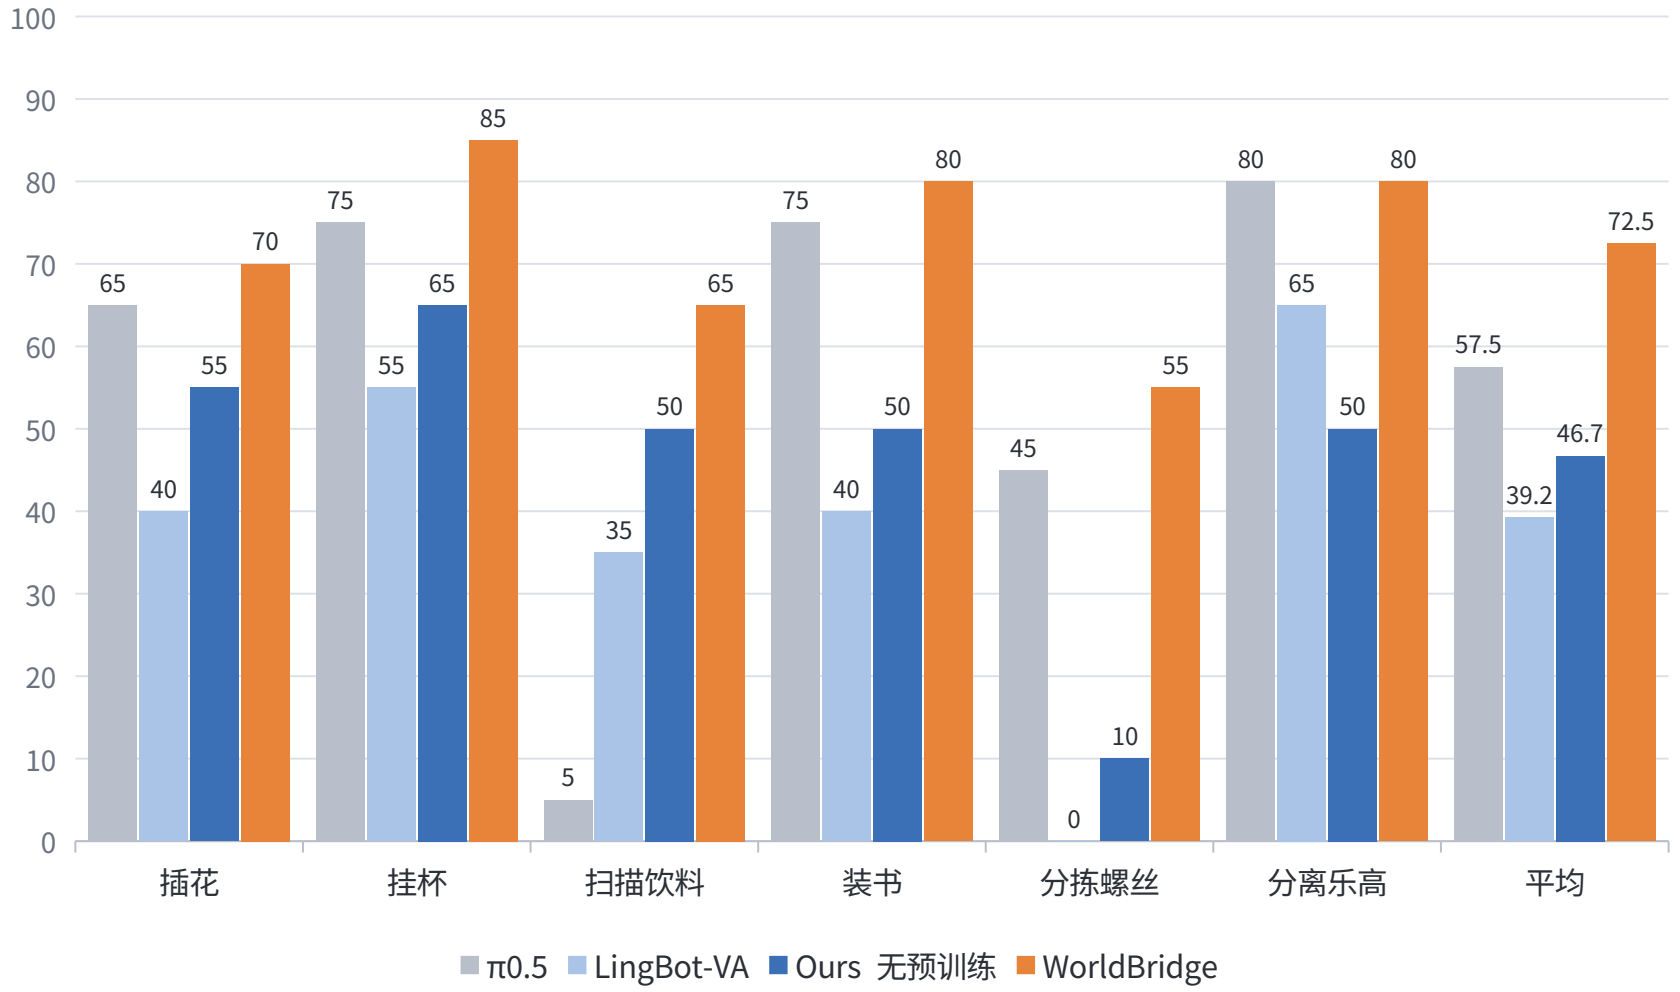

65% vs 5%

记忆任务“扫描饮料”
WorldBridge vs π0.5

+25.8

联合预训练带来的平均提升
（46.7 → 72.5）

10 → 55

分拣螺丝：预训练收益最大
（但仍是最难任务）

来源： arXiv 2610.40748 Fig. 7 （节选 4 个方法）

推理优化 9.2× 提速：单次调用 957 ms → 104 ms，真机约 7 Hz

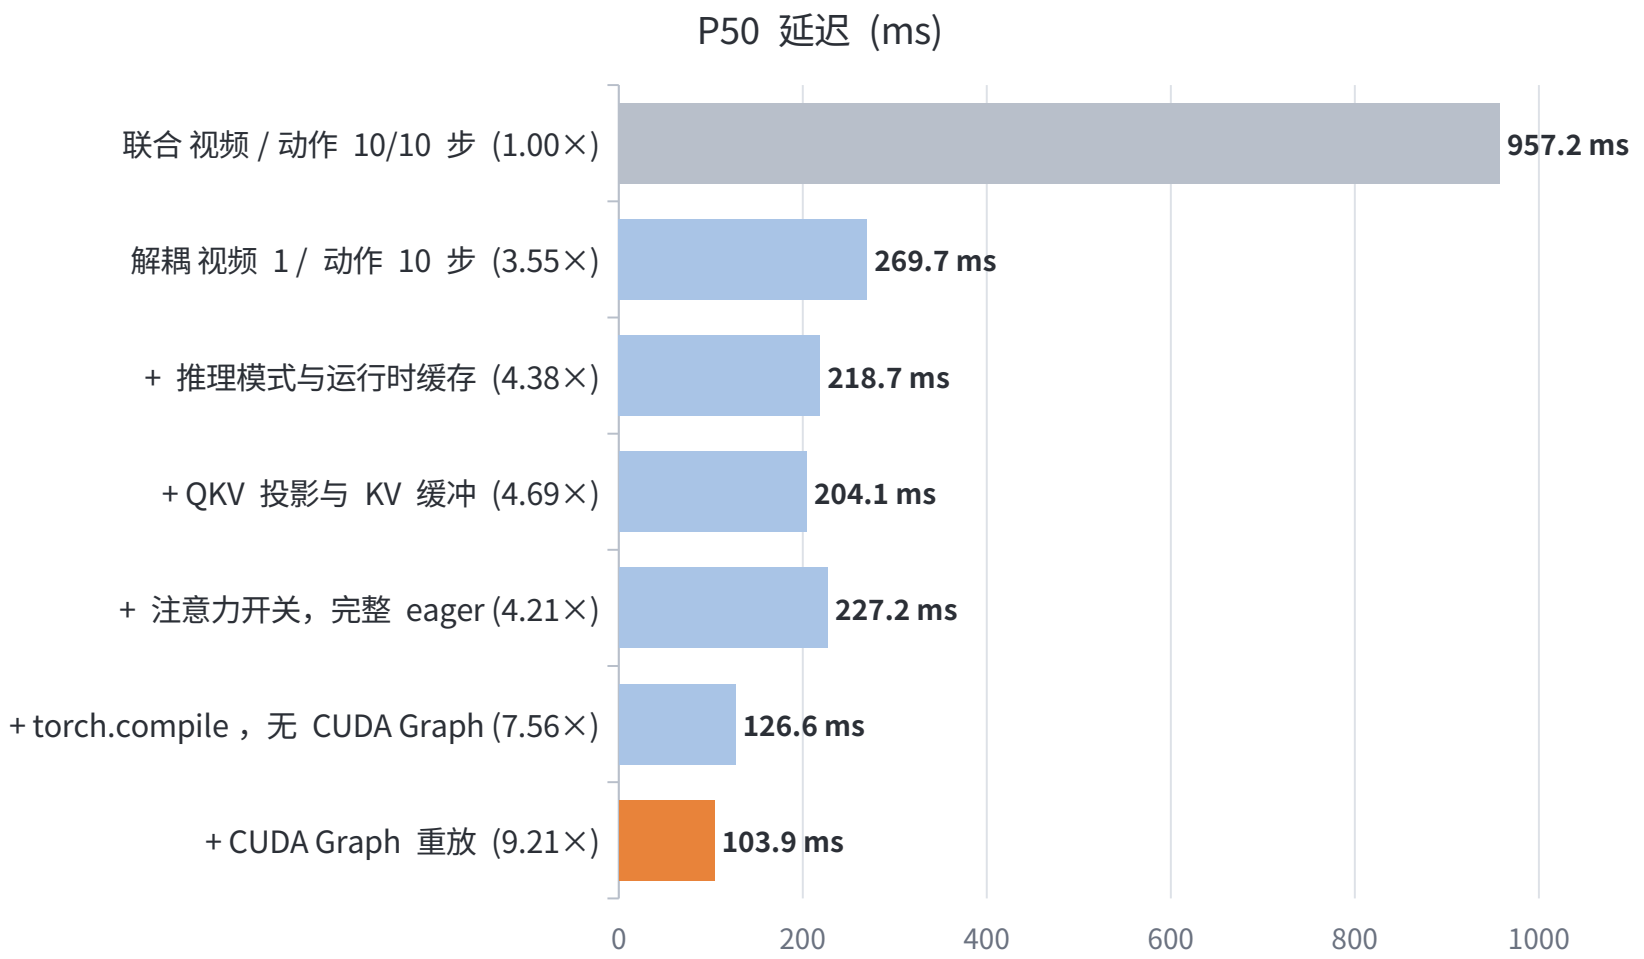

关键：解耦去噪

视频只同步去噪 1 步并缓存逐层 KV，剩余步只跑动作；单向掩码使复用合法（但属近似）

工程叠加

编译 + CUDA Graph 再快约 2×；P95 105.6 ms

真机闭环

异步执行 + 时间戳拼接，含通信约 7 Hz

来源： arXiv 2610.40748 Table 8 、 §2.4

评价：问题拆分清晰、工程完整，但泛化设定偏理想

亮点

1. 问题拆分清楚：视频覆盖 vs 视频→动作之桥，可控实验量化边际收益
2. 结构呼应论点：后训练掩码强制 动作 ← 预测的未来
3. 工程完整： 46D 统一动作空间、双管线数据清洗、 9.2× 推理加速
4. 评测广： 6 个仿真基准（含记忆、动态、 real-to-sim ） + 2 种真机

局限与注意点

1. OOD “ 视频” 是同仿真器、同机器人的去标注示范，远比人类 / 网络视频容易； ID/OOD 划分未说明
2. 未单独度量 OOD 视频预测质量，无法区分失败来自画面还是桥
3. SOTA 需打折扣： SimplerEnv 、 RoboDojo SR 非第一； RMBench 并列； RoboTwin 近饱和
4. 推理视频仅 1 步去噪，与叙事有张力；真机每任务仅 20 次

来源： arXiv 2610.40748 （本解读的分析）

总结与启示

任务泛化 = 更广的视觉经验 + 可迁移的“视频→动作之桥”

数据策略

无标注视频扩覆盖 + 少量配对示范校准桥： 20 条 / 任务即达 90.03% （全量 92.83% ）

模型设计

双专家 + 定向注意力掩码 + 双尺度记忆 + Action Forcing， 2.2 万小时混合预训练

下一步

用人类 / 跨具身视频验证结论；单独评测并增强桥（ IDM ），减少新任务动作标注

arXiv 2610.40748 • 项目主页 worldbridge-jd.github.io