论文解读 · arXiv 2610.40799

CaPtain

A Pipeline for Post-Training Code-as-Policy Robot Agents

把语言 Agent 的 SFT + 多轮 RL 配方

搬到 Code-as-Policy 机器人上

4B 开源 VLM，只用低层原语写代码完成操作

Yijia Fan, Xilin He, Yilei Jiang, Dongming Wu, Jiaxu Wang, Xiangyu Yue †
MMLab, The Chinese University of Hong Kong · NovaXBot

首次提交： 2026-10-29

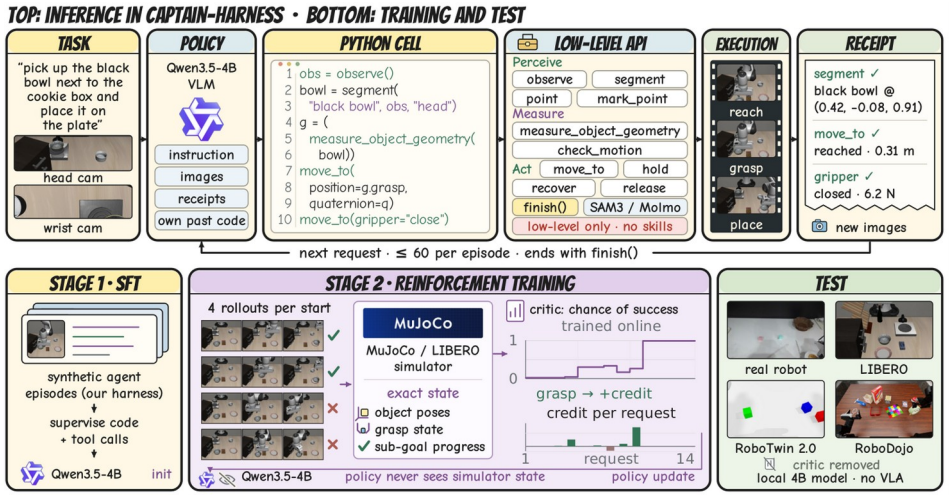

图源：论文 Figure 1 （方法总览）

一句话：4B 开源 VLM 经 SFT+RL，从 0% 到比肩前沿模型的 CaP Agent

只给 22 个低层原语（无 grasp/place 技能、无 VLA），**先在 harness 内 SFT，再用“读模拟器特权物理状态”的 critic 做多轮 RL**，把稀疏的回合成败变成每个 request 的稠密 credit；测试时只靠相机图像和执行回执。

0% → 73.8%

LIBERO held-out 成功率

Qwen3.5-4B 零样本 → SFT 55.4% → RL 73.8%

78.5%

LIBERO-PRO （3 套件）

高于 K1 77.2 / WAA 75.6 / ASPIRE 71.7

+17.6~21.2

RL 增益在扰动下保持

LIBERO-PRO / Plus / MAX 三个扰动套件

83.3%

SimplerEnv WidowX 零样本

未用目标域数据；π0.5 （Bridge 微调） 57.1%

75.0

CaP-Bench 零样本

高于 Gemini-3-Pro 73.5、CaP-RL 7B 62.0

$0.03–0.06

每回合估算成本

OpenRUA （Claude Opus 5）为 $8–22 / 回合

现有 CaP Agent 都在回避训练：要么靠闭源模型，要么把操作交给 VLA

① 闭源前沿模型直接 prompt

- OpenRUA 、 K1 、 WAA 、 ASPIRE …
- 不更新权重；成本高（ OpenRUA $8–22/ 回合）
- 无法为新机器人 / 任务微调，无法跑在机载算力上

② 委托 VLA / 高层技能

- PyRUA 、 AgenticRoboRL 、 RoboRSI 、 Gemini 4 Argon
- 代码决定“调哪个技能”，技能决定“怎么抓、怎么放”
- 上限被技能训练数据锁死， RL 最多学会排序

③ 小型开源 VLM 直接失败

- Qwen3.5-4B 在 harness 中 LIBERO 成功率 0%
- 已有训练工作主要靠 SFT （ Guava ）
- 或单轮纯文本 RL （ CaP-X ， 3 个 Robosuite 任务）

难点：多轮信用分配

- 无技能 → 抓哪里、从哪接近、何时合爪都由策略决定
- 每回合几十个 request ，多数只是感知 / 验证
- 物理后果常在数轮后显现，奖励只有回合末一个结果

机会：仿真中的不对称信息

- 训练在模拟器中：物体位姿、抓取状态、子目标进度精确可知
- 部署时策略只能看相机

→ critic 读特权状态， policy 只看图像与回执

CaPtain 总览：固定 harness + harness 内 SFT + 模拟器 critic 引导的多轮 RL

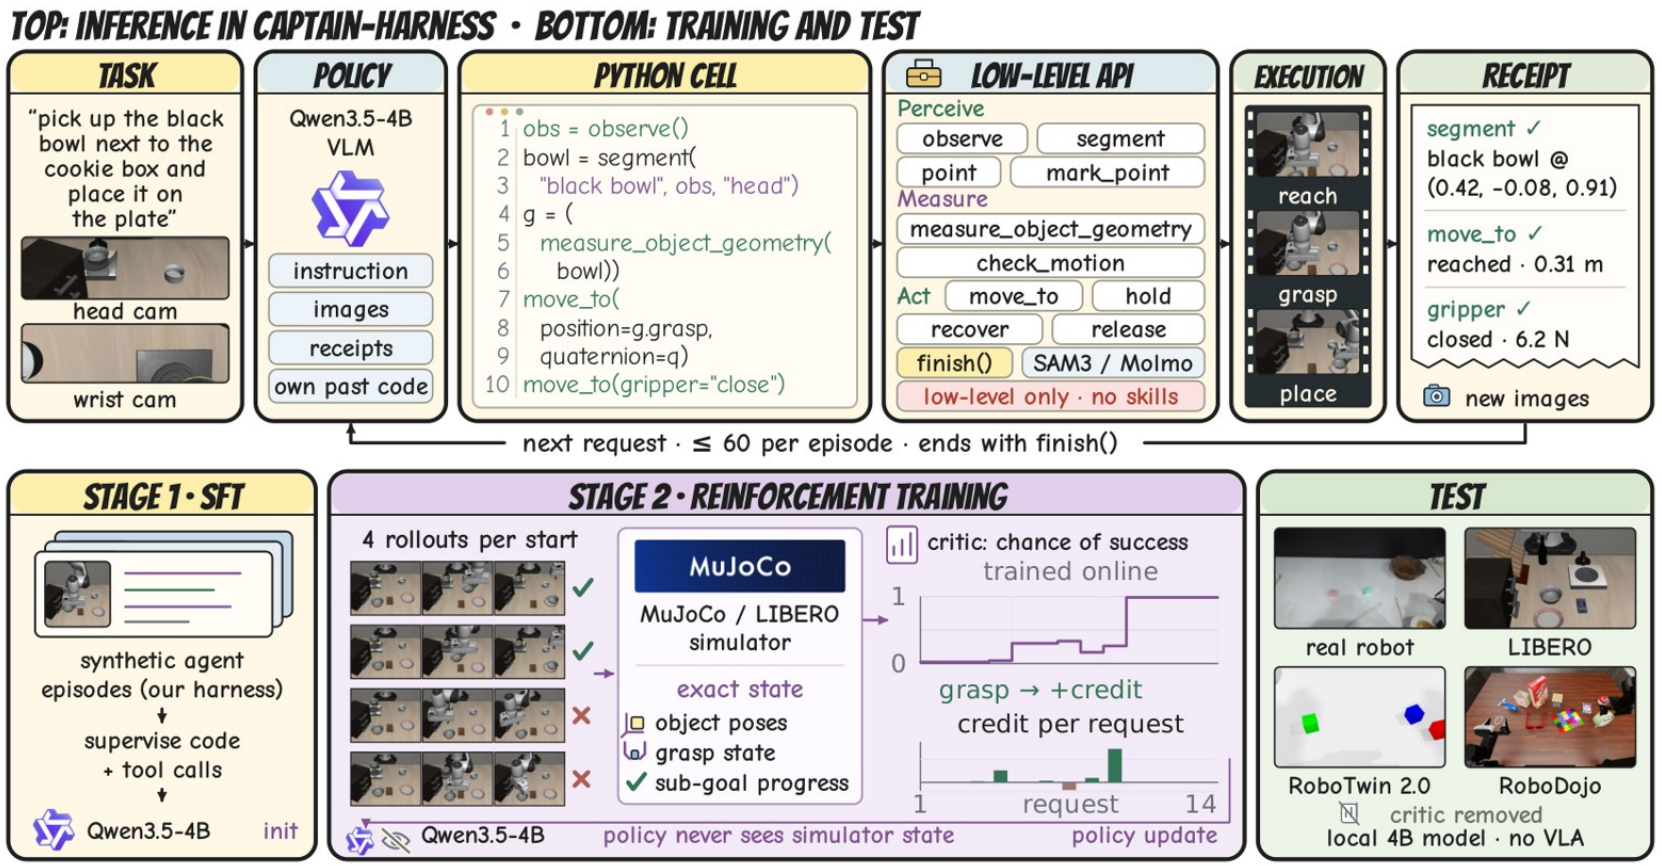

推理

每个 request 写一个 Python cell → 调低层 API → 读回执和新图像；≤ 60 request/ 回合，以 finish() 结束

Stage 1 · SFT

在同一 harness 中用 GPT-6 Astra 生成的合成轨迹对齐交互格式

Stage 2 · RL

每个起点 4 条 rollout； critic 读精确物理状态，把成功概率的变化作为每个 request 的 credit

测试

移除 critic； LIBERO / RoboTwin / RoboDojo / 真机；本地 4B，无 VLA

CaPtain-Harness：只给低层原语，每个操作决策都写在代码里

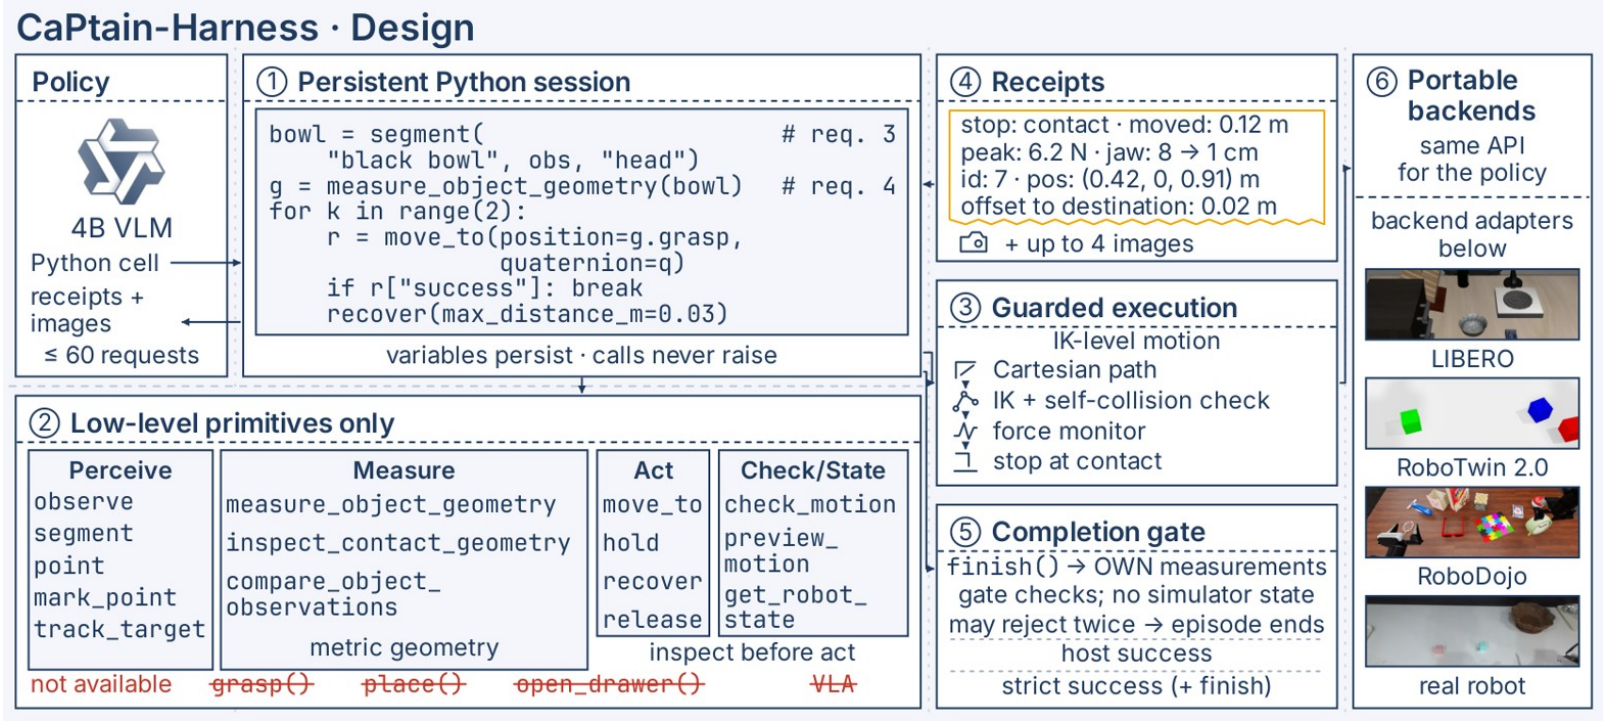

22 个原语 + finish()

感知 / 测量 / 运动 / 规划与状态；没有 grasp 、 place 、 open-drawer ，也没有 VLA

文字回执 Receipt

≤300 字符：停止原因、移动距离、峰值力、夹爪开合、物体度量坐标与到目标的偏移

持久 Python 会话

变量与自写 helper 跨 request 保留；调用不抛异常，可写 if / 循环 / 重试

Host vs Strict 成功

Strict = 环境判定成功 + Agent 主动 finish() ；后者才是可部署指标

图源：论文 Figure 6 ；内容： §3.1 、附录 A/B

Stage 1 SFT：用前沿 Agent 轨迹让 4B 学会接口（0% → 55.4%）

同格式对齐

chat template、TASK.md、tool schema、receipt 与部署完全一致；只监督 assistant token（推理 + 代码）

代码归一化

原始轨迹中 226 种“preview 后 move”写法 → 统一为 4 个 helper（val / need / downq / go），mock robot 逐点验证

逼模型看图

历史中的 mark_point 像素坐标以 p=0.2 替换为 <masked>，防止照抄旧坐标

布局多样性

官方初始状态物体位置 std≈1.4 cm → 模型背坐标；改用宽布局 std≈15 cm 后才真正依据图像定位

SFT 数据配比（token 占比 %）

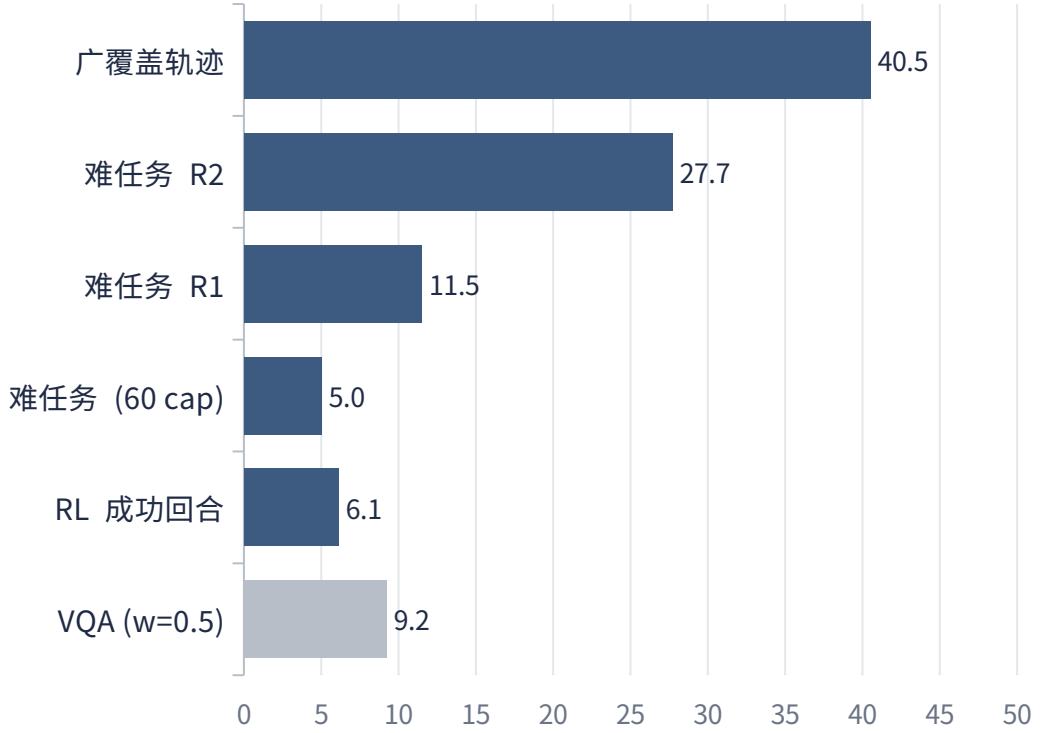

25,961 行 · 861M tokens，其中 GPT-6 Astra 生成 654M；全参微调 LLM、冻结视觉塔，训练 1.5 epoch

数据：论文 §3.2、附录 C Table 5、附录 D

Stage 2： critic 读特权物理状态，按成功概率的变化给每个 request 记分

特权物理状态 $x(s_t)$

36 维：末端 / 夹爪、目标进度、距离、物体抬升位移、关节与 held 标志
（排除策略自身行为计数）

Critic V(s, t)

5 个 MLP 集成预测 host 成功概率；旧策略 1,000 回合热启动，再随策略在线 BCE 共训

每 request 的 TD credit

$$\delta_t = c_t + V(s_{t+1}, \mathbf{t}) - V(s_t, \mathbf{t})$$

两个 V 用同一时间索引 t → 时间流逝不产生 credit；纯感知请求 $\delta \approx 0$

Advantage

组内结果项（G=4 rollout / 起点） + 回合内 GAE （λ=0.9）；同一 request 的所有 token 共享

终端回报 R_i 的排序

成功 + finish()	1.0
成功但没 finish()	0.25
部分子目标（8 个难任务）	⩽0.1125
其他失败	0
预算耗尽	−0.1
误报完成 false finish	−0.3

- 即时代价 $c_t \leqslant 0$： 失败动作、动作过多、成功后多余操作
- 更新： SAO 式流式单遍 + 双侧 token mask (0.2<r<4)
- 每步累积 1,024 回合梯度； KL 到 SFT （β=0.002）

credit 集中在物理操作上：感知请求只分到 1.3% 的 advantage 质量

|A| 质量按请求类型分布

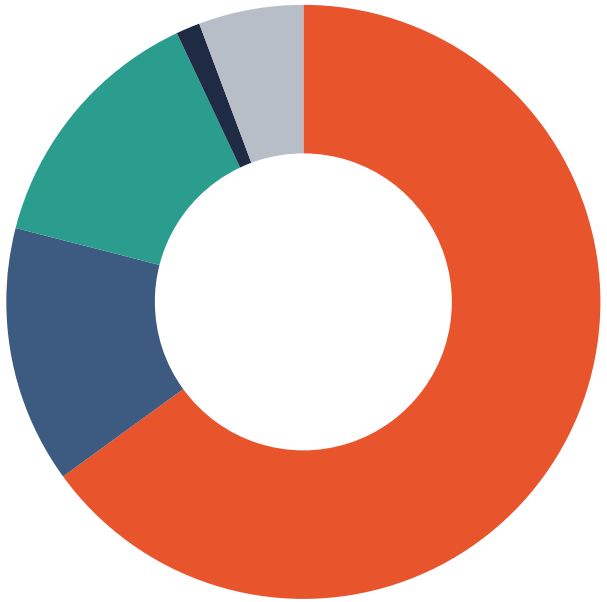

运动 65% · 抓取 14% · 释放 14% · **纯感知 1.3%**

+0.058

成功抓取 ΔV 中位数

IQR [0.036, 0.090]

−0.0075

失败抓取 ΔV

−0.0002

纯感知请求 ΔV

≈0，与 token 数无关

0.970

critic 预测成功 AUC

组内 AUC 0.904，校准误差 0.006

反例：为什么不用策略侧特征

- 行为计数：抓取前 AUC 0.773→0.862，但充当时间代理，负 credit 漏到感知
- LM 隐藏状态：可解码 request 序号 R^2=0.80，35% |A| 质量漂到感知

梯度噪声尺度（k 回合，越低越好）

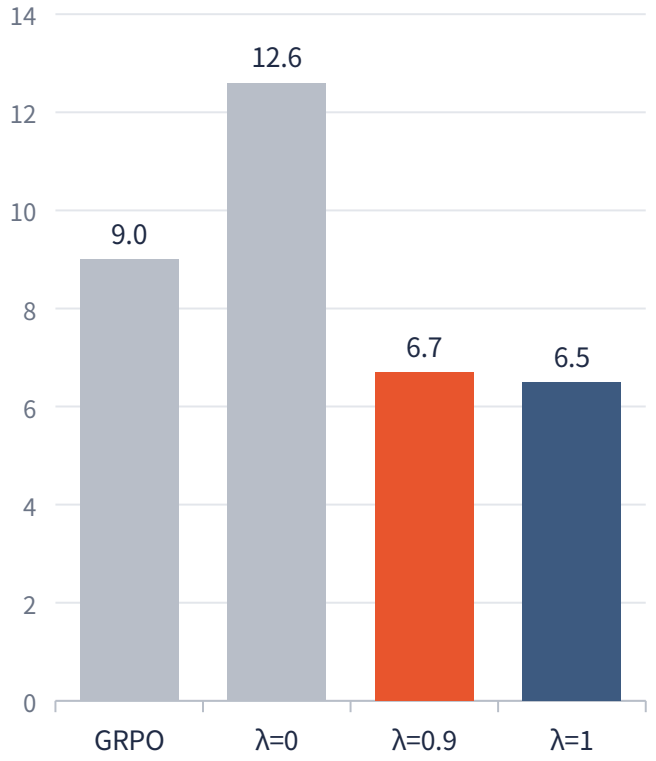

outcome-only GRPO 9.0k → simulator critic (λ=0.9) 6.7k； λ=0 反而更高（12.6k）

数据：论文 §4.5、附录 H Table 7（9B 策略离线 rollout： 15k 回合 / 573k 状态）

RL 在 LIBERO 全家族上一致带来 +17.6 ~ +21.2 个点的提升

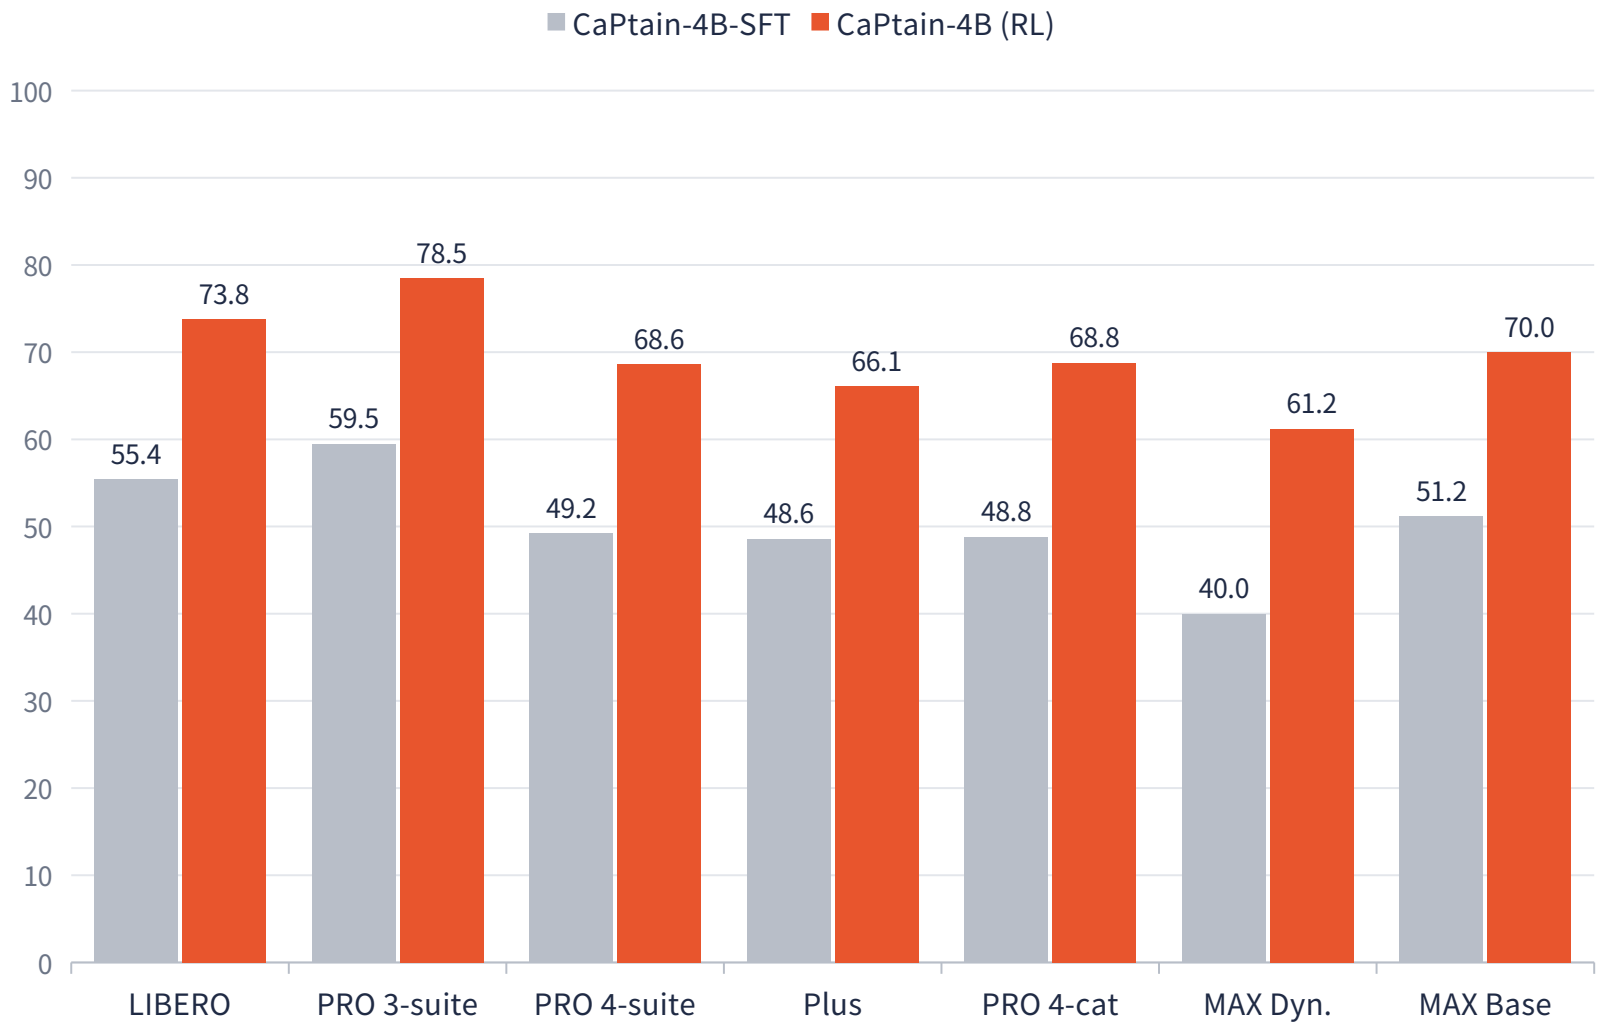

+18.3

LIBERO host （55.4→73.8）

strict 52.1→67.5； 55 翻正 / 11 翻负

7.1% → 2.1%

误报完成率下降

平均 request 数 39.1 → 32.6

$p < 10^{-5}$

主要套件配对 McNemar

基座 Qwen3.5-4B 各套件 ≤ 0.3%

数据：论文 Table 1 / Figure 2 （host success %），p 值见附录 K Table 10

增益在扰动下依然成立： LIBERO-Plus 七个扰动维度全部显著提升

LIBERO-Plus 各扰动维度（host %）

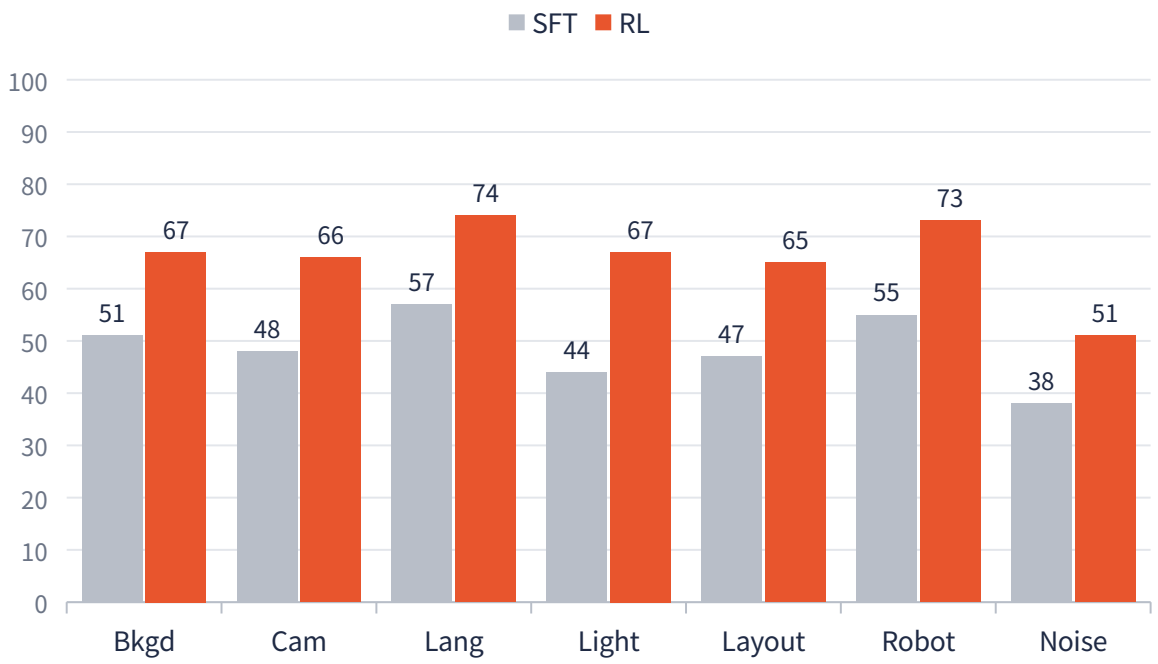

LIBERO-PRO 按套件 × 扰动类型（host %）

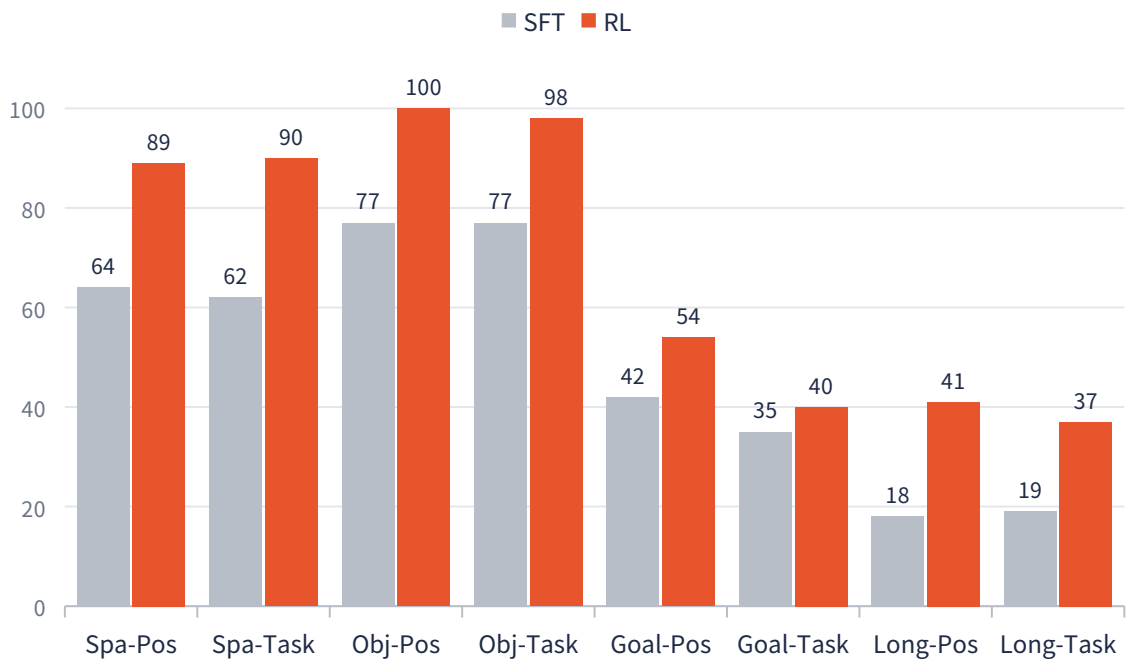

π0.5 **97% → 12.8%**

标准 LIBERO → LIBERO-PRO 位置 + 任务扰动

RIPT-VLA **68.4 vs 69.6**

VLA 上做 RL， LIBERO-Plus 不及基座 OpenVLA-OFT

CaPtain-4B **保留 90%**

LIBERO-Plus / LIBERO = 66.1 / 73.8；未用任何 LIBERO 示教

数据：论文 Figure 3(b)(c)、§4.1、附录 Q Table 14

一个独立的 4B 策略，在 LIBERO-PRO 上超过多个前沿模型 Agent

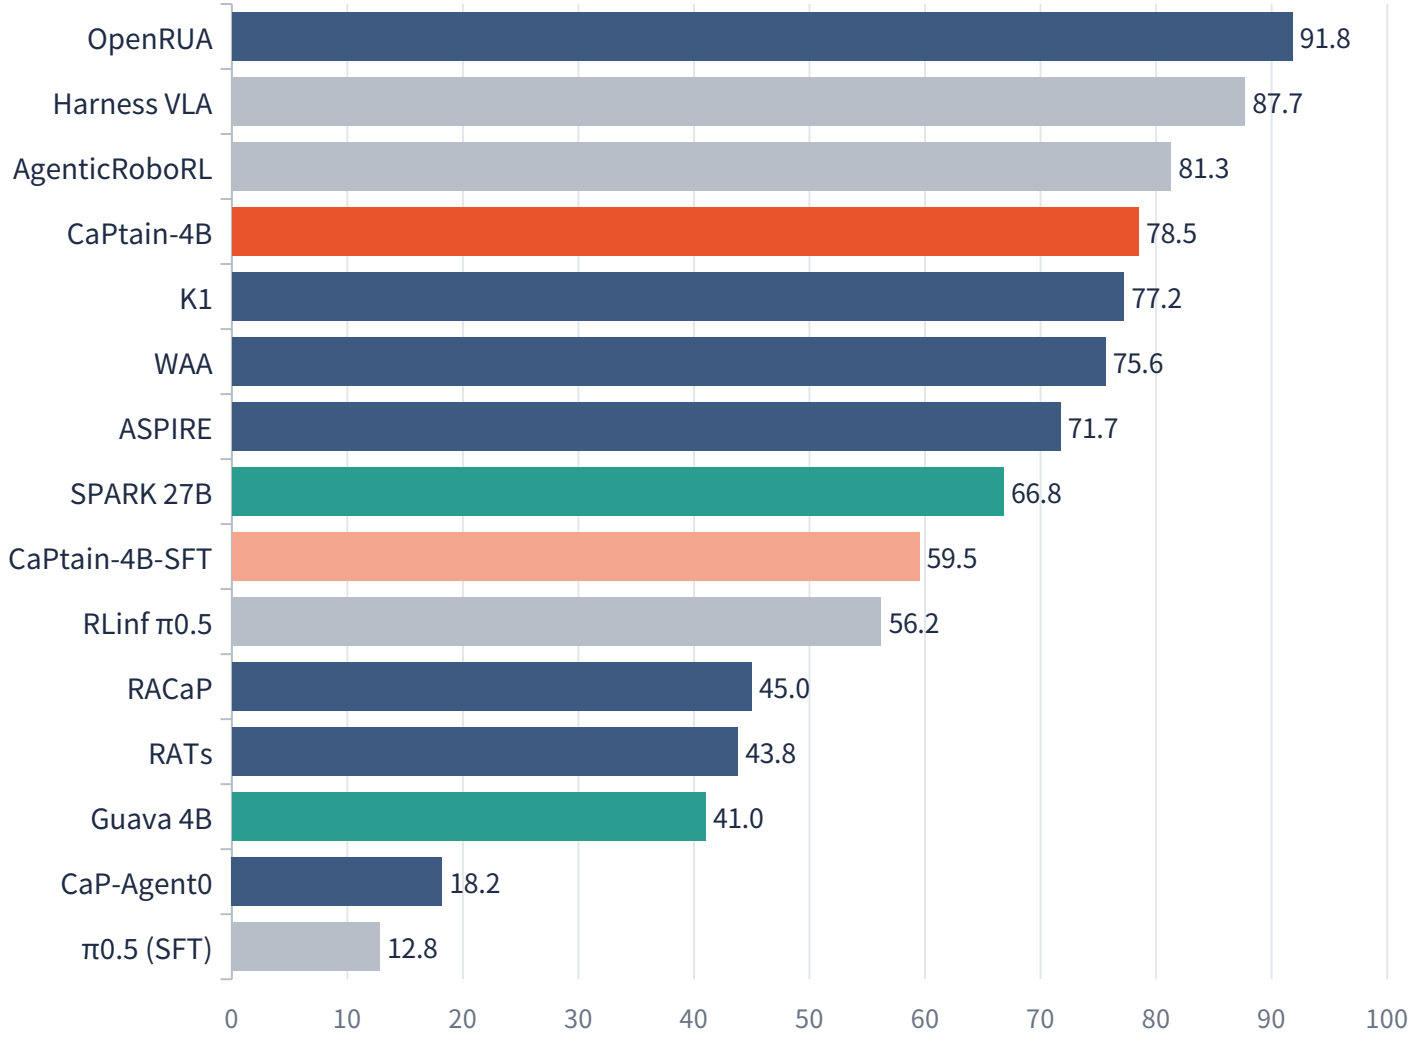

- CaPtain （本文）
- 闭源前沿模型 CaP Agent
- 开源 CaP Agent （无 VLA 技能）
- 端到端 VLA / VLA 辅助 Agent

RL 增益对比（4 套件平均）

+19.4

CaPtain · 低层原语
49.2 → 68.6

+5.9

AgenticRoboRL · 冻结 VLA
65.1 → 71.0

成本：每回合 32.6 request 、 7.3k 输出 token 、约 52 GPU 秒 ≈ **$0.03–0.06**

对比： SPARK / WAA / RACaP $0.18–0.24 ； OpenRUA $8–22

注：两者 RL 起点不同； baseline 协议各异（回合预算、温度、oracle 等）

数据：论文 Table 2 （LIBERO-PRO 3 suites， baseline 取自原论文，协议差异见附录 K）

只在 LIBERO 上训练，零样本迁移：单臂任务强，双臂与陌生机械臂仍是短板

83.3%

SimplerEnv WidowX

ManiAgent (GPT-5) 86.8 · PhysBrain 80.2 · π0.5 57.1

75.0

CaP-Bench

Gemini-3-Pro 73.5 · CaP-RL 7B 62.0；不限步数 Lift/Stack 97.5%

22.6%

RoboTwin 2.0 （Hard）

单臂子集 30.0%； π0.5 同域 46.0 · OpenWAM-α 48.7

0.8%

RoboDojo （双 ARX X5）

Score 1.7； GPT-6 Astra 29.0；同域 VLA Score ≤0.5

失败归因：需双臂同时动作的 RoboTwin 任务 0/35； RoboDojo 首个阻塞失败中 21/46 为 IK / 可达性（X5 俯抓工作空间仅约 0.5 m）；另有反复验证导致 request 耗尽

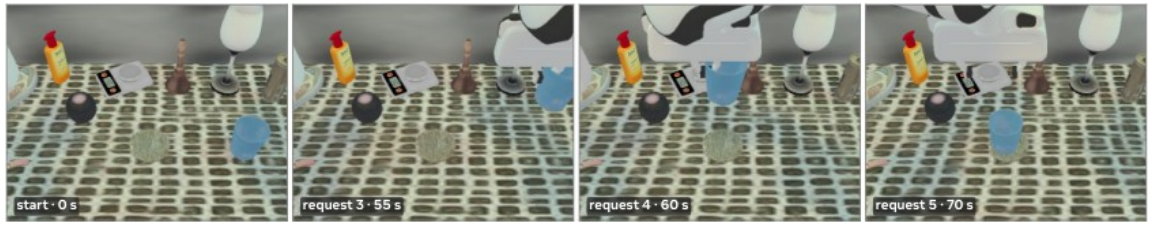

RoboTwin： 抓杯沿 → 按测得偏移搬运 → 放上杯垫（7 request， 77 s）

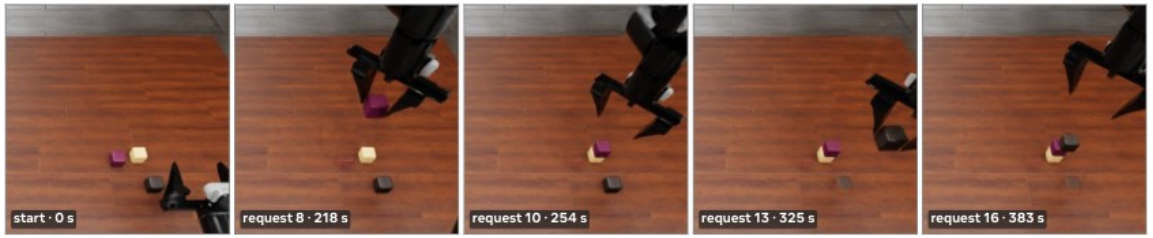

RoboDojo： 受力停止后 recover、旋转 45° 重抓，堆三块（20 request， 413 s）

数据：论文 Table 3、 §4.3、附录 J；图源： Figure 8 （RoboTwin）、 Figure 9 （RoboDojo）

真机：仅在粗糙孪生仿真中适配，零真实数据，完成新物体、新布局任务

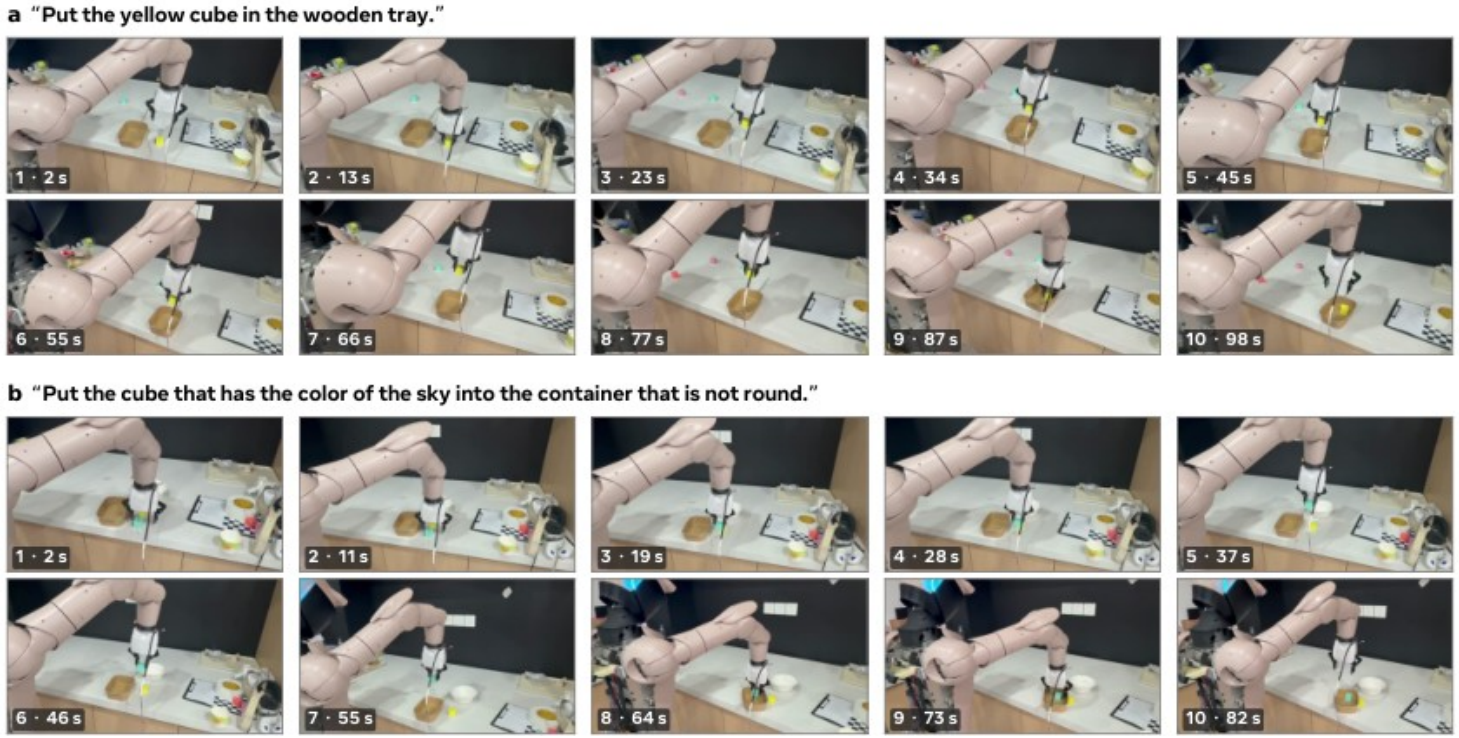

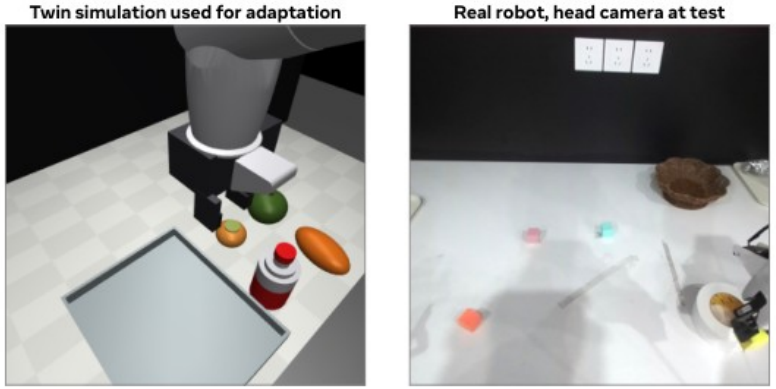

左： XR1 孪生仿真（几何原语、无纹理） 右：真实场景

设置

• Astrabot XR1 + 头部 RGB-D + 腕部相机； API / 回执不变，不用 critic

观察到的行为

• (b) 推理“天空色 = 浅蓝” “非圆 = 矩形托盘”

• 拒用不可靠掩码、切换相机、放下后重新测量再 finish()

仅 2 个成功的定性案例，无成功率统计

图源：论文 Figure 4 （真机回合）、 Figure 5 （孪生仿真 vs 真实场景）；轨迹见附录 O

值得警惕： RL 后期出现 “ finish collapse” ，策略学会过度验证而不肯结束

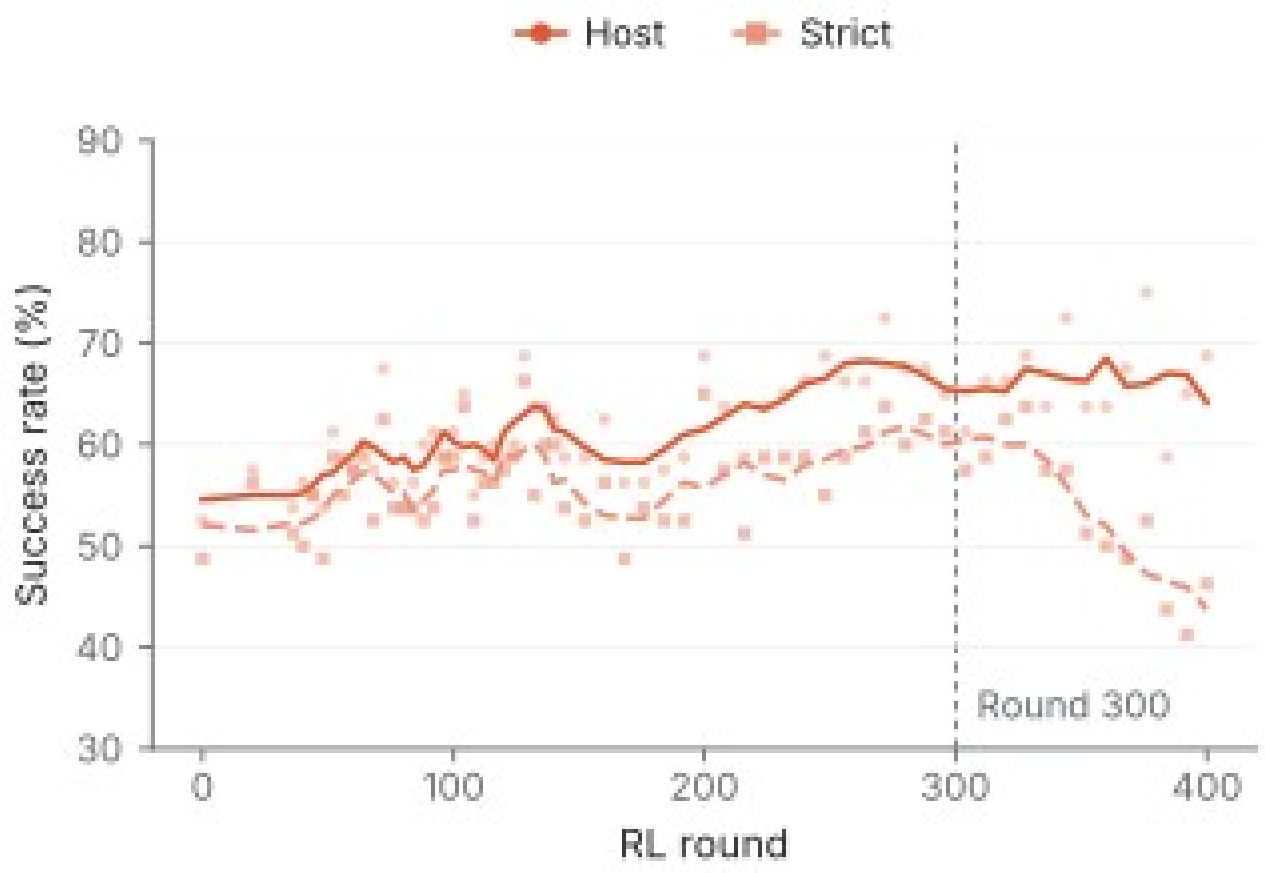

现象（约第 340 轮后）

host 稳定在 ≈ 65%， strict 从 ≈ 60% 跌到 **44%**
丢失的回合在反复验证已完成的场景中耗尽 request

机制：停止决策拿不到 credit

- 成功但没 finish 仍得 0.25
- 成功后的代价有上限（− 0.45 ）
- critic 按 host 成功训练，对所有成功后状态给 V≈1

应对：选用第 300 轮检查点作为 CaPtain-4B （存在一定的挑选成分）；
作者建议为“结束”单独设目标，如 success-and-finished

图源：论文 Figure 7 ；分析：附录 I

局限：长时程与双臂、仿真特权状态、动作空间与评测可比性

长时程与双臂

libero_10 仅 +13.3 （p=0.13，不显著）；双臂同时协作任务 0/35； RoboDojo 0.8%

依赖仿真特权状态

位姿加 2 cm 噪声时 ΔV 相关性降到 0.49， 5 cm 降到 0.36，用策略自身感知仅 0.21 → 真机在线 RL 需外部状态估计

动作空间受限

带保护的笛卡尔位置原语无法表达持续施力（CaP-Bench Wipe 无法执行）；行为覆盖受 SFT 数据限制

训练依赖前沿模型

SFT 轨迹由 GPT-6 Astra 等生成（654M token）：测试时不需要，但训练离不开

评测可比性

baseline 取自原论文，回合预算 / 温度 / 试验数 / oracle 使用各异； RoboDojo 用可达布局与专用适配

速度与外部服务

LIBERO 每回合平均 417 s （8 回合共享 GPU）；感知依赖 SAM 3 与 Molmo2-8B，“4B” 不是全部算力

Takeaways： 机器人操作也可以像语言 Agent 一样做后训练

1

低层原语是 RL 增益的来源

没有技能和 VLA，抓取、接近、放置都写在代码里 → RL 优化的是操作本身（+19.4 vs 冻结 VLA 上 RL 的 +5.9）

2

非对称 critic + 同时间索引 ΔV

critic 读仿真物理状态、 policy 只看相机；时间流逝不产生 credit，感知请求只占 1.3% 的 advantage 质量

3

工程细节决定成败

每步累积 1,024 回合对抗梯度噪声；宽布局防止背坐标；起点覆盖全任务；“结束”需要独立信号

4

仍待解决

终止决策（finish collapse）、长时程与双臂、力控任务，以及训练对前沿模型数据和仿真特权状态的依赖

arXiv 2610.40799 • 代码、 SFT 数据与 CaPtain-4B 权重均已开源（据论文）