TinyAstral

Transferring Self-Evolving Harnesses to Tiny Generalist Manipulation Agents

论文解读 · Kehong Gong 等 · Huawei Technologies / Noah Research Institute · arXiv 2610.41216

一句话总结：先在统计门控下自进化大教师的 harness，再把其推理与恢复行为蒸馏进 4B 小模型——小模型接近教师性能，只需约 1/5 的加速器时间。

33.4% → 63.6%

harness 进化后教师 RoboTwin 成功率

62.8%

TinyAstral-4B 学生（同一 harness）

4.9×

教师 / 学生 部署加速器 · 秒之比

机器人智能体 = 规划器 + harness，两者共同决定性能

规划器（Planner）决定“做什么”

选哪个物体、哪个部位、参照物与空间关系

用哪只臂、什么顺序、何时结束（调用 done）

每轮：一段推理 + 恰好一个工具调用，不输出关节角 / 坐标

Harness 决定“怎么做”

感知： SAM 3 分割 + 深度点云

抓取 / 放置几何、无碰撞运动规划、闭环纠正

工具返回实测结果（如 OFF_TARGET + 偏移量）、任务记忆、恢复逻辑

两条已有路线，各有短板

Harness 进化

冻结模型、改外壳（PhysEvo、HarnessPAI、RoboRSI…）

但收益依附于大模型，推理贵

智能体蒸馏

用强模型轨迹训小模型（Guava、World Action Agent…）

但教师 harness 通常是静态的

本文的问题

先进化大教师的 harness，进化收益能否随蒸馏转移到小模型，从而低成本部署?

两阶段方案：进化 harness → 冻结 → 蒸馏小学生

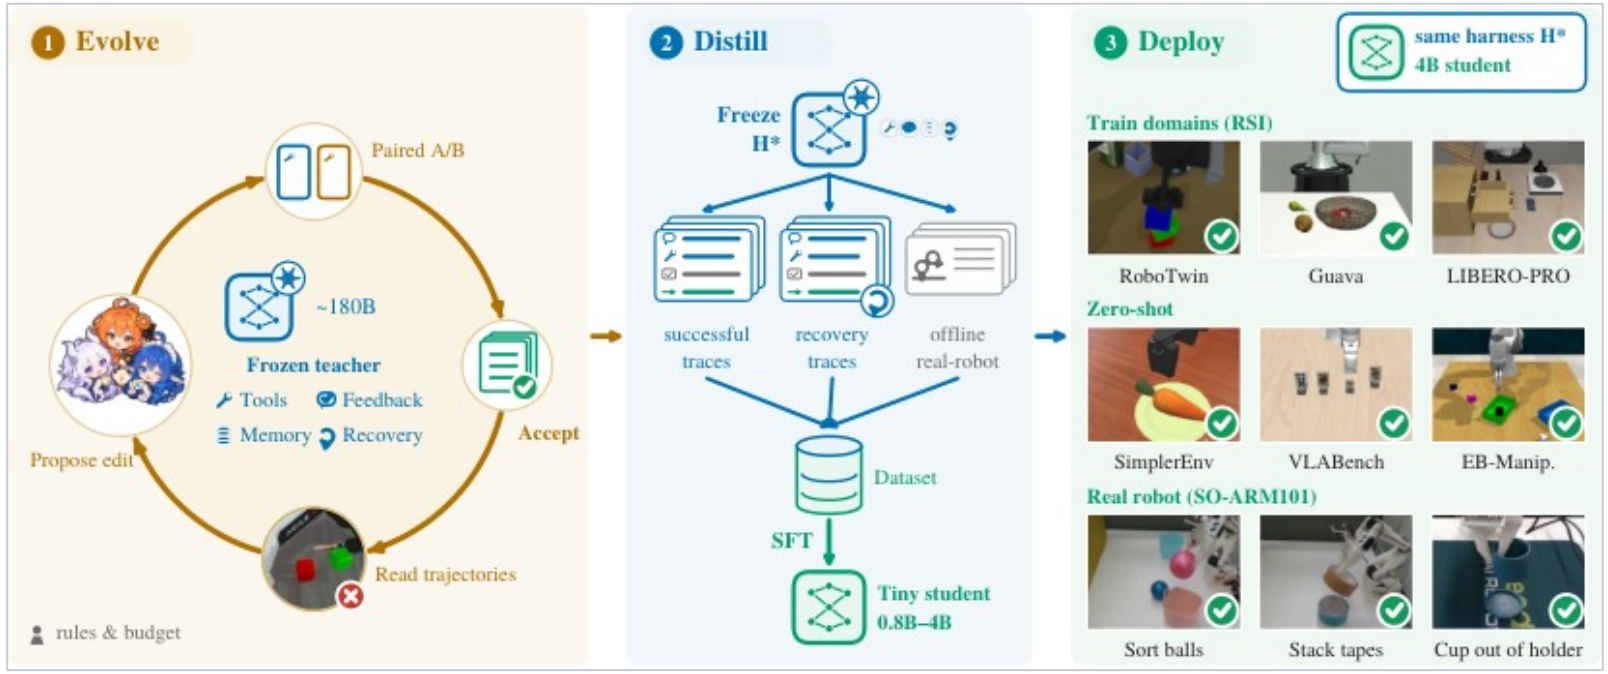

① Evolve

教师权重冻结；前沿 LLM「master」读轨迹、提 harness 编辑，配对 A/B 统计检验通过才接受

② Distill

冻结最终 H*，收集成功轨迹 + 恢复分支 + 离线真机数据， SFT 训练 0.8B–4B 学生

③ Deploy

学生替换教师，放进同一 H*；评测 3 个训练域 +3 个零样本基准 +SO-ARM101 真机

阶段一： harness 编辑必须通过预注册的配对统计检验

1. 读轨迹

在开发种子上运行 H_k；把失败归入 10 类（放偏、虚假完成、缺原语、记忆错误、认错实例…）

2. 提编辑

新工具 / 原语、更诚实的返回、感知修复、失败处理、局部修改任务记忆

3. 配对检验

候选 H′ 与父版本在 ~1,150 个预注册 (task, seed) 对上交错并行运行

接受 / 否决规则

接受：触发集合 J 上配对增益的 task 聚类 bootstrap 单侧 97.5% 下界 > 0，且目标簇净胜场 > 0

否决：未触发集合 U 退步 ≥ 2 pp （双侧 95% 上界 < 0）

前置：方向筛选（目标簇增益 95% 上界 < +2 pp 即丢弃）；中途 futility 早停

防作弊：不得按任务名分支； system prompt 与已有工具描述逐字节不变；新组件须显式 trigger + 日志 marker + 代码审计

能力台账（全程）

296	候选能力
121	采纳
142	拒绝
101	最终 H* 中的能力

只改 harness、不改权重，教师 RoboTwin 成功率接近翻倍

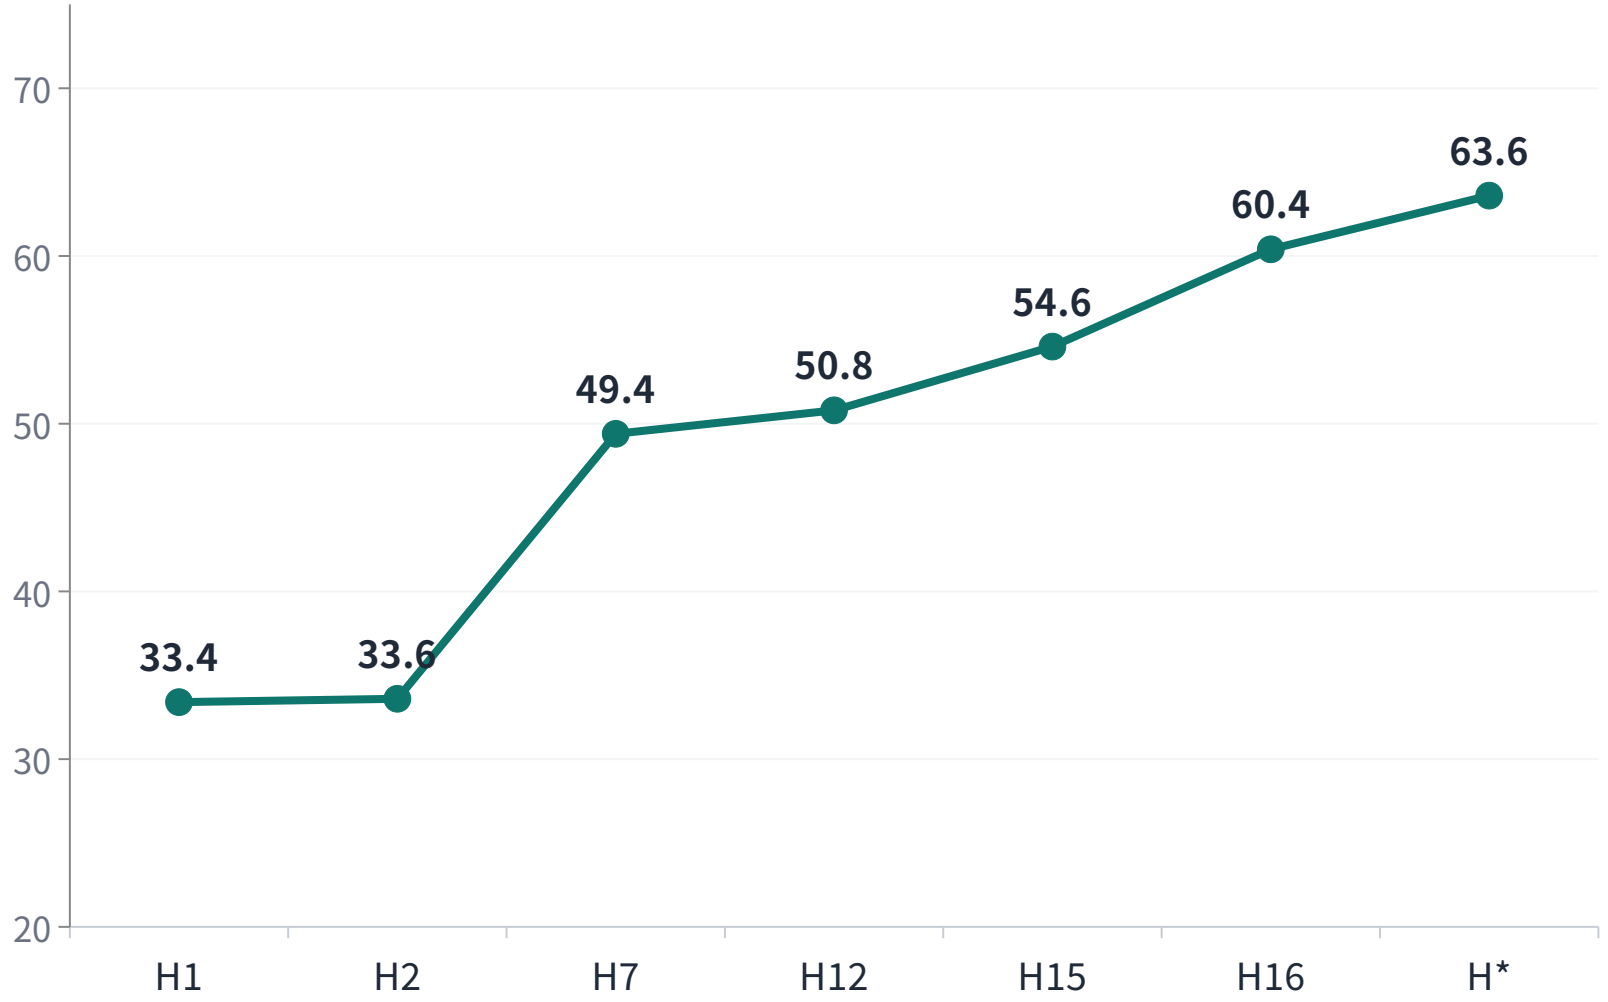

+30.2 pp

H1 → H*： 33.4% → 63.6%

说明

H_k 为第 k 个被接受的主线快照

最终集成阶段 7 个候选中接受 3 个

任务记忆仅用于 RoboTwin：每任务一条终态说明，不含动作，评测时只读

进化收益可以转移：各版本学生都紧跟对应教师

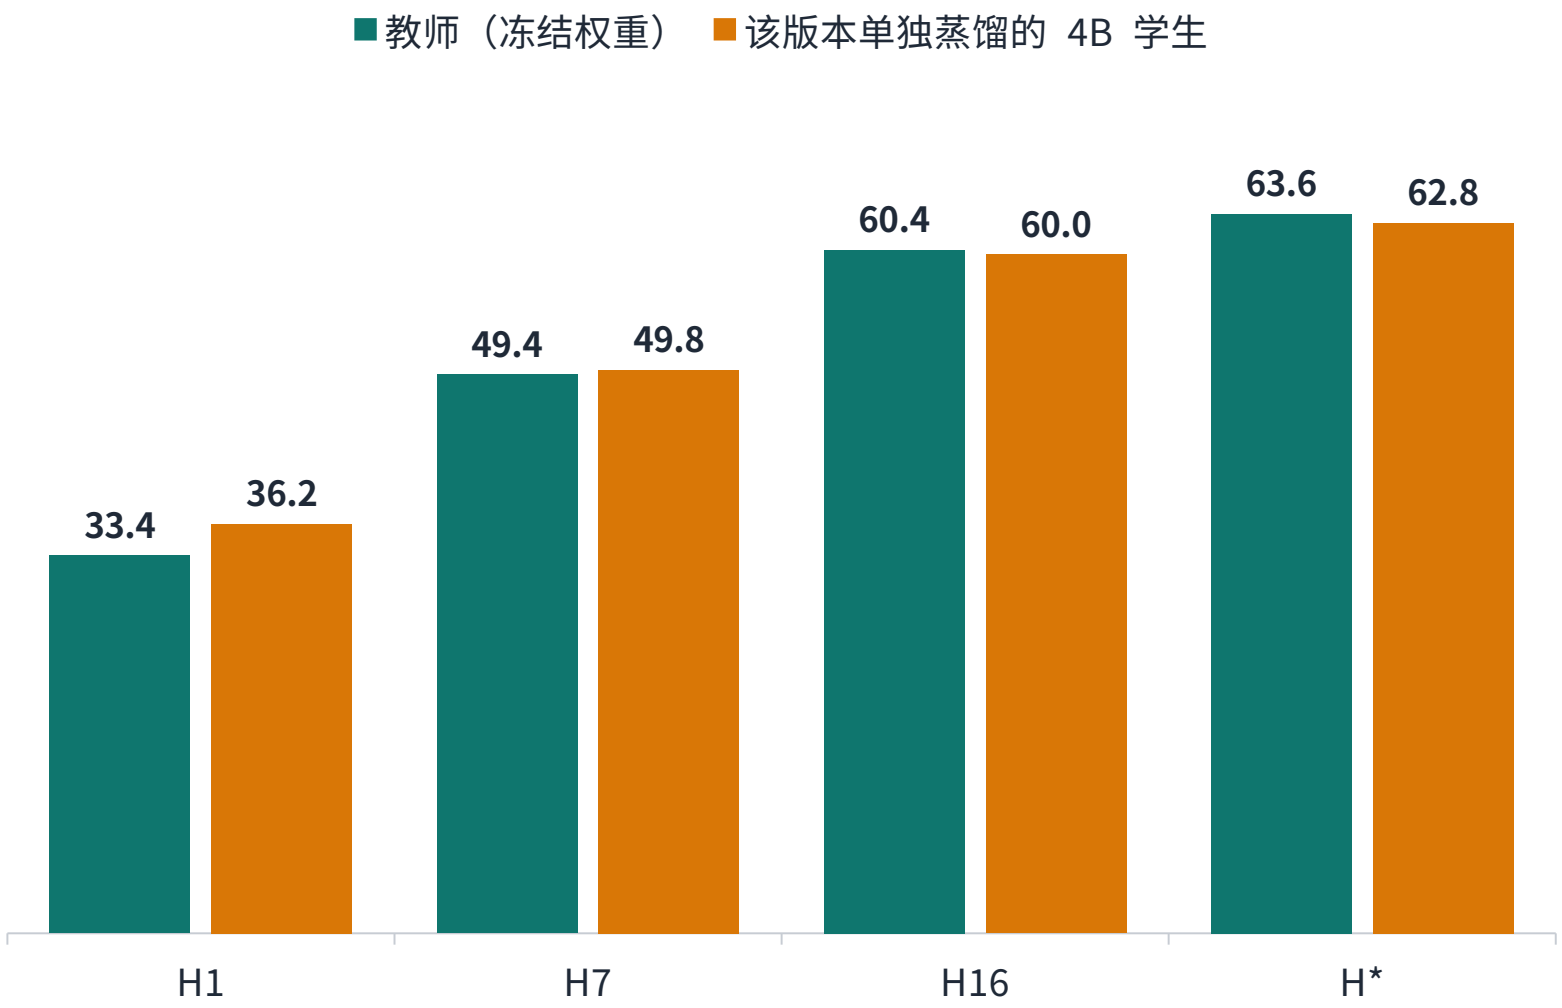

跨规划器迁移

DeepSeek-V4.1-Flash （552B）

未参与进化， H1→H* +30.6 pp

未训练 Qwen3.5-4B

同样受益： 14.6% → 41.2%

无需针对模型改 harness

蒸馏的额外价值

同在 H* 下： 62.8% vs 41.2%

蒸馏比未训练 4B 高 21.6 pp

阶段二：蒸馏配方 = 推理 + 恢复分支 + 严格成功 + 真机辅助

保留教师推理

目标 = <think>…</think> + 下一个工具调用；损失只算最后一个 assistant 回合

恢复分支

从成功轨迹第 k 步无模型回放，注入扰动（滑落、目标移动 6–10 cm 、抓空、推不到位），教师在线继续；仅保留扰动生效、回放一致、严格成功的分支

只收严格成功

温度 0；失败种子最多以 0.7 重试两次；须 done 结束且终态成功，“成功后又破坏”的丢弃；成功标签不进训练消息

离线真机辅助

AgiBot World 、 Fractal 、 Bridge V2 、 DROID 、 UR5 转成 harness 格式；推理用 STaR 式合理化并质检

训练数据： 83,753 个决策样本

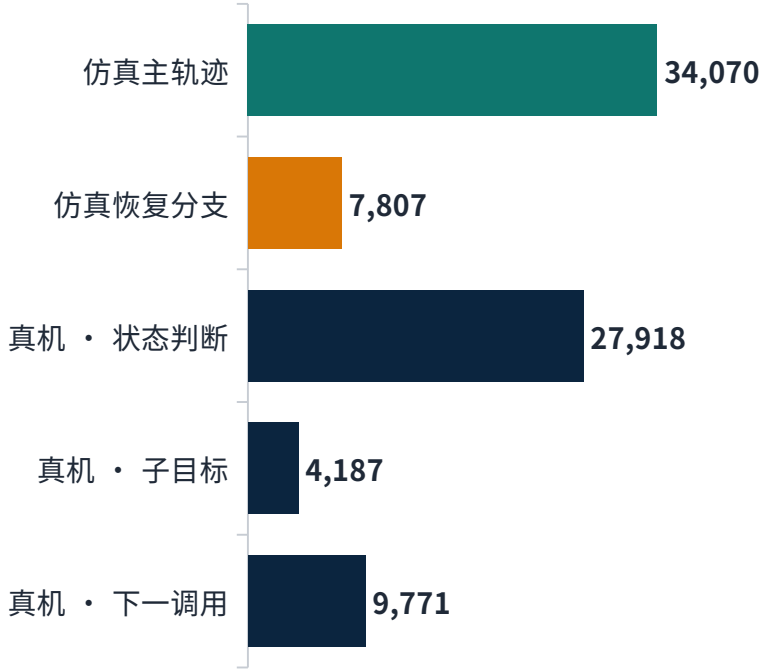

仿真 41,877 条： RoboTwin / Guava / LIBERO 主轨迹 13,857 / 9,054 / 11,159 ，恢复分支 3,471 / 2,048 / 2,288

全参微调 Qwen3.5-4B 语言部分， 2 epoch ， lr 1e-5 ，视觉编码器冻结

训练域： 4B 学生与教师差距均在 1.7 pp 以内

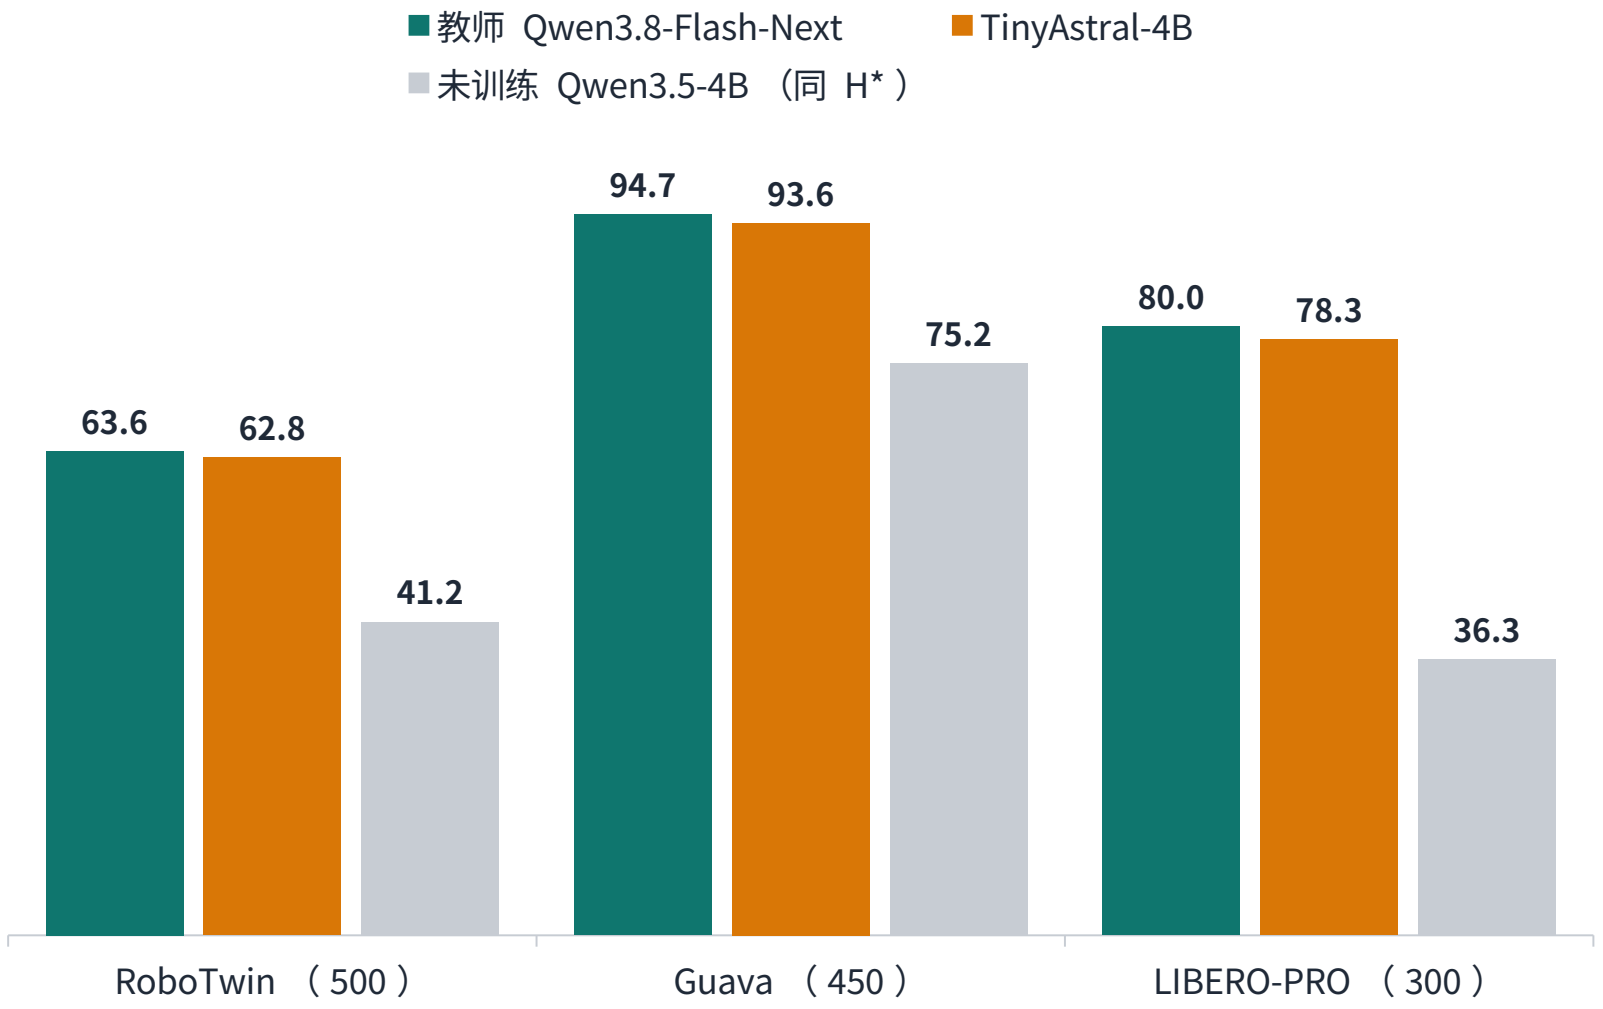

−0.8 / −1.1 / −1.7

学生相对教师的差距（pp）

+18.4 / +42.0

相对未训练 4B： Guava / LIBERO-PRO （pp）

把未决结果全算成功，未训练 4B 在 LIBERO-PRO 最多也只有 57.3%

LIBERO-PRO 训练数据只来自 LIBERO-90

同 episode 对比：胜过开源对手与“同教师 + 别家 harness”

Guava （15 任务 × 30 种子）

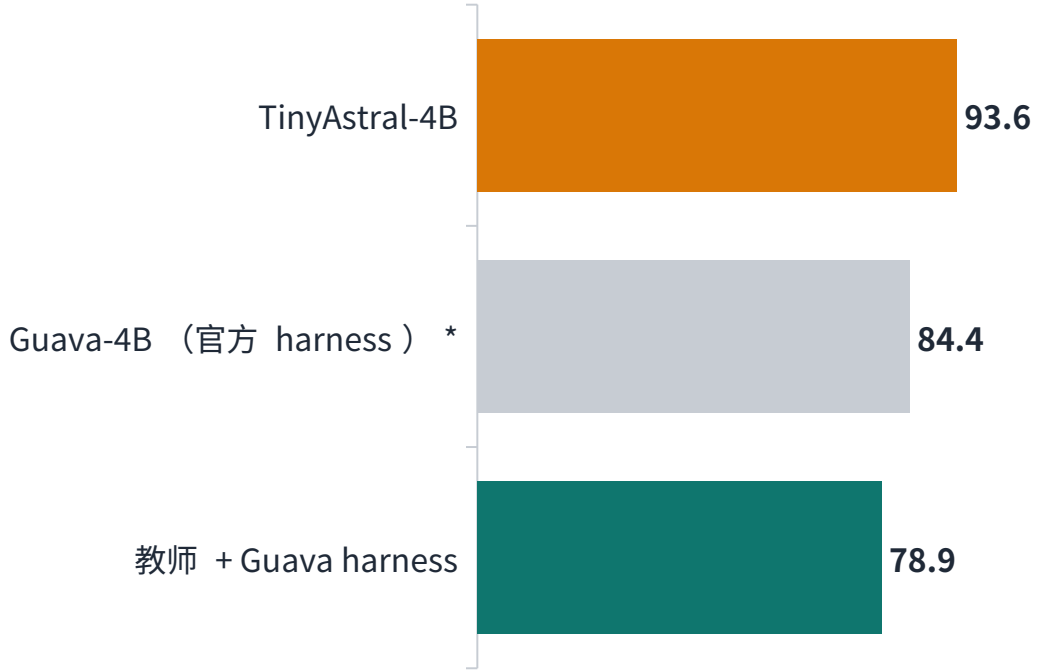

LIBERO-PRO （300 episode）

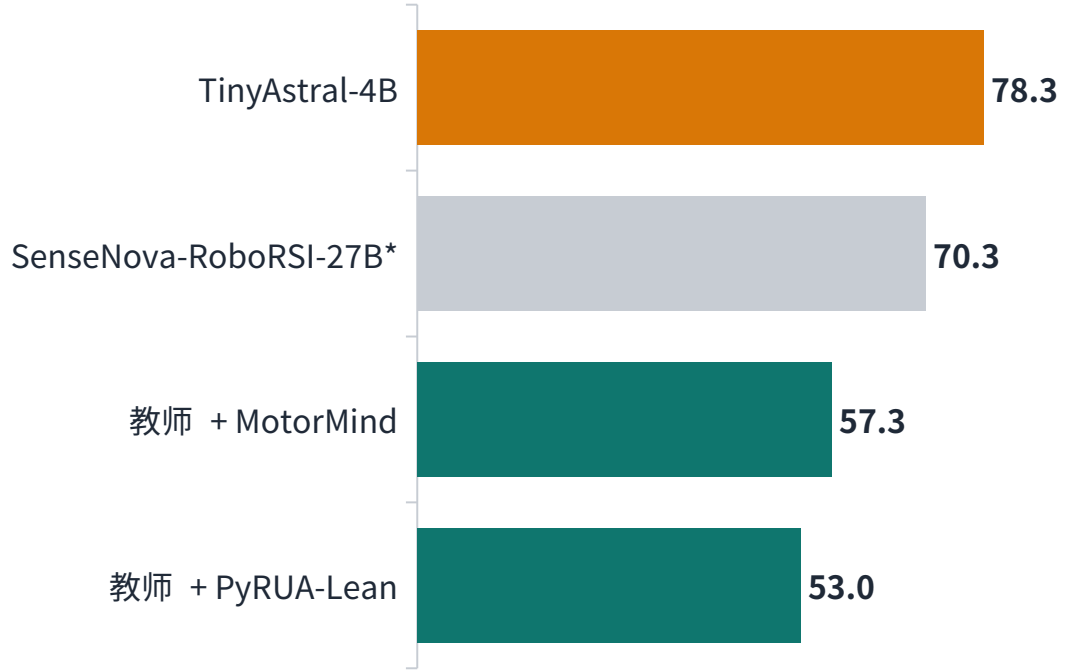

RoboTwin： PyRUA-Lean-4B 仅 12.8% （64/500）

其训练 / 自评依赖逐步环境成功信号；本协议不提供该信号，它常过早宣布成功

说明：同一教师模型放进别家 harness 明显更差

→ 优势来自进化的 harness + 蒸馏策略，而非只靠底座模型（各竞品协议见附录 B）

零样本基准： 4B 学生与 552B 规划器相差不超过 2.4 pp

SimplerEnv Google VM

66.6%

已发表 π0-FAST 61.9
（Fractal 微调）

SimplerEnv WidowX

88.5%

已发表 π0-FAST 32.1
（Bridge 微调）

VLABench （500 episode）

41.2%

已发表 π0 29.4 / π0-FAST 43.1
（VLABench 微调）

EB-Manipulation （228 episode）

27.6%

GPT-4o 28.9
（GT 坐标与框 + ICL 示例）

⩽ 5.0 pp

与教师的差距

⩽ 2.4 pp

与 552B DeepSeek-V4.1-Flash 的差距

+10.0 / +13.6

相对未训练 4B： Google VM / VLABench （pp）

缩到 0.8B 多数基准几乎不掉分，LIBERO-PRO 是例外

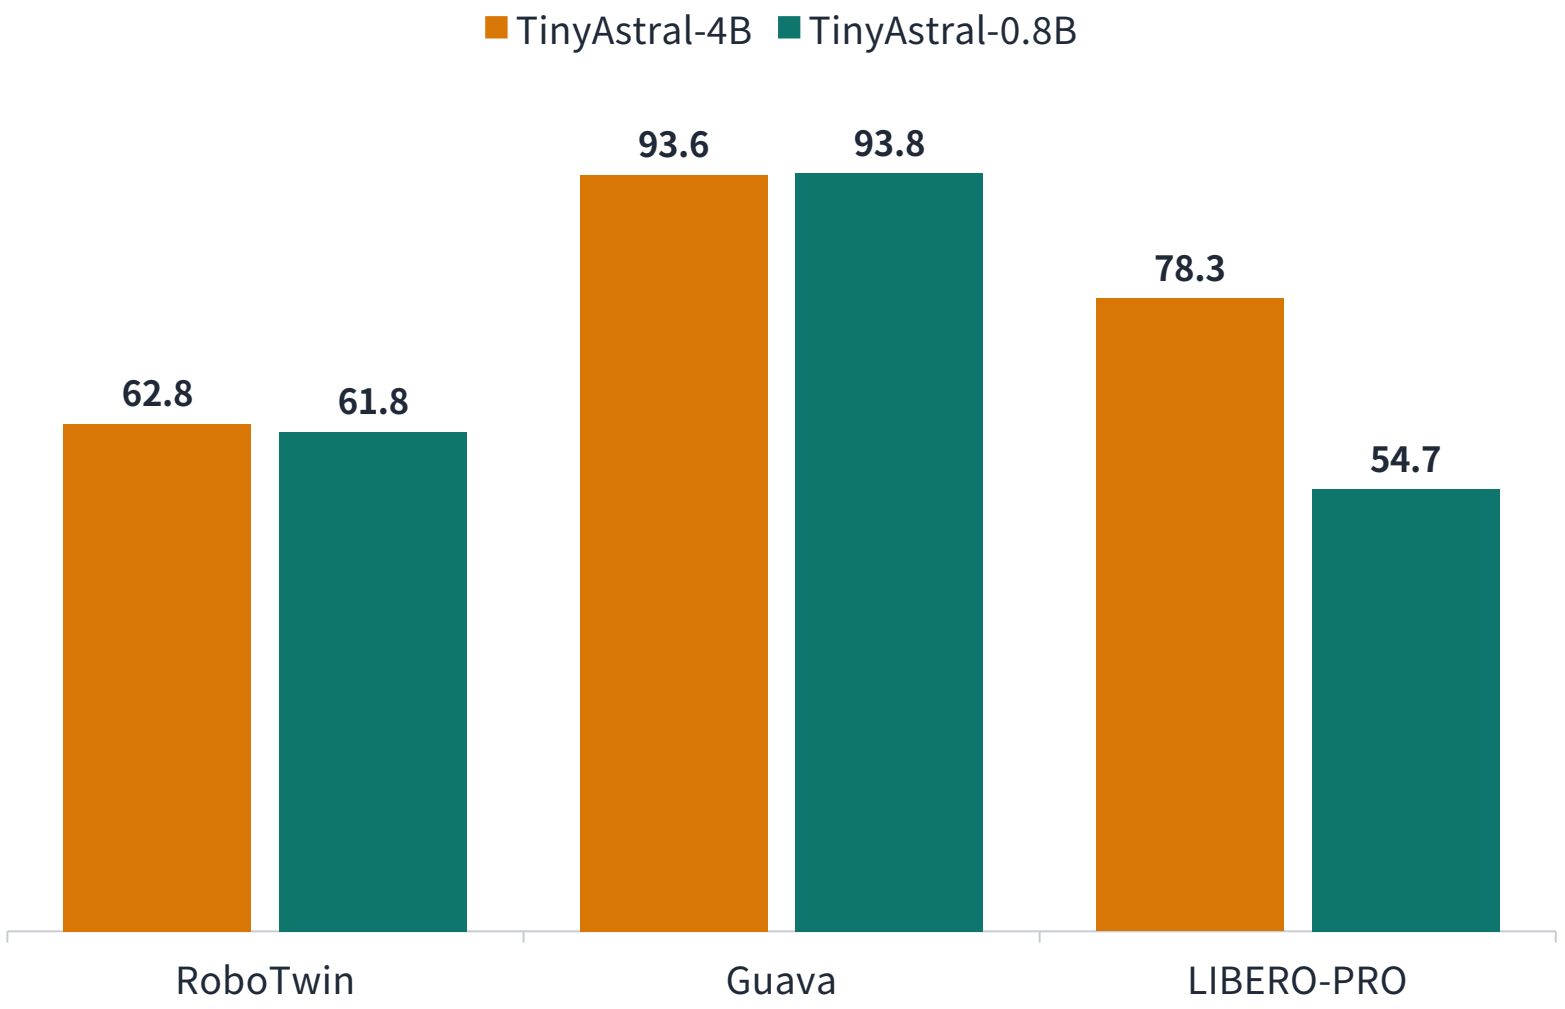

−23.6 pp

0.8B 在 LIBERO-PRO 的降幅（78.3 → 54.7）

⩽ 3.0 pp

零样本 4 个设置上 0.8B / 2B 与 4B 的差距

0.8B、2B 与 4B 使用相同数据与配方

模型规模的影响在 LIBERO-PRO（含语言 / 空间扰动）上最明显

消融：保留教师推理是影响最大的蒸馏要素

去掉推理文本（样本其余不变）带来的降幅（ pp ）

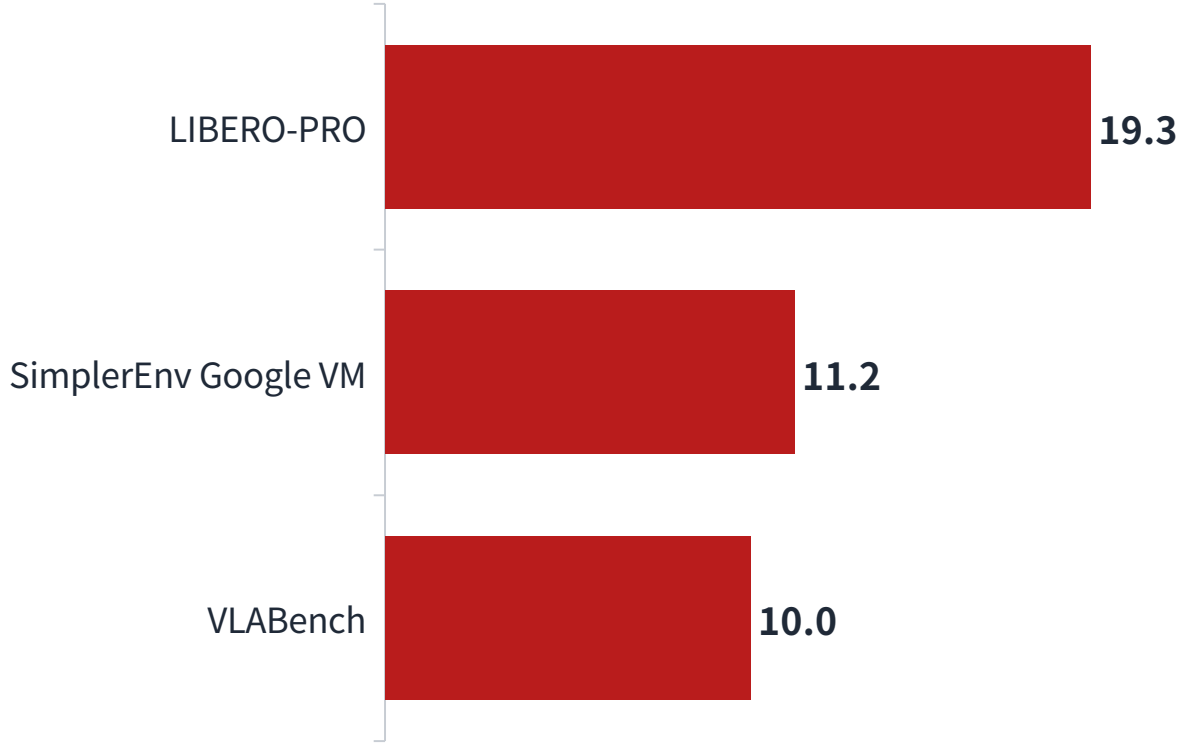

LIBERO-PRO 耗尽调用上限的 episode： **49 / 300** （无推理） vs **7 / 300** （完整配方）

真机辅助数据：作用在真实图像上

held-out 真机 episode 下一步调用准确率

0.235 → 0.923

但对仿真成功率…

7 个仿真设置上无统计可检测的变化

→ 真机数据的收益在于真实观测上的离线决策，并未提高仿真分数

学生学会了自主恢复：换描述、换抓点、按实测补救

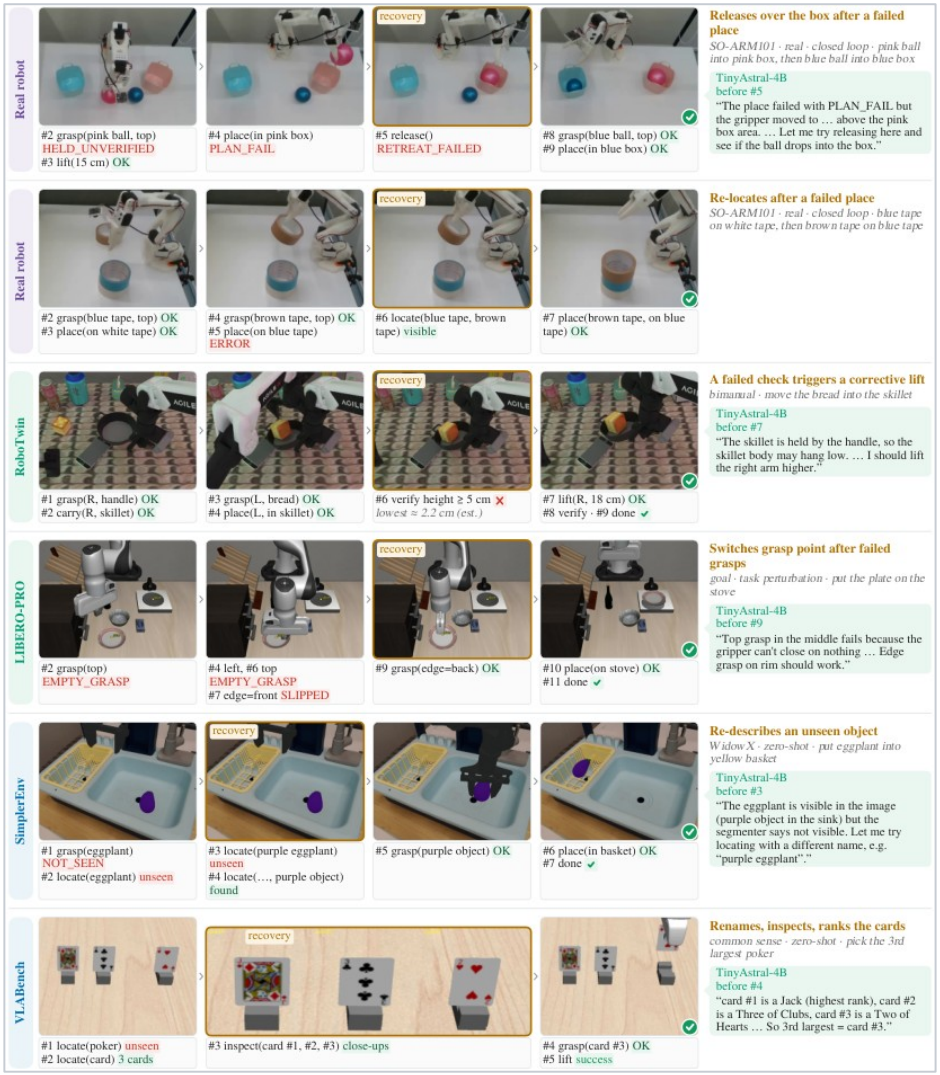

真机 SO-ARM101

place 返回 PLAN_FAIL → 在盒子上方释放；放置失败后重新 locate

训练域

verify 发现高度不足 → 纠正性 lift；顶部抓取 EMPTY_GRASP → 改抓边缘

零样本

eggplant NOT_SEEN → 改述为“purple object”；VLABench 特写检查卡牌后排序

图中从上到下：真机 ×2 / 训练域 ×2 / 零样本 ×2

对照未训练 4B： 失败多因反复无效调用耗尽预算

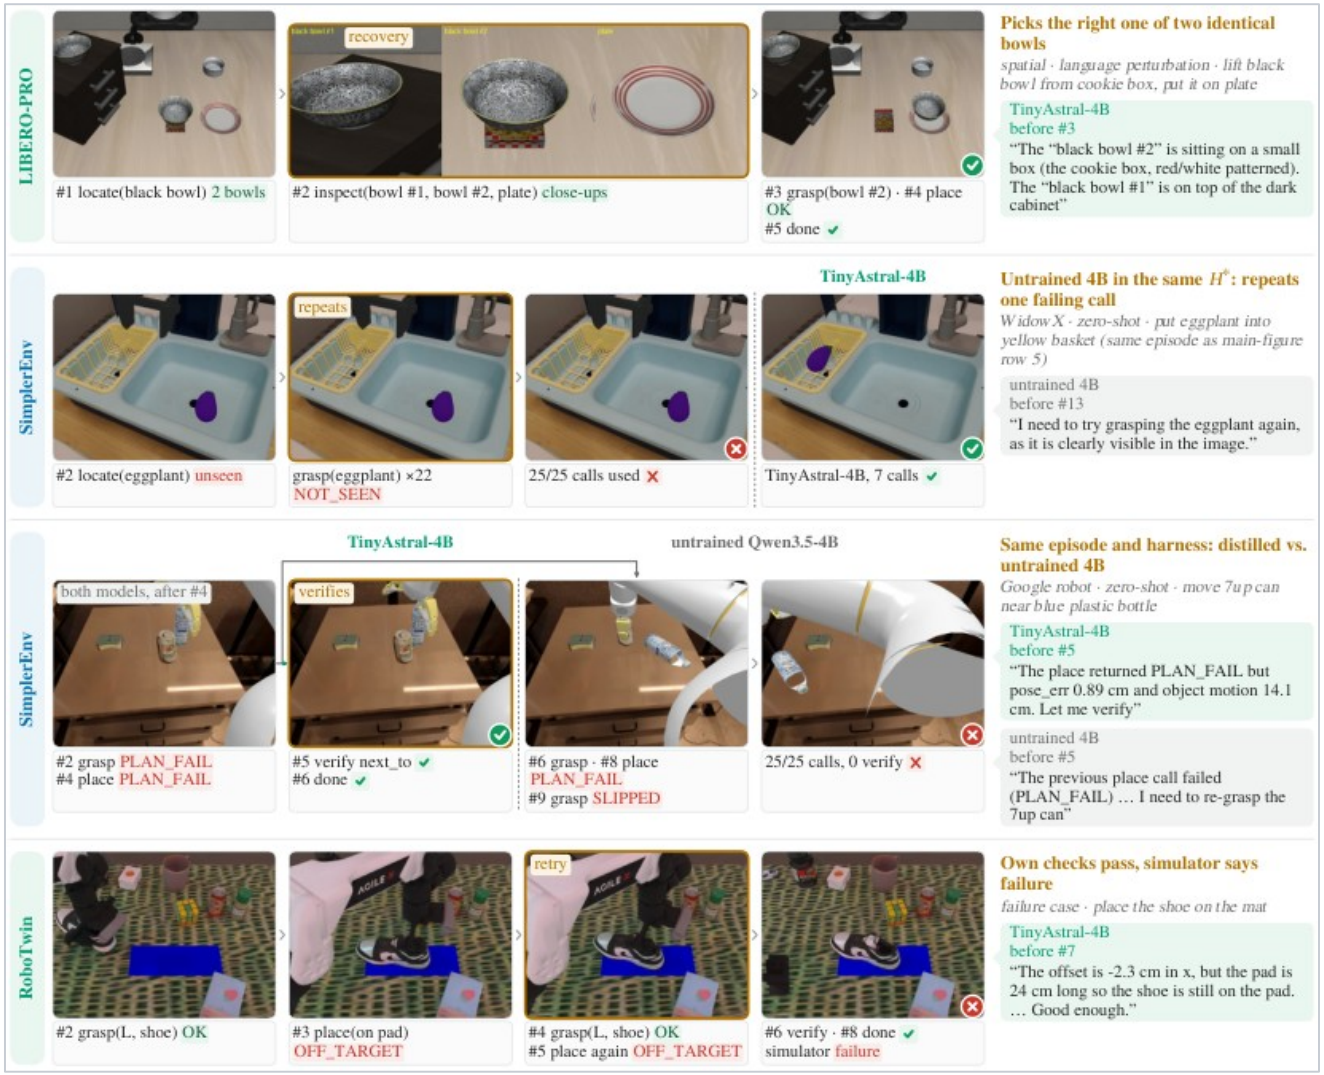

171 / 271

学生成功而未训练 4B 失败的零样本 episode 中， 63% 因未训练模型耗尽调用预算

典型对照（第 2 行）

未训练 4B 重复 grasp(eggplant) 22 次（NOT_SEEN）至预算耗尽；学生改述目标， 7 次调用成功

学生的失败（第 4 行）

鞋子 OFF_TARGET 2.3 cm ，学生自检通过并宣布成功，仿真器判失败——自检容差与基准判定不一致

部署成本：学生约为教师 1/5 、 552B 模型 1/10 的加速器时间

加速器 • 秒 / episode （加速器数 × 中位时长）

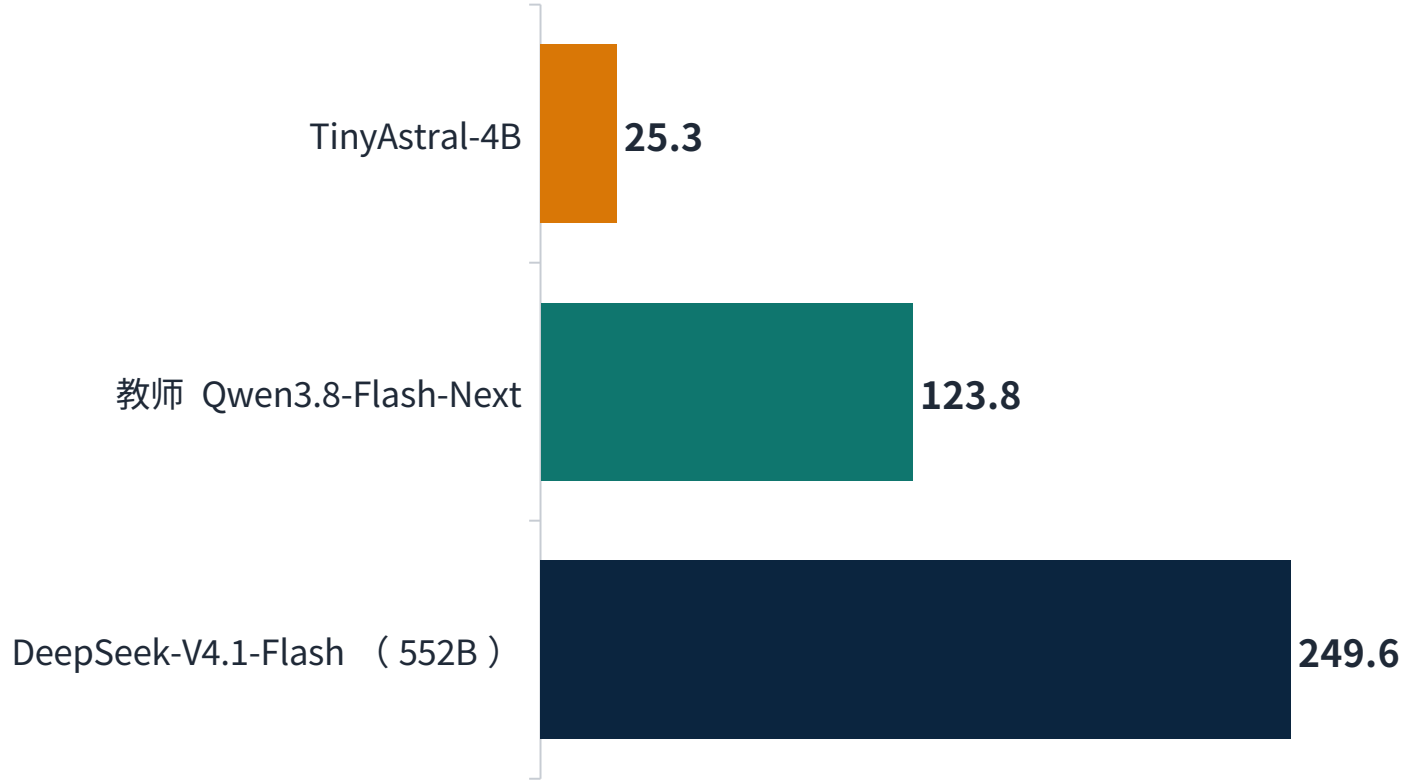

中位 episode 时长（含仿真与感知）： 学生 25.3 s ，教师 31.0 s ， DeepSeek 31.2 s

4.9×
vs 教师

9.9×
vs DeepSeek

部署配置（同型加速器）

学生： 1 卡， bf16 ，无量化、无投机解码

教师： 4 卡， FP8 + 张量并行 + 投机解码

DeepSeek-V4.1-Flash： 8 卡 + 投机解码

注意：仅 20 个 episode ；墙钟时间差距较小，节省主要体现在加速器占用

评价：结论扎实，但适用范围限于高层工具调用式 harness

亮点

多快照蒸馏：四个版本学生都紧跟教师，直接验证“进化收益可转移”

RSI 统计纪律严格：预注册检验、配对交错、 trigger 审计、种子三分、完整台账

评测相对公平：不给成功信号、严格成功、固定分母、同 episode 配对、同教师放进竞品 harness

实用：单个 4B 覆盖 6 个基准 + 真机，单卡 bf16 部署

局限与疑问

RSI 与任务记忆只在 RoboTwin 上，其他基准收益的来源没有分解

感知、几何、运动规划都由 harness 承担，“4B≈552B” 只在这种高抽象接口下成立

只蒸馏严格成功轨迹，学生上限受教师约束，未展示超越教师

master 依赖前沿 LLM， RSI 总成本未报告；成本只测了 20 个 episode

自检容差可能误判成功；真机仅展示少量任务，缺乏大规模统计

Takeaway

1. **Harness 是一等公民：**只改外壳、权重冻结，教师 RoboTwin 成功率 33.4% → 63.6% ，且对其他规划器同样有效

2. **进化收益可蒸馏：**四个 harness 版本的 4B 学生都紧跟对应教师，最终 62.8% vs 63.6%

3. **小模型够用且便宜：**零样本与 552B 相差 ⩽ 2.4 pp ，部署加速器时间约为教师 1/5

4. **推理是蒸馏关键：**去掉推理文本最多掉 19.3 pp

arXiv 2610.41216 · TinyAstral （Huawei, 2026-10-30）