论文解读 · arXiv:2610.42096 · 2026-10-30

CausalWAM

Learning the Causes of Actions in World Action Models

Juntao Cheng, Jinzhou Tang, Fan Feng, Henrik I. Christensen, Yujia Zheng （UIUC · UCSD）

一句话总结

世界动作模型必须编码整个场景才能预测，但动作只取决于其中一块。作者证明：对“潜变量→动作”依赖施加稀疏约束，仅凭示范即可把这块动作相关潜变量整体识别出来；据此在 Cosmos 3 上加一条稀疏路由支路，RoboCasa365 成功率 0.24→0.43，真机叠方块 0.46→0.82。

问题

预测要看全场景，动作只取决于一小块——拟合示范分不开二者

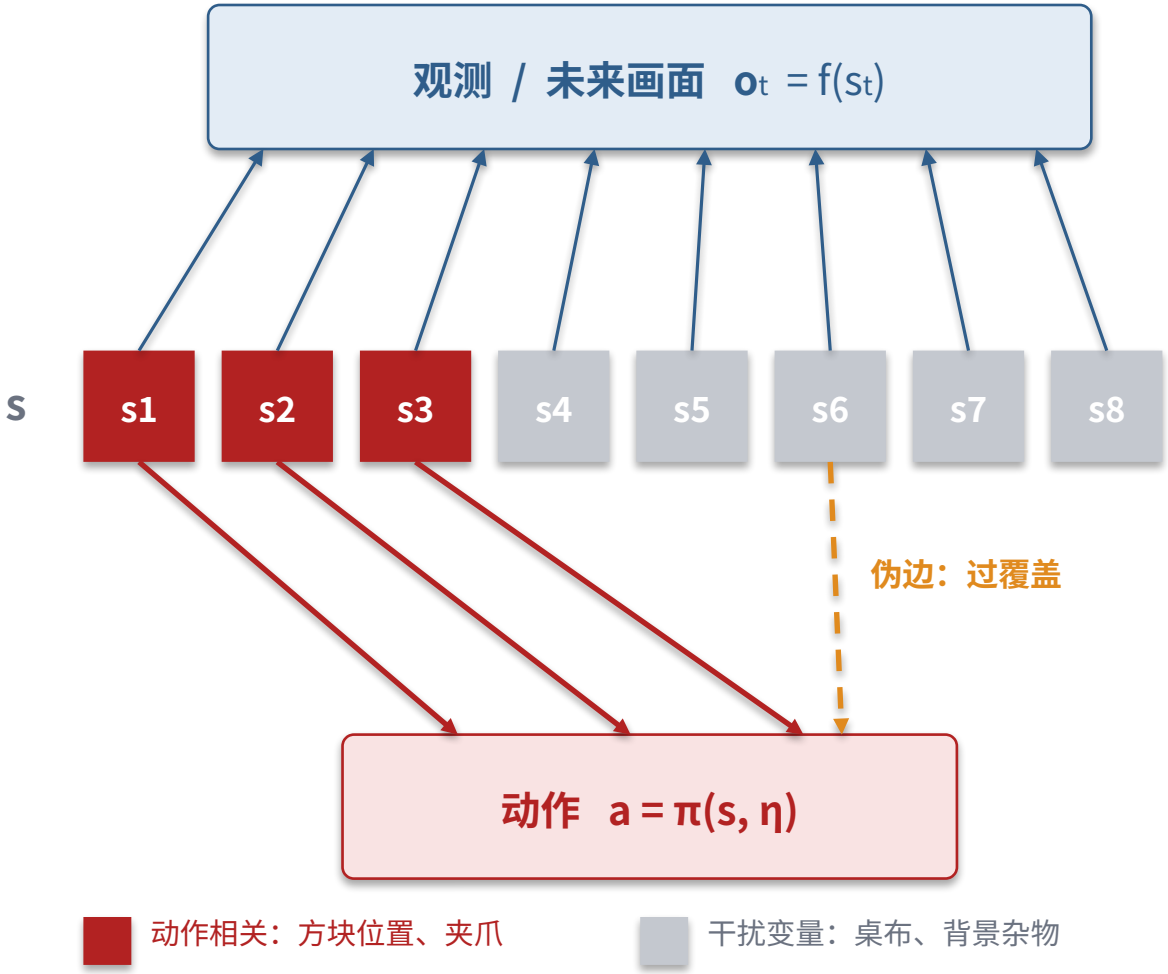

为什么分不开？

- 对潜变量做任意可逆变换 ϕ，(o, a) 分布不变
- 变换可以把桌布信息混进“动作用的”变量里
- 足够灵活的动作头照样拟合示范，损失一样低

后果：过覆盖（over-coverage）

学到的动作机制依赖的潜变量比真实的多，干扰变量经由“伪边”进入动作端

本文问题：只用示范，能否把“导致动作的”与“预测需要的”分开？

定位

已有可识别性条件在机器人示范中难以满足；本文只约束动作端

辅助变量 / 时序依赖

非线性 ICA 用域、时间索引；因果过程要求足够的时序依赖或潜动力学条件

× 示范中有的时间步近似独立，潜动力学不一定马尔可夫

已知目标的干预

通过可控干预锁定潜变量

× 机器人场景中干预代价过高或根本做不到

识别全部潜变量

函数类限制 / 依赖结构稀疏，条件要对所有潜变量成立

× 桌布、杂物这类机器人可以忽略的变量也要满足条件

本文：让动作自己指出哪些潜变量相关

只在动作端加稀疏约束，预测端照样使用全部潜变量。不需要干预、不需要时序依赖、不对隐藏 regime 的演化作假设，也允许动作相关变量与干扰变量统计相关。

理论主线：稀疏把“至少这么多”变成“恰好这些”

命题 1 下界

不加稀疏

$\| \hat{I}_i \|_0 \geq \| I_i \|_0$ （每维动作）

拟合示范只保证每维动作依赖的潜变量不少于真实的；可能多出伪边

定理 1 结构识别

+ 稀疏 $\| I(J_{\hat{\pi}}) \|_0 \leq \| I(J_{\pi}) \|_0$

$I(J_{\hat{\pi}}) = I(J_{\pi}) \cdot P_{\rho}$

潜变量→动作的二部图被识别，最多差一个置换 ρ

定理 2 块识别

同上条件

$C_t = \hat{s}_{t,\rho(I_A)} = h(s_{t,I_A})$

动作用的紧凑状态是真实动作相关块的可逆重编码，与干扰变量分离

关键卖点：结论是函数层面的（C_t 只依赖并决定 s_{IA}），无论动作相关变量与干扰变量之间统计相关性多强都成立。

为什么成立

关键一步：支撑对齐迫使重参数化 Jacobian 出现零块

$P = J_{\phi^{-1}}$ （真实 s 与估计 ŝ 之间的重参数化）

右上零块 ⇒ $\hat{s}_{\rho(I_A)} = h(s_{I_A})$ ， h 可逆

① **链式法则** $J_{\hat{\pi}} = J_{\pi} \cdot P$ ，把两个模型联系起来

② **span 条件** 每维动作的 Jacobian 行在若干状态上张满其真实父变量，重参数化无法消掉真实依赖

③ **公共置换** $\det P \neq 0 \Rightarrow$ Leibniz 展开中存在 ρ ，使 $\rho(I_i) \subseteq \hat{I}_i$ （对所有动作维度通用）

④ **稀疏取等** 支撑总数不超过真实值 ⇒ 包含变等号 ⇒ P 块下三角 ⇒ 块可逆

假设的代价

- span 条件不是白给的：如 $\pi_i = g(s_1+s_2)$ ， Jacobian 行共线即不满足
- 只到块级识别，块内单个潜变量仍可能混合（作者承认的局限）

CWAM： 世界建模目标不变，只在动作头旁加一条稀疏路由

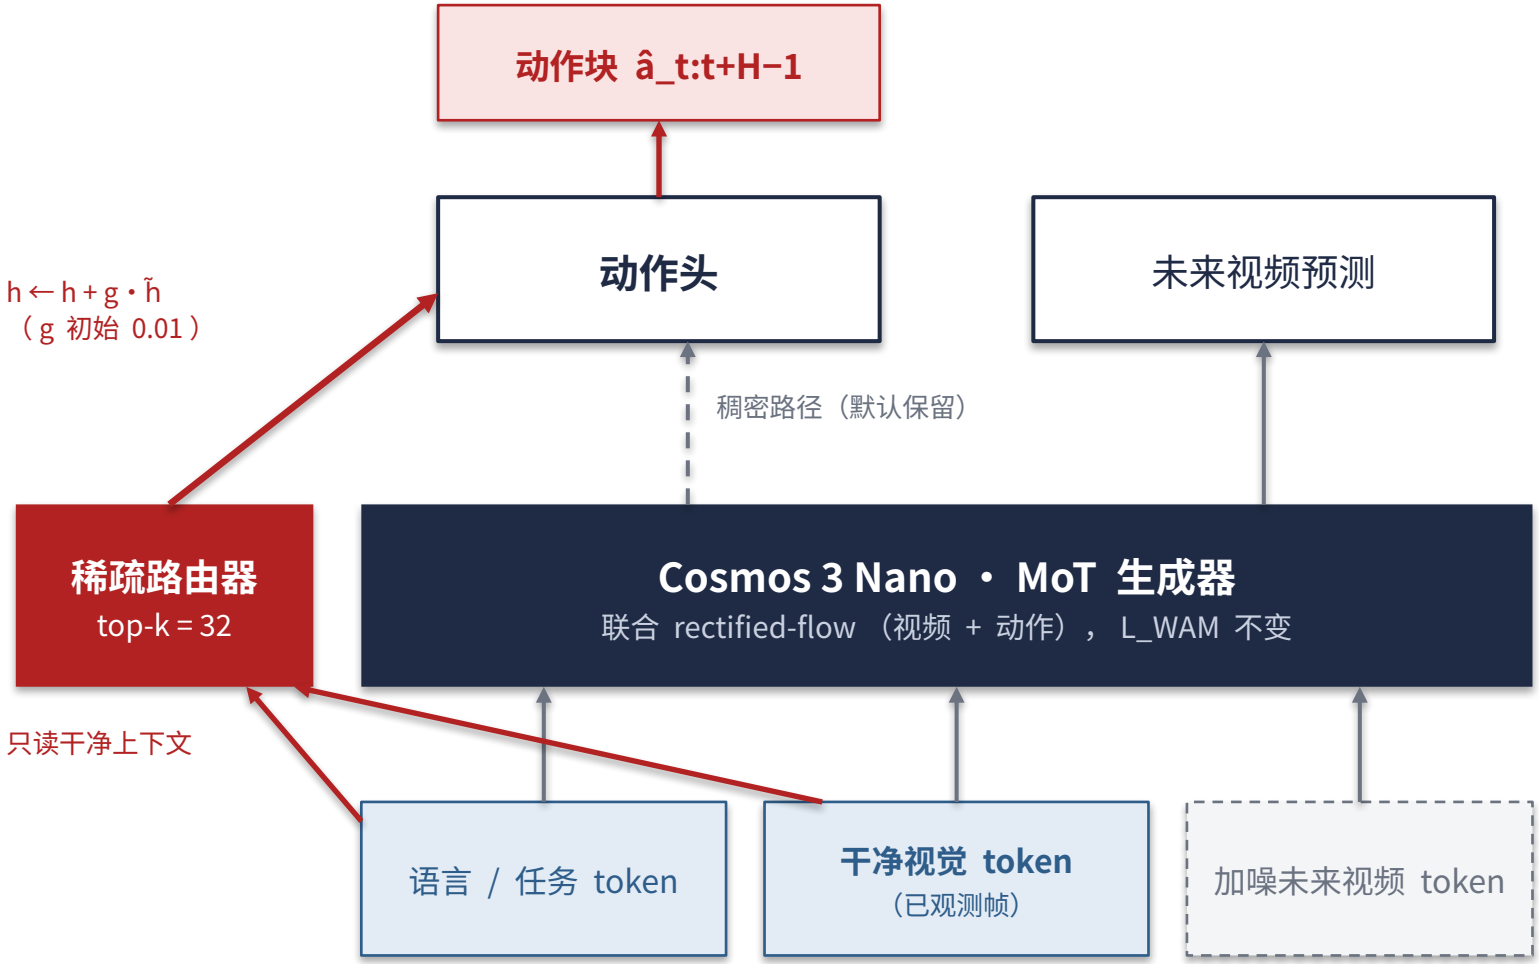

路由权重

$w_{ij} = \mathrm{softmax}_j(q_i^\top k_j/\sqrt{d_r} + b_{ij})$

b_{ij}： 位置 / 模态 / 动作块进度偏置

稀疏代理损失（式 3 的 token 级近似）

$L_{sparse} = \lambda \cdot E_i[1 - \Sigma_{top\text{-}k}\, w_{ij}]$

鼓励注意力质量集中在 top-k token

$L_{total} = L_{WAM} + L_{sparse}$

- $d_r = 512$， 8 头， $k = 32$
- $\lambda = 0.01$，第 1k 步启用、 4k 步线性爬升
- C_t = 进入某个动作 query top-k 的 token

合成验证：带稀疏选出的 4 维几乎只含动作相关信息

相关变量 R^2 ↑ （紧凑状态能解码多少动作相关块）

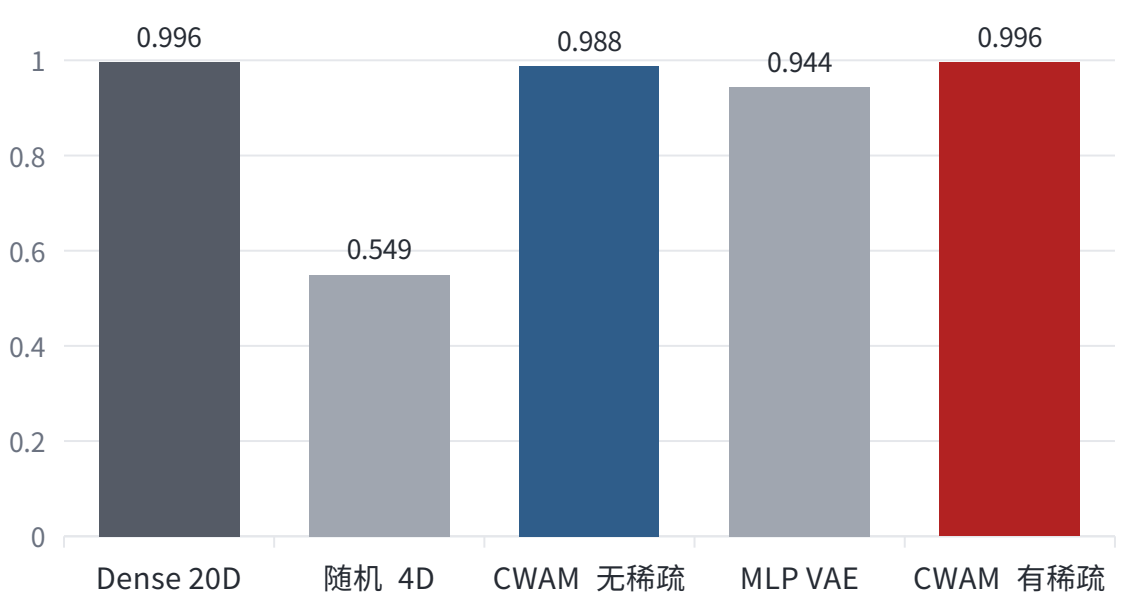

Δ_nuis ↓ （对干扰变量的解码超出真实块多少）

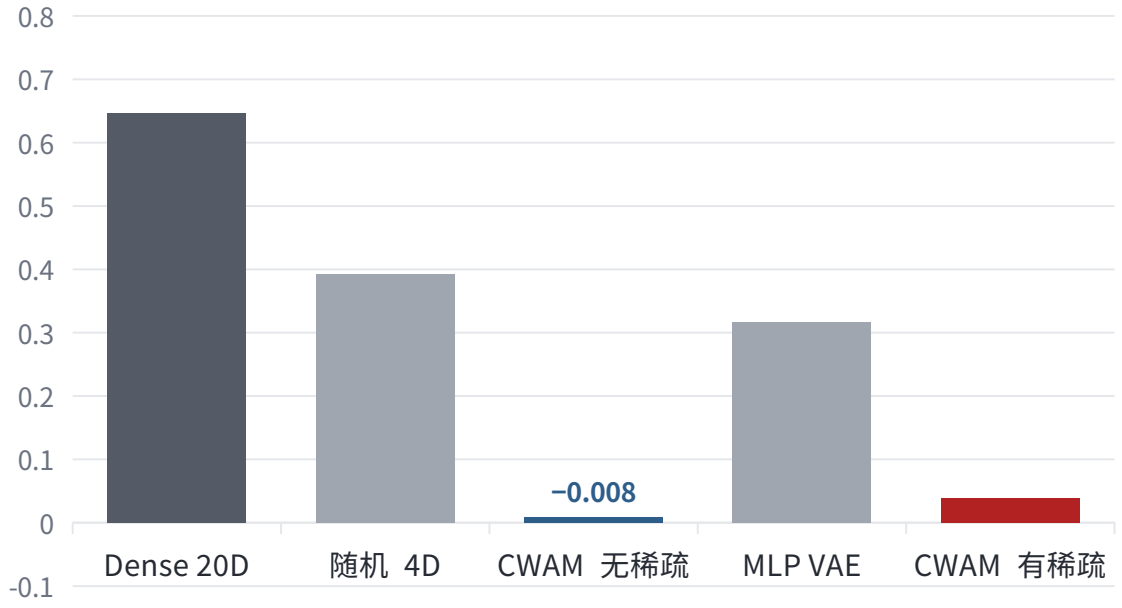

≈ 0

带稀疏的 Δ_nuis = 0.039， Dense 为 0.646

1.70×

只保留 C_t 时动作 MSE 仅为全量的 1.70 倍（随机 4D： 48.1 倍）

稳定

隐藏环境数 E 从 1 增到 5，带稀疏的 Δ_nuis 均 ≈ 0； Dense 维持 0.64–0.68

闭环成功率全面提升：仿真两大基准 + 真机叠方块

RoboCasa365

0.24 → **0.43**

17 任务 × 100 回合，宏平均； 13/17 任务提升

LIBERO

4 / 4 个 suite 提升

40 任务 × 100 回合；每个 suite 都更高， Goal 提升最大

Franka 真机叠方块

0.46 → **0.82**

50 次试验 / 策略

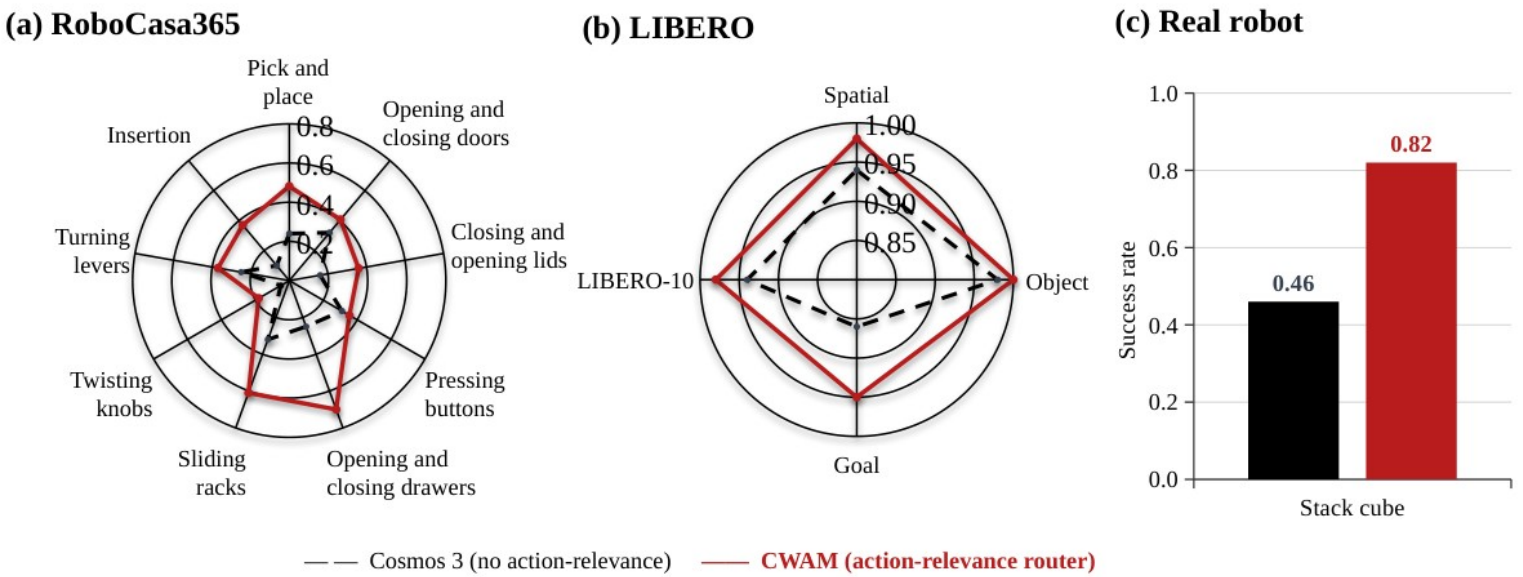

图 2 原图： (a) RoboCasa365 各技能族平均成功率 (b) LIBERO 各 suite (c) 真机；黑虚线 = Cosmos 3 基线，红线 = CWAM

RoboCasa365： 17 个任务 13 个提升，增益集中在抓放与开合类

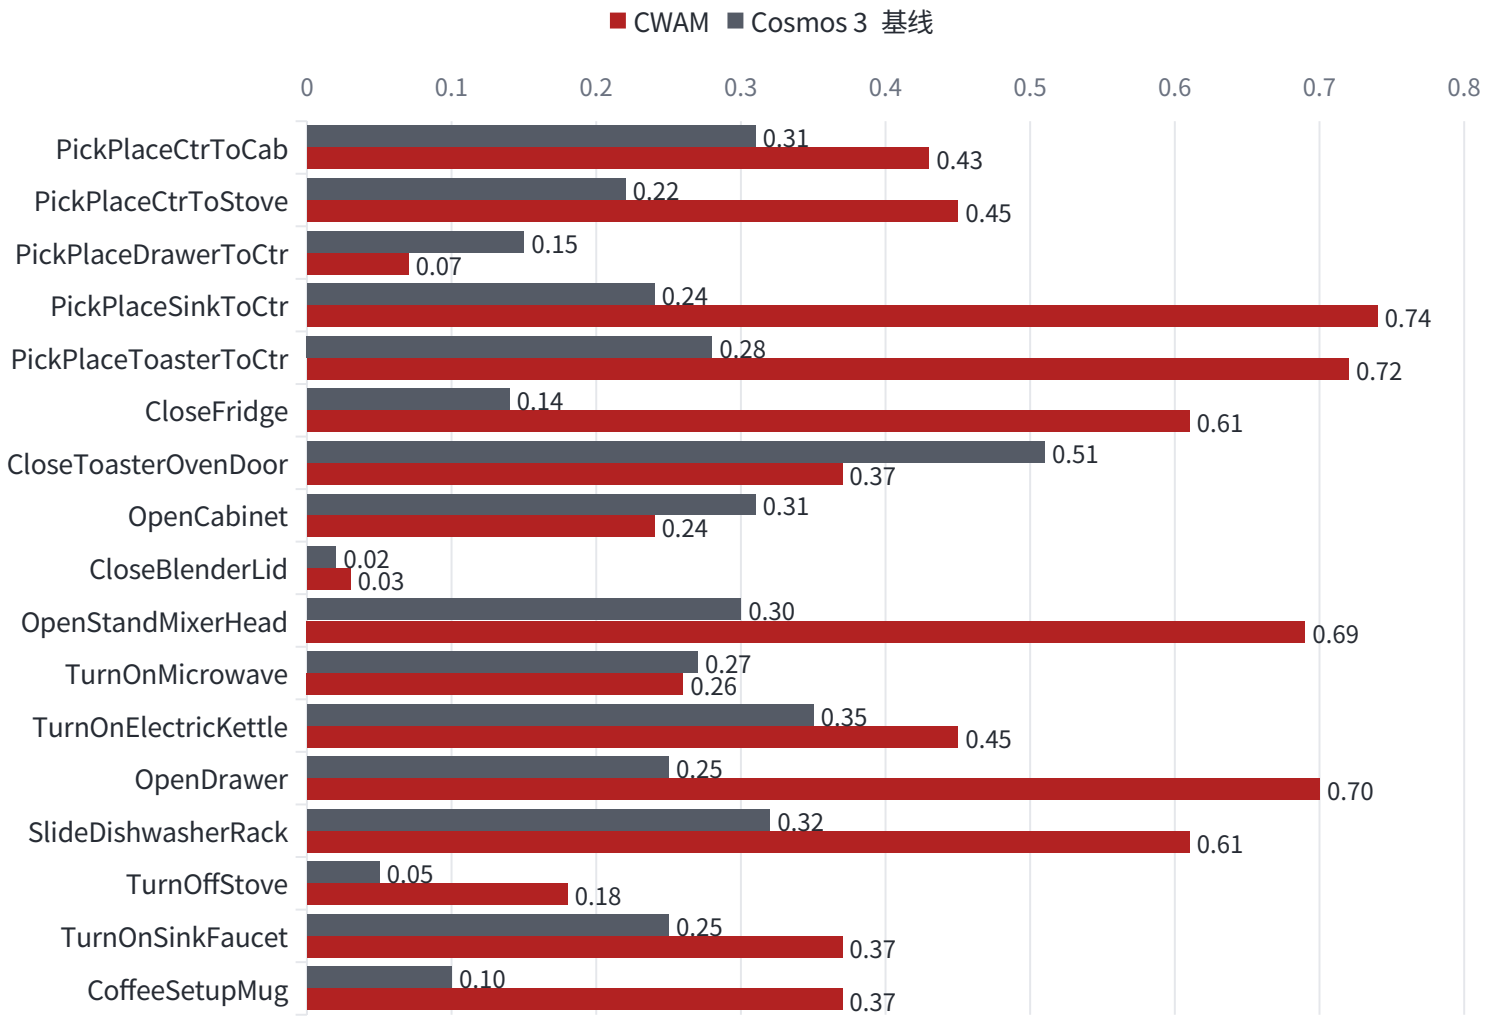

宏平均

0.24 → 0.43

提升最大

SinkToCtr 0.24 → 0.74
ToasterToCtr 0.28 → 0.72
OpenDrawer 0.25 → 0.70
OpenStandMixerHead 0.30 → 0.69
CloseFridge 0.14 → 0.61

下降或持平

DrawerToCtr 0.15 → 0.07
CloseToasterOvenDoor 0.51 → 0.37
OpenCabinet 0.31 → 0.24
TurnOnMicrowave 0.27 → 0.26

路由多落在被操作物体及其目标上，且这些 token 本身就够用

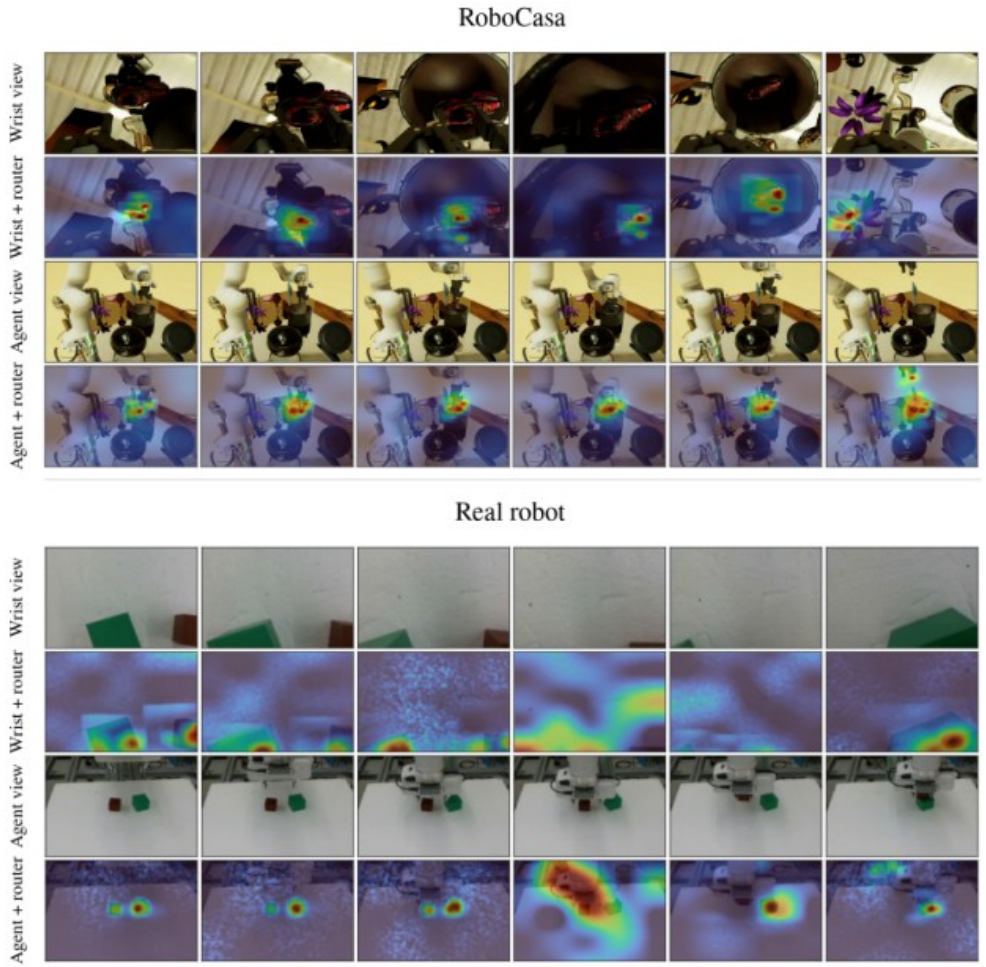

图 3：上 RoboCasa365，下真机（红块叠到绿块）；暖色 = top-k 路由质量

固定 50k 步检查点，不重训，只改动作 query 能看到的视觉 token

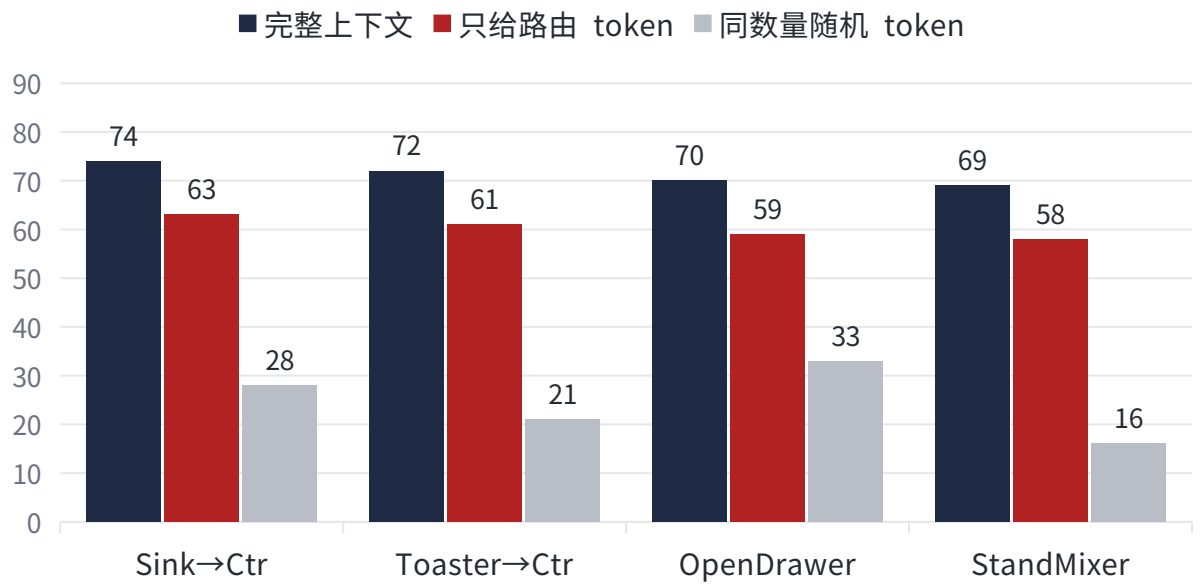

71.3%	60.3%	24.5%
完整上下文	只给路由 token	同数量随机

4 任务平均成功率（%）。仅评测 CWAM 最好的 4 个任务；少数帧路由会扩散到机械臂和墙面。

评价

冷静看待：理论扎实，但从理论到实现跳跃较大，证据仍有缺口

亮点

问题刻画清楚　“预测要全场景，动作只要部分”被形式化为过覆盖下界 + 稀疏取等

识别条件弱　无需干预、时序依赖、马尔可夫性，并允许统计相关

即插即用　后训练模块，不改世界建模目标；真机提升 +36 个百分点

可解释　路由热力图与 token 干预实验相互印证

疑点

理论 ≠ 实现　定理针对潜坐标的 ℓ_0 支撑且需知道真实支撑大小；实现是注意力 top-k 代理并保留稠密路径

稀疏必要性　合成实验中“无稀疏” $\Delta_nuis = -0.008$，不逊于有稀疏； top-4 用了真实 $|I_A|$

缺关键消融　没有“有路由器、无 L_sparse” 对照，难以排除增益来自新增参数

统计不足　机器人结果无多种子 / 置信区间；真机仅一个任务；RoboCasa 基线仅 0.24

表 2 过于规整　4 任务 C-only 均恰好降 11 个点，且只测最好 4 个任务

Takeaways

1. **分离预测与动作**
   WAM 的潜变量要描述全场景，但动作只该来自其中的因果块；只拟合示范会产生过覆盖。

2. **稀疏即可识别**
   对潜变量→动作依赖加支撑稀疏：结构识别到置换，动作用的紧凑状态是真实动作块的可逆函数。

3. **工程上有效**
   Cosmos 3 + 稀疏路由： RoboCasa365 0.24→0.43 ， LIBERO 全 suite 提升，真机 0.46→0.82 。

4. **待补的证据**
   token 级代理与理论的差距、无稀疏的路由对照、多种子统计。