论文解读 | arXiv:2611.01112

Auriga： 面向零样本具身操作的任务无关 Agent Harness

Auriga Technical Report: A Task-Agnostic Agent Harness for Zero-Shot Embodied Manipulation

一句话总结

不训练策略、不在目标任务上试错，只给通用 VLM 加一层“**先预览、再执行、偏离即停**”的执行外壳，就在单 episode 零样本条件下补回 **68.3%** 的规划–执行鸿沟，登顶 RoboDojo （**57.7% SR**）。

首次提交 2026-10-31 · 基座模型 GPT-6 Astra （high）

论文 Fig. 1： 单 episode 内定位→预览→空抓被拦截→原地修正→完成

TL;DR

四个数字看懂 Auriga

57.7%

RoboDojo 总榜第一

64.0 Score， 6,300 episode；同模型参考 harness 仅 22.5% SR / 29.0 分

68.3%

补回规划–执行鸿沟

参考接口 22.5% → 免手臂上限 76.2%， Auriga 达 59.2%（210 episode 诊断集）

45.6%

随机场景 SR 仍第一

标准 52.3% → 随机 45.6%（– 6.7）；学习型策略最多掉 33.9 个点

73.2%

RoboCasa365 Overall

无 VLA、无跨 episode 记忆；复合任务领先 VLA 智能体 19.4–23.1 个点

方法关键词

- **任务无关：**无任务专属代码 / 提示 / 技能，无特权仿真状态； 13 次跨任务迭代后冻结评测
- **模型做全部决策：**一个持久会话 + 显式任务信念 B_t（计划 / 关注 / 前提账本） + 离线证据记录 E_t
- **唯一准入网关 $\mathcal{A}$：**暂停世界下预览整段轨迹 → 原样回放 → 按阶段容差核验，偏离即停并返回实测偏差

瓶颈在“执行”而非“规划”：模型想得对，手臂做不到

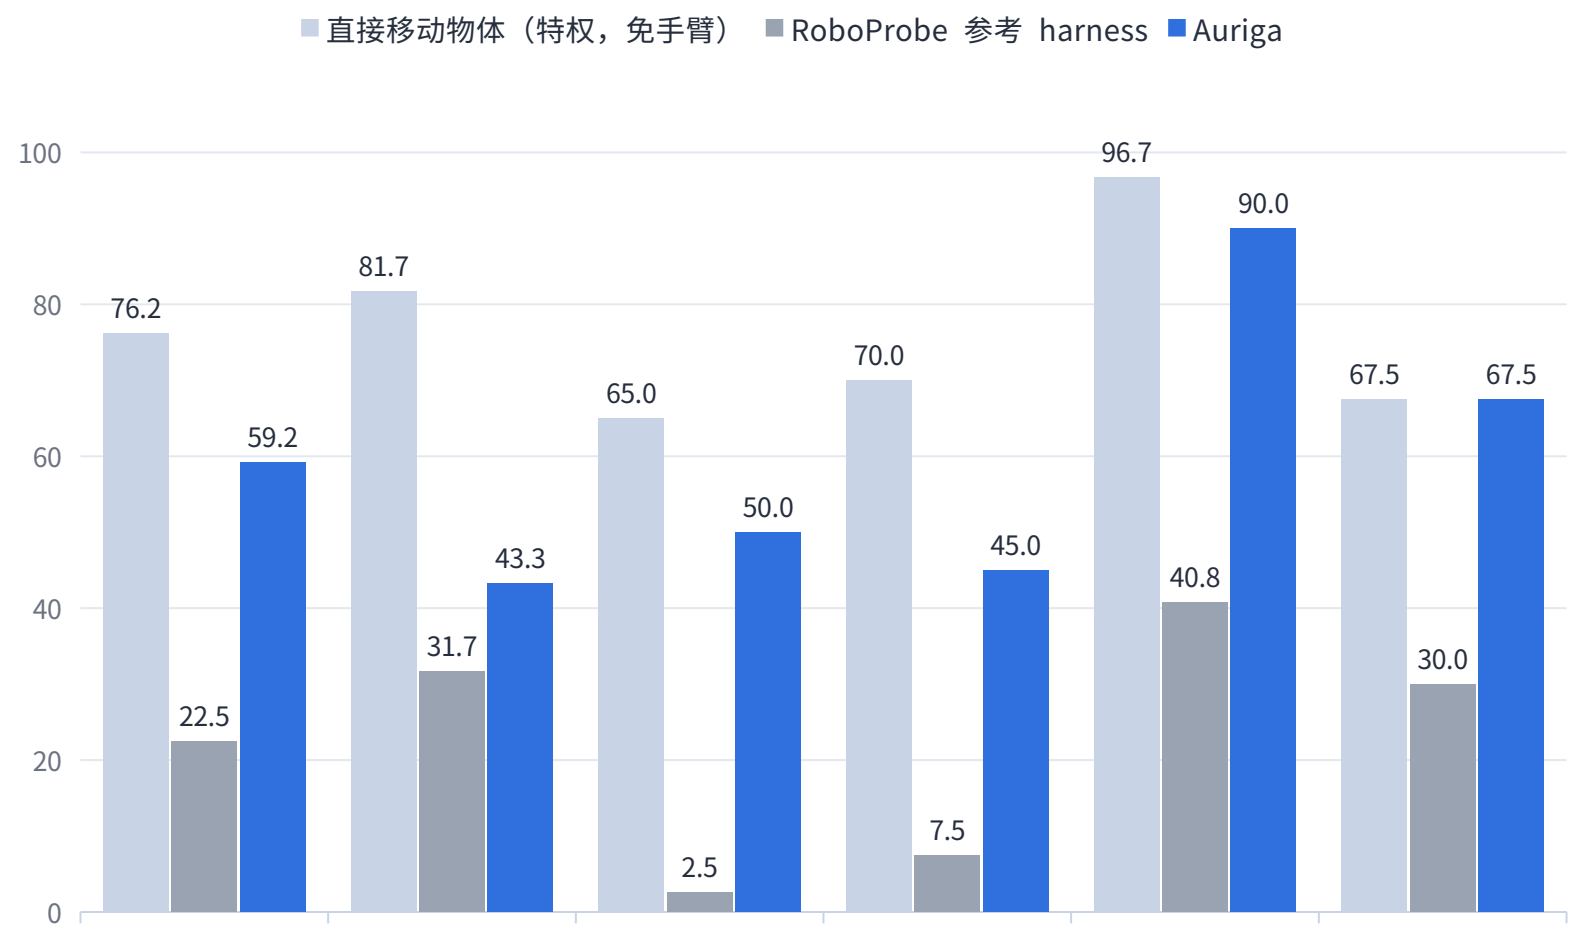

成功率 SR （%）； Memory 列 RoboProbe 基于 29 个 episode

鸿沟补回比例

68.3%

(59.2 − 22.5) / (76.2 − 22.5)

按 Score 计为 70.6%

- 模型通常能选对物体和目的地
- 失败来自执行：抓偏几毫米、运输中掉落、撞到容器边沿
- 常见控制接口无法及时发现这些错误

01 问题

常见范式补不上鸿沟； Auriga 在更严格的零样本协议下解决它

执行判断放在哪里?

逐步 / 分块动作输出 参考 harness 、 VLA

每次只发一步，看不到完整路线；碰撞在手臂动完后才被发现

Code-as-Policy 程序直接调用控制接口

脚本看不见场景；动作失败了程序仍可能 exit 0

Auriga 完整序列 + 预览 + 核验

执行前看整条轨迹、耗时与间隙；每段执行后核验实测结果

单 episode 零样本协议

1. **评测前不在目标任务上探索**

   不在目标任务（含其他布局）上开发提示、程序、技能或策略；模型参数固定

2. **评测时不给示范**

   只有任务说明与允许的观测

3. **每个 case 只执行一次**

   无 reset 、无重跑；只能从当前物理状态原地恢复

对比： HexaShell / EmbodiedEvo / SEAR 在目标场景反复 reset 调参（RSI L0–L2）。

Auriga： 失败用于升级通用的定位、接触检查、状态跟踪工具（L3–L5），评测时冻结。

三层分工：模型决策，工具测量，唯一网关放行运动

论文 Fig. 4： Auriga 总览（上）与 hang_mugs 闭环执行（下）

Cortex • 持久模型会话

做全部任务决策：分解、测量、目标、恢复；无任务专属提示

Capability layer • 通用工具

Measure / Act / Compute / Recall ，只提供能力，不编码解法

Admission gateway $\mathcal{A}$

唯一能让机器人动的通道；直接调用与程序请求同一路径

审议调用 $\mathcal{U}$ d： s_{t+1}=s_t ，世界暂停，不耗仿真时间

物理调用 $\mathcal{U}$ p： (s,r,o)=$\mathcal{A}$(s,u) ，必须经网关

预览–执行–核验：执行的就是预览过的，偏离就停下汇报

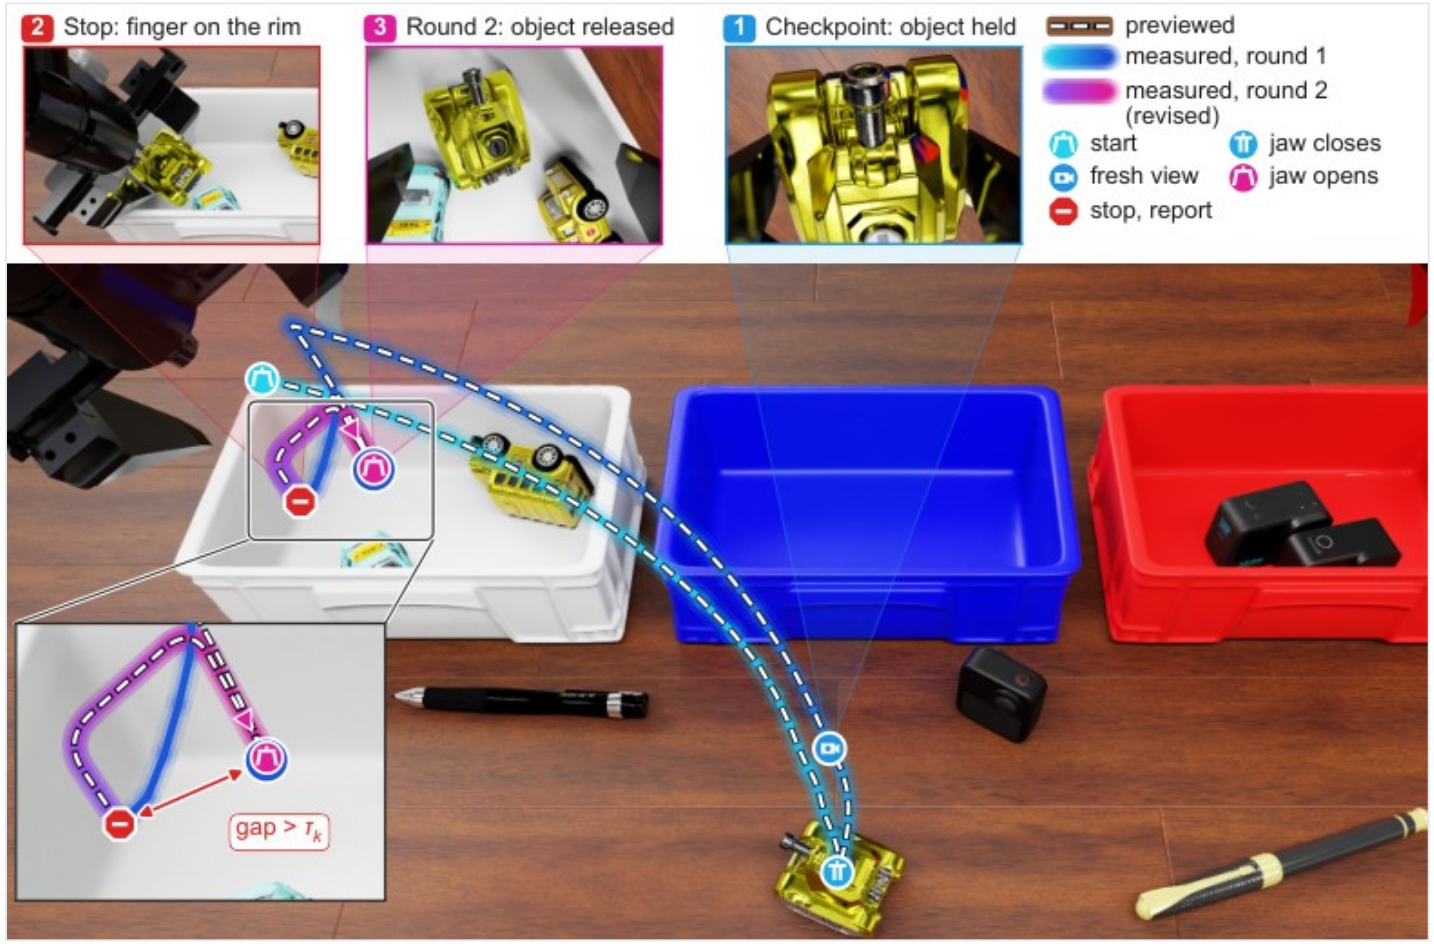

论文 Fig. 6： 两轮预览与核验（篮沿接触与第二轮为示意）

① 预览 暂停世界

整段多阶段双臂序列 → 轨迹投影、每段步数、间隙告警；不可规划则不执行

② 原样回放 不重规划

执行的正是预览的轨迹；自由空间偏差 ≈ 接触信号

③ 核验 $\tau k=(\delta p, \delta\theta)$

默认 10 mm / 0.15 rad ；超出即停机保持，回执给出失败段、偏差、未执行段和新视角

④ 检查点 模型放置

无条件或按夹爪开口触发；比“每次夹爪动作后都停”效果更好

显式任务信念 + 三层闭环：恢复时不丢失已完成的进度

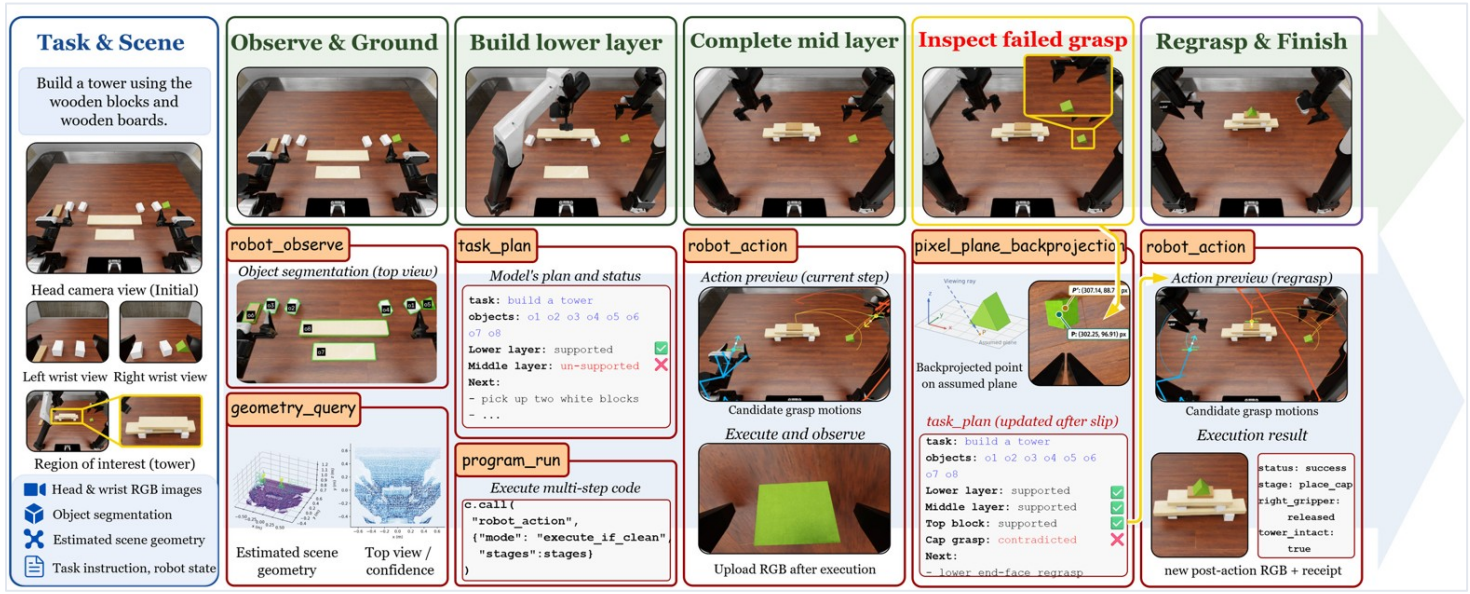

论文 Fig. 2：搭塔 episode 中的规划、执行与恢复（场景从未重置）

swap_T 实例：动作“完成”但夹爪开口为 0 → 蓝块“保持”记为 contradicted，粉块放置仍为 supported → 换左臂仅补救蓝块，不重做整个交换

任务信念 B_t （模型维护）

plan 目标、方法、完成判据

attention 当前关键不确定性及可消解的证据

ledger 关键前提： pending / supported / contradicted / unknown

三层闭环

Stage loop 网关 $\mathcal{A}$

超容差 / 抓取检查失败即停，防止错误传给后续阶段

Action loop 模型

对比回执与新观测，形成原因假设再行动

Belief loop 模型

前提反复被否定 → 换接触点、路线或目标

把物理状态变成可读的事实，让动作用任务语言来表达

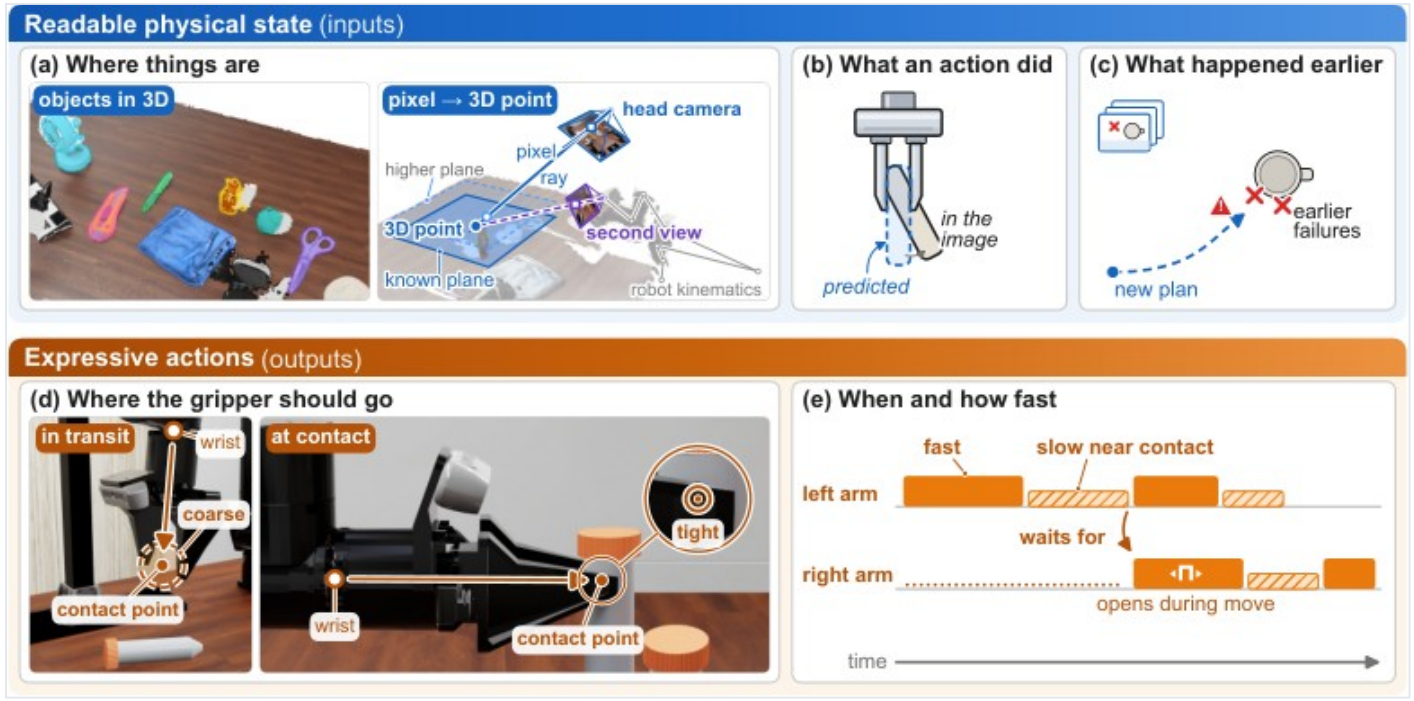

输入侧：可读的物理状态

- 像素射线 $d = R\,K^{-1}\,(u, v, 1)^{T}$ ， 3D 定位 = 求射线上的距离
- 粗： VGGT-Omega 深度（按桌面高度定尺度） + SAM 3.1 分割 → 每个物体的位姿 / 尺寸 / 可靠度
- 细：已知高度平面求交（报告 $\partial\, p/\partial h$ ）或腕部相机二视角三角化
- 实测夹爪开口、手内滑移；回到历史失败区域时附带警告

输出侧：表达力强的动作

- 目标以指尖 / 指垫接触点表达，而非腕部法兰
- 按段设容差：运输粗、接触紧
- 双臂共享时间线：可声明等待、近接触减速、移动中开合夹爪

论文 Fig. 7 ： 感知与动作接口（ a–c 输入侧， d–e 输出侧）

13 次跨任务迭代：分数从 21.5 涨到 64.0 ，靠升级通用工具

里程碑（总分）

#2	运动预览	26.2
#3	统一双臂动作	30.0
#4	重构 + 原文任务说明	45.5
#7	ROI 放大	49.9
#9	阶段容差 + 障碍检查	53.4
#11	显式运动控制	58.8
#12	VGGT-Omega + SAM 3.1	64.0

#4 → 最终版： Long-Horizon +29.5 、Memory +30.8 ， Precision 仅 +5.6

论文 Fig. 3： Harness 能力迭代 #0–#12 （RoboDojo 总分）

RoboDojo 总榜第一： 64.0 分，同模型下是参考 harness 的 2.2 倍

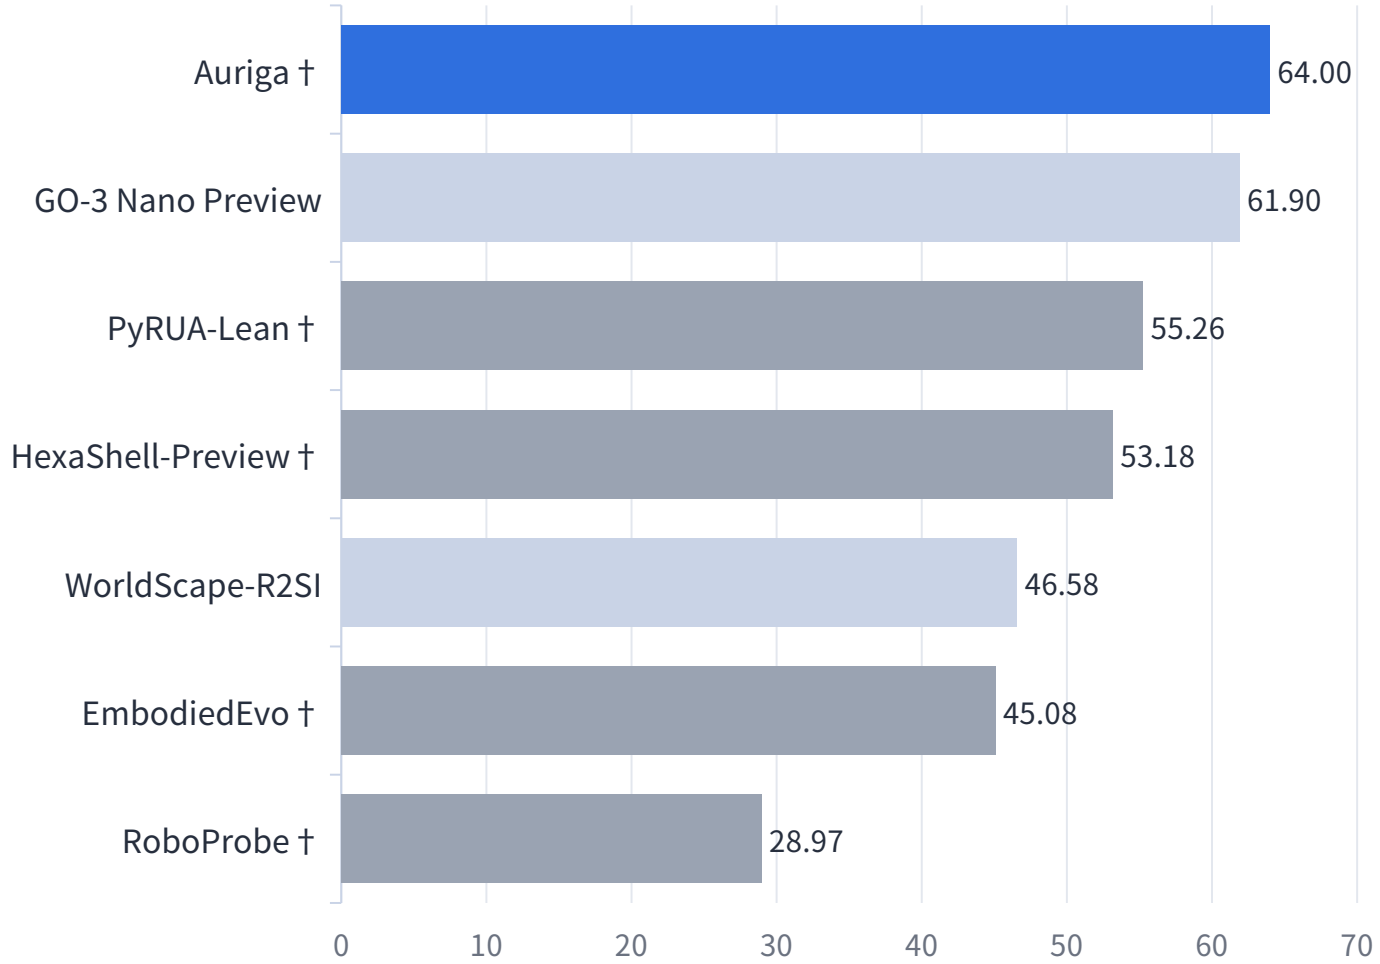

平均 Score （0–100）； † 使用 gpt-6-astra ； 浅色 = WAM/VLA 学习型策略（含智能体组合）

64.00

平均 Score

57.74%

平均 SR

- **vs RoboProbe （同模型）：** 28.97 → 64.00 分，22.48% → 57.74%
- **vs GO-3 Nano （Agent+WAM）：** 61.90 / 56.42% ，总榜第二
- **智能体组：** 12 列全部第一；领先 PyRUA-Lean 8.7 分
- **逐任务 Score：** 对 PyRUA-Lean 24 胜 17 负，对 RoboProbe 41 胜 1 负

Memory 、 Generalization 、 Open 领先； Precision 明显落后于 GO-3

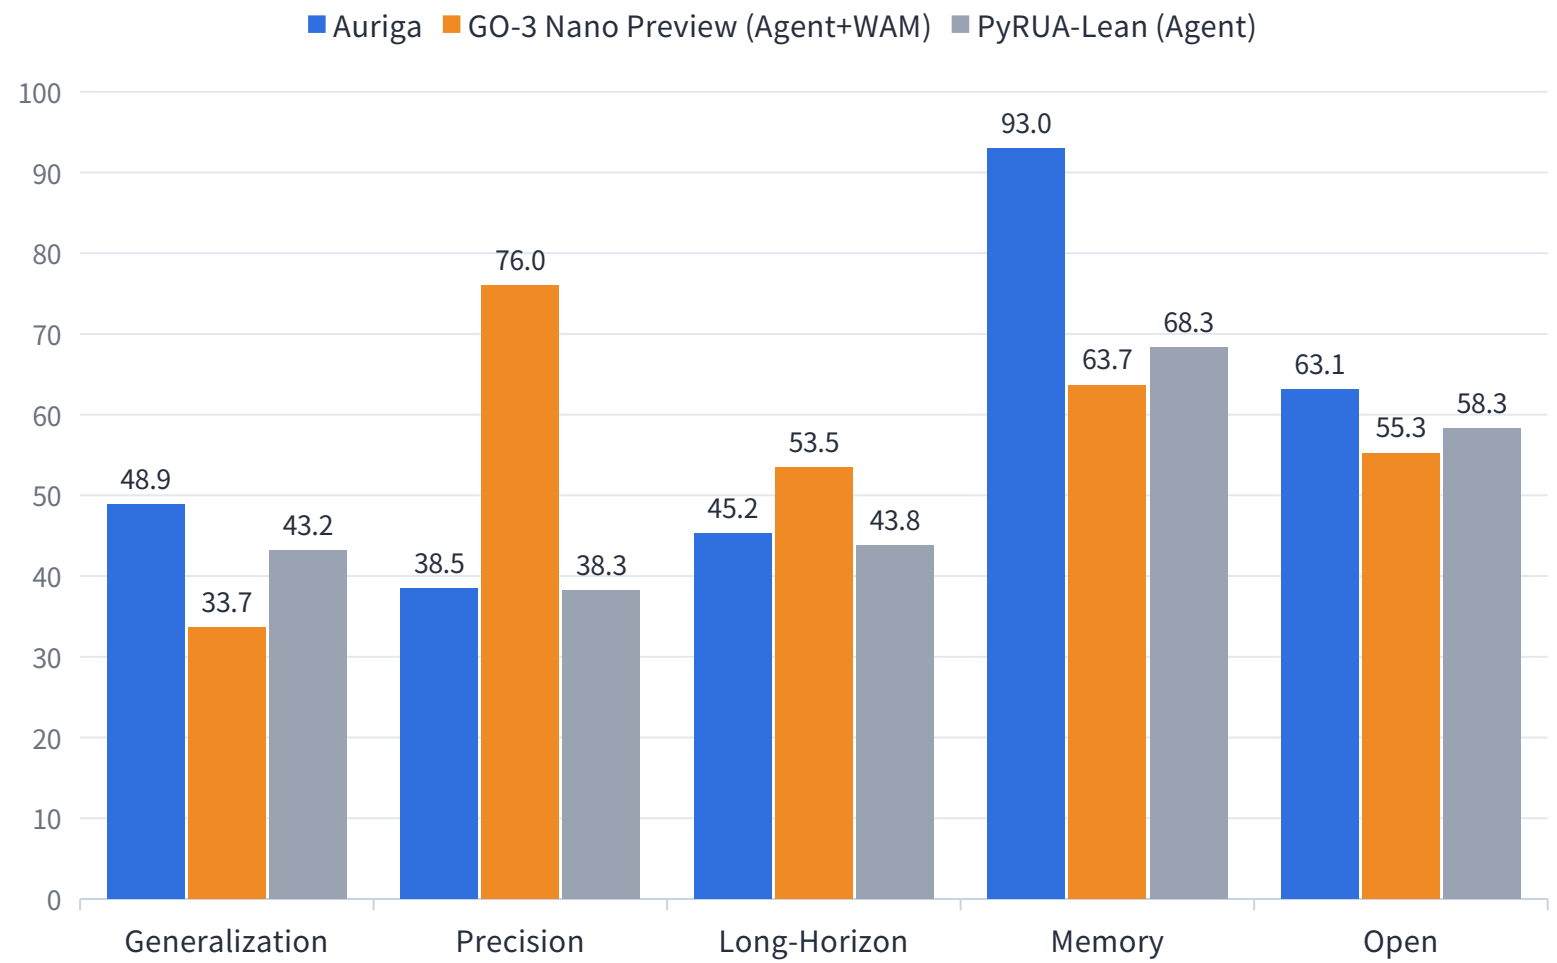

各维度 SR （%），数据来自 Tab. 4

领先

- Memory 93.0% （+12.0 个点）
- Generalization 48.9% （+5.7 ）
- Open 63.1% （+4.8 ）

短板

- Precision 38.5% vs GO-3 76.0%
- Long-Horizon 45.2% vs 53.5%
- insert_key 、 store_tools_in_toolbox 、 store_laptop_and_headphones 均为 0

场景随机化后仍居第一：学习型策略最多掉 33.9 个点

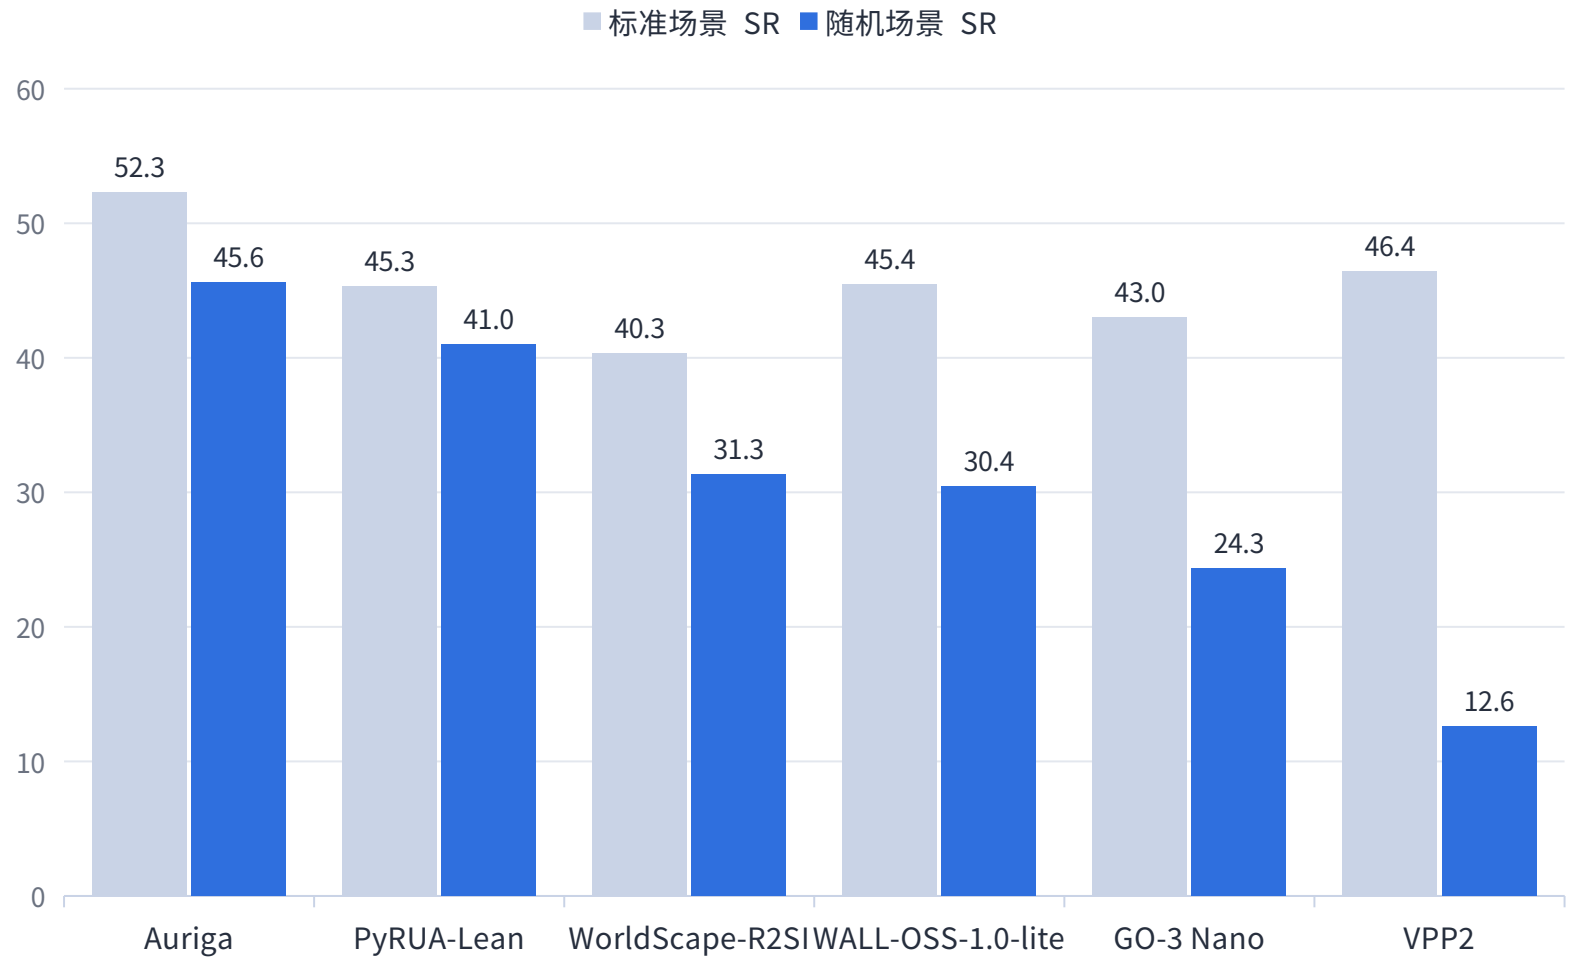

SR （%），按综合泛化指标 G 排序（选取部分方法）

随机 − 标准（SR 个百分点）

Auriga	−6.7
PyRUA-Lean	−4.3
WALL-OSS-1.0-lite	−15.0
GO-3 Nano Preview	−18.7
PhysicalRSI	−20.1
VPP2	−33.9

综合泛化指标 G

46.27

第一； PyRUA-Lean 43.87 第二

$G = \frac{1}{2}(S_{std}+S_{rand}) - |S_{rand}-S_{std}|$

迁移到 RoboCasa365：不用 VLA 也达 73.2%，复合任务优势最大

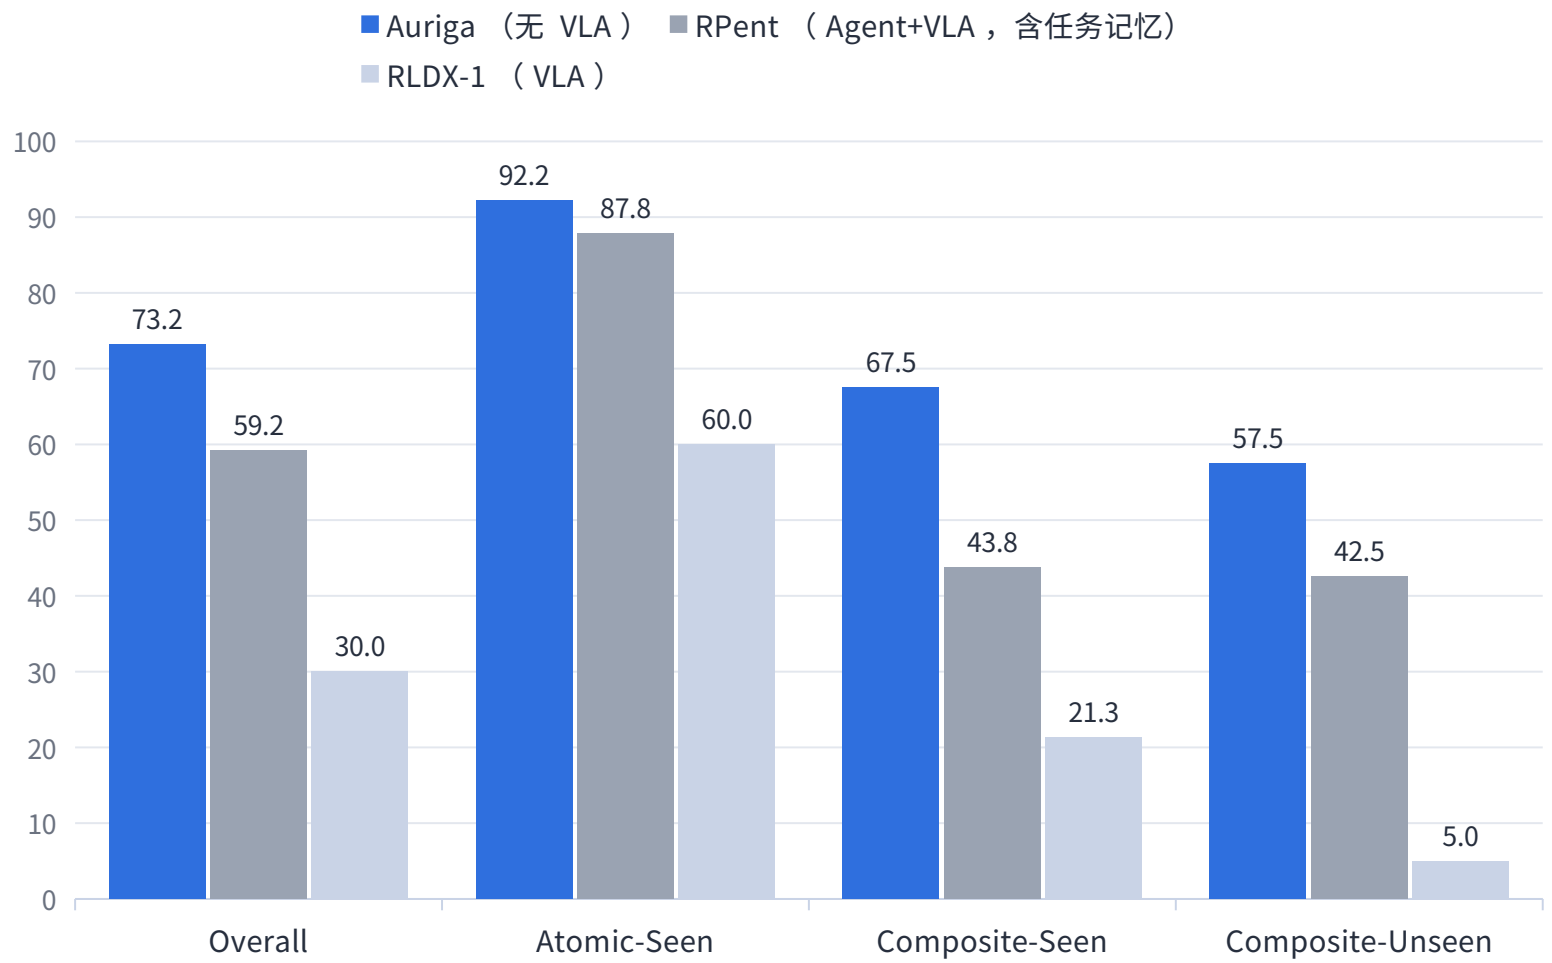

62.5%

复合任务整体 SR

+19.4 / +23.1

- 基线把接触密集阶段交给 RLDX-1；它单独跑 Composite-Unseen 仅 5.0%
- Auriga 所有阶段都由带阶段核验的动作程序完成
- 67 个失败：23 个请求用尽，44 个模型停止行动
- 提示：该环境提供渲染深度坐标图与谓词实时值

SR （%），250 episode，均在未见过的目标厨房；PyRUA-Lean 仅报告 Overall 56.4 / 复合整体 39.4

消融： 3D 测量和“可审查的程序”贡献最大

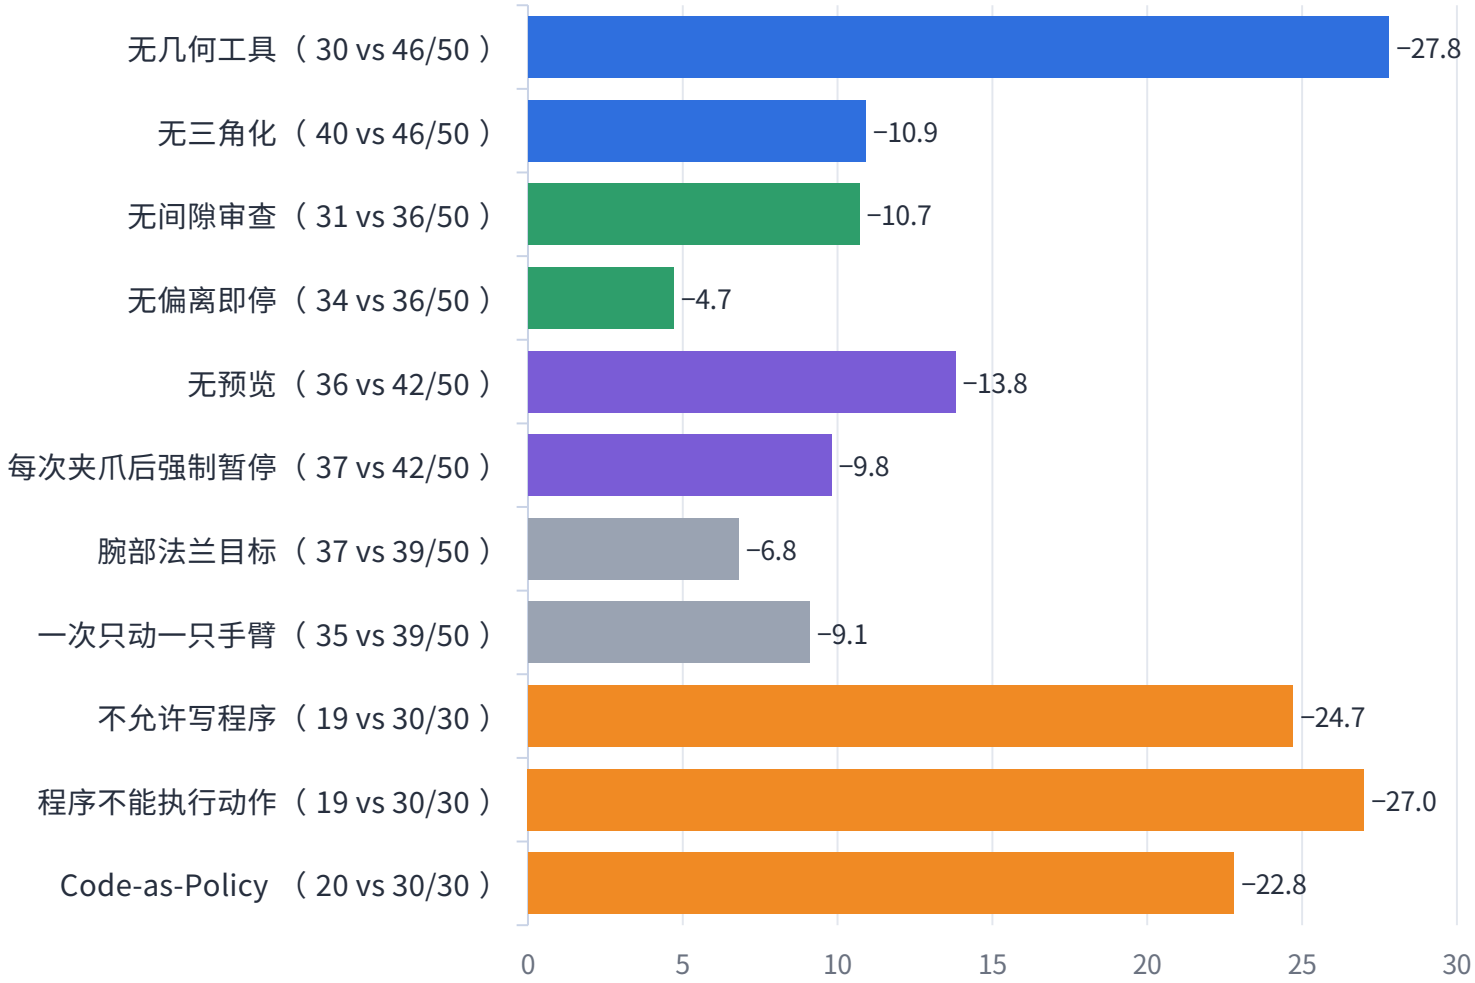

相对同组 Full 的平均 Score 下降；括号内为成功数（消融 vs Full ）

Code-as-Policy 的静默失败

120 个程序发出的动作中， 2 个因超容差被停、 1 个在检查点暂停；

没有回执时，这些程序全部以 **exit 0** 退出

其中一个还继续发了 8 个动作。

Full： 30/30 ， Score 100 ，模型调用 46.2 次（ vs ~66–72 ）

代价：更多调用和 token；失败的 episode 吃掉七成输入

每 episode 平均	Auriga	PyRUA-Lean
平均 Score	**64.00**	55.26
模型调用	**47.5**	25.7
输入 token （M）	**5.63 （缓存 85.4%）**	0.75
输出 token （k）	**18.3**	9.0
时长（min）	**18.8**	12.7

Tab. 11；两者均为 reasoning effort high

成功 episode （3,405）

30.3 次调用

3.10M 输入 · 11.5 min

失败 episode （2,894）

67.6 次调用 · 27.5 min

占全部输入 token 70.2%

swap_T 匹配场景： Auriga vs RoboProbe

14/15

Auriga 成功

RoboProbe 3/15 （+73.3 个点）

−90.6%

物理执行批次

3.1 vs 33.4 次 /episode；每批 107.3 vs 10.9 步

- 模型调用更少： 25.4 vs 36.6 次 /episode
- 总步数相近： 336.2 vs 365.1
- 接近–抓取–运输–释放作为一个多阶段操作整体预览、核验

定性：根据回执诊断原因，换抓法、换手臂或换操作方式

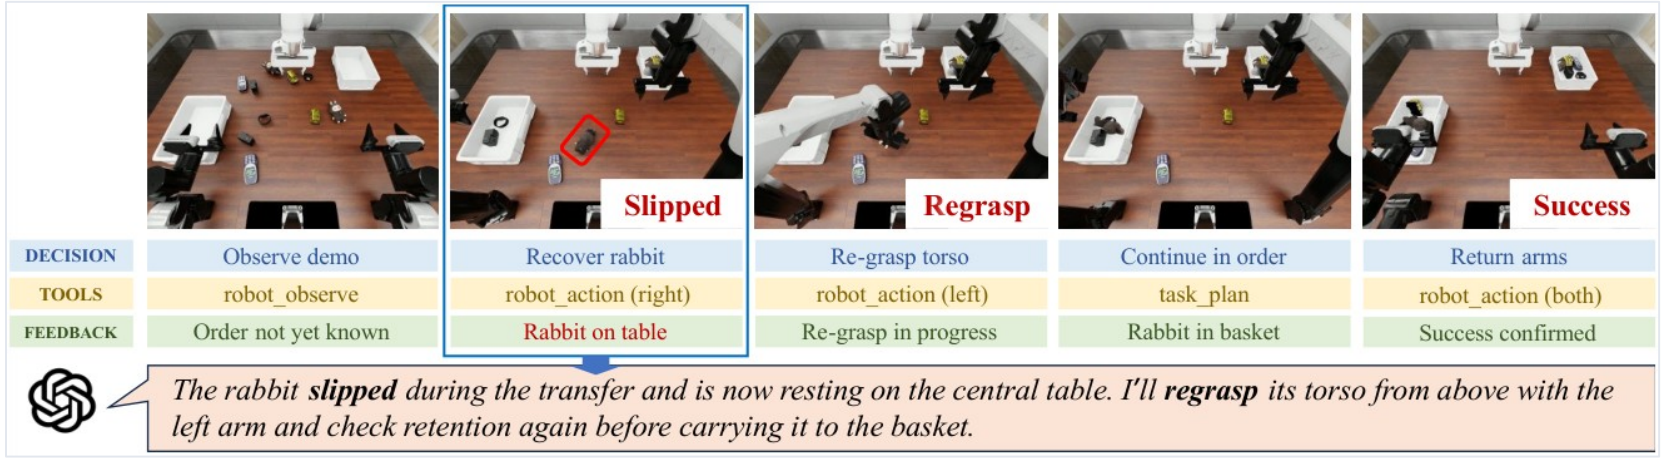

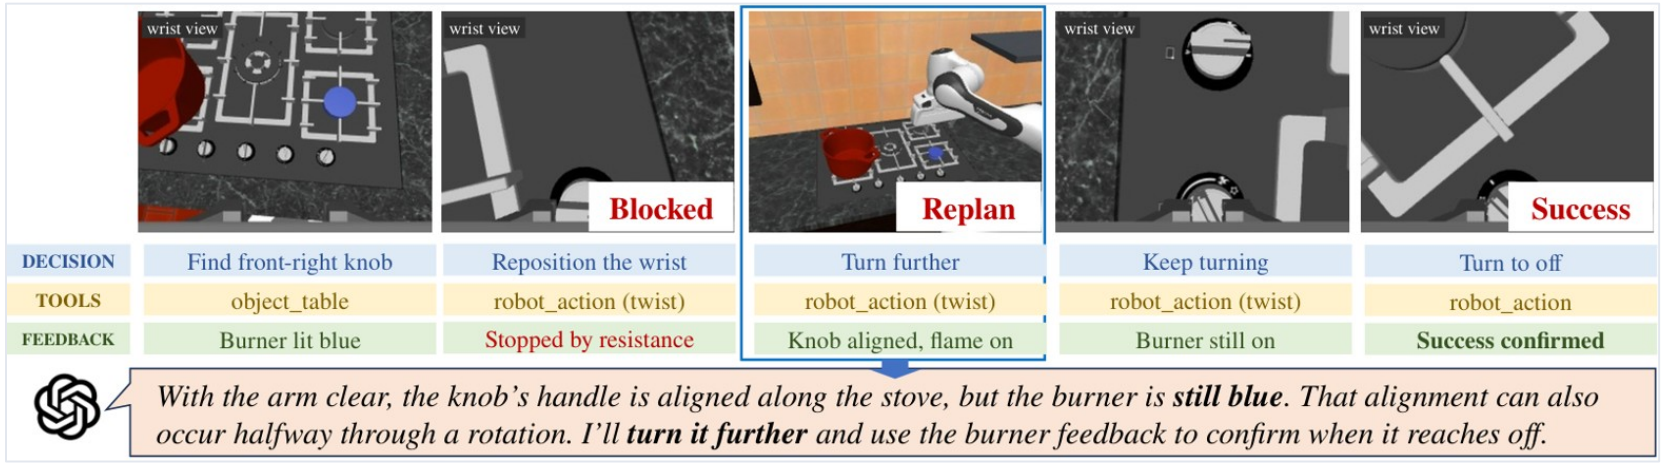

imitate_sorting_sequence

兔子转移中滑落 → 第 3 位保持 pending，不跳到下一个 → 换左臂抓躯干 → 确认保持 → 按序完成

TurnOffStove （RoboCasa）

旋转受阻 → 松手调整腕部姿态；把手看似“关”但火仍蓝 → 继续旋转，以火焰状态为准

失败边界：多体耦合结构上的反复修正会把预算耗光

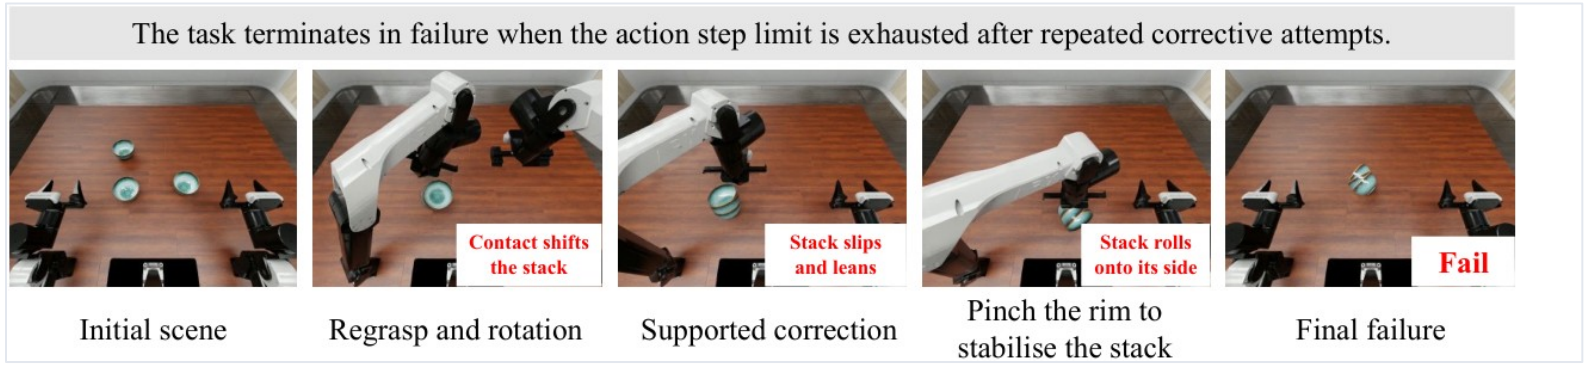

(a) RoboDojo stack_bowls： 800 步预算耗尽， Score 15

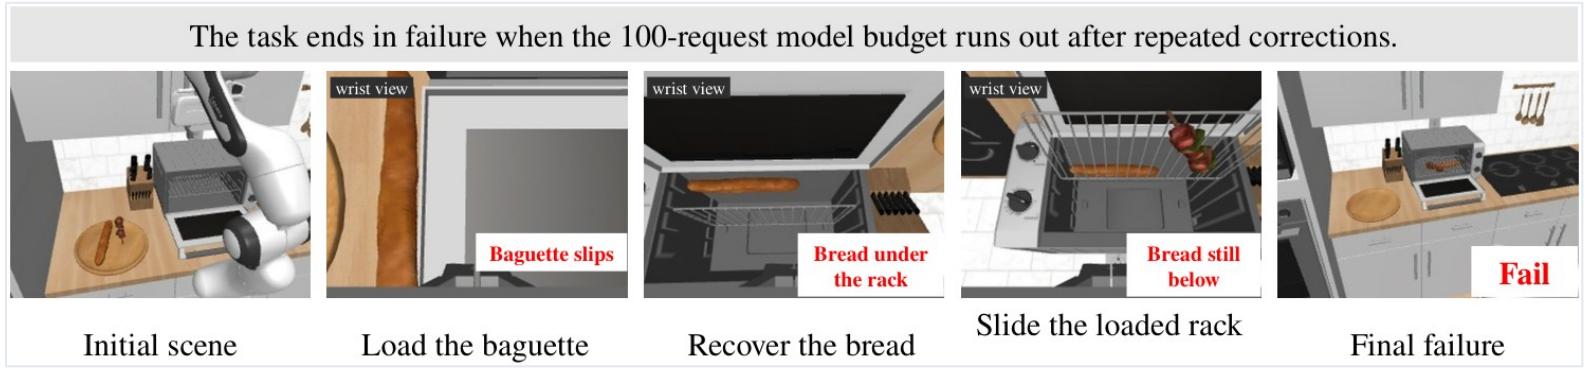

(b) RoboCasa365 HeatKebabSandwich： 100 次请求耗尽

stack_bowls （Tab. 22）

242 步：两碗已叠好

440 步：扶正顶部碗时带起整摞，滑落滚倒

691→800 步：撤臂后又滚倒，预算耗尽

HeatKebabSandwich （Tab. 23）

第 41 次：法棍掉到烤架下

63→86 次：细前轨反复打滑

100 次：请求耗尽，法棍仍在架下

核心教训：能可靠地发现偏差，但面对耦合多体结构或次生障碍，局部动作“完成”不等于整体进度在推进。

启示：在模型之外把执行闭环做扎实，回报可能高于再训练一个 VLA

贡献

- **诊断：**用免手臂特权动作量化“规划–执行鸿沟”，把问题定位到执行闭环
- **设计原则：** harness 只测量、只停机汇报，决策全部留给模型
- **统一网关：**程序与直接调用共用 预览→回放→核验 通道，避免静默失败
- **结果：**严格零样本下 RoboDojo 第一（57.7%）、随机化稳健、跨基准迁移（73.2%）

局限与待验证

- **仅仿真：**暂停世界思考 + 每 episode 18.8 min，在真机实时约束下不成立
- **精细接触弱：** Precision 38.5% vs GO-3 76.0%；缺少力控
- **对基准开发：** 13 次迭代都以 RoboDojo 全部任务衡量； RoboCasa 环境给了更多特权信息
- **成本与依赖：**输入 token 约为 PyRUA-Lean 的 7.5 倍；仅测试 GPT-6 Astra
- **消融规模：**每组 10 个任务、 30–50 个 case，置信度有限

一句话：把测量、预览、核验、证据和显式任务状态这条执行闭环做扎实，不靠专门训练的策略，通用 VLM 在仿真操作中的成功率也能大幅提升；下一步要突破的是力敏感的精细接触、真实时间约束和多体耦合场景下的恢复。