论文解读 · 具身智能 / 机器人学习

ODE Policy

Robot Learning via Action Dynamics, Not Actions

学“动作怎么变”，而不是学“动作是什么”

一句话：用神经 ODE 学习动作的速度场，每个动作从上一个动作积分而来，执行天然连续；它学得更快、生成更快、动作更平滑，并可作为视觉运动策略、 VLA/WAM 动作头和 RL actor 即插即用。

Jindou Jia, …, Jianfei Yang · MARS Lab, Nanyang Technological University

arXiv 2611.01729 · 首次提交 2026-11-01

核心结论速览

一个改动，四个维度同时变好：学习、数据、速度、平滑

策略输出从“动作值”改为“动作的速度场 $da/dt = f\theta(a, s, z)$”，在物理时间上积分。

79.2%

LIBERO 训练 1 个 epoch

6 个视觉运动基线最高 43.2%

10.8×

动作 chunk 生成快于 flow matching

Euler 积分 8 步动作仅 5.7 ms

14 / 14

真机任务成功率均最高

单臂、双臂、灵巧手、人形机器人

96.0%

作为 π0.5 动作头，1 个 epoch

随机初始化 FM 专家 75.5%，参数仅约 3%

需要注意：最大优势集中在训练早期。充分训练后差距收窄：LIBERO 第 100 轮 93.8% vs FM-DiT 85.4%；π0.5 预训练 FM 第 2 轮追平；ImageWAM 第 6 轮后三种动作头都约 98%。

动机： direct-action 范式的局限

现有策略把连续的物理运动当作离散点来学

1 连续性靠数据隐式学

模型不规定相邻动作关系； chunk 边界常出现跳变或停顿

2 学习和推理都昂贵

依赖大量数据与算力；扩散 / 流匹配每个 chunk 要多次网络前向，生成完整 chunk 才能执行

3 RL 动作高频抖动

浪费控制能量、磨损电机，扩大 sim-to-real 差距

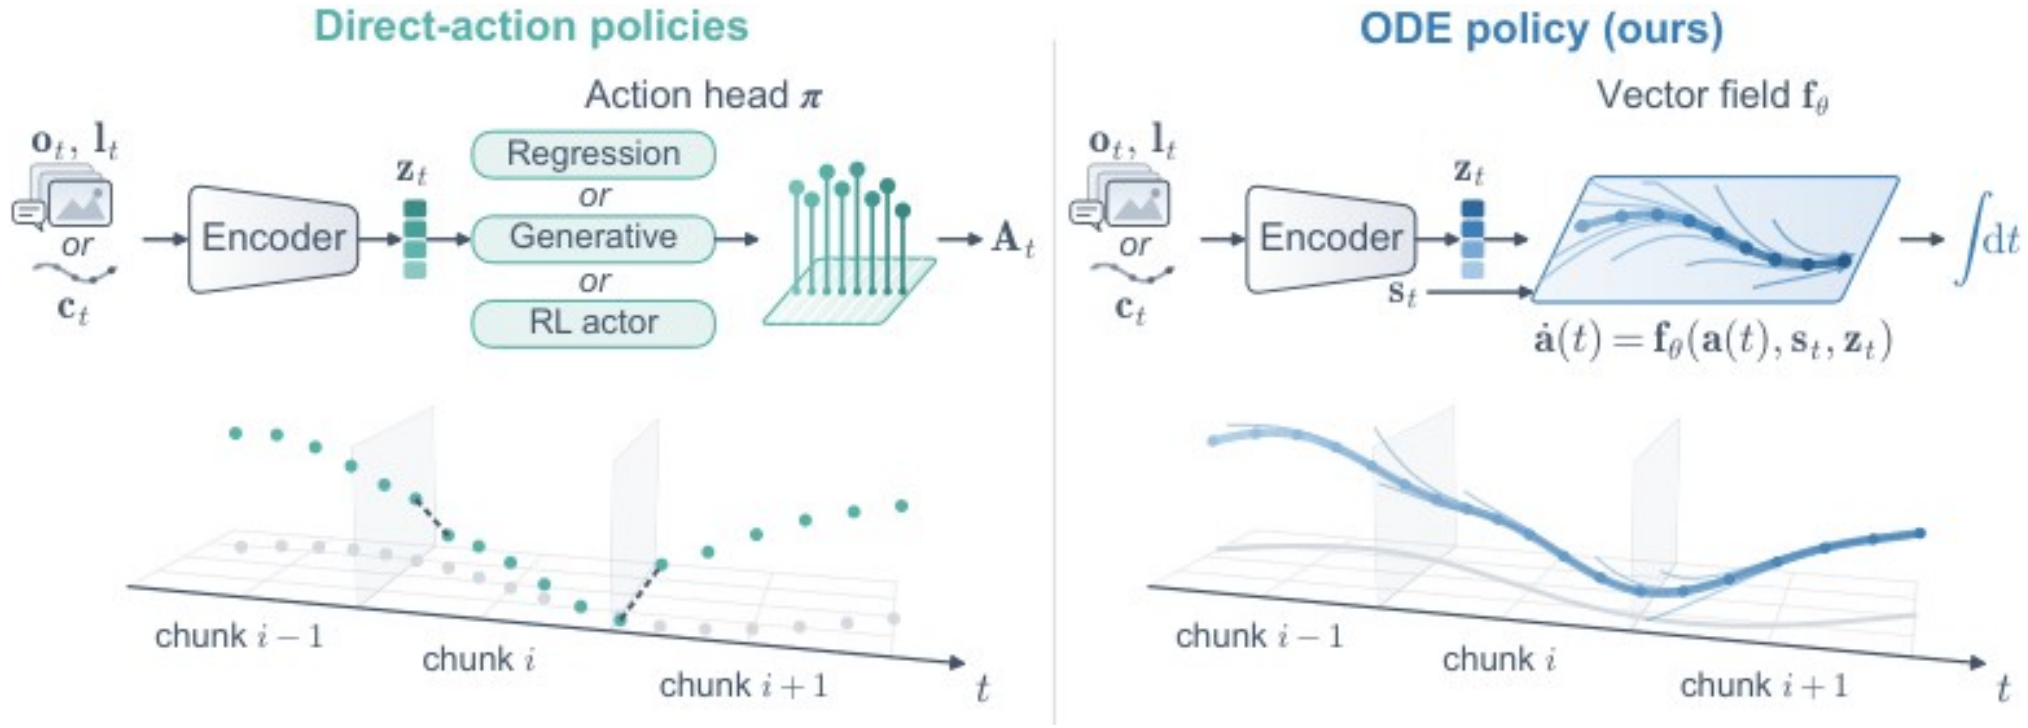

方法核心：策略 = 物理时间上的向量场，动作由积分得到

观测输入
图像历史 + 语言
（RL：参考动作）

编码器
每个 chunk 只算一次
→ 条件 z_t

向量场 fθ
FiLM-MLP
输入 (a, s_t, z_t) → da/dt

数值积分
RK4 / RK2 / Euler
chunk 长 H = 8

动作流
积出一个就发一个
给底层控制器

↑ 本体感受 s_t 直接输入向量场

↺ 每个动作从上一个动作出发，跨 chunk 接续

$$da/dt = f_\theta(a(t), s_t, z_t) \qquad \hat{a}(t+k) = \hat{a}(t+k-1) + \int f_\theta(a(t'), s_t, z_t)\, dt',\ k = 0 \ldots H-1$$

物理时间 vs 生成时间

- 扩散 / 流匹配的 τ∈[0,1] 是生成时间，中间样本不是机器人可达状态
- 每个 chunk 都从噪声重新生成，与上一个 chunk 的结尾无关
- ODE 的 t 是物理时间：积分路径就是执行轨迹

训练：只监督积分路径

- 从示教动作 a_{t−1} 积分 H 步，与示教做 L2 匹配
- chunk 短，梯度直接穿过求解器，不需要 adjoint
- 不回归速度标签，避免差分放大示教噪声

推理：三点收益

- 平滑：整条执行是一条积分曲线，chunk 交界无跳变
- 流式：积出一个动作就发送，无需等整个 chunk
- 自由步长：部署时可换积分步长、换控制频率

两个关键设计让 ODE 早期就学得稳：收缩扰动 + 无缝分块

收缩扰动 Contractive Perturbation

- 起点加扰动 δ （约 1 cm / 0.03 rad ，半数片段）
- 目标： a_{t+k} + ρ^{k+1} · δ ， ρ = 0.7 ，偏差几何衰减 → 局部收缩

消融：第 1 轮 **79.8% → 58.4%** （去掉后），第 20 轮前差距消失

无缝分块 Seamless Chunking

- 新 chunk 从上一 chunk 末尾的期望动作继续积分，不从测量状态重启
- 保留期望动作相对测量状态的“领先量”

消融：第 1 轮 **79.8% → 47.8%** ；收敛后边界比高 3–4× ， jerk 高 1.3–2.2×

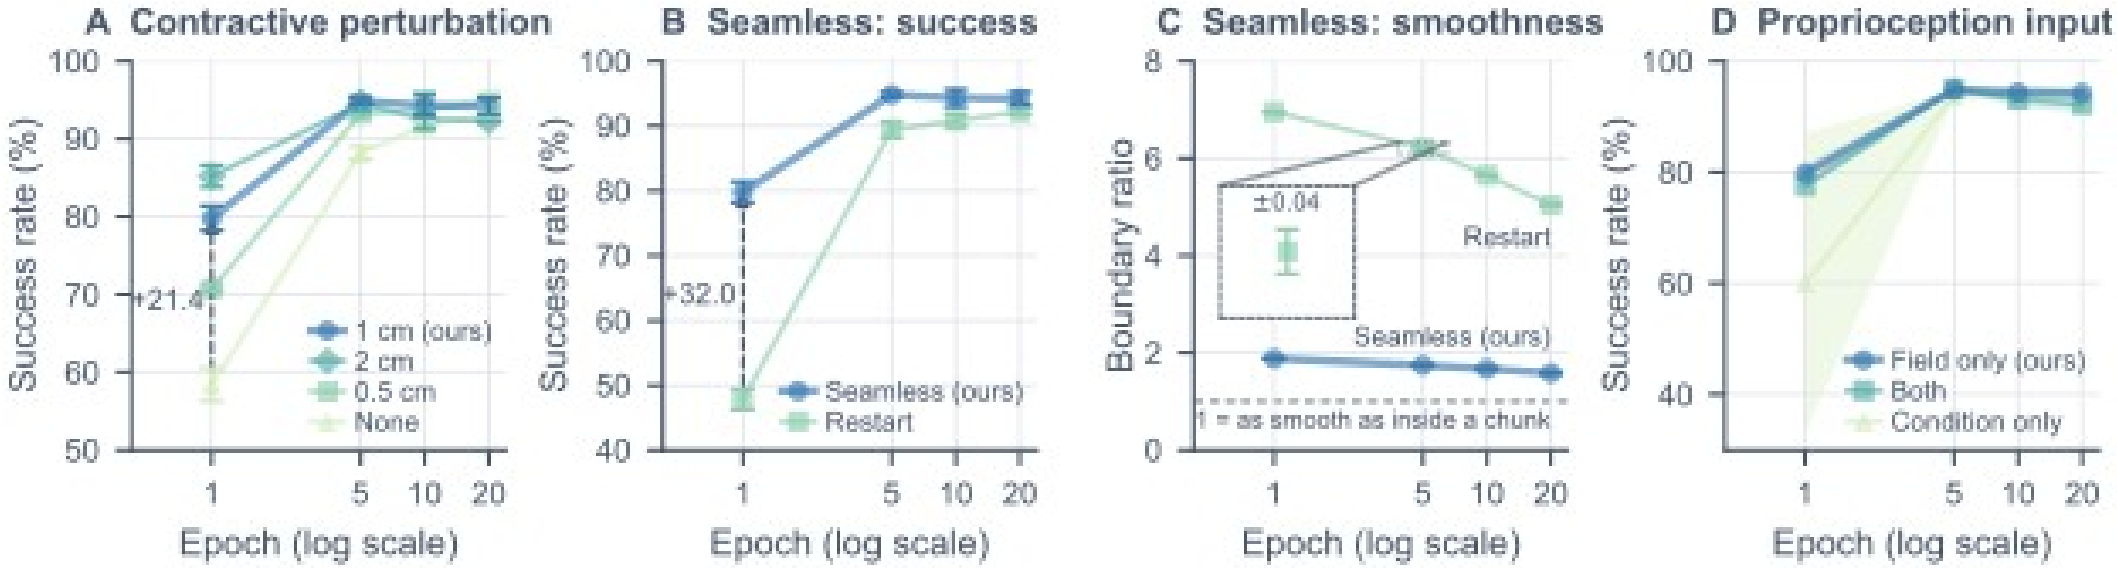

多样性头：随机“倾斜”向量场，一个确定性 ODE 也能多模态

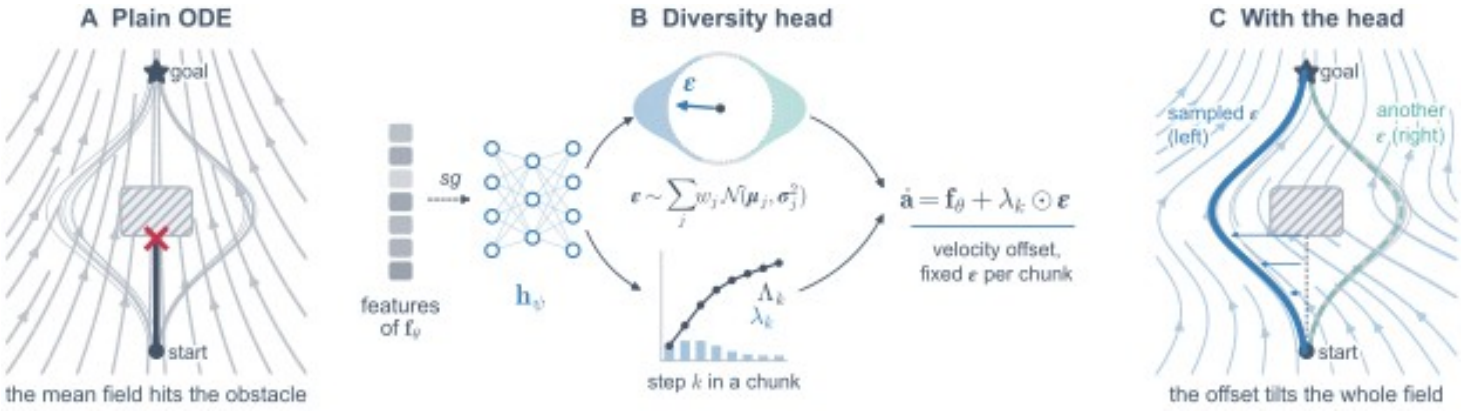

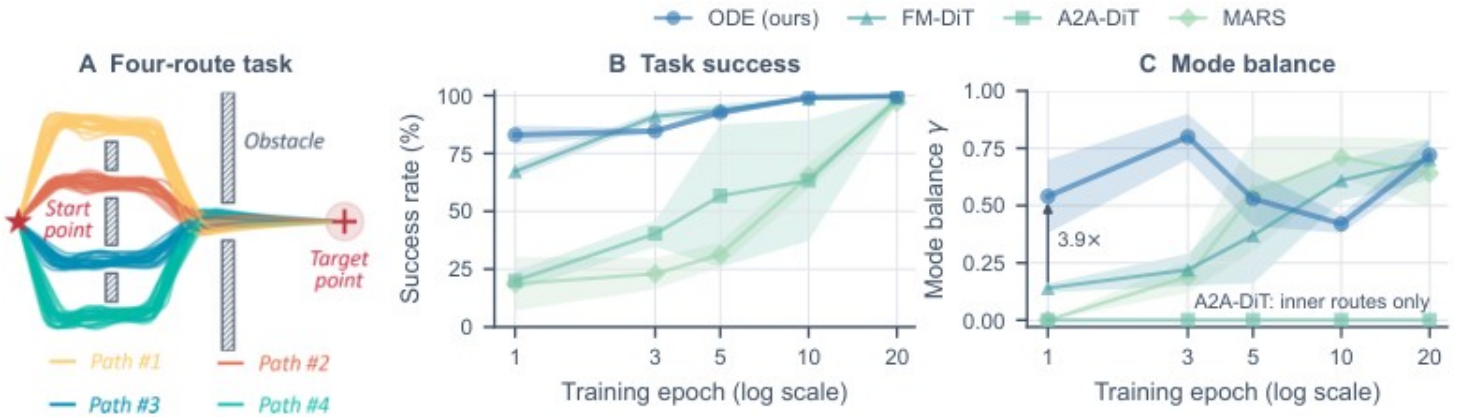

机制

- 速度 = fθ + λ_k ⊙ ε，ε 从 K=12 分量 GMM 采样，chunk 内固定
- 头的输入和目标均 stop-gradient，不改变 fθ 的梯度
- 单模态任务（LIBERO）用分量均值

结果

3.9× 第 1 轮平衡度 γ

相对 FM-DiT

- A2A-DiT 只走内侧两条（γ = 0）
- 第 10 轮 FM-DiT 更平衡，第 20 轮两者相近
- 真机抽屉：左 / 右臂取苹果 40% / 60%，成功 60%（FM-DiT 0%）

学得极快： 1 个 epoch 79.2%， 2 个 epoch 越过 85%

2 vs 30

达到 85% 所需 epoch

A2A-DiT 4 、 FM-DiT 30 、 DDPM 50–60 、 ACT >100

87.7% > 85.4%

数据效率

每任务 20 条示教（第 100 轮）超过 FM-DiT 用满 50 条

1.5M > 48M

参数效率

1.5M ODE 第 10 轮 92.5%， 48M FM-DiT 最高 87.5%

放进大模型依然有效： π0.5 与 ImageWAM 第一轮大幅领先

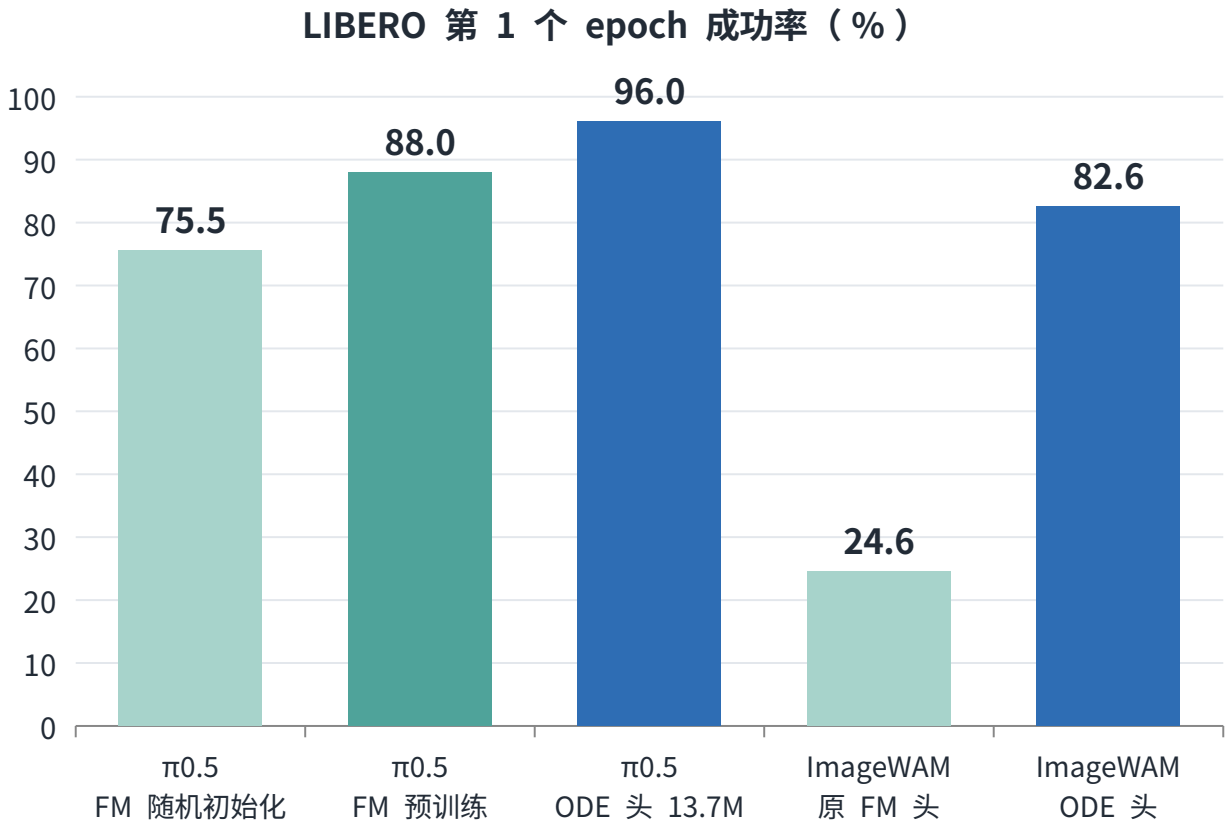

π0.5 为单 seed， ODE 头参数约为原专家（430M）的 3%，非等容量比较； ImageWAM 第 6 轮后三种头均约 98%。

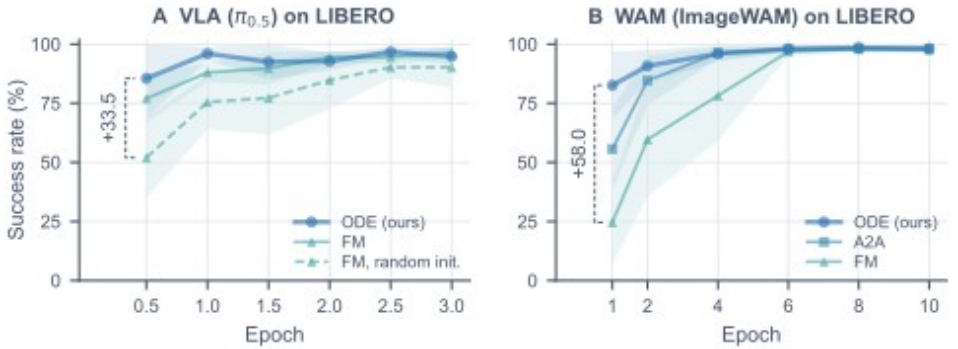

2.2 ms
π0.5 动作头 /chunk
FM 专家 31.8 ms

55 ms
ImageWAM 模型 /chunk
原 FM 头 223 ms

- π0.5 中 chunk 边界指令变化约减半（0.097 vs 0.206）
- ImageWAM LIBERO-plus 最佳： 89.9% vs 81.9%

生成又快又好：接近单次前向的速度，成功率高于生成式策略

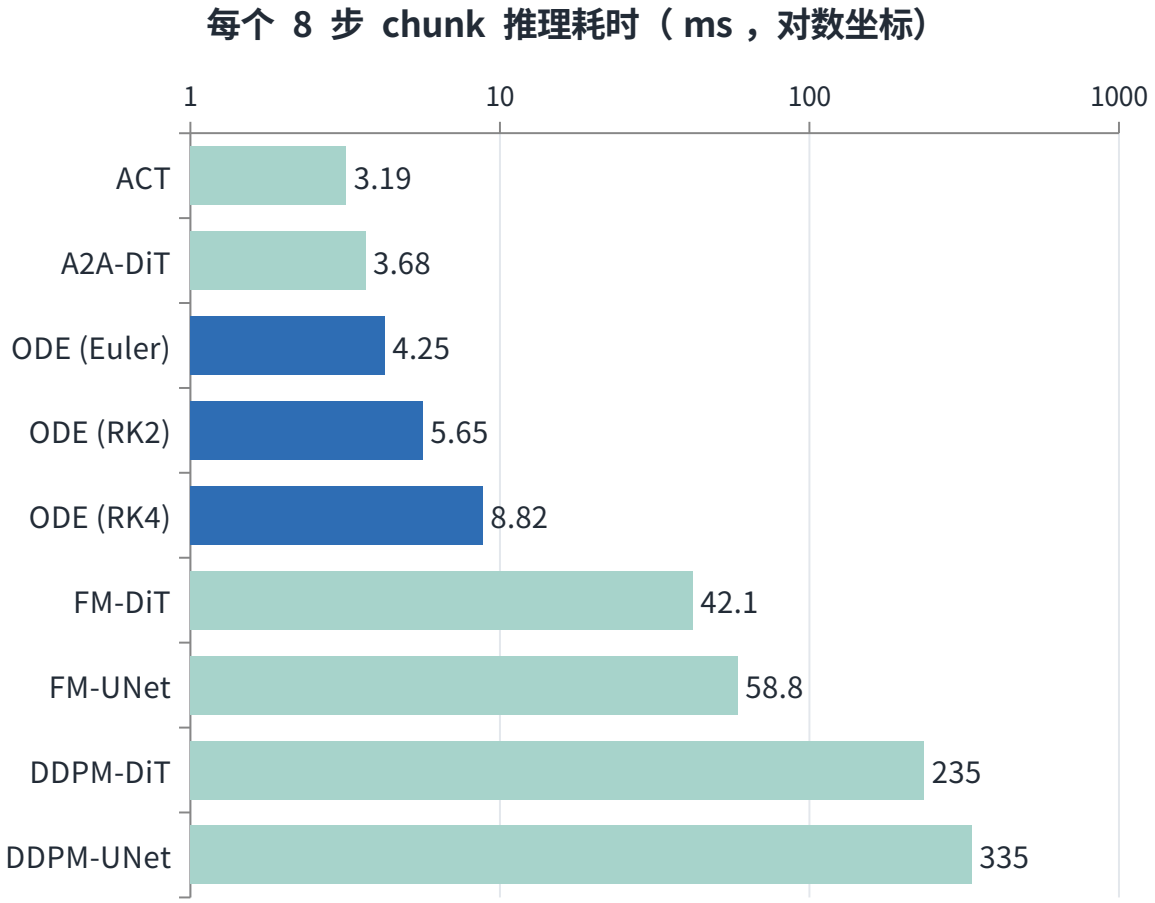

编码器约 1.2 ms，各方法相同，差异来自动作头；正文共享 GPU 测得 Euler 5.7 ms，为 FM-DiT 的 1/10.8。

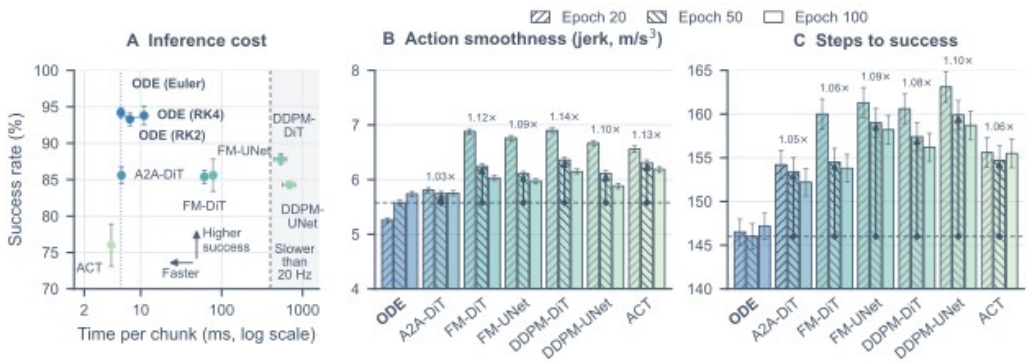

执行质量（成功回合）

- 末端 RMS jerk 每个 checkpoint 都最低，基线为 1.03–1.14×
- 完成任务步数最少（约 146 步），基线多 5–10%
- RK4 / RK2 / Euler 成功率差 < 1 个点 → 部署用 Euler 即可
- DDPM 超出 20 Hz 控制 8 步 400 ms 的预算

真机上比人类示教还平滑： chunk 边界几乎不跳

chunk 边界处指令加速度（ rad/s² ，越低越平滑）

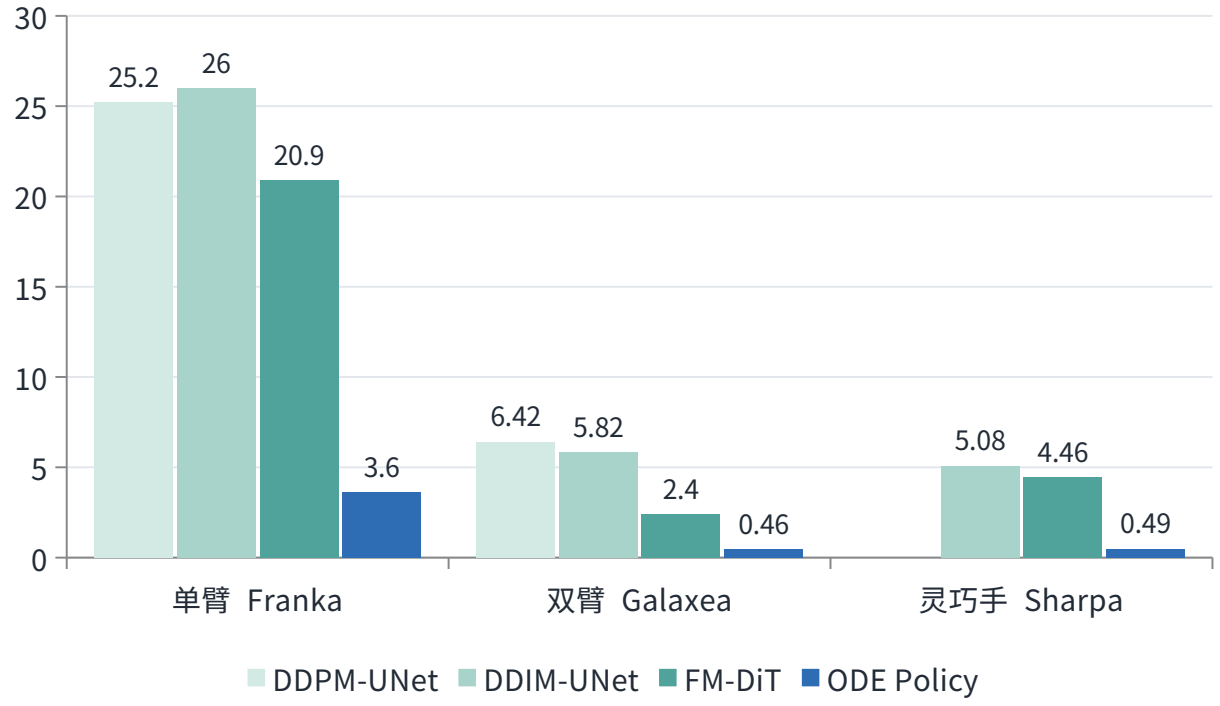

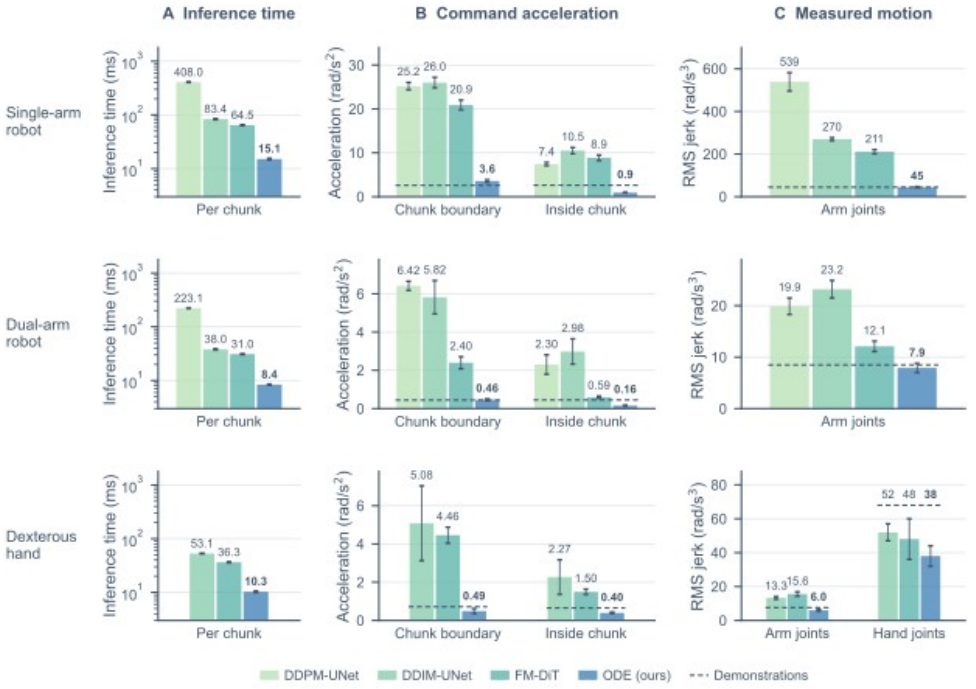

45 vs 211–539
单臂实测 arm jerk (rad/s³)

3.5–27×
真机推理快于扩散 / 流匹配

强化学习同样受益：替换 SuperMimic 的 actor，学得更快、动作更稳

+37%
训练回报 @0.75 h
0.630 vs 0.460

+30%
评估回报 @0.4 h
全部 40 段动作

0.885
3 h 评估回报
原 actor 0.845，PPO 0.452

1.0–1.1
首步 / 末步梯度范数比
原 actor 约 0.57

−21%
执行动作加速度
相对原 actor；不到 PPO 一半

抗扰泛化：早期领先明显，训练后期与最强基线持平

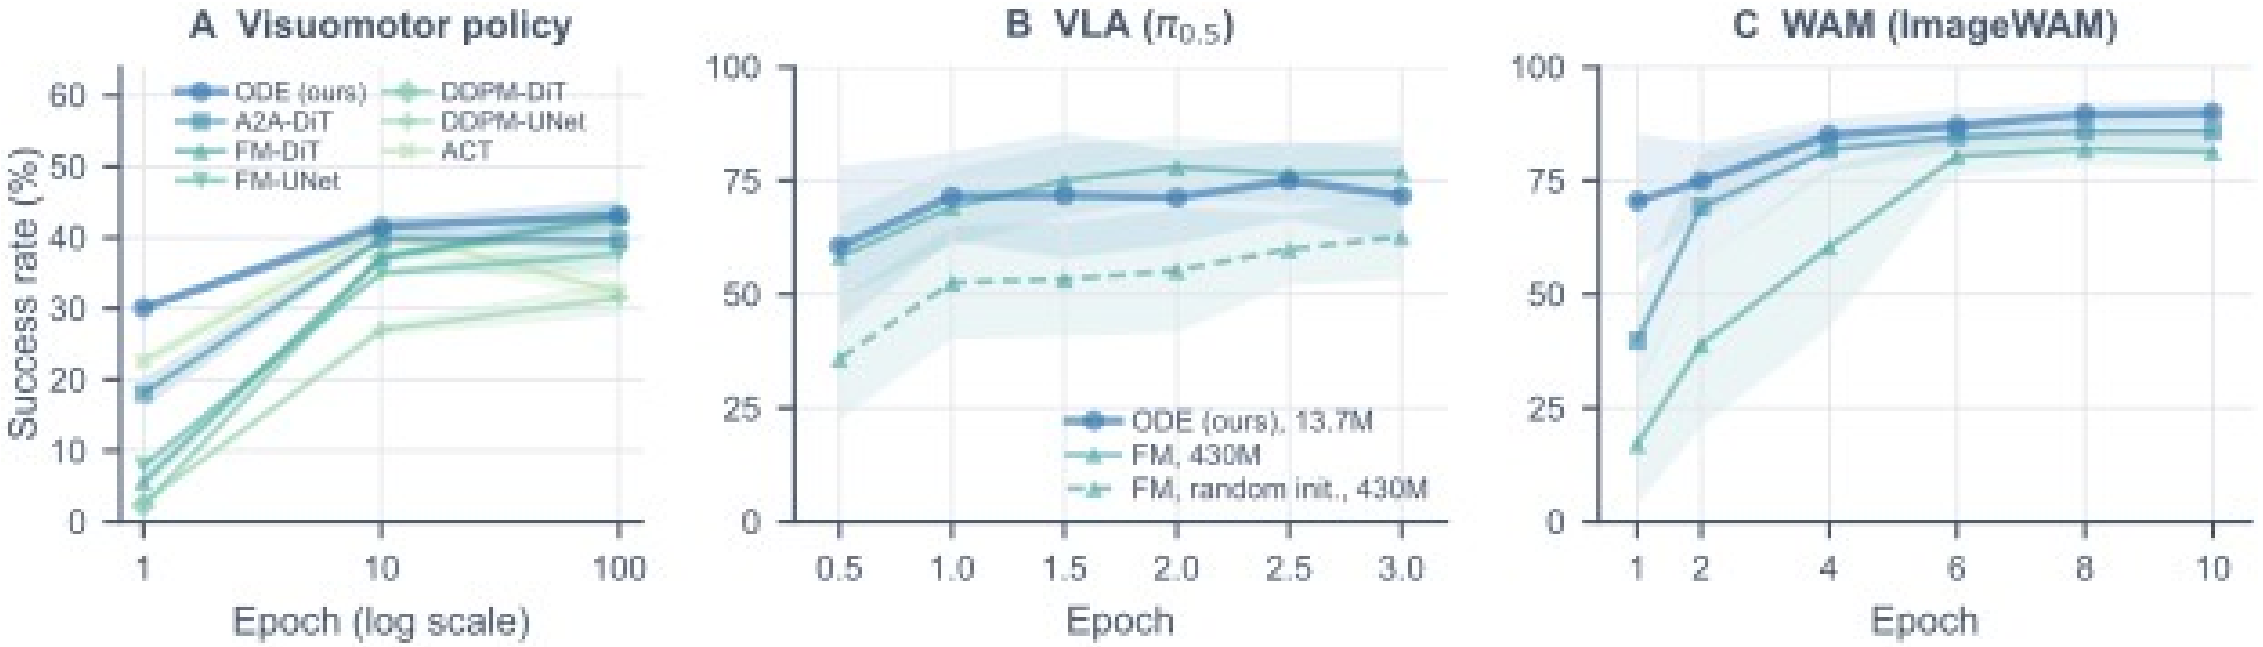

视觉运动策略

第 1 轮 **30.1% vs 22.6%** （ACT）

- 第 100 轮与最强基线持平

ImageWAM

第 1 轮 **70.5% vs 17.1%**

最佳 checkpoint **89.9%** vs FM 81.9 / A2A 85.8

分扰动类型（第 100 轮）

- 传感器噪声领先最多： 34% vs 约 15–22%
- 初始位姿： FM/DDPM-DiT 更好；相机变化：全部 ≈ 0

真机 14 个任务：每个任务成功率都最高

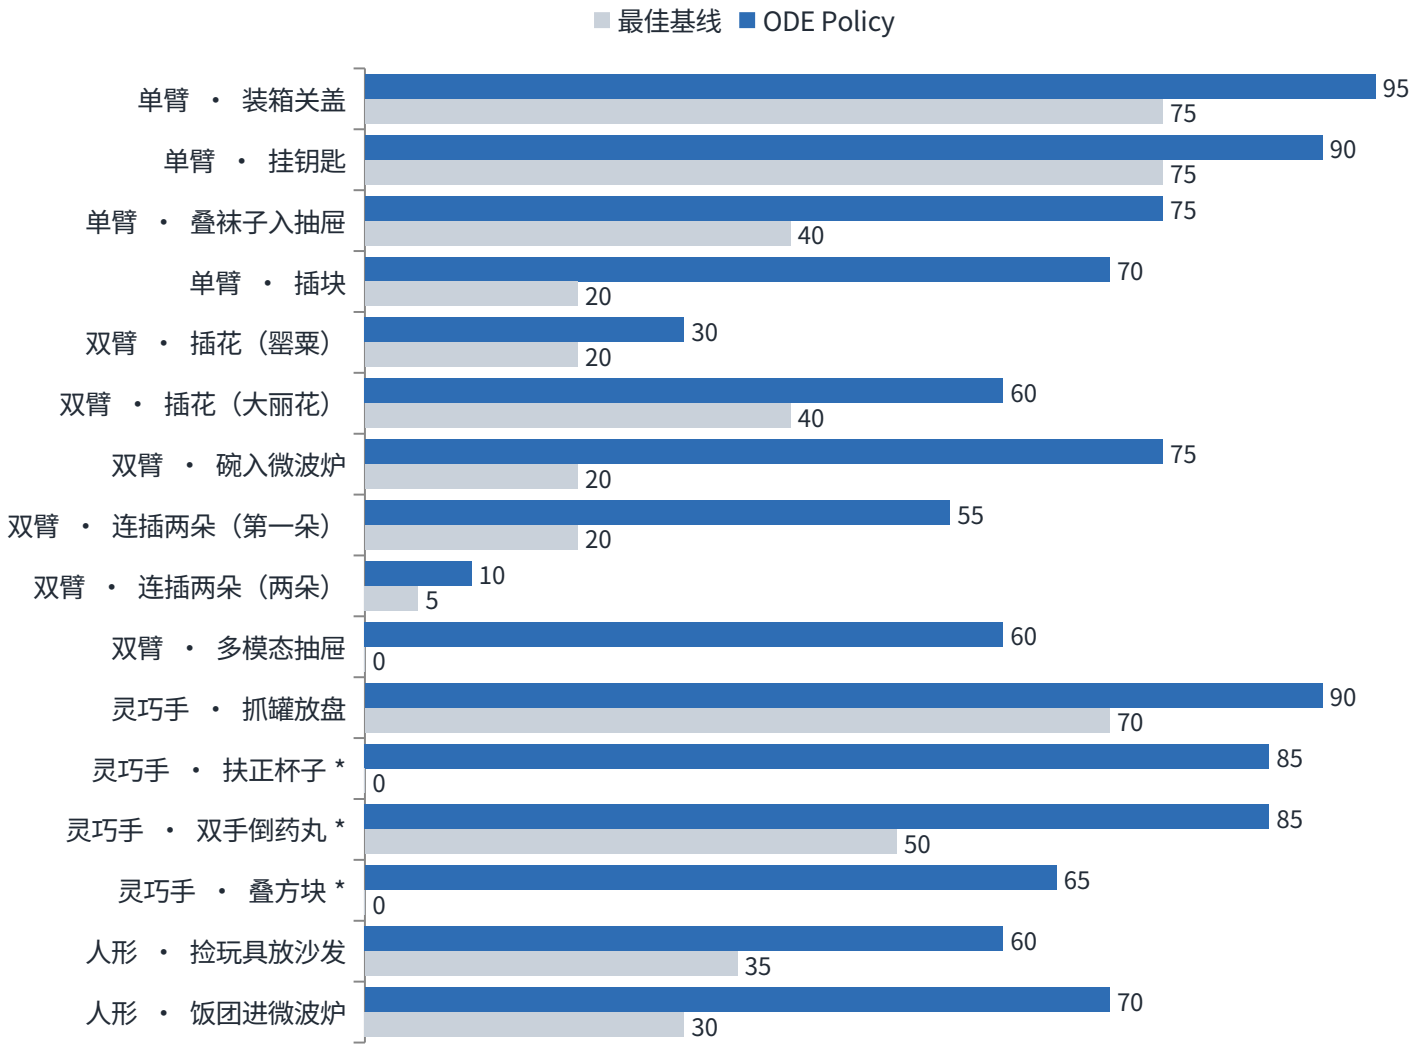

成功率（%，20 次试验）

- 单臂 Franka：40 条示教，仅训练 50 epoch；插块 70 vs 20
- 双臂 Galaxea：微波炉仅 34 条示教，75 vs 20
- 灵巧手 Sharpa：* 为只用另一实验室公开数据训练、在本实验室部署
- 人形 G1：替换 GR00T N1.7 动作头，+25 / +40

注意：部分差距较小（如 10 vs 5 、 30 vs 20 ），样本量有限。

跨实验室迁移：只用别人的公开数据，灵巧手技能在新环境照样成功

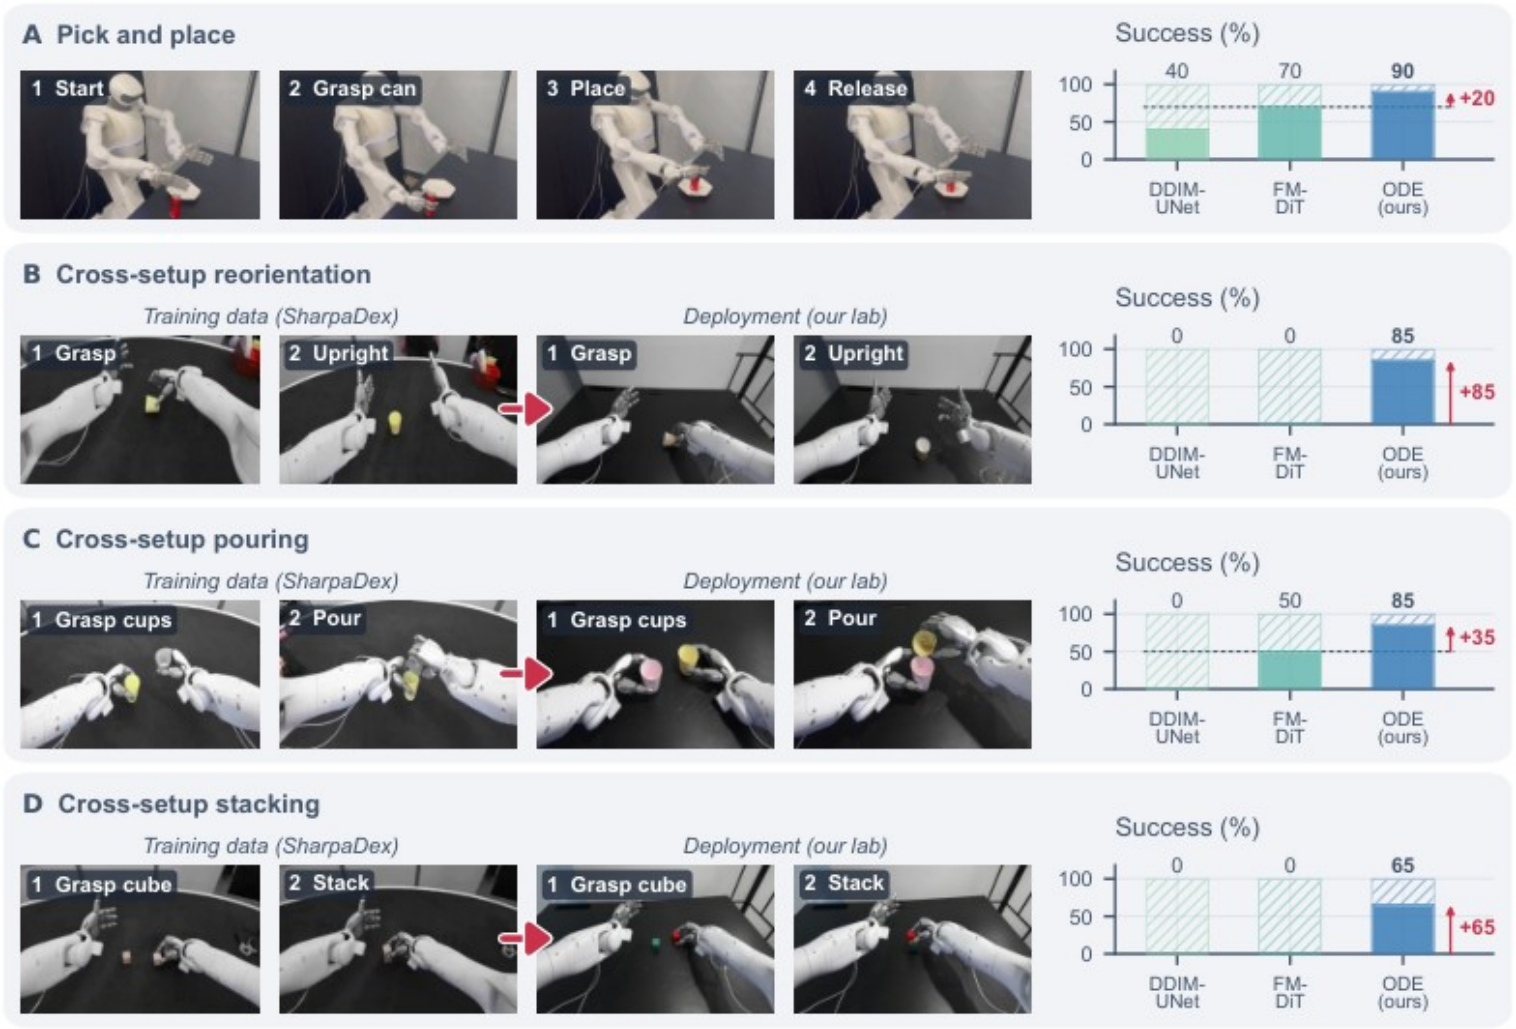

跨实验室三任务（%）

85 — **扶正杯子**
FM-DiT / DDIM: 0 / 0

85 — **双手倒药丸**
FM-DiT / DDIM: 50 / 0

65 — **叠方块**
FM-DiT / DDIM: 0 / 0

- 另换杯子、背景，木方块→彩色方块
- 扶杯任务边界 / 内部加速度比 0.86 （示教 0.96 ，基线 2.03 / 2.97 ）
- 抓罐（本地 50 条示教） 90 vs FM-DiT 70

消融：收益来自 ODE 表述本身，而非精确求解器或大网络

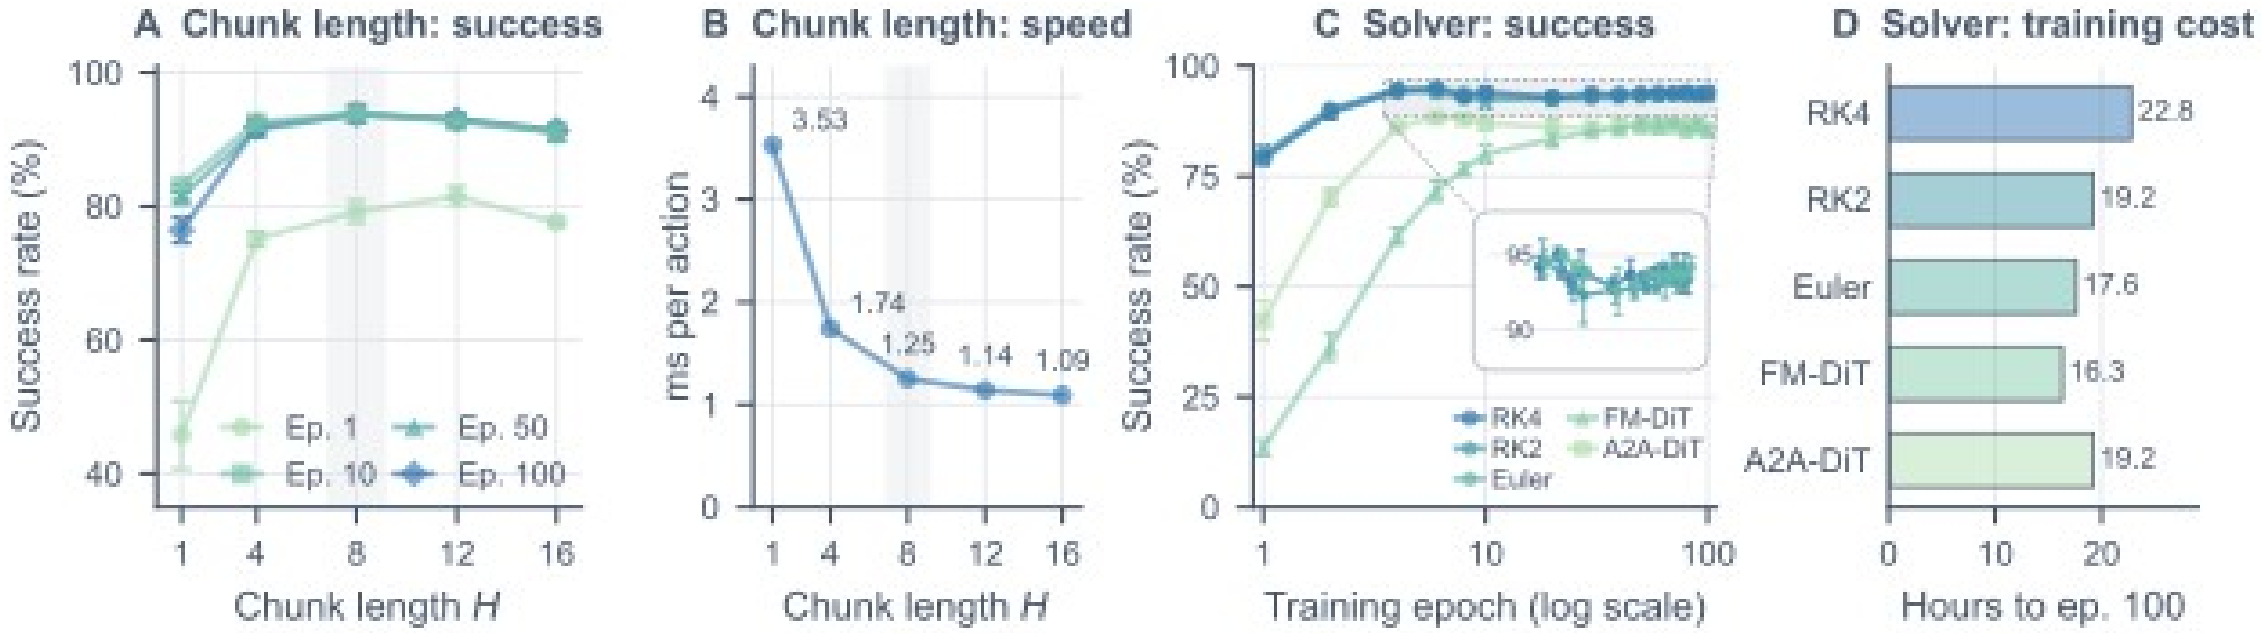

Chunk 长度

- H = 1： 76.4% ，每动作最慢
- H ⩾ 4： > 91% ， H = 8 最佳
- H ⩾ 12 训练偶有 loss 尖峰

积分器

- RK4 / RK2 / Euler 差 < 1 个点
- Euler 训练时长 ≈ FM-DiT
- → 收益不靠精确求解

向量场架构

- FiLM-MLP 93.8% vs Transformer 91.2%
- 每 chunk 11.0 ms vs 51.9 ms
- 时序结构由积分承担

多样性头

- K 只需大于模态数（默认 12 ）
- 无偏移第 1 轮 85.3% ，均值 79.8%
- 第 5 轮起差距 ⩽ 4.2 点

连续时间向量场带来新用法：无动作标签数据、任意控制频率

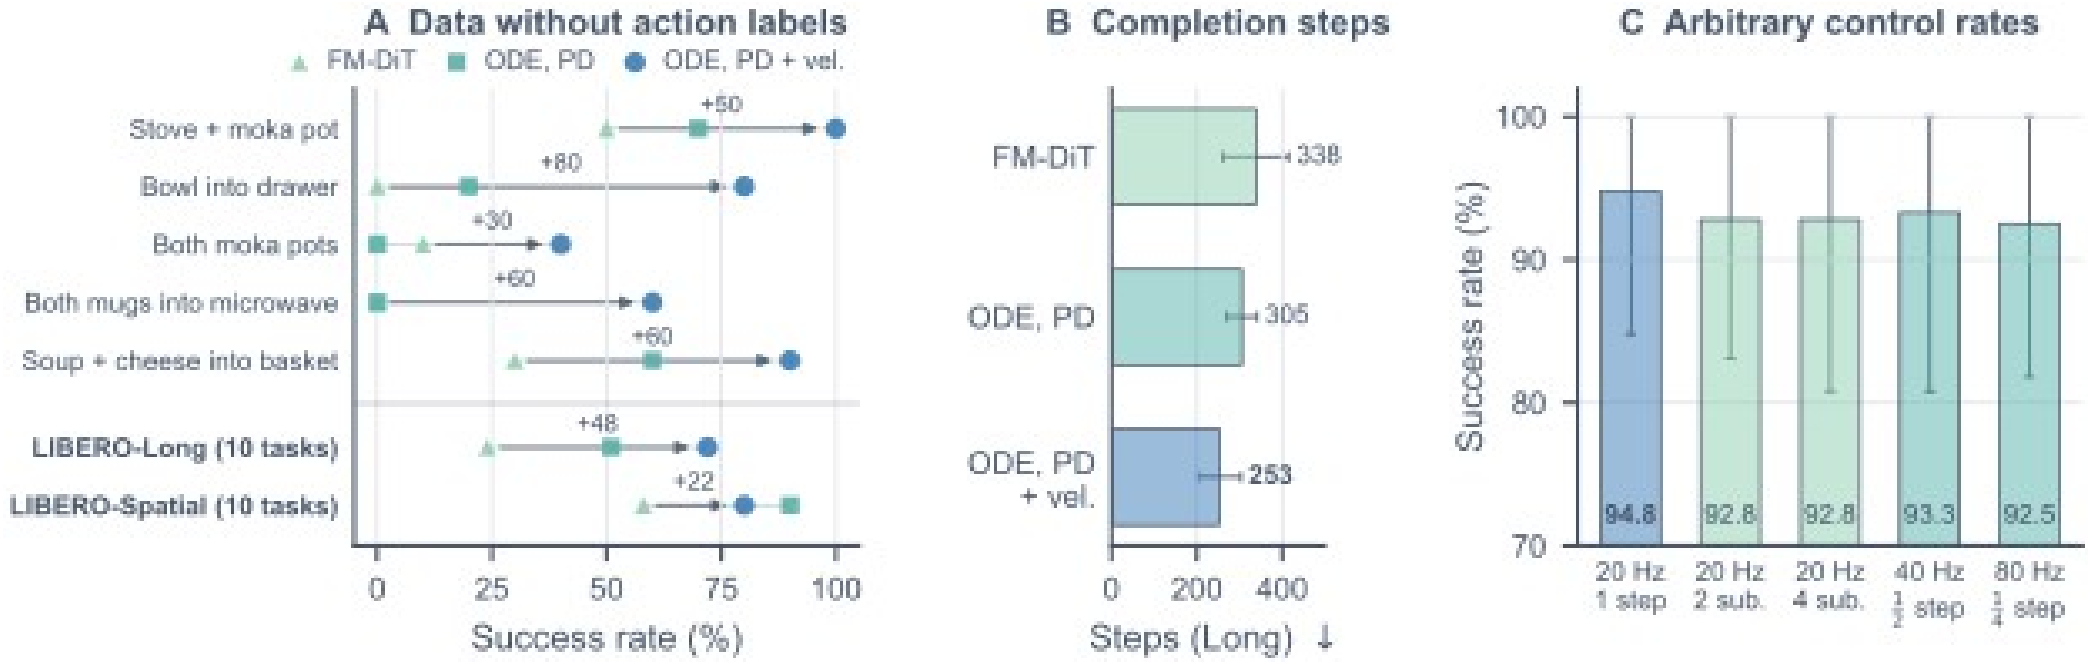

无动作标签：速度前馈 PD

LIBERO-Long **51% → 72%** （FM-DiT 24%）

- 成功回合步数 305 → 253
- 代价： Spatial 90% → 80%

任意控制频率

20 Hz **94.8%** → 40 / 80 Hz **93.3% / 92.5%**

- 只改部署时积分步长，无需重训
- 子步积分路径偏移 ≤ 1 mm

弱项：离散信号

- 二值夹爪用单独分类头
- 夹爪也进 ODE： 第 1 轮 79.2% → 74.5%，主要掉在 Long
- 无模型 RL 中收益小，有时有害

评价：范式简洁、通用性强，但优势主要体现在“学得快”

亮点

- 改的是范式而非堆模型： FiLM-MLP + 短 chunk 积分，无需速度标签、无需 adjoint
- 通用：视觉运动策略、 π0.5 VLA 、 ImageWAM 、 GR00T N1.7 、 SuperMimic RL actor 均可替换
- “场以当前动作为输入”同时支撑收缩扰动、无缝分块、流式执行
- 执行收益实在：推理快、 chunk 边界无跳变、 jerk 不高于人类示教、控制频率可改
- 真机覆盖广，含跨实验室迁移与人形移动操作

局限与注意

- 优势集中在早期：摘要中的 5.9× / 5.4× / 3.9× 均为第 1 轮比值；充分训练后差距收窄
- 对比不完全对等： π0.5 头参数仅约 3% 且单 seed ；单臂真机只训 50 轮，不利于扩散基线
- 真机每任务 20 次，部分差距小（ 10 vs 5 、 30 vs 20 ）
- 多模态有限： GMM 偏移，导航第 10 轮平衡度不如 FM-DiT
- 短板：离散夹爪需单独头；无模型 RL 收益小；相机变化全失败； RL 需加界防漂移

Takeaway

把运动的连续性写进策略结构，而非让网络从数据里学

学得快

LIBERO 第 1 轮 79.2%；20 条示教超过 FM 用 50 条

跑得快

8 步 chunk 5.7 ms，约为 FM-DiT 的 1/10.8；可流式执行

动得稳

chunk 边界无跳变，真机 jerk 不高于人类示教

用得广

视觉运动策略 / VLA / WAM / 人形 / RL actor 即插即用

开放问题：大规模预训练、训练充分时优势能否保持？离散事件与强多模态如何更自然地融入 ODE？