论文解读 | arXiv 2611.01815 | 2026-11-01

When Does Latent Prediction Error Support Physical Surprise Claims in Video World Models?

视频世界模型的潜空间预测误差，什么时候才能当作“物理惊讶”？

Anton Hristov · Aleksandar Slavov · Vasil Vasilev （同等贡献； TUES / Baba Tonka High School of Mathematics ）

一句话总结

表征里能读出一些物理信息，模型也确实会用到输入的动作；但原生预测误差主要跟着**轨迹类型、颜色和静态内容**走。在对照实验中，**不可能事件的误差甚至比可能事件更低**，所以不能直接把它当作物理惊讶。

代码与数据记录： github.com/3-ml/jepa-surprise

预测误差高，不一定意味着物理违例

预测误差分数

$$S(x, a) = d(p(f_C(x), a), f_T(x))$$

f_C / f_T：上下文与目标表征（含编码和 token 选择）
p：预测器； **a**：可选动作； **d**：打分距离
它衡量的是：**在这个表征里预测有多难**

常见用法

违反预期 (VoE) 检测	IntPhys 等物理基准评测	生成视频物理打分 / 奖励

误差变大，可能来自……

物理违例	我们真正想测的
外观	颜色、亮度变化
静态内容	画面里有什么
运动	动得越多越难预测
普通预测难度	模型本身的误差

方法

评估框架：把“表征里有什么”和“误差在响应什么”分开检验

Readout 读出

表征层面

冻结表征上训练线性探针，在没见过的场景上区分可能 / 不可能事件

Geometry 几何

表征层面

逐层测外观 / 物理位移的相对大小、方向一致性、子空间重叠

Action 动作

误差层面

观测结果固定，对比正确动作与错误动作，看误差是否上升

Appearance / static

误差层面

只改颜色（物理状态不变）或把单帧重复成整段，与原片段比较

Physical validity

误差层面

在不同运动 / 外观条件下，不可能事件的误差是否都更高

Calibration 阈值迁移

误差层面

在校准数据上定阈值，原样迁移到新场景，统计误报和漏报

评测对象： V-JEPA2-G （IntPhys2 、 Kubric ） · V-JEPA2-L （Physion++ ） · VideoMAE2-G 与像素统计（对照） · LeWorldModel / DINO-WM / JEPA-WM （TwoRoom 、 PushT ）。每个模型保留官方流水线，误差只在同一模型内比较。

关键设计：同一条轨迹，在两个世界里物理合法性正好相反

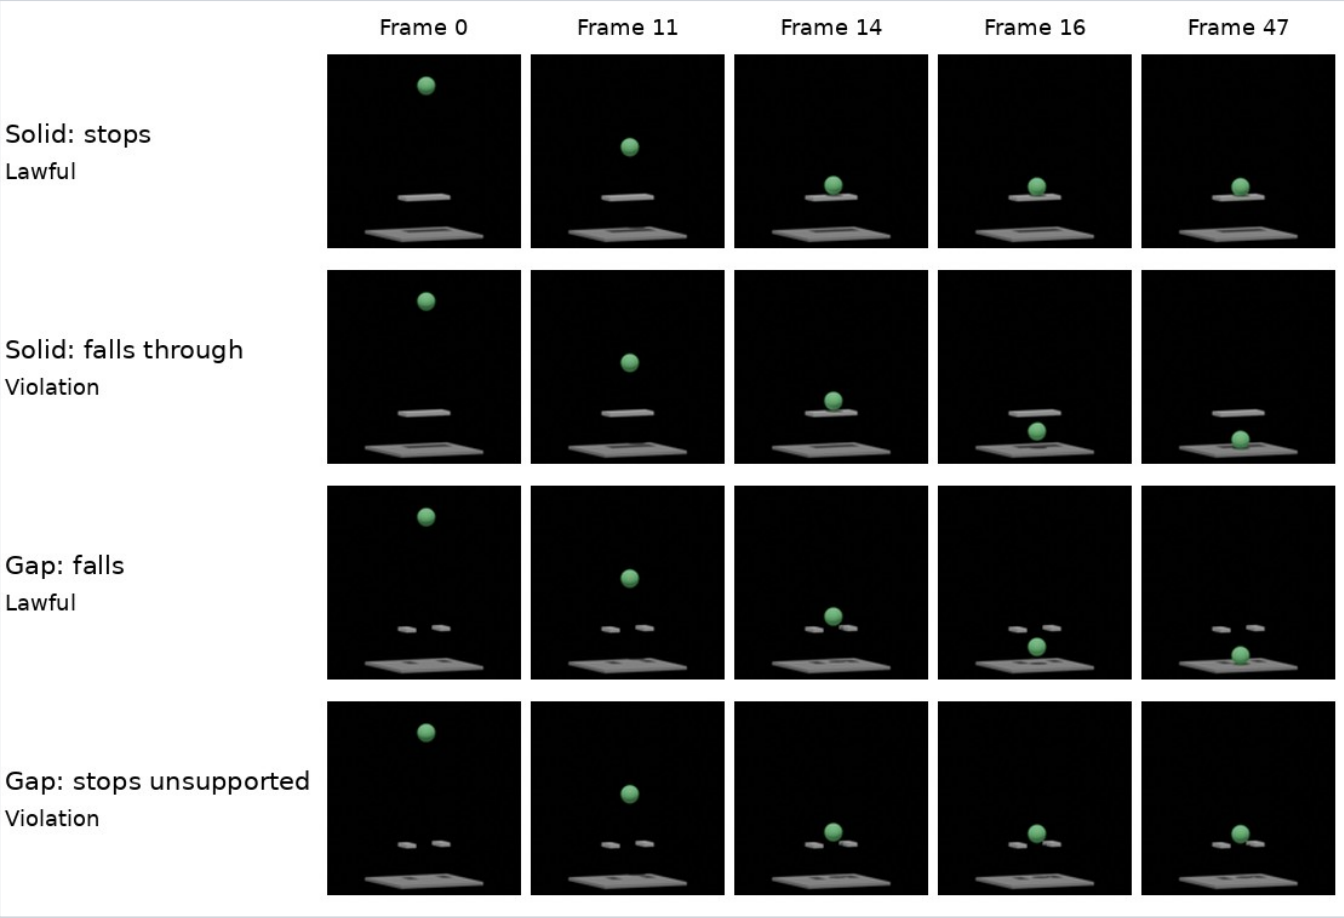

Fig. 8： 中层平台为实心或中间有缺口，下方平台接住下落的球

	停在平台高度	继续下落
实心平台	合法	违例 穿过固体
有缺口	违例 无支撑悬停	合法

256 配置 × 4 情形 × 3 外观 = **3,072** 段

外观：原始 / 全程色相偏移 30° / 从目标段开始突然偏移

V-JEPA2-G 看前 12 帧，预测后 36 帧；误差 = 相对 EMA 目标 token 的平均绝对误差

两个世界的“停住”轨迹完全相同，“下落”轨迹也相同

核心结果 1

误差跟着轨迹走，而不是跟着物理合法性走

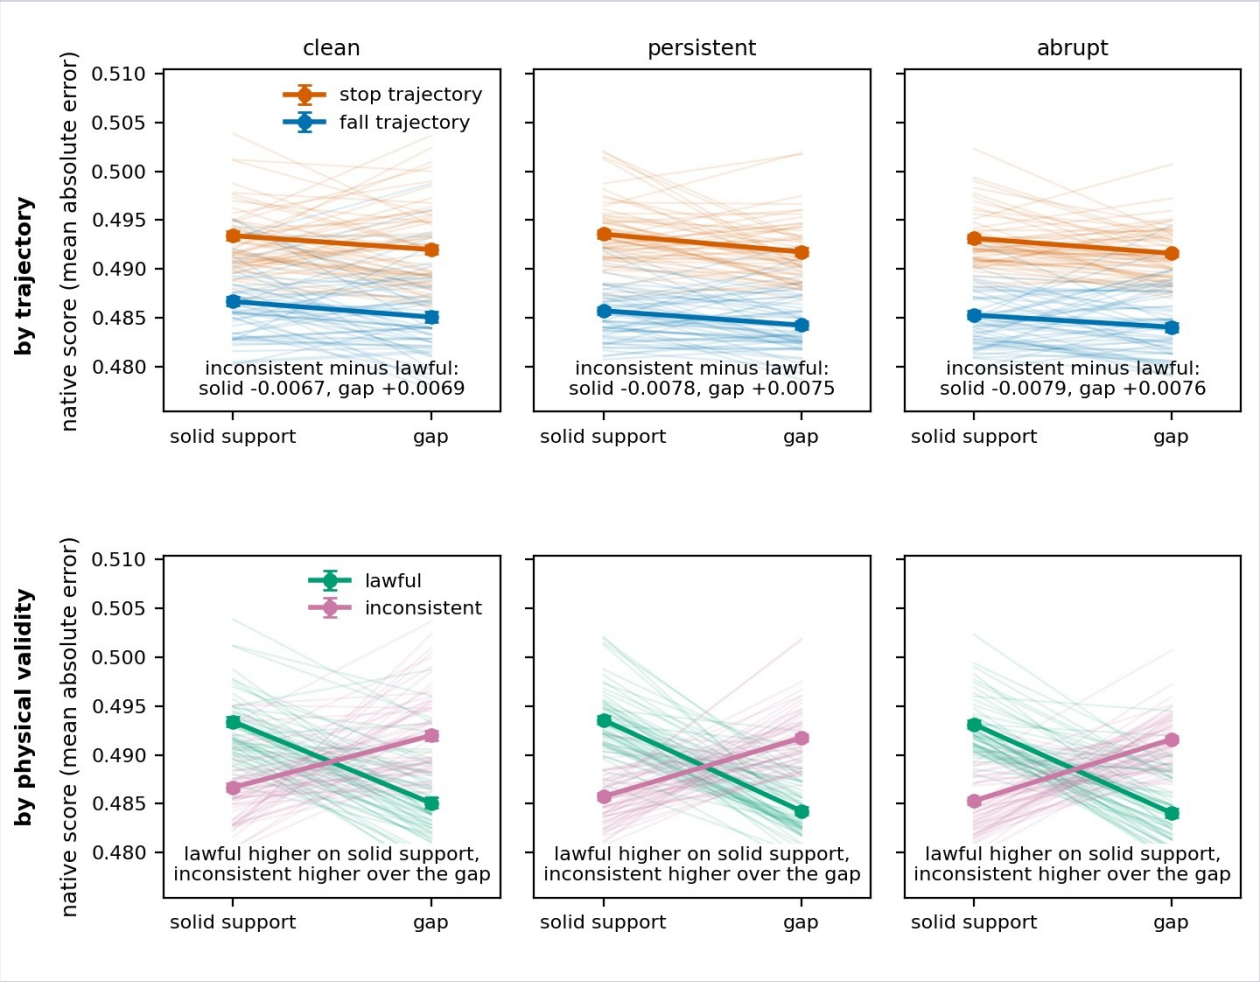

不可能 − 可能（clean）

−0.0067
实心平台
违例误差反而更低

+0.0069
有缺口
违例误差更高

- 在两个世界里，**“停住”轨迹的误差都更高**（约 0.493 对 0.485）
- 因此违例差值的符号随支撑反转；clean 和全程色相两种外观下，4 个校正后区间都不含 0
- 如果把两个世界平均，相反的排序会互相抵消，**问题被掩盖**

核心结果 2

固定阈值：实心平台上合法片段 100% 被误报

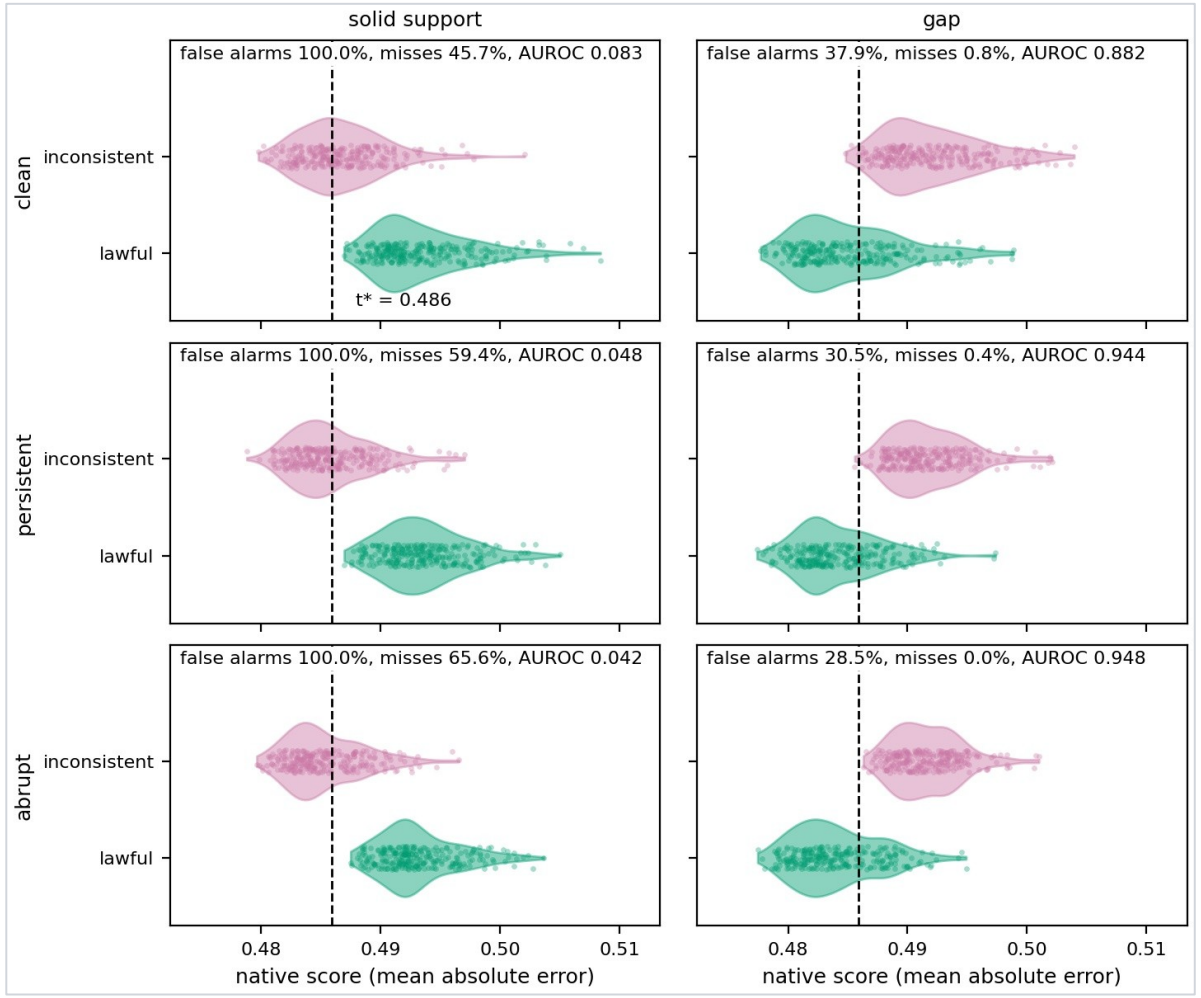

53.9%
clean 平衡准确率
（50% 为随机）

~69%
合法片段被误报

27.1%
实心平台准确率
AUROC 0.083

80.7%
缺口准确率
AUROC 0.882

- 阈值 $t^* = 0.486$，在 24 个独立的 clean 配置上拟合，不重新拟合、不反转方向
- 实心平台上 AUROC 接近 0，说明分数方向几乎完全反了
- “略高于随机”的平均值，背后是大量误报

去掉运动，误差反而更高；全程改色，误差反而更低

≈84%

窗口的原始误差不高于
“重复单帧”的静态版本（V-JEPA2-L）

- 192 个官方 Physion++ Mass 视频，每个完整的 16 帧窗口与重复首 / 中 / 末帧的版本比较
- 三个场景的平均差值都是负的

注意：官方实现先编码全部 16 帧再选上下文 token，目标帧信息会泄漏给预测器；结论只针对这一实现

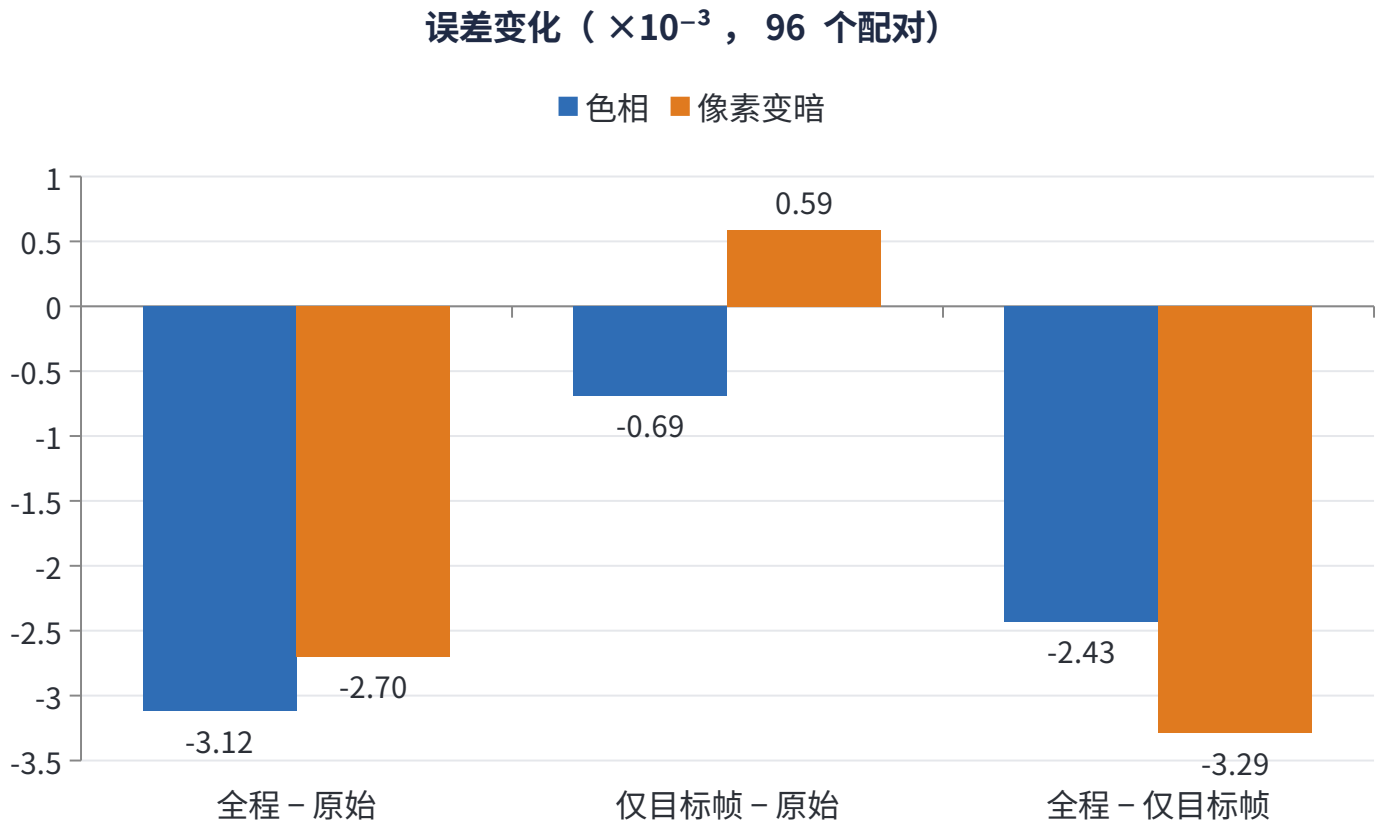

全程改色的两项区间不含 0；“仅目标帧”两项区间跨 0。数据来自 Table 2 （99.17% 配对 bootstrap 区间）

表征里的物理信息“能读出，但很弱”；外观几乎都能读出来

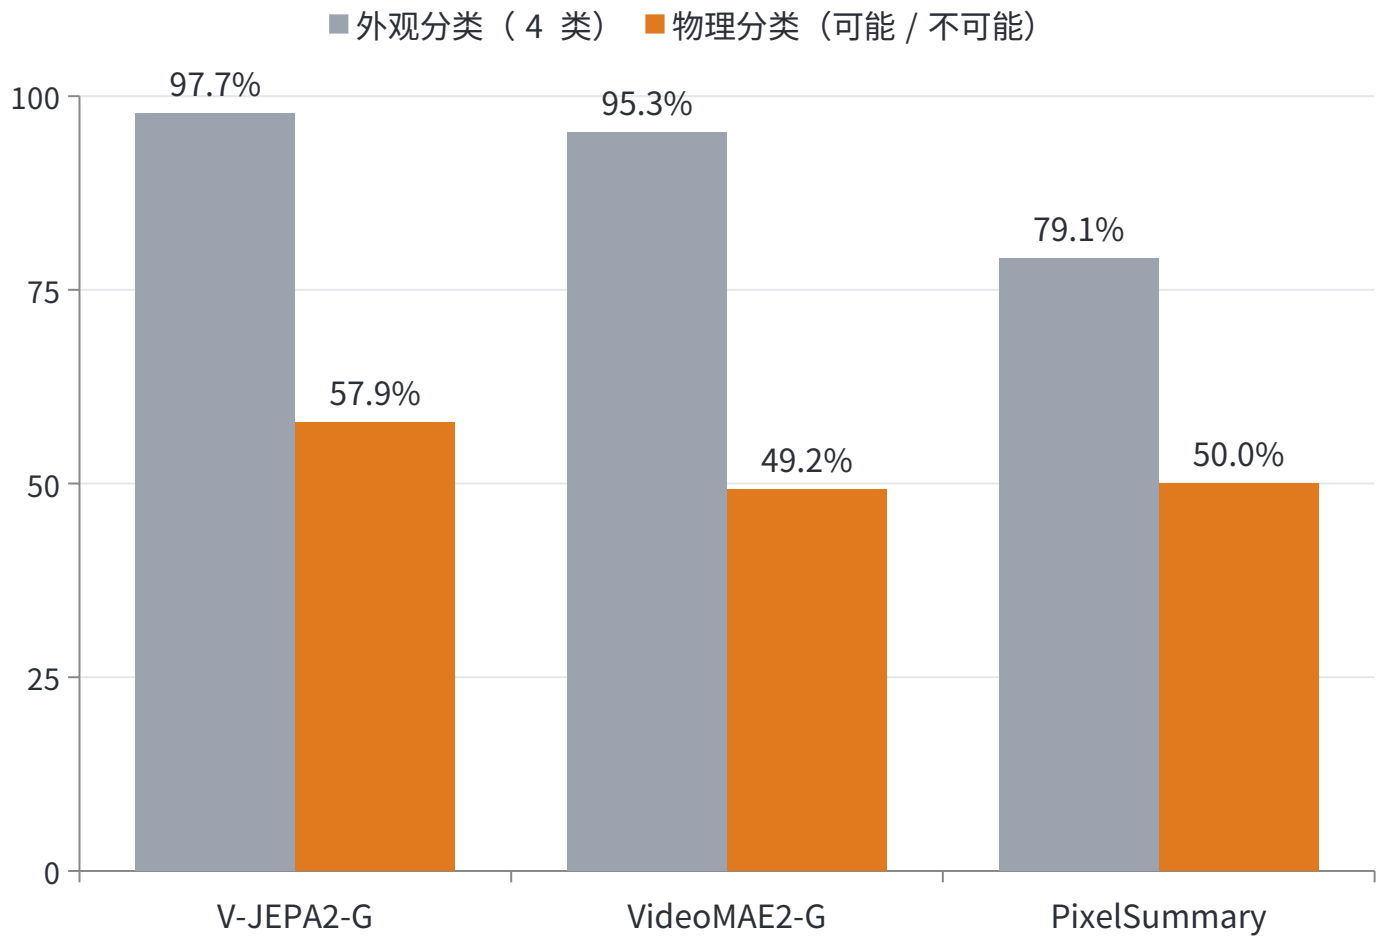

+8.7 pp

V-JEPA2-G 对 VideoMAE2-G 的物理分类优势
区间 [4.4, 13.3]

+7.9 pp

V-JEPA2-G 对像素统计的物理分类优势
区间 [4.1, 11.8]

- 57 个测试场景，按场景做 5 折交叉拟合，类别平衡的逻辑回归
- 只用 clean 片段时， V-JEPA2-G 对像素统计的优势不显著
- 架构和训练都不同，不能归因到 JEPA 目标；而且这属于 post-hoc 分析

越往深层，外观位移相对越小、方向越一致，与物理变化的重叠越少

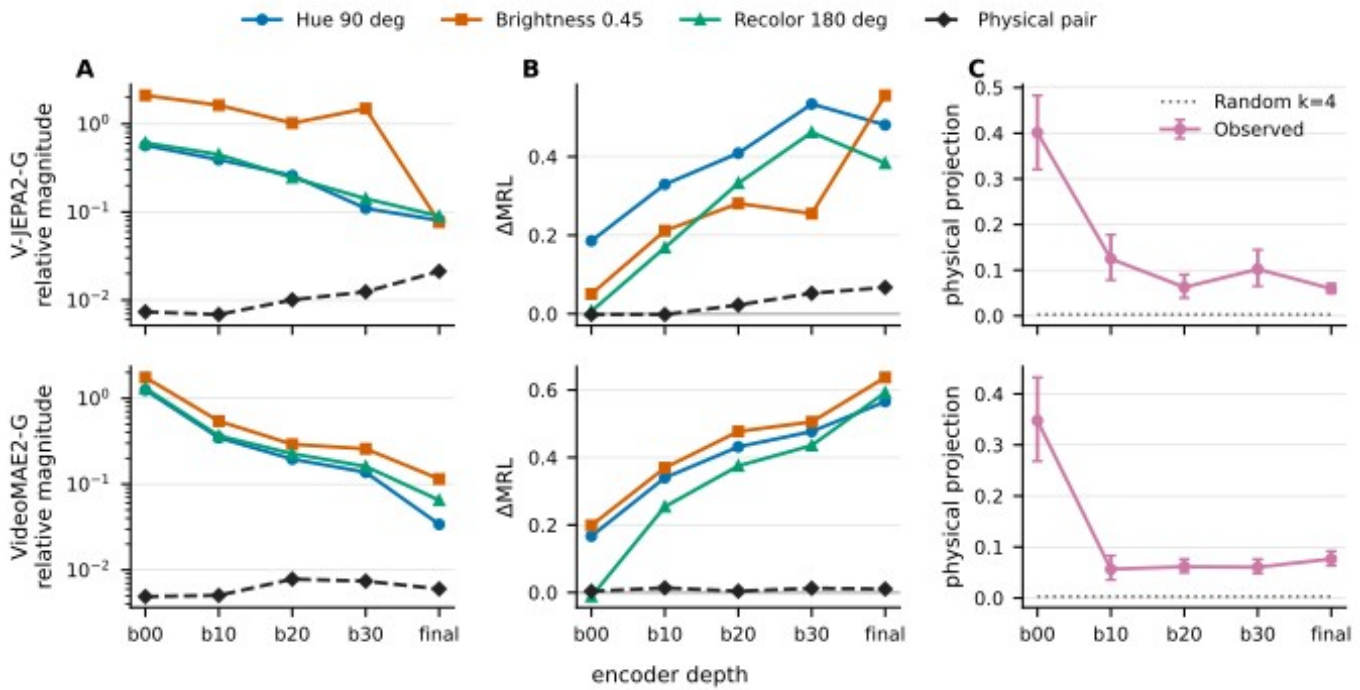

A 相对幅度

57% → 8%

V-JEPA2-G 色相位移 / 无关视频中位距离（首层 → 末层）

B 方向一致性 ΔMRL

0.4–0.6 vs ≈0.07

深层外观位移方向一致；物理位移接近打乱后的参考水平

C 外观子空间重叠

0.40 → 0.06

仍高于随机参考 0.0028；下降不单调（b30 回升到 0.10）

漂亮的几何结构，几乎解释不了原生误差的差异

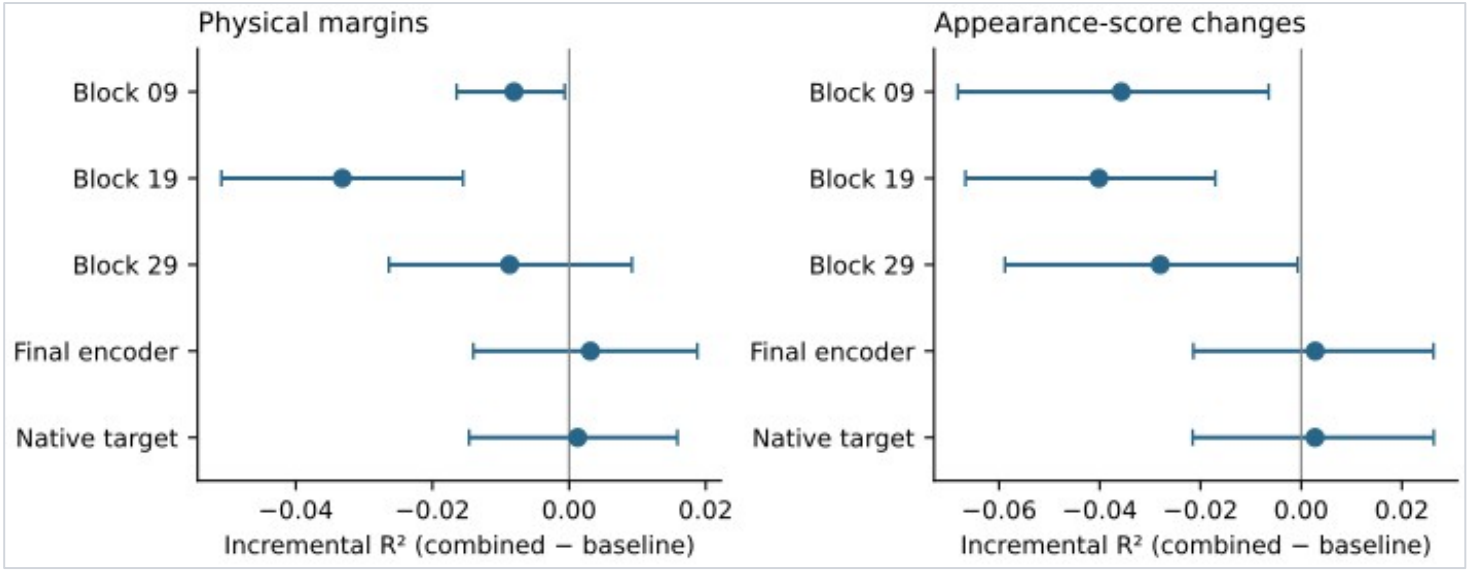

0.771 → 0.774

物理 margin 的 R^2：加入末层几何后增量区间跨 0

0 / 10

5 个层位 × 2 个任务中，增量区间整体在 0 以上的个数

- 基线：条件标签加静态、运动、打乱帧统计；扩展模型加入表征距离及交互项
- Block 19 反而显著变差（−0.033）；外观分数变化连基线的 R^2 都是负的

Fig. 12： 加入几何特征后的增量 R^2 （99.5% 配置 bootstrap 区间）

动作条件模型会用到动作，但对颜色的反应更大

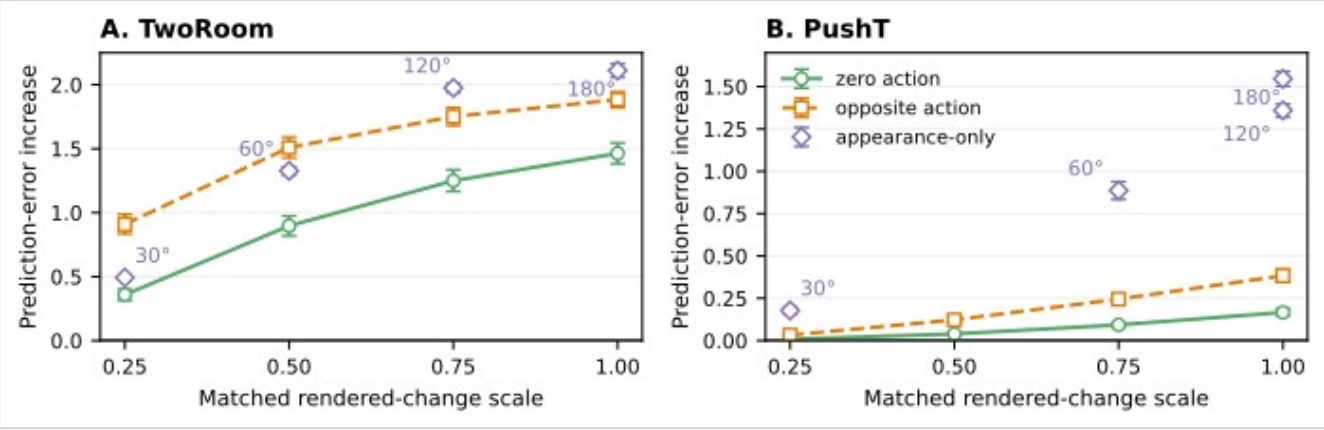

Fig. 3： LeWM 误差增量；紫色菱形为只改颜色（物理状态不变）

动作有效：目标帧固定时，相反动作都会提高误差（LeWM TwoRoom +1.88，PushT +0.38； DINO-WM 、 JEPA-WM 也为正）

PushT： 色相 60° 与动作尺度 0.75 的增量对比

模型	色相增量	动作增量	倍数
LeWM	0.887	0.245	≈3.6×
DINO-WM	0.0498	0.0031	≈16×
JEPA-WM	0.0174	0.0028	≈6×

增量相对各自的合法基线；倍数由 Table 15 均值计算，仅作描述

基线陷阱

DINO 系模型如果直接比较绝对分数，色相反而“低于”相反动作，原因是运动目标的合法基线本来就难得多（− 0.157 / −0.139 ）。论文用分解式把这一项单独拆了出来。

误差取决于“改成什么颜色”，而不只是“改了多少”

物理状态完全不变， RGB 变化幅度严格匹配：把块涂成 agent 的蓝色 vs 新颜色橙色；把 agent 涂成块的灰色 vs 新颜色紫色

+0.493

块：蓝 – 橙（仅目标帧）
233/256 个 episode 为正

+0.397

agent：灰 – 紫（仅目标帧）
245/256 个 episode 为正

- 全程改色时差距缩小（0.111 / 0.088），但两个排序都还在
- 精确分解：只改目标帧时预测完全不变，分数差约等于**目标编码器位移差**（0.493 vs 0.495），即来自编码器对颜色方向的敏感性
- 颜色在任务里本身带信息；这项实验**不能**说明 LeWM 是否编码了“角色”

总结

证据汇总：读出与动作敏感，都不足以证明“误差 = 物理惊讶”

模型 / 数据	读出	几何	动作	外观 / 静态	物理有效性	阈值迁移
V-JEPA2-G / IntPhys2	支持	支持	–	–	–	–
VideoMAE2-G / IntPhys2	不足	支持	–	–	–	–
V-JEPA2-G / 交叉支撑	–	–	–	依赖	矛盾	不足
V-JEPA2-L / Physion++	–	–	–	依赖	–	–
LeWM / TwoRoom	–	–	支持	依赖	不足	–
LeWM / PushT	–	–	支持	依赖	不足	–
DINO-WM / PushT	–	–	支持	依赖	不足	–
JEPA-WM / PushT	–	–	支持	依赖	不足	–

支持 = 检查通过；不足 = 证据不足；依赖 = 误差受外观 / 静态内容影响；矛盾 = 实心平台上不可能事件的平均误差低于可能事件；– = 未测试

启示：把“误差”当作“物理惊讶”之前，先过两道检验

给使用者的建议

1

条件内违例排序

在每个相关条件（支撑、外观、运动）内部，违例是否稳定地得到更高误差；不能只看平均值

2

固定阈值迁移

阈值原样迁移到新场景和新外观后，误报率和漏报率是多少

3

用作奖励或安全信号前

要在目标任务和环境里重新验证，弄清误差到底在响应什么

局限（作者已承认）

- 交叉支撑只有一类程序化场景（单球、受限的相机 / 颜色 / 光照），没有测真实视频
- IntPhys2 读出和几何→误差回归是 post-hoc 分析，区间没有包含重新拟合的不确定性
- Physion++ 官方打分实现有目标帧信息泄漏； Physion++ 没有违例标签
- 模型之间架构、规模、预训练都不同，无法归因到训练目标；论文只做诊断，不提出改进方法