RoboColosseum

在真实世界里大规模评测“物理智能”

RoboColosseum: Evaluating Physical Intelligence at Scale In-The-Wild

NUS · University of Washington · Stanford · UNC · Allen Institute for AI · Oxford · Hugging Face · BitRobot · Singapore Embodied AI Centre

arXiv 2611.02497 · 首次提交 2026-11-02 · 论文解读

TL;DR

一句话总结：评测网络先行，发现“单一排行榜说明不了物理智能”

RoboColosseum 用**全职操作员运营的分布式真机网络**评测 5 个 VLA 与 3 个前沿 agent：**agent 零样本即可与专用 VLA 打平**，但所有系统开放世界成功率都很低；排名在本体之间、赛道之间**都不一致**； G1 人形上**无一策略完成任何任务**。

5,699
开放赛道盲测成对比较

124
真实评测站点（办公室 / 家庭 / 工厂 …）

4
种本体
SO-101 / Franka / YAM / G1

5 + 3
VLA 策略 +
前沿 AI agent

20 × 25
微调任务 ×
每对试验次数

评测时间： 2026-09-17 至 2026-10-28，共 41 天。 **微调赛道：**每任务 100 条现场遥操作示教， 25 次评测。

真机评测的两难：要可比就得控制，要可信就得多样

仿真基准

James et al. 2020； Tao et al. 2025 等

- 可重复重置、可控变化
- 感知、标定、动力学、外观差异
- → 难以预测真机表现

单站点真机

FurnitureBench 、 RoboDojo 等

- 统一硬件与任务协议
- 重置、维护、执行全靠人力
- → rollout 少，估计方差大

分布式成对评测

RB2 、 RoboArena

- RoboArena： 7 所高校、 612 次比较
- 仅 DROID/Franka 单一本体
- → 志愿者驱动，难持续扩展

RoboColosseum 的回答

最多 30 名全职操作员 · 100+ 台机器人（美 / 英 / 新加坡 / 马来西亚 / 中国）

统一硬件配置 + 统一策略服务 + 两条赛道各自明确“固定什么、放开什么”

框架总览：分布式站点 + 统一策略服务 + 两条互补赛道

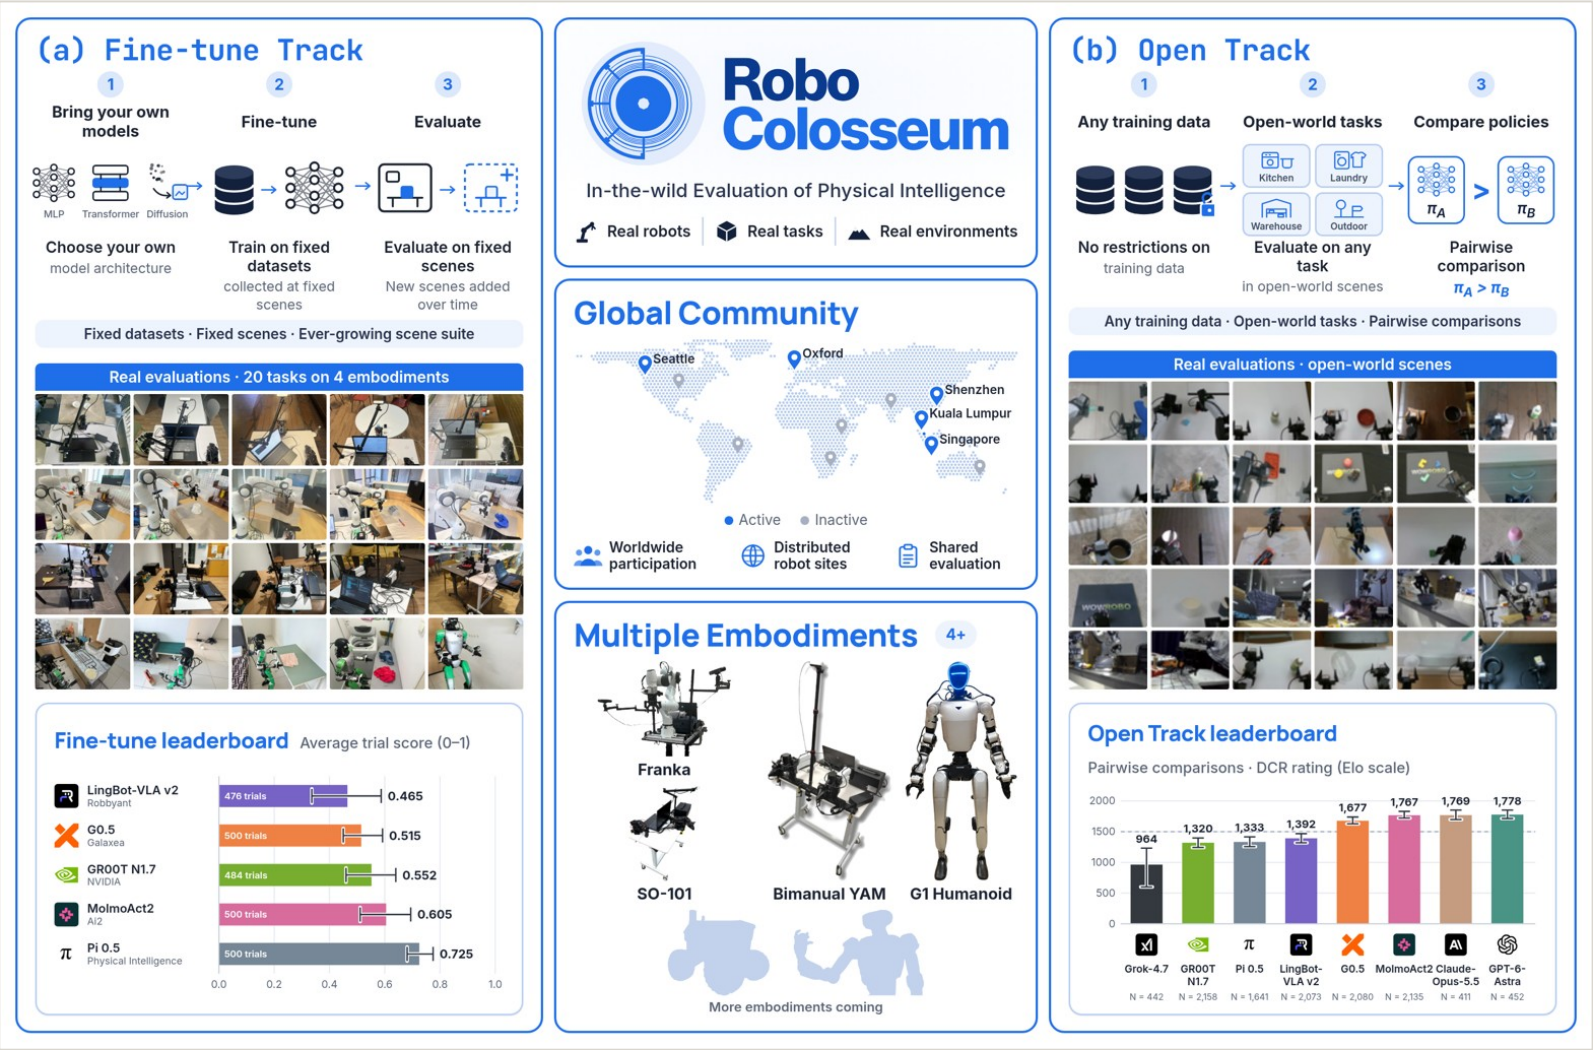

微调赛道

固定 100 条示教 + 固定任务卡；比较“从同一份数据学会新任务”的能力。

开放赛道

无任务适配；任务和场景随意变化，但每次 A/B 比较内条件完全一致。

四种本体覆盖低成本单臂、科研级单臂、双臂与人形

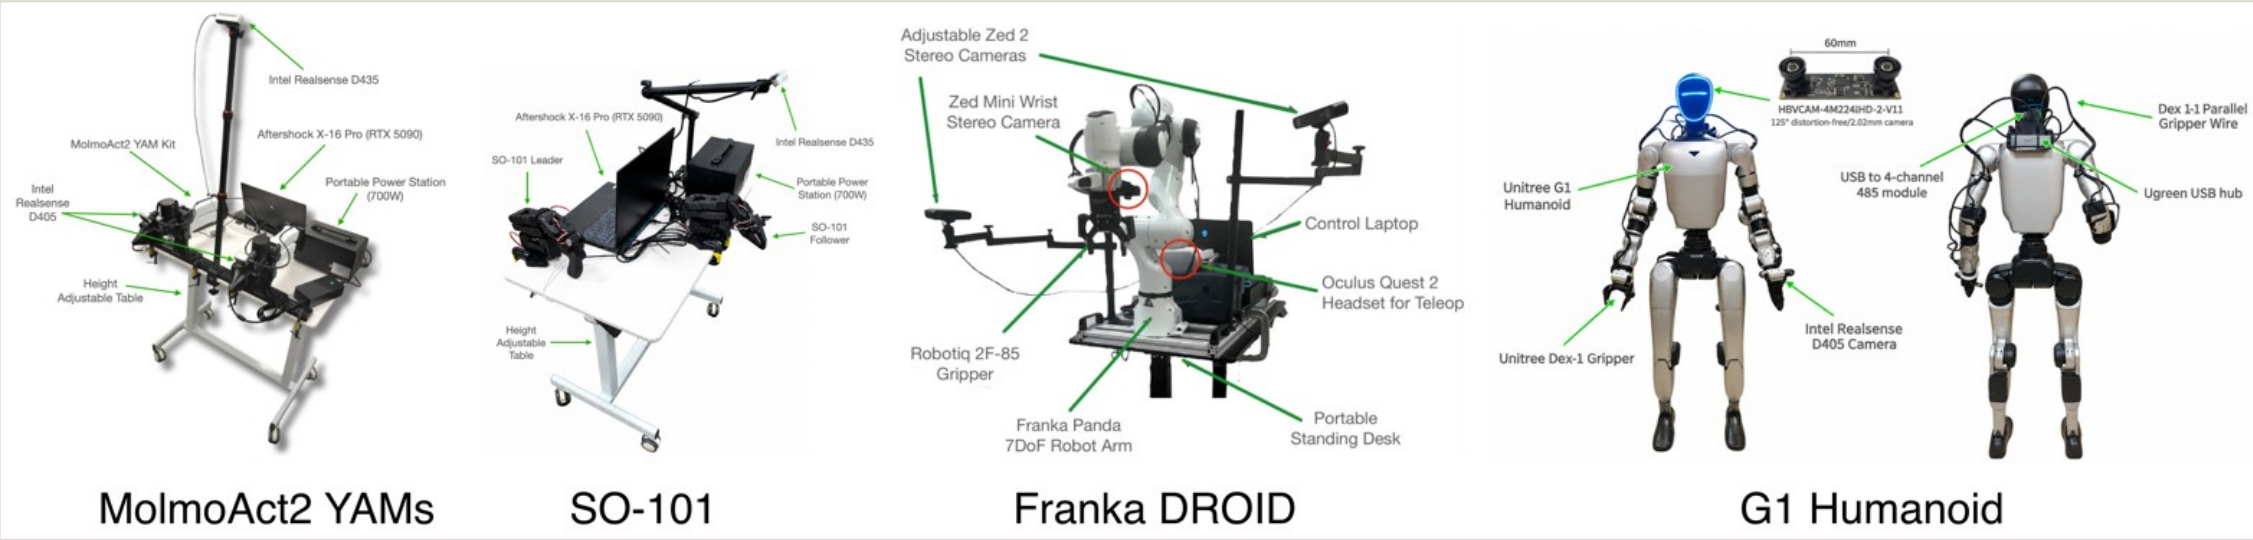

Bimanual-YAM

14 维关节（每臂 6+1）
1 顶部 +2 腕部相机
GELLO 遥操作

SO-101

6 维关节（5+1）
1 外部 +1 腕部相机
主从臂遥操作

Franka (DROID)

8 维关节（7+1）
2 外部 +1 腕部相机
DROID Quest 遥操作

Unitree G1

人形 + 平行夹爪，可行走
仅参与微调赛道
Pico VR + 全身控制器

方法

两条赛道的核心：明确写出“固定什么、放开什么”

	微调赛道 Fine-tune Track	开放赛道 Open Track
测什么	用固定示教适配新任务的能力	无任务适配的零样本泛化
固定	每任务 100 条现场遥操作示教（公开） 统一任务卡、成功与进度标准	同一次 A/B 比较内：机器人、指令、 物体、初始摆放、超时完全一致
放开	各模型官方训练配方（超参、步数不同）	不同比较之间任务与环境任意变化
规模	4 本体 × 5 任务 = 20 任务；每对 25 次	5,699 次比较， 124 个站点， 3 种本体
指标	成功率 SR + 进度分 PS = 平均 (s_n / K)	DCR 评分（Elo 尺度），盲测胜 / 平 / 负
参评	5 个 VLA （从 base checkpoint 微调）	5 个 VLA + 3 个前沿 agent

开放赛道排名：同时估计“模型能力”与“任务难度”

1. **盲分配**
   系统指派两个匿名模型 A、B
2. **同条件执行**
   同一机器人、同一任务配置先后运行
3. **记录**
   胜 / 平 / 负、各自进度、文字反馈、难度 1–10
4. **联合推断**
   能力 θ、难度 β、难度先验参数一起估计

成功概率（Rasch / 1PL）

$$P(y=1) = \sigma(\theta_p - \beta_t)$$

θ_p：策略能力；β_t：任务难度

人评难度作为先验

$$\beta_t \mid d_t = k \sim N(\mu_k, \tau^2),\ \mu_1 < \ldots < \mu_{10}$$

物理结果可把单个任务拉离其类别均值

排行榜（Elo 尺度，线性变换）

$$R_p = 1500 + (400 / \ln 10) \cdot E[\theta_p \mid D]$$

不改变排序；不是逐场更新的 Elo

主动配对（沿用 Chatbot Arena）

$$P_t(a) \propto \sqrt{(\Sigma_{aa} / n_a)} - \sqrt{(\Sigma_{aa} / (n_a+1))}$$

优先比较不确定、样本稀少的模型对

全局排行：前沿 agent 与最强 VLA 并列榜首，Grok 垫底

全局 DCR 评分（Elo 尺度）：柱子以平均线 1500 为基准向左右延伸

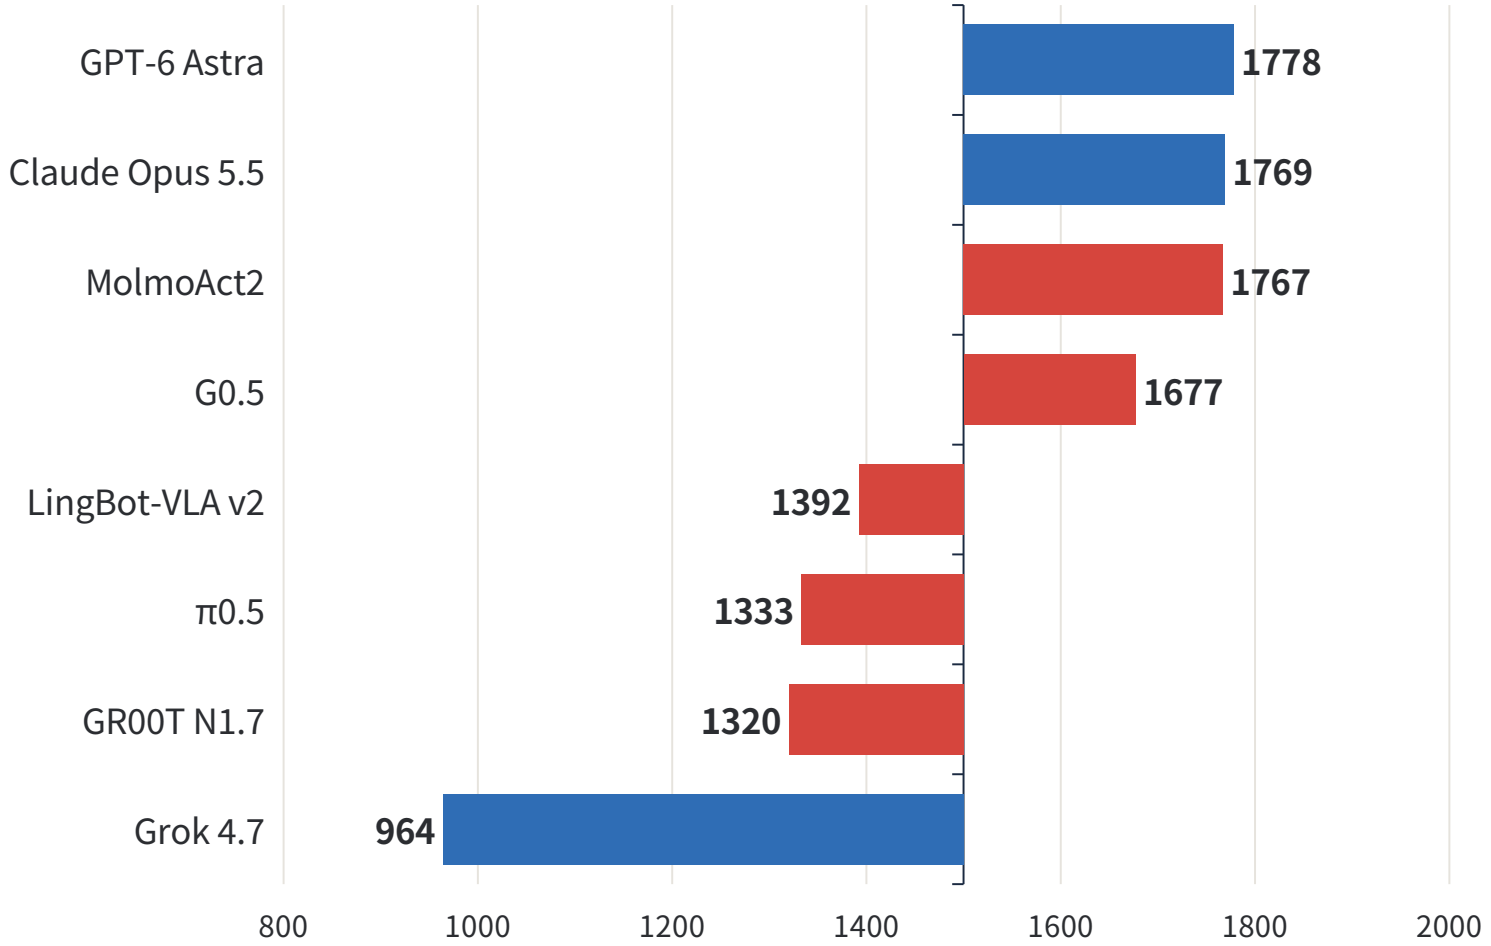

1778 ≈ 1769 ≈ 1767

GPT-6 Astra / Claude / MolmoAct2 并列第一梯队

964

Grok 4.7 远低于平均：agent 之间差异很大

零微调

agent 通过关节位置工具调用控制机器人，无示教

来源：论文 Figure 1 Open Track leaderboard（DCR，Elo 尺度）

但谁领先取决于本体：每种机器人上的冠军都不同

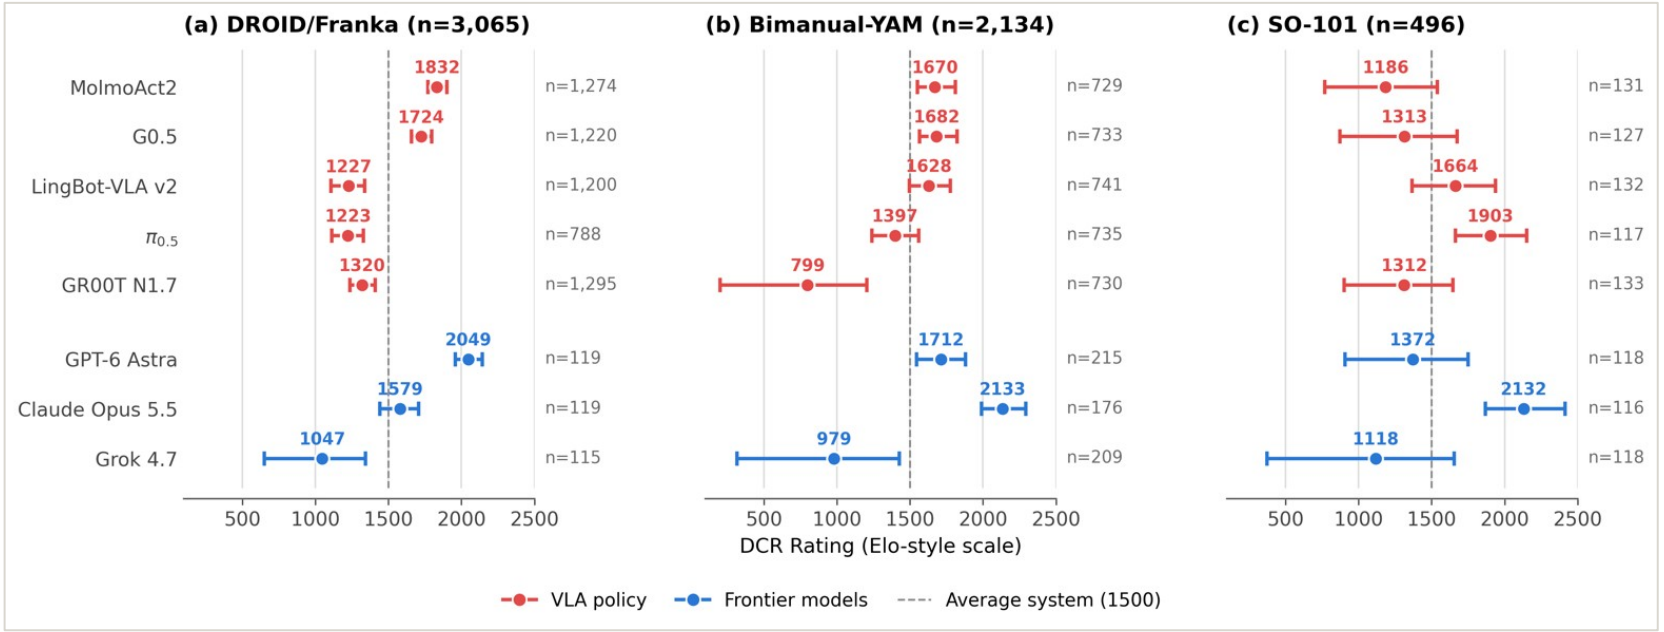

DROID / Franka（n=3,065）

agent： GPT-6 Astra 2049
VLA： MolmoAct2 1832 · G0.5 1724

Bimanual-YAM（n=2,134）

agent： Claude Opus 5.5 2133
VLA： G0.5 1682 · GR00T 仅 799

SO-101（n=496）

agent： Claude Opus 5.5 2132
VLA： π0.5 1903；样本少、区间宽

来源：论文 Figure 3 （95% 可信区间； n 为参与评测次数）

同任务对比： agent 平均多推进 5.3 个百分点，但三家差异巨大

(a) 胜 / 平 / 负次数（按进度比较）

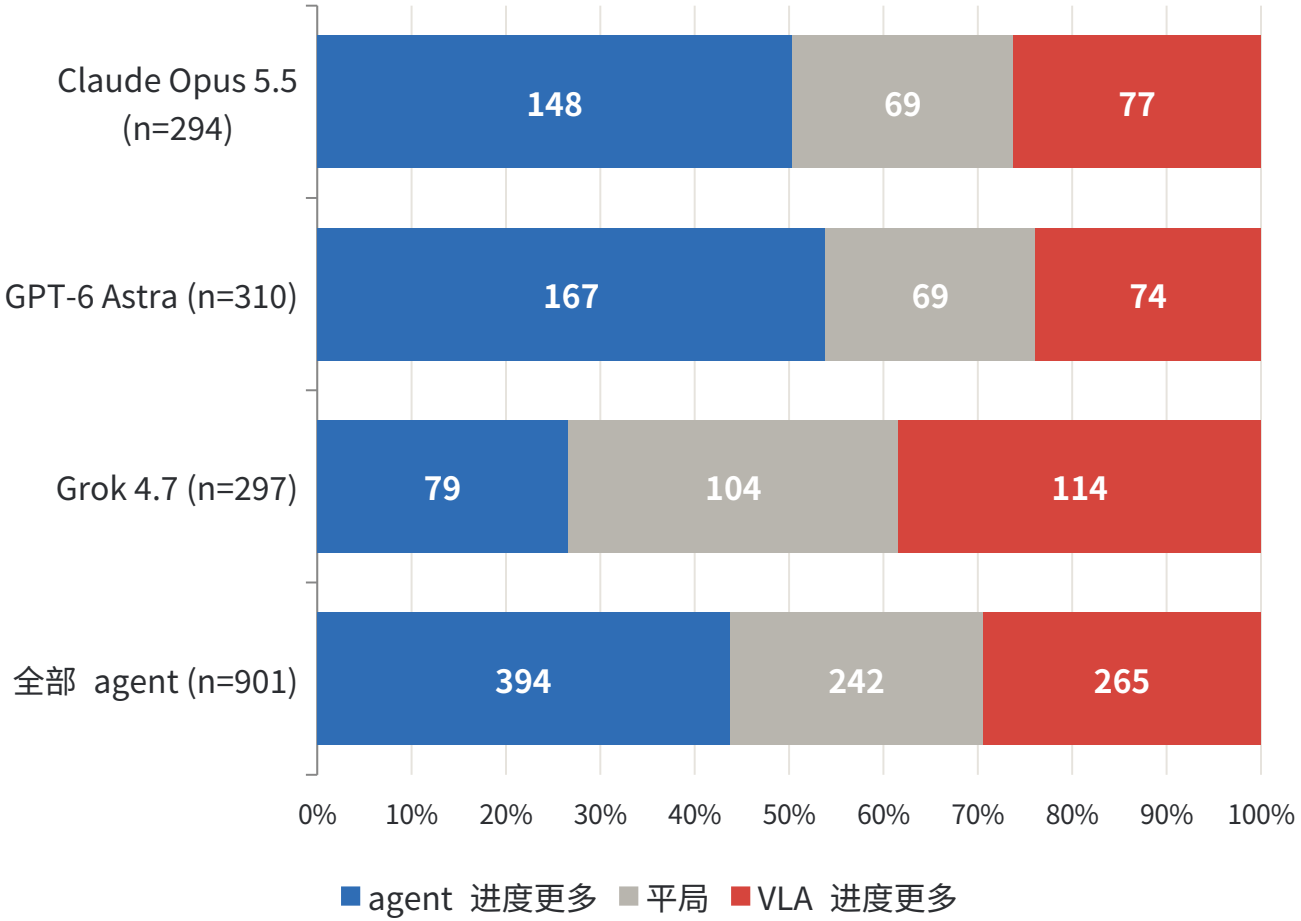

(b) 平均进度差 agent − VLA （百分点）

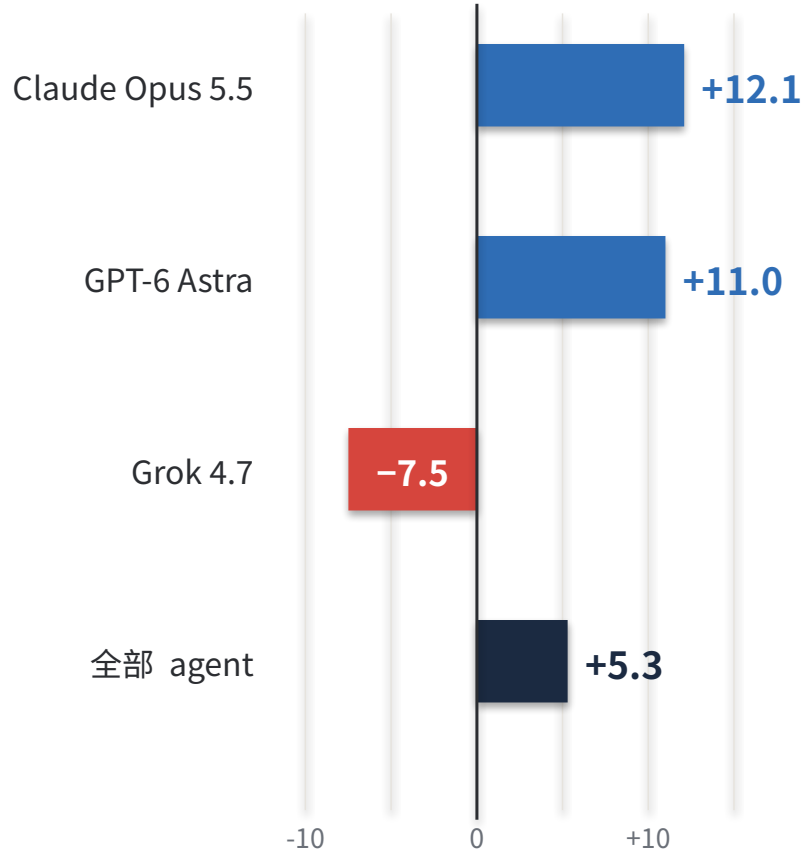

正值 = agent 进度更多；全部 agent 的 95% 区间不跨 0

来源：论文 Figure 4 （901 次 agent–VLA 配对，归一化任务进度）

相对领先 ≠ 真正完成：开放世界任务的成功率普遍极低

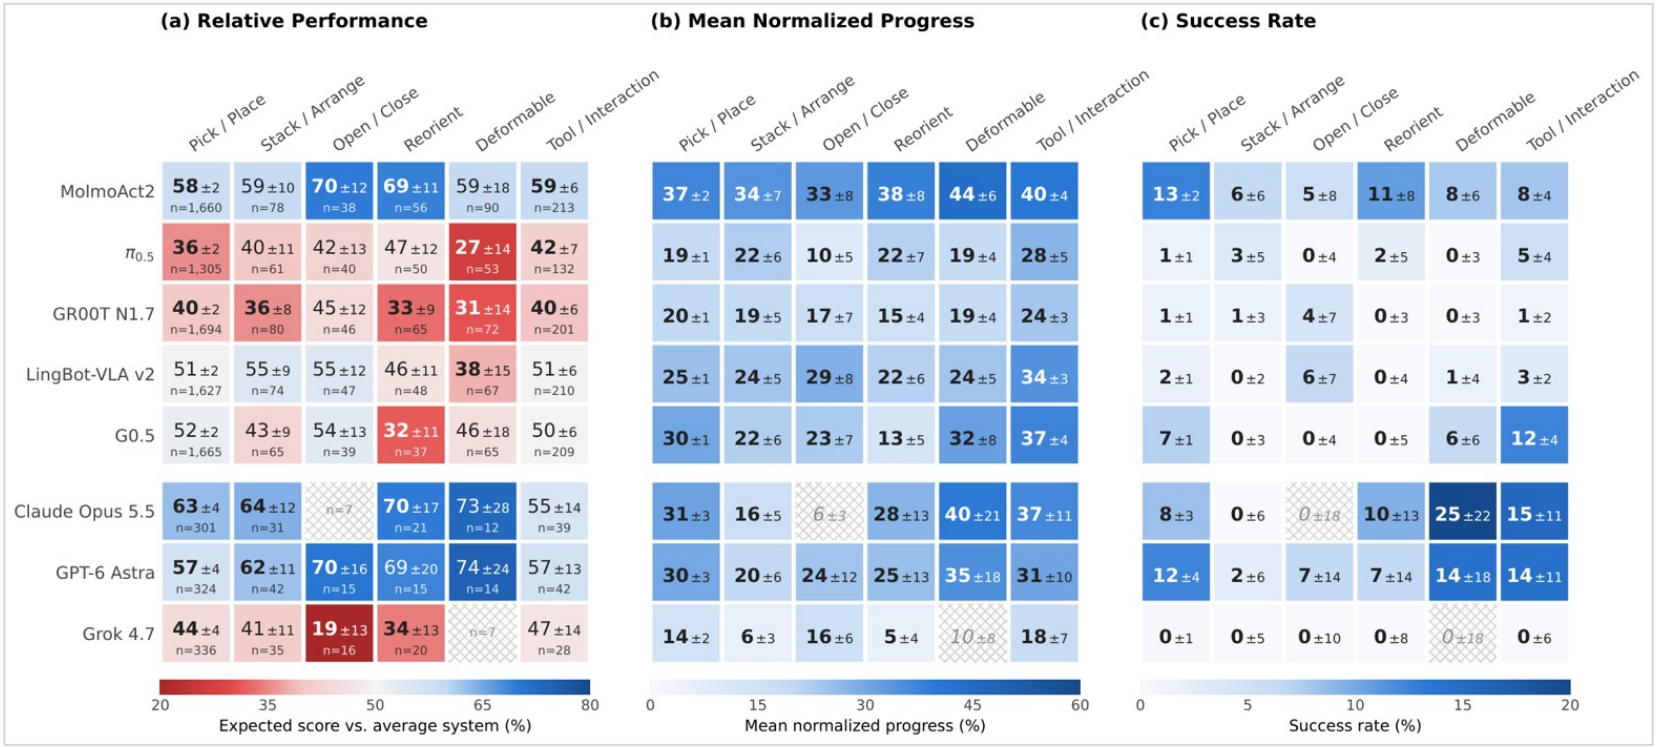

58% – 77%

MolmoAct2 相对得分： VLA 中六类全部第一

6% – 13%

MolmoAct2 的实际任务成功率

⩽ 13%

论文：无系统在任一类别超过（Claude 可变形类 25%±22， n=12 例外）

来源：论文 Figure 5 （六类操作； (a) 进度型 BTD 期望得分 (b) 平均进度 (c) 成功率）

任务越难，不只是失败，连“前几步”都做不到

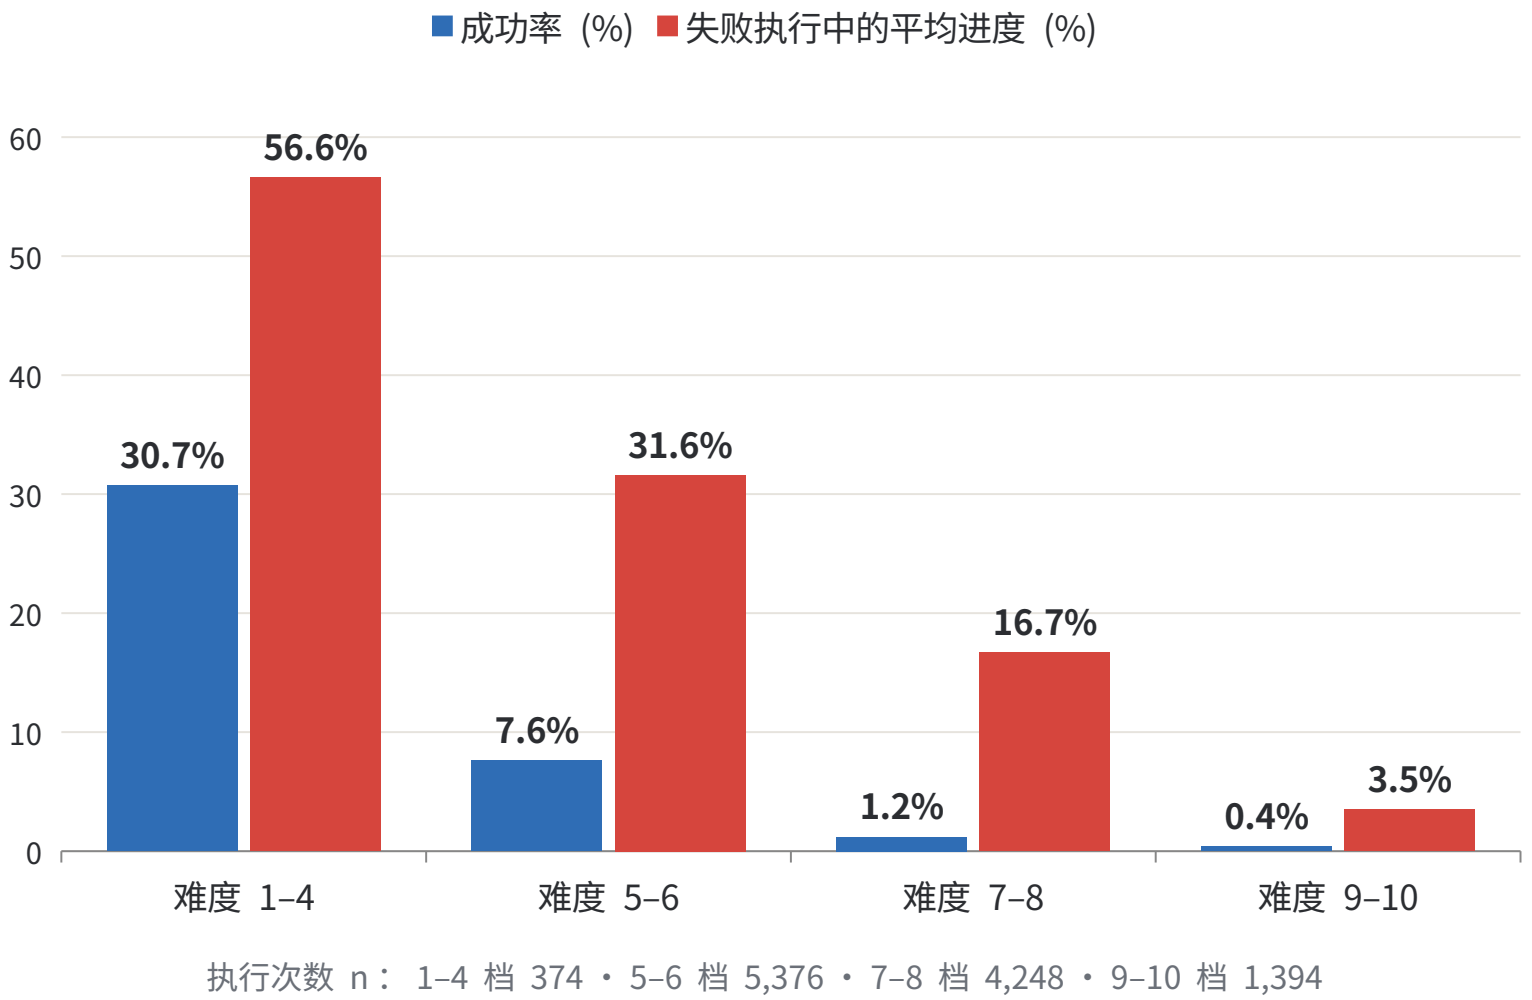

执行次数 n： 1–4 档 374 · 5–6 档 5,376 · 7–8 档 4,248 · 9–10 档 1,394

30.7% → 0.4%

成功率随难度骤降

56.6% → 3.5%

失败时的平均进度也趋近于零

97%

执行集中在难度 5–10 档（11,018 / 11,392）

来源：论文 Figure 6 （按人评难度分组；每次 A/B 评测贡献两次执行）

微调后：π0.5 最稳，GR00T 领先 SO-101，G1 人形全军覆没

各本体平均进度分 PS（%，5 个任务等权平均）

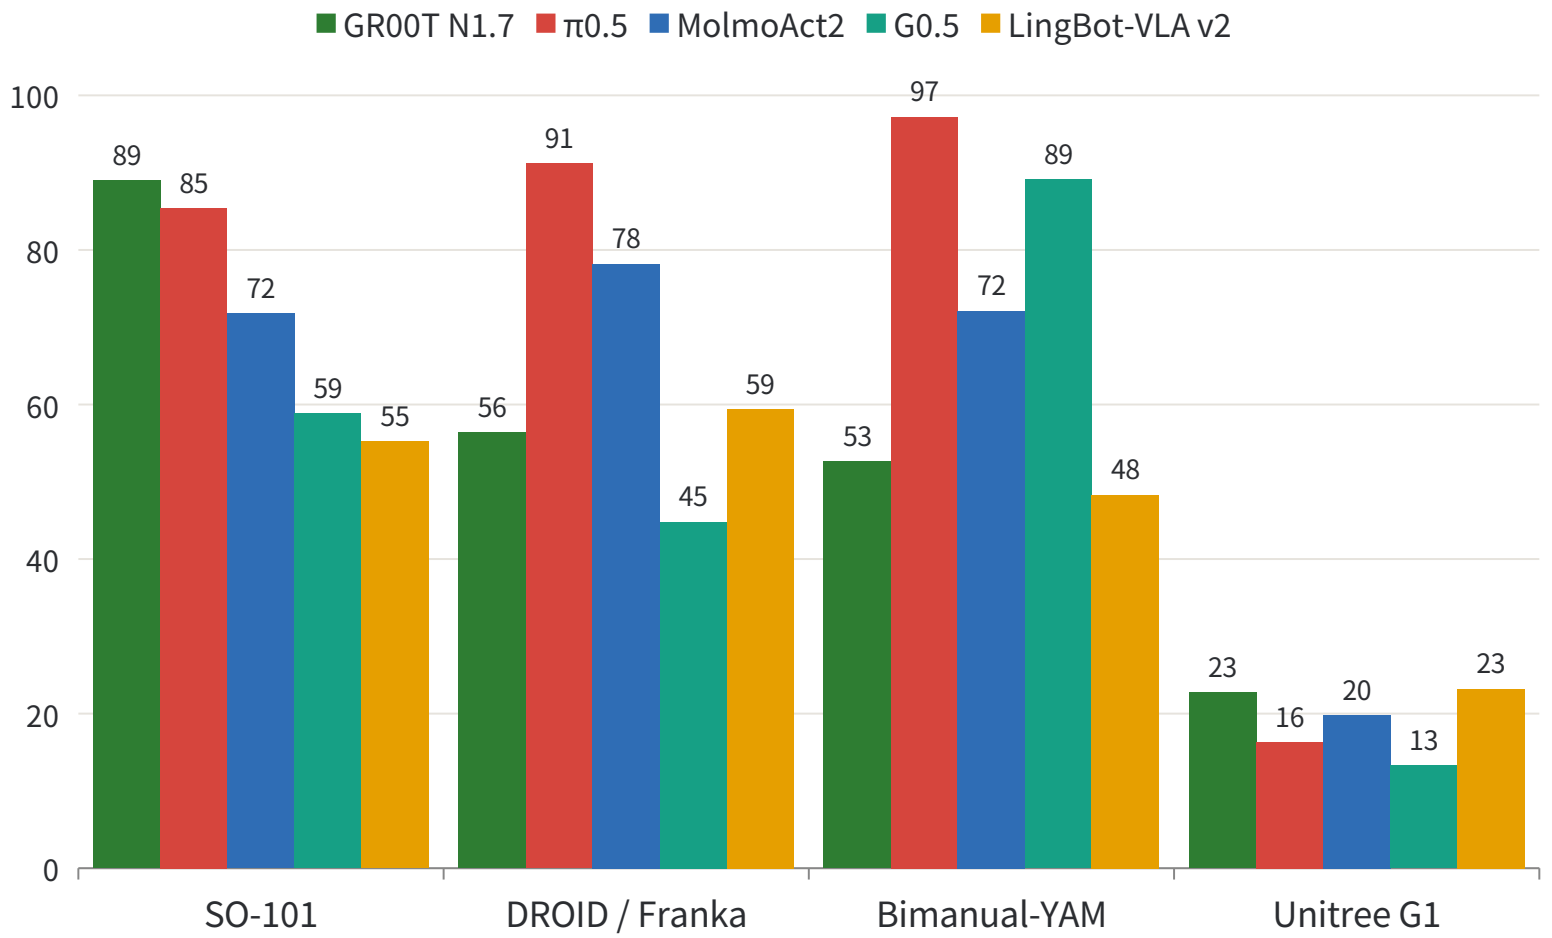

各本体冠军（按成功率）

SO-101

GR00T N1.7 SR 82.4%

DROID / Franka

π0.5 SR 84.0%

Bimanual-YAM

π0.5 SR 93.6%

Unitree G1

无人完成 全部 SR 0%（PS 13.3–23.2）

来源：论文 Table 2（每模型–任务 25 次；本体内 5 任务等权平均）

进度分揭示成功率看不到的差异：失败也分“差一点”和“没开始”

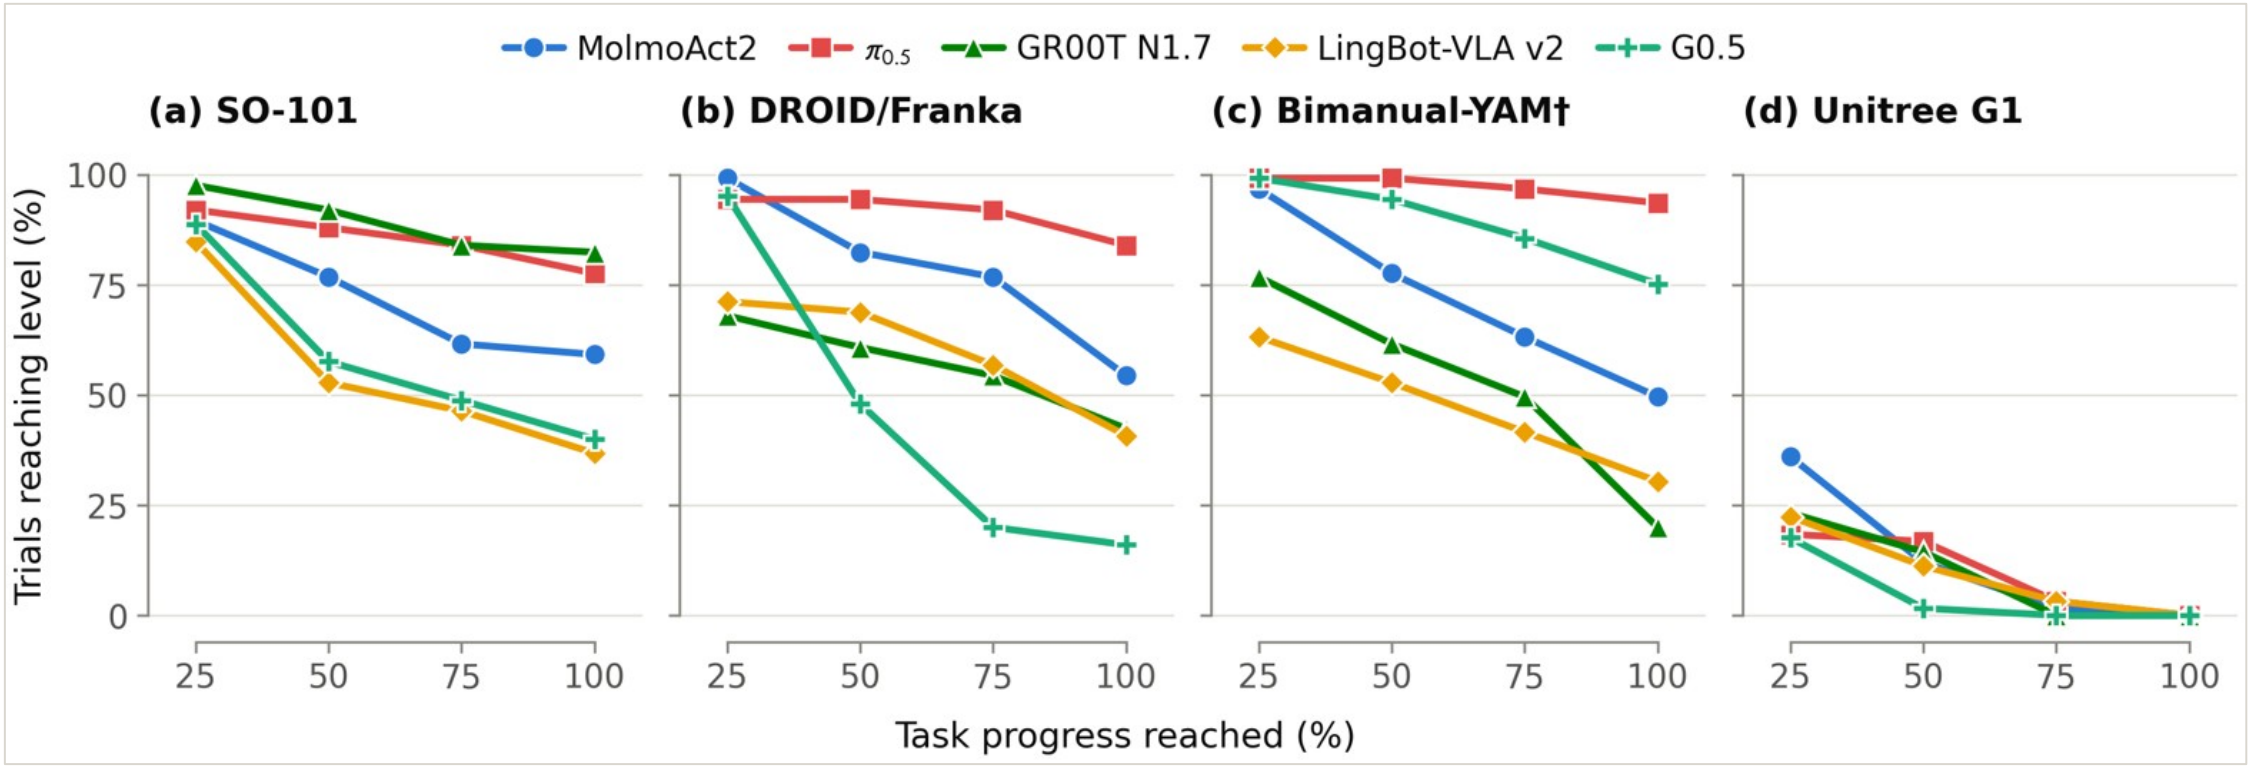

~100% → 16%

DROID 上 G0.5：几乎都能起步，却很少完成

93.6%

YAM 上 π0.5 全程保持高覆盖并完成

< 40%

G1：连 1/4 标准都达不到的试验占多数

来源：论文 Figure 7（达到某进度阈值的试验比例；100% 点即成功率）

同一份示教，不同的瓶颈：各模型卡在任务的不同阶段

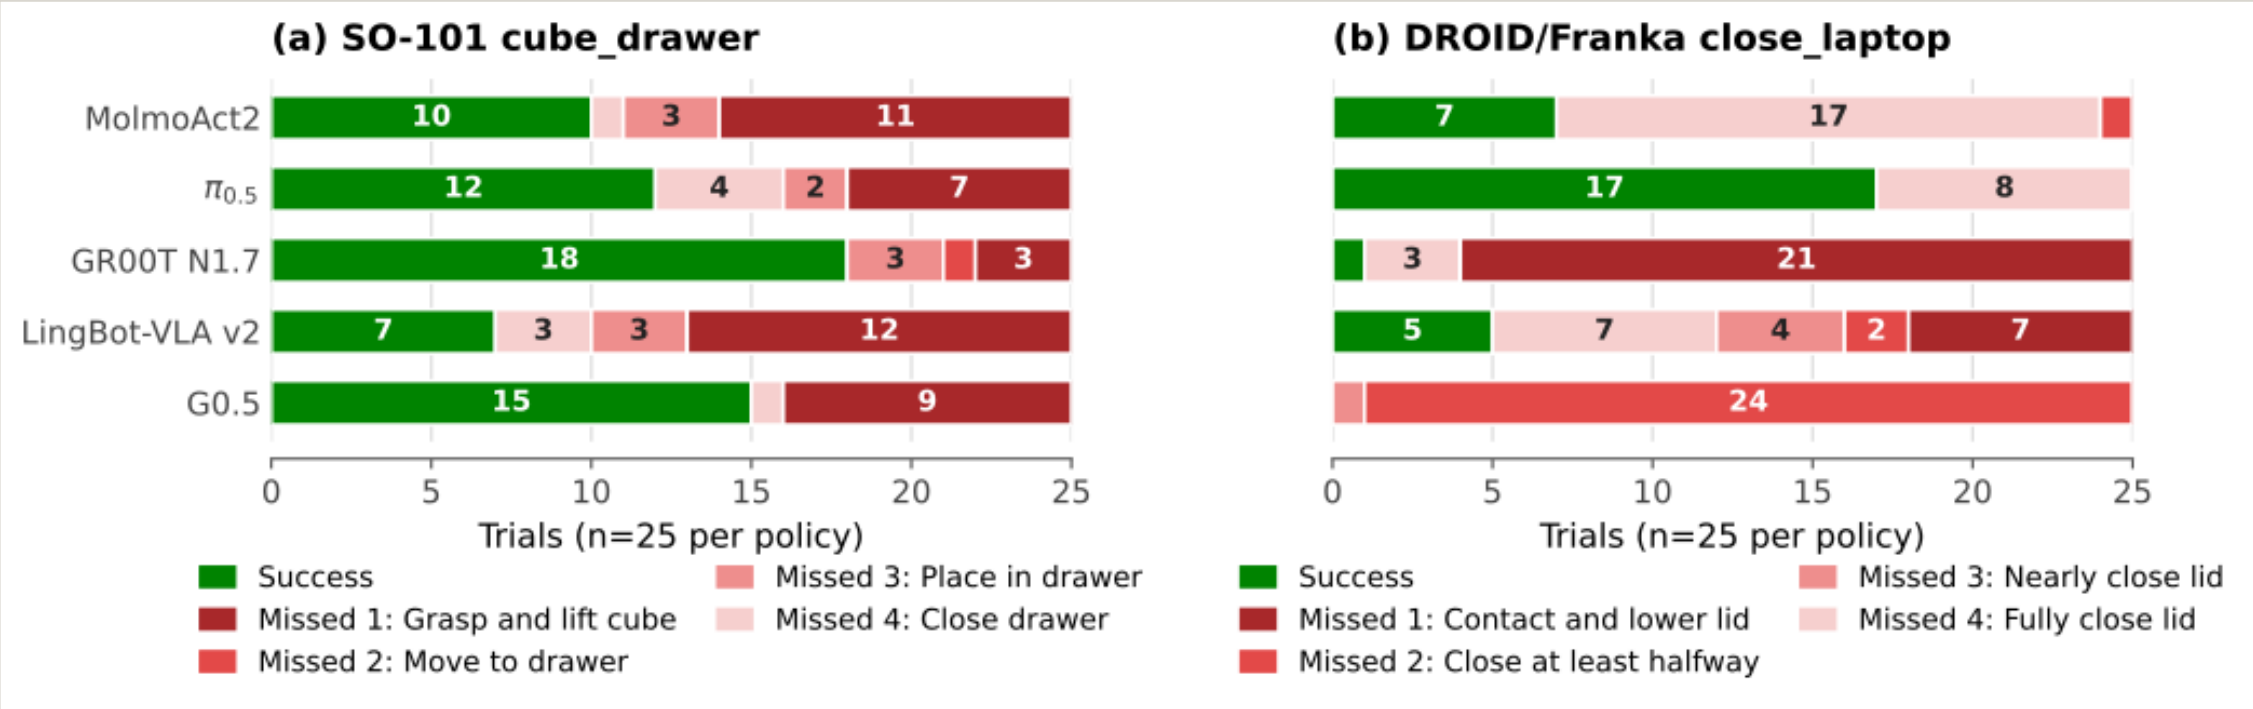

SO-101 cube_drawer： 共同难点在第一步

“抓取并抬起方块”未满足的比例 12%–48% （GR00T 3 次 → LingBot 12 次）

DROID close_laptop： 瓶颈各不相同

G0.5 24/25 没合到一半 · MolmoAct2 接近合上却仅成 7 次 · π0.5 成功 17 次 · GR00T 21 次卡在第一步

来源：论文 Figure 8 （25 次试验按“首个未满足标准”分组）

开放赛道排名几乎预测不了微调后的排名

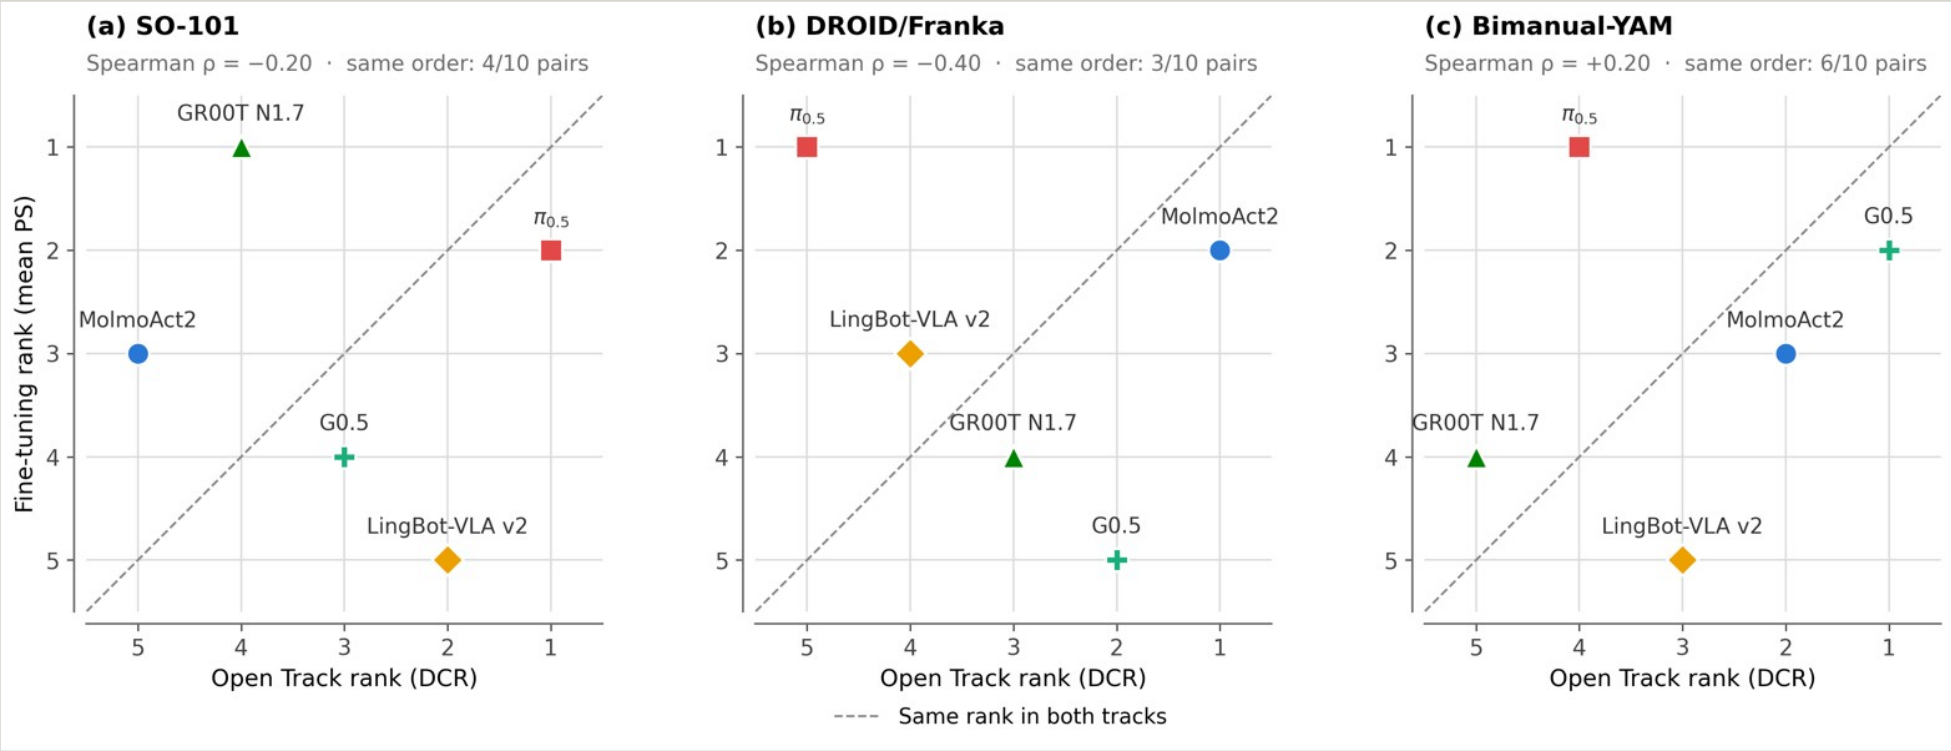

SO-101

ρ = −0.20

4 / 10 对顺序一致

DROID / Franka

ρ = −0.40

3 / 10 对； π0.5 第 5 → 第 1

Bimanual-YAM

ρ = +0.20

6 / 10 对； π0.5 第 4 → 第 1

来源：论文 Figure 9 （Open： DCR 排名； Fine-tune： 平均 PS 排名）

跨本体排名同样不稳： Kendall's W 仅 0.24

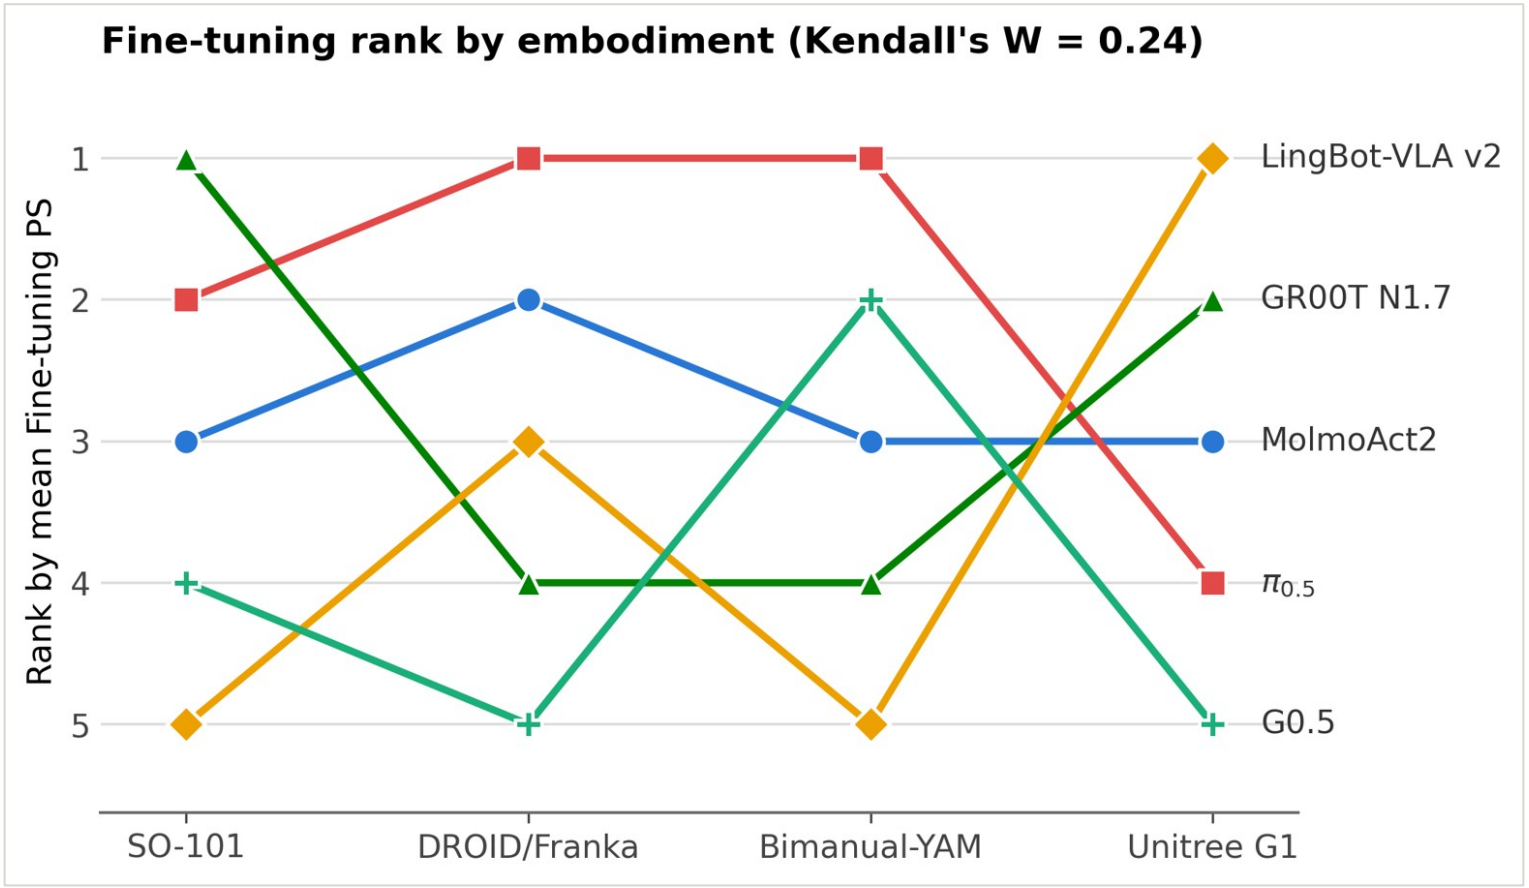

W = 0.24

四个本体排名的一致性系数
（1 = 完全一致）

- **π0.5：** DROID、YAM 第 1 → G1 第 4
- **GR00T N1.7：** SO-101 第 1 → DROID、YAM 第 4
- **LingBot-VLA v2：** SO-101、YAM 第 5 → G1 第 1
- **注意：**各本体任务与场所不同，差异不能只归因于形态

来源：论文 Figure 10a （微调赛道平均 PS 排名）

评测本身可靠吗？数据充足时可复现，主动配对省一半试验

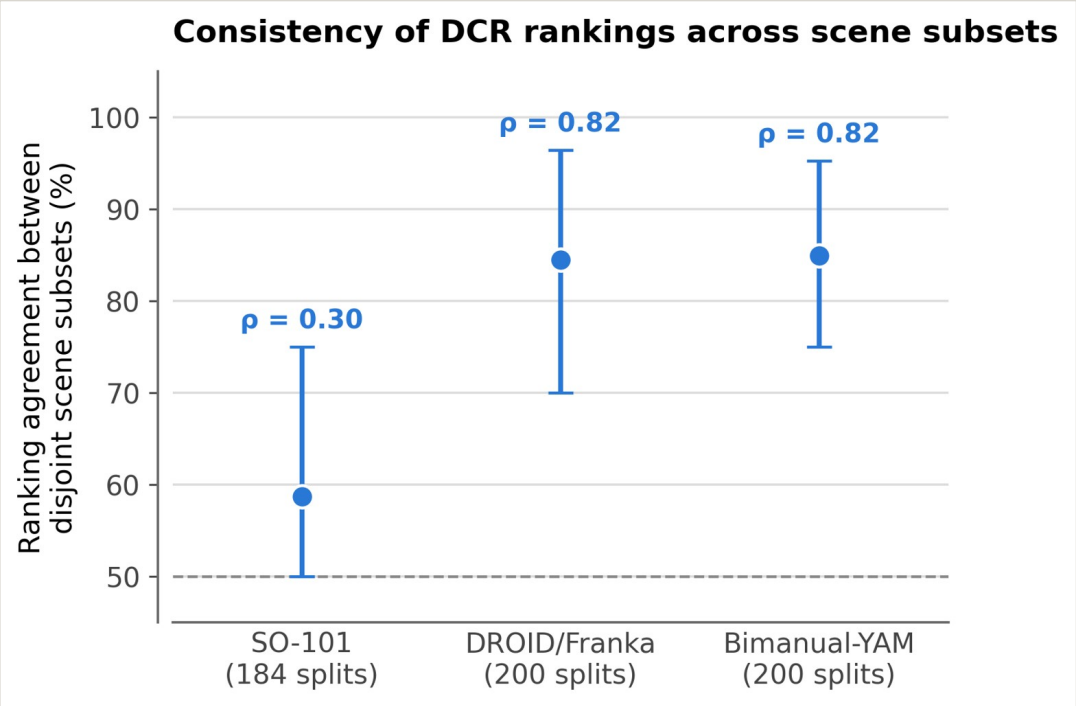

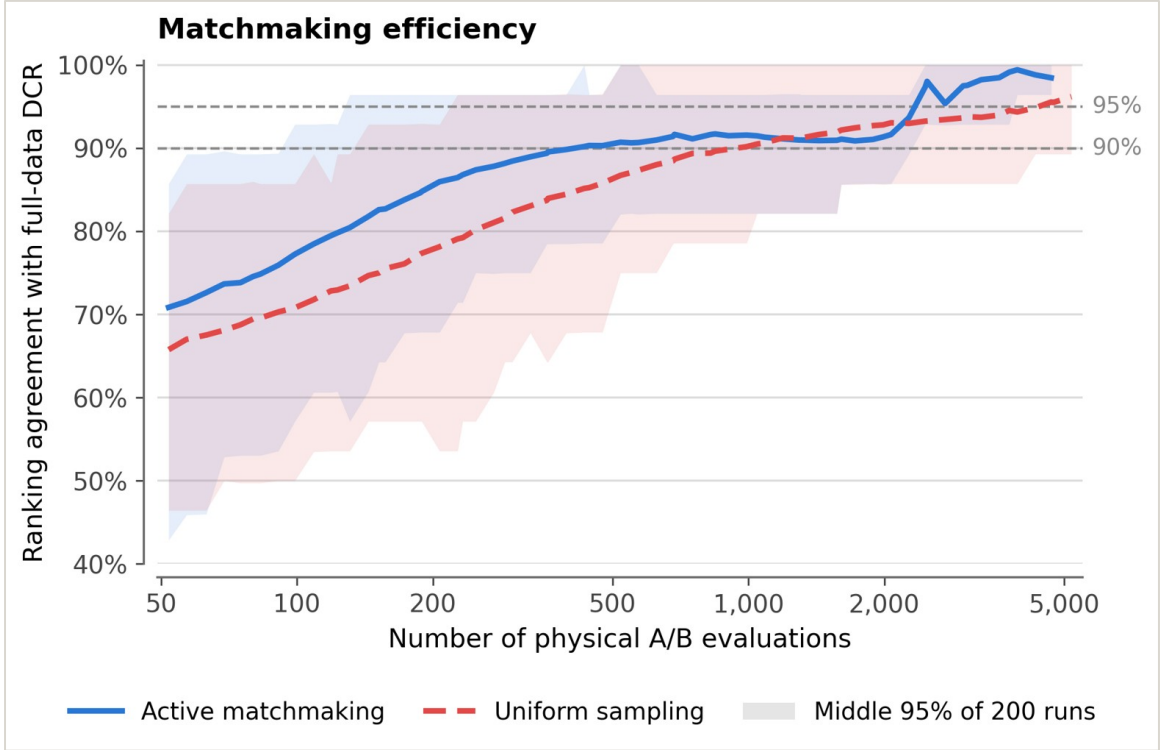

≈85%
DROID / YAM 站点二分一致（ρ = 0.82）

59%
SO-101 仅 ρ = 0.30，对站点敏感

400–500
主动配对达到 ~90% 一致所需评测数

~1,000
均匀采样达到同等一致所需评测数

来源：论文 Figure 10b 、 Figure 11a （200 次独立运行）

平均排序出现得早，但要“稳”需要多得多的数据

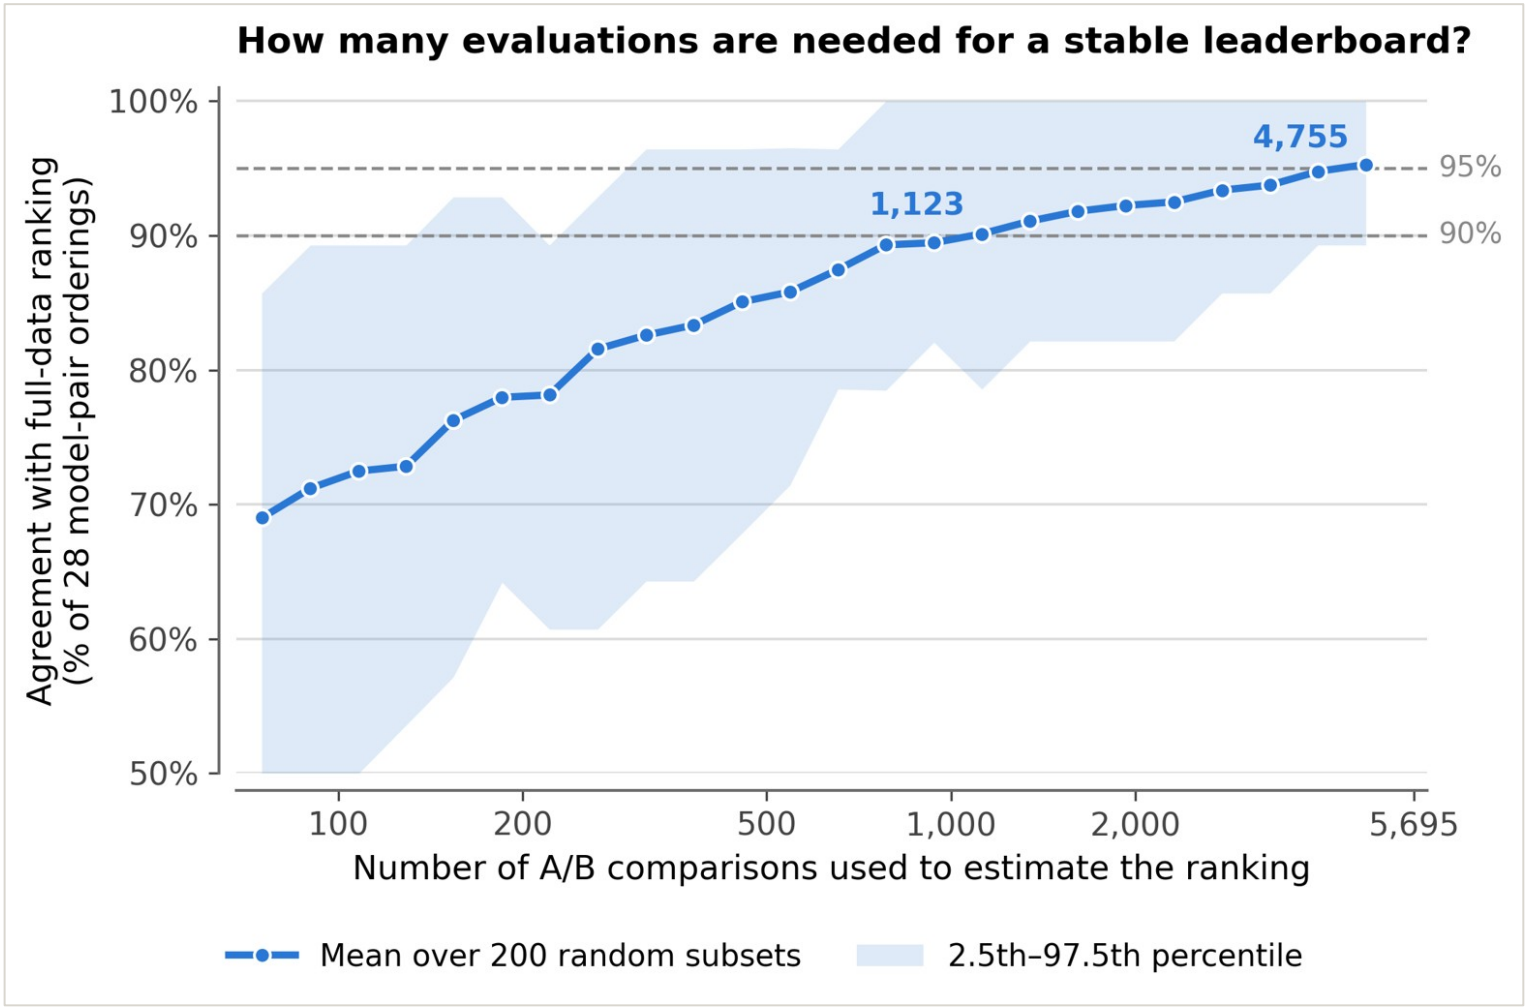

1,123 次

平均排名一致率达到 90%

4,755 次

平均排名一致率达到 95%

分位带很宽

同样规模的不同子集仍可能给出明显不同的排名

来源：论文 Figure 11b （每个预算 200 个随机子集， 28 个模型对）

贡献与局限：基础设施价值大，具体排名宜当快照阅读

贡献

- **可持续的评测设施：**全职操作员、跨国多本体、统一服务；承诺 1 万小时免费学术评测
- **两条赛道分工清晰：**零样本泛化 vs 固定数据适配，控制变量明确
- **DCR 排名：**人评难度作先验、保留绝对成败，适合“每题一测”
- **有信息量的发现：** agent 可竞争、排名不迁移、人形需进度分
- **开放资源：** 20 任务 × 100 条示教、任务卡、代码与模型

局限与值得商榷之处

- **微调赛道单站点：**每任务一个场所、一个时段，并非真正 in the wild
- **训练配方混杂：** GR00T 仅在 SO-101 冻结主干，恰好也只在此夺冠
- **样本不均：** SO-101 仅 496 次； agent 在 DROID 每个约 119 次
- **跨赛道对比不干净：** checkpoint 、任务、指标都不同，仅 5 个模型
- **可靠性以自身为参照：**全量数据部分由主动配对收集，存在一定循环

四点结论

01 agent 已能竞争，但没人能可靠完成

前沿 agent 零样本与最强 VLA 并列；开放世界成功率各类均 ⩽ 13%，最难档仅 0.4%

02 单一排行榜说明不了物理智能

跨赛道 $\rho \in [-0.40, +0.20]$，跨本体 $W = 0.24$，排名频繁翻转

03 进度分不可或缺

G1 上 5 个策略成功率全为 0，进度 13.3%–23.2%；失败位置因模型而异

04 大规模真机评测可行且可省

主动配对 400–500 次达 ~90% 一致（均匀 ~1,000）； 95% 稳定需 ~4,755 次