论文解读 · 具身智能安全 · arXiv 2611.04166

Say the Same, Act Differently

Diagnosing and Steering Text–Action Divergence in Reasoning VLAs

说得一样，做得不同：推理型 VLA 中文本与动作的分歧——诊断与引导

Zihao Feng, Qingzhao Zhang, Chunyu Xia, Bo Yu, Z. Morley Mao, Ramesh Govindan
University of Southern California · University of Arizona · General Motors
首次提交： 2026-11-03

52.6%

Alpamayo 驾驶场景中，理由一字不差、却新增碰撞（全图 TNAS 攻击）

问题

同一句 rationale，可以对应完全相反的动作

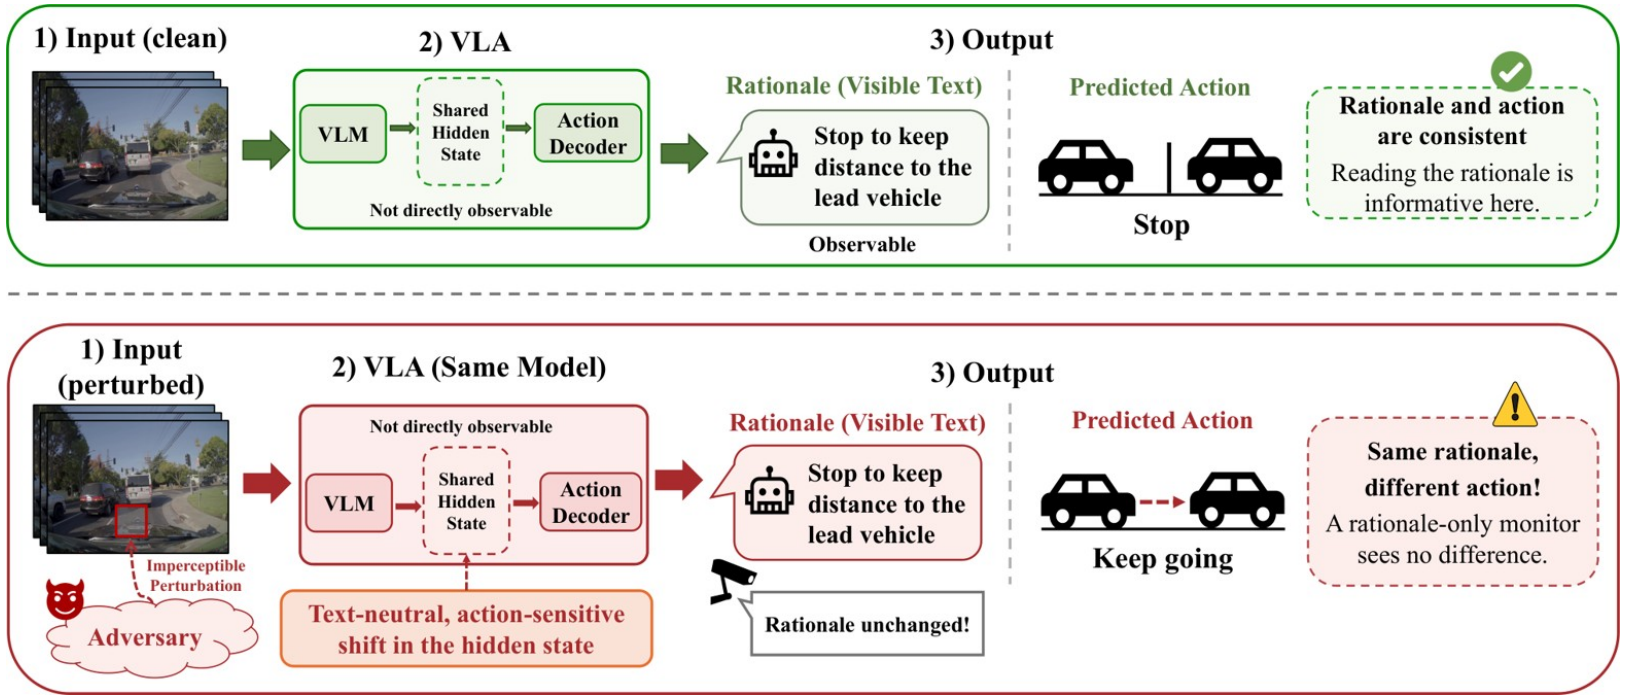

干净输入

说 “ Stop to keep distance to the lead vehicle” ，并且确实停车

加不可察觉扰动

rationale 一字不差，动作却变成 Keep going ，撞向前车

后果

只看 rationale 的监控器，在两种情况下看到的证据完全相同

已有攻击会在文本里留下痕迹，本文攻击的是“文本不变”这个盲区

已有攻击：先改文本 → 再带偏动作

- TRAP：对抗补丁劫持 CoT
- Trinh 等：直接篡改推理链

→ 篡改在 rationale 中留下可见证据，监控有机会发现

本文：动作改变，文本一字不变

- 扰动只加在视觉输入上，端到端反传
- 驾驶（Alpamayo-1.5）+ 操作（InstructVLA）两种具身形态

→ rationale-only 监控在干净 / 攻击两种情况下证据完全相同

机制直觉：文本是共享隐状态的“低带宽、多对一”读出

VLM 共享隐状态
连续、高维、不可直接观测

→

文本 = 离散读出
许多隐状态 → 同一句话

→

动作头读取同一状态
存在“动作敏感、文本不敏感”自由度

诊断 • Probe 1： rationale 本身有多少信息?

rationale 有信息量，但粒度太粗：同一句话覆盖 10–208 m 的行为

84.3%

仅读 rationale 预测“是否停车”的准确率
AUROC 0.882 （只按初速度：0.820 ）

258

1,181 个片段只用了 258 种不同的 rationale

36.9%

片段的 rationale 也出现在相反的停车结果上

245

片段共享最常见的一句话，前向位移 10.1–208 m

设置

- 读者模型： Qwen3-14B （关闭 thinking 、贪心解码），只看到 rationale 字符串，看不到图像、轨迹、车速或地图
- 标签： Alpamayo 计划在 6.4 s 时域内是否停车； 1,181 个干净片段，每个片段一次贪心生成
- 最常见的一句： “ Keep distance to the lead vehicle since it is directly ahead in our lane”

方法一 · TNAS 诊断

TNAS：把文本梯度子空间从“最能推动动作的方向”中投影掉

挂钩位置（共享隐状态）

Alpamayo

推理 token，第 32–35 层

InstructVLA

响应 token，第 14–17 层

干预：在活跃 token 区间 R 上，每层广播加同一个向量 δ

选块依据：文本梯度非零且动作响应强；相邻层块结论一致、幅度较小（A.4.1）

① **动作方向 d_act**

动作输出 Jacobian J_A 的主右奇异向量

动作位移范数在 δ=0 不可导，不直接求梯度；Alpamayo 显式 SVD，InstructVLA 用随机向量 VJP 估计

② **文本损失子空间 $\mathcal{T}$（秩 2）**

Gram–Schmidt(∇NLL, ∇margin)

KL / hinge 在 δ=0 梯度为零，改用干净点仍“活跃”的目标 token NLL 与 signed margin

③ **TNAS 方向**

$d_{TNAS} = \mathrm{normalize}((I - P_{\mathcal{T}})\, d_{act})$

一阶上不改变干净 rationale 的 NLL 与 margin，但仍推动动作

诊断 · 干净状态几何

动作最敏感方向与文本梯度子空间几乎正交

1.87%

Alpamayo： ρ = ‖ P_𝒯 d_act ‖ / ‖ d_act ‖ 均值（200 片段，中位数 1.79% ）

5.28%

InstructVLA： ρ 均值（200 例，中位数 4.90% ）

>99.8%

投影掉文本子空间后，动作方向保留的范数（两个模型平均）

解读提示：“几乎正交”本身信息量有限

- 高维空间中随机单位向量的 ρ 均值为 **0.978%** （95 分位 1.91% ）， d_act 约为其 2 倍
- 但 Alpamayo 中 **43.5%** 的片段超过随机 95 分位、 **25.5%** 超过 99 分位（随机预期为 5% / 1% ）
- TNAS 与 d_act 几乎重合：现象主要源于动作 Jacobian 主方向本就不在文本子空间里 → 更有力的证据见等范数干预

同样的扰动范数： TNAS 只动动作，文本梯度方向只动文本

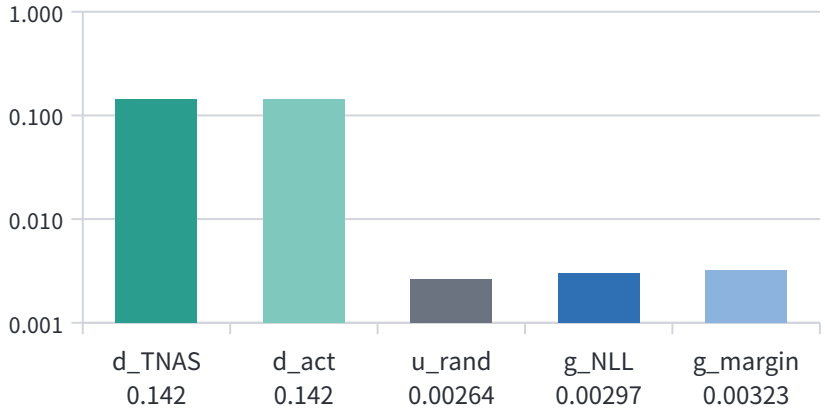

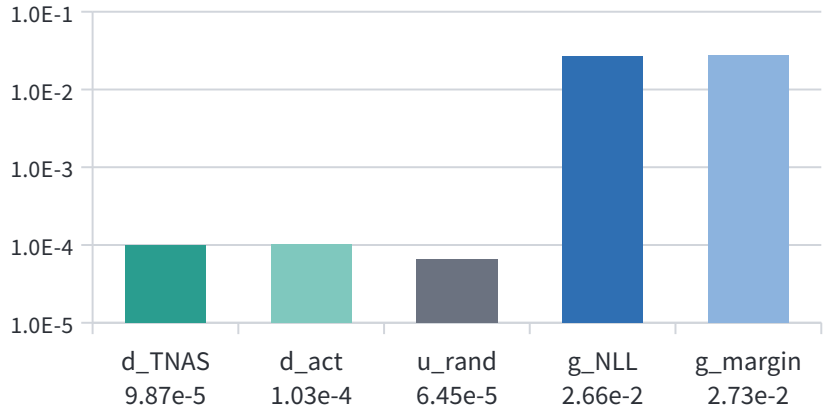

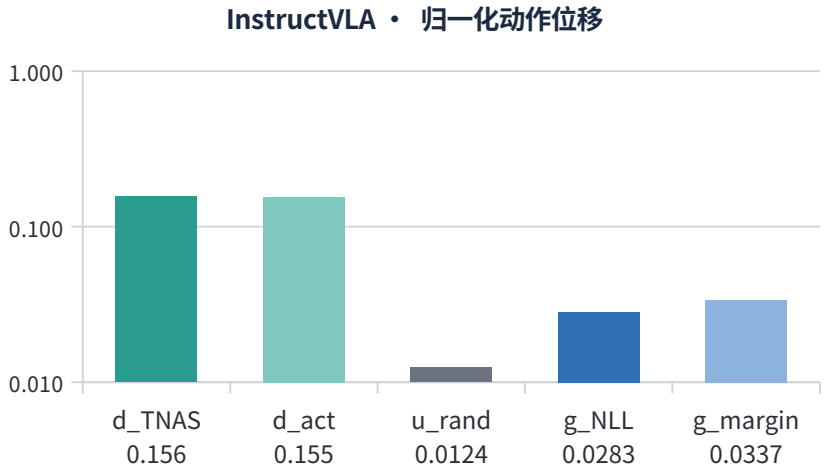

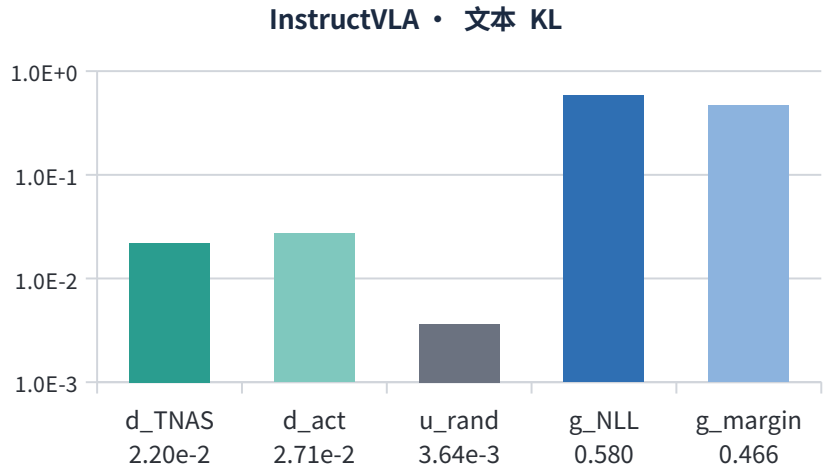

动作位移： TNAS 是文本梯度方向的

44–48×

Alpamayo （随机方向 54× ）

4.6–5.5×

InstructVLA （随机方向 12.6× ）

文本 KL： 文本梯度方向是 TNAS 的

269–277×

Alpamayo

21–26×

InstructVLA

诊断 • Probe 2： 固定文本 KL 预算

花同样的“文本漂移预算”， TNAS 推动的动作是对照方向的 63–212 倍

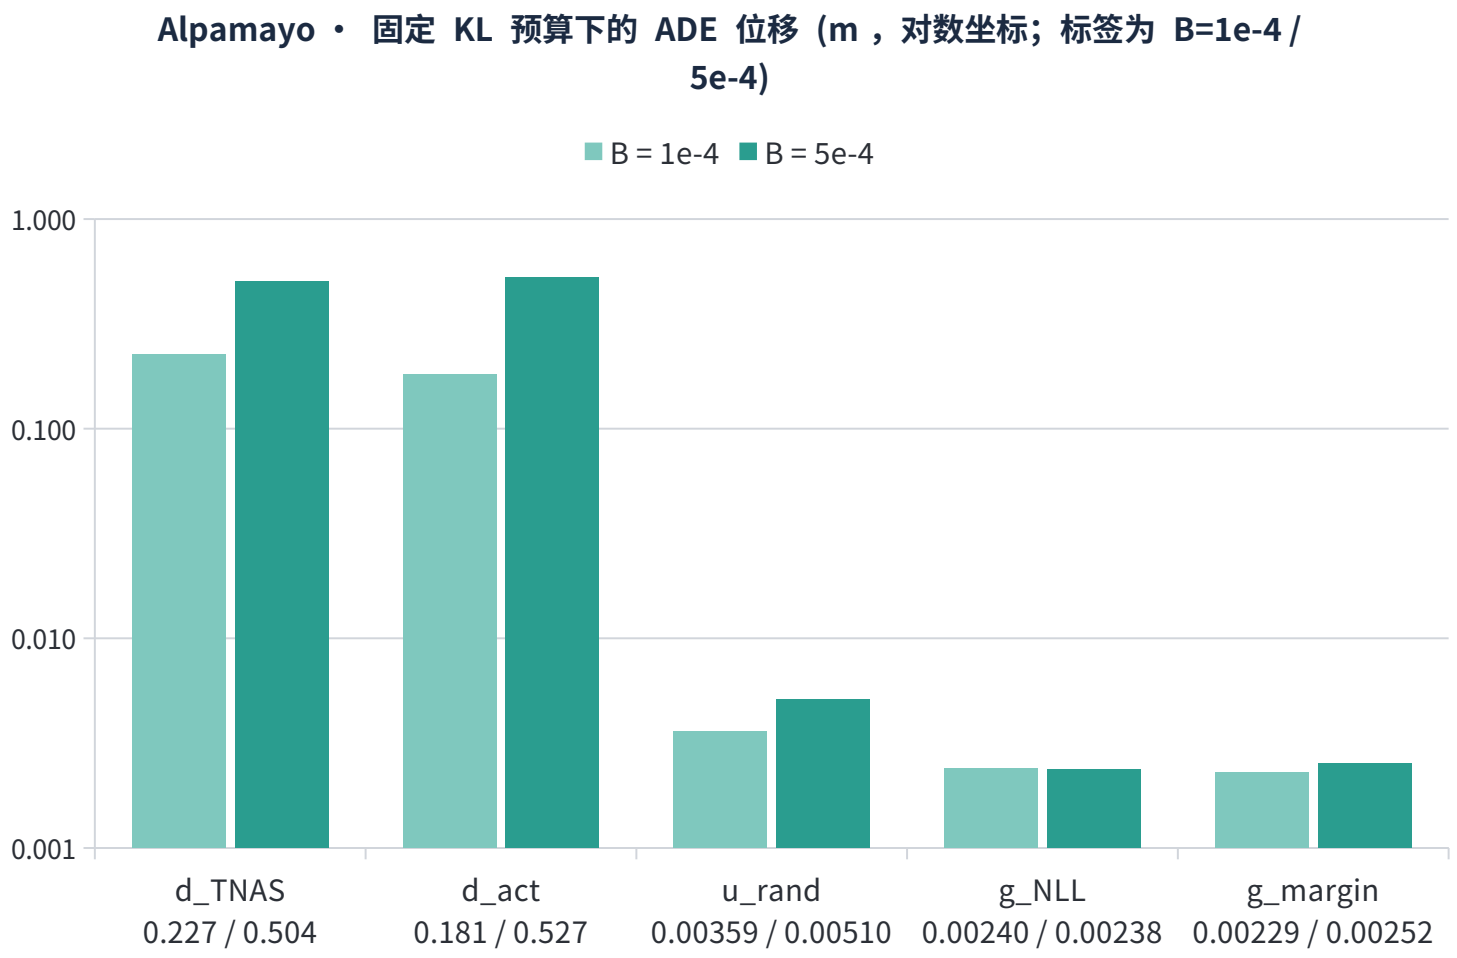

63–212×

Alpamayo： TNAS 相对对照方向（对照 ≤ 5.10 mm）

InstructVLA （B = 1e-3， n = 200）

方向	归一化动作位移
d_TNAS	0.0137
d_act	0.0166
u_rand	0.00752
g_NLL	0.00918
g_margin	0.00817

InstructVLA 上优势倍数小得多（约 1.5–1.8×）

方法二 · TNAS 引导的视觉攻击

攻击：在像素空间优化，并把隐状态位移“导”向 TNAS 方向

威胁模型

- 白盒、数字扰动
- 加在视觉编码器前的归一化图像张量上，端到端反传
- 200 步 PGD
- 全图 ε = 0.05
- 局部补丁 ε = 0.5 （归一化像素坐标）

评测数据： 200 个标准片段 / 样例；碰撞用 154 个有障碍物标注的 Alpamayo 片段

Action-only PGD

max 动作位移

只追求动作偏离

Text-preserving PGD

L_act+txt = 动作位移 − 文本惩罚

惩罚干净目标 token 的 NLL 增量与 margin 下降（Eq. 7）

TNAS-guided PGD

L_act+txt + λ_cos · cos(Δh, d_TNAS)

额外奖励隐状态位移 Δh 与 d_TNAS 对齐（Eq. 8）

评测指标

ADE

固定前缀下轨迹位移（m）

KL_tf

teacher-forced 全词表 KL

Exact

自由生成 rationale 一字不差率

静默碰撞

干净无碰撞 ∧ 攻击后碰撞 ∧ 文本一字不差

结果 · Alpamayo 全图攻击

加上文本保持约束，静默碰撞率从 4.55% 跃升到约一半场景

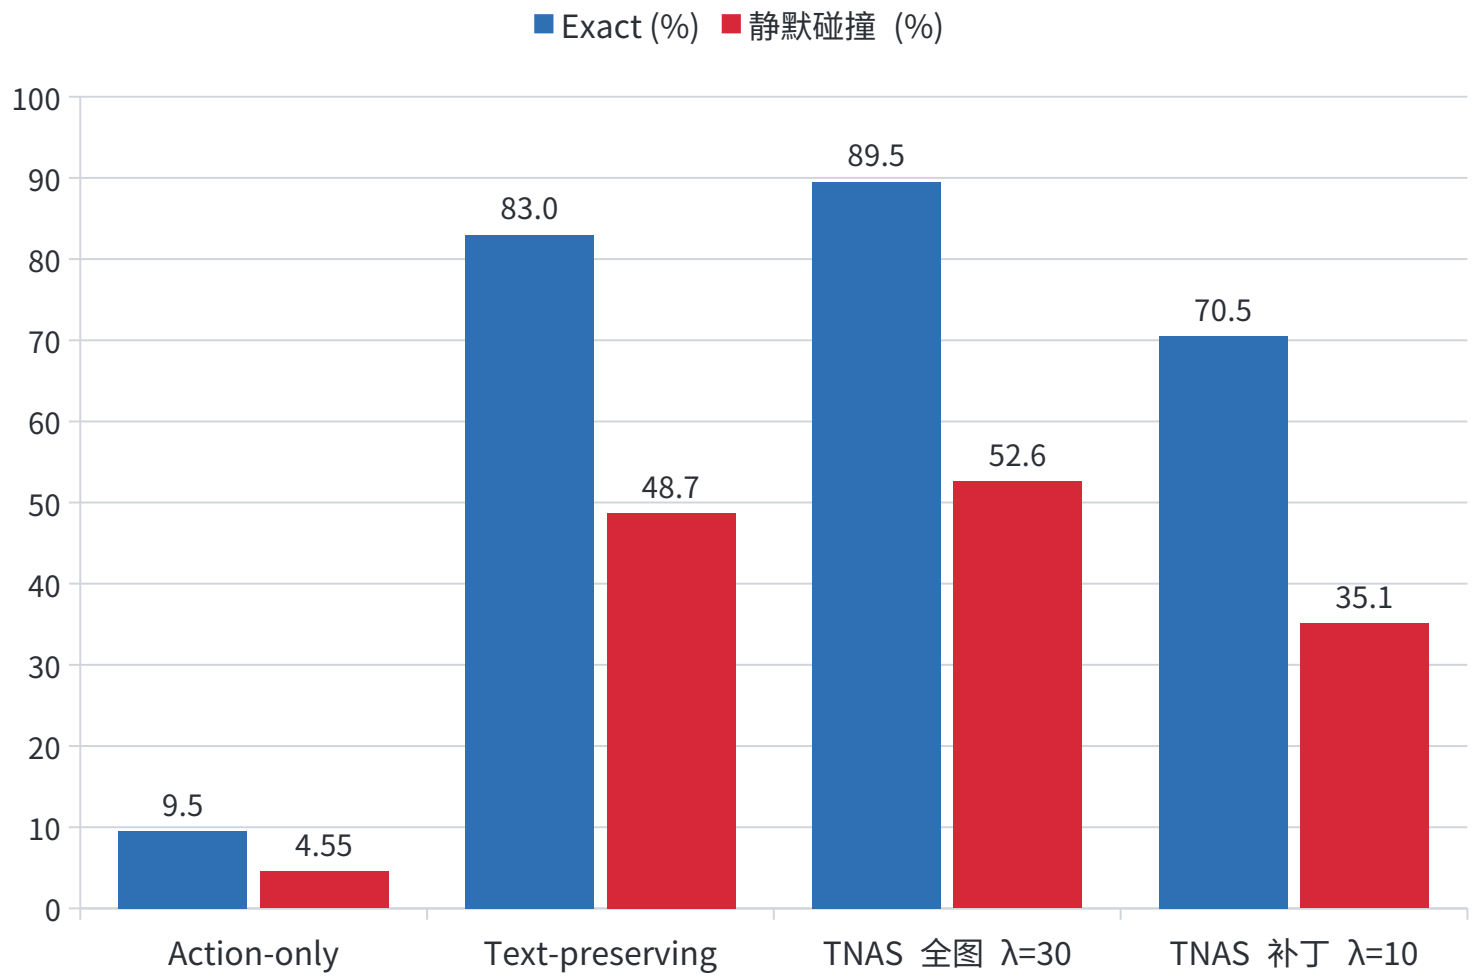

方法	ADE (m)	KL_tf
Action-only	70.1	0.278
Text-preserving	69.2	0.326
TNAS 全图 λ=30	53.0	**0.103**
TNAS 补丁 λ=10	39.8	0.124

52.6%

154 个有障碍物标注的场景中，rationale 一字不差却新增碰撞（对比 Action-only 4.55%）

输出层文本惩罚与动作梯度相互拉扯；余弦引导单调压低 KL、提升 Exact

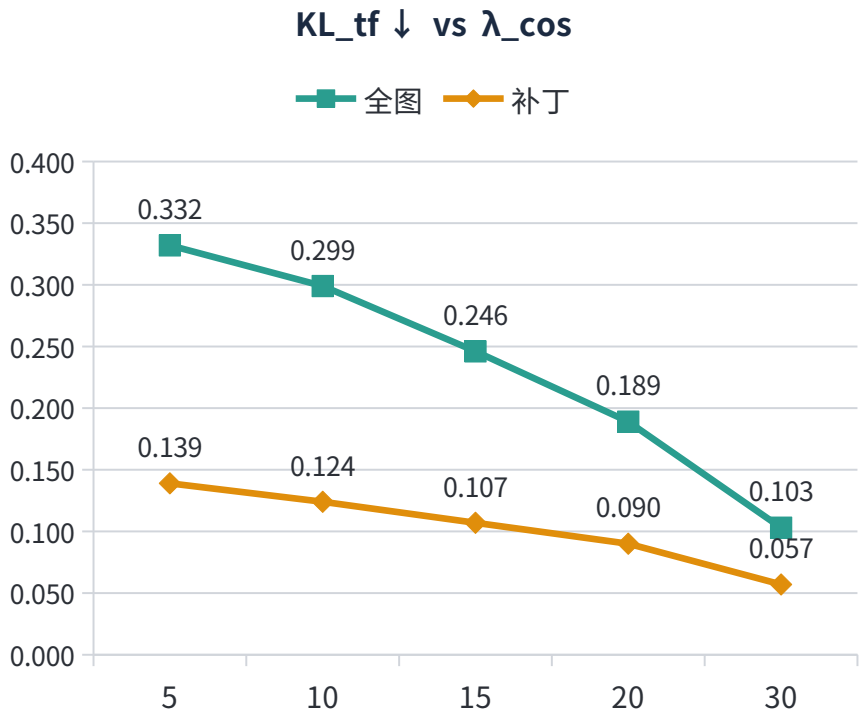

参照（Text-preserving，λ=0）：KL_tf 0.326，Exact 83.0%；横轴为 λ_cos

全图 λ=30：KL_tf 相比 Text-preserving 降低 68.4%；补丁 λ 5→30：KL 降低 59.0%，Exact 70.5% → 80.5%

冲突

加文本惩罚后全词表 KL 反而上升

0.278 → 0.326

惩罚只管住目标 token 的 NLL 与 top-1 margin

代价与收益

ADE 69.2 → 53.0 m，但攻击后整体碰撞率持平

61.7% vs 61.0%

文本保真度直接转化为静默碰撞

结果 · 局部补丁攻击

只改前向相机中 13.1% 的视觉 token，仍有约三分之一场景出现静默碰撞

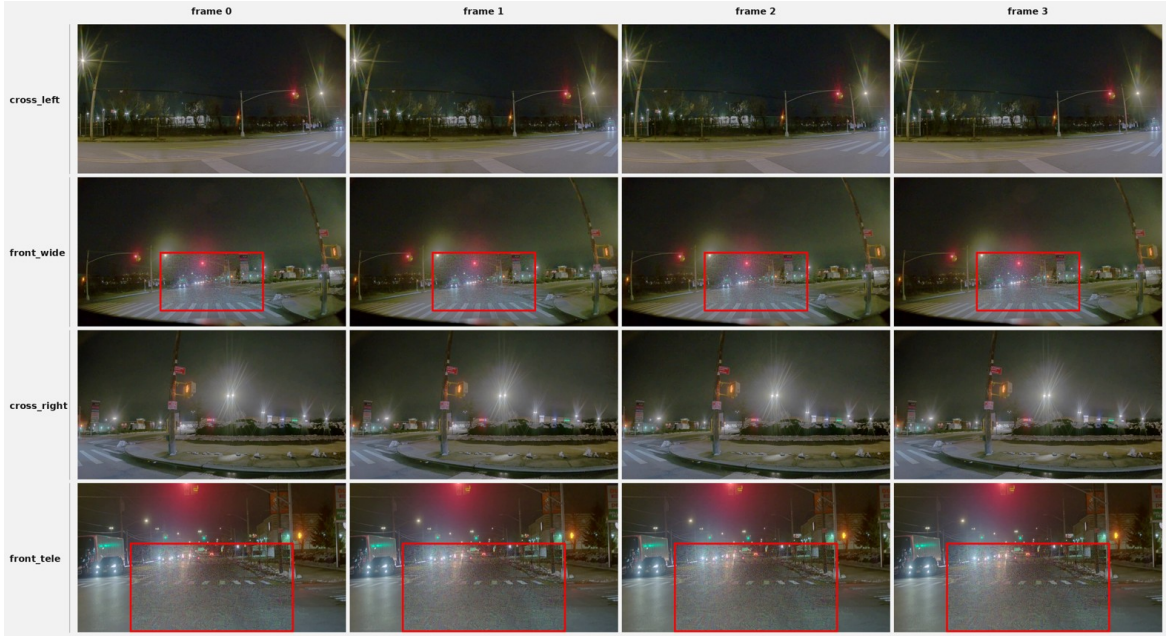

夜间路口：补丁贴近前方路面（行 = 4 个相机，列 = 4 帧）

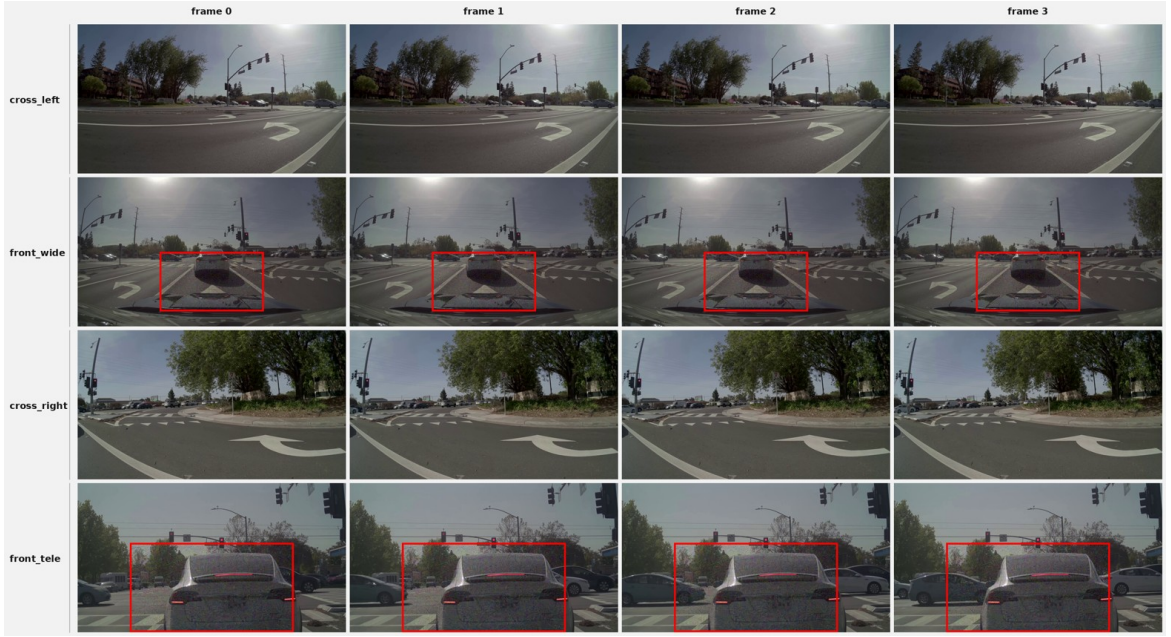

白天路口：补丁覆盖前车尾部（红框 = 补丁区域）

13.1%

视觉 token 被补丁覆盖（前长焦 + 缩放到前广角，四帧共享；侧向相机保持干净）

−59%

KL_tf （λ_cos 5→30）， Exact 70.5% → 80.5%

31.8–35.1%

静默碰撞率（154 个有障碍物标注的场景）

操作模型上同样成立： KL 降 40.5%， Exact 达 85%

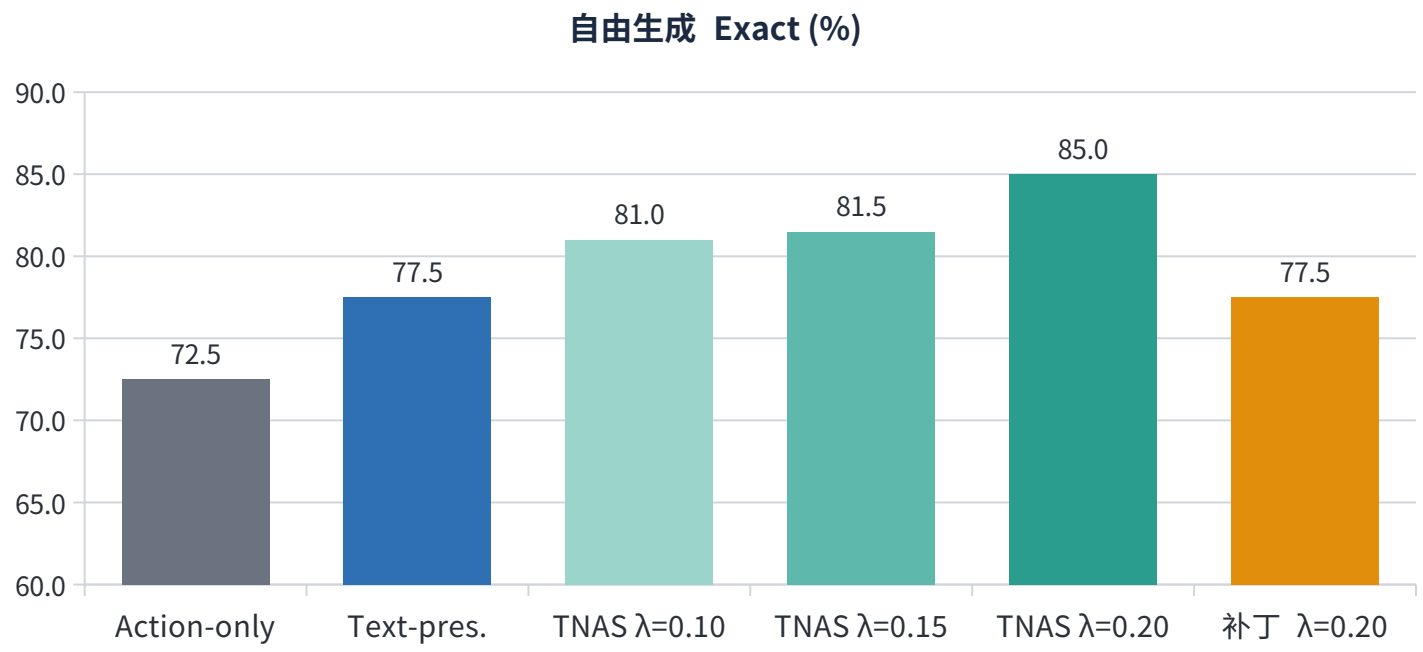

	Action-only	Text-pres.	TNAS λ=0.20	补丁 λ=0.20
动作位移（norm.）	2.04	1.97	1.73	1.32
KL_tf	4.66e-2	3.46e-2	**2.06e-2**	2.80e-2

72.5%

Action-only （无任何文本惩罚）下响应已保持不变

意图句平均 9.6 词， 200 例只有 178 种字符串，一句话概括整个 16 步 7-DoF 动作块——很粗的多对一瓶颈

TNAS 引导的增量

- KL_tf −40.5% （相对 Text-preserving），保留其 87.5% 的动作位移
- 消除了 Text-preserving 下剩余响应变化的约 1/3
- 补丁仅覆盖 16% 图像， KL 仍比全图 Text-preserving 低 19.1%

结果 · 配对检验

Exact 提升显著；但相对文本保持基线，静默碰撞的增益并不显著

比较	指标	计数	p 值	结论
Alpamayo： TNAS λ=30 vs Text-preserving	Exact match	179 vs 166	0.0192	显著
	更低 KL_tf	179 / 200	1.95e-32	显著
	攻击后碰撞	95 vs 94	1.00	持平
	静默碰撞	81 vs 75	0.451	不显著
Alpamayo： TNAS λ=30 vs Action-only	静默碰撞	81 vs 7	2.04e-21	显著
InstructVLA： TNAS λ=0.20 vs Text-preserving	Exact match	170 vs 155	0.0135	显著
	更低 KL_tf	163 / 200	4.58e-20	显著
InstructVLA：补丁 vs 全图 Text-preserving	Exact match	155 vs 155	1.00	持平
	更低 KL_tf	130 / 200	2.65e-5	显著

怎么读

1. 静默碰撞的主要来源是“加文本保持约束”： 7 → 75 （Action-only → Text-preserving ）

2. TNAS 的显著收益在文本侧：Exact 与 KL

3. 碰撞 81 vs 75 不显著 → TNAS 对攻击强度是“锦上添花”

最重要的发现是漏洞本身存在

批判性分析

需要谨慎看待的六点：强威胁模型、开环评测、增量有限

“几乎正交”信息量有限

随机单位向量 ρ 均值 0.978%， d_act 仅约 2 倍； TNAS ≈ d_act，投影一步作用很小，关键证据在等范数干预

TNAS 攻击增量有限

Text-preserving 已达 83% Exact、48.7% 静默碰撞； TNAS 碰撞 +3.9 pp 不显著

位移量级与开环判定

ADE 53–70 m；对照日志参与者开环判定（他车不反应），无闭环与动作合理性评估

威胁模型偏强

白盒 + 直接改预处理张量；补丁 ε=0.5 肉眼可辨、逐片段优化，无打印 / 物理验证

Exact 依赖解码与文本粒度

Alpamayo 采样解码（T=0.6, top-p 0.98）； InstructVLA 意图句粗，本就易保持不变

覆盖面与防御

仅两种“VLM + flow-matching 动作头”架构；未评估检测 / 防御方法

总结

rationale 不变 ≠ 动作安全：监控必须直接检查动作通道

01

新的失效模式

首次系统展示“ rationale 一字不差、动作偏离”的攻击；视觉输入端到端实现，覆盖驾驶与操作

02

机制解释

TNAS 诊断：动作敏感方向几乎与文本梯度正交；等范数干预显示两类方向选择性相差数十至数百倍

03

安全启示

rationale 监控（ CoT monitoring 的具身对应物）不能单独作为安全证明，需配合动作校验、运行时验证

一句话：文本是隐状态的低带宽、多对一读出，动作却能利用文本读不到的自由度。

在 Alpamayo 中，仅加文本保持约束就有 48.7% 的场景出现理由一字不差的碰撞， TNAS 引导后为 52.6% 。