论文解读 | arXiv 2611.04527 | 2026-11-04

Future Representation Distillation for Imagination-free World Action Models

DreamFree：把视频扩散模型的“预见能力”蒸馏进单帧视觉编码器，
不生成未来视频，也能做出更好的机器人动作

Jaehyeong Jo*, Sangwon Jang*, Sihyun Yu, Seonghyeon Ye, Yekyung Nah, Hojung Jung, Kimin Lee †, Sung Ju Hwang †
KAIST | 代码：github.com/harryjo97/dreamfree

TL;DR

一句话：把“想象未来”从推理时的像素生成，搬到训练时的特征监督

冻结的视频扩散模型（看过完整未来）当老师 → 蒸馏给只看当前帧的视频 DiT 编码器 → **一次前向**得到“预见未来”的特征 → 动作 DiT 直接输出动作块。

64%
真实世界 DROID 平均成功率
DreamZero 56% · π0.5 16%

11 Hz
14B 视频骨干下的实时闭环控制（91 ms/chunk）

17.8×
相比生成视频的 WAM DreamZero 的推理加速

74.4%
RoboCasa-Kitchen 24 任务
14B + 无标注额外视频

额外能力：第一阶段不需要动作标签，可以从无标注视频（甚至其他机器人形态的视频）学新任务。

问题：生成未来视频的 WAM 推理慢，且容易被错误想象带偏

VLA （如 π0.5 ）	生成视频的 WAM （如 DreamZero ）	DreamFree （本文）
■ 图文预训练，语义先验强 ■ 单次前向，速度快 ■ 缺乏时空动态 / 物理演化知识	■ 继承视频模型的预测知识 ■ 迭代视频去噪：约 1.6 s / chunk ■ 未来视频预测错误 → 动作出错	■ 预测知识蒸馏进当前帧特征 ■ 推理不生成视频，单次前向 ■ 目标：兼顾 VLA 的速度与 WAM 的先验

核心问题：动作预测真的需要像视频生成那样逐像素“想象”未来吗？能否让预测信息直接出现在当前帧的视觉特征里？

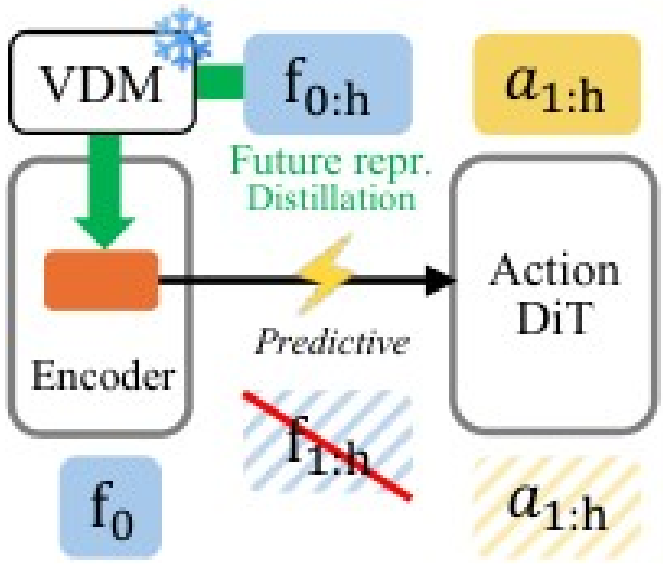

Figure 1 左： VDM 老师蒸馏给 Encoder ，未来帧 f1:h 不再生成

方法：两阶段训练，先学会“预见未来”的视觉编码器，再学动作

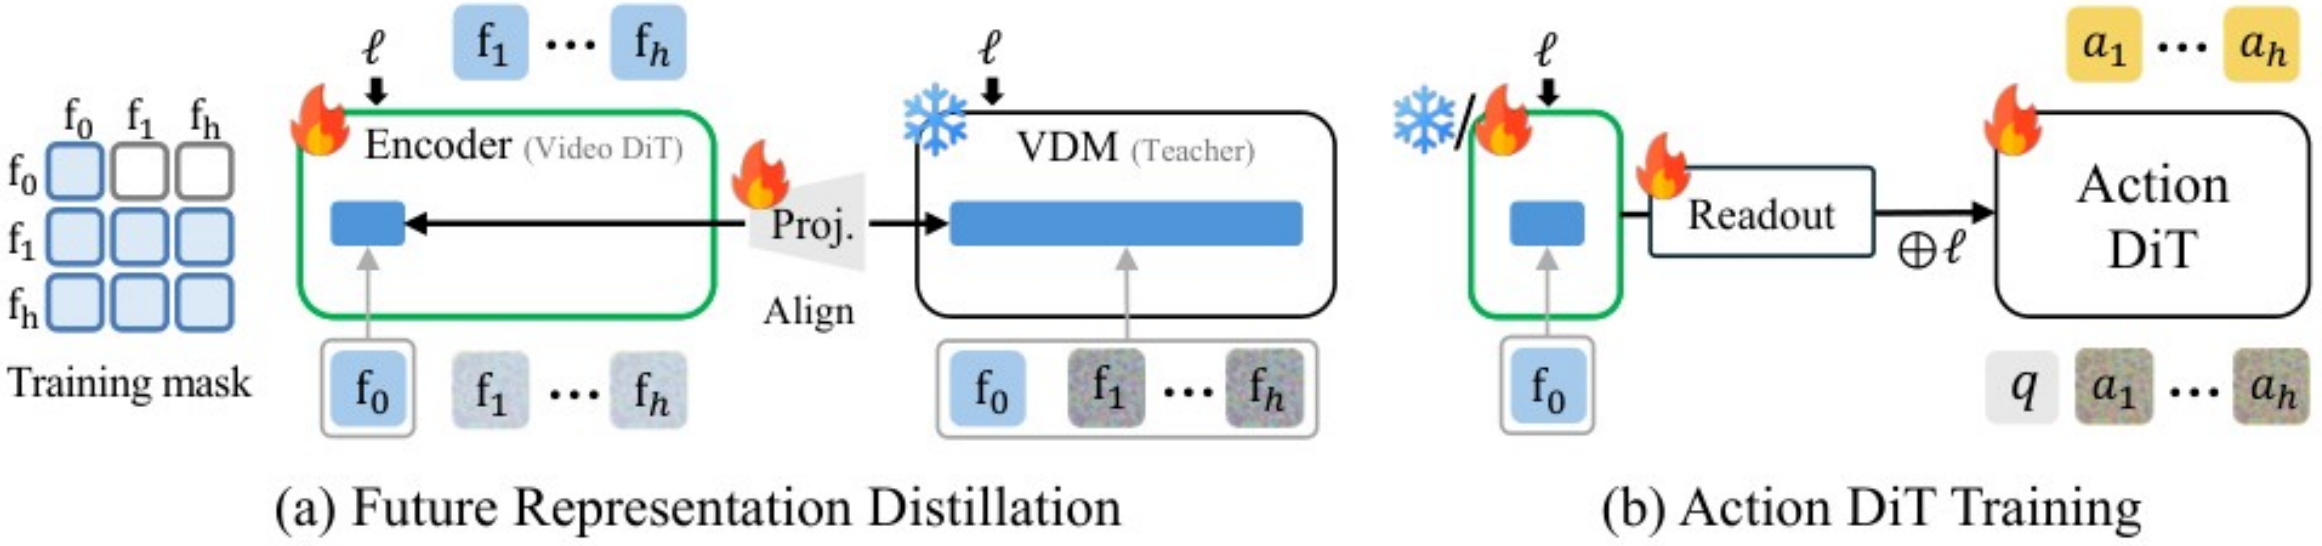

阶段 1 · 预测式视觉编码器

Wan2.2 视频 DiT 初始化；结构化 mask 让当前帧只看自身；当前帧隐状态经投影器对齐冻结 VDM 的未来表征。无需动作标签。

阶段 2 · 动作模块

编码器冻结； 64 个 query 的 Perceiver readout 提取动作 token ； 1B 动作 DiT 结合指令和本体状态，用 flow matching 输出 32 步动作块。

推理 · 无视频去噪

编码器在 t=0 只跑一次，不用 CFG ；动作用 10–16 步 Euler 采样；老师 VDM 与投影器在部署时丢弃。

关键设计：用余弦相似度对齐“只看当前帧的学生”与“看到未来的老师”

训练目标

$$L_{distill} = -sim(\, p_\psi(h_i),\ g_j(x_{td}, t_d, \ell)\,)$$

学生当前帧表征经投影器 ↔ 冻结老师对加噪全视频的第 j 层表征

$$L_{gen} = \| \, u_\theta(x_t, t, \ell) - (\varepsilon - x^*) \, \|^2$$

原生 flow matching：干净当前帧 + 加噪未来帧，保住预测能力

$$L = L_{gen} + L_{distill}$$

两项等权相加

- **结构化注意力：**当前帧 token 只互相注意；每个未来帧只看当前帧和自身，且不接收文本——迫使规划信息进入当前帧表征。
- **投影器：**当前 N 个 token 复制成 F×N 个，加上可学习帧嵌入，经两层 decoder 对齐老师。
- **只监督未来位置：**当前帧 token 不参与蒸馏损失；用非仿射 LayerNorm 后的余弦距离。
- **超参：**老师噪声 $t_d = 0.7$（仿真）/ 0.8（DROID）；14B 骨干 $i = j = k = 31$。
- **训练成本：**DROID 两阶段训练在 16 张 H200 上约一周。

蒸馏让当前帧特征更“懂动作”也更“懂未来”，接近直接看到未来

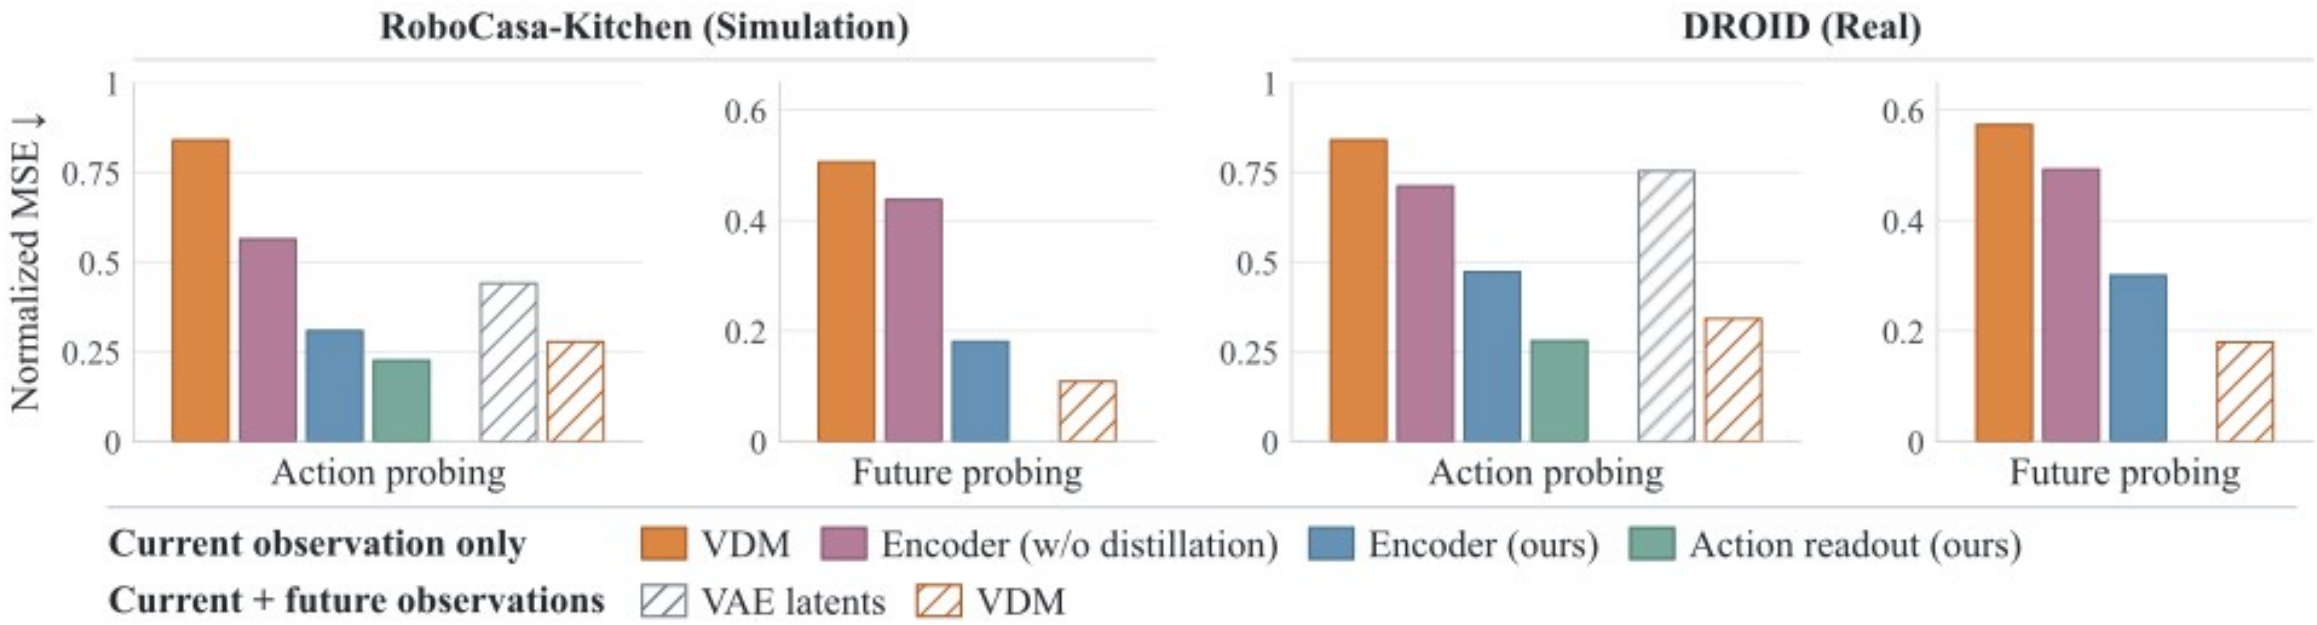

动作可解码性

编码器误差 < 无蒸馏版本 < 原始 VDM，蒸馏带来最大降幅

只看当前帧

动作误差低于“当前 + 真实未来”的 VAE latent，接近看到未来的 VDM

Readout 特征

误差进一步降低，动作相关信息被有效提取

局限

DROID 上未来探针与看到未来的 VDM 之间仍有明显差距

Q2 / Q3 • 仿真基准

RoboCasa： 14B 达 71.7%，加无标注视频 74.4%，远超 Fast-WAM

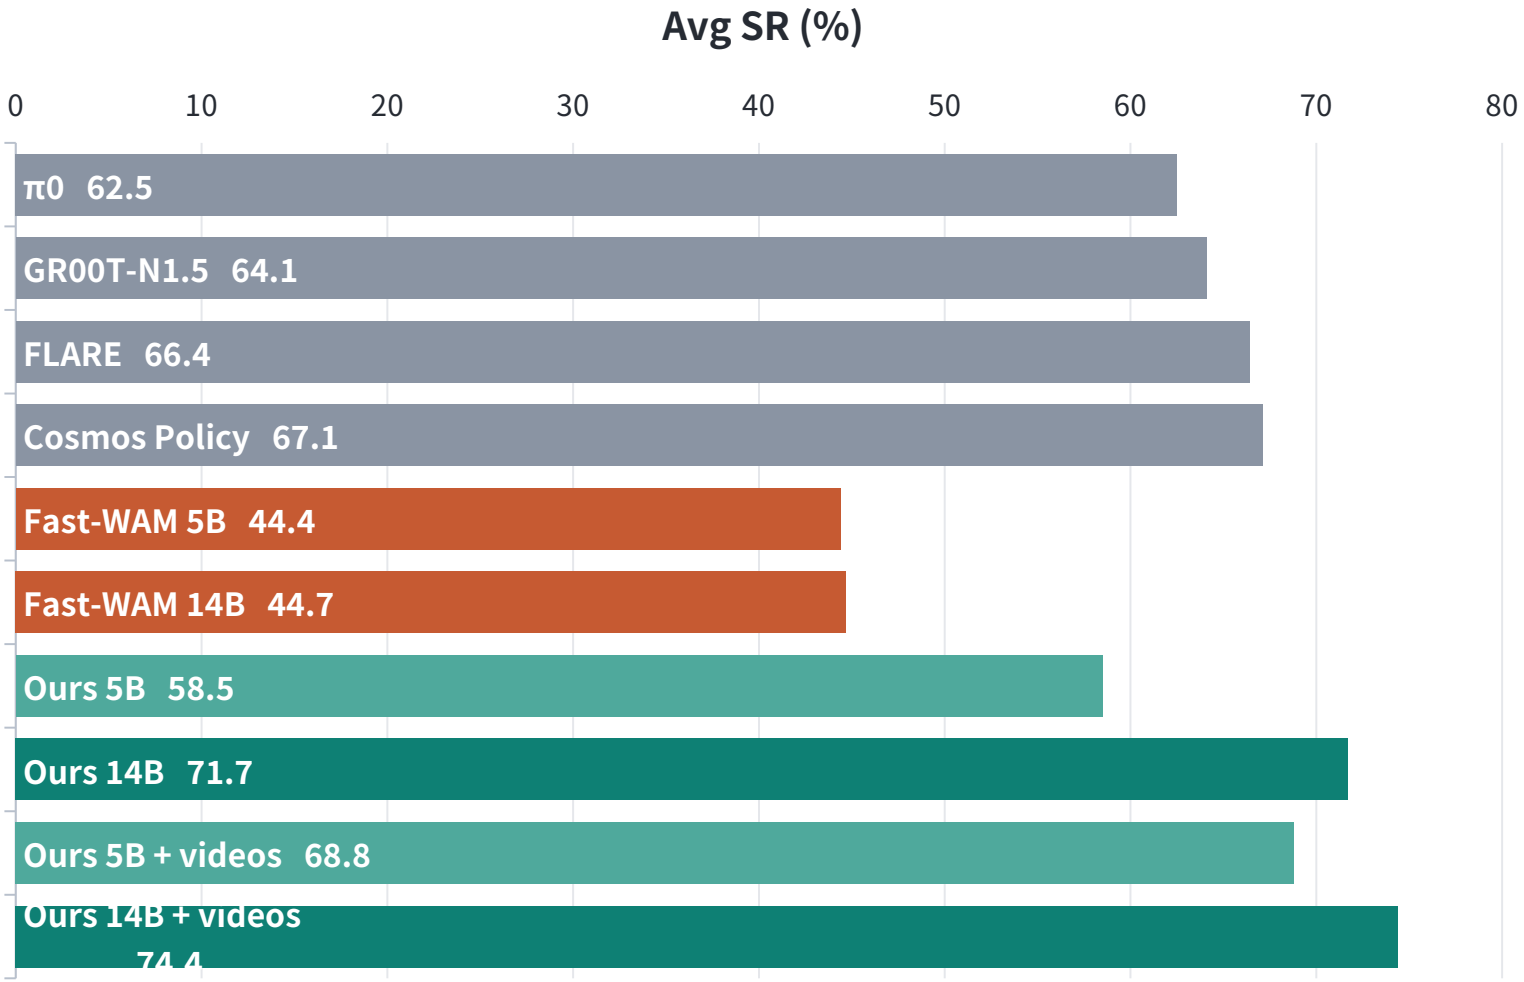

+13.2 pp

5B → 14B 骨干的提升

（Fast-WAM 仅 +0.3 pp）

+2.7 / +10.3

加入无标注视频后的提升

（14B / 5B，单位 pp）

98.6%

LIBERO 四个 suite 平均

（LingBot-VA 98.5，已近饱和）

arXiv 2611.04527 | 来源： Table 2 （RoboCasa-Kitchen 24 任务平均成功率 %）、 Table 1 、 Table 7

消融：去掉蒸馏损失跌幅最大， RoboCasa 从 71.7% 跌到 47.2%

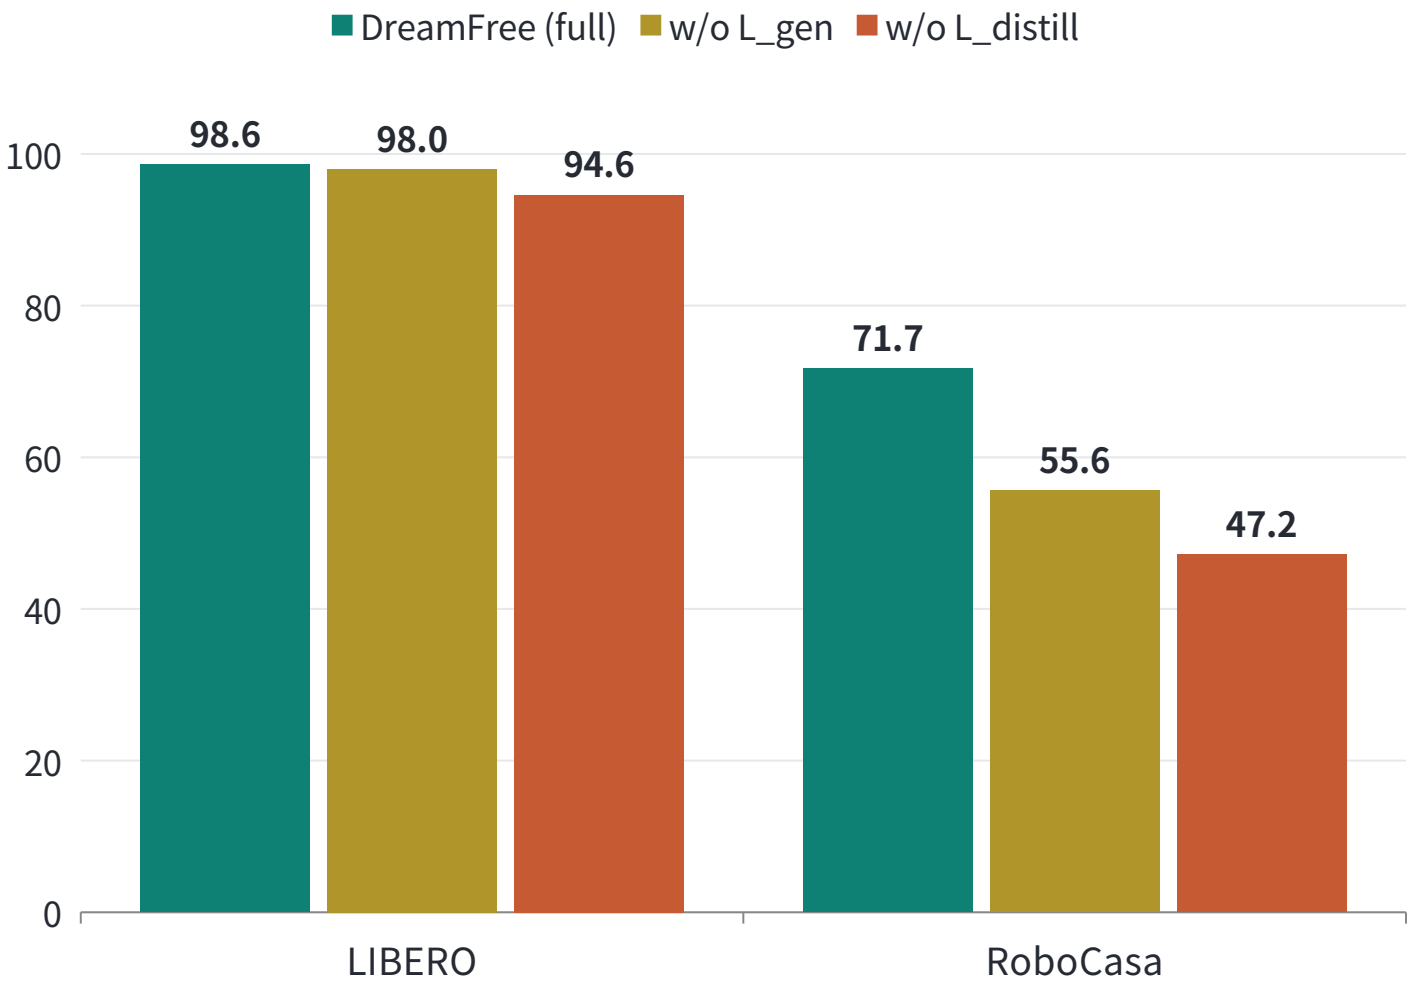

−24.5 pp

RoboCasa 去掉 L_distill

−16.1 pp

RoboCasa 去掉 L_gen

- 两个目标都有贡献，蒸馏起主导作用
- 与表征探针结论一致：去掉蒸馏后，动作和未来的可解码性都下降

真实世界 DROID：平均成功率 64%，形变与多步重排任务优势明显

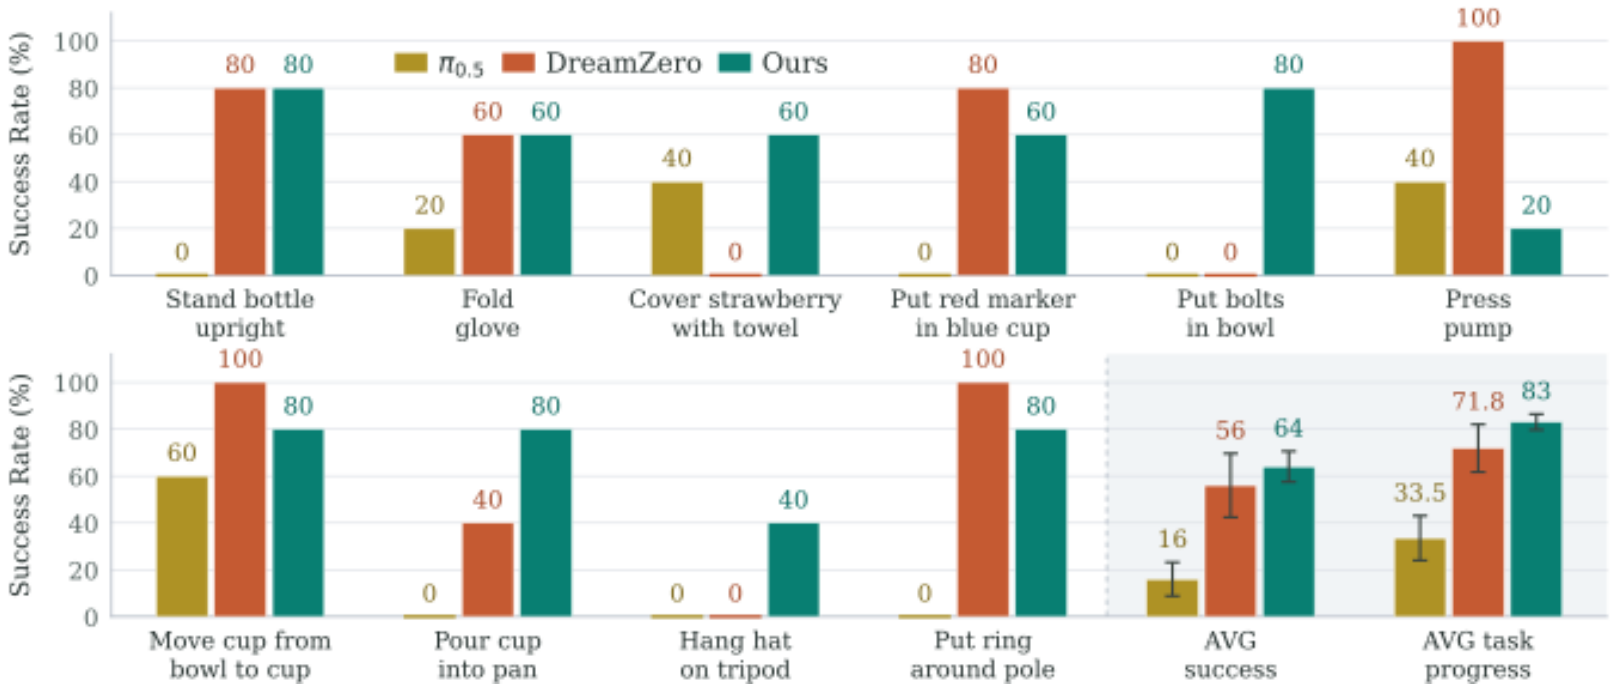

64%
平均成功率
DreamZero 56% • π0.5 16%

83%
平均任务进度
DreamZero 71.8% • π0.5 33.5%

DreamZero 0% → 本文：
盖草莓 60% • 放螺栓 80% • 挂帽子 40%

仍落后 DreamZero：
按压泵头 20% vs 100%；放红笔、杯子转移、套环

Q4 • 推理延迟

效率： 91 ms / chunk ，几乎和 VLA 一样快，比 DreamZero 快 17.8 倍

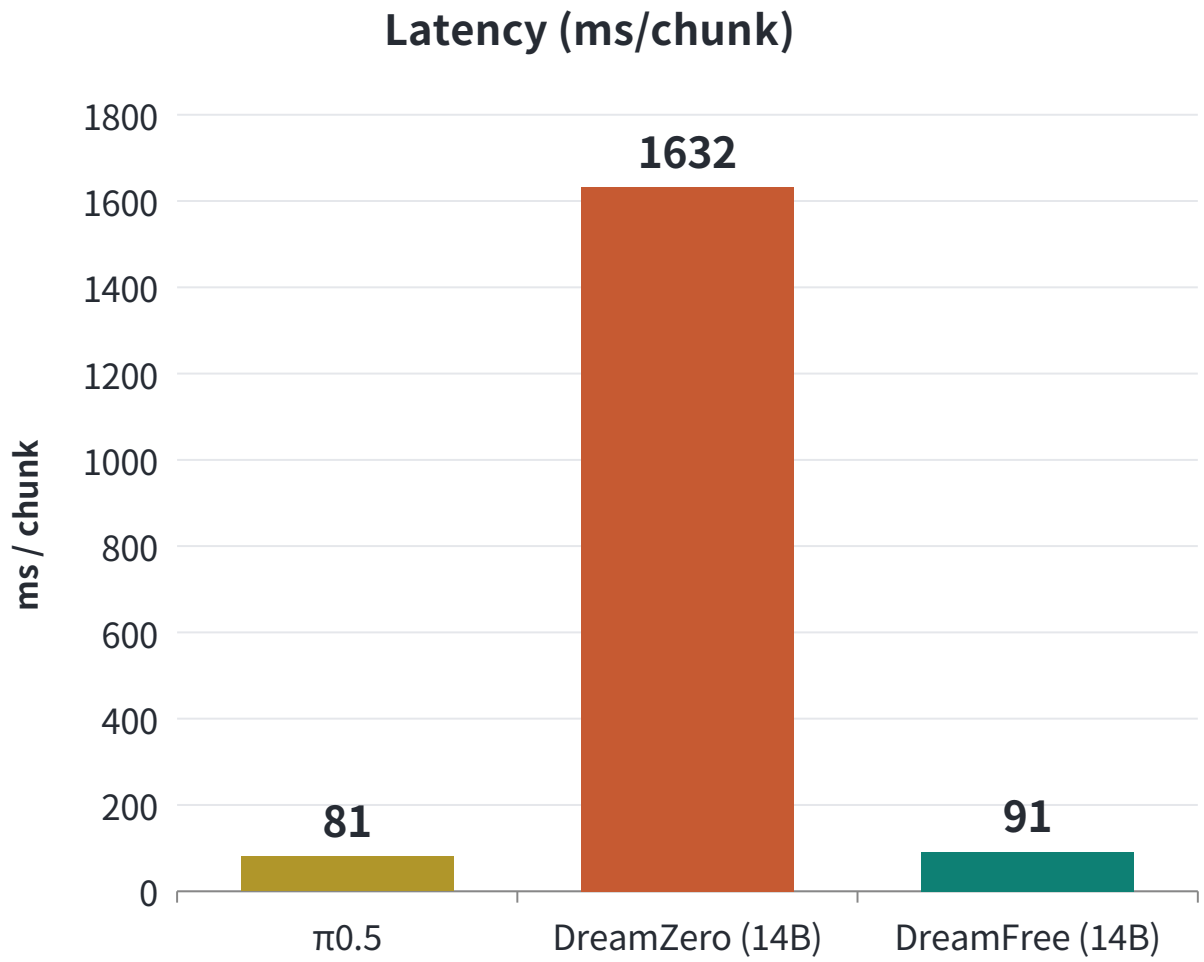

17.8×
快于 DreamZero

1.1×
π0.5 的延迟

快在哪里?

- **算法：**编码器单次前向（t=0），不做视频去噪、不用 CFG
- **工程：**只 VAE 编码当前帧、融合注意力与 QKV 、torch.compile 、 CUDA graph
- **任务耗时：**放 6 块积木时总完成时间明显短于 π0.5 与 DreamZero

无标注视频也能教新任务：组合任务 0→21.7%，跨形态 6.7→30%

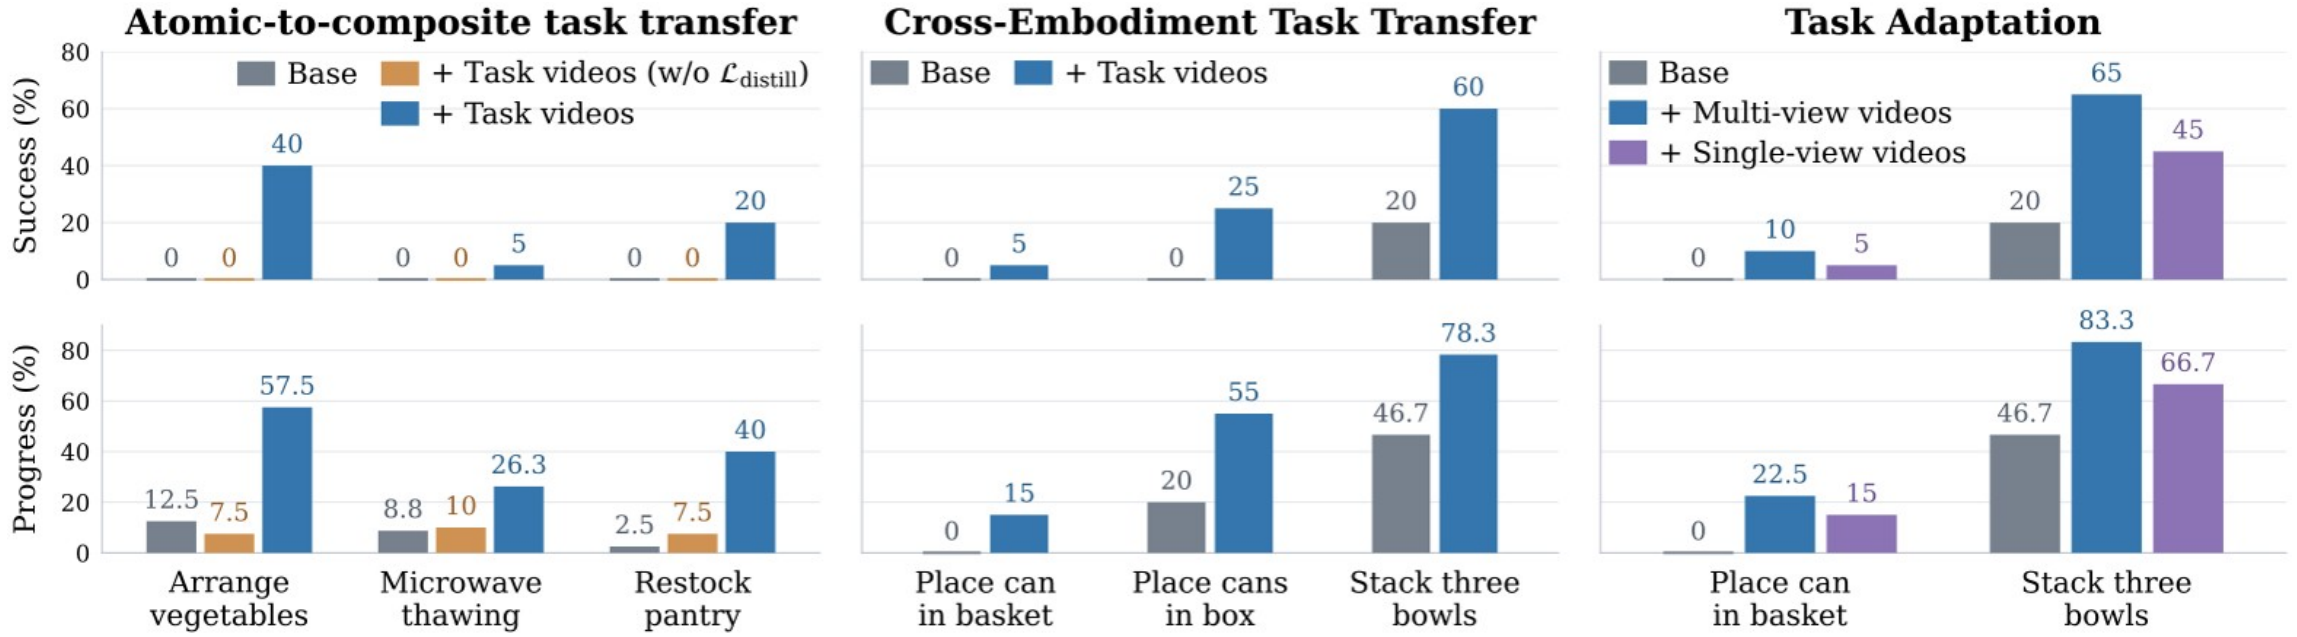

0 → 21.7%
原子 → 组合任务（同形态）
不蒸馏时仍为 0%

6.7 → 30%
跨形态： Franka 双臂视频 → ALOHA-AgileX 执行

20 → 65%
训练后适配： 10 条视频微调编码器
叠三个碗（多视角），约 10 分钟

局限
基座策略不会开柜门时，仅靠视频也学不会“放进柜子”——视频补的是任务知识，不是新的运动技能。

定性结果：方法可用于双臂 YAM，并能执行仅从视频学到的组合任务

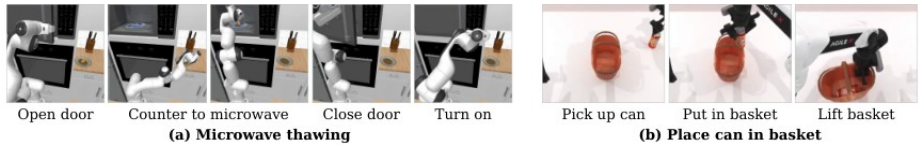

仅从视频学到的组合任务：微波炉解冻（4 个子目标）与提篮

- **双臂 YAM：** ABC-130k 中约 100 小时子集，无跨形态预训练，新场景开箱测试
- **注意：**双臂部分只有定性展示，没有定量成功率

讨论

评价：思路清晰、证据链扎实，但真实世界样本量与迁移性能有限

亮点

- 把“想象未来”从推理时的像素生成，换成训练时的特征监督
- 探针分析 + 消融形成完整证据链：蒸馏 → 未来信息 → 动作可解码性
- 对照 Fast-WAM：只有生成损失时，换大骨干几乎无收益；加蒸馏后骨干规模与视频数据都能转化为收益
- 第一阶段无需动作标签，支持从跨形态视频学新任务

需要注意

- 真实世界每任务仅 5 次（共 50 次），64% 对 56% 的差距统计上不稳固；按压、插入类任务仍落后 DreamZero
- 视频迁移绝对成功率偏低（21.7%、30%），偏概念验证
- 三段式训练（骨干适配 / 蒸馏 / 动作），16×H200 约一周；层号需人工选定
- 17.8× 加速中有一部分来自工程优化；DROID 上未验证额外视频与跨形态预训练

Take-away

视频模型对机器人控制的价值，在于它学到的“预测性表征”，而不一定是把未来视频真正生成出来。

方法	冻结 VDM 老师 → 只看当前帧的学生编码器做未来表征蒸馏；推理单次前向
效果	DROID 64% 成功率、 11 Hz； RoboCasa 74.4%； LIBERO 98.6%
扩展性	更大骨干、更多无标注视频 → 更好的控制；可从跨形态视频学新任务

arXiv 2611.04527 | github.com/harryjo97/dreamfree