论文解读 · arXiv 2611.04870

PrimeSim

A Generalist World Model Simulator from Large-Scale Cross-Embodiment Demonstrations

从大规模跨本体示范中学到的通用世界模型模拟器

Travis Davies, Wentao Ma, Lihao Guo, Tengfei Ma, …, Xiaoqi Li, Qian Zhu, Ran Cheng, Hao Dong

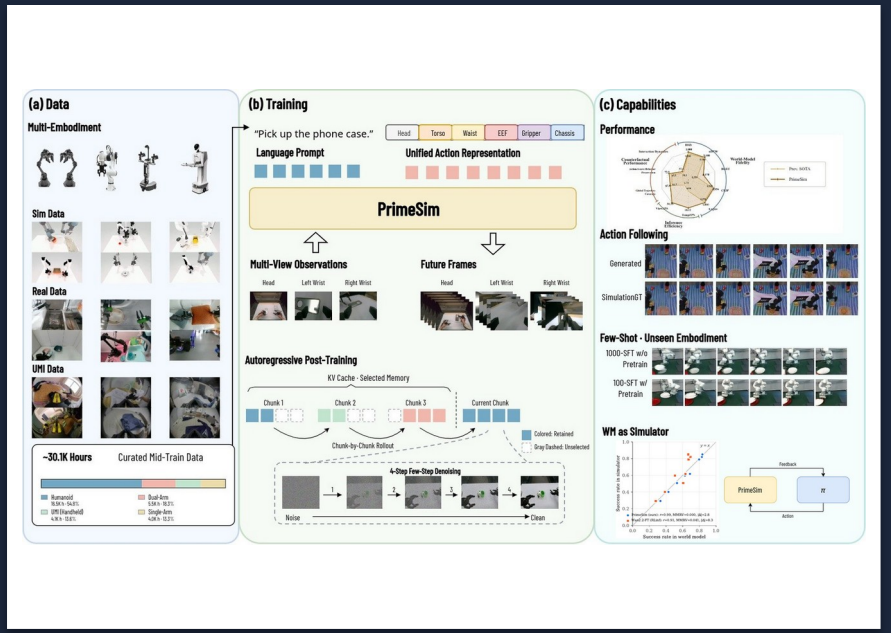

图源：论文 Fig. 1

PrimeBot Research · 东南大学 · 上海交通大学 · 香港中文大学 · 中国科学院大学 · 北京航空航天大学 · 北京大学 · 上海创智学院

首次提交 2026-11-03 | 开源：模型权重 · 推理代码 · 训练代码

TL;DR

一句话总结：把通用视频生成器训练成 10 FPS 、可练策略的机器人模拟器

PrimeSim 以 Wan2.2-TI2V-5B 为起点，先在 **22 个平台、 30,110 小时** 机器人示范上中训练，学会**按动作生成、三视角一致**；再用“快视频、慢记忆”四阶段后训练，变成 **4 步去噪、约 10 FPS 、可稳定滚动 60–105 秒** 的自回归模拟器，其预测的策略成功率与物理仿真器高度一致，且可在其中直接做 RL 。

30,110h	10.1FPS	66.6	6.09	ρ=1.00	61.7→73.2
22 个平台的中训练语料	4 步去噪 单卡 A100	WorldSimProbe 均值， 4/5 项第一	EWMBench 总分 排名第一	8 个策略排序与仿真器一致 （ r=0.99 ）	PrimeSim 内 GRPO 200 步 仿真器成功率 （ % ）

核心贡献：大规模跨本体中训练（统一动作接口 + 帧对齐动作条件 + 视角感知注意力）＋“快视频、慢记忆”后训练（因果化、 4 步蒸馏、自滚动 DMD 、层级时间记忆）。

问题定义

视频生成 ≠ 模拟器：世界模型要同时满足三个硬要求

01 动作跟随

难点

全局注意力下每帧可聚合任意时刻的动作，现有模型常“幻觉”出与指令不符的机器人运动

PrimeSim 的解法

统一 31 维动作表示 + 首帧锚定的相对动作块 + 帧对齐双路动作条件

02 多视角一致

难点

腕部相机随臂运动、彼此可见；各视角独立生成会不一致，无约束的全局注意力又会淹没视角特有信息

PrimeSim 的解法

视角感知交错注意力（2 块视角内 + 1 块全局） + 显式相机身份 token

03 长时程 & 实时

难点

推理时以自身不完美的预测为条件，误差持续累积；双向模型需 50 步去噪，太慢

PrimeSim 的解法

“快视频、慢记忆”后训练：因果分块 → 4 步蒸馏 → 自滚动 DMD → 层级时间记忆

方法总览

整体框架：预训练 → 中训练 → 后训练，把视频生成器改造成模拟器

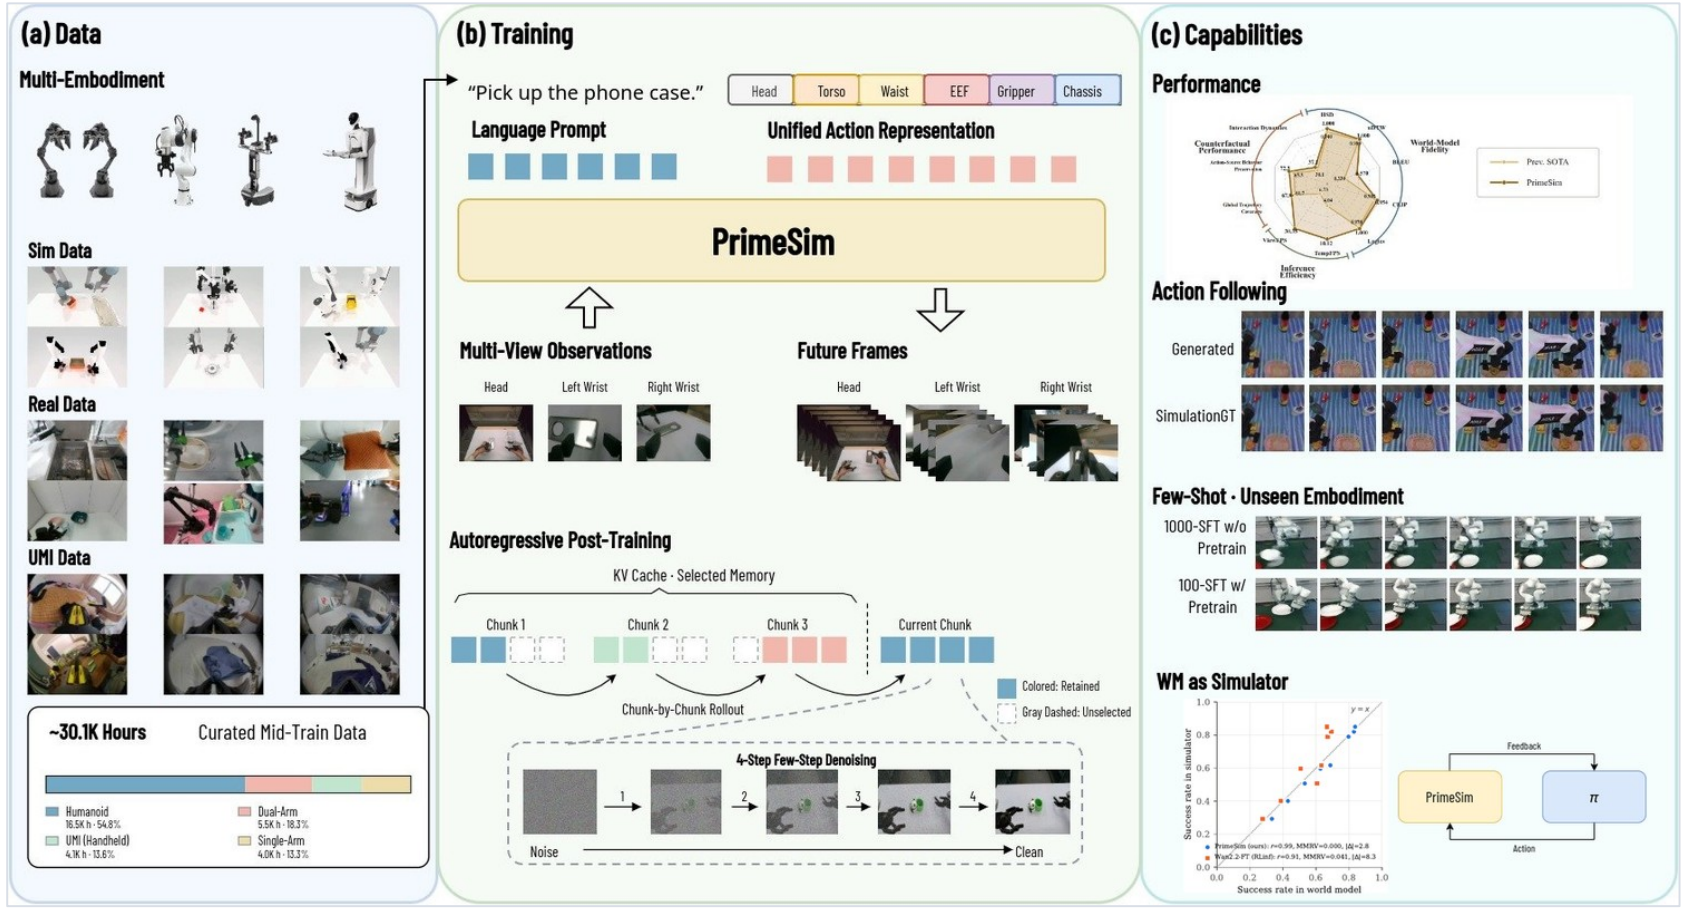

预训练

直接采用 Wan2.2-TI2V-5B （5.05B 参数）：物体恒存、光照材质、短时运动等通用视频先验

中训练

30,110 h · 22 平台；统一动作 + 帧对齐条件 + 视角感知注意力；双向 flow matching

后训练

因果分块 → 4 步一致性蒸馏 → 自滚动 DMD → 层级记忆； 10.1 FPS 自回归模拟

数据： 30,110 小时纯机器人示范，人形占一半以上

30,110 小时
总时长 · 2.38B 帧

1.52M
episodes （正文 / Table 12 ）

22 个平台
20 个数据集家族 · 1,773 个仓库

84 : 16
真实 ： 仿真（按轨迹时长）

54.8%
人形（ 16.5K h ），双臂 18.3%

9,540 h
自采人形家务数据，最大单一来源

注： Fig. 3 标注 2.8M episodes 、 85:15 ，与正文不一致

数据管线：四阶段清洗，把异构数据统一成同一种格式

原始来源	① 视频质量	② 动作质量	③ 数据对齐	④ 动作对齐
遥操作	光流运动分数做分布控制，平台内对近静止片段降采样	去灵巧手、带腿人形（保留轮式人形）	统一重采样到 10 Hz（容差 0.03 s）	URDF + 正运动学补末端位姿
UMI 手持夹爪	去除 JPEG 伪影 / 数值损坏	一阶差分离群检测异常跳变	相机固定 3 路：多则删，少则复制主相机	旋转统一为 (x,y,z,w) 四元数
仿真	丢弃 < 1 s 片段	缺失且无法 FK 补算的动作丢弃	无指令的用模板生成 prompt；转 LeRobot	31 维统一表示 + 首帧相对动作块

分阶段用数据 中训练用全部语料求覆盖；后训练只用少量面向下游任务的完整 episode，求长时程与实时性

不用人类视频 池化后的机器人数据规模已可比肩人类第一视角语料，省去潜动作 / 人手→末端的对齐

动作表示：统一 31 维 + 以窗口首帧为锚的相对动作块

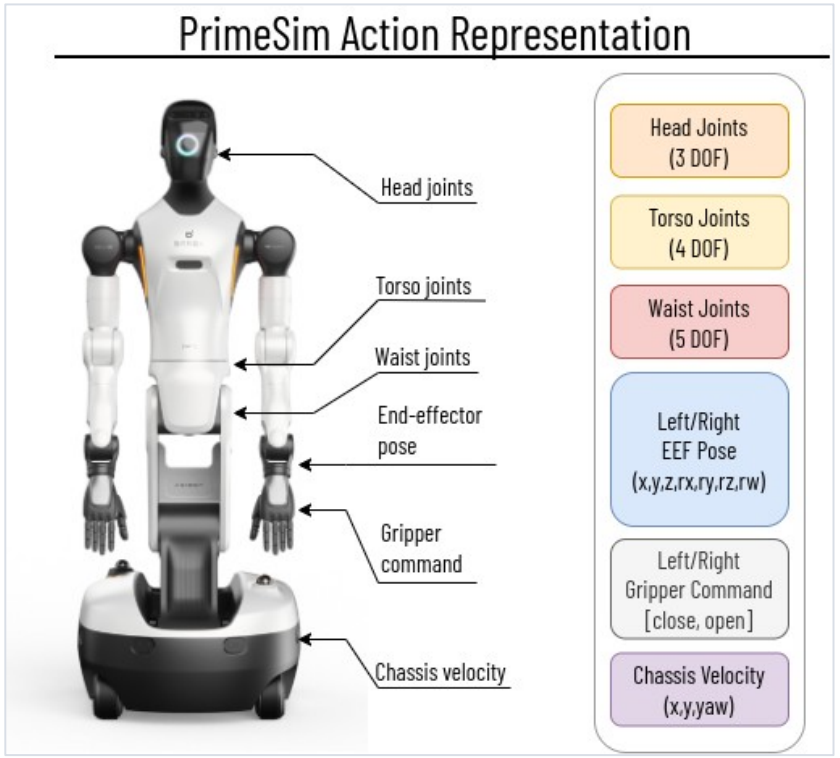

头 3	躯干 4	腰 5	末端 2×7	夹爪 2	底盘 3

= 31 维；缺失的槽位置 0 （等价于“不动”）

相对动作块：所有动作都相对窗口第 0 帧表达

关节： $\tilde{q}_t = q_t - q_0$　　位姿： $\tilde{T}_t = T_0^{-1} T_t$ （ $\tilde{p}_t = R_0^\top (p_t - p_0)$ ， $\tilde{R}_t = R_0^\top R_t$ ）

夹爪（二值）与底盘速度（v_x, v_y, ω）保持不变

- 缺失维度天然为 0：不同本体无需额外处理
- 消除各本体的绝对原点偏移
- 所有帧锚定同一参考状态：条件信号更强、分布更集中（对比“相对上一帧”的增量）

Table 9 · PSNR ↑ （纵轴不从 0 开始）

帧对齐双路动作条件：注意力决定“哪个动作”，Adapter 保证“确实生效”

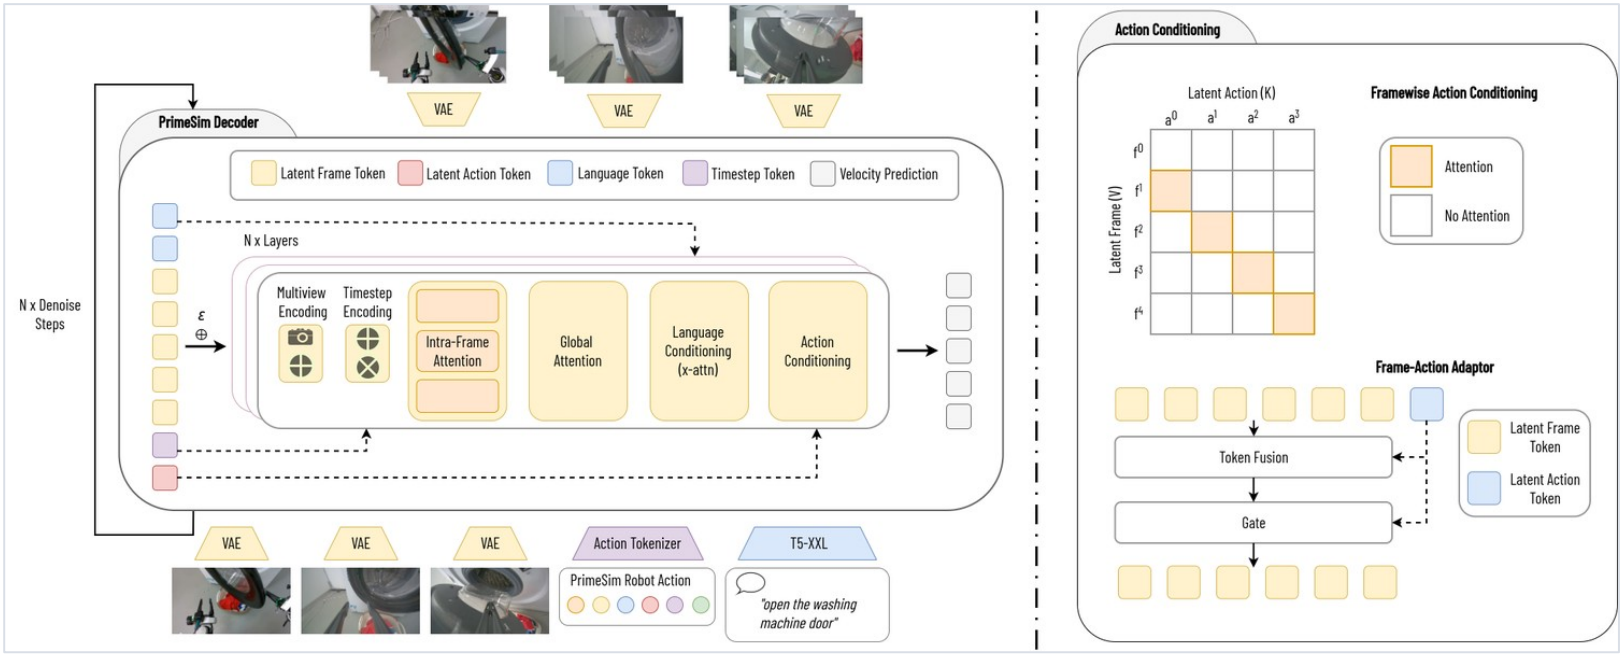

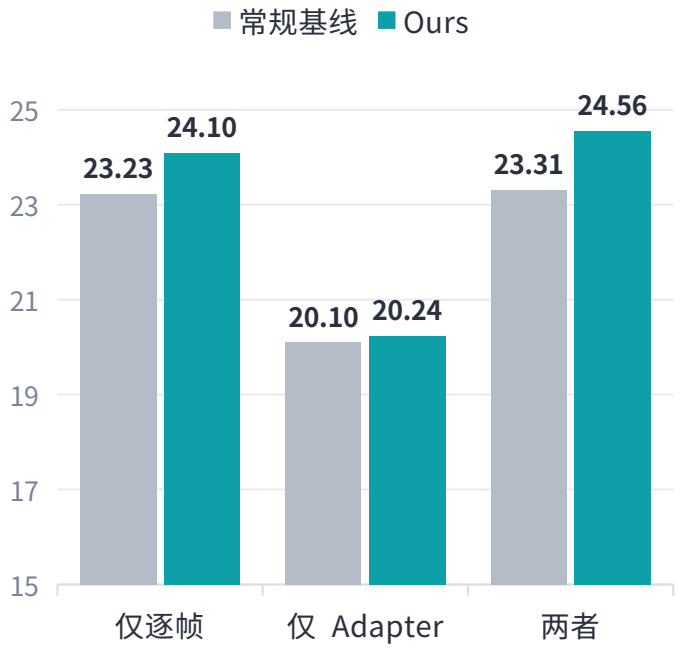

Table 10 • PSNR ↑ （基线： cross-attn / AdaLN ）

① 逐帧注意力（移位对角掩码）

动作 a_t 驱动进入第 t+1 帧 → 第 t 帧只注意 a_{t-1}，首帧不接收动作；从注意力层面杜绝无关时刻动作的干扰

② Action-Frame Adapter

由对应动作 token 经 Token Fusion + Gate 计算残差特征偏移，直接注入帧 token，不依赖学到的注意力权重

动作 Tokenizer

两层 MLP 把相对动作块编码成动作 token，每个潜帧一个，为两条路径提供共同的时间轴

视角感知交错注意力：相机身份 token 带来最大的一步提升

30 个 DiT 块的注意力排布

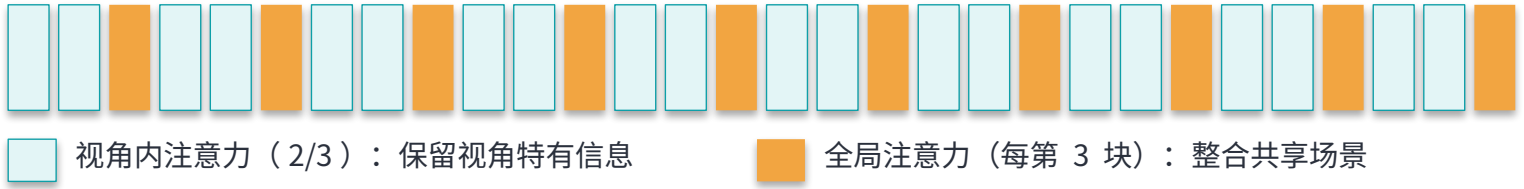

视角内注意力（2/3）：保留视角特有信息　　全局注意力（每第 3 块）：整合共享场景

+ 每个视角前置可学习相机 token：标明 token 来自哪个相机

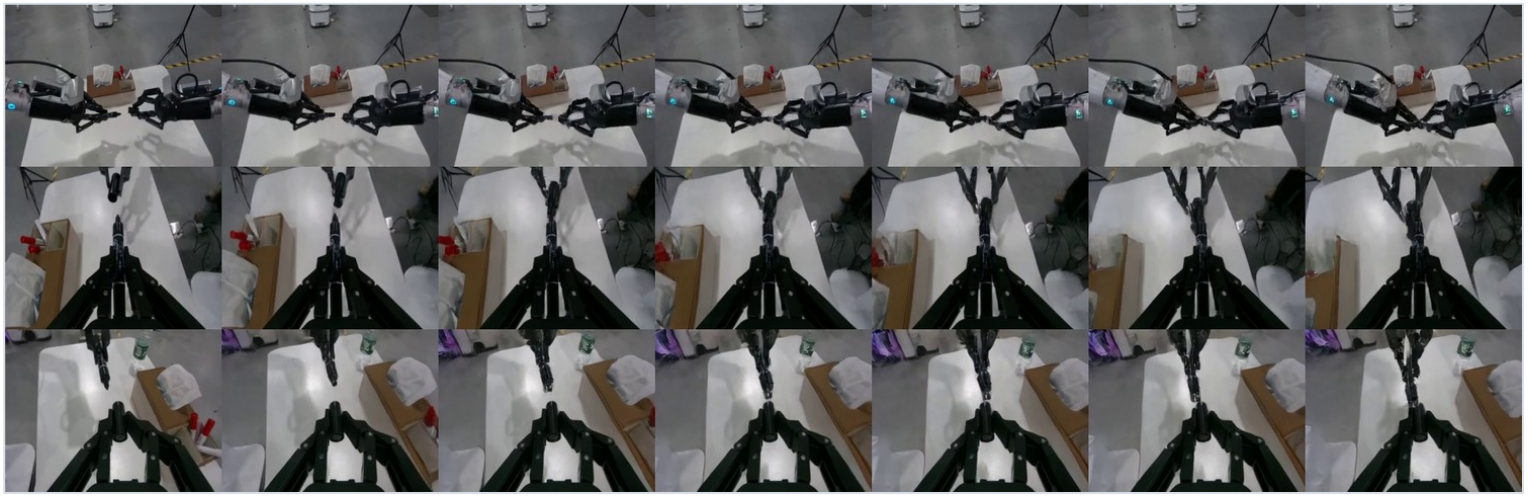

Fig. 11　三视角联合生成（行：头部 / 左腕 / 右腕），同一动作序列驱动

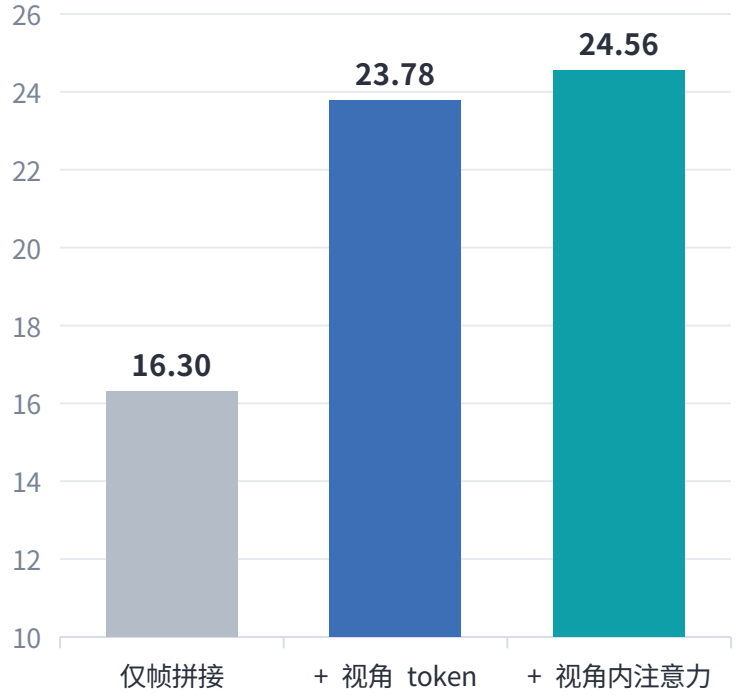

Table 11 · PSNR ↑ （逐步叠加组件）

指标	拼接	+token	+ 视角内
SSIM ↑	0.62	0.83	**0.84**
LPIPS ↓	0.58	0.18	**0.15**

后训练“快视频、慢记忆”：四阶段把双向生成器变成实时模拟器

Stage 1
自回归建模

做法

块内双向、块间因果注意力；teacher forcing （仍是 flow matching，只换掩码）

解决

能逐块自回归生成

Stage 2
因果一致性蒸馏

做法

Stage 1 模型作冻结教师，在线匹配教师 ODE 的局部转移；只训 LoRA

解决

50 步 → 4 步，让自滚动训练算得动

Stage 3
片段级自滚动 + 非对称 DMD

做法

学生用自身 KV cache 续写；冻结的双向中训练模型作教师，反向 KL；fake-score 网络 5:1 更新

解决

exposure bias；蒸馏造成的模糊 / 平均化

Stage 4
episode 级长时程适配

做法

自滚动扩展到整段 episode；层级时间记忆；潜空间续写；摊销监督；动作锚定到 episode 起点

解决

短训练–长推理的差距、遮挡后遗忘

50 → 4	去噪步数
≈ 9.0×	Stage 3 相对 Stage 1 吞吐
k = 3	每块 3 个潜帧，每窗口 3 块
r = 32	Stage 3 学生 LoRA 秩

层级时间记忆：同样 21 个槽位，长时程退化明显小于滚动缓存

层级记忆（3 + 9 + 9 = 21 槽）

全局 sink　　慢记忆：稀疏长期历史（降采样）　　局部记忆：稠密近期运动

对照：滚动缓存（3 + 18）

- 每个窗口后：旧局部记忆并入慢记忆 → 按时间降采样到固定容量，保留时间位置；三视角帧索引同步
- 除初始帧外全部来自模型自身生成：训练与推理同一机制，无 teacher forcing 分布差
- 潜空间续写，不反复解码 / 编码；动作锚定到 episode 起点

首末窗口 ΔPSNR ↓ （Table 8）

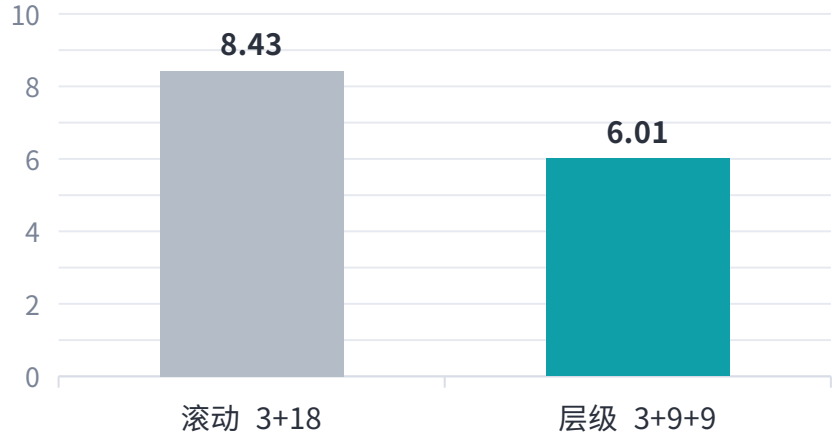

退化 ↓	滚动	层级
ΔSSIM	0.120	**0.079**
ΔLPIPS	0.233	**0.159**

Fig. 12　RoboTwin 2.0 头部视角：第 4 帧手臂完全遮挡左下角的鞋子，移开后鞋子在原位置、原尺度、原朝向重现。评测： 10 条 held-out episode， 61–105 s，仅首帧为真值

WorldSimProbe：五个子项赢四个，均值 66.6 领先 11.1 分

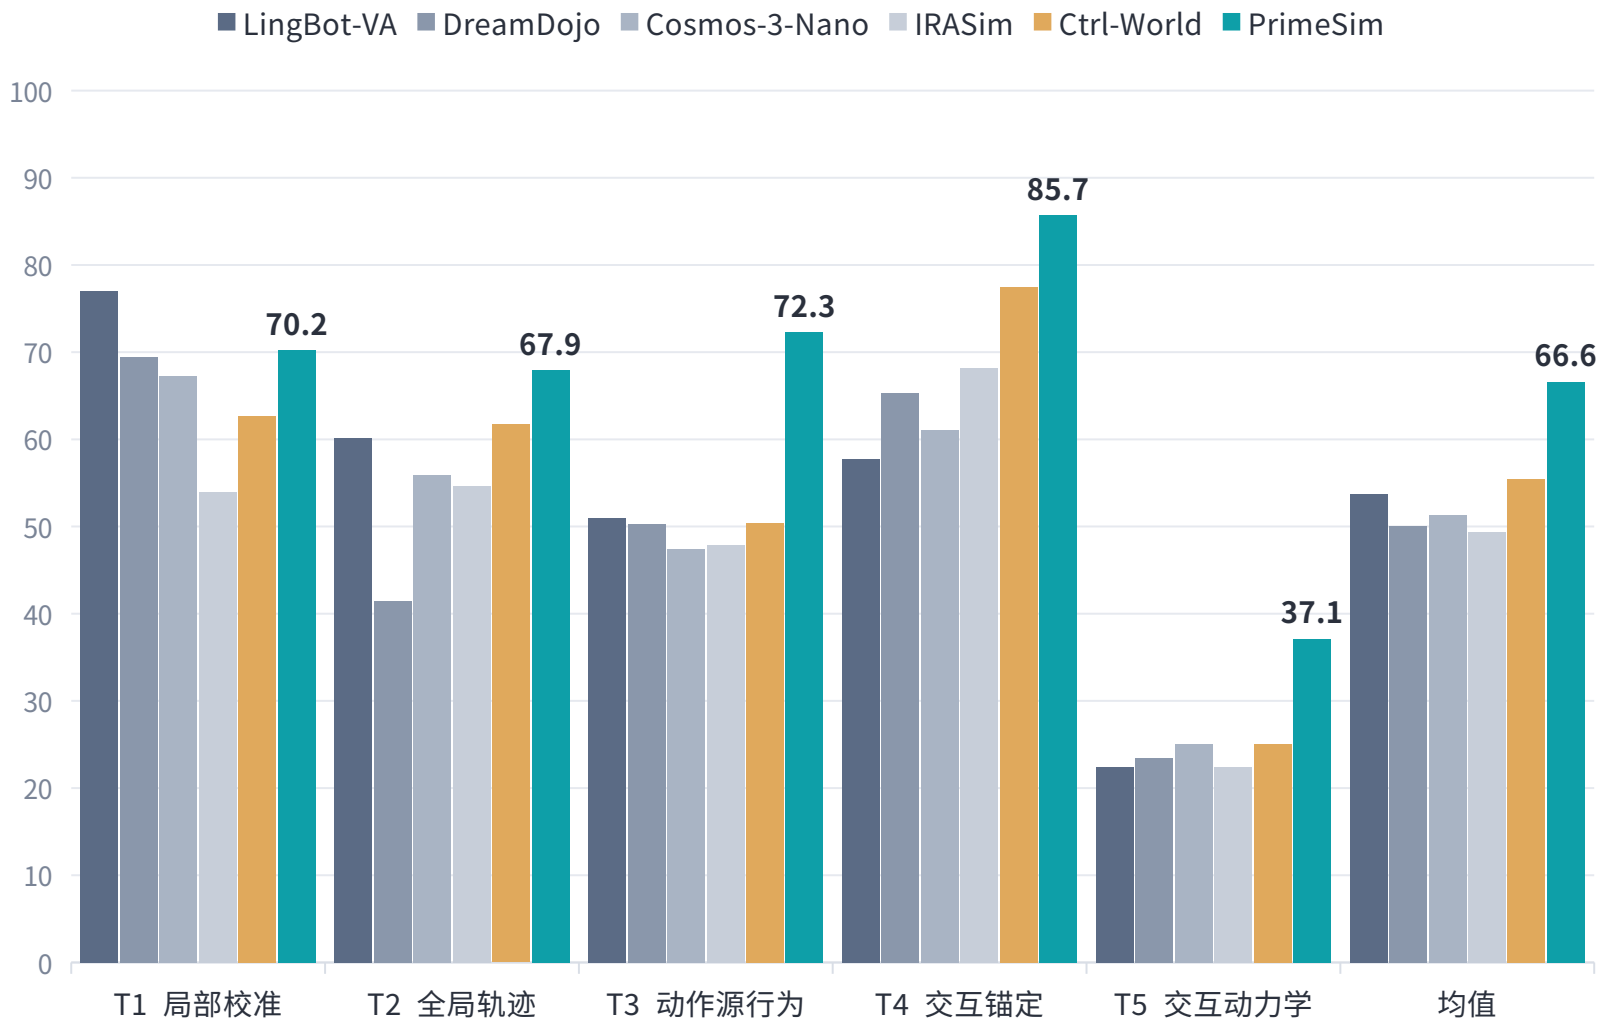

测什么

“可观测模拟器契约”：动作 → 产生对应运动 → 环境只响应实际实现的运动（PSNR 看不出的失败）

- **领先 4/5：** T2 67.9 （+10.0%）、 T3 72.3 （+41.8%）、 T4 85.7 、 T5 37.1 （+48.4%）
- **唯一失手：** T1 局部校准 70.2 < LingBot-VA 77.0 ，细粒度控制仍非最佳
- **T4 解释：** 记忆在自身 rollout 上训练，学到环境对“实际运动”的响应

注意：评测时额外构造了 VLA 多轨迹 / 扰动轨迹 / 替换物体的训练数据并加视觉噪声； 192×256 、 33 帧

EWMBench： 总分 6.09 居首，但这是同域微调后的评测

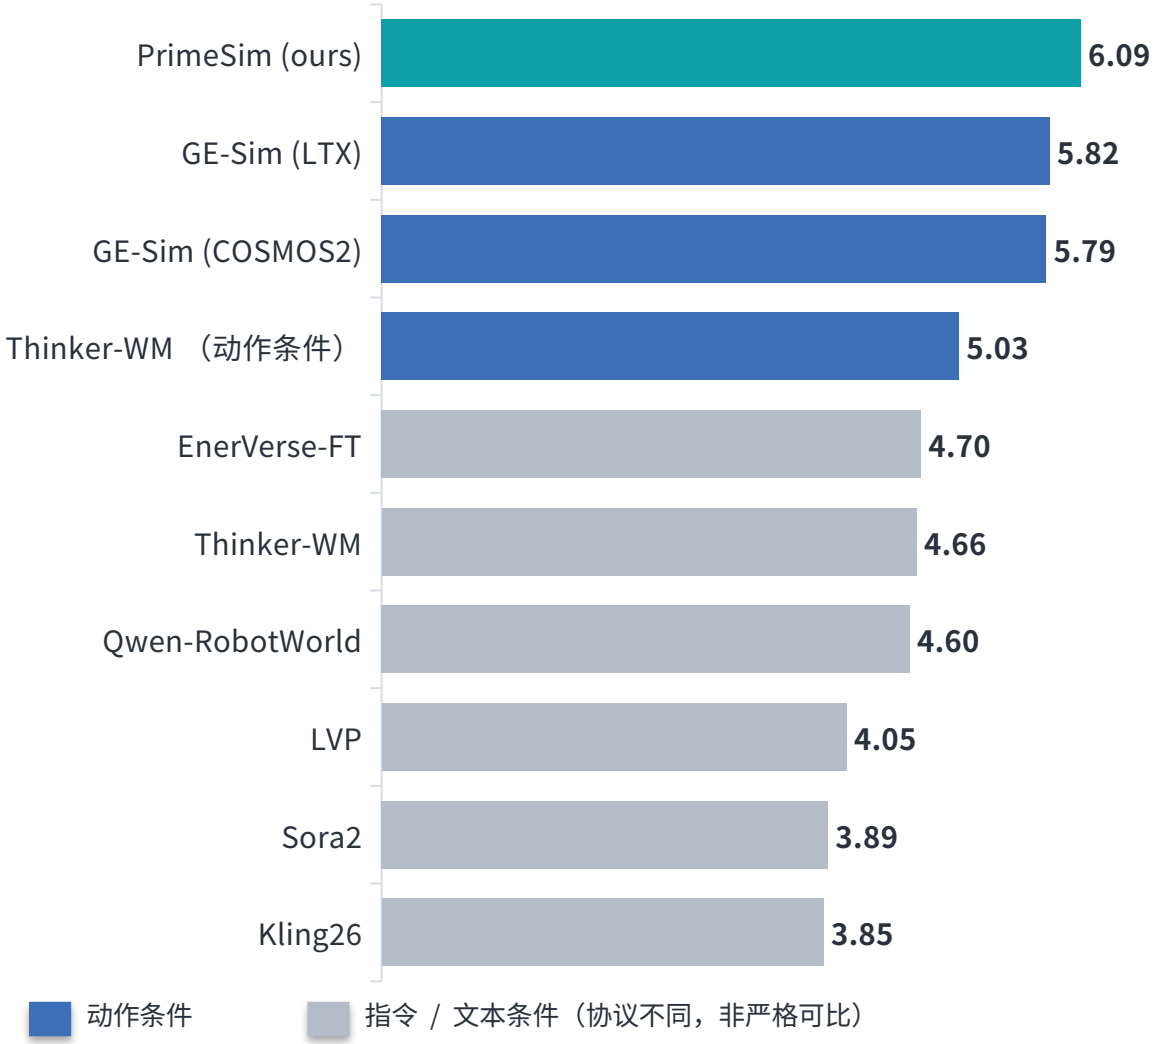

逐项对比： PrimeSim vs. GE-Sim (LTX)

维度	PrimeSim	GE-Sim (LTX)
SceneC 场景一致	**0.887**	0.900
HSD	**1.000**	0.940
Dyn	**0.666**	0.780
nDTW 轨迹对齐	**1.000**	0.980
Diversity	**0.010**	0.011
BLEU 动作语义	**0.570**	0.330
CLIP	**0.954**	0.908
Logics 逻辑一致	**1.000**	0.970

解读注意 AgiBot World 在训练语料中，且评测前在该数据上微调；使用 50 步 + CFG 1.5 （非 4 步模型），并探索了一小族采样设置；多项满分可能已饱和。

推理速度： 30.35 ViewFPS ，比同为 4 步三视角的 GE-Sim 2.0 快约 4.5×

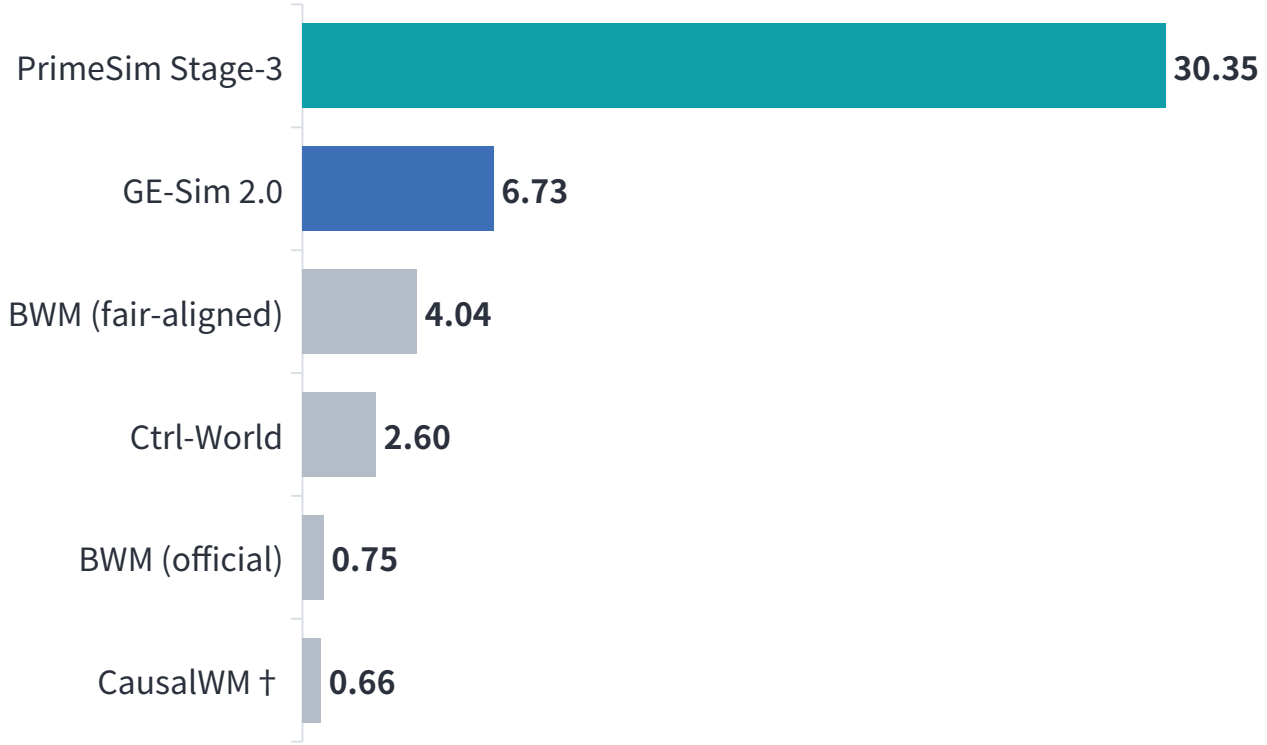

10.12
TempFPS
（时间步 / 秒）

3.16 s
每个 33 帧
三视角窗口

模型	视角	分辨率 / 视角	步数	TempFPS
PrimeSim	3	288×384	4	**10.12**
GE-Sim 2.0	3	384×512	4	**2.24**
Ctrl-World	3	192×320	50	**0.87**

比较前提（论文自述）

- 分辨率、预测长度、步数均未对齐，比较的是各自公开的推理配置
- 速度在 288×384 下测；质量评测用 192×256
- KV cache 增长后降到 7.63 TempFPS ；冷启动 6.41
- 只计世界模型分块生成，不含策略闭环
- †CausalWM 为文本 + 首帧条件，非动作条件

中训练学到可迁移的动作接口：新平台 100–200 步即可上手

xArm 7 · 中训练模型（200 步）

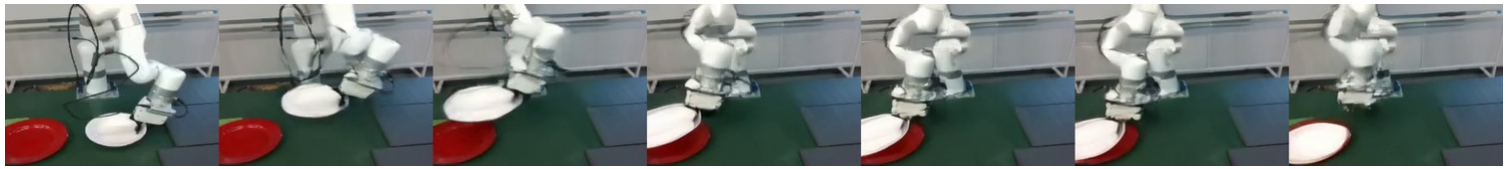

xArm 7 · 预训练骨干（2000 步，未达到）

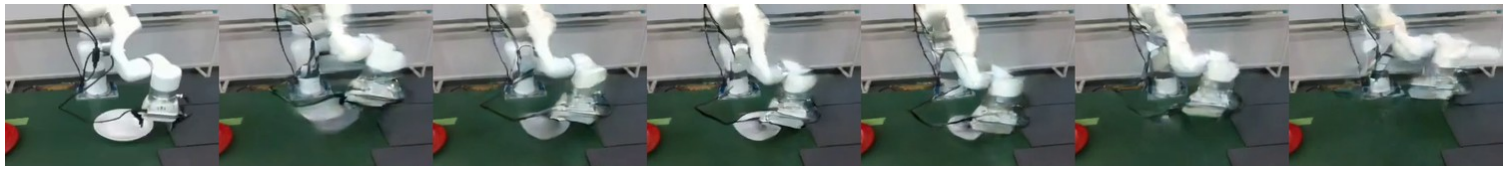

ViperX 300 · 中训练模型（100 步）

ViperX 300 · 预训练骨干（2000 步，未达到）

达到“动作跟随 rollout”所需步数

平台	中训练	预训练
xArm 7 （单臂）	**200**	2000 †
ViperX 300 （双臂）	**100**	2000 †
UMI 夹爪（手持）	**200**	2000 †

† 预算内未达到（Table 4）

- 同一配方： batch 1 、 lr 3e-5 ，无本体 ID 或专属参数
- 200 步参数仅移动约 10^{-2} ：是迁移而非重新拟合
- 预训练骨干需从零初始化动作 / 多视角模块，生成模糊、无合理接触
- **局限：**无法区分语料规模与“有动作接口”各自的贡献

新场景、新相机位零样本可用，微调 200 步追回大部分差距

(a) 零样本：能控臂、能渲染布料，接触复杂时布料状态漂移

(b) 微调 200 步：轨迹与布料形变贴近指令，三视角一致

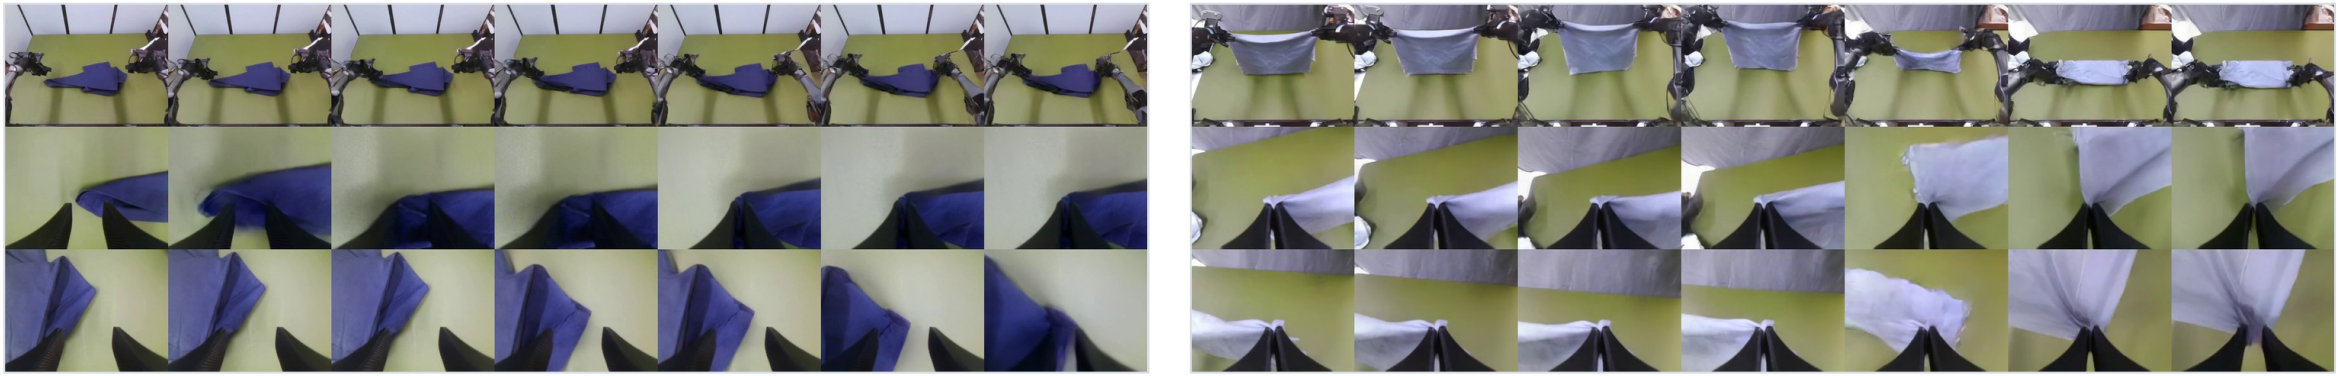

行：头部 / 左腕 / 右腕相机；列：单条 rollout 均匀采样 7 帧（AgileX Piper， XVLA 数据集，训练中完全未见）

−3.97 dB

PSNR： 19.79 → 15.82
（分布内 XR2 → 零样本 XVLA）

+0.105

LPIPS： 0.192 → 0.297
（越低越好）

评估三维度 动作可控性 · 物体运动合理性 · 跨视角一致性

协议 同一 checkpoint、50 步、seed 42、192×256、8 个验证窗口；SSIM 跨数据集不可比

结论 迁移的是“动作 → 视觉后果”的映射，而非机器人外观

当策略模拟器：评估排序与仿真器完全一致，内部 RL 的增益可迁回

(a) 策略评估：世界模型成功率 vs. LIBERO 仿真器成功率

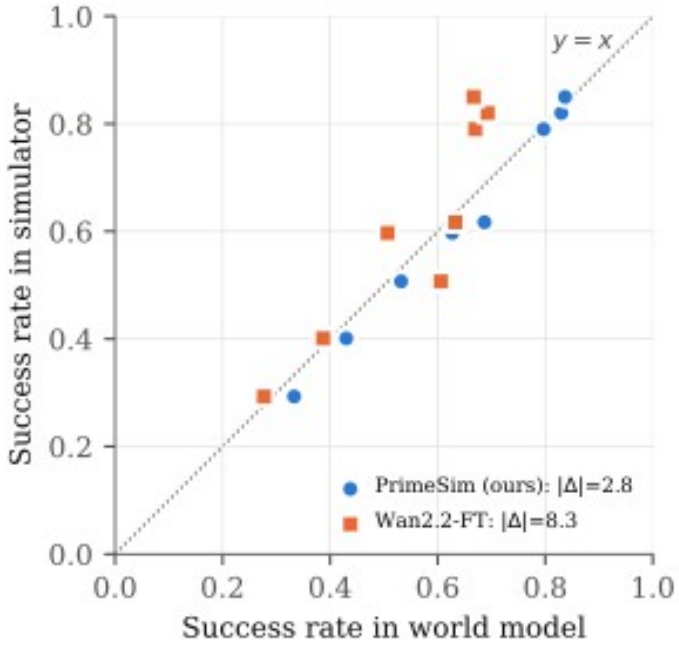

(b) 在 PrimeSim 内做 GRPO （组大小 8） 200 步

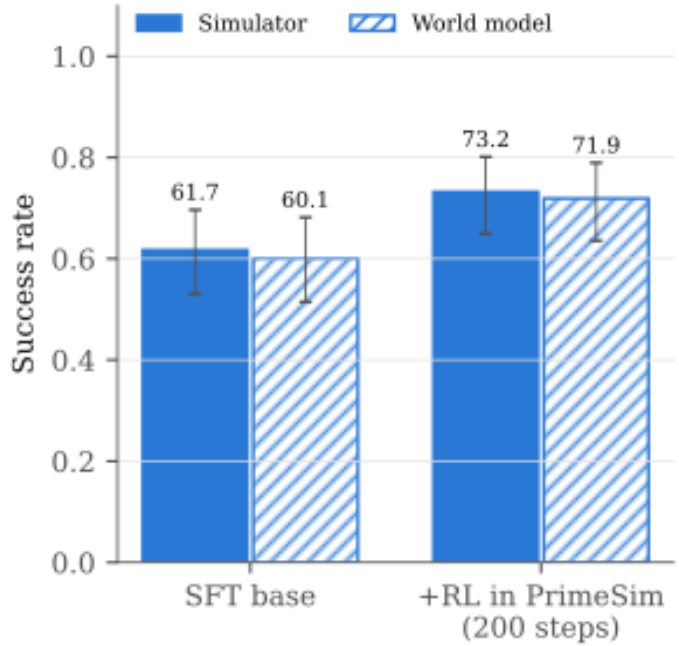

ρ=1.00
Spearman 排序

2.8 pt
平均绝对差
(Wan2.2-FT 8.3)

18.3 pt
Wan2.2-FT 对最强
策略的最大低估

61.7 → 73.2%
仿真器中的真实成功率

⩽ 1.6 pt
PrimeSim 估计与仿真器之差

定性结果：布料形变连续，反事实动作下静态场景保持稳定

布料操作（AgiBot G2 人形，头部视角， Fig. 13 ）

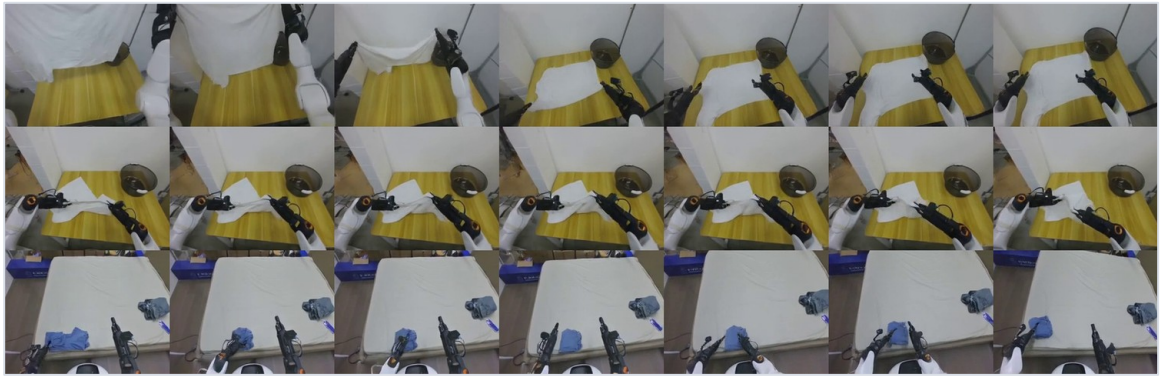

布料全程连续形变，且与下方桌面 / 床面可区分，没有“融进背景”

EWMBench：传送带取瓶并装箱（ Fig. 14 上）

EWMBench：把面包片放到吐司机旁的盘子上（ Fig. 14 下）

开环生成：首帧 + 指令 + 真值动作轨迹， 10 FPS ， 480×640 下评分

反事实动作跟随（ LIBERO ， Fig. 10 ）

动作序列不同于演示：机械臂按指令下探再抬起，柜子、碗等静态元素保持不动

反事实动作跟随（ LIBERO ， Fig. 10 ）

定性图只是辅助证据；定量的反事实检验见 WorldSimProbe T3 （ 72.3 ，第一）

局限与疑点

冷静看待：证据集中在仿真与行为层面，几处评测协议需留意

1 闭环证据仅在仿真

策略评估与 GRPO 都在 LIBERO （且 LIBERO 在训练语料中）；真机上能否替代真实交互尚未验证——作者自认最重要的局限

2 评测协议有利条件

WorldSimProbe 额外构造专门训练数据；EWMBench 同域微调后评测并探索采样设置， HSD / nDTW / Logics 满分可能已饱和

3 速度与质量配置分离

速度： 4 步、 288×384 ；质量： 50 步 + CFG 、 192×256 ；跨模型的分辨率、长度、步数均未对齐

4 分辨率与精细控制

192×256 / 视角，只主张模拟器保真度而非像素真实感； T1 局部动作校准落后 LingBot-VA

5 消融范围有限

仅单一本体、从预训练权重出发；动作条件只报 PSNR ；小样本迁移以“达到动作跟随所需步数”衡量，偏定性

6 文本细节不一致

Fig. 3 写 2.8M episodes 、 85:15 ，正文 / Table 12 为 1.52M 、 84:16 ；结论段的“三阶段课程”表述有笔误

总结

要点回顾：一套把视频模型工程化为机器人模拟器的完整配方

01 数据 + 接口

30,110 h 跨本体机器人数据 + 统一 31 维相对动作接口 → 可迁移的“动作 → 视觉后果”映射；新平台 100–200 步上手

02 轻量而有效的架构

帧对齐双路动作条件（掩码 + Adapter ） + 视角感知交错注意力（相机 token ）

03 快视频，慢记忆

4 步因果蒸馏 + 自滚动非对称 DMD + 自生成的层级 KV 记忆 → 10.1 FPS 、 60–105 s 稳定滚动

04 模拟器价值

WorldSimProbe 4/5 第一、 EWMBench 6.09 ； 策略排序 ρ=1.00 ， 内部 GRPO 增益迁回仿真器； 下一步： 真机验证

开源：模型权重 · 推理代码 · 训练代码 | 项目页： primebottech.github.io/PrimeSim-website