论文解读 · Physical AI / 持续学习

DRAP：按“物理放大风险”调节参数可塑性，让 VLA 不回放也能少遗忘

DRAP: Dynamics-Risk Adaptive Plasticity for Continual Learning in Physical AI

Oswaldo Ludwig

arXiv:2611.05029 · 首次提交 2026-11-03

代码： github.com/oswaldoludwig/DRAP-Dynamics-Risk-Adaptive-Plasticity

一句话总结：用物理风险加权的重要性，直接压低关键张量的学习率

DRAP 用专家轨迹拟合局部线性动力学，以 **σ_max(A_t)** 衡量“此刻出错会被物理放大多少”，以此加权逐样本动作梯度、累积成张量级重要性，再直接调小重要张量的 **AdamW 学习率**——全程不回放旧数据、不存参考权重。

0.77 → 0.31

学完 Goal 后的平均遗忘

标准微调 0.77 · KappaTune+EWC 0.63 · DRAP 0.31

0.55

学完 Goal 后的平均成功率

标准微调 0.26 · KappaTune+EWC 0.32

0.02

学完 Object 后 Spatial 的遗忘

标准微调 0.66 · KappaTune+EWC 0.35

问题：在物理 AI 中，小动作误差会沿轨迹滚雪球

一步动作
小误差 → 下一物理状态
偏离示范 → 观测落到
训练分布之外 → 后续误差放大
→ 闭环任务失败

顺序微调会覆盖旧技能；现有持续学习方案各有代价：

经验回放

效果强，但需存储或重新生成旧观测

扩展 / 路由（CLARE、Stellar VLA）

隔离任务，但要新增模块或路由机制

参数正则（EWC、SI、MAS）

保护旧解，但可能限制新任务学习

更新抑制（CLASSP）

按历史更新压低可塑性，大模型上可能过于保守

DRAP 的出发点：在动力学敏感的轨迹时刻支撑正确动作的参数，在后续任务中应当变得更“不可塑”。

方法全景： KappaTune 决定“改哪里”， DRAP 决定“改多少”

改哪里

① KappaTune 选张量

- 按条件数 $\kappa(W)=\sigma max/(\sigma min+\varepsilon)$ 打分
- 视觉 / 语言 / 动作头各选固定预算的低 κ 张量
- 只选一次，其余参数冻结

改多少

② 动力学风险 r_t

- 专家轨迹滑窗岭回归拟合 A_t, B_t
- $\rho_t = \sigma_{max}(A_t)$
- 中位数归一化，裁剪到 [0.25, 4]

改多少

③ 张量重要性 I_T

- 学完任务 k 后， batch=1 逐样本求动作 token 梯度
- r_i^2 加权的均方梯度
- 归一化后累加进历史记忆

改多少

④ 学习率调节

- $s_T = (1+\beta \bar{I}_T)^{(-1/p)}$
- $\eta_T = \eta \cdot s_T$ （AdamW 分组）
- 重要张量从新任务第一步起就小步更新

✓ 无需回放旧示范数据

✓ 无需保存参考权重 θ*

✓ 每个张量只存一个重要性标量

依据：论文第 VI 节、 Algorithm 1 、 Fig. 2 图注

风险信号：局部线性模型的 σ_max(A_t) 刻画一步扰动放大

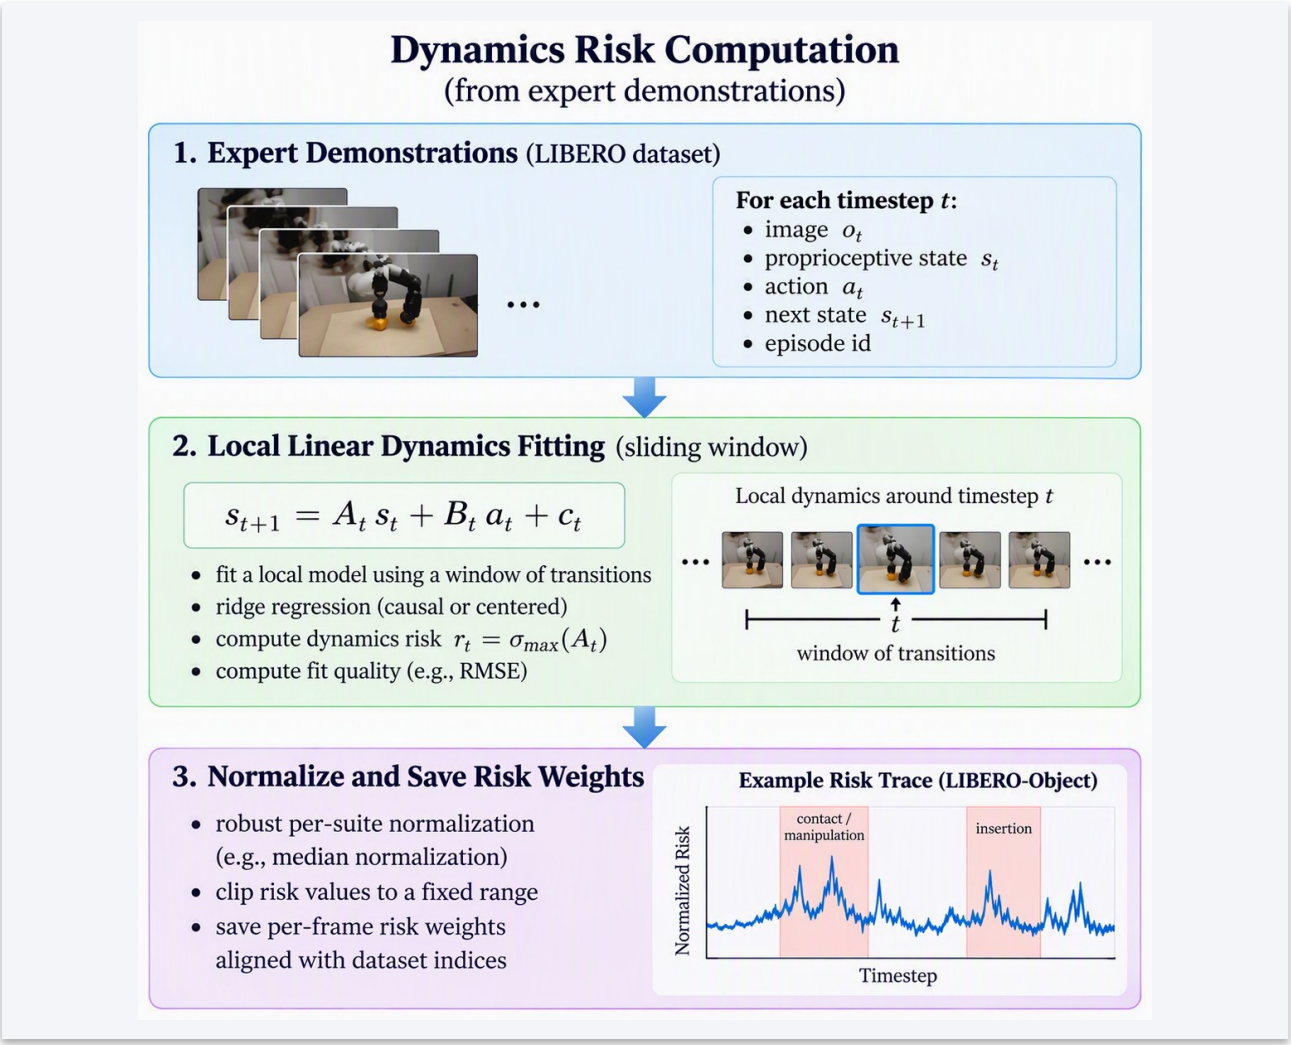

1 滑窗局部线性拟合（单个 episode 内）

$\tilde{s}_{j+1} = A_t \tilde{s}_j + B_t \tilde{a}_j + c_t$ （岭回归）

2 一步扰动能量上界（Lyapunov 启发）

$\delta s_{t+1} \approx A_t \cdot \delta s_t \Rightarrow V(\delta s_{t+1}) \leqslant \sigma^2_{max}(A_t) \cdot V(\delta s_t)$

3 归一化为样本权重

$\rho_t = \sigma_{max}(A_t)$， $r_t = \mathrm{clip}(\rho_t / \mathrm{median}\ \rho, 0.25, 4)$

示例曲线（LIBERO-Object）： 风险尖峰集中在“接触 / 操作”和“插入”阶段（示意图）。

注意： 只含状态项 A_t，不含策略反馈 $B_t \cdot J_\pi$；作者明确说明这不是稳定性证明，只是与策略无关的相对敏感度指标。

图：论文 Fig. 1；公式： Eq. (3)–(9)

重要性 → 可塑性：风险加权梯度直接决定每个张量的 AdamW 步长

1 逐样本动作损失

$$\ell_i(\theta) = \text{平均}_{q \in Q_i} \mathrm{CE}(\text{动作 token})$$

只取动作 token 位置，排除图像、语言、 padding

2 风险加权张量重要性

$$\hat{I}_T = (1/N_k) \Sigma_i r_i^2 \cdot \| \nabla_T \ell_i \|^2_F / n_T$$

batch=1 先平方再平均；除以 n_T 消除张量大小偏差

3 归一化 + 累积记忆

$$I_T^{(k)} = \gamma \cdot I_T^{(k-1)} + N(\hat{I}_{new})_T \ , \ \gamma = 1$$

$N(\cdot)$：除以正值中位数，去掉任务相关的整体尺度

4 转为学习率

$$s_T = (1 + \beta \cdot \bar{I}_T)^{(-1/p)} \ , \ \eta_T = \eta \cdot s_T$$

β 控制抑制强度， p 控制曲线形状

和 EWC 的关键不同

不惩罚位移： 不存 θ^* ，没有 $\| \theta - \theta^* \|^2$ 正则项

保护立即生效： EWC 惩罚在新任务起点为 0； DRAP 从第一步起就缩小步长

调的是优化器步长： 论文强调抑制的是实际 AdamW 步长，而非仅缩放原始梯度

代价： 重要张量仍可能经多次小步更新而累积漂移（Table I）

与 EWC / CLASSP 对比： DRAP 引入物理依据，状态最轻量

维度	EWC	CLASSP	DRAP （本文）
历史信号	旧任务梯度估计的对角 Fisher	累积梯度 / 更新量（幂次）	动力学风险加权的逐样本梯度
物理依据	无	无	**局部轨迹放大风险**
保护机制	Fisher 加权二次位移惩罚	更新分母 + 梯度阈值	**逐张量 AdamW 学习率**
参考权重	需要 θ*	不需要	不需要
保护何时生效	新任务起点为 0，随位移增大	立即	立即
重要性粒度	参数级	通常参数级	张量级（来自逐样本梯度）
存储状态	对角 Fisher + 参考参数	累积调整统计量	仅累积张量重要性
主要风险	Fisher 不准或正则过强限制学习	过度抑制阻碍新任务	重要张量仍可能累积漂移

依据：论文 Table I （节选）

评测协议：单个 checkpoint 跨三个 LIBERO 套件顺序学习，零回放

实验设置

- 模型： OpenVLA （7B，离散动作 token），只训练 KappaTune 选出的子网络
- 每阶段只能用当前套件数据，不存任何旧示范
- 每阶段结束评测所有已见套件 → 下三角成功率矩阵
- 汇总 6 次 Gym 评测 × 每次 50 个 episode
- 遗忘 F = 该套件历史最佳成功率 − 当前成功率（正值表示遗忘）

5 种对比配置

- 标准顺序微调
- KappaTune + EWC
- **KappaTune + DRAP （完整方法）**
- KappaTune + 均匀风险 DRAP （r_i = 1）
- DRAP 不用 KappaTune

主结果：学完 Goal 后， KappaTune+DRAP 成功率最高、遗忘最低

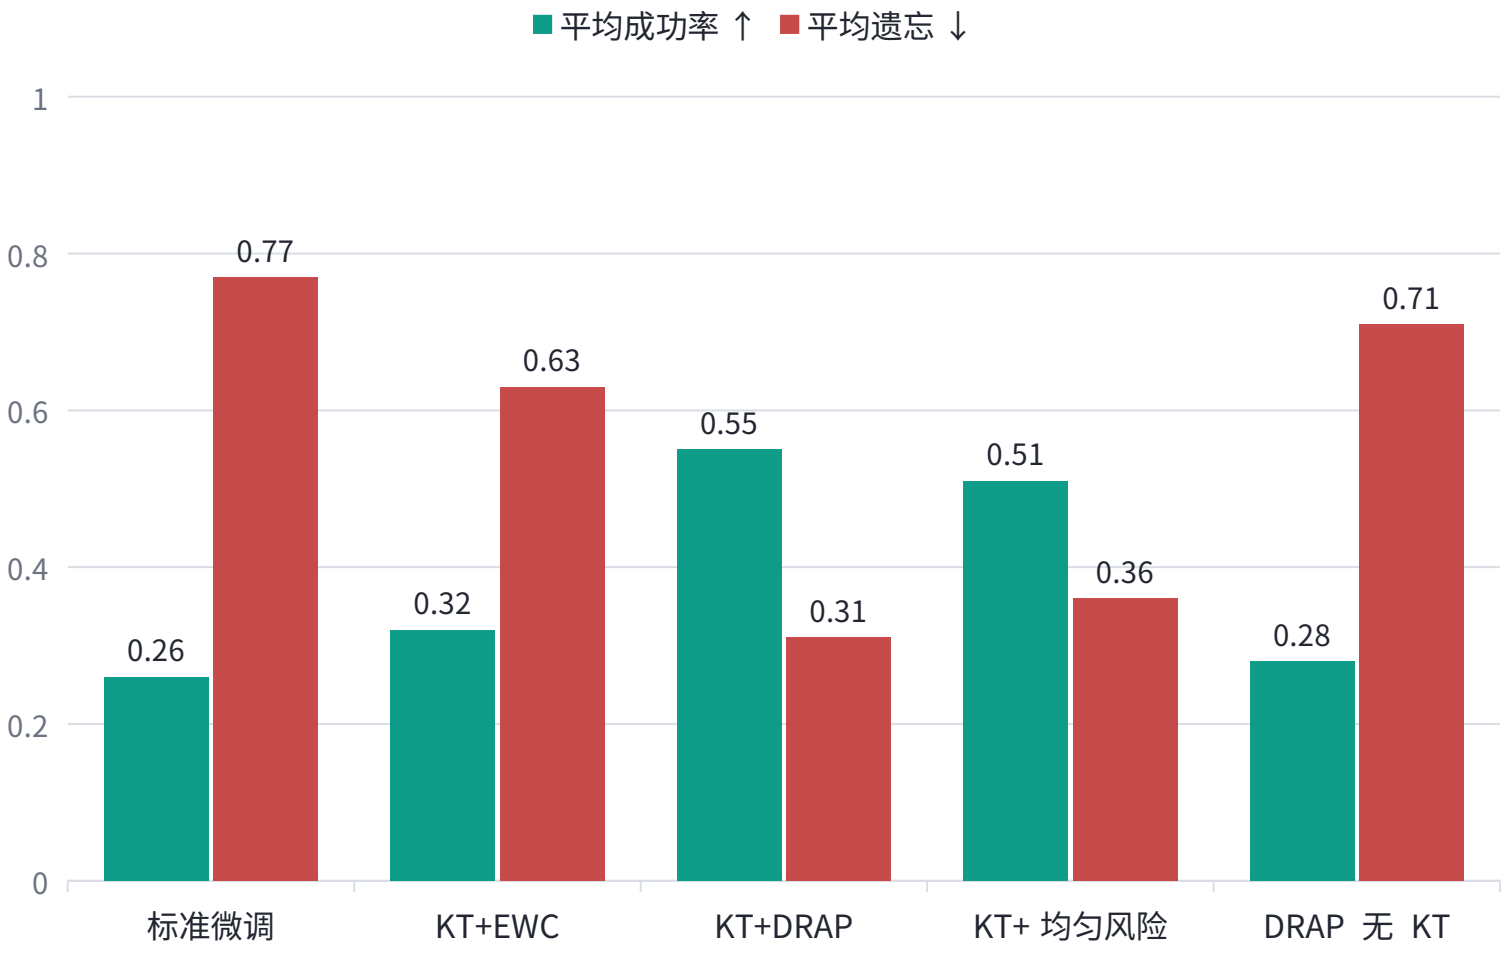

注： KT = KappaTune

读图要点

0.55 vs 0.32

平均成功率： DRAP 比 EWC 高 0.23

0.31 vs 0.63

平均遗忘：约为 EWC 的一半

0.71

Goal 新任务成功率与标准微调持平，未以牺牲学习换取稳定

数据来源：论文 Table III （学完 Goal 后）

成功率矩阵：标准微调只记得最新套件， DRAP 保住了大部分旧技能

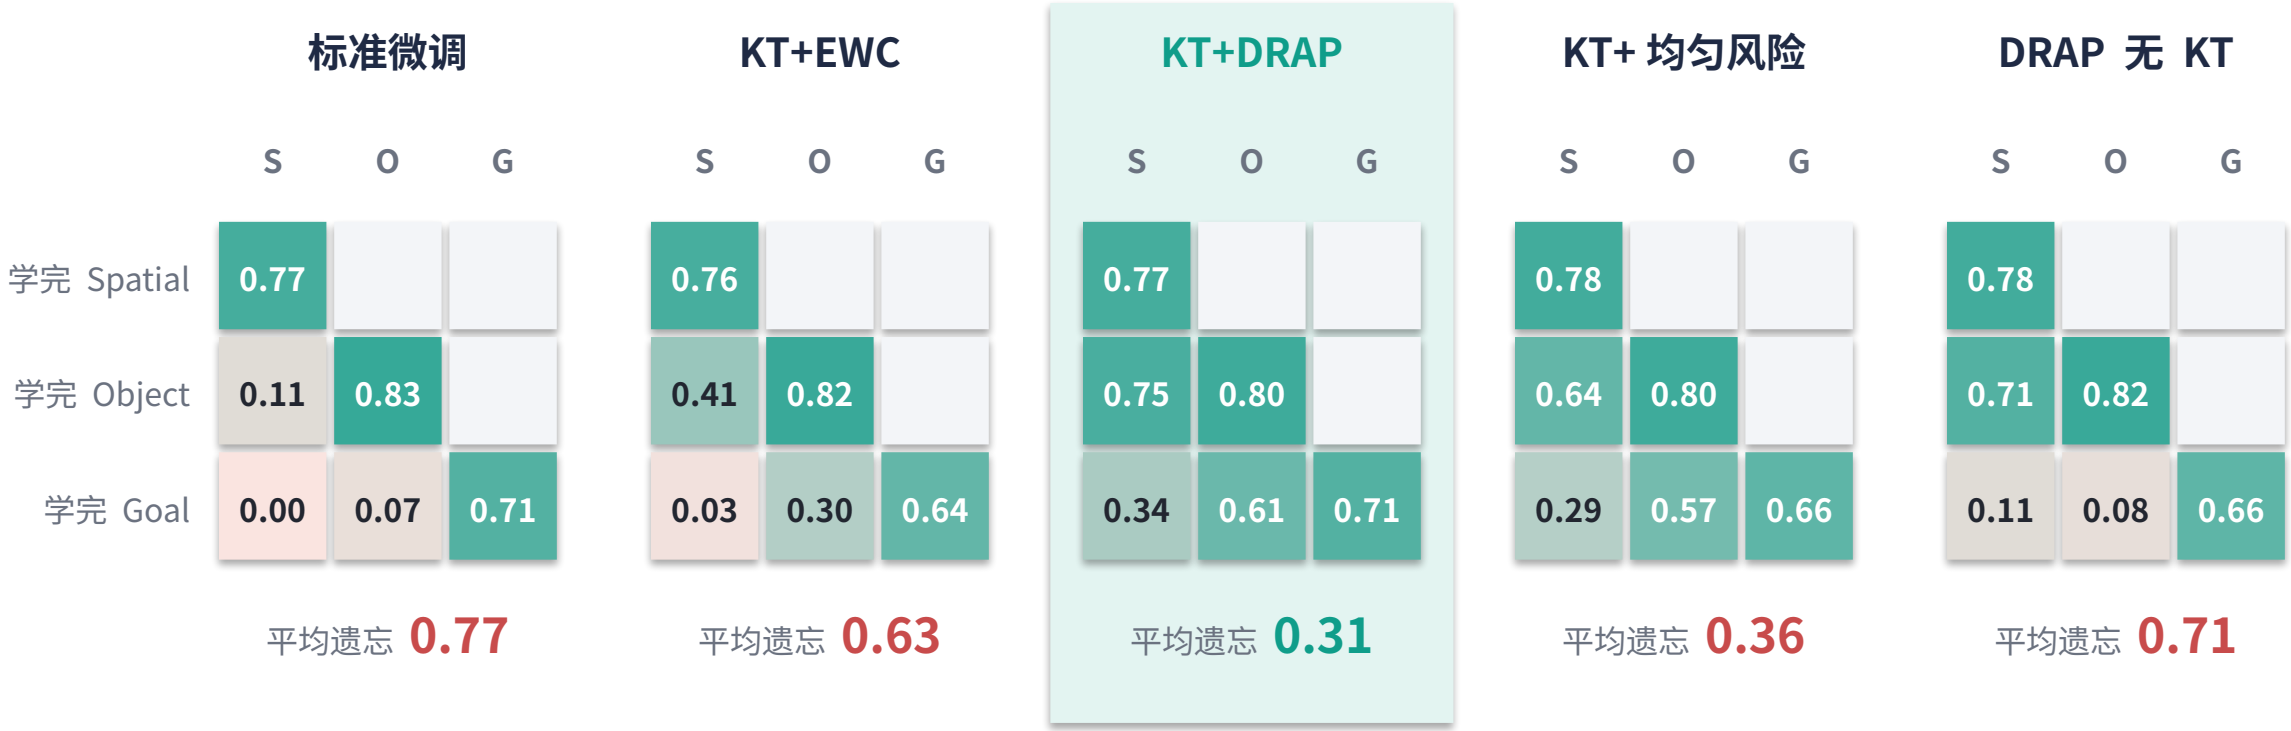

标准微调

学完 Object， Spatial 0.77→0.11；学完 Goal，旧套件 0.00 / 0.07

EWC

第一次切换尚能保留 Spatial 0.41，学完 Goal 后最早的 Spatial 只剩 0.03

KT+DRAP

学完 Object 后 Spatial 仍有 0.75；学完 Goal 后旧套件 0.34 / 0.61

数据来源：论文 Table II （6 次 × 50 episode 汇总）

消融： KappaTune 防止后期崩溃；物理风险加权再多保留一点

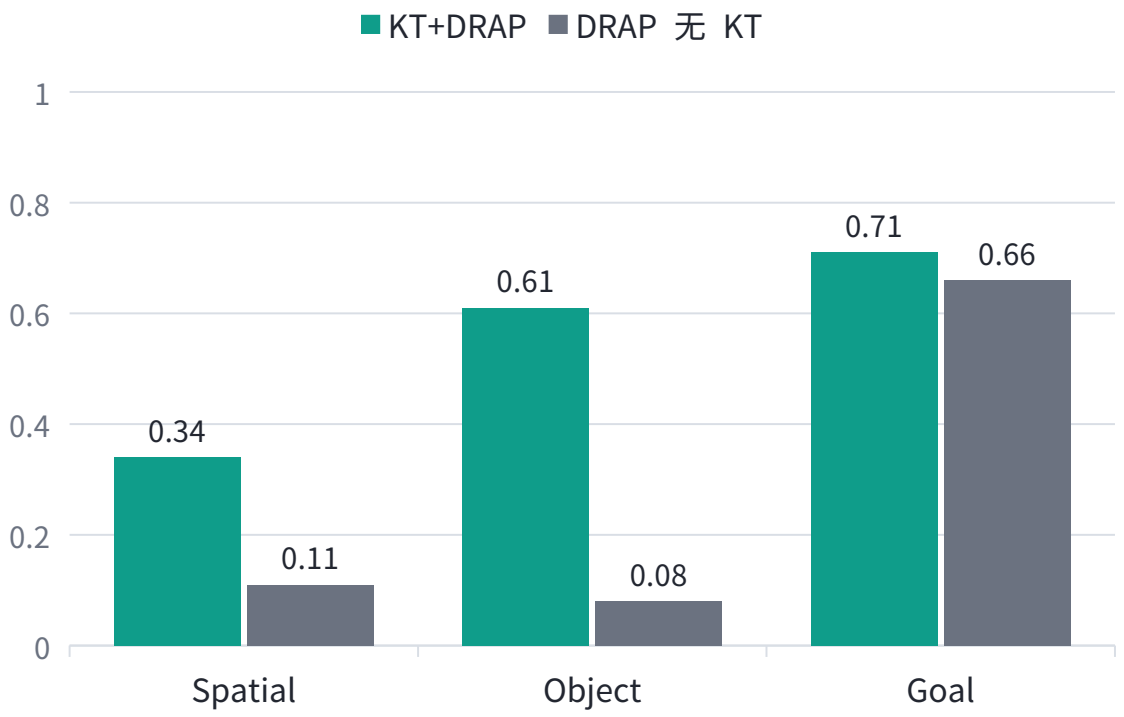

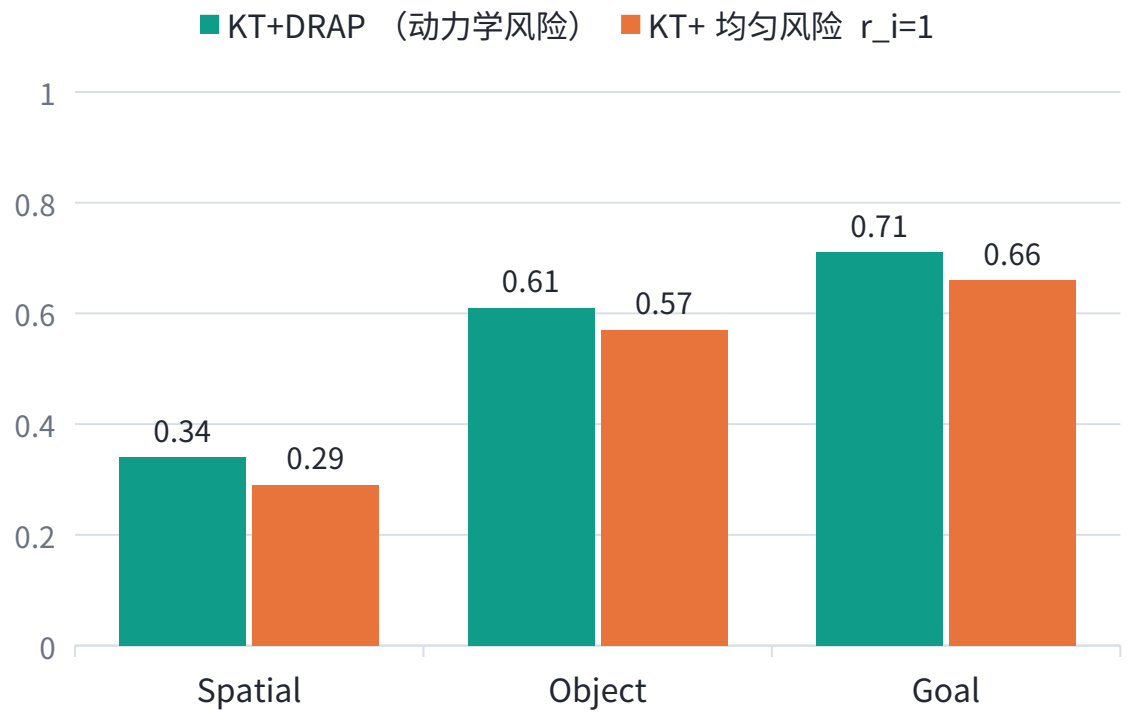

去掉 KappaTune： 学完 Object 时表现接近（平均成功率均为 0.77），但学完 Goal 后旧套件跌到 0.11 / 0.08，平均遗忘 0.71，接近标准微调。

→ 可训练参数空间越大，干扰路径越多； KappaTune 与 DRAP 互补。

风险全设为 1： 平均遗忘 0.36 （完整版 0.31），仍远好于 EWC 的 0.63。

→ 主要收益来自“重要性→学习率”机制；物理风险再带来约 0.04–0.05 的保留提升，新任务学习不受影响。

数据来源：论文 Table II、 III （学完 Goal 后）

客观评价：思路新颖且轻量，但物理风险的增益仍需更强证据

亮点

- 把“物理后果”引入持续学习的参数重要性估计，直觉清晰
- 实现轻量：每张量一个标量 + AdamW 参数分组，无需回放、无需参考权重
- 保护从新任务第一步生效，避免 EWC 起点处惩罚为零
- 跨套件（布局 / 物体 / 目标语义均变化）且零回放，设置有挑战性
- 坦诚说明风险估计的局限：不含策略反馈、仅一步、局部线性

局限与疑问

- 物理风险 vs 均匀风险仅差约 0.03–0.05，且只有一个任务顺序、无多训练种子
- 绝对遗忘仍不小： Spatial 0.77 → 0.34
- 基线少：未比较 CLASSP、SI、MAS、LoRA 类方法及少量回放上限
- 序列短（3 个套件），各阶段成功率约 0.7–0.8，低于单套件 SOTA
- 未定量验证 r_t 与实际失败位置的相关性；β、p 等超参与敏感性未在正文给出

要点回顾与未来方向

1. 物理 AI 的持续学习要同时看“模型敏感度”和“行为错误的物理后果”。

2. DRAP：风险加权梯度重要性 → 逐张量 AdamW 学习率；配合 KappaTune，平均遗忘 0.77→0.31。

3. 收益主体来自重要性驱动的可塑性控制，动力学风险提供额外的保留提升。

作者提出的未来方向

- **纳入控制通路 $B_t \cdot J_\pi$**
- **多步扰动传播**
- **接触感知 / 学习的局部动力学**
- **在线估计 + CLASSP 式更新阈值**
- **更长的持续学习序列**