论文解读 · arXiv 2611.05163

RoboTryOn

Synthesizing Dexterous Robot Demonstrations from Human Videos via Virtual Try-On

像“虚拟试衣”一样：保留人的动作，把人手换成机器人手，**从人类视频合成可训练的灵巧手机器人示教**

Seungyong Lee, Suhyeok Jang, Minyoung Kim, Jinwoo Shin

KAIST · RLWRLD · Korea University | 首次提交 2026-11-03

一页看懂：人类视频 → 机器人视频 → 动作标签 → 策略学会新任务

2.1% → 60.0%
7 个无机器人示教新任务，两台机器人平均
（仅遥操作 → 遥操作 + 合成）

45.9%
双臂任务平均成功率
而所有遥操作示教都是单臂

≈ 1/3 成本
仅人类视频匹配 50 条 / 任务遥操作
（1.87 vs 5.26 人时）

一句话总结

RoboTryOn 把人到机器人的迁移当作**虚拟试衣**：自回归翻译关键帧 + 手部骨架引导的视频插帧生成目标机器人视频，再用**逆动力学模型（IDM）**从生成视频读出关节动作；生成模型只用机器人数据训练，无需人 - 机配对数据。

① 关键帧翻译
图像模型把遮罩后的人类关键帧
“修补”成机器人关键帧

② 视频合成
视频模型在关键帧之间插帧
手部骨架流提供运动引导

③ 伪动作标注
IDM 从生成视频预测关节动作
腕部用人手重建 + IK 修正

④ 策略训练
合成示教与遥操作同格式
微调 π0.5 / RLDX-1-Img

问题：人类视频便宜，但对灵巧手存在“视觉”与“动作”两道鸿沟

视觉鸿沟

训练时画面里是人手人臂，部署时是机器人。

已有方法： EgoMimic 遮掉手臂、Masquerade 叠加渲染机器人 —— 部署时必须对实时相机画面做同样编辑。

动作鸿沟

人手重建本身不准；人手与机器人手形态 / 运动学不同，不存在精确重定向映射。

即使形状映射完美，也不知道该抓多紧。

为什么值得：采集成本差 5–6 倍（ Table 10 ）

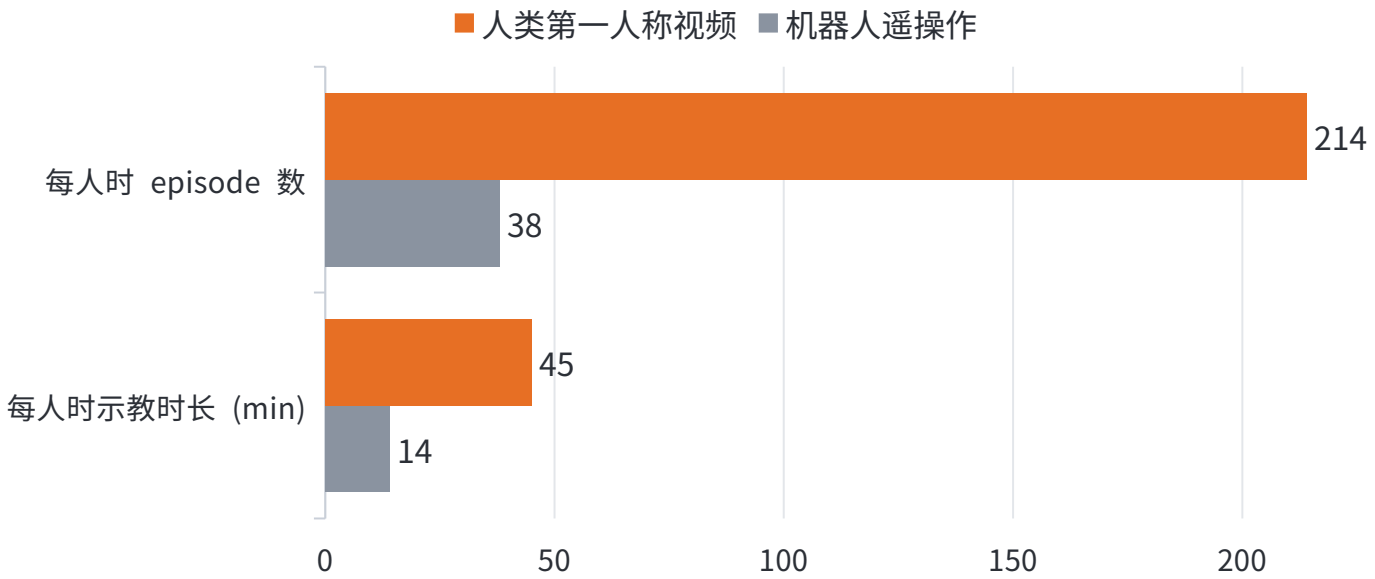

- 遥操作： 2 人 / 场次、需机器人 + 遥操作系统 + 训练有素的操作员，双臂开销高
- 人类视频： 1 人 + 固定相机，不占用机器人，双臂无额外开销
- 目标：让新任务“只录人类视频”就能学会

核心思路：像虚拟试衣一样“保留动作、更换执行者”

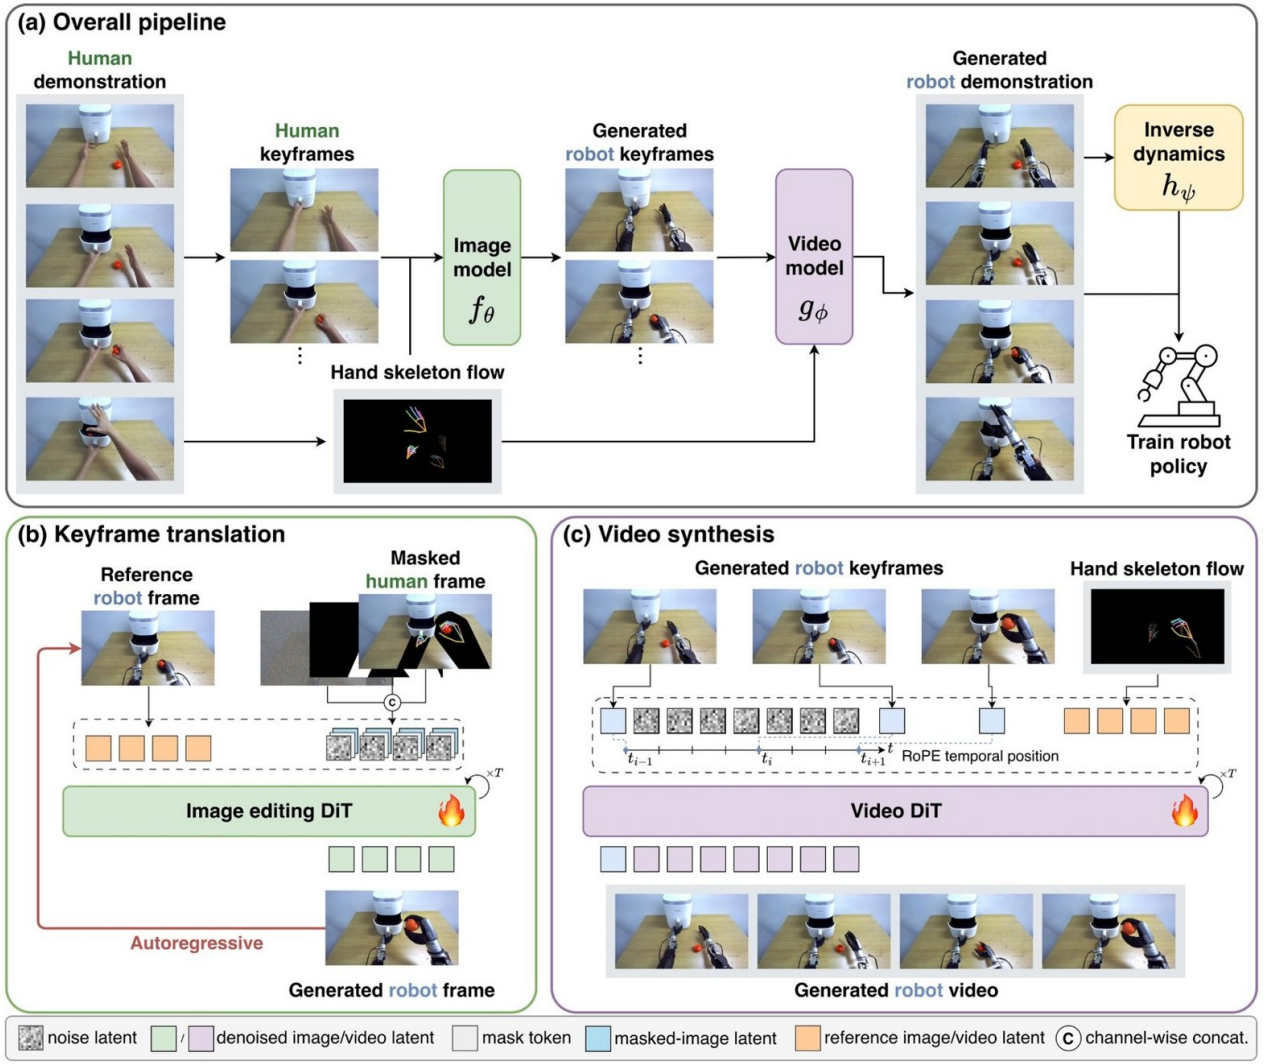

三段式流水线

(a) 人类关键帧 → 图像模型 f_θ → 机器人关键帧 → 视频模型 g_ϕ （+ 手部骨架流）→ 机器人视频 → IDM h_ψ → 动作

(b) 关键帧翻译 以“上一张机器人关键帧”为参考，对遮罩后的人类帧做修补；结果自回归地作为下一帧参考

(c) 视频合成 关键帧按 RoPE 时间位置放入，骨架流作 in-context token，生成中间帧

训练只用机器人数据： 机器人帧同样被遮罩 + 画骨架，推理时换成人类帧的遮罩与骨架即可

关键设计：用“与执行者无关”的条件接口，避开配对数据与重定向误差

遮罩 + 骨架 条件

- 遮罩放大并平滑，轮廓不泄露被遮住的是人还是机器人
- 17 点手部骨架统一人手 / 6-DoF / 20-DoF 机器人手
- 训练时骨架扰动（≤半个指节）、整体丢弃 p=0.2 、单点丢弃 p=0.2 → 只作粗引导

关键帧与长视频

- 关键帧：双腕速度局部极小（手不模糊）且位移超阈值；首尾必选
- PnP 约 4 个关键帧，长任务 6–7 个
- 每段 ≤ 145 帧（约 7.25 s），相邻段共享边界关键帧，可合成 10–25 s 示教

IDM 伪动作标注

- Depth Anything V2 主干 + flow-matching 动作头
- 输入相隔 1 s 的两帧 → 20 步关节动作块，滑窗平均 + S-G 平滑
- 腕部平移用人手重建 + IK 修正，手指关节保留 IDM 预测

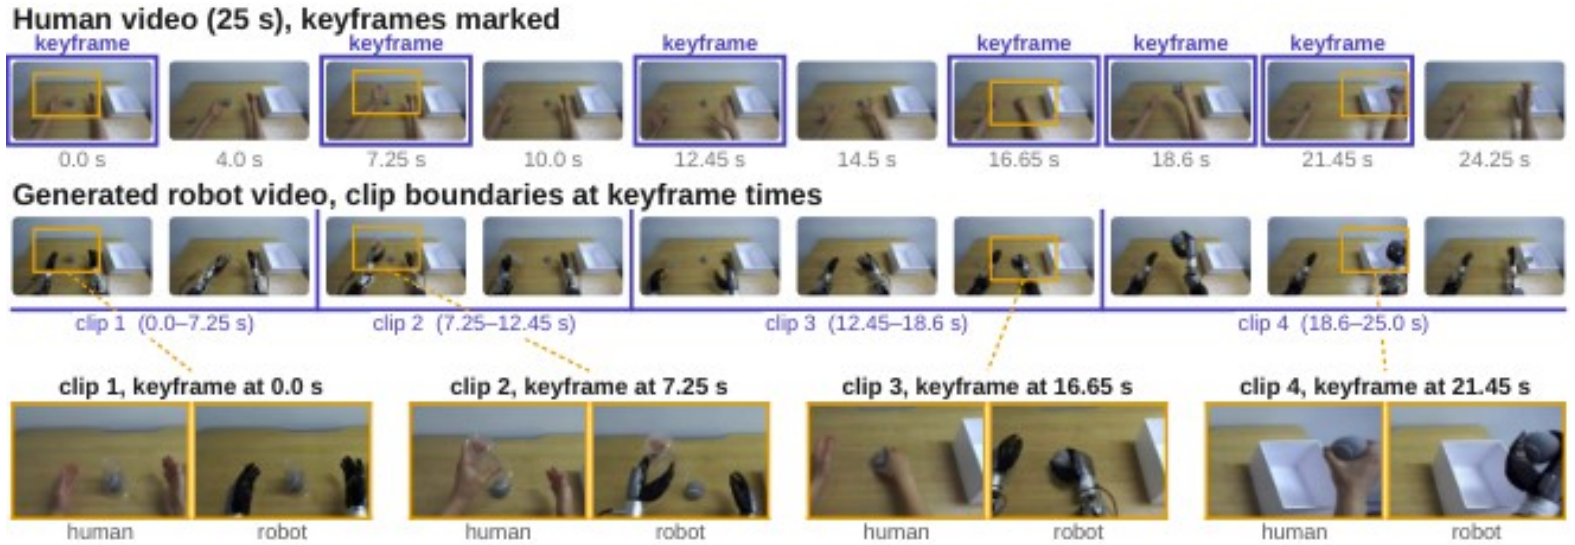

来源：论文 §3、附录 B.2、 Figure 14

实验设置：两台双臂灵巧手人形机器人，11 个真实桌面任务

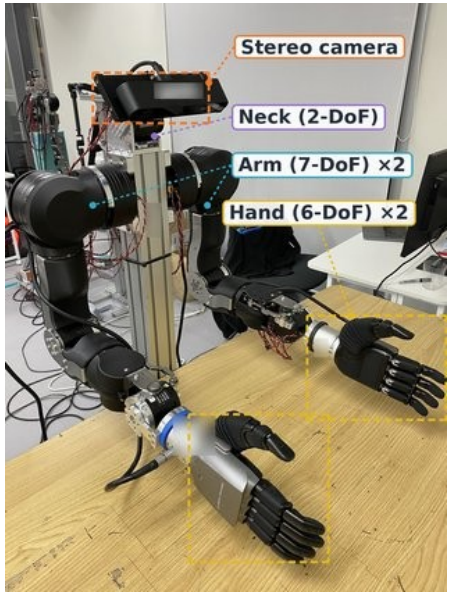

OpenArm
7-DoF 臂 + 6-DoF Inspire 手

RB-Y1
7-DoF 臂 + 20-DoF WujiHand2

- 头部双目相机，颈部 / 底座固定；人类视频在机器人头部相机位置录制
- 策略： π0.5 微调 30k 步； 200 条遥操作 / 550 条合成 / 合计 750 条
- 每任务 28 次试验，物体位置随机

域内 4 个 PnP 任务

Bottle / Doll / Box / Ball
各 50 条遥操作 + 50 条人类视频

域外 7 个任务（仅人类视频）

新物体 Coffee Pot · 新目标 Bottle to Shelf
新技能 Pouring / Brushing
双臂 Box Convey / Air Fryer / Ball in Cup

来源： Figure 7 、 Figure 8 、 § 4.1

主结果：基线在新任务上几乎全军覆没，RoboTryOn 让策略真正学会

域外 7 任务平均成功率（%）

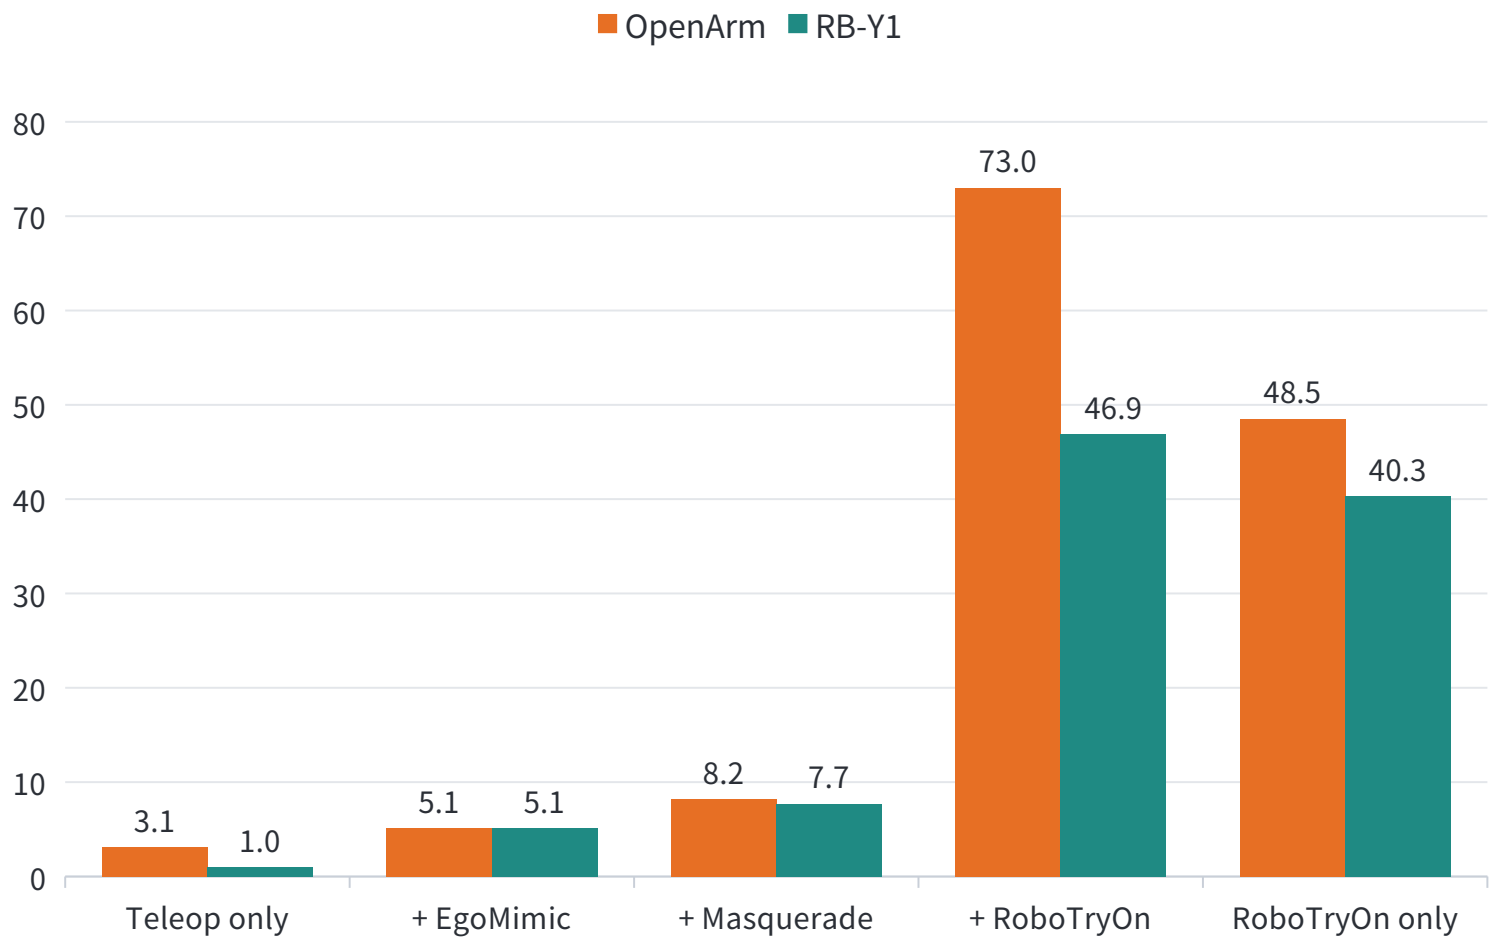

域内 4 任务平均（%）

	OpenArm	RB-Y1
Teleop only	47.3	69.6
+ Masquerade	67.9	63.4
+ RoboTryOn	**75.9**	**79.5**

< 10%

两个基线在域外任务上的平均成功率
（重定向动作 + 测试时画面编辑）

40–49%

完全不用遥操作数据训练策略
（仅 RoboTryOn 合成数据）的域外成功率

来源： Table 1 / Table 11 （成功率 %，每任务 28 次）

逐任务看：新物体、新目标、新技能乃至双臂协作都能学会

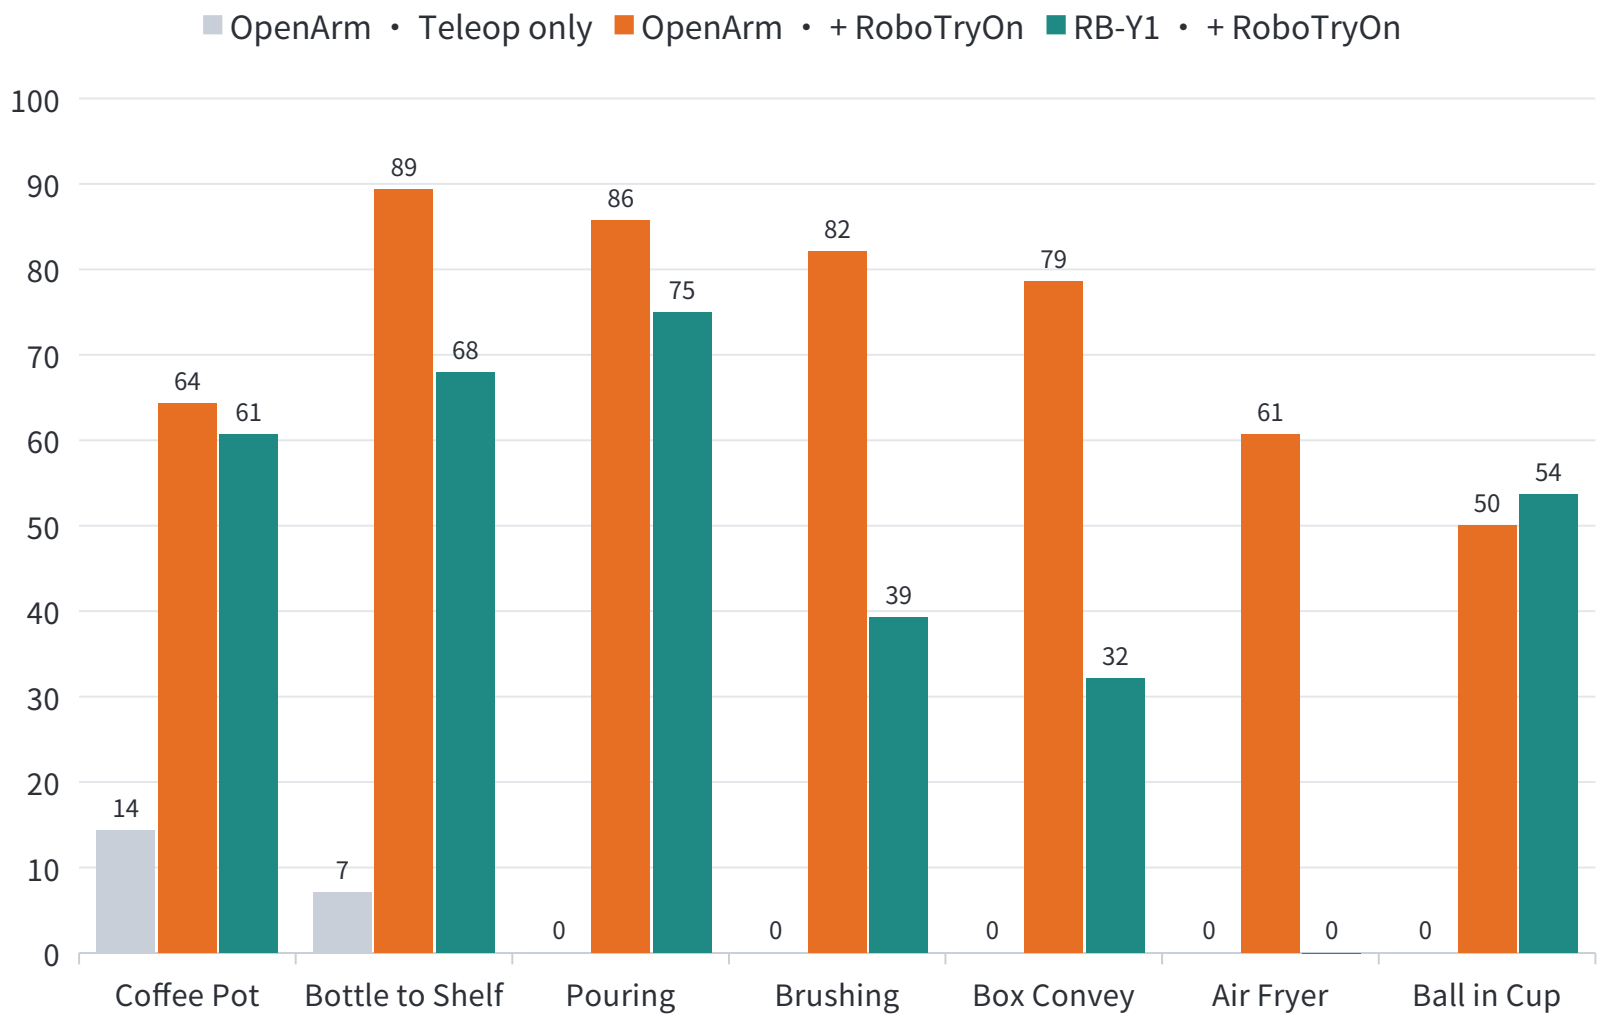

读图要点

单臂遥操作 → 双臂策略： OpenArm 三个双臂任务 78.6 / 60.7 / 50.0

RB-Y1 Air Fryer = 0%： 需要把手指插入把手与机身之间，超出遥操作数据与 IDM 标注精度；20-DoF 长手指关门时易推走炸锅

双臂评分： 每只手完成各计 0.5 分，含部分得分

统计提醒： 每任务 28 次，单任务数值波动约 ±9 个百分点

来源： Table 11 （域外任务，成功率 % ）

视觉鸿沟：合成画面最接近真实机器人，部署时无需编辑相机画面

原始人类视频 | EgoMimic （遮罩） | Masquerade （叠加渲染） | RoboTryOn （合成） | 真实遥操作

与真实机器人帧的 Fréchet SigLIP 距离（越低越接近）

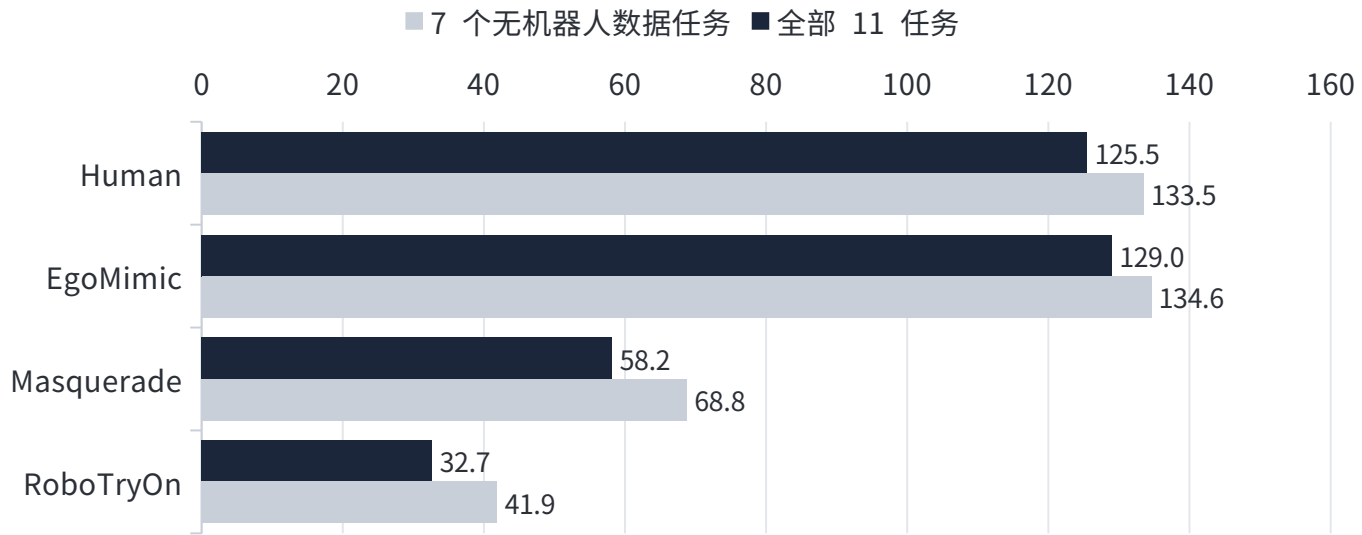

125.5 → 32.7

RoboTryOn 把与真实机器人帧的距离降到约 1/4；叠加约减半，遮罩基本不变

- 特征来自 π0.5 的 SigLIP 视觉编码器
- 7 个无机器人数据任务上仍只有 41.9 → 不是在复现训练集
- 基线只能靠部署时对每帧做同样遮罩 / 叠加来缩小差距

来源： Figure 3(a) 、 Table 7 （ Fréchet SigLIP 距离）

动作鸿沟： IDM 从生成视频“读”出的动作比重定向更可执行

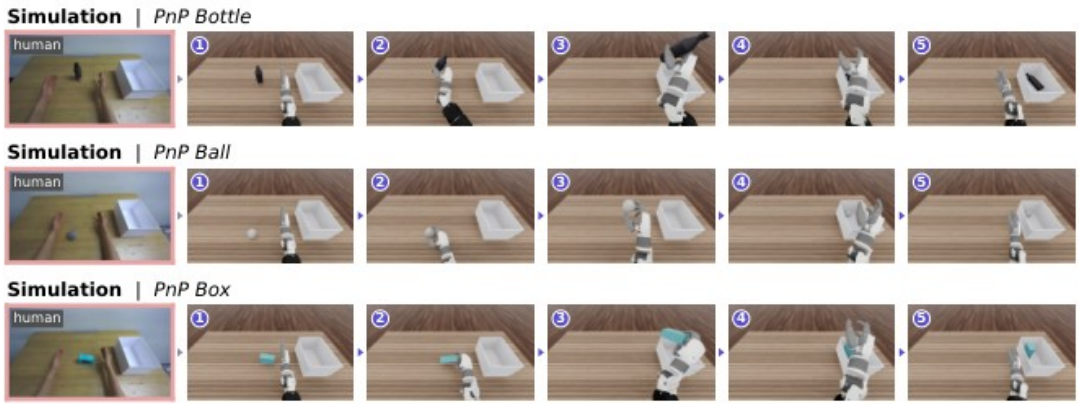

Isaac Lab 场景复刻：人类视频 → 开环回放（抓取、抬起、放入）

仿真开环回放成功率（%），每任务 22 条

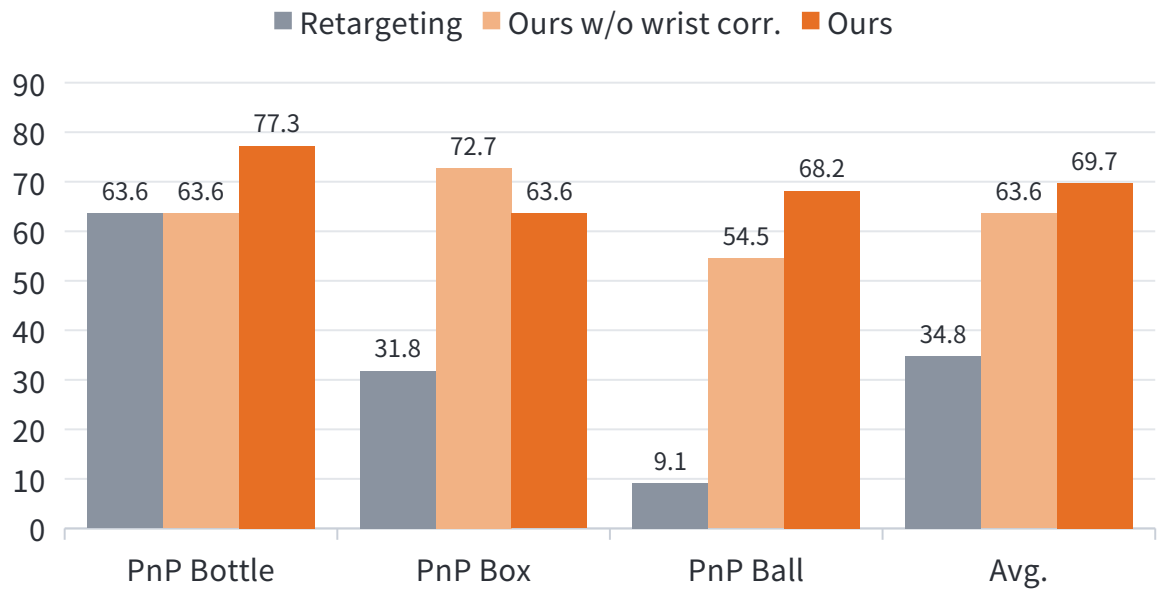

69.7% vs 34.8%

回放成功率： IDM 标签 vs 重定向标签
差距主要出在抓取阶段

0.53 vs 0.17 / 0.14

与遥操作数据的策略梯度余弦相似度
（ Ours vs EgoMimic / Masquerade ）

- 重定向：手能到物体附近，但重建误差与手形差异导致抓不牢
- 重定向数据在 action expert 上梯度余弦略为负 → 与遥操作数据冲突
- 真机 rollout： 基线域外手部动作偏离遥操作分布，Ours 保持贴近

来源： Figure 4 、 Figure 5 、 Table 8 、 Figure 9

成本：人类视频单条略弱，但按人时计算性价比高得多

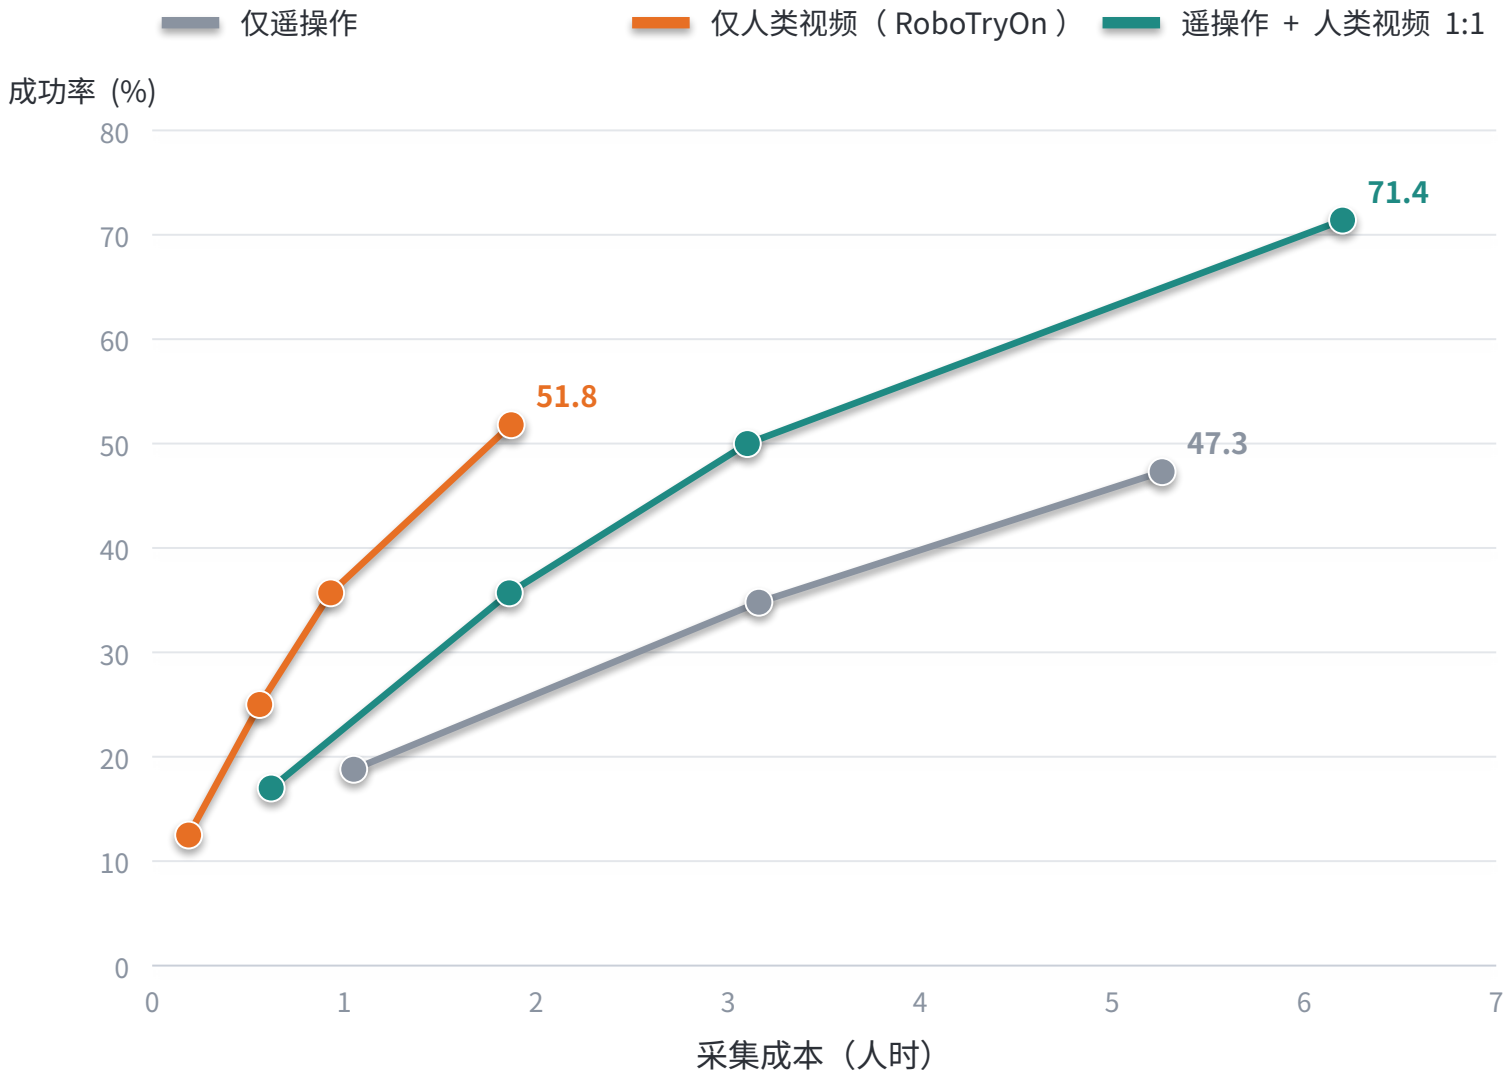

51.8% @ 1.87h

仅人类视频（100 条 / 任务）
≥ 遥操作 50 条 / 任务的 47.3% @ 5.26h

71.4%

遥操作 + 人类视频 1:1（各 50 条 / 任务）
总计 6.20 人时

- 同为 50 条 / 任务：人类视频 35.7% vs 遥操作 47.3%
- 人时未计入：每台机器人一次性的数小时遥操作（训练生成模型 /IDM）与 GPU 合成算力

来源：Figure 6、Table 9（4 个 PnP 任务，112 次试验）

消融：手部骨架流最关键，每个组件都不可或缺

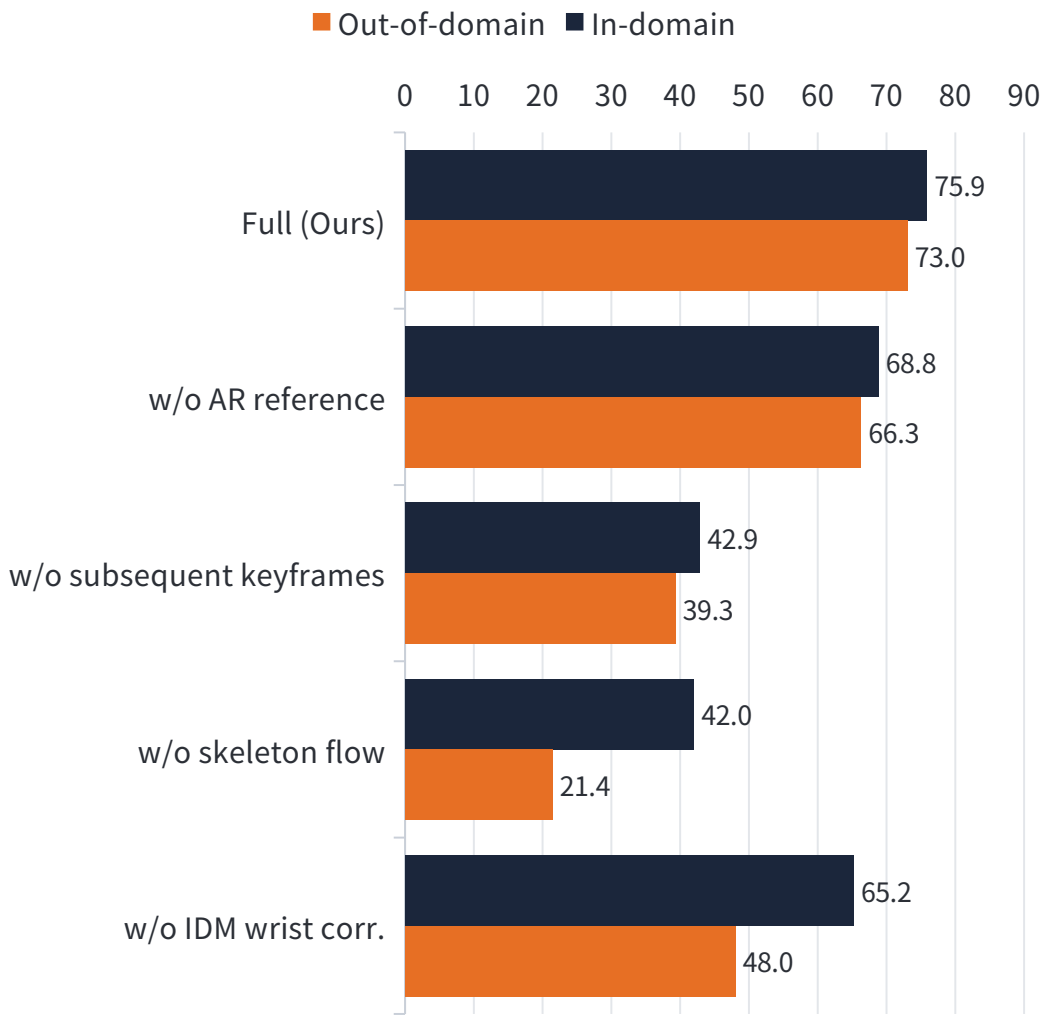

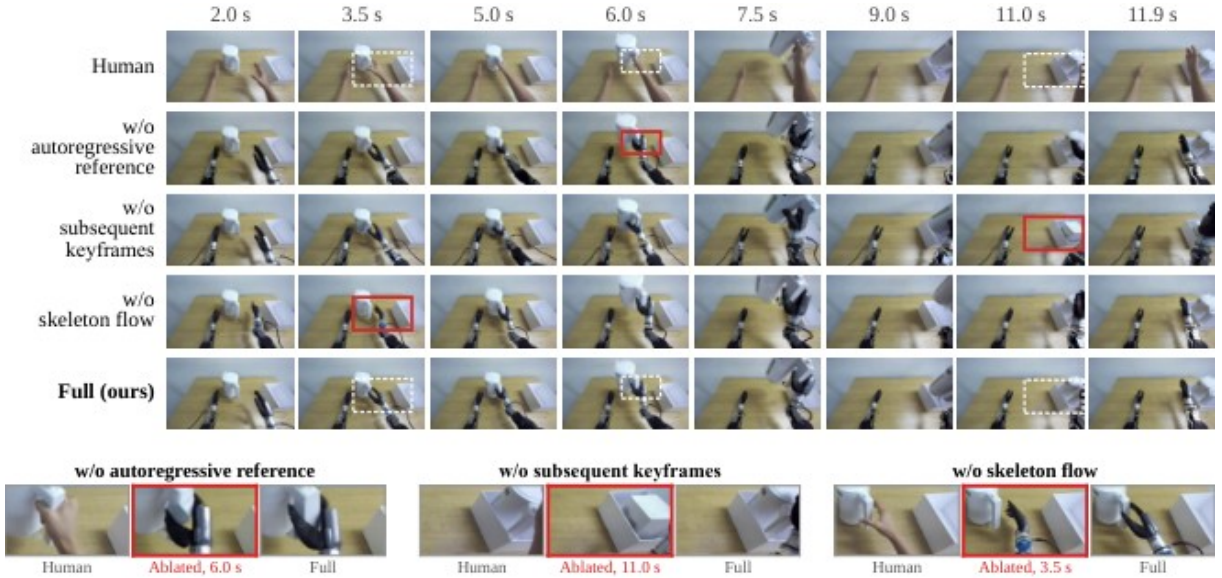

w/o 骨架流：中间帧无运动引导，不再跟随示范者（域外 21.4% ）

w/o 后续关键帧：动作保留但物体漂移，咖啡壶在 11 s 变成了盒子

w/o 自回归参考：相邻关键帧抓握构型不一致，手部抖动

w/o 腕部修正：域外跌幅更大（ 73.0→48.0 ），新动作超出 IDM 训练分布

来源： Table 3(a) 、 Figure 11 （ OpenArm ， π0.5 ）

两个实用发现：策略继承示教速度；换 VLA 主干依然有效

执行速度（retiming 骨架流后重新合成）

数据	速度	域内	域外	用时（s）
Teleop only	1×	47.3	3.1	14.2
Ours （原速）	1.25×	75.9	73.0	11.9
Ours （retimed）	**1×**	**85.7**	**70.4**	**13.8**
Ours （retimed）	2×	57.1	42.9	7.4

- 人类示范约为遥操作的 1.25× 速度
- 按阶段把骨架流重定时到 1×：域内 75.9 → 85.7，域外基本持平
- 2× 最快但成功率明显下降 → 策略继承训练示教的速度

策略主干：π0.5 与 RLDX-1-Img

策略	域内	域外
π0.5 （Teleop only）	47.3	3.1
+ RoboTryOn	**75.9**	**73.0**
RLDX-1-Img （Teleop only）	53.6	0.0
+ RoboTryOn	**60.7**	**40.3**

- RLDX-1-Img 采用 GR00T N1 式独立动作头，架构与 π0.5 不同
- 域外 0.0 → 40.3：合成数据的收益不依赖特定 VLA

来源：Table 2、Table 3(b)（OpenArm）

一套模型、多种机器人：同一段人类视频只换执行者

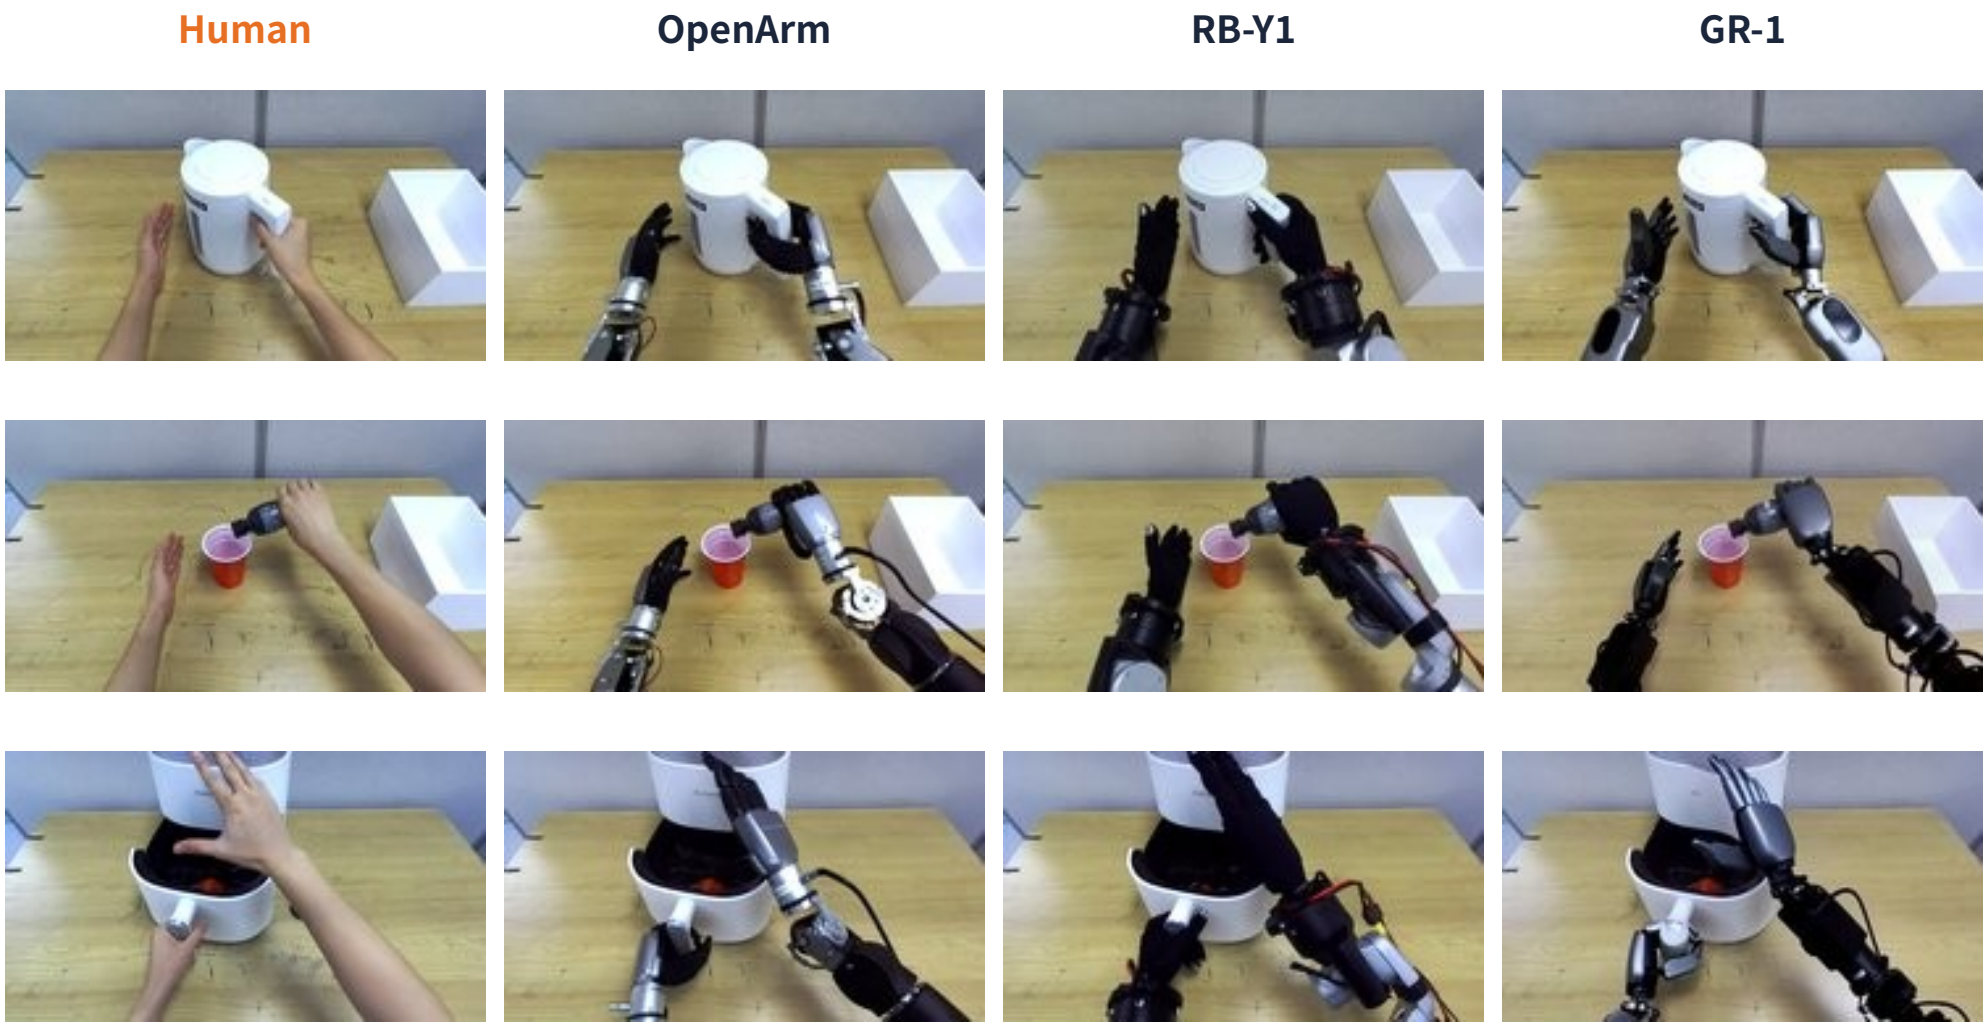

同一套图像模型 + 视频模型 + IDM

训练语料：OpenArm 3.79 h 、RB-Y1 2.53 h 、GR-1 2.50 h 遥操作

GR-1 仅做视频翻译，未做真机策略评测

局限：生成与伪标签会出错，且依赖受控视角和机器人先验

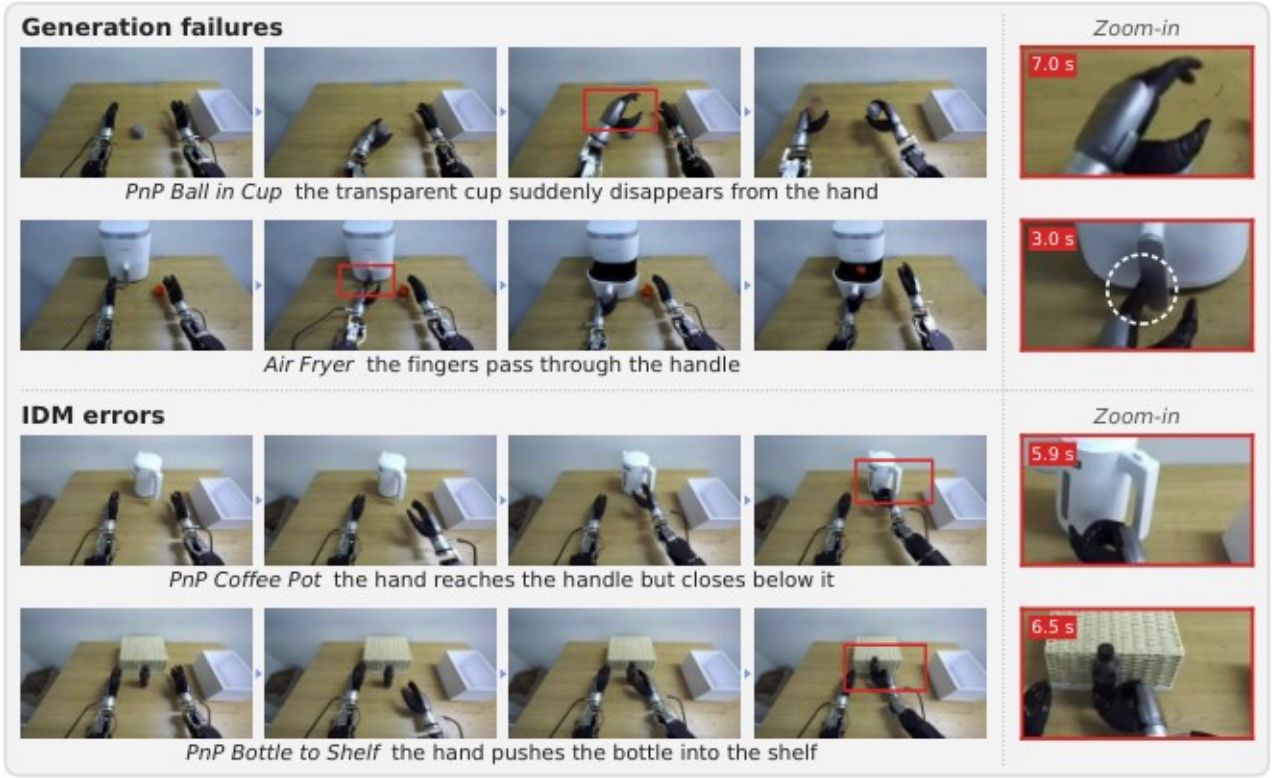

仍需机器人数据

每台新机器人需数小时遥操作（任意任务）训练生成模型与 IDM；且训练语料含 4 个域内任务的遥操作示教

固定视角

人类视频在机器人头部相机位置录制、颈部 / 底座固定； in-the-wild 移动视角视频超出分布

伪标签精度

无法表达力；紧配合插入等精细任务不够准；腕部修正依赖相机标定

算力换人力

15 s 示教在单张 H100 上约 695 s （≈ 11.6 min ）

可执行性

能重定时，但无法修正机器人够不着或手做不出的抓握

来源： Figure 15 、附录 A 、 Table 6

总结：换外观、保动作、读动作

换外观

生成式“虚拟试衣”
遮罩 + 骨架接口，只用机器人数据训练，无需配对；部署时直接用原始相机画面

保动作

自回归关键帧 + 骨架流引导插帧
场景、物体与示范者运动保持一致，支持 10–25 s 长示教

读动作

IDM 从生成视频读关节动作 + 腕部 IK 修正
比重定向更可执行，梯度方向与遥操作一致

带走的结论

- 对高自由度灵巧手，“生成机器人视频 + IDM 标注”比“遮罩 / 叠加 + 重定向”更能跨越人 - 机鸿沟
- 两台真机上：新任务 2.1% → 60.0%，双臂 45.9%，约 1/3 采集成本即可匹配遥操作
- 下一步关键：能否扩展到 EgoDex 等 in-the-wild 大规模第一人称视频，并持续提升 IDM 精度