论文解读 • arXiv 2611.05377 • 2026-11-03

DreamX

视频扩散模型是通用的潜动作学习器

Video Diffusion Model is a Universal Latent Action Learner

Jisoo Kim*, Chaehyun Kim*, Junsu Kim, Jiho Park, Seongchan Kim,
Eunbeen Hong, Soowon Son, Fu-En Yang, Seungryong Kim
KAIST • **NVIDIA**

图源：论文 Figure 1

TL;DR

一句话总结：让视频扩散模型自己“读出”动作，再自己“演出”未来

DreamX 用预训练视频扩散模型（Cosmos-Predict2.5 2B）**同时充当编码器和解码器**：可学习 query 从时空特征中读出紧凑潜动作，解码器仅凭**“初始帧 + 潜动作”**重建未来视频——外观交给生成先验，潜动作只剩运动，从而形成人与机器人共享的动作接口。

300×

潜动作 token 压缩

每个潜帧 1,200 个视频 token → 4 个潜动作 token

0.17 | 69.7%

LARYBench 回归 MSE | 分类准确率

此前最强 DiLA： 0.38 | 62.25%

96.7%

真机关抽屉子目标成功率

Mimic-Video 50%；单次推理 1.47 s，快 19.1×

问题：动作标签绑死在本体上，现有潜动作又把动作与外观缠在一起

① 标签不可共享

人类视频没有机器人动作标签

不同机器人控制空间各异

同一行为 ≠ 同一底层动作

② 动作与外观纠缠

LAM 以“重建未来帧”训练编码器

视角、场景外观只要有助于重建，就会混进潜动作

跨本体迁移受限

③ 视角太局部

LAPA / Genie / UniVLA： 从头学、只看一对帧

AdaWorld / VideoWorld2： 视频模型只当生成器，动作编码器仍外挂

作者洞察

预训练视频扩散模型自带两种先验：**时空表征**（运动 / 对应 / 几何 / 语义）用来“读”动作；**生成先验**（给定首帧即可合成合理未来）用来“监督”动作。

核心思路：外观交给视频先验，运动交给紧凑潜动作

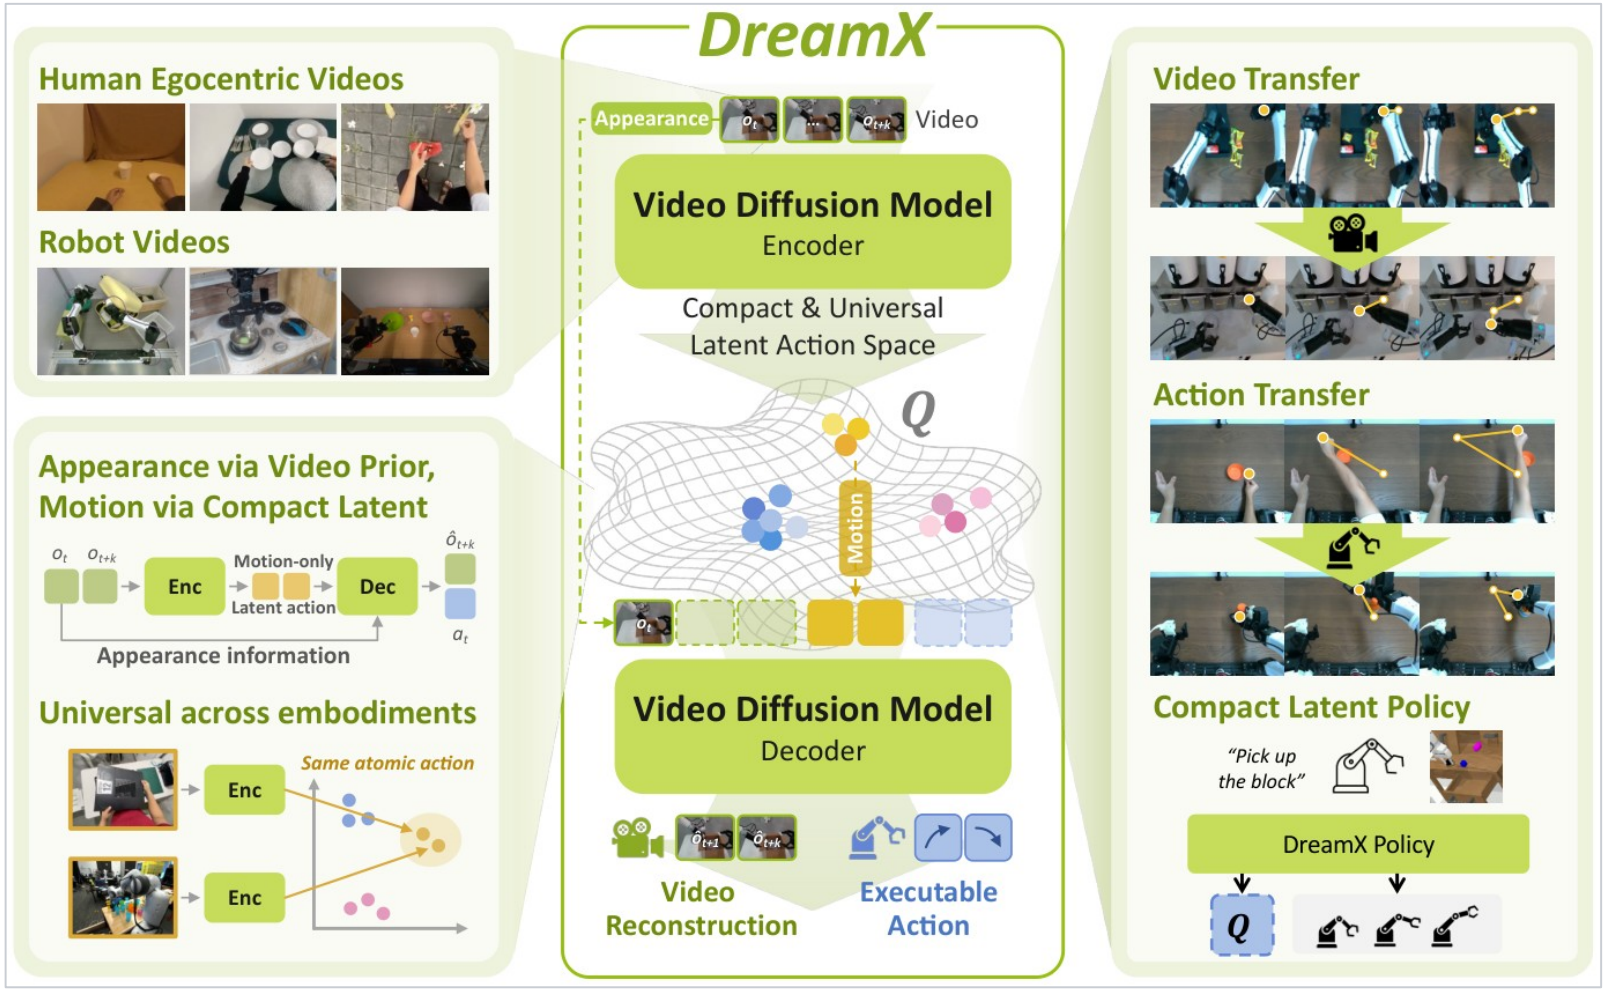

训练

- 人类第一视角视频 + 机器人视频，无需配对

编码

- 视频扩散模型 → 紧凑、跨本体的潜动作空间 Q

解码

- 首帧提供外观， Q 提供运动 → 重建视频 / 可执行动作

应用

- 视频迁移 • 动作迁移 • 紧凑潜策略

出处：论文 Figure 1

同一骨干既当编码器又当解码器，注意力掩码决定信息流向

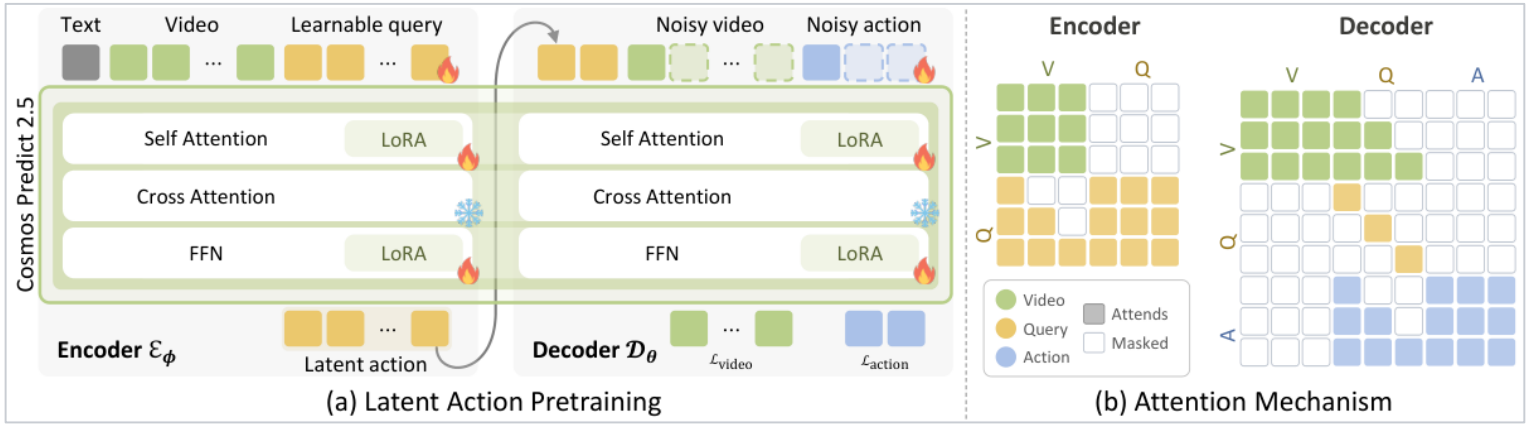

编码器 E_ϕ

每个潜帧配 4 个可学习 query
与视频 token 共享时空注意力
query→video 帧因果： Q_g 只看 V_0:g

解码器 D_θ

条件仅为首帧 V_0 + 潜动作 Q （不给文本）
有标签时加状态 p_0 ，辅助解码动作
视频与动作 token 互不可见，只读 Q

L = L_video + λ • L_action flow matching ； 无动作标签时 λ=0 ； 骨干冻结

出处：论文 Figure 2 、 §3.2 、附录 A.2

一个潜空间，三种用法：视频迁移、动作迁移、潜动作策略

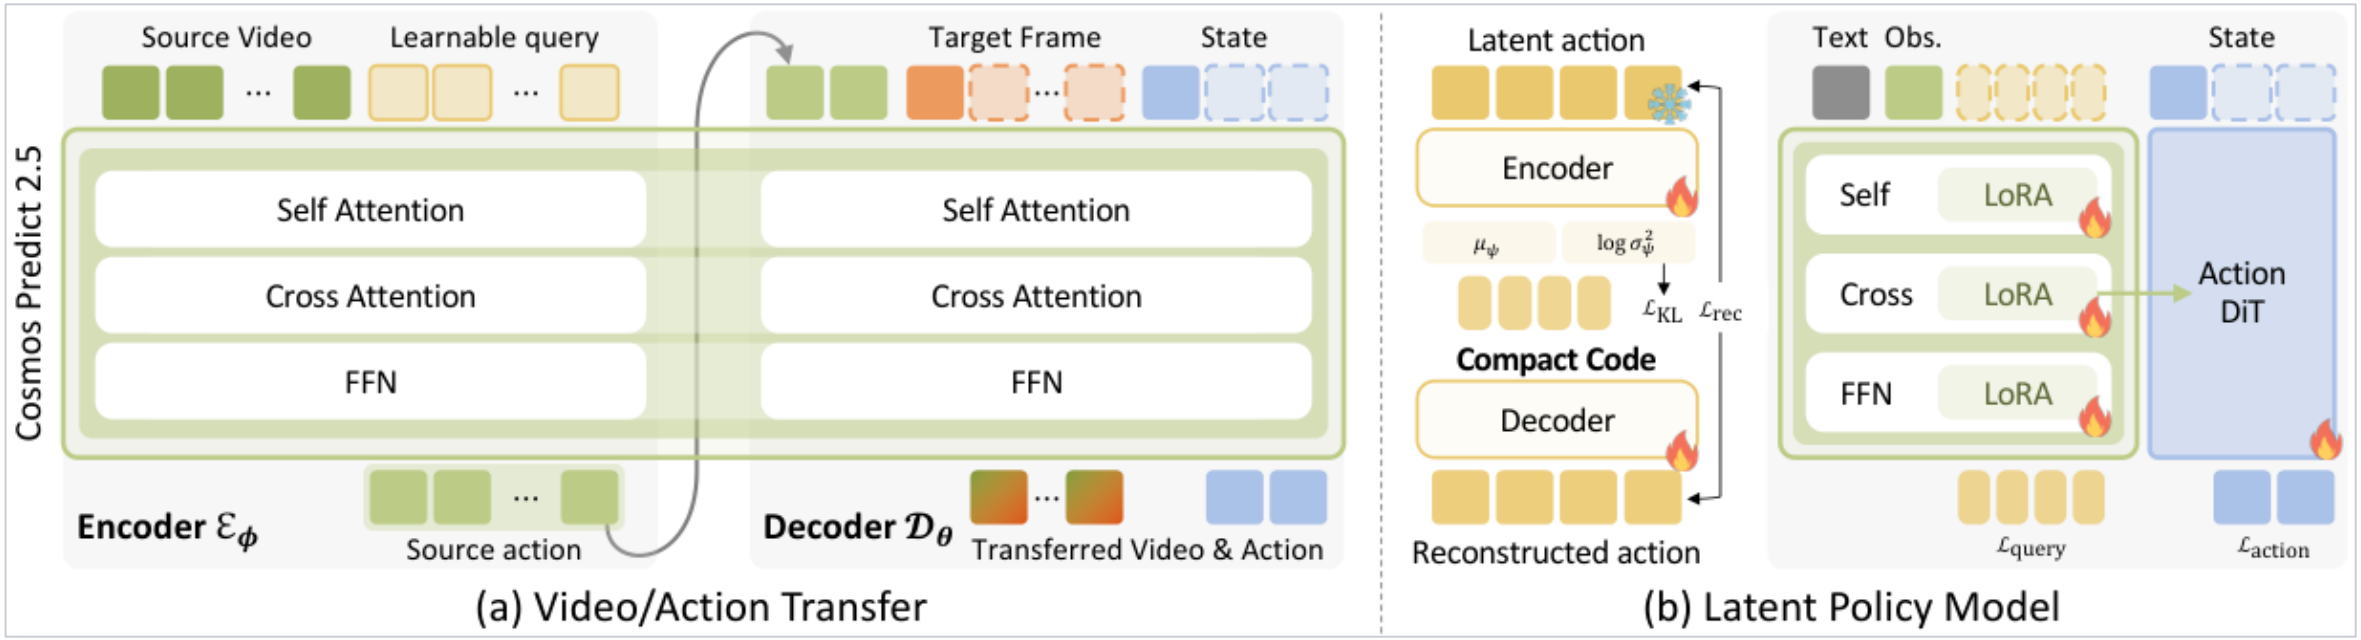

(a) 运动迁移：零额外训练

$\hat{V}^{tgt} = D(Q^{src}, V_0^{tgt})$　$\hat{A}^{tgt} = D(Q^{src}, p_0^{tgt})$

(b) 潜策略： $\pi(Z, A \mid V_0, \ell, p_0)$

FAE 将每个 token 2048 → 32 维；人类视频只监督 Z，机器人数据再监督 A

2.19k 小时异构数据：约 1/5 来自人类第一视角视频

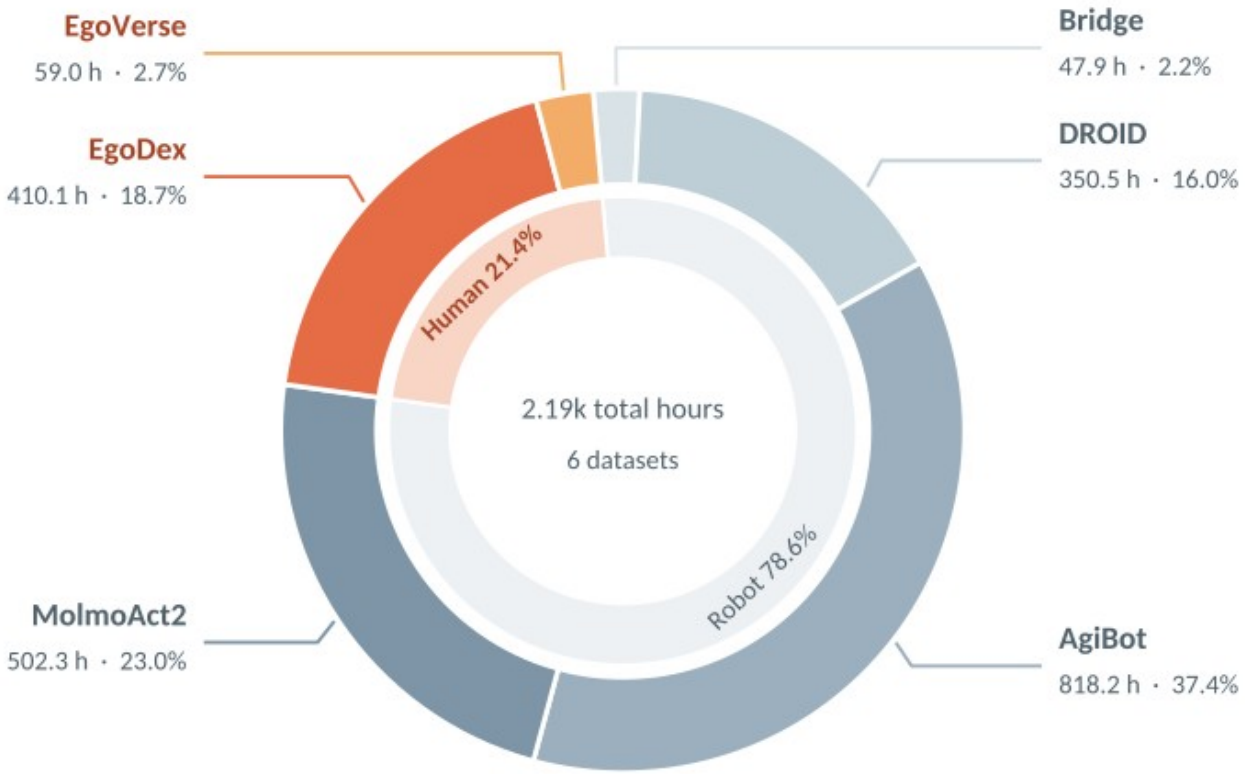

2.19k h

总时长

21.4%

人类视频

关键配置

- 骨干： Cosmos-Predict2.5 2B ，权重冻结
- 片段： 5–29 帧 → 2–8 个潜帧，最多 32 个 query
- 编码器 / 解码器各一套 rank-16 LoRA
- 学习率 1e-4 （LoRA 、 query ）， 78,000 步
- 有动作标签时视频与动作损失等权

出处：论文 Figure 9 、附录 A.1–A.2

LARYBench：回归误差降低一半以上，分类准确率领先 7.4 个点

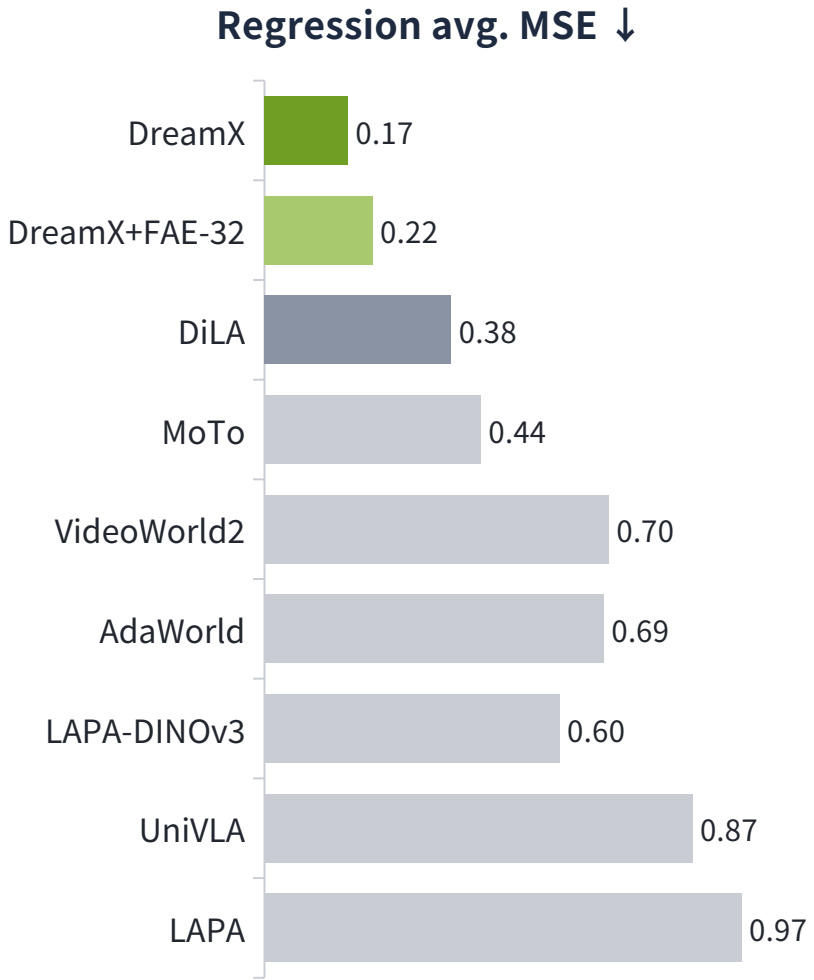

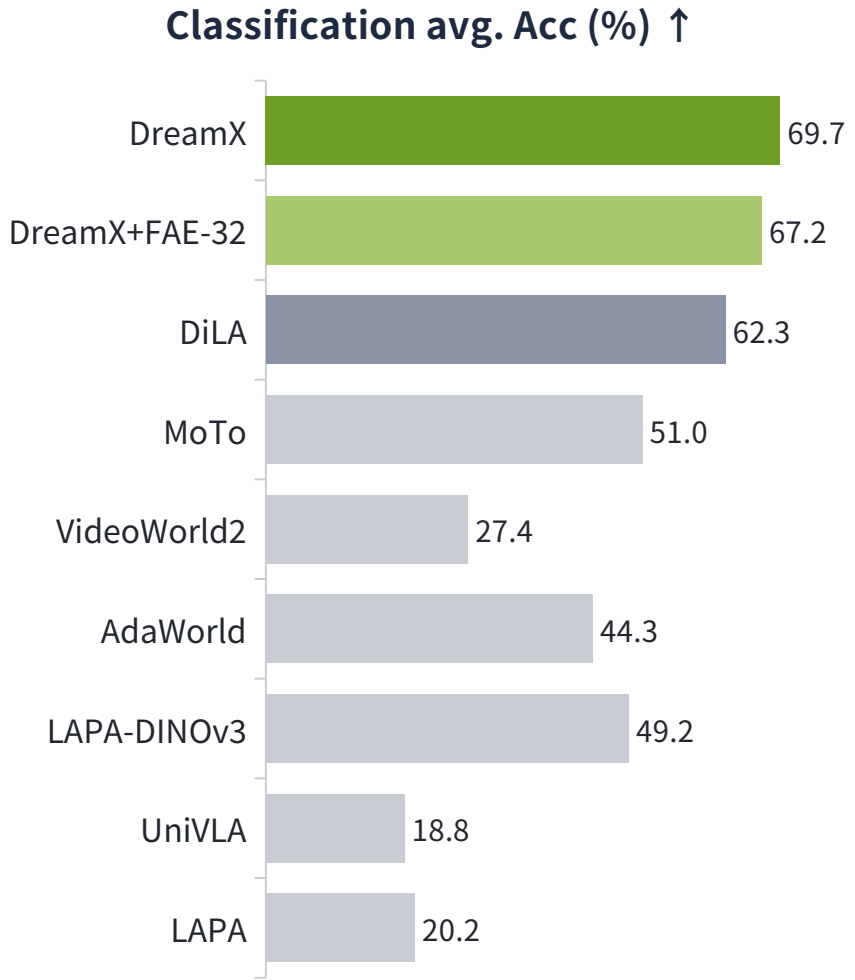

0.38 → 0.17

回归 MSE （对比 DiLA）

62.3 → 69.7

分类准确率 % （对比 DiLA）

- 压到 32 维的 FAE-32 仍优于所有基线
- 同样借助视频先验的 AdaWorld / VideoWorld2 反而落后：关键在“直接读骨干内部特征”

出处：论文 Table 1 （冻结表征 + attentive probe）

视频迁移：跨场景、跨本体复现运动，且没有人手“泄漏”

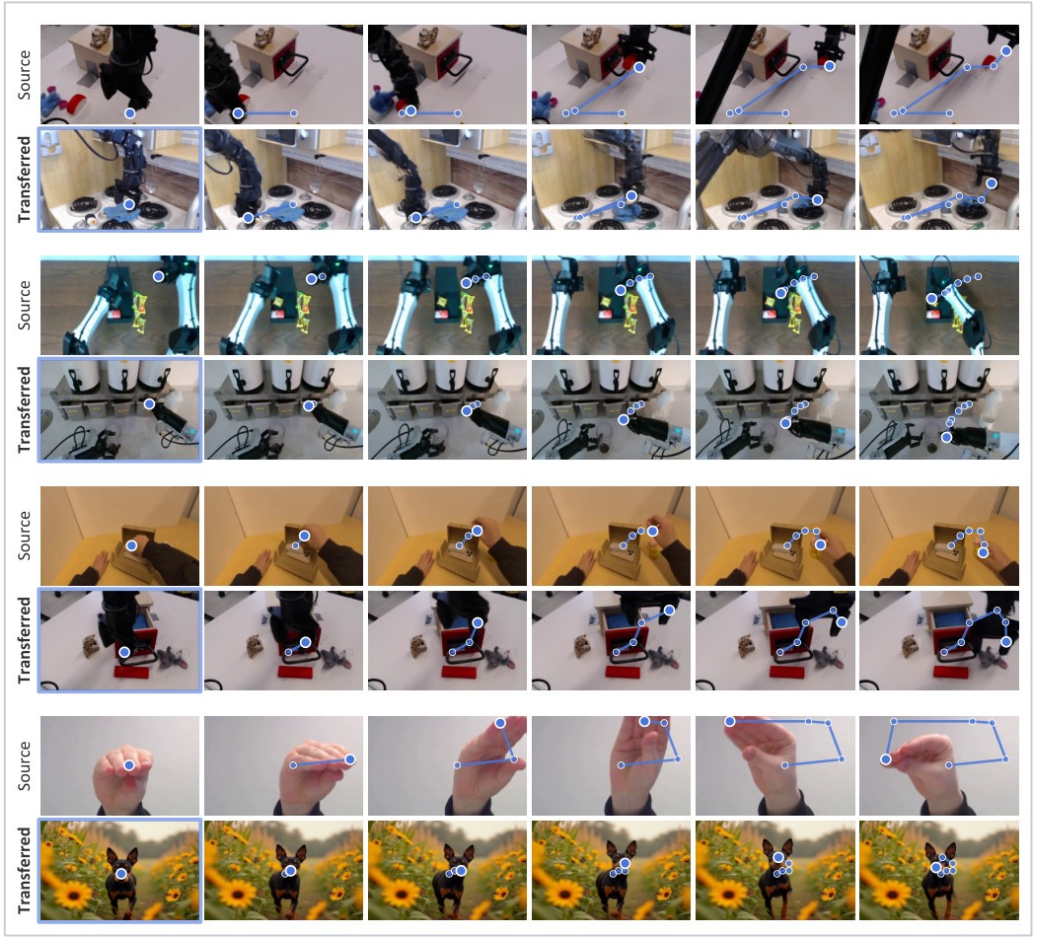

任意到任意迁移：机器人↔机器人、人→机器人、人→ DAVIS （蓝点为末端轨迹）

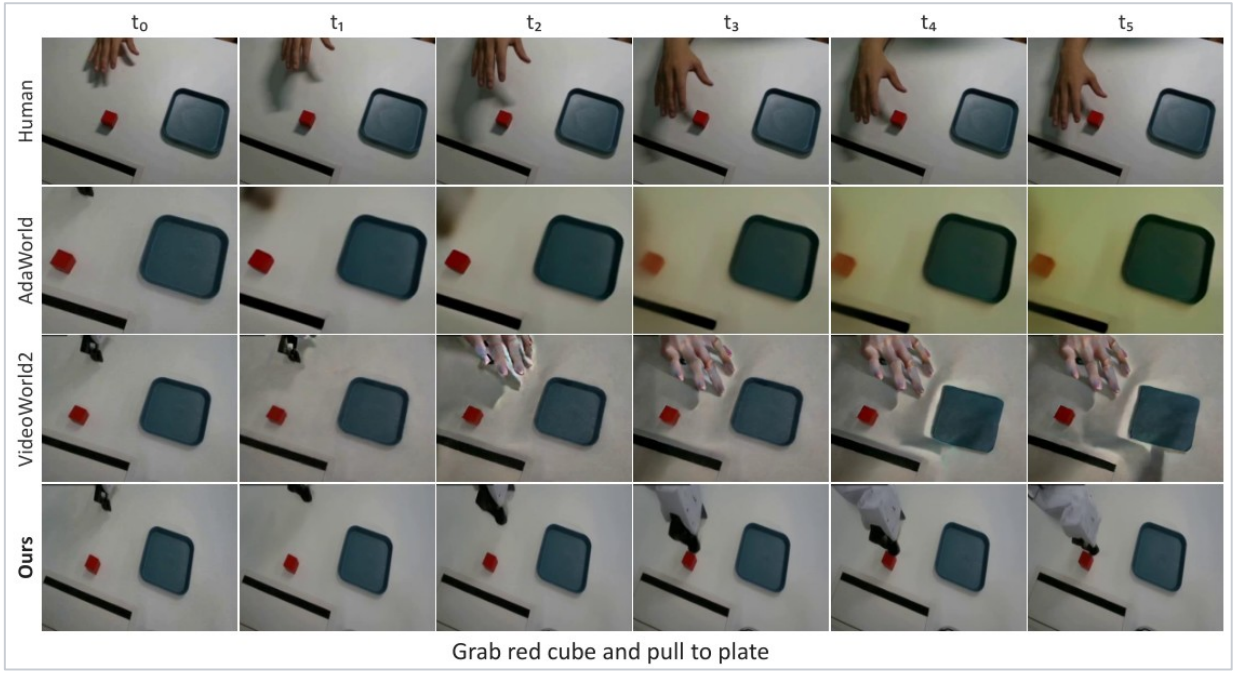

HumanAndRobot 零样本人→机器人（ Grab red cube and pull to plate ）

训练不用任何人 - 机器人配对数据； Table 2 中 FVD / LPIPS / PSNR / SSIM 全部优于 AdaWorld 与 VideoWorld 2

AdaWorld： 画面退化　VideoWorld 2： 偶现人手　DreamX： 保留机器人外观

出处：论文 Figure 4 、 Figure 5 、 Table 2 、附录 B.5

动作迁移：人类视频 → 机器人关节指令，开环执行仍能保留轨迹结构

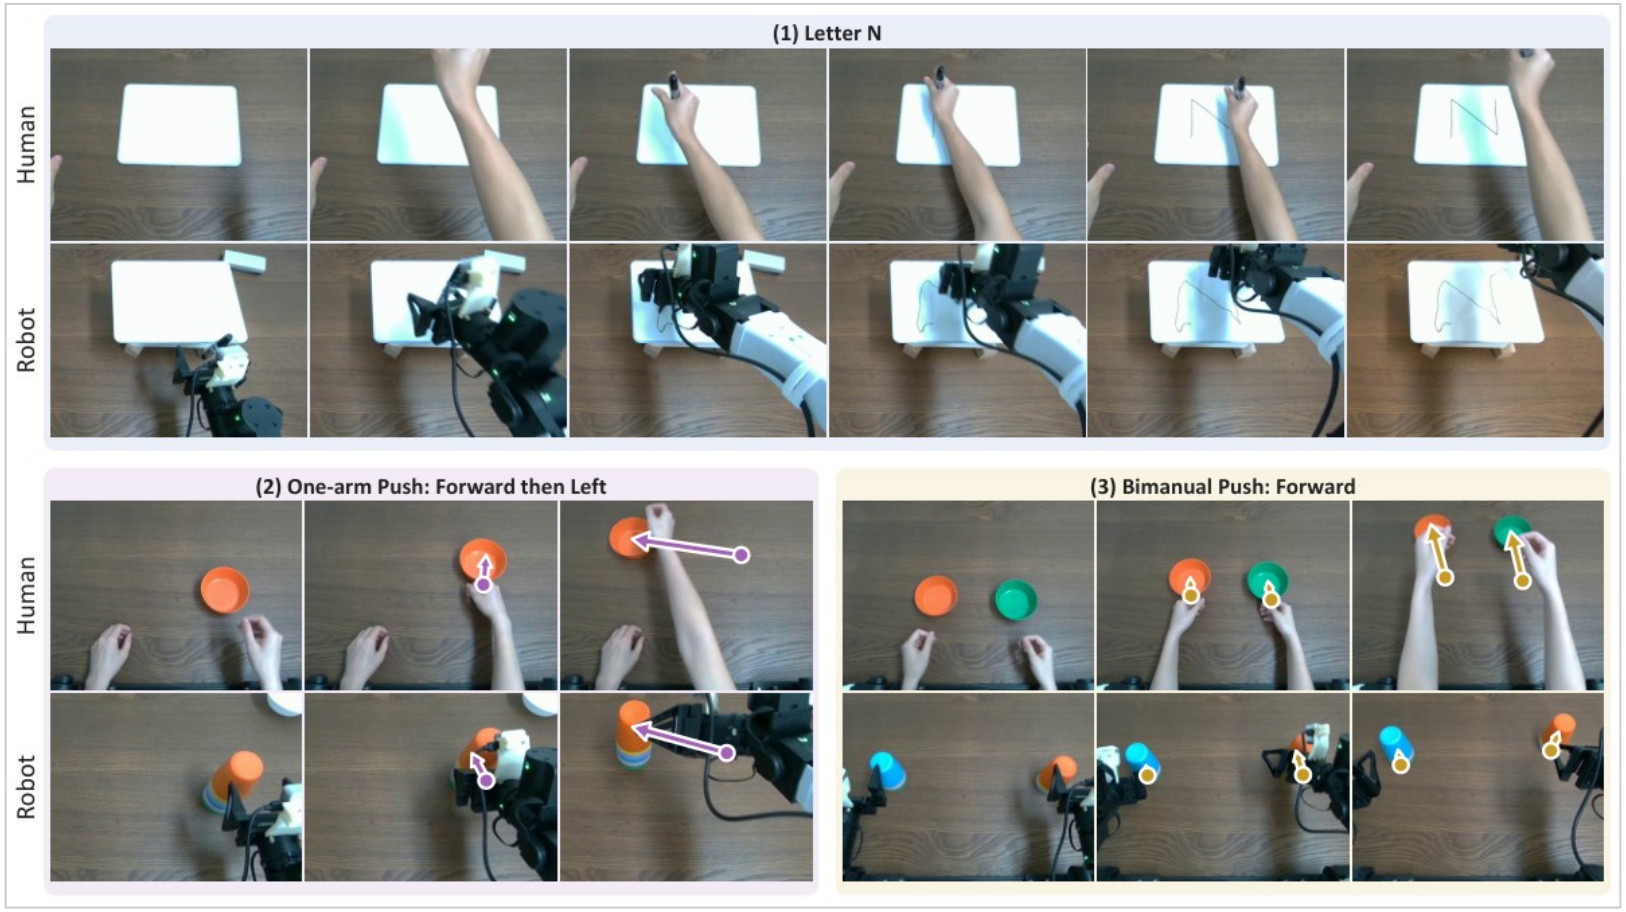

写字母 “N”

精细空间轨迹 + 笔画顺序

单臂推：先前后左

方向变化 + 时间顺序

双臂推：向前

左右臂运动分别对应

设置

双臂 YAM， 14 维绝对指令；无视觉反馈、无配对数据。仅有定性展示，未报告定量指标。

出处：论文 Figure 6、 §4.3、附录 B.1–B.2

潜动作策略：关抽屉成功率 96.7%，推理比视频策略快 19.1 倍

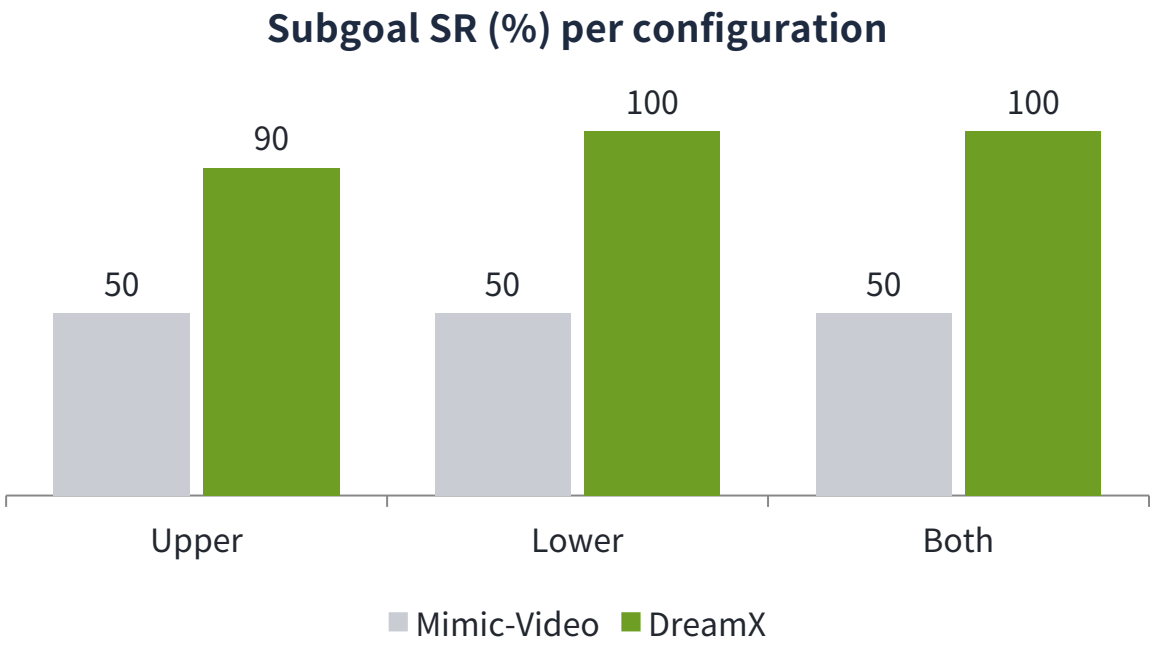

96.7%
DreamX 平均 SR

50%
Mimic-Video

1.47 s
单次推理 快 19.1×

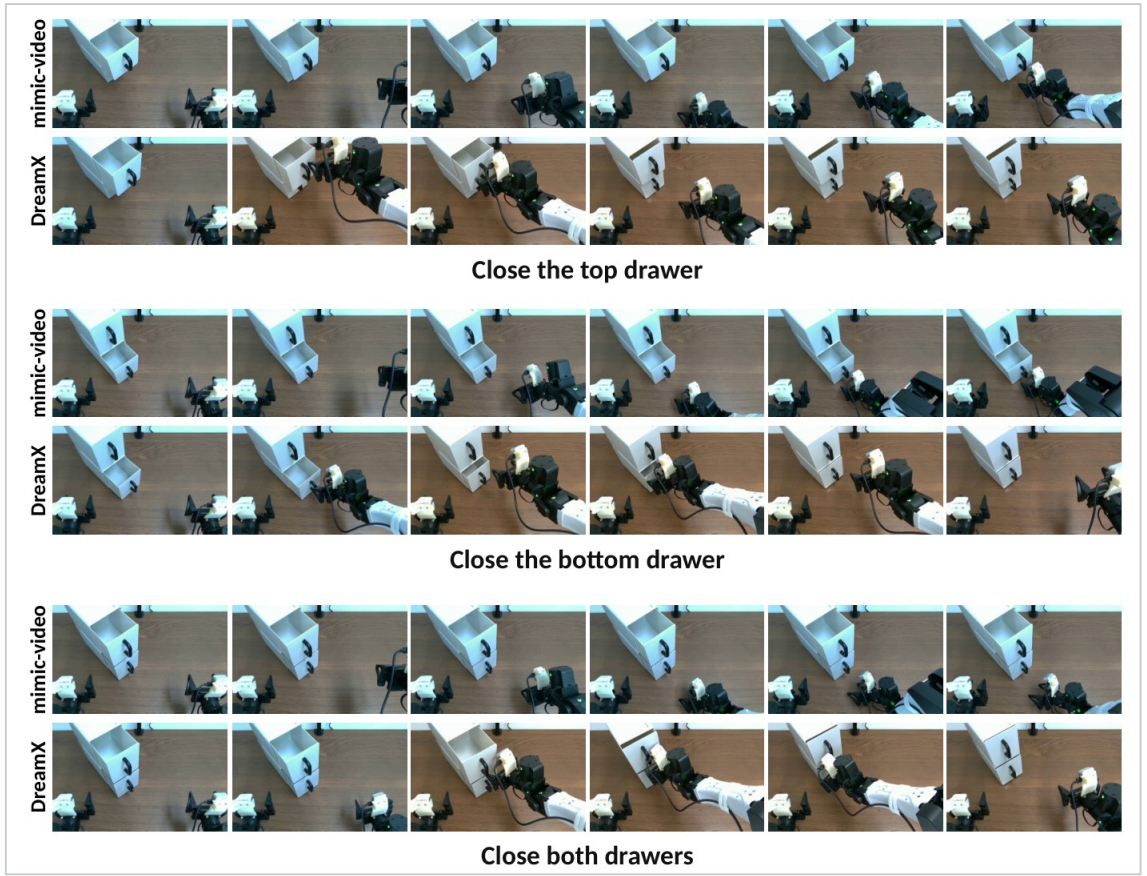

仅用人类视频训练上抽屉配置（无机器人动作标签）仍达 100%（附录 Table 6）

出处：论文 Table 3、Table 5、Table 6、Figure 19、附录 B.3

潜动作控制的是“运动”而不是“外观”：置零后运动几乎消失

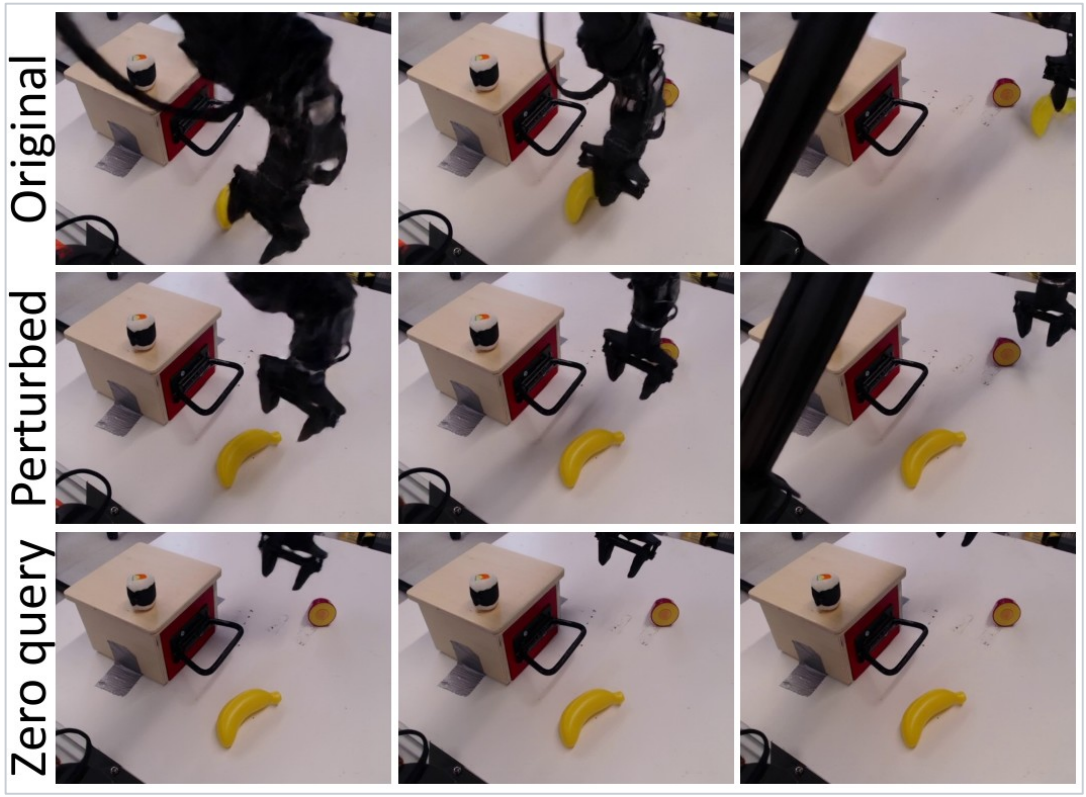

Conditioning	Motion ratio	Flow dev.	RGB L1	Static L1
Original	1.000	0.000	0.0000	0.0000
Noise α=0.1	1.000	0.141	0.0054	0.0030
Noise α=0.3	0.995	0.211	0.0077	0.0034
Noise α=1.0	0.946	0.481	0.0215	0.0077
Zero queries	**0.456**	**0.866**	**0.0758**	**0.0227**

- 扰动越强，解码出的运动偏离越大
- 置零后运动比例只剩 0.456
- 静态区域 RGB 变化（0.0227）远小于全图（0.0758）→ 外观基本由首帧与生成先验维持

出处：论文 Figure 7、Table 8、附录 C.3

潜动作关注手和夹爪，运动方向结构在不同机器人之间共享

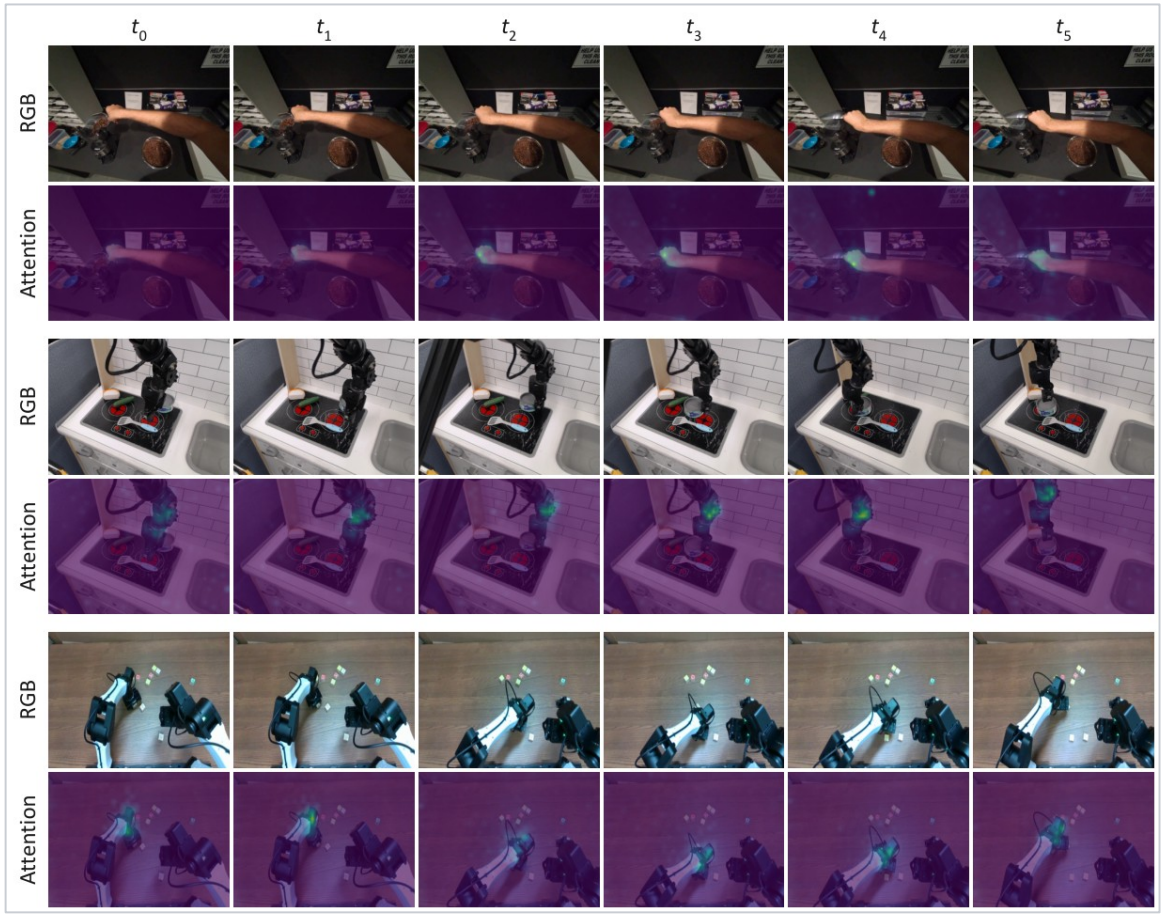

Query→video 注意力集中在运动的手 / 夹爪及被操作物体

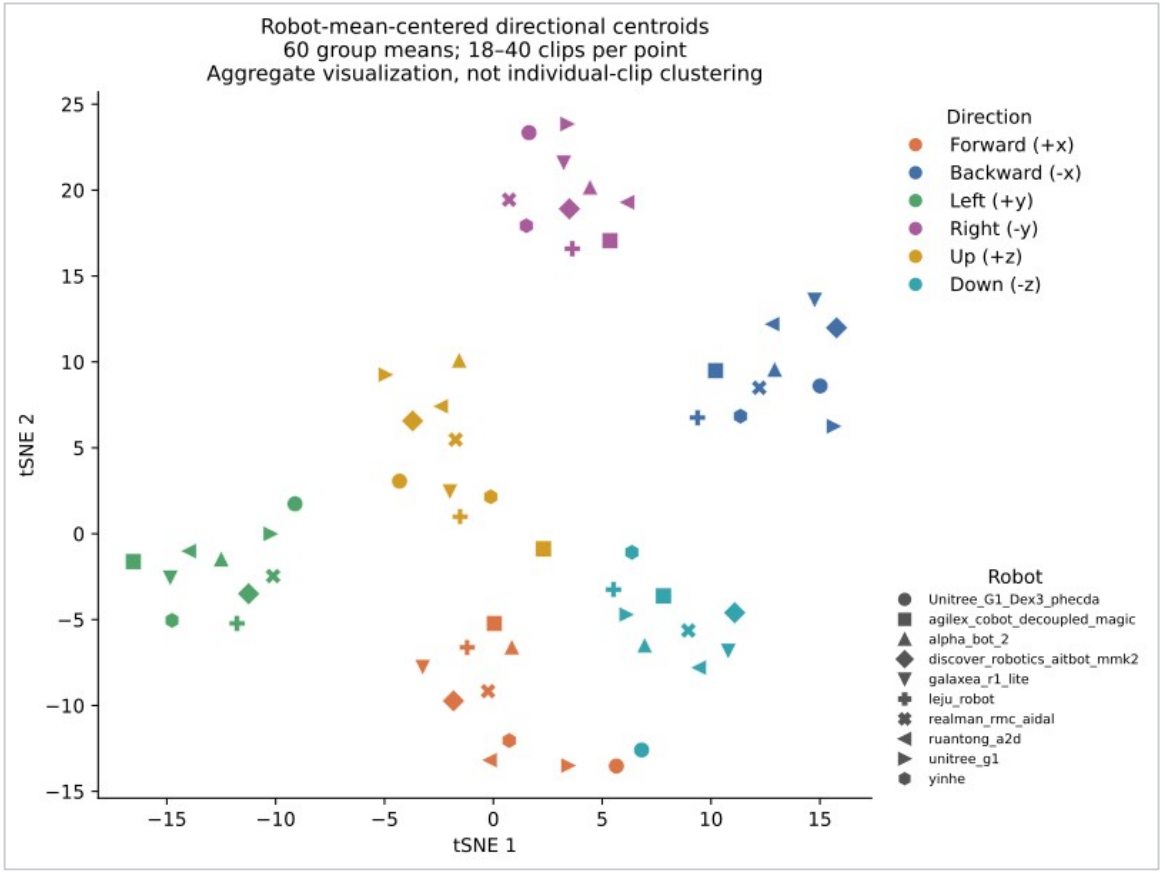

RoboCOIN： 10 种机器人 × 6 个方向的质心按“方向”而非“机器人”聚类

出处：论文 Figure 8 、 Figure 12 、附录 C.3 、 D.4

消融：动作标签不是关键，而潜动作确实帮助策略预测动作

辅助动作监督（Table 4，子集训练）

Supervision	Reg. avg. ↓	Cls. avg. ↑
RGB only	0.24	65.3
RGB + action	0.23	64.8

≈ 持平

加入动作标签：回归 − 0.01，分类 − 0.5 个点

→ 运动与动作语义主要来自视频本身

CALVIN 策略：是否让动作头读取潜动作（Table 7）

Policy	⩾1	⩾2	⩾3	⩾4	⩾5	Avg. Len.
w/o latent actions	83.4	61.7	42.5	29.8	20.4	2.378
DreamX policy	**85.7**	**67.0**	**49.5**	**36.4**	**25.7**	**2.643**

2.378 → 2.643

平均完成长度；五个长度阈值下的成功率全部提升

→ 潜动作为底层动作预测提供有效引导

出处：论文 Table 4、Table 7（附录 C.2）

评价：思路简洁、效果显著，但真机验证和对比公平性仍需更多证据

亮点

- 思路干净：同一视频骨干同时负责“读特征”和“生成监督”，只加 query + 掩码 + LoRA
- 解耦机制可解释：首帧和生成先验负责外观，有扰动实验与“无人手泄漏”佐证
- 一个表征三种用途：视频迁移、开环动作迁移、潜动作策略
- 人类视频可直接监督策略的潜动作分支

局限 / 疑点

- “300×” 只算 token 数，每个 token 仍是 2048 维，策略还需再压缩一层 FAE
- LARYBench 比较： 2B 骨干特征 + 语言指令；预训练含 AgiBot，与 AgiBotWorld-Beta 可能重叠
- 真机规模小：单一关抽屉任务、每配置 10 次、仅一个基线；动作迁移无定量指标
- 辅助动作监督几乎无收益； 1.47 s/ 次对高频闭环仍偏慢

Takeaways

01 视频基础模型即动作表征学习器

直接从预训练视频扩散骨干内部读潜动作，比从两帧之间从头学强得多（LARYBench 0.38 → 0.17 MSE）

02 生成先验是天然的解耦器

解码器只拿到首帧 + 潜动作，外观由先验补全，潜动作被迫只编码运动

03 共享动作接口打通人与机器人

无需配对数据，即可实现视频迁移、开环动作迁移，以及基于人类视频监督的潜动作策略

arXiv 2611.05377 · 项目主页：cvlab-kaist.github.io/DreamX