论文解读 · arXiv 2611.06817

Open-HumanWAM

用 5 万小时第一人称人类视频，扩展具身基础模型的开放配方

An Open Recipe for Scaling Human and Robot Experience for Embodied Foundation Models

PKU · NUS · MIT · UCSB · NVIDIA | 通讯作者： Daquan Zhou

首次提交： 2026-11-04

注：提示中的标题为 “Open-HumanScale”，论文正文与开源资源名称为 Open-HumanWAM

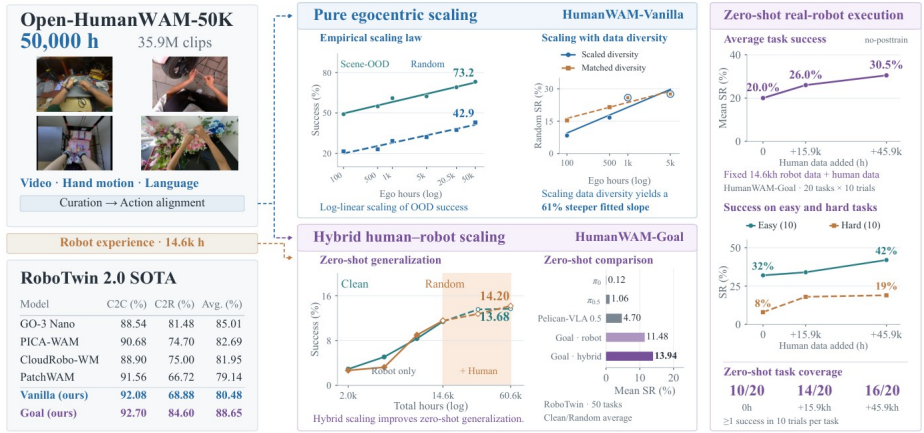

图源：论文 Figure 1 （总览）

ONE-SENTENCE SUMMARY

一句话总结：人类视频越多，机器人越能泛化；再混入机器人数据，就能零样本执行

开源 **5 万小时**第一人称人类视频（含手部动作 + 语言标注），预训练世界–动作模型后，机器人**分布外成功率随预训练小时数近似对数线性上升**；再混入 1.46 万小时机器人数据、用目标图像指定任务， HumanWAM-Goal 在 RoboTwin 2.0 达到 **88.65% 平均成功率（SOTA）**，并能零样本执行、只换目标图就改变行为。

50,000 h

Open-HumanWAM-50K： 5 个来源、 35.9M 片段，统一 16 维双手动作

49.1→73.2%

IDM 版本 Scene-OOD 成功率，100 h → 50k h 人类预训练（R^2=0.969）

88.65%

HumanWAM-Goal RoboTwin 2.0 平均（Clean 92.70 / Random 84.60）

20.0→30.5%

真机 20 任务零样本平均成功率，+45.9k h 人类数据

三段式故事线： ① 构建并开源语料 → ② 纯人类数据预训练的缩放研究（HumanWAM-Vanilla）→ ③ 人类 + 机器人混合训练与目标图条件（HumanWAM-Goal）→ 真机零样本、上下文学习与长程任务

MOTIVATION

已有工作证明“人类数据有用”，但多用 loss 衡量、且不开源

已有工作

EgoScale

2 万小时以上动作标注第一人称预训练；数据规模与验证 loss 呈对数线性

HumanScale

后训练后，验证动作 loss 随人类预训练小时数对数线性下降；同等时长人类数据优于机器人数据

Dyna-2

扩展到 100 万小时，报告零样本动作预测的缩放

空缺：多用 loss / 开环指标衡量；分布内与分布外混在一起；数据与流程多不公开。

本文要回答的问题

- **规模** — 100→50k h，闭环成功率提升在分布内还是分布外?
- **配方** — 多样性、跨源动作对齐、人类动作监督各有多大作用?
- **数据源** — 同样小时数，人类数据能否胜过机器人数据?
- **范式** — 混合人类 + 机器人数据，能否零样本执行、免逐任务微调?

数据： 10.4 万小时原始视频，清洗对齐后保留 5 万小时

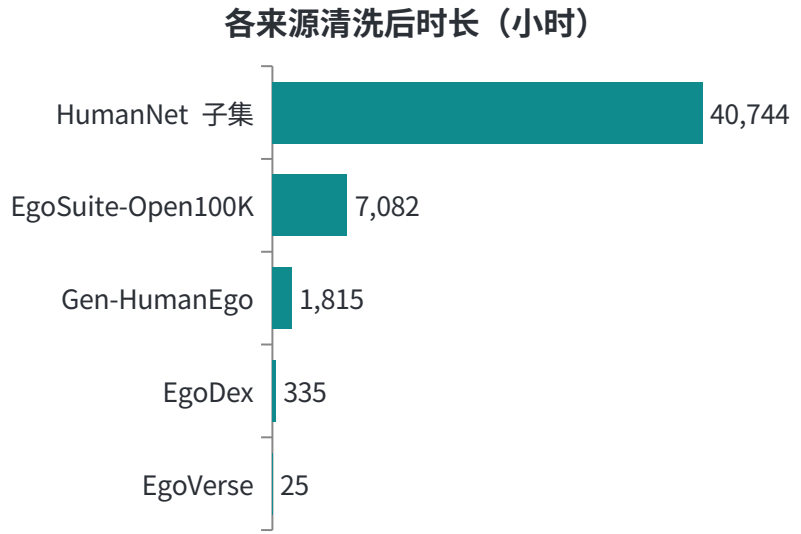

104k → 50k h 清洗前 → 清洗后

35.9M 连续片段（31.4M 原始 episode）

16 维 双手 EEF： 位置 3 + 四元数 4 + 开合 1

来源：论文 Figure 2 、 Table 1

MODEL & PROTOCOL

HumanWAM-Vanilla： 视频专家 + 动作专家，共享注意力联合去噪

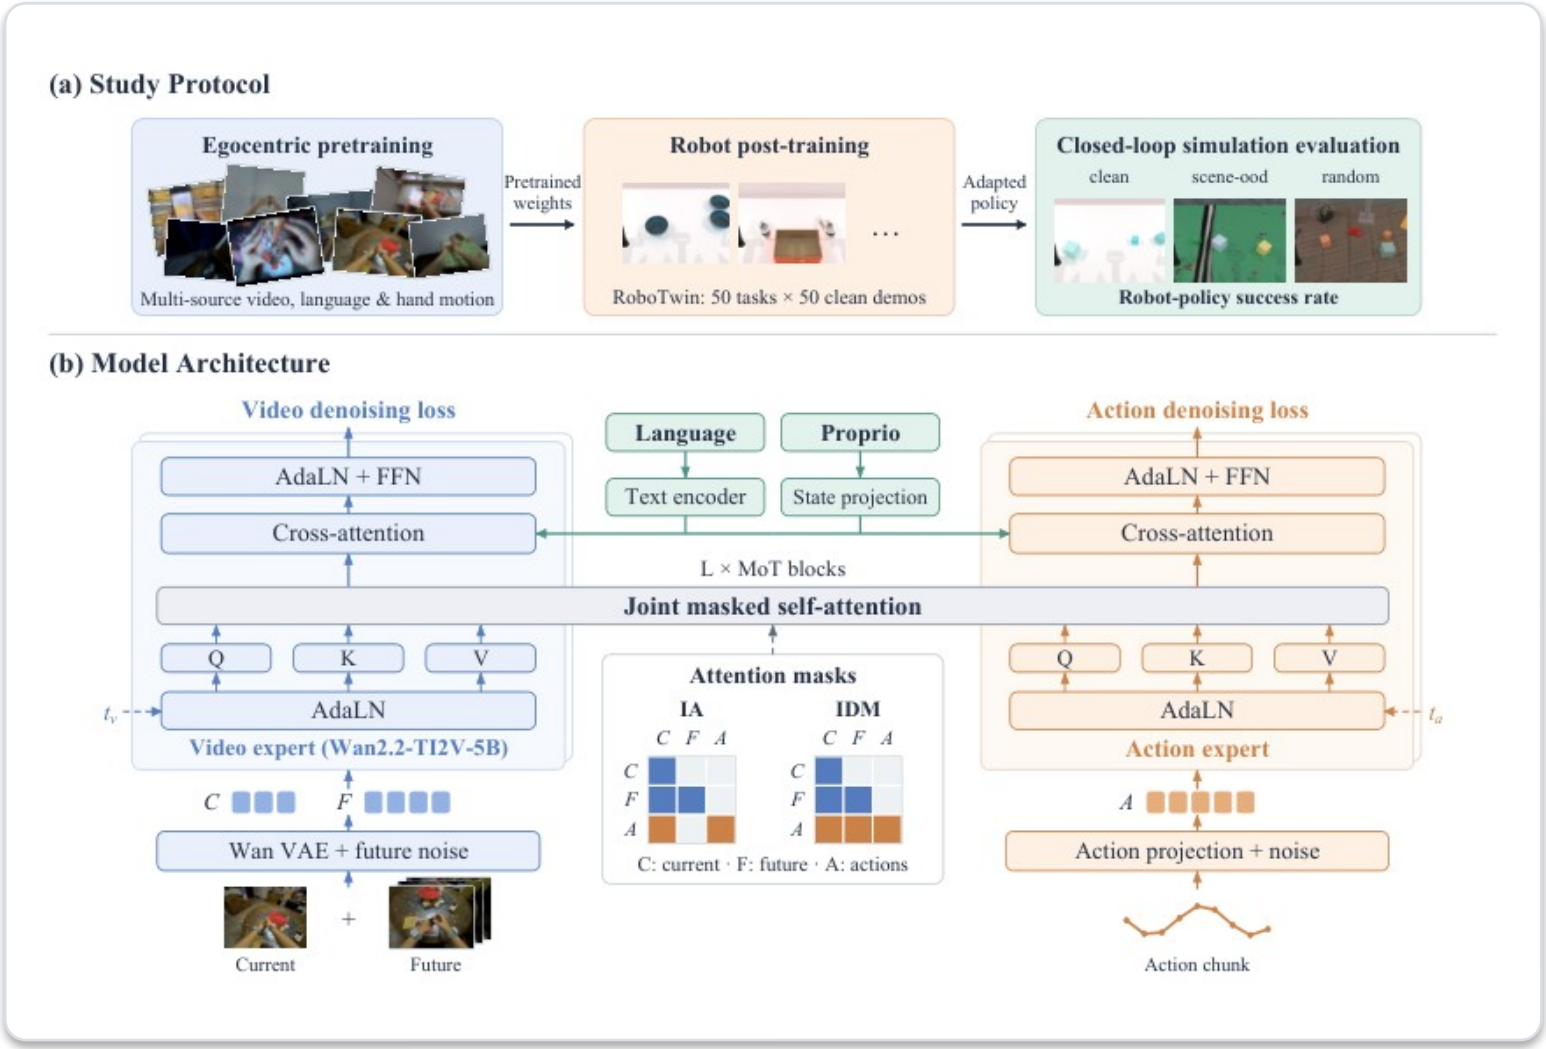

骨干

Wan2.2-TI2V-5B 视频专家 + 同深度动作专家（MoT）

两种掩码

IA： 动作只看当前帧（快）
IDM： 动作还能看未来视频帧

最终配置

IDM + 相机系绝对位姿； 32 步动作块，先生成未来视频再出动作

评测三档

clean （同分布） / scene-ood （换背景纹理） / random （杂物、光照、桌高）

Q1 • SCALING 100 → 50,000 HOURS

规模换来的主要是分布外泛化： OOD 成功率随小时数对数线性上升

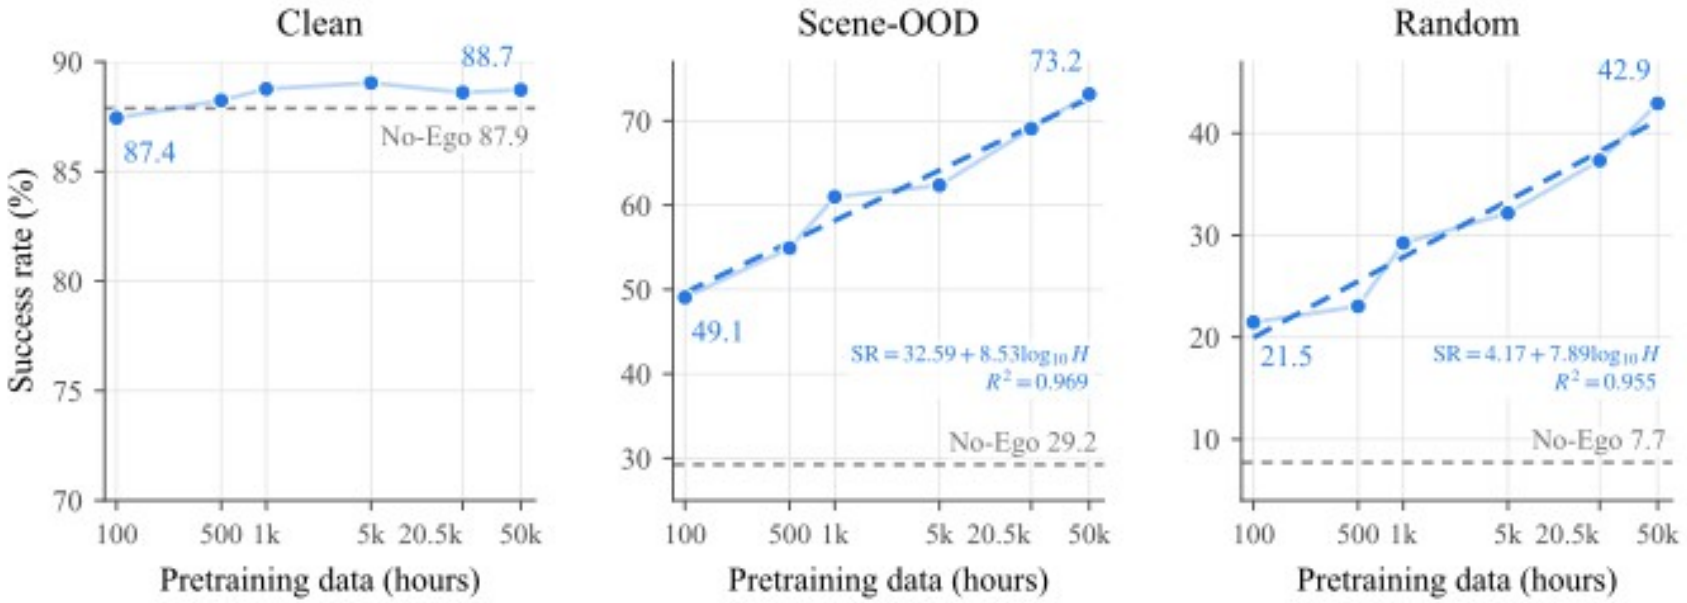

上图： IDM 注意力， 100 h → 50k h （灰虚线 = 无人类预训练基线）

87.4 → 88.7%

Clean： 基本持平（No-Ego 87.9%）

49.1 → 73.2%

Scene-OOD： R^2=0.969 （No-Ego 29.2%）

21.5 → 42.9%

Random： R^2=0.955 （No-Ego 7.7%）

+4.4/+15.9/+10.2

IA 版本每 10 倍数据的增益（pp）： Clean / Scene-OOD / Random

来源：论文 Figure 5 、 Figure 6

多样性同样是缩放维度：同样时长下，任务与场景覆盖越广越好

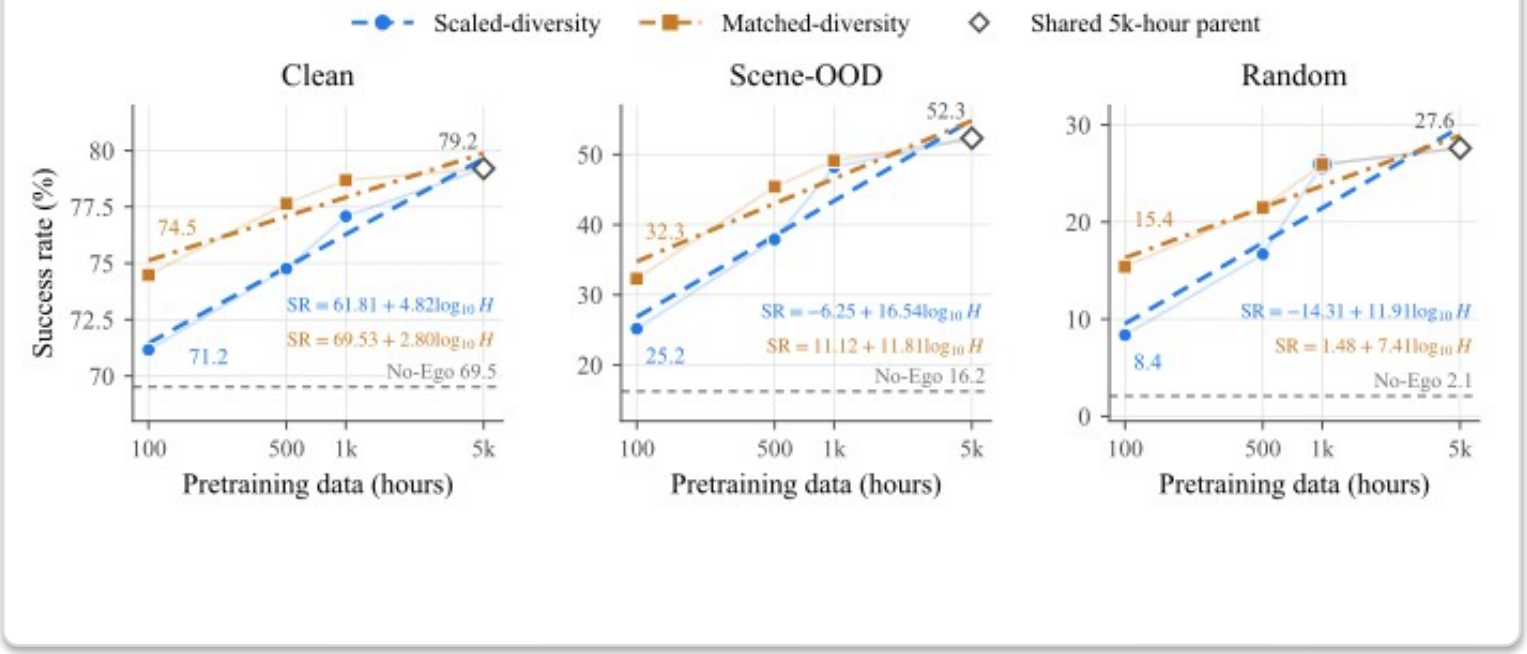

100 h 时	任务数	场景数	Clean	Scene-OOD	Random
Scaled-diversity （蓝）	62	222	71.2	25.2	8.4
Matched-diversity （橙）	**2,288**	**2,953**	**74.5**	**32.3**	**15.4**

论文结论

任务 / 场景覆盖随规模一起扩大，拟合斜率更陡：

Clean +2.0 • Scene-OOD +4.7 • Random +4.5

解读时需注意

两组在 5k h 共用同一父集，终点必然重合；

100–1k h 区间，覆盖更广的 matched 组反而更高。

→ 更直接的结论：同等时长，覆盖越广越好。

来源：论文 Figure 7 、 Table 3

Q3 • SAMPLE EFFICIENCY

更大规模预训练 = 更少机器人示范：一半示范，泛化反而更好

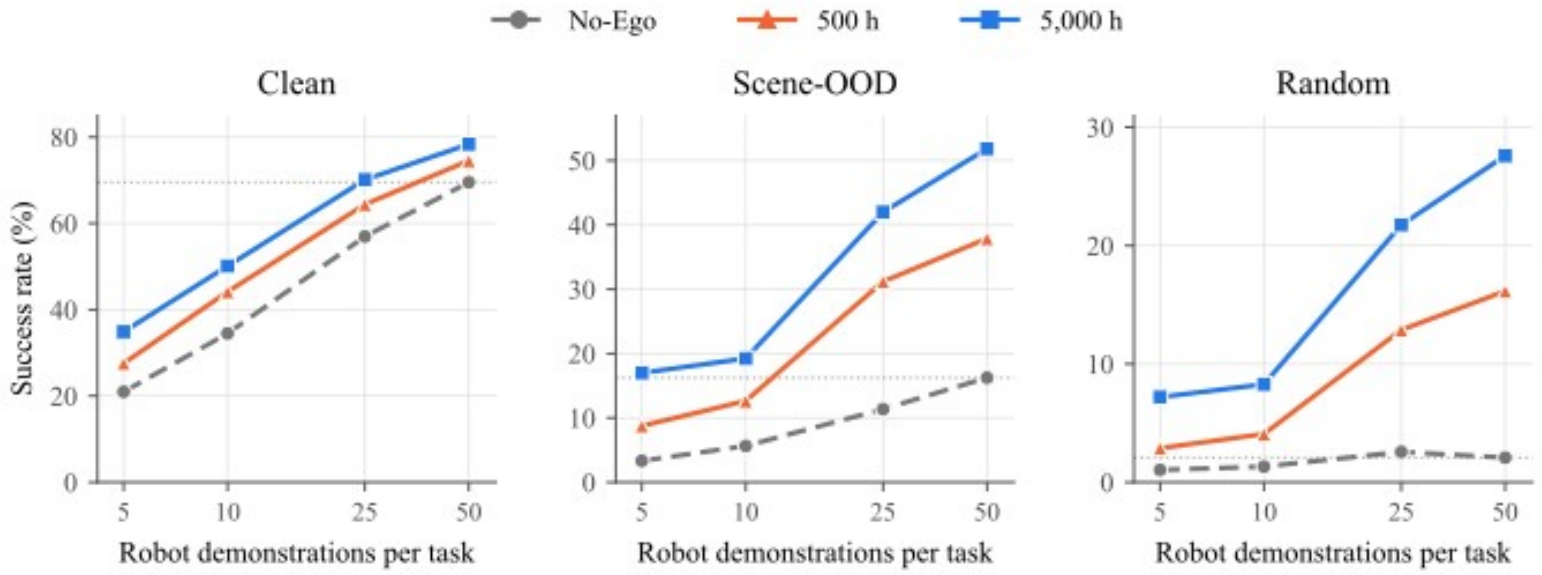

34.5 → 44.2 → 50.1%

每任务 10 条示范的 Clean 成功率
No-Ego → 500 h → 5,000 h

25 条 > 50 条

5k h + 25 条示范 超过 500 h + 50 条：
Scene-OOD 42.0 vs 37.9 • Random 21.8 vs 16.2

5 条 > 50 条

Scene-OOD： 5k h 模型 5 条示范即超过 No-Ego 50 条示范

来源：论文 Figure 8 、 §3.4

两个必要配方：跨源动作对齐 + 预测人类动作（只做视频预测几乎无用）

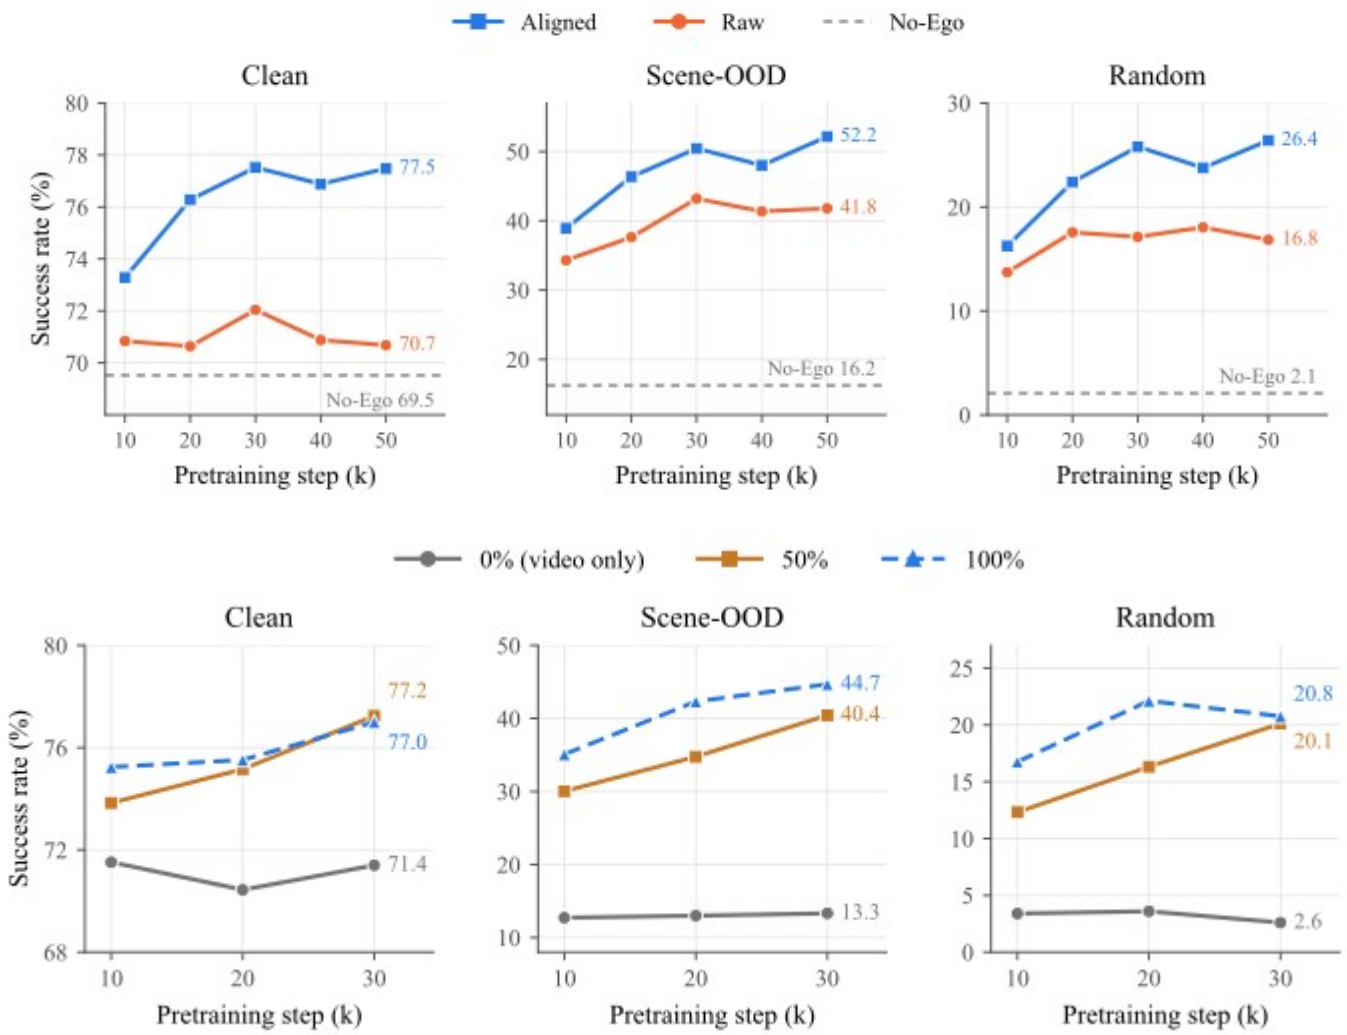

跨源对齐（ 1k h 四源）

Scene-OOD 52.2 vs 41.8

Random 26.4 vs 16.8

对齐后动作 loss 更低，视频 loss 几乎相同（ Fig.10 ）：对齐让多源动作监督更一致。

人类动作监督

仅视频预测： Scene-OOD ≈13% 、Random ≈3% ，训练再久也不涨

加入动作监督（ 30k 步）： Scene-OOD 40.4% （ 50% ） / 44.7% （ 100% ）

50% 与 100% 标注比例效果接近。

来源：论文 Figure 9 、 Figure 11

Q6 • EGOCENTRIC vs ROBOT PRETRAINING

同样小时数，人类视频比机器人数据更有效（≥ 500 h 全面占优）

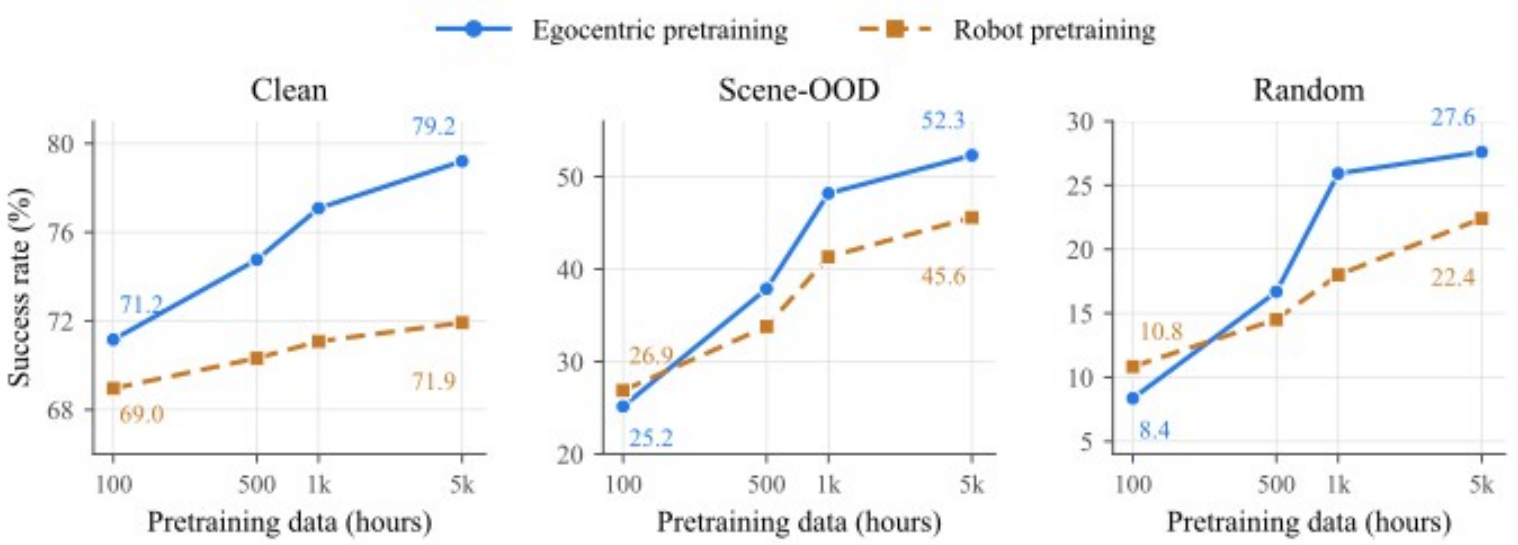

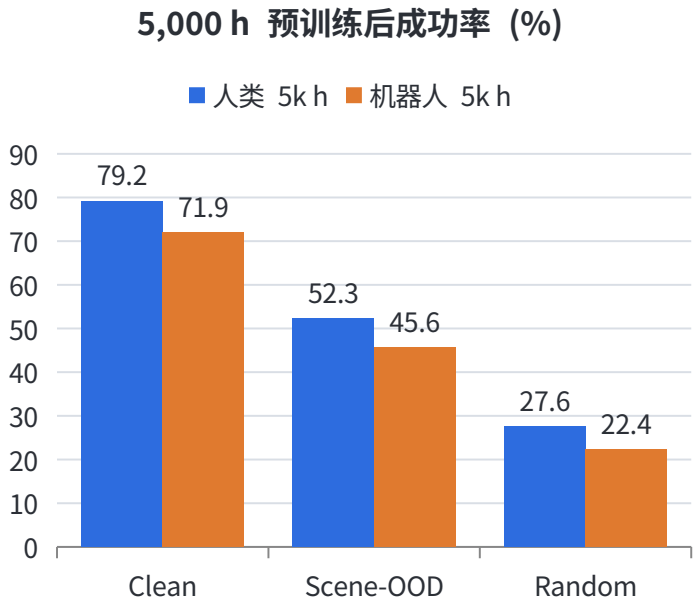

1k h 人类 > 5k h 机器人

Scene-OOD 48.2 vs 45.6 • Random 25.9 vs 22.4

100 h 时机器人略优

Scene-OOD 26.9 vs 25.2 • Random 10.8 vs 8.4

Clean 优势 2.2 → 7.3 pp

机器人预训练 Clean 几乎不随规模上涨

加腕部相机会冲淡人类先验；先做多视角人类数据 mid-training 可补回

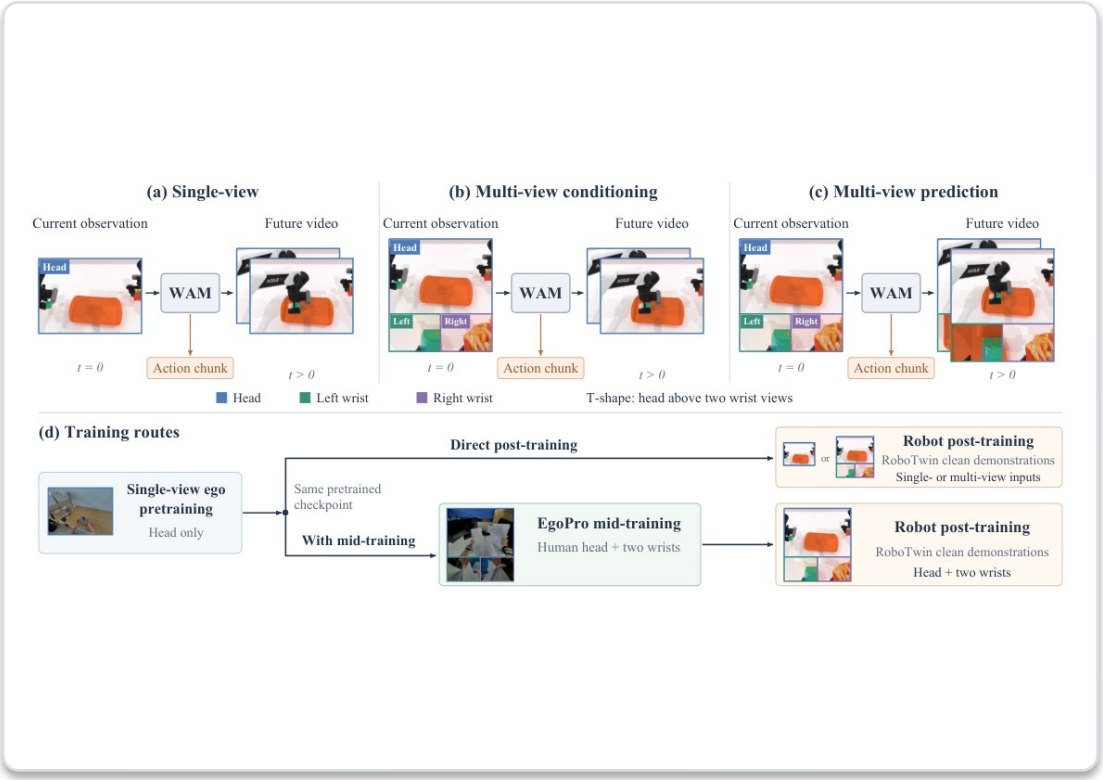

配置（RoboTwin 成功率 %）	Mid-train	Clean	Scene-OOD	Random
IA • 单视角	—	75.68	46.08	22.48
IA • 多视角条件	—	74.60	34.08	12.92
IA • 多视角预测	—	75.04	33.00	14.84
IDM • 单视角	—	88.48	62.00	28.56
IDM • 多视角条件	—	90.56	59.52	29.08
IDM • 多视角条件	**EgoPro**	**90.28**	**61.20**	**30.68**
IDM • 多视角预测	—	89.84	56.28	26.16
IDM • 多视角预测	EgoPro	88.72	58.80	27.36

结论

IA 下直接加腕部视角： Scene-OOD 46.1 → 33.0–34.1%； **IDM + EgoPro mid-training + 多视角条件**： Scene-OOD 61.2%（接近单视角 62.0），Random 30.7%（超过 28.6）→ 被选为最终路线

来源：论文 Figure 13 、 Table 5

HUMANWAM-VANILLA RESULTS

HumanWAM-Vanilla： Clean2Clean 第一，真机 OOD 2.5% → 67.5%

RoboTwin 2.0 （仅 clean 示范后训练， % ）

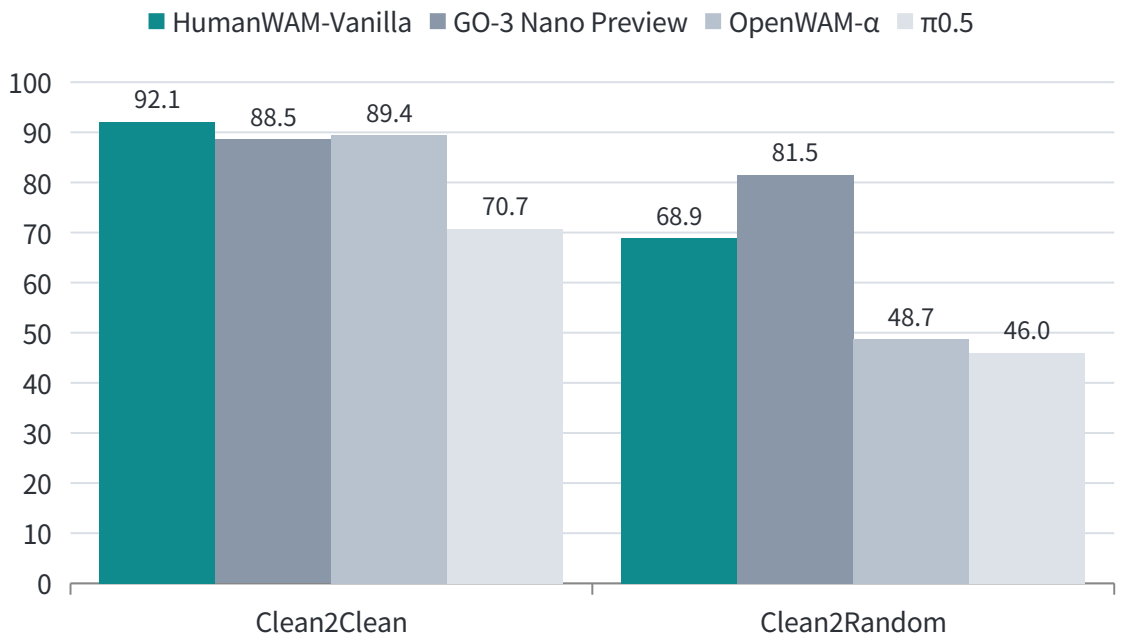

真机 Cobot Magic： 换桌布 / 光照后成功率（ % ，每格 10 次）

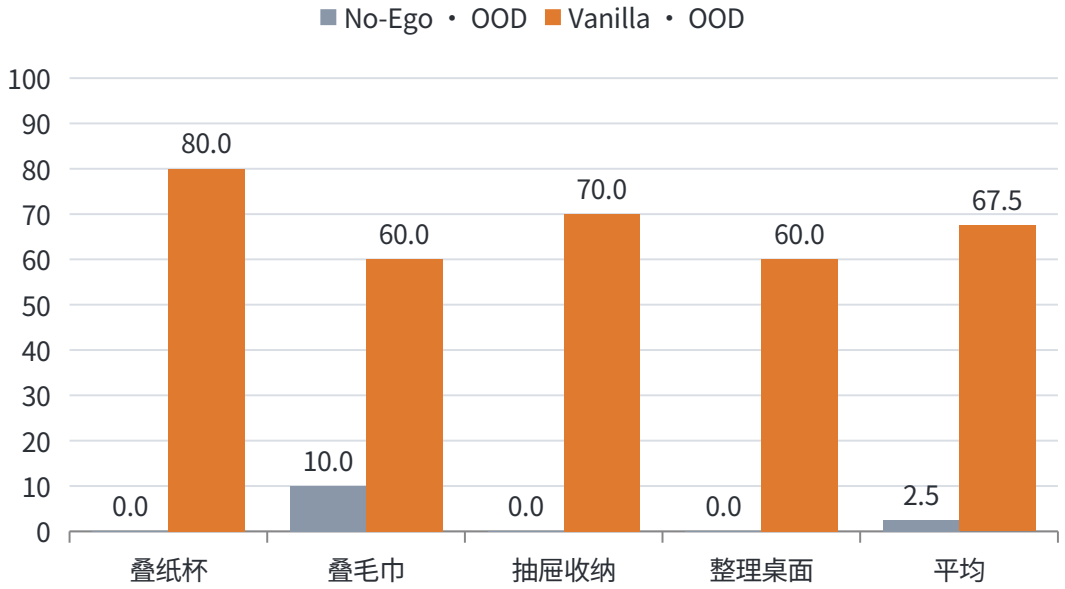

92.08%

RoboTwin Clean2Clean ，表中最高；平均 80.48%

14.17% / 19.00

RoboDojo 平均成功率 / 进度分； Precision 20.5% 、 Long-Horizon 33.0%

57.5 → 87.5%

真机分布内平均成功率（ No-Ego → Vanilla ）

来源：论文 Table 7 、 Table 8 、 Table 9

HYBRID HUMAN–ROBOT MODEL

HumanWAM-Goal： 用目标图像指定任务， 49 维混合动作统一人类与多种机器人

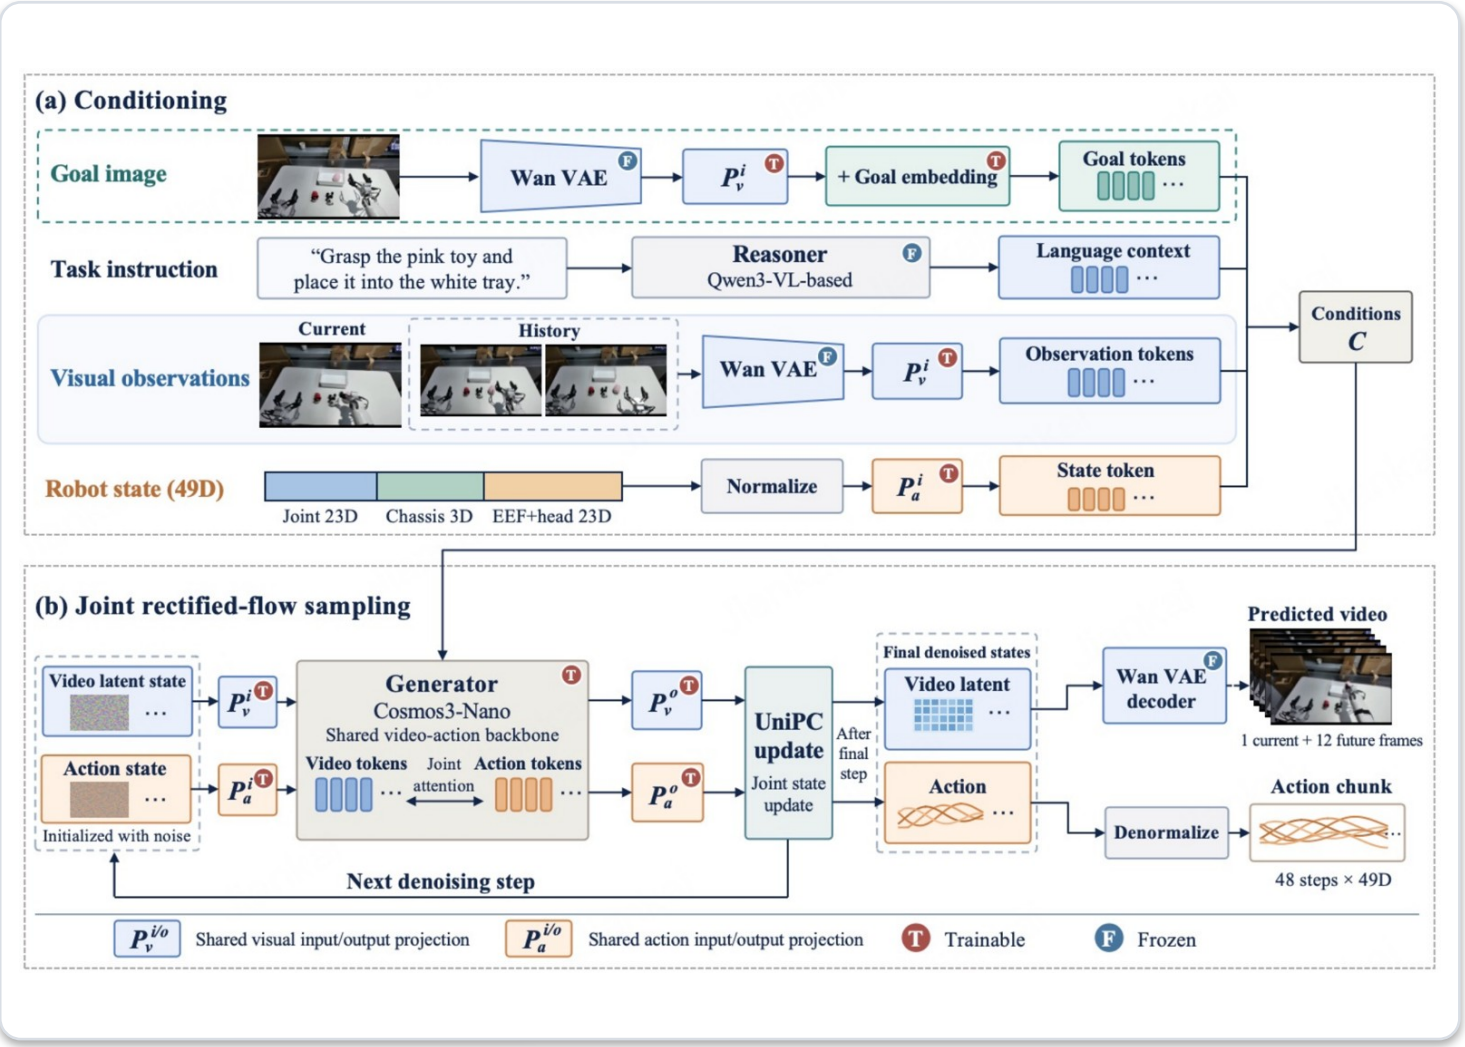

主干

Cosmos3-Nano-16B： 冻结 Qwen3-VL Reasoner + 共享视频 - 动作 Generator

49 维动作

关节 23 + 底盘 3 + EEF • 头部 23； 关节用本体专属投影，并做 dropout

跨本体关键

EEF 块内相对位移 + 夹爪以米计（ ÷0.12 m ）→ 归一化统计直接迁移到新机器人

目标图采样

未来 2–8 s 帧 40% • 终帧 20% • 子任务终帧 20% • 空目标 20%

数据

机器人 14,618 h 固定，加 15,901 / 45,938 h 人类数据

ZERO-SHOT ON AN UNSEEN EMBODIMENT

RoboTwin 零样本：机器人数据扩到 7.3 倍是主力，人类数据再加 2.46 pp

零样本成功率（%）vs 总训练小时（* 含人类数据）

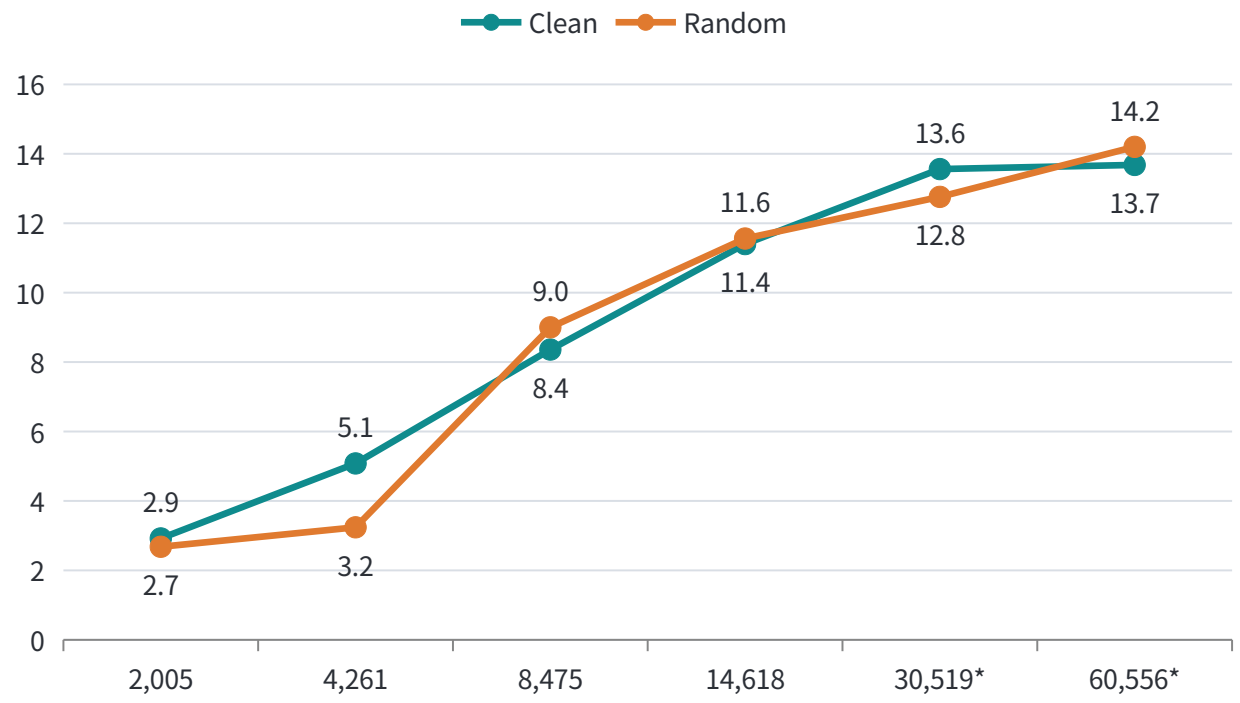

前四点只用机器人数据；后两点固定机器人 14,618 h，分别加入 15,901 / 45,938 h 人类数据

零样本平均成功率对比（%）

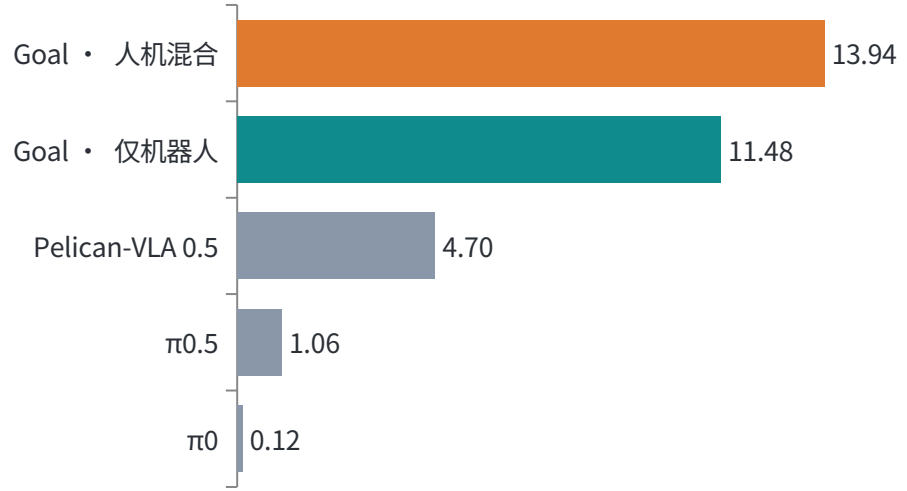

8 → 18 → 22

单 checkpoint 覆盖任务数（≥ 2%），累计 29

+1.44 vs +0.12

人类数据 15.9k→45.9k h：Random vs Clean 增益（pp）

多数开源模型因未发布归一化统计、控制空间不兼容或无公开权重而无法零样本评测（论文 Table 13 标为 ERR0–2）。

来源：论文 Figure 17、Table 13

POST-TRAINING & LEADERBOARD

后训练：人类数据打破机器人数据的 Random 平台，排行榜平均 88.65%

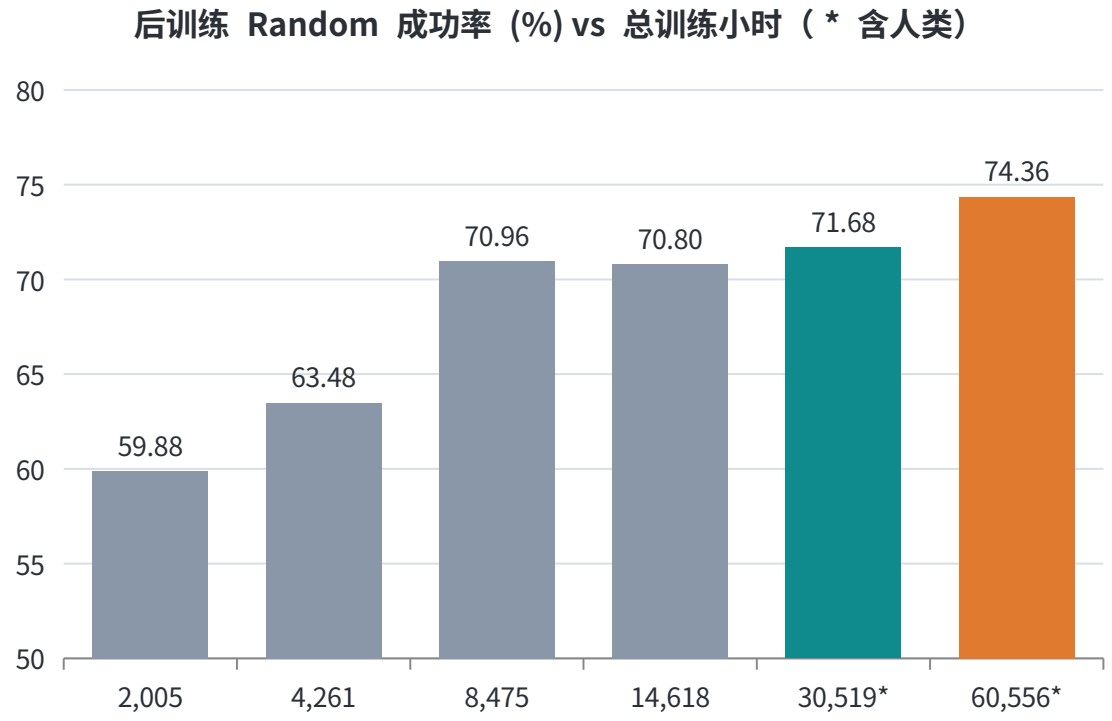

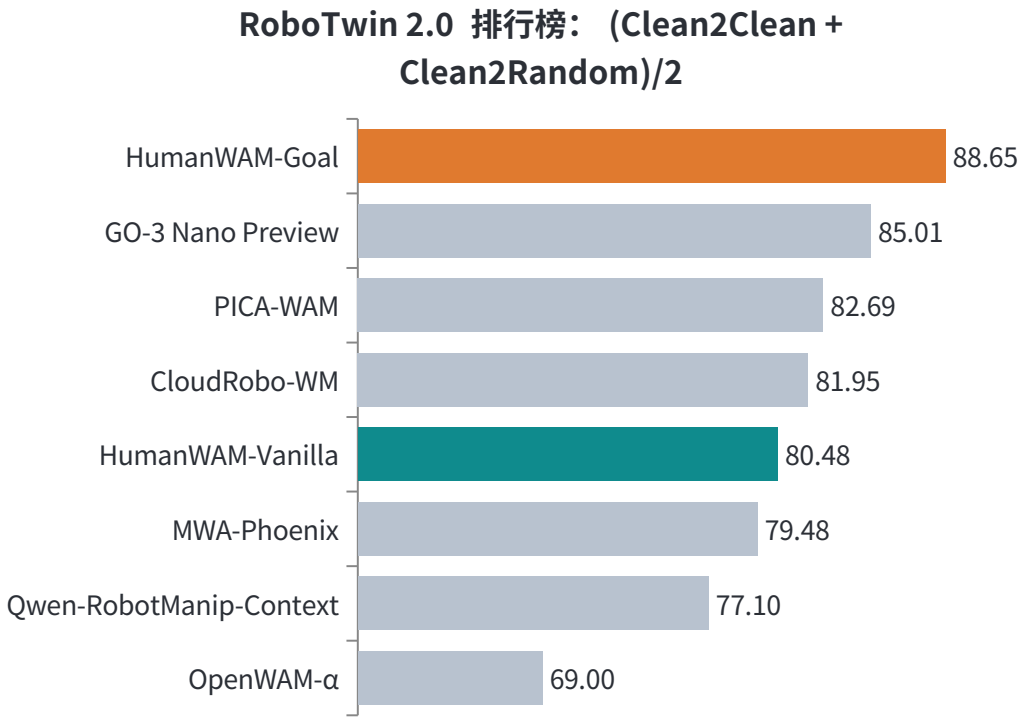

Clean 已饱和： 87.24 → 89.84 （仅机器人）； 加人类后 89.00 / 88.96

+3.56 pp
人类数据对 Random 的受控增益

92.70 / 84.60
HumanWAM-Goal Clean / Random （加增强与改进配方）

+3.64 pp
平均分领先此前第一 GO-3 Nano Preview

来源：论文 Figure 19 、 Table 14

真机零样本： 20 个任务平均 20.0% → 30.5% ，可完成的任务从 10 个增到 16 个

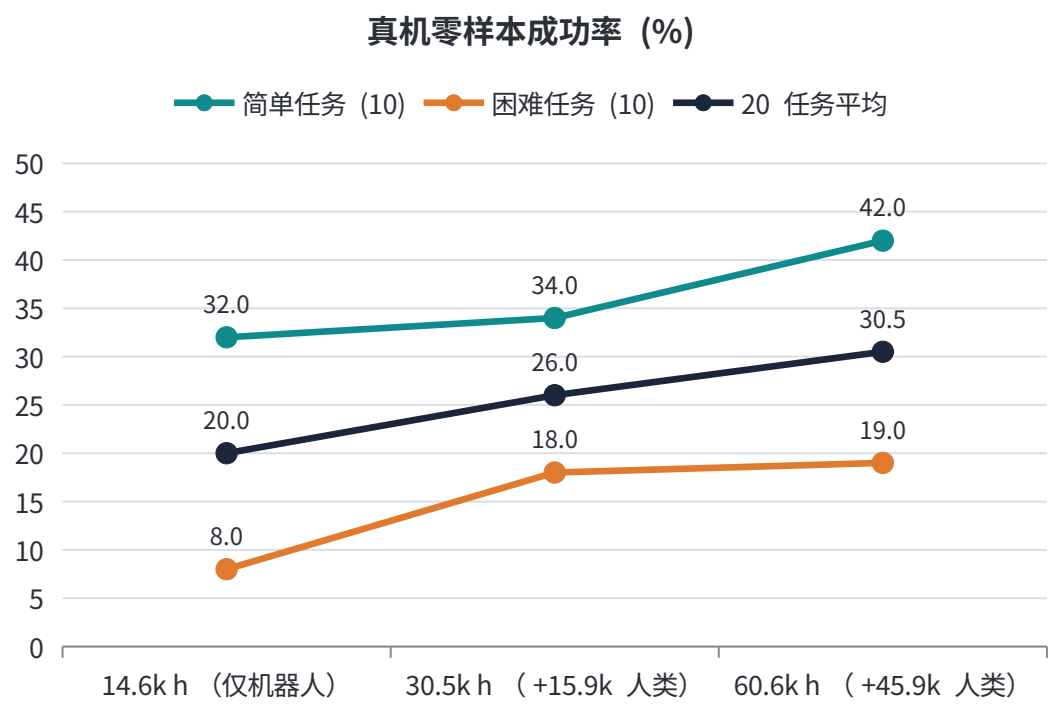

Task	Success rate (%)				Progress score (0–10)			
	14.6k h Robot only	30.5k h + Human	60.6k h + Human	60.6k h Balanced†	14.6k h Robot only	30.5k h + Human	60.6k h + Human	60.6k h Balanced†
Easy								
Grasp and lift a block	80	70	30	90	8.6	7.6	4.9	9.3
Fully compress a sponge	60	30	70	20	8.0	3.0	7.9	4.3
Open a hardcover book	0	0	0	0	0.0	3.6	2.4	2.2
Ring a bell	60	100	70	20	8.4	10.0	8.5	6.7
Click a ballpoint pen	50	0	50	50	5.0	3.0	5.9	6.5
Open a drawer	0	0	10	0	2.0	3.0	3.4	1.5
Push an object away	0	70	30	20	1.2	7.0	6.3	4.4
Grasp and shake a bottle	60	20	90	100	6.3	1.7	9.0	10.0
Arrange blocks	0	10	20	0	1.3	3.4	3.5	2.7
Place a block on a tray	10	40	50	10	1.3	3.9	4.0	0.8
Hard								
Stack blocks	0	20	30	10	0.9	2.6	4.8	1.6
Place a can beside a book	20	40	20	10	2.5	3.9	3.3	2.9
Place a cup on a coaster	10	10	20	10	1.0	1.0	2.6	1.1
Place an egg in a bowl	30	10	30	30	2.6	1.0	3.3	3.0
Place an object on stacked books	20	40	50	50	1.6	4.0	5.0	5.0
Put a glue stick in a pen holder	0	30	10	40	0.0	3.0	1.0	4.3
Stack two bowls	0	30	0	60	0.0	3.0	1.2	6.0
Lift one bottle with each hand	0	0	30	60	0.0	1.6	6.5	7.8
Open drawer and place object inside	0	0	0	0	0.0	1.0	0.4	0.0
Plug a cable into a power strip	0	0	0	0	0.0	0.0	0.2	1.7
Average · 20 tasks	**20.0**	**26.0**	**30.5**	**29.0**	**2.535**	**3.365**	**4.205**	**4.090**
	0 — 100				0 — 10			

Column headers show total training hours; robot data are fixed at 14,618 h.
10 trials per task. † Balanced: 50% robot samples per batch, with 45,938 h of human data.

10 → 14 → 16

至少成功 1 次的任务数（ /20 ）

19% → 27%

robot-balanced 采样后的困难任务成功率

看热图时注意

每任务仅 10 次试验，逐任务不单调（如“抓起方块” 80→70→30 ）；balanced 的 20 任务平均 29.0% ，略低于 30.5% 。

来源：论文 Figure 20 、 Figure 21

EMBODIED IN-CONTEXT LEARNING

具身上下文学习：参数冻结，只换目标图，机器人就改变执行方式

后训练策略 · 同一场景三种目标（Fig. 24）

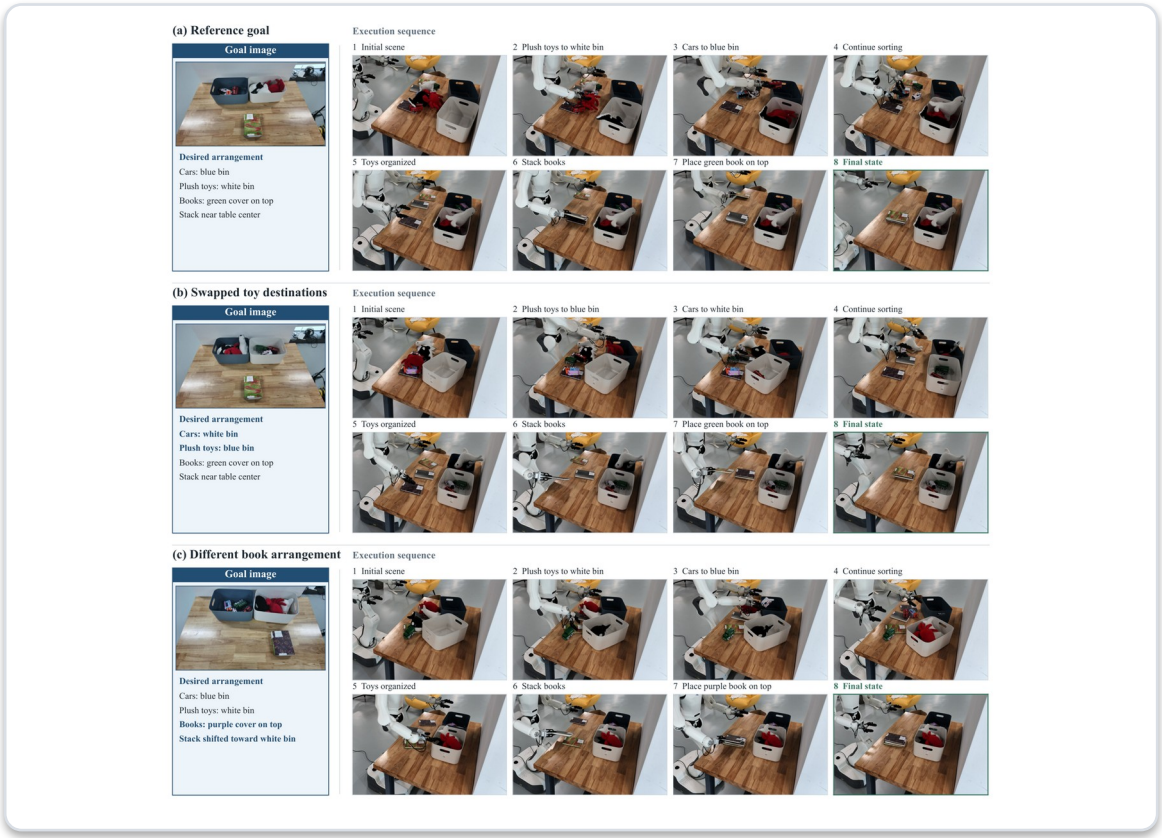

跨具身 · 目标图来自人类第一人称照片（Fig. 26）

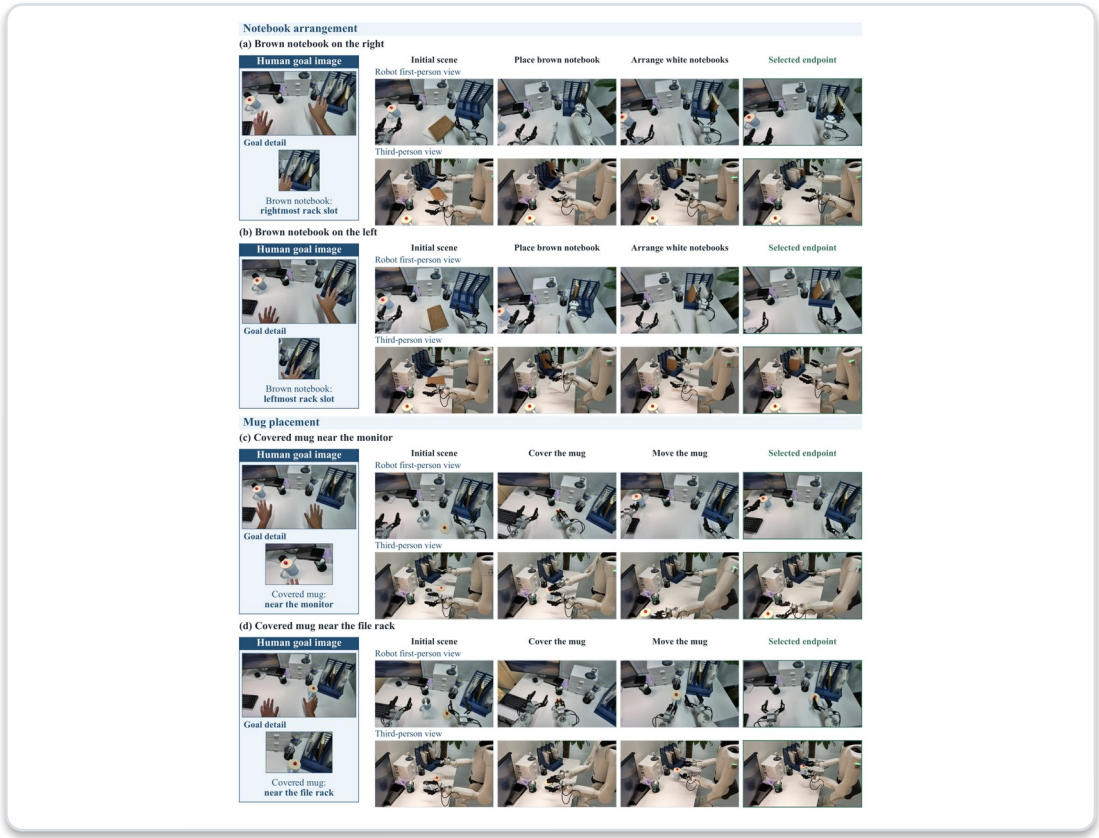

能力：改变放置位置、类别→箱子映射、叠放顺序、选择哪层抽屉；预训练模型（未后训练）已具雏形（Fig. 23）。**局限：**均为单次 rollout 的定性展示，无成功率统计。

来源：论文 Figure 24 、 Figure 26

LONG-HORIZON EXECUTION

长程任务：后训练后可连续完成 14 阶段桌面整理与跨区域移动家务

14 阶段办公桌整理（Fig. 27）

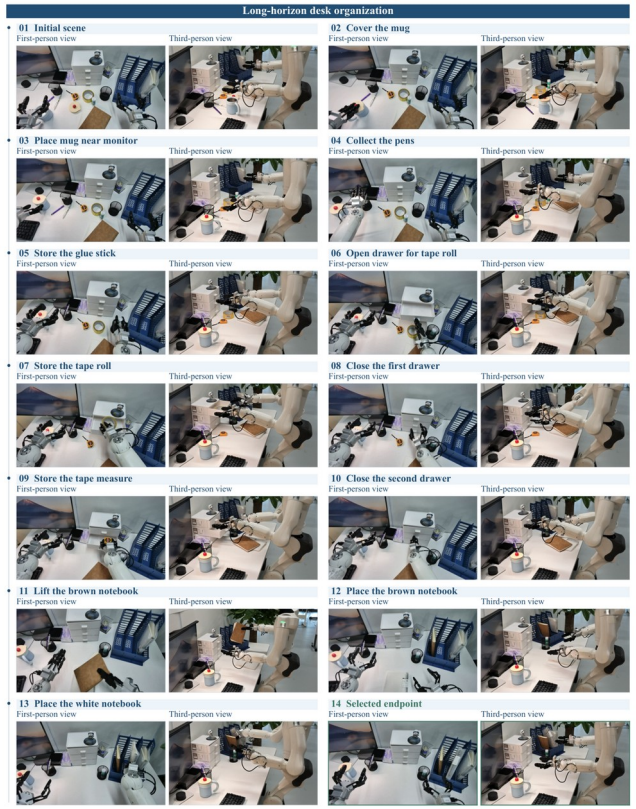

28 关键帧跨区域移动家务（Fig. 28）

分拣玩具 | 叠书 | 去边桌收瓶 | 扔进垃圾桶 | 椅子上收衣 | 放入洗衣篮 | 回到桌面

来源：论文 Figure 27、 Figure 28

CRITICAL ASSESSMENT

批判性看待：结论方向可信，但几处数字需要打折

缩放律统计偏弱

每条曲线 5–7 个点、单种子；每个设置用测试集挑最佳 checkpoint → 数字偏乐观，宜视为经验趋势

多样性斜率易误读

两组共享 5k h 终点；小规模下覆盖更广的 matched 组反而更高 → 更直接结论是“覆盖越广越好”

SOTA 非人类数据独功

Goal 换了 16B 主干、加机器人数据与增强； RoboTwin 目标图由 GPT Image 2.5 合成，与纯语言基线不完全可比

真机零样本噪声大

每任务仅 10 次；逐任务非单调； robot-balanced 总平均 29.0% < 30.5%

零样本绝对值仍低

RoboTwin 约 14%、真机约 30%；人类数据增量为数个 pp 量级

定性展示为主

上下文学习、长程任务均为单次 rollout；Vanilla 真机只与 No-Ego 对比

TAKEAWAYS

给研究者的四条可用结论

01 **必须预测人类动作 + 做跨源对齐**

仅视频预测对 OOD 几乎无用；对齐让 Random 16.8 → 26.4%

02 **扩覆盖，而不只是堆时长**

同等时长下，任务与场景覆盖越广，下游越好

03 **用分布外指标衡量人类数据**

Clean 很快饱和；收益集中在 Scene-OOD / Random

04 **混合训练要保住机器人样本比例**

1:1 采样让困难任务 19 → 27%；目标图是更明确的任务接口

开源内容

- Open-HumanWAM-50K 语料（5 万小时）
- 数据清洗与动作对齐流程
- 预训练 / 后训练流程
- HumanWAM 预训练与后训练权重
- 推理代码与仿真评测套件（含评测种子）

一句话： 人类视频规模主要换来机器人的分布外泛化；与机器人数据混合并以目标图驱动，开始出现零样本执行与上下文学习。