论文解读 | arXiv 2611.08286

Interactive Visual Gym

Evaluating Visual Interaction Models with Simulated Users in Interactive Worlds

让视觉助手在“会犯错的模拟用户 + 可执行世界”中闭环接受检验

Chenhao Zheng, Zixian Ma, … , Ranjay Krishna, Ran Xu, Honglu Zhou
University of Washington · Salesforce AI Research · 首次提交 2026-11-05

一句话总结

最强 VLM 仅能按时完成约一半任务，且常常“说得太晚”

把视觉助手评测从“回放录像、对照参考答案”改为在做饭 / 家务 / 手机设置三个可执行环境中，与有画像、会犯错的 VLM 模拟用户闭环交互；该环境同时可作为 RL 训练信号。

53.4%

最强模型 Gemini 4 Argon
三环境平均按时完成率

−27.8 pt

计入实测延迟后
Argon 在 CookSim 成功率
60.9 → 33.1

78.5%

交互质量指标与
真人偏好一致率
Kendall τ = +0.57

+8.9 pt

Qwen3.5-4B
经 12 步 GRPO 后验证集
成功率 33.3 → 42.2

离线回放测不出“助手的话改变了什么”，必须闭环评测

离线回放（现有基准）

用户动作预先录好，与助手回复无关；对照参考回复打分 → 无法衡量对任务结果的因果影响与时机

闭环仿真（本文）

助手回复 → 模拟用户决定听不听 → 世界状态改变 → 任务成败；同时计入推理延迟

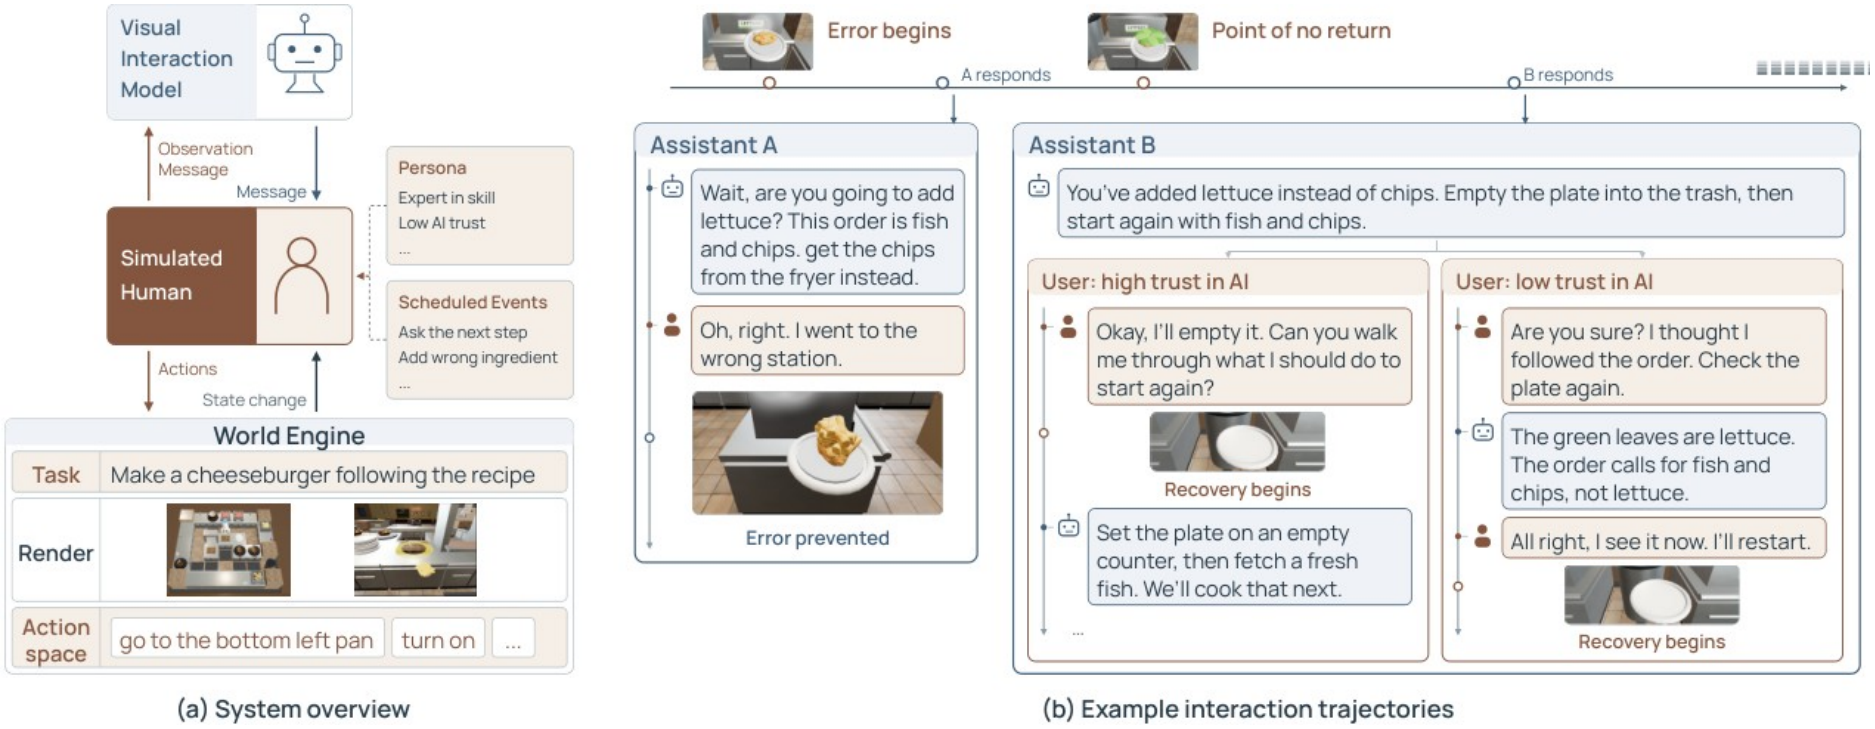

(a) System overview

(b) Example interaction trajectories

三个可执行环境：用“人话”级别的语义动作操作世界

CookSim · 150 场景

仿 Overcooked 自研； 5 个菜谱 × 2 布局；要求食材处理状态与装盘顺序

VHSim · 75 场景

基于 VirtualHome (Unity)；导航 + 物体操作，如把碗装进洗碗机

ScreenSim · 90 场景

复刻 iPhone 17 设置；多步配置，且不能改动无关设置

场景图追踪进度

子目标 = 局部图状态条件，与执行路线无关

模拟用户：按进度注入“计划外事件”，并用四维画像制造差异

A 预设计划外事件（以 CookSim 为例）

执行错误	重复 / 遗漏 / 跳步；装盘顺序错；用错食材；加多余食材；生食上桌；无人看管烹饪
时间类提问	动作顺序；计数；已用时间；持续时长；事件回忆
主动请求	“X 好了告诉我”——在条件成立时提醒
计划变更	修改菜谱；插入副任务

B 用户画像（四轴 × 三级）

技能	**低 / 中 / 高** 规划与预判	对助手隐藏
对 AI 的信任	**低 / 中 / 高** 接受建议所需证据	对助手隐藏
执行速度	**谨慎 / 平衡 / 快速** 细致 vs 快速执行	告知助手
打扰偏好	**逐步 / 适中 / 仅必要** 对频繁指导的接受度	告知助手

错误事件机制： harness 接管用户动作队列强制犯错 → 用户只用“嘴”配合 → 被助手说服并 accept 后才交还控制权。全基准共 1,113 个事件，平均 3.53 个 /episode 。

评测同时看结果、时机与每句话的质量，且计入推理延迟

延迟如何进入仿真

$$d = \lceil \ell / \Delta \rceil$$

ℓ：助手实测推理延迟； Δ ≈ 1.2 s / tick （VHSim 中 1 tick = 走 1 米）

在 t 时刻观测生成的回复，到 t + d 才送达

等待期间用户继续执行已排队的动作 → 建议可能已经过时

主对比用固定 2 tick；另做实测延迟消融

按时成功 In-time success

引擎判定目标达成，且用时 ⩽ 2×(无错参考时长 + 事件余量)

错误检测 / 错误阻止

窗口内正确指出错误；阻止还要求用户在不可逆点前改正

交互质量（5 维 · 10 条 rubric）

事实接地 · 情境相关 · 可执行 · 意图承接 · 简洁；两个 LLM 评委对照世界状态打分，事实错误整轮记 0

时间问答 / 主动提醒

参考答案由执行历史推导；提醒须落在状态决定的时间窗内

最强模型也不可靠：家务环境成功率普遍 ⩽ 16% ，开源模型远落后

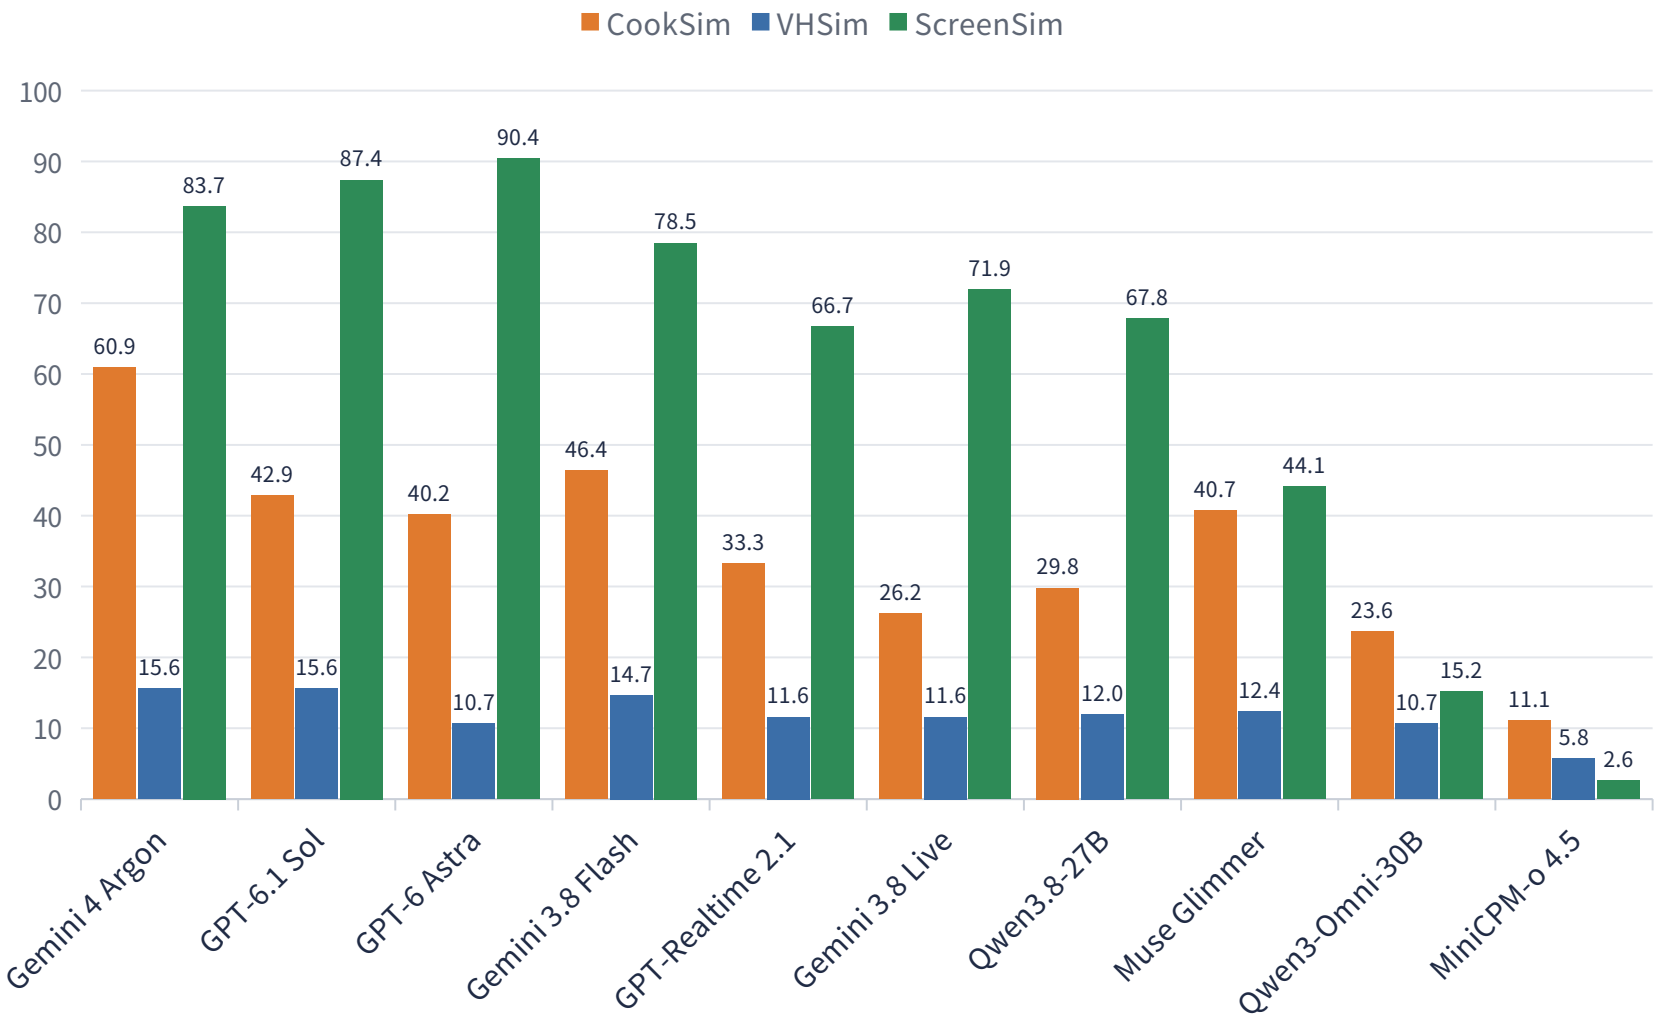

按时成功率（%）

53.4%

Argon 三环境平均成功率，排名第一

⩽ 15.6%

VHSim 中所有模型的成功率上限

70.2 / 71.4

Argon 在 CookSim 的事实接地 / 可执行性得分，是其短板

任务成功 ≠ 指导质量：完成任务不能证明助手说得好

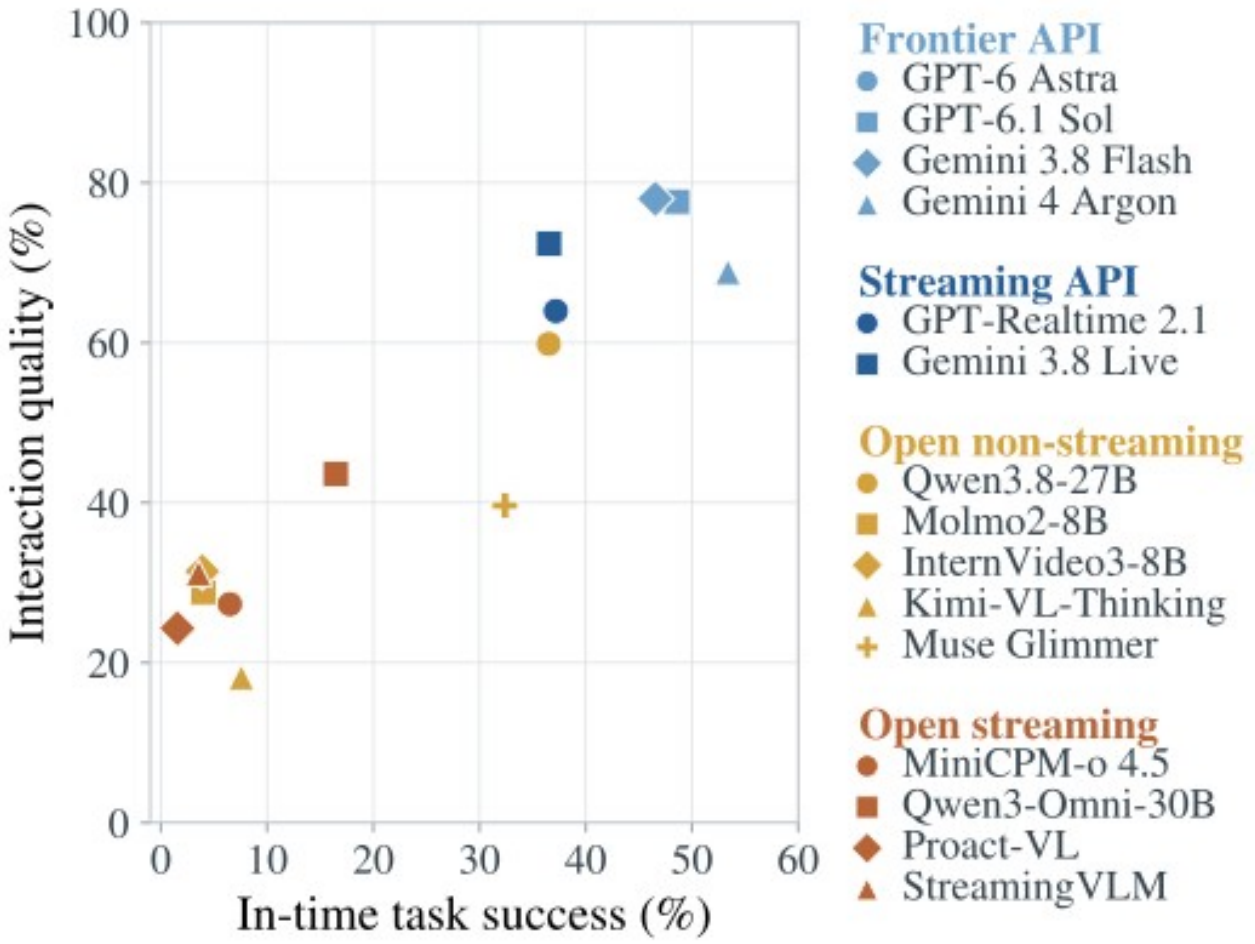

整体正相关，但有显著反例

Muse Glimmer 在 CookSim 成功率 40.7% > Astra 40.2%，交互质量却仅 21.6 vs 76.0

流式模型：说得不错，做得不够

Gemini 3.8 Live 平均交互质量约 72，成功率仅约 37；可能是低延迟与推理 / 规划能力的权衡

开源模型整体落后

多数开源 VLM 聚集在成功率 <8%、交互质量 18–32% 的左下角

结果 ③ 延迟消融

计入真实延迟后，“聪明但慢”的模型掉队，排名随之改变

CookSim 按时成功率（%）

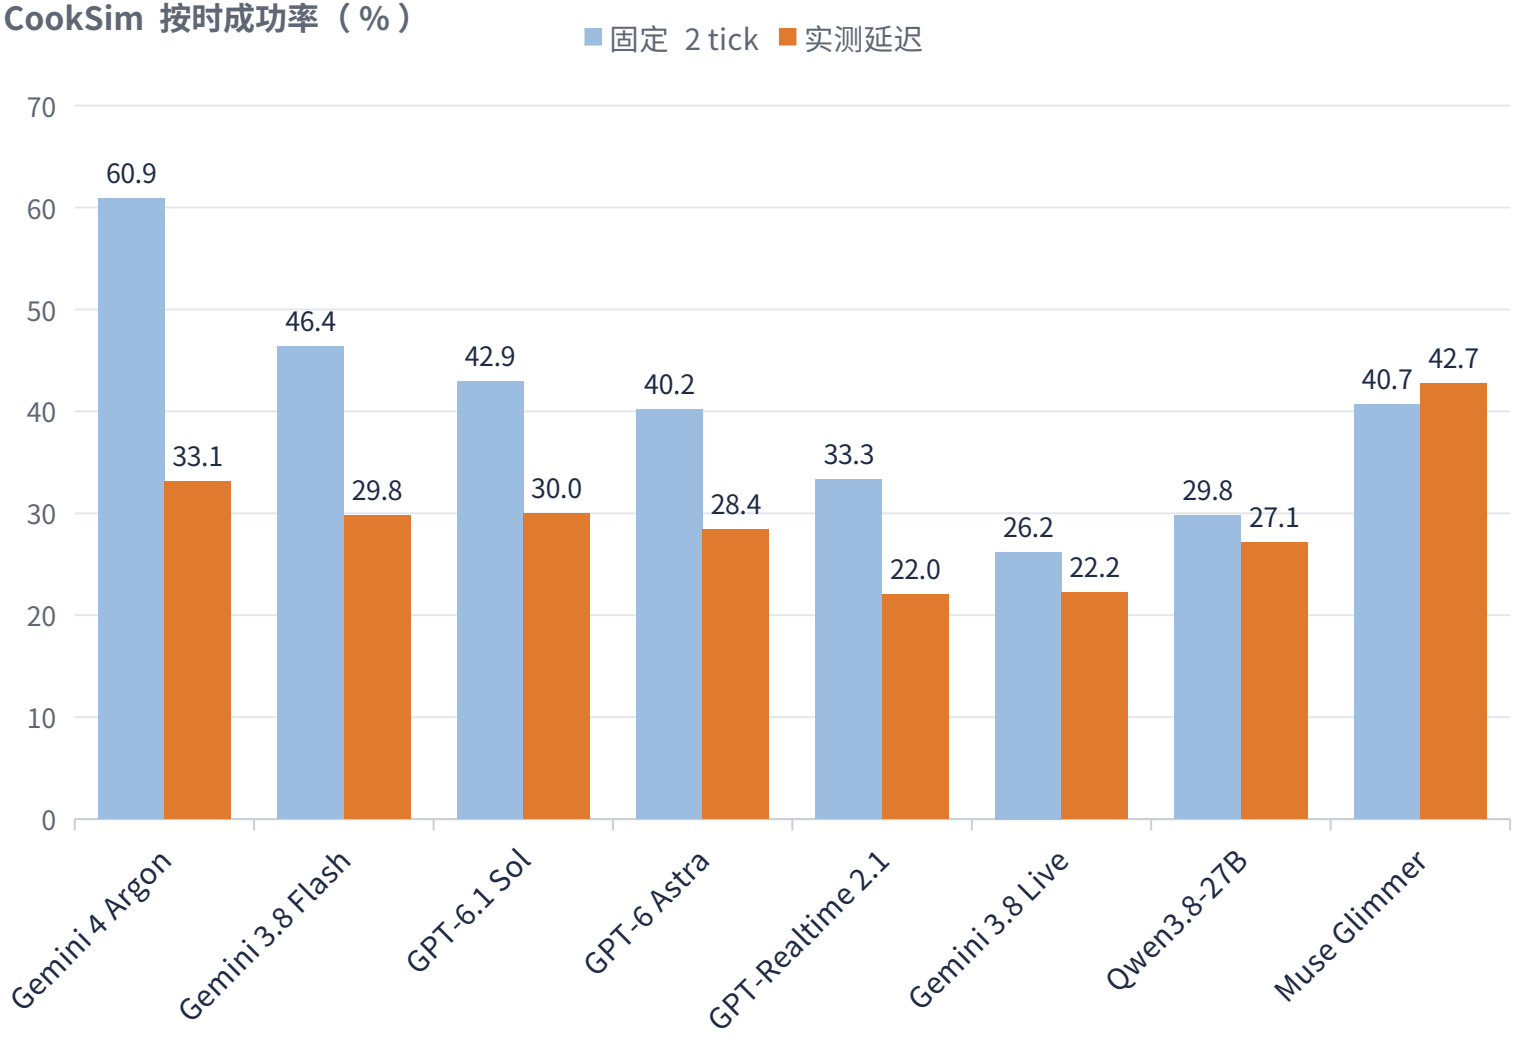

错误阻止率（CookSim, Tab.20）

模型	平均延迟	固定→实测
Gemini 4 Argon	6.5 s	**62.3 → 39.9**
Gemini 3.1 Pro	13.2 s	**57.1 → 19.3**
GPT-6 Astra	6.6 s	**48.5 → 36.8**
Muse Glimmer	1.5 s	**45.0 → 45.5**

排名反转

Argon： 60.9 → 33.1 （− 27.8）

Muse Glimmer： 40.7 → 42.7，成为 CookSim 第一

警告送达时，用户往往已经犯下错误

典型失败：建议过时、喋喋不休，用户体验受损

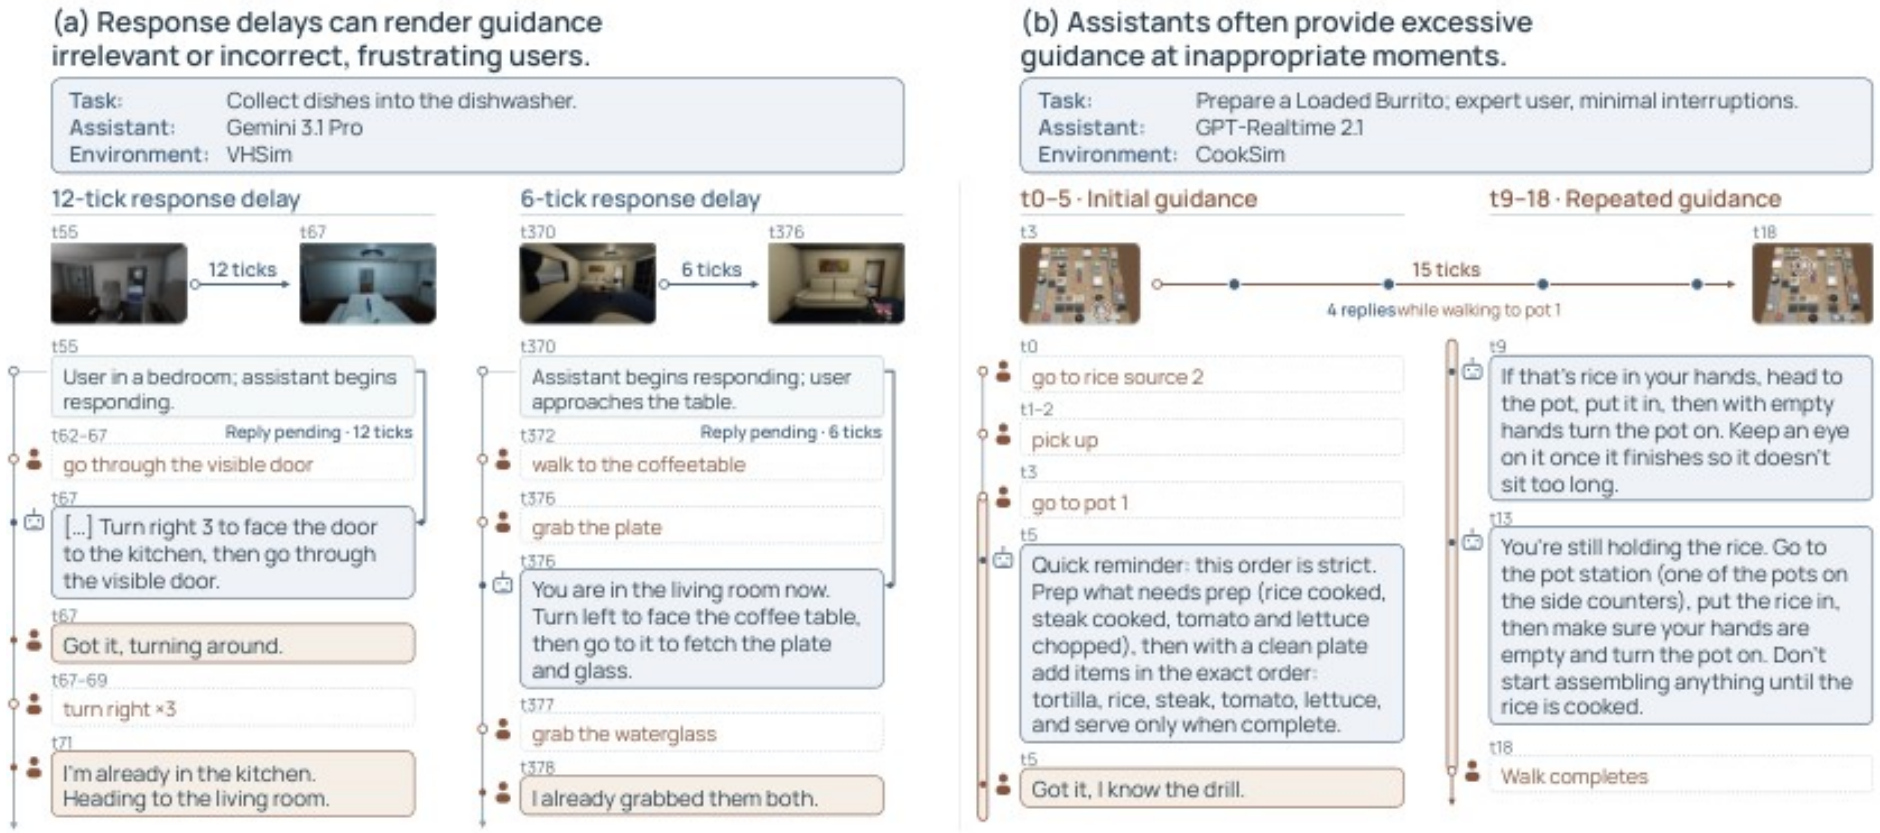

(a) 延迟 → 建议过时（VHSim · Gemini 3.1 Pro）

用户已进厨房，助手仍指挥“右转 3 次去厨房”，用户照做后动作被拒

(b) 过度指导（CookSim · GPT-Realtime 2.1）

专家用户偏好少打扰，助手仍在 15 tick 内重复指导 4 次

边协助边答题很难：动作计数是普遍短板，开源模型常忘记问题

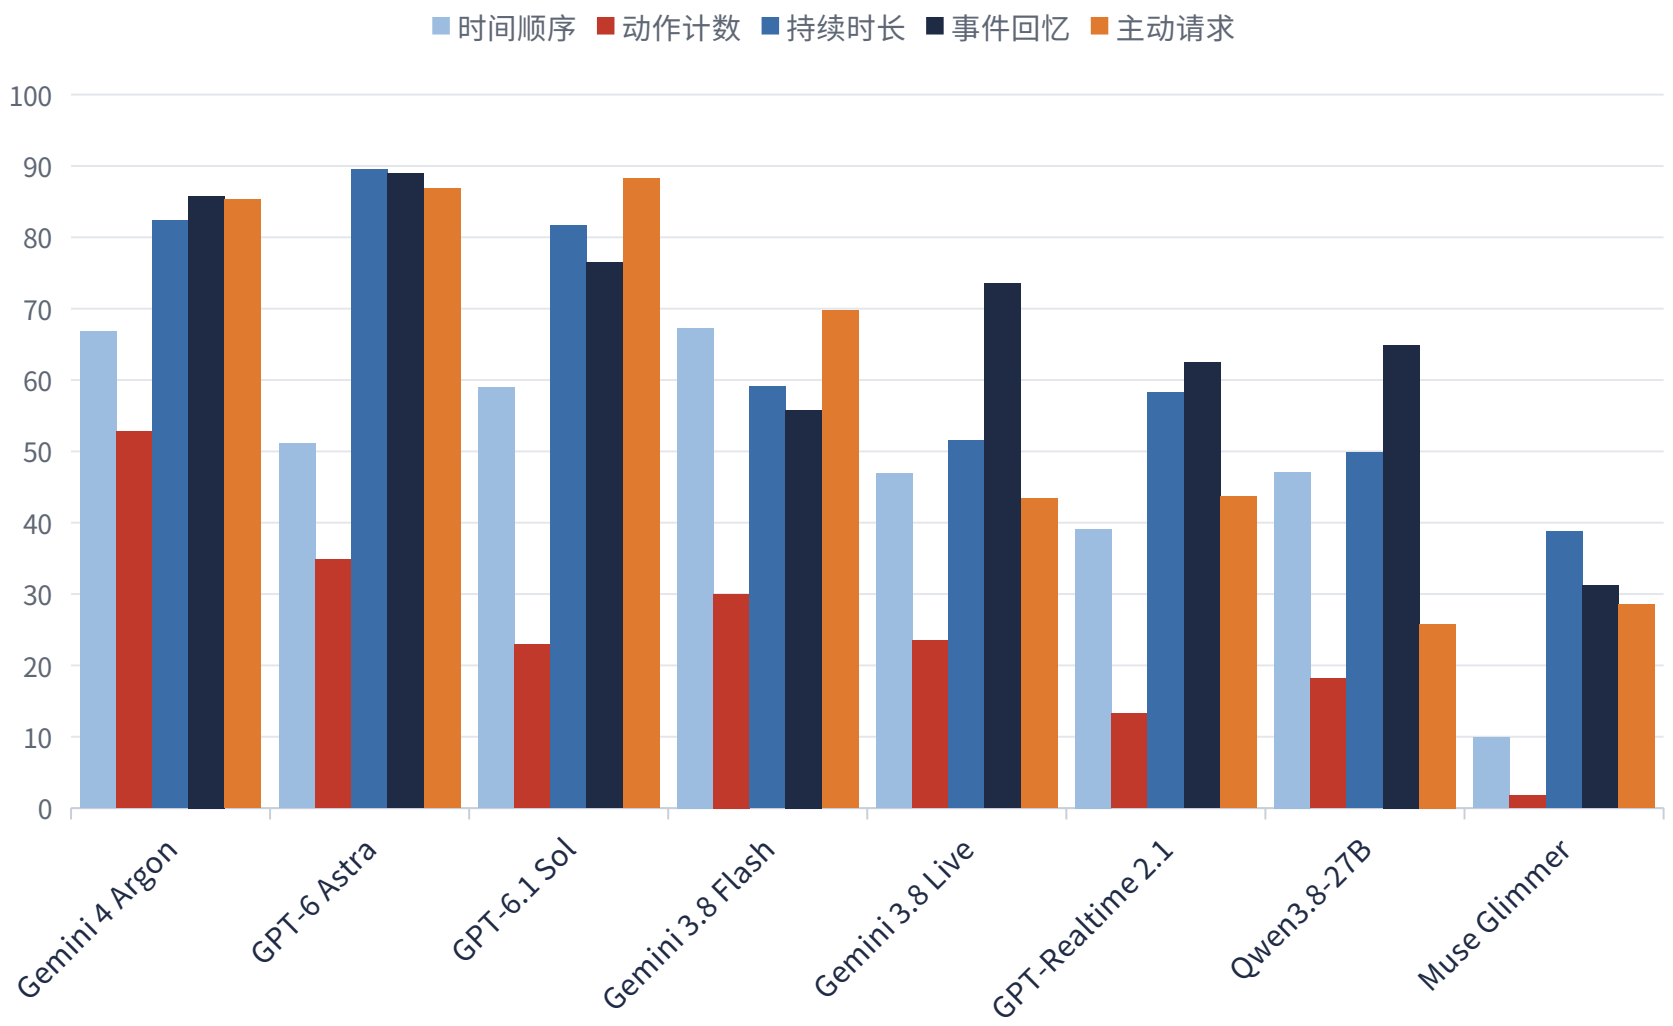

79.0 / 78.6

Argon / Astra 总分领先

22.9–52.8

前沿模型动作计数得分区间（Sol 最低）

1.3 / 3.4

Proact-VL / StreamingVLM 总分，几乎完全失效

人类研究：指标与人类偏好较一致，但模拟用户比真人“话痨”得多

交互质量指标 vs 真人偏好

78.5%

两两比较一致率 · Kendall τ = +0.57

最大偏差：说话频率

每 100 tick 发言 **真人 0.39 vs 模拟 16.1**

10 tick 内回复 **真人 2% vs 模拟 79%**

真人 112 个自然错误均落在预设错误类型内；另有 51 个超出分类体系的行为

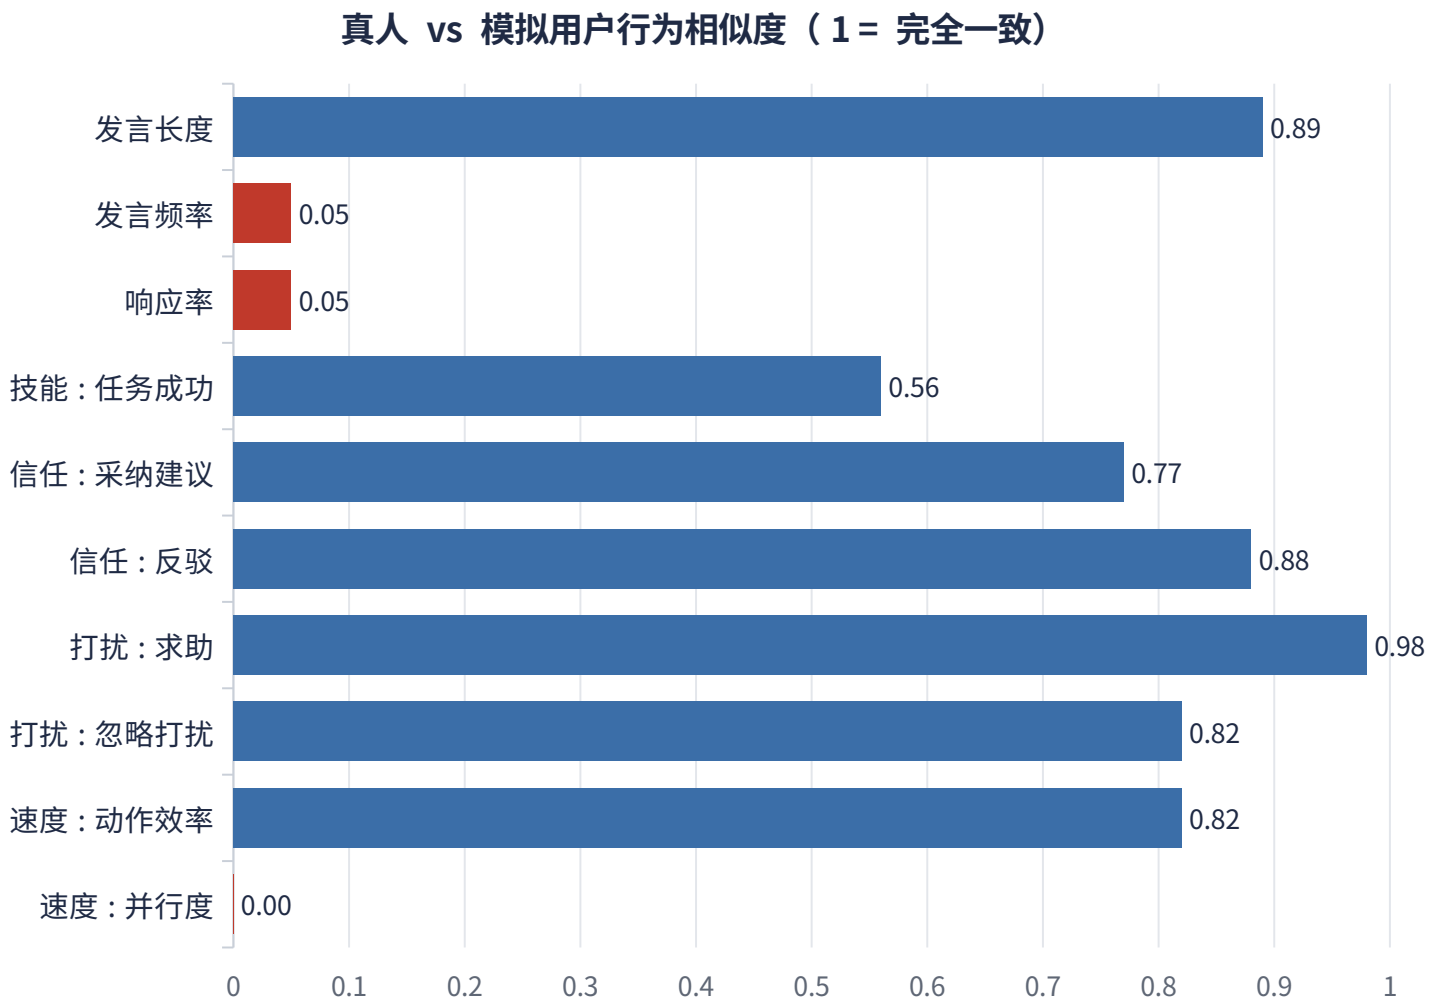

可作 RL 环境： 12 步 GRPO 即提升成功率，但检测召回率下降

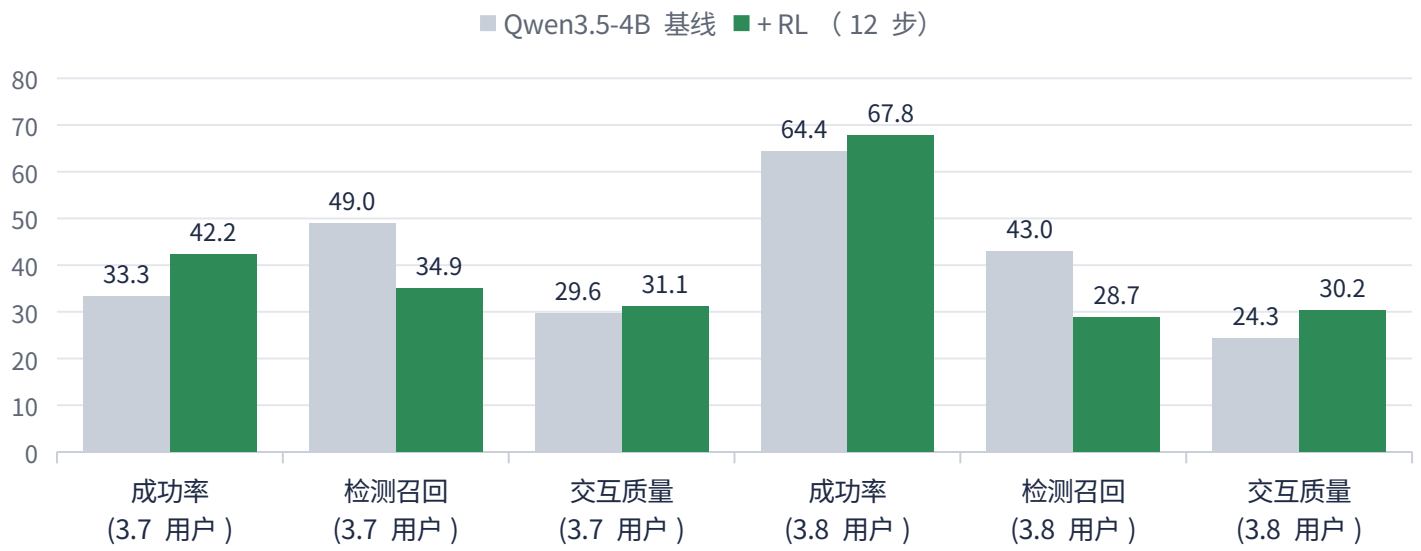

整形奖励

r = 1[成功] + 0.30 · 1[阻止错误] − 0.02 · min(误报 , 15) − 0.05 · min(T/200, 1)

注意： 验证集与训练集共享菜谱 / 布局，无冻结测试集； ScreenSim 上 RL 无可靠提升（App.C）

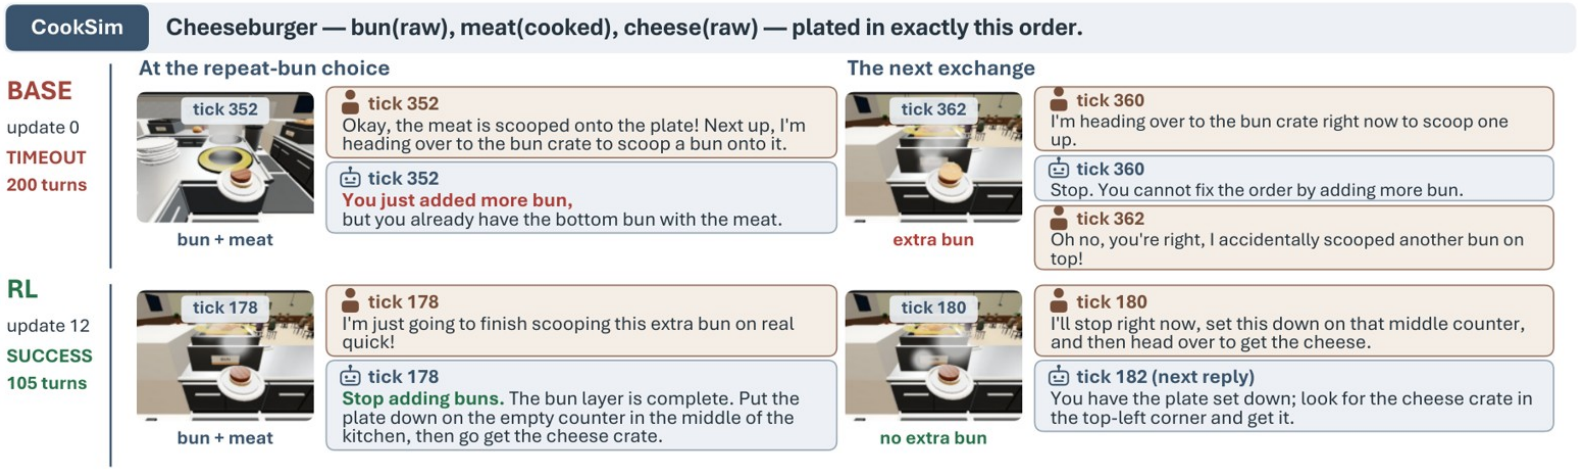

Fig.7 芝士汉堡

BASE： 误判状态、提醒太晚 → 多加面包， 200 轮超时

RL： 动手前即喊停 → 105 轮完成

局限：结论能否迁移到真人，取决于模拟用户的保真度

模拟用户过于健谈

发言频率 / 响应率相似度仅 0.05；并行操作相似度 0.00

依赖用户模型选择

同一助手： Gemini 3.1 Pro 用户 28.9% vs Qwen3.8-27B 用户 2.2%

用户拥有特权信息

模拟用户读取结构化世界状态，真人只能靠视觉感知

可能的同族偏差

Gemini 3.7 Flash 同时担任用户与评委之一，论文未分析

人类研究规模有限

45 人、仅 CookSim，助手版本与主基准不同

RL 仅为概念验证

12 步、无冻结测试集； ScreenSim 上无可靠提升；环境难度不均衡

总结：视觉助手评测应从“对答案”走向“看效果”

01

闭环才能测出因果与时机

三个可执行环境 + 会犯错、有画像的模拟用户； 315 个场景，事件按任务进度触发

02

当前 VLM 远非可靠助手

最佳平均成功率 53.4%；事实接地、可执行性、动作计数是短板；计入延迟后排名改变

03

可训练，但仍需验证泛化

GRPO 12 步后成功率提升 3.3–8.9 个百分点；模拟用户保真度与跨域泛化有待后续工作