论文解读 · arXiv 2611.08373 · 2026-11-05

SLA: Scaling Spatial-Language-Action Model via Continual Pre-training

用“隐式 3D 表征对齐 + 持续预训练”，把 2D VLA 升级为空间感知的机器人基础模型

Fuhao Li, Wenxuan Song, Qizhou Huang, Ziyang Zhou, Jingbo Wang, Junwu E, Pengwei Wang, Yan Wang, Shunbo Zhou, Haoang Li

港科大（广州） · OLA Dimensions · 北京智源人工智能研究院 · 清华大学

一句话总结

训练期加一个 3D 对齐损失，推理零开销，四个基准 + 真机全面领先

SLA 以 π0.5 为起点，在 ~1.7M 条异构机器人轨迹上做**持续预训练**：训练时让 VLA 多层视觉 token 与**冻结的 OmniVGGT 3D 特征**做余弦对齐（门控融合 + 状态 dropout），后训练继续对齐；**推理时结构与 π0.5 完全相同，不需要深度或相机标定。**

87.4%

LIBERO-Plus 总体成功率

π0.5： 84.4% （+3.0）

72.3%

RoboTwin 2.0 Clean2Random

π0.5： 46.0% （+26.3）

33.9%

RoboDojo-Real 成功率

π0.5： 12.8% （+21.1）

+24.0

8 个真机条件平均（百分点）

83.8% vs π0.5 59.8%

问题与动机

2D VLA 的视觉 token 里几乎没有 3D 结构

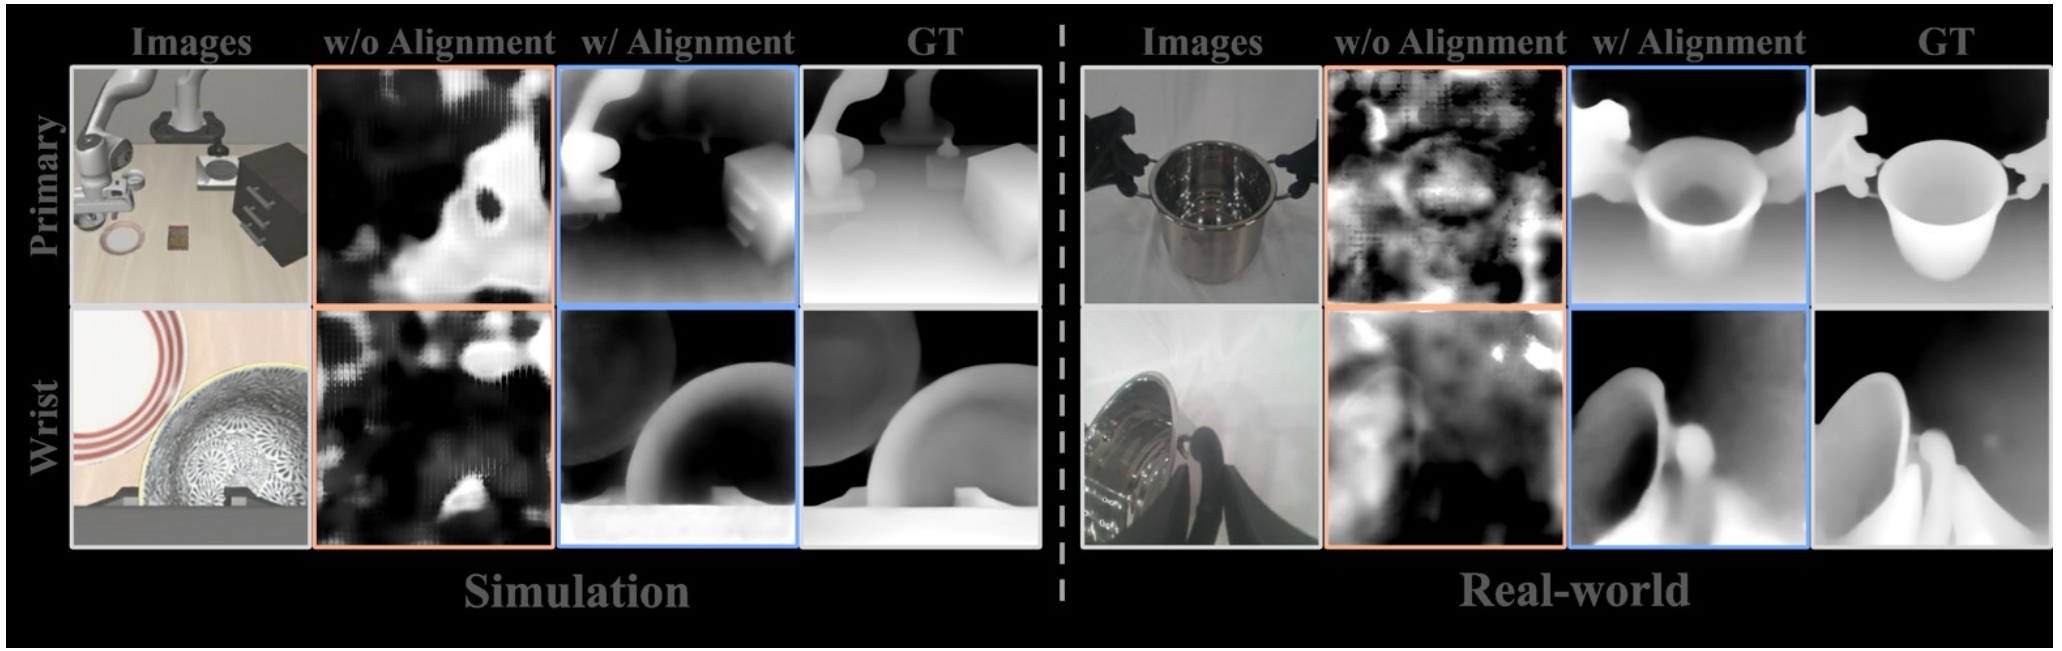

2D 预训练缺 3D

视觉表征继承自 2D 图文 VLM，空间监督往往只在下游任务才引入。

显式 3D 输入难扩展

深度 / 点云噪声大、相机类型与标定各异、大量公开数据集没有深度，且要改网络结构。

仅后训练对齐不够

Spatial Forcing 只在后训练做隐式对齐，空间能力是单任务附加项，没沉淀到基础模型。

方法总览

三步走：统一异构数据 → 训练期 3D 对齐 → 推理保持原架构

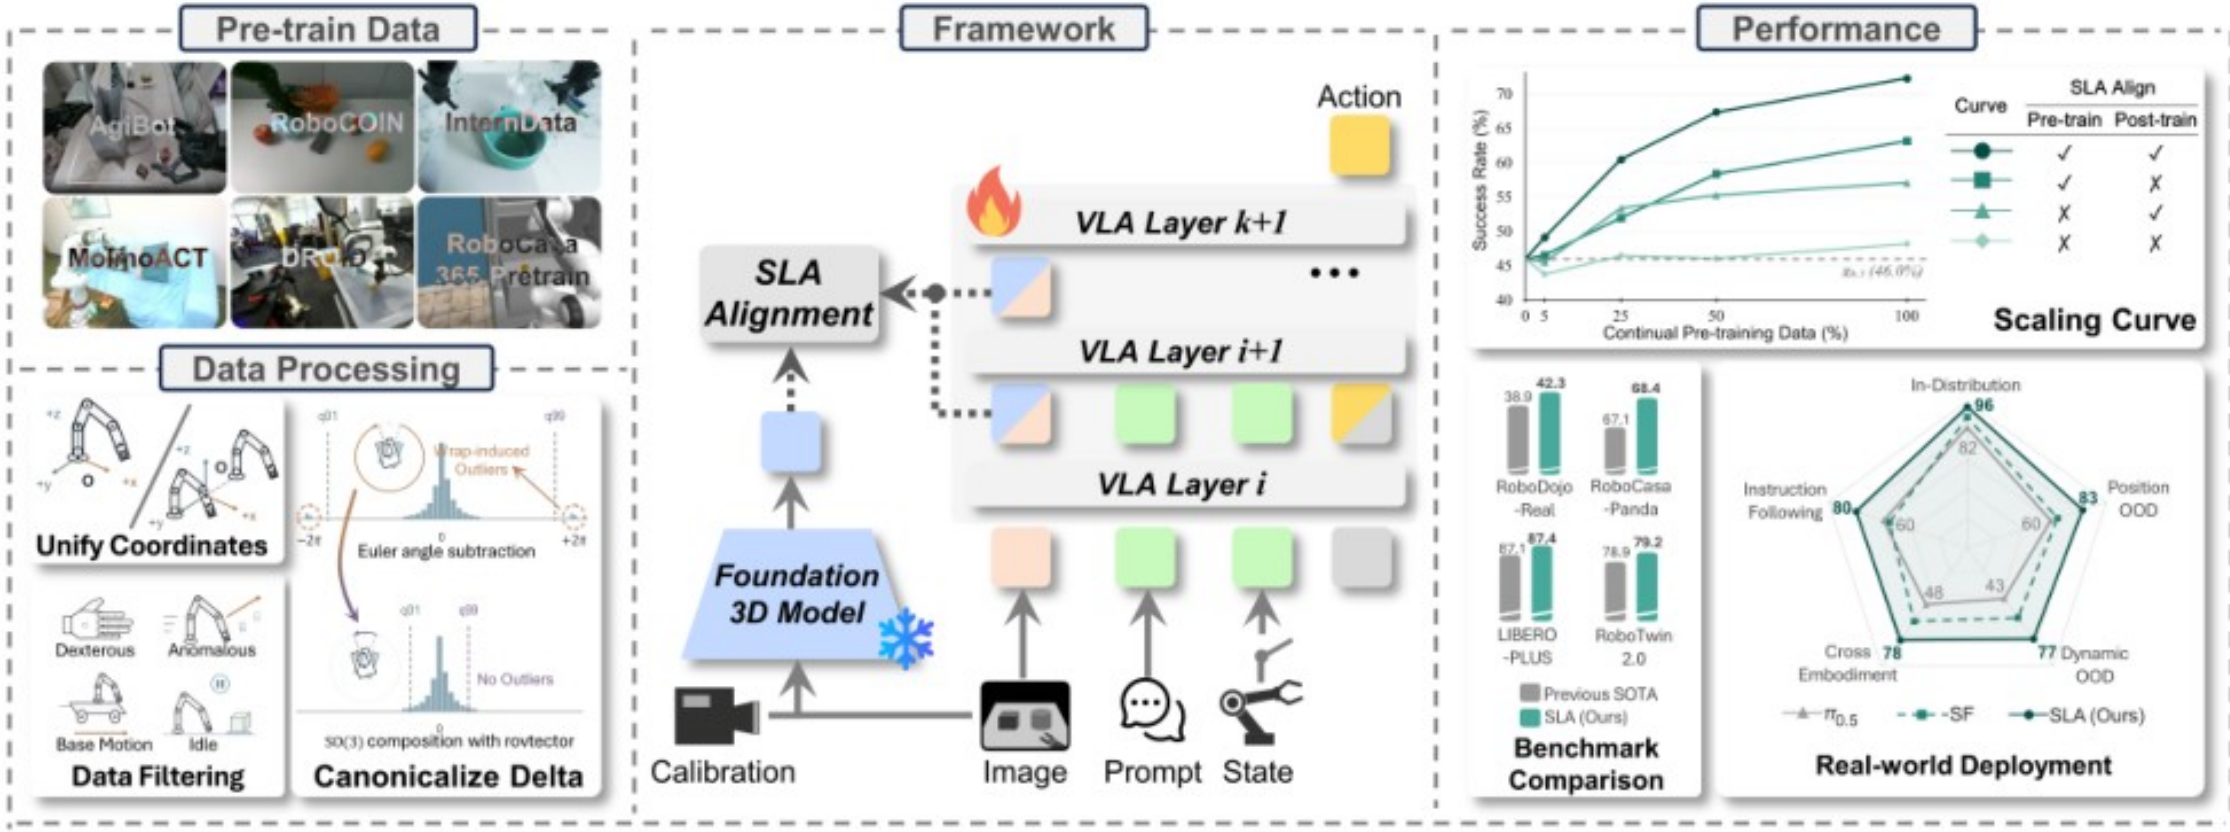

① **数据** 6 个公开数据集，统一 EEF 坐标与动作表示

② **训练** VLA 多层视觉 token ↔ 冻结 OmniVGGT 特征

③ **部署** 教师 / 投影器 / 门控全部丢弃，零额外开销

方法细节

只加一个训练期辅助损失： $L = L_{action} + \alpha \cdot L_{align}$

① 隐式空间对齐

$y = R[\, f^{3D}(I) + E \,]$

$L_{align} = 1/N \cdot \Sigma\, [1 - \cos(z_i, y_i)]$

教师：冻结的 OmniVGGT ，输入 RGB ，并利用可用的相机内外参 / 深度（缺失时用占位 token ）

目标特征加位置编码，双线性重采样到 VLA 视觉 token 分辨率

② 自适应层选择

$z = \Sigma_\ell\, g_\ell \odot \mathrm{MLP}(\mathrm{LN}(x_\ell))$

$g_\ell = \sigma(W_g \cdot x_\ell + b_g)$

受 Gated Attention 启发：逐 token 、逐通道、依赖特征的门控

数据异构，固定一层不一定适合所有域；LN/MLP 与门控参数跨层共享

③ 状态 Dropout

$p = 25\%$ （最优）

每个样本独立地整段丢弃本体状态 token ，保留图像与指令

抑制“状态 → 演示轨迹”的捷径，迫使策略依赖视觉

两阶段训练都使用；推理时关闭

推理时： 教师、投影 MLP 、门控全部丢弃 → 架构与 π0.5 完全一致，可直接复用预训练权重；不需要深度图或相机标定作为输入。

预训练数据

1.7M 条轨迹、 14,330 小时：先统一坐标与动作表示，再训练

各数据源时长（小时）

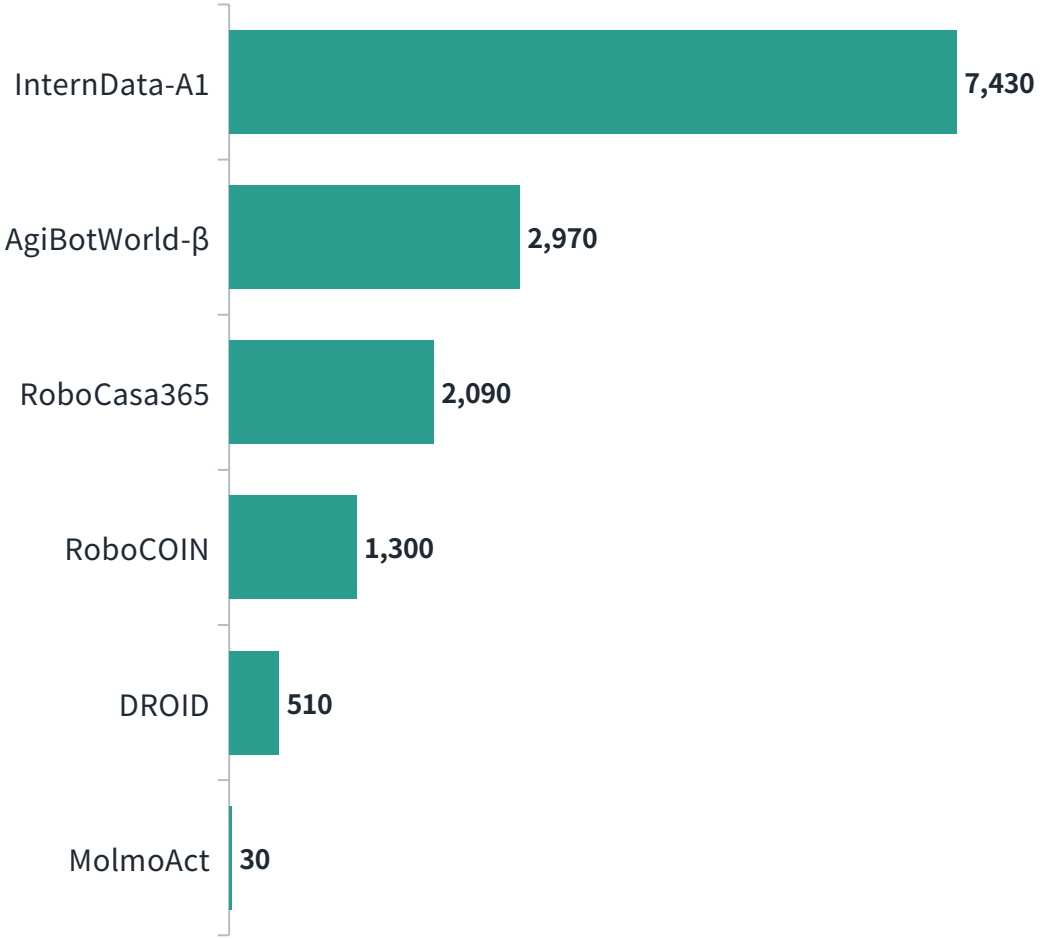

- **统一坐标：** EEF 位姿，原点为臂基座（双臂取中点），轴向前 +x / 左 +y / 上 +z
- **动作：**绝对 EEF 状态 + chunk 内相对当前位姿的 delta
- **下采样：** InternData 仅留 3–10%， RoboCasa MimicGen 仅留 0.5%
- **过滤：**去掉灵巧手、底盘移动、速度异常与静止帧；排除下游评测数据

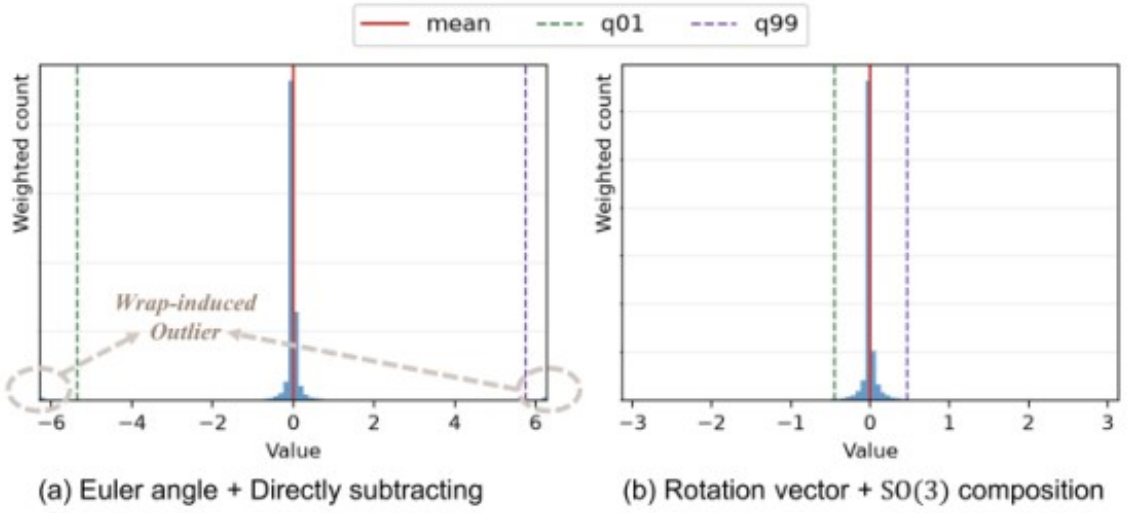

(a) 欧拉角相减： ±2π 处 wrap 离群点 (b) 旋转向量 + SO(3) 复合：无离群点

主要结果

全面超过 π0.5，泛化最难的场景提升最大

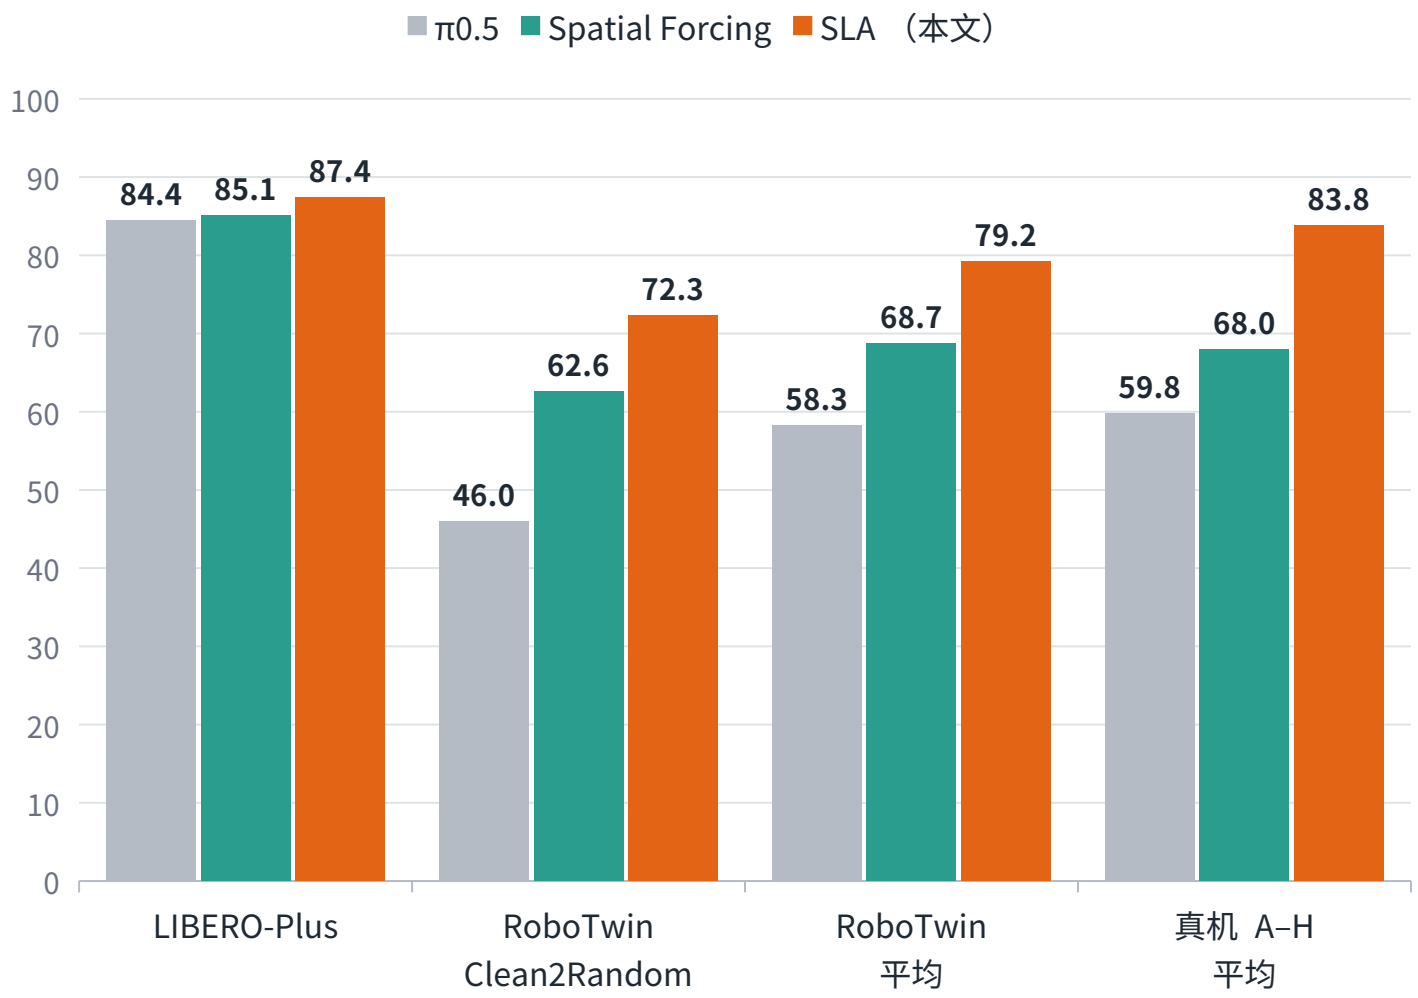

RoboCasa-Panda： 68.4%

每任务仅 50 条演示，最高； Cosmos Policy 67.1% （同为 50 条），其他方法用 300–3000 条

RoboDojo-Real： 33.9% SR

单策略跨 3 种本体； π0.5 12.8% ，次优 InternW0-Δ 31.7% （训练时额外加了记忆机制）

客观看： LIBERO-Plus 、 RoboTwin 平均分仅领先次优 0.3 个点； RoboTwin Clean2Clean 86.0 低于 ME-Dex-1.0 的 89.6

核心发现：数据规模化

只加数据几乎没用，加了空间对齐后，数据越多提升越明显

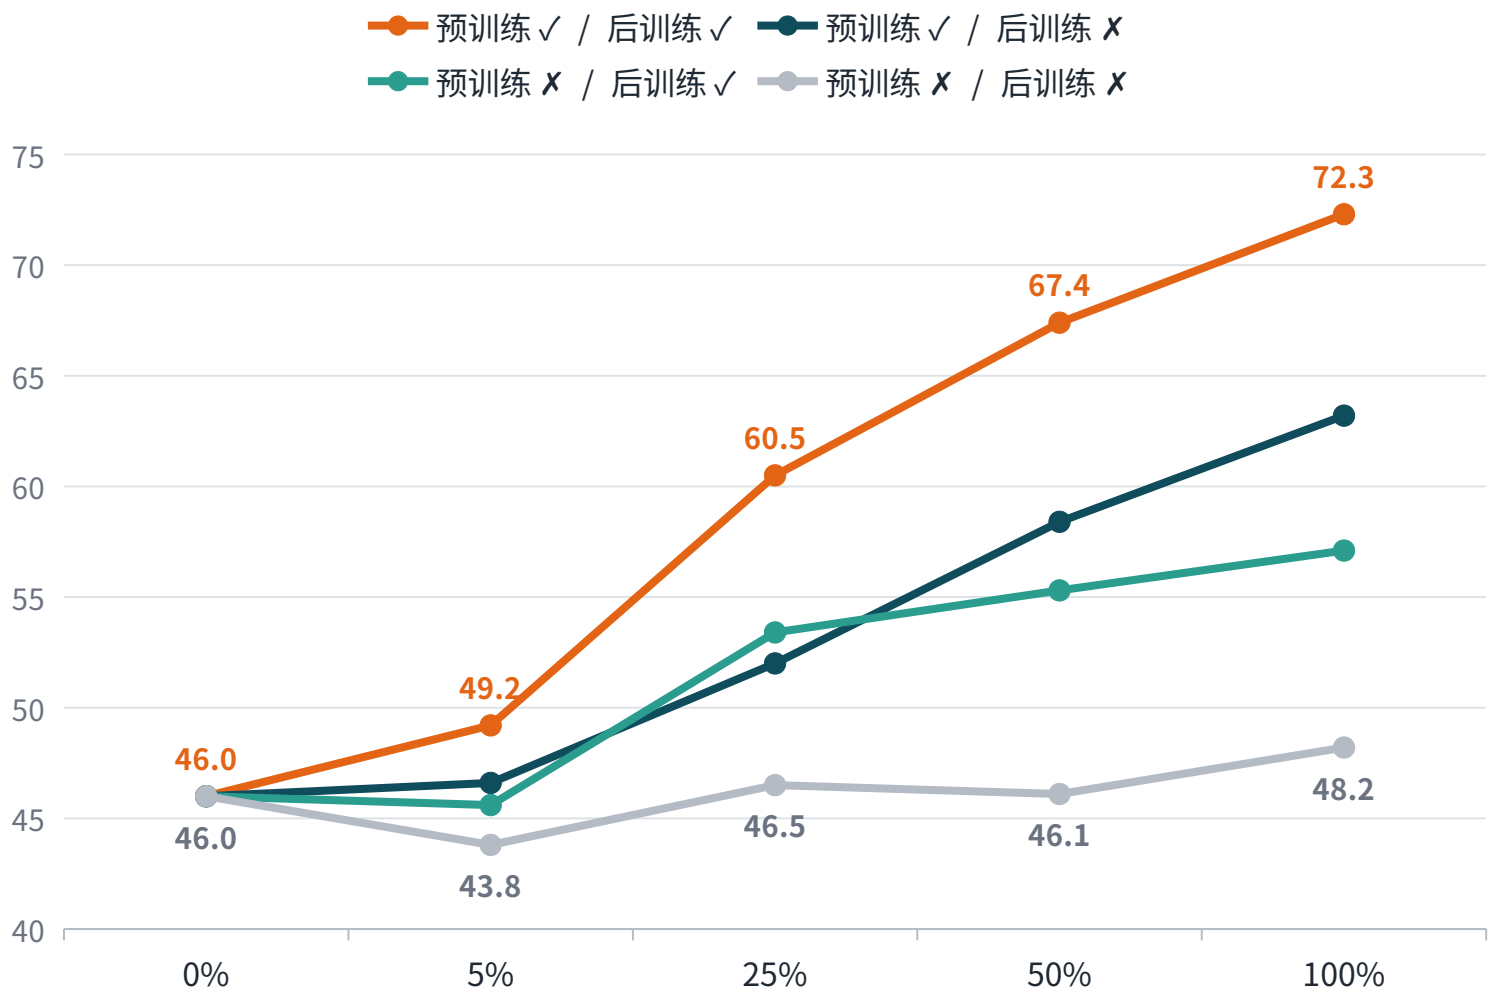

+26.3

两阶段对齐， 100% 数据，相对 π0.5 （46.0 → 72.3）

+2.2

不对齐、只加数据，相对 π0.5 （46.0 → 48.2）

+9.1 / +15.2

两阶段叠加，相对只在预训练对齐 / 只在后训练对齐

arXiv 2611.08373 • 数据：论文 Table 6 / Figure 4 （RoboTwin 2.0 Clean2Random， 50 任务平均； 0% 点为共享 π0.5 基线 46.0%）

消融实验

每个组件都有贡献，其中状态 dropout 最敏感

对齐层选择

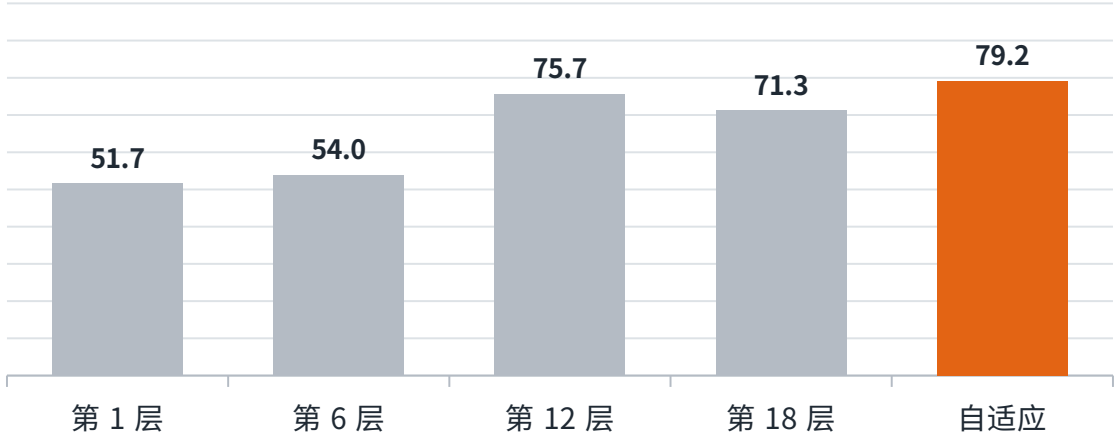

状态 dropout 概率

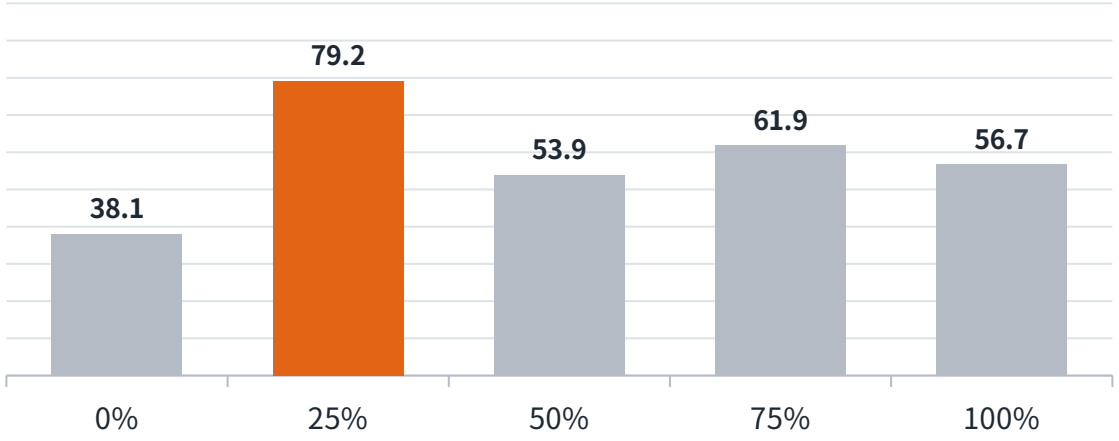

旋转表示（均用 SO(3) 复合）

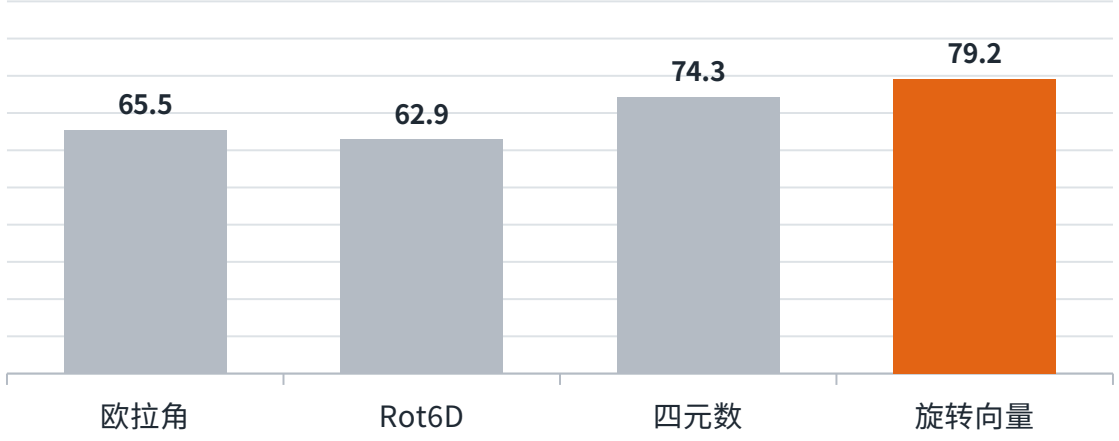

对齐教师 / 相机标定

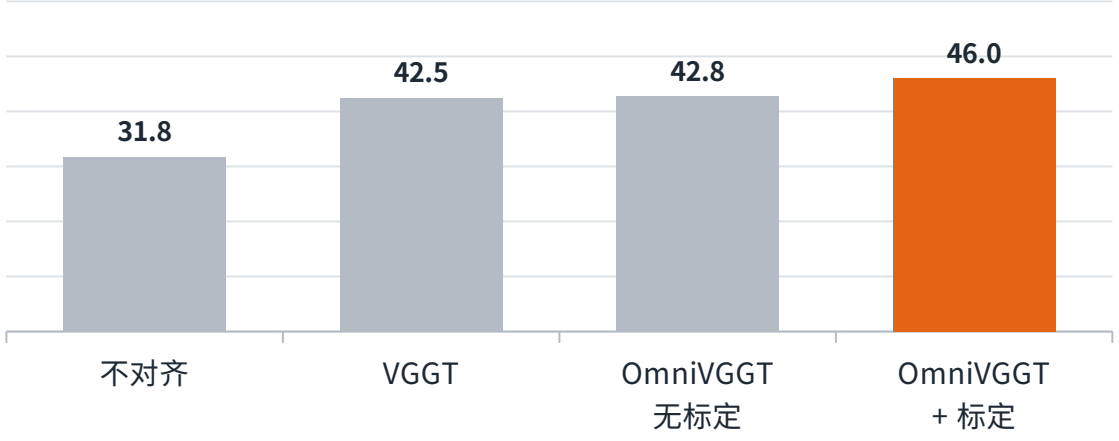

arXiv 2611.08373 • 数据：论文 Table 7–10 （RoboTwin 2.0， Clean2Clean 与 Clean2Random 平均成功率 %； Table 10 使用作者自采 RoboTwin clean 数据）

8 个真机条件全部第一：平均 83.8%，π0.5 为 59.8%

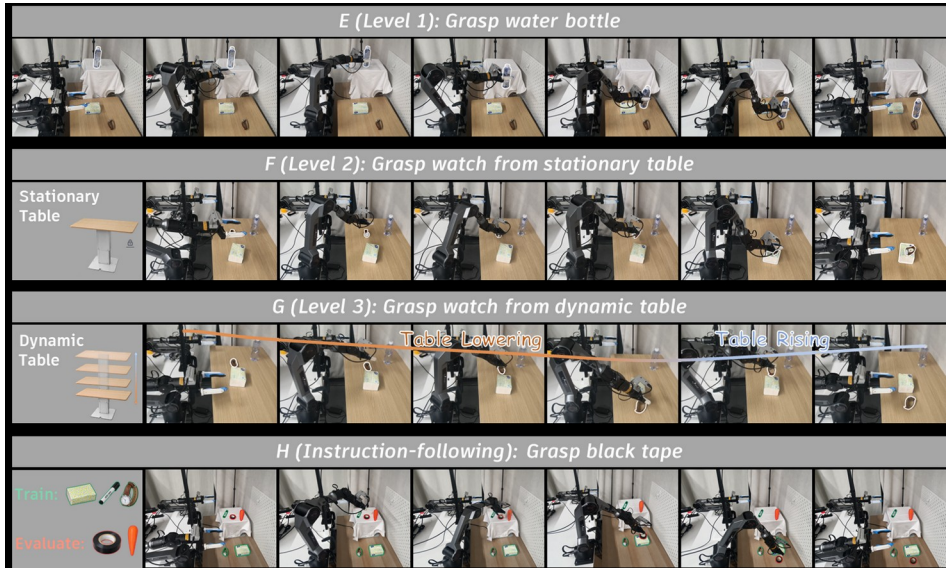

A 双臂传递 5 个蔬菜入碗（训练场景）
B 人把水果扔出，机器人捡回
C 抓取时人移动目标
D Franka 仅 10 条演示的跨本体
E 抓水瓶（训练场景） **F** 换桌高
G 抓取时桌子升降 **H** 未见物体 + 干扰物

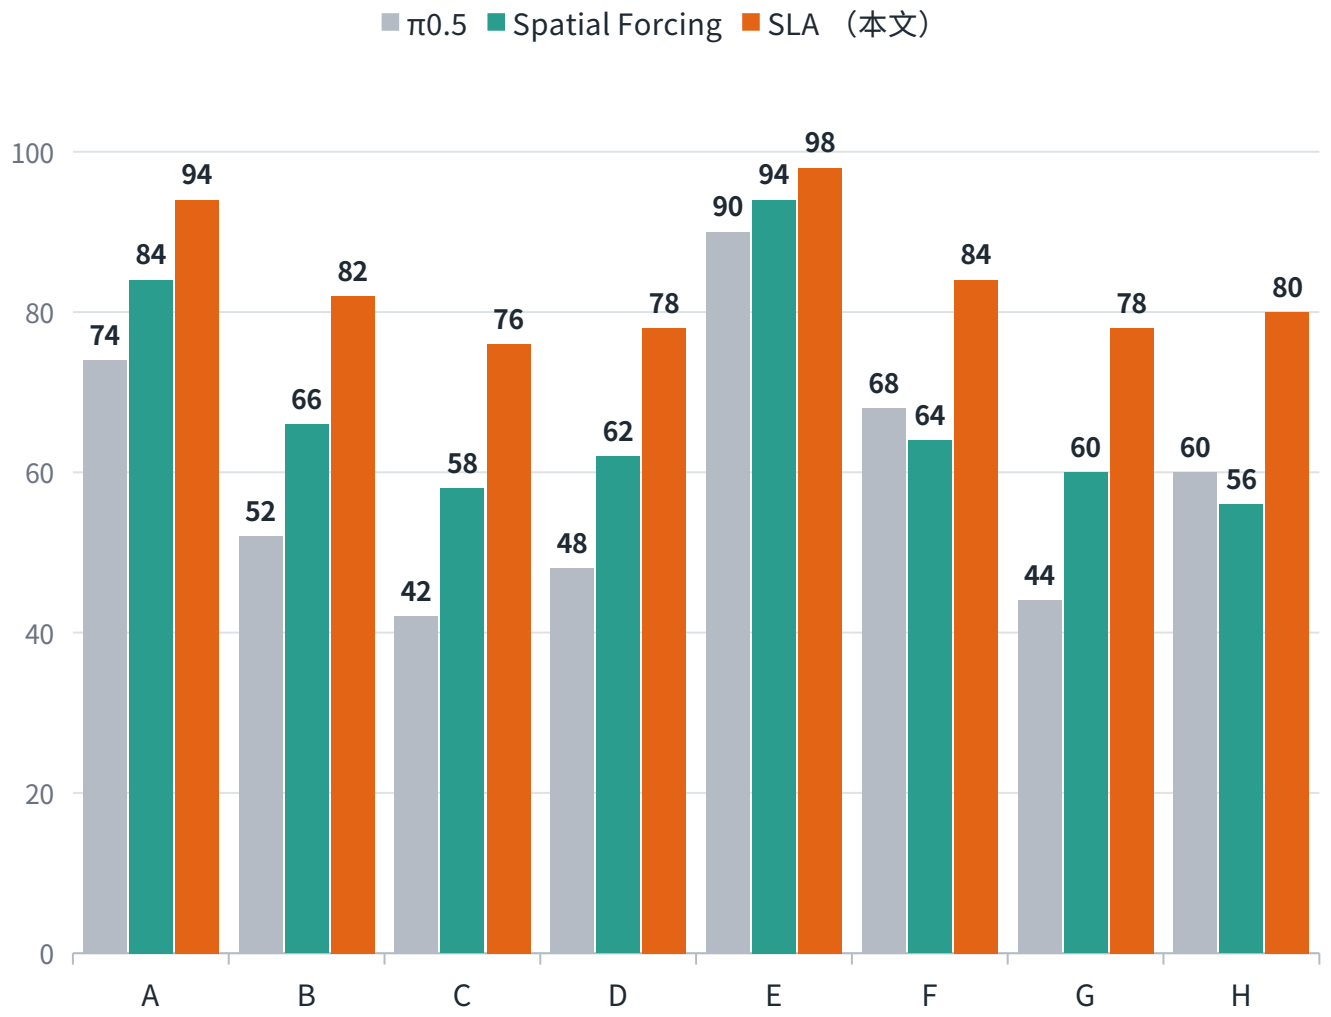

评价

方法实用、对照清晰，但对超参敏感、部分领先幅度很小

亮点

- **推理零开销：** 3D 能力只靠训练期损失注入，部署可直接替换 π0.5 权重
- **对照干净：** 2×2 对齐设置 × 4 档数据量，证明空间监督才让数据规模化有效
- **能用不完整的几何标注：** OmniVGGT 接受任意组合的标定 / 深度，异构数据都能用
- **工程配方实用：** 统一 EEF 坐标、 SO(3) 复合 + 旋转向量，消融差距显著（ 79.2 vs 65.5 ）

局限与疑问

- **超参敏感：** dropout 25% → 50% ，平均 79.2 → 53.9 ；不加 dropout 仅 38.1 ，低于 π0.5 的 58.3
- **消融覆盖窄：** 全部只在 RoboTwin 上，最优配置即主结果
- **领先幅度：** LIBERO-Plus / RoboTwin 平均仅 +0.3 ；RoboDojo-Real 额外用了记忆机制
- **证据强度：** 真机每条件 50 个实例、无方差；深度探针只有定性图，没有分析门控权重
- **成本：** 持续预训练约 48 张 H100 × 110 小时

结论与启示

空间监督是 VLA 持续预训练“吃得下数据”的关键

01

隐式对齐，不改架构

冻结 3D 教师只在训练期提供监督，部署与 π0.5 完全一致，不需要深度或标定输入

02

两个阶段都要对齐

预训练对齐 + 后训练对齐在每档数据量下都最好；只加数据几乎没有提升（48.2 vs 46.0）

03

配方细节决定上限

多层门控、 25% 状态 dropout 、旋转向量 + SO(3) 复合，各自都带来明显增益