论文解读 • arXiv:2611.10771 • 2026-11-07

WorldFoundry

Towards Unified Infrastructure for World Intelligence

用“闭环”定义世界模型，用统一基础设施让世界模型可复现、可比较

OpenEnvision • Juanxi Tian, Jiadong Hou, …, Ming-Hsuan Yang, Felix Heide, Wei Xiong, Enze Xie, Wanhua Li

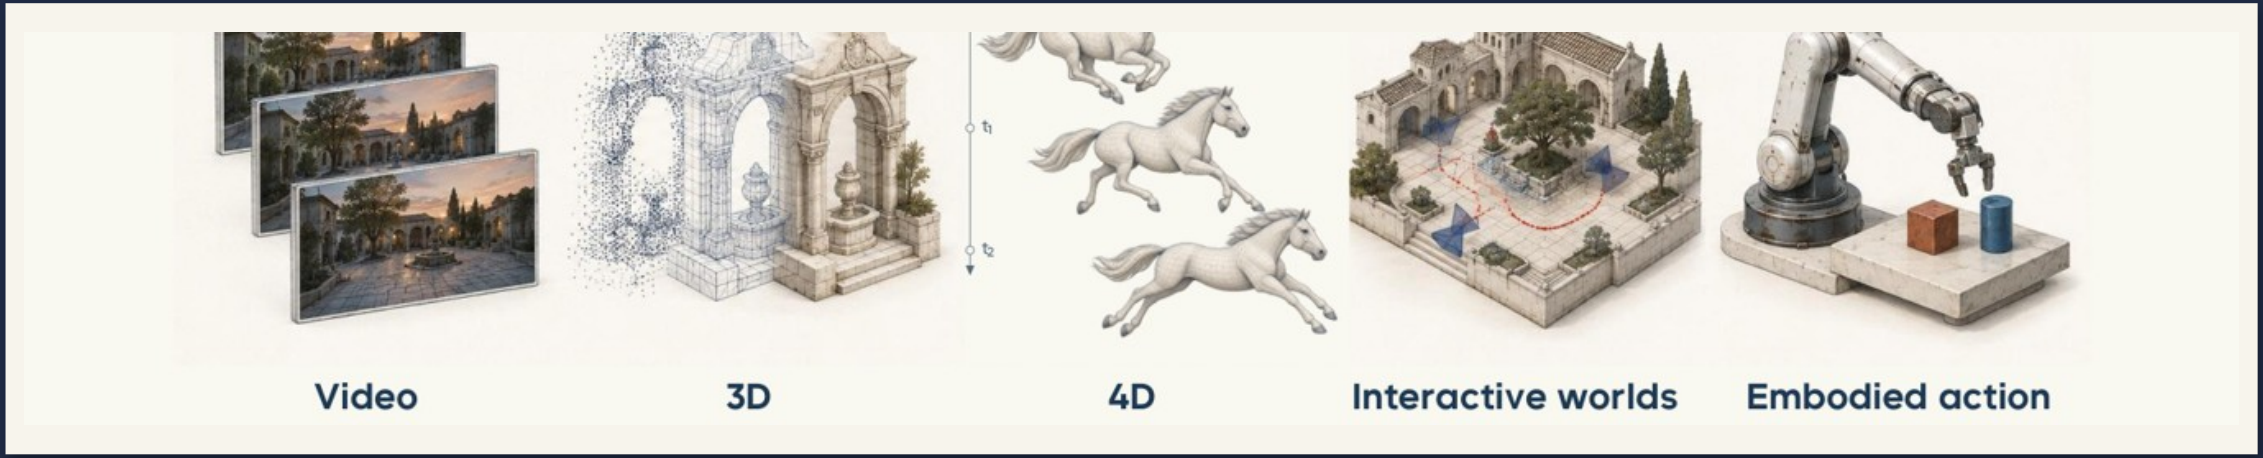

TL;DR

一句话总结：用“闭环”定义世界模型，再用统一基础设施去度量它

世界模型 ≠ 画面逼真。判据是 **闭环**：干预在持久状态里留下痕迹，观测反过来修正状态。
WorldFoundry 用 manifest 、 artifact 契约和证据 scorecard ，把异构世界模型放进同一条可复现、可追溯的推理 - 评测链路。

270	74	62	5
模型条目	Benchmarks	注册指标条目	类模态

五类模态：视频 · 3D · 4D · 交互世界 · 具身动作。每个模型 runner 都按有文档的参考工作流做过端到端执行验证（运行就绪 ≠ 性能结论）。

问题：瓶颈不只在算法，也在基础设施和评测

① 工作流碎片化

- 视频生成器、神经场景表示、具身策略各管一段
- 表示 / 运行时 / 接口 / 评测协议互不兼容
- → 能力难组合、结果难复现、进展难衡量

② 评测以感知为中心

- 视觉合理只反映“观测解码器”
- 对持久状态既不必要也不充分
- 物理 / 世界类 benchmark 反复暴露缺口（VBench-2 、 VideoPhy-2 、 WorldModelBench 、 WorldArena ）

结果： “基础生成模型”与“生成式世界模型”的边界模糊，动力学、可控性与交互效用无法被可复现地评估

Definition • 1

最小功能抽象：状态推断 → 前向模拟 → 交互响应

功能性、非架构性：这是共享接口，不要求每个系统实现全部三个算子 —— 不同模型族各有侧重

静态 3D

持久状态推断 + 几何解码

视频模型

隐式学习状态转移 + 观测生成

4D 方法

显式表示随时间变化的结构

具身模型

状态估计 + 动作预测 → 决策

Definition • 2

判据是“闭环”，不是“画面合理”

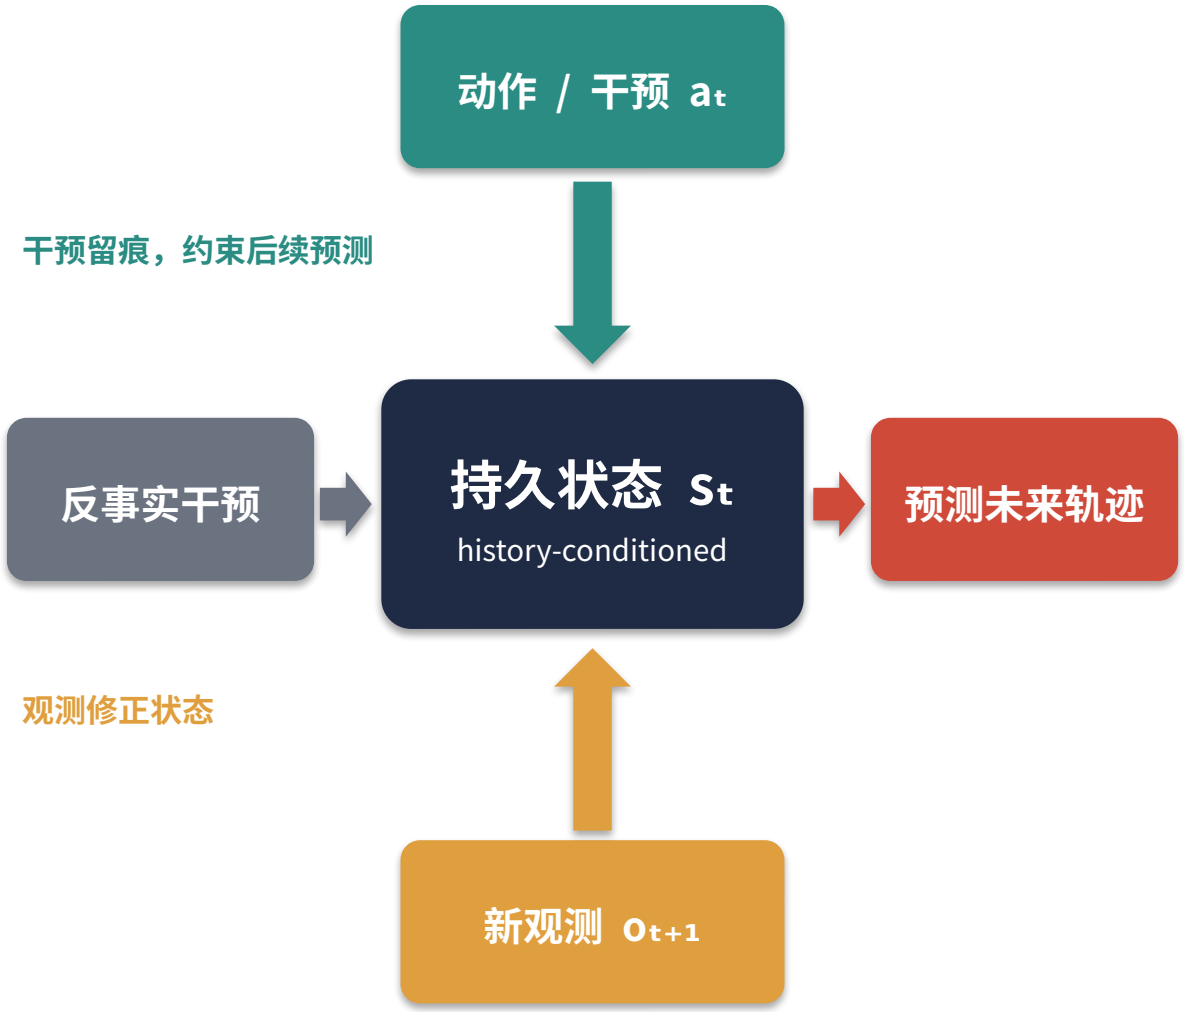

基础生成模型	生成式世界模型
合成 / 变换观测	**生成耦合到演化中的状态**
无需持久状态	**推断并维持持久状态**
干预不必留下痕迹	**干预留痕并约束未来**
观测不回写状态	**吸收观测、修正状态**
视觉合理即可	**判据：闭环 closure**

“It is closure, not plausibility, that draws a principled boundary.”

由定义导出能力框架：从感知合成走向闭环交互

用途：给异构系统做“能力画像”——按其实现的算子与支持的能力来比较，而非按架构。

从“感知合成” → “可度量的世界智能”

System

WorldFoundry 架构：五层串起“发现→运行→产物→评测”

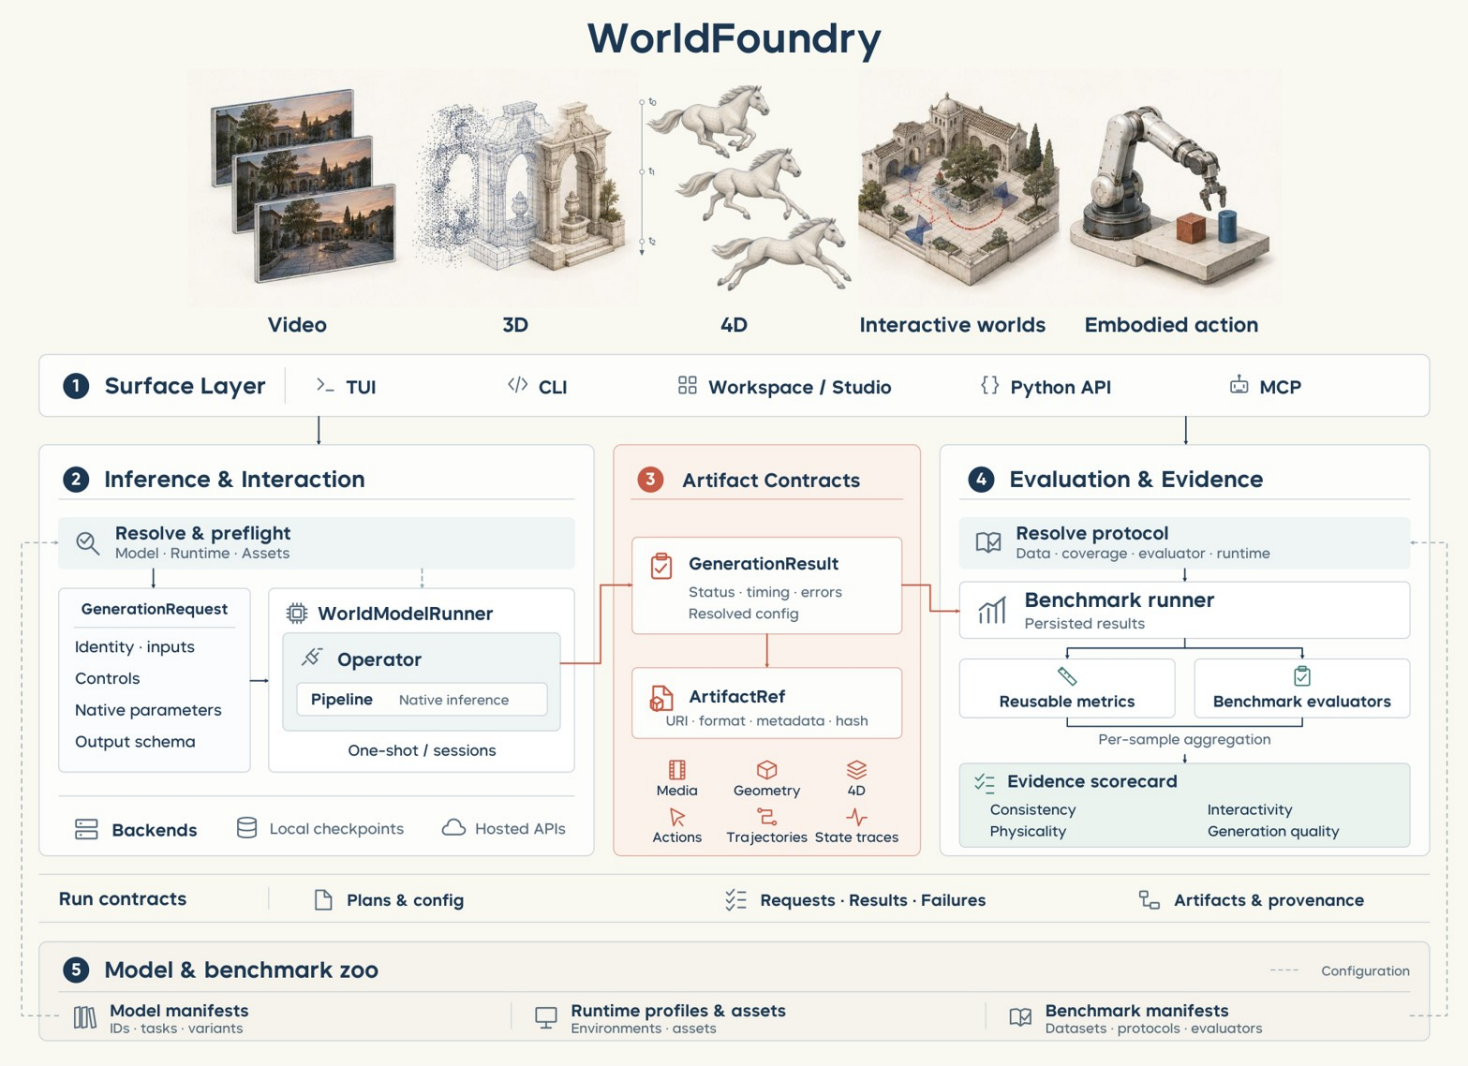

1 **Surface Layer**

TUI • CLI • Studio • Python API • MCP

2 **Inference & Interaction**

preflight → Request → Runner → 原生 pipeline； one-shot / session

3 **Artifact Contracts**

GenerationResult + ArtifactRef(URI • hash)

4 **Evaluation & Evidence**

协议 → benchmark runner → 指标 → scorecard

5 **Model & Benchmark Zoo**

模型 / 运行时 / benchmark manifest

Artifact 契约：执行与评测解耦，每条结论都能追溯到产物

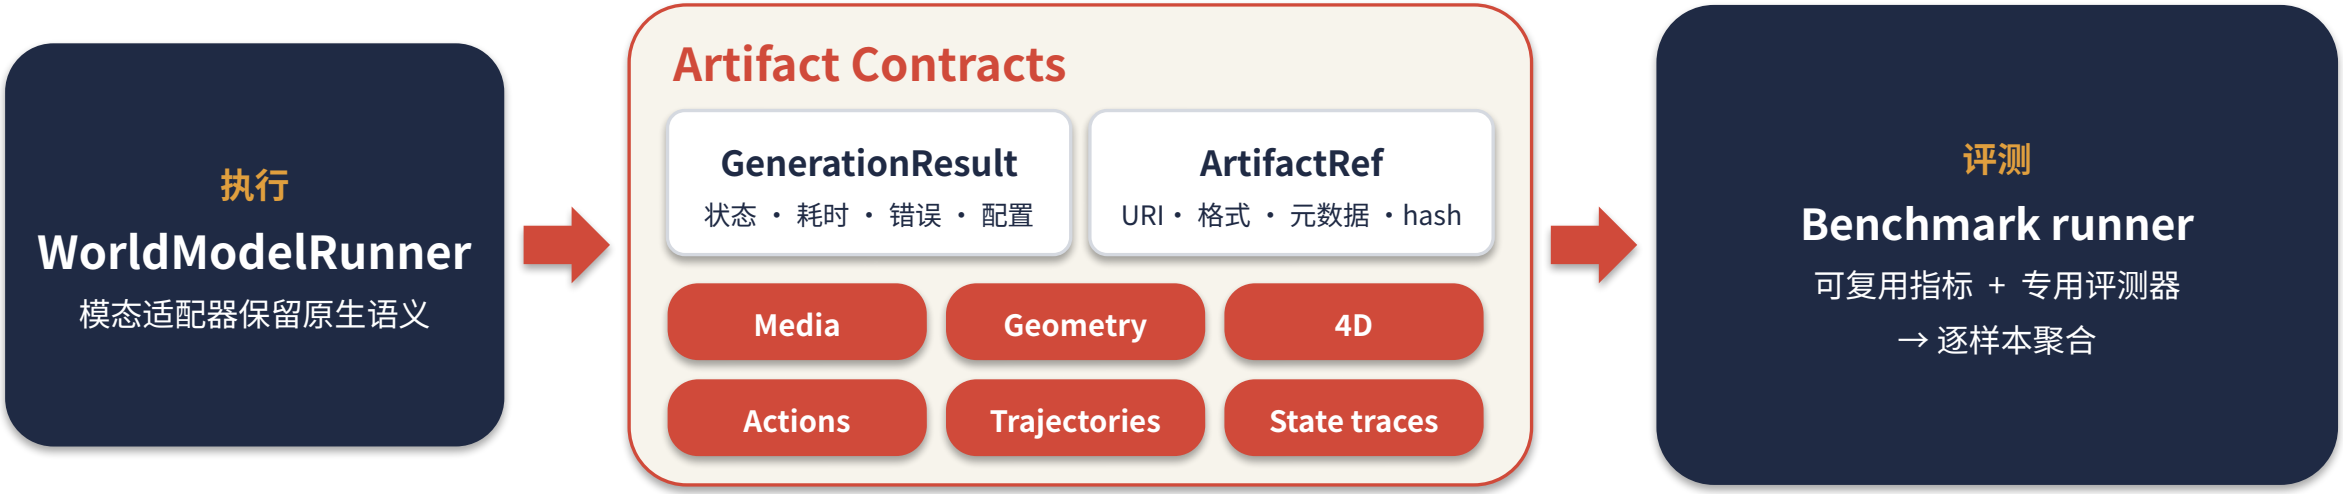

Evidence scorecard 四个维度

一致性	物理性	交互性	生成质量
Consistency	Physicality	Interactivity	Generation quality

好处：一次执行、多次评测；结论可审计、可复查（每个产物带 hash 与解析后的配置）

证据分级：“能跑”和“跑得好”分开报告

目录登记：模型 / benchmark / 指标条目及其 manifest

声明支持
Declared support

端到端执行通过参考工作流；记录执行证据

运行就绪
Operational readiness

基于持久化产物的评测分数，可追溯到产物

验证性能
Validated performance

当前目录（摘要数字）

270	模型条目
74	benchmarks
62	注册指标条目

所有模型 runner 都经端到端参考工作流验证 = 运行就绪，不等于性能结论

Assessment

评价：定义与工程扎实，但“闭环”如何量化仍待验证

亮点

- 定义可操作：干预留痕 + 观测修正，指向状态持久性与反事实响应的评测
- 工程抽象到位： manifest → request → artifact → scorecard ，可复现、可追溯
- 覆盖广：五类模态统一调度，支持 MCP ，便于 agent 使用
- 证据分级：把“接入了”和“评过了”分开

局限 / 疑问

- 可见材料中没有跨模型的实质评测结果
- “闭环”判据如何落成具体指标尚未看到
- 视频模型与具身策略能否公平共用交互性 / 物理性指标?
- 隐式状态的持久性只能靠行为探针检验；长期价值依赖维护与社区

Takeaways

对具身智能的启示：在同一契约下比较“世界模型 + 策略”

01

统一框架

具身动作模型与视频 / 4D / 交互世界共享执行与评测契约； Actions 、 Trajectories 、 State traces 是一等产物

02

选型标准

“干预留痕 + 观测修正”与具身对世界模型的诉求（预测动作后果、支持规划）一致

03

研究实践

附带 manifest 与可追溯 artifact 提交结果，让孤立 demo 变成可累积、可审计的证据

Take-home： 从“感知合成”走向“可度量的世界智能”，需要的是闭环的证据和可复现的基础设施