论文解读 · 离策略强化学习 / 长视野价值学习

Horizon-Scalable Q-Learning

用一道“价值比较闸门”，让 TD 目标自己决定该往后走几步

Haoran Xu · Pragya Srivastava · Xinjie Liu · Siddhant Agarwal · Amy Zhang

The University of Texas at Austin

arXiv 2611.10987 · 首次提交 2026-11-07

TL;DR

一句话：只在“数据动作不比策略差”时，才把 TD 目标往后延一步

HQL：若目标 critic 认为数据动作 ≥ 行为策略 best-of-N 候选中的最佳者，就让目标穿过该动作继续回溯；否则退回一步 TD。

→ 逐 transition 自动在一步 TD 与多步 TD 之间取舍，无需动作密度，兼容 flow / diffusion 策略。

0.74 vs 0.49

OGBench 6 组配置平均成功率
HQL vs 最佳 TD 基线（8-step）

81% vs 62% / 45%

Chunked-HQL 平均成功率
vs LQL / Q-chunking

0.82 vs 0.53

OCBench 8 个长视野任务
Chunked-HQL vs 100-step TD

反直觉发现： 77% 的 HQL 目标仍是一步目标——它赢在“选择哪些目标延长”，而不是“延得更远”。

长视野下，一步 TD 与 n 步 TD 各有一种失败模式

一步 TD：残差沿视野累积

价值误差 = 下游残差之和

$$\varepsilon_t = \sum_{\tau \geqslant t} e_\tau$$

残差视为弱相关噪声时：

$$\mathrm{RMSE}(\varepsilon_0) \approx \sqrt{(H \cdot L_{TD})}$$

TD loss 小 ≠ 价值准，误差按 $\sqrt{H}$ 增长

n 步 TD：继承次优动作的偏差

目标偏离 Q^π 的量包含途经动作的优势

$$\sum_{j=1}^{n-1} A^\pi(s_{t+j}, a_{t+j}) \leqslant 0$$

同号、系统性，不会平均掉

$$\text{偏差} \to H \cdot |\bar{A}_\mu|$$ （随 n 增长）

Retrace 等修正需 π/μ 密度， flow/diffusion 无法提供

统一误差律（Eq. 3）

$$\mathrm{RMSE}(\varepsilon_0)^2 \approx (H/n) \cdot L_{TD}^{(n)} + (1-1/n)^2 \cdot H^2 \cdot \bar{A}_\mu^2$$

残差累积：n↑ 则 ↓　　行为偏差：n↑ 则 ↑

没有固定的 n 适合整条轨迹

→ 需要逐 transition 的规则

HQL：给每个数据动作加一道“价值比较闸门”

带闸门的多步目标（Eq. 6）

$$Y_t = r_t + \gamma \cdot V'(s_{t+1}) + \gamma \cdot c_{t+1} \cdot [Y_{t+1} - Q'(s_{t+1}, a_{t+1})]$$

一步目标 + **闸门** × **下游修正**

$c \equiv 0 \rightarrow$ 一步 TD； $c \equiv 1 \rightarrow$ 无修正多步回报； Q'/V' 为目标网络

闸门规则（Eq. 7）

$$c_i = \mathbb{I}[\, Q'(s_i, a_i) \geq \max_m Q'(s_i, a_i^{(m)}) \,]$$

$a_i^{(m)} \sim \mu(\cdot \mid s_i)$， $m = 1..N$

✓只看排序：与奖励尺度无关
✓无需密度：行为模型只用来采样
✓唯一超参：候选数 N

示意：一个窗口内的闸门与每个目标的实际回溯长度

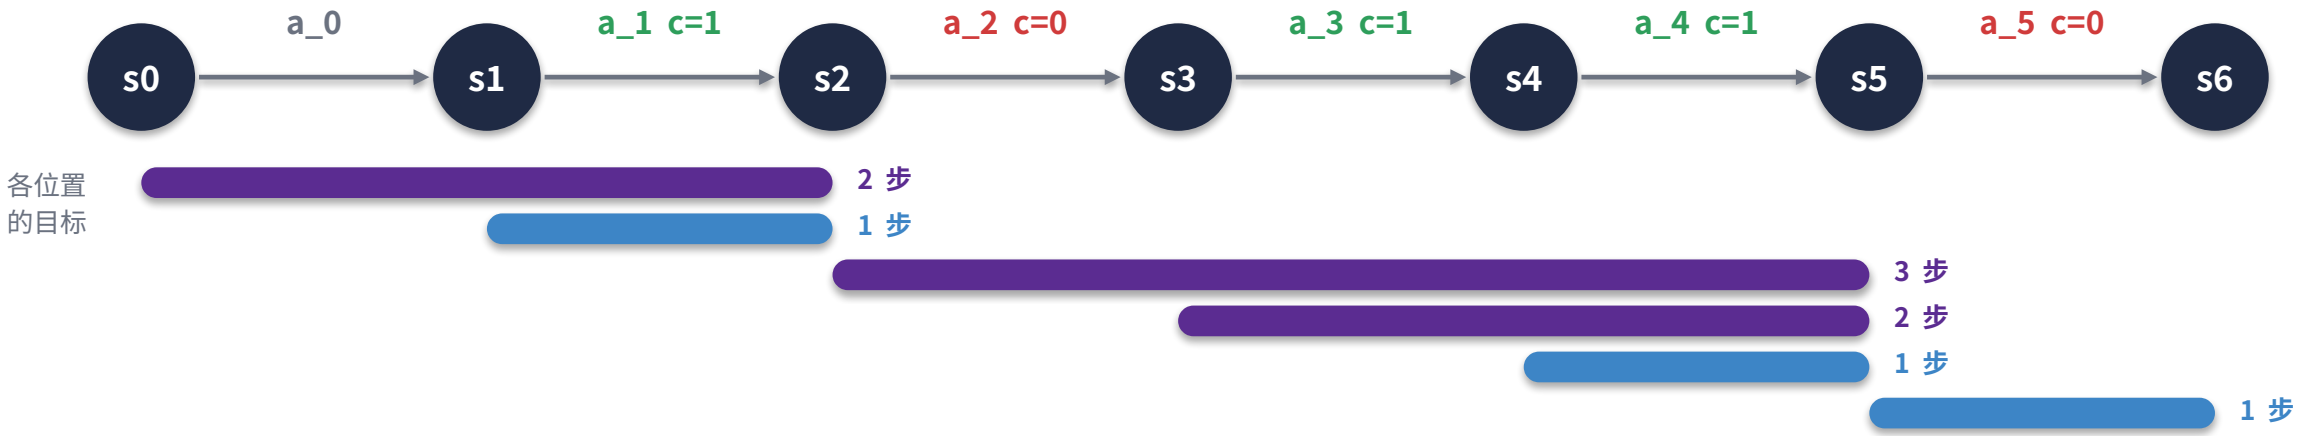

来源： Section 4.1， Eq. 6–7；下方示意图为本解读绘制

硬闸门 = 重要性采样“合法闸门”在 τ→∞ 时的极限

1 合法闸门

$c_i \leqslant \pi(a_i|s_i) / \mu(a_i|s_i)$ 即保持 Q^π 不动点（Retrace 思想）

2 指数倾斜策略

$\pi \propto \mu \cdot \exp(\tau Q) \Rightarrow \log(\pi/\mu) = \tau Q - \log Z$， μ 被约掉

3 软闸门（Eq. 9）

$c_i = \exp(\min\{0, \tau Q'(s_i,a_i) - \log \hat{Z}(s_i)\})$， $\hat{Z}$ 由 N 个样本 LSE 估计

4 两个极限

τ→0：闸门全开 = 无修正 n 步；τ→∞：恰为硬比较（Eq. 7）

平均成功率（%）：软闸门 vs 硬闸门

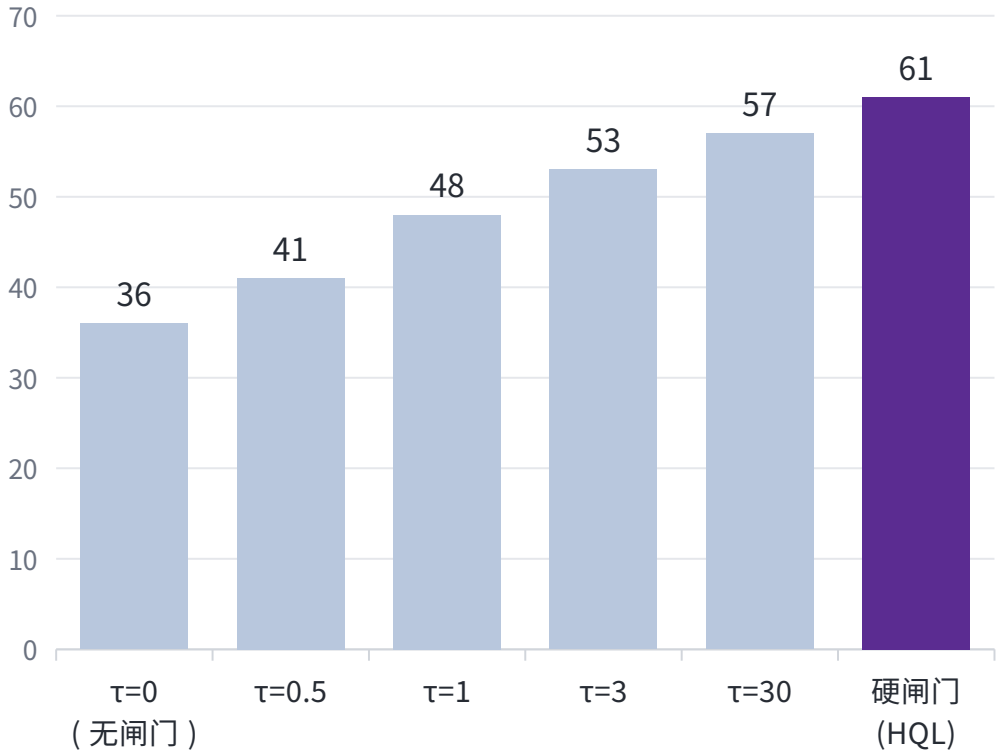

τ 越大越好，硬闸门最佳； hmaze-medium 91 vs 77 （最佳软闸门）。软闸门给次优动作留“部分信用”，仍继承部分偏差。

来源： Section 4.2， Eq. 8–9；右图数据来自 Table 7（单 seed）

一个框架涵盖一步 TD、n 步 TD 与 Q-chunking

窗口内稠密目标

采样 H 个连续 transition，先算所有位置的闸门，再从窗口末端反向递推，每个 (s,a) 都回归到自己的目标。

公平预算：每次更新 critic 目标数固定（OGBench 512），HQL 采 B/H 个窗口。

Chunked-HQL

一个决策 = L 个原始动作组成的块，critic 打分 Q(s_t, a_{t:t+L})；H 个块最远覆盖 L · H 个环境步。

闸门不变：比较数据块与 best-of-N 策略块；γ 换成 γ^L。

L（每决策步数）	H（目标串联决策数）	闸门	等价方法
1	1	—	一步 TD
1	H > 1	无	无修正 H 步 TD
1	**H > 1**	**有**	**HQL**
k	1	—	Q-chunking（块长 k）
k	**H > 1**	**有**	**Chunked-HQL**

增大 H：一个目标可串更多决策，闸门决定实际用几个。

增大 L：块内开环执行，策略需在 L · dim(A) 维空间里搜索。

组合锁：只有 HQL 同时扛住长视野与数据损坏

设定： H 个线性状态，正确动作前进、错误动作重置；每步奖励 −1 ；数据窗口长 64 ，后续动作以概率 p 被替换为错误动作（ 0% / 12% / 27% / 50% / 75% 的窗口含损坏）

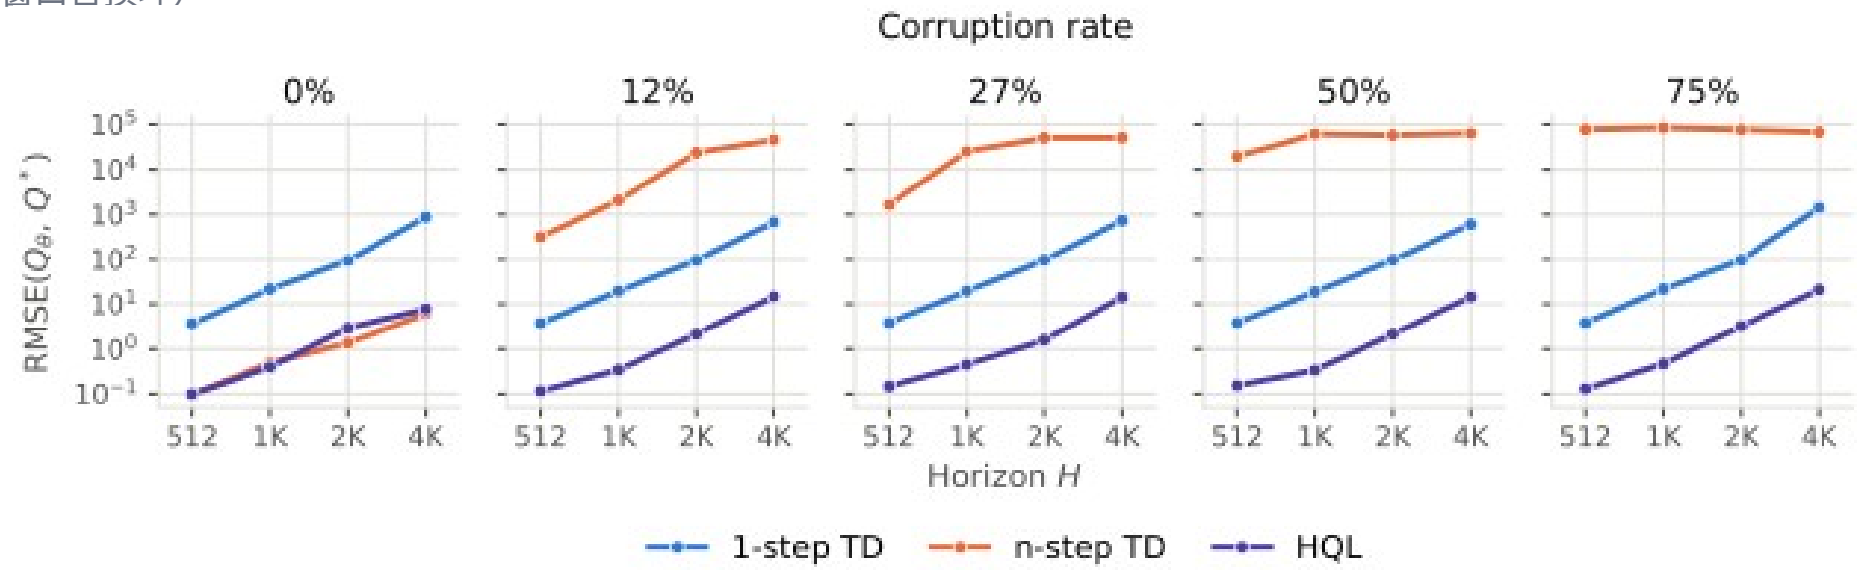

1-step TD

不受损坏影响，但误差随 H 剧增：H=512→4096 约增长 3 个数量级

64-step TD

干净数据上与 HQL 相当；只要有任何损坏就发散（ RMSE ≈ 10^3–10^5 ）

HQL

所有损坏率、所有视野下误差最低：在损坏动作处截断回溯

来源： Figure 3 （ RMSE ，对数坐标， 1M 次更新后）

OGBench： HQL 在全部 6 个配置上领先各类 TD 基线

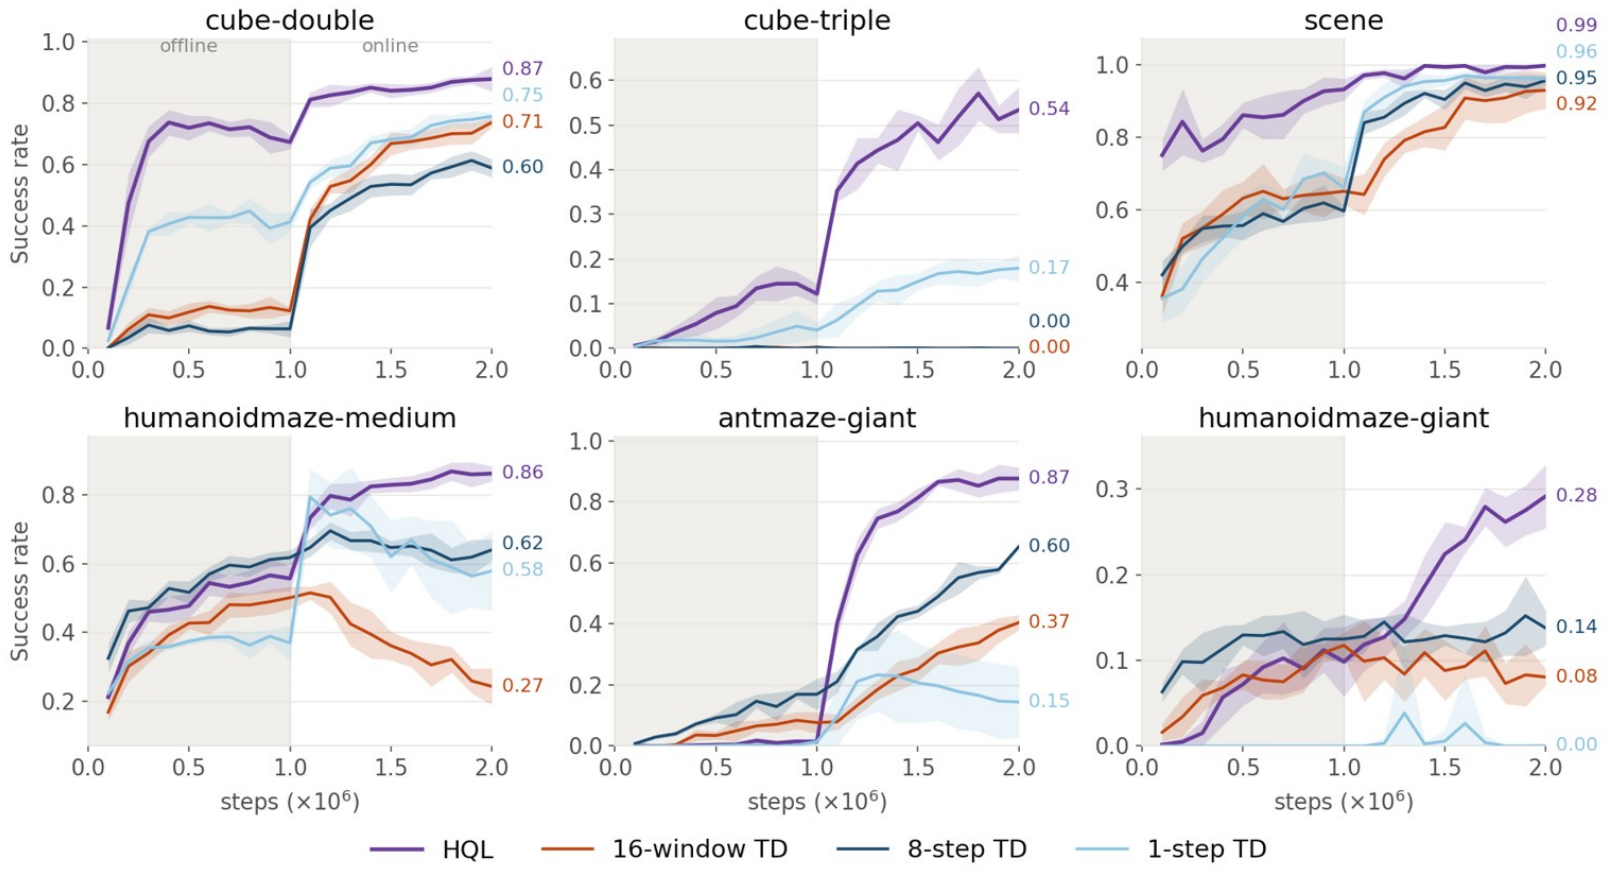

0.74 vs 0.49

平均成功率： HQL vs 最佳 TD 基线（8-step TD）

长视野差距最大

cube-triple： 0.54 vs 多步基线 0.00

antmaze-giant： 0.87 vs 0.60

hmaze-giant： 0.28 vs 0.14

闸门是关键

16-window TD 与 HQL 只差闸门，却平均最弱； hmaze-medium 在线阶段降到 0.27

来源： Figure 4 （5 任务 × 5 seeds，灰色为离线阶段）

对比 LQL / QC： Chunked-HQL 平均 81%， QC 人形迷宫为 0

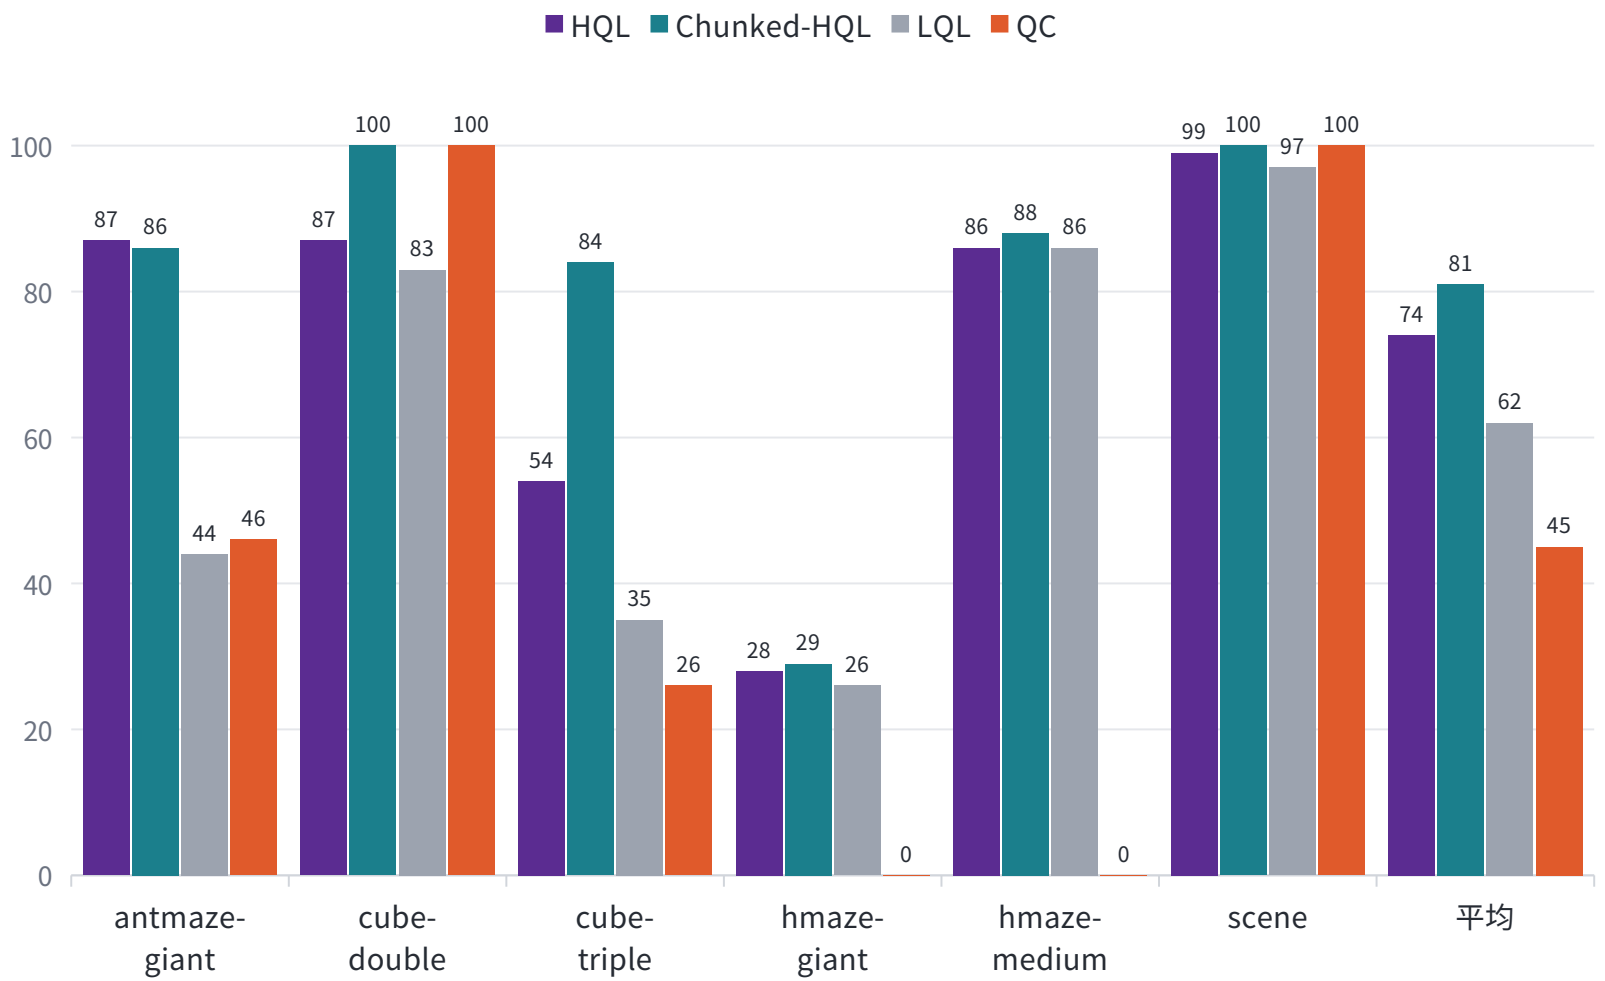

QC 为何在人形迷宫失败

动作块达 L · dim(A) 维（21×8），best-of-N 覆盖稀疏

块内开环执行，无法中途纠正

闸门与分块互补

45% → 81%

在 QC 的动作块上加闸门（Chunked-HQL）； HQL 比 LQL 平均高 12 个百分点

来源： Table 1 （在线训练结束时成功率 %， 5 seeds ）

OCBench： Chunked-HQL 均值 0.82，远超 100 步 TD 的 0.53

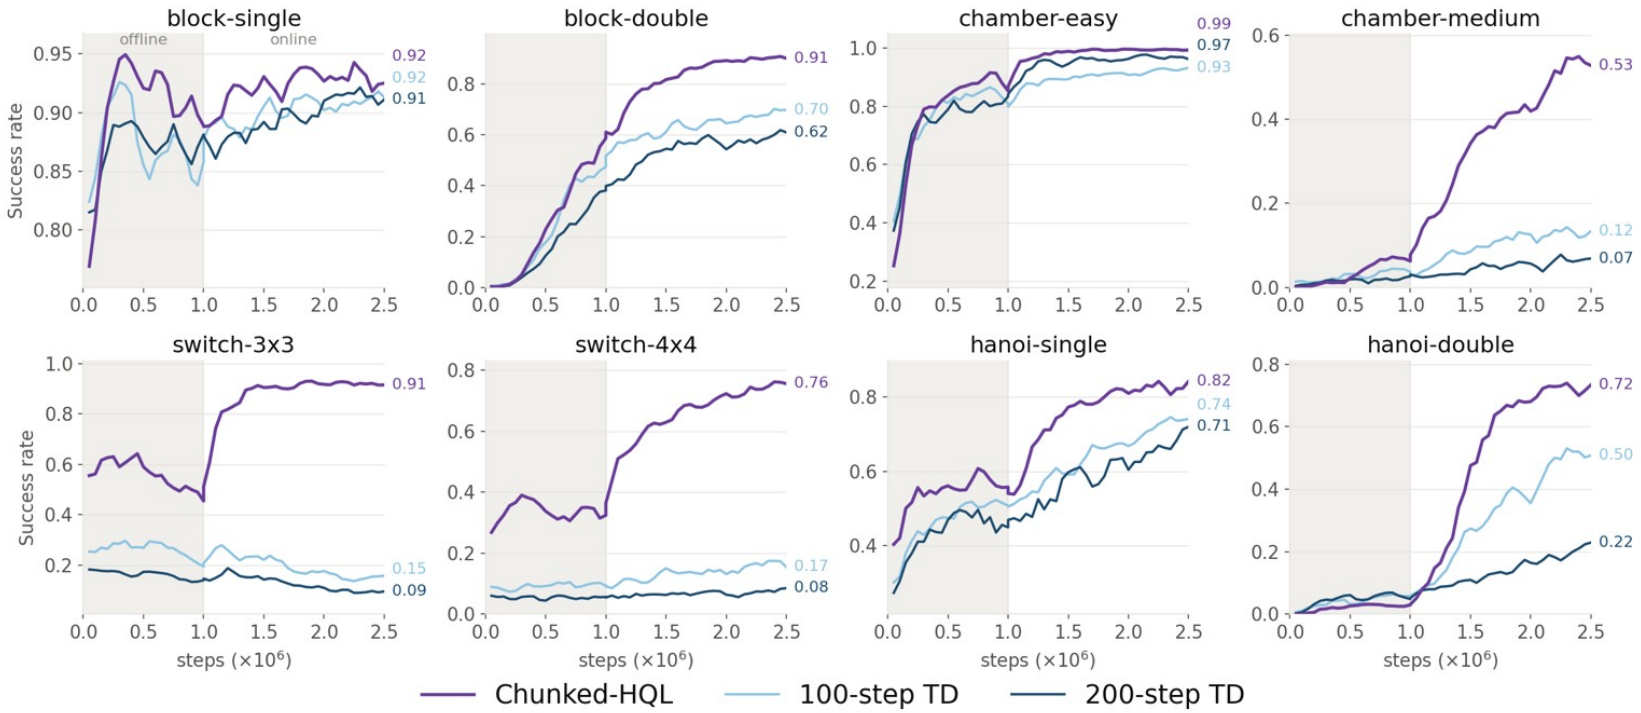

0.82 vs 0.53 / 0.46

均值： Chunked-HQL vs 100 / 200-step TD

设置

L=25， H=8 （200 步窗口）；闸门 N=2，执行 best-of-16

差距最大

switch-3x3： 0.91 vs 0.15

switch-4x4： 0.76 vs 0.17

chamber-medium： 0.53 vs 0.12

印证误差律

200 步 TD 在 7/8 任务上不如 100 步

注：每组仅 1 个 seed

来源： Figure 5 （OCBench， 8 个 50 Hz 任务；每组 1 个 seed）

反直觉： 77% 的目标只有一步—— HQL 赢在“选哪些延长”

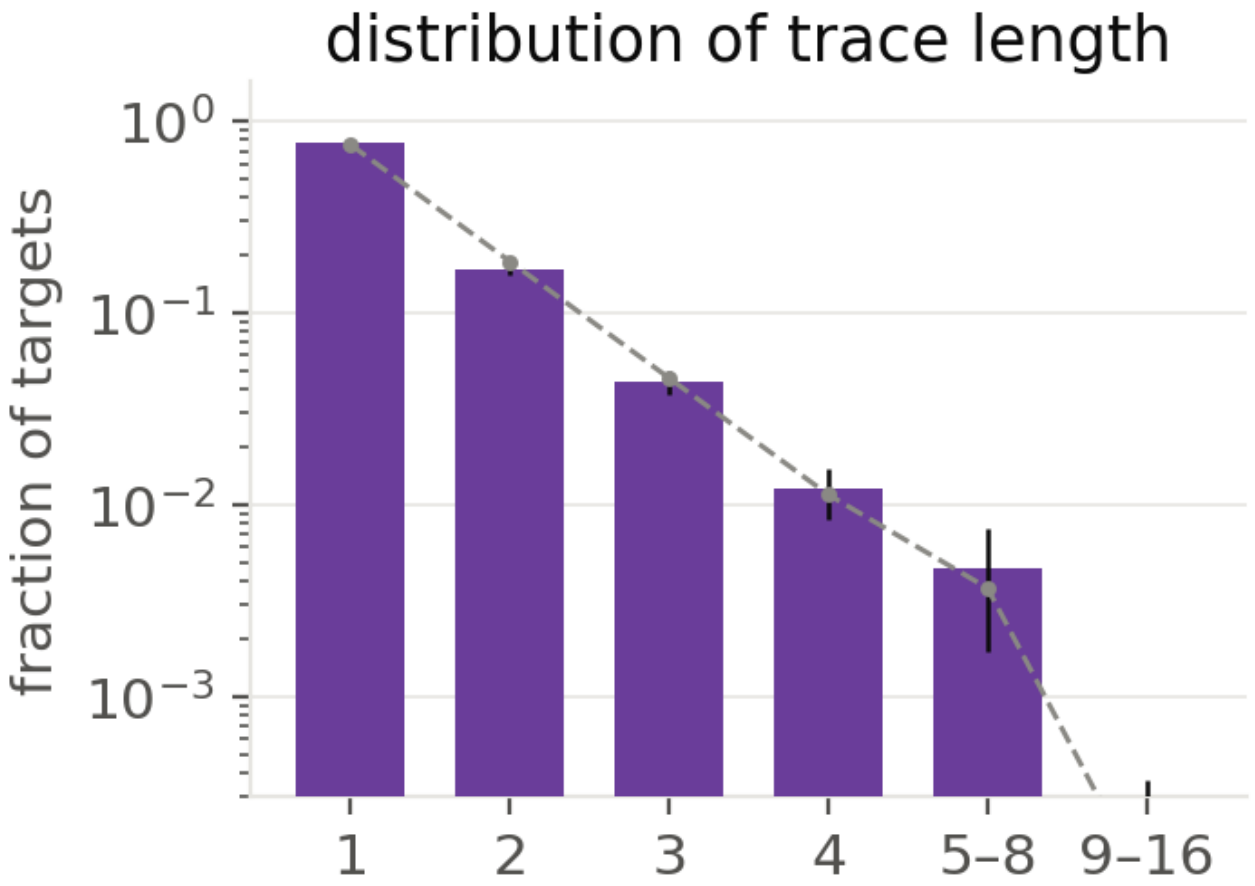

77% 一步目标

17% 两步目标

6% 三步及以上

没有目标超过 6 步（窗口共 16 步）

n 步 TD 全部延长 → 继承每个偏差
1 步 TD 全不延长 → 残差累积
HQL 只延长通过闸门的目标

即插即用：给 QAM 与 VGF 换上 HQL critic，四个任务全部提升

QAM （adjoint matching flow 策略）

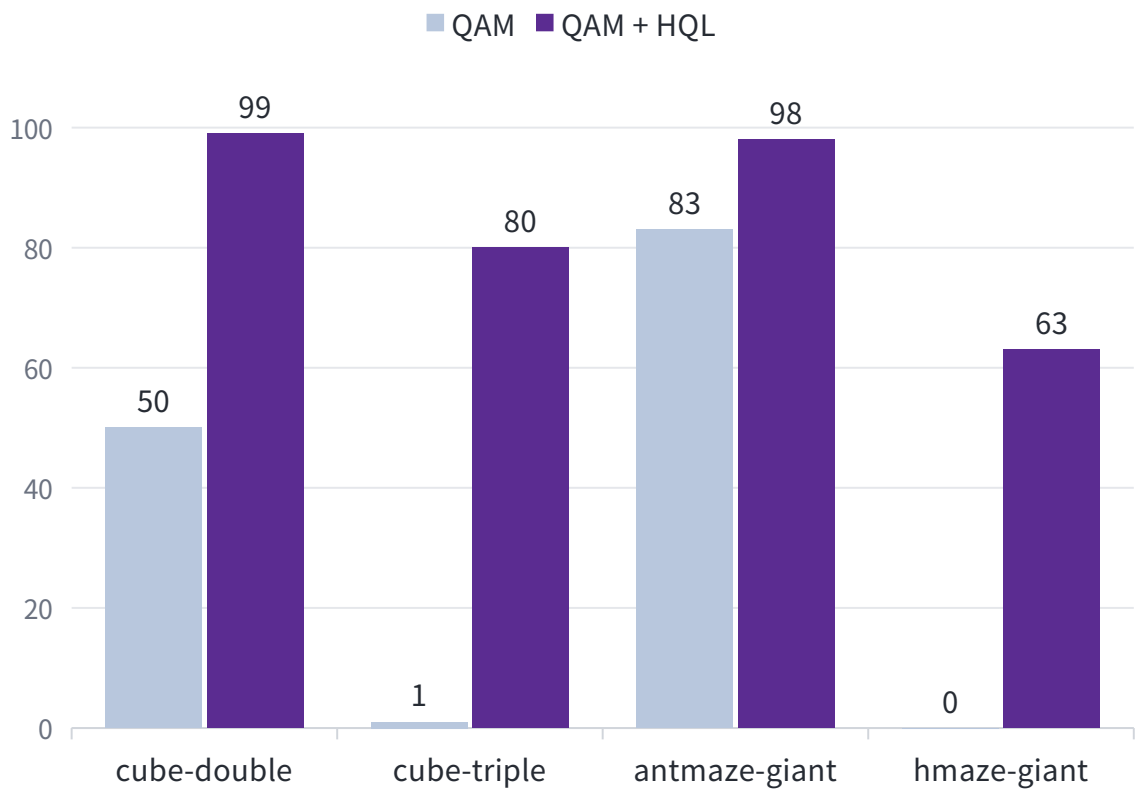

VGF （value gradient flow）

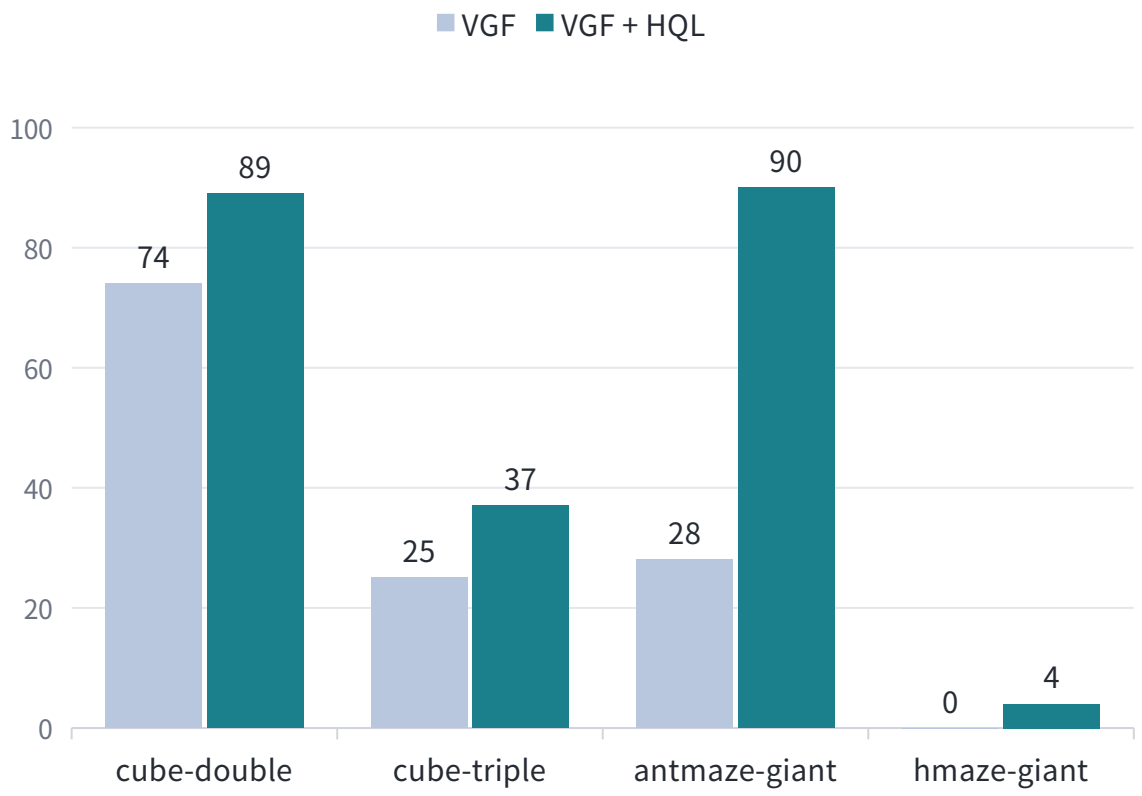

亮点： QAM cube-triple 1→80 、 hmaze-giant 0→63； VGF antmaze-giant 28→90 （hmaze-giant 仅 0→4）

来源： Table 2 （task 2，在线训练结束时成功率 %）

消融：窗口长度 H 不敏感，候选数 N 越小越好

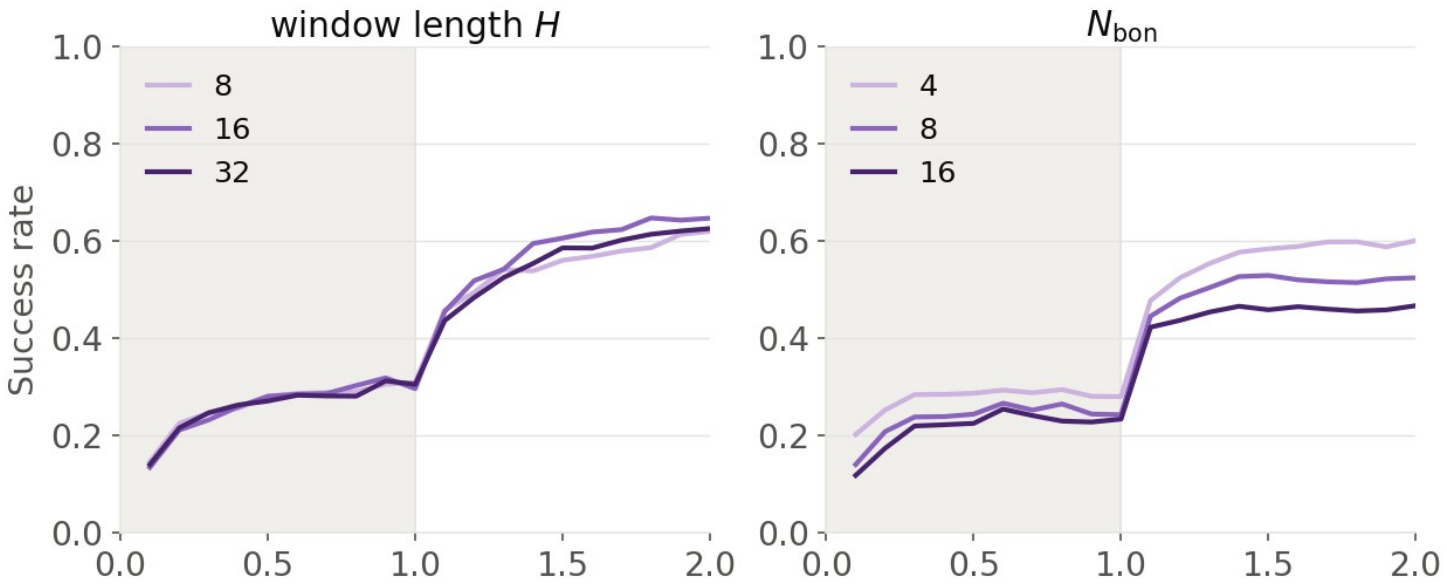

窗口长度 H

0.607 / 0.646 / 0.621

H = 8 / 16 / 32 ，基本不敏感：实际目标 ⩽ 6 步，H=16 已足够

best-of-N 宽度

0.596 / 0.521 / 0.461

N = 4 / 8 / 16 ， N 越小越好

数据动作胜过全部 N 个候选的概率约 1/(N+1)： N 大 → 闸门难开 → 退化为一步 TD

评价：简洁且有理论支撑，但依赖 critic 自身的排序

优点

- 误差律统一解释一步 / n 步 TD 的失败，动机清晰
- 极简：只改 critic 目标，唯一超参 N，无需密度
- 理论：硬闸门是 IS 合法闸门在 τ→∞ 的极限
- 通用：可作为 QAM、VGF 的即插即用 critic
- 对照公平： 16-window TD 单独隔离闸门作用

局限与疑点

- 闸门依赖 critic 自身排序，可能误放 / 误截
- 不动点保证限于表格情形与指数倾斜策略
- 保守： N 越大越接近一步 TD，需调 N
- OCBench、软闸门仅 1 seed； N 消融 2 seeds
- 收益多在在线阶段（antmaze-giant 离线仅 1%）

三点要记住

01

长视野价值误差有两个来源

一步 TD 的残差按 $\sqrt{H}$ 累积； n 步 TD 的行为偏差随 n 增长，固定 n 无解。

02

一道价值比较闸门即可逐步取舍

数据动作 ≥ best-of-N 候选才继续回溯；无需密度，是 IS 合法闸门的 $\tau \to \infty$ 极限。

03

赢在“选哪些延长”而非“延多远”

77% 目标仍是一步，却在 OGBench 、 OCBench 长视野任务上大幅领先。

作者展望：把 HQL 用在子目标层面，构建分层的长视野 Q 学习。 · arXiv 2611.10987