论文解读 · arXiv 2611.11166 · 2026-11-10

DexForesight

Grounding Dexterous Policies with Implicit Spatial Foresight

用「隐式空间预见」武装灵巧手策略：训练时学会预见未来，部署时不生成任何未来

Zhongxi Chen, Yi Yang, Xinyi Chen, Mingzhe Ye, Yaping Li, Zhihong Liu, Congsheng Xu, Haonan Wang, Zhijie Deng

Sharpa Robotics · 上海交大– Sharpa 具身智能联合实验室 · 港中文 · 复旦

项目页： dexforesight.github.io

TL;DR

一句话总结：把世界模型的「空间预见」蒸馏进策略潜空间

训练时用离线深度、手部运动学点云和示范动作训练一个动作条件空间世界模型，预测 3D 手部点流与 DINOv3 特征变化；冻结后通过 query 对齐把它的特征注入 VLA 策略。**部署时**只用 RGB + 语言 + 机器人状态，不跑世界模型、不估深度、不解码未来。

49.4% → 60.5%

仿真 11 个 DexJoCo 任务总成功率
（基座 GR00T N1.7 ， +11.1 个点）

58.3% vs 50.0%

真机 3 个灵巧手任务总成功率
（对比最强基线 WLA ）

+3.0 ms

推理延迟 227.4 → 230.4 ms
（ +1.3% ）
同硬件对比 QwenVLA 基座

核心主张：预测性知识不必在部署时显式生成，可以作为训练期的特权信号被策略「吸收」。

灵巧手需要「空间预见」，但现有路线都要付出部署代价

显式生成未来

世界 - 动作模型（ WAM ）

- 推理时生成未来图像 / 运动再选动作
- 每个控制步都增加计算： Cosmos3 生成 16 帧视频需 930 ms
- 要重建纹理、背景等与动作关系不大的外观细节

部署时输入深度

3D / 深度条件策略

- 依赖在线深度重建管线
- 额外计算，且手和物体运动时需要时序一致的深度视频

静态空间表征监督

ReconVLA 、 Spatial Forcing 等

- 主要提升场景几何表征
- 没有建模「被控的多指手如何运动」

共同盲区：相机看不到被遮挡的手指——但机器人运动学和关节状态可以给出手部各连杆位置，与可见性无关。

论文的问题：能否在训练时学到空间预见所需的预测特征，而部署时不解码任何未来输出？

出处： Sec. 1 、 Sec. 2 ； Sec. 4.2 （ Cosmos3 延迟）

核心思路：世界模型只做训练期的「空间老师」，部署只留策略

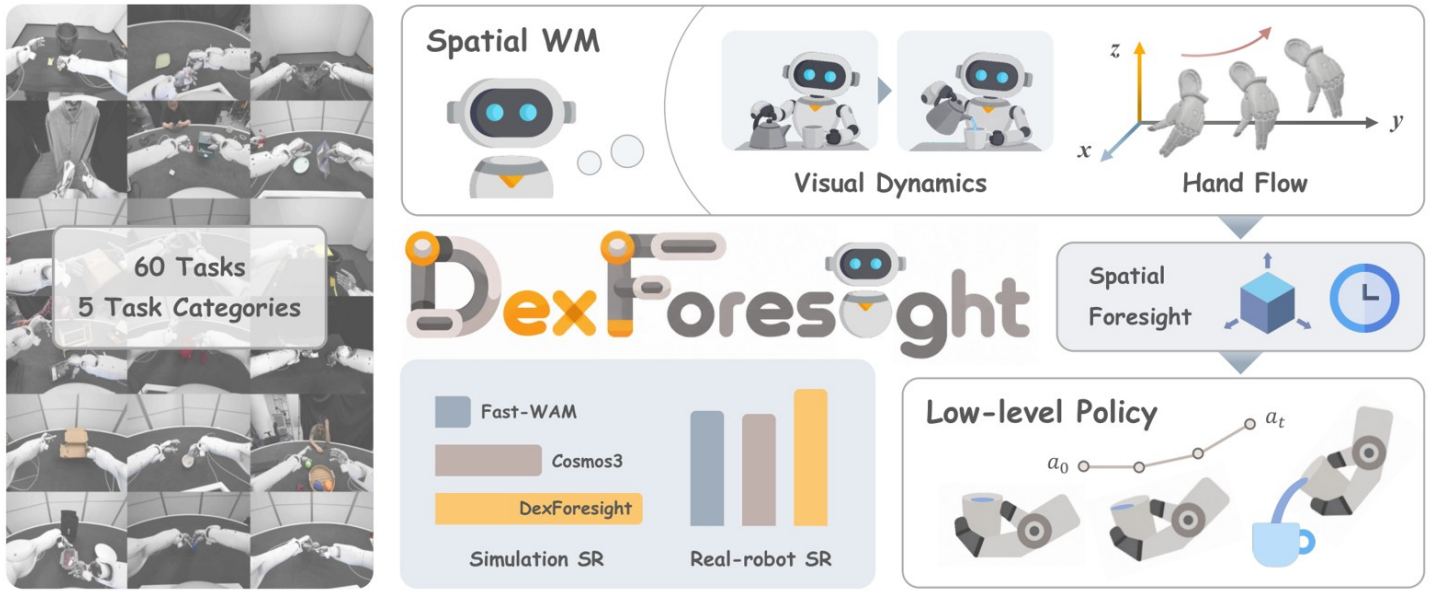

训练时可用（特权信息）

- 多视角 RGB 、语言、机器人状态
- 离线深度（真机 StereoAnyVideo / 仿真渲染）
- URDF + 正运动学得到的手部点云
- 示范动作与记录的未来状态

▼ query 对齐蒸馏

部署时只用

- 当前 RGB + 语言 + 机器人状态
- 不跑世界模型、不在线估深度
- 不生成未来图像 / 运动

两阶段架构：动作条件世界模型 → query 对齐 → 动作专家

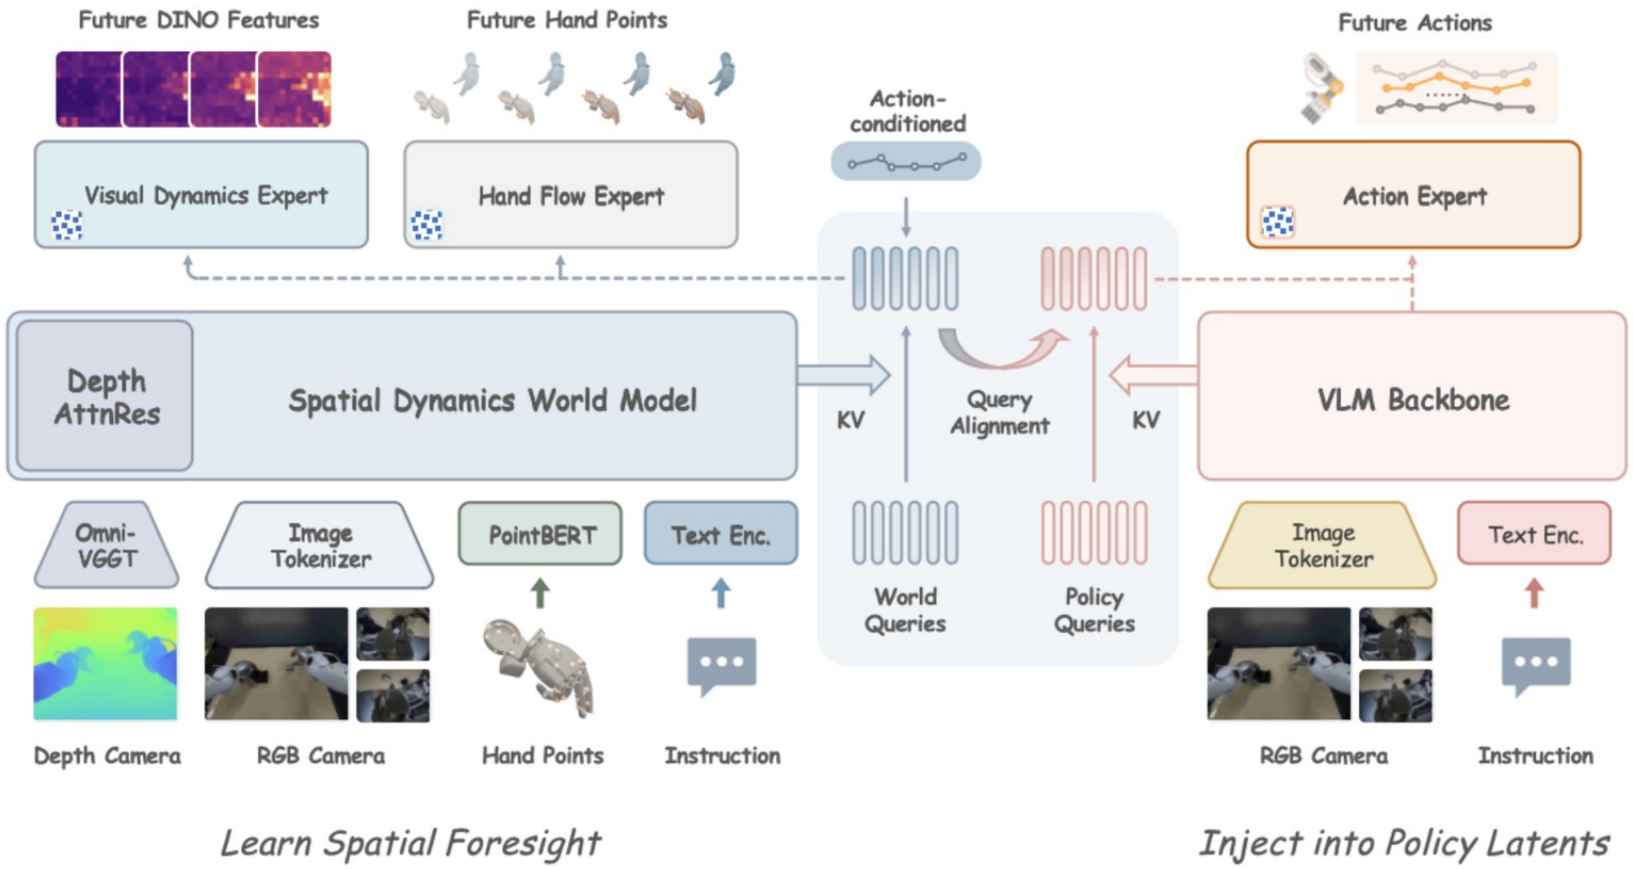

1 空间动力学世界模型

RGB 、离线深度（OmniVGGT + Depth AttnRes）、手部点（Point-BERT）、指令共同编码； backbone 由 RynnBrain 初始化

2 动作条件 World Queries

示范动作经 query adapter 调制 world queries，驱动 Hand Flow / Visual Dynamics 两个专家预测未来

3 Query 对齐 → 动作专家

冻结教师；策略 VLM 的 policy queries 对齐 world queries，并拼进 Action Expert 的上下文

教师学什么：被遮挡手指的 3D 点流 + 场景特征变化

手部几何

- 在 URDF 各连杆上采样固定点，用记录的关节状态做正运动学到基座系
- 每个点保持连杆归属与局部坐标 → 跨帧对应关系不变
- 被遮挡的手指也有精确坐标
- Point-BERT 编码当前点云 + 短历史

深度融合

- OmniVGGT 把 RGB-D 编码为几何 token
- 在第 2, 6, …, 26 层后用交叉注意力注入（可学习缩放 γ）
- 第 4, 8, …, 28 层前按 Attention Residuals 做 token 级 softmax 路由
- 初始化贴近预训练计算，保护原有特征

动作条件预测

- N 个 world queries 读取第 12/20/28 层
- 16 帧未来窗口分 4 个 bin，每 bin 采 1 个偏移（K=4）
- 示范动作（相对当前状态）经 adapter 注入
- 两个扩散专家 + Smooth L1；future-horizon dropout

Hand Flow： $F = P(t+\delta) - P(t)$， M 个手部锚点的 3D 位移

Visual Dynamics： $\Delta V = \Phi(I(t+\delta)) - \Phi(I(t))$， DINOv3 特征残差

$$L_{world} = L_{hand} + \lambda v \cdot L_{visual} + \lambda c \cdot L_{context}$$

深度只作为当前几何条件，不需要未来深度目标；动作是条件输入，手部运动与视觉变化才是预测目标。

出处： Sec. 3.1， Eq. (2)–(4)

学生如何吸收： query 对齐 + 拼进动作上下文，部署只多 3 ms

1 冻结教师

只跑世界模型 backbone + query adapter 得到 Z^w，不执行两个预测专家

2 对齐 query

策略 VLM 新增 N 个 policy queries 读取隐藏层，投影到教师特征空间：逐 query 余弦（token） + 两两相似度矩阵（relation）

3 条件动作

对齐后的 query 经 W_act 投影后拼接： $\tilde{C} = [C ; Z^{\pi} \cdot W_{act}]$，与原动作损失联合训练

4 部署

移除世界模型、深度编码器、手部编码器和两个专家；上下文每次观测只算一次，采样时复用

$$L_{policy} = L_{action} + \lambda_{align} (L_{token} + \beta \cdot L_{relation})$$

注意：学生看不到示范动作 U_t，对齐只是辅助目标，不是精确复现教师预测

单次推理延迟（ms，越低越好）

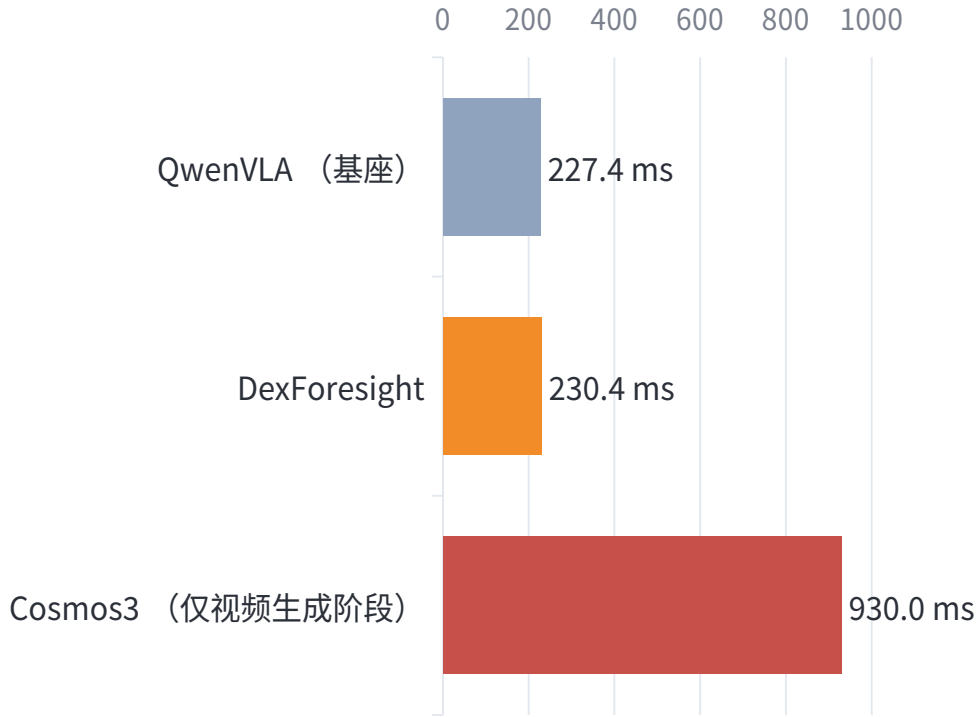

同硬件同设置： DexForesight 比 QwenVLA 仅多 3.0 ms（+1.3%）。 Cosmos3 的 930 ms 只计入其 16 帧未来视频生成阶段。

出处： Sec. 3.2， Eq. (5)； Sec. 4.2 （延迟数据）

约 370 小时、 60 个任务的真机示范训练世界模型，分三阶段

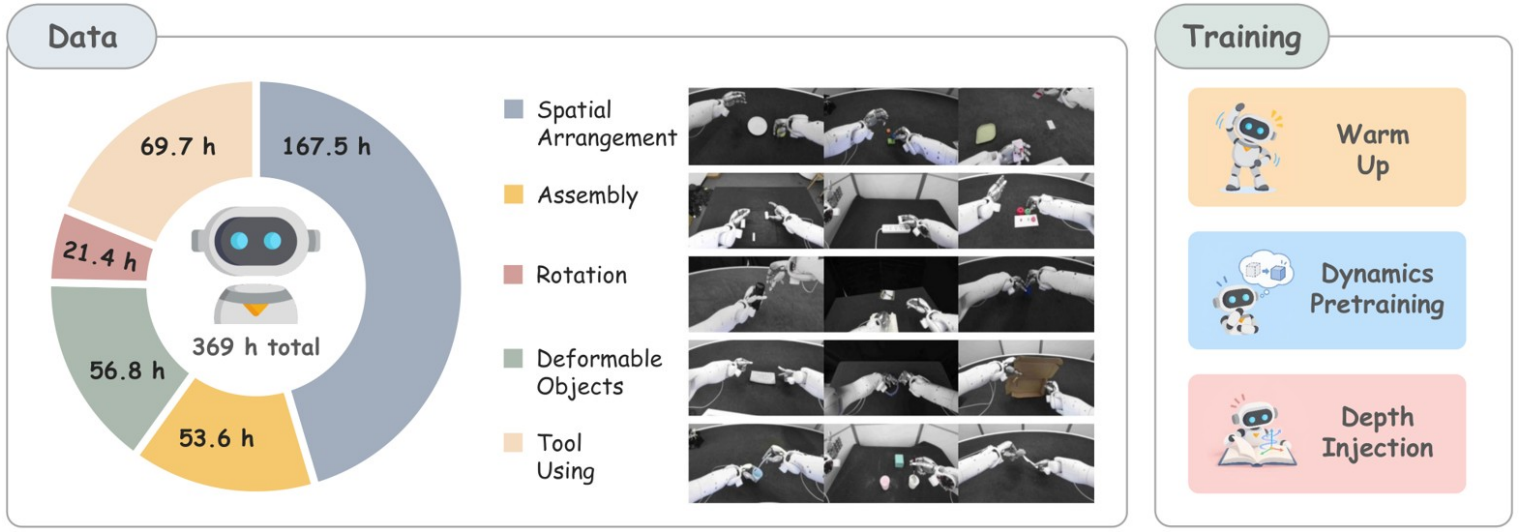

369 h

60 个任务 · 5 个类别（Figure 3 合计）

类别	时长
空间摆放	167.5 h
工具使用	69.7 h
可变形物体	56.8 h
装配与接触	53.6 h
旋转与铰接	21.4 h

三阶段： Warmup → 动力学预训练（无深度）→ 深度注入

深度阶段： 100 h 子集，覆盖空间摆放 / 装配 / 旋转三类，深度由 StereoAnyVideo 离线估计

出处： Figure 3； Sec. 3.1 Data and training

评测覆盖仿真 11 个任务与真机 3 个高难度灵巧任务

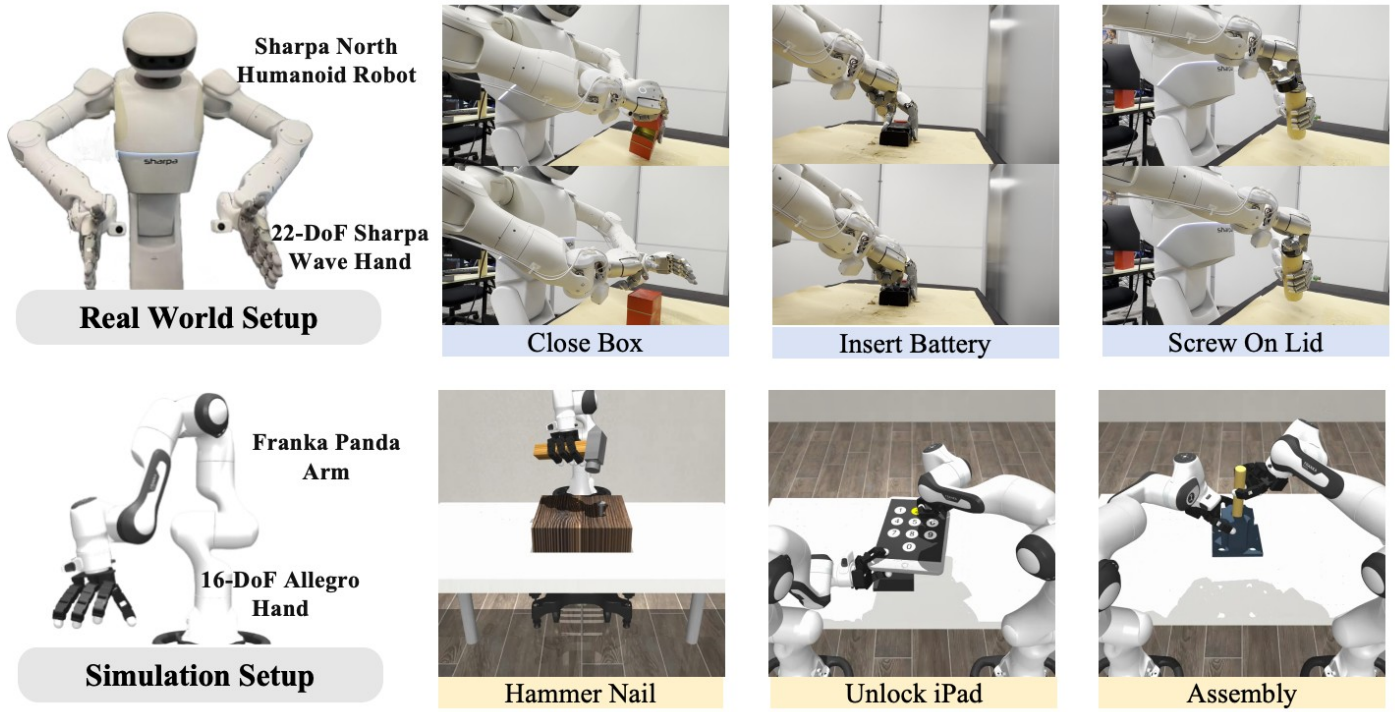

仿真 · DexJoCo

- 11 个任务，单臂 + 双臂
- Franka Panda + 16-DoF Allegro 手
- 基座 GR00T N1.7；深度由 MuJoCo 渲染
- 每任务 100 次试验

真机 · Sharpa North

- 22-DoF Sharpa Wave 手；基座 QwenVLA
- Close Box / Insert Battery / Screw On Lid
- 测试位置训练中未见过； Screw 还换杯子颜色
- 各方法微调 30 epoch，每任务 20 次

仿真：总成功率 60.5%，比最强基线 Fast-WAM 高 9.6 个点

DexJoCo 11 任务总体成功率（%）

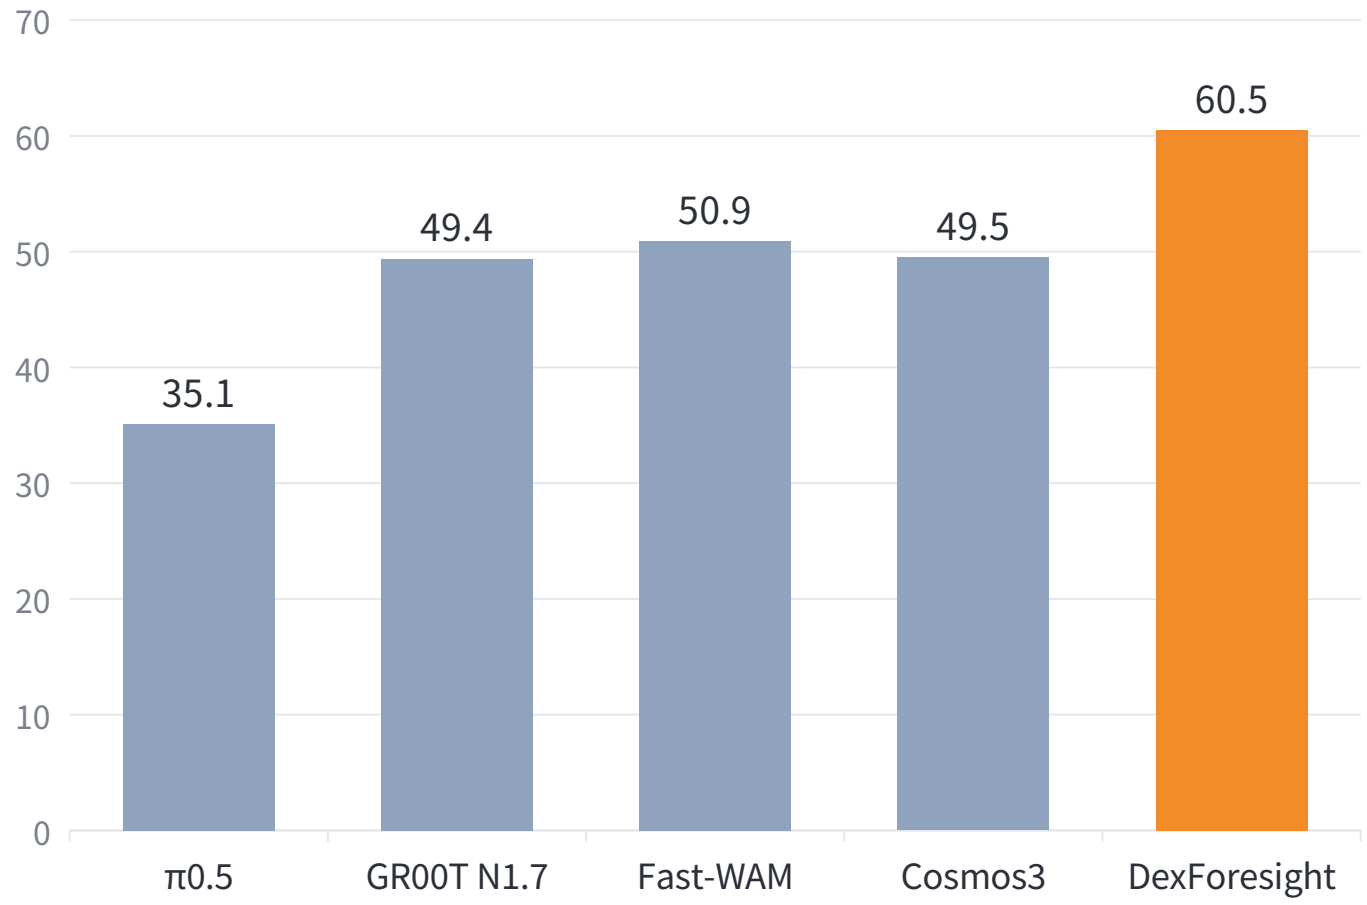

+11.1 个点

相对自身基座 GR00T N1.7 （49.4 → 60.5）

方法	单臂	双臂
π0.5	53.0	13.6
GR00T N1.7	61.5	34.8
Fast-WAM	60.2	39.8
Cosmos3	59.5	37.4
DexForesight	**76.3**	**41.6**

单臂提升最大（+14.8 vs GR00T）；双臂仅比 Fast-WAM 高 1.8 个点。每任务 100 次。

真机：总成功率 58.3%，三个任务都是最高（Screw 与 WLA 持平）

真机成功率（%，每任务 20 次，测试位置训练中未见过）

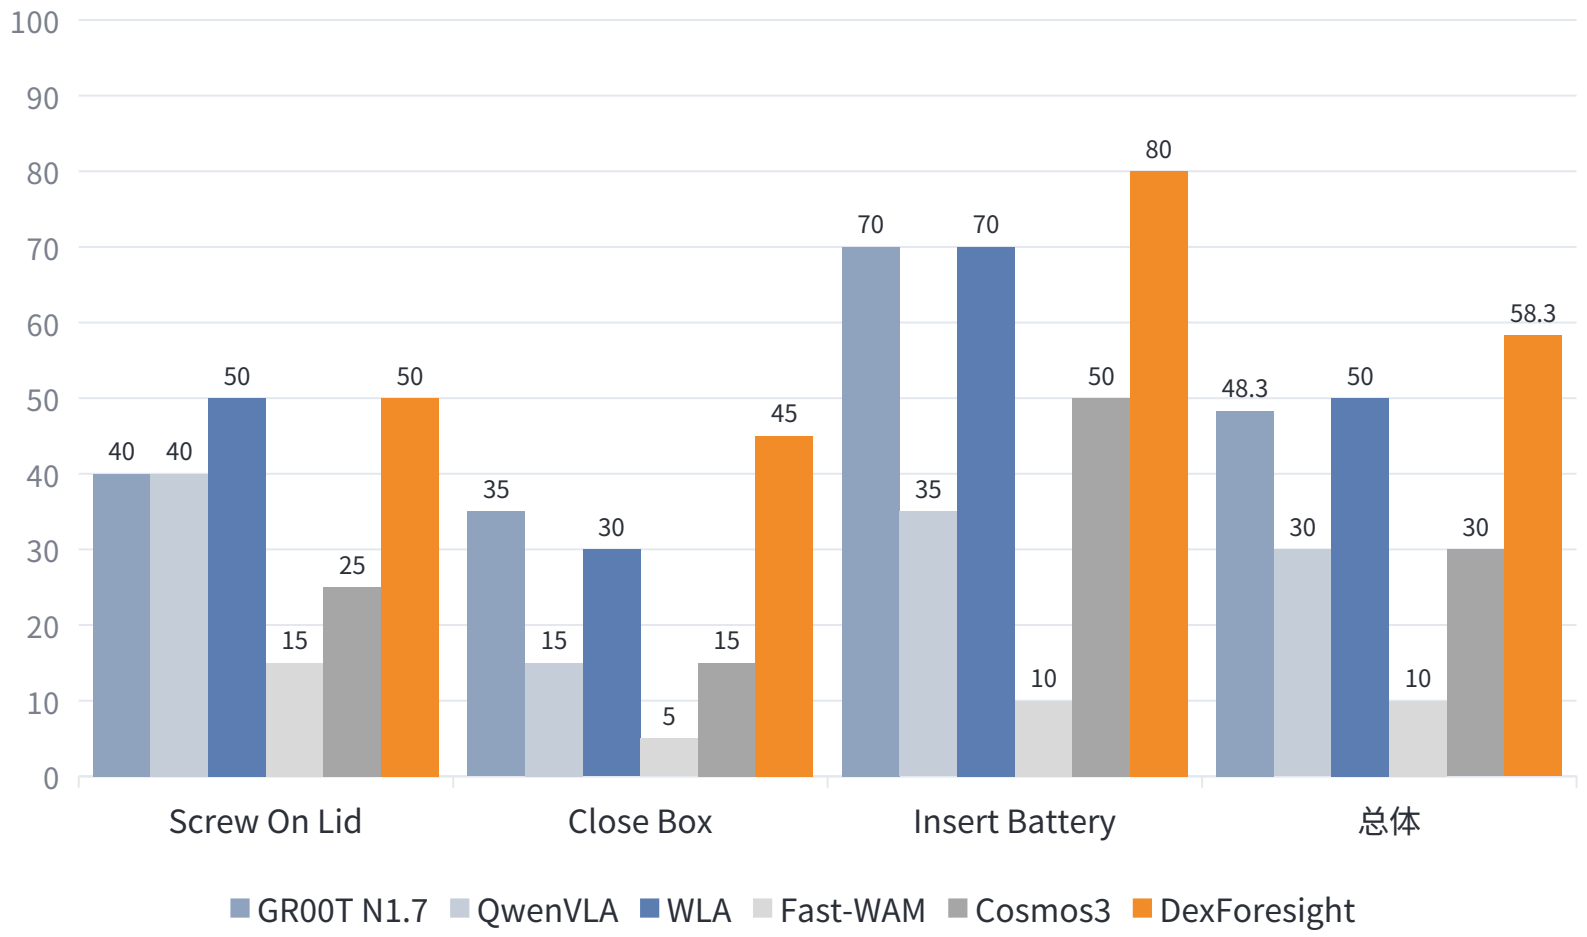

+28.3 个点

相对 QwenVLA 基座（30.0 → 58.3）

35/60 vs 30/60

对 WLA 的领先换算成次数，样本量有限

失败模式与设计挑战一致

Screw： 手指遮挡

Insert： 物体部分遮挡

Close： 盖子与盒子的几何关系

出处： Table 2； Sec. 4.2

去掉教师后，策略特征里仍保留更多未来手部运动信息

未来 3D 手部点位移的线性探针误差（mm，越低越好）

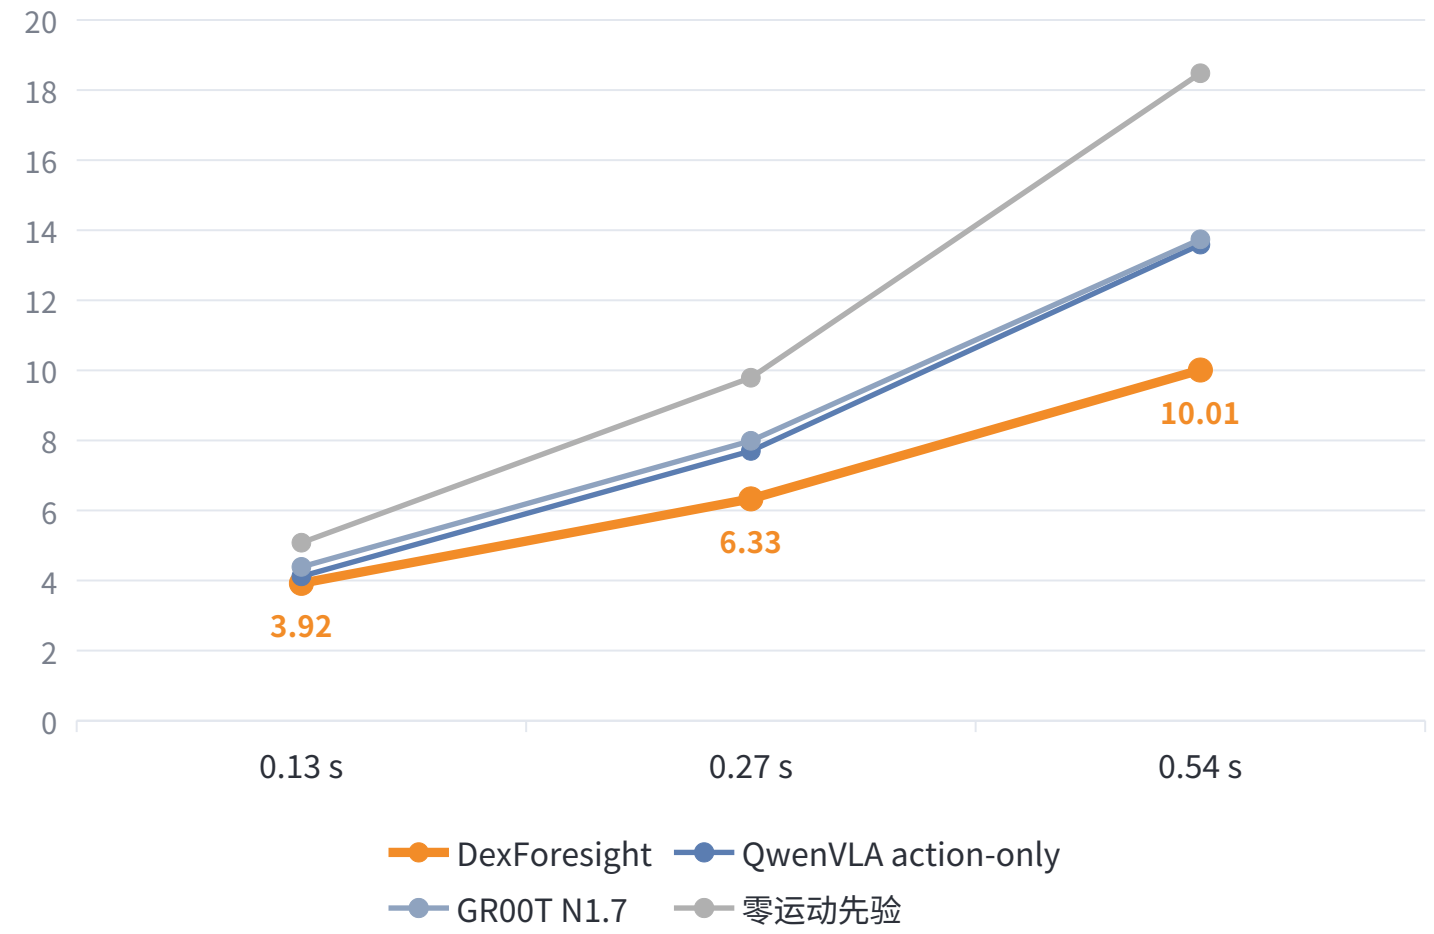

−26.3%

0.54 s 处误差 13.59 → 10.01 mm
（对比架构相同的 QwenVLA action-only）

探针怎么做

- 冻结真机检查点，只从策略本身取特征
- 岭回归线性探针，训练 / 测试按 episode 划分
- 95% episode bootstrap 置信区间

要注意：预测越远差距越大；但 0.13 s 处置信区间重叠（[3.47, 4.13] vs [3.83, 4.47]），短时程差异不显著。

出处： Table 3； Sec. 4.3

蒸馏优于给策略直接加预测头，且教师必须以真实动作为条件

DexJoCo 总体成功率（%）

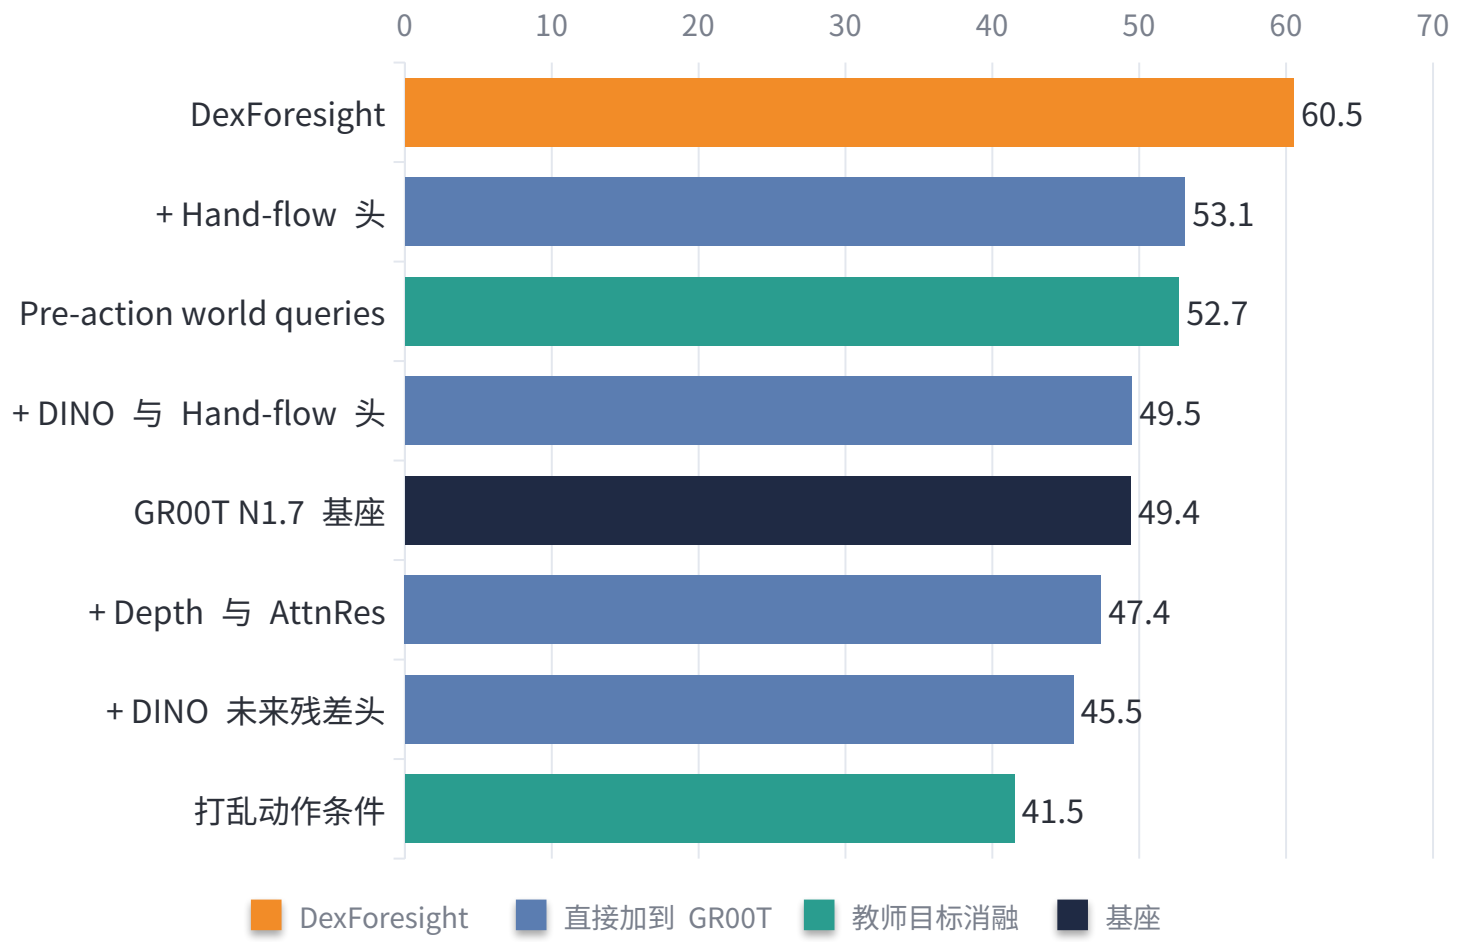

直接加头不如蒸馏

最好的直接方案 Hand-flow 头 53.1%，DexForesight 高出 7.4 个点；两个头一起反而降到 49.5%

动作条件是关键

不以动作为条件的 pre-action queries 只有 52.7%；以真实动作为条件提升到 60.5%

错误教师会伤害策略

打乱动作条件后降到 41.5%，比基座还低 7.9 个点

出处：Table 4（上、中两组）；Sec. 4.3

教师质量决定学生：深度、融合方式与手部流目标缺一不可

去掉离线深度

49.7%

仿真 − 10.8 个点

真机 58.3 → 43.3 （− 15.0 ）
Screw 35 / Close 25 / Insert 70
部署输入完全不变

拼接深度 token 代替跨层融合

42.0%

仿真 − 18.5 个点

作者推测：直接拼接深度 token
扰动了预训练的多模态特征

未来动作目标 代替手部点流

48.4%

仿真 − 12.1 个点

低于 GR00T 基座 49.4%
支持用运动学手部流做监督
（可覆盖被遮挡的手部表面）

对照：完整 DexForesight 仿真 60.5% / 真机 58.3%； GR00T N1.7 基座仿真 49.4% 。各项只改教师，学生部署输入不变。

出处： Table 4 （下组）； Sec. 4.4

批判性解读

评价：思路干净、证据链完整，但真机统计与基线适配仍需加强

亮点

特权信息蒸馏：深度、点云、未来状态只在训练用，部署只多 3 ms

运动学手部点流：不受遮挡影响，正对灵巧操作的手指遮挡痛点

证据链完整：成功率 + 线性探针 + 对比直接加预测头，回答了「为何要先训教师再蒸馏」

有参考价值的负面结果：直接加头、拼接深度 token 都会变差

局限与疑问

真机样本小：每任务 20 次，对 WLA 是 35/60 vs 30/60； Screw 持平

基线适配存疑： Fast-WAM 仿真 50.9%、真机仅 10%

仿真与真机现象不一致：去掉深度后仿真 ≈ 基座，真机仍明显高于基座

负迁移风险：打乱动作后低于基座；学生看不到动作，多模态行为下对齐目标可能被平均化（文中未分析）

成本与泛化：需约 370 h 数据 + 单独训练的大世界模型；真机只有 3 个任务，泛化只测了新位置和颜色

出处：基于 Table 1–4 与 Sec. 4 的分析

TAKEAWAYS

世界模型不必在部署时运行，也能让策略获得预见能力

01 **训练期特权信号**

离线深度 + 运动学手部点云 + 示范动作，训练一个动作条件空间世界模型

02 **预测目标的选择**

3D 手部点流 + DINOv3 特征残差；用未来动作或拼接深度 token 替代都会明显变差

03 **query 对齐注入**

对齐后的 query 直接拼进动作上下文；仿真 +11.1 个点，真机 58.3%，延迟 +3 ms