论文解读 · arXiv 2611.11344

Spatial Harness

把空间推理“落地”到物理引擎中可执行的世界状态

Grounding Spatial Reasoning in Executable World States with Physics Engines

Chentao Cao*, Zhanke Zhou*, Sangni Duan, Bo Han, Hang Li

TMLR Group，香港浸会大学 · ByteDance Seed · 首次提交 2026-11-08

代码： github.com/tmlr-group/Spatial-Harness

TL;DR

一句话总结：先把场景“写下来”，再让引擎“算出来”

Spatial Harness 由 **Perceiver** 把题目中的文本约束与检测 / 深度 / 朝向 / 相机位姿等专用视觉估计融合成**显式 JSON 世界状态**，再实例化到 **MuJoCo**，由 **Reasoner** 写 Python 转相机、量距离、渲染视角，以引擎**计算出的反馈**而非模型内部想象来回答空间问题。

52.70% → 71.14%

MindCube 端到端准确率

Qwen3.5-27B， +18.44 pp

+7.52 pp

超过最强基线 pySpatial

同一 VLM （Qwen3.5-27B）

98.25% vs 71.81%

相同真值地图：执行 vs 想象

排除感知误差后的纯推理对比

Motivation

问题： VLM 在“脑内”同时做场景表示与空间变换，错误无从检查

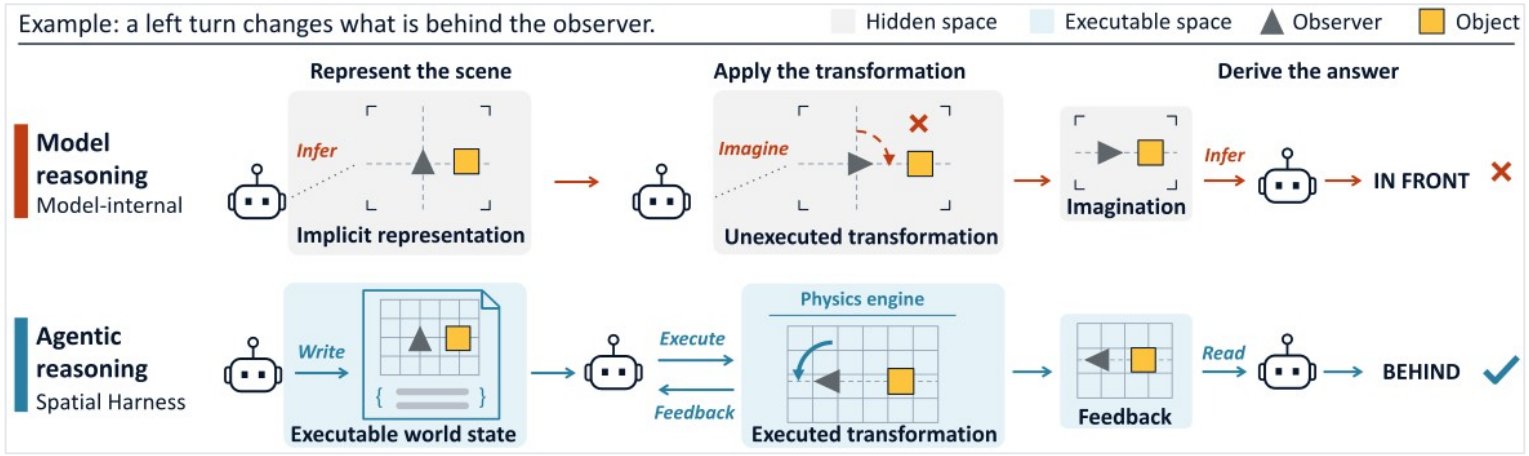

两类不可区分的失败

① 布局读错 → 一致地推出错答案

② 布局读对 → 变换想象错（如左右颠倒）

现有方法的不足

MindJourney 生成新视角，但画面不受显式场景约束；文本地图仍要模型自己想后果

现状： GPT-5 在 MindCube 上

仅 47.59%

随机猜测为 32.35%

Method

方法总览： Perceiver 估计世界状态， Reasoner 在 MuJoCo 中执行查询

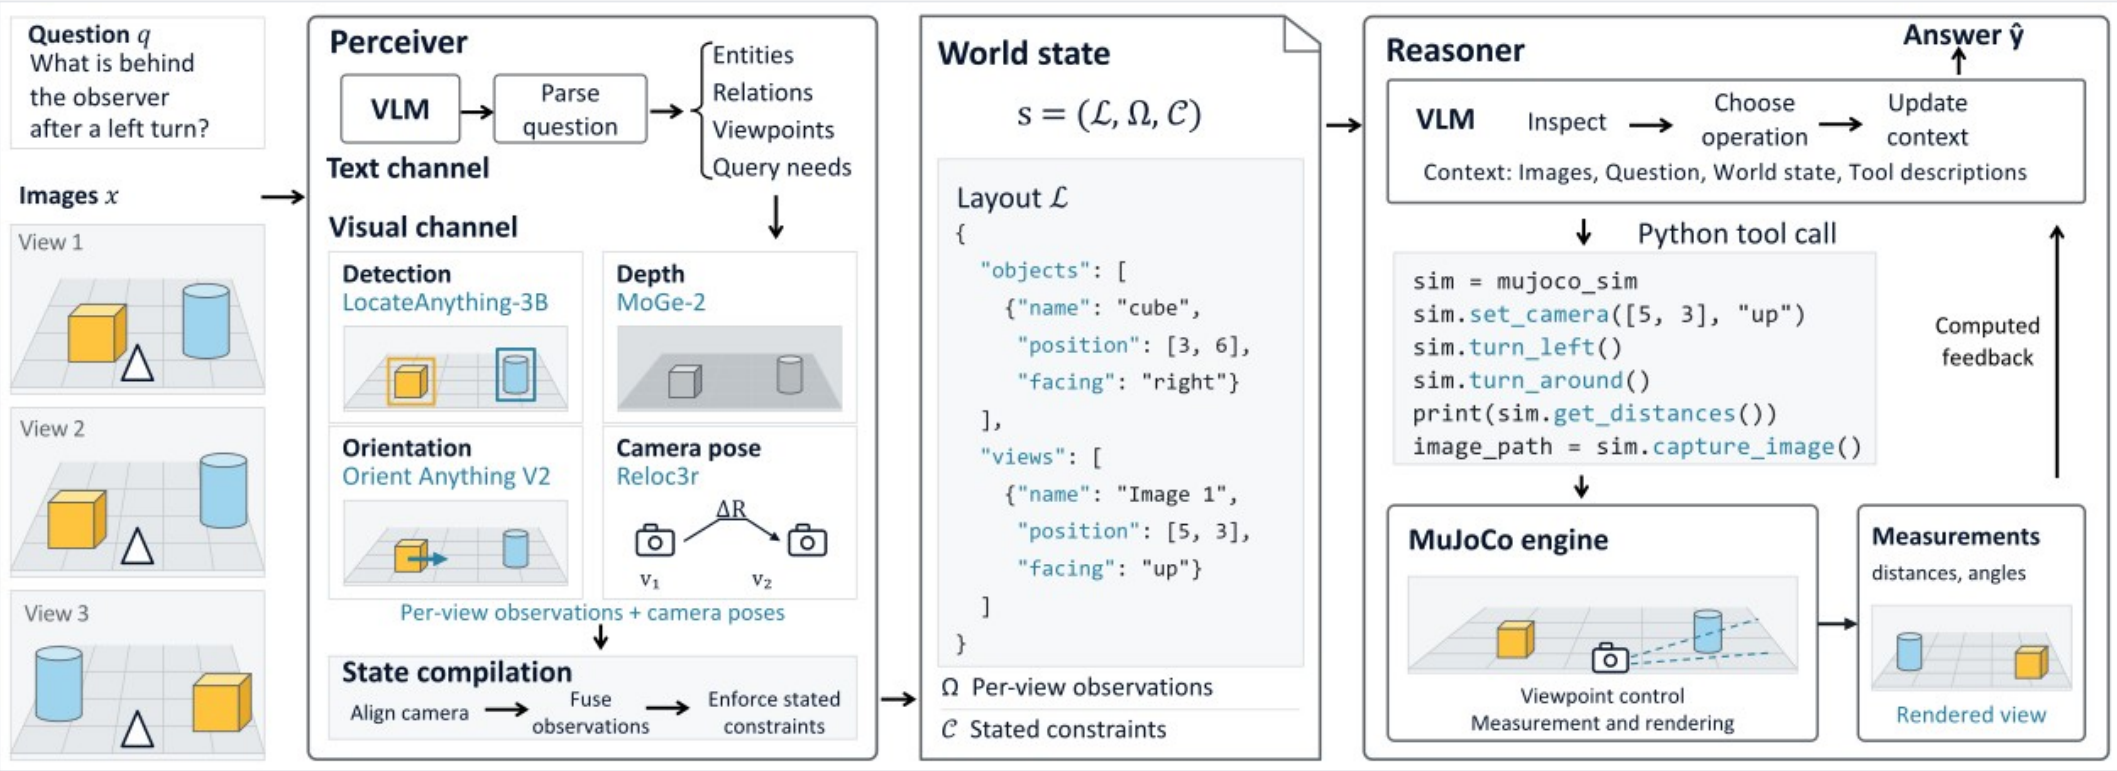

Perceiver $\hat{s} = P(x, q)$

文本通道解析问题 + 视觉专家估计几何 → 编译为共享坐标系中的布局

World state $s = (L, \Omega, C)$

布局 L · 每视图观测 Ω · 题目陈述约束 C；显式、可检查、可执行

Reasoner $\hat{y} = R(x, q, \hat{s}; E[\hat{s}])$

在引擎实例 E[ŝ] 上调用视角控制 / 测量 / 渲染，用计算反馈作答

来源： Figure 4 （论文 fig03 ）

世界状态分两层：逐视图观测 Ω 经相机位姿对齐为共享布局 L

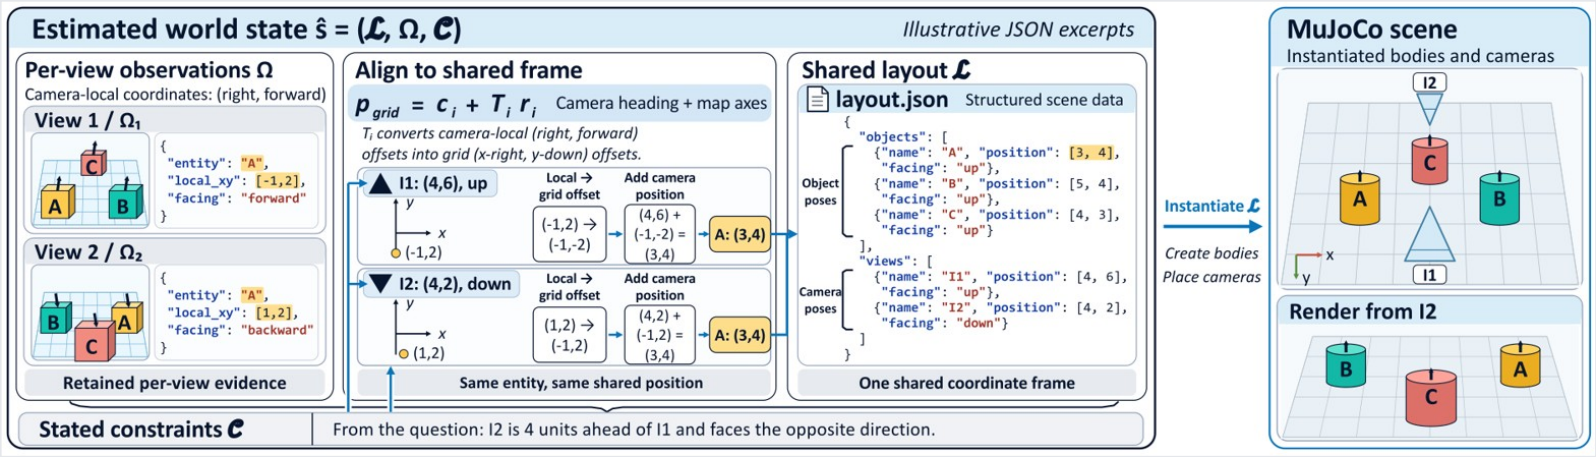

Ω 观测层

每张图中实体相对相机 i 的方向、距离、朝向（度量或定性）

L 布局层

以相机 1 为原点的共享坐标系；实体 (p, θ) 与相机 (c, ϕ)，用于实例化

C 约束

题目陈述的关系 / 相机运动，严格成立（硬约束）

$$p_{ij} = c_i + R(\phi_i) \cdot r_{ij}$$
$$\theta_{ij} = (\phi_i + \alpha_{ij}) \bmod 2\pi$$

来源： Figure 5 （论文 fig04 ）, Eq. 2

Perceiver： 语言约束 + 视觉专家，按可信度优先级编译出布局

文本通道（ VLM 解析问题 q ）

实体 O

问题涉及的物体与观察者

关系

如“A 在 B 左边”

视点

如“两张图之间相机左转”

查询类型

方向 / 距离 / 朝向 / 相机运动

视觉通道（专用模型）

检测 → 方向

LocateAnything-3B （+ Qwen3-Reranker 绑定名称）

深度 → 距离

MoGe-2： 度量深度与内参

朝向 → facing

Orient Anything V2

相机相对位姿

Reloc3r： 旋转与平移方向

编译（ Compilation ）

相机朝向来源优先级

题目陈述 0.95 › 共同地标 0.6 › Reloc3r 0.5 › VLM 0.4

观测投影到共享坐标系

多候选：取最高置信位置，朝向投票

网格局部搜索（ Eq. 3 ）

$\max \Sigma w_k \cdot 1[L \models r_k] - \lambda \Sigma \| p_j - \hat{p}_j \|$

题目陈述关系权重 20 （硬约束），其余来自图像描述 / 检测方位

Reasoner： 把物理引擎当工具，视角控制 • 测量 • 渲染都由状态算出

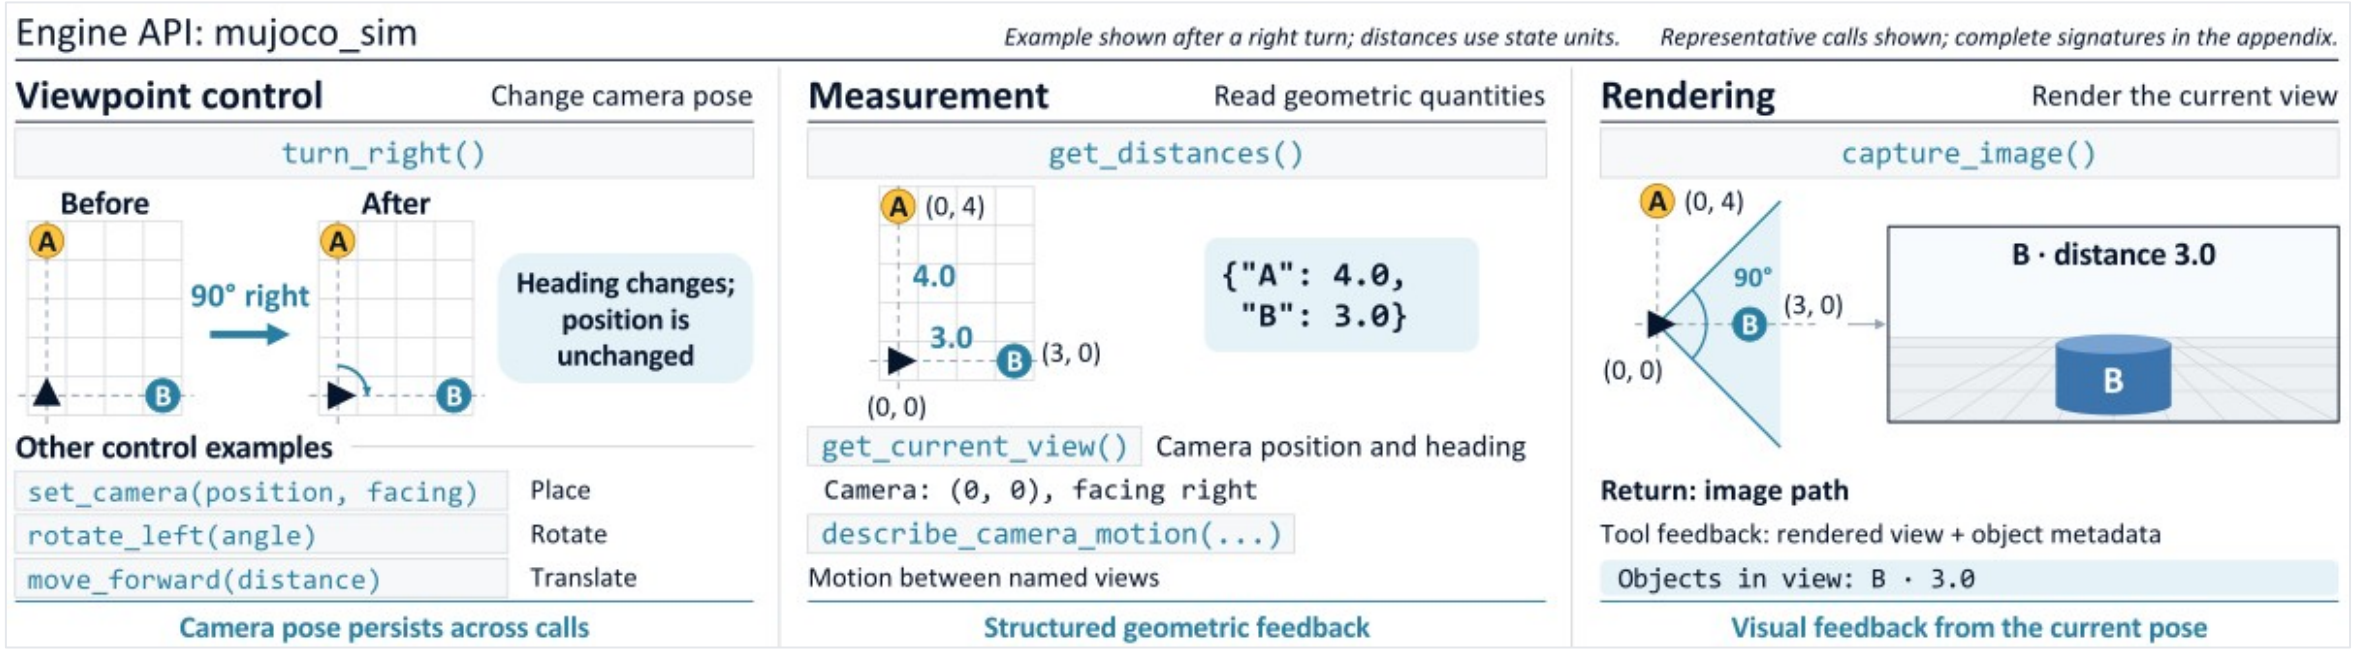

交互循环（ Eq. 4 ）

$$a_t = R(h_t),\ f_t = E[\hat{s}](a_t),\ h_{t+1} = h_t \oplus (a_t, f_t)$$

最多 T_max = 5 轮；至少一次引擎调用后才接受答案；反馈确定且与 ŝ 一致

代理体表示

实体 = 带标签与朝向标记的圆柱；不做网格重建

路由

外观 / 遮挡等状态无法描述的问题 → 退回 VLM 直接回答

来源： Figure 6 （论文 fig05 ） , Eq. 4, Appendix C.3

Walkthrough

示例：执行 180° 转身发现“前方是窗”，于是再转身检查“身后”

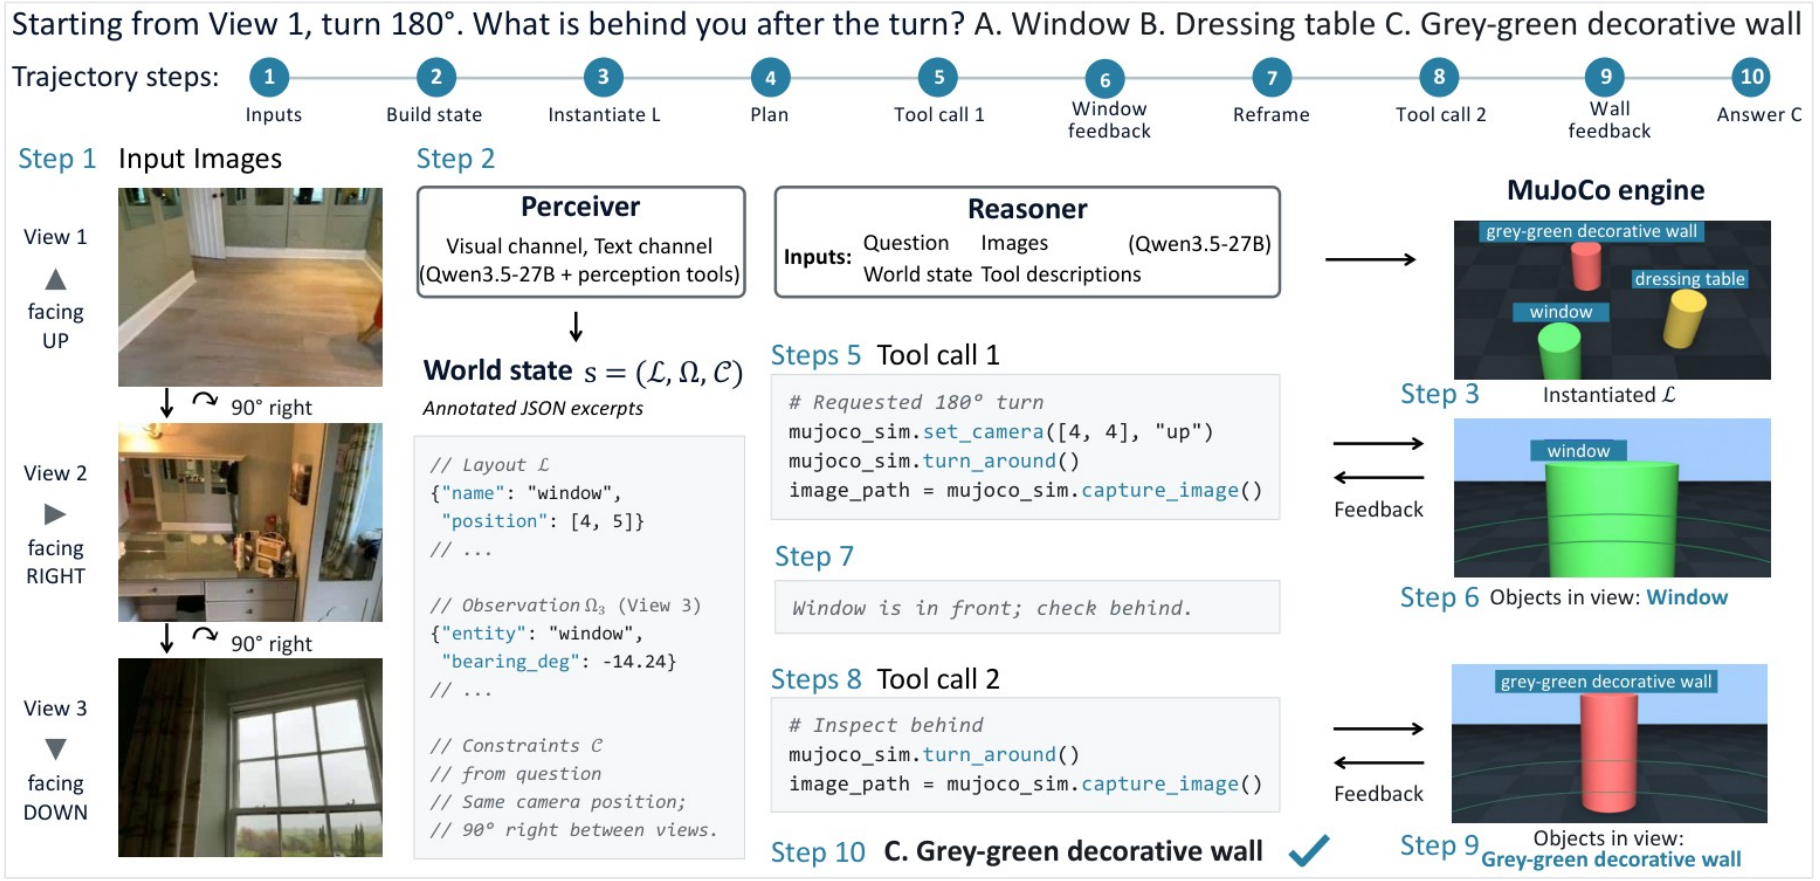

1–3	构建并实例化状态
4–6	turn_around → 看到 window
7	发现问的是“身后” → 重新规划
8–10	再转身 → 灰绿装饰墙 → 选 C

Result · 推理与感知解耦

相同真值地图下，执行推理在 7 个 VLM 上全面胜出：最高 98.25%

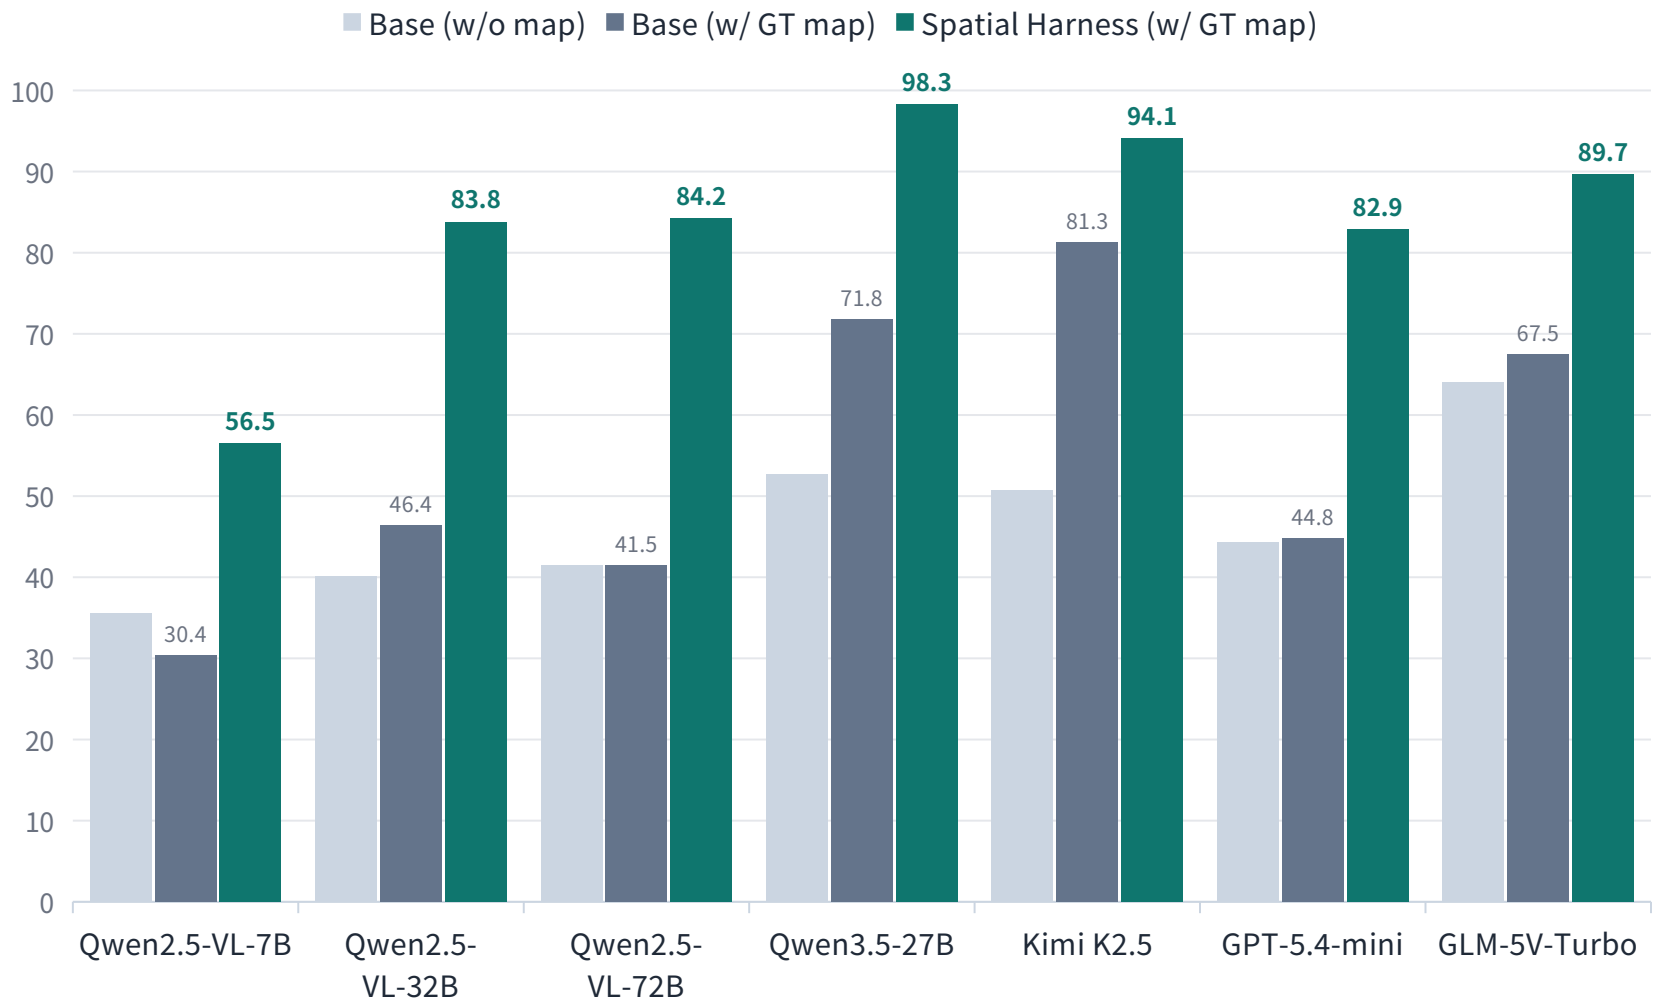

Qwen3.5-27B · 同一地图

71.81 → 98.25

增益无法归因于更好的场景估计

- 文本地图帮助不稳定： 7B 模型 **35.59 → 30.35**
- 执行推理相对 Base （有图）提升 **+12.83 ~ +42.76 pp**
- 3 次运行标准差多 < 1 pp （ Table 11 ）

注： Qwen2.5-VL-7B 的 Rotation 子类反而 35.50 → 34.33 ，小模型用不好工具

来源： Table 1 / Figure 3 （ MindCube ， GT-map 设定）

端到端： 4 个 VLM 上全部第一，平均超 pySpatial 5.40 pp

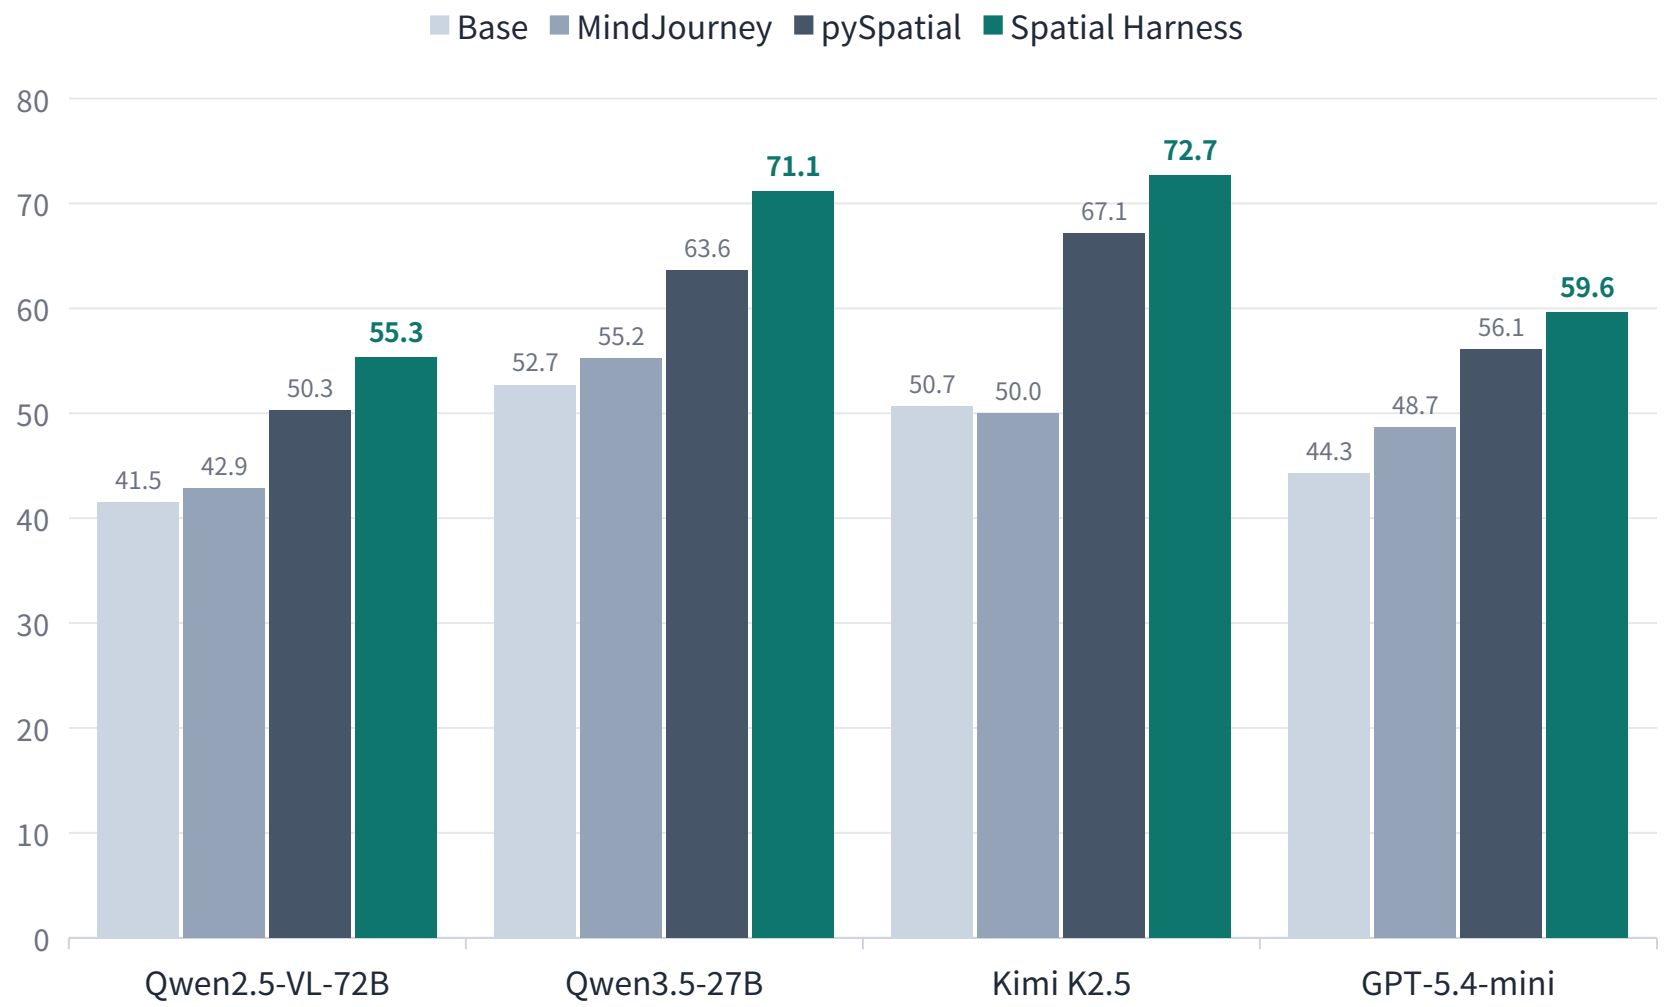

MindJourney： ⩽ +4.42 pp

视频世界模型想象新视角，生成画面不受显式场景约束

pySpatial： 部分类别 < Base

从像素重建 3D，无法吸收题目陈述的相机运动等信息

Spatial Harness

状态同时吸收图像与问题；所有反馈由同一状态算出

来源： Table 2 （MindCube，端到端）

跨基准： SAT 、 SpatialRGPT 领先明显， MMSI-Bench 依赖骨干模型

模型	方法	SAT	MMSI-Bench	SpatialRGPT	Avg
Qwen2.5-VL-72B	Base	68.60	29.60	40.72	46.31
	MindJourney	68.60	30.60	39.12	46.11
	pySpatial	55.40	**33.20**	31.64	40.08
	Spatial Harness	**71.60**	29.00	**84.11**	**61.57**
Qwen3.5-27B	Base	81.80	33.40	48.20	54.47
	MindJourney	78.40	33.00	45.66	52.35
	pySpatial	68.00	36.70	39.79	48.16
	Spatial Harness	**83.20**	**39.50**	**83.31**	**68.67**

SAT： 单图题，重建方法吃亏

pySpatial 比 Base 低 13.2 / 13.8 pp； 本方法 71.60 / 83.20 小幅领先

MMSI-Bench： 依赖骨干

27B： 33.40 → 39.50； 72B 持平（29.00 vs 29.60），常读错坐标、忽视反馈

SpatialRGPT： +35 ~ +43 pp

距离 / 尺寸来自度量深度工具与引擎测量；方向题 98.13%

消融①：世界状态必须结构化构建，视觉通道贡献最大

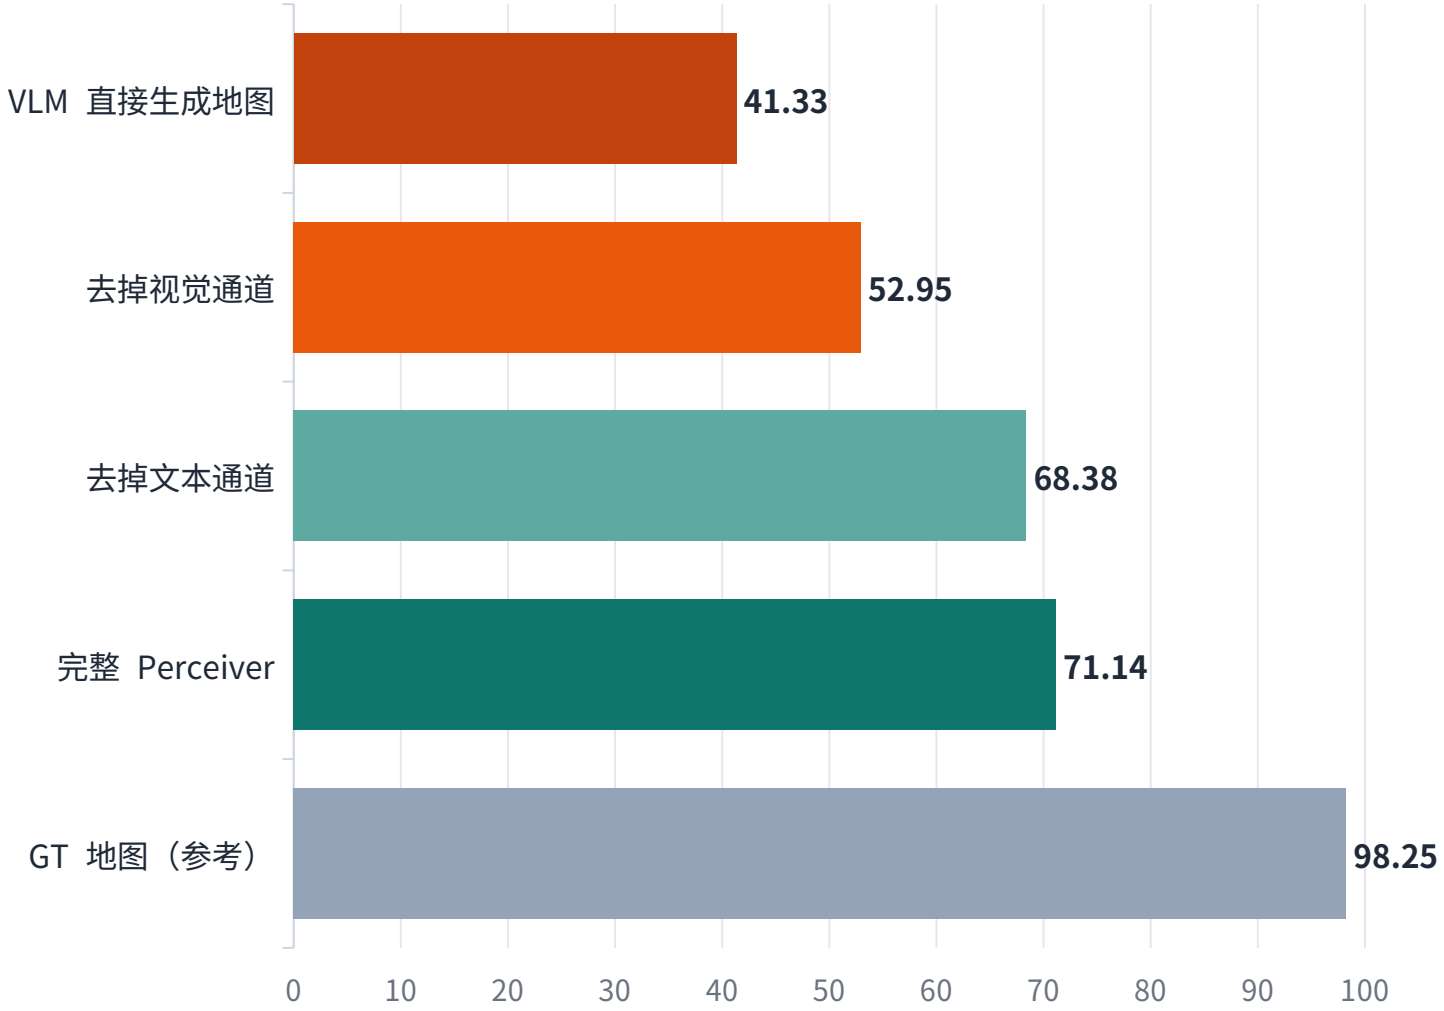

通道内部模块（Figure 7）

去掉相机 / 视图约束

Rotation 81.5 → 48.0

62.29

相对位姿 → VLM

损失最大， Among/Around 受影响

54.10

朝向估计 → VLM

仅 36/1050 题依赖朝向

70.57

完整 71.14 与 GT 98.25 之间仍有 **27 pp** 差距 → 感知是主要瓶颈

来源： Table 4, Figure 7 （MindCube， Qwen3.5-27B）

Ablation • Grounded feedback

消融②：增益来自引擎反馈而非“多想几轮”，数值与渲染反馈互补

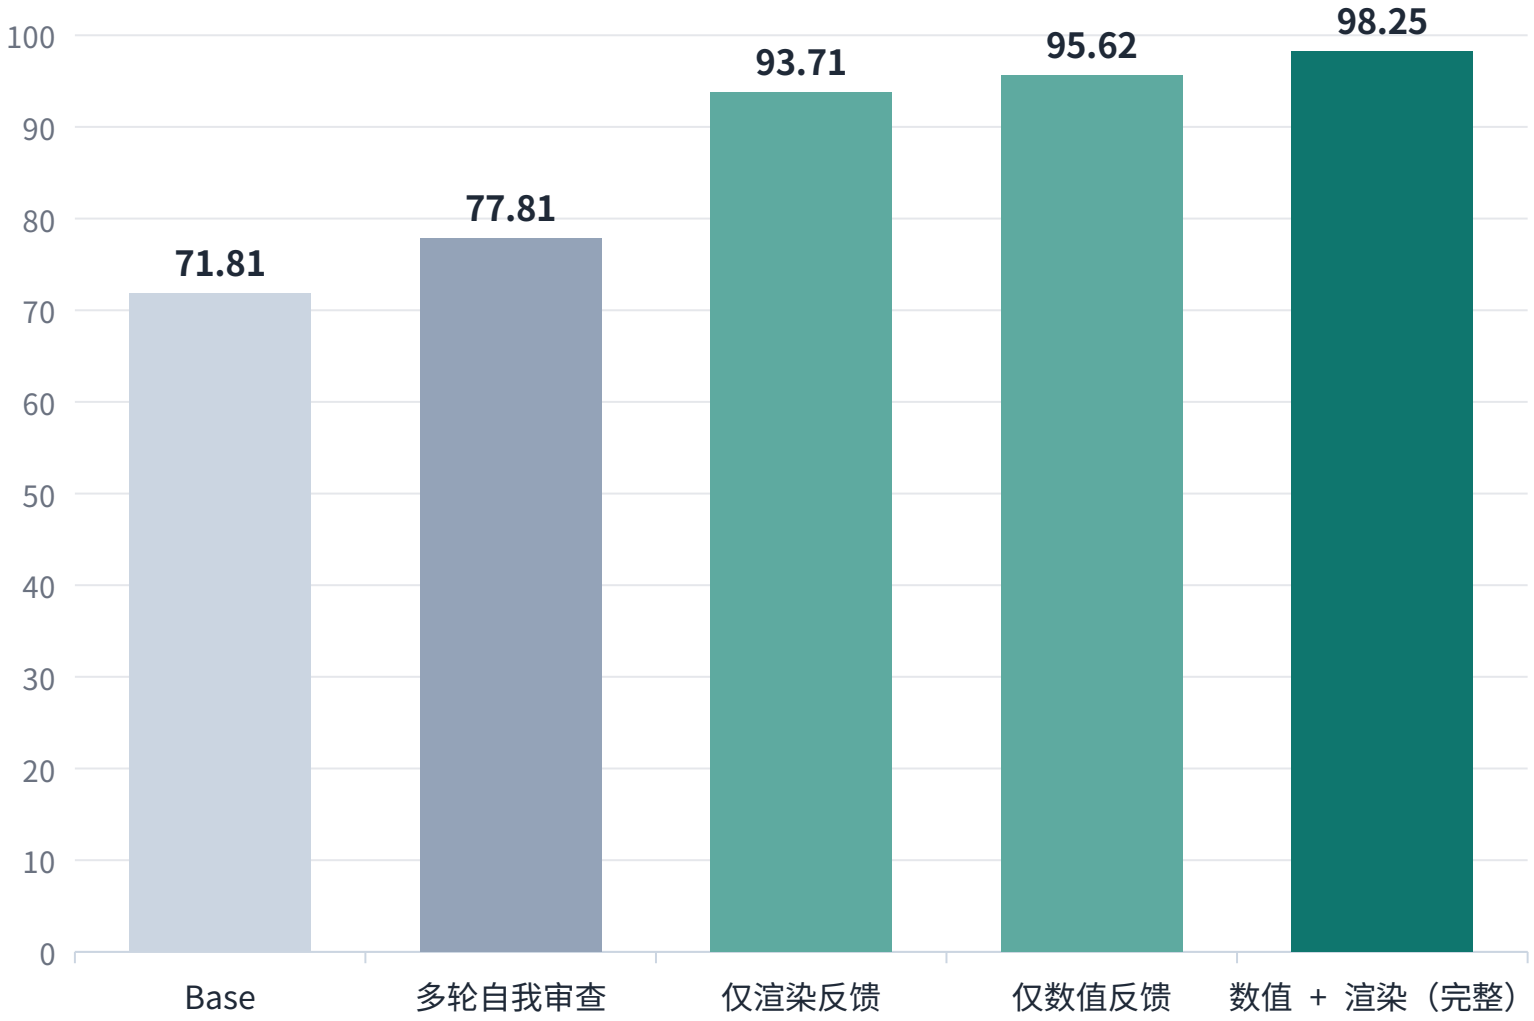

只多想几轮

+6.00 pp

71.81 → 77.81，无新场景信息

任一种引擎反馈

> 90%

数值 95.62 / 渲染 93.71

两者结合

98.25%

互补：测量给精确量，渲染给直观视野

来源： Table 5 （MindCube， Qwen3.5-27B，固定 GT 地图）

状态误差敏感性：相机朝向错误最致命，小幅位置偏差可容忍

单维扰动（GT 地图）	Low	Mid	High
一个物体位置偏移	1 格 92.13	2 格 89.40	3 格 87.78
一个相机偏航	⩽30° 98.10	**30–90° 84.89**	**90–180° 76.67**
物体朝向旋转 90°	1 个 96.06	N/A	2 个 94.32

无扰动参考： 98.25% ； 朝向扰动在 364 / 129 道含朝向标注的题上评测（参考 97.53 / 98.45 ）

99.52%

地图有效率 Validity

≈72%

标注实体覆盖率 Coverage

相机偏航扰动 → 准确率

Perceiver （Qwen3.5-27B ）在 1,050 题上的估计状态质量（ Figure 8 ）

地图几乎都合法，但**仍漏掉约 28% 实体**；更准的地图应能进一步提升端到端结果

Case study

案例：引擎能给出正确证据，但不能强迫模型采纳

成功 · Qwen3.5-27B　**从图 4 看，红瓶左边是什么？**

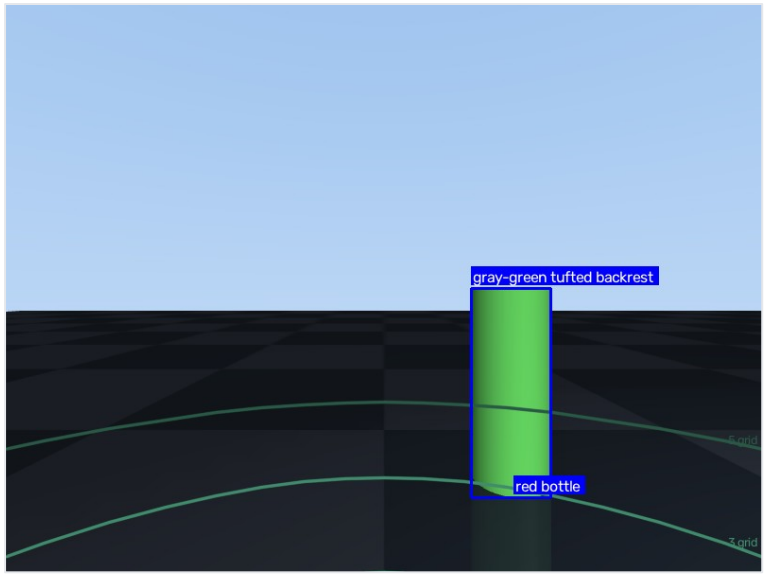

- set_camera([6,5], "left") → turn_left() → capture_image()
- 视野中唯一物体： **gray-green tufted backrest** （3.2）→ 选 B ✓
- Base 三次均把“左边”当成正前方，选窗帘 ✗

失败 · Kimi K2.5　**从图 3 看，玩具火车左边是什么？**

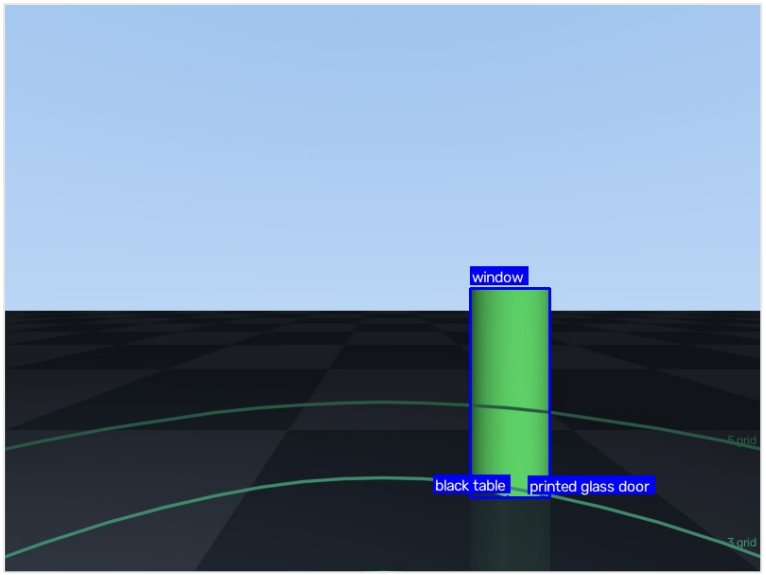

- 第 3 轮 turn_left() 后，引擎渲染出 **window** （正确答案 A）
- 模型改按“火车自身的左边”理解题意，坚持选 D （墙） ✗
- 同模型另两次运行答对； Qwen3.5-27B 三次全对

Critical review

评价：证据有力，但“物理引擎”更像几何计算器，感知仍是短板

亮点

感知 / 推理解耦可诊断：同一 GT 地图 71.81 vs 98.25，直接定位“想象变换”的缺陷

语言约束进入状态：题目陈述的相机运动作为硬约束，去掉后 Rotation 81.5 → 48.0

免训练、模型无关：7 个开源 / 闭源 VLM 均有效；温度 0、3 次运行方差、提示词全部公开

反馈消融扎实：自我审查仅 +6 pp，排除“多轮”混淆

局限与疑问

引擎只做几何：静态场景、圆柱代理体，无动力学，换任意 3D 渲染器大概率等效

感知瓶颈：端到端与 GT 差 27 pp，实体覆盖约 72%

贴合 MindCube：10×10 网格、四向朝向、大量手设权重；MMSI 上 72B 无增益

增益来源：SpatialRGPT 的提升主要来自 MoGe-2 度量深度

未报告推理成本 / 延迟与路由回退比例

Takeaways

让 VLM 负责理解与编排，让引擎负责计算

01

显式 + 可执行

世界状态 s=(L,Ω,C) 让感知结果可检查、空间变换可计算

02

推理瓶颈被量化

相同 GT 地图：执行 98.25% vs 想象 71.81%

03

端到端全面领先

MindCube 4 个 VLM 均第一； Qwen3.5-27B 52.70 → 71.14

04

下一步

提升感知覆盖与相机位姿；加入时间维度以支持视频 / 运动问题

arXiv 2611.11344 · 代码： github.com/tmlr-group/Spatial-Harness