LO-World

Unified BEV Latent Modeling for Joint 4D Occupancy and LiDAR Forecasting

在统一 BEV 隐空间中，联合预测 4D 语义占据与 LiDAR 点云

Zhimin Liao, Ping Wei, Kai Mao, Shuaijia Chen

西安交通大学 人机混合增强智能全国重点实验室 / 人工智能与机器人研究所

arXiv 2611.11912 · 首次提交 2026-11-09 · 论文解读

一句话：一个共享隐变量，同时预测占据与点云，且两者互相增益

LO-World 用 “range 图像 → 体素 → BEV” 的混合编码，把语义占据与 LiDAR 点云融合进**同一个 BEV 隐变量**，再用“上下文只算一次 + 4 层浅流网络”的 flow matching 生成器，**4 步采样**一次性预测未来 3 秒的两种模态。

57.46%

占据 Avg IoU

LO-World-T （占据 +LiDAR 输入）

较 GenieDrive 51.80% 相对 +10.9%

0.58 m^2

LiDAR Avg Chamfer Distance

LO-World-TBM （+ 框 & 地图）

较 LaGen 0.83 m^2 相对 − 30.1%

25.31

FPS-E2E （单卡 RTX 4090 ）

含 6 帧未来占据 + LiDAR 解码

OpenDWM-DiT 仅 0.10

注：相同输入（仅占据）时， LO-World-T* 的 IoU 为 53.47% vs GenieDrive 51.80% （约 +3.2% ）；两种模态联合后再升至 57.46% 。

现有范式各自为战：占据与 LiDAR 之间没有相互约束

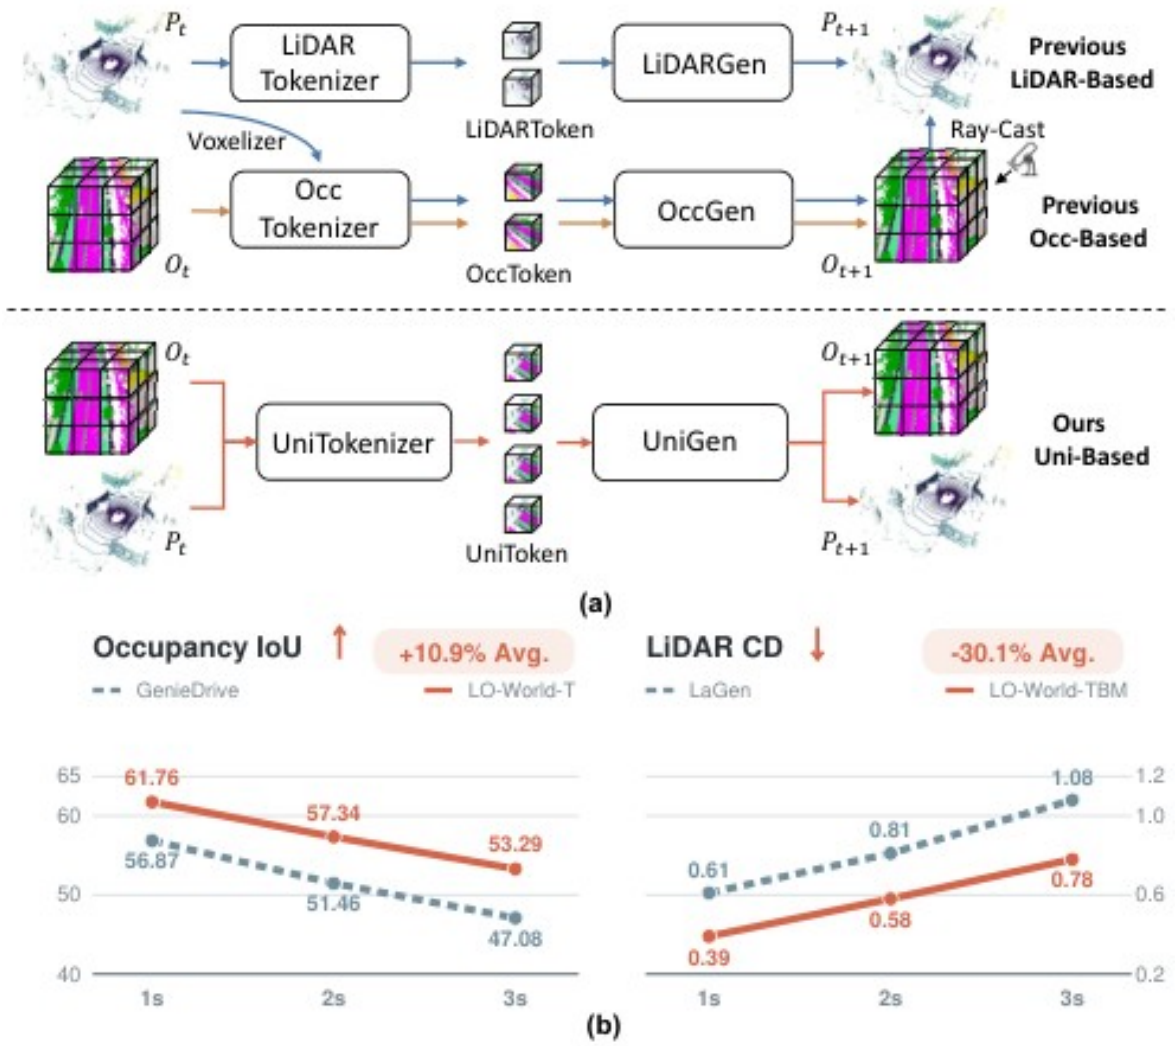

语义占据：稠密有语义，但边界模糊

0.4 m 体素离散化，细结构被“糊”掉

LiDAR 点云：几何精确，但稀疏

米制精度，没有语义，远处稀疏

旧范式的不足

独立管线：两次生成推理，没有跨模态约束

级联（UniScene）： LiDAR 监督传不回占据

核心问题：能否用一个生成过程，让稠密语义与精细几何互相正则？

来源：图 1（论文 Fig. 1）

两阶段框架： LO-VAE 统一分词， LO-Former 在隐空间生成未来

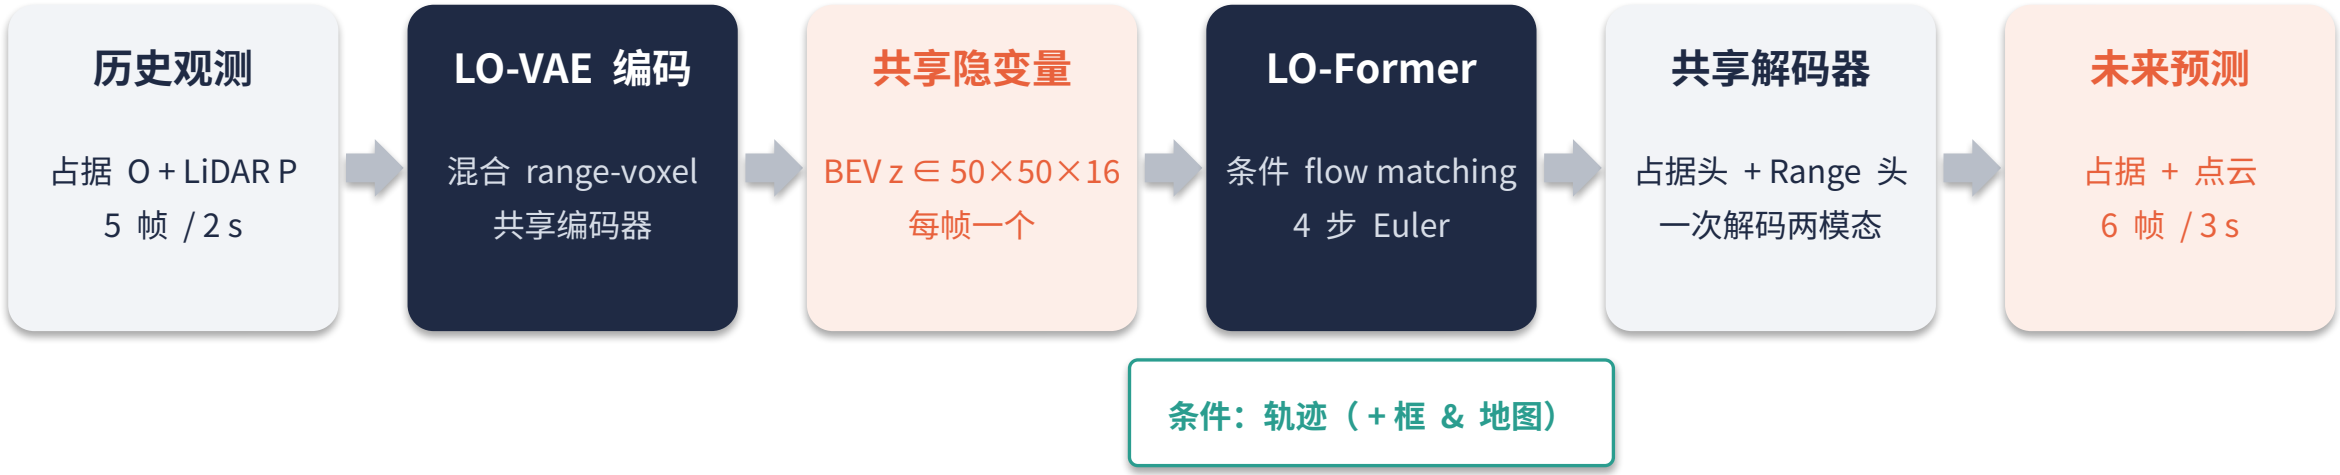

建模目标： $p(P_{\tau'}, O_{\tau'} \mid P_{\tau}, O_{\tau}, C_{\tau'})$ 一个联合条件分布同时刻画未来点云 P 与占据 O； C 为未来轨迹 / 框 / 地图

阶段 1： 训练 LO-VAE （40 epoch）

重建成对的占据与 LiDAR；损失 = 占据损失 + range 损失 + KL（10^{-6}）

阶段 2： 冻结 VAE，训练 LO-Former

先 2 帧，再 6 帧； 6 s 预测再微调 12 帧，分两个 chunk 自回归

LO-VAE： 混合 range-voxel 编码，低成本对齐两种模态

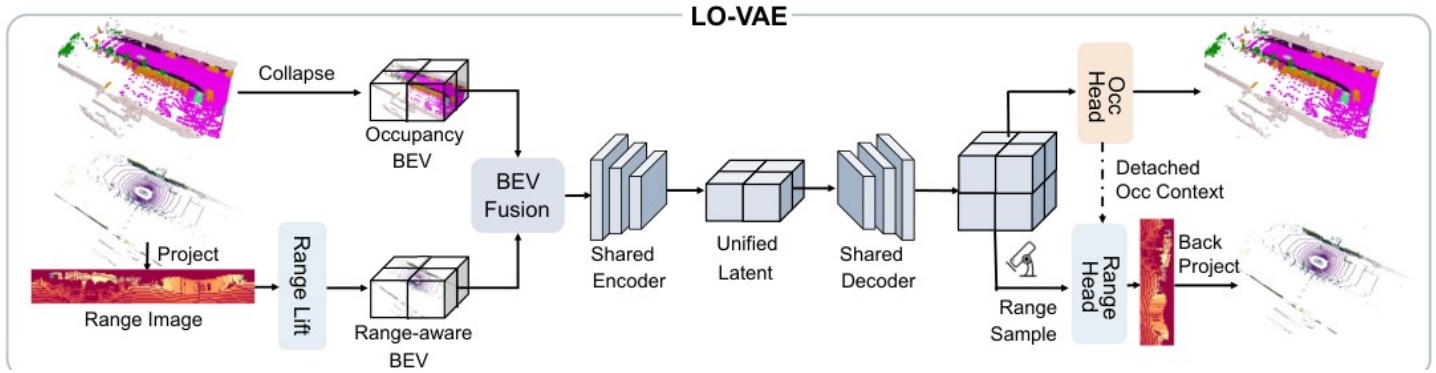

LO-VAE 结构（论文图 2 上半部分）

消融（表 6）： 换成普通体素化， CD 0.70 → 0.92 、 FPD 5.16 → 75.23 ； 换成高分辨率体素， CD 0.75 ，但速度 26.3 → 6.7 FPS 。

① 投影成 range 图像

32×1024 ； 每像素 [log 深度 , 有效位] ，保留原生扫描线

② 体素聚合 → BEV

反投影到 0.4 m 体素做平均池化，折叠 Z ； 只有 2×16 通道

③ 共享编码器

两模态各一 stem → 拼接 → ResNet → VAE 隐变量 50×50×16

④ 双头解码

占据头： Focal + Lovasz

Range 头：每条射线 192 个深度 bin + 空射线类

占据概率以 stop-gradient 作为先验

LO-Former： 历史只编码一次，每步只跑 4 层浅网络

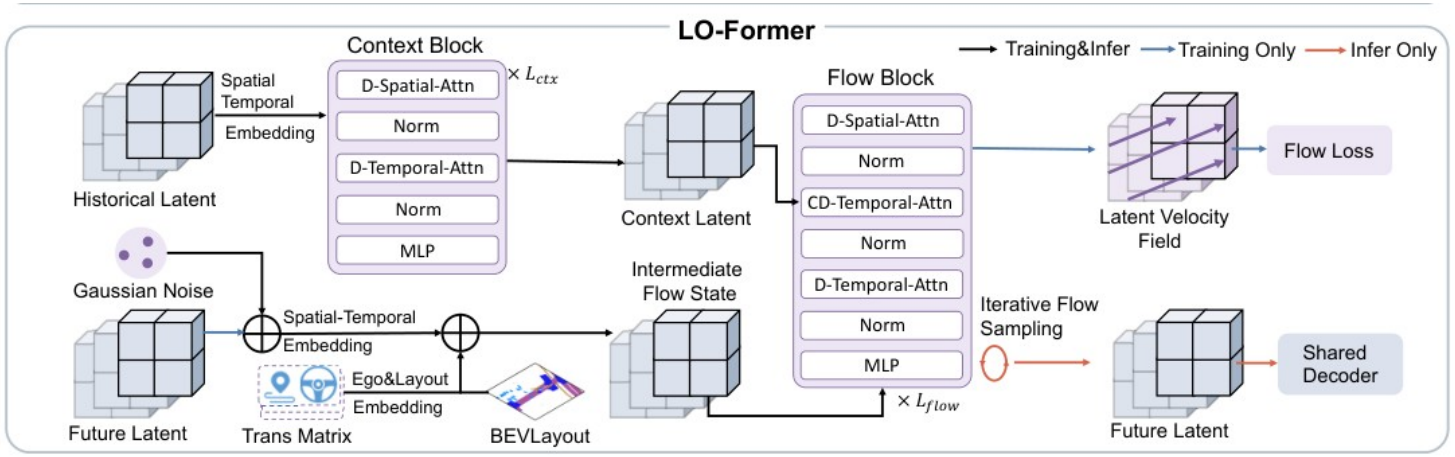

LO-Former 结构（论文图 2 下半部分；蓝色箭头只在训练时走，橙色只在推理时走）

训练： $x_\sigma = (1-\sigma)x_0 + \sigma\varepsilon$，回归速度 $v = \varepsilon - x_0$

推理： 高斯噪声 → 4 步 Euler → 6 帧未来隐变量 → 共享解码器

8 层

上下文块 · 只算一次

DSA + DTA 聚合时空历史，结果 H 缓存

4 层

流网络 · 每步执行

DSA + CDTA + DTA； CDTA 从 H 中稀疏采样

4 步

Euler 采样

隐藏维度 512， 8 头； 43.2M 参数

来源：图 2 下半部分（LO-Former）、论文 3.2 节、表 A2

占据预测：加入 LiDAR 后 IoU 达 57.46%，全面领先基线

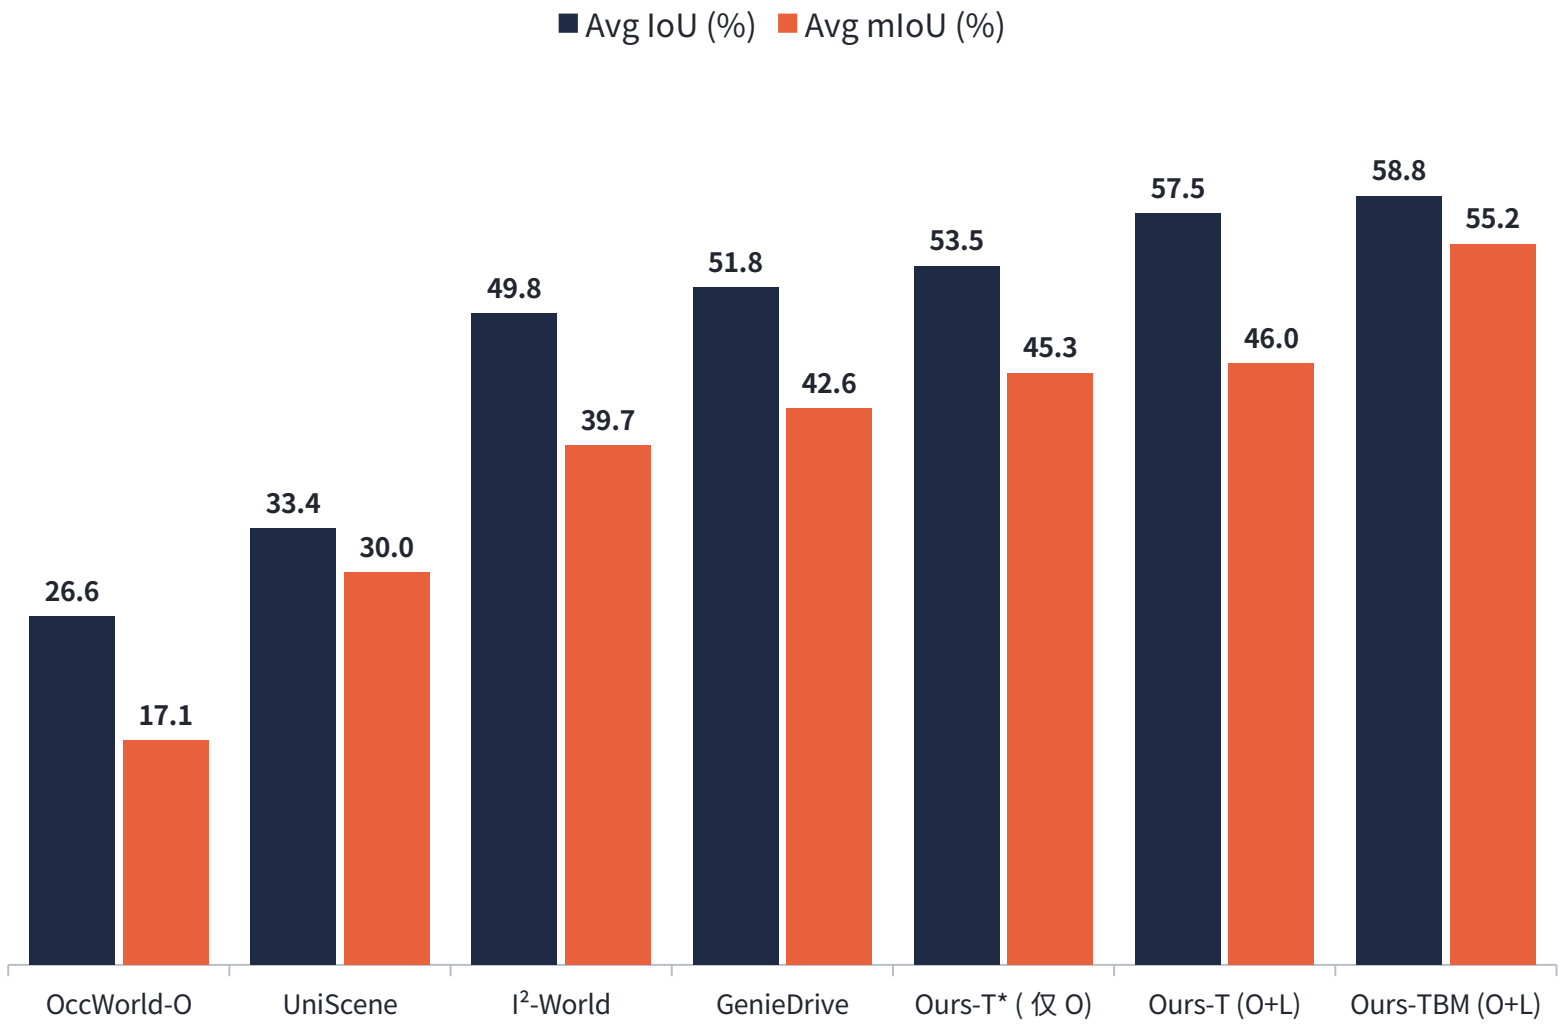

T* 单模态已领先

IoU 53.47 vs GenieDrive 51.80

mIoU 45.28 vs 42.59

+LiDAR 输入

IoU 53.47 → 57.46

模型 FPS 仍有 45.2

+ 框 & 地图（TBM）

mIoU 46.01 → 55.15 （相对 +19.9%）

相机占据输入（STC）

IoU 31.69 vs I²-World-STC 28.77

绝对值明显下降

来源：表 1 （Occ3D-nuScenes 验证集，1/2/3 s 平均）

LiDAR 预测： CD 降至 0.58 m^2 ，速度快两个数量级

Avg Chamfer Distance （ m^2 ，越低越好）

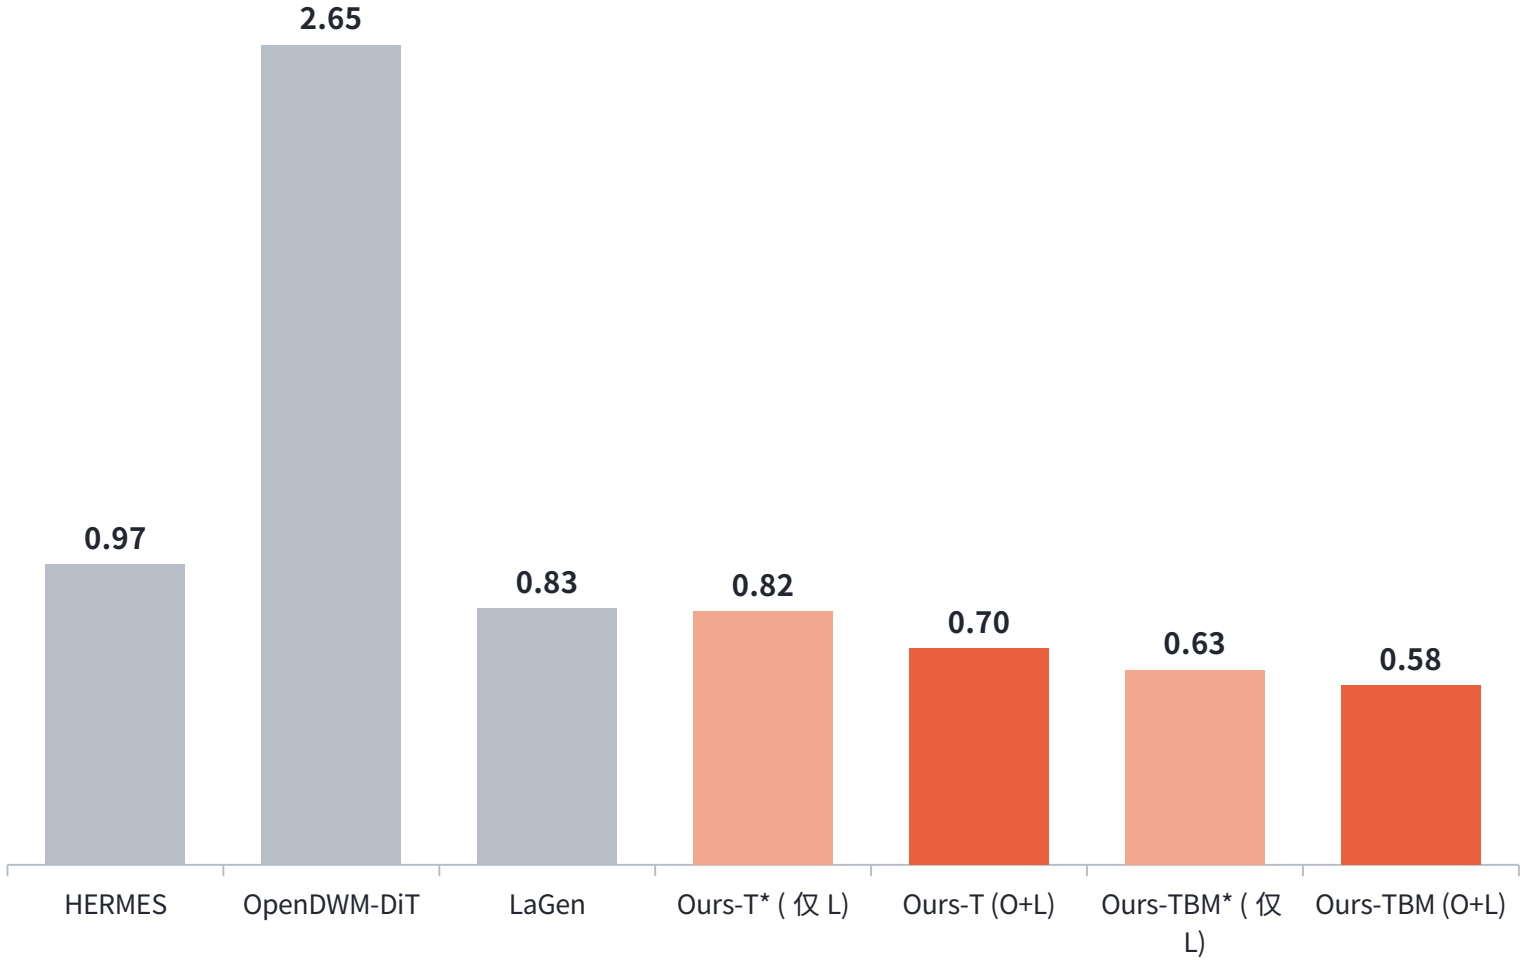

端到端速度 FPS-E2E

OpenDWM-DiT	0.10
UniScene	0.19
HERMES	0.51
LO-World-T	26.26
LO-World-TBM	25.31

分布保真度（ FPD↓ ）

Ours-TBM 4.68

Ours-T 5.16 vs 仅 LiDAR 8.84

OpenDWM-DiT 381.91

来源：表 2 （nuScenes 验证集， 1/2/3 s 平均 CD ）

核心证据：联合建模让两种模态同时变好

占据 Avg IoU (%) ↑

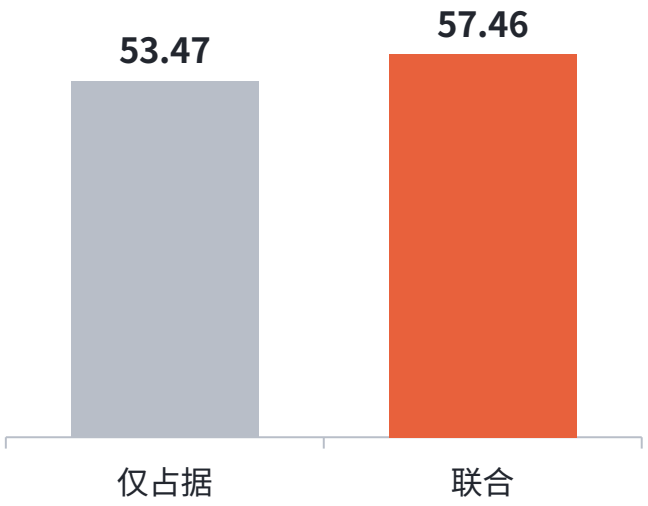

+3.99 个百分点

LiDAR Avg CD (m^2) ↓

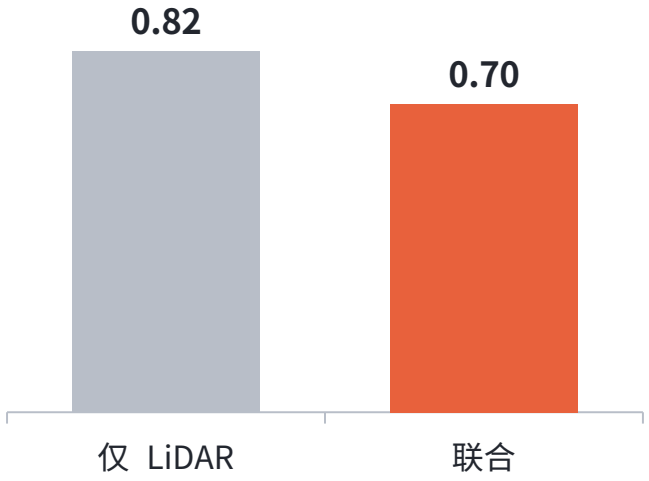

−14.6%

B-JSD (×10^2) ↓

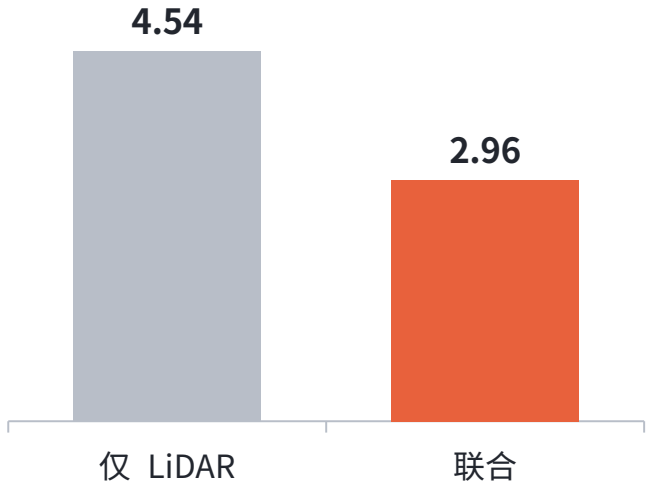

−34.8%

对采样步数稳健（表 A5）

1 / 2 / 3 / 4 / 8 步下，联合模型的 mIoU、IoU、CD 均优于对应的单模态模型

语义帮助几何（表 6）

去掉占据语义标签：CD 0.70 → 0.97，FPD 5.16 → 56.12

来源：表 1、表 2、表 6、表 A5（均为 LO-World-T）

共享隐空间优于“拼接”和“跨模态注意力”，而且更快

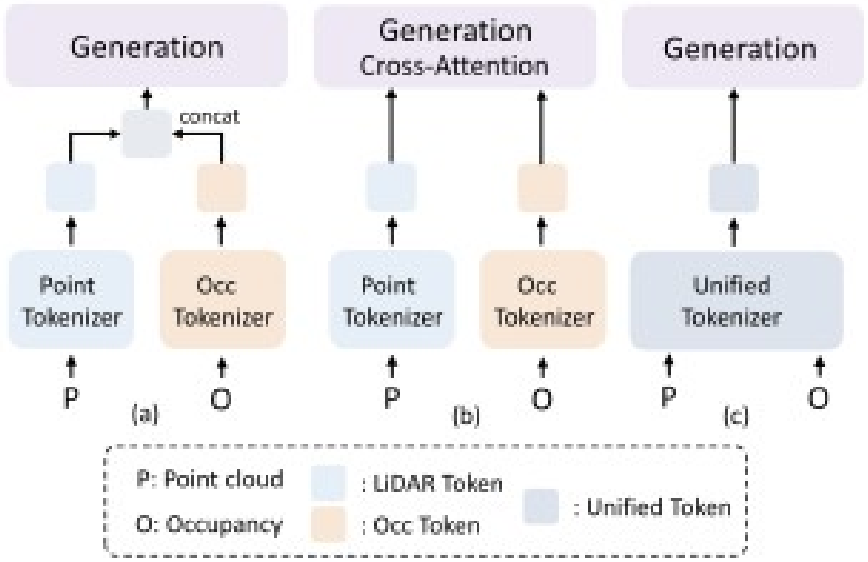

(a) token 拼接 (b) 跨模态注意力 (c) 统一分词器（本文）

设置	Avg IoU ↑	Avg CD ↓	FPD ↓	JC ↑	FPS-E2E ↑
(a) 分离隐变量 + 拼接	54.08	0.84	9.01	0.52	17.76
(b) 分离隐变量 + 跨模态注意力	54.71	0.80	8.94	0.55	10.24
(c) 共享 BEV 隐变量（本文）	**57.46**	**0.70**	**5.16**	**0.77**	**26.26**
w/o 混合表示（普通体素）	50.01	0.92	75.23	0.65	26.30
w/o 混合表示（高分辨率体素）	55.87	0.75	32.59	0.67	6.72
w/o 占据语义标签	–	0.97	56.12	0.60	26.27

JC（联合一致性）：联合表面召回率与占据精度的调和平均，衡量两种模态是否支撑同一几何

结论：把“融合”前移到分词阶段，比在生成器里做后期融合更准、更省；混合 range-voxel 表示在精度与速度之间取得了最好的平衡。

上下文缓存是关键； 4 步采样是精度与速度的折中

配置（上下文，流）	mIoU ↑	CD ↓	FPS-E2E ↑
完整模型（8, 4）	**46.01**	**0.70**	**26.26**
w/o 上下文块	37.19	1.58	34.34
w/o 上下文块， 12 层流网络 ‡	43.60	0.74	18.43
(4, 4)	42.81	0.90	31.71
(6, 4)	44.52	0.78	30.44
(8, 6)	46.36	0.68	24.12
(8, 2)	40.85	0.83	35.53

‡ 等深度对照： 12 层流网络，没有上下文块。上下文与流网络解耦，在精度和速度上都更优。

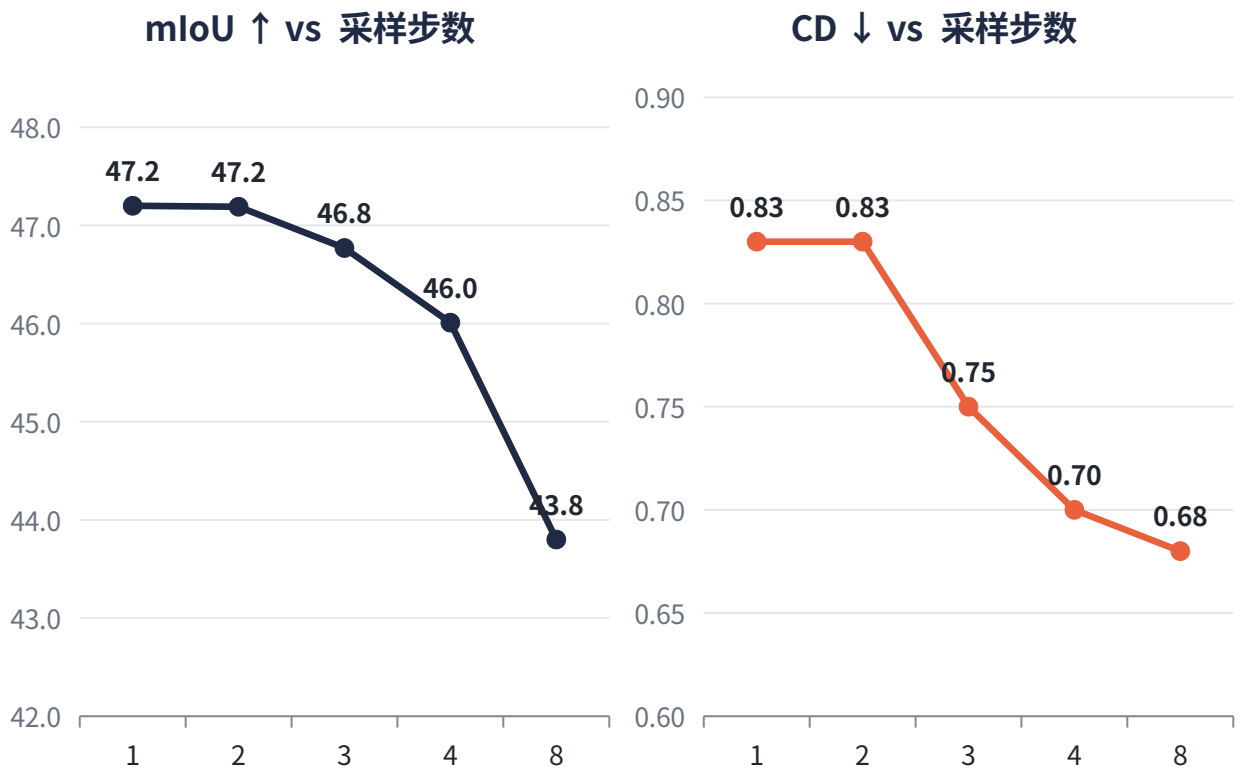

权衡：步数越多，几何（CD）越好，但语义（mIoU）越差，速度越慢（1 步 40.06 → 8 步 21.54 FPS-E2E），所以默认取 4 步。

来源：表 7、表 A5 （LO-World-T 联合模型）

长时、跨数据集、下游视频：优势基本延续

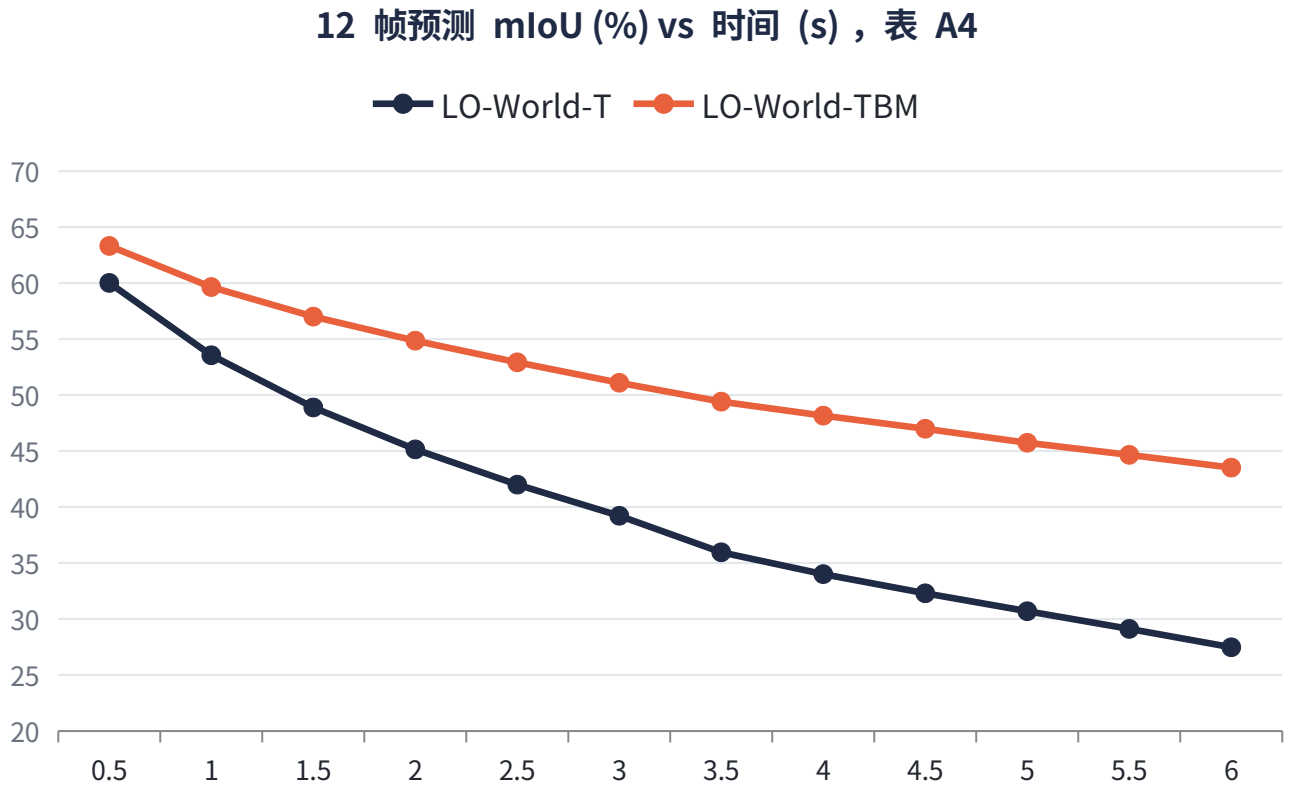

6 s mIoU： TBM 43.52 / T 27.48 / GenieDrive 23.66 / I^2-World 22.55

注意： T 版本的长时 LiDAR CD （4.0 s 1.49）不如 LaGen （1.32）

Waymo 跨传感器（32 线 → 64 线）

零样本： mIoU 41.31 vs I^2-World 36.38

零样本 CD@1s 0.91，低于微调过的 OpenDWM＋ 2.27

50 个序列（<7%）微调： mIoU 46.00， CD@1s 0.51

下游视频生成（接入 GenieDrive）

FVD↓： 本文 60.41 vs GenieDrive 92.78

mIoU 34.83 / mAP 27.15 （均优于基线）

Oracle （12 Hz GT 占据） FVD 40.78，仍有差距

来源：表 3、表 4、表 5、表 A4

定性结果：轮廓更完整，并且能被轨迹控制

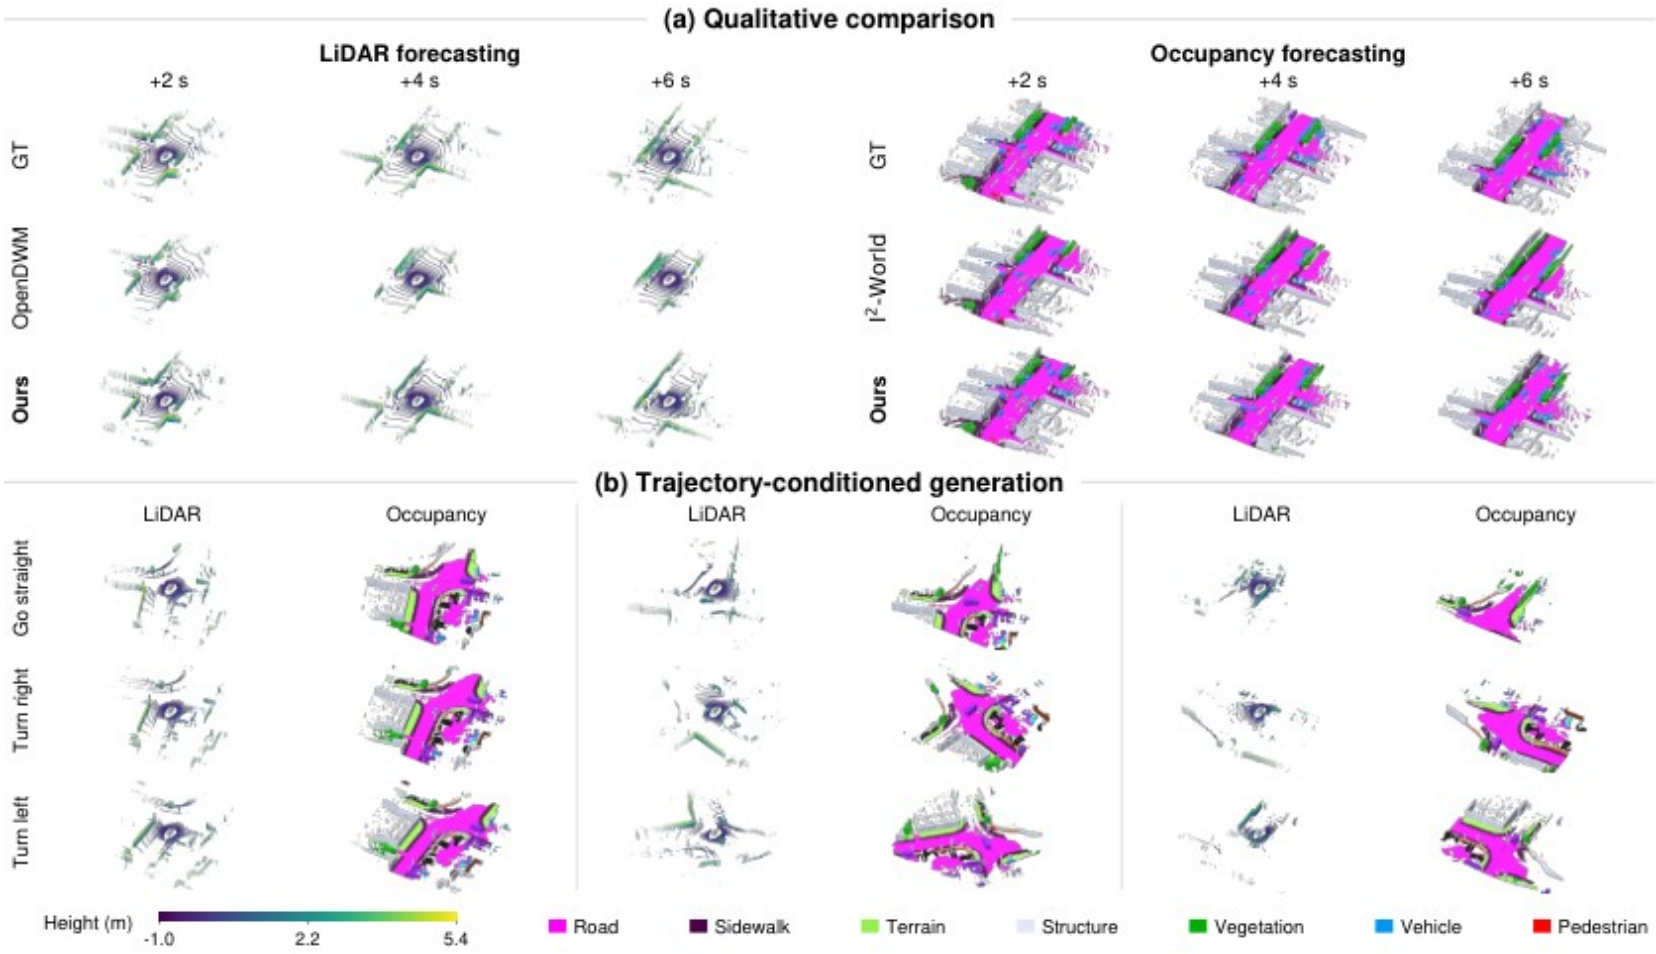

(a) 2 / 4 / 6 s 对比

LiDAR：对比 OpenDWM，后者 4 s 后点云稀疏、缺失

占据：对比 I^2-World，本文道路布局更贴近 GT

(b) 轨迹控制

同一段历史，分别给直行 / 右转 / 左转轨迹

占据和点云的未来预测同步变化，两种模态保持一致

冷静看数字：六点需要注意

① 比较口径不对等

+10.9% IoU 是 O+L 输入对比只输入 O 的 GenieDrive；同输入下为 53.47 vs 51.80 （约 +3.2% ）

② 依赖 GT 输入

T/TBM 输入 GT 历史占据，框和地图也来自外部；相机占据输入（ STC ） IoU 仅 31.69

③ FPS 的含义

FPS-E2E 按“每秒生成多少个未来帧”计；一次 6 帧 rollout 约 228.5 ms （表 A6 ）

④ 多样性未评估

1 步采样 mIoU 最高（ 47.20 ），更像确定性预测；没有多次采样的多样性指标

⑤ 评测口径

mIoU 排除了所有 IoU=0 的类别（附录 B.2 ），与常见协议不同； JC 为作者自定义

⑥ 泛化与下游

没有倒车训练数据，倒车时占据残缺、点云稀疏（图 A3 ）；没有验证感知或规划收益

来源：论文表 1/2/7 、表 A6 、附录 B.2 、附录 D （图 A3 ）

结论：单流共享隐空间是多模态驾驶世界模型的简洁路线

融合前移	把占据与 LiDAR 在分词阶段就合成一个 BEV 隐变量，比后期拼接或交叉注意力更准、更快
相互增益	同一模型下，联合建模使 IoU 53.47 → 57.46 、 CD 0.82 → 0.70 ； 语义还能改善点云分布
足够高效	混合 range-voxel 编码 + 上下文缓存 +4 步采样，端到端约 25 FPS （ RTX 4090 ）
仍需检验	依赖 GT 历史占据，生成多样性未评估；更适合定位为强条件、高效的预测器或数据生成器

arXiv 2611.11912 · 代码： github.com/lzzzzzm/LO-World