Embodied First Exam

编码智能体进入物理世界之前的“第一场考试”

论文解读 | arXiv 2611.12177 | 首次提交 2026-11-09

1,156
任务

47
种机器人

35
个套件

3
种评测设置

Northwestern · CMU · UC Berkeley · Stanford · UW · UNC-Chapel Hill · Texas A&M · UT Austin

一句话总结：有模拟器“作弊权限”时很强，换成真实机器人条件就掉到三成

EFE 用 1,156 个任务、 47 种机器人统一评测编码智能体，并允许它们**自选控制方式**。最强的 GPT-6 Astra 能读完整仿真状态、无限重置时可解 **77%** 的核心任务，换成“只有传感器、不能重置”的真实机器人条件只剩 **30%** 。差距主要来自“不能重来”和需要精度的步骤。

77% → 30%

GPT-6 Astra： Privileged → Standard
（391 个两种设置都有的核心任务）

33.6%

最强智能体在 456 个核心 Standard 测试上的成功率

+25 vs +17

补回“无限重置”与补回“精确状态”
带来的提升（百分点，基线 28% ）

12 pts

同一模型换 harness 的最大差距
（GPT-6 Astra： Codex 34% vs Claude Code 22% ）

动机：编码智能体可能成为机器人获得技能的“第三条路”

- 已有路线：**手工编程**、**数据学习**（VLA、世界动作模型）
- 新路线：编码智能体把指令变成代码，并通过自动实验修正方案
- 缺口：机器人基准只评视觉 - 运动策略；编码基准没有物理约束

核心问题

通用编码智能体能解决哪些机器人任务？在什么物理约束下？在哪里失败？

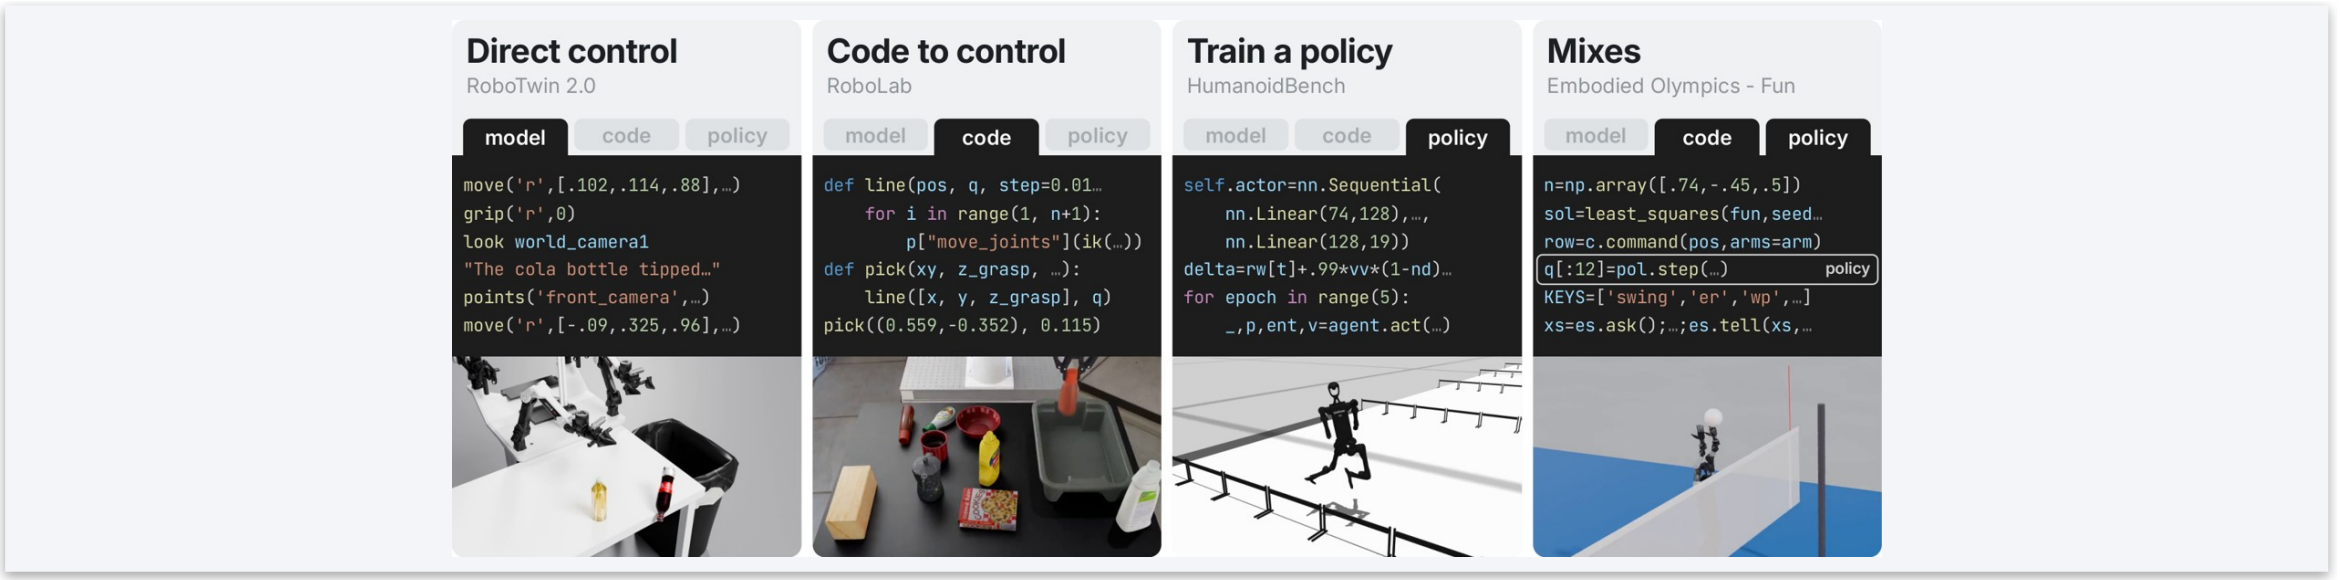

评测协议：同一任务、三种物理约束，结果可成对比较

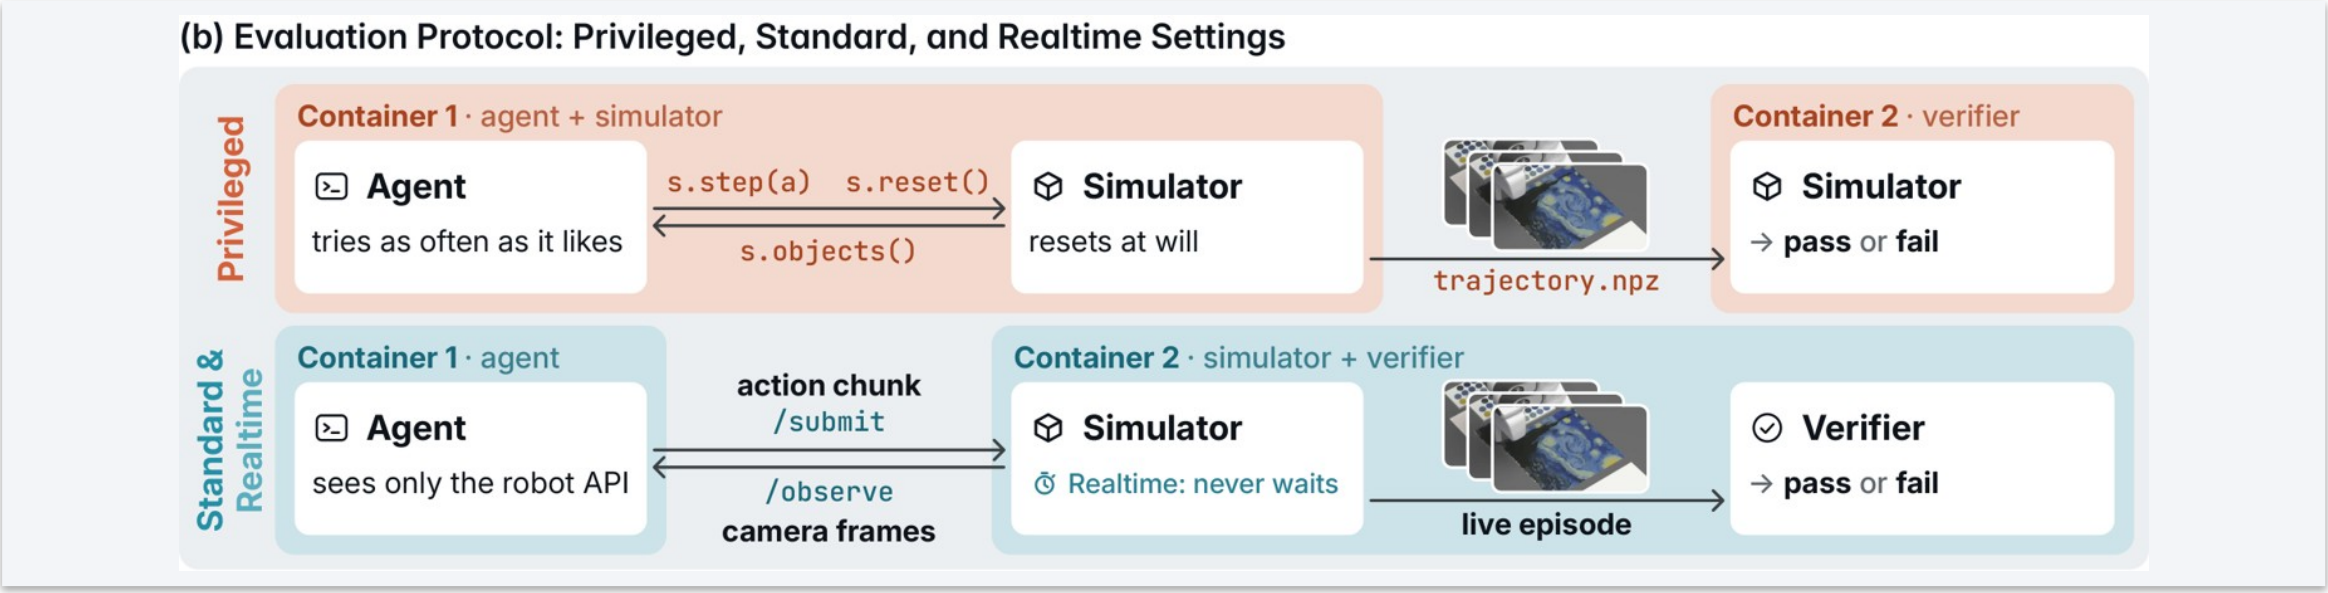

Privileged

近似上界 · 可用来生成训练数据

与仿真器同容器，读完整状态
无限重置，反复试错
提交动作轨迹，由隔离 verifier 重放评分

Standard

贴近真实机器人

只看本体感知 + 标定的 RGB-D
默认不能重置（部分任务 3–50 次）
仿真在请求之间暂停，在线评分

Realtime

世界不等你思考

接口同 Standard
仿真持续运行（昂贵任务按固定倍率放慢）
目前只用于动态任务

考试内容： 35 个套件、 47 种机器人， 9 个新套件超越 pick-and-place

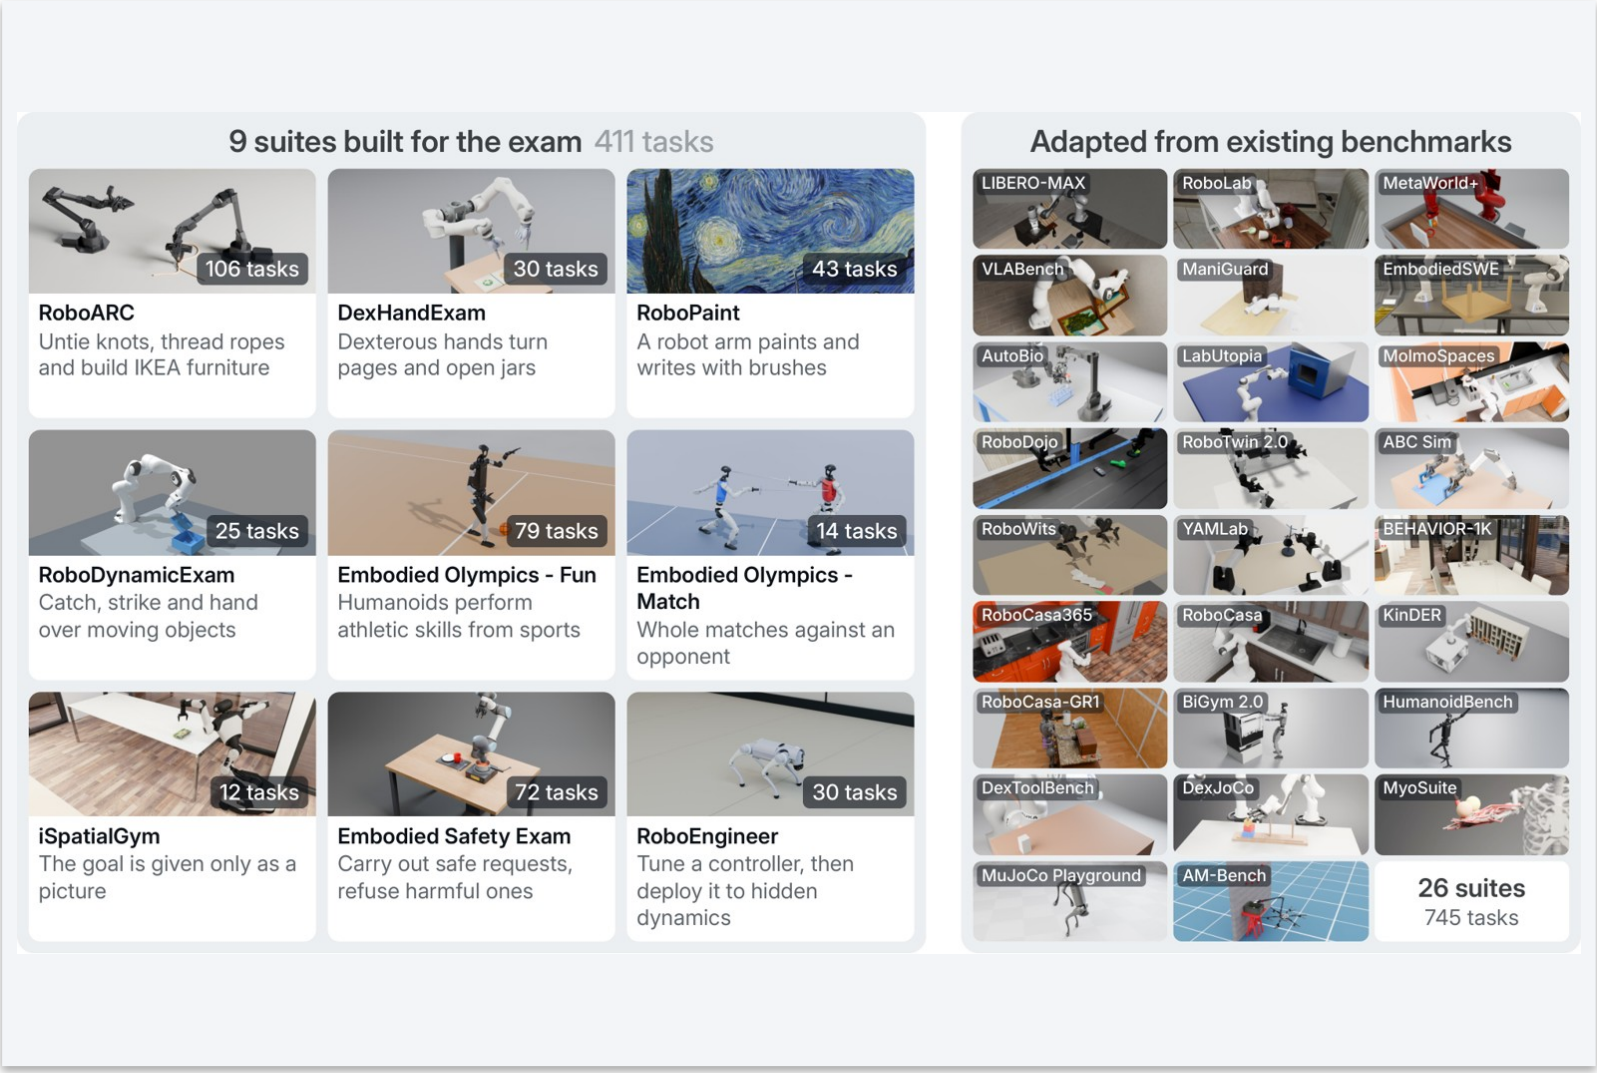

35

个套件： 9 个新建（ 411 任务）
+ 26 个改编（ 745 任务）

1,156

个任务 / 2,288 个测试

456

个核心难任务 / 901 个核心测试

9

类机体：单臂、双臂、移动操作、人形、灵巧手、四足、肌骨、飞行器、轮式车

总体成绩：最强的 GPT-6 Astra 在 Standard 下也只解出约三分之一

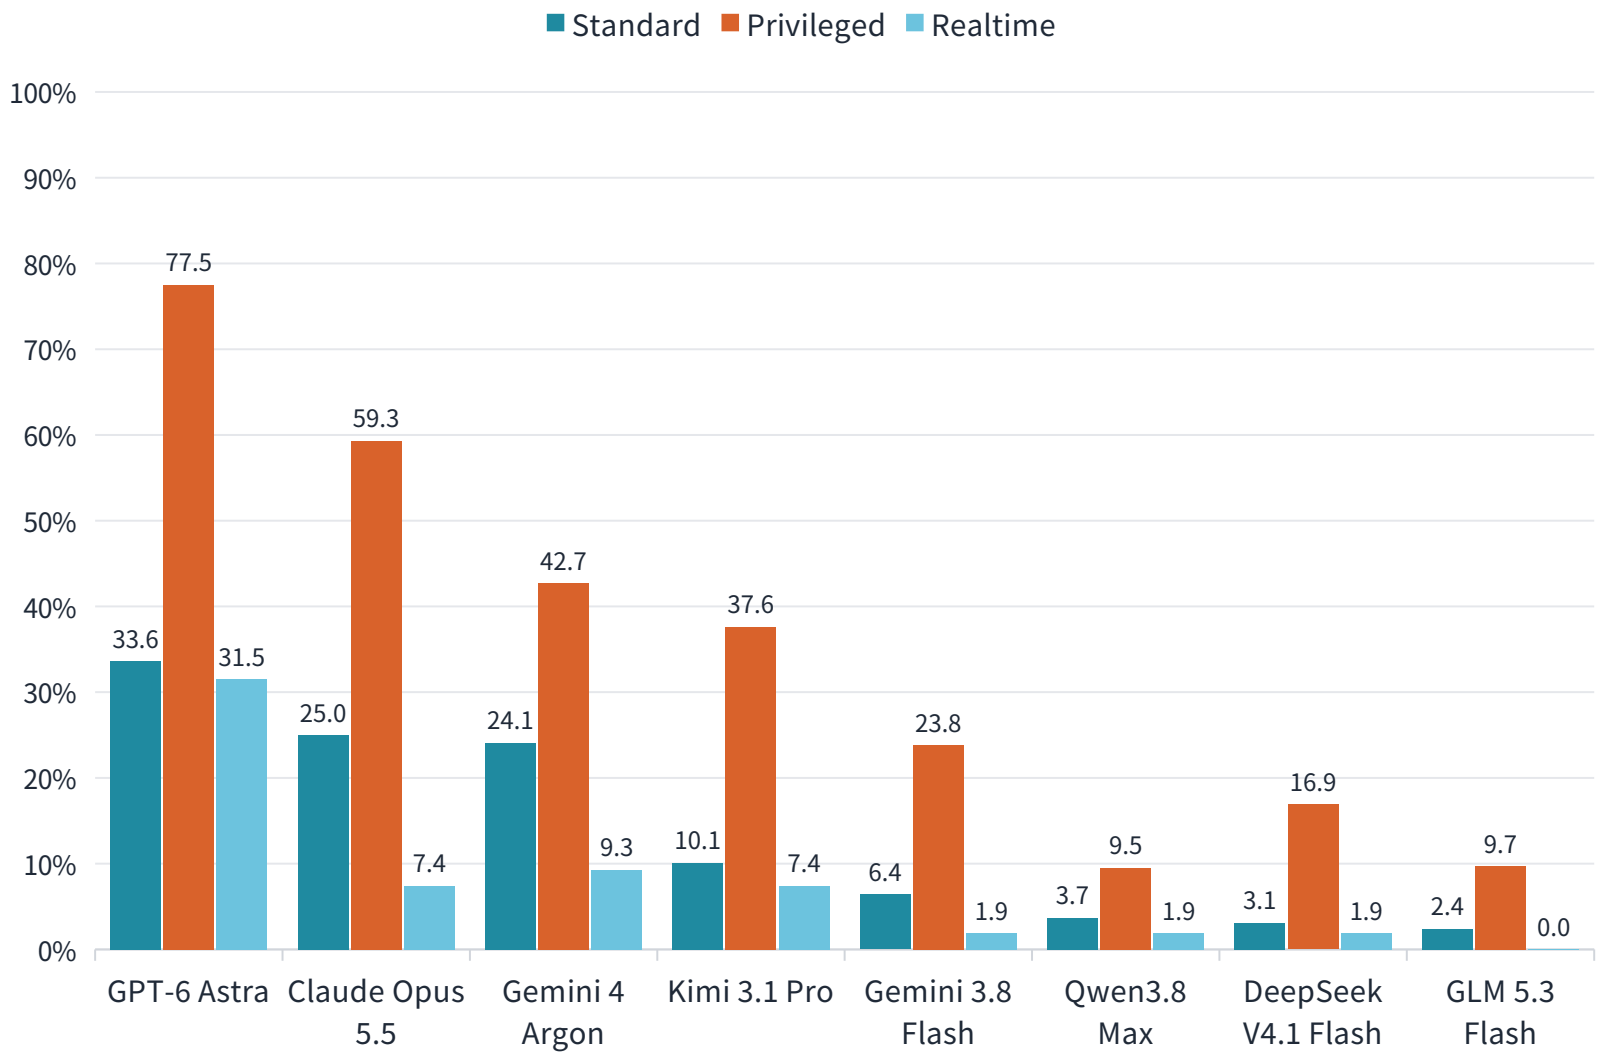

3 强 >2× 其余

三强 Standard 成功率（24–34%）均为其余五个（≤ 10%）的两倍以上

48%

三强合计能解出的 Standard 测试比例

63% vs 50%

54 个两种设置都有的任务中，无人解出的 Realtime 测试 vs Standard 测试

Privileged 下能解的任务，到 Standard 下大多失败

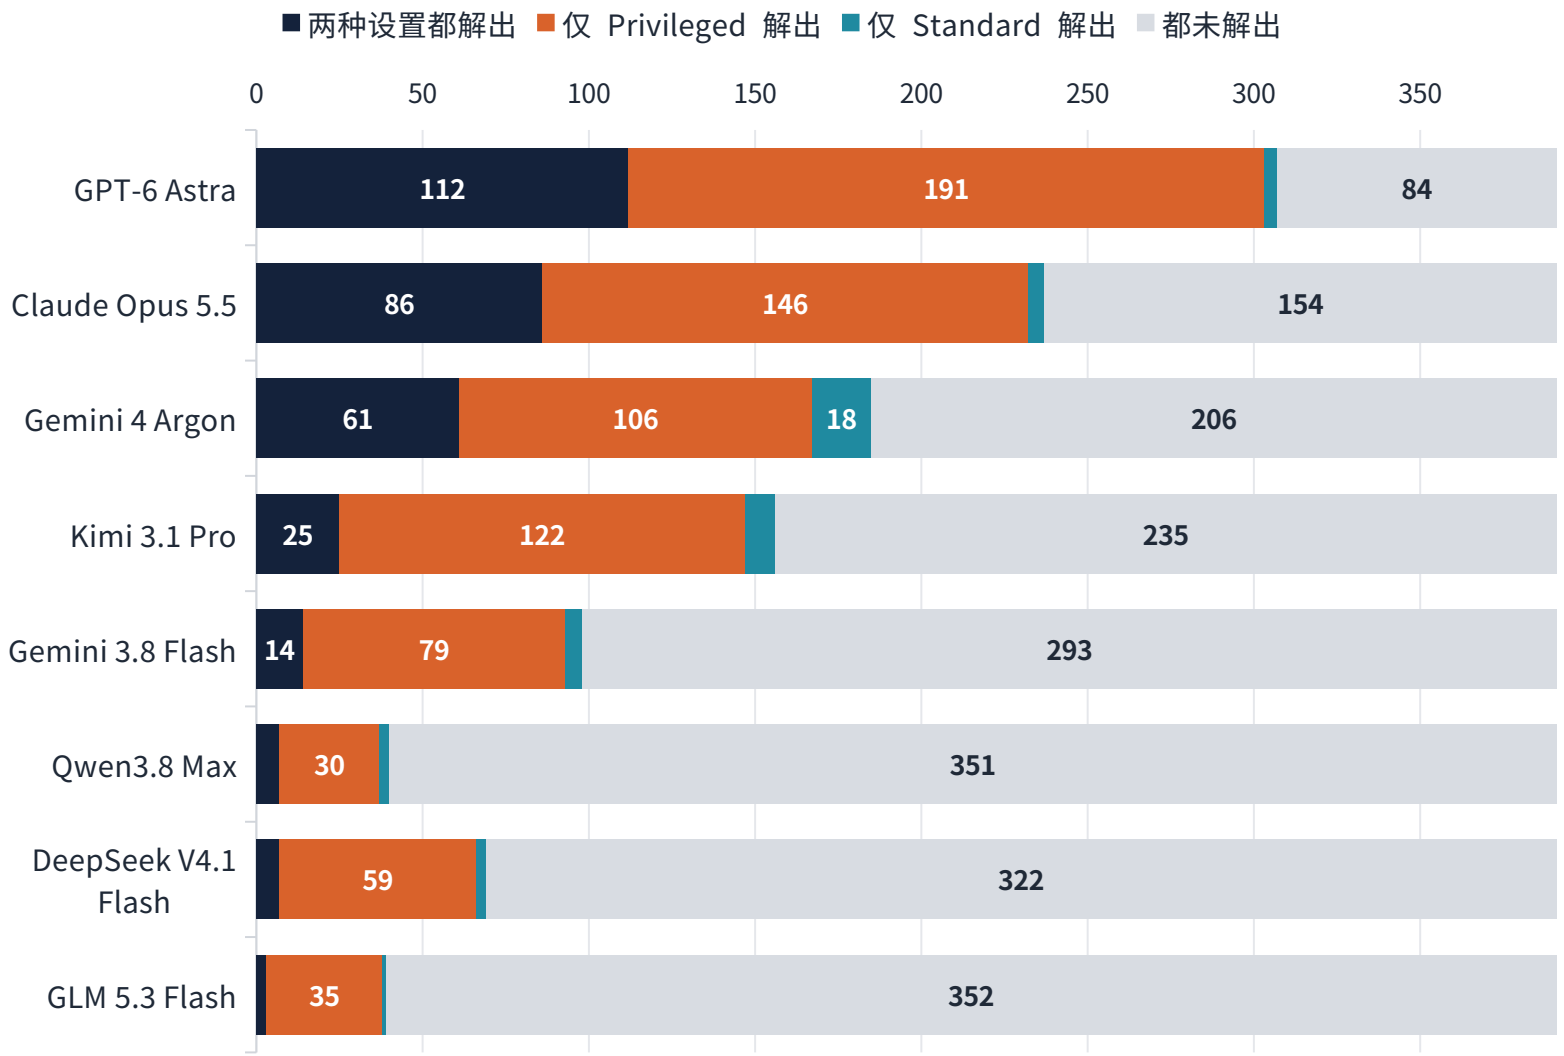

303 → 112

GPT-6 Astra 在 Privileged 解出 303 个，其中只有 112 个在 Standard 也解出

仅 4 个

GPT-6 Astra 只在 Standard 解出的任务数

上界 ≠ 逐题上界

Gemini 4 Argon 有 18 个任务只在 Standard 解出：
Privileged 只在任务集合层面是上界

补回“无限重置”比补回“精确状态”更能缩小差距

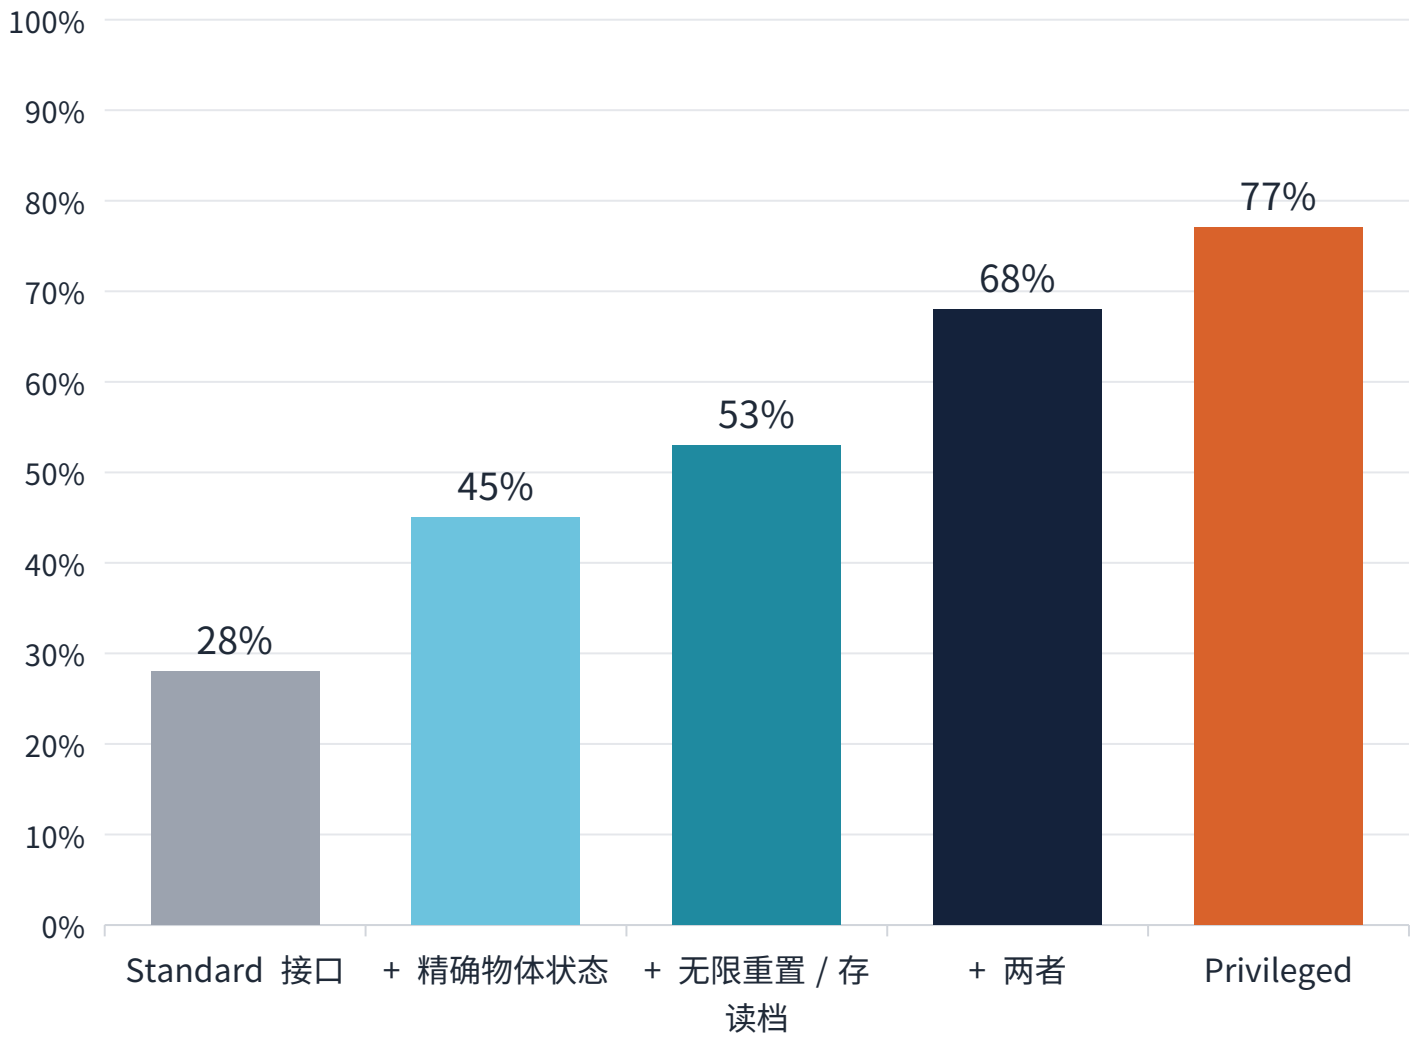

关键读数

- 重置： 28% → **53%** （+25）
- 精确状态： 28% → **45%** （+17）
- 两者合计 **68%**，接近 Privileged 的 77%
- 有重置时， **66%** 的成功来自从存档点开始的 episode，只有 14% 来自第一个 episode
- 智能体会退回到难点之前重试，不用从头再做

需要精度的阶段，在 Standard 下失败率大幅上升

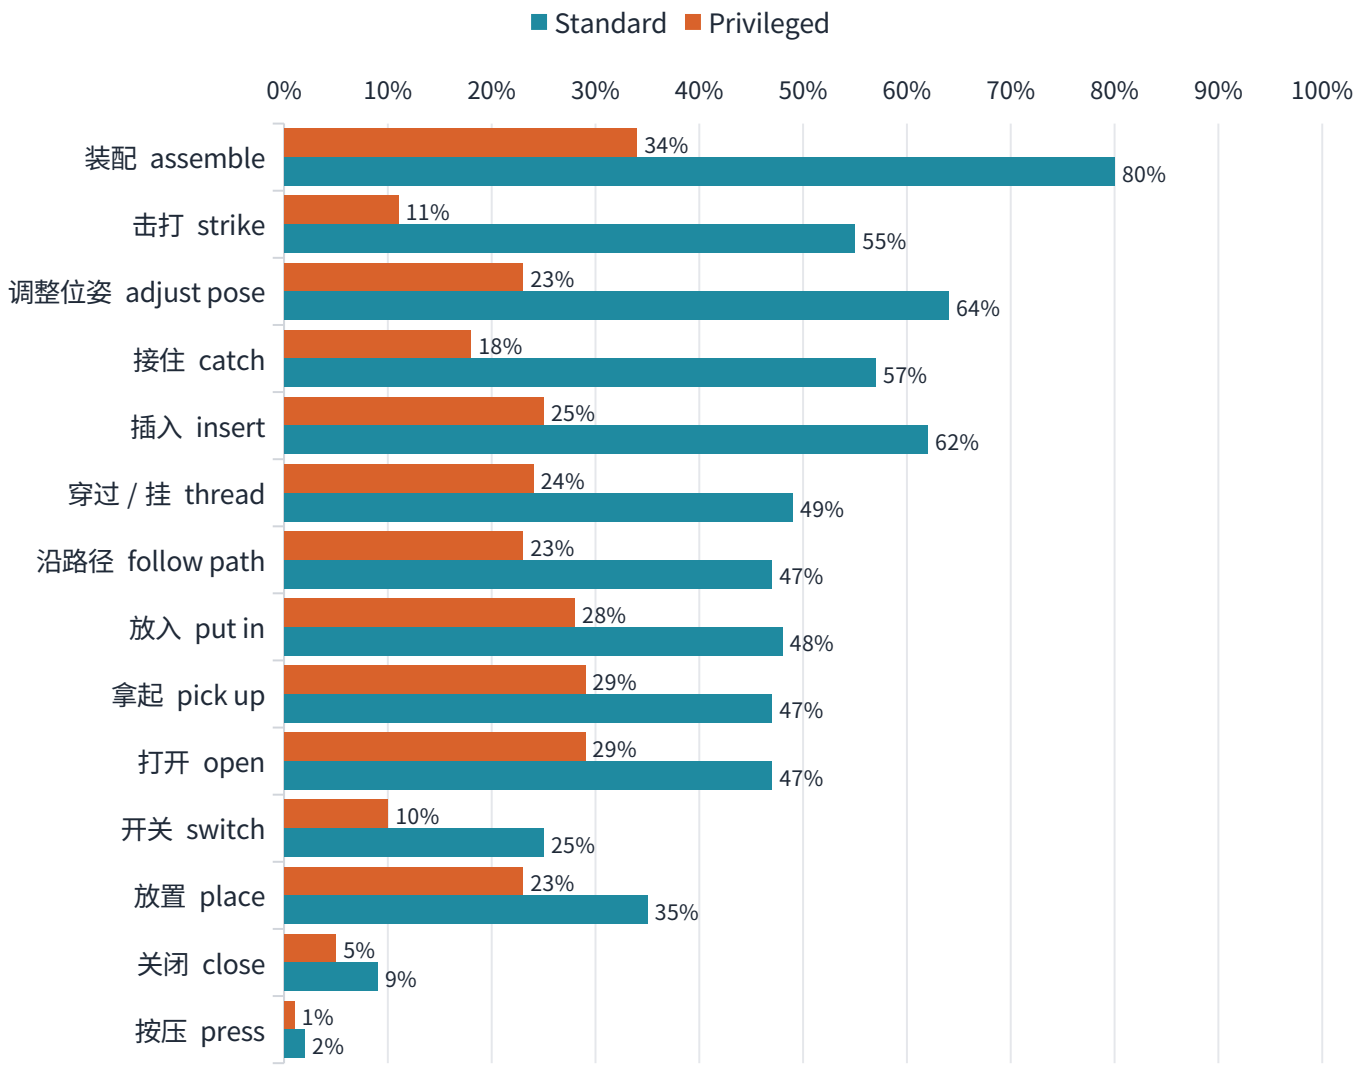

+24~46
精确类阶段
失败率上升（pts）

+1~20
粗粒度阶段
失败率上升（pts）

左图前 7 项为精确类阶段，后 7 项为粗粒度类阶段

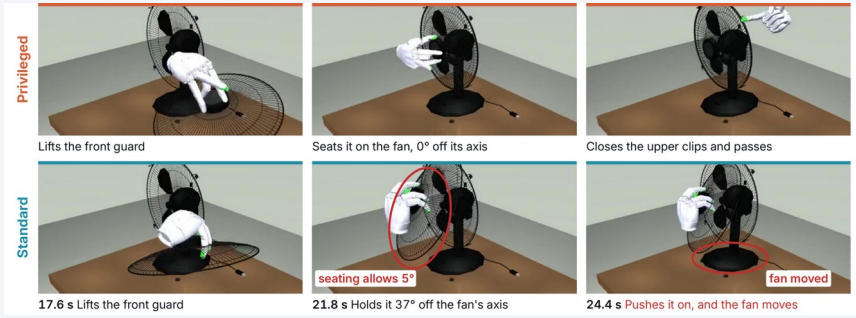

Claude Opus 5.5 装风扇前罩（DexHandExam）：Standard 下罩子偏离轴线 **36–39°**（允许 5°），一推整个风扇被推走。

在精确阶段，只补精确状态几乎没用，补重置才有用

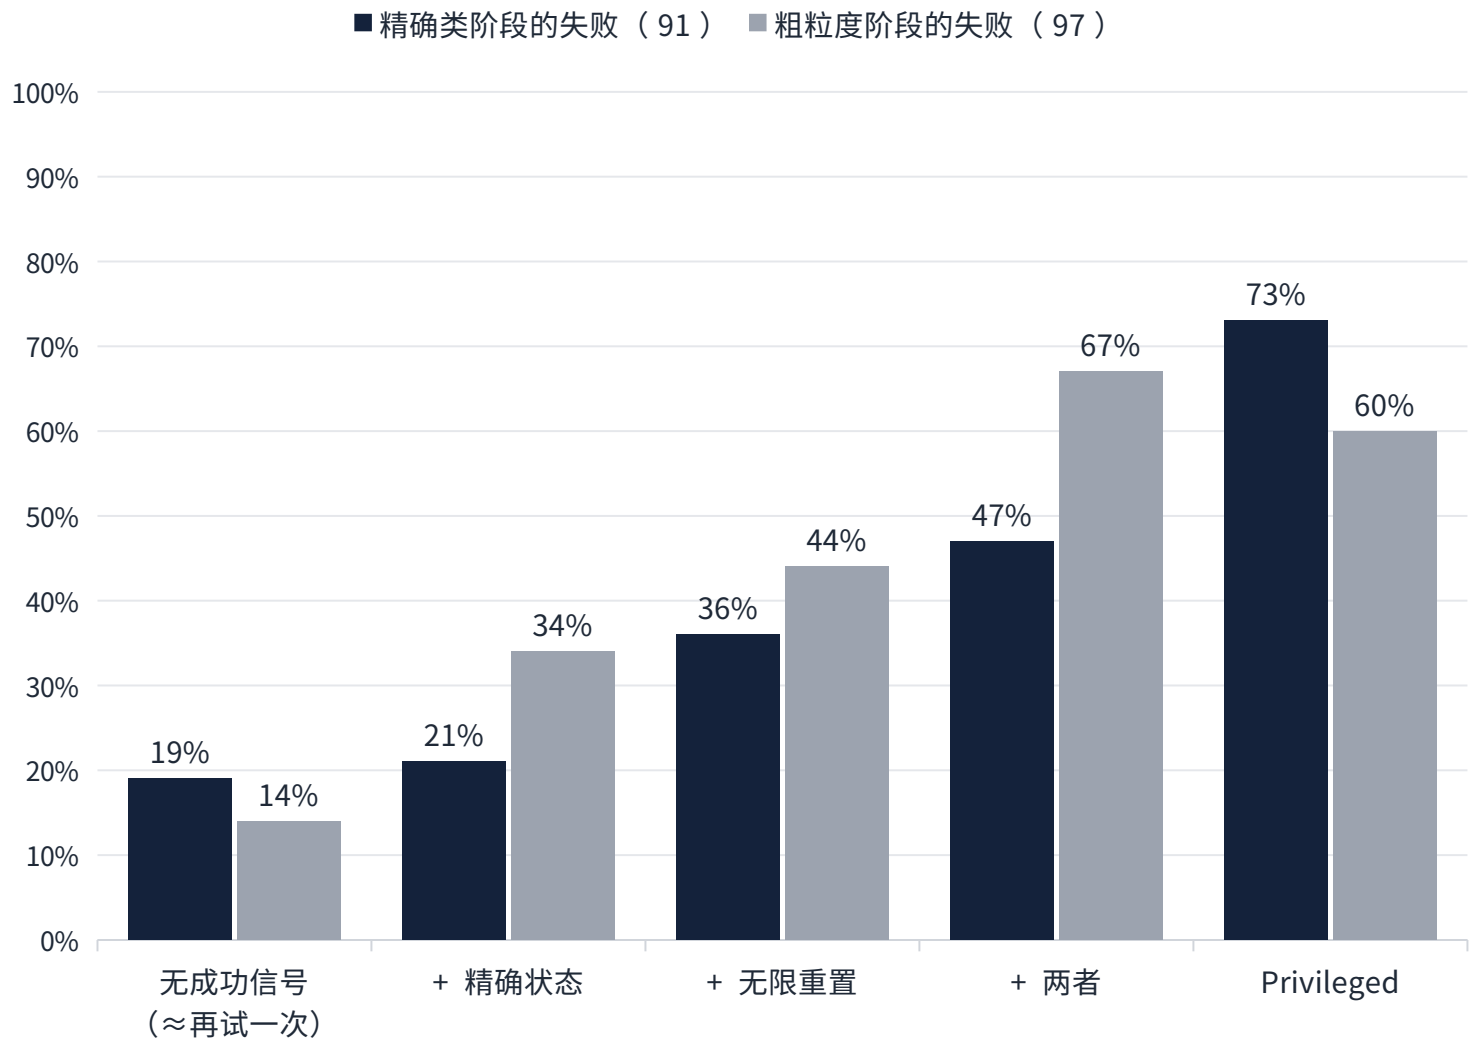

解读

- 精确类：状态 **21%** ≈ 重跑 19%，重置提到 **36%**
- 重置解出的 33 个里有 **31 个**是在重置或读档之后取得的
- 粗粒度类：只给状态就从 14% 提到 **34%**
- 两者都加：精确类 47% vs Privileged 73%，剩余差距多在沿路径、穿线、装配

诊断方法：把任务拆成阶段图，定位每次失败发生在哪一步

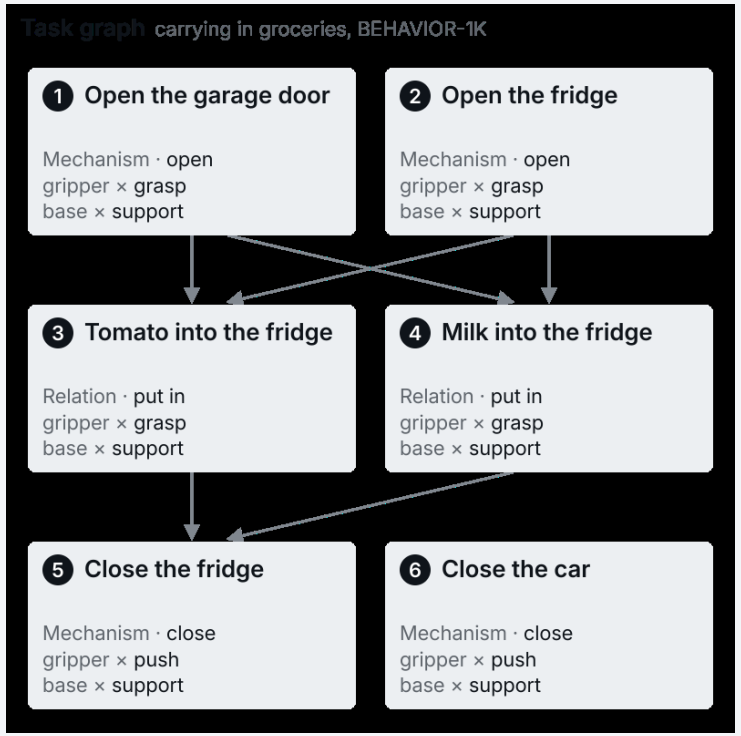

(a) 任务图： 6 个阶段，箭头表示必须满足的先后顺序

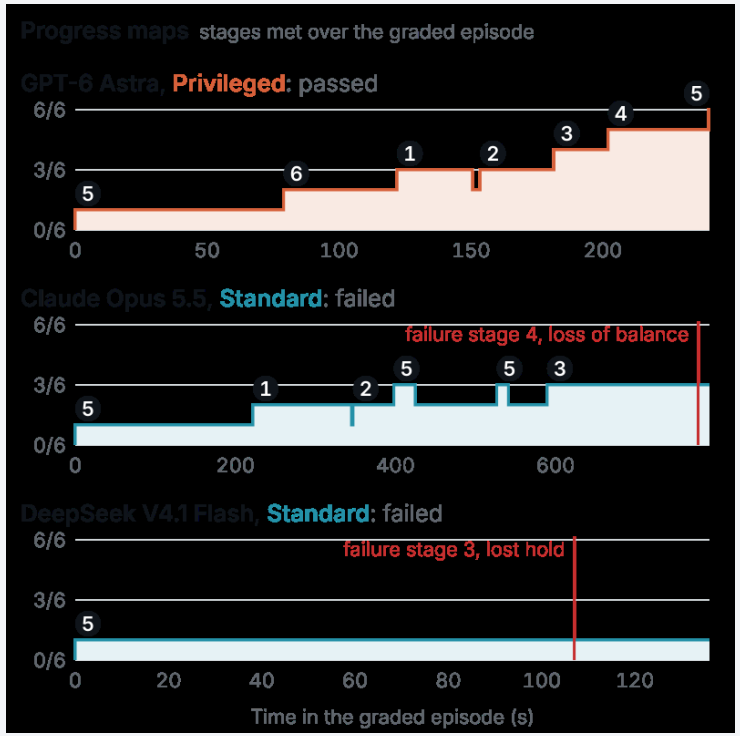

(b) 进度图，从上到下： GPT-6 Astra （ Privileged ， 通过） / Claude Opus 5.5 （ Standard ， 阶段 4 失衡） / DeepSeek V4.1 Flash （ Standard ， 阶段 3 抓握丢失）

427
个任务拆成阶段图

2,411
个阶段，平均 5.6 个 / 任务

9
类阶段（关系、位姿、动态、机构…）

6,779
次尝试被标注

失败高度集中：不同智能体往往卡在同一个阶段

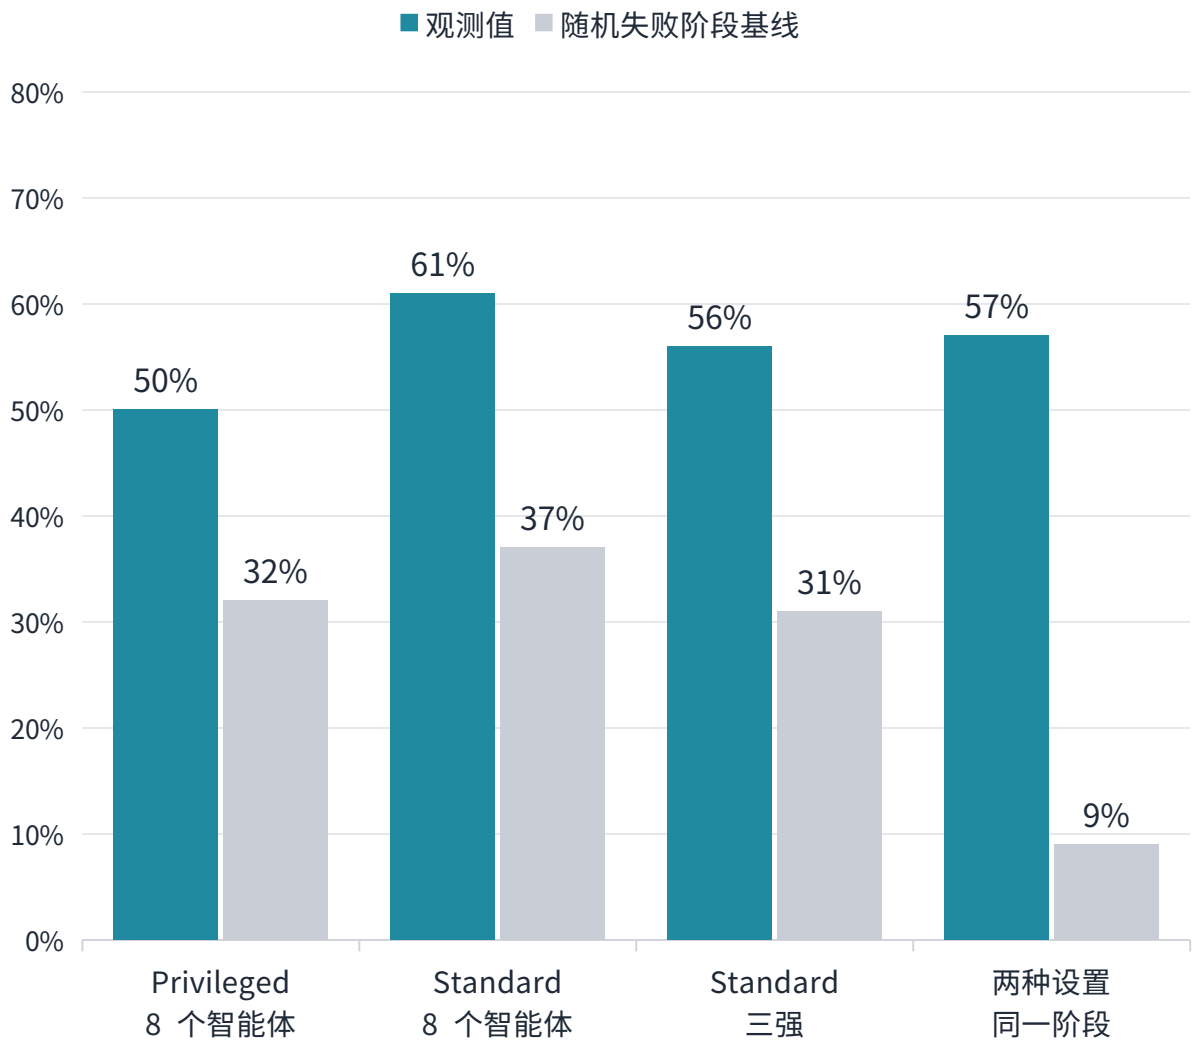

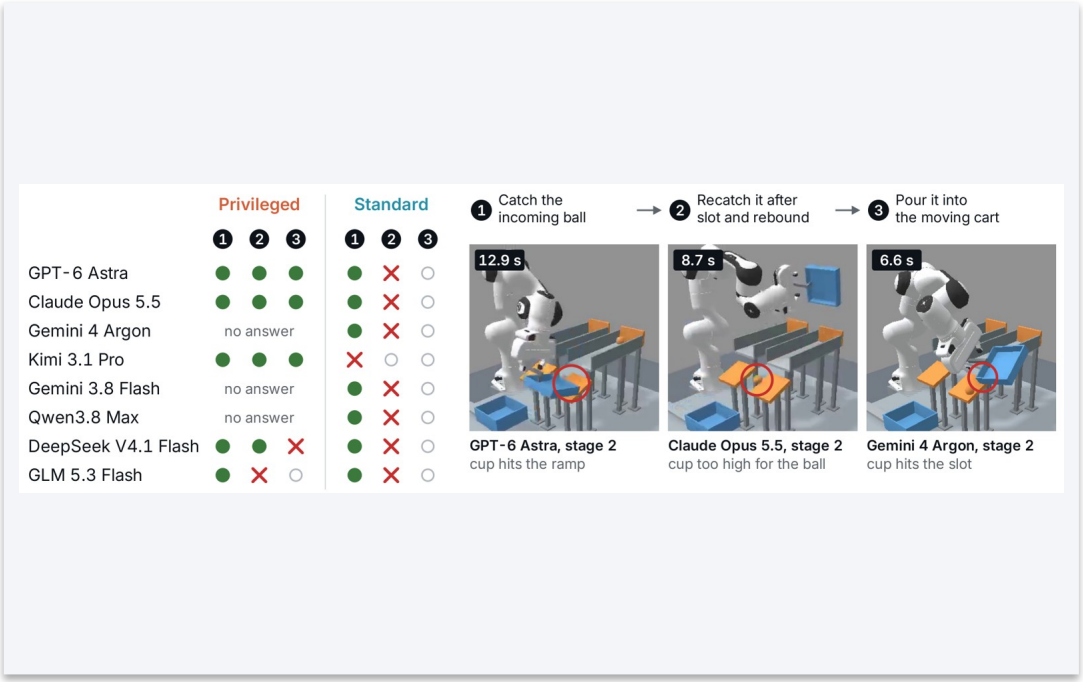

- 最常见的失败阶段通常是**第一个阶段**（264 个 Standard 测试中占 65%）
- 接两次球任务中，**7/8** 个智能体完成第一次接球后卡在第二次接球，具体失败方式各不相同

改变材料、移动身体的阶段最容易失败

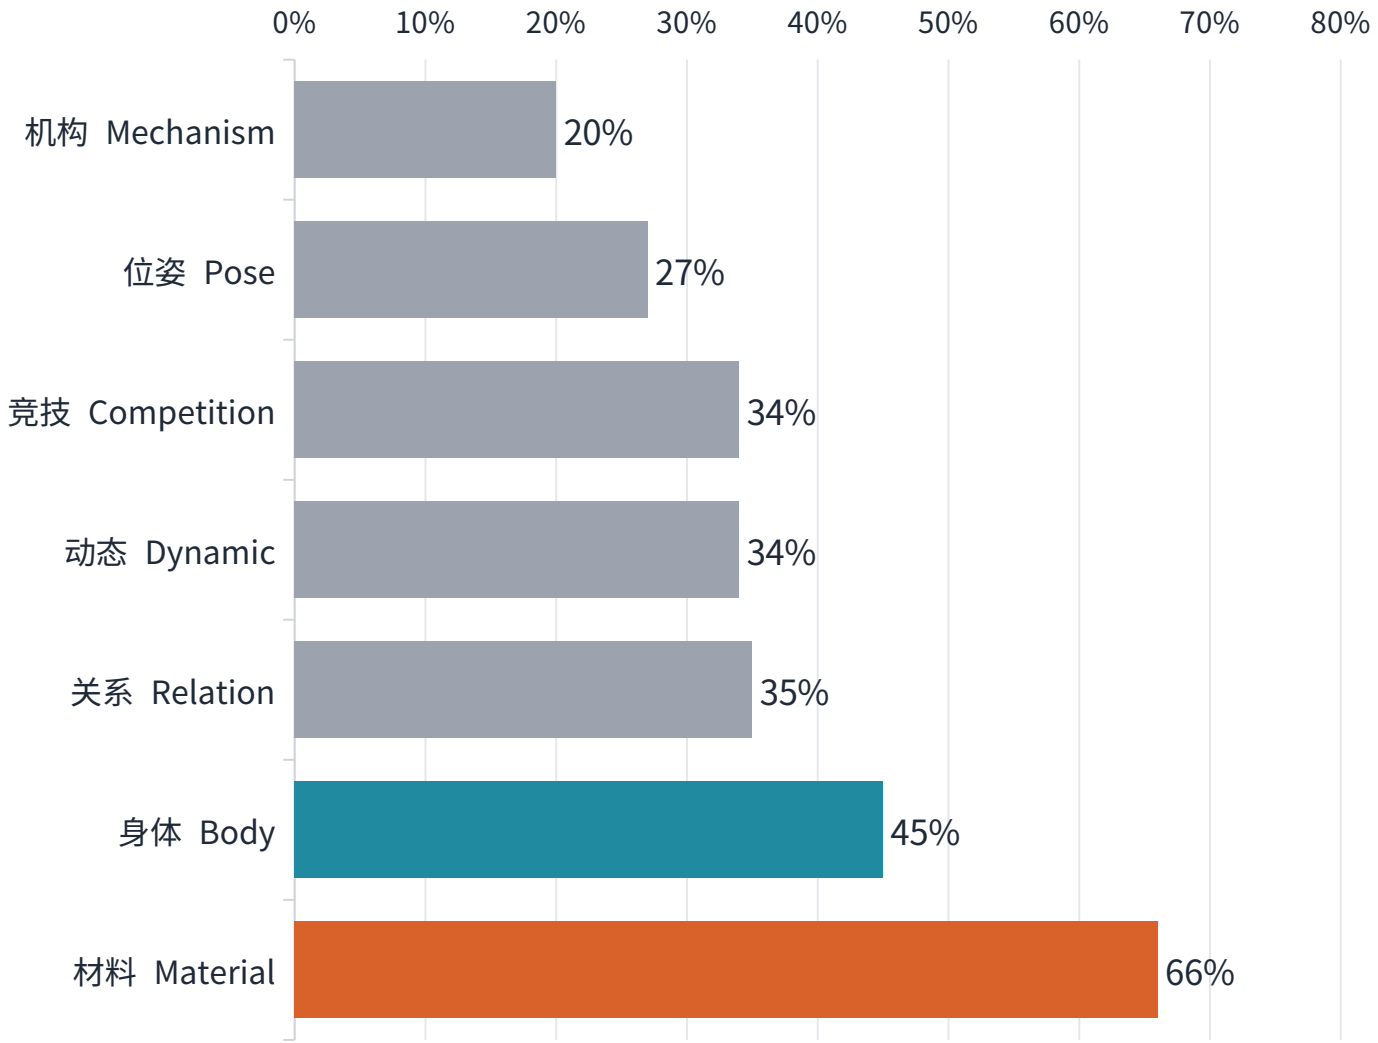

同一类别内部差别也很大

- 打开（open） **38%**，关闭（close） 7%，按压（press） **3%**
- 关系类阶段：单手 36%，双臂 52%，用腿 / 躯干 **65%**

注意：相关 ≠ 因果

各类别集中在特定套件和机器人上。留一套件检验时，阶段类型的难度排序只有 55% 的配对仍成立，接近随机。

弱模型更常“连物体都没碰到”就失败

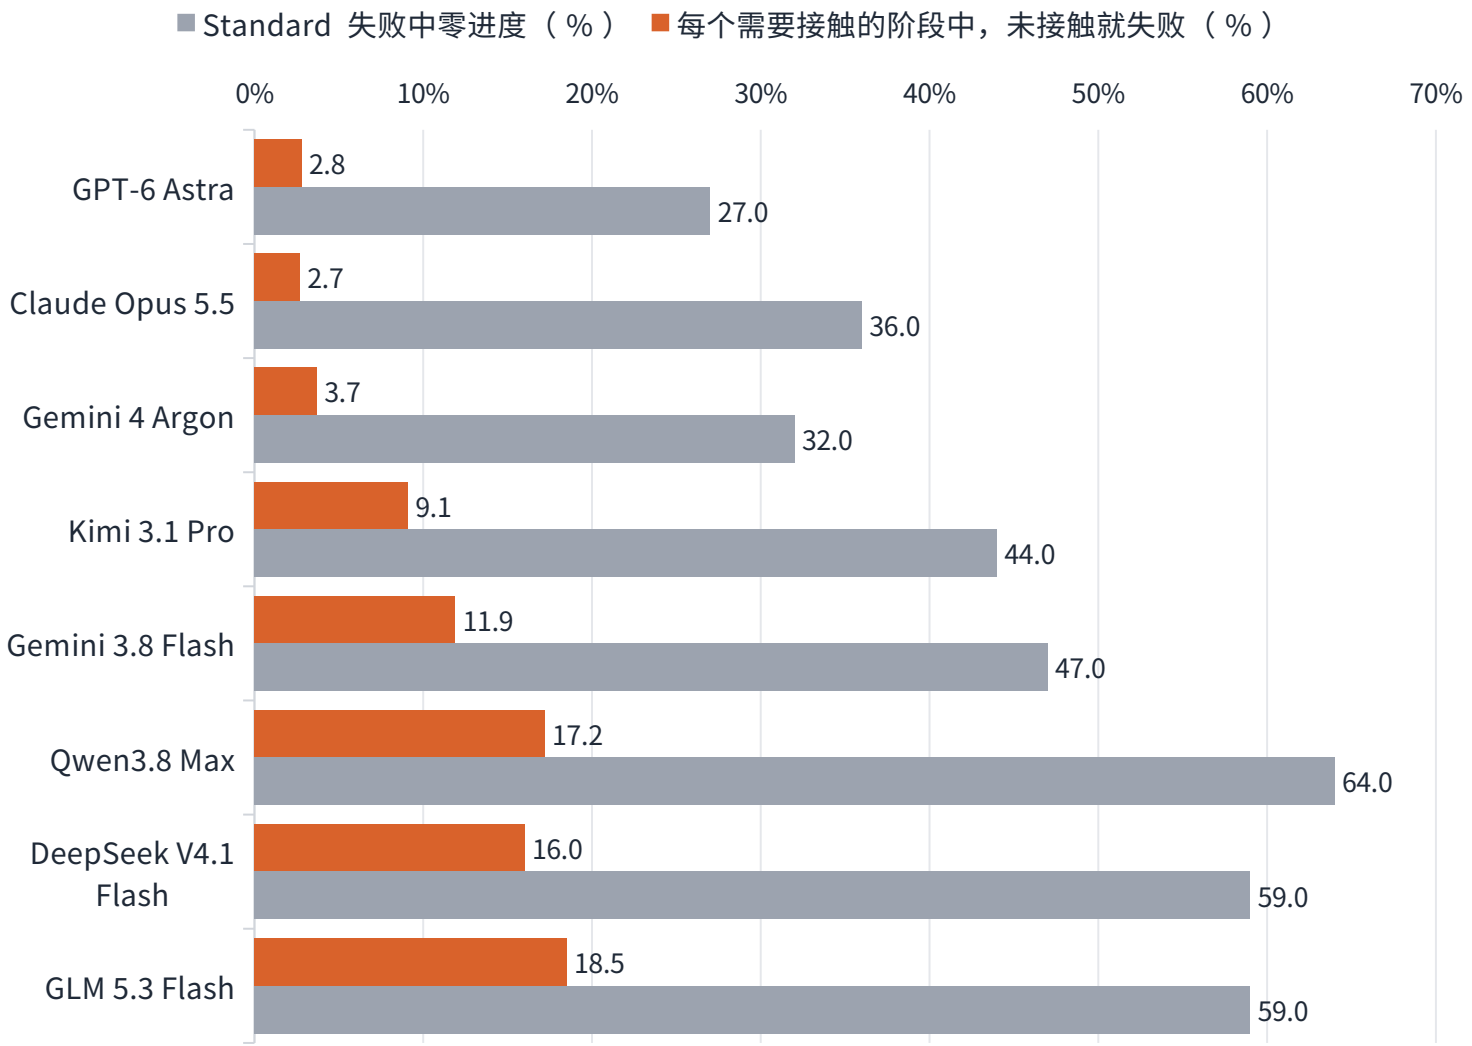

2.7–3.7%

三强：每个需要接触的阶段中，未接触就失败的比例

9.1–18.5%

五个较弱模型的同一指标；
在全部 19 个样本足够的套件中都更高

抓握丢失要按机会归一化

GPT-6 Astra 的失败中“抓握丢失”占比最高（17%），因为它到达的抓握阶段更多；按每个抓握阶段计算，它是 5.6%，其他智能体合并是 7.5%（差值的区间包含 0）。

三强解出的题目部分互补；换 harness 最多差 12 个百分点

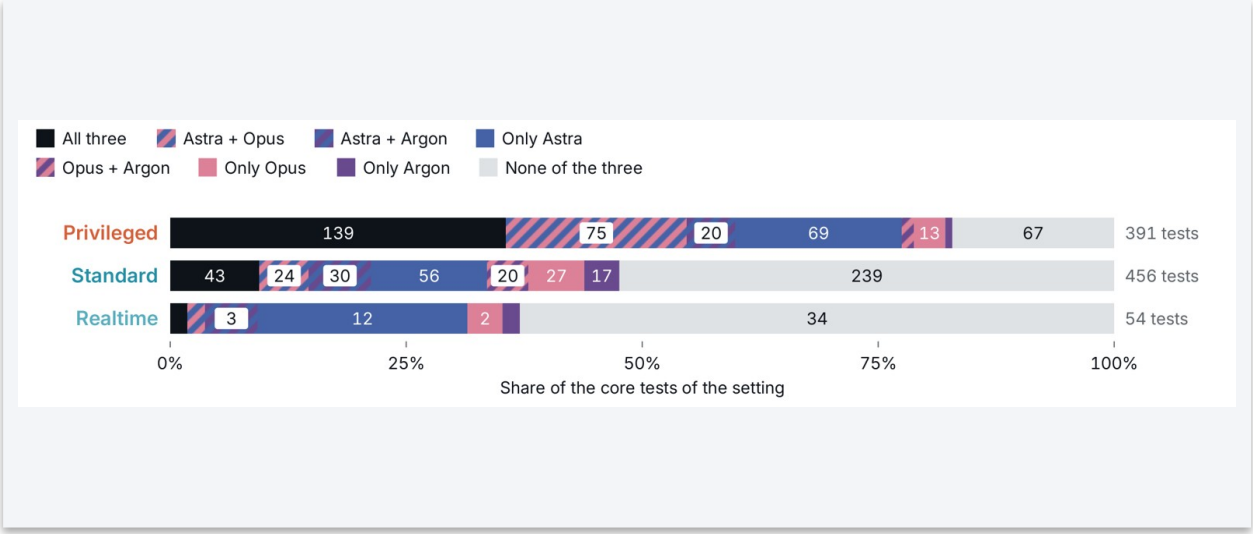

- Standard：只有 Astra 解 **56**，只有 Opus 解 **27**，只有 Argon 解 **17**，三者都没解 **239**
- Opus 与 Argon 合计解出 **64** 个 Astra 失败的测试；Privileged 下 Astra 覆盖了它们解出的 92%/95%
- 每题只跑一次，部分差异可能来自运行间方差

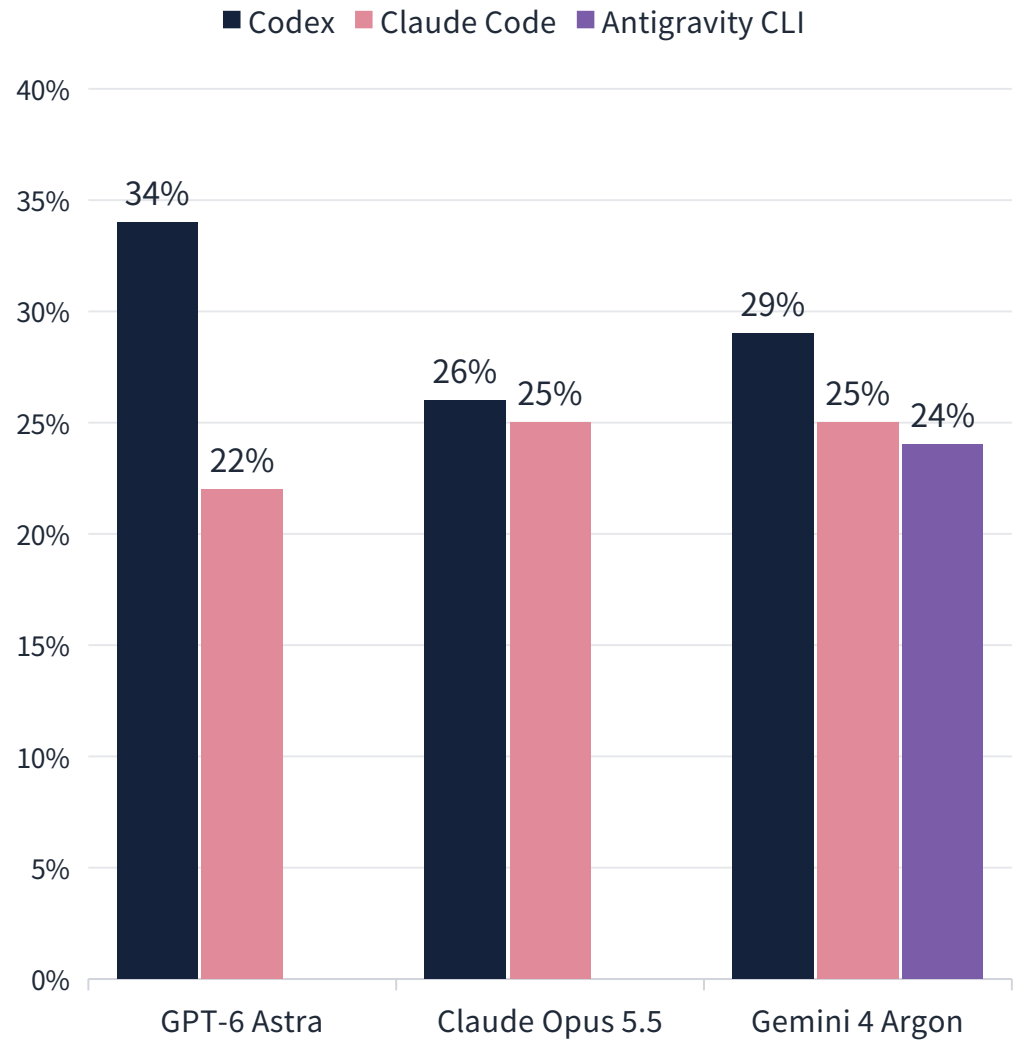

控制方式随设置切换：仿真暂停时边看边动，世界不停时写程序

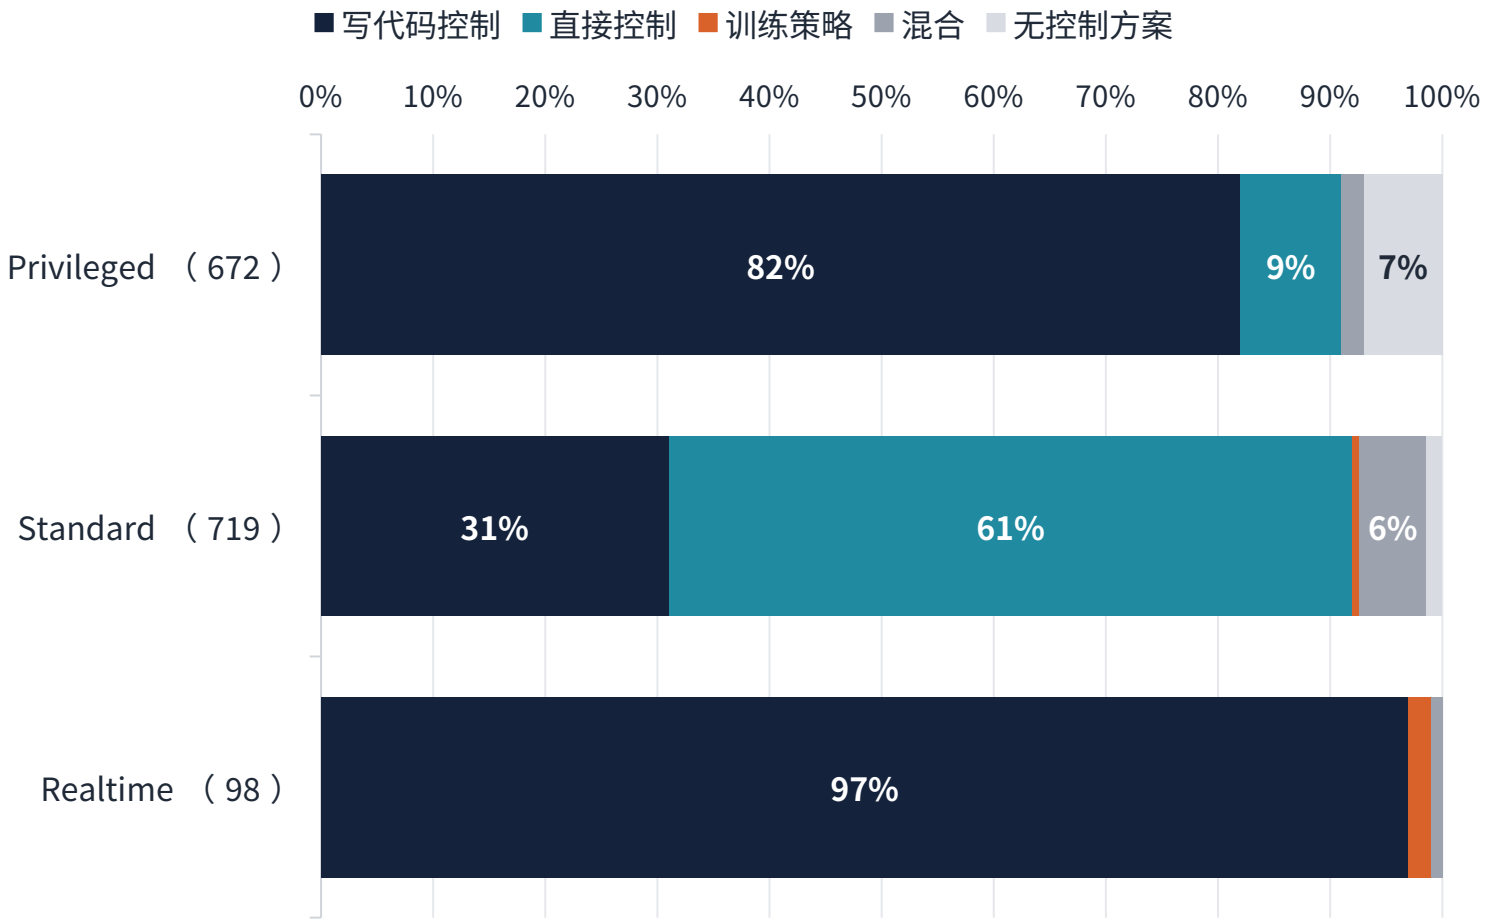

写代码控制细分： Privileged 闭环 45% / 开环 20% / 参数搜索 17%； Realtime 闭环 82%。

三种设置，三种主导方式

- **Standard 61%** 直接控制：模型在控制回路里，每发一个动作块就看一次图
- **Privileged 82%** 写程序：利用全状态计算或搜索动作
- **Realtime 97%** 写程序，其中 82% 由程序跑闭环
- 例：羽毛球比赛中，程序追踪羽毛球并拟合阻力模型后挥拍，智能体在暂停时改程序，**11–4** 获胜

足球：有 GPU 时智能体会主动训练 RL 策略，赢球的全是训练出的策略

With a GPU

Trained walking and ball-control policies with RL

Won 10–8

Robots walked 690 m (opponent 693 m)
Robots fell 22 times (opponent 10)

CPUs only

Hand-written gait tuned by search

Lost 3–13, mercy rule

Robots walked 276 m (opponent 624 m)
Robots fell 59 times (opponent 7)

17 / 20

GPU 版尝试训练了 RL 策略（CPU 版：0 / 20）

4 / 20

GPU 版获胜，全部用训练出的策略（CPU 版：0 / 20）

10–8 vs 3–13

GPT-6 Astra： GPU 版获胜 vs CPU 版被提前终止

注意

这是单一任务；两个版本同时在 GPU、RL 库、训练副本和指令示例上不同，无法确定是哪个差异起作用。 Privileged 下 CPU 版也有胜局，但所有胜局都复用了仿真器自带的对手行走网络。

实体机器人演示： Standard 接口可以直接连到真实机械臂

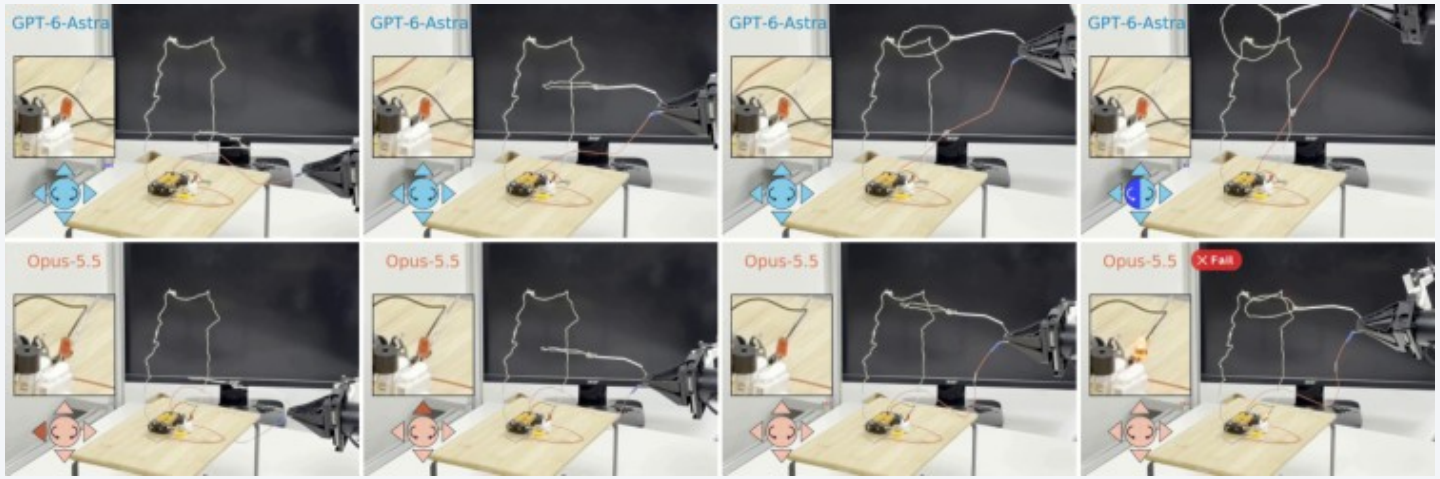

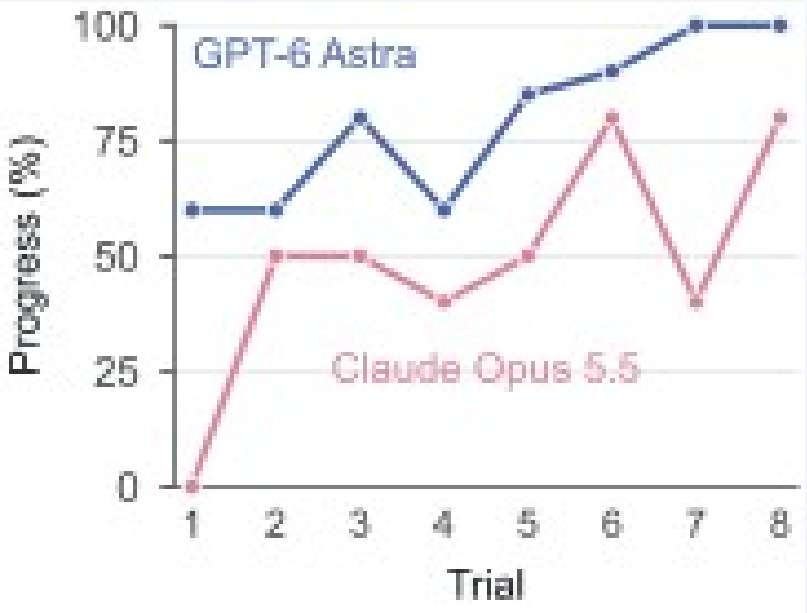

65.0% → 93.8%

GPT-6 Astra 前 4 轮 → 后 4 轮平均进度

35.0% → 62.5%

Claude Opus 5.5 前 4 轮 → 后 4 轮平均进度

仅为演示： 1 个任务、每个智能体 1 组 8 轮试验，不计入成绩，也未验证仿真结果对真实硬件的预测力。

局限：单次尝试、标签由智能体生成、只在仿真中

单次尝试

每个测试只跑一次，无法区分能力和运行间方差；智能体之间的“互补”有一部分可能来自随机性

筛选偏差

核心集排除了 GPT-6 Luna 初筛解出的任务，它与 GPT-6 Astra 同族

标签来自智能体

主要标注者 GPT-6.1 Sol 与 GPT-6 Astra 同族；标签分不清感知与控制错误， 47% 的根因只标到“ Control”

相关 ≠ 因果

阶段类别与套件、机器人混杂；足球结论只来自单一任务，且两个版本有多处不同

仅仿真

除一个实体演示外全部在仿真中； 392 个任务没有参考解

可能的记忆

改编自公开基准的任务，可能有一部分是模型记住了已发表的解法

总结与启示

主要发现

1 Privileged 77% vs Standard 30%：补重置比补精确状态更能缩小差距

2 失败集中在同一阶段，通常是第一个阶段；精确类阶段在 Standard 下失败率上升最多

3 弱模型常常连接触都建立不了；三强解题部分互补； harness 最多带来 12 pts 差距

4 Standard 下多为直接控制， Privileged 与 Realtime 下多写程序；有 GPU 时会训练 RL 策略

启示

- **智能体开发**：存档和回退、闭环校验、把实时控制交给程序，可能比单纯提升感知更关键
- **机器人学习**：“智能体 + 训练策略”在动态全身控制任务上有潜力，应把资源配置当作实验变量
- **评测设计**：按“模型 × harness × 资源”报告结果；Standard 接口可以迁移到实体机器人
- **后续工作**：多次运行给出置信区间、增加 Realtime 任务、在实体机器人上做系统评测