论文解读 · arXiv 2611.12200

Learning to Act with World Models by Valuing What Comes Next

WM-PPO：用世界模型预测“下一步”，用 PPO 的 critic 给它估值

Chenghao Gao, Zhi Zhang, Dian Jin, Yihe Pan, Doudou Zhou

National University of Singapore · Fudan University · UCLA | 首次提交：2026-11-09

稀疏奖励信用分配 | 世界模型 | PPO critic | ALFWorld / ScienceWorld

一句话：给“每个候选动作的下一步”估值， PPO 学得更快更好

世界模型预测候选动作的下一步观测 → critic 给预测后继估成功概率 → **比较 = 策略辅助优势，均值 = critic 辅助目标**，两者都由真实分支结果校准的门控加权；无教师、无特权信息，推理只用策略。

ALFWorld

63.5% → 87.5%

PPO-160 → WM-PPO （贪心，真实步数相当）

ScienceWorld

39.3% → 52.9%

PPO-160 → WM-PPO （贪心，真实步数相当）

vs 最强 PPO 改进

+6.5 分

ScienceWorld： 52.9% vs SO-PPO 46.5%
（ p=0.004 ）

推理开销

0 额外模型

部署时只用策略；训练 GPU 时约 2.7–3.8× PPO-160

终局 0/1 奖励说不清哪一步错了，但环境动态里早有线索

例：清洗盘子并放进柜子

找到盘子

↓

拿起盘子

↓

漏掉：去水槽清洗

↓

放进柜子

R = 0

只有终局一个信号

观测文本变多 ≠ 离成功更近：打开柜子可能刷出一长串无关物品；
一句简短的“加热完成”却可能满足关键前提。

世界模型

能学会“每个动作改变了什么”

但预测出的观测本身不说明成功是否更可能

↓

PPO 的 critic

$R \in \{0,1\}$、 $\gamma=1$ 时： $V^{\pi}(s) = Pr_{\pi}(\text{成功} \mid s)$

但只用于实际走到的状态、执行过的动作

↓

WM-PPO

把二者接起来： critic 给“预测出的后继”估值

→ 同一状态下的候选可以按后果比较

先做诊断： critic 给预测后继估值，能选出更好的动作，也能教会策略

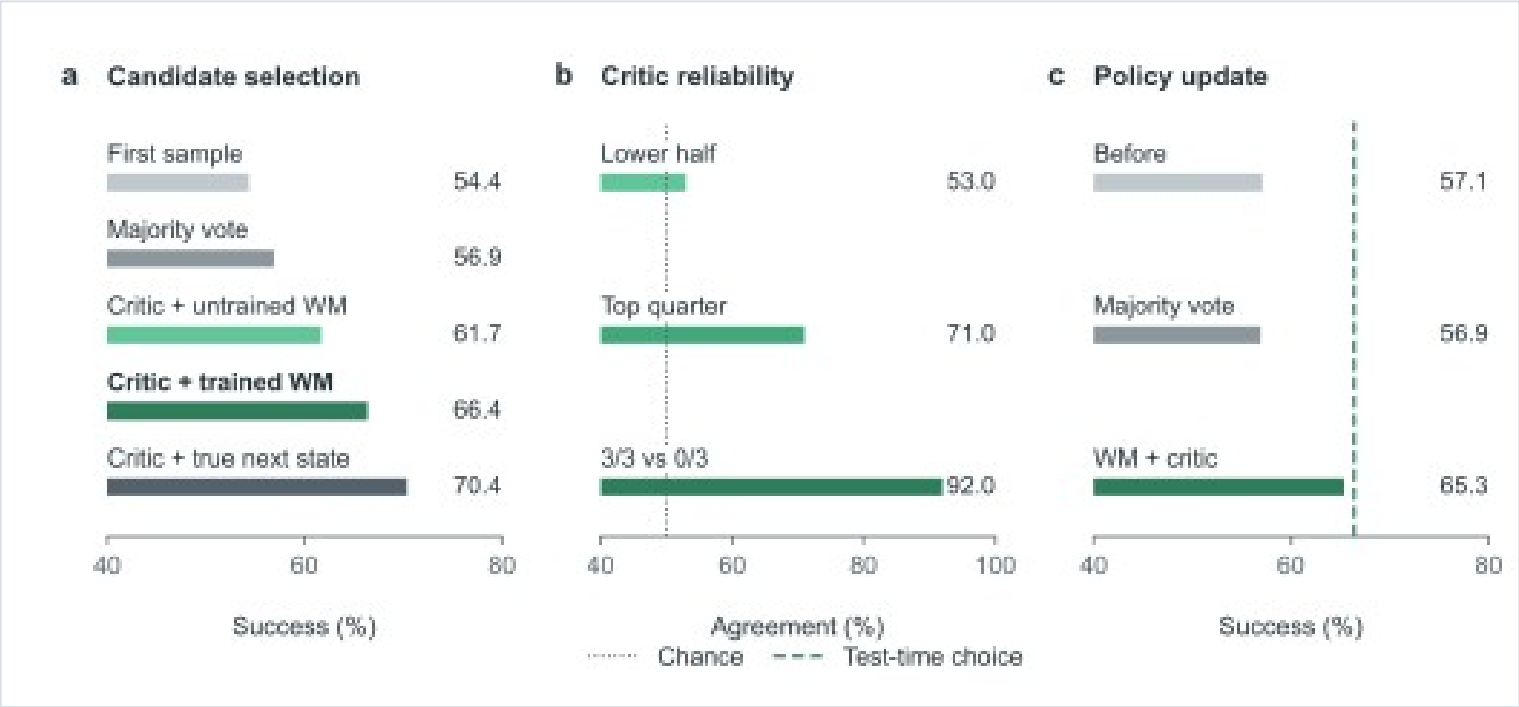

70.4%

按 critic 对真实后继估值选动作（多数投票 56.9%， peek 对照 59.5%）

66.4%

换成训练后世界模型的预测后继（未训练世界模型 61.7%）

57.1→65.3%

用世界模型 +critic 标签做 1 轮离线更新，不用任务奖励；多数投票标签： 56.9%

53%→71%

critic 排序正确率随价值差增大而上升（下半 → 上四分位），因此需要校准

来源： Fig. 1， §2 （ALFWorld， PPO 第 24 轮检查点， 274 局）

WM-PPO：一个世界模型 + 一个共享门控，两条学习通道

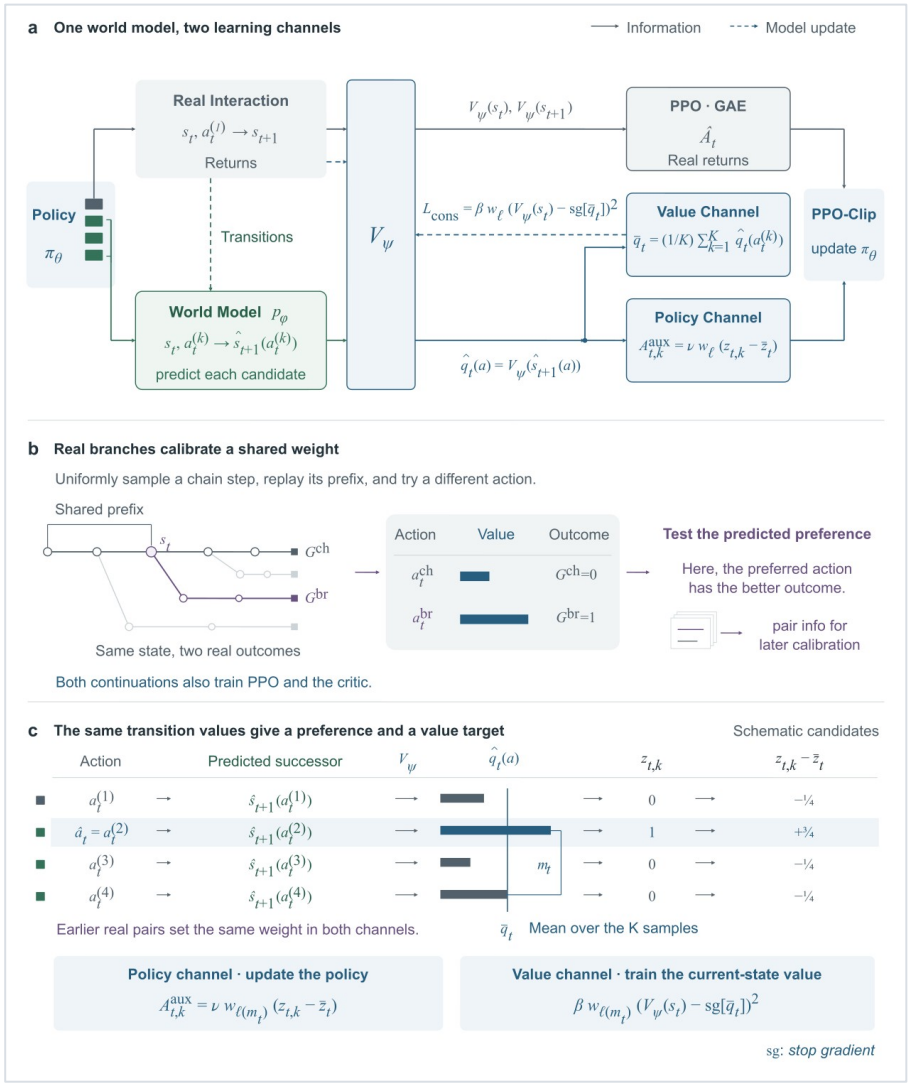

① 采样候选

每个链上状态采 K=4 个响应，执行第 1 个（不改变行为策略）

② 预测后果

世界模型对每个不同候选贪心预测下一观测 ô(a)，拼出后继状态 ŝ(a)

③ 估值

q̂(a) = V_ψ(ŝ(a))； ScienceWorld 预测到结束标记时直接取 1 或 0

④ 两条通道

比较 → 策略辅助优势；均值 q̄ → critic 辅助目标

⑤ 门控

主链 +3 条真实分支，按价值差分 bin 校准权重 w_ℓ，两通道共用

同一组 transition value ，既给策略偏好，也给 critic 目标

策略通道

$$A_{aux} = v \cdot w_{\ell}(m) \cdot (z - \bar{z})$$

- z： 样本是否为首选动作 $\hat{a} = \text{argmax}\, \hat{q}$
- 组内和为 0： 概率质量移向首选动作
- 只学“选哪个”，不学“好多少”； $v = 1$，与普通 PPO 样本同在一个 clip 目标中

价值通道

$$L_{cons} = \beta \cdot w_{\ell}(m) \cdot (V_{\psi}(s) - sg[\bar{q}])^2$$

- $\bar{q} = K$ 个候选 $\hat{q}$ 的均值，即 $V^{\pi}(s)$ 的一步模型估计
- $\beta = 0.5$； 真实回报回归仍是 critic 的主监督
- critic 更准 → 下一轮 PPO 自己的 GAE 优势也更好

示例（ScienceWorld， Fig. 19）： 任务是“调出橙色颜料再 focus”，碗里已有红、黄颜料

mix bowl	mix bowl	mix bowl	focus on orange paint
$A_{aux} = +1/4 \times w$	$A_{aux} = +1/4 \times w$	$A_{aux} = +1/4 \times w$	$A_{aux} = -3/4 \times w$

核心性质（Eq. 7）： $\hat{q}(a) - \hat{q}(a') \approx A(s,a) - A(s,a')$，共同项 V(s) 被消去，比较不依赖 critic 对当前状态的估值。

$\hat{q}(\text{mix}) - \hat{q}(\text{focus}) = +0.153$

世界模型预测： mix → 生成橙色颜料； focus → 命令被拒。两条真实续玩都成功，终局奖励分不出好坏，偏好仍然指向“先 mix”。

用真实分支结果校准：只有“以往说对了”的价值差才被信任

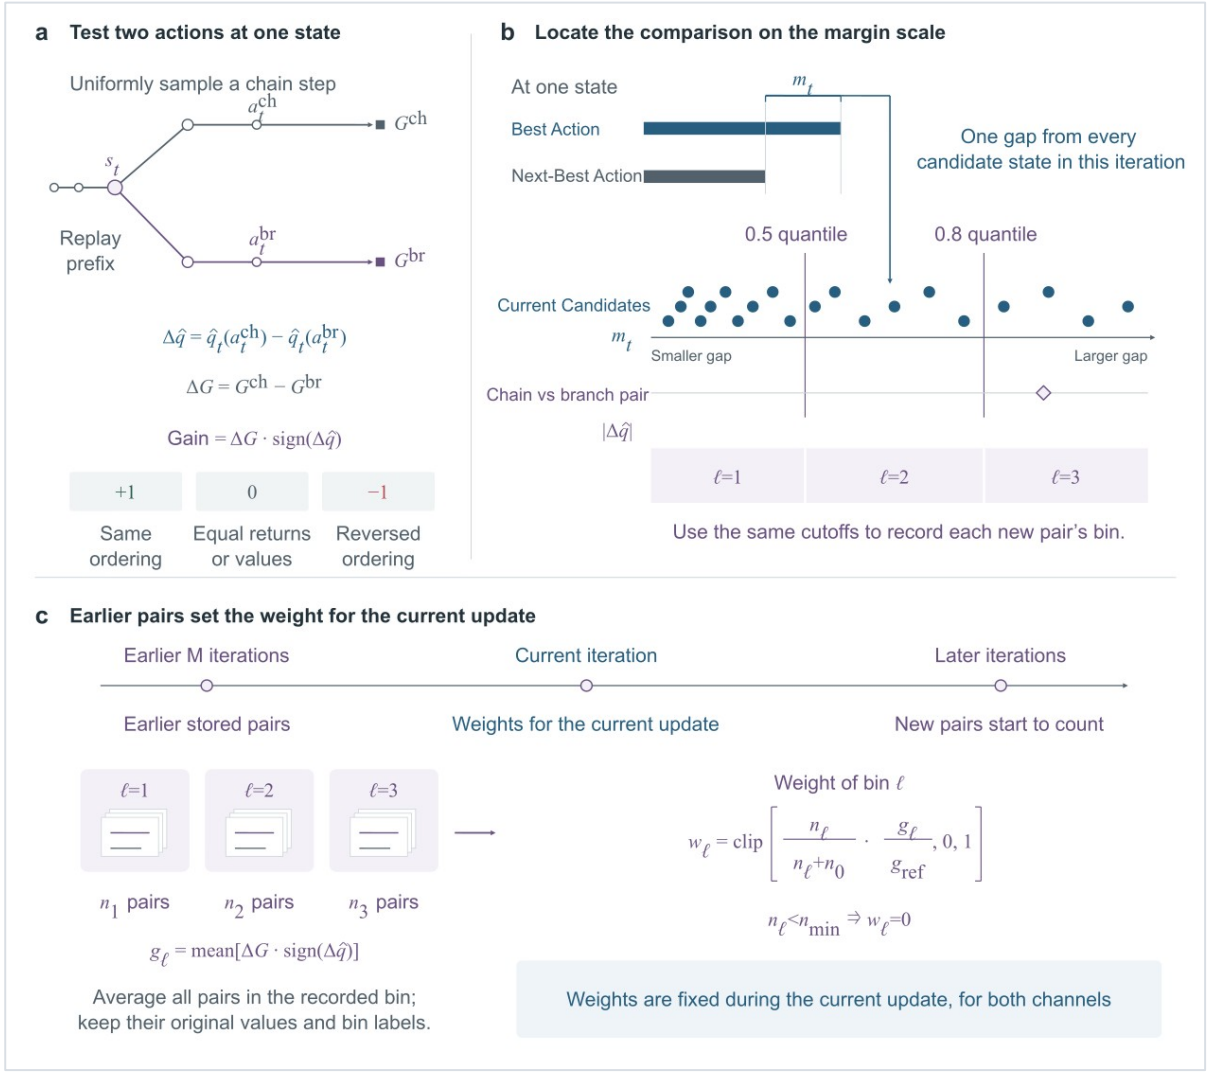

Gain = ΔG · sign(Δq̂)

同一状态 chain vs branch： 偏好对 +1，错 − 1，结果相同 0

$w_\ell = \mathrm{clip}(n/(n+n_0) \cdot g_\ell/g_{ref}, 0, 1)$

pair 数 n < n_min 时，该 bin 关闭（w = 0）

- 3 个 bin： 本轮非零 margin 的 0.5 / 0.8 分位数
- M = 4 轮历史 pair； n_0 = 40， g_ref = 0.05， n_min = 20
- 只在 ALFWorld 预实验设一次，两个环境原样使用
- 门控关闭时 = 普通树上 PPO； 一个权重同时作用于两条通道

ScienceWorld 高出最强基线 6.5 分； ALFWorld 与强基线持平

ALFWorld （较简单，接近上限）

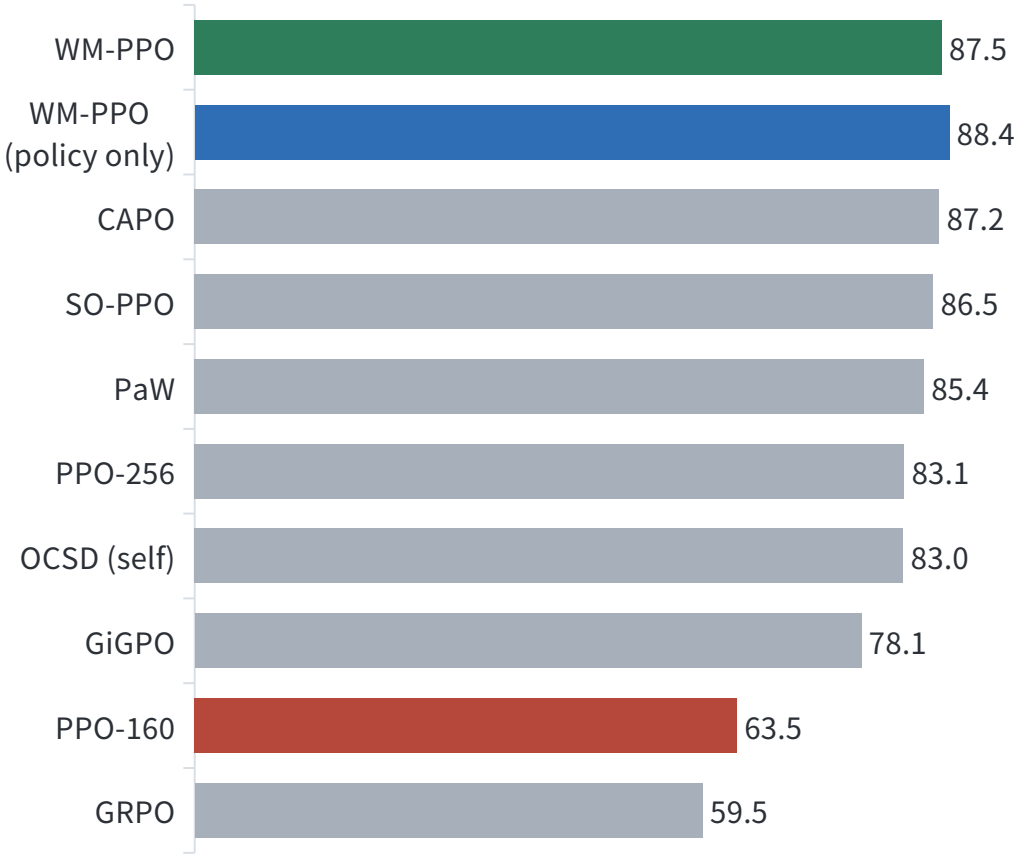

ScienceWorld （更难，需建立中间条件）

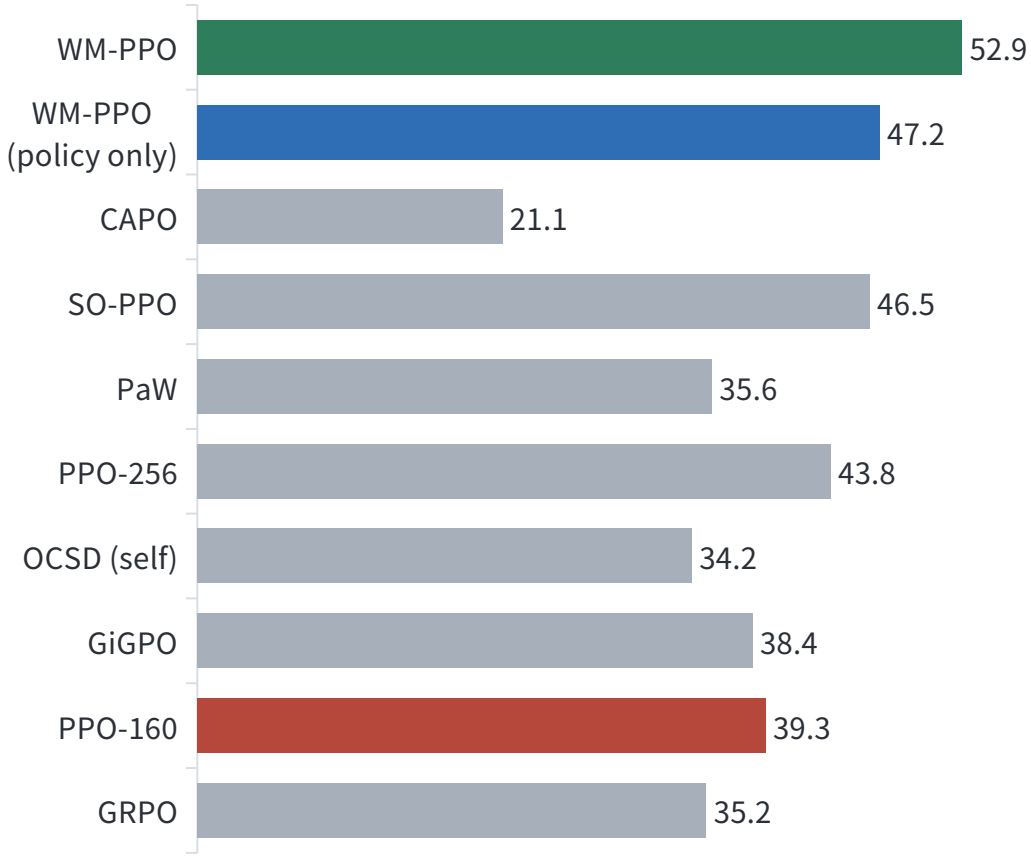

绿： WM-PPO ；蓝：仅策略通道；红：步数相当的 PPO-160 。 ScienceWorld 的 CAPO 三种设置均发散，取发散前最好检查点（ 21.1% ）。 WM-PPO 与 PPO-160 每个运行都高于对方所有运行。

来源： Table 2 （贪心成功率 % ， ALFWorld 第 36 轮 / ScienceWorld 第 60 轮）

同等真实交互下成功率更高，达到同一水平用的步数更少

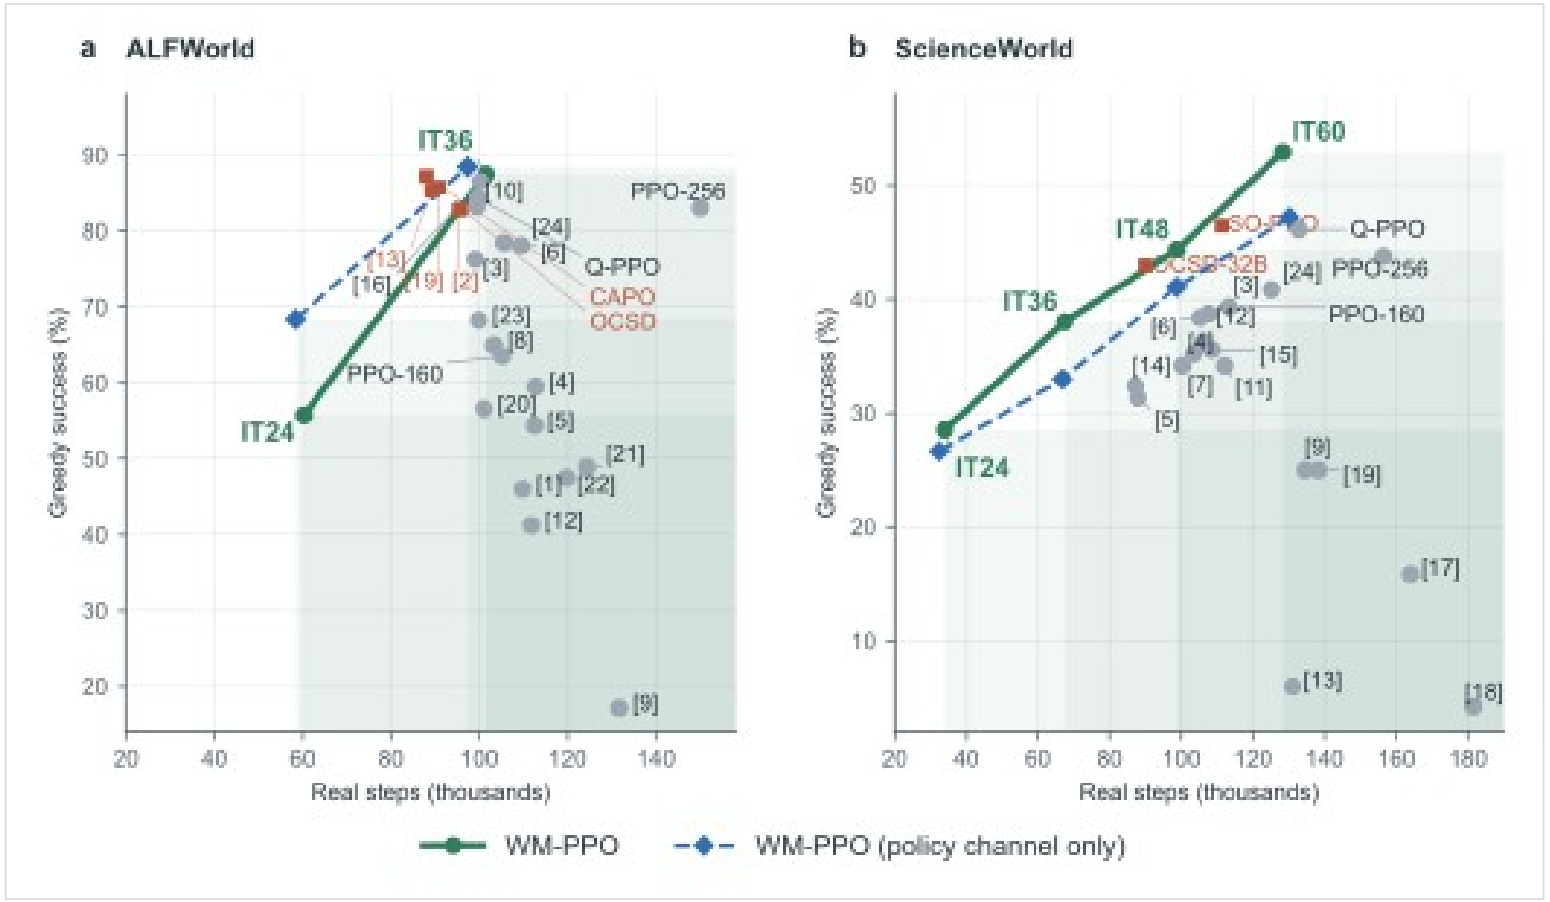

18 / 23

ALFWorld 上落入被支配区域的其他方法

18 / 20

ScienceWorld 上落入被支配区域的其他方法

69–97k vs 129–141k

ALFWorld 达 80%： WM-PPO vs PPO-256（PPO-160 到第 36 轮未达到）

94–120k

ScienceWorld 达 45%： WM-PPO； PPO-160 在 108–118k 步内未达到

代价：单轮墙钟 1.3–1.6×， GPU 时 2.7–3.8×（训练阶段）

来源： Fig. 4、 Fig. 13 表（Table 14）、 Table 17

消融：去掉辅助更新、冻结世界模型或去掉门控，都会明显掉分

结构对照（贪心成功率 %）

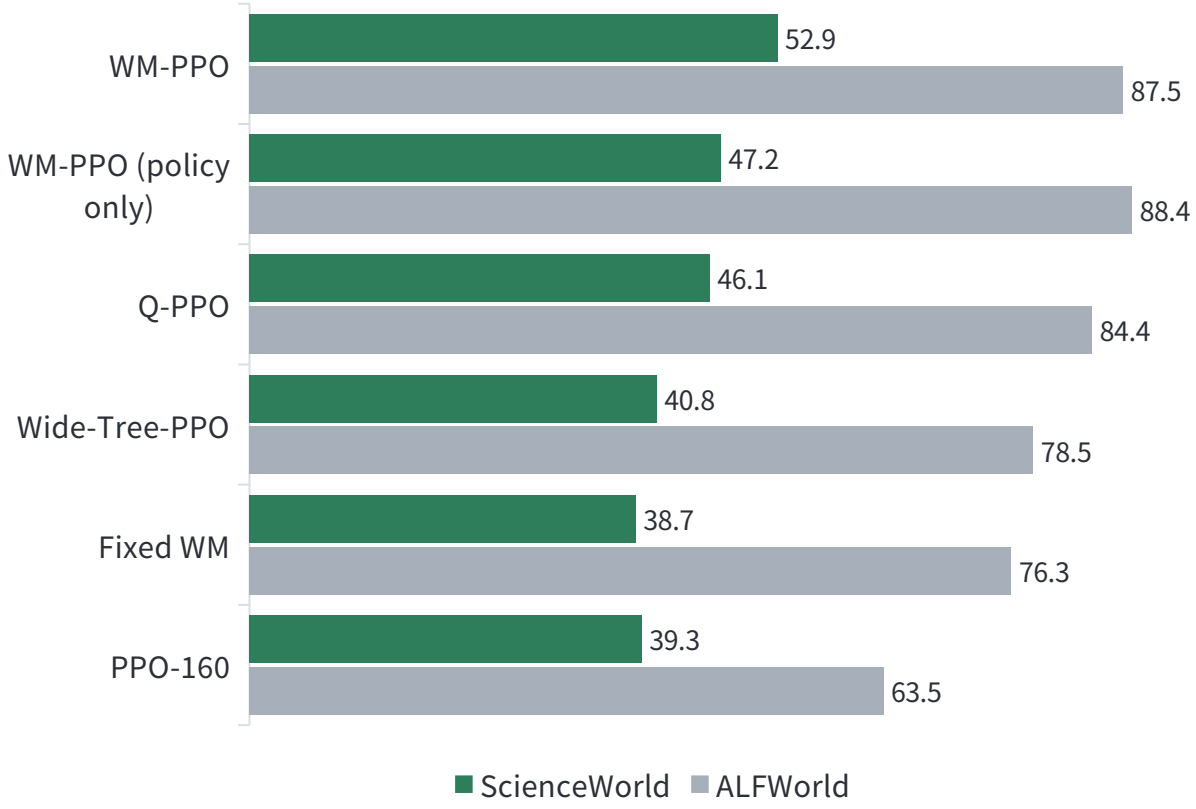

Wide-Tree-PPO 在 ScienceWorld 上 82% 的分支点各候选终局回报完全相同，真实结果分不出好坏，而 transition value 仍能区分。

门控消融（ScienceWorld 第 60 轮，单种子）

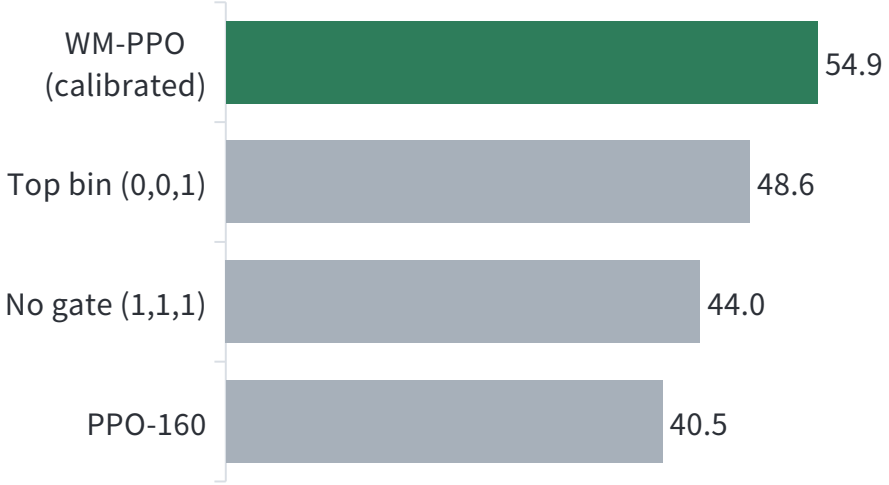

- **Wide-Tree：** 同样的树、只去掉辅助更新 → − 10.0 / −6.3 分
- **Fixed WM：** 世界模型不更新 → ScienceWorld 跌回 PPO-160 水平（38.7 vs 39.3）
- **Q-PPO：** 直接学 Q 估值 → 不如“预测后继 + V”
- **门控：** 全开会注入近随机偏好；只开最大 bin 会丢掉弱信号

来源： Table 2 （运行均值， Fixed WM 为单次运行）、 Table 21 （门控消融，单一种子）

大价值差的比较越训越准；在线更新的世界模型保持预测质量

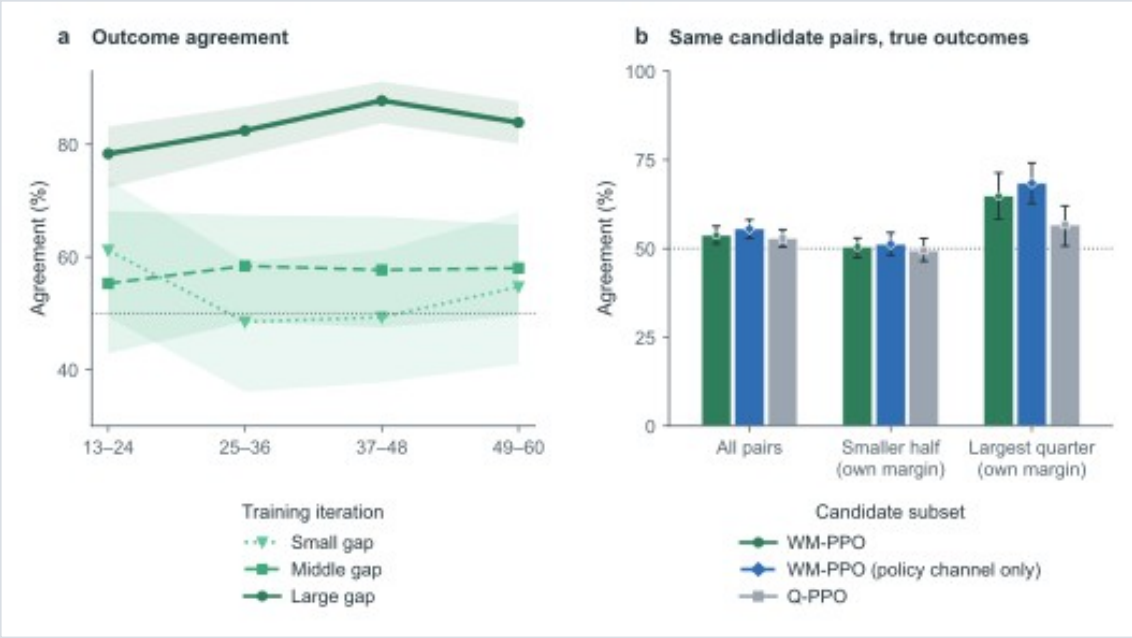

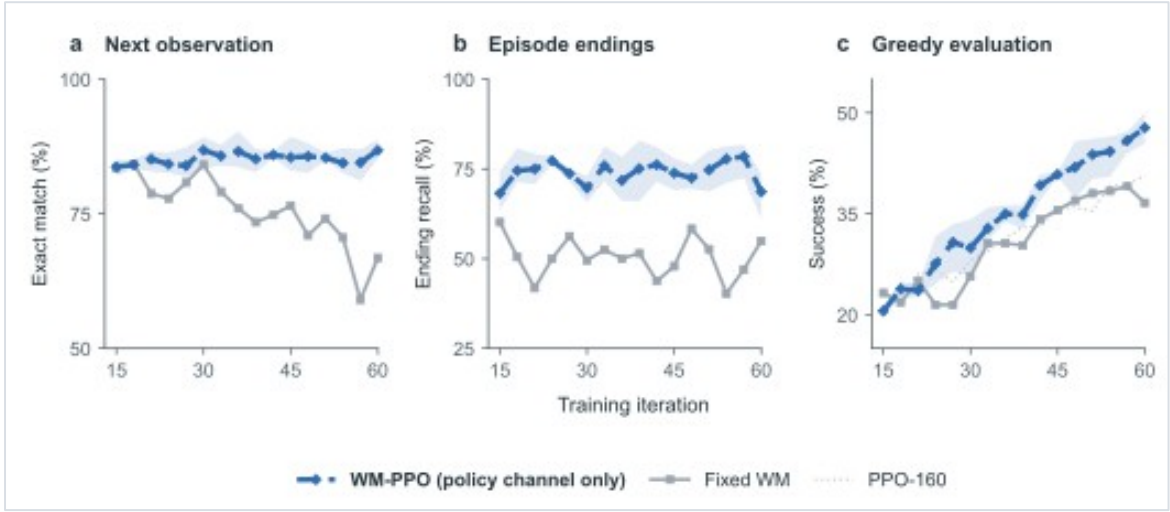

最大 margin bin 一致率： 78% → 88% （后期 84% ）

小 / 中 bin 一直 50–60% ，接近随机。最大 bin 中：预测后继 +V 一致率 85% ，直接学 Q 的 Q-PPO 76% 。例： focus on air 被估为 0.03–0.34 ， 24 次真实续玩全部失败。

在线世界模型：精确预测 84–86% ；固定世界模型： 81% → 68%

结束召回约 74% vs 约 50% 。固定世界模型那次运行后期最大 bin 一致率只有 53–64% ，成功率与 PPO-160 相当。

来源： Fig. 5 、 Fig. 6 、 Table 19/20/23 （ ScienceWorld ）

价值通道让 critic 更准，门控更早打开， ScienceWorld 再多 5.8 分

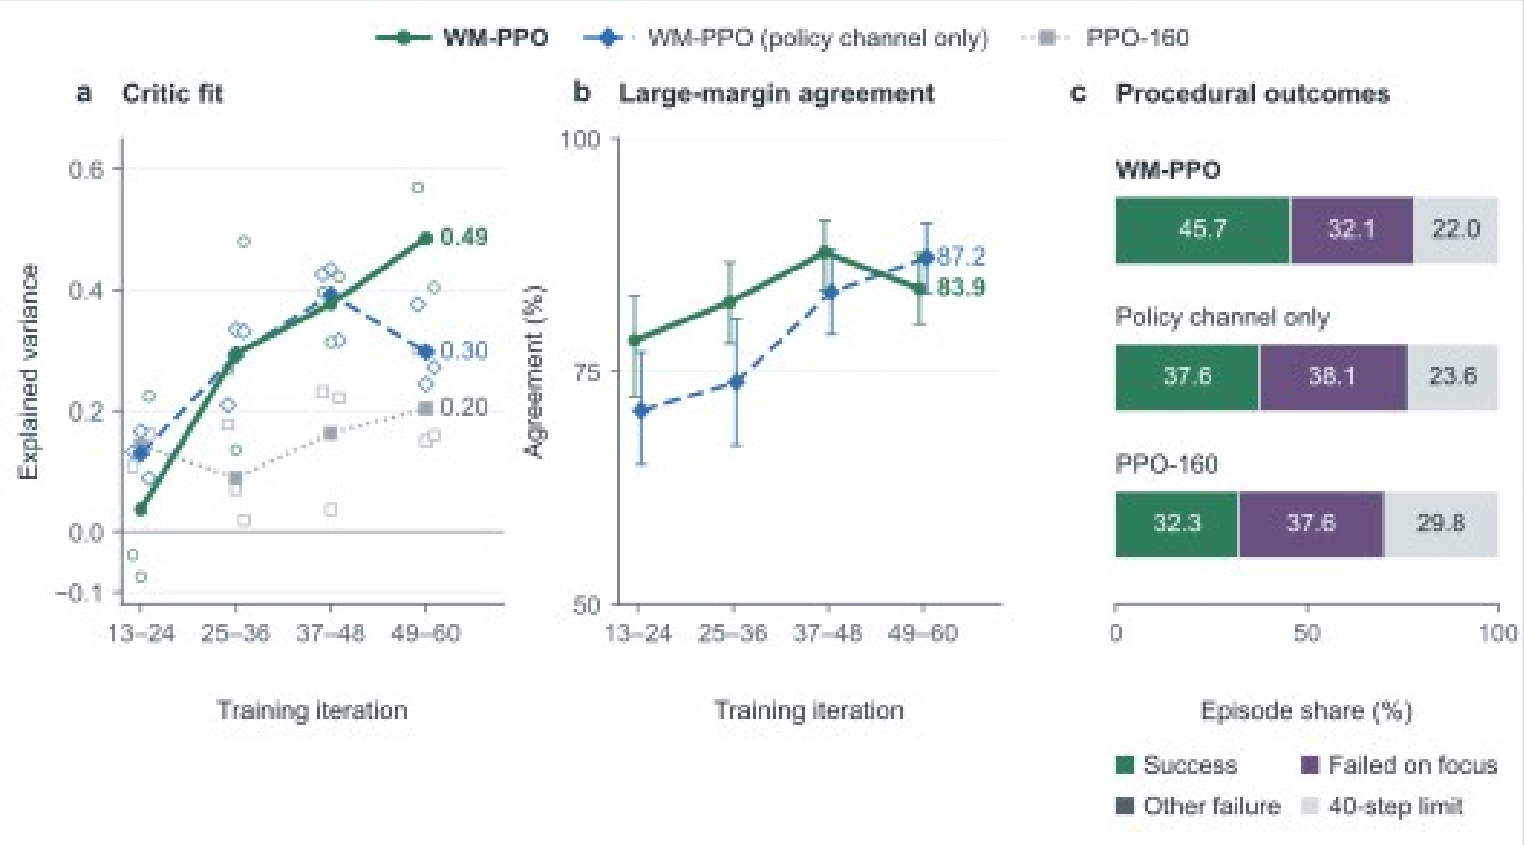

0.49 vs 0.30

后期 critic 解释方差（WM-PPO vs 仅策略通道；PPO-160 0.20）

78–82% vs 71–74%

早期最大 margin 比较的一致率

55% → 62%

两个后继都由 critic 估值的比较（有预测结束的比较约 95%）

+5.8 分

ScienceWorld 贪心成功率： 52.9% vs 47.2%

注意： ALFWorld 接近上限，结果不同的分支 pair 很少，门控自动收回权重（第 36 轮最大 bin 关闭），价值通道没有额外增益（87.5% vs 88.4%，不显著）。

来源： Fig. 7 、 Fig. 8 、 Table 20 （ScienceWorld）

学到的行为：先完成前置条件，再放置物体或提交答案

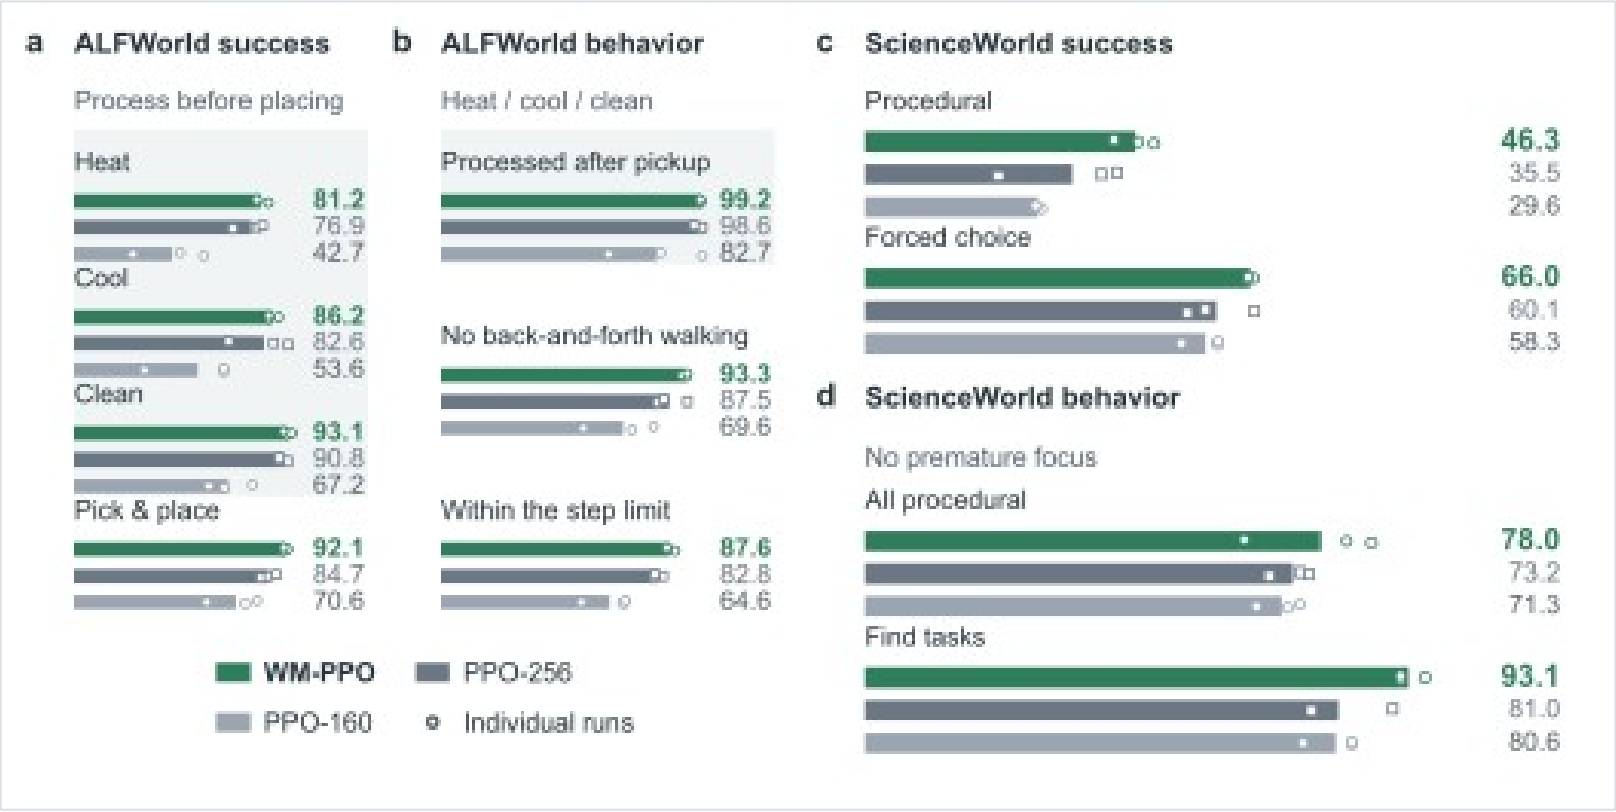

81.2% vs 42.7%

ALFWorld Heat 任务： WM-PPO vs PPO-160

41% → 17%

拿起物体后“先放后处理”的错误顺序

46.3% vs 29.6%

ScienceWorld 程序型任务成功率

28.7% → 22.0%

过早 focus （还没建立前提就提交答案）；
find 类： 19.4% → 6.9%

强制选择类任务增益较小：正确与否要到最后才显现。

来源： Fig. 10 、 § 5.3 、 Appendix F.5

两个案例： PPO-160 跳过前提或过早下结论， WM-PPO 先把条件做好

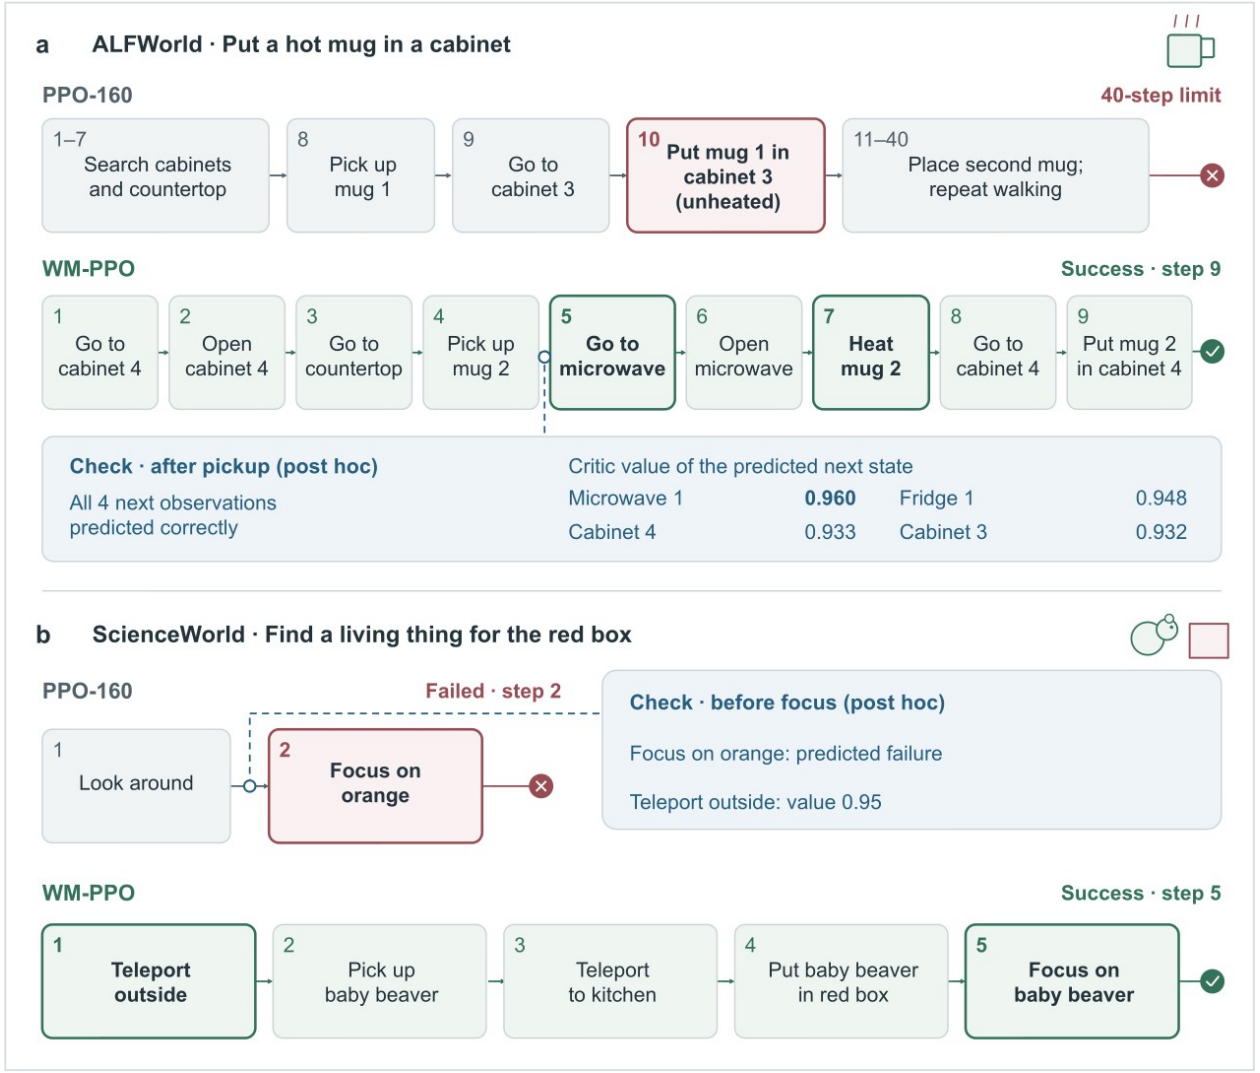

ALFWorld： 热杯子放进柜子

PPO-160： 未加热就放进柜子 → 撞 40 步上限

WM-PPO： 先去微波炉加热，第 9 步成功；事后 critic： 微波炉 0.960 为最高

ScienceWorld： 找一个生物

PPO-160： 第 2 步 focus 橙子 → 失败

世界模型预测这一步会失败；teleport outside 估值 0.95 。WM-PPO 第 5 步成功

来源： Fig. 11 （最终策略的贪心对局； Check 为事后检查）

代价与局限：额外计算留在训练里，需要可重放的环境

训练代价（vs PPO-160）

1.3–1.6×	单轮墙钟时间（ALFWorld 40 vs 32 分钟；ScienceWorld 55 vs 34 分钟）
2.7–3.8×	GPU 时（上界：7 张 GPU，共享服务器全额计入）
≈ PPO-256	算上前缀重放后的环境调用总数
0	推理时的额外模型：部署只用策略

局限（作者承认）

- 只用了一个 4B 基座（Qwen3-4B）和两个文本环境（外加 Sokoban），每局 ⩽ 40 步
- 分支与门控需要确定性重放或保存环境状态
- 分支动作是在“与链上不同”的条件下采样的，更新未做修正
- 单次贪心预测，不表达不确定性；揭示新物体的观测精确率只有 26%
- 长程影响完全靠 critic；预测误差会带偏辅助信号
- 大量小 margin 比较权重接近 0，没被利用

来源：§4.3、§7、Table 17

要点回顾

1

估值预测出的后果

世界模型说明“会发生什么”， critic 说明“这对成功意味着什么”；都只从自身交互中学习，部署只用策略。

2

校准比数量重要

critic 比较整体接近随机，只有大价值差可靠；真实分支在线校准的共享门控是方法稳定的关键。

3

更少交互、更好行为

ALFWorld 63.5→87.5%， ScienceWorld 39.3→52.9%；策略学会先满足前提，再放置或提交答案。

适用场景：真实交互慢或贵、环境可重放的稀疏奖励多步任务；扩展到非确定性或物理环境，需要先解决状态重放和预测不确定性。