论文解读 · arXiv 2611.12806 · cs.RO

LingBot-Touch：一个编码器读懂三类触觉传感器

Learning Heterogeneous Tactile Representation for General Dexterous Manipulation

Bing Han, Yichuan Peng, Haoyu Dong, … , Nan Xue, Wei Ning †
Ant Group · Robbyant　首次提交 2026-11-09

压阻 · 磁 · 视触觉 | Tactile-JEPA | 即插即用触觉 token

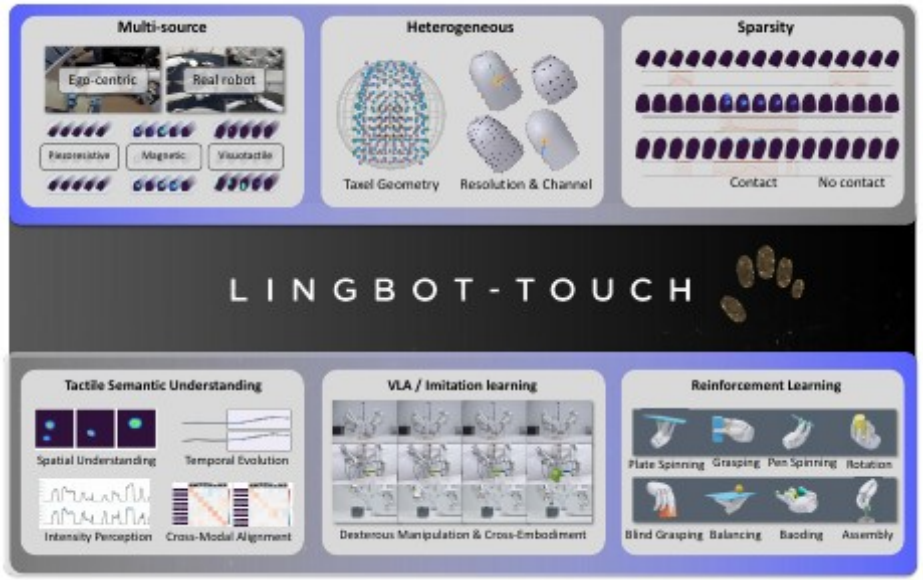

图源：论文 Fig.1 （LingBot-Touch 总览）

一句话总结

一句话： 5M 参数的冻结触觉编码器，让四类策略平均提升 14–25 个点

统一坐标 + 潜空间预测 → 通用触觉表征。

把压阻、磁、视触觉的 taxel 都映射到标准指尖球面坐标系，用 Tactile-JEPA 在 ~5,000 h 手套 + 遥操作数据上预训练共享 Haptic Transformer；冻结后作为即插即用 token 接入 IL / VLA / RL 策略，并零参数迁移到未见过的传感器型号。

4,983 h

预训练语料
3 类传感原理

+13.9~24.8

26 个真机任务
平均提升（pp）

69.0%

12 个仿真 RL 任务
无触觉仅 21.4%

0 参数更新

迁移到未见过的
XHand1 磁传感器

<0.2%

Tiny 编码器参数
占所接入策略比例

注：真机提升为 26 任务均值（Fig.11 / Tab.2）； RL 为 12 任务等权平均（Tab.3）。

动机

触觉难以规模化的根源：数据被绑定在传感器物理上

① 没有统一输入格式

每种传感器的通道、布局、分辨率、采样率各不相同；一个传感器的读数对另一个传感器上训练的模型毫无意义。

② 没有大规模语料

数据无法跨传感器合并；每一小时数据都需要一只带传感器的手真实地触摸世界。

③ 没有成熟配方

“触觉有用”的证据分散在各传感器、各任务的独立研究中，缺乏可比较的共享表征。

核心洞察

接触本身与传感器无关

同一次“指尖压在边缘上”，无论被磁力计、电阻网格还是凝胶相机记录，都是同一个物理事件。

→ 去除传感器特有物理后，接触的表征可以共享。

数据

5,000 小时语料：三分之二来自人戴手套，三分之一来自机器人遥操作

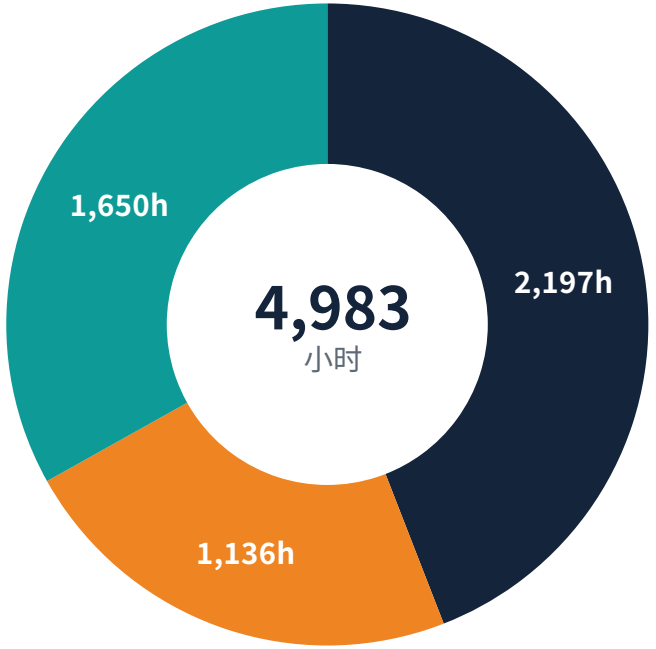

■压阻（手套） ■磁（手套）
■视触觉（遥操作）

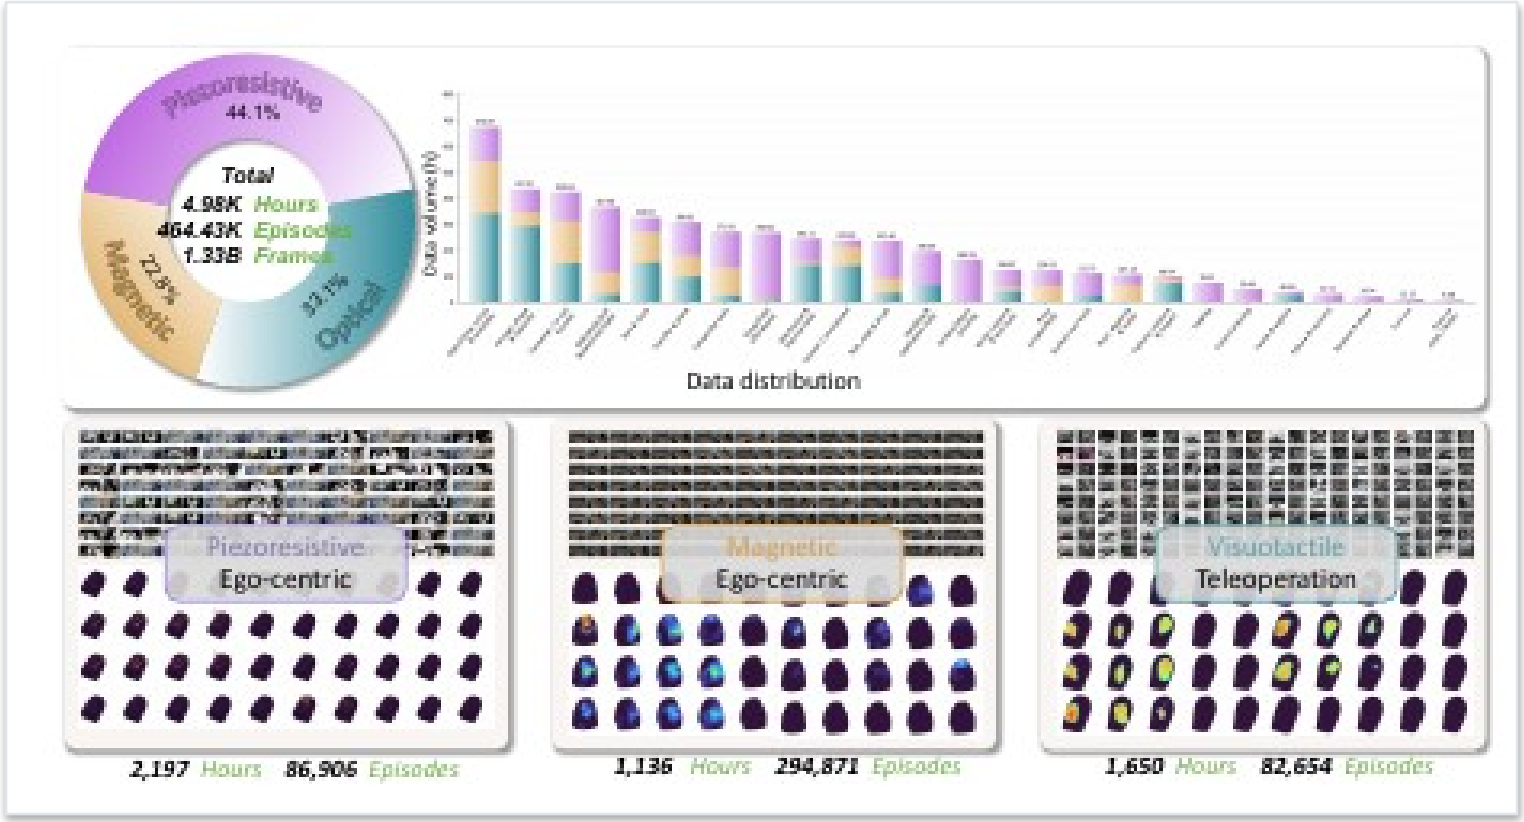

464K
episodes

1.33B
帧

24
类任务，多数类别跨来源覆盖

仅类别标签
无力 / 位置 / 时序标注 → 自监督

Tactile-JEPA： 在潜空间预测被遮挡 taxel 的表征，而不重建信号

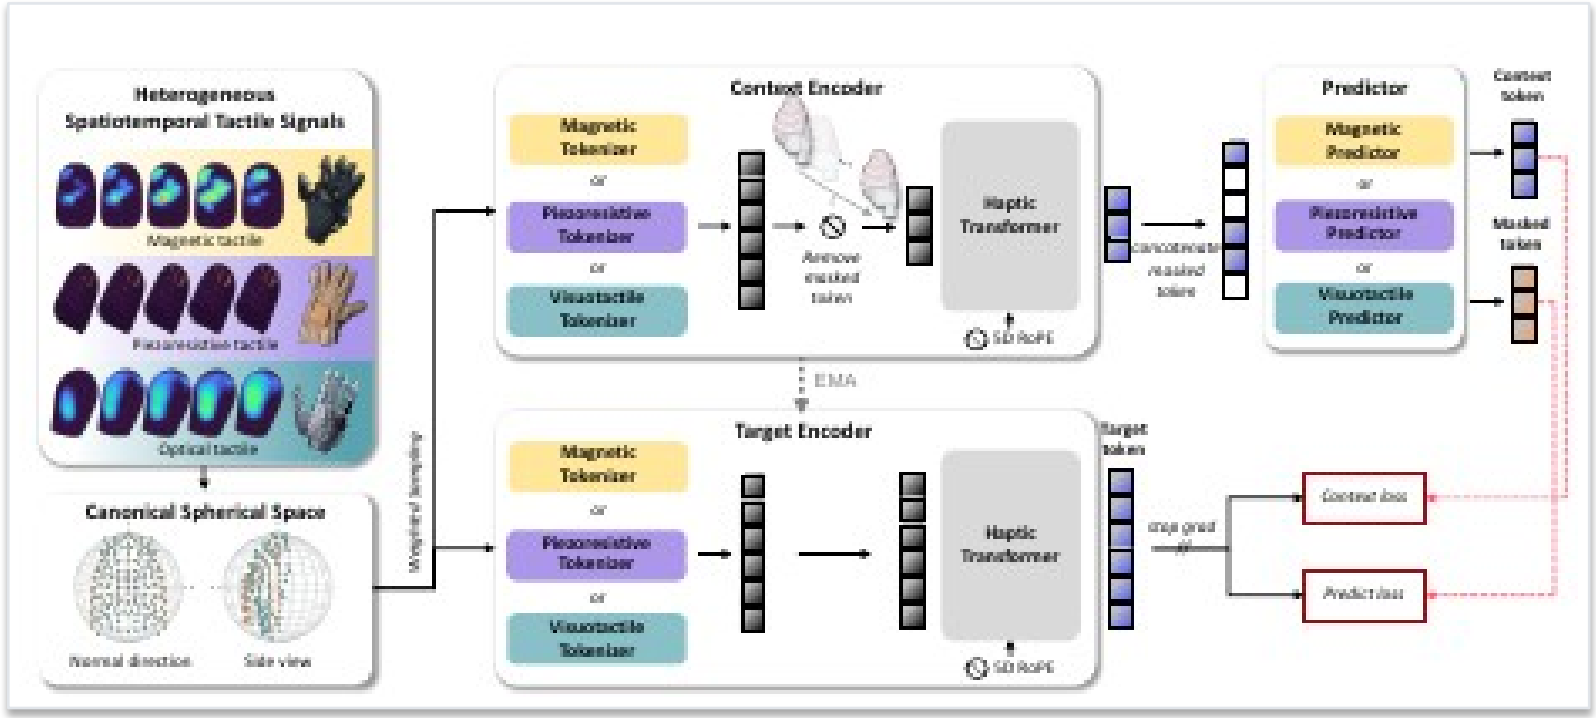

① 统一输入

taxel → 标准指尖空间坐标； 5D 地址 (t, 手指 , x, y, z) 仅经 5D RoPE 进入注意力；幅值按量程归一化。

② 两端专用、中间共享

磁 / 压阻 / 视触觉各一个 2 层 MLP tokenizer （每 token = 1 taxel × 2 帧 × 3 通道）； 共享 12 层 HaT 。

③ 潜空间目标

目标 = EMA 编码器 4 个深度特征拼接； L1 损失：遮挡位置 + 0.5 × 可见位置；下游冻结 EMA 编码器。

四个关键设计让 JEPA 适配稀疏、异构的触觉信号

标准指尖空间

按最小包围球把每个传感器的指尖几何缩放、平移到单位半径参考球： $p = \alpha\tilde{p} + b$ 。
模型看到“手指上的位置”，而非传感器数组下标。

5D RoPE 位置编码

地址（时间窗，手指，3D 坐标）每轴占注意力头维度的一段。
无需固定 token 数或传感器专用位置表 → 新布局可直接输入。

遮挡率 warm-up

整段时间遮挡同一批 taxel，最终遮挡率 80% 。
稀疏接触被全部遮住概率 ≈ 0.8^k → 早期梯度爆炸；前 300 步 40%→80% （共 20 万步）。

布局无关增强

多分辨率：磁 24–96 taxel/ 指，视触觉 32/96/200 虚拟 taxel 。
位置扰动： $\|\delta_i\| \leqslant 0.5 \cdot d_i$ （最近邻距离），两分支共享。

模型规模 Tiny： 5.46M 参数（宽 192） Small： 21.76M 参数（宽 384） 均为 12 层 Transformer，预训练 200,000 步

冻结表征即可读出接触物理，在未见过的传感器上同样大幅领先 FTP-1

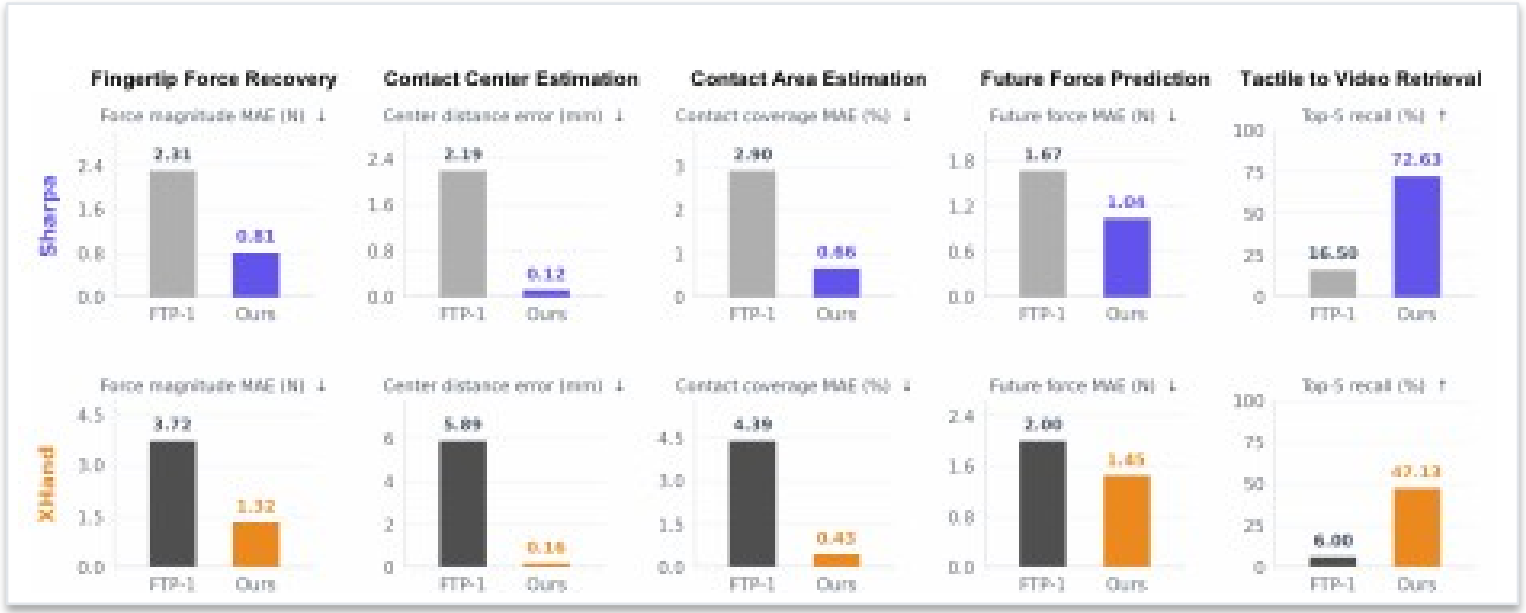

0.16 mm

XHand1 （未见）接触中心误差
FTP-1： 5.89 mm

47.1% vs 6.0%

XHand1 触觉→视频检索 R@5

0.81 N vs 2.31 N

Sharpa 指尖力恢复 MAE
（量程 0–30 N ）

协议：冻结 EMA 目标编码器 + 每任务一个注意力探针； FTP-1 冻结骨干但每个传感器 / 任务训练专用适配器。灰： FTP-1 ； 彩： Ours-Small （ 5K h ）。

数据越多表征越好，但模型容量必须同步增长

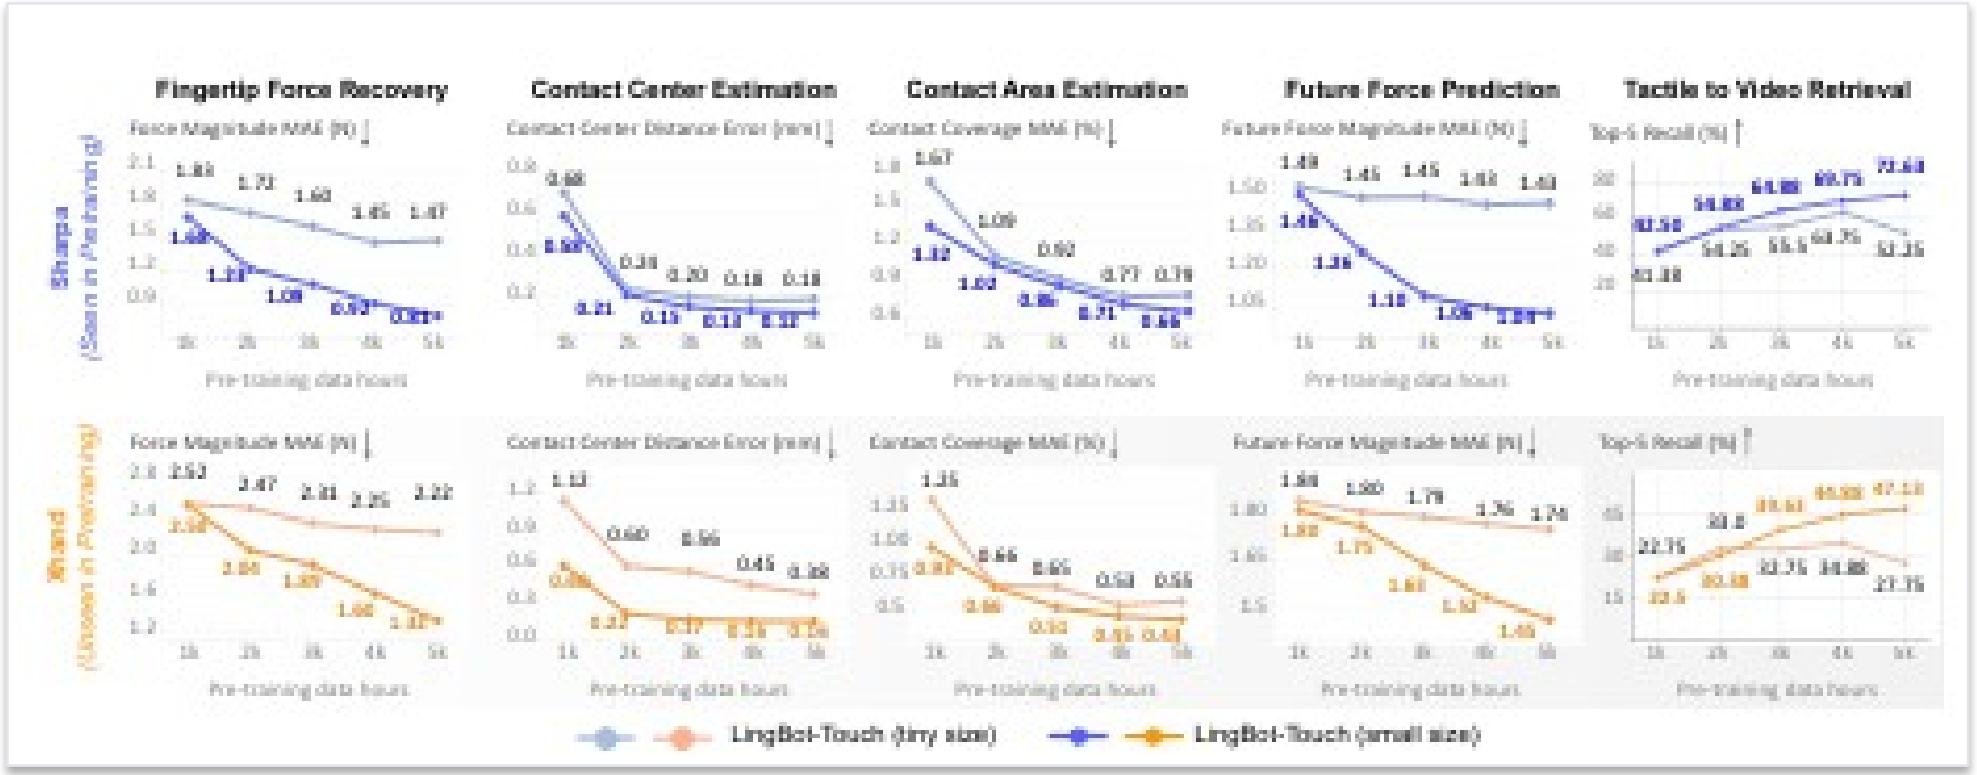

Sharpa （见过） • Small

力 MAE 1.68 → 0.81 N
检索 R@5 42.5% → 72.6%

XHand1 （未见） • Small

力 MAE 2.50 → 1.32 N
检索 R@5 22.5% → 47.1%

Tiny 的天花板

约 4K h 后趋平， 5K h 时两只手的检索召回都回落 → 容量需随数据扩展

多源互补：力与动态可跨传感原理迁移，空间精度依赖本传感器布局

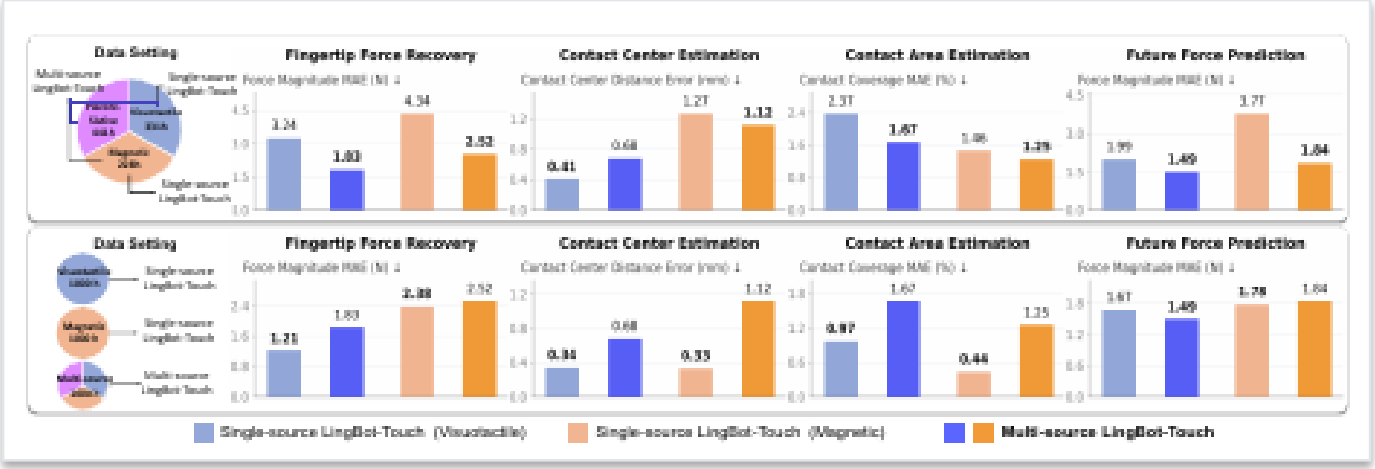

固定本源数据，再加入他源 → 7/8 改善

- 磁（XHand1 测）：力 4.34 → 2.52 N；未来力 3.77 → 1.84 N
- 视触觉：接触中心 0.41 → 0.68 mm （唯一变差）

固定 1,000 h 总预算 → 单源 7/8 胜

- 接触中心：视触觉 0.34 vs 0.68 mm；磁 0.33 vs 1.12 mm
- 时间预测差距小，视触觉未来力多源反而更好（1.49 vs 1.67 N）

启示：用“最易采集”的传感器扩数据，部署到任意手上；代价是一部分空间精度。

实验 · 目标函数对比

潜空间预测胜过信号重建： VAE 甚至数据越多越差

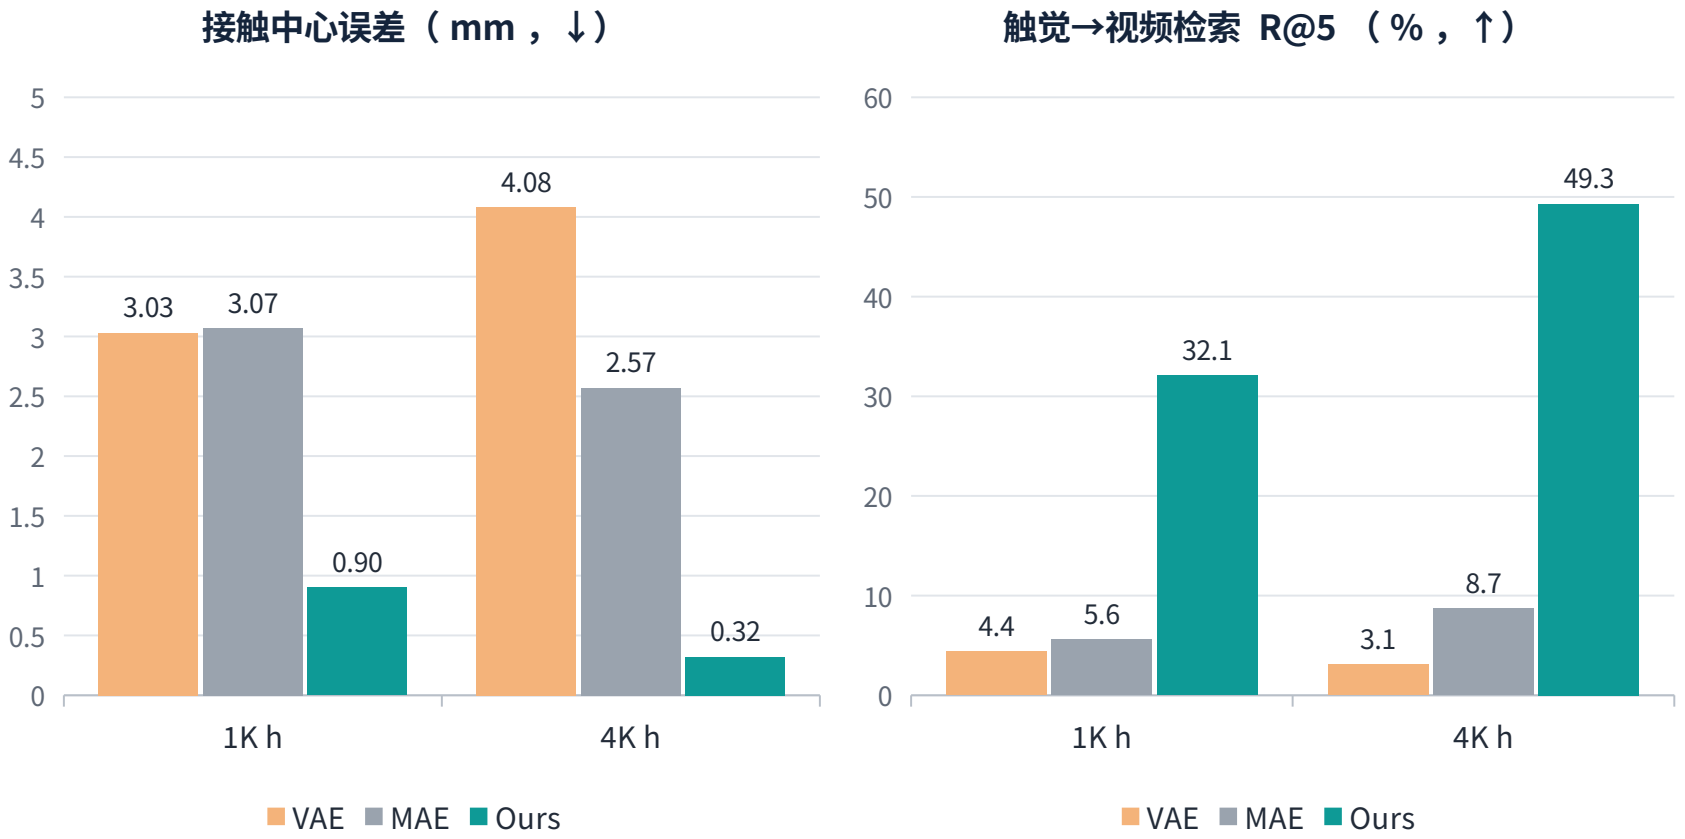

真机 · LingBot-VLA 5 任务

无触觉	55.9%
+ VAE (4K)	≈65%
+ MAE (4K)	≈62%
+ Ours (4K)	≈81%

VAE / MAE 在叠杯分离、擦盘子上低于无触觉基线； Ours 在 5 个任务上均最高。

三者参数量相同（5.46M）、 MAE 与 Ours 遮挡率同为 80%。真机均值为按 Fig.9 柱状读数计算的近似值（基线 55.9% 与 Fig.13 一致）。

消融：遮挡率、 EMA 速度、增强与分组接口决定成败

设计维度	最佳设置	关键证据（ Sharpa Wave ，冻结探测）
空间遮挡率	80%	5 项指标全部最佳； 90% → 检索 R@5 仅 14.4% ， 80% → 35.4%
时间遮挡范围	整段 clip	[100,100]% 在 4/5 项最佳：禁止从相邻帧“抄”被遮 taxel
数据增强	值 + 位置	检索 25.6% （无增强）→ 37.1%；接触中心 0.64 → 0.24 mm
clip / tubelet	32 帧 · 2–4 帧 /token	≈1.07 s @30Hz； 1 帧或 8 帧 tubelet 明显更差
EMA 动量	0.999 → 1.0	0.998 → 1.0 坍塌：力 MAE > 7 N ，检索 ≈ 1%
tokenizer / 预测器	分组 / 分组路由	全共享 → 分组：接触中心 2.32 → 0.70 mm ， 5 项全优
训练目标	target + context	加入 context loss 近似中性（ 3 项略好， 2 项略差）

注：消融均为 Tiny 、 1K h 子集、 100 epochs；默认配置（ 90% 遮挡等）≠ 最终配置，只宜块内比较。

潜空间保留接触的连续演化，而不仅是“有 / 无接触”

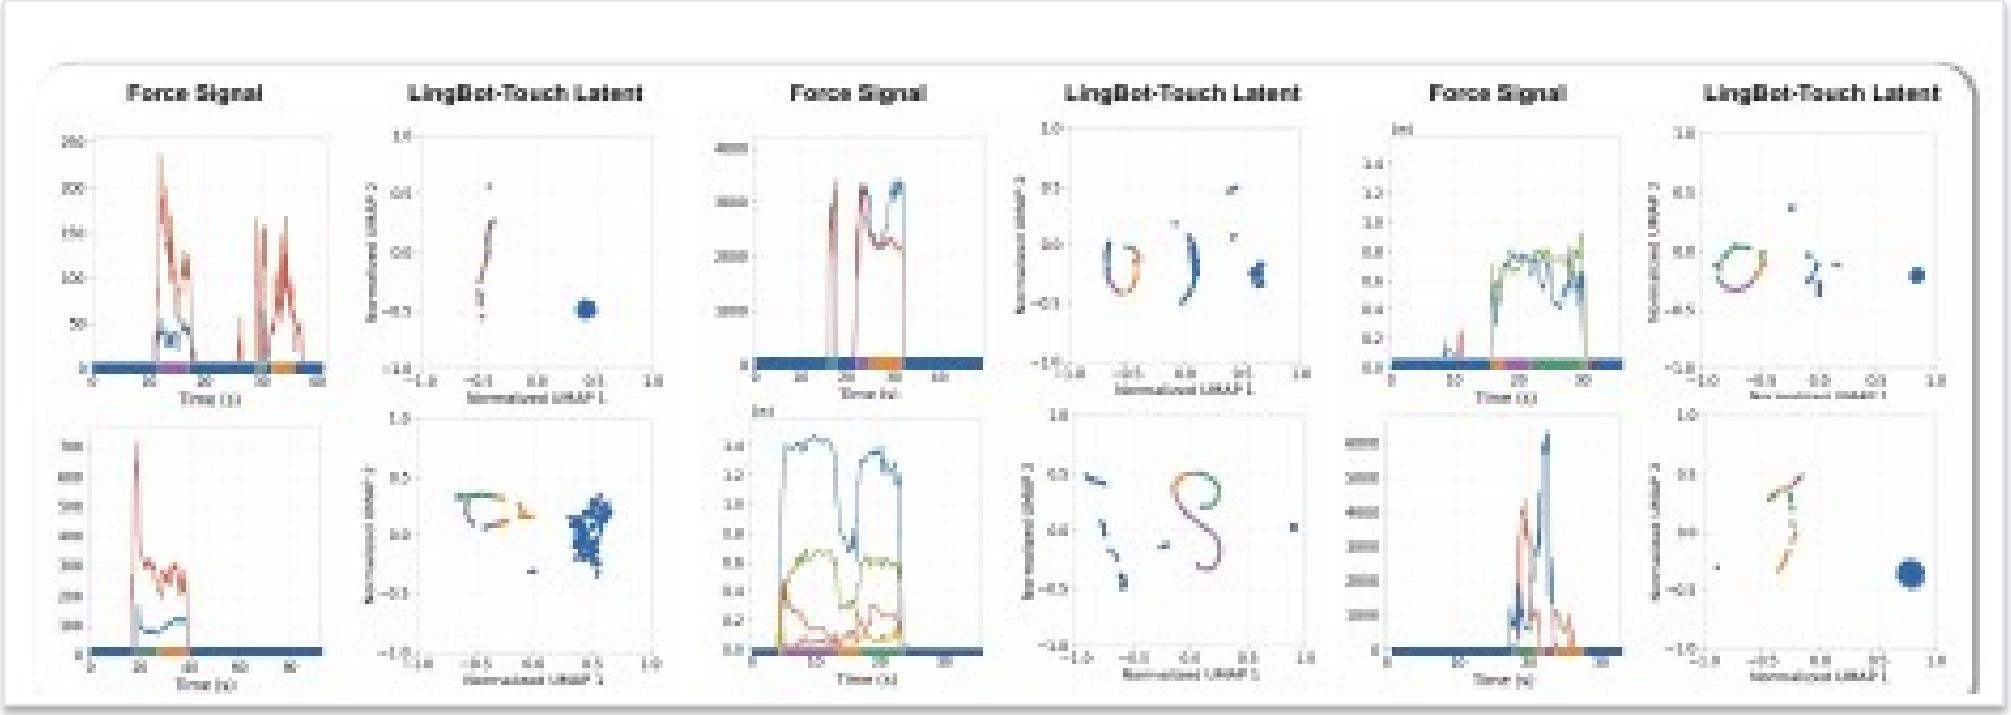

无接触 → 一个紧凑簇

输入近乎为零，聚成一团并远离其他点（符合预期）。

接触 → 连续有序的曲线

力增强、减弱、在手指间重新分布时，相邻窗口在曲线上相邻；不同阶段占据曲线不同段。

对策略的意义

表征编码了接触“进行到哪一步”，策略可据此把握抓握力度与动作时机。

冻结触觉 token 让四类策略在 26 个真机任务上平均提升 14–25 个百分点

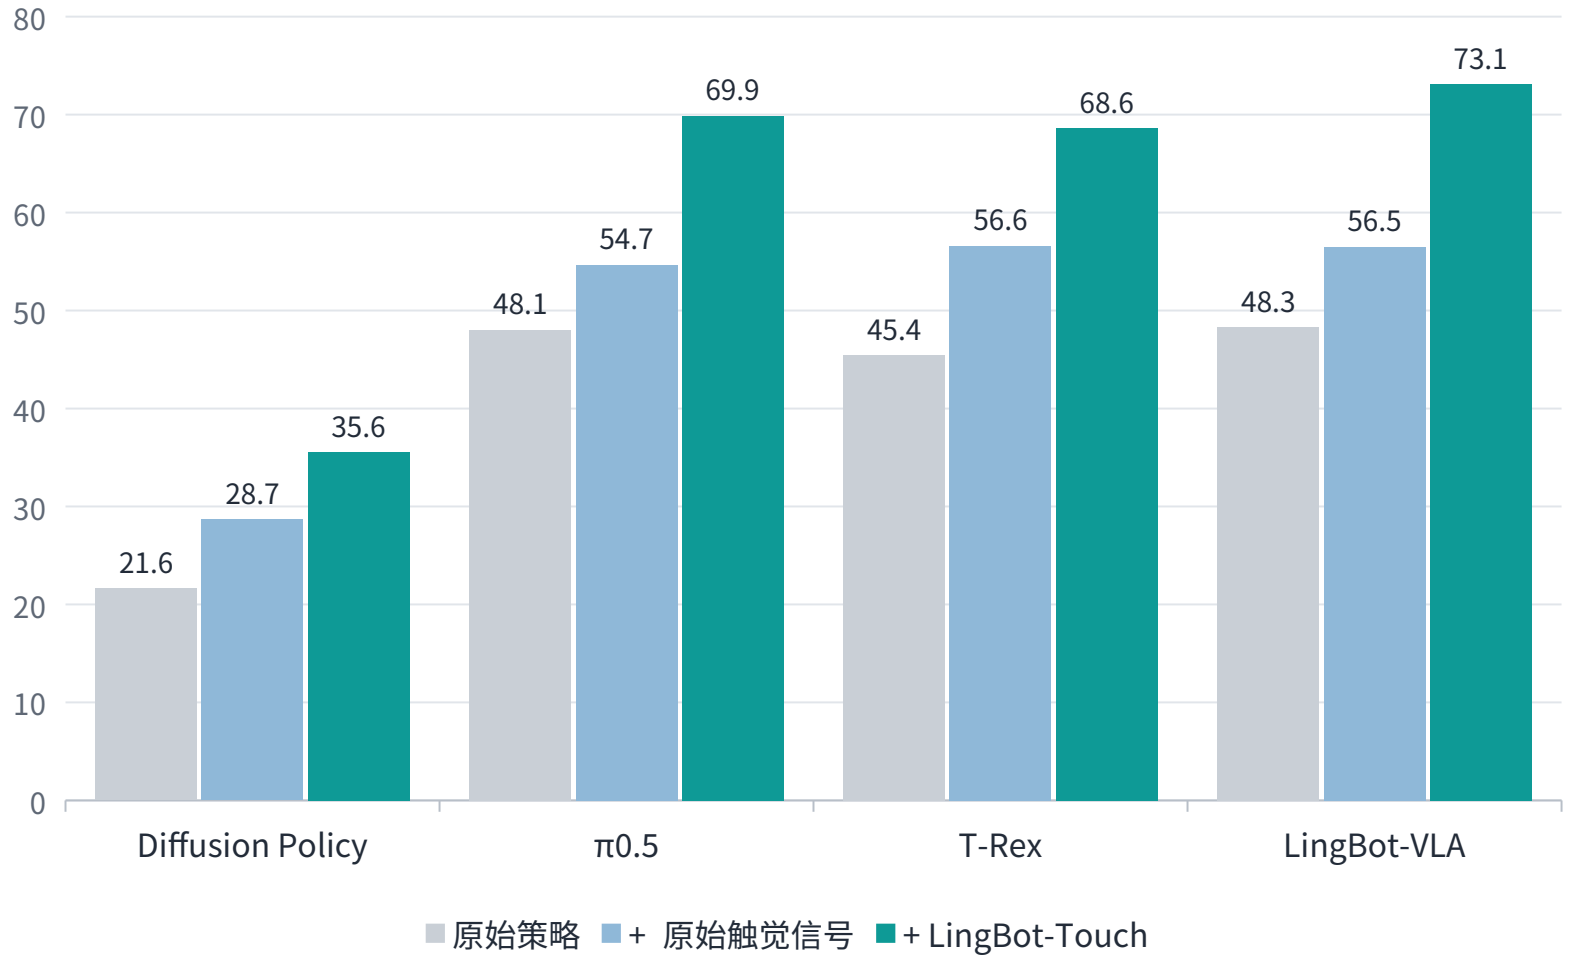

89 / 104

任务 × 策略组合中 Ours 为三种配置最佳；99 个不低于原始策略

≤ 一半

原始信号的提升幅度（+7.0 / 6.6 / 8.2 / 11.2 pp），且 22/104 组合反而变差

< 0.16%

编码器占 T-Rex / π0.5 / LingBot-VLA 参数比例

提升来自“懂触觉”：视觉判断不了的那一步，以及未见过的手

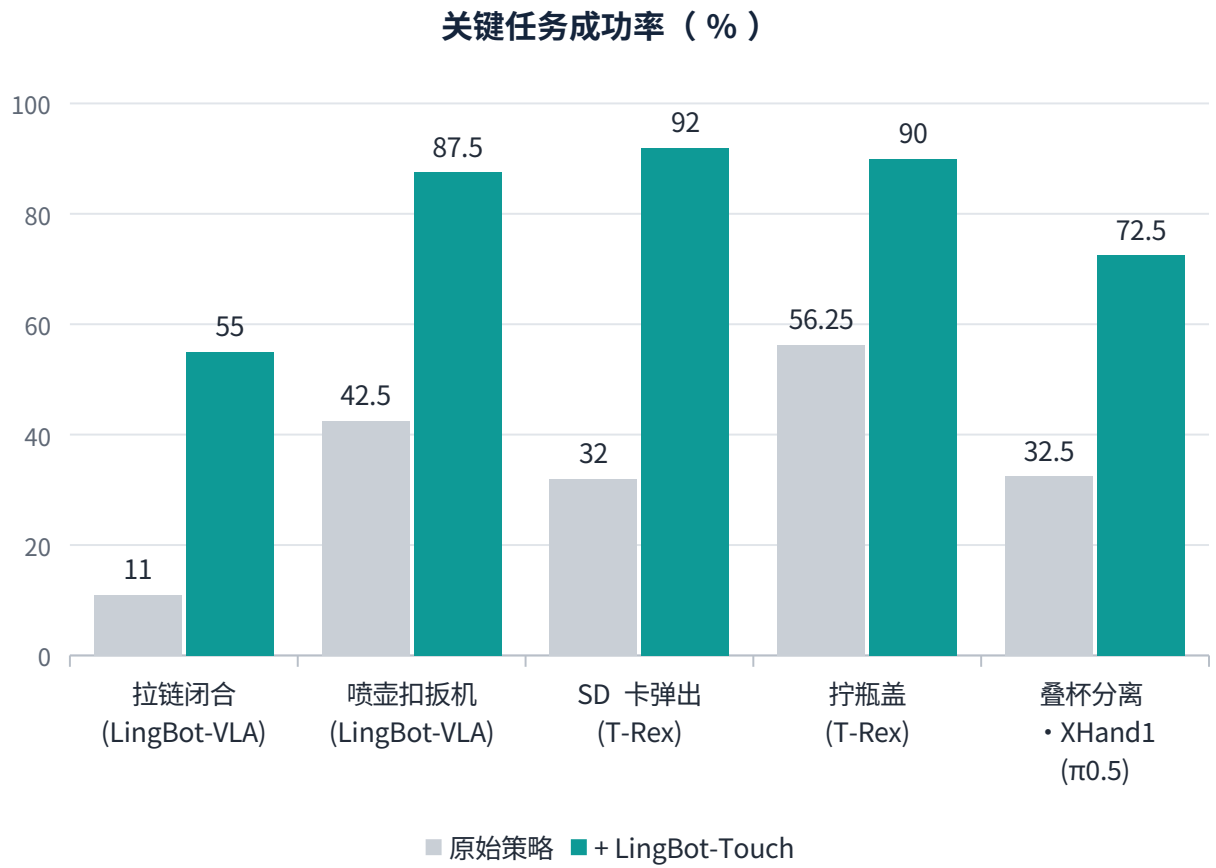

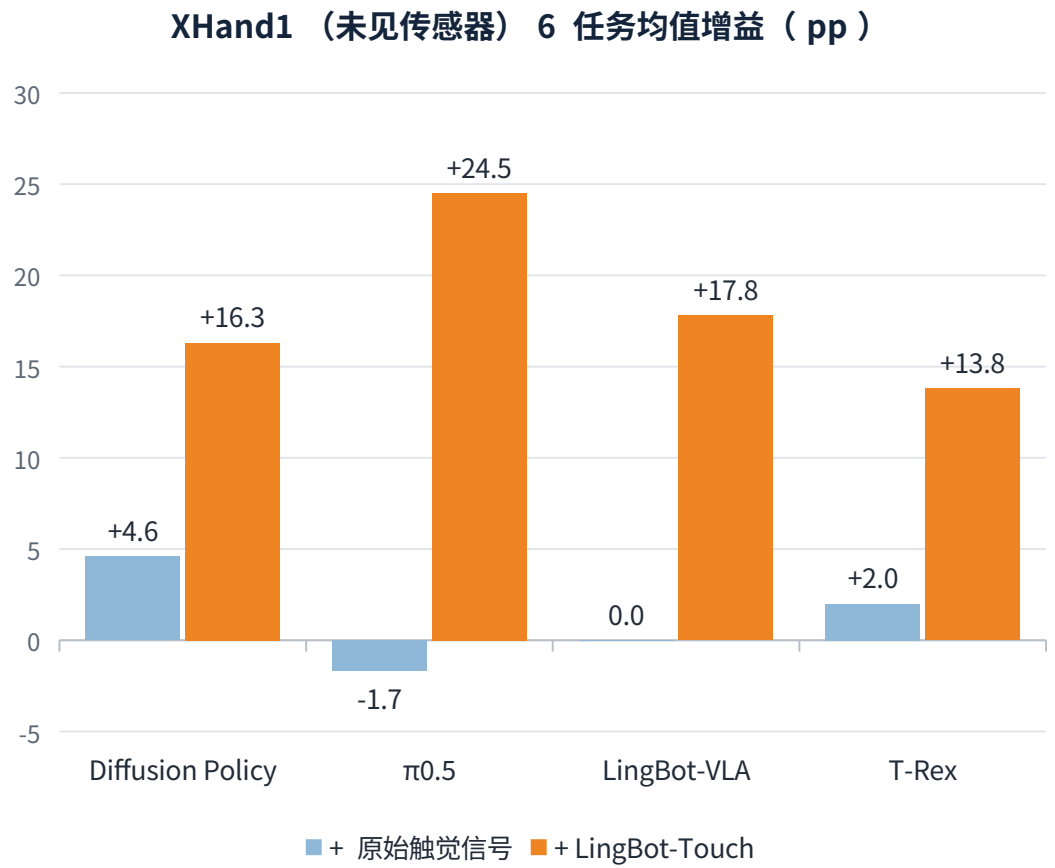

并非处处更好：Ours 在 104 组中有 9 组低于“原始信号”配置（其中 5 组为 Diffusion Policy），5 组低于原始策略。

仿真 RL：预训练触觉特征把平均成功率从 21% 提到 69%，且种子间更稳定

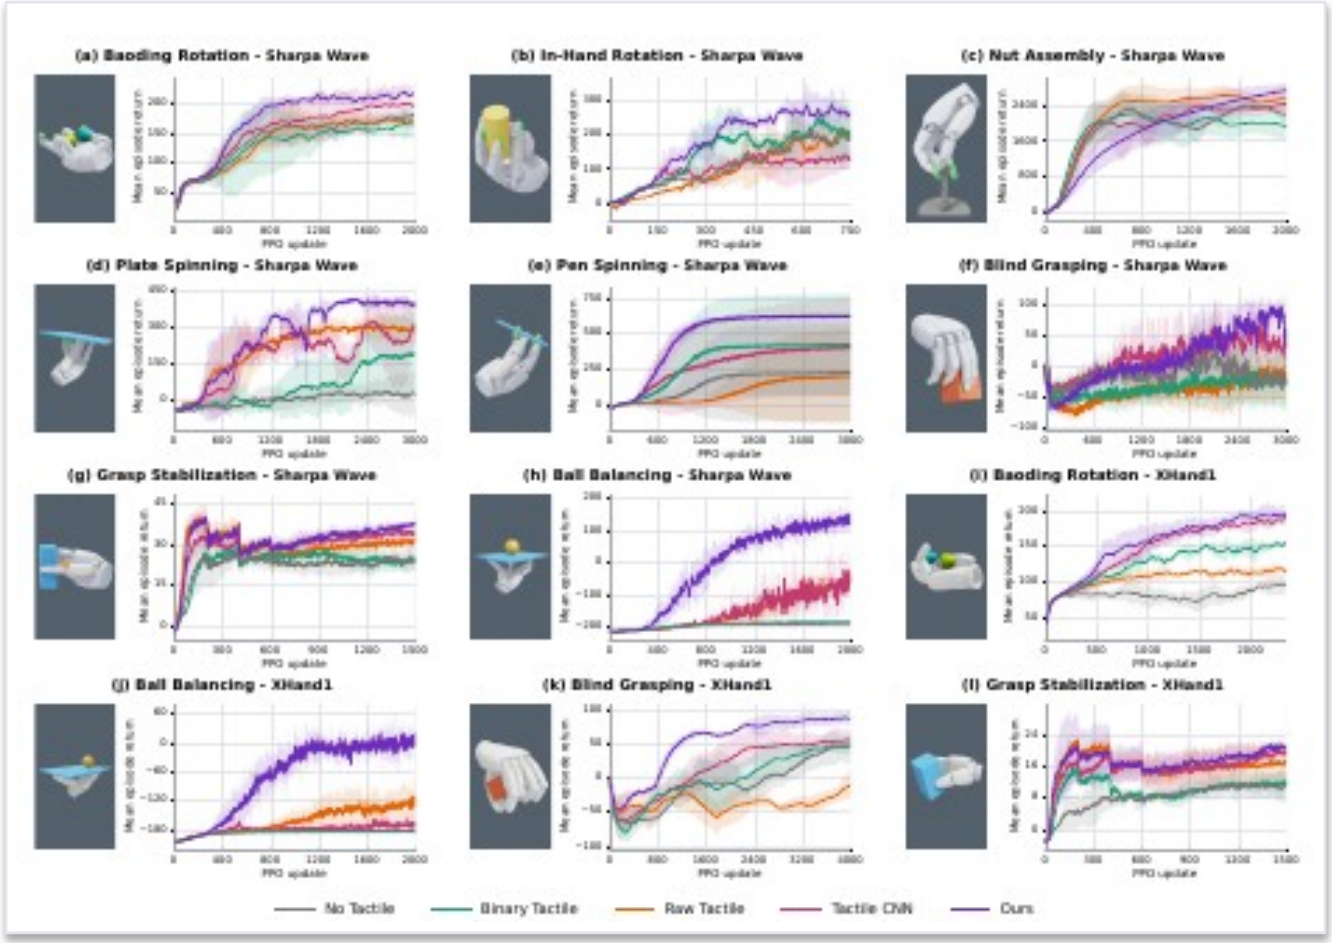

97.1%

转笔（次优 64.2%）
转盘 97.4%（次优 82.9%）

σ ⩽ 9.2

Ours 种子间标准差（均值 3.9）；其他方法最高达 55

探测排名能转化为策略收益：预训练数据越多， VLA 越强

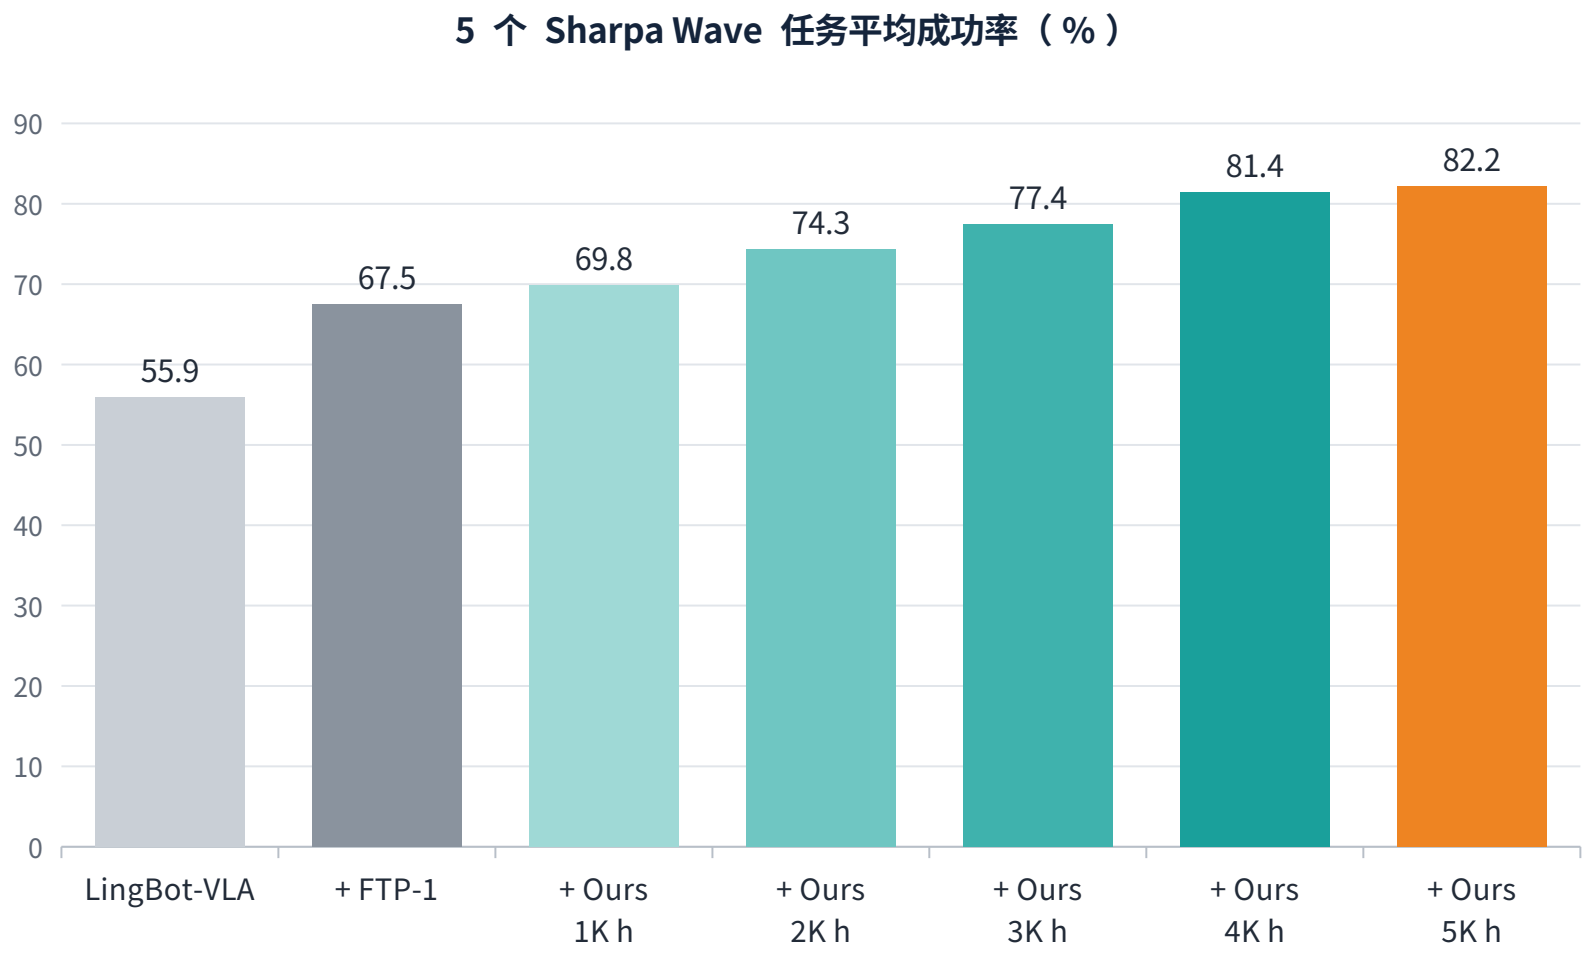

+26.3 pp

5K h 编码器带来的提升（55.9% → 82.2%）

单调上升

每多 1K h 与任务无关的触觉数据，策略都更好

67.5%

换用 FTP-1 编码器；叠杯分离 95→85、擦盘子 74→67 低于基线

批判性视角

局限与审慎解读：“未见传感器”仍是同原理，探测标签源自信号本身

作者承认的局限

- 硬件形态有限：真机与仿真仍需更多种灵巧手验证
- 传感器覆盖：电容式因数据质量未达标而缺席预训练
- 只覆盖指尖：手掌及手指其他部位的接触代表性不足，需扩展到全手
- 固定预算下多源混合会损失部分空间精度

解读者关注点

- “未见传感器” XHand1 仍是磁原理，复用磁 tokenizer 且需已知几何；对全新传感原理的迁移未验证
- 接触中心 / 面积 / 力标签由传感器读数导出 → 探测衡量“信息保留”，而非外部物理真值
- 对比 FTP-1：其适配器需用约 2 h 下游数据从零训练，条件不完全对等
- 真机每任务 20 次、按分项计分、无置信区间；原始触觉基线接入细节较少
- 口径差异：消融默认配置 ≠ 最终配置； Tab.2 用 4K h 编码器、Fig.13 用 5K h
- 开源仅含推理代码、少量样例与 Tiny/Small 权重，预训练难以复现

总结

三点启示：表征属于接触、收益来自表征、规模可跨传感器累积

01

表征属于接触，而非传感器

标准指尖空间 + 5D RoPE + 布局增强 → 同一编码器零参数服务未见过的手，并全面优于带专用适配器的 FTP-1 。

02

收益来自表征，而非模态

冻结 token 同时提升 IL 、 VLA 、 RL ； 直接拼原始触觉信号最多一半收益，且常常有害 → 触觉应以预训练语义 token 进入策略。

03

规模可跨传感器累积

力与动态跨原理迁移：用最易采集的手套扩数据、部署到任意手；潜空间预测随数据持续提升，重建目标停滞甚至退化。