论文解读 · 具身智能 / 世界动作模型

SWAM：用跨模态对齐扩展世界动作模型

SWAM: Scaling World Action Models with Cross-Modal Alignment

Yu Zhou*, Xinyuan Xia*, Xuankun Yang*, Yinghao Yang*, … , Cewu Lu, Yanwei Li †
上海交通大学 · 上海创智学院 · Noematrix · 西湖大学 · 同济大学

arXiv 2611.12870 · 首次提交 2026-11-09 · 数据 / 代码 / 权重已公开

一句话总结

保住视频预训练的语言–视频对齐，是 WAM 泛化的关键

SWAM 用约 **4.7 万小时**多源数据（通用视频、第一人称视频、 UMI 手持夹爪示教、机器人示教），系统研究世界动作模型在学习动作时如何保住语言–视频对齐；得到的配方是：**细致的子任务 caption + UMI 动作标签 + Ego/UMI 1:1 混合 + 动作分支只经视频读取语言**，在未见场景下显著优于现有 VLA 与 WAM 。

47k h

多源预训练数据

General / Ego / UMI / Robot 四类

61.56%

RoboTwin Hard (C2R) SR

比最强基线 OpenWAM 高 12.86 pt

88.10%

RoboTwin Easy (C2C) SR

与 OpenWAM 89.30% 基本持平

40.00%

真机 Hard SR

3 任务平均； OpenWAM 为 23.33%

研究动机

加入动作学习，可能会破坏视频预训练获得的语言–视频对齐

什么是 WAM

World Action Model： 以语言为条件，联合预测未来视频与未来动作，把视频模型学到的视觉 / 动力学先验接到机器人控制上。

已有工作的盲点

Motus 、 LingBot-VA 、 Fast-WAM 、 OpenWAM 等主要改进架构与训练机制，默认视频预训练带来的语言–视频对齐是“现成的基础”。

本文的问题

引入动作监督后，如何保住语言–视频先验、并建立语言–视频–动作对应？不同数据来源与监督形式各起什么作用？

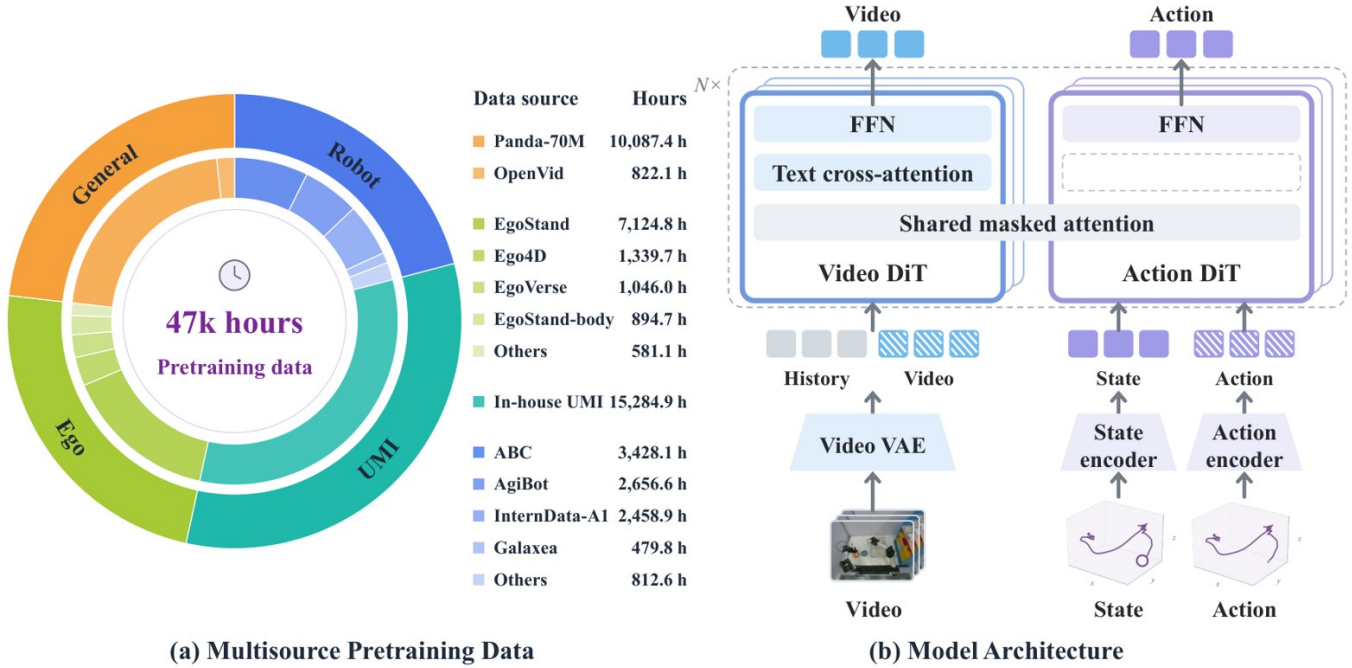

(a) Multisource Pretraining Data (b) Model Architecture

Fig. 2： (a) 47k 小时多源预训练数据； (b) 视频 / 动作双分支经共享掩码注意力连接

研究框架

三层对齐 + 规模扩展：四组实验各自给出一条可操作的结论

01

语言–视频对齐

caption 怎么写?

细节越丰富、带场景 / 光照、按子任务对齐 → Hard SR 47.20 → 55.04

02

语言–视频–动作对齐

人类示教的动作有用吗?

UMI 动作标签覆盖 0% → 100%， Hard SR 46.72 → 51.28

03

联合训练

怎么配比、怎么连接?

Ego:UMI = 1:1 最佳；动作分支只经视频读语言 57.36

04

扩展规模

多训是否更好?

RoboTwin Hard： 0 h 34.56 → 67.5k h 59.60；真机 Hard SR 在 90k h 达 48.89

数据

47k 小时、四类经验： UMI 占比最大，提供可扩展的动作监督

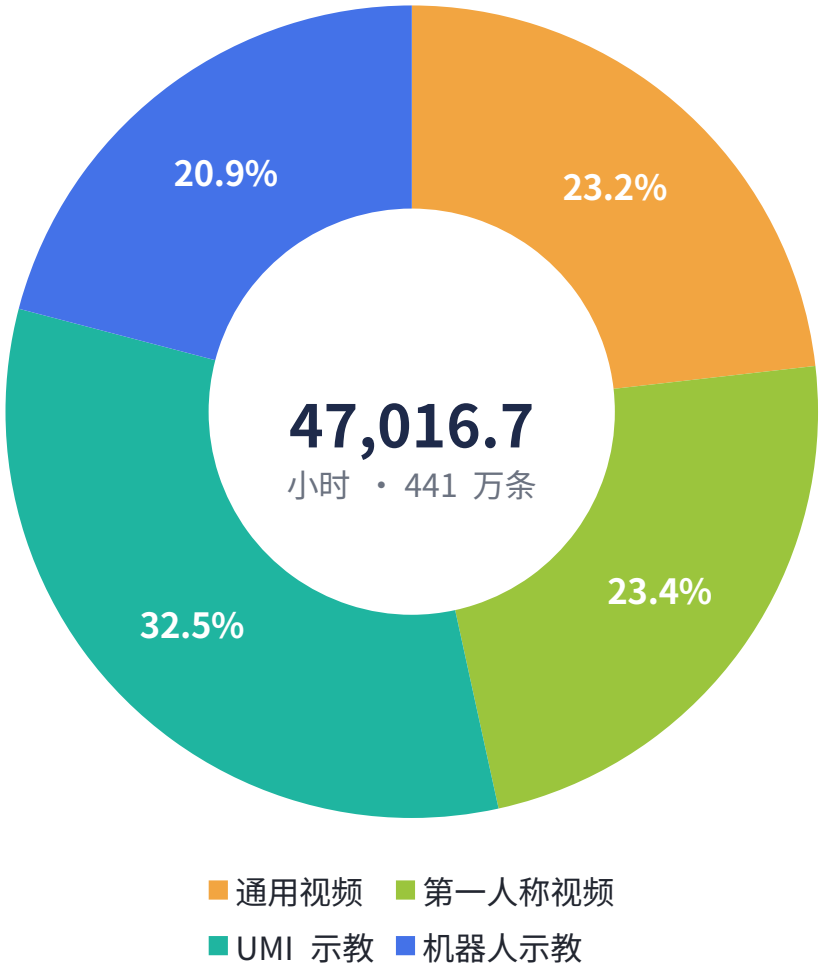

通用视频

10,909.6 h

Panda-70M 、 OpenVid

语言–视频：通用视觉动力学

第一人称视频

10,986.3 h

EgoSuite 、 Ego4D 、 EgoVerse

语言–视频：人手交互

UMI 示教（自采）

15,284.9 h

RoboPocket： 手机 + 手持自适应夹爪， 41.2 万条

语言–视频–动作：可扩展的人类操作经验

机器人示教

9,836.0 h

ABC 、 AgiBot 、 InternData-A1 、 Galaxea 、 RoboCOIN 、 RoboMIND

语言–视频–动作：直接但有限的机器人经验

数据处理

质检 → 统一格式 → 子任务切分 → 三级 caption + 场景 / 光照

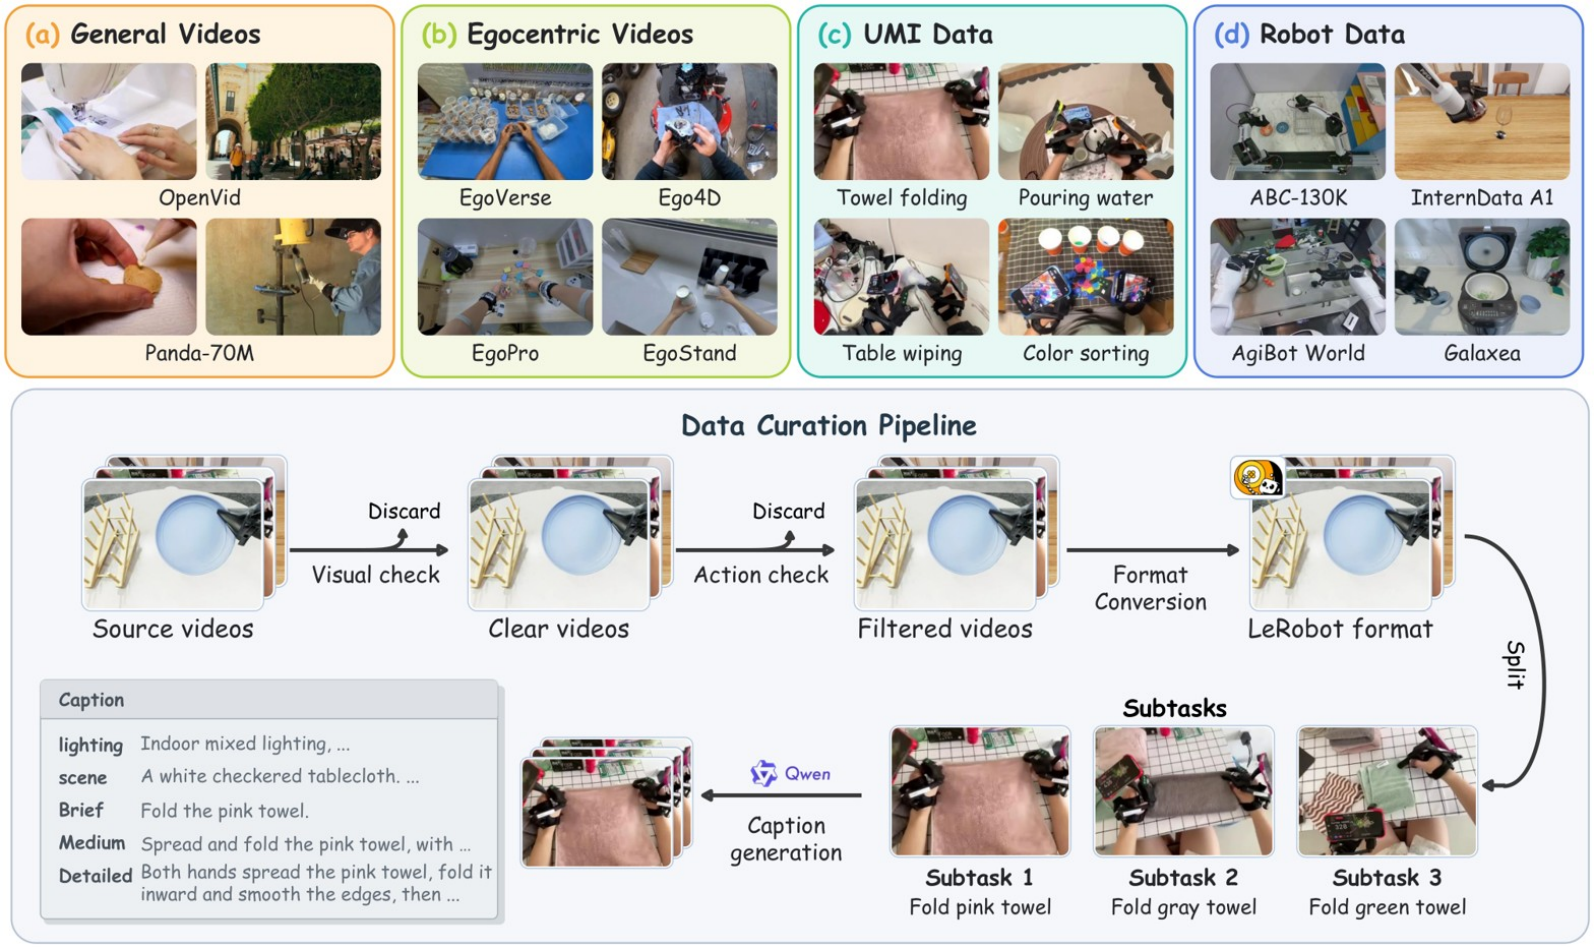

1 视觉质检

VLM 过滤动画、静态画面、模糊、过暗、遮挡、无有效动作片段

2 动作质检

NaN/ 非法四元数；关节 |q|>20 rad 、相邻帧跳变 >1 rad ； 末端位移 >0.2 m 或旋转 >90°

3 统一格式

LeRobot 2.1； 16 维双臂末端（xyz + wxyz 四元数 + 夹爪），各源 q1/q99 归一化

4 子任务切分

Qwen 3.8 Max 按动作意图切分为不重叠子任务（机器人数据整段视为一个子任务）

5 Caption

Seed 2.1 Pro 生成 Brief / Medium / Detailed 三级描述 + 场景 + 光照

模型

MoT 双流 WAM：信息只从视频流向动作，动作分支不直接读文本

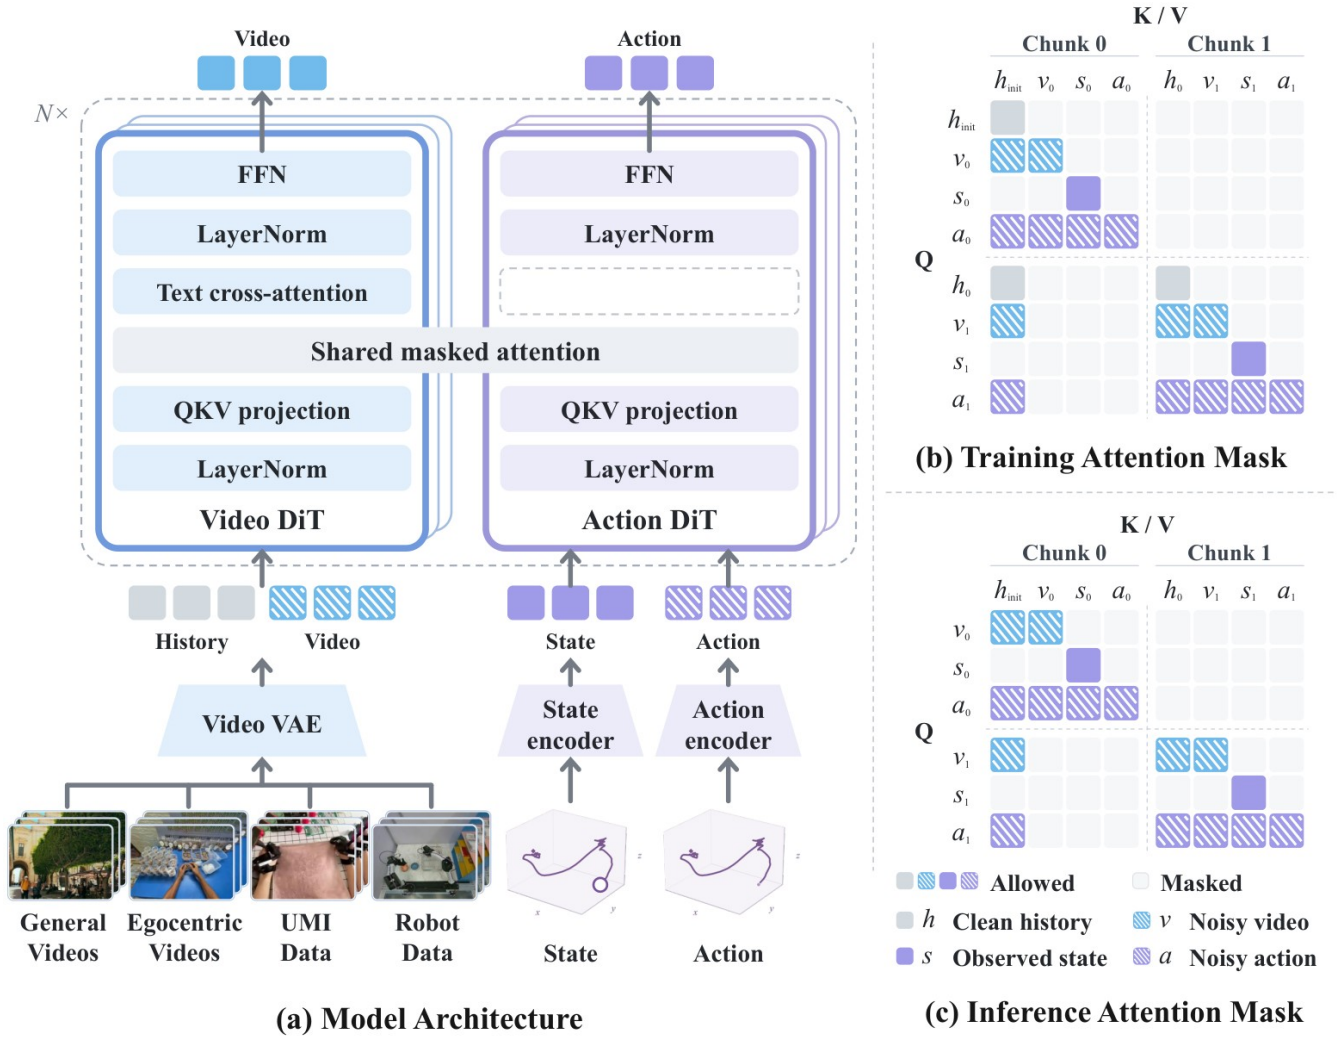

双流 MoT

视频 DiT 由 Wan2.2-TI2V-5B 初始化；动作 DiT（state/action 编码器、Transformer、解码器）随机初始化。

单向共享掩码注意力

动作 token 看历史与当前视频；视频 token 看不到动作 → 无动作标签的视频只训练视频分支。

语言只经视频进入动作

仅视频分支有 text cross-attention，复用预训练建立的语言–视觉对应。

联合 flow matching

L = L_video + L_action （等权）；每 chunk 2 个视频 latent 帧 + 48 步动作，推理逐 chunk 生成。

发现 1 · 语言–视频对齐

caption 越细、带环境信息、按子任务对齐，泛化越好

Ego + UMI 预训练 20k 步，不同 caption 设计

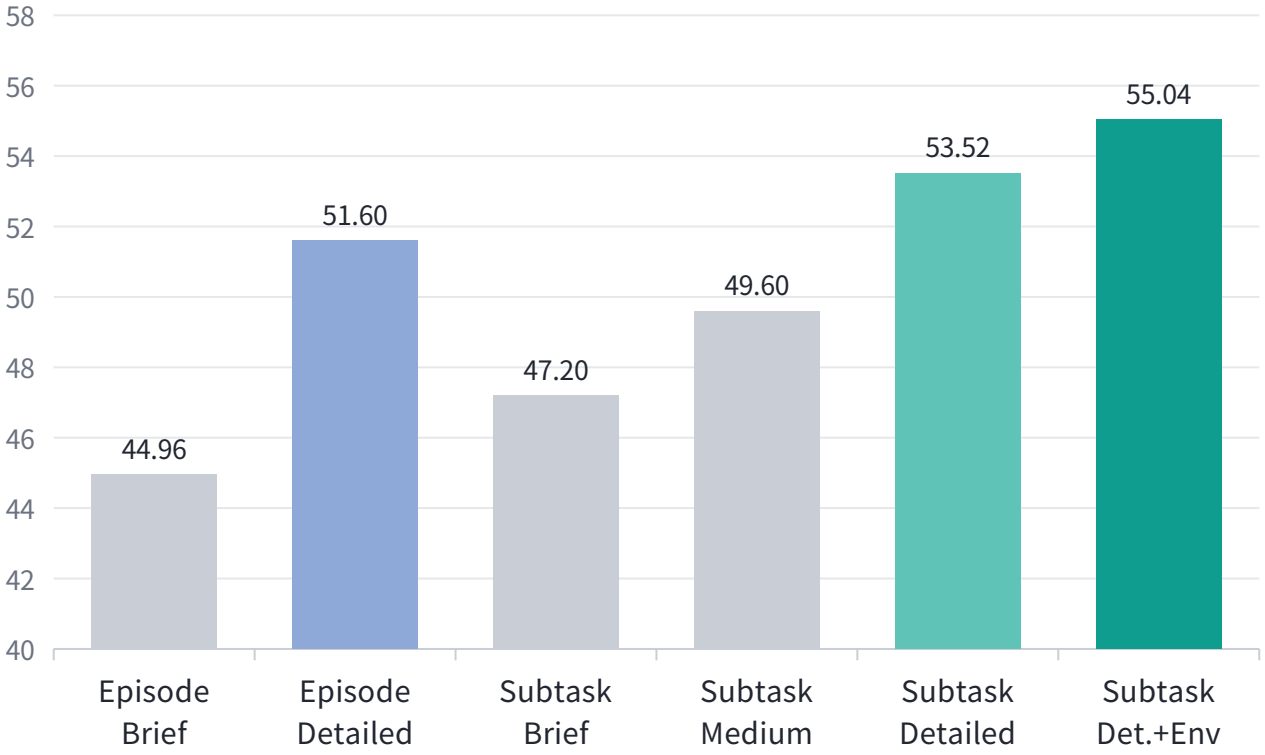

开源机器人数据：重写 caption

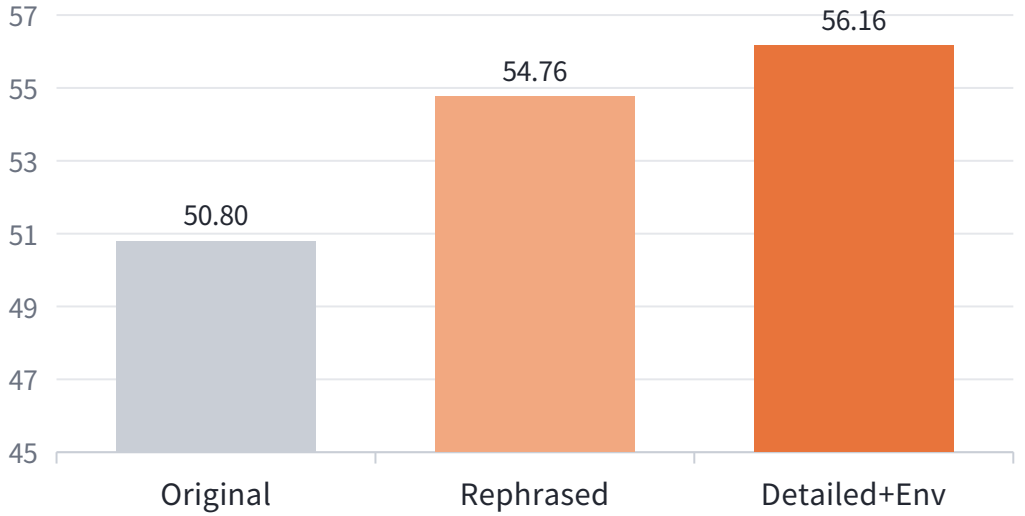

145,430 条轨迹只有 **592** 条任务指令
仅做 100 种同义改写即 +3.96 pt

对齐准确也重要：在轨迹内打乱 Detailed 子任务描述与片段的对应， Hard 53.52 → 52.00 ；**各变体 Easy 差距仅约 1–2 pt ，收益主要体现在泛化。**

发现 2 · 语言–视频–动作对齐

UMI 人类示教的动作标签有效； Ego 与 UMI 1:1 混合最佳

UMI 动作标签覆盖率（视频全部保留）

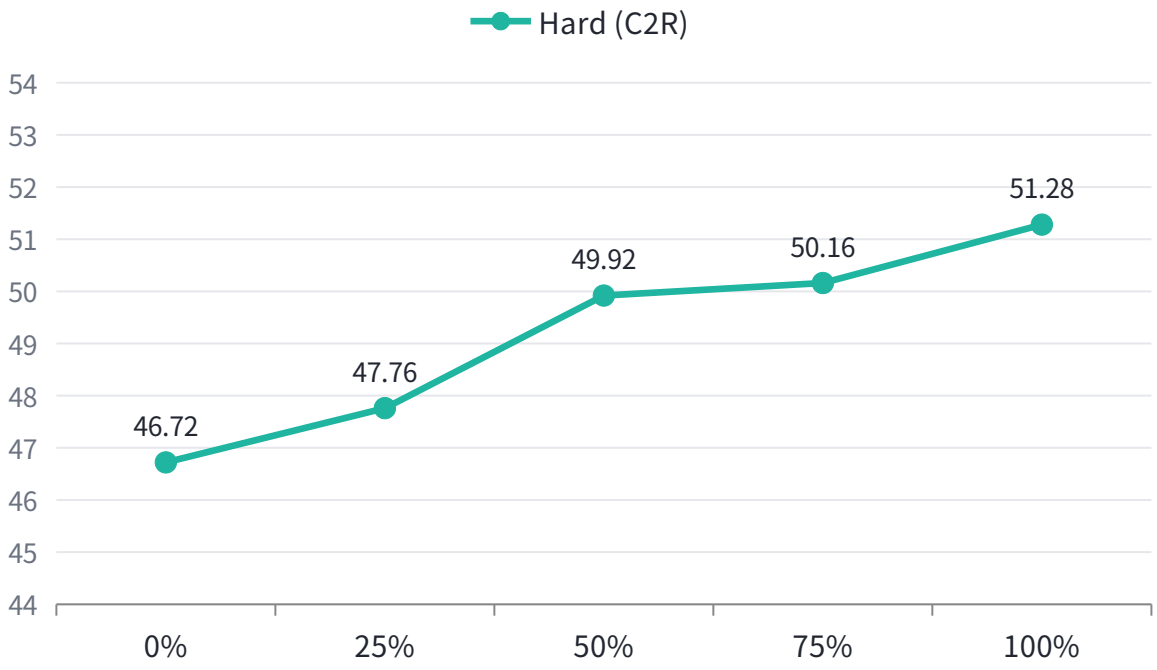

Ego : UMI 采样比（固定 20k 步预算）

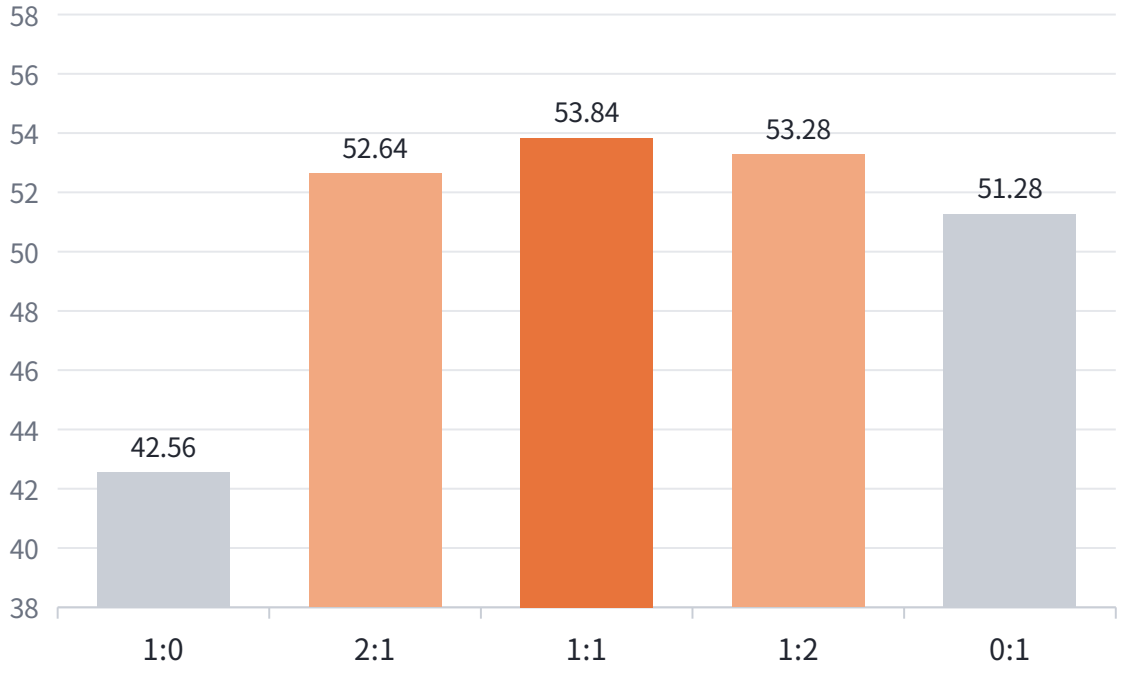

+4.56 pt

动作覆盖 0%→100%， Hard SR 逐级上升； UMI 视觉上与机器人不同，动作监督仍可迁移

混合 > 单源

三种混合比例均优于纯 Ego （42.56）或纯 UMI （51.28）：两者互补

发现 3 · 联合训练

动作只经视频“读”语言；外接视觉编码器反而伤害泛化

架构与语言通路（30k 步多源预训练）

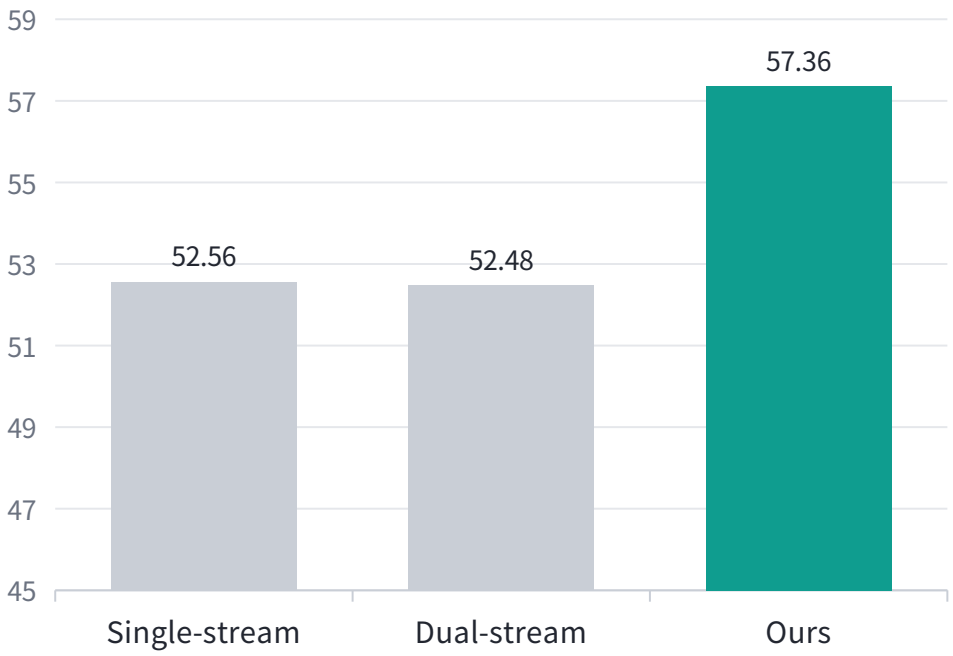

额外图像特征（经 cross-attention 注入）

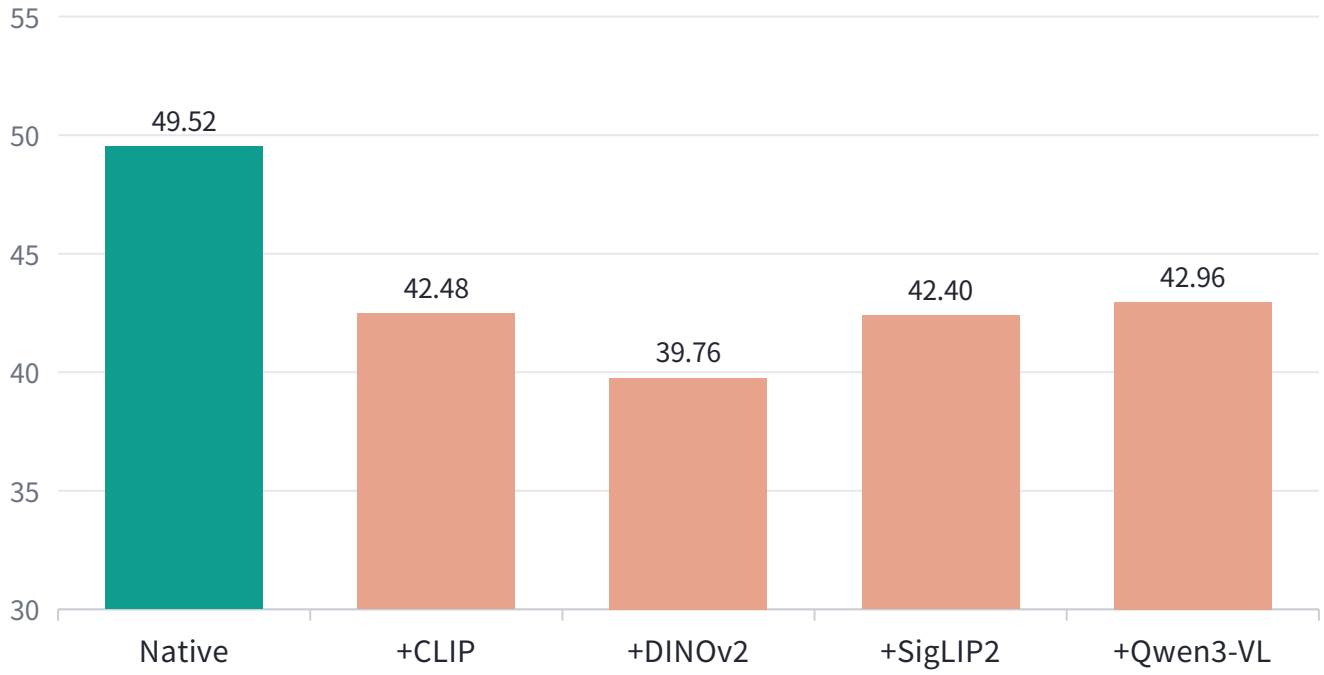

+4.88 pt

动作分支去掉文本 cross-attn 、只经视频获取语言，较标准双流 52.48 → 57.36

−6.6 ~ −9.8 pt

新加的视觉通路未经大规模语言–视频预训练，模型更依赖训练分布内外观线索

+2.64 pt

先用通用视频做 25k 步过渡预训练，再 Ego+UMI 混训： Hard 53.84 → 56.48

发现 4 · 规模扩展

更多预训练带来显著收益，但仿真曲线并非单调

RoboTwin SR （%） vs 训练视频小时

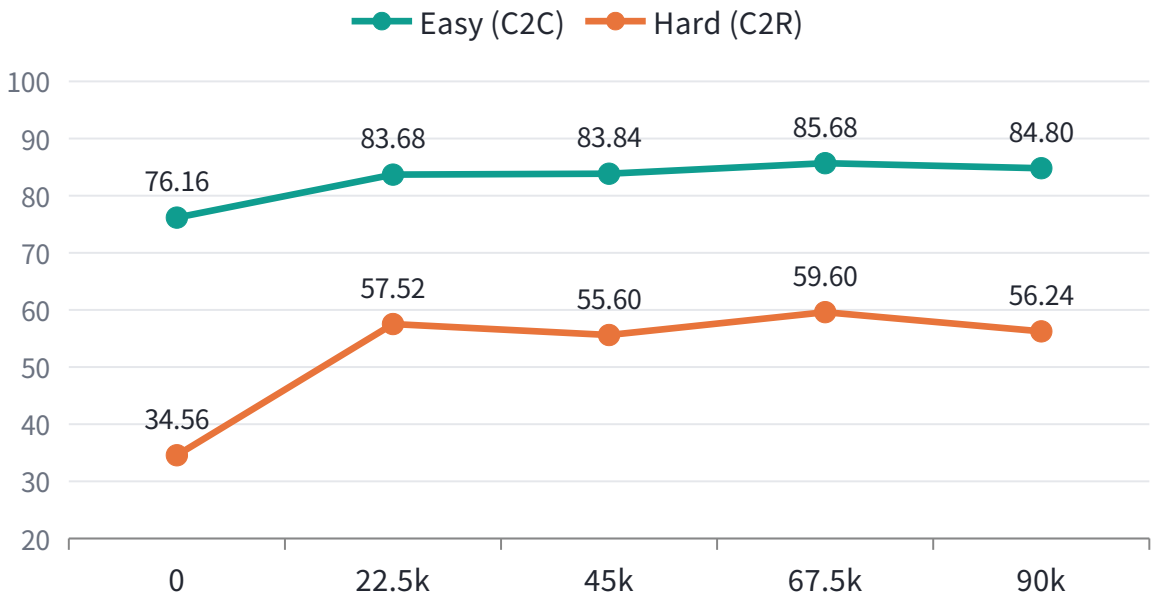

真机 Hard （3 任务平均，%）

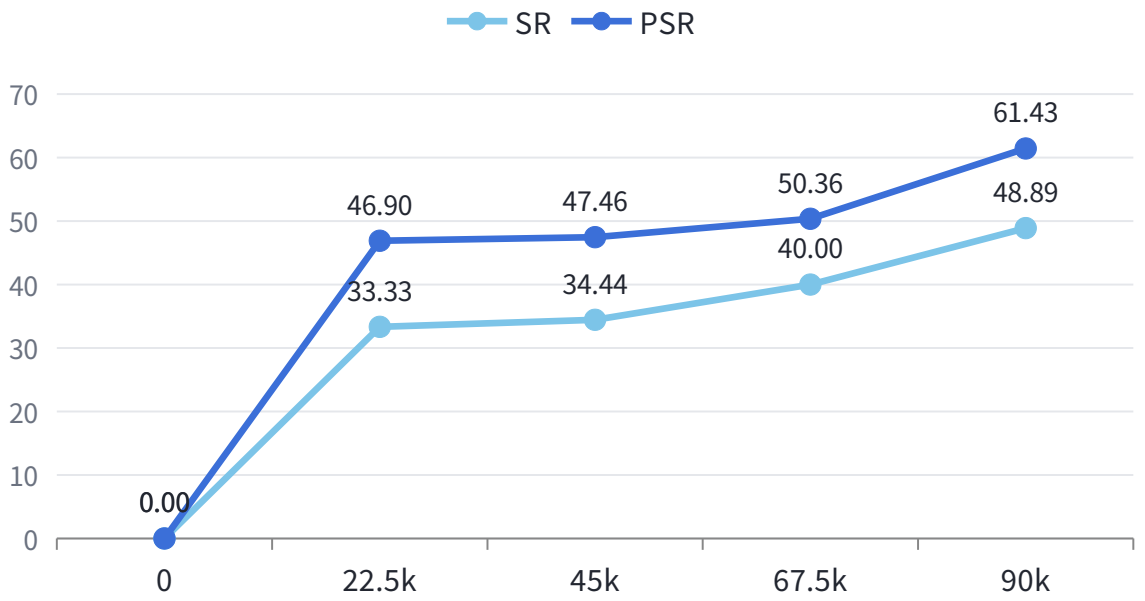

两阶段： Ego+UMI （Stage 1）→ 机器人数据（Stage 2）， RoboTwin Hard

34.56	53.84	59.60	61.52
0k / 0k	20k / 0k	75k / 0k	75k / 25k

值得注意

仿真 Hard 在 67.5k h 达峰（59.60）， 90k h 回落至 56.24；

真机 Easy 平均 SR 57.78 → 48.89 未随规模上升（Fig. 12）。 0 h 模型真机全部失败。

RoboTwin 2.0： Clean 上与 OpenWAM 持平，随机场景领先 12.86 pt

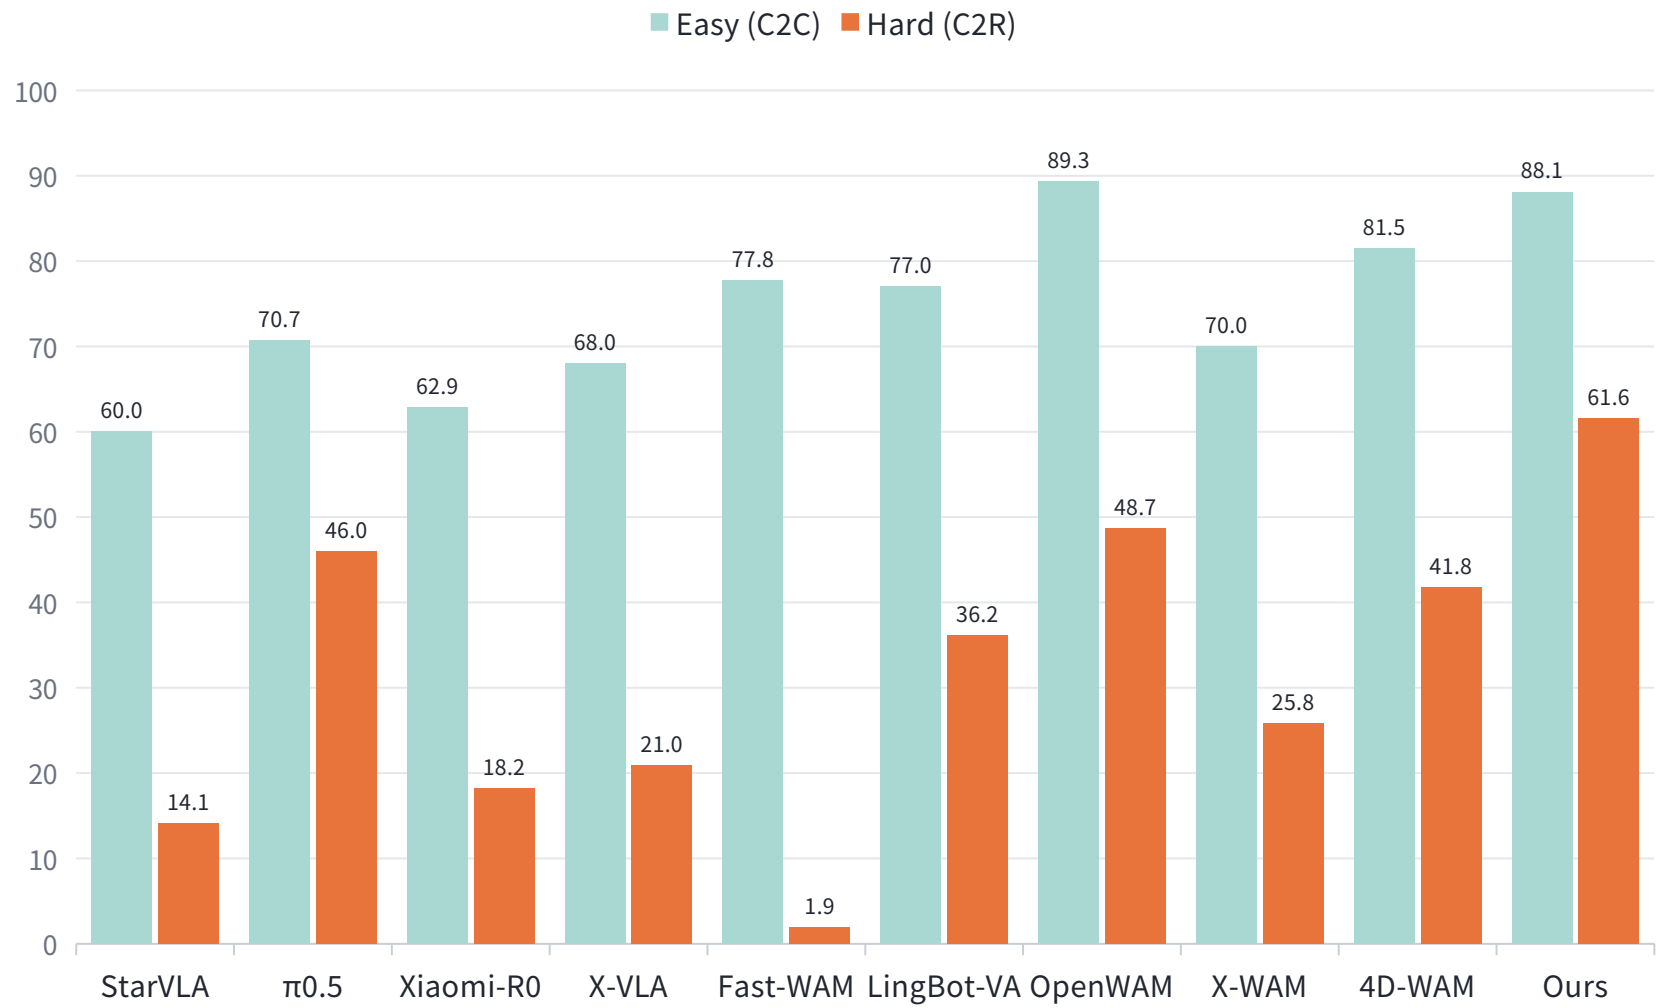

61.56%

Hard SR，全场最高； OpenWAM 48.70%

74.83%

Easy/Hard 平均，最高； OpenWAM 69.00%

77.76 → 1.92

Fast-WAM： Clean 很高、随机场景几乎归零，说明 Clean 分数不代表泛化

真机 Hard 设置： SR 40.00%，比最强基线高 16.67 pt

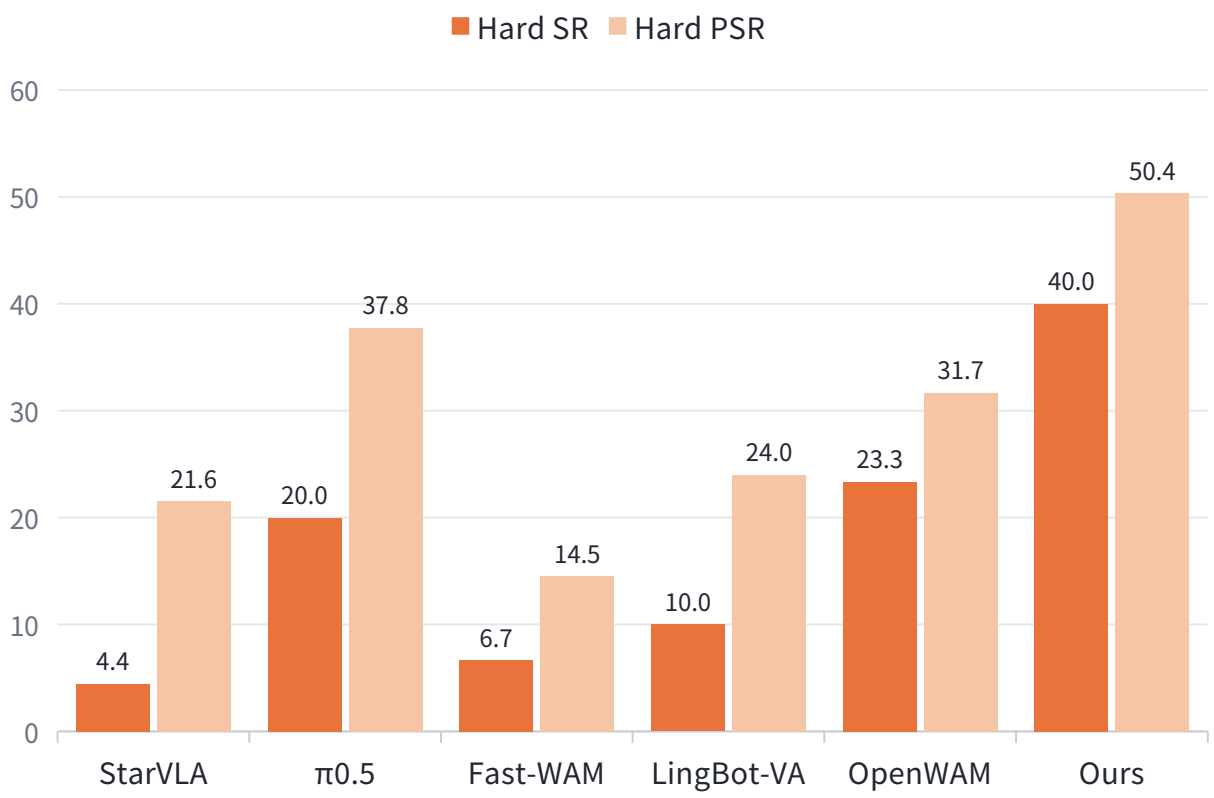

Easy： Ours SR 56.67 最高； PSR 68.57 略低于 π0.5 的 71.87
任务： 叠杯（7 子任务）、叠毛巾（4）、礼物入盒（2）

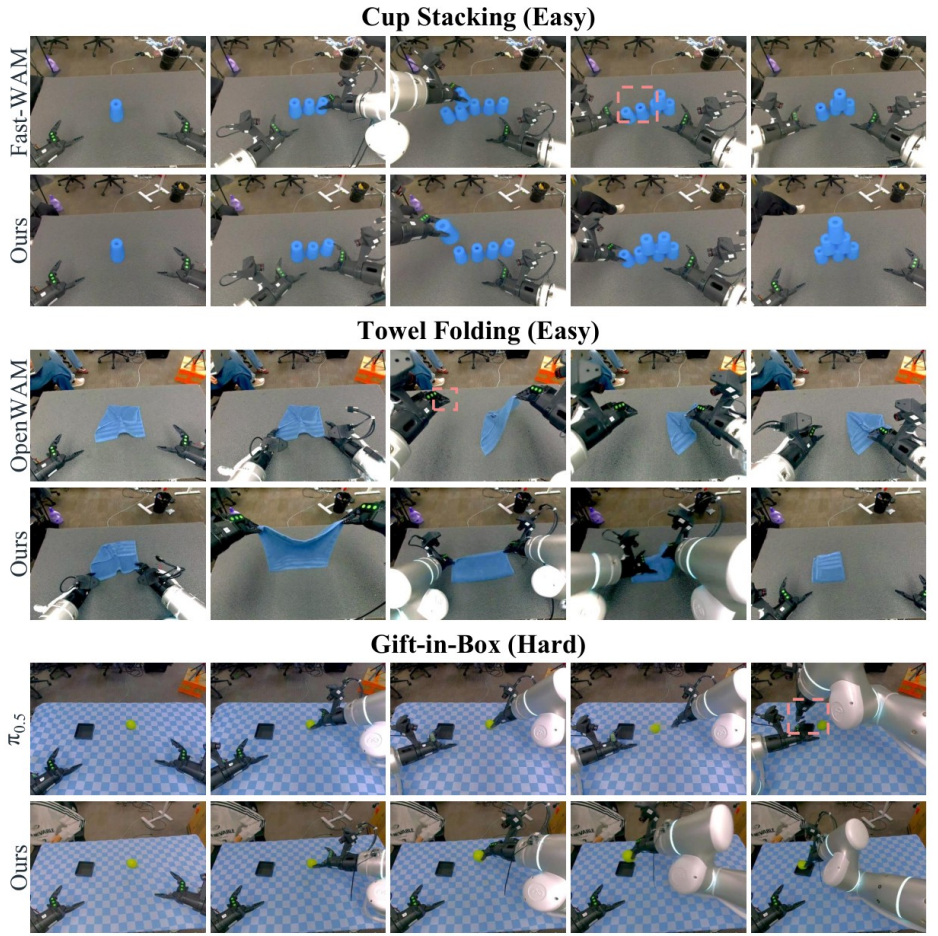

Fig. 7： 基线失败（红框）： 叠杯倒塌 / 毛巾只提一边 / 夹爪松脱

定性结果

学到的技能可迁移到新物体、新容器和新桌面外观

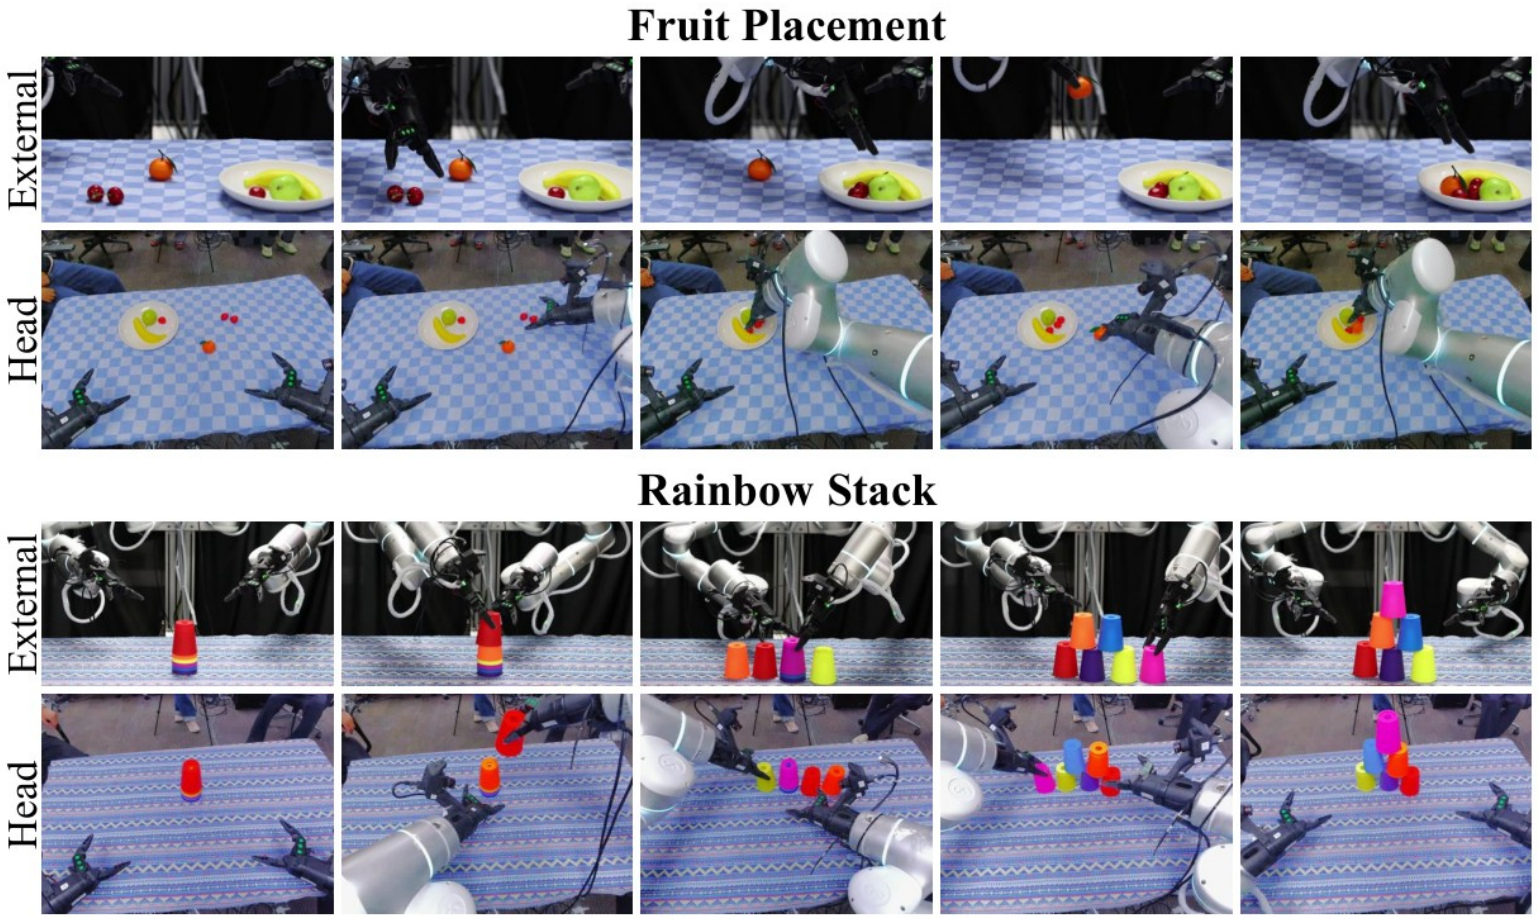

Fruit Placement

由礼物入盒任务的模型完成：场景、被操作物体和目标容器都与训练不同。

Rainbow Stack

叠杯模型只用同色杯、灰色桌布训练，却能在花纹桌布上叠起多色杯。

批判性审视

结论有价值，但部分“规模 / 真机”证据需要谨慎解读

规模并非处处单调

仿真 Hard 67.5k h 达峰 59.60， 90k h 回落 56.24；真机 Easy 平均 SR 57.78 → 48.89 。仅真机 Hard 单调上升。

checkpoint 取舍

Table 11 真机 56.67 / 40.00 与 67.5k h 点吻合，而非 Hard 最高（48.89）的 90k h 点： Easy 与 Hard 之间存在取舍。

真机优势集中在单任务

Fig. 11 目测：叠毛巾 Hard 约 53% 而基线≈ 0；叠杯 Hard 所有方法 SR≈0， Ours PSR 低于 π0.5；礼物入盒差距较小。

消融统计强度有限

消融每任务仅 25 episodes 、无多种子方差；不少差距只有 1–3 pt （如打乱 caption 仅 − 1.52 ）。

曝光与预算混杂

Table 7 增加数据曝光同时增加总步数；UMI 10k→20k 时 Hard 反而 53.84 → 51.20 。

作者自述局限

复杂推理与显式多阶段规划能力有限；历史上下文短，长时程任务受限。

总结与启示

数据与监督设计的作用，不亚于架构创新

1

把 caption 当作核心资产

逐轨迹、子任务级、带场景 / 光照的详细描述，比共享一条任务指令显著更好。

2

用低成本人类示教扩展动作监督

UMI 手持夹爪数据的动作标签可迁移到机器人；与第一人称视频 1:1 混合效果最佳。

3

尽量复用视频基座的通路

动作只经视频读语言；不额外接 CLIP/DINOv2 等视觉编码器；先用通用视频过渡适配。

4

评测要看泛化

Clean 分数接近时，随机场景与真机 Hard 才拉开差距（61.56 vs 48.70； 40.00 vs 23.33）。

开放资源

- 47k 小时多源数据（含 15k 小时自采 UMI）
- 训练代码
- 模型权重

后续方向（作者）

- 记忆机制
- 分层规划

谢谢！欢迎讨论