论文解读 · arXiv 2611.13028

GTAGym

Real AAA Game Tasks Environment for Evaluation and Reinforcement Learning

把 GTA V 主线任务变成可自动判分、可批量生成的评测与 RL 环境

Jiajun Chen, Shicheng Fang, Jiahao Lu, Yuxin Wang †, Xipeng Qiu †
上海创智学院 · 复旦大学（OpenMOSS） · 2026-11-09

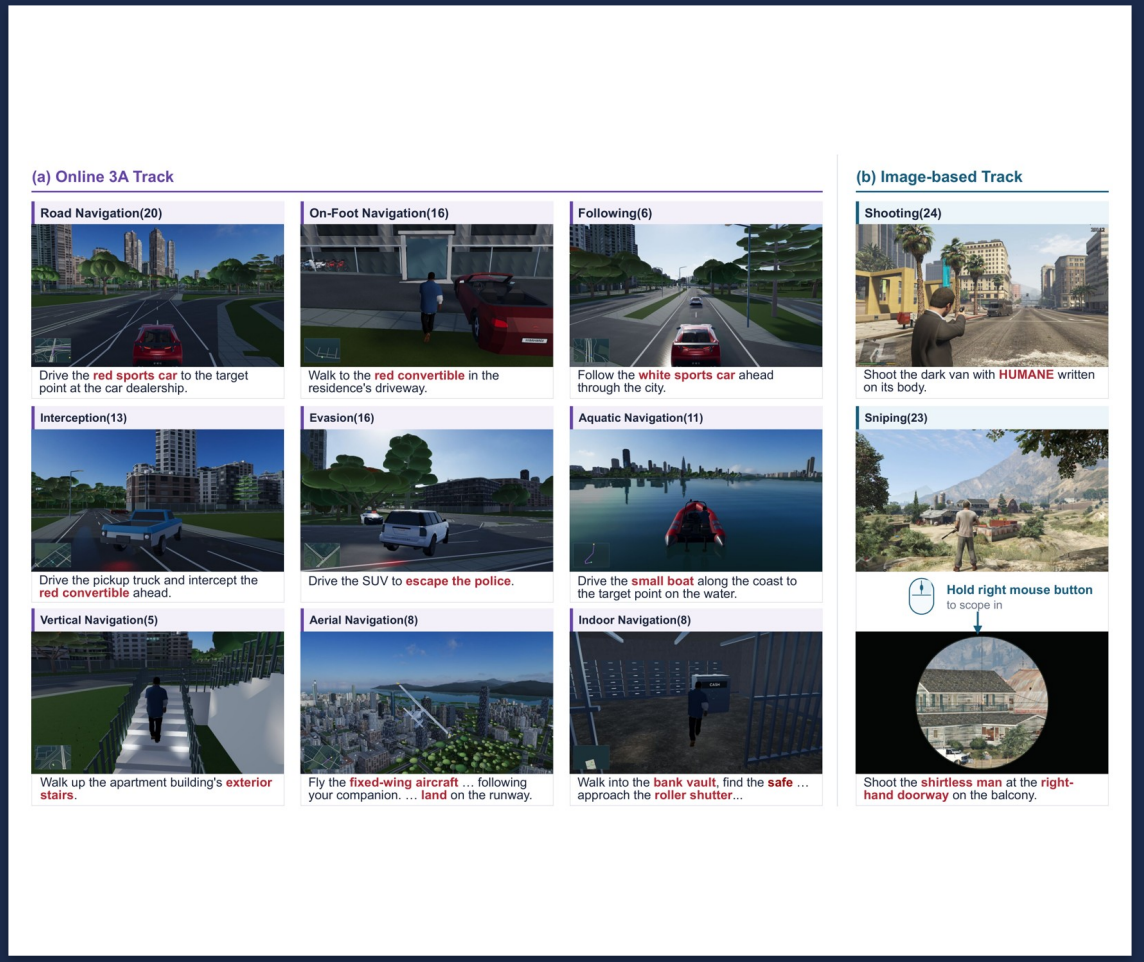

图： GTAVBench 任务套件总览（论文 Figure 2）

一句话总结

任务结构取自 GTA V、由引擎状态自动判分，智能体仍明显落后人类

作者把 **75 个 GTA V 主线任务**拆成 **150 个可由引擎状态自动判成败的任务**，并配套参数化的 RL 环境生成器；评测显示最强 VLM 智能体仅 **70.9%**（人类 89.8%），短板集中在**飞行、拦截、躲避等连续闭环控制**，取消推理暂停后更是骤降；仅用 50 个生成任务做 LoRA-GRPO，就能带来分布内和原生 GTA V 上的提升。

150

个任务

103 个在线 3D + 47 个图像射击 / 狙击，源自 75 个主线任务

70.9%

最强模型

GPT-6-Astra + Codex；人类 89.8%，差距 18.9 pt

−22.3 pt

取消推理暂停

GPT-6.1-Sol 在 3D 任务上 62.1% → 39.8%

15→23%

原生 GTA V

Qwen3.8-27B 经 50 个生成步行任务 LoRA-GRPO 后

数据来源：论文 Table 2、Section 4.3、Section 5.4

现有游戏基准各缺一角，GTAGym 试图把它们合在一起

① 沙盒 / 自建游戏的可验证任务

MineDojo · GameWorld · OmniGameArena

缺：不是 AAA 开放世界任务

② 在商业 3D 游戏中直接游玩

Cradle (RDR2) · SIMA · Lumine · OctoGTA

缺：成败靠人工 / OCR / VLM 判断，难并行

③ 视频轨迹或离线问答基准

VideoGameBench · GameVerse · GameHorizon-Bench

缺：非在线闭环，或用 VLM 里程碑打分

工作	3D 交互	AAA 开放世界任务	状态判分	Web 执行	RL 实例生成
Procgen	—	—	●	—	●
MineDojo	●	—	●	—	●
VideoGameBench	●	—	—	●	—
GameVerse	●	●	—	—	—
GameWorld	●	—	●	●	—
OmniGameArena	●	—	●	—	—
GameHorizon-Bench	●	—	—	—	—
GTAGym （本文）	●	●	●	●	●

● 支持 — 未报告

GTAGym 是表中唯一五项全部支持的工作

表格来源：论文 Table 1

11 类能力、 150 个任务，覆盖导航、交互与用枪

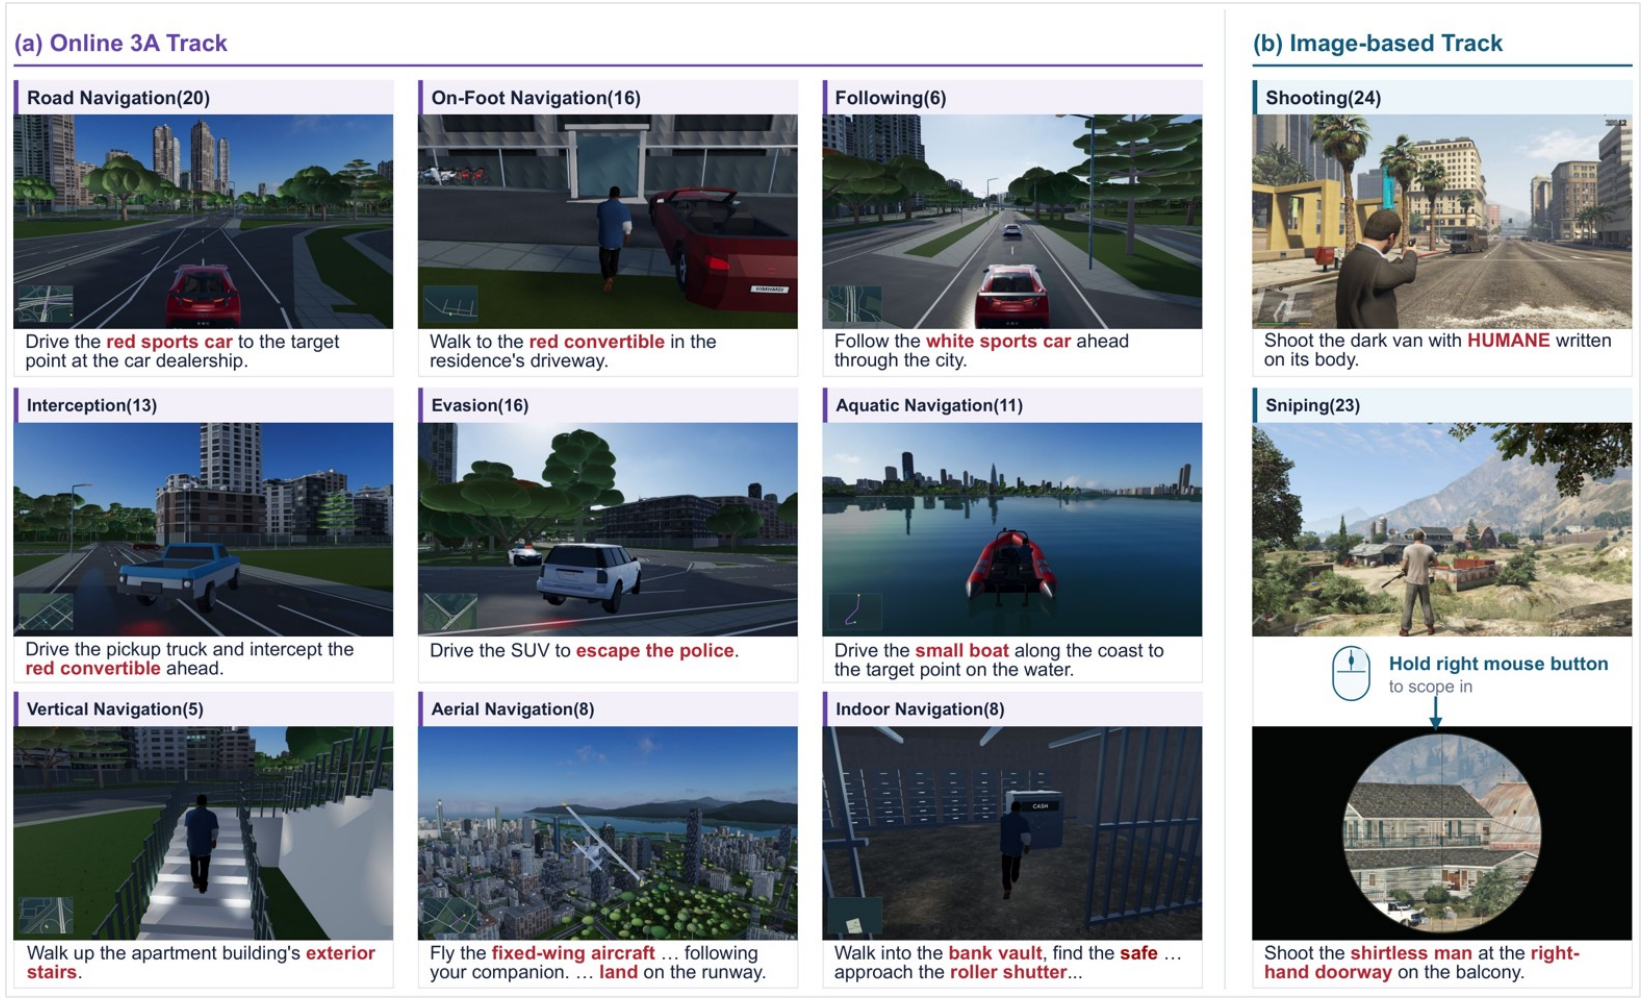

导航 68 题

Road 20 · On-Foot 16 · Aquatic 11
Vertical 5 · Aerial 8 · Indoor 8

交互 35 题

Following 6 · Interception 13
Evasion 16

用枪 47 题

Shooting 24 · Sniping 23
（图像赛道，真实 GTA V 画面）

注意：在线 3D 场景是用 Babylon.js 重建的城市（基于开源 GTA_SZ），并非 GTA V 引擎本身；“真实 AAA” 指任务结构取自主线任务。

图源：论文 Figure 2；任务数来自 Table 2

从攻略视频到可执行谓词：每个任务由引擎状态自动判成败

01 任务拆解

依据攻略视频，人工把 75 个主线任务拆成子任务，标注目标、交互顺序、完成约束、 NPC 行为

02 场景重建

Babylon.js 搭建 3D 环境；在源小地图上描出原路线，再找转弯数相近的路线；配置 NPC 行为与碰撞减速

03 模板实例化

每个子任务 = 初始状态 + 指令 + 回合预算 + 可执行的成功 / 失败谓词

04 自动判定

在线任务读引擎状态，图像任务查标注命中区域；二值成败，没有部分分

判定谓词示例

智能体自己“声明完成”不算数，必须满足谓词

拦截 Interception

目标车速连续 1.5 s ⩽ 3 m/s；智能体位于目标前方，间隙 < 2.5 m 、自身速度 ⩽ 4 m/s 。摩托车目标需 3 次独立撞倒。

躲避 Evasion

总时限 180 s 内，连续 60 s 不进入任何扫描扇区（半径 12 m 、90°）；在扇区内累计 3 s 即被捕。

降落 Aerial

需有起飞记录；落在指定跑道 / 停机坪，速度 ⩽ 1.5 m/s 、油门 < 5% 、静止 2 s 。坠毁或离开空域即失败。

狙击 Sniping

准星落点按镜头与倍率反变换到标注坐标系； K 个目标只给 K 发子弹，打空或重复命中即失败。

来源：论文 Section 3.2 、 Appendix A.2

两种协议共享任务与动作接口，只在指令呈现和上下文管理上不同

共享设置

- 截图 → 动作的闭环，键盘 + 鼠标控制
- 每个按键指定按住时长 $d \in (0, 1]$ s，多键并发；回合时长 = 最长按键
- 默认：**模型推理时游戏暂停**
- 预算：导航 / 交互 ≤ 300 轮，用枪 ≤ 20 轮
- 指标： 150 题 micro 平均准确率， 3 个随机种子
- 人类基线： 3 名通关过 GTA V 的玩家，各做一遍全部任务
- 6 个模型： GPT-6-Astra 、 GPT-6.1-Sol 、 DeepSeek-V4.1-Flash 、 GLM-5.3-Flash 、 Kimi-K3 、 Qwen3.8-27B

GTAVBench

普通 GUI 协议

- 文本任务指令 + 固定系统 prompt
- 模型直接输出 JSON 动作，适配器校验后执行
- 在线任务历史上限 10 对截图–回复，超出时丢掉最早 5 对
- 图像任务保留完整历史

GTAVBench-AGI

Codex harness

- 任务目标只出现在首张截图左上角，模拟游戏内任务提示
- 通过 game_step 工具提交动作
- Codex 原生历史 + 自动上下文压缩
- 后续返回结果不再重复目标

```
{"keys": [{"key": "w", "duration_seconds": 1},
          {"key": "Space", "duration_seconds": 0.1}],
 "mouse": {"move": {"dx": 120, "dy": 30}}}
```

动作示例：视角右移 120 px 、上移 30 px ，同时按住 W 1 s 、 Space 0.1 s （Appendix A.3）

来源：论文 Section 3.3 、 4.1 、 Appendix A.3–A.5 、 D

模板 + 参数区间：批量生成带奖励与终止信号的 RL 环境

$$\theta \sim P_T(\cdot|C) \qquad E = G(T, \theta; \xi)$$

T 模板	固定场景、资产、交互逻辑、判定器、回合预算
C 约束	用户给出的数值区间或候选集合
θ 参数	在约束与模板可行性内采样；不可行组合被拒绝，找不到则报告
ξ 种子	保存解析后的配置与种子，实例可复现

奖励与终止：任务结果作为稀疏奖励；成功 / 失败结束回合，预算耗尽记为截断。 3D 任务用引擎状态谓词，图像任务用命中检查。

可由用户限定范围的采样参数

起点 / 终点	初始朝向	路线长度
转弯数	交通域（陆 / 水 / 空）	移动方式
NPC 速度	初始距离	追捕者数量
图像–目标对	瞄准偏移	生成种子 ξ

驾驶模板示例

路线长度限定 $[200, 500]$ m ，转弯数 $\in \{2, 3, 4, 5\}$ ；两者共同决定可选路线，生成器据此构造完整路线和初始状态

躲避模板示例

追捕者数量 $\in \{1, 2, 3\}$ ，初始距离 $[20, 40]$ m ，速度 $[2, 4]$ m/s ；由种子 ξ 决定具体取值

狙击只用于评测，不参与环境生成

来源：论文 Section 3.4 、 Eq. (1) 、 Appendix B 、 Table 7/8

GPT 系与其余模型呈断层：最强 70.9%，距人类仍差 18.9 个点

总体准确率（%，150 题，3 个种子均值）

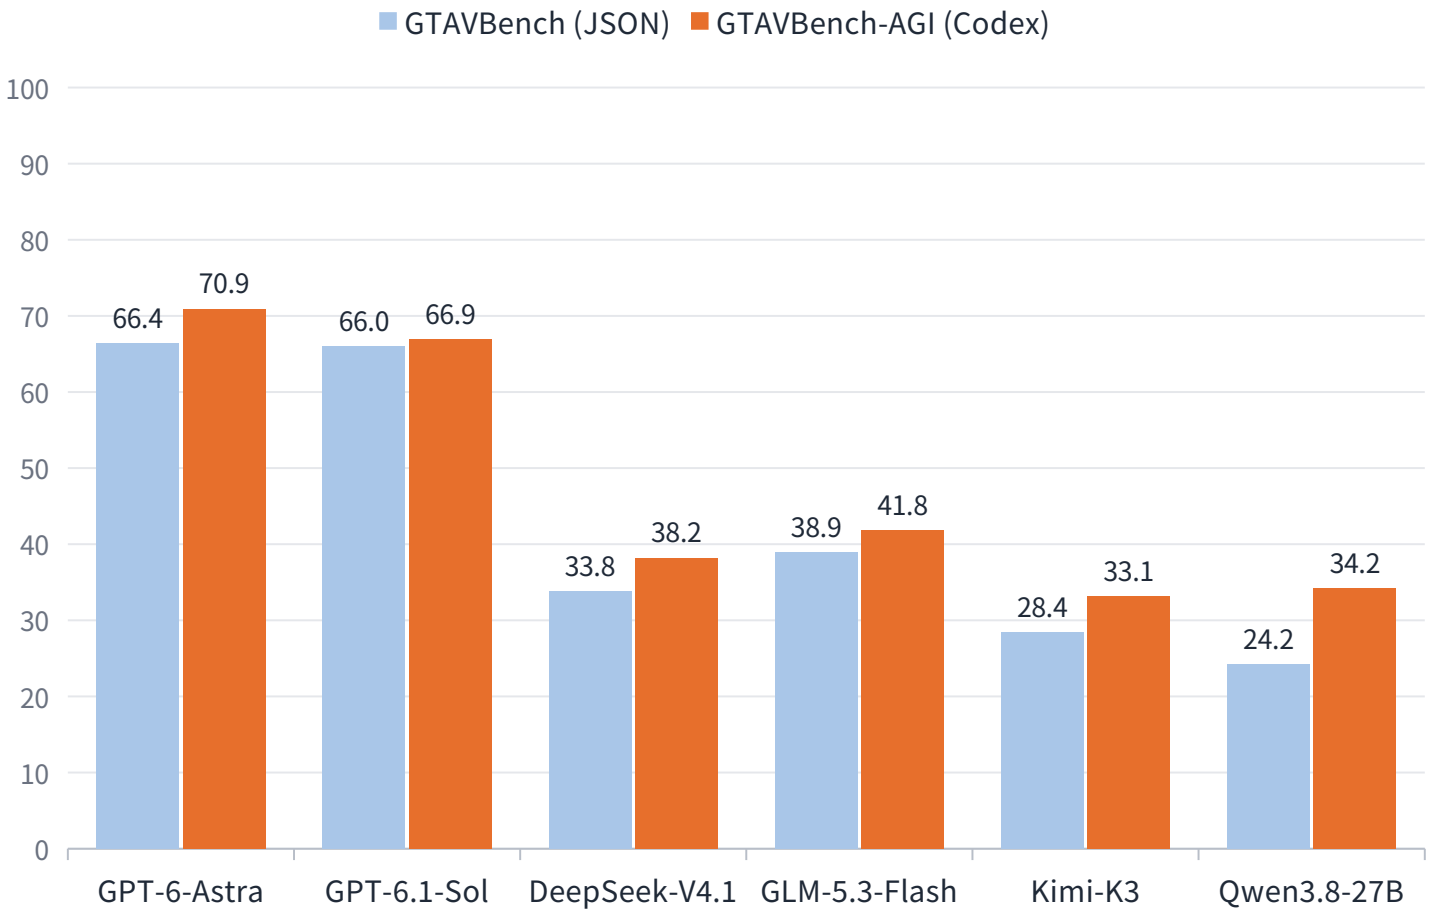

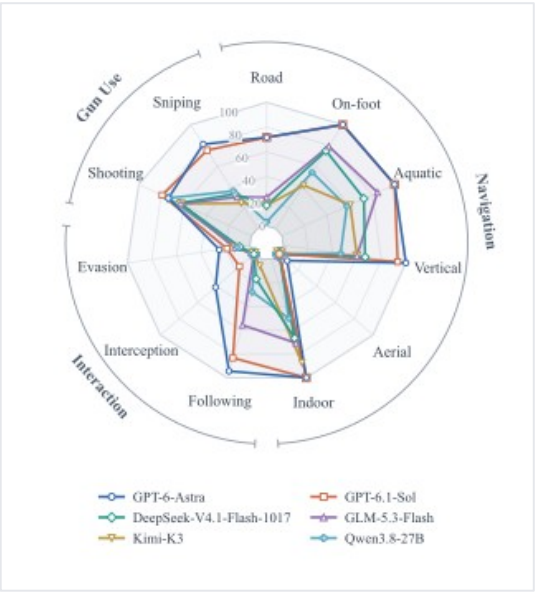

Figure 1： Codex harness 下 6 个模型的 11 类准确率

89.8%

人类平均
（3 名玩家）

AGI 协议让 6 个模型全部提升 **+0.9 ~ +10.0 pt**

注：图像指令与 harness 同时改变，未分开消融

数据：论文 Table 2；右图： Figure 1

分类别结果

静态导航接近满分，飞行、拦截、躲避几乎全军覆没

各类别准确率（%）

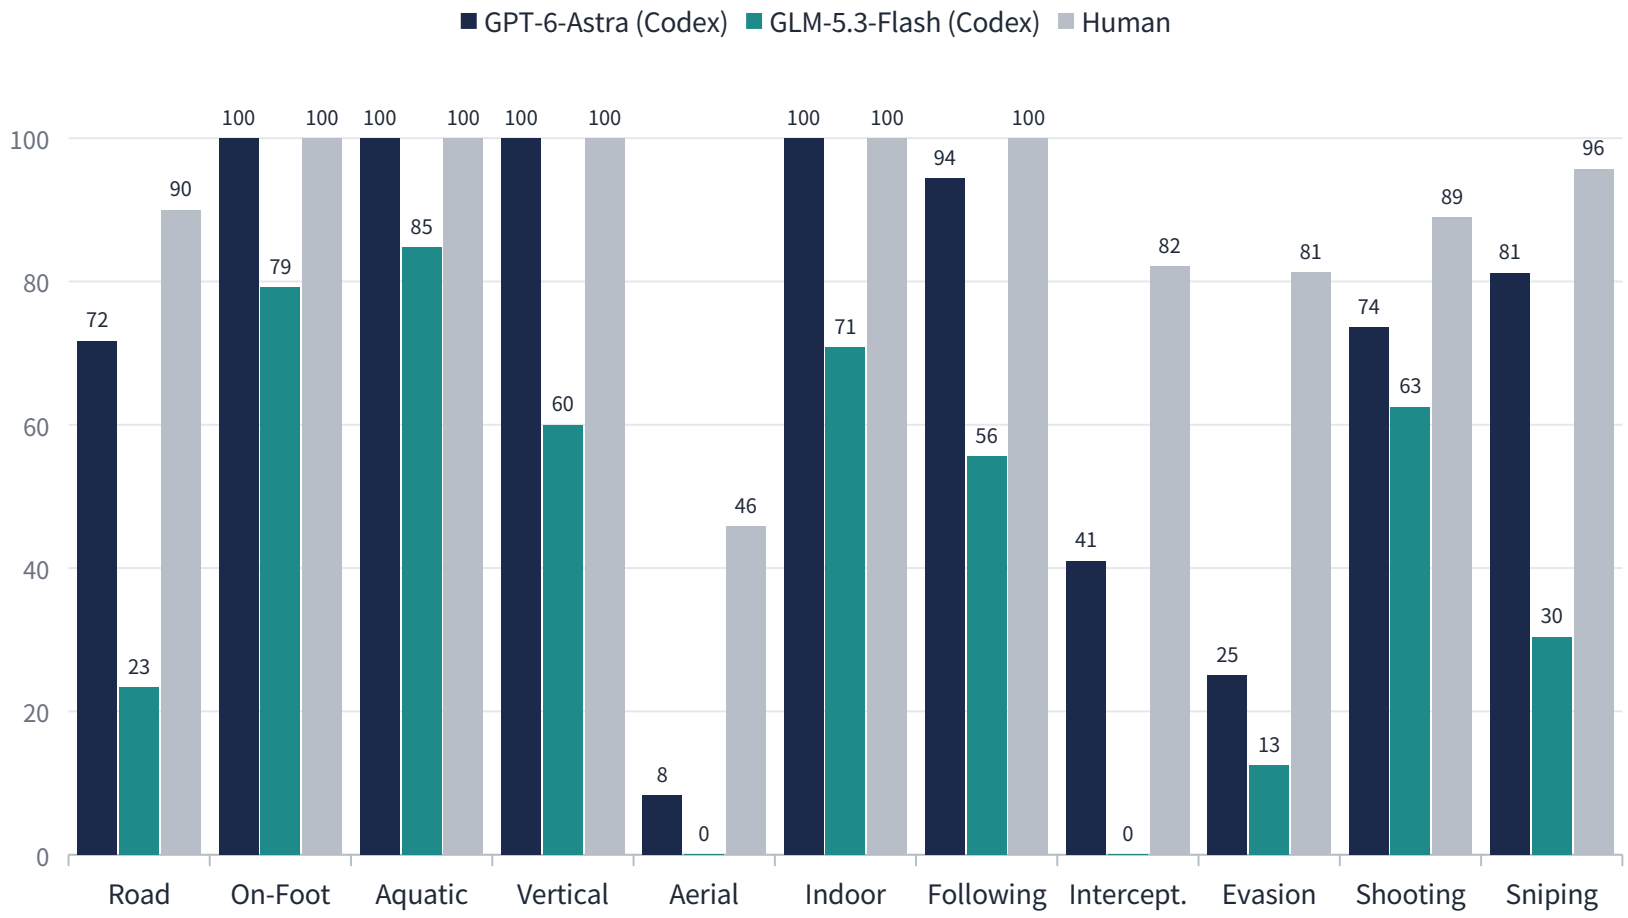

Aerial 飞行

≤ 8.3%

所有模型 0–8.3%；人类也只有 45.8%

Interception 拦截

≤ 41.0%

仅 Astra + Codex 达 41.0 ± 18.1，其余 0–15.4%；人类 82.1%

Evasion 躲避

≤ 25.0%

模型最高 25.0%；人类 81.3%

数据：论文 Table 2（GTAVBench-AGI 与人类）

准确率高不等于想得多： GPT 每任务仅约 2–3k 输出 tokens

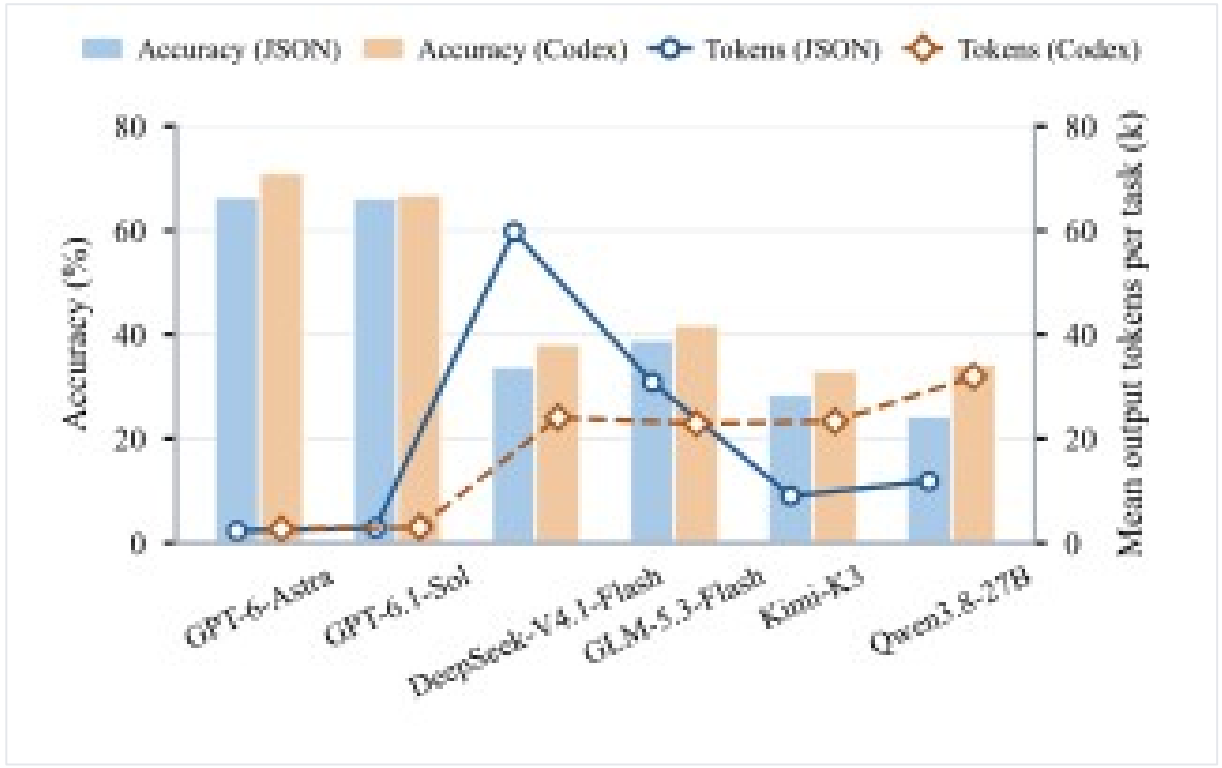

Figure 3： 准确率（柱）与每任务平均输出 tokens （折线）

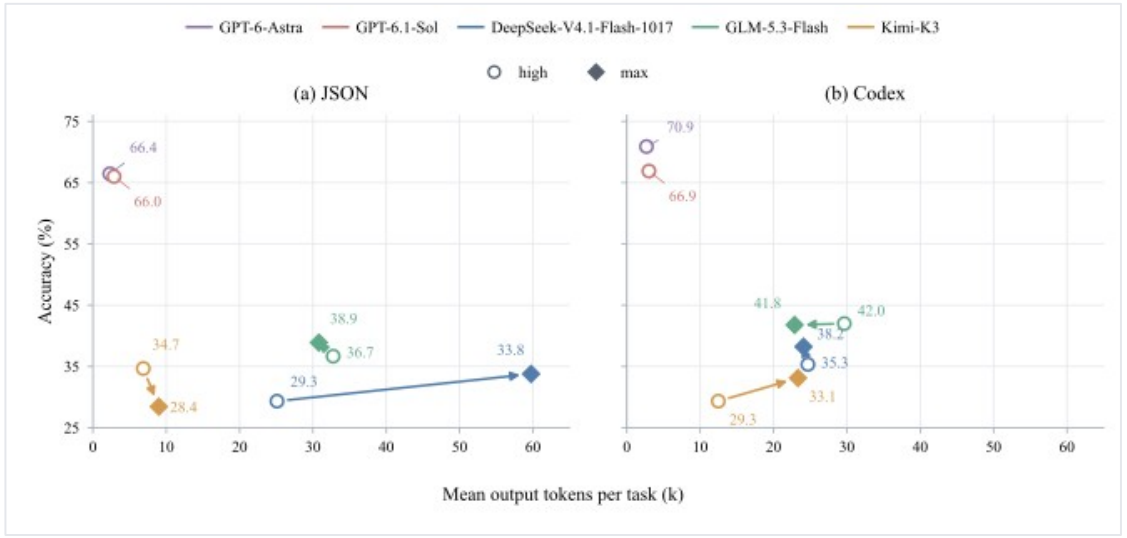

Figure 8： 推理强度 high （空心） vs max （实心）

GPT 系 每任务约 2–3k 输出 tokens，准确率却最高

DeepSeek (JSON) 输出 tokens 约为 Astra 的 26×，准确率 33.8%

high → max 不稳定： Kimi JSON 34.7 → 28.4； DeepSeek JSON 29.3 → 33.8，但 tokens 大幅增加

图源：论文 Figure 3 （左）、 Figure 8 （右）

四类典型失败：问题出在“控制”，而不是“看懂”

道路驾驶 · Kimi-K3 (JSON)　　机制：**转向过量且仍在加速**

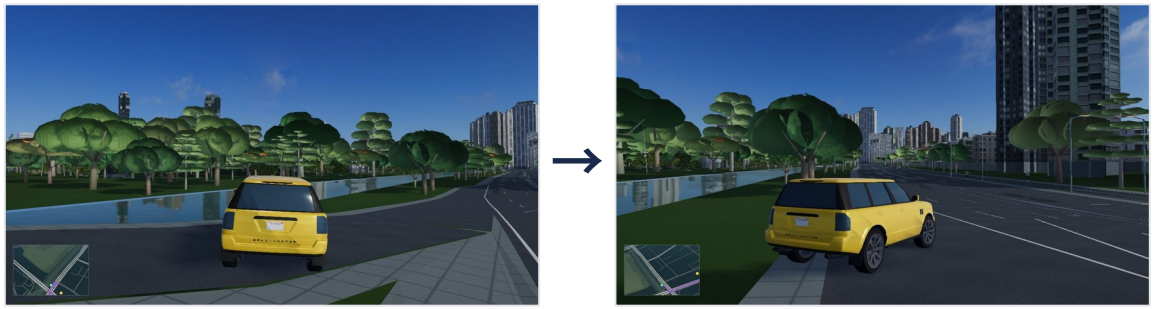

W 1 s + D 1 s：车速 24.2 → 30.5 m/s，转约 67° 冲上路缘

拦截 · GPT-6.1-Sol (Codex)　　机制：**撞停后不刹车，未保持阻挡**

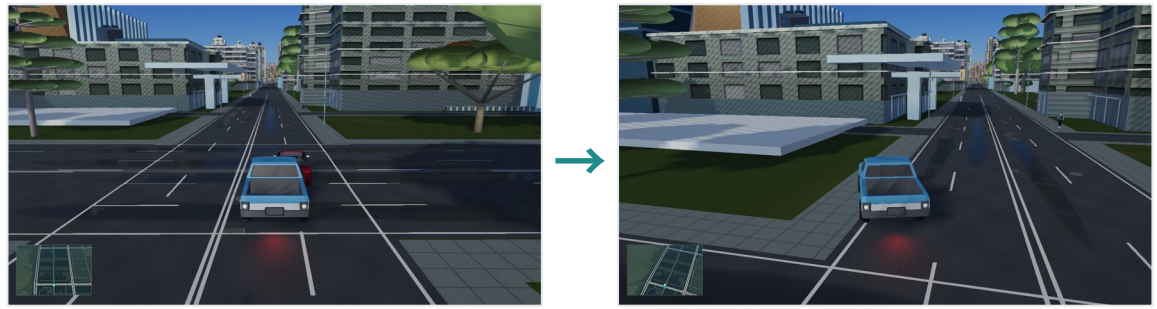

撞后目标降至 0.2 m/s，自身仍 37.5 m/s，冲出 20.4 m 失去接触

飞行降落 · GPT-6.1-Sol (Codex)　　机制：**下沉率修正过晚**

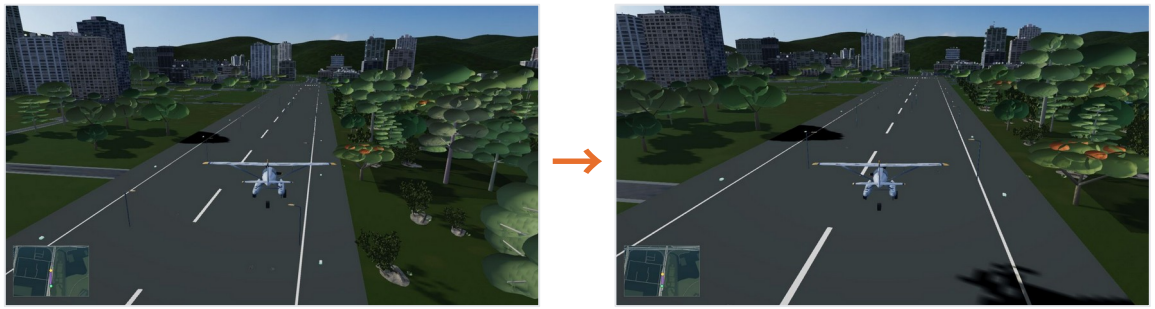

S 1 s 减油门：高度 18.6 → 9.4 m，下沉仍 9.2 m/s，随后坠毁

躲避 · GPT-6.1-Sol (Codex)　　机制：**贴墙被困，迟一步才倒车**

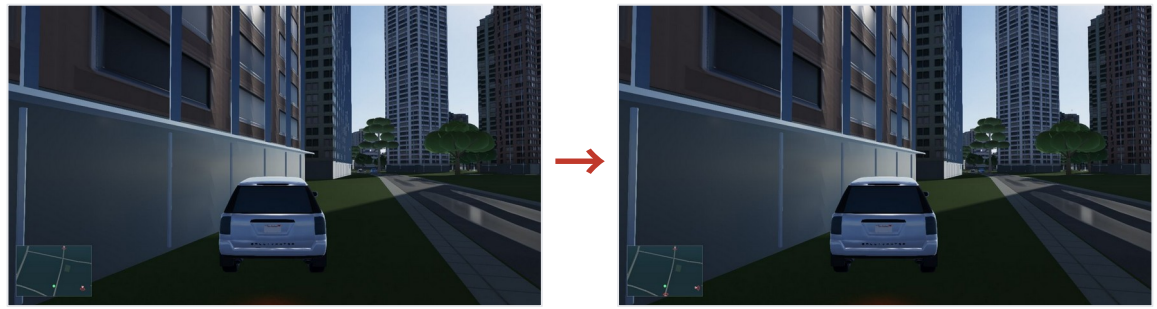

撞楼后继续 W 1 s + D 0.4 s，整整 1 s 零位移

图源：论文 Table 11 （动作前 → 动作后的原始观察）

63.2% 的首个错误属于校准与调节； GPT 出错后更能改回来

首个错误发生率（每格 = 该类首错数 / 150）

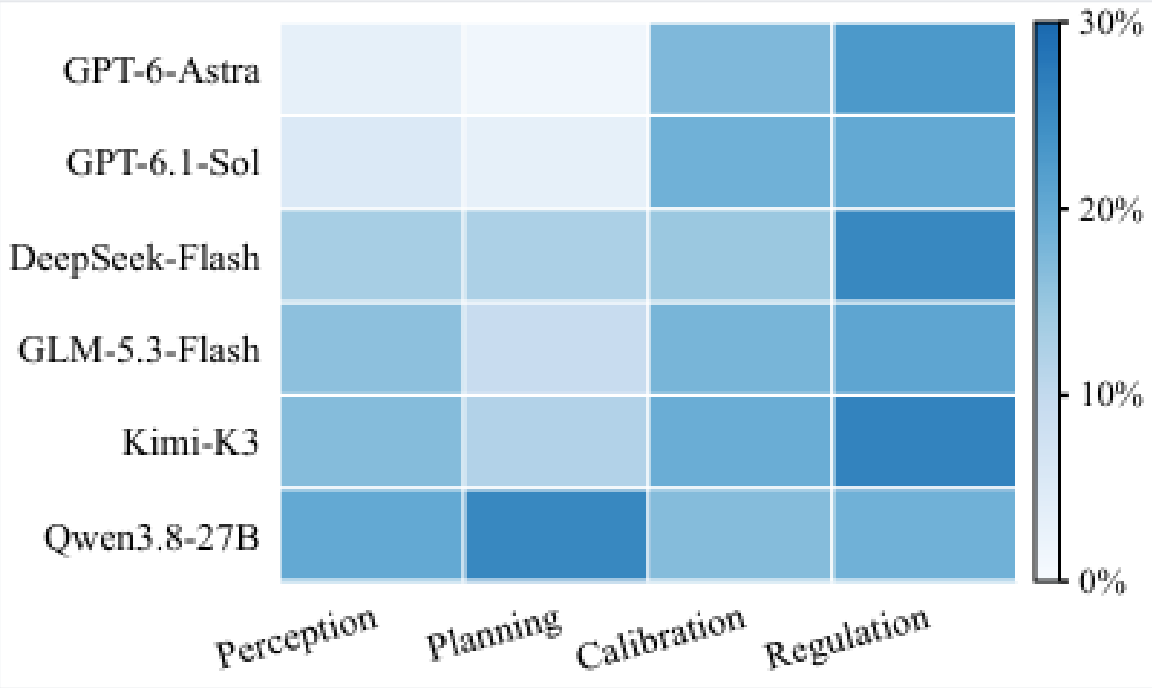

首错后 10 步内的恢复率（%）

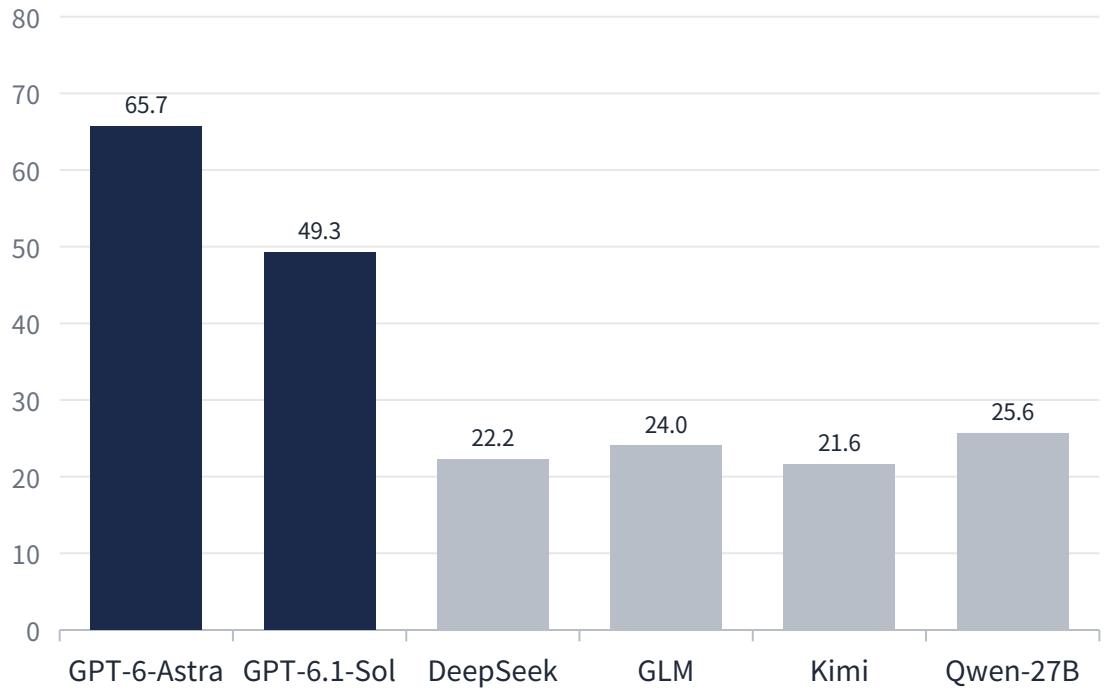

112	96	157	200
感知 Perception	规划 Planning	校准 Calibration	调节 Regulation

整体恢复率 179 / 565 = **31.7%**；校准 + 调节占 565 个首错的 63.2%

样本： JSON 协议下每个模型 1 次运行，共 900 条轨迹， 565 条可定位并归类首错

图源：论文 Figure 6 左；数据： Appendix C 、 Table 13

长记忆帮助换策略，但上下文压缩也可能丢掉目标

帮助：记住尝试过的策略

- 比 JSON 协议的 10 图窗口保留更长历史，用文字摘要保持连贯
- GPT-6-Astra 拦截摩托车：记得某条接近路线被挡，换个机动再接近
- DeepSeek-Flash 室内导航：记住已搜过的房间和无效的开门尝试

风险：错误被保留、目标被替换

- 长历史与压缩也会保留错误理解、削弱对目标的坚持
- Kimi-K3：先正确识别别屋顶目标，压缩后换成驾驶目标，最终从摘要中丢失原目标
- GLM-5.3-Flash：把颠倒的小地图标记含义一路带到后续决策

AGI（Codex）相对 JSON 协议的总体提升（pt）

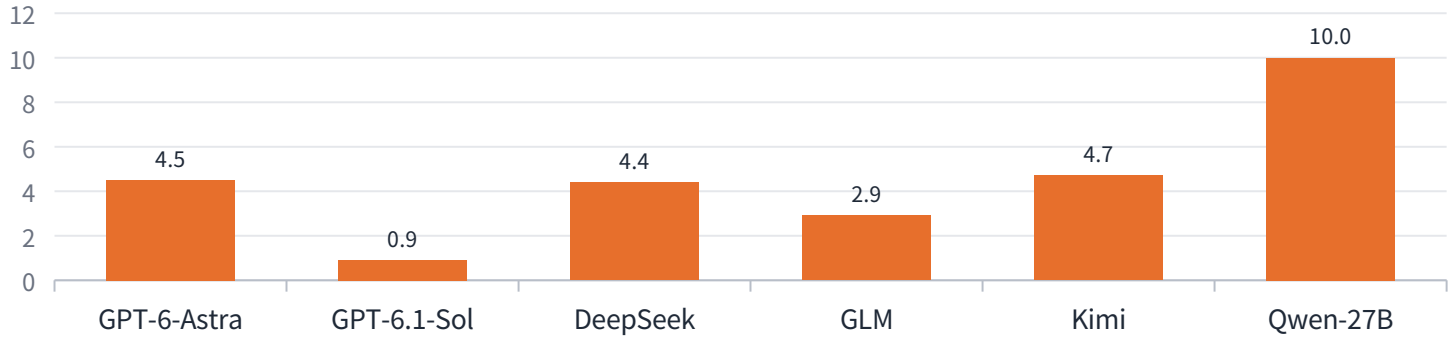

启示

上下文交接（压缩）点是轨迹漂移与目标丢失的高发处；harness 设计本身就是智能体能力的一部分。

来源：论文 Section 5.3；数据： Table 2

取消推理暂停后准确率骤降 22.3 个点：延迟卡住动态交互

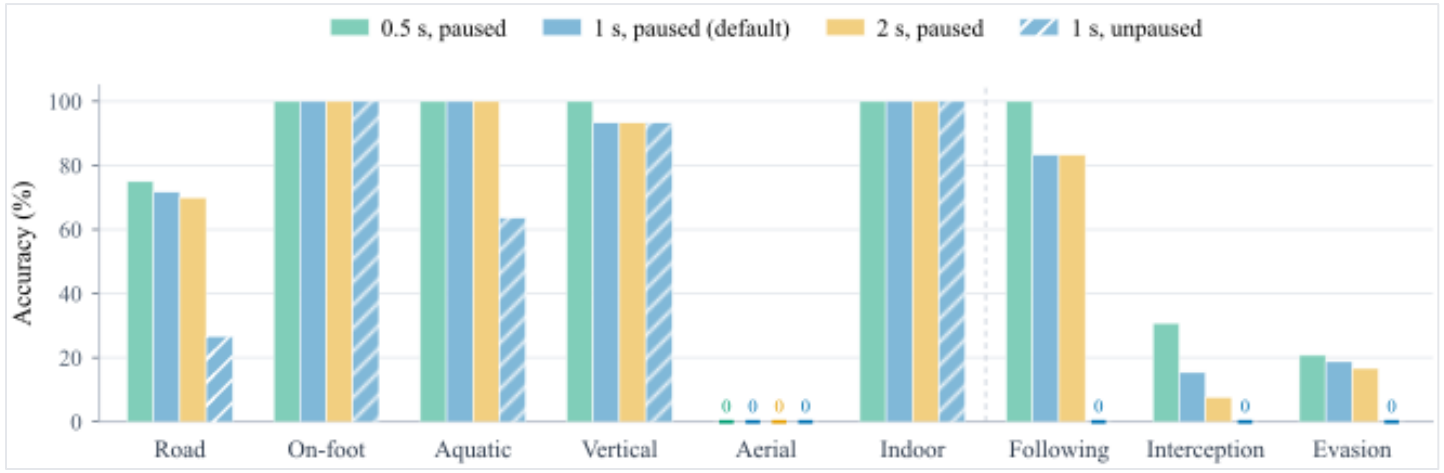

Figure 7： 四种按键时长上限 / 暂停设置下各类别准确率

d_max	暂停	3D 准确率	轮数	输入 tokens
0.5 s	是	66.3%	121.2	11.20M
1 s*	是	62.1%	62.6	4.32M
2 s	是	60.5%	42.5	2.50M
1 s	**否**	**39.8%**	**31.8**	**1.83M**

* 默认设置；任务均值

- **0.5 s：** 反馈更频繁， Following 达 100%、Interception 约 31%；代价是轮数 ×1.9、输入 tokens ×2.6
- **2 s 上限：** 66.6% 的动作超过 1 s，模型不会自选合适时长
- **不暂停：** Following / Interception / Evasion 全部归零；On-Foot、 Indoor 仍 100%

解读： 主表成绩建立在“游戏等模型思考”的设定上，对实时部署偏乐观。

图源： Figure 7；数据： Section 5.4、 Table 5 （GPT-6.1-Sol + Codex）

50 个生成的步行任务做 LoRA-GRPO：分布内 +18.7 个点

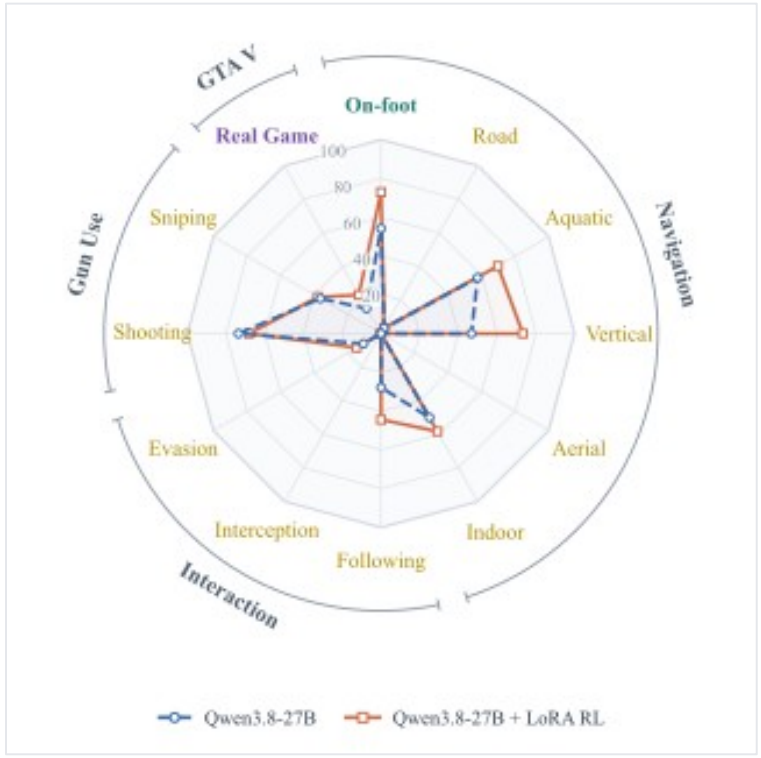

Figure 4：绿 = 分布内，黄 = 分布外，紫 = 原生 GTA V

Qwen3.8-27B 训练前后准确率（%）

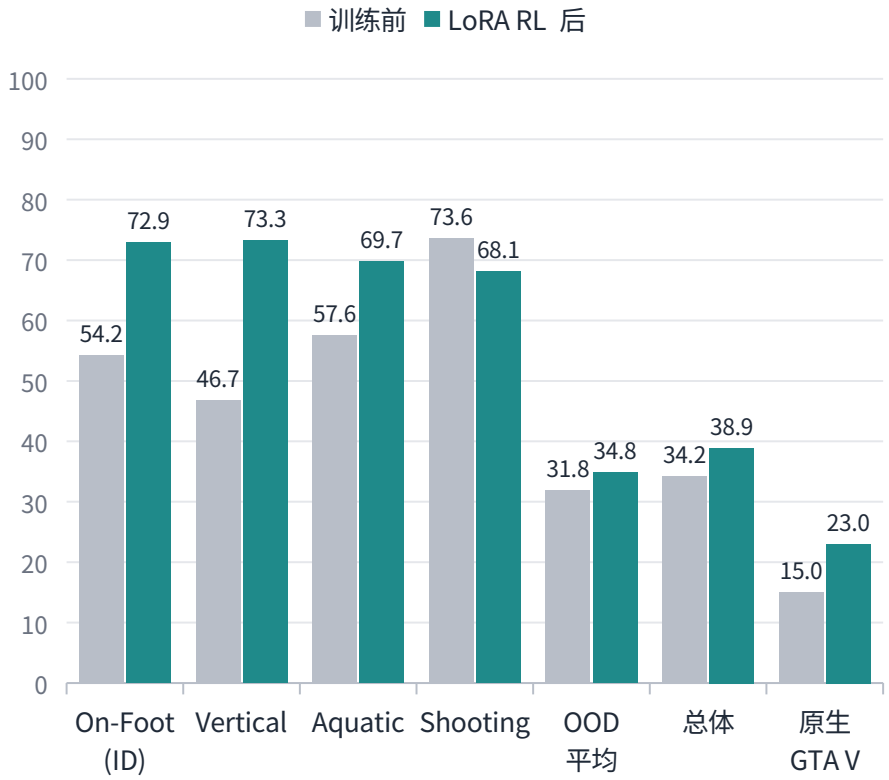

训练设置

- 50 个生成步行实例，路线与基准空间分离
- GRPO + LoRA： r = 32 、 α = 64 （q/v 投影）
- 每步 4 任务 × 8 rollout； 8 × H200
- 在 Codex harness 内训练

终止奖励

$$R = S + 0.3(1-S)\cdot P - 0.1\cdot \mathbb{1}[N>100]$$

P：按 A* 可通行距离算的最终进度，只给失败 rollout 部分分

未改善： Road 仍 3.3%， Aerial 、 Interception 仍为 0， Shooting 73.6 → 68.1； Vertical 仅 5 题，原生 GTA V 由人工看录像判定，未报告显著性。

图源：论文 Figure 4；数据： Section 4.3 、 Appendix B.1–B.3

工程扎实、诊断清晰，但“真实 AAA” 与样本量需打折扣

亮点

1. 工程完整：判定谓词细致（防穿帧、终止优先级、 K 弹 K 靶），动作严格校验， Web 并行，种子可复现
2. 区分度好：静态导航接近饱和，动态控制几乎全灭，清楚定位短板
3. 诊断可执行：首错与恢复分析指向校准和调节，而不是感知
4. 暂停 / 时长消融量化了“慢思考 VLM” 与实时控制的矛盾； RL 闭环一直打通到原生 GTA V

局限

1. “真实 AAA” 打折扣： 3D 任务跑在简化重建城市中，路线只是转弯数相近的替代
2. 单类题量小： Vertical 5 、 Following 6 、 Aerial 8 题，单题值 12–20 pt
3. AGI 增益原因混杂：图像指令与 Codex 上下文管理同时改变，未分开消融
4. 主表依赖推理暂停，对实时部署偏乐观
5. RL 规模小：只训练步行一类，奖励用宿主侧 A* 距离； Road / Aerial / Interception 无提升

基于论文内容的解读者评价

三点结论，以及这篇论文适合谁读

01	**可验证 + 可生成**	GTAGym 把 AAA 任务结构、引擎状态判分、 RL 实例生成放进同一个 Web 并行环境
02	**瓶颈在闭环控制**	飞行、拦截、躲避与推理延迟是下一步要攻克的方向； 63.2% 的首错属于校准与调节
03	**小规模 RL 已见效**	50 个生成任务带来分布内 +18.7 pt ，并部分迁移到未见类别与原生 GTA V （ 15% → 23% ）

适合谁读

游戏 / computer-use 智能体评测

可直接使用的状态判分 AAA 风格基准 + 并行 Web 接口

智能体强化学习

参数化环境生成器、稀疏奖励接口，以及 GRPO + LoRA 的参考配置

实时具身控制

暂停 / 时长消融与错误分布，指出推理延迟和连续控制精度两大方向