ExRL：只学“执行多长”
样本高效地在线适配长动作块策略

ExRL: Sample-Efficient Online Adaptation of Long-Chunk Policies via Execution Length Control

Xu Luo, Jiaying Yang, Hao Wu, Junlin Xie, Zijin Hong, Ji Zhang, Lianli Gao, Jingkuan Song
UESTC · Tongji University · The Hong Kong Polytechnic University

arXiv 2611.13482 · 首次提交 2026-11-10 · exrl-project.github.io · 论文解读

一句话总结

冻结底座，只学一个离散标量 k：长动作块策略的高效在线 RL 接口

ExRL 不修改长动作块（H≈50）里的动作，而是冻结底座策略，用离线策略 RL 训练一个轻量适配器，决定**每个预测动作块先执行前 k 步再重规划**。优化空间从随块长增长的高维连续动作，变成 {1,…,H} 中选一个数； DP 、 ACT 、 π0/π0.5 、 π0-FAST 、 Cosmos Policy 都能借此样本高效地提升。

{1, …, H}

适配空间：每个动作块只选执行步数 k，维度不随块长增长

>90%

DP Tool Hang （H=50）上 ExRL-SAC 的成功率；其余基线约 20% 或更低

≈10 min

真机 π0.5 叠方块的物理交互时长；最终评估 17/20 （固定 k=10 时 9/20）

块越长，在动作空间做 RL 就越费样本

- 长动作块已成主流： π0.5 、 π0-FAST 、 DreamZero 等每次预测 20–50 步并开环执行，支撑 50 Hz 高频控制、减少推理停顿
- 部署后仍需在线 RL 补短板，但真机交互慢、贵、有风险 → 样本效率是第一要求
- 现有方法的优化维度随 H 线性增长：残差 RL 学 $H \times d_a$ 维修正， DSRL 在 $H \times d_a$ 维噪声空间里调，OGPO / PA-RL 直接改整个生成过程

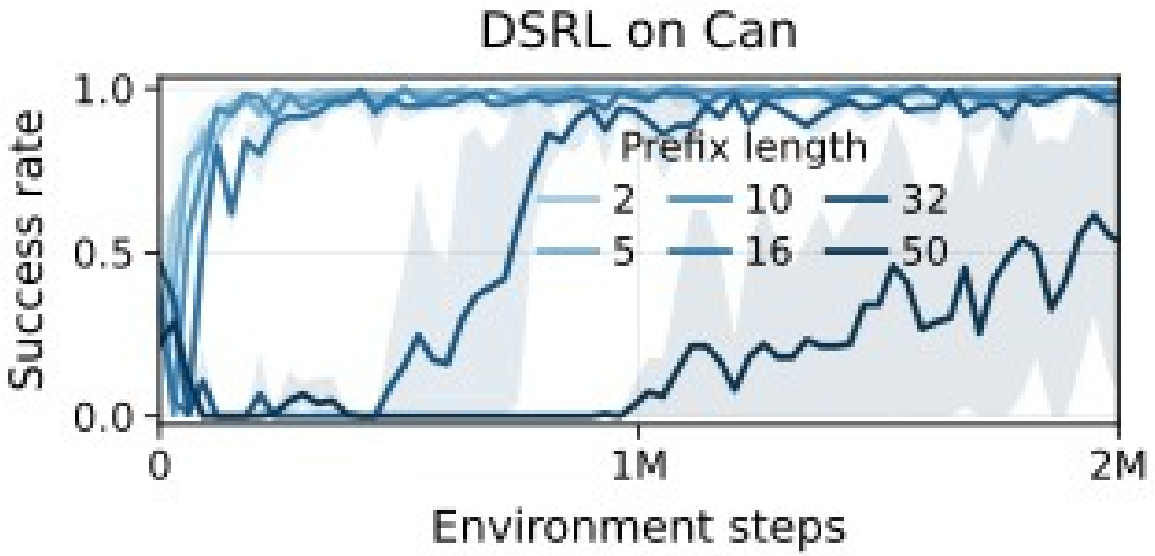

块越长 → 优化空间越高维 → 在线样本需求越大

对照实验： 同一 DP 在 Can 上只把前 L 步暴露给 DSRL 。 L=2–16 很快到 ~100% ； L=32 明显变慢； L=50 训练 2M 步仍约 50% 。 Can 上底座成功率对 L 不敏感，差距主要来自优化维度。

来源： Sec. I ； Fig. 11 （附录 A-C ， DSRL on Can ）

核心思想

换一个调节口：不改动作，只学每个动作块执行几步

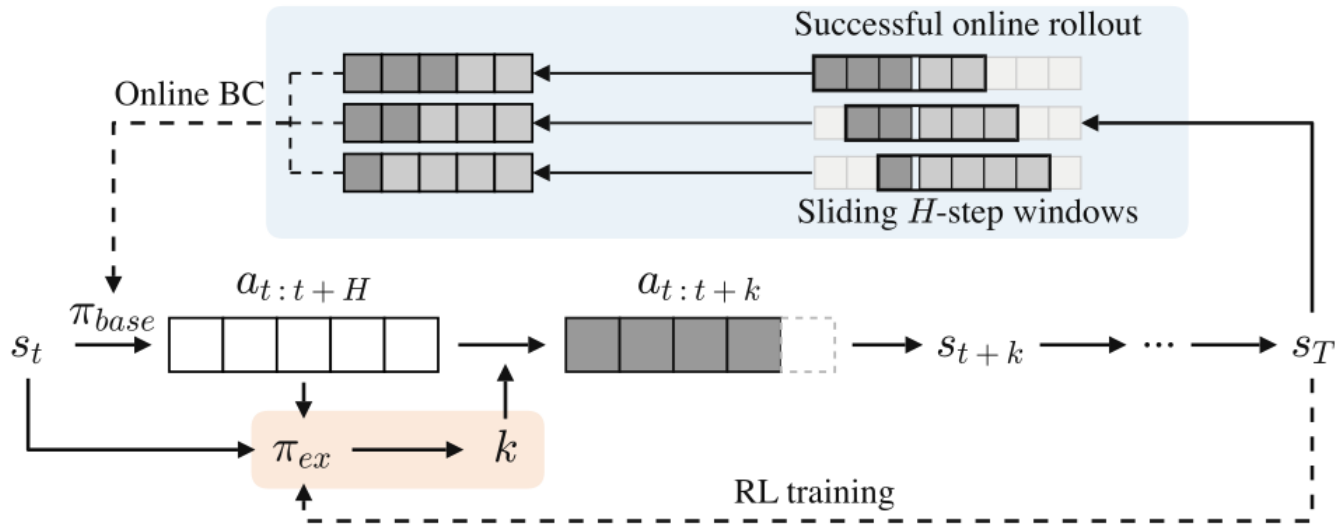

π_base 冻结负责产生动作块； π_ex(k | s, chunk) 只决定执行前几步再重新查询；可选地把成功轨迹以 Online BC 回灌底座。

k 大 → 长时间开环

充分利用动作块的时序一致性；推理停顿少，动作平滑

k 小 → 及时重规划

对意外状态变化、动力学偏差反应更快

块越长，反而越合适

可选 k 随 H 增多 → 表达力上升；而优化始终只是“H 选 1” 的低维离散问题

来源： Fig. 2； Sec. I 、 IV

考虑持续时长的 Q 学习：把执行长度当作 SMDP 的“元动作”

$$y_t = \sum_{i=0\ldots k-1} \gamma^i r(s_{t+i}, a_{t+i}) + \gamma^k \cdot V(s', a')$$

critic 记为 Q(s, a_{t:t+H}, k)：奖励累加和 bootstrap 折扣都由所选 k 决定； a′ 由冻结底座在新状态 s′ 重新采样。附录 E 证明这等价于冻结底座诱导出的半马尔可夫决策过程（SMDP）。

ExRL-Q：纯价值方法

- $V(s',a') = \max_{k'} Q(s',a',k')$，执行时 k = argmax Q
- 没有 actor，最简单；真机实验默认使用它
- CQL 系数 0.3， UTD 1/4

ExRL-SAC：离散 actor-critic

- actor 输出 k 的类别分布；软价值对所有 k 精确求和
- 熵项保持探索，防止过早坍缩到某个固定 k
- CQL 系数 0.01，目标熵 0.98 · log H

共同设计： critic 输入 = 状态 + 预测动作块 · 10 个 critic 集成 · CQL 抑制低覆盖 k 的高估 · 超参大多跨任务共享

来源： Sec. IV， Eq. (3)–(9)； Table III；附录 E

两个可选扩展：把好行为蒸馏回底座，把离线数据变成执行长度经验

① Online BC：突破底座上限

- 冻结底座时， ExRL 只能在底座已有的预测里挑选、拼接
- 自适应截断 = 把不同动作块的前缀拼成新轨迹，能产生开环执行不会出现的成功轨迹
- 从成功 rollout 切出 H 步滑窗作为动作块目标，用与预训练相同的 BC 损失更新 π_base
- DP / ACT 额外加冻结 teacher 约束，限制偏离预训练行为

② 离线数据 → 执行长度经验

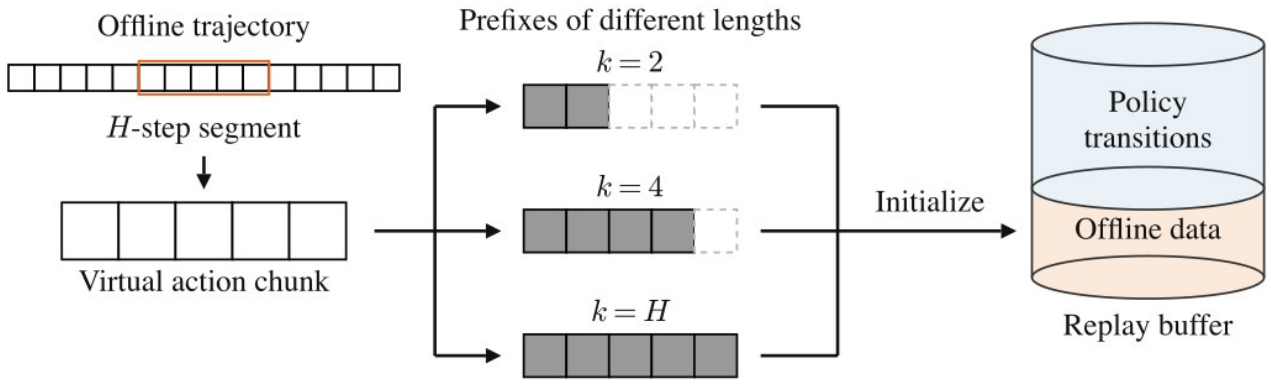

- 任意离线轨迹（即使不是按动作块采集）里的 H 步片段 = 虚拟动作块；它的每个长度为 k 的前缀都是真实的执行经验
- bootstrap 用当前底座 + 当前执行策略，价值锚定在 ExRL 自身行为上，而非示范者的行为

来源： Fig. 2 、 Fig. 3 ； Sec. IV

为什么要“学” k

最优固定 k 因任务和策略而异，而扫参本身就很贵

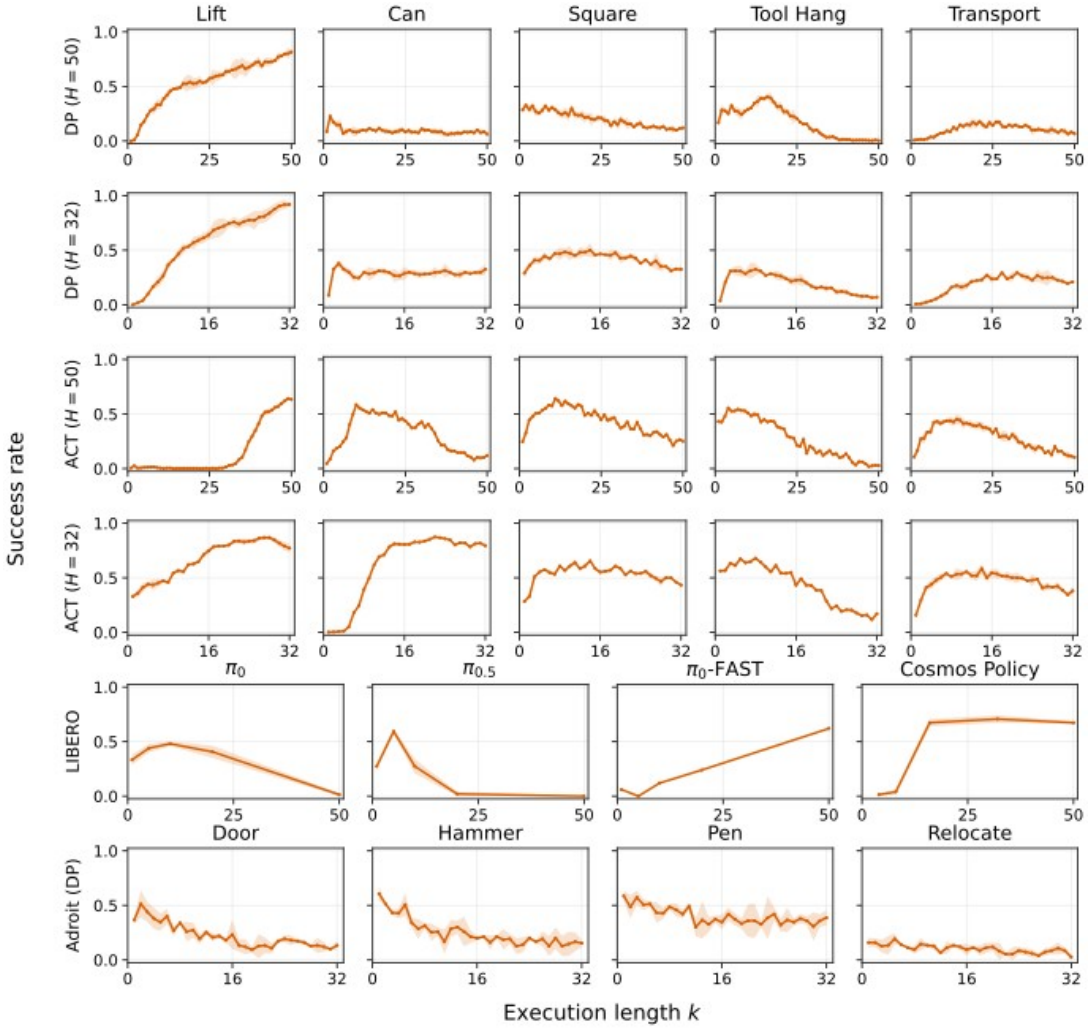

固定 k 扫描（冻结底座，读图近似值）

DP Lift （H=50）	k 越大越好， k=50 约 0.8
ACT Can / Square （H=50）	峰值在 k≈10，约 0.6
π0.5 • LIBERO	k≈5 峰值约 0.6，更长跌到≈ 0
π0-FAST • LIBERO	随 k 上升， k=50 约 0.6
Adroit （DP）	整体小 k 更好

一律用短 k 做常规 RL： 初始性能可能极差、推理开销大、长时程任务的决策步数暴增。

先扫最优固定 k： 真机要上百次 rollout，已接近一次在线 RL 的预算。

来源： Fig. 16 （附录 C）； Sec. IV Remark

Robomimic （H=50）：只学 k，就在难任务上大幅领先

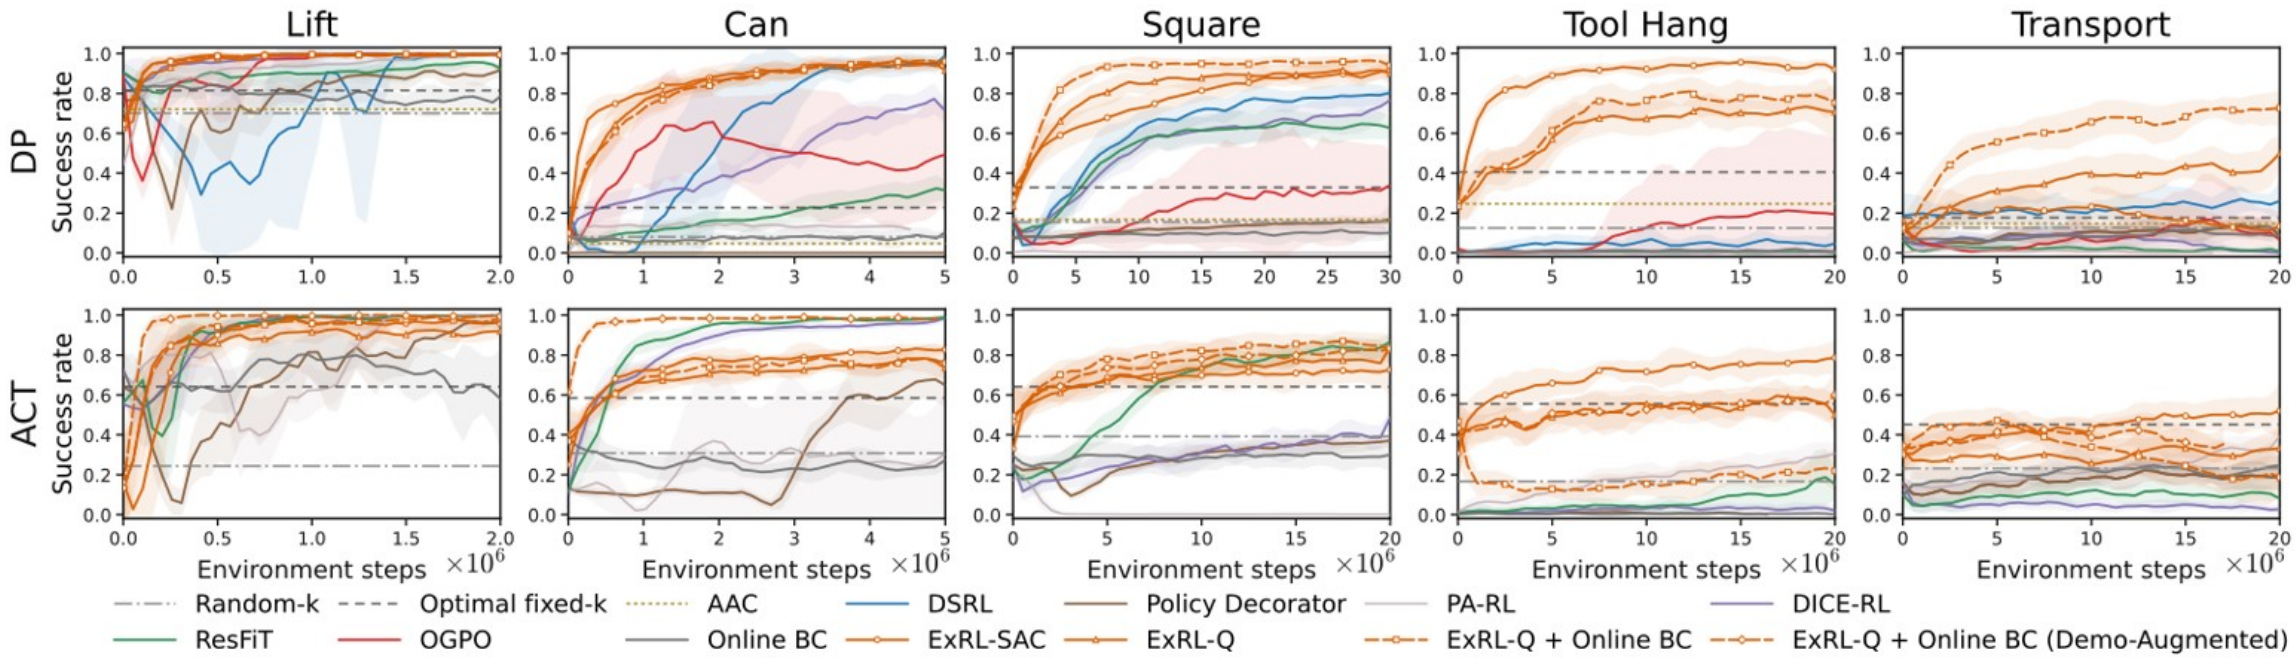

>90% vs ⩽~20%

DP Tool Hang： ExRL-SAC vs 其余所有基线

超过最优固定 k

DP 的 Can / Square / Tool Hang 上提升最大，且不改底座的任何动作

Transport 最难

冻结底座不够，需要 ExRL-Q + Online BC（加示范）才明显提升

来源： Fig. 4 （DP / ACT， H=50， 3 个种子均值与 95% CI）

跨架构通用： flow / 自回归 VLA 和世界动作模型都被提升到约 90% 以上

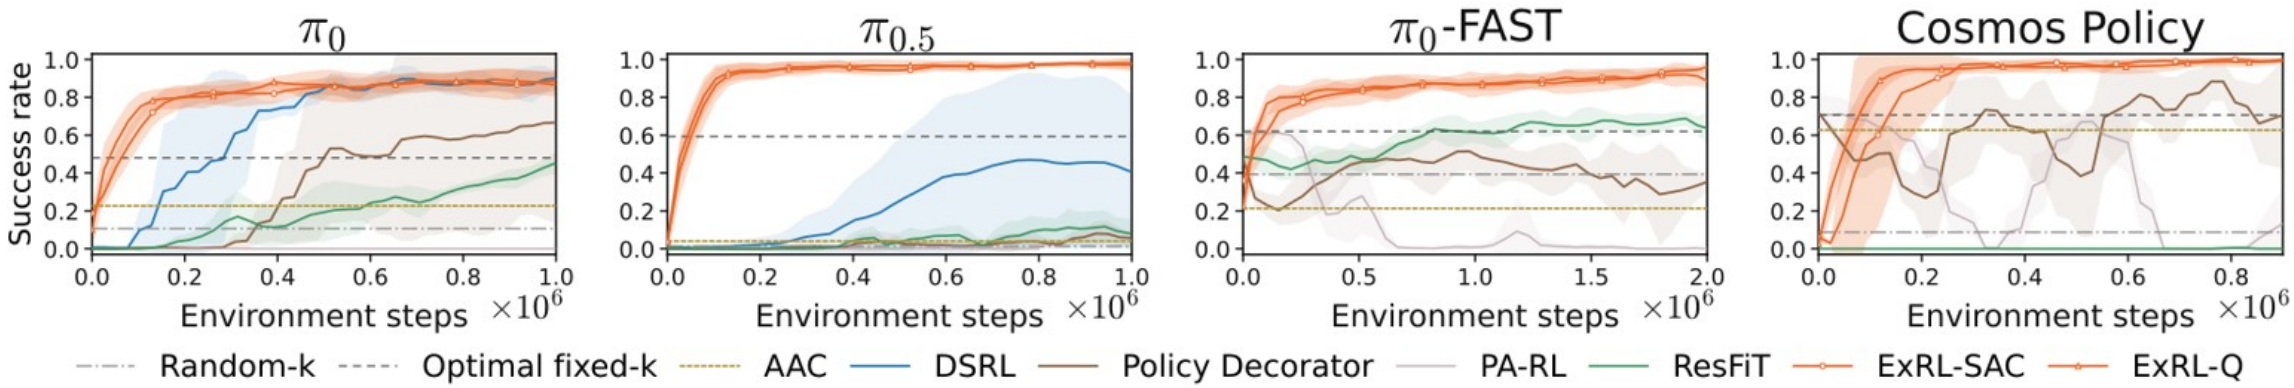

≈0% → >90%

π0.5 在 0.2M 环境步内（LIBERO-90 单任务）

- 四类底座： flow VLA （π0 、 π0.5 ）、自回归 VLA （π0-FAST ）、世界动作模型（ Cosmos Policy ），块长均为 50
- 同一套执行长度公式即可适配，无需访问梯度、潜变量或去噪过程
- π0.5 上：最优固定 k 约 0.6 ， DSRL 最高约 0.4 ，其余 RL 基线接近 0 （读图）

来源： Fig. 6 （LIBERO ， H=50 ）

加上 Online BC 和人类示范，能突破“只挑长度”的上限

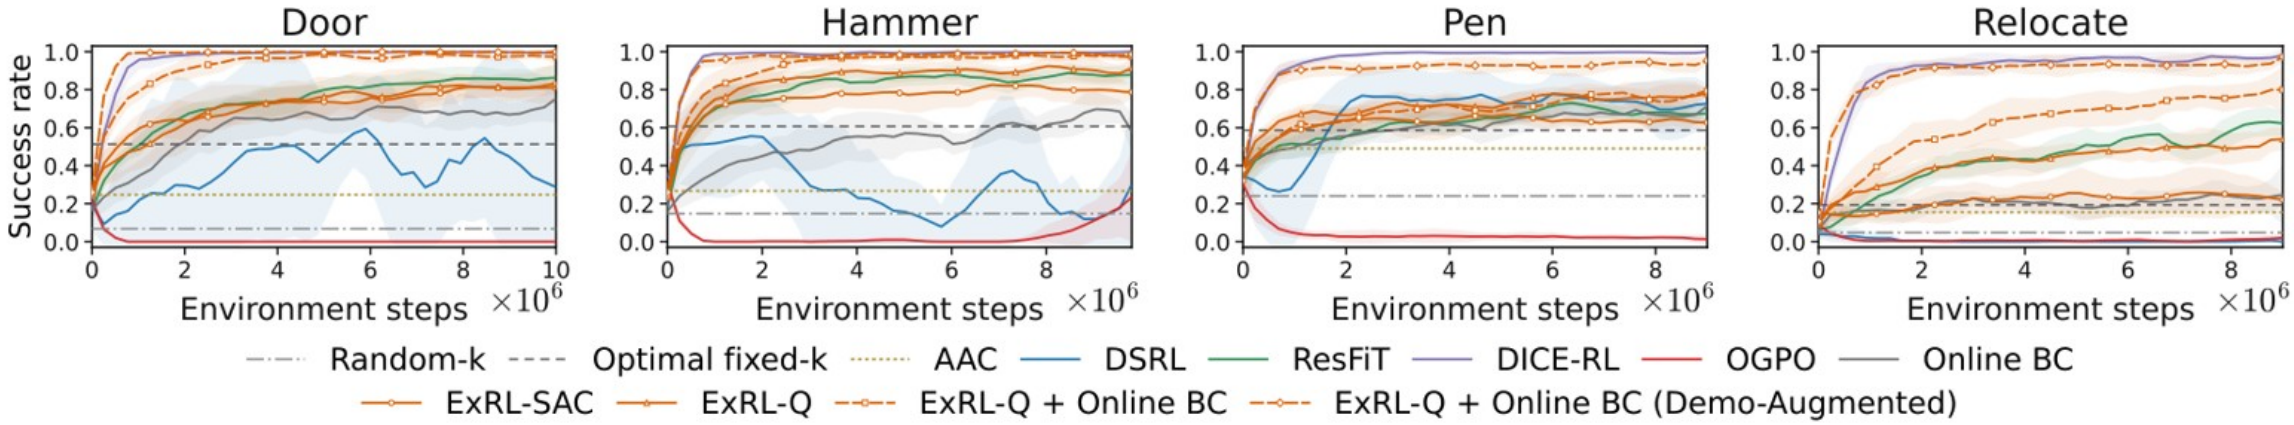

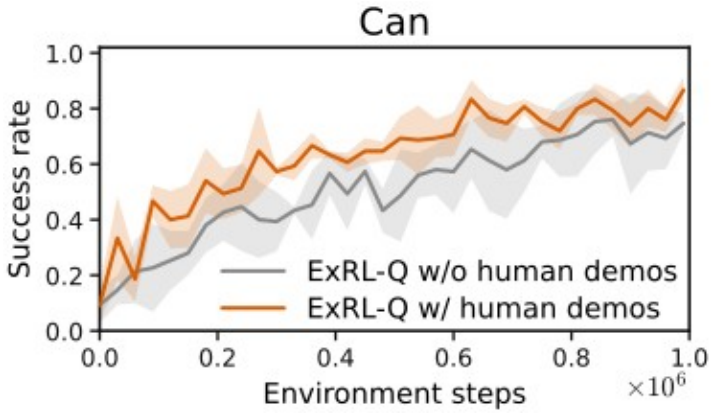

- Adroit （灵巧手， H=32 ）： 冻结底座的 ExRL 在 Relocate 上偏弱；加 Online BC 明显提升；再加示范后四个任务都接近 100% ，与 DICE-RL 等示范增强方法相当
- Robomimic： Online BC 对 DP Transport 尤其有效， ExRL-Q + Online BC 明显优于单独的 ExRL-Q 或单独的 Online BC
- 左图（ Can ， H=50 ）： 人类示范放进 RL 回放、底座仍冻结，早期学习更快

来源： Adroit 学习曲线（ Sec. V-C ）； Fig. 7

真机 π0.5 （冻结）： 4 个任务都明显超过固定执行长度

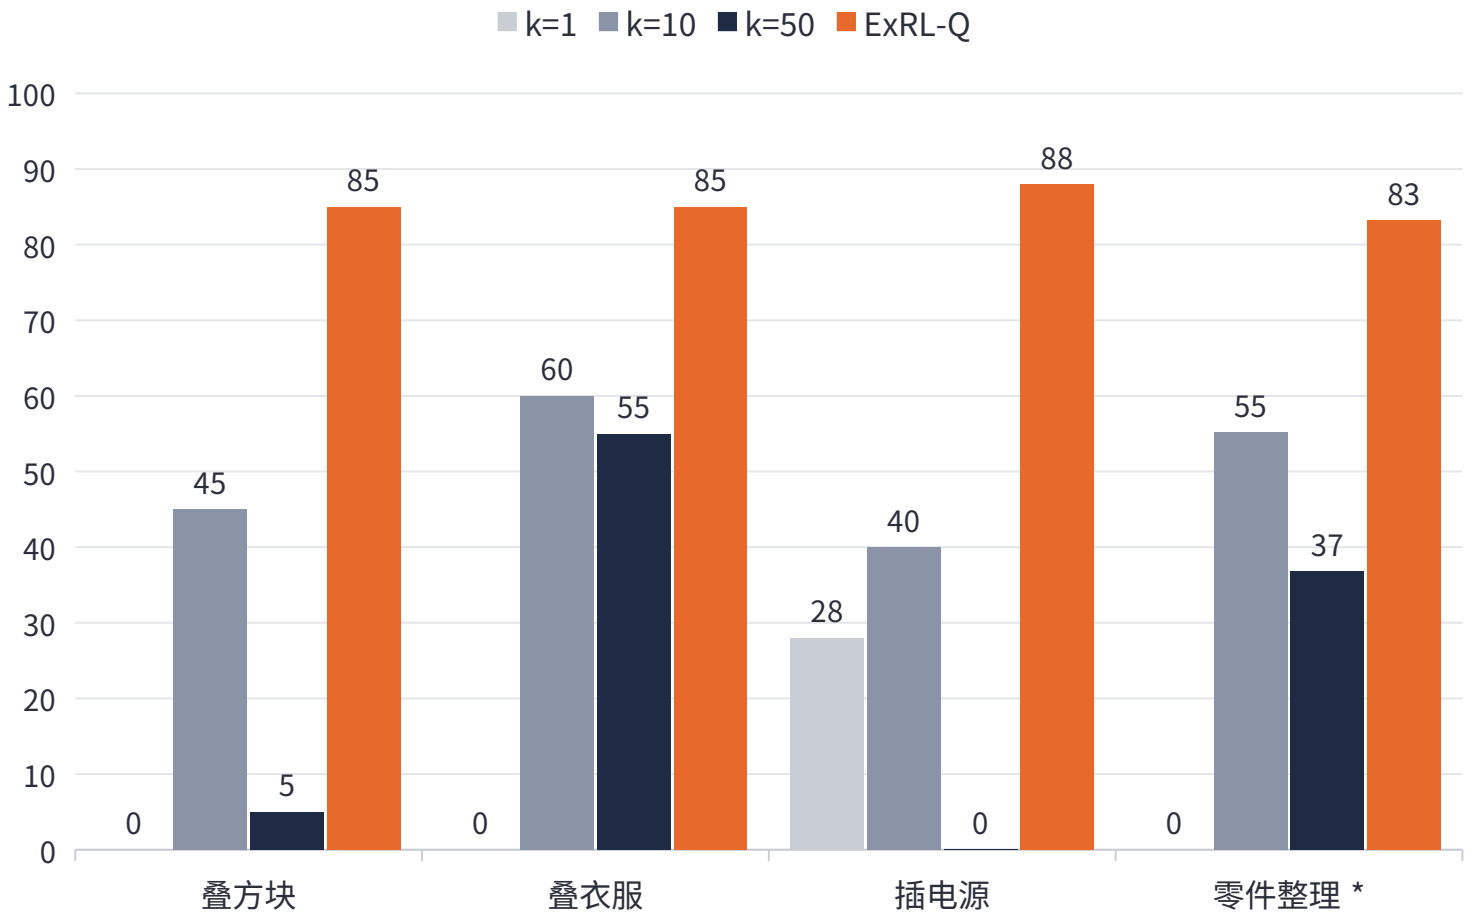

成功率 % （Table I： 17/20 、 17/20 、 22/25 、 104/125 ）； * 零件整理为完成阶段 / 总阶段

Power insertion task

Parts organization task

~10 min

叠方块接近 100%

~85 min

叠衣服接近 90%

- AgileX Piper 单臂， 20 Hz ， H=50 ；只更新执行长度 critic
- 插电源、零件整理：几百次 rollout 内提升
- 后期改为按物理时间（含推理停顿）计奖励和折扣，约束过度重规划

来源： Table I ； Fig. 12 ；附录 A-G

关键设计都有用：时长感知 TD 、 critic 看到动作块、离线策略学习

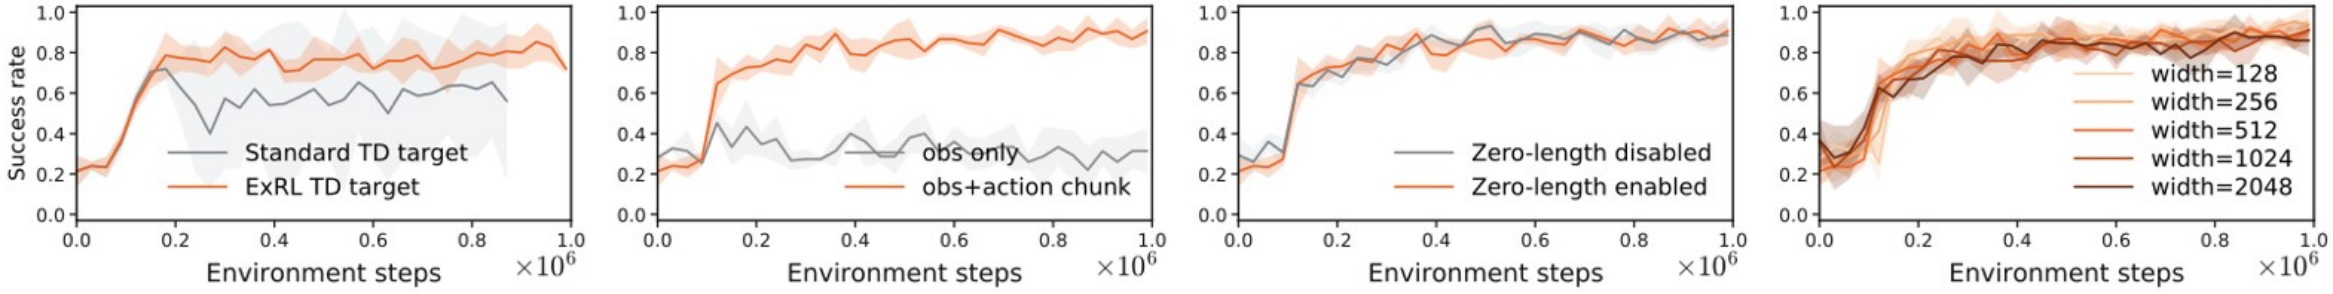

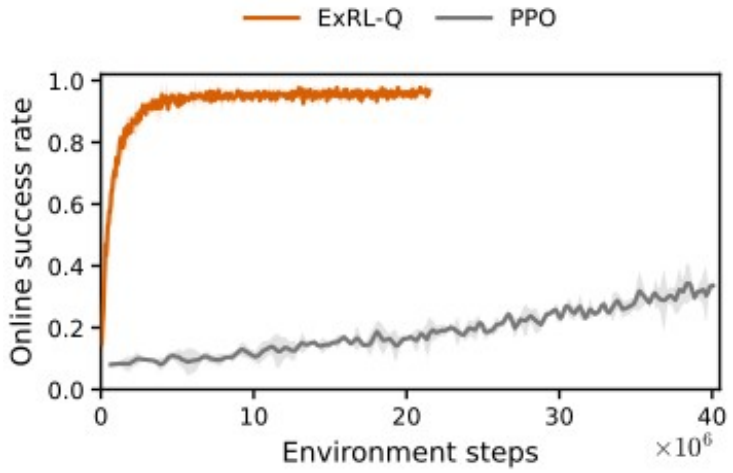

时长感知 TD 目标	≈0.8 vs 一步式标准 TD ≈0.6 ，且后者不稳定
critic 看到预测动作块	≈90% vs 只看观测 ≈ 30%
允许 k=0 / 宽度 128–2048	几乎无差别 → 不需要精调网络容量
离线策略 vs PPO （左图）	ExRL-Q 约 3M 步 >90%； PPO 40M 步仍 <40%

来源： Fig. 8 （消融）； Fig. 14 （附录 B， Can， H=50 ）

学到的策略：接近交互时缩短执行，自由运动时拉长执行

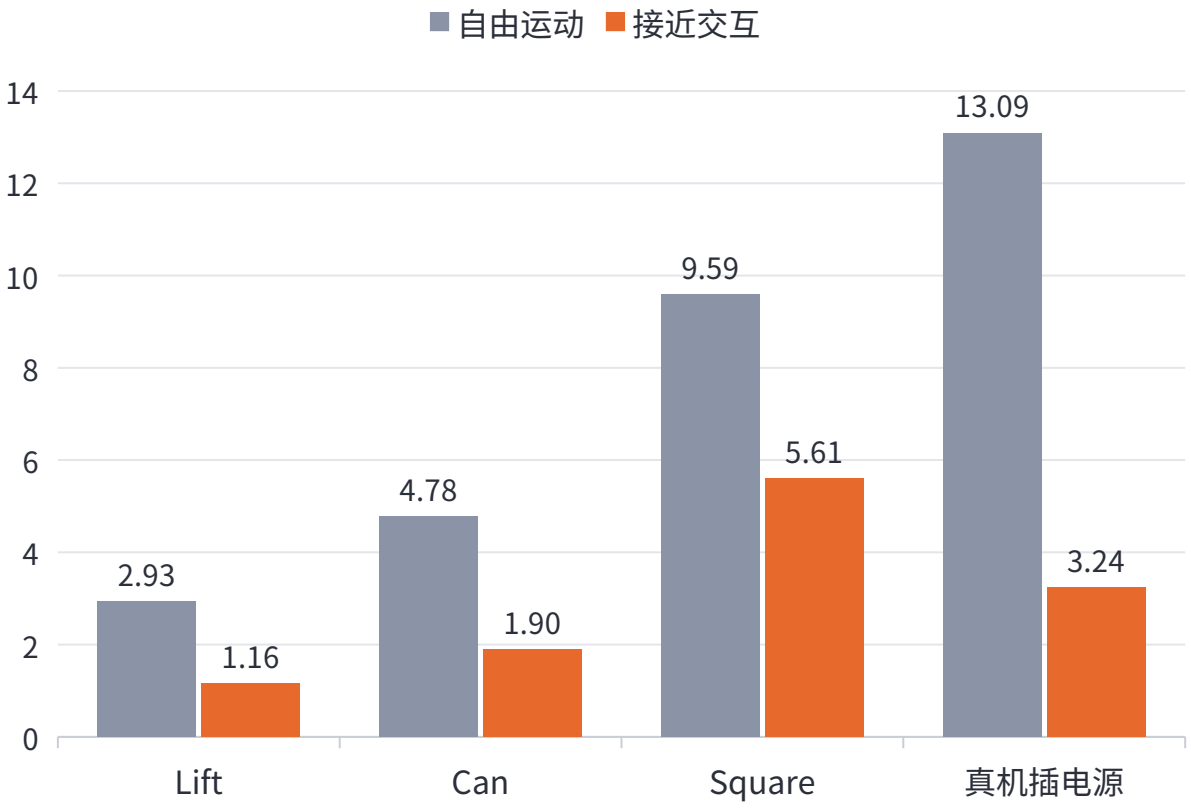

平均执行长度 k （Fig. 9a）。9 个仿真“任务 × 种子”组合和真机上都在交互附近缩短 k；距离阈值取 6 / 8 / 10 cm 结论不变。

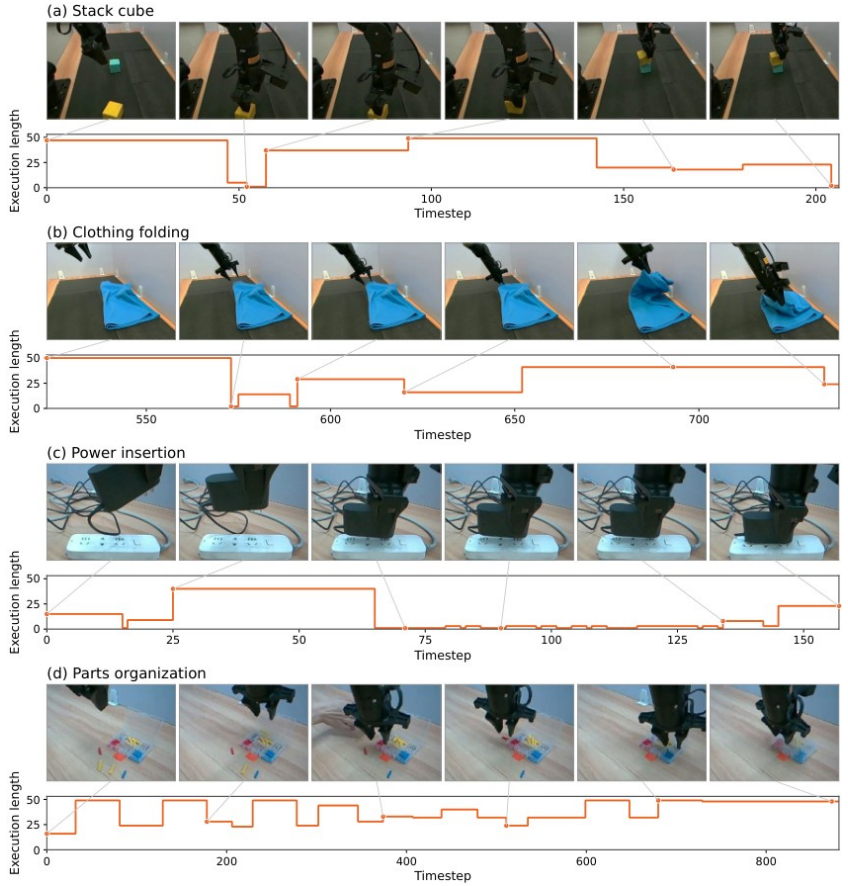

真机：叠方块 / 叠衣服在抓取附近短、搬运时长；插电源在接触段持续短 k；零件整理全程偏长。

来源： Fig. 9(a)； Fig. 17 （附录 D-A）

关键在“何时用哪个 k”：打乱分配后成功率降 38–58 个百分点

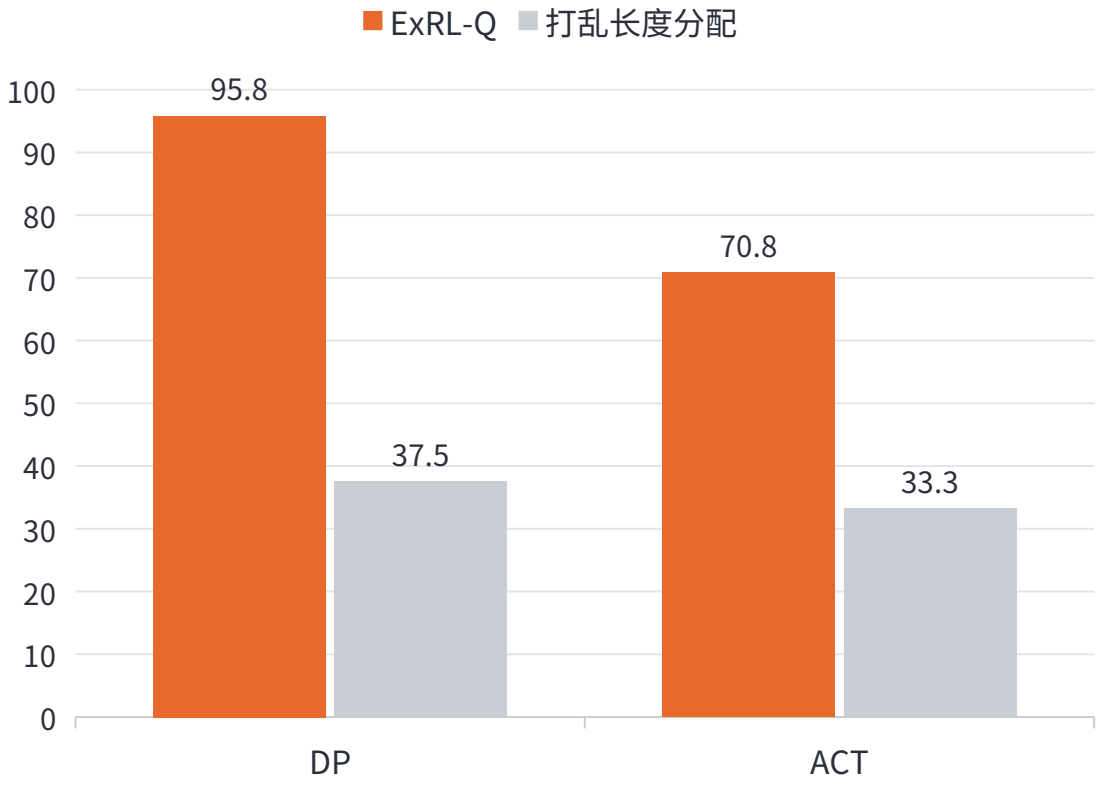

Square （H=32）成功率 %，每组 24 次配对 rollout （共享初始状态、初始动作块和推理随机性）。增益（95% CI）： DP 58.3 [37.5, 79.2]， ACT 37.5 [16.7, 58.3]。

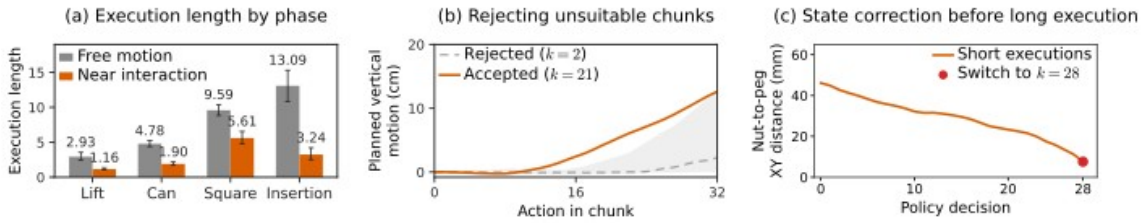

短执行 ① 拒绝坏预测

Square 上反复以 k=2 截断几乎不动的动作块，直到出现规划了约 12 cm 抓取抬升的动作块，再以 k=21 执行（图 b）

短执行 ② 小步纠偏

连续短执行把螺母到桩的 XY 距离从约 45 mm 缩小到约 8 mm，然后切换到 k=28 完成（图 c）

来源： Table VIII （附录 D-B）； Fig. 9(b)(c)

学到了什么 · ③

为什么不能总用短 k：特征混叠会让每步重规划反复“重启”同一个动作

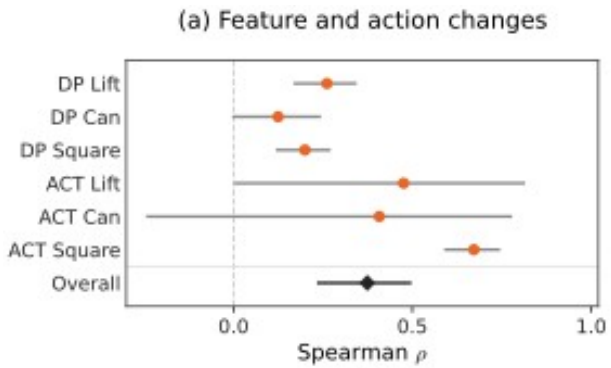

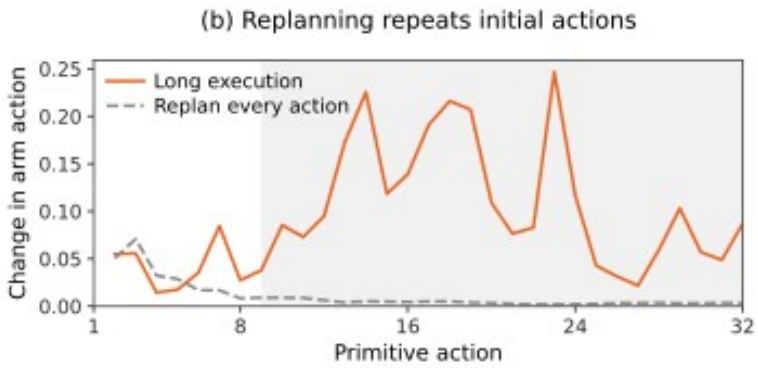

ρ = 0.374

特征变化与新预测首动作变化的 Spearman 相关（95% CI [0.237, 0.494]），DP / ACT × 3 任务全为正

3.6%

ACT Square：每步重规划时末端移动 19.4 mm，指令变化却只有沿原动作块执行时的 3.6%

从 3 个选定的 ACT Square 状态出发（Table IX，诊断样例，非基准成功率）：

一直 k=1 → 1/3 · 先 k=32 再用 ExRL-Q → 1/3 · 全程 ExRL-Q → **2/3**

启示：在“需要新预测”和“让已有预测继续展开”之间做平衡，这是固定策略做不到的。

来源：Fig. 18；Table IX（附录 D-C）

评价

优点很实用，但结论的适用范围要看清

优点

- 切入点简洁：表达力随 H 增长、优化维度不增长，和 Fig. 11 的证据衔接紧密
- 真正与策略结构无关：只要求底座能输出动作块，对闭源 / 超大 VLA 、世界模型友好
- 工程友好： ExRL-Q 没有 actor 、对网络宽度不敏感、超参大多共享；真机只需 10–85 分钟量级的交互
- 分析扎实：打乱对照和特征混叠解释了“为什么只改长度就够”

局限与疑问

- 冻结底座有上限；真机未用 Online BC ，部分任务仍未到 100% （作者自述）
- 设定偏向长动作块：许多基线原本按短动作块设计；H=32 时差距明显缩小
- 底座 checkpoint 刻意留有提升空间（如 ACT Lift 只训练 0.12 个 epoch ）
- 短 k 意味着更多大模型推理；仿真中的计算成本未单独比较
- 单任务训练；未验证多任务泛化，也未与 RTC 等异步推理结合（作者自述）

来源： Sec. VII Limitations ； Table II ； Fig. 13 ；解读者评价

带走三点

01

“何时重规划”是被低估的控制量

对长动作块策略而言，只调执行长度就能解锁底座里已有的大量能力

02

低维离散接口 + 离线策略 RL

让在线适配的样本量降到真机可承受的量级：几十分钟或几百次 rollout

03

实用路线：先调长度，再蒸馏

先用 ExRL 低成本、不改权重地提升，再用 Online BC 把发现的行为写回底座