论文解读 · arXiv:2611.14256

A Cross-Scenario Survey and Analysis of Self-Evolving Multimodal Agents

自进化多模态智能体：为什么机制换个场景就不灵了？

MR 多模态推理 | MG 多模态生成 | GW GUI/Web 导航 | EM 具身操作

作者： Jingjing Jiang | 首次提交： 2026-11-10 | 主页： jingjing12110.github.io/SE-MMAgents

一句话总结

用「经验生成 → 反馈获取 → 更新固化」三阶段循环统一四类场景，以**「rollout 数上限 K_max × 反馈保真度上限 F_max」**给场景定位，再把每种自进化机制看作**「借用任务结构资源去提升稀缺因子」的交易**，从结构上解释机制跨场景迁移为何不对称，并给出可证伪的可移植性裁决与测量议程。

① 分析框架

三阶段循环 EG / FA / UC

每阶段 = 两个相乘的因子

② 定位矩阵

K_max （能负担多少次尝试）

× F_max （反馈能有多可信）

③ 机制即交易

提升哪个因子 · 预设什么资源

→ 可移植 / 有条件 / 阻断 / 冗余

④ 测量议程

裁决尚未验证

指出哪些对照实验能推翻它们

注意：所有可移植性裁决都来自单场景证据推理，是「可检验的前提条件」，不是迁移增益的经验保证。

问题：同一对场景，机制迁移的两个方向遇到的障碍不同

多数投票：推理 → 机器人

在推理中：对采样答案做一致性投票，直接得到无标签奖励

在机器人上：动作轨迹无法判等，物理 rollout 还要付执行与重置成本

⇒ 找不到对应物（缺少「输出可判等」这一资源）

世界模型：机器人 → 推理

在机器人上：用想象 rollout 绕开昂贵的环境交互

在推理中：直接从策略采样本来就便宜

⇒ 提升的是一个并不稀缺的因子（冗余）

但四个场景共享同一个循环：生成探索性经验 → 获取评价反馈 → 固化持久更新

已有综述的空白（Table I）：要么不把自进化循环作为分析对象，要么把它当作与场景无关；最接近的工作也只把可验证反馈和重训练成本归到领域层面，而不落到具体机制。本文聚焦 **跨场景可移植性**。

贡献 1 条件式定义与范式划界	**贡献 2** 分阶段综述与定位矩阵	**贡献 3** 跨场景有向可移植性	**贡献 4** 可证伪的测量议程

定义：自主学习循环（4 条判据） + 自指 = 自进化

C1 自主性

初始化后，目标、反馈、更新与动作流中都没有人工输入（事先固定的任务集、检查器、裁判算 bootstrap ）

C2 新鲜性

每轮经验来自当前策略，而不是静态数据集

C3 持久性

更新写入参数、长期记忆、工具或接口，跨越 episode 边界

C4 递归性

循环迭代不止一轮，每轮输出成为下一轮的智能体

种差：自指（Self-Reference, SR）

智能体自己至少实现一个元算子：目标采样器 σ、反馈函数 V 或进化算子 f。缺少自指的自主学习循环称为「固定循环」，在全文中充当对照组。

溯源矩阵 Γ：行 = 元算子，列 = 实现方（h 人 / b bootstrap / e 环境 / a 智能体）

SimpleVLA-RL （固定循环）

	h	b	e	a
σ	0	1	0	0
V	0	1	0	0
f	0	1	0	0

VisPlay （自进化）

	h	b	e	a
σ	0	1	0	1
V	0	0	0	1
f	0	1	0	0

判据可以直接读矩阵： C1 ⇔ h 列全为 0； SR ⇔ a 列不全为 0。 VisPlay 由内部 Questioner 出题、对自己的答案投票打分，所以 σ 和 V 两行出现 a 。

划界： 16 个邻近范式里，只有 4 个按定义就是自进化

5

在「属」之外

- 自训练（作用于分类器）
- 测试时适应
- 测试时扩展（不持久）
- 自纠错（单回合内）
- 交互式模仿学习（专家动作进入数据）

2

从不满足种差

- 持续学习（任务流事先固定）
- RLHF （奖励模型拟合人类偏好）

5

由种差划分

- Self-Improvement
- RLVR
- Agentic RL
- 提示 / 工作流优化
- 经验学习

4

按定义即自进化

- Self-Play （σ）
- 自动课程学习（σ）
- 自奖励 / 无标签 RL（V）
- 递归自我改进（f）

争议边界取决于 a 项：同一批次中丢弃打平的组不算自指，按任务成功率分配后续 rollout 才算；

进化算子看「谁写更新」： TextGrad 由另一个固定模型（GPT-4o）指导 → 固定循环； ExpeL 的洞见、 STaR 的推理链由行动模型自己写 → 自进化。

与已有综述不同：在固定数据集上用环境或规则奖励做 RL （如 SimpleVLA-RL ）若智能体不实现任何元算子，不算自进化。

分析框架：每轮循环 = 三个阶段，每个阶段的有效性 = 两个因子相乘

① 经验生成 EG

上限 K_max

元算子：目标采样器 σ

$$Q = K_k \times E[I]$$

- K_k：每个目标的 rollout 数，受上限 $K_{max} = B / E[c(\tau)]$ 约束
- I：回报方差（二值奖励下为 $p(1-p)$），已掌握或够不着的目标 $I \approx 0$

决定：进化的速度与广度

② 反馈获取 FA

上限 F_max

元算子：反馈函数 V

$$Q = (2F_v - 1) \times L_v$$

- F_v：反馈排序与真实回报排序的一致率，受上限 F_{max} 约束
- L_v：能分配到信用的环境动作比例

决定：与真实奖励 R 对齐的方向

③ 更新固化 UC

元算子：进化算子 f

$$Q = S_\zeta \times G_\zeta$$

- S_ζ：后续若干轮之后仍保留的增益比例
- G_ζ：增益泛化到未采样目标的比例

决定：保留与泛化

↺ **跨周期耦合：** agent edge （更新 → 下一轮 rollout 策略） + goal edge （本轮轨迹与得分 → 下一轮目标采样）

为什么只有 K_max 与 F_max 做坐标轴? 只有它们同时满足「由场景任务结构外生决定」和「不能被同阶段另一个因子替代」。信息增益的上限由 backbone 覆盖决定； L_v 的不足可以用更高的 F_v 抵消； S_ζ、 G_ζ 没有场景固定的上限。

定位矩阵：四个场景各占一个象限，限制它们的上限不同

三种位移（橙色箭头）

① 仿真：成功谓词抬高 F_max、组采样放宽 K_max → EM 向 GW 移动（多数具身循环其实在仿真里学习）

② 可验证子族（OCR 打分提示、程序渲染图表）→ MG 向 MR 移动

③ 在线网站 / 自由形式目标没有状态脚本，只能靠截图裁判 → GW 向 EM 移动

要点

两个非对角格——便宜但可被利用的生成、昂贵但可验证的导航——是单一「难度排序」会合并掉的组合。

局限：定位来自各场景报告的数值推断； backbone 预训练覆盖是混杂因素。

各场景的瓶颈落在不同阶段、不同因子上

阶段 / 指标	MR 多模态推理	MG 多模态生成	GW GUI/Web 导航	EM 具身操作
EG 经验生成	质量（饱和）	质量	数量	两者（真机）
FA 反馈获取	实现的保真度 F_v^(k)	保真度上限 F_max	信用定位 L_v	两者（真机）
UC 更新固化	保留	保留	泛化	泛化
主要失败模式	长周期漂移	复合奖励黑客	分布偏移	遗忘与分布偏移
报告的组大小 K_k	4–10	3–16	8–64	8
单次 rollout 成本	一次解码	一次采样或工具链	每步环境延迟	每步延迟 + 回合重置

读法：相同数值不代表相同瓶颈。 MG 与 GW 报告的组大小重叠，但 MG 的采样便宜、可逆，受限于固定提示池的信息量； GW 的 episode 受延迟约束，受限于 K_max 本身。同样， MR 与 GW 都有高 F_max ，但 MR 的 $L_v = 1$ ，受限于自指带来的保真度下滑， GW 则受限于对长 episode 的信用定位。

多模态推理：瓶颈来自自指——放弃答案钥匙后，自产标签的保真度下滑

同一批 500 道人工审核题目上，保留标签的错误率（VQS）

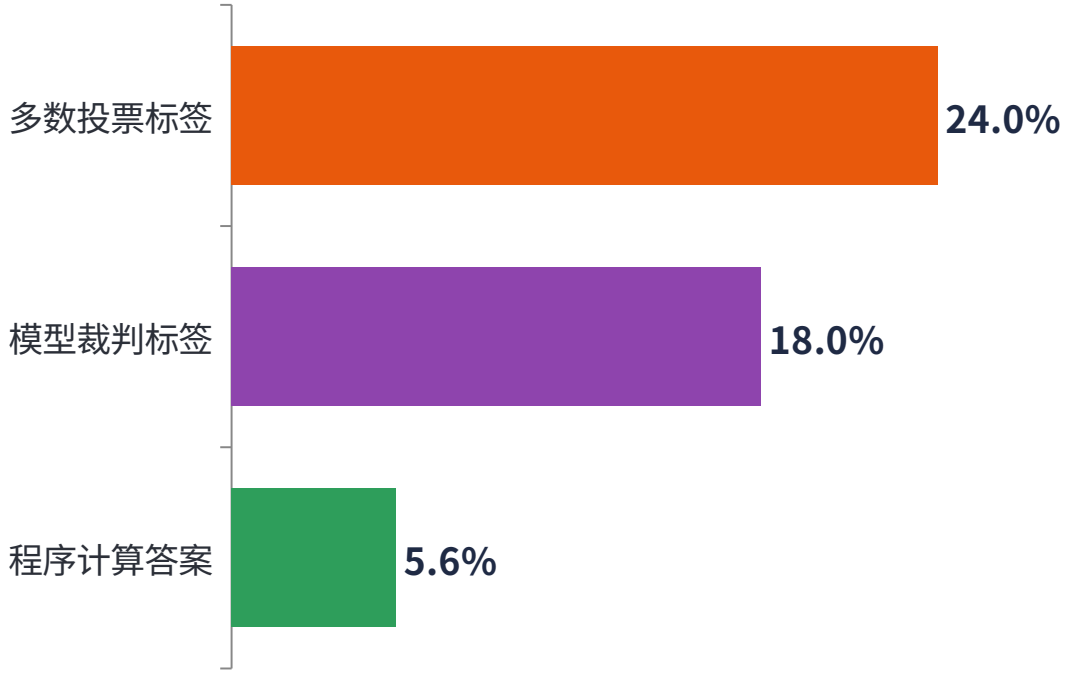

程序计算的答案在 94.4% 的保留题目上正确；共识和自评在第一轮就已低于这个水平。

一致性投票的前提：答案可判等，且预训练先验集中在正确答案上——后者由 backbone 决定，不由任务决定。

72.0→61.0

VisPlay 伪标签准确率（3 轮）

64.5→37.5

Video-Zero 伪标签准确率（5 轮）

4–6

EvoLMM 自洽奖励的最佳组大小；到 12 出现过度共识崩塌

30.61→44.16

VisPlay 受训 Questioner 一轮后；未训练 Challenger 只到 33.77

解读

两个上限都不紧，固定循环（如 M-STAR）用答案钥匙做精确匹配；自进化循环为了自己出题而放弃钥匙，代价落在反馈上。注意：跨轮准确率下降与题目难度上升相互混杂。

多模态生成：保真度天花板在自指之前就已经卡住

0.63→0.95

Flow-GRPO （固定循环）在 GenEval 上的提升——检查过的提示池随之饱和；但人类评分认为其图像质量低于基座

r = −0.17

ManimAgent 的冻结评审与 37 个教学视频人类盲评的相关系数

8.6 vs 0.5

RSI in UMMs：用执行验证的图表训练 vs 用冻结初始模型自评择优（相同请求与步数）的增益（点）

72%→60%

RSI in UMMs 换掉词表后旧词表上的精确文本保留率——唯一跨轮测量的保留

自验证器与策略的依赖程度不同，偏差形态也不同（ Table IX 的四组）

随策略更新的自验证器

生成置信度、理解分支 → 偏差随策略移动，易复合奖励黑客（ SOLACE 、 IRIS 在单次训练内退化）

共进化 / 滞后验证器

上一轮 LVLM 、共训 critic 、滑动平均教师 → 移动变慢

冻结自验证器

冻结初始模型或冻结 backbone 既评又写 → 偏差固定，但评判者与写入者共享同一偏差

外部 / 程序验证器

冻结外部打分器、程序执行 → 切断 agent edge ，但只覆盖可检查子族

GUI/Web 导航：每个 episode 都昂贵；写下的经验值多少取决于读者

2.5–4.0 s

每步延迟（UI-TARS-2 虚拟机）；一个 episode 最多 25 步，可达几十分钟

8–64

组大小靠并行实例买来， DigiRL 最多 64 个模拟器

11.3% / 18.1%

SEAgent 、 UI-Genie 的起始成功率——难目标上 $p(1-p)\approx 0$

同一份记忆，读者不同，效果相反（WebVoyager 成功率）

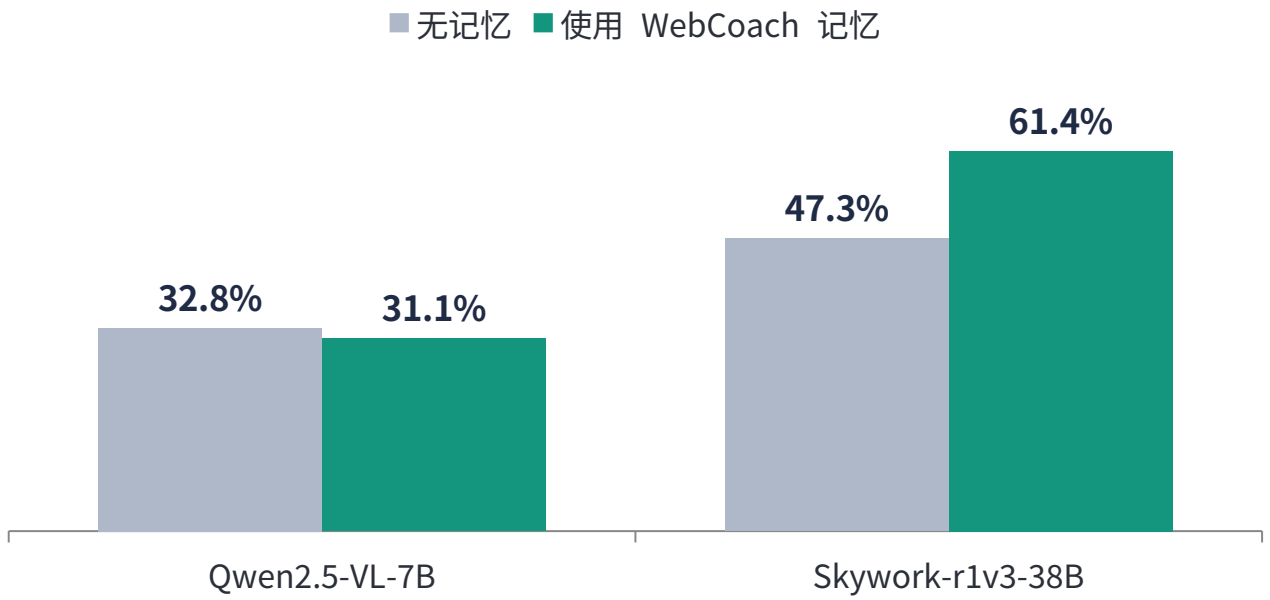

要点

提升信息量的三条路：复用（记忆 / 技能）、按成功率重加权（DART-GUI 、MobileRL ）、生成新目标（SEAgent 、 ACuRL ）。为得到步级信用而在自身轨迹上重拟合奖励模型，又让保真度随策略移动。 EvoSkill-GUI 的同骨干 critic 在 143 个审计失败中判错 28 个。

具身操作：离练习越远成功率越低；写入者之外的检验至关重要

SEAR： 测试离练习越远，成功率越低

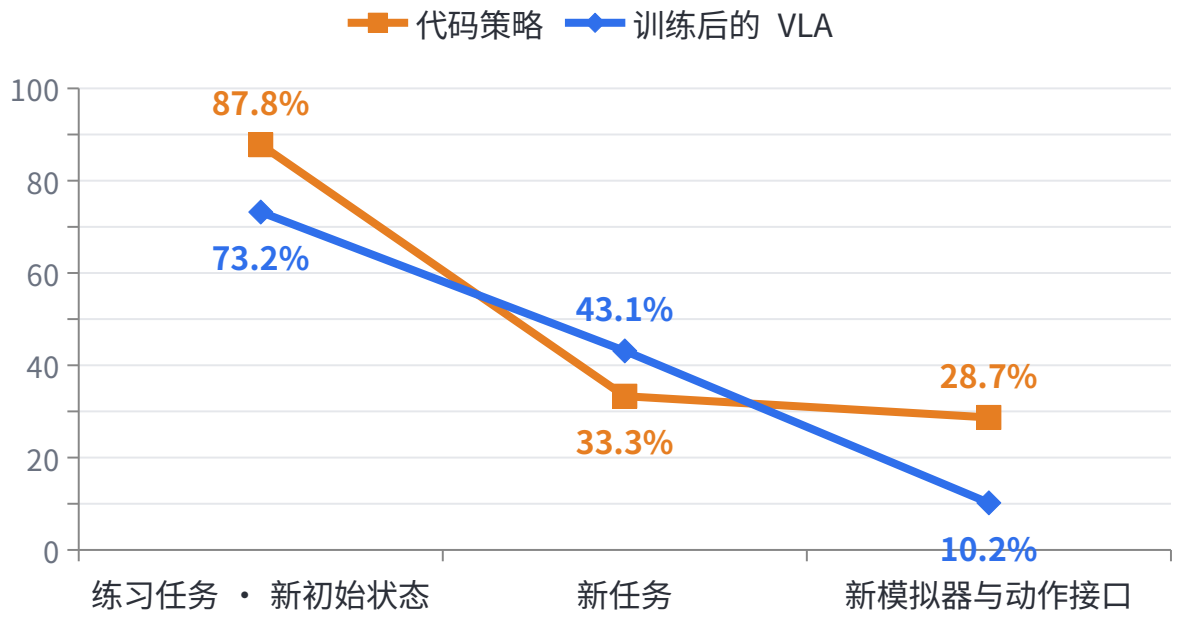

真机代价： Self-Improving EFMs 每次真实实验约 20 小时并需人工重置； Find Something 的 456 个自主 episode 中 6.58% 以只有人能恢复的场景结束；外部 VLM 裁判每次查询 2.6–16.9 s，真机裁判准确率 69%–100%。

Scale and Selection： 是否有写入者之外的检验

40%→0%

接受每一次修订
（20 轮）

51%→67%

champion-challenger 选择
（留出集成功率）

另一个反例： SEAR 某次运行把自校准但出错的放置验证器存进记忆，最终只有 4.6%，两次未保存的兄弟运行分别为 15.5% 和 23.6%。

要点

真机上两个上限对固定循环与自进化循环同样紧；自指改变的是「谁出题、谁打分、谁写入」，而不是物理 rollout 的成本或可达保真度。检验离写入者越远，保住的增益越多。

跨周期的五种退化：显现、传播与最佳缓解的位置未必相同

退化模式	跨周期机制	显现于	传播路径	主要缓解位置
① **复合奖励黑客**	FA 中每轮可容忍的保真度缺陷被反复放大为方向性偏差	UC	agent edge （V 读取智能体时进入 FA）	在 FA 收紧 F_v，或缩小更新步长
② **分布偏移**	rollout 漂出 V 的校准支撑，误差变成外推	FA	agent edge 、环境路径	在 FA 重新校准 V，或在 EG 重采样
③ **遗忘与可塑性丧失**	目标分布移动，参数写入相互干扰	UC	环境路径、 goal edge	在 EG 回放早期目标，或隔离 / 重置参数
④ **课程崩塌**	σ 把目标支撑收缩到已掌握区域， E[I] 衰减	EG	goal edge 或进入 σ 的 agent edge	向 σ 注入探索，或按难度给目标打分
⑤ **模型崩塌**	自生成数据使策略变窄、抹去尾部	EG	agent edge	累积真实或外部数据，而不是替换

最典型的错位：奖励黑客和遗忘都在 UC 显现，但更好的解法在上游——在 FA 收紧保真度、在 EG 回放。长周期漂移是前三种在同一任务族内叠加，不是第六种模式。现有循环只跑几轮，这些机制多由单次运行内与固定循环的证据推断。

机制即交易：提升一个稀缺因子，代价是预设某种资源

机制	入口	提升	预设的资源	代价
成功率条件分配	σ	E[I]	带可检查结果的固定任务集（T）	被刻意降权任务的覆盖
智能体出题	σ	E[I]	可检查结果或输出可判等（T）	放弃答案钥匙 / 脚本；标签准确率 72%→61%
程序可检查目标族	σ	E[I]	程序、模拟器或脚本化场景检查（T）	族外覆盖
世界模型想象 rollout	V	超越 K_max 的 K	可学习的短程动力学（T）	模型误差拉低 F_v；视频约 300 帧后退化
自洽投票	V	无钥匙的 F_v	输出可判等（T）+ 先验集中于正确答案（M）	每目标 K 次 rollout；标签错误
模型自我评判	V	无检查器的 F_v	生成 - 验证差距（M）	保真度随策略移动
生成置信度奖励	V	无检查器的 F_v	生成器的置信度（M）	保真度绑定于被更新的权重
在自身轨迹上重拟合验证器	V	L_v / 自由目标上的 F_v	有标签种子或参考集	保真度随策略移动
冻结自派生估计器	V	L_v / 自由目标上的 F_v	示范或初始模型校准	训练支撑之外的固定偏差
记忆 / 技能复用	f	G_ζ、难目标上的 E[I]	写入者的生成 - 验证差距（M）或在线检查（T）	暴露于写入者的错误

（T）任务结构资源　（M）智能体模型的能力　未标注 = 循环前编写的工件。**只有（T）类资源在场景间分布不均，因而决定裁决；（M）和工件被视为在所有目标场景都具备。**

裁决规则：可观测性 → 稀缺性 → 资源，依次判定四类结果

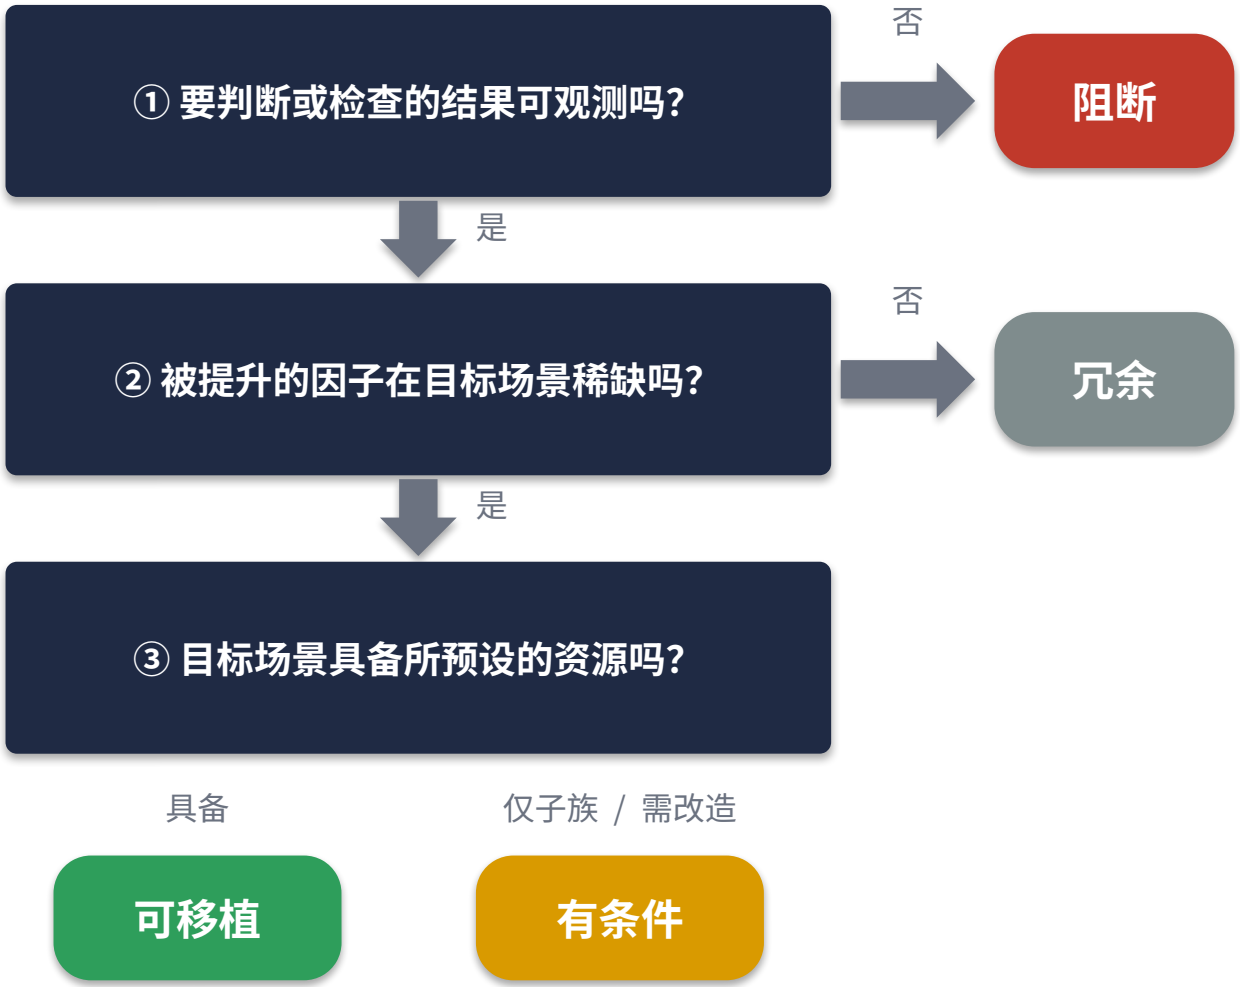

三类任务结构资源在四个场景中分布不均

资源	MR	MG	GW	EM
输出可判等	✓	✗	✗	✗
可检查结果	✓	仅程序可检查子族	✓（沙箱）	仅仿真
可重置、可并行 rollout	✓ 免费	✓ 免费	需购买实例	仅仿真

两条补充说明

- 可观测性单独决定阻断，连只依赖模型能力的机制也会被它挡住。
- 有资源不等于用上了资源：只有循环内运行的「在线检查」才能降低交易成本。任务流、开放提示、自选练习没有在线检查—— SEAR 某次运行保存的自建验证器在后续 91% 的 rollout 上出错。

跨场景不对称：裁决的类型主要由「目标场景」决定

MR → EM （真机） — 有条件

投票、目标机制变为「有条件」；在接触决定成败的子族上被「阻断」（ FailBench 中没有裁判超过 0.60 平衡准确率，总体最佳为 0.77 ）

EM → MR — 冗余

世界模型、估计器在有答案钥匙或程序计算答案的推理题上「冗余」（ rollout 便宜、 $L_v = 1$ ）

MG → GW — 冗余

生成场景的裁判在有在线检查的导航目标上「冗余」；但无检查的任务流上自我评判仍可移植

GW → MG — 有条件

导航的自建目标在开放提示上「有条件」：需借助图像提问、渲染图表或外部裁判

进入 MR 只遇到「冗余」；进入 MG 与真机主要是「有条件」的目标机制与投票；结果不可观测处（ GW 后台状态、真机接触装配）一律「阻断」。

稀缺性	决定冗余
任务结构资源	决定可移植 / 有条件
可观测性	单独决定阻断

评测：基准与裁判本身就不可靠，自进化智能体更容易被它们误导

43.6%

Sphinx-X-MoE 不看图在 MMMU 上的得分，比其语言骨干高 17.9 分

>90%→0.0%

VLA 在 LIBERO 上的成绩 → LIBERO-PRO 扰动下

+14.9

MemGUI-Bench：仅靠重试，M3A 就提升的分数

62.9–72%

最强多模态裁判在固定输出上的准确率

48.1%

VQA 策略上出现的奖励黑客比例

17.7

GenEval 与人类判断的最大偏差（分）

为什么对自进化更危险：用评测打分器来训练的循环（如在 LIBERO 上的 Reflection-VLA）会把记忆化的目标和打分器错误写进智能体。自进化基准很少，覆盖推理与生成的只有 Flex-RSI。

三个目前无法检验的主张

增益来自自进化

需要预算匹配的非进化基线（真机还要计入人工重置），以及循环拿不到的留出参照

场景定位正确

需要统一单位的 rollout 成本，以及在优化后输出上测得的 F_max

可移植性裁决成立

需要在目标场景中「不经改造直接迁移」的预算匹配对照；有条件裁决还需改造组

四个开放问题：答案的「是 / 否」会直接改写裁决

参照构建

能否在没有人参与的情况下，为不可观测的结果构造替代参照?

是 → 阻断变为有条件；否 → 阻断是结果本身的属性。现有四条路（输出转答案、程序、世界模型、 VLM 裁判）都只部分成功。

自派生验证

策略离开验证器形成时的支撑域后，任何依赖程度的验证器还能与 R 保持一致吗?

是 → 可靠性成为「依赖程度」的选择；否 → 生成与真机的低 F_max 成为结构性极限。

跨载体迁移

技能、 harness 、策略能否不经新经验跨读者、平台、本体（含 sim→real ）生效?

目前跨平台零样本迁移只见于固定循环 GUI-HARVEST （ GPT-5 +13.87 ）；尚无跨越仿真到真机边界的报告。

自主下的安全

没有人工否决时，循环能否跨周期保持安全性质?

现有证据显示安全性沿各条自修改路径下降： SEAgent 在 RiOSWorld 上的不安全完成率 39.5%→55.3% 。

总结与评价

三条带走的结论

1. 判断一个自进化机制能否搬到新场景，不要看场景「难不难」，而要看目标场景缺什么因子、有什么任务结构资源、结果能否观测。

2. 在两个上限都宽松的推理场景，瓶颈反而来自自指本身——放弃答案钥匙，换来随策略漂移的自产标签。

3. 任何自写入（技能、记忆、 harness ）都需要写入者之外的检验；离写入者越远，保住的增益越多。

优点

- 溯源矩阵让「什么算自进化」可以逐项判定
- 用固定循环作对照，分离场景限制与自进化代价
- 给出可证伪的预测与具体测量议程，如实标注证据局限
- 对具身研究启发明确：接触类任务可能不可观测， VLM 裁判有结构性缺陷

局限

- 裁决由规则推出，没有迁移实验支持
- 定位来自单场景估计，与 backbone 先验纠缠
- 溯源标注与分类轴由单人完成，且在识别瓶颈之后确定
- 未覆盖音频、触觉、力反馈；术语密集，可读性较差