arXiv 2611.14815 · 论文解读

BirdDreams

Joint Perspective and BEV Video Generation for a Plausible, Reactive Driving World Model

联合生成前视视频与 BEV 视频：一个可信、可反应的驾驶世界模型

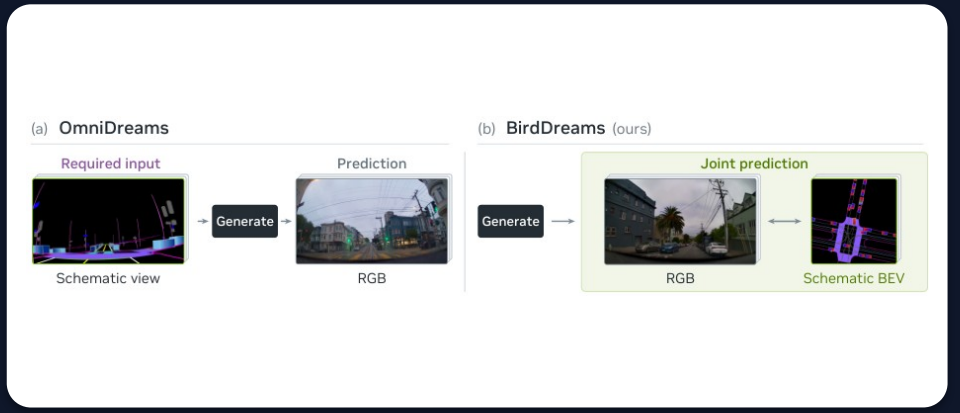

图源：论文 Fig. 1

Junyoung Seo, Jaewoo Seo, Seungryong Kim, Laura Leal-Taixé, Xiuming Zhang, Seung Wook Kim

NVIDIA · KAIST | 首次提交 2026-11-10

一句话总结：把场景布局从“输入”变成“联合预测的输出”

BirdDreams 用两个联合注意力耦合的因果视频扩散 Transformer，从**单张前视图像**同时生成前视视频与米制示意 **BEV 视频**；再把最新 BEV 帧按自车轨迹**平移 + 旋转**作为软动作条件——自车更听话，周车也能对反事实动作作出合理反应。

−35% / −36%

有自车动作条件时的 ADE
对比 OmniDreams (Plücker)
PhysicalAI-AV / nuScenes

−21% / −37%

无动作条件时的 minADE
对比同数据训练的 OmniDreams (Vanilla)
PhysicalAI-AV / nuScenes

57% : 24%

人评“周车行为更真实”的偏好
BirdDreams：基线（另有 19% 平局）
25 人，375 次成对判断

数据来源：论文 Tab. 1、Tab. 2、Fig. 8

现有方法的两难：周车要么只能回放日志，要么很难学好

布局条件化路线

如 OmniDreams：需要 HD 地图 + 周车未来轨迹作为输入

日志回放：自车偏离日志时周车不会反应

外部交通模型：交互预测在世界模型之外

纯透视视频学习

运动与纹理、光照纠缠

车辆经常被遮挡

同一像素位移 ≠ 同一速度（近大远小）

无布局基线在复杂路口会出现车辆消失或动作离谱

BirdDreams 的思路

把布局从“输入”变成“联合预测的输出”

推理时只需一张前视图像

不需要 HD 地图，也不需要车辆状态

图源：论文 Fig. 1

为什么用示意 BEV：它与透视 RGB 恰好互补

示意 BEV：擅长“动力学”

- 去掉纹理与光照，预测目标更简单
- 固定米制尺度：像素位移 = 相同物理距离
- 俯视视角，车辆之间遮挡少
- 车身前红后蓝，朝向一目了然
- 车辆相对道路、车道的关系很明确

联合
注意力

透视 RGB：擅长“外观与细节”

- 红绿灯状态等交通信号
- 路面细节与物体外观
- BEV 范围（约 69 m）之外的远处物体
- 最终交付给仿真的观测本身

BEV 渲染规范 正交俯视 · 自车居中、车头向上 · 每帧约 69.3 m × 69.3 m · 道路边界品红、人行横道紫、行人黄 · 车辆为有向长方体 · 训练时由地图 + 3D 框标注渲染（轨迹插值补帧和补遮挡，并去除重复框）

架构：双流因果 DiT，每个 Transformer 块都做联合注意力

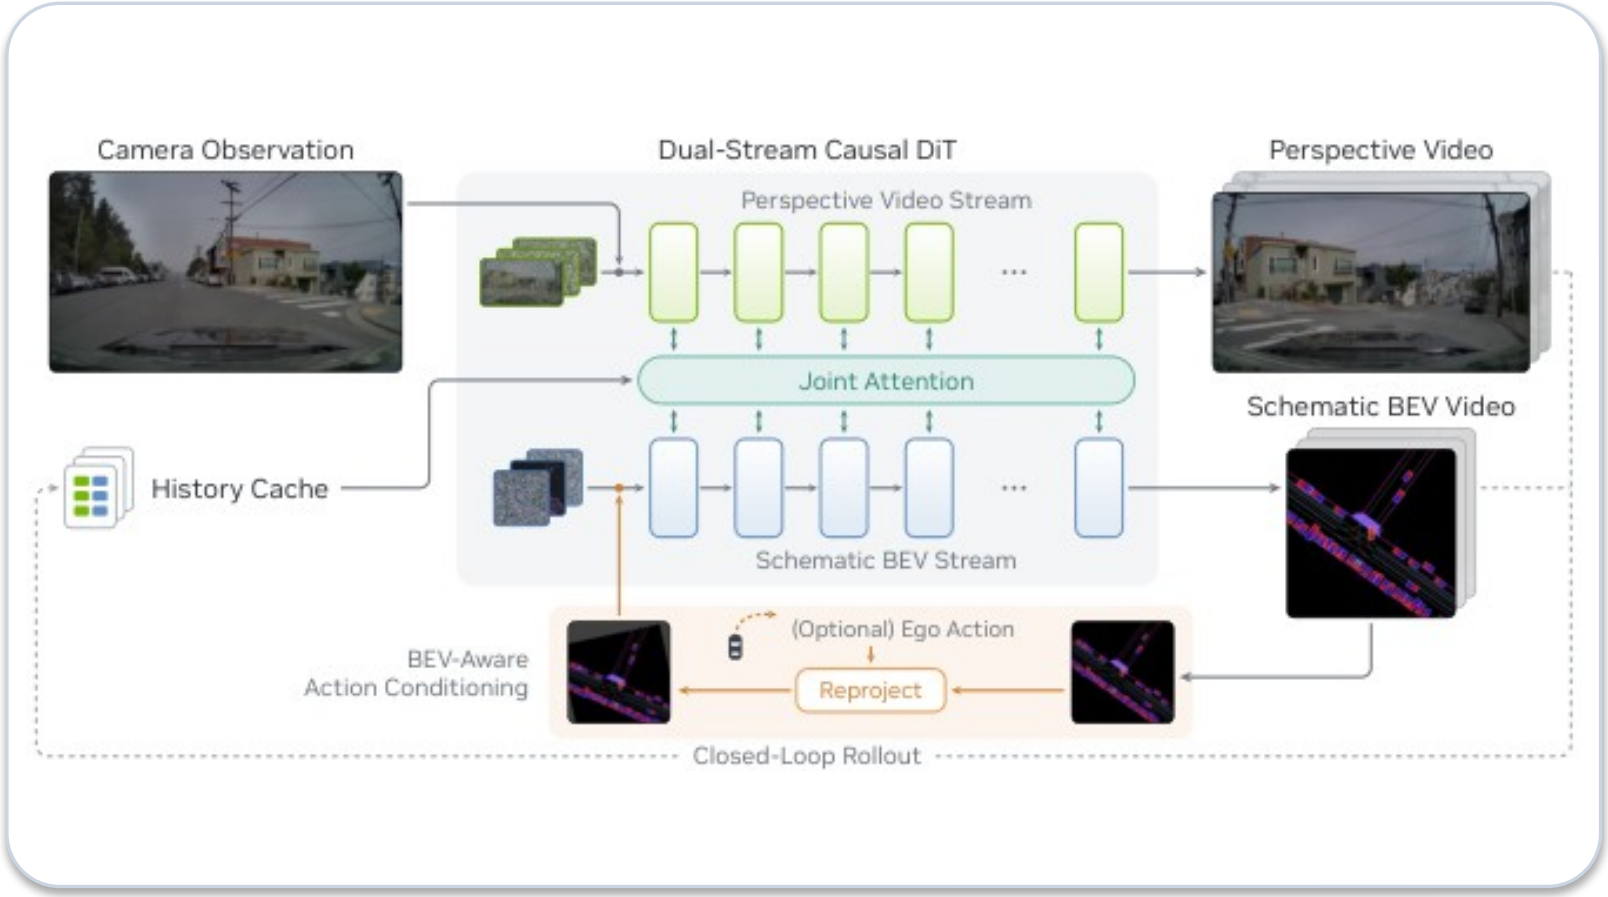

推理时：先由 I_0 生成 B_0，再逐 chunk 联合生成两路视频；每生成一个 chunk 就缓存其 KV，并把 BEV 参考帧更新为该 chunk 的末帧

权重共享初始化

透视分支 = 预训练 vanilla OmniDreams

BEV 分支 = 复制同一份权重

联合注意力 + 独立专家

每个块的 Q 同时看两流的 K/V

投影、FFN、输出头各自独立

块因果自回归

每 3 个潜帧为一个 chunk

chunk 内双向、chunk 间因果，配合 KV cache

≈4B 参数 · RGB 848×480 · BEV 480×480

图源：论文 Fig. 2；细节见 §3.2.1、§4.1

按流独立加噪：一条流可以“提示”另一条流，还带来灵活条件化

$$x = (1 - \sigma) \cdot z + \sigma \cdot \varepsilon$$

σ 在 chunk 之间、也在 RGB / BEV 两流之间独立采样

BEV 干净 + RGB 噪

道路几何、车辆位置 → 引导透视生成

RGB 干净 + BEV 噪

视觉特征（如红绿灯）→ 补全 BEV

两者都噪

通过联合注意力一起去噪

损失：每条流内部按潜元素数归一化，两流再等权，避免分辨率更大的 RGB 主导

灵活条件化：同一个模型，固定已知潜变量，只去噪其余部分（绿框为输入）

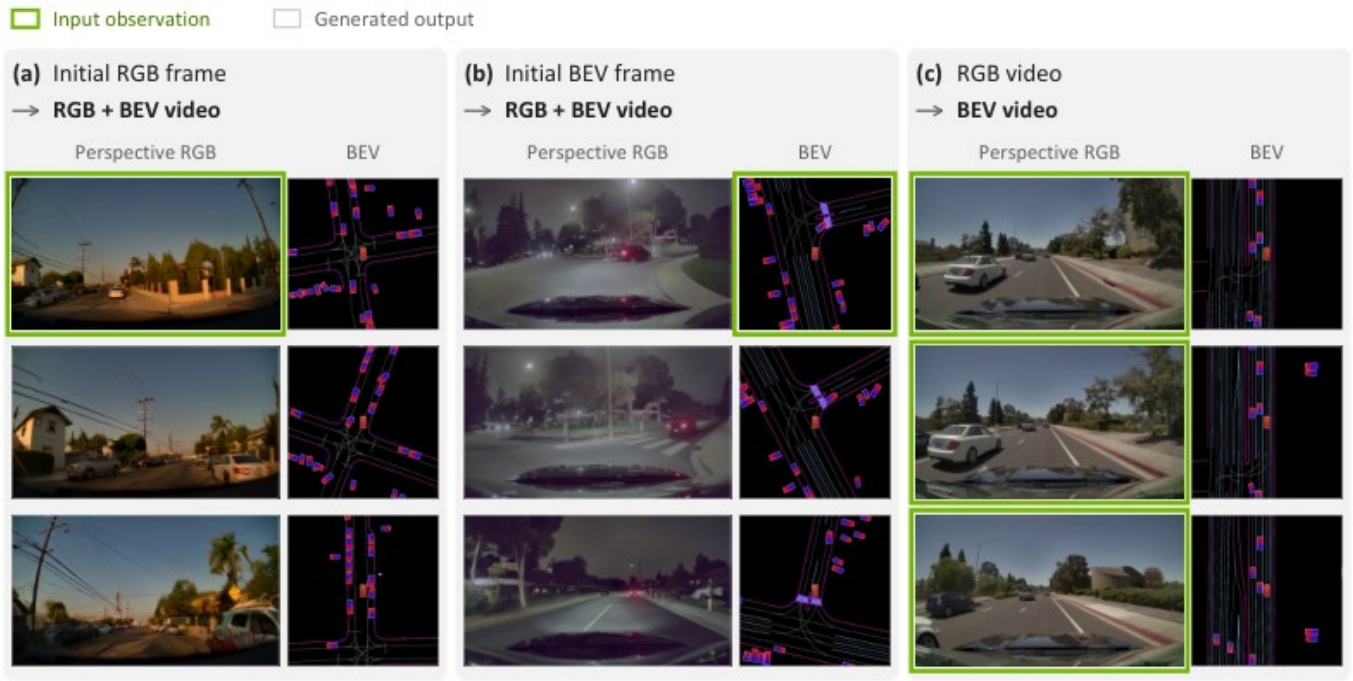

图源：论文 Fig. 3；方法见 §3.2.2、§3.2.5

动作接口：把上一帧 BEV 按自车轨迹做刚体变换，作为软条件

① 参考帧
上一 chunk 生成的 BEV 末帧 B_r（首块用 B_0）

② 刚体重投影
按每个位姿 (p_t, θ_t) 平移 + 旋转，见式 (4)

③ 编码加噪
VAE 编码
加少量噪声 $\sigma_{cond} = 0.1$

④ 软条件注入
零初始化投影
加到 BEV 输入 token

⑤ 跨流传递
联合注意力传给透视分支
→ 生成 RGB

$$\tilde{B}_t(u) = B_r\left(\Pi\left[R(\theta_r)^{\top}\left(R(\theta_t)\cdot\Pi^{-1}(u) + p_t - p_r\right)\right]\right)$$

Π：自车坐标（米）→ BEV 像素的映射；$R(\theta)$：二维旋转矩阵。含义：假设周围静止、只有自车在动时，场景看起来会怎样移动

为什么可行

正交 + 固定米制：平移 = 均匀像素位移

转向 = 绕自车旋转

不需要深度估计（对比 Gen3C 的 warp 渲染）

为什么是“软”条件

重投影只反映自车造成的视运动

监督目标是真实未来 BEV

周车运动和新出现的内容由模型补全

闭环与可选性

每个 chunk 后更新参考帧，条件反映新预测的场景

训练中随机丢弃条件

→ 同一个模型也支持无动作 rollout

两阶段训练：先 Diffusion Forcing，再 Resampling Forcing 抑制漂移

阶段 1 · Diffusion Forcing

历史 = 加噪的真值 chunk

噪声在 chunk 之间、 RGB/BEV 两流之间独立采样

flow-matching 损失，速度目标为 ε − z

阶段 2 · Resampling Forcing 微调

共享噪声 τ 腐蚀真值 → 一步 Euler 自回归去噪 → 预测历史（截断梯度）

让模型接触到自己历史中的误差

目标 chunk 依然独立加噪，并行训练

数据与算力 RDS-HQ-1M 子集约 670 h · nuScenes train 约 3.9 h （评测前后训练） · 64×H100 · AdamW, lr 3e-5

图源：论文 Fig. 4；细节见 §3.2.4、 §3.3、 §4.1

不给动作时： BirdDreams 生成的自车运动最接近真实日志

minADE ↓ （米， 3 个样本取最小） OmniDreams = Vanilla 版本

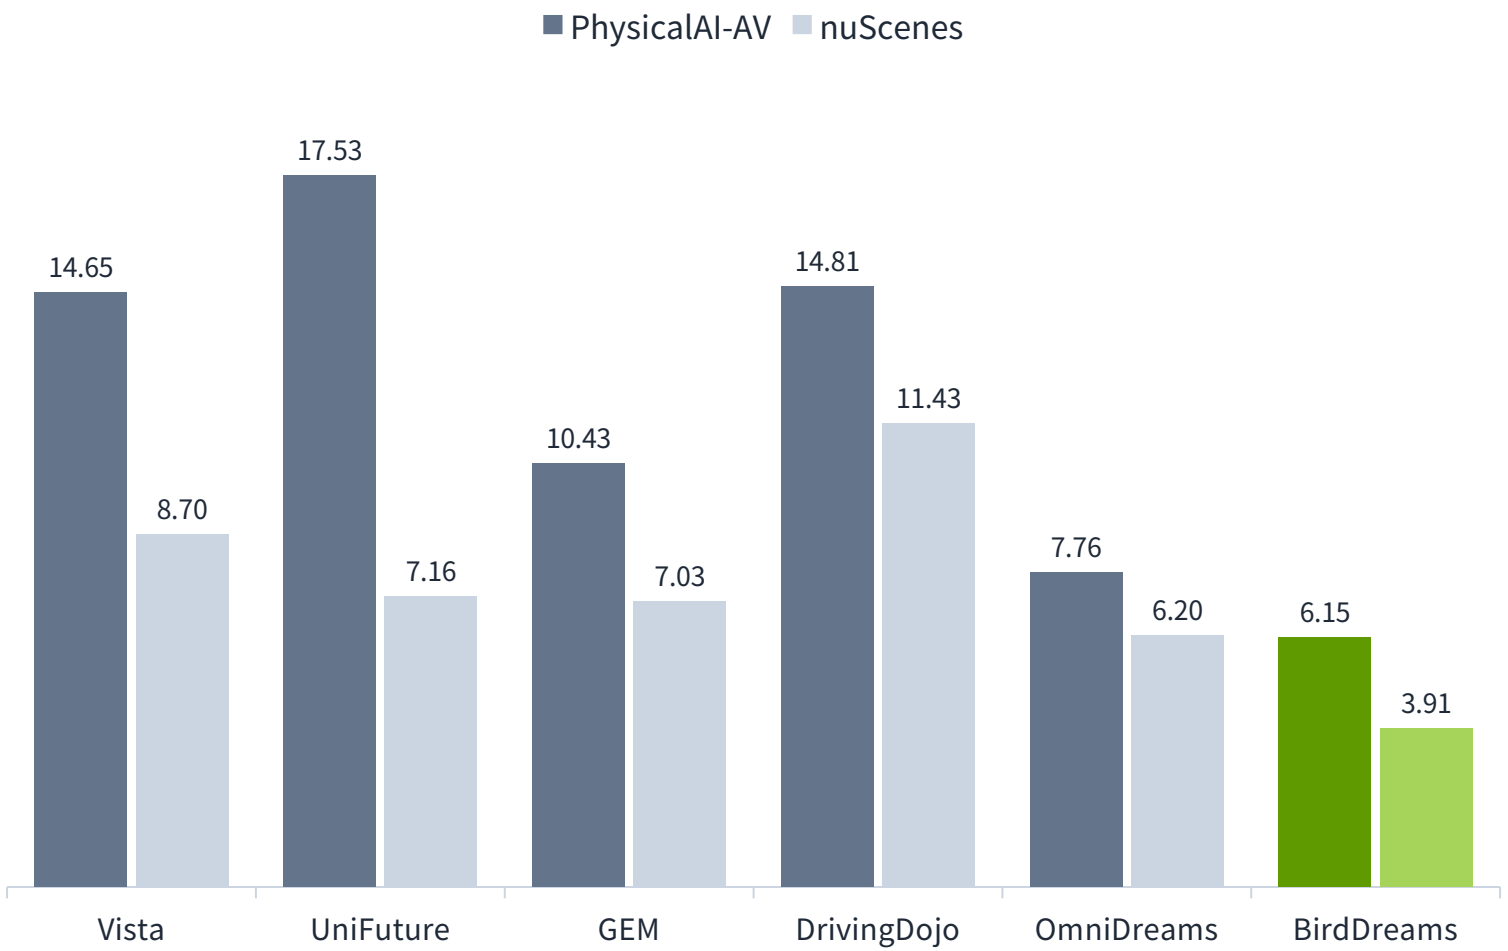

−21% / −37%

minADE vs OmniDreams (Vanilla)

4.15 → 0.43

nuScenes FTD （轨迹分布距离）

视频质量同样最好

FVD 271 / 309， FID 10.70 / 11.48 （均为最低）

Image Quality 0.428 / 0.439 只排第二，收益主要在运动上

数据来源：论文 Tab. 1 （每格为 PhysicalAI-AV / nuScenes ）

给定动作时： BirdDreams 在两个数据集上跟随轨迹都最准

ADE ↓ （米，单样本） OmniDreams = Plücker 版本

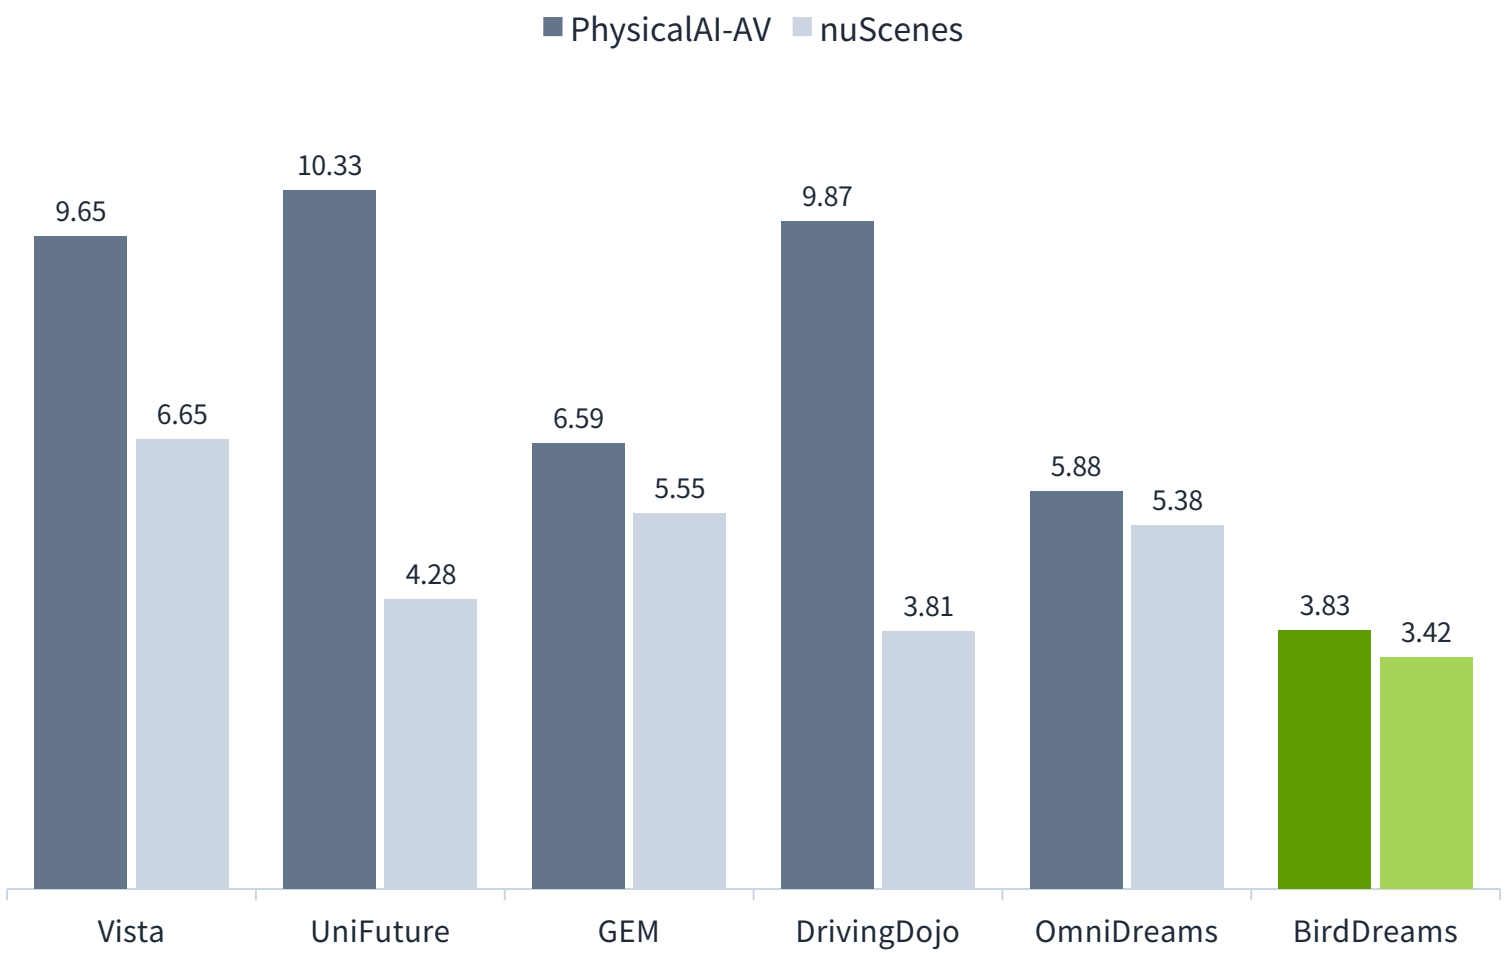

−35% / −36%

ADE vs OmniDreams (Plücker)

对比 OmniDreams (Plücker)

DTW 197.1 → 95.2 / 234.8 → 133.3
FTD 3.02 → 0.48 / 1.47 → 0.56
FVD 271.5 → 238.9 / 343.1 → 294.0
FID 15.35 → 11.81 / 18.27 → 14.80

注意

这组对比同时改变了“是否预测 BEV” 和“动作注入方式”，论文未拆开做消融

数据来源：论文 Tab. 2 （每格为 PhysicalAI-AV / nuScenes ）

周车会“反应”：自车改变行为，周围车辆会刹车、让行

(a) 不给动作

自车与横穿车相互避让，一起停下

自车运动由模型自主预测

(b) 自车强行通过

横穿车辆停下让行

(b) 自车切入车道

后车减速，保持车距

动作极端、无法避让时会发生碰撞，作者认为这同样是合理结果

同样给定道路几何时，只用透视视频的基线常出现不合理的车辆运动

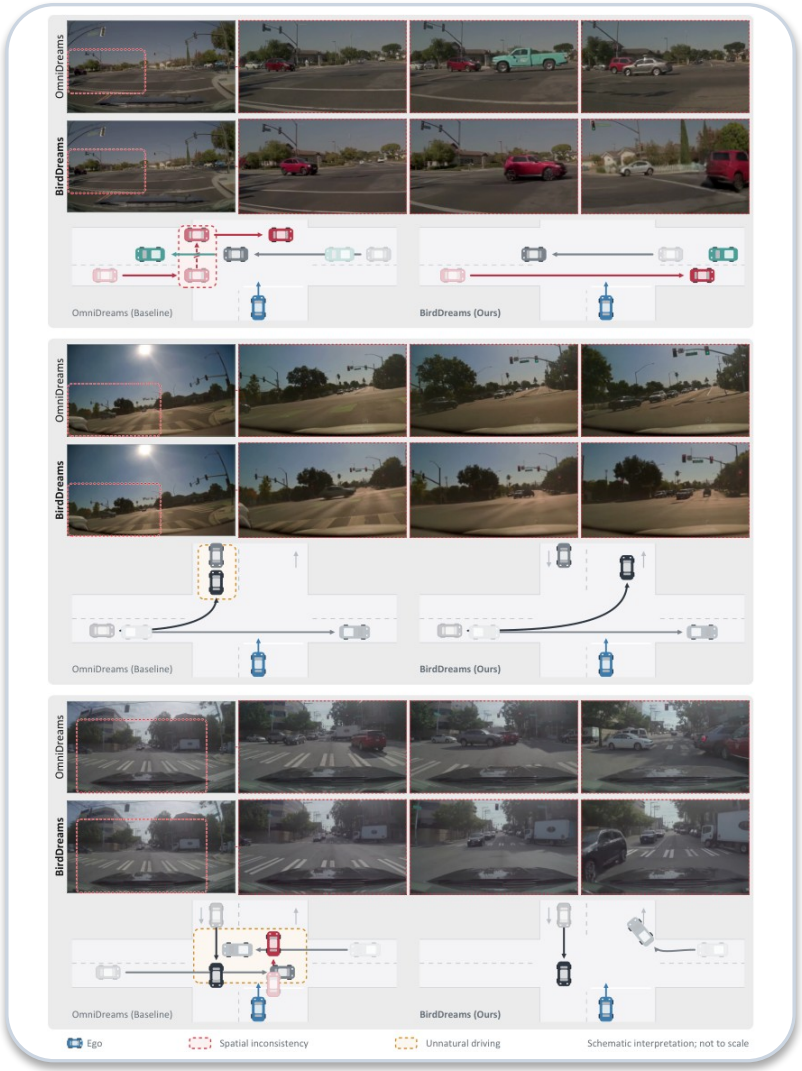

对比设定（公平起见）

OmniDreams (HDMap) 与 BirdDreams (HDMap)：相同初始观测、反事实自车动作和静态道路几何，都不给周车状态，周车运动全靠模型预测

场景 1 · 路口横穿

基线 红车中途“跳”到对向车道（空间不一致）

BirdDreams 红车沿同一条车道平滑横穿

场景 2 · 左转

基线 左转车转入后与同车道车辆挤在一起（驾驶不自然）

BirdDreams 左转车顺利进入正确车道

场景 3 · 城市路口

基线 多车在路口中心路径冲突，交互不连贯

BirdDreams 对向车直行、侧向车转弯，交互一致

图源：论文 Fig. 6；设定见 §4.3

人评： 57% 的判断认为 BirdDreams 的周车行为更真实

(a) 总体偏好

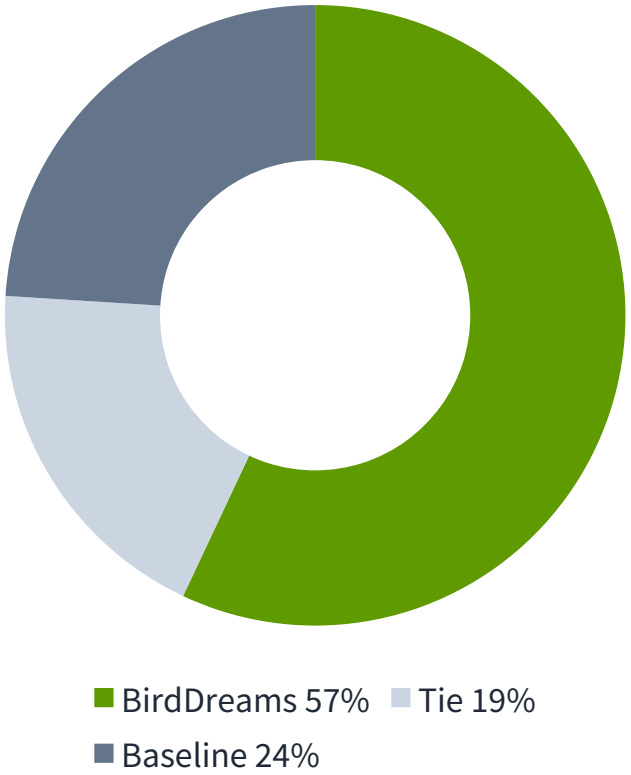

(b) 为落选视频标记的问题（占全部 375 次判断的比例，可多选）

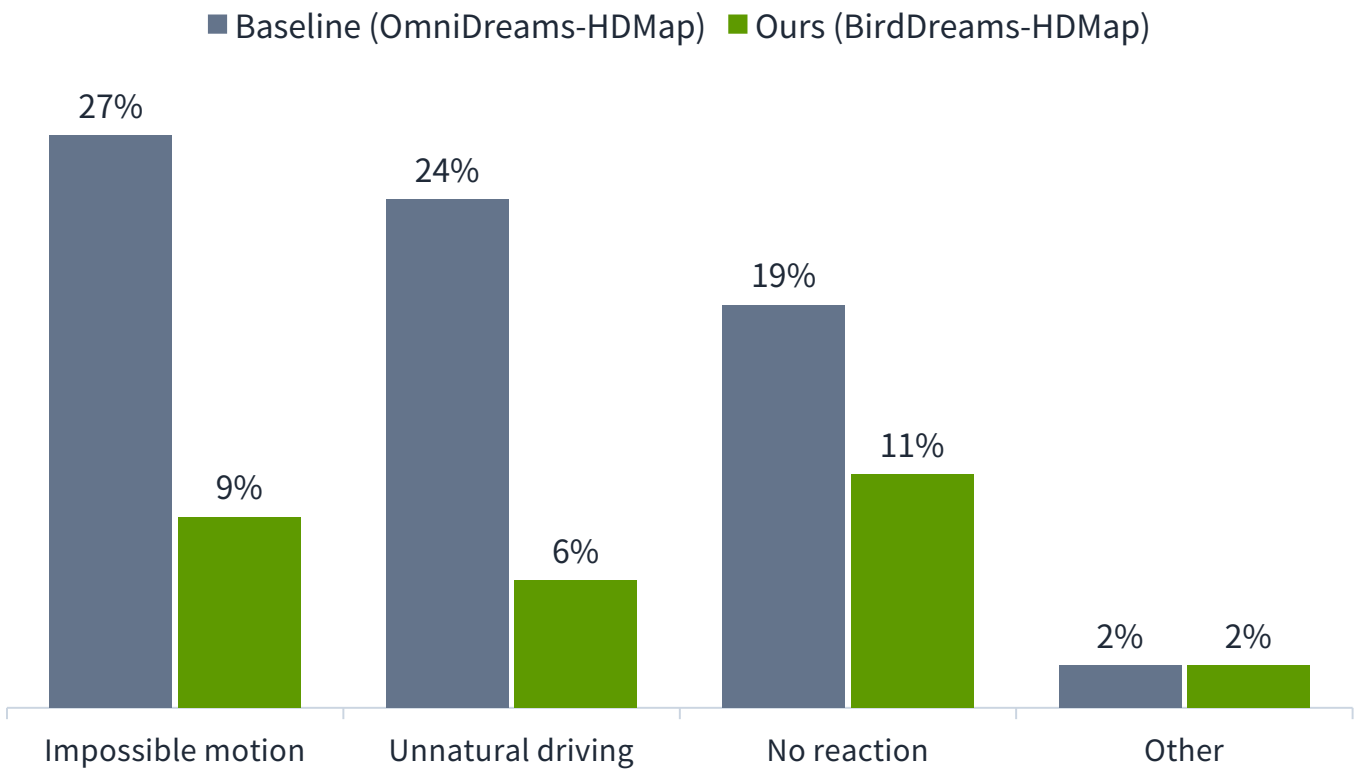

设定 25 人 × 15 对（从 119 对样本池中随机抽取，顺序随机）；问题：哪段视频中周车运动和行为更真实；来不及避让时的碰撞也算“真实”

数据来源：论文 Fig. 8 （N = 375 次成对判断， 25 名参与者）

同一动作可采样出不同结局，场景也可以直接在 BEV 里编辑

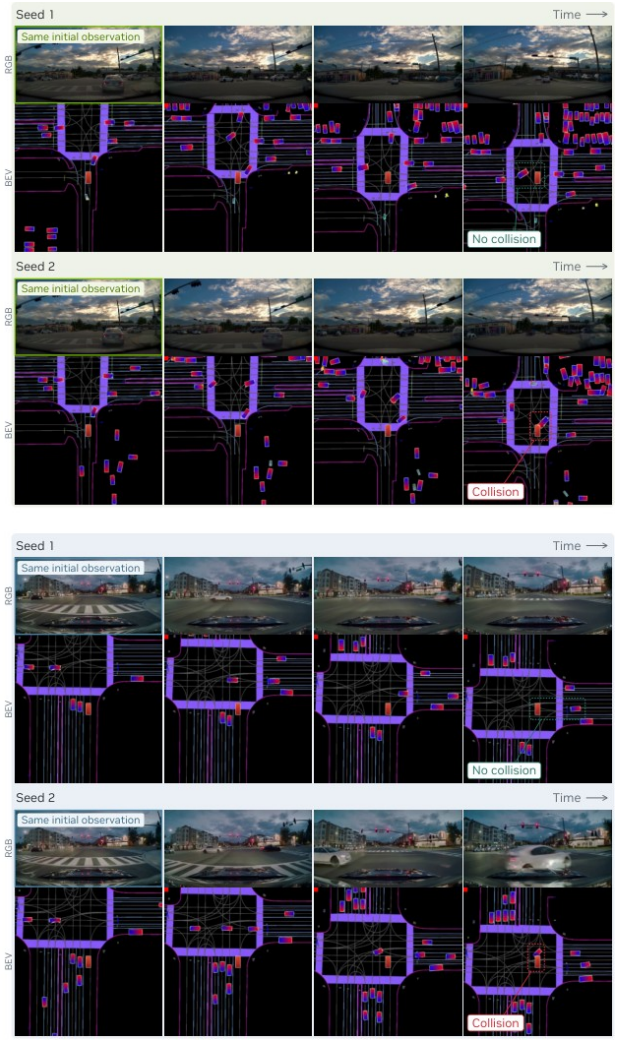

多样未来 初始观测、反事实轨迹、道路几何都相同，只换随机种子：

Seed 1 → 无碰撞　　Seed 2 → 发生碰撞

模型能采样周车对同一自车动作的不同反应

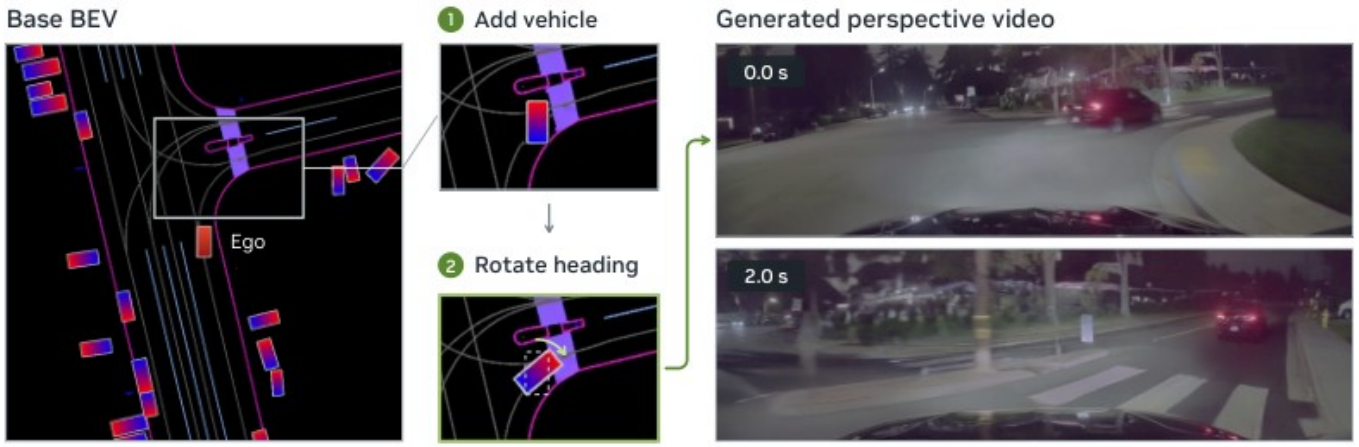

BEV 场景编辑 加车 → 调朝向 → 直接生成透视视频（包括第一帧），无需操作 3D 框，也无需真实图像

图源：论文 Fig. 7 、 Fig. 11

消融与扩展：独立加噪确实有用， BEV 训练对轨迹预测也有小幅帮助

噪声采样 · FVD ↓
RDS-HQ-1M 验证集

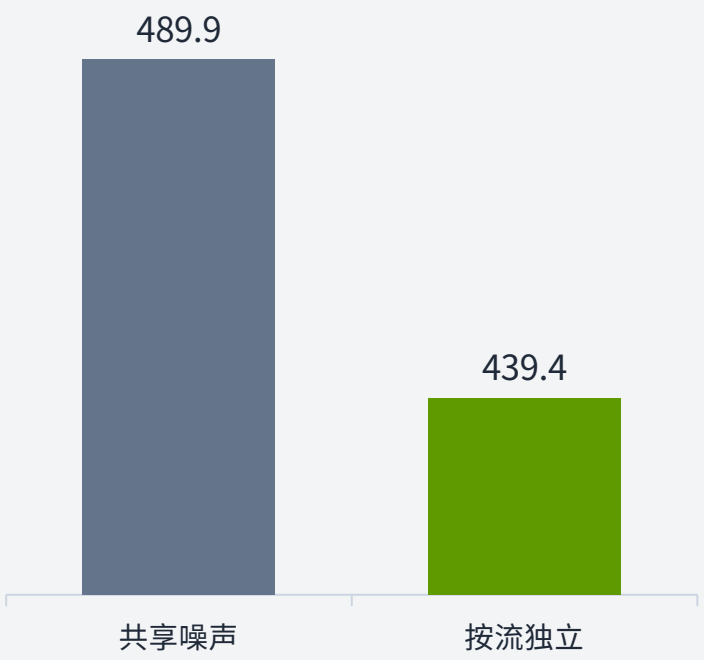

噪声采样 · FTD ↓
RDS-HQ-1M 验证集

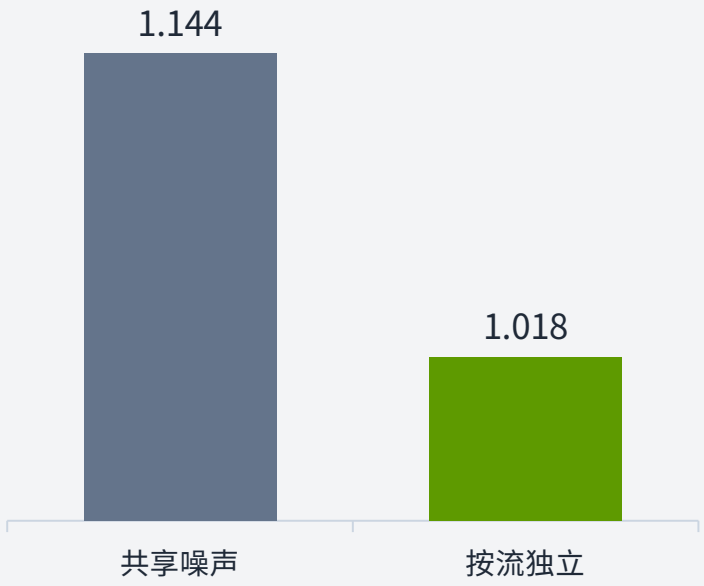

WAM · minADE@3s ↓ （m）
世界 - 动作模型， 100 个片段， best-of-6

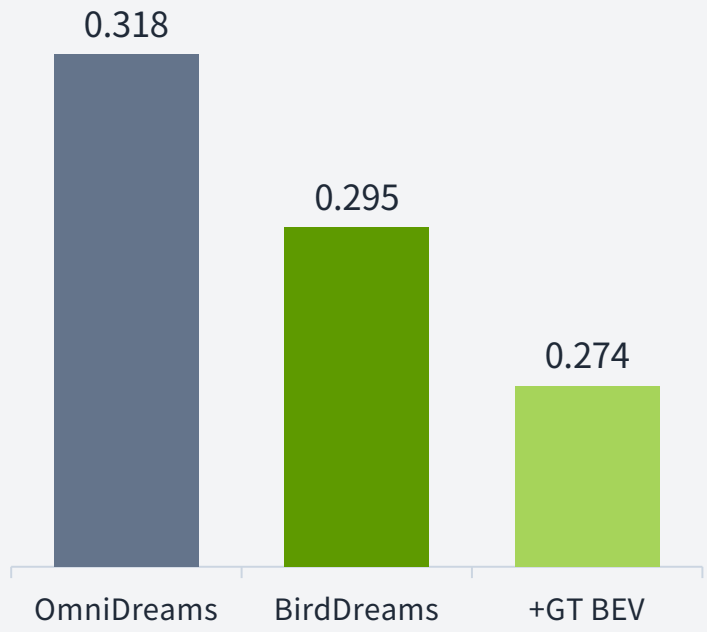

按流独立加噪 FVD −10% 、 FTD −11% ，证明“一条流干净、另一条噪”的训练组合有价值

WAM −7.3% 属于初步结果； +GT BEV 用了特权输入

数据来源：论文 Fig. 10 （ §4.4.1 、 §4.4.2 ）

局限与待验证之处

反应性缺少定量指标

核心卖点主要靠定性例子与 25 人人评支撑；人评用的是给了 HD 地图的 HDMap 变体

动作对比有混杂因素

Tab. 2 同时改变了“是否预测 BEV” 和“动作注入方式”，未拆开做消融

评测协议有噪声

轨迹靠 Depth Anything 3 从视频重建；nuScenes 上额外做了后训练，比较时需谨慎

依赖标注

BEV 监督需要地图 + 3D 框，难以扩展到无标注视频；只覆盖约 69 m，信号灯只能靠 RGB

设定较窄

只用单前视相机；重投影假设参考场景静止；未报告推理速度，而闭环仿真对此很敏感

WAM 结果初步

只有 100 个片段， minADE 提升 0.023 m （ 7.3% ），作者也称之为初步实验

结论：把结构化视图作为共同生成目标，自车更可控，周车更可信

BEV 是监督

低维、米制、少遮挡的示意视图让模型更容易学到周车动力学；人评偏好 57% 对 24%

BEV 是接口

刚体重投影 + 软条件，让模型精确执行米制轨迹：相比 OmniDreams (Plücker)， ADE 降低约 35%， DTW 约减半

BEV 可编辑

按流独立加噪带来任意流条件化：从 BEV 加车、调朝向即可生成 RGB 场景

值得关注：这为“不依赖外部交通模型的反应式闭环仿真”提供了一条清晰路线；**待验证：**反应性的系统化定量评测、多相机设定，以及推理效率。