论文解读 · arXiv 2611.16728

EgoX

以自我为中心的跨本体操作：用「本体做梦」共享人类、真机与仿真经验

EgoX: Egocentric Cross-Embodiment Manipulation with Embodiment Dreaming

一句话总结 把异构示教拆成语义对应的模态并统一到自我中心坐标系，用「模态级模块化 + 共享 Transformer 主干 + 仅训练期的未来潜表示预测」做跨本体预训练， 13 个任务–本体组合的平均任务进度从 0.63 提升到 0.80 。

7	5	13	0.63→0.80
种本体（人 + 6 种机器人）	个操作任务	个任务–本体组合	平均任务进度

Yaru Niu, Binghong Chen 等 · CMU / Bosch Center for AI / NVIDIA / UC Berkeley / UT Arlington · 2026-11-12 首次提交

不同本体的经验互补，但形态、感知与控制接口各不相同

形态不同

人形、四足、轮式双臂、桌面臂；五指手、四指手、夹爪、固定工具

感知不同

相机位置与视角不同，本体感知（关节状态）的维度与含义不同

控制与动力学不同

动作语义、动作维度与运动动态各异，直接混合难以正迁移

核心问题

如何从多种本体中学到共享的操作知识，同时保留每个本体自己的感知与控制差异？

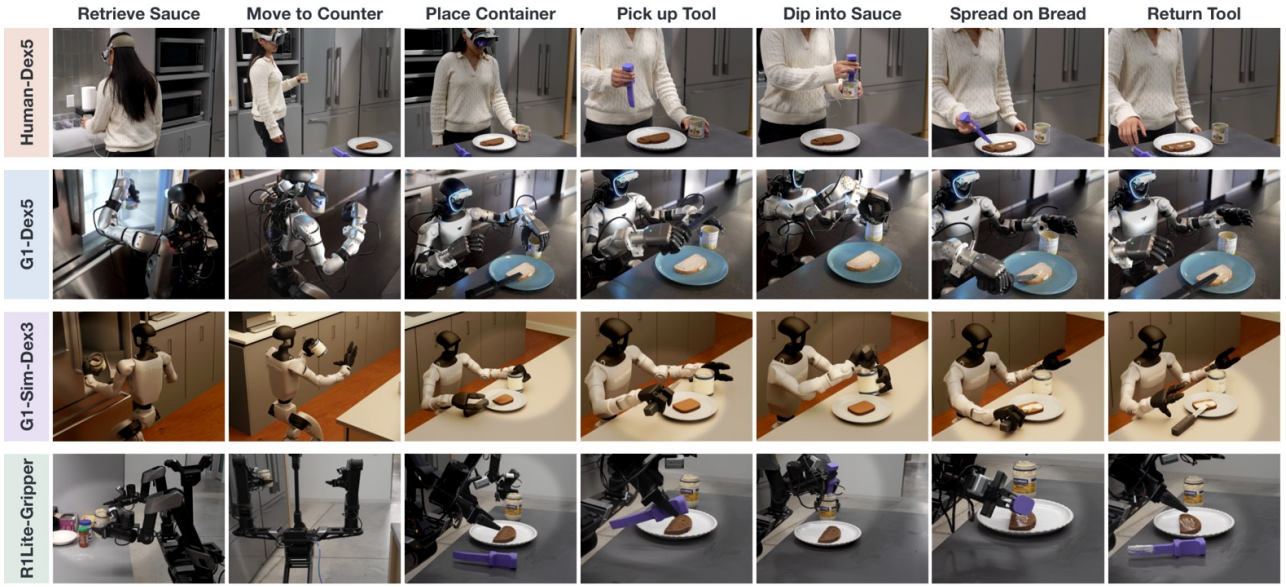

同一任务 Kitchen-Bread 的对应阶段： Human-Dex5 、 G1-Dex5 、 G1-Sim-Dex3 、 R1Lite-Gripper

EgoX：迁移经由语义对应的模态发生，接口保持本体专属

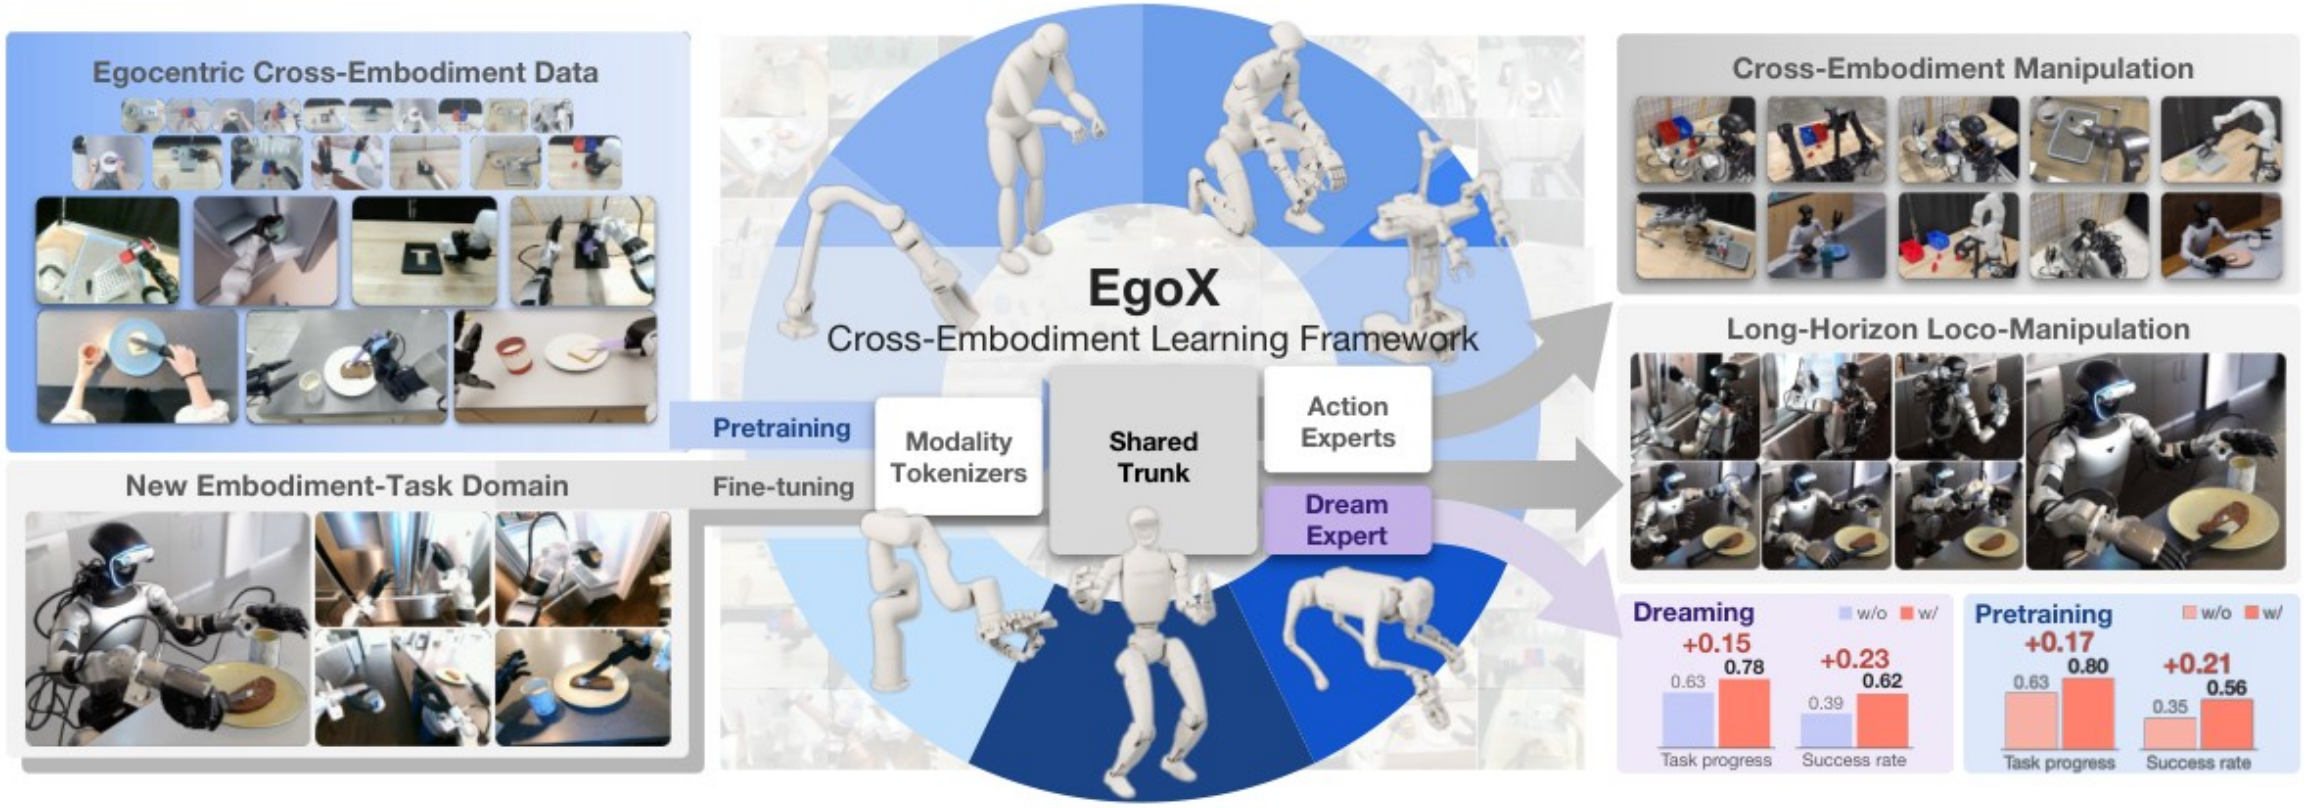

① 统一模态表示

人类 / 真机 / 仿真都拆成图像、腕位姿、指尖关键点、躯干等模态，统一到自我中心坐标系

② MXT+ 模块化模型

每个模态一个 tokenizer 、每个动作模态一个 expert ，中间共享 Transformer 主干

③ 本体做梦

训练期预测未来视觉与本体感知的潜表示，让主干学到各本体的动力学

三类自我中心坐标系 + 指尖关键点，让不同身体可比

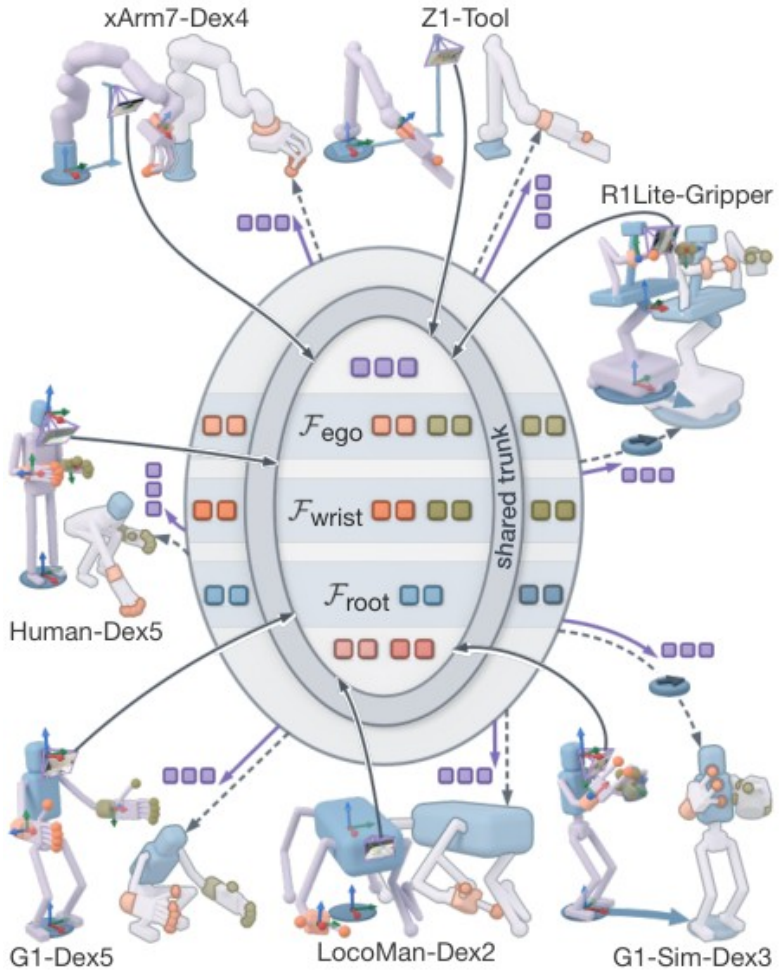

F_root： 躯干位姿、速度指令

参考身体部位的地面投影（人形双脚 / 四足躯干 / 人类为起始时的头部）

F_ego： 左 / 右腕位姿与腕目标

固连在携带主相机的刚体上；固定基座臂取臂基座

F_wrist： 末端关键点

指尖或接触点在腕坐标系下的 3D 位置，最多 5 个槽位，缺失则掩码

为什么用关键点而不是关节角?

五指手、三指手、夹爪、勺子的运动学完全不同，但「指尖在哪里」可以直接比较；人手数据因此能监督机器人。缺失的观测模态省略，缺失的动作模态不计损失。

模态级 tokenizer 与动作 expert，共享 Transformer 主干承担迁移

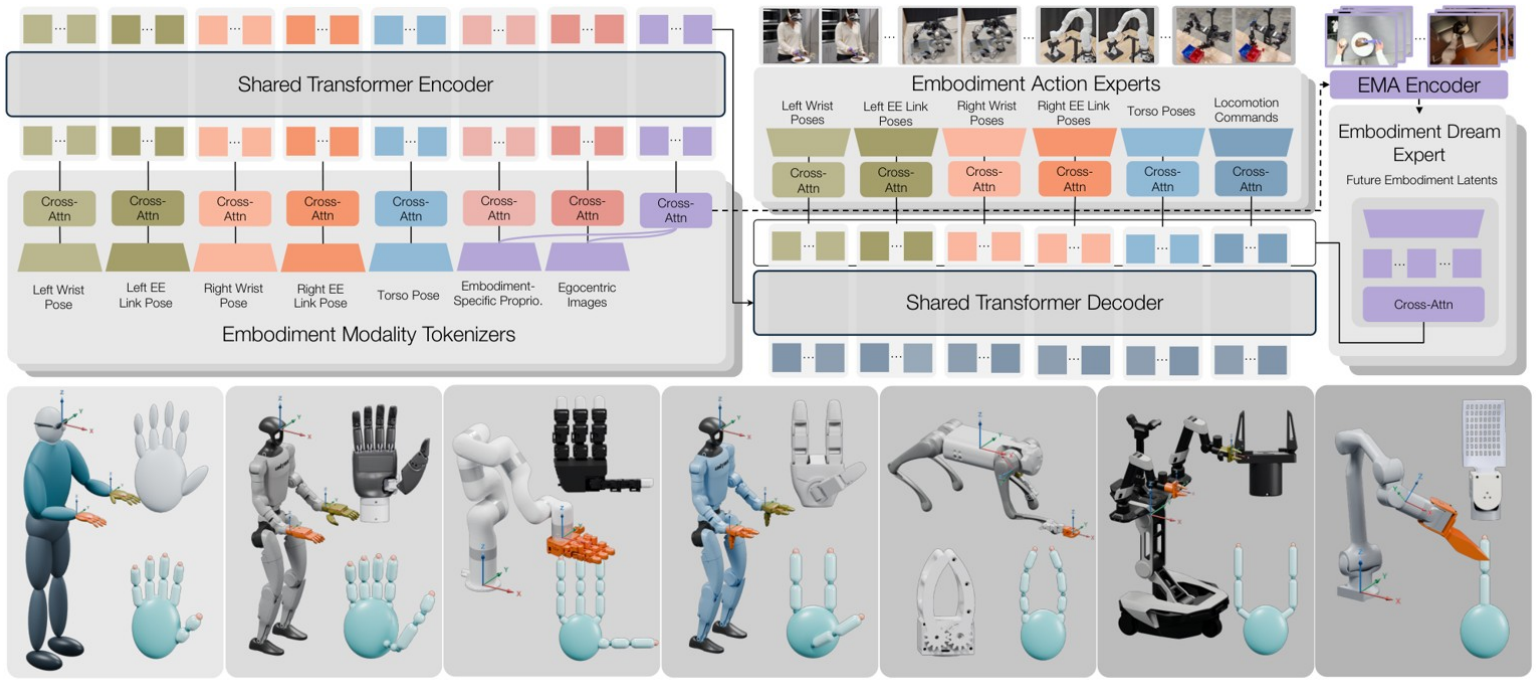

$$\pi^e = \Psi^e \circ G_\theta \circ \Phi^e$$

Φ^e 模态 tokenizer

每本体每观测模态一个；图像用共享 ResNet-18 + 本体专属聚合器

G_θ 共享主干

encoder-decoder Transformer，所有本体都训练它，是迁移主通道

Ψ^e 动作 expert

每个动作模态一个，输出 60 步动作块（30 Hz 下 2 s）

模型规模

预训练 120M–185M；微调 50M–90M 参数

图源： Fig. 3 、 Appendix A.2

组件 ③ 本体做梦

训练期预测未来本体潜表示，推理时零额外开销

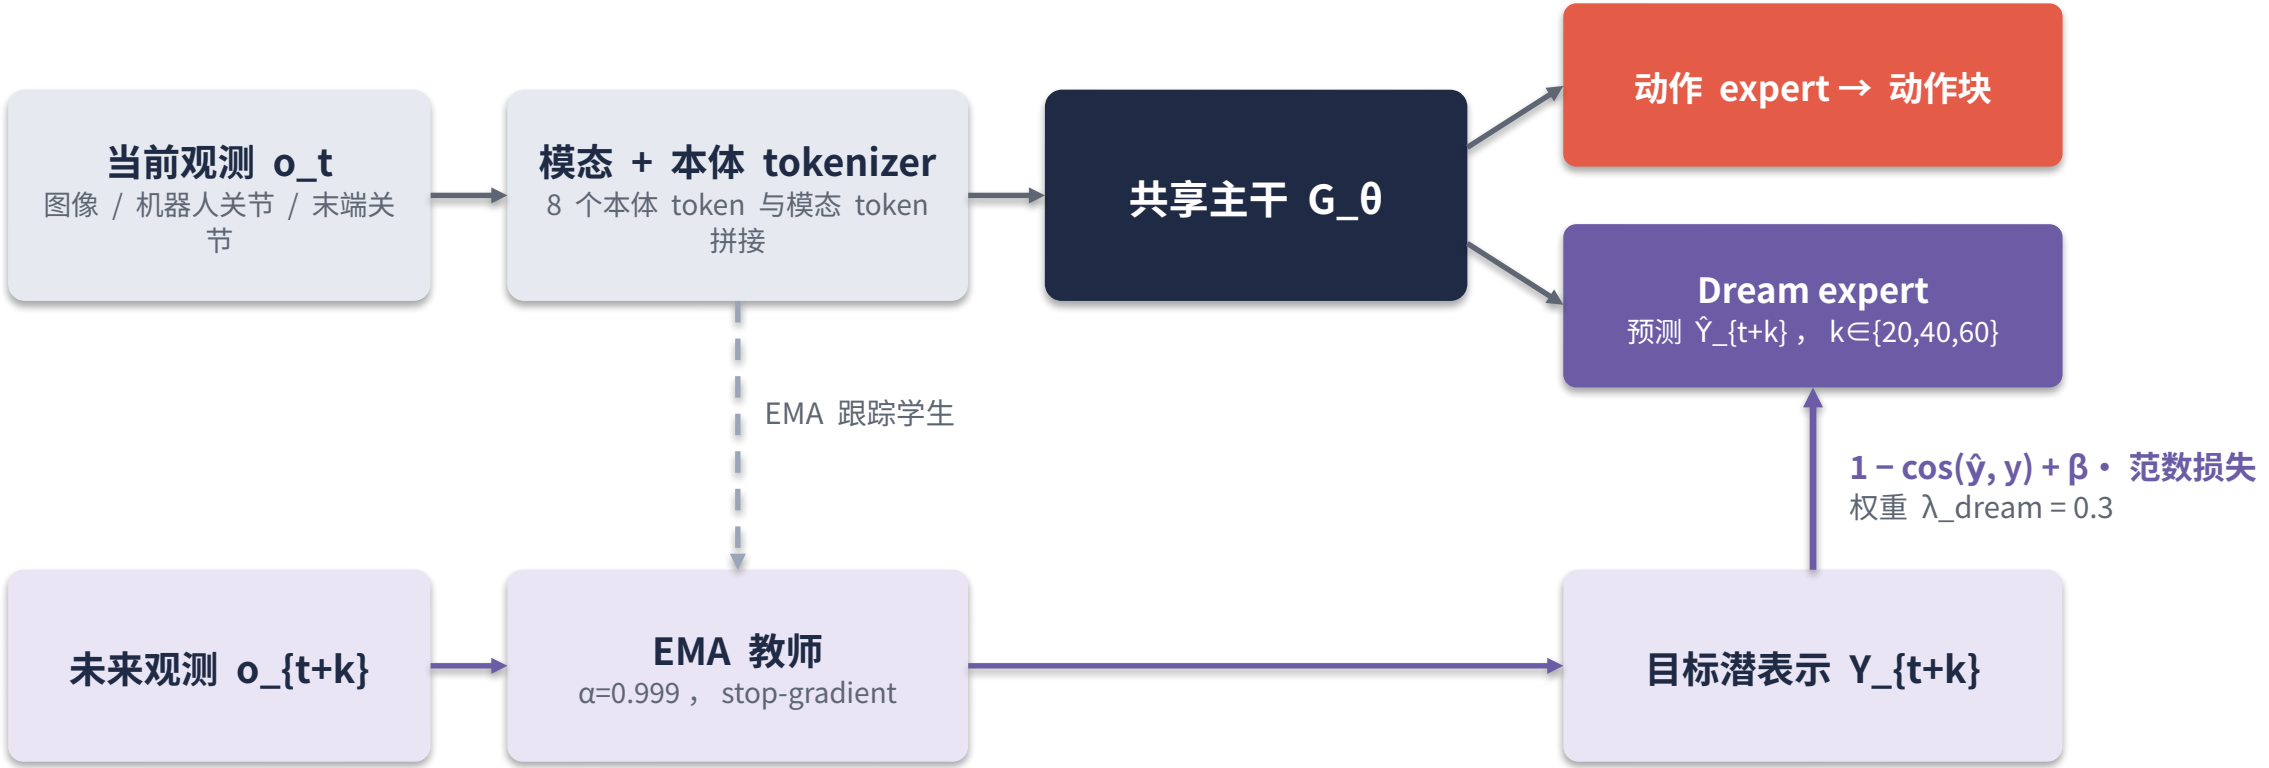

仅训练使用
部署时去掉 dream expert 与 EMA 教师，推理无额外计算

潜空间而非像素
JEPA 式目标，不需要重建高维图像

学到本体动力学
迫使主干编码各本体视觉与身体状态如何演化

来源： Sec. 3.3 、 Eq. (6)–(9) 、 Appendix A.3

7 种本体、 5 个任务、 13 个组合；人类数据占近一半

各本体示教轨迹数（珊瑚 = 人类，紫 = 仿真，深蓝 = 真机）

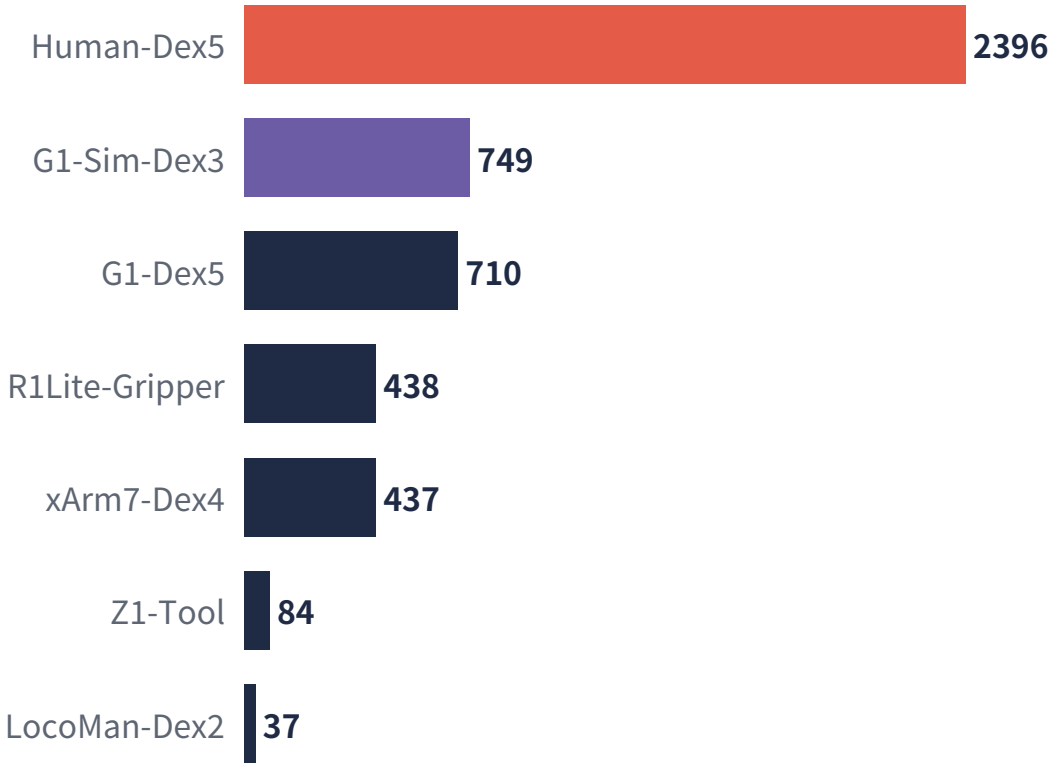

共 4,851 条 / 34.38 小时；人类 49.4%、真机 35.2%、仿真 15.4%，各本体数据量极不均衡

5 个任务

Kitchen-Bread	长时程行走 + 操作：开冰箱取酱、走到台面、蘸酱涂面包
Kitchen-Cleanup	仿真：把刮刀放进容器
Sort	按颜色把积木分拣进对应箱子
Insert	T 形块的抓取、对齐与精确插入
Scoop	用勺子铲猫砂并倒进垃圾桶（工具使用）

评测协议

真机每组合 20 次（13 ID + 7 OOD），仿真 50 次（32 + 18）；指标为分阶段归一化任务进度，成功额外 +1 分

注意 OOD 的含义

OOD 相对目标本体的微调数据定义，部分条件可能出现在其他本体（尤其人类）的预训练数据中：测的是跨本体迁移

来源： Table 6、 Sec. 4.1、 Appendix A.9

主要结果

跨本体预训练平均任务进度 0.63 → 0.80 ， OOD 下提升最明显

0.63 → 0.80

13 组合平均任务进度（MXT+ 无预训练 → 预训练）

0.53 → 0.77

OOD 平均任务进度：提升 13/13 个组合（ID 提升 11/13）

12 / 13

预训练 MXT+ 在各方法中排名第一的组合数

13 组合平均成功率（Appendix A.10）

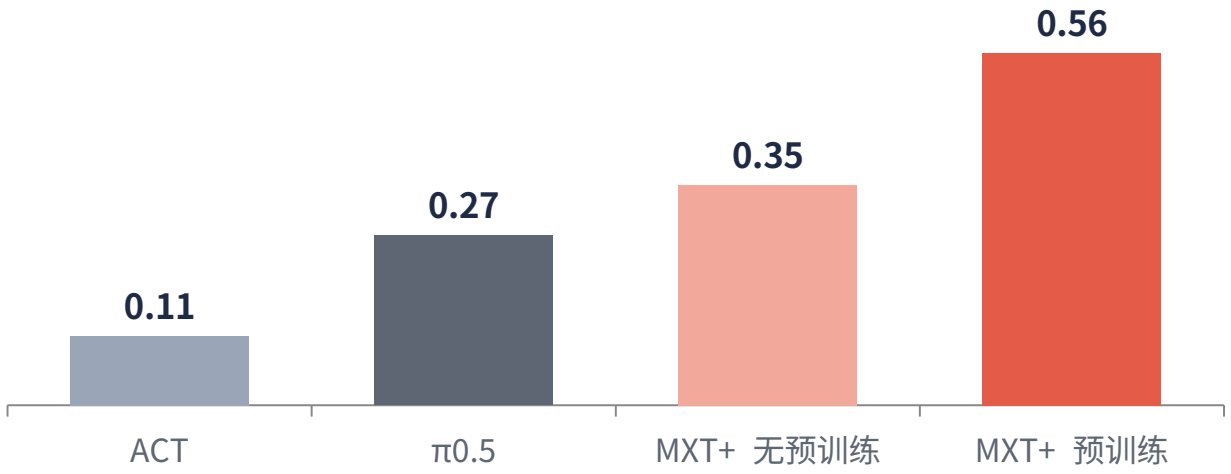

OOD 成功率：差距靠预训练拉开

无预训练 MXT+ 0.18 ≈ π0.5 0.19 → 预训练 MXT+ 0.52； ID 则为 0.44 → 0.58

小模型也有竞争力

MXT+ 微调规模 50M–90M，对比 π0.5 约 3.4B；无预训练时平均成功率已高于 π0.5 （0.35 vs 0.27）

来源： Fig. 5 、 Appendix A.10

逐组合结果

OOD 上收益最大： G1-Dex5 Insert 与 Z1-Tool Scoop

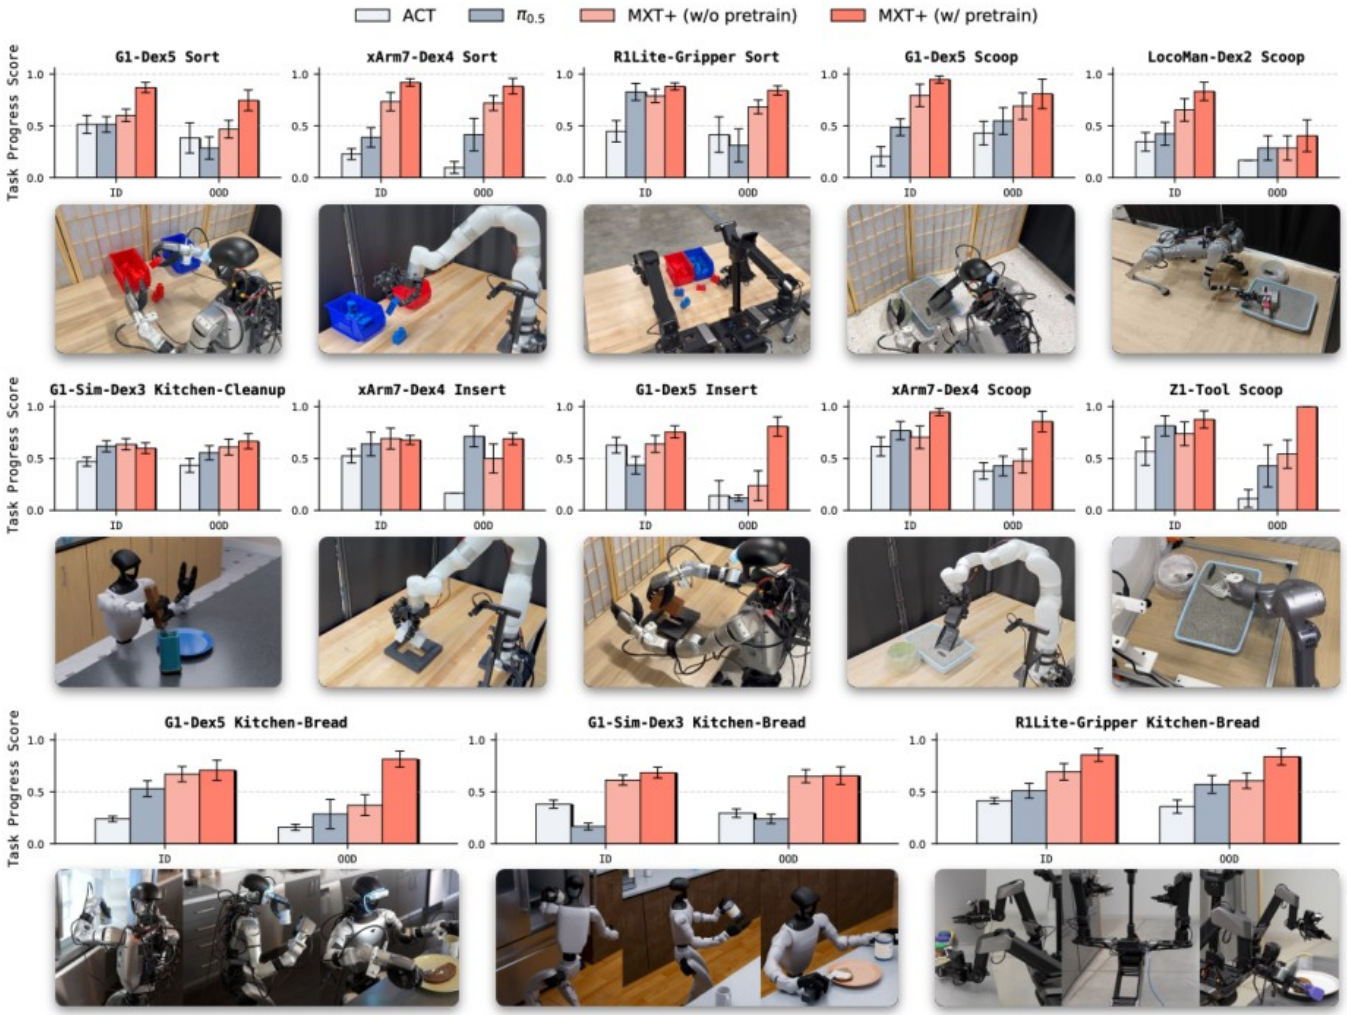

G1-Dex5 Insert • OOD

无预训练 ≈ 0.23 → 预训练 ≈ 0.82

Z1-Tool Scoop • OOD

无预训练 ≈ 0.55 → 预训练 1.0

例外与持平

xArm7-Dex4 Insert： π0.5 与预训练 MXT+ 接近（OOD ≈0.72 vs 0.70），成功率上 MXT+ 更低

G1-Sim Kitchen-Cleanup： 各方法均约 0.6

注：带「≈」的数值为读图近似值

预训练混合越宽，迁移越好：人类数据也能提供可迁移先验

无预训练
只用目标本体、目标任务数据

+ 人类示教
OOD 提升 5/6 组合， G1-Dex5 Insert 最明显

+ 其他机器人
ID 提升 5/6 组合

+ 目标机器人其他任务
OOD 提升 6/6 组合：完整跨本体预训练

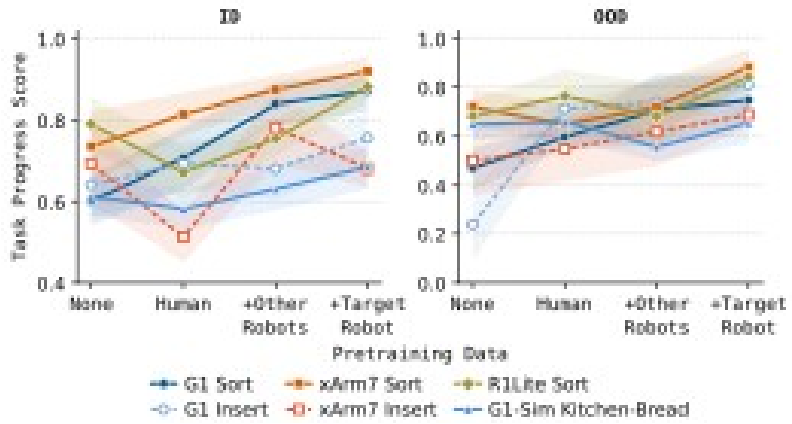

+0.12
ID： 完整混合 vs 无预训练

+0.23
OOD： 完整混合 vs 无预训练

去掉做梦目标后性能普遍下降： 7 个设置全部受益

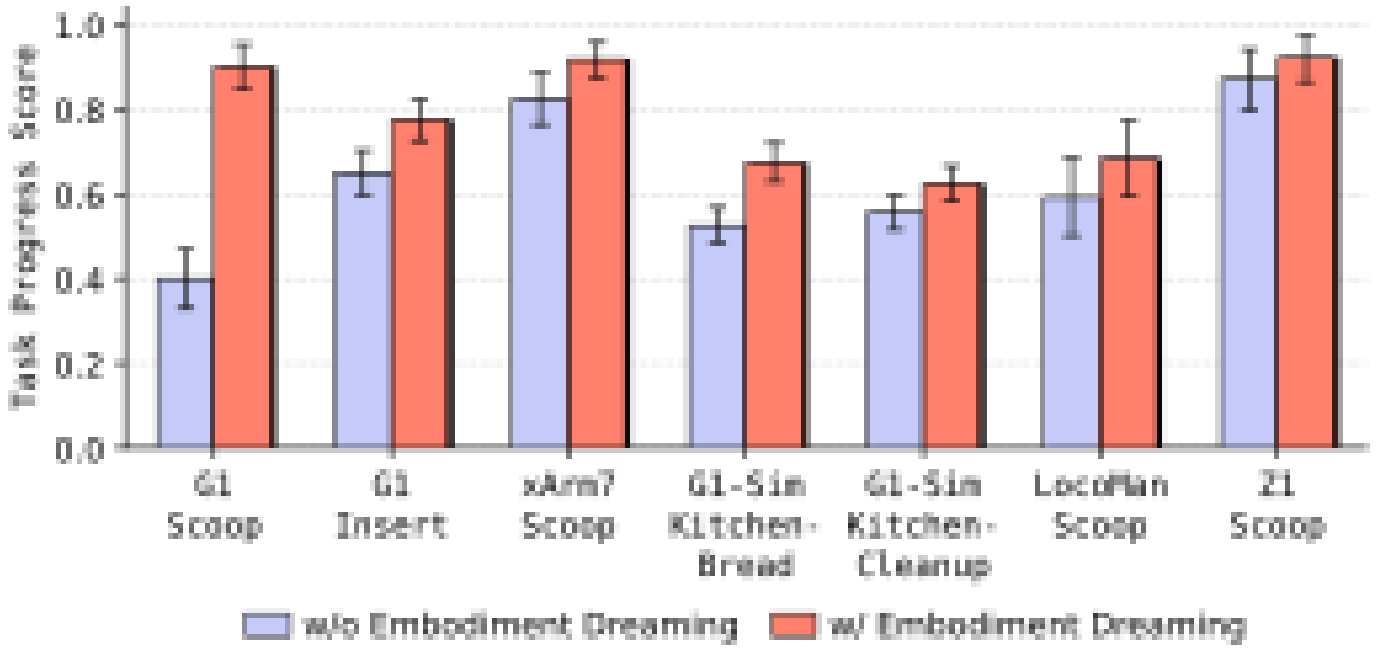

MXT （无做梦） vs MXT+ （有做梦）在 7 个任务–本体设置上的任务进度

0.63 → 0.78
平均任务进度（7 个设置全部提升）

0.39 → 0.62
平均成功率

0.27 → 0.60
OOD 平均成功率（ID： 0.46 → 0.63 ）

3 → 16 / 20
G1-Dex5 Scoop 成功次数（提升最大）

来源： Fig. 7 右、 Appendix A.10

粗粒度共享在模态丰富时会被预训练带偏，模块化避免了大幅下降

跨本体预训练带来的任务进度变化 Δ （无预训练 → 预训练）

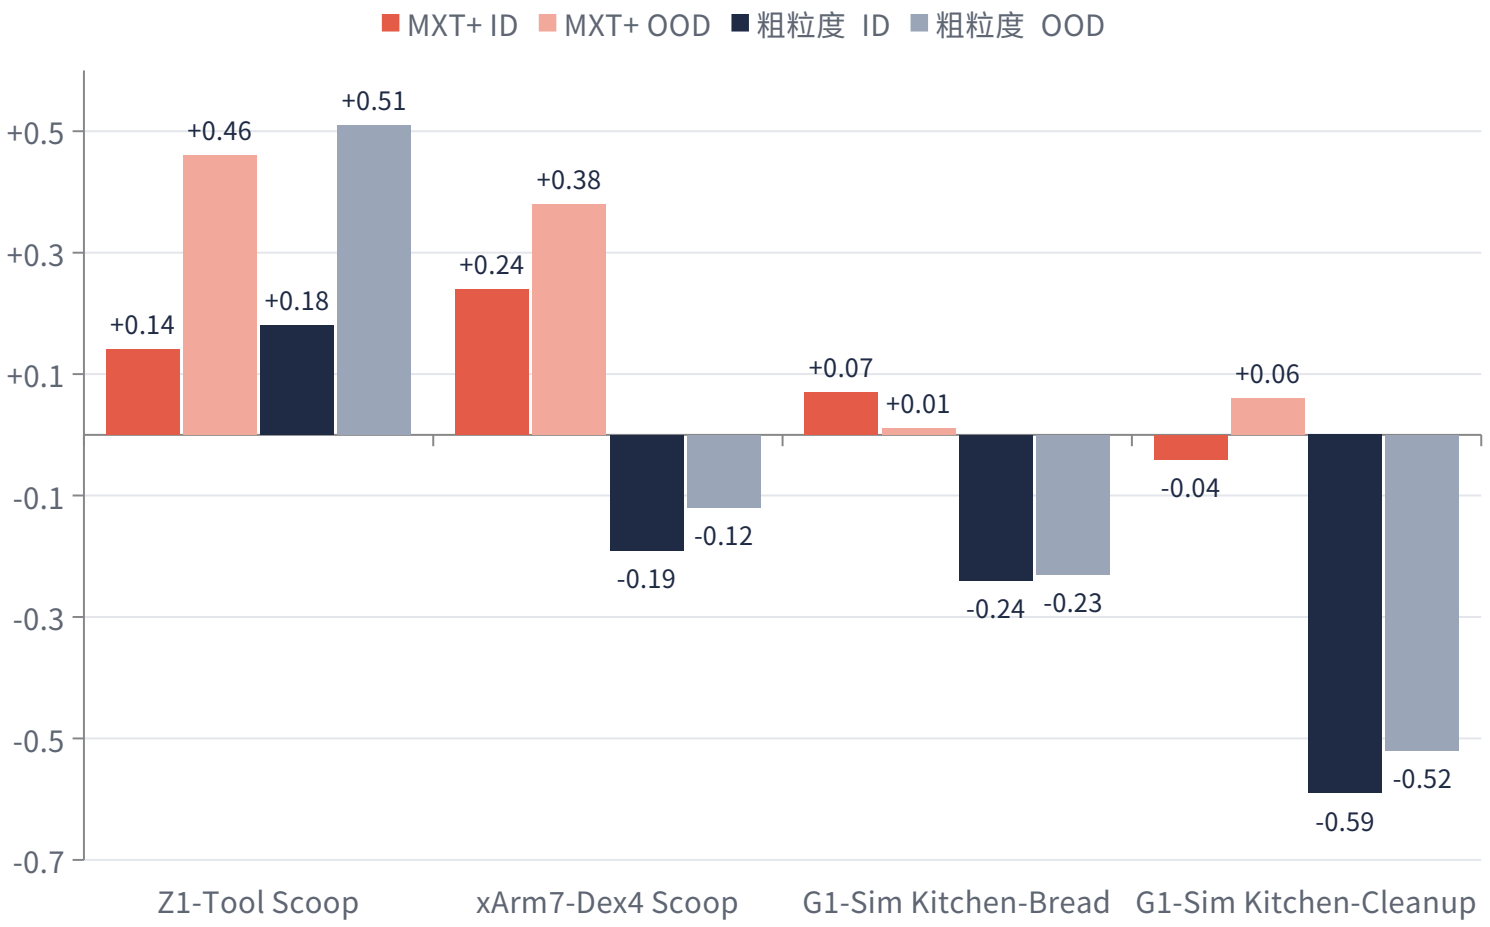

粗粒度变体

所有相机 1 个 tokenizer；位姿 + proprio 拼接 1 个；所有动作 1 个 expert

模态越丰富，差距越大

Z1-Tool 模态少，两者都受益； xArm7 与仿真 G1 上粗粒度预训练后下降

Kitchen-Cleanup 归零

开局需要行走， 3 维速度指令只占 51 维动作，粗粒度可能把它淹没

预训练后

模块化 MXT+ 在每个 ID / OOD 设置都不低于粗粒度

来源： Fig. 8 （图中标注的 Δ 值）

预训练与做梦都让不同本体的主干表示几何更相似

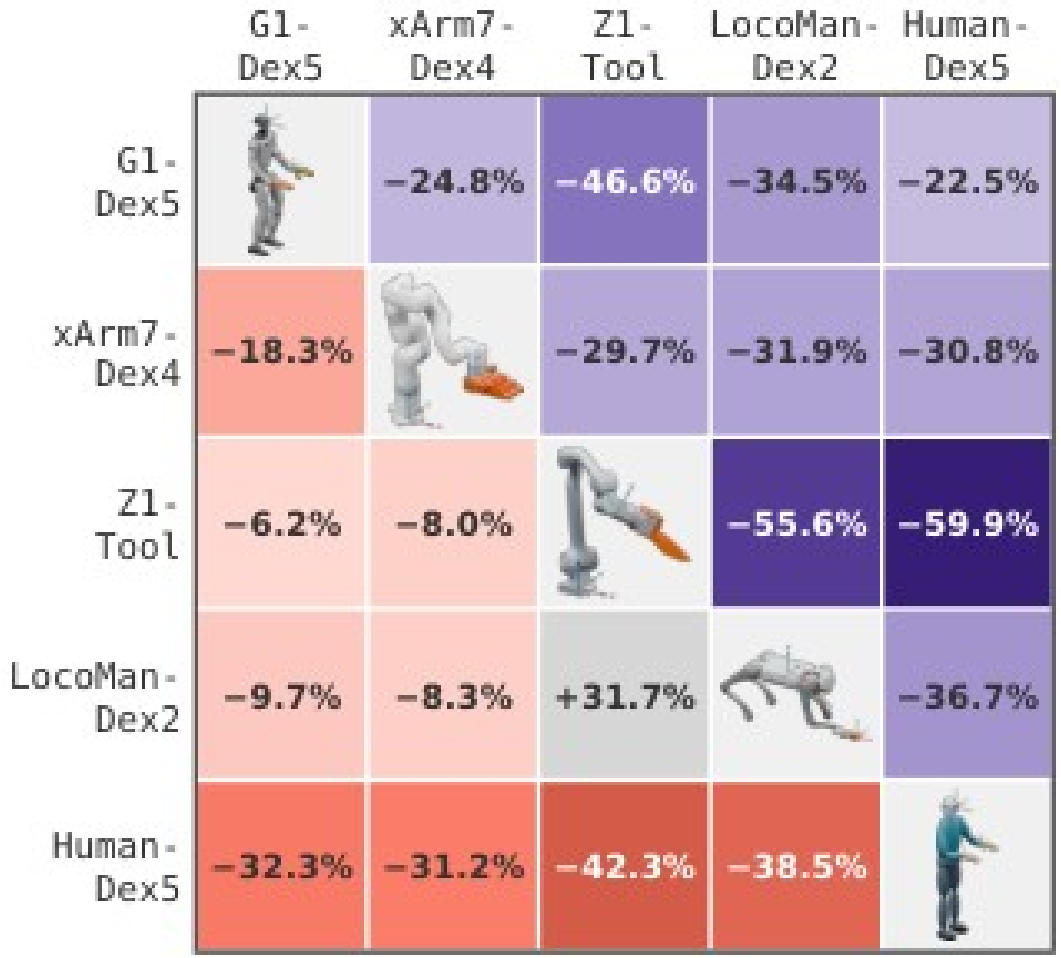

GW 距离变化：下三角 = 预训练（珊瑚），上三角 = 本体做梦（紫）

−21.30%

预训练：平均 GW （9/10 对下降）

−38.52%

本体做梦：平均 GW （10/10 对下降）

怎么测的

在 Scoop 示教上取共享主干输出的右腕 token，平均池化为 512 维，计算本体两两之间的 Gromov–Wasserstein 距离；越低表示几何越相似

细节

预训练下人类–机器人对降幅最大（− 31% ~ −42%）；唯一上升的是 LocoMan–Z1 （+31.7%）

做梦下 Z1–Human −59.9%、 Z1–LocoMan −55.6%

评价

系统性强、真机覆盖广；规模与对比的严格性仍待加强

亮点

本体覆盖极广

人形、轮式双臂、四足、桌面臂、仿真 + 人类；五指手到夹爪到固定工具，均做真机评测

表示简单有效

指尖关键点 + 自我中心坐标系绕开关节空间不可比，人手数据可直接监督

做梦性价比高

仅训练期使用，推理零开销， 7/7 设置提升，并有潜空间几何佐证

模块化消融有指导意义

揭示粗粒度共享在模态丰富时的负迁移风险

局限与疑问

数据与试验规模小

约 34 小时、 4.8k 轨迹，均为团队自采；真机每组合 20 次、 OOD 仅 7 次

OOD 定义偏宽松

部分 OOD 条件见于其他本体的预训练数据，更接近「跨本体迁移」而非泛化

对比不完全对等

π0.5 仅在目标数据上 LoRA 微调；缺少同数据下与其他跨本体架构的对比

扩展与采样成本

新本体需人工指定模态对应与坐标变换；均衡采样使小数据集被反复使用

总结与启示

01 按语义对应的模态共享，按本体保留接口

统一表示 + 模态级 tokenizer / expert + 共享主干，让人类、真机、仿真在同一模型中正迁移

02 跨本体预训练的价值主要体现在 OOD

OOD 任务进度 0.53 → 0.77 、成功率 0.18 → 0.52 ； 预训练混合越宽越好，人类数据也有用

03 预测「身体的未来」是廉价而有效的辅助信号

本体做梦：任务进度 0.63 → 0.78 ，推理零开销，并让跨本体潜空间几何更相似（ GW −38.52% ）

下一步要验证：更大规模、更均衡的数据，自动化的本体接入，以及在同等数据下与其他跨本体架构的对比。