论文解读 · 具身智能数据集

Ropedia Xperience 2

A Gold Standard for Scaling Physical AI Environments and Behaviors

真实场景 3D 扫描 × 第一人称人类行为：联合采集、空间配准、复用为机器人数据

Ropedia Research Team （项目负责人 Hao Li, Zhaoxi Chen, Fangzhou Hong；顾问 Ziwei Liu ）
arXiv 2611.17060 · 首次提交 2026-11-12

一句话总结

扫一次场景、录多次任务，把人类行为放进度量 3D 场景里复用

> “一名操作员先用手持 LiDAR 扫描真实场景，再戴头戴式相机 HOMIE 完成任务；管线把第一人称视频、相机轨迹、手与全身动作配准到同一个度量场景坐标系，使一次采集同时成为 **3D 感知基准的参考**，并可转成 **仿真环境与机器人轨迹**。

1,589	4,230	74	131 h	596
已发布场景扫描	条 HOMIE 录制 *	个任务定义 *	录制总时长 *	个采集地点 *

* 采集清单口径（collection inventory），不保证已处理或已配准；论文也不含 scaling 实验：它回答“扩什么数据、怎么生产”，不给出 scaling law。

大模型已能控制机器人，但在长时程真实任务上依然脆弱

22.48%

GPT-6 Astra · RoboDojo 平均成功率

0 / 11

插头插入（三个平台）全部失败

9 / 23

导航 + 搜索试验成功次数

需要两类互补资源

行为 Behaviors

人类示范“任务怎么做”，以及由此派生的机器人动作与交互

环境 Environments

真实空间的布局与物体关系，可让策略闭环 rollout 、评估、改进

核心问题

物理 AI 的能力如何随“环境”和“行为”的规模扩展?

前提：先确定扩什么数据，以及如何持续地生产与复用它 → 本文的答案是“环境 + 行为联合采集”

两台设备、两阶段：一次扫描为多条任务录制提供空间上下文

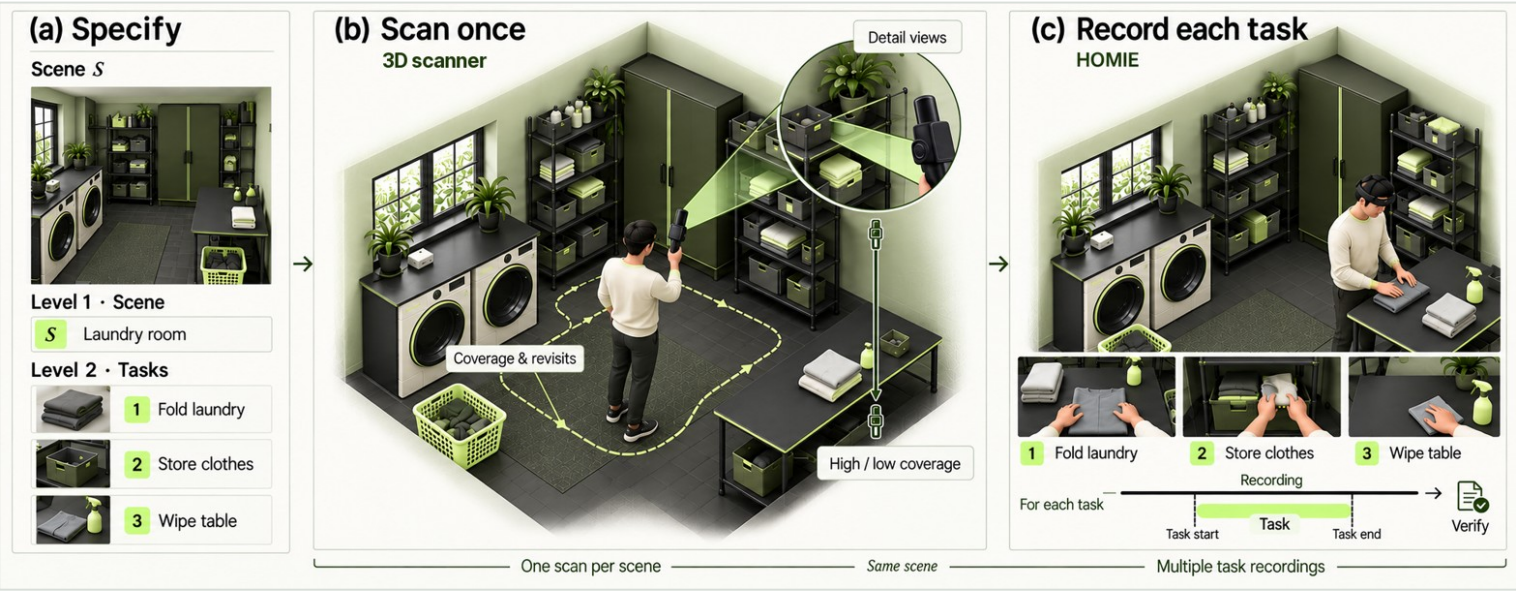

3D 扫描仪 · 手持

LiDAR + 2 鱼眼 + 2 广角（卷帘快门）

→ 度量网格、 3DGS 、 COLMAP 位姿

HOMIE · 头戴

4 全局快门鱼眼（前 2 后 2） + IMU + 4 路音频

→ 双手空闲，跟随第一人称视角

采集协议要点

- 场景静止：关屏、固定灯光、清人和宠物、遮玻璃
- 扫描：双向遍历、细节近扫、高低视角
- 录制：完整包住任务首尾，事后校验文件

自动化管线：观测 → 估计 → 生成，最终统一到度量场景坐标系

观测

3D 扫描仪
鱼眼图像

HOMIE
4 路鱼眼视频 30 fps
IMU 200 Hz · 4 路音频
硬件同步 < 50 µs

估计

扫描重建
COLMAP 位姿 · 网格 · 3DGS（度量）

双目 SLAM
6-DoF 设备位姿 + 稀疏地图， 30 Hz

双目度量深度
逐像素置信度

手： MANO
每只手 21 关节，双目重投影一致性

全身： SMPL-H
52 关节， EgoAllo （头轨迹条件 + 手引导）

生成

任务级
整体任务与活动描述

子任务 / 动作
带时间区间

逐帧（2 fps）
物体状态、手状态、手 - 物交互

配准

变换 S

录制 SLAM 坐标系

↓

扫描的度量场景坐标系

轨迹、手、身体统一到场景；语言标注随时间戳保留

配准：图像定位 + 轨迹拟合，再用独立几何检查分级

1 **定位** SIFT + RANSAC 匹配扫描图像，关键点投到网格， PnP 求相机位姿

2 **拟合** ~200 帧鲁棒 Umeyama；偶数帧拟合、奇数帧 held-out；跨度 ⩾ 2.5 m 才允许尺度修正

3 **检查** IMU 重力 vs 地面法向；双目深度 vs 网格 ICP 位移

PASS held-out 中位 ⩽ 5 cm 、 p90 ⩽ 12 cm ； 重力 ⩽ 2° ； ICP ⩽ 10 cm / 2°

WEAK 未满足任一 PASS 条件

FAIL 无一致初始化 / 定位 < 8 帧 / p90 > 30 cm / ICP > 30 cm （如同户型邻居）

示例 PASS： 0.7 / 1.8 cm （中位 / p90 ），重力 1.01°

任务设计覆盖工作场景，但录制量高度集中在家庭

74
任务定义

31
在工作 / 零售场景

按动作（任务数）

放置 / 取出 25 · 擦拭清洁 23
整理 18 · 清洗 5 · 折叠 2 · 检查 1

录制最多的格子

卧室 · 放置 887
卧室 · 取出 786
卧室 · 折叠 460
客厅 · 擦拭 421
工作 / 零售：有数据的格子仅 5–26 条

98.7% 扫描被保留，但 Perfect 仅 9.3%，厨房 82% 为 Reuse

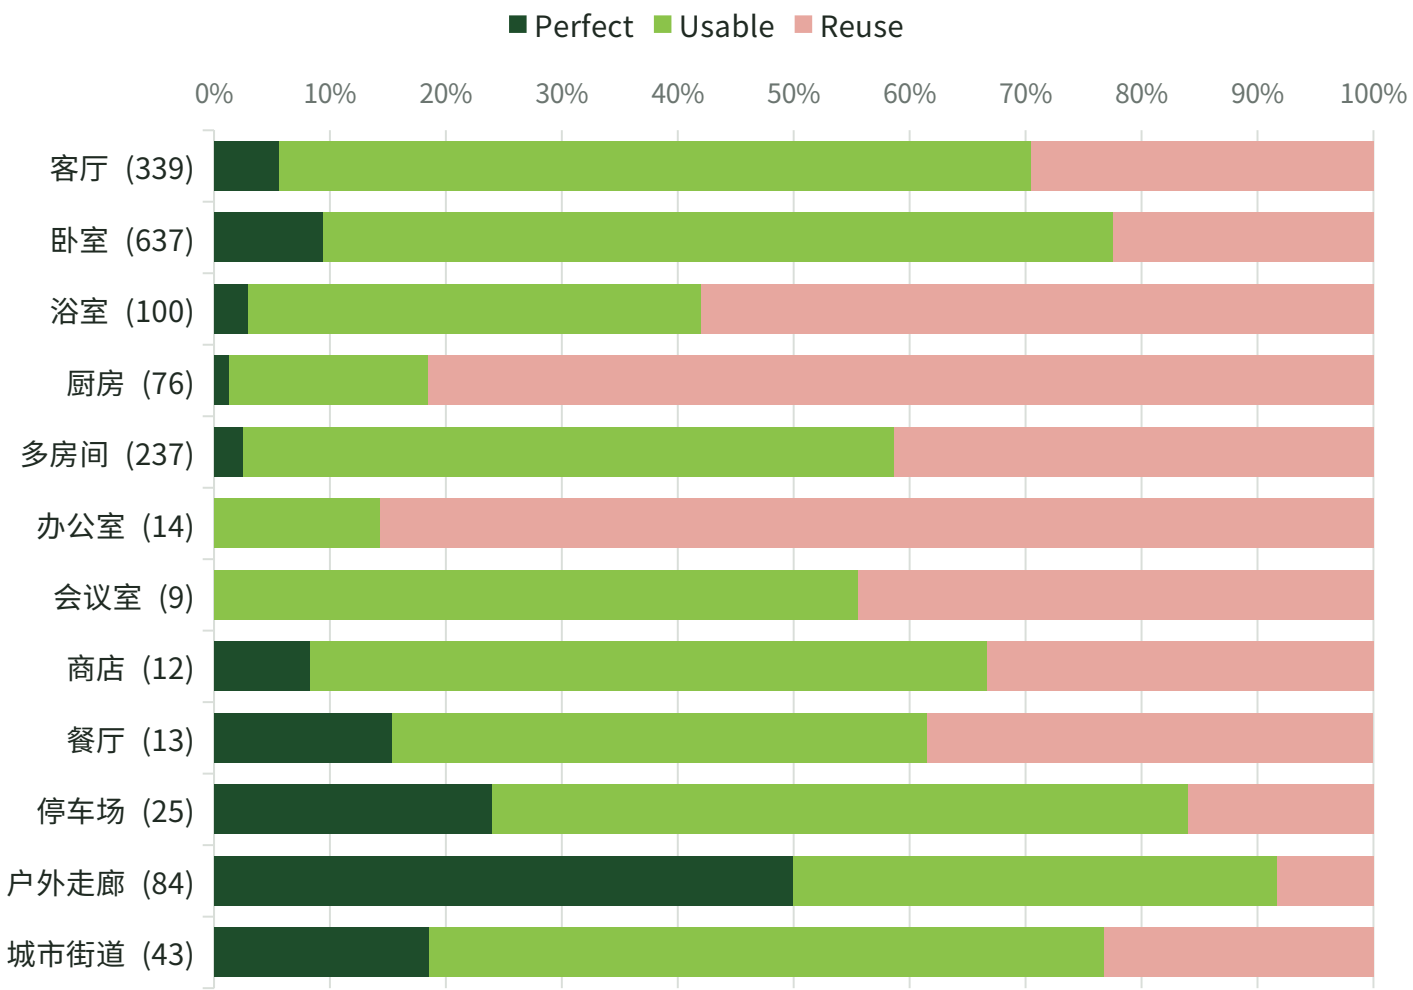

1,589
保留（98.7%）

21
Delete （1.3%）

Perfect 148 个 · 9.3%

Usable 934 个 · 58.8%

Reuse 507 个 · 31.9%

口径提醒

- 8 类场景中原 Delete 改判为 Reuse
- 91 个无 QC 结果者按 Usable 保留
- 33 个冲突等级取最好值
- 家庭室内占 87.4%；卧室 + 客厅占 61.4%

几何基准：没有全能模型，输入视图更多也不一定更好

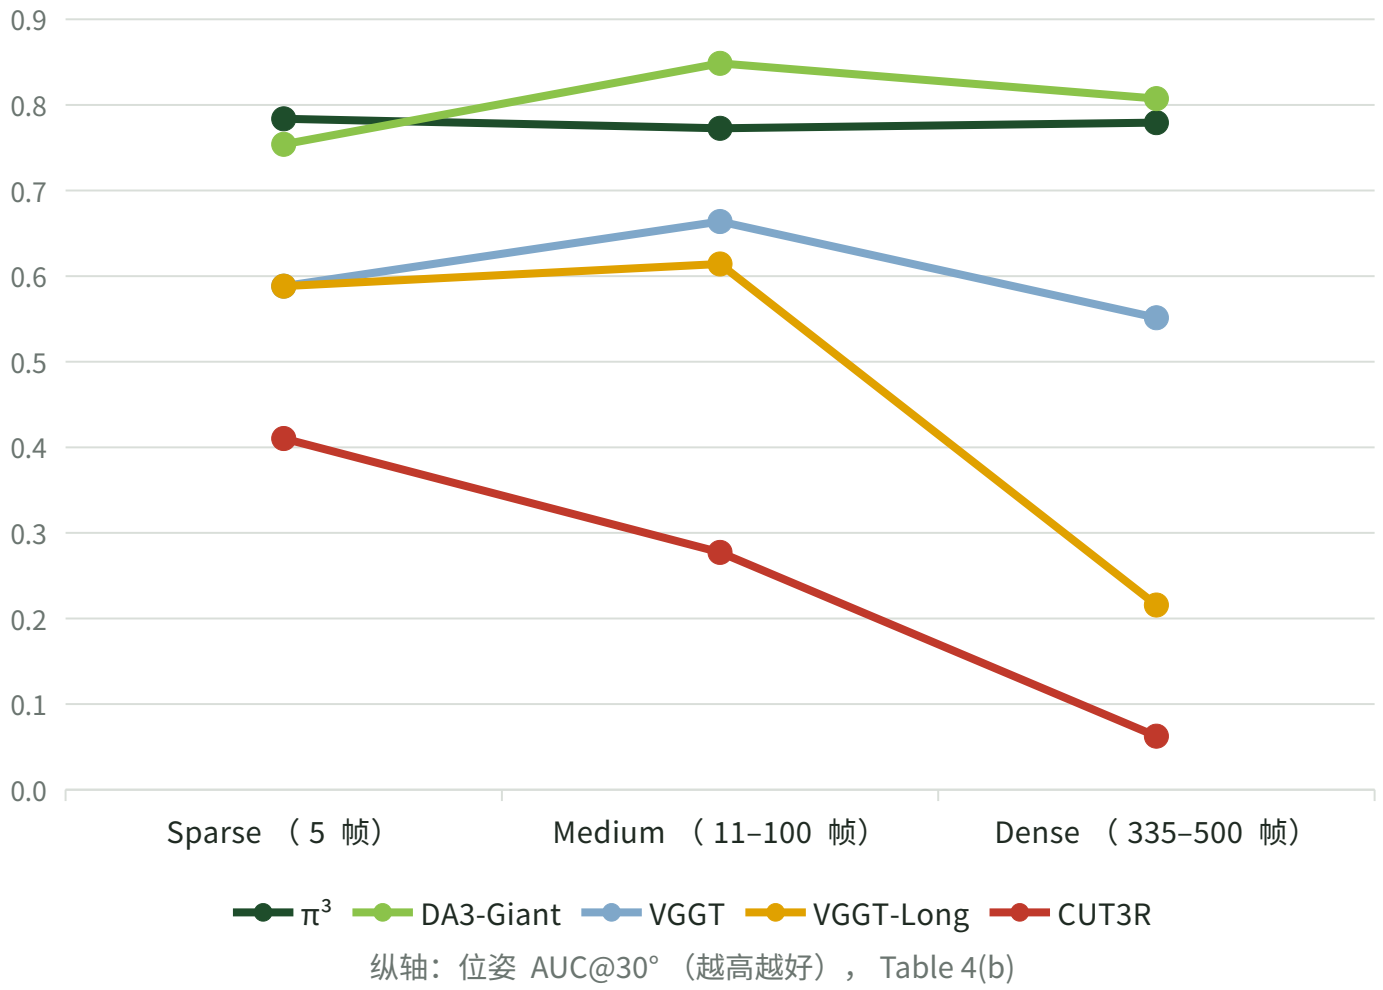

纵轴：位姿 AUC@30°（越高越好）， Table 4(b)

π^3
三种密度下 ATE 最低、 F@5cm 最高（Sparse：ATE 0.43 m， F 0.25）

DA3-Giant
Medium / Dense 位姿 AUC 最高： 0.849 / 0.807，CD 也最优

CUT3R
位姿 AUC 0.41 → 0.06： 视图越多越差

DUSt3R / MASt3R
Dense 输入显存溢出（OOM）

深度经逐场景中位数缩放，评估的是尺度归一化后的质量；参考几何为扫描伪真值。

3D 检测：真实杂乱场景中，紧致 3D 框远未解决

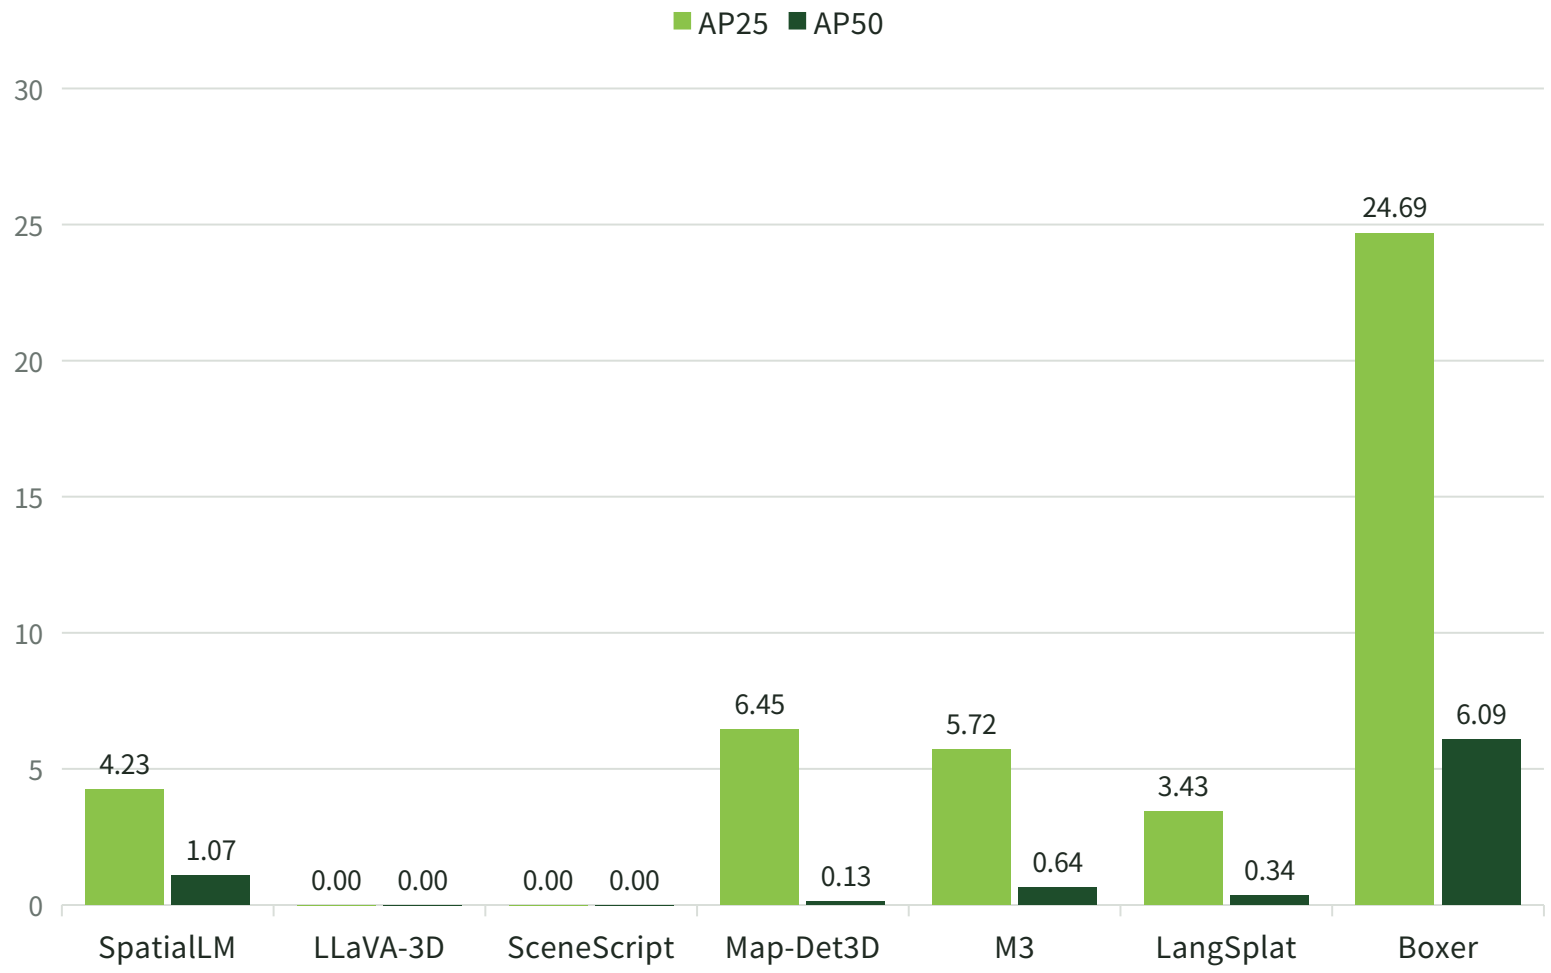

24.69

Boxer AP25 （%） · 三项第一

< 7

所有方法的 AP50 （%）

端到端模型： SpatialLM / LLaVA-3D / SceneScript / Map-Det3D

3DGS 语言场： M3 / LangSplat

2D→3D 提升： Boxer

空间问答：高度 / 相对位置容易，距离 / 平移普遍失分

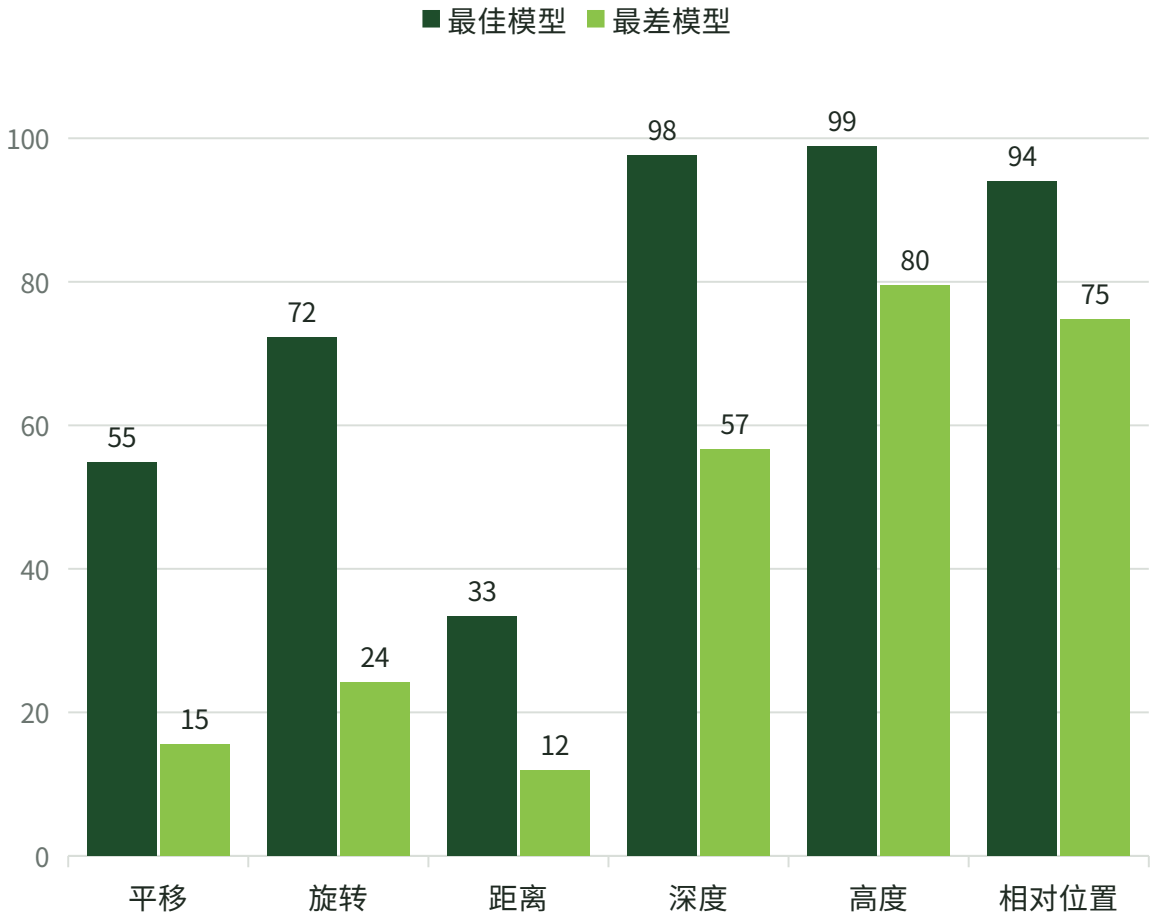

各题型准确率（%）的最高值与最低值

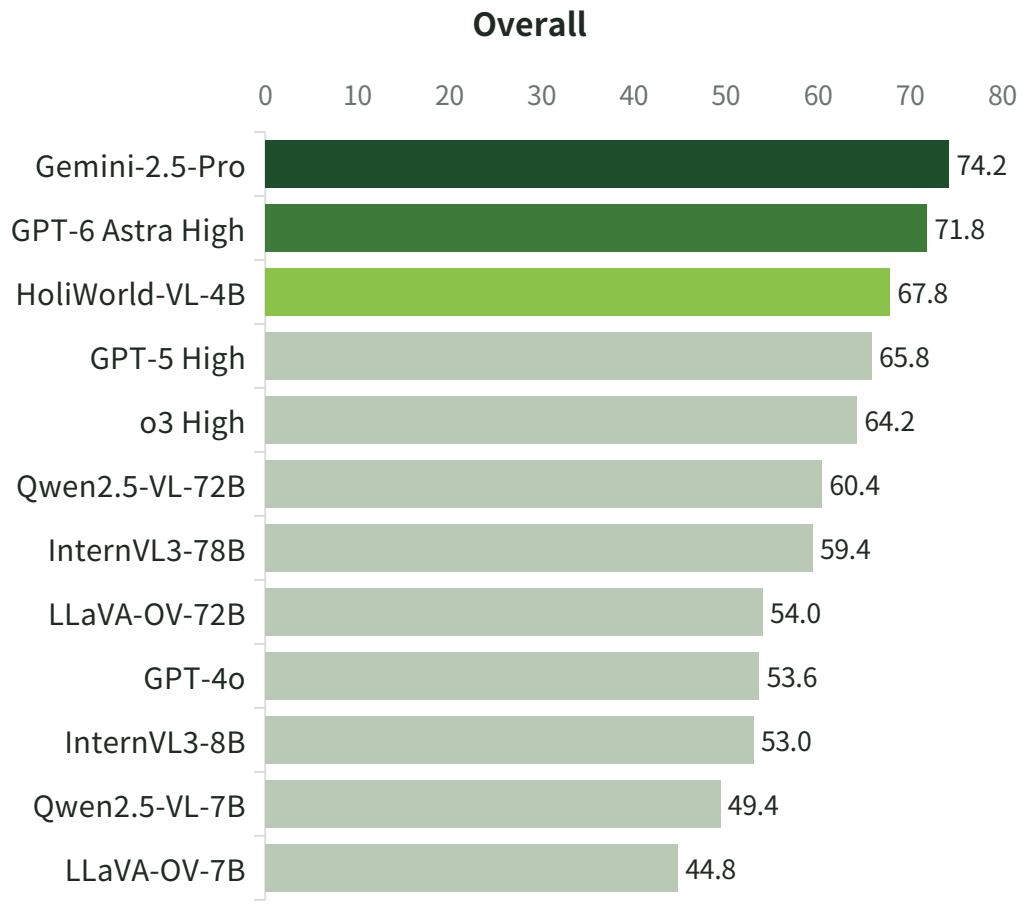

总体准确率（%）； HoliWorld-VL-4B 高于开源组全部模型（≤ 60.4）

一次采集 → 四条机器人数据路线，规模随操作员而非机器人扩展

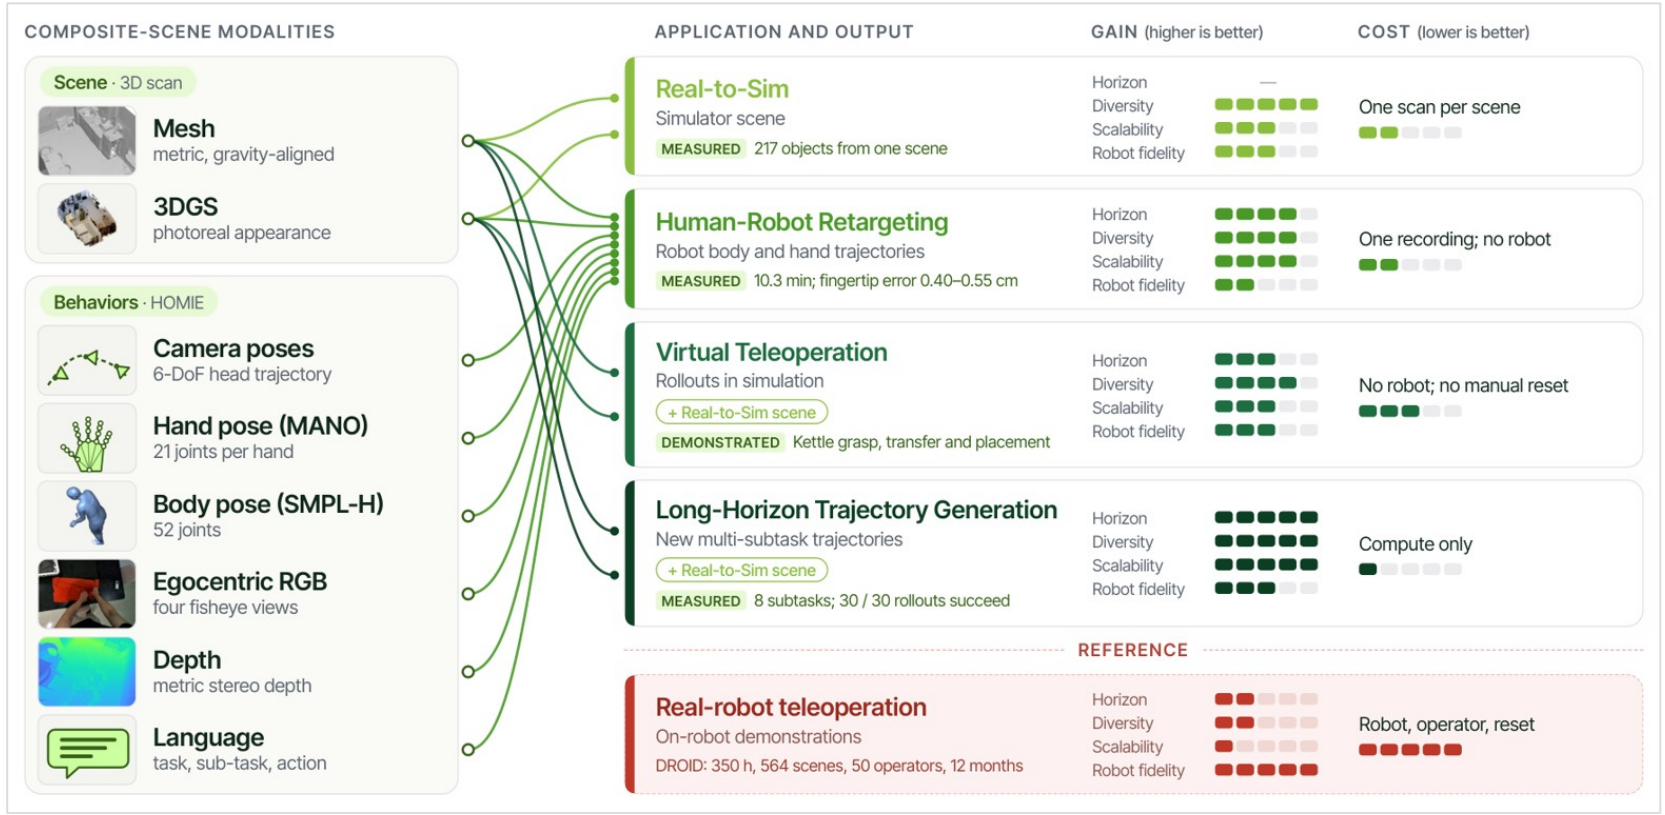

扩环境

Real-to-Sim： 扫描 → 可交互数字孪生

扩行为

人–机重定向
虚拟遥操作（无真机、自动复位）
长时程生成（只需算力）

参照：真机遥操作

DROID 350 h • 564 场景 • 50 人 • 12 个月

注意：图中条形为定性五级评分，非测量值

Real-to-Sim 保留度量几何；重定向指尖误差约半厘米

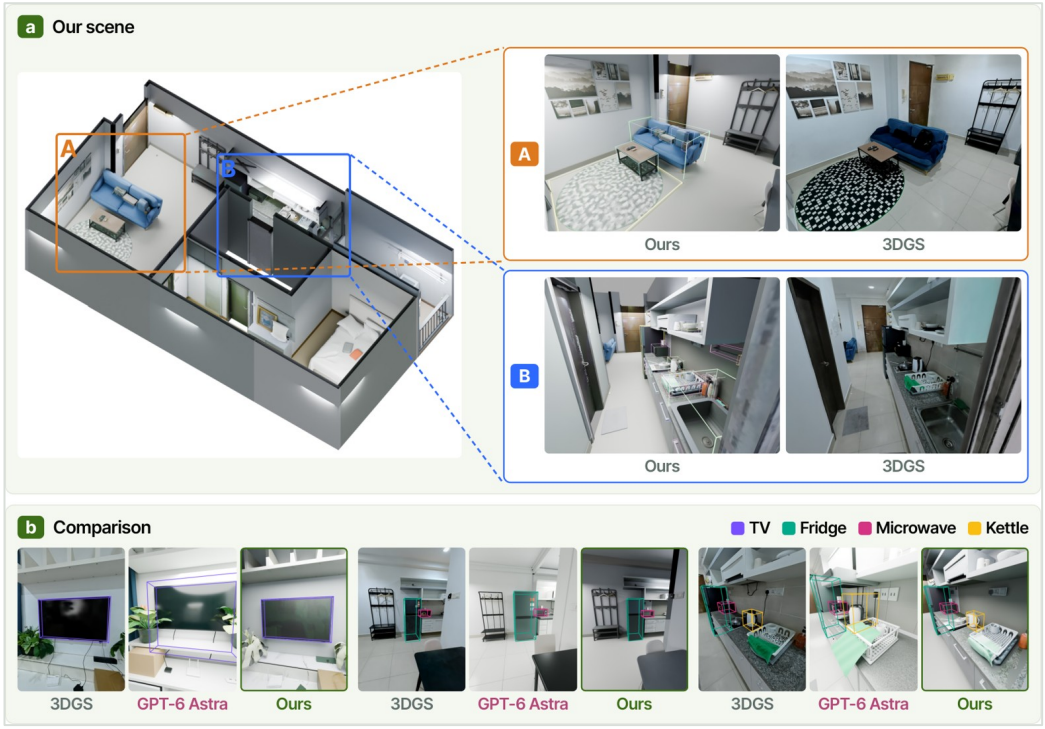

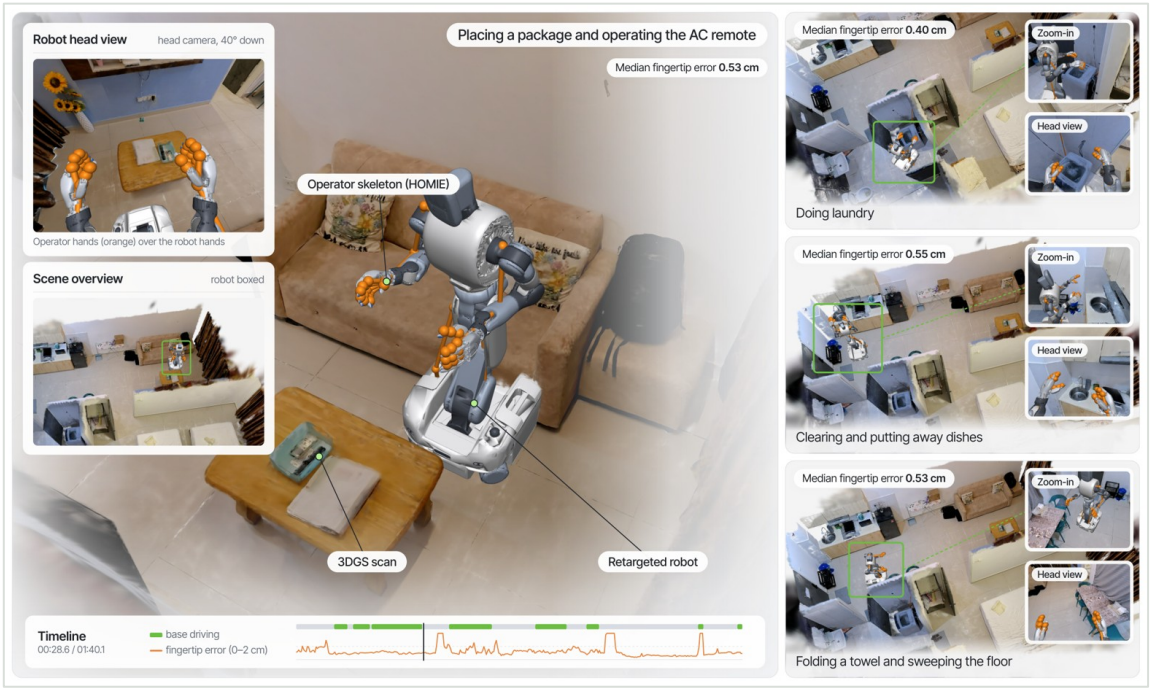

Real-to-Sim 217 个独立物体 / 场景

与 3DGS 同相机逐视角对比，布局、尺寸、外观一致；仅图像建场景（GPT-6 Astra）出现颜色 / 尺寸 / 位置漂移

框衡量的是与 3DGS 的一致性，非独立真值精度

人–机重定向 0.40–0.55 cm 指尖中位误差

同一场景 4 条录制 • 10.3 min • 底盘行驶 96 m • p95 < 2 cm

所有帧通过：关节速度 / 力矩 ≤ 90% 限值、ZMP 在支撑多边形内、无碰撞

虚拟遥操作 + 长时程生成： 30/30 完成 8 个子任务

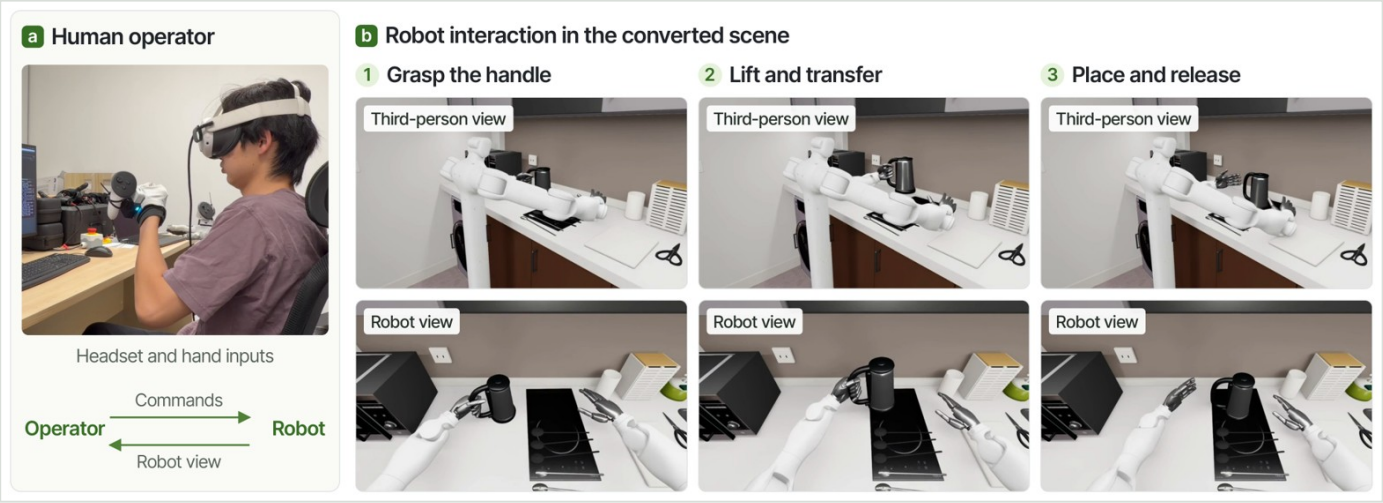

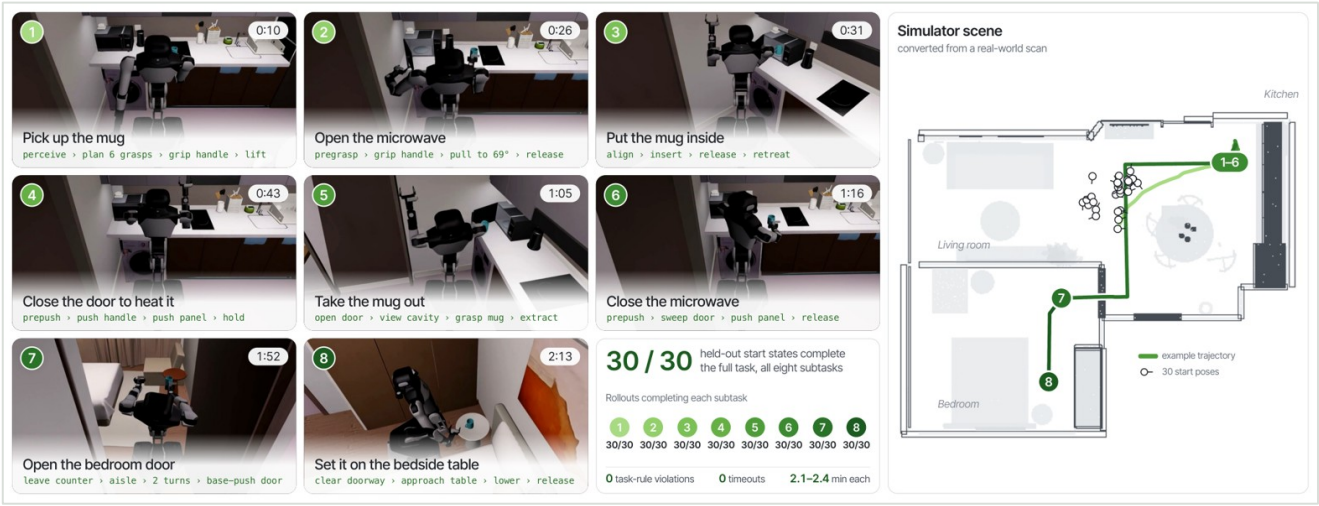

③ 虚拟遥操作

头显 + 手部输入设备，在转换后的厨房中操控仿真人形：

抓壶把 → 提起转移 → 放到灶台松开

无需真机；仿真中自动复位场景（单次演示）

④ 长时程生成

30/30 个 held-out 起点完成全部 8 个子任务

连续执行无重置； 0 违规、 0 超时；每条 ≈ 2.2 min ，单 worker 耗时 10–16 min

由人工编写的策略程序完成，仅通过感知观察物体；仅 1 个任务

工程扎实、披露诚实，但“金标准”与“ scaling law” 尚缺实验支撑

✓ 亮点

流程务实可复制

“扫一次、录多次”，单人、无机器人、无动捕即可完成现场采集

披露透明

配准阈值、 held-out 设计、失败模式公开；区分发布 / 清单、观测 / 估计 / 生成

基准有信息量

多视图几何“视图更多未必更好”、 3D 检测 AP50 < 7 、 VLM 距离题 ⩽ 34%

！ 保留

无 scaling 实验 未用数据训练策略，也未展示性能随环境 / 行为规模的变化

机器人演示均为单例 1 个场景转换、 1 次遥操作、 1 个长时程任务（脚本策略程序）

行为可用量不明 4,230 条为清单口径， PASS 比例未报告； 131 h ≪ 前作 10,000 h

QC 与基准口径 保留率含政策覆写；基准仅 20 场景、扫描伪真值

分布偏差 87.4% 为家庭室内，工作 / 零售录制稀少

总结 · Takeaways

环境与行为“联合采集 + 空间配准 + 复用”的可复制范式

01

数据范式

单人、两台设备、无机器人： 1,589 个度量扫描 + 第一人称行为，统一到场景坐标系

02

基准发现

几何模型视图越多未必越好； 3D 检测 AP50 < 7 ；VLM 距离 / 平移推理普遍薄弱

03

复用路线

Real-to-Sim 、重定向、虚拟遥操作、长时程生成均已打通，但目前都是单例演示

04

待验证

“金标准”与物理 AI scaling law 需后续的策略训练与规模化实验来证明

arXiv 2611.17060 · ropedia.com/xperience/2-research · github.com/Ropedia/Ropedia-Xperience-2